

Maestría en Economía
Facultad de Ciencias Económicas -- Universidad Nacional de La Plata

Seminario de Stata

clase 1

Santiago Garganta
(CEDLAS-UNLP)

Universidad Nacional de La Plata
2017

Contenido

- Curso introductorio de Stata (4 clases)
- En este curso se cubren temas referidos a la utilización de Stata como software estadístico/econométrico
- Evaluación: TPs y Examen domiciliario.
- Fechas de entrega: Examen (28/4 o 5/5)
- Dropbox?

Clase 1

- Introducción a Stata y su sintaxis
- Comandos básicos.
- Gestión de base de datos
- Organización de un proyecto en archivos .do y .log
- Algunos ejercicios introductorios

Descripción Stata

- El Stata es un paquete estadístico-econométrico que puede utilizarse para
 - manipulación de datos
 - análisis de datos (tabulados, gráficos, etc.)
 - econometría
 - además, es programable


Utilización de Stata

- Interfaz Stata: comprende el entorno del trabajo que se realiza con el software.
- En primera instancia se trabajará con la interfaz de ventanas.
- Luego, interacción archivos .do y .log (ventanas siguen siendo útiles).
- Esto permite una utilización más eficiente del software.

Utilización Stata

- Es recomendable la lectura del manual impreso del Stata “User’s Guide”
 - Desde el “help” de stata se puede acceder al .pdf del “User’s Guide”
- Se sugiere configurar Windows para utilizar la coma (,) como separador de miles y el punto (.) como separador decimal
 - es particularmente útil cuando se importan datos a Stata; por ejemplo, desde Excel, Access, SPSS, etc.

La Interfaz de Stata



La interfaz de Stata

- Las diferentes ventanas que componen la interfaz son:
 - “**Variables**”: muestra las variables que están en la base de datos
 - “**Command**”: en esta ventana el usuario introduce los comandos
 - “**Results**”: muestra los resultados que se obtienen al aplicar los comandos
 - “**Review**”: muestra el historial de comandos utilizados

La Interfaz de Stata – cont.

- El Stata puede utilizarse mediante menús y cuadros de diálogo. Sin embargo, preferimos trabajar con la línea de comandos
 - escribiendo cada comando que queremos ejecutar
- Los comandos pueden introducirse
 - (a) de forma inmediata a través de la ventana Command, o
 - (b) a través de archivos de texto que Stata ejecuta de manera secuencial (archivos do)
- Los resultados que Stata muestra en la ventana Results pueden almacenarse en un archivo de texto (archivos log).

La Sintaxis del Lenguaje

La sintaxis básica del lenguaje que utiliza Stata es

```
[by varlist:] command [varlist] [=exp] [if exp]  
                                [in range] [weight]  
                                [using filename] [, options]
```

donde los corchetes indican que se trata de una parte opcional; cabe resaltar que el “help” incluido en Stata explica qué parte de esta sintaxis acepta cada comando.

Bases de Datos

- En el seminario se utilizarán diferentes bases de datos
 - Encuestas de hogares
 - Cuentas Nacionales
 - Datos experimentales
 - otros
- Diferentes ejemplos de comandos simples para ver cómo se utilizan las diferentes partes de la sintaxis. Luego, aplicación de ejercicios más extensos.

Bases de Datos

- A modo de ejemplo, en este ejercicio introductorio utilizaremos la Encuesta de hogares de Ecuador 2011 (ENEMDU)
- ¿qué es una encuesta de hogares?
- Es un relevamiento sobre los hogares que nos permiten conocer características socioeconómicas, laborales y de ingreso (consumo) de los mismos.

Primeros Comandos

- Los comandos que veremos a continuación se introducen de a uno por vez en la línea de comando del Stata.
- Luego, veremos cómo utilizar archivos para almacenar nuestro trabajo (.do)
- Utilizaremos pocas variables (base resumida procesada en CEDLAS)
 - ipcf = ingreso per cápita familiar
 - pondera = factor de expansión
 - hombre =1 si hombre
 - urbano =1 si urbano
 - region = varía según país

Primeros Comandos

- `* intro_stata.do`
- `clear all`
- `set mem 100m`
- `cd "C:\cedlas\2017\Seminario_Stata\clase1"`
- `cd`
- En primer lugar, nos ubicamos en la carpeta donde vamos a trabajar con el comando “cd ...”
- Este comando se puede aplicar también para saber dónde estamos ubicados o trabajando

set memory

- En Stata la base de datos se almacena en la memoria RAM (ventaja: ejecución de comandos rápida pero el tamaño de las base de datos se encuentra limitado por la memoria RAM de la pc)
- Para ampliar el espacio de memoria RAM que usa Stata:

set memory 200m (asigna 200 MB)

- Versión 13 de Stata no es necesario asignar memoria

Primeros Comandos

- `* apertura base de datos`
- `use "ecu11_cedlas_resumida.dta", clear`
- Se puede importar una base de datos en otro formato que no sea .dta (para ello, se utilizan otros comandos)
- Comando *describe*, detalle general de la base de datos
- `describe`
- Encuesta de Hogar: notar que hay variables que son individuales y otras a nivel de hogar.

Primeros Comandos

- **Comando “summarize”**
- Descripción estadística de una, varias o todas las variables de la base de datos. No considera los missing data (.)
- `summarize ipcf`
- `summarize ila ipcf`
- `summarize`
- `summarize p*`
- **Explicación, sintaxis del comando**
- `help summarize`

Abreviaturas

- Es posible utilizar abreviaturas para los comandos y variables
- Recomendación no abusar de las mismas
- summarize **su**
- comandos para realizar tablas

Primeros Comandos

- **[if exp]**: la aplicación de algunos comandos puede restringirse a alguna condición o grupos de condiciones.
 - `summarize ipcf if urbano == 1`
 - `summarize ipcf if urbano == 0`
- urbano es una variable dummy. Qué interpretación tiene la media de la misma?
 - `summarize urbano`

Primeros Comandos

- Sintaxis
 - Sentencias condicionales
 - == igual
 - != distinto
 - >, <, >=, <=
 - Operadores lógicos
 - & (ampersand) and
 - | or

Replace

- `replace itf = itf / 1000`
- `replace ipcf = 0 if urbano == 0`
- `replace ipcf = 0 if urbano == 0 & hombre == 1`
- `replace ipcf = 0 if urbano == 0 | hombre == 1`

Primeros Comandos

- **[in range]**: la aplicación de algunos comandos puede restringirse a un rango de observaciones

summarize hombre in 1/10

summarize hombre in -10/-1

- Dependiente del orden de la base de datos.

Primeros Comandos

- Ordenar la base de datos

sort id

gsort -id (de manera descendente)

gsort +id (igual a sort)

- Ordenar por varias variables

sort id edad

gsort id -edad

preserve y restore

- * preserve y restore
- summarize hombre
- preserve
- replace hombre=0 if hombre==1
- summarize hombre
- restore
- summarize hombre

Primeros Comandos

- `generate edad2 = edad*edad`
- `gen grupo = 1 if edad<=10 & hombre==1`
- `replace grupo = 0 if grupo==.`
- Cómo generar una variable que sea igual al `ipcf` normalizada por la media de `ipcf`

Primeros Comandos

- `summarize ipcf`
- `return list`
- `gen ipcf_media = ipcf/r(mean)`

- `rename ipcf_media ipcf_mu`

Otros Comandos (Tablas)

- **tabulate**, tabular diferentes valores de una variable (cantidad de observaciones)

tabulate region

- Se puede tabular más de una variable

tabulate region hombre

Otros Comandos (Tablas)

- **table**, tabla más flexible
- Se pueden combinar valores de una variable con estadísticos de otras referidos a los valores de la primera.
- `table region`
- `table region, c(mean ipcf)`
- `table region, c(freq mean ipcf sd ipcf)`
- `table region, c(freq mean ipcf mean ila)`

Ver los diferentes estadísticos (help)

Primeros Comandos

- **[by varlist:]** Permite particionar la base de datos en tantos grupos como valores de la variable existan.
- `by region: summarize ipcf`
- Es requisito ordenar la base de datos por la variable que se utiliza en el **by**, o
- `sort region`
- `by region: summarize ipcf`
- `bysort region: summarize ipcf`

Primeros Comandos

- En ciertos casos necesitamos más de una variable para particionar la base (utilizar la variable `ila`)

`sort region hombre`

`by region hombre: summarize ila`

- Resumir en una sola variable las seis categorías que surgen de las variables `region` y `hombre`. Aplicar el comando **`by`** con esa nueva variable

Primeros Comandos

- Resumir en una sola variable las seis categorías que surgen de las variables `region` y `hombre`.
Aplicar el comando **by** con esa nueva variable

```
egen reg_h = group(region hombre)
```

```
sort reg_h
```

```
by reg_h: summarize ila
```

- Comando **egen** muy útil, varias opciones

Otros Comandos

- Borrar observaciones y variables
- `drop if edad < 5`
- `drop ii`
- No es posible borrar estas dos dimensiones al mismo tiempo

Otros Comandos

- **[, opciones]** existen comandos que aceptan opciones adicionales (help es muy importante para esto)

summarize ipcf

summarize ipcf, detail

egen (más opciones)

- `gen suma1 = sum(pondera)`
- `egen suma2 = sum(pondera)`
- `egen suma3 = total(pondera)`

egen (más opciones)

- `gen aux = ila + inla`

egen (más opciones)

- `sort ila`
- `gen aux = ila + inla`
- `egen aux1 = rsum(ila inla)`

egen (más opciones)

- `sort ila`
- `gen aux = ila + inla`
- `egen aux1 = rsum(ila inla)`
- `egen aux2 = rsum(ila inla), missing`
- `summ aux*`
- `drop aux*`

La Utilización de Ponderadores

- El Stata permite distintos tipos de ponderación (help weight):
 - **fweights = frequency** (indican el número de observaciones duplicadas)
 - **pweights = sampling** (representan la inversa de la probabilidad de que la observación sea incluida de acuerdo al diseño de la muestra)
 - **awweights = analytic** (las observaciones representan promedios y los ponderadores son inversamente proporcionales a la varianza del mismo)
 - **iweights = importance** (indican la importancia de cada observación de acuerdo a algún criterio)
- En general, los comandos de Stata tienen asignado un tipo de ponderación por defecto; es el que utilizaremos.

La Utilización de Ponderadores

- **Sin ponderar**

summarize ipcf

- **Ponderado**

summarize ipcf [w=pondera]