

Lectura 1: **El Modelo de Regresión Lineal.**

El plan de esta lectura es ofrecer una revisión del análisis de regresión para la función media condicional $E(y | x_j, x_{-j})$. Se introducirá el modelo de regresión básico y, luego, nos concentraremos en el caso simple de una regresión bivariada. Al final de la lectura, se discuten las propiedades estadísticas del estimador de Mínimos Cuadrados Ordinarios (MCO).

1) Análisis de Regresión Multivariable.

Se comienza asumiendo un modelo lineal con p variables independientes:

$$\underset{1 \times 1}{y} = \underset{1 \times p}{x'} \underset{p \times 1}{\beta} + \underset{1 \times 1}{u}, \quad (1)$$

donde y es la respuesta o variable dependiente y β son los coeficientes asociados con las variables independientes x' . En el núcleo de la econometría, está el concepto de efectos causales o relaciones causales. Obviamente, no se refiere a la noción de correlación entre x_j e y desde $\text{Corr}(x_j, y) = \text{Corr}(y, x_j)$.

Se define x_j como una variable independiente, y pasa a ser una variable dependiente y se podrían tener otras variables (independientes) que se mantienen en un nivel constante, x_{-j} . Para investigar las relaciones causales, se emplean modelos y el modelo clásico de interés es el valor esperado condicional de la variable dependiente condicional en las variables independientes:

$$E(y | x_j, x_{-j}) = E(y | x) = \int y f_{Y|X=x} dx.$$

También se puede definir:

$$\frac{\partial E(y | x_j, x_{-j})}{\partial x_j} = \text{efecto parcial.}$$

obtenido manteniendo x_{-j} igual a una constante. Tener en cuenta que esto está bien definido si x_j es una variable continua.

Para estimar los efectos causales, una suposición crucial es que todos los factores observables (las variables independientes $x_1, x_2, \dots, x_p$) que afectan a la variable dependiente y no están correlacionados con el término de error.

$$E(u | x_1, x_2, \dots, x_p) = 0. \quad (2)$$

Si se cumple la condición (2), se dice que las variables $\{x_1, x_2, \dots, x_p\}$ son estrictamente exógenas. Como se explica a continuación, la implicación es que el término de error tiene una media igual a cero.

$$E(u | x) = E(u) = 0.$$

Para resumir, los primeros dos supuestos del modelo de regresión clásico son:

- A1 (Linealidad): El modelo es lineal como en (1).
- A2 (Exogeneidad estricta): Se supone que $E(u | x_1, x_2, \dots, x_p) = 0$.

Más adelante, se utilizará un modelo con p variables independientes como en la ecuación (1). Concentrémonos, ahora, en un caso particular, suponiendo que se tiene una variable independiente, $p = 2$.

2) Expectativas Condicionales.

El modelo de regresión simple es:

$$y = \beta_0 + \beta_1 x + u, \quad (3)$$

donde y es la variable dependiente, x es la variable independiente y u es el término de error o perturbación. El modelo sugiere que los cambios en y son inducidos por cambios en x y u . Se quiere saber cuánto y se puede explicar en términos de x .

Ejemplo 1. Se supone que se quiere saber el efecto de la educación en los salarios y los salarios y la educación están relacionados linealmente. Entonces, se puede escribir:

$$\text{wages} = \beta_0 + \beta_1 \text{educ} + u. \quad (4)$$

En este ejemplo, se supone que la relación entre la variable de respuesta y la variable independiente es lineal en los parámetros β_0 y β_1 . Puede ser que el modelo sea:

$$\ln(\text{wages}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{educ}^2 + u,$$

que no es lineal en las variables.

Se puede definir la función de regresión de la población (FRP) o, en este caso, la línea de regresión de la población (LRP) de la ecuación (3) como:

$$\begin{aligned} E(y | x) &= E(\beta_0 + \beta_1 x + u | x) \\ E(y | x) &= E(\beta_0 | x) + E(\beta_1 x | x) + E(u | x) \\ E(y | x) &= \beta_0 + \beta_1 x + 0 \\ E(y | x) &= \beta_0 + \beta_1 x. \end{aligned} \quad (5)$$

por las suposiciones A1 y A2. Dice que el valor esperado de la variable dependiente para un valor dado de las variables independientes es igual al parámetro β_0 más β_1 multiplicado por la variable independiente. En el caso de la LRP con un parámetro de pendiente, el modelo contiene dos parámetros desconocidos β_0 (la intersección) y β_1 (la pendiente).

Nuestro interés radica en estimar la FRP, lo que implica estimar las dos incógnitas, es decir, el intercepto y la pendiente.

Ahora, se discuten las implicaciones de las condiciones previas A1 y A2. Se puede escribir el modelo como:

$$y = E(y | x) + u. \quad (6)$$

$$E(u | x) = 0. \quad (7)$$

La ecuación (7) implica:

$$E(u) = 0. \quad (8)$$

$$\text{Cov}(u, x_j) = 0, \quad \text{para } j = 1, \dots, p. \quad (9)$$

$$\text{Cov}(u, h(x_j)) = 0, \quad \text{para } j = 1, \dots, p. \quad (10)$$

donde Cov denota covarianza y $h(\cdot)$ es una función conocida [por ejemplo, $h(x_1) = x_1^2$, $h(x_1, x_2) = x_1 x_2^2$, $h(x_2) = e^{x_2 x_2^2}$, etc.]. Para ver estos resultados, primero, tener en cuenta que, por definición, $u = y - E(y | x)$. Entonces:

$$E(u) = E[y - E(y | x)]$$

$$E(u) = E(y) - E[E(y | x)]$$

$$E(u) = E(y) - E(y)$$

$$E(u) = 0. \quad (11)$$

Para mostrar que también implica independencia entre el término de error y las covariables, se tiene que demostrar que:

$$E(ux) = E[E(ux | x)]$$

$$E(ux) = E[x E(u | x)]$$

$$E(ux) = E(x * 0)$$

$$E(ux) = E(0)$$

$$E(ux) = 0. \quad (12)$$

Por lo tanto, las condiciones (11) y (12) implican, para $j = 1, \dots, p$:

$$\text{Cov}(u, x_j) = E(ux_j) - E(x_j) E(u)$$

$$\text{Cov}(u, x_j) = 0 - E(x_j) * 0$$

$$\text{Cov}(u, x_j) = 0 - 0$$

$$\text{Cov}(u, x_j) = 0. \quad (13)$$

3) Mejor Predictor Lineal.

Se define una función de pérdida de una forma genérica, $L(u) = L[y - m(x)]$, donde $m(x)$ es el predictor en términos de x y u es el error de predicción. Naturalmente, un tomador de decisiones intenta resolver el siguiente problema:

$$\min_{m \in M} E \{L[y - m(x)] | x\},$$

es decir, le gustaría elegir un predictor de y que minimice la pérdida esperada.

Es conveniente asumir una pérdida cuadrática [por ejemplo, $L(u) = u^2$]. Por lo tanto, el problema puede ser transformado para minimizar el error cuadrático medio de $m(x)$ para y :

$$\begin{aligned} E\{[y - m(x)]^2 | x\} &= E\{[y - \mu(x) + \mu(x) - m(x)]^2 | x\} \\ E\{[y - m(x)]^2 | x\} &= E\{[y - \mu(x)]^2 + [\mu(x) - m(x)]^2 + 2[(y - \mu(x))(\mu(x) - m(x))] | x\} \\ E\{[y - m(x)]^2 | x\} &= E\{[y - \mu(x)]^2 | x\} + E\{[\mu(x) - m(x)]^2 | x\} + 2E\{[(y - \mu(x))(\mu(x) - m(x))] | x\} \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + E\{[\mu(x) - m(x)]^2\} + 2[\mu(x) - m(x)] E\{[y - \mu(x)]\} \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 2[\mu(x) - m(x)] \{E(y) - E[\mu(x)]\} \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 2[\mu(x) - m(x)] [\mu(x) - \mu(x)] \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 2[\mu(x) - m(x)] * 0 \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 0 \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2, \end{aligned}$$

donde $V(y | x)$ es la varianza condicional de y .

Si los primeros dos momentos condicionales de y existen [por ejemplo, $E(y | x) < \infty$ y $V(y | x) < \infty$], el error cuadrático medio (incondicional) se minimiza a la varianza condicional de y cuando $m(x)$ es igual a la media condicional $\mu = E(y | x)$:

$$E\{[y - m(x)]^2\} = V(y | x).$$

Se supone, ahora, que se conoce la forma funcional de m . Por ejemplo, considerar, ahora, que es un modelo lineal en parámetros:

$$\begin{aligned} \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y - x'\beta)'(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y' - \beta'x)(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[y^2 - y'x'\beta - \beta'xy + (x'\beta)^2] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y - 2\beta'xy + \beta'xx'\beta) \quad (*) \text{ y } (**) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - E(2\beta'xy) + E(\beta'xx'\beta) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - 2\beta' E(xy) + \beta' E(xx') \beta. \end{aligned}$$

$$\begin{aligned} (*) \quad (x'\beta)^2 &= (x'\beta)'(x'\beta) \\ (x'\beta)^2 &= \beta'xx'\beta. \end{aligned}$$

(**) $\beta'xy$ es un escalar, por lo que es, trivialmente, igual a su transpuesto, $y'x'\beta$.

Tomando la condición de primer orden, se tiene:

$$\begin{aligned} -2 E(xy) + 2 E(xx') \beta &= 0 \quad (***) \text{ y } (****) \\ 2 E(xx') \beta &= 2 E(xy) \\ \beta &= \frac{2E(xy)}{2E(xx')} \\ \beta &= [E(xx')]^{-1} E(xy). \end{aligned}$$

(***) $\frac{\partial(b'a)}{\partial b} = a$, donde a y b son dos vectores de dimensiones $(p \times 1)$.

(****) $\frac{\partial(b'Ab)}{\partial b} = 2Ab$, donde b es un vector de dimensión $(p \times 1)$ y A es una matriz simétrica de dimensión $(p \times p)$.

Por lo tanto, el parámetro β se puede interpretar como el mejor predictor lineal bajo la pérdida de error al cuadrado.

Tener en cuenta que, para que exista, se necesita la dimensión $(p \times p)$ de la matriz $E(xx')$ para ser invertible. También se necesita que $E(y^2) < \infty$ y $E(\sum_j x_j^2) < \infty$ [ver Hansen (2017), Teorema 2.18.1]. Si no se incluyen variables redundantes en el vector x , entonces, la matriz de diseño $E(xx')$ es invertible y se puede decir que β es único e identificado. Un requisito es que $E(xx')$ sea definida positiva. La identificación, en esta clase de modelos lineales, significa que se puede escribir el parámetro de interés en términos de condiciones de momento que son funciones de variables observadas tales como y y $x_1, x_2, \dots, x_p$.

Esto está relacionado con otra suposición del modelo lineal. La condición:

- A3 (Matriz de diseño de rango completo): El rango de $E(xx') = p$.

Esta condición descarta la colinealidad perfecta o, en otras palabras, descarta relaciones lineales exactas entre las variables independientes.

4) Efectos Parciales y Elasticidades.

Considerar que se tiene el siguiente modelo de regresión de la población:

$$E(y | x) = \beta_0 + \sum_{j=1}^p \beta_j x_j,$$

y se está interesado en el efecto marginal de la j -ésima variable independiente sobre el valor esperado condicional de y :

$$\frac{\partial E(y | x)}{\partial x_j} = \beta_j.$$

Esto dice el aumento en el valor medio de y cuando la variable independiente se incrementa en 1 unidad, manteniendo todo lo demás constante. Esta interpretación es equivalente a la noción de *ceteris paribus*: el efecto de x sobre y , manteniendo todo lo demás constante. Notar que, si x_i y x_j están relacionados, encontrar el efecto marginal es algo más complicado, pero la linealidad del modelo de regresión tiene una implicación simple y, a veces, útil para el análisis empírico.

Considerar el siguiente modelo con $p=4$ y $x_3 = x_1 x_2$:

$$E(y | x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2,$$

donde $x' = (1, x_1, x_2, x_3)$. El efecto parcial de x_1 en el valor esperado condicional de la variable dependiente es:

$$\frac{\partial E(y | x)}{\partial x_1} = \beta_1 + \beta_3 x_2$$

y

$$\frac{\partial E(y | x)}{\partial x_2} = \beta_2 + \beta_3 x_1.$$

A veces, se está interesado en la elasticidad de y con respecto a x_j :

$$\frac{\partial \log(y)}{\partial \log(x_j)} = \frac{\partial y}{\partial x_j} \frac{x_j}{y}.$$

Nuestra elasticidad parcial es:

$$\frac{\partial E(y | x)}{\partial x_j} \frac{x_j}{E(y | x)} = \frac{\partial \log[E(y | x)]}{\partial \log(x_j)}.$$

Por ejemplo, la elasticidad parcial con respecto a x_1 en nuestro ejemplo anterior es:

$$\frac{\partial E(y | x)}{\partial x_1} \frac{x_1}{E(y | x)} = \frac{(\beta_2 + \beta_3 x_2)x_1}{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2}.$$

Cuando y y x no están correlacionados, como es el caso en los modelos anteriores, se puede tener una definición alternativa de elasticidad que es más conveniente:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)}.$$

Tener en cuenta que $E(y | x) = e^{x'\beta}$ implica:

$$\log[E(y | x)] = x'\beta.$$

Si $y = e^{x'\beta + u}$, entonces, $\log(y) = x'\beta + u$ y, por suposiciones previas, $E[\log(y)] = x'\beta$, ya que $E(u | x) = 0$.

Por lo tanto, el parámetro β_j se debe interpretar como una elasticidad si el modelo está en una forma “log-log”:

$$\log(y) = \beta_0 + \beta_1 \log(x_1) + \beta_2 \log(x_2) + u,$$

o como una semielasticidad si el modelo es un modelo “log-lineal”:

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u.$$

Lo que implica que el efecto parcial es:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)} = \beta_j.$$

Por último, se puede introducir el concepto de efectos parciales promedio (para más detalles, ver Blundell y Powell 2003). Se supone que se tiene el siguiente modelo:

$$E(y | x, z) = g(x, z),$$

donde x es una variable observada y z es una variable latente. El efecto parcial es:

$$\frac{\partial E(y | x, z)}{\partial x_j} = \frac{\partial g(x, z)}{\partial x_j}.$$

Tener en cuenta que el efecto parcial depende de una variable latente que puede tomar diferentes valores de una distribución subyacente. El efecto parcial promedio en $x = x_0$ es:

$$\delta_j(x_0) = E\left[\frac{\partial g(x_0, z)}{\partial x_j}\right] = \int \frac{\partial g(x_0, z)}{\partial x_j} f(z) dz.$$

¿Se puede estimar el efecto parcial promedio si no se observa z ? Se tienen, esencialmente, dos casos importantes. Si x y z son independientes, el efecto parcial promedio es, simplemente, el efecto parcial con respecto a x_j :

$$\frac{\partial E(y | x)}{\partial x_j}.$$

Alternativamente, si se quiere modelar la heterogeneidad no observada, se puede encontrar $E(y | x)$ integrándola sobre la distribución de la variable latente z .

Ejemplo 2. Suponer:

$$y = \beta_0 + \beta_1 x_1 + \gamma_1 x_1 z_1 + u,$$

donde $E(u | x_1, z_1) = 0$. El modelo de media condicional es:

$$E(y | x, z) = \beta_0 + \beta_1 x_1 + \gamma_1 x_1 z_1$$

y

$$\frac{\partial E(y | x, z)}{\partial x_1} = \beta_1 + \gamma_1 z_1.$$

Si $E(z_1) = E(z_1 | x_1) = 0$, entonces, el efecto parcial promedio es:

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1 + \gamma_1 z_1)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1) + E(\gamma_1 z_1)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \gamma_1 E(z_1)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \gamma_1 * 0$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + 0$$

$$E \left[\frac{\partial E(y | x, z)}{\partial x_1} \right] = \beta_1.$$

Si x y z no son independientes, pero son, condicionalmente, independientes en una variable *proxy* w , es posible mostrar que el efecto parcial promedio es:

$$\delta_j(x_0) = E_z \left[\frac{\partial E(y | x_0, z)}{\partial x_j} \right] = E_z \left[\frac{\partial E(y | x_0, w)}{\partial x_j} \right].$$

5) Estimación.

Considerar una muestra aleatoria $\{y_i, x_i\}$ del tamaño n de la población. El par de puntos de datos (y_i, x_i) representa la i -ésima observación. El tamaño de la muestra n denota el número total de observaciones. Como cada punto de datos proviene del modelo (1):

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad (14)$$

donde $i = 1, \dots, n$. El objetivo es estimar los parámetros β_0 y β_1 .

5.1) Método de Momentos.

Primero, se revisa un método de estimación llamado Método de Momentos usando el siguiente ejemplo.

Ejemplo 3. Se supone que se quiere estimar el primer momento de una variable aleatoria. El método de momentos (MM) se puede usar para estimar la media de la población. Considerar que $\{y_i\}$ es una variable aleatoria distribuida de forma independiente e idéntica (i.i.d.) extraída de una distribución cuyo primer momento existe (por ejemplo, y no se distribuye como Cauchy). En la población:

$$E(y - \mu) = 0,$$

para que se pueda usar la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}.$$

Para obtener el estimador MM para el modelo lineal, recordar la condición de momento:

$$E(x_i u_i) = E[E(x_i u_i | x)]$$

$$E(x_i u_i) = E[x_i E(u_i | x)]$$

$$E(x_i u_i) = E(x_i * 0)$$

$$E(x_i u_i) = E(0)$$

$$E(x_i u_i) = 0,$$

o, alternativamente:

$$E[x_i (y_i - x_i' \beta)] = 0,$$

donde $x'_i = [1 \quad x_{i1}]$ y $\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$. El estimador MM podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x'_i \beta)] = 0,$$

resolviendo:

$$\sum_{i=1}^n [x_i (y_i - x'_i \beta)] = 0 * n$$

$$\sum_{i=1}^n (x_i y_i - x_i x'_i \beta) = 0$$

$$\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x'_i \beta = 0$$

$$\sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x'_i = 0$$

$$\beta \sum_{i=1}^n x_i x'_i = \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = (\sum_{i=1}^n x_i x'_i)^{-1} \sum_{i=1}^n x_i y_i.$$

Se pasa, ahora, a algunos modelos básicos de regresión lineal.

5.2) Estimación de Mínimos Cuadrados Ordinarios (MCO).

Las suposiciones del modelo fueron:

- $E(u) = E(y - \beta_0 - \beta_1 x) = 0.$
- $Cov(x, u) = E(xu) - E(x)E(u) = 0 - E(x) \cdot 0 = 0.$

Estas dos ecuaciones son restricciones impuestas a los datos sobre la distribución de probabilidad conjunta de x e y . Hay dos incógnitas y dos ecuaciones, lo que sugiere que se puede resolver para β_0 y β_1 . La contraparte de la muestra de estas ecuaciones es:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (15)$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \beta_0 - \beta_1 x_i)] = 0. \quad (16)$$

El Estimador de Mínimos Cuadrados Ordinarios es el argumento que minimiza la siguiente función de criterio:

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2, \quad (17)$$

con respecto a las incógnitas β_0 y β_1 . Es fácil ver que las ecuaciones normales correspondientes a este problema son idénticas a las dos ecuaciones anteriores (15) y (16). Por lo tanto, el estimador MCO es un estimador MM en este caso.

De la ecuación (15), se obtiene:

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 * n$$

$$\sum_{i=1}^n y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 x_i = 0$$

$$n\bar{y} - n\beta_0 - n\beta_1 \bar{x} = 0$$

$$n(\bar{y} - \beta_0 - \beta_1 \bar{x}) = 0$$

$$\begin{aligned}
\bar{y} - \beta_0 - \beta_1 \bar{x} &= \frac{0}{n} \\
\bar{y} - \beta_0 - \beta_1 \bar{x} &= 0 \\
\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x},
\end{aligned} \tag{18}$$

donde $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$. Por lo tanto, si se conoce el estimador de mínimos cuadrados ordinarios de la pendiente β_1 , se puede obtener una estimación de la intersección. ¿Cómo se puede obtener $\hat{\beta}_1$? Conectar el último resultado en la ecuación (16) para obtener:

$$\begin{aligned}
\sum_{i=1}^n \{x_i [y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i]\} &= 0 * n \\
\sum_{i=1}^n [x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)] &= 0 \\
\sum_{i=1}^n \{x_i [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]\} &= 0 \\
\sum_{i=1}^n [x_i (y_i - \bar{y}) - \hat{\beta}_1 x_i (x_i - \bar{x})] &= 0 \\
\sum_{i=1}^n x_i (y_i - \bar{y}) - \sum_{i=1}^n \hat{\beta}_1 x_i (x_i - \bar{x}) &= 0 \\
\sum_{i=1}^n x_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= 0 \\
\hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= \sum_{i=1}^n x_i (y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})}.
\end{aligned}$$

Se puede demostrar (*) que la última ecuación es igual a:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \tag{19}$$

el cual resulta el estimador para el parámetro β_1 .

Por lo tanto, $\hat{\beta}_0$ y $\hat{\beta}_1$ son los estimadores de mínimos cuadrados ordinarios (MCO) para los parámetros de intersección y de pendiente del modelo de regresión lineal simple.

$$\begin{aligned}
(*) \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n \bar{x} y_i + \sum_{i=1}^n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y}) - \bar{x} \sum_{i=1}^n y_i + n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i (y_i - \bar{y}) - n \bar{x} \bar{y} + n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i (y_i - \bar{y}).
\end{aligned}$$

$$\begin{aligned}
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i^2 - 2x_i \bar{x} + \bar{x}^2) \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2x_i \bar{x} + \sum_{i=1}^n \bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x} \bar{x} + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i x_i - \sum_{i=1}^n x_i \bar{x} \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i x_i - x_i \bar{x}) \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i (x_i - \bar{x}).
\end{aligned}$$

5.3) Propiedades aritméticas de MCO.

Es útil discutir, brevemente, las propiedades de los estimadores MCO. Considerar las siguientes cuatro propiedades:

1. La suma de los residuos $\hat{u}_i$ es cero, ya que $\hat{\beta}_0$ y $\hat{\beta}_1$ se eligen de forma que:

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = \sum_{i=1}^n \hat{u}_i = 0.$$

2. La covarianza muestral entre la variable independiente y los residuos es cero. Para ver esto, es crucial encontrar ver:

$$\begin{aligned} \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n [x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)] \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n [x_i (y_i - x_i \hat{\beta})] \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n (x_i y_i - x_i x_i' \hat{\beta}) \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \hat{\beta} \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \hat{\beta} \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - 1 * \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i \hat{u}_i &= 0. \end{aligned}$$

3. El promedio de muestra de los valores ajustados es igual al promedio de muestra de las observaciones:

$$\begin{aligned} y_i &= \hat{y}_i + \hat{u}_i \\ \sum_{i=1}^n y_i &= \sum_{i=1}^n \hat{y}_i + \sum_{i=1}^n \hat{u}_i \\ \frac{1}{n} \sum_{i=1}^n y_i &= \frac{1}{n} \sum_{i=1}^n \hat{y}_i + \frac{1}{n} \sum_{i=1}^n \hat{u}_i \\ \bar{y} &= \bar{\hat{y}} + \frac{1}{n} * 0 \\ \bar{y} &= \bar{\hat{y}} + 0 \\ \bar{y} &= \bar{\hat{y}}. \end{aligned}$$

4. El punto $(\bar{x}, \bar{y})$ siempre está en la línea MCO de regresión:

$$\begin{aligned} \bar{y} &= \bar{\hat{y}} \\ \bar{y} &= \frac{1}{n} \sum_{i=1}^n \hat{y}_i \\ \bar{y} &= \frac{1}{n} \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i) \\ \bar{y} &= \frac{1}{n} (\sum_{i=1}^n \hat{\beta}_0 + \sum_{i=1}^n \hat{\beta}_1 x_i) \\ \bar{y} &= \frac{1}{n} (n \hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i) \\ \bar{y} &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x}. \end{aligned}$$

5.4) Sesgo del estimador MCO.

Bajo las condiciones A1 y A2, el estimador MCO es insesgado, es decir, el valor esperado del estimador MCO es igual al parámetro desconocido.

Se puede mostrar el resultado de la siguiente manera. Recordar que:

$$\begin{aligned}
\hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) y_i \quad (*) \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i) \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n [\beta_0 (x_i - \bar{x}) + \beta_1 (x_i - \bar{x}) x_i + (x_i - \bar{x}) u_i] \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\sum_{i=1}^n \beta_0 (x_i - \bar{x}) + \sum_{i=1}^n \beta_1 (x_i - \bar{x}) x_i + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \quad (**) \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_0 * 0 + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \quad (***) \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [0 + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\
\hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i].
\end{aligned}$$

$$\begin{aligned}
(*) \quad \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n \bar{x} y_i + \sum_{i=1}^n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - \bar{x} y_i) - \bar{y} \sum_{i=1}^n x_i + n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x}) y_i - n \bar{y} \bar{x} + n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x}) y_i.
\end{aligned}$$

$$\begin{aligned}
(**) \quad \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i^2 - 2x_i \bar{x} + \bar{x}^2) \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2x_i \bar{x} + \sum_{i=1}^n \bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x} \bar{x} + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i x_i - \sum_{i=1}^n x_i \bar{x} \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i x_i - x_i \bar{x}) \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i - \bar{x}) x_i.
\end{aligned}$$

$$\begin{aligned}
(***) \quad \sum_{i=1}^n (x_i - \bar{x}) &= \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \\
\sum_{i=1}^n (x_i - \bar{x}) &= n\bar{x} - n\bar{x} \\
\sum_{i=1}^n (x_i - \bar{x}) &= 0.
\end{aligned}$$

Por lo tanto, el estimador MCO de la pendiente se puede escribir como:

$$\hat{\beta}_1 = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i. \quad (20)$$

Tomando esperanza:

$$\begin{aligned}
E(\hat{\beta}_1) &= E\left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\
E(\hat{\beta}_1) &= E(\beta_1) + E\left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right]
\end{aligned}$$

$$\begin{aligned}
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n E[(x_i - \bar{x}) u_i] \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) E(u_i) \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) * 0 \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} * \sum_{i=1}^n 0 \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} n * 0 \\
 E(\hat{\beta}_1) &= \beta_1 + 0 \\
 E(\hat{\beta}_1) &= \beta_1.
 \end{aligned}$$

Ya que $E(u | x) = E(u) = 0$, $E(\hat{\beta}_1) = \beta_1$. Además, recordar que:

$$\begin{aligned}
 \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \\
 \hat{\beta}_0 &= \beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}.
 \end{aligned}$$

$$\begin{aligned}
 E(\hat{\beta}_0) &= E(\beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}) \\
 E(\hat{\beta}_0) &= E(\beta_0) + E(\beta_1 \bar{x}) + E(\bar{u}) - E(\hat{\beta}_1 \bar{x}) \\
 E(\hat{\beta}_0) &= \beta_0 + \bar{x} \beta_1 + E\left(\frac{1}{n} \sum_{i=1}^n u_i\right) - \bar{x} E(\hat{\beta}_1) \\
 E(\hat{\beta}_0) &= \beta_0 + \bar{x} \beta_1 + \frac{1}{n} \sum_{i=1}^n E(u_i) - \bar{x} \beta_1 \\
 E(\hat{\beta}_0) &= \beta_0 + \frac{1}{n} \sum_{i=1}^n 0 \\
 E(\hat{\beta}_0) &= \beta_0 + \frac{1}{n} n * 0 \\
 E(\hat{\beta}_0) &= \beta_0 + 0 \\
 E(\hat{\beta}_0) &= \beta_0.
 \end{aligned}$$

Por lo tanto, los estimadores de MCO son insesgados:

$$E(\hat{\beta}_0) = \beta_0; \quad E(\hat{\beta}_1) = \beta_1. \quad (21)$$

5.5) Varianza del estimador MCO.

Se va a obtener la varianza de los estimadores de MCO, pero, primero, se debe establecer una de las suposiciones del modelo de regresión lineal simple:

- A4 (Homocedasticidad): $\text{Var}(u | x) = \sigma^2$.
- A5 (Errores no correlacionados): $\text{Cov}(u_i, u_j) = 0$ para $i, j = 1, \dots, i-1, i+1, \dots, n$.

En otras palabras, la varianza del término de error es constante (no cambia con x) y el error u_i es independiente de u_j para $i \neq j$. Las suposiciones A4 y A5 juntas implican errores esféricos o, más precisamente, varianza de error esférico.

¿Cuál es la varianza de $\hat{\beta}_1$? Lo que se sabe:

$$\hat{\beta}_1 = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i.$$

Considerando A4 y A5, se obtiene la varianza de la siguiente manera:

$$\begin{aligned}
 \text{Var}(\hat{\beta}_1) &= \text{Var} \left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i \right] \\
 \text{Var}(\hat{\beta}_1) &= \text{Var}(\beta_1) + \text{Var} \left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i \right] \\
 \text{Var}(\hat{\beta}_1) &= 0 + \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \text{Var} \left[\sum_{i=1}^n (x_i - \bar{x}) u_i \right] \\
 \text{Var}(\hat{\beta}_1) &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \left[\sum_{i=1}^n \text{Var} \left[(x_i - \bar{x}) u_i \right] \right] \\
 \text{Var}(\hat{\beta}_1) &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(u_i) \\
 \text{Var}(\hat{\beta}_1) &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 \\
 \text{Var}(\hat{\beta}_1) &= \sigma^2 \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \\
 \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.
 \end{aligned}$$

Del mismo modo, para obtener la varianza de la intersección, bajo los supuestos establecidos, se escribe:

$$\begin{aligned}
 \text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{y} - \hat{\beta}_1 \bar{x}) \\
 \text{Var}(\hat{\beta}_0) &= \text{Var} \left(\bar{y} - \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \bar{x} \right) \\
 \text{Var}(\hat{\beta}_0) &= \text{Var} \left\{ \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] y_i \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \text{Var} \left\{ \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] y_i \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 \text{Var}(y_i) \\
 \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 \sigma^2 \quad (*** \text{ y } ****) \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \sum_{i=1}^n \left\{ \frac{1}{n^2} + \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 - \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \sum_{i=1}^n \frac{1}{n^2} + \sum_{i=1}^n \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 - \sum_{i=1}^n \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \frac{n}{n^2} + \sum_{i=1}^n \frac{\bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \frac{1}{n} + \frac{\sum_{i=1}^n \bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} * 0 \right\} \quad (*****) \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \frac{1}{n} + \frac{\bar{x}^2 \sum_{i=1}^n (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - 0 \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n (x_i^2 + \bar{x}^2 - 2x_i \bar{x}) + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^n \bar{x}^2 - \sum_{i=1}^n 2x_i \bar{x} + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n \bar{x}^2 - 2n \bar{x} \bar{x} + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n \bar{x}^2 - 2n \bar{x}^2 + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]
 \end{aligned}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right],$$

que es la varianza de la intersección estimada.

$$\begin{aligned} (***) \text{Var}(y_i) &= \text{Var}(\beta_0 + \beta_1 x_i + u_i) \\ \text{Var}(y_i) &= \text{Var}(\beta_0) + \text{Var}(\beta_1 x_i) + \text{Var}(u_i) \\ \text{Var}(y_i) &= 0 + 0 + \text{Var}(u_i) \\ \text{Var}(y_i) &= \text{Var}(u_i) \\ \text{Var}(y_i) &= \sigma^2. \end{aligned}$$

$$\begin{aligned} (****) \text{Cov}(y_i, y_j) &= E\{[y_i - E(y_i)][y_j - E(y_j)]\} \\ \text{Cov}(y_i, y_j) &= E(u_i u_j) \\ \text{Cov}(y_i, y_j) &= \text{Cov}(u_i, u_j) + E(u_i) E(u_j) \\ \text{Cov}(y_i, y_j) &= 0 + 0 * 0 \\ \text{Cov}(y_i, y_j) &= 0. \end{aligned}$$

$$\begin{aligned} (*****) \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{n\bar{x} - n\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{0}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= 0. \end{aligned}$$

Aunque no se conoce el parámetro σ^2 , se puede agregar su estimador $\hat{\sigma}^2$.

Observación 1. La varianza del término de error es otro parámetro desconocido de la población, pero se puede estimar usando el principio analógico. Recordar que u se distribuye como una variable normal con media cero y varianza σ^2 .

$$E(u) = 0.$$

$$\begin{aligned} V(u) &= E(u^2) - [E(u)]^2 \\ V(u) &= E(u^2) - 0^2 \\ V(u) &= E(u^2) - 0 \\ V(u) &= E(u^2) \\ V(u) &= \sigma^2. \end{aligned}$$

Lo que implica que se puede usar (de la contraparte de la muestra):

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i^2,$$

como un estimador de σ^2 .

Desafortunadamente, éste es un estimador sesgado, pero se puede corregir, fácilmente, para tener un estimador insesgado de la varianza del término de error:

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2, \quad (22)$$

donde $(n - 2)$ son los grados de libertad.

Por lo tanto, los estimadores de la varianza de los estimadores MCO serían:

$$\widehat{Var}(\hat{\beta}_0) = \hat{\sigma}^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]; \quad \widehat{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (23)$$

Entonces, se puede definir el error estándar del coeficiente de la pendiente como:

$$\begin{aligned} \widehat{se}(\hat{\beta}_1) &= \sqrt{\widehat{Var}(\hat{\beta}_1)} \\ \widehat{se}(\hat{\beta}_1) &= \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \\ \widehat{se}(\hat{\beta}_1) &= \frac{\hat{\sigma}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}. \end{aligned} \quad (24)$$

6) Modelos Lineales Multivariados.

Hasta ahora, se ha estudiado el modelo de regresión simple, que incluye sólo una covariable. Tiene sentido extender el modelo anterior a un modelo con p variables independientes:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + u = \beta_0 + \sum_{j=1}^p \beta_j x_j + u, \quad (25)$$

donde β_0 es el intercepto, β_1 es el coeficiente asociado con la variable independiente x_1 , β_2 con la variable x_2 y β_p con la variable x_p . La variable aleatoria u es el término de error, que contiene otros factores además de $x_1, x_2, \dots, x_p$.

La suposición crucial es que todos los factores observables (las variables independientes $x_1, x_2, \dots, x_p$) que afectan a la variable dependiente y no están correlacionados con el término de error: $E(u | x_1, x_2, \dots, x_p) = 0$.

6.1) Método de Momentos.

La idea básica, aquí, es aplicar las restricciones en la población a los datos. Por ejemplo, recordar que se tienen las suposiciones:

$$\begin{aligned} E(u_i) &= 0. \\ E(x_{i1} u_i) &= 0. \\ E(x_{ip} u_i) &= 0. \end{aligned}$$

Por lo tanto, se deben encontrar las estimaciones de coeficientes que resuelven el siguiente sistema de ecuaciones:

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{i1} \hat{u}_i = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{ip} \hat{u}_i = 0.$$

De nuevo, se tiene $(p + 1)$ ecuaciones y $(p + 1)$ incógnitas. Las soluciones se llaman estimadores del método de momentos para los parámetros de regresión $\beta_0, \dots, \beta_p$.

Por ejemplo, considerar el modelo con dos variables independientes. Las condiciones serán:

$$E(u_i) = 0.$$

$$E(x_{i1}u_i) = 0.$$

$$E(x_{i2}u_i) = 0.$$

Por consiguiente:

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{i1} \hat{u}_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n x_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{i2} \hat{u}_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n x_{i2} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.$$

Como se verá a continuación, el método de momentos proporciona coeficientes estimados que son idénticos a las estimaciones de mínimos cuadrados.

6.2) MCO.

El procedimiento de mínimos cuadrados es similar al que se discutió anteriormente. Calcula los coeficientes estimados como minimizadores de la suma de residuales al cuadrado:

$$S = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

La diferencia es que, ahora:

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + u_i,$$

en lugar de la muestra $y_i = \beta_0 + \beta_1 x_i$. Por ejemplo, el valor predicho de y_i es:

$$\hat{y}_i = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j x_{ij},$$

bajo los supuestos estándar. Para obtener la solución de este problema, se utilizan las derivadas parciales para desarrollar un conjunto de $(p + 1)$ ecuaciones normales simultáneas:

$$\frac{\partial S}{\partial \hat{\beta}_0} = 0$$

$$\frac{\partial S}{\partial \hat{\beta}_1} = 0$$

$$\vdots$$

$$\frac{\partial S}{\partial \hat{\beta}_p} = 0,$$

que tiene $(p + 1)$ incógnitas $\hat{\beta}_0, \dots, \hat{\beta}_p$. Por simplicidad, nos enfocamos en el problema de minimizar:

$$S = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2})^2,$$

con derivadas parciales:

$$\begin{aligned} \frac{\partial S}{\partial \hat{\beta}_0} &= -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0. \\ \frac{\partial S}{\partial \hat{\beta}_1} &= -2 \sum_{i=1}^n x_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0. \\ \frac{\partial S}{\partial \hat{\beta}_2} &= -2 \sum_{i=1}^n x_{i2} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0. \end{aligned}$$

Estas ecuaciones se pueden escribir como:

$$\begin{aligned} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_{i1} + \hat{\beta}_2 \sum_{i=1}^n x_{i2} &= \sum_{i=1}^n y_i. \\ \hat{\beta}_0 \sum_{i=1}^n x_{i1} + \hat{\beta}_1 \sum_{i=1}^n x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^n x_{i1} x_{i2} &= \sum_{i=1}^n x_{i1} y_i. \\ \hat{\beta}_0 \sum_{i=1}^n x_{i2} + \hat{\beta}_1 \sum_{i=1}^n x_{i1} x_{i2} + \hat{\beta}_2 \sum_{i=1}^n x_{i2}^2 &= \sum_{i=1}^n x_{i2} y_i. \end{aligned}$$

Se puede demostrar que la estimación del coeficiente de intercepción β_0 es:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2.$$

Es algo más tedioso encontrar esto:

$$\begin{aligned} \hat{\beta}_1 &= \frac{S_y(r_{x_1 y} - r_{x_1 x_2} r_{x_2 y})}{S_{x_1}(1 - r_{x_1 x_2}^2)}. \\ \hat{\beta}_2 &= \frac{S_y(r_{x_2 y} - r_{x_1 x_2} r_{x_1 y})}{S_{x_2}(1 - r_{x_1 x_2}^2)}. \end{aligned}$$

Donde $r_{x_j y}$ es la correlación muestral entre x_j e y , $r_{x_1 x_2}$ es la correlación muestral entre x_1 y x_2 , S_{x_j} es la desviación estándar muestral para x_j y S_y es la desviación estándar muestral para y .

Lo que se puede aprender de estos estimadores es que, en el modelo de regresión múltiple, la estimación del coeficiente de regresión β_1 depende de la correlación entre x_1 y x_2 y entre x_2 e y . Si no hay correlación entre x_1 y x_2 (por ejemplo, $r_{x_1 x_2} = 0$), la estimación del coeficiente es:

$$\begin{aligned} \hat{\beta}_1 &= \frac{S_y r_{x_1 y}}{S_{x_1}} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (y_i - \bar{y})(x_{i1} - \bar{x}_1)}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}} \frac{\sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}}}{\sqrt{\frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}{n-1}}} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (y_i - \bar{y})(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}. \end{aligned}$$

Si $r_{x_1x_2} = 1$, la estimación del coeficiente β_1 no será definida. Se podrían obtener las mismas conclusiones sobre $\hat{\beta}_2$. En el análisis empírico, siempre es importante explorar la correlación entre las variables independientes.

7) Análisis de Varianza y R^2 .

Considerar:

$$\begin{aligned} y_i &= \hat{y}_i + \hat{u}_i \\ y_i - \bar{y} &= \hat{y}_i - \bar{y} + \hat{u}_i \\ (y_i - \bar{y})^2 &= (\hat{y}_i - \bar{y} + \hat{u}_i)^2 \\ (y_i - \bar{y})^2 &= (\hat{y}_i - \bar{y})^2 + 2 \hat{u}_i (\hat{y}_i - \bar{y}) + \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n [(\hat{y}_i - \bar{y})^2 + 2 \hat{u}_i (\hat{y}_i - \bar{y}) + \hat{u}_i^2] \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n 2 \hat{u}_i (\hat{y}_i - \bar{y}) + \sum_{i=1}^n \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) + \sum_{i=1}^n \hat{u}_i^2. \end{aligned}$$

Tener en cuenta que, al usar las propiedades aritméticas de los estimadores MCO:

$$\begin{aligned} \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i [(\hat{\beta}_0 + \hat{\beta}_1 x_i) - (\hat{\beta}_0 + \hat{\beta}_1 \bar{x})] \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i (\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i (\hat{\beta}_1 x_i - \hat{\beta}_1 \bar{x}) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i [\hat{\beta}_1 (x_i - \bar{x})] \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 \sum_{i=1}^n \hat{u}_i (x_i - \bar{x}) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 \sum_{i=1}^n (\hat{u}_i x_i - \hat{u}_i \bar{x}) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (\sum_{i=1}^n \hat{u}_i x_i - \sum_{i=1}^n \hat{u}_i \bar{x}) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (\sum_{i=1}^n \hat{u}_i x_i - \bar{x} \sum_{i=1}^n \hat{u}_i) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (0 - \bar{x} * 0) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (0 - 0) \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= \hat{\beta}_1 * 0 \\ \sum_{i=1}^n \hat{u}_i (\hat{y}_i - \bar{y}) &= 0. \end{aligned}$$

Por lo tanto:

$$\begin{aligned} \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 * 0 + \sum_{i=1}^n \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 0 + \sum_{i=1}^n \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2. \end{aligned} \tag{26}$$

Si se divide esta expresión por la variable del lado izquierdo:

$$\begin{aligned} \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} &= \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \\ 1 &= \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} + \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \end{aligned}$$

que indica una proporción que se explica por el modelo lineal estimado (primer término) y una que no se explica por el modelo lineal (segundo término). El R^2 de una regresión se define como:

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Tener en cuenta que una suma pequeña de residuos al cuadrado significa que el modelo explica muy bien y una suma grande de residuos al cuadrado significa que el modelo no produce un buen ajuste a los datos. Por lo tanto, un R^2 cercano a 1 nos dice que el modelo produce un buen ajuste a los datos y un R^2 cercano a 0 nos dice que el modelo no produce un buen ajuste a los datos. Tener en cuenta, también, que $0 \leq R^2 \leq 1$, ya que $0 \leq \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \leq 1$.

Un estadístico alternativo es el R^2 ajustado, que se define como:

$$\bar{R}^2 = 1 - \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

y proporciona una compensación entre la bondad de ajuste y la parsimonia. La bondad de ajuste se mide por R^2 y la parsimonia del modelo se mide por los grados de libertad ($n - p$). Tener en cuenta que el R^2 puede no estar bien definido y también puede ser negativo.

Es, inmediatamente, evidente que:

$$1 - \bar{R}^2 = 1 - \left[1 - \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \right]$$

$$1 - \bar{R}^2 = 1 - 1 + \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$1 - \bar{R}^2 = \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$1 - \bar{R}^2 = \frac{n-1}{n-p} (1 - R^2).$$