

Lectura 2: Proyecciones Ortogonales.

Se comienza asumiendo un modelo lineal:

$$\underset{1 \times 1}{y_i} = \underset{1 \times p}{x_i'} \underset{p \times 1}{\beta} + \underset{1 \times 1}{u_i}, \quad \text{para } i = 1, 2, \dots, n, \quad (1)$$

donde y es la variable de respuesta para el sujeto i y x_i' es un vector de p variables independientes que incluye una intersección. El modelo se puede escribir en una notación de matriz, más conveniente, como:

$$\underset{n \times 1}{y} = \underset{n \times p}{X} \underset{p \times 1}{\beta} + \underset{n \times 1}{u}, \quad (2)$$

donde y , ahora, se define como un vector de $(n \times 1)$, la matriz X es $(n \times p)$, el vector de parámetros es $(p \times 1)$ y el vector aleatorio u es $(n \times 1)$. En otras palabras:

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p-1} \\ 1 & x_{21} & x_{22} & \dots & x_{2p-1} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np-1} \end{bmatrix}; \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_n \end{bmatrix}; \quad u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}.$$

Resulta que:

$$\sum_{i=1}^n x_i x_i' = X'X.$$

$$\sum_{i=1}^n x_i y_i = X'y.$$

1) Estimación.

Se puede estimar el parámetro usando el Método de Momentos o, alternativamente, el método tradicional llamado Mínimos Cuadrados Ordinarios (MCO). La derivación del estimador MCO se basa en minimizar la suma de los errores al cuadrado:

$$\|u\|^2 = \|y - X\beta\|^2,$$

donde $\|\cdot\|$ es la norma euclidiana definida como $(z'z)^{\frac{1}{2}} = (\sum_{i=1}^n z_i^2)^{\frac{1}{2}}$ para un vector genérico z . Por lo tanto, la función objetivo es:

$$\begin{aligned} \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} [(y - X\beta)'(y - X\beta)] \\ \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} [(y' - \beta'X')(y - X\beta)] \\ \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} (y'y - \beta'X'y - y'X\beta + \beta'X'X\beta) \\ \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} (y'y - 2\beta'X'y + \beta'X'X\beta), \end{aligned}$$

porque $\beta'X'y = y'X\beta$. La condición de primer orden es:

$$-2X'y + 2X'X\beta = 0,$$

lo que implica que $X'(y - X\beta) = 0$ y, en consecuencia, bajo los supuestos A1, A2 y A3:

$$\hat{\beta} = (X'X)^{-1}X'y. \quad (3)$$

Alternativamente, se define el estimador como:

$$\hat{\beta} = \arg \min \|y - X\beta\|^2. \quad (4)$$

El estimador MCO $\hat{\beta}$ da el vector $X\beta$ más cercano, en términos de la norma euclidiana, a y entre todos los vectores que se encuentran en el espacio abarcado por el vector X .

También se puede obtener la varianza del estimador bajo homocedasticidad y errores independientes (supuestos A4 y A5). Tener en cuenta que:

$$\begin{aligned} V(\hat{\beta} | X) &= V[(X'X)^{-1}X'y | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'(X\beta + u) | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[I\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + V[(X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + (X'X)^{-1}X' V(u | X) X(X'X)^{-1} \\ V(\hat{\beta} | X) &= 0 + (X'X)^{-1}X' \sigma_u^2 I_n X(X'X)^{-1} \\ V(\hat{\beta} | X) &= (X'X)^{-1}X' \sigma_u^2 X(X'X)^{-1} \\ V(\hat{\beta} | X) &= \sigma_u^2 (X'X)^{-1}X'X(X'X)^{-1} \\ V(\hat{\beta} | X) &= \sigma_u^2 I(X'X)^{-1} \\ V(\hat{\beta} | X) &= \sigma_u^2 (X'X)^{-1}, \end{aligned}$$

bajo el supuesto de que la varianza del término de error es “esférica”, es decir, $V(u | X) = \sigma_u^2 I$. La varianza depende de σ_u^2 , que es desconocida y necesita ser estimada. Como en la Lectura 1, se estima usando $\frac{\hat{u}'\hat{u}}{n-p}$.

Nótese también que la suposición de homocedasticidad simplifica la expresión de la varianza de MCO.

2) Propiedades de Muestra Finita.

El estimador MCO $\hat{\beta}$ es insesgado cuando las variables independientes son independientes del término de error (supuesto A2):

$$\begin{aligned} E(\hat{\beta} | X) &= E[(X'X)^{-1}X'y | X] \\ E(\hat{\beta} | X) &= E[(X'X)^{-1}X'(X\beta + u) | X] \\ E(\hat{\beta} | X) &= E\{[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u] | X\} \\ E(\hat{\beta} | X) &= E[I\beta + (X'X)^{-1}X'u | X] \\ E(\hat{\beta} | X) &= E[\beta + (X'X)^{-1}X'u | X] \\ E(\hat{\beta} | X) &= E(\beta | X) + E[(X'X)^{-1}X'u | X] \end{aligned}$$

$$E(\hat{\beta} | X) = \beta + (X'X)^{-1}X' E(u | X)$$

$$E(\hat{\beta} | X) = \beta + (X'X)^{-1}X' * 0$$

$$E(\hat{\beta} | X) = \beta + 0$$

$$E(\hat{\beta} | X) = \beta.$$

Por la ley de las esperanzas iteradas, también se tiene que:

$$E(\hat{\beta}) = E[E(\hat{\beta} | X)]$$

$$E(\hat{\beta}) = E(\beta)$$

$$E(\hat{\beta}) = \beta.$$

El estimador MCO es insesgado y lineal, lo que significa que se puede escribir $\hat{\beta}$ como una función lineal de la variable de respuesta y, por ejemplo:

$$\hat{\beta} = Ay,$$

donde $A = (X'X)^{-1}X'$. Ahora, considerar otro estimador lineal insesgado:

$$\tilde{\beta} = (A + B)y.$$

Por lo tanto, debe ser el caso de $E(\tilde{\beta}) = \beta$ porque $BX = 0$. Además, la varianza del estimador $\tilde{\beta}$ es:

$$V(\tilde{\beta} | X) = E\{[\tilde{\beta} - E(\tilde{\beta})][\tilde{\beta} - E(\tilde{\beta})]' | X\}$$

$$V(\tilde{\beta} | X) = E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)' | X]$$

$$V(\tilde{\beta} | X) = E\{[(A + B)u][(A + B)u]' | X\} \quad (*)$$

$$V(\tilde{\beta} | X) = E[(A + B)uu'(A + B)' | X]$$

$$V(\tilde{\beta} | X) = (A + B)E(uu' | X)(A + B)'$$

$$V(\tilde{\beta} | X) = (A + B)V(u | X)(A + B)'$$

$$V(\tilde{\beta} | X) = (A + B)\sigma^2 I(A' + B')$$

$$V(\tilde{\beta} | X) = (A + B)\sigma^2(A' + B')$$

$$V(\tilde{\beta} | X) = \sigma^2(A + B)(A' + B')$$

$$V(\tilde{\beta} | X) = \sigma^2(AA' + AB' + BA' + BB')$$

$$V(\tilde{\beta} | X) = \sigma^2[(X'X)^{-1}X'X(X'X)^{-1} + (X'X)^{-1}X'B' + BX(X'X)^{-1} + BB']$$

$$V(\tilde{\beta} | X) = \sigma^2[I(X'X)^{-1} + (X'X)^{-1} * 0 + 0 * (X'X)^{-1} + BB'] \quad (**)$$

$$V(\tilde{\beta} | X) = \sigma^2[(X'X)^{-1} + 0 + 0 + BB']$$

$$V(\tilde{\beta} | X) = \sigma^2[(X'X)^{-1} + BB']$$

$$V(\tilde{\beta} | X) = \sigma^2(X'X)^{-1} + \sigma^2 BB'$$

$$V(\tilde{\beta} | X) = V(\hat{\beta} | X) + \sigma^2 BB'.$$

$$(*) \tilde{\beta} = (A + B)y$$

$$\tilde{\beta} = (A + B)(X\beta + u)$$

$$\tilde{\beta} = AX\beta + BX\beta + (A + B)u$$

$$\tilde{\beta} = (X'X)^{-1}X'X\beta + 0 * \beta + (A + B)u \quad (**)$$

$$\tilde{\beta} = I\beta + 0 + (A + B)u$$

$$\tilde{\beta} = \beta + (A + B)u$$

$$\tilde{\beta} - \beta = (A + B)u.$$

$$\begin{aligned}
 (**) E(\tilde{\beta}) &= \beta \\
 E[\beta + BX\beta + (A+B)u] &= \beta \\
 E(\beta) + E(BX\beta) + E[(A+B)u] &= \beta \\
 \beta + BX\beta + (A+B)E(u) &= \beta \\
 \beta + BX\beta + (A+B) \cdot 0 &= \beta \\
 \beta + BX\beta + 0 &= \beta \\
 \beta + BX\beta &= \beta \\
 \beta(1 + BX) &= \beta \\
 1 + BX &= \frac{\beta}{\beta} \\
 1 + BX &= 1 \\
 BX &= 1 - 1 \\
 BX &= 0.
 \end{aligned}$$

La última ecuación sugiere que la varianza del estimador $\tilde{\beta}$ es mayor que la varianza del estimador $\hat{\beta}$. Esto se puede establecer en el siguiente importante teorema.

Teorema 1 (Gauss-Markov). Si $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I$, en un modelo de regresión lineal, entonces, el estimador MCO es eficiente, por ejemplo:

$$V(\tilde{\beta} | X) \geq V(\hat{\beta} | X)$$

ó

$$V(\tilde{\beta} | X) - V(\hat{\beta} | X) \text{ es semidefinida positiva.}$$

Tener en cuenta que el teorema es para varianzas condicionales. ¿Se puede afirmar también que $V(\tilde{\beta}) \geq V(\hat{\beta})$? Se necesita un poco más de trabajo. Considerar, primero, la definición:

$$V(\hat{\beta}) = E[V(\hat{\beta} | X)] + V[E(\hat{\beta} | X)].$$

Primero, notar que el segundo término es igual a cero porque el estimador es insesgado y, por lo tanto, $V(\beta) = 0$. Por lo tanto:

$$\begin{aligned}
 V(\hat{\beta}) &= E[V(\hat{\beta} | X)] + V[E(\hat{\beta} | X)] \\
 V(\hat{\beta}) &= E[V(\hat{\beta} | X)] + V(\beta) \\
 V(\hat{\beta}) &= E[\sigma^2(X'X)^{-1}] + 0 \\
 V(\hat{\beta}) &= \sigma^2 E[(X'X)^{-1}] \\
 V(\hat{\beta}) &= \sigma^2(X'X)^{-1}.
 \end{aligned}$$

Similarmente:

$$\begin{aligned}
 V(\tilde{\beta}) &= E[V(\tilde{\beta} | X)] + V[E(\tilde{\beta} | X)] \\
 V(\tilde{\beta}) &= E[V(\tilde{\beta} | X)] + V(\beta) \\
 V(\tilde{\beta}) &= E[\sigma^2(X'X)^{-1} + \sigma^2 BB'] + 0 \\
 V(\tilde{\beta}) &= E[\sigma^2(X'X)^{-1}] + E(\sigma^2 BB') \\
 V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} + \sigma^2 BB'.
 \end{aligned}$$

Por lo tanto, se concluye que:

$$V(\tilde{\beta}) \geq V(\hat{\beta}),$$

porque $E(BB')$ es semidefinida positiva.

3) Proyecciones.

Se define la matriz de proyección:

$$P = X(X'X)^{-1}X'$$

El i -ésimo elemento diagonal de P se denomina punto de apalancamiento y se define como $h_i = x_i'(X'X)^{-1}x_i$. La matriz P es simétrica e idempotente y su traza es igual al número de variables independientes. La simetría implica:

$$P' = [X(X'X)^{-1}X']'$$

$$P' = X(X'X)^{-1}X'$$

$$P' = P.$$

La idempotencia implica:

$$PP = X(X'X)^{-1}X'X(X'X)^{-1}X'$$

$$PP = XI(X'X)^{-1}X'$$

$$PP = X(X'X)^{-1}X'$$

$$PP = P.$$

Finalmente:

$$\text{tr}(P) = \text{tr}[X(X'X)^{-1}X']$$

$$\text{tr}(P) = \text{tr}[X'X(X'X)^{-1}] \quad (*)$$

$$\text{tr}(P) = \text{tr}(I_p)$$

$$\text{tr}(P) = p.$$

$$(*) \text{tr}(AB) = \text{tr}(BA).$$

El vector de valores ajustados, definido como:

$$\hat{y} = X\hat{\beta},$$

representa la proyección ortogonal de y sobre el espacio de columna de X . Tener en cuenta que:

$$\hat{y} = X(X'X)^{-1}X'y$$

$$\hat{y} = Py,$$

donde la matriz P es la matriz de proyección. Por otro lado, el vector residual:

$$\hat{u} = y - \hat{y}$$

$$\hat{u} = y - Py$$

$$\hat{u} = (I - P)y$$

$$\hat{u} = My,$$

donde $M = I - P$, que es una matriz que produce “residuos”. Tener en cuenta que también se puede escribir el vector de residuos como:

$$\hat{u} = My$$

$$\hat{u} = M(X\beta + u)$$

$$\hat{u} = MX\beta + Mu$$

$$\hat{u} = 0 * \beta + Mu \quad (**)$$

$$\hat{u} = 0 + Mu$$

$$\hat{u} = Mu.$$

$$(**) MX = (I - P)X$$

$$MX = IX - PX$$

$$MX = X - X(X'X)^{-1}X'X$$

$$MX = X - XI$$

$$MX = X - X$$

$$MX = 0.$$

porque $PX = X$. Esto implica que los residuos de la regresión y las variables independientes son ortogonales:

$$X'\hat{u} = X'Mu$$

$$X'\hat{u} = X'(I - P)u$$

$$X'\hat{u} = (X'I - X'P)u$$

$$X'\hat{u} = (X' - X')u \quad (***)$$

$$X'\hat{u} = 0 * u$$

$$X'\hat{u} = 0.$$

$$(***) X'P = X'X(X'X)^{-1}X'$$

$$X'P = IX'$$

$$X'P = X'.$$




Figure 1: OLS fitting and projections

Observación 1. La geometría básica de MCO se puede ver en la Figura 1. Sea y y $X = [X_1 : X_2]$ vectores, se define el espacio abarcado por las columnas de X como:

$$S(X) = \{z \in \mathbb{R}^n \mid z = Xc, c \in \mathbb{R}^p\}.$$

El ajuste MCO proporciona el vector más cercano a y en el espacio abarcado por las X .




Figure 2: OLS fitting with two observations

Ejemplo 1. Para ilustrar la geometría básica de MCO, se presenta un ejemplo simple (Figura 2). Sean $y = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ y $X = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ vectores y considerar el modelo de regresión $y_i = X_i\beta + u_i$. El estimador MCO es:

$$\arg \min \{(y_1 - 1 * \beta)^2 + (y_2 - 1 * \beta)^2\}$$

$$\arg \min \{(y_1 - \beta)^2 + (y_2 - \beta)^2\}.$$

Y la condición de primer orden asociada es:

$$2(y_1 - \beta)(-1) + 2(y_2 - \beta)(-1) = 0$$

$$-2(y_1 - \beta) - 2(y_2 - \beta) = 0$$

$$-2[(y_1 - \beta) + (y_2 - \beta)] = 0$$

$$(y_1 - \beta) + (y_2 - \beta) = 0$$

$$y_1 - \beta + y_2 - \beta = 0$$

$$-2\beta + y_1 + y_2 = 0$$

$$2\beta = y_1 + y_2$$

$$\hat{\beta} = \frac{y_1 + y_2}{2}$$

$$\hat{\beta} = \frac{1+3}{2}$$

$$\hat{\beta} = \frac{4}{2}$$

$$\hat{\beta} = 2.$$

Por lo tanto, se obtiene $\hat{y} = X\hat{\beta} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} * 2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$ y $\hat{u} = y - \hat{y} = \begin{bmatrix} 1 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$, con $X'\hat{u} = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = 0$. Como está claro en la figura, también es interesante obtener la longitud de los siguientes vectores usando la norma euclidiana:

$$\|y\| = \sqrt{1^2 + 3^2}$$

$$\|y\| = \sqrt{1 + 9}$$

$$\|y\| = \sqrt{10}.$$

$$\|\hat{y}\| = \sqrt{2^2 + 2^2}$$

$$\|\hat{y}\| = \sqrt{4 + 4}$$

$$\|\hat{y}\| = \sqrt{8}.$$

$$\|u\| = \|y - \hat{y}\|$$

$$\|u\| = \sqrt{(1 - 2)^2 + (3 - 2)^2}$$

$$\|u\| = \sqrt{(-1)^2 + 1^2}$$

$$\|u\| = \sqrt{1 + 1}$$

$$\|u\| = \sqrt{2}.$$

4) Ajuste Particionado (Teorema de Frisch-Waugh-Lovell).

Considerar un modelo de regresión particionado:

$$y = X\beta + Z\gamma + u \quad (5)$$

y el estimador correspondiente $\hat{\beta}$. Además, considerar el modelo de regresión alternativo:

$$\tilde{y} = \tilde{X}\beta + \tilde{u}, \quad (6)$$

con el correspondiente estimador $\tilde{\beta}$, con $\tilde{Z} = M_Z Z$ para un vector genérico Z .

Teorema 2. Los estimadores $\hat{\beta}$ y $\tilde{\beta}$ son, numéricamente, idénticos.

Prueba. Las fórmulas estándar de MCO en el modelo (5) dan las siguientes ecuaciones normales:

$$X'y = X'X\hat{\beta} + X'Z\hat{\gamma}.$$

$$Z'y = Z'X\hat{\beta} + Z'Z\hat{\gamma}.$$

Resolviendo para $\hat{\gamma}$ en la segunda ecuación y reemplazando en la primera ecuación, se obtiene:

$$Z'Z\hat{\gamma} = Z'y - Z'X\hat{\beta}$$

$$\hat{\gamma} = (Z'Z)^{-1} (Z'y - Z'X\hat{\beta})$$

$$\hat{\gamma} = (Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}.$$

$$X'y = X'X\hat{\beta} + X'Z [(Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}]$$

$$X'y = X'X\hat{\beta} + X'Z(Z'Z)^{-1} Z'y - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X'y - X'Z(Z'Z)^{-1} Z'y = X'X\hat{\beta} - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X' [I - Z(Z'Z)^{-1} Z'] y = X' [I - Z(Z'Z)^{-1} Z'] X\hat{\beta}$$

$$X' (I - P_Z) y = X' (I - P_Z) X\hat{\beta}$$

$$X'M_Z y = X'M_Z X\hat{\beta}.$$

Por lo tanto:

$$\hat{\beta} = (X'M_Z X)^{-1} X'M_Z y$$

$$\hat{\beta} = (X'M'_Z M_Z X)^{-1} X'M'_Z M_Z y$$

$$\hat{\beta} = (\tilde{X}'\tilde{X})^{-1} \tilde{X}'\tilde{y}$$

$$\hat{\beta} = \tilde{\beta}.$$

Además de las estimaciones puntuales, los residuos son idénticos. Para ver esto, considerar:

$$y = \hat{y} + \hat{u}$$

$$y = X\hat{\beta} + Z\hat{\gamma} + \hat{u}$$

y multiplicar por M_Z :

$$M_Z y = M_Z X\hat{\beta} + M_Z Z\hat{\gamma} + M_Z \hat{u}$$

$$\tilde{y} = \tilde{X}\hat{\beta} + 0 * \hat{\gamma} + (I - P_Z) \hat{u} \quad (*)$$

$$\tilde{y} = \tilde{X}\hat{\beta} + 0 + I\hat{u} - P_Z \hat{u}$$

$$\tilde{y} = \tilde{X}\hat{\beta} + \hat{u} - 0 \quad (**)$$

$$\tilde{y} = \tilde{X}\hat{\beta} + \hat{u},$$

donde $M_Z \hat{u} = \hat{u}$ porque $P_Z \hat{u} = 0$.

$$(*) M_Z Z = (I - P_Z) Z$$

$$\begin{aligned}M_Z Z &= IZ - P_Z Z \\M_Z Z &= Z - Z(Z'Z)^{-1}Z'Z \\M_Z Z &= Z - ZI \\M_Z Z &= Z - Z \\M_Z Z &= 0.\end{aligned}$$

$$\begin{aligned}(**) P_Z \hat{u} &= P_Z My \\P_Z \hat{u} &= P_Z M_Z My \\P_Z \hat{u} &= 0 * My \quad (***) \\P_Z \hat{u} &= 0.\end{aligned}$$

$$\begin{aligned}(***) P_Z M_Z &= P_Z (I - P_Z) \\P_Z M_Z &= P_Z I - P_Z P_Z \\P_Z M_Z &= P_Z - P_Z \\P_Z M_Z &= 0.\end{aligned}$$

Otra forma es viendo que este resultado está considerando el siguiente argumento. Recordar que:

$$\begin{aligned}y &= \hat{y} + \hat{u} \\y &= Py + My \\y &= X\hat{\beta} + Z\hat{y} + My.\end{aligned} \quad (7)$$

Tener en cuenta que M es una matriz de proyección que usa $[X : Z]$. Aplicando fórmula particionada, se puede mostrar que $M = I - P_{xz} = I - [P_Z + M_Z X(X' M_Z X)^{-1} X' M_Z]$.

Si se multiplica (7) por M_Z , se tiene:

$$M_Z y = M_Z X\hat{\beta} + M_Z Z\hat{y} + M_Z My. \quad (8)$$

Por lo tanto, se necesita mostrar que $M_Z M = M$ o, en palabras, que los últimos términos en las ecuaciones (7) y (8) son iguales. Tener en cuenta que:

$$\begin{aligned}M_Z M &= (I - P_Z) (I - P_{xz}) \\M_Z M &= I - P_{xz} - P_Z + P_Z P_{xz} \\M_Z M &= I - P_{xz} - P_Z + P_Z [P_Z + M_Z X(X' M_Z X)^{-1} X' M_Z] \\M_Z M &= I - P_{xz} - P_Z + P_Z P_Z + P_Z M_Z X(X' M_Z X)^{-1} X' M_Z \\M_Z M &= I - P_{xz} - P_Z + P_Z + 0 * X(X' M_Z X)^{-1} X' M_Z \\M_Z M &= I - P_{xz} + 0 \\M_Z M &= I - P_{xz} \\M_Z M &= M,\end{aligned}$$

que da los resultados desde $My = Mu = \hat{u}$.

Notar también que, en el caso de $Z'X = 0$, los elementos “fuera de la diagonal” de la matriz inversa en la fórmula particionada son cero, entonces, $M = I - P_{xz} = I - (P_Z + P_x)$. De nuevo, se tiene que $P_Z (P_Z + P_x) = P_Z$ y el resultado continúa manteniéndose.

El teorema implica que las estimaciones MCO del parámetro de pendiente se pueden obtener de la siguiente manera:

1. Regresando y en Z y obteniendo los residuos $\tilde{y}$.
2. Regresando X en Z y obteniendo los residuos $\tilde{X}$.
3. Regresando $\tilde{y}$ en $\tilde{X}$ y obteniendo el estimador MCO $\hat{\beta}$.

Ejemplo 2. Considerar un modelo simple bivariado:

$$y = \gamma + \beta x_i + u_i,$$

donde, en este caso, $X = x_i$ y $Z = 1$. Antes de pasar a la aplicación del teorema FWL, se puede usar el método de momentos para derivar el estimador de pendiente. Nuestras suposiciones de modelo fueron:

- $E(u) = E(y - \gamma - \beta x) = 0$.
- $Cov(x, u) = E(xu) - E(x)E(u) = 0 - E(x) \cdot 0 = 0 - 0 = 0$.

Estas dos ecuaciones son restricciones impuestas a los datos sobre la distribución de probabilidad conjunta de x e y . Hay dos incógnitas y dos ecuaciones, lo que sugiere que se puede resolver por y . La muestra homóloga de estas ecuaciones es:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \gamma - \beta x_i) = 0. \quad (9)$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \gamma - \beta x_i)] = 0. \quad (10)$$

De la ecuación (9), se obtiene $\hat{\gamma} = \bar{y} - \hat{\beta} \bar{x}$ y, reemplazando en (10), se obtiene:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2,$$

lo que implica que el estimador para el parámetro es:

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (11)$$

Siguiendo el teorema de FWL, primero, se tienen que obtener los residuos en la regresión:

$$x_i = \alpha + \epsilon_i \quad \Rightarrow \quad \tilde{x}_i = x_i - \hat{\alpha} = x_i - \bar{x}.$$

Similarmente:

$$y_i = \delta + v_i \quad \Rightarrow \quad \tilde{y}_i = y_i - \hat{\delta} = y_i - \bar{y}.$$

Finalmente, se tienen que regresar los residuos de la variable de respuesta sobre los residuos de la variable de interés:

$$\tilde{y}_i = \pi \tilde{x}_i + \omega_i.$$

Resultando:

$$\begin{aligned}\hat{\pi} &= \frac{\sum_{i=1}^n \tilde{x}_i \tilde{y}_i}{\sum_{i=1}^n \tilde{x}_i^2} \\ \hat{\pi} &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \hat{\pi} &= \hat{\beta}.\end{aligned}\tag{12}$$

Se va a verificar, ahora, que los residuos en las dos ecuaciones son iguales, entonces, los errores estándar de $\hat{\beta}$ y $\hat{\pi}$ son iguales. Nuevamente, por definición:

$$y_i = \hat{\gamma} + \hat{\beta}x_i + \hat{u}_i\tag{13}$$

y

$$\tilde{y}_i = \hat{\pi}\tilde{x}_i + \hat{\omega}_i.\tag{14}$$

Se puede escribir la última ecuación como:

$$\begin{aligned}y_i - \bar{y} &= \hat{\pi}(x_i - \bar{x}) + \hat{\omega}_i \\ y_i - \bar{y} &= \hat{\beta}(x_i - \bar{x}) + \hat{\omega}_i \\ y_i &= \bar{y} + \hat{\beta}x_i - \hat{\beta}\bar{x} + \hat{\omega}_i \\ y_i &= (\bar{y} - \hat{\beta}\bar{x}) + \hat{\beta}x_i + \hat{\omega}_i \\ y_i &= \hat{\gamma} + \hat{\beta}x_i + \hat{\omega}_i,\end{aligned}$$

usando la definición de la intersección $\hat{\gamma}$ (recordar lo que se discutió en la Lectura 1). Notar que los valores ajustados son iguales y, por lo tanto, el residuo en la ecuación (13) es igual al residuo en la ecuación (14).

Ejemplo 3. Se supone que se quieren estimar los rendimientos de la educación teniendo en cuenta el siguiente modelo:

$$lw_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i,\tag{15}$$

donde lw_i es el registro de los salarios del i-ésimo trabajador y x_{1i} , x_{2i} y x_{3i} son el nivel de educación, los años de experiencia y los años con el empleador real del i-ésimo trabajador, respectivamente. La variable de interés es educación, por lo tanto, se puede reescribir el modelo usando nuestra notación anterior:

$$y = Z'\gamma + X\beta + u,$$

donde $y = (lw)$, $Z' = (x_2, x_3)$ y $X = (x_1)$.

Se usa el conjunto de datos de Wooldridge (2002) para estimar el modelo anterior. El conjunto de datos contiene observaciones para 500 individuos (la Figura 1 muestra la relación bivalente entre variables dependientes e independientes). El último gráfico muestra la pendiente obtenida usando parcelas residuales parciales. El retorno a la educación es del 9 por ciento con un error estándar de 0,0075.

5) Error de Especificación y Trade-Offs.

Bajo los supuestos clásicos, el estimador MCO es insesgado, $E(\hat{\beta}) = \beta$. Sin embargo, el estimador puede estar sesgado si se omite una variable en el modelo de regresión. La introducción de variables en el modelo para “corregir” el problema de sesgo no funciona porque la varianza de los estimadores de la versión “larga” del modelo (por ejemplo, el modelo que incluye la variable explicativa adicional) puede ser mayor que la varianza de los estimadores de la versión “corta” del modelo (por ejemplo, el modelo que no incluye la variable explicativa).

Bajo los supuestos discutidos hasta ahora, considerar:

$$y_i = x_i' \beta + z_i' \gamma + u_i.$$

$$y_i = x_i' b + v_i.$$

Tener en cuenta que la segunda ecuación proporciona una proyección de y en x_1 . En este caso, se tiene:

$$E(\hat{b}) = E[(x_i x_i')^{-1} x_i y_i]$$

$$E(\hat{b}) = E[(x_i x_i')^{-1} x_i (x_i' \beta + z_i' \gamma + u_i)]$$

$$E(\hat{b}) = E[(x_i x_i')^{-1} x_i x_i' \beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = E[\beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = E[\beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = E(\beta) + E[(x_i x_i')^{-1} x_i z_i' \gamma] + E[(x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i E(u_i)$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i * 0$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma + 0$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma,$$

lo que, obviamente, implica que la proyección en la segunda ecuación no identifica un coeficiente de interés β a menos que $x_i z_i' = 0$.

Se analiza, ahora, la disyuntiva que, a menudo, se enfrenta en la econometría aplicada cuando no se observan algunas variables independientes. Se supone, ahora, que el verdadero modelo es:

$$y = X\beta + Z\gamma + u, \tag{16}$$

pero, en cambio, se estima el modelo:

$$y = X\beta + \epsilon. \tag{17}$$

El estimador MCO del parámetro de interés β es:

$$\hat{\beta}_s = \arg \min \|y - X\beta\|^2$$

$$\hat{\beta}_s = (X'X)^{-1}X'y.$$

Podría estar sesgado si cualquier $\gamma \neq 0$ o si las variables independientes observables X y Z no son independientes:

$$E(\hat{\beta}_s) = \beta + (X'X)^{-1}X'Z\gamma$$

$$E(\hat{\beta}_s) = \beta + \Gamma\gamma,$$

donde $\Gamma = (X'X)^{-1}X'Z$. Tener en cuenta que Γ es el estimador de una regresión de Z en X .

Ejemplo 4. Se comienza a estudiar el efecto de sesgo al omitir una variable relevante en el modelo de regresión. Considerar que el verdadero modelo de población es:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u, \quad (18)$$

pero se obtienen estimadores MCO de un modelo similar:

$$y = \beta_0 + \beta_1 x_1 + u, \quad (19)$$

que excluye la variable relevante x_2 . Se supone que se está interesado en el parámetro de pendiente β_1 . En este caso:

$$E(\tilde{\beta}_1) = \beta_1 + \beta_2 \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)x_{i2}}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}$$

$$E(\tilde{\beta}_1) = \beta_1 + \beta_2 \tilde{\alpha}_1.$$

¿Cuál es la interpretación de $\tilde{\alpha}_1$? Tener en cuenta que, si se tiene un modelo de regresión simple de la forma:

$$x_2 = \alpha_0 + \alpha_1 x_1 + \epsilon,$$

y se obtiene el estimador MCO para el parámetro de pendiente α_1 , éste es igual a:

$$\tilde{\alpha}_1 = \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}.$$

Por lo tanto, el sesgo de variable omitida es:

$$E(\tilde{\beta}_1) - \beta_1 = \beta_2 \tilde{\alpha}_1. \quad (20)$$

El sesgo es cero si $\beta_2 = 0$, lo que significa que la variable independiente x_2 no tiene un efecto sobre la variable dependiente y , o si $\tilde{\alpha}_1 = 0$, lo que significa que las variables independientes x_1 y x_2 no están correlacionadas. Si $\beta_2 \approx 0$ o $\tilde{\alpha}_1 \approx 0$, el tamaño del sesgo sería pequeño y, por lo tanto, puede no ser motivo de preocupación.

Algunas veces, es posible inferir el signo del sesgo. Si el signo del parámetro desconocido β_2 es igual al signo de la correlación entre las variables independientes x_1 y x_2 , el sesgo es positivo. En este caso, se dice que $\tilde{\beta}_1$ tiene sesgo ascendente. Por otro lado, si el signo de β_2 es diferente al signo de la correlación entre las variables independientes, el sesgo es negativo. En este caso, se dice que $\tilde{\beta}_1$ tiene sesgo descendente.

Ejemplo 5. Tener en cuenta que y es el logaritmo de los salarios, x_1 indica años de educación y x_2 es la capacidad o “agallas” de algunos trabajadores. Se puede creer que β_2 es positivo y diferente de cero porque hay evidencia que sugiere que las personas con

más talento reciben salarios más altos. Por otro lado, se sospecha que $\text{Corr}(x_1, x_2) \neq 0$. La gente talentosa tiende a pasar más años en la escuela, por lo que se infiere que la relación entre educación y capacidad es positiva. En consecuencia, el sesgo puede ser positivo, por lo que puede ser el caso de la estimación MCO de β_1 .

Aunque $\hat{\beta}_s$ es sesgado, es eficiente en comparación con el estimador de β_1 del modelo largo:

$$\hat{\beta}_l = (X' M_z X)^{-1} X' M_z y.$$

Para ver esto, primero, se escribe el estimador a partir de un modelo corto como:

$$\begin{aligned}\hat{\beta}_s &= (X' X)^{-1} X' y \\ \hat{\beta}_s &= (X' X)^{-1} X' (\hat{y}_l + \hat{u}),\end{aligned}$$

donde $\hat{y}_l$ y $\hat{u}$ son los vectores de los valores ajustados y residuales del modelo largo. Así:

$$\begin{aligned}\hat{\beta}_s &= (X' X)^{-1} X' \hat{y}_l + (X' X)^{-1} X' \hat{u} \\ \hat{\beta}_s &= (X' X)^{-1} X' (X \hat{\beta}_l + Z \hat{\gamma}) + (X' X)^{-1} * 0 \\ \hat{\beta}_s &= (X' X)^{-1} X' X \hat{\beta}_l + (X' X)^{-1} X' Z \hat{\gamma} + 0 \\ \hat{\beta}_s &= I \hat{\beta}_l + \Gamma \hat{\gamma} \\ \hat{\beta}_s &= \hat{\beta}_l + \Gamma \hat{\gamma}.\end{aligned}$$

Por lo tanto, la varianza del estimador en el modelo largo es:

$$\begin{aligned}V(\hat{\beta}_l) &= V(\hat{\beta}_s - \Gamma \hat{\gamma}) \\ V(\hat{\beta}_l) &= V(\hat{\beta}_s) + \Gamma V(\hat{\gamma}) \Gamma', \\ (21)\end{aligned}$$

lo que implica que:

$$V(\hat{\beta}_l) \geq V(\hat{\beta}_s),$$

ya que el término cuadrático es semidefinido positivo. El resultado en la ecuación (21) se cumple si el término de covarianza (faltante) es cero. Se verifican las condiciones bajo las cuales la ecuación (21) se cumple en el siguiente teorema.

Teorema 3. $\text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) = 0$.

Prueba. Primero, recordar esto:

$$\begin{aligned}\hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x y \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x (X \beta + Z \gamma + u) \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x X \beta + (Z' M_x Z)^{-1} Z' M_x Z \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' * 0 * \beta + I \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= 0 + \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= \gamma + (Z' M_x Z)^{-1} Z' M_x u.\end{aligned}$$

Además, recordar que:

$$\begin{aligned}
\hat{\beta} &= (X'M_z X)^{-1} X' M_z y \\
\hat{\beta} &= (X'M_z X)^{-1} X' M_z (X\beta + Z\gamma + u) \\
\hat{\beta} &= (X'M_z X)^{-1} X' M_z X\beta + (X'M_z X)^{-1} X' M_z Z\gamma + (X'M_z X)^{-1} X' M_z u \\
\hat{\beta} &= I\beta + (X'M_z X)^{-1} X' * 0 * \gamma + (X'M_z X)^{-1} X' M_z u \\
\hat{\beta} &= \beta + 0 + (X'M_z X)^{-1} X' M_z u \\
\hat{\beta} &= \beta + (X'M_z X)^{-1} X' M_z u.
\end{aligned}$$

Por definición, se tiene esto:

$$\begin{aligned}
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [\hat{\beta}_s - E(\hat{\beta}_s)] [\Gamma\hat{\gamma} - E(\Gamma\hat{\gamma})]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [\Gamma\hat{\gamma} - \Gamma E(\hat{\gamma})]' \} \quad (*) \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [\Gamma(\hat{\gamma} - \gamma)]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [(\hat{\gamma} - \gamma)' \Gamma]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [(Z'M_x Z)^{-1} Z'M_x u]' \Gamma' \},
\end{aligned}$$

$$\begin{aligned}
(*) \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - E[\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - \{E(\beta) + E[(X'X)^{-1} X'Z\gamma] + E[(X'X)^{-1} X'u]\} \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X' E(u)] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X' * 0] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + 0] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= \beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u - \beta - (X'X)^{-1} X'Z\gamma \\
\hat{\beta}_s - E(\hat{\beta}_s) &= (X'X)^{-1} X'u.
\end{aligned}$$

reemplazando por definiciones. La última expresión se puede escribir como:

$$\begin{aligned}
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [u'M_x Z(Z'M_x Z)^{-1} \Gamma]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'uu'M_x Z(Z'M_x Z)^{-1} \Gamma]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' E(uu') M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' V(u) M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' \sigma^2 I M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' \sigma^2 M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= \sigma^2 (X'X)^{-1} X' M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= \sigma^2 (X'X)^{-1} * 0 * Z(Z'M_x Z)^{-1} \Gamma' \quad (**) \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= 0,
\end{aligned}$$

$$\begin{aligned}
(**) X'M_x &= X'(I - P_x) \\
X'M_x &= X'[I - X(X'X)^{-1}X'] \\
X'M_x &= X'I - X'X(X'X)^{-1}X' \\
X'M_x &= X' - IX' \\
X'M_x &= X' - X' \\
X'M_x &= 0.
\end{aligned}$$

porque $V(u) = \sigma^2 I$. Tener en cuenta que $M_x X = 0$, por lo tanto, la covarianza es igual a cero bajo homocedasticidad.

Ahora, se resumen los puntos principales. Ya que, en la economía aplicada, generalmente, las variables independientes están correlacionadas y hay variables que se omiten debido a que son difíciles de medir:

1. Omitir variables independientes introduce sesgo.
2. Agregar variables independientes “infla” la varianza.

Observación 2. Se supone, ahora, que se está interesado en el efecto de omitir una variable que está correlacionada con X_1 . Se supone, ahora, que hay una matriz de variables Z y se considera descomponer X como:

$$X\beta = X_1\beta_1 + X_2\beta_2$$

$$X\beta = P_Z X_1\beta_1 + M_Z X_1\beta_1 + X_2\beta_2.$$

Para $\gamma = 0$, se tiene esto:

$$X\beta = P_Z X_1 (\beta_1 + \gamma) + M_Z X_1\beta_1 + X_2\beta_2$$

$$X\beta = P_Z X_1\beta_1 + P_Z X_1\gamma + M_Z X_1\beta_1 + X_2\beta_2$$

$$X\beta = (P_Z + M_Z) X_1\beta_1 + X_2\beta_2 + P_Z X_1\gamma$$

$$X\beta = I X_1\beta_1 + X_2\beta_2 + P_Z X_1\gamma$$

$$X\beta = X_1\beta_1 + X_2\beta_2 + P_Z X_1\gamma.$$

Por lo tanto, ahora, se puede usar una prueba F con $H_0: \gamma = 0$ usando la siguiente regresión:

$$y = X\beta + \hat{X}_1\gamma + u.$$

Esto está relacionado con la versión de regresión auxiliar de la célebre prueba de Hausman (1978) [véase también Wu (1973)]. Tener en cuenta que, si reemplaza $\hat{X}_1$ por una matriz que contenga potencias de $\hat{y}$ (por ejemplo, $\hat{y}^2$, $\hat{y}^3$, etc.), se tiene la prueba de Ramsey para error de especificación.

6) Implicaciones Prácticas.

Si X y Z en la ecuación (16) no están correlacionados, entonces, no hay un sesgo de variable omitida y, si la LRP está especificada correctamente, el parámetro β_1 en (17) puede tener una interpretación causal. Sin embargo, los experimentos no son comunes, por lo que los investigadores se basan en variables de control para eliminar los sesgos.

Esto está conectado con lo que se conoce como el *supuesto de independencia condicional* o CIA [como en Angrist y Pischke (2009)]. Ésta es una condición que se quiere satisfacer para la estimación y para la inferencia y aquí está el por qué. Considerar un modelo simple bivariado:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$

donde β_1 es un parámetro o efecto causal constante. Por ejemplo, y_i es ganancias y x_i tiene un título universitario o un indicador de estado de veterano. El término de error ϵ_i captura otros factores que afectan las ganancias. Si:

$$\epsilon_i = \delta_0 + \delta_1 z_i + v_i,$$

donde z_i denota una variable “observable” o, simplemente, un vector de observables. Como se supone que v_i no está correlacionado con z_i , se tiene que $E(\epsilon_i | x_i) \neq 0$ pero $E(v_i | x_i, z_i) = 0$. Por lo tanto, se estima un modelo “aumentado” con control z_i :

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + v_i,$$

por MCO, obteniendo una estimación no sesgada de β_1 . Tener en cuenta que esto no sería posible si se usa MCO para estimar (17).

Ejemplo 6. El papel de las covariables se puede ver en la ilustración presentada en la Tabla 1. Se usan datos de la Seguridad Social y datos administrativos de Angrist (1998), que estudió el efecto del servicio militar voluntario sobre las ganancias de los soldados. Se utilizan trabajadores que solicitaron el servicio militar entre 1976 y 1981 y se estima el modelo antes del servicio militar y después (es decir, para los años 1974 y 1985, como se muestra en la tabla). El servicio militar voluntario, obviamente, no es aleatorio y, probablemente, esté correlacionado con la educación, la edad, los puntajes de las pruebas, los efectos de cohorte, etc. También se sabe que estos observables afectan las ganancias. Por lo tanto, es probable que la omisión de estas variables introduzca sesgos.

El punto es que, después de controlar todas estas diferencias “observables” (usando también interacciones), los veteranos y los no veteranos son comparables. Si no se cree en esta premisa, los resultados que se muestran en la Tabla 1 apuntan al hecho de que el modelo estimado sin controles arroja resultados que parecen engañosos.

Observación 3. Nos referimos a los controles como variables exógenas u observables, no a variables que están determinadas por la variable de interés. Estos controles no son, potencialmente, variables del lado derecho para otras ecuaciones (o variables endógenas en general). Por ejemplo, en la ecuación de Mincer:

$$\log(wage)_i = \beta_0 + \beta_1 educ_i + \alpha_i + u_i,$$

α_i mide la capacidad del trabajador i y no se observa (parte del término de error). Tiene sentido suponer que $Cov(\alpha_i, educ_i) \neq 0$. En el mundo de la CIA, es tentador incluir variables para satisfacer esta condición y, a veces, estas variables están disponibles para los profesionales. Por ejemplo, es posible que se tengan puntajes de prueba utilizados para evaluar a los solicitantes de empleo. El verdadero problema es que el rendimiento en la prueba, probablemente, se correlacione con la educación también.

Para simplificar, considerar que los puntajes de las pruebas se modelan como $score_i = \pi_0 + \pi_1 educ_i + \alpha_i + \epsilon_i$. Si se usan los puntajes de las pruebas como una variable de control, se estima:

$$\log(wage)_i = \gamma_0 + \gamma_1 educ_i + \gamma_2 score_i + v_i,$$

donde $\gamma_1 = \beta_1 - \pi_1 \neq \beta_1$. Angrist y Pischke (2009) llaman a estas variables, incluida la puntuación de la prueba utilizada en este ejemplo, “controles malos”.