

Lectura 3: **Teoría de Muestra Grande.**

Las suposiciones mantenidas, hasta ahora, han sido:

- A1: El modelo es lineal y está dado por $y_i = x_i' \beta + u_i$.
- A2: El rango de la matriz X es p .
- A3: El valor esperado condicional de y es igual a $E(y_i | X) = x_i' \beta$ para todos los sujetos i en la muestra de tamaño n .
- A4: La varianza condicional de y es igual a $V(y | X) = V(X\beta + u | X) = V(u) = \sigma^2 I$, donde $\sigma^2 > 0$ y I es la matriz identidad.

A menudo, se supone que $u_i \sim \mathcal{N}(0, 1)$, pero esta condición es muy fuerte. Se puede reemplazar por una condición más débil en los momentos de las variables aleatorias:

- A5: Las observaciones $\{(y_i, x_i); i = 1, 2, \dots, n\}$ están i.i.d. a través de i y sus cuartos momentos existen, es decir, $E(z_i^4) < \infty$ para una variable genérica z . También $E(x_i x_i')$ es una matriz no singular.

Se supone que y_i y x_i se distribuyen conjuntamente y su cuarto momento existe (por ejemplo, $E(z^4) < \infty$ para $z = \{x, y\}$). Una implicación es que el término de error u_i no necesita ser distribuido normalmente, pero su cuarto momento debería existir: $E(u^4) < \infty$.

1) Asintóticos como Herramienta.

Varios resultados obtenidos en econometría se basan en el supuesto de normalidad. Esto, ciertamente, no es una suposición leve y no se cumple en la práctica.

Asintótica es una herramienta que ayuda a aproximar la distribución de los estimadores o estadísticos de prueba sin asumir una distribución paramétrica, por supuesto siempre que el número de observaciones n (es decir, el tamaño de la muestra) es, suficientemente, “grande”. La mayoría de los métodos econométricos utilizados en economía aplicada funcionan bien cuando el tamaño de la muestra es grande. Además, a veces, es muy difícil obtener el error estándar de los estimadores no lineales en modelos lineales como en los ejemplos siguientes. Se usa una aproximación asintótica de la distribución del estimador, llamada “método delta” (ver el Lema 3.9 en Wooldridge 2010 y la Sección 5 a continuación).

Ejemplo 1. Considerar el modelo $y_t = x_t' \beta + u_t$, con t que denota el tiempo, y el interés está en estimar el parámetro de elasticidad, $\eta_j = \frac{\partial E(y | x)}{\partial x_j} \frac{x_j}{E(y | x)}$. Un estimador es:

$$\hat{\eta}_j = \hat{\beta}_j \frac{\bar{x}_j}{\bar{y}},$$

pero el error estándar de $\hat{\eta}_j$ es difícil de obtener porque $\hat{y}$ y $\bar{x}_j$ son variables aleatorias. Se puede aplicar el método delta y obtener el error estándar de $\hat{\eta}_j$. (Se necesita aplicar la regla de la cadena desde $\beta_j \frac{x_j}{x' \beta}$).

Ejemplo 2. Considerar un modelo dinámico de la forma, $y_t = \gamma y_{t-1} + x_t' \beta + u_t$, con variables en logaritmos. La elasticidad a largo plazo de un cambio en x_j es, en este caso, $\eta_j = \frac{\beta_j}{1-\gamma}$. De nuevo, el estimador no es lineal en los parámetros:

$$\hat{\eta}_j = \frac{\hat{\beta}_j}{1-\hat{\gamma}},$$

entonces, el error estándar de $\hat{\eta}_j$ se puede obtener aplicando el método delta.

2) Antecedentes.

2.1) Resultados de muestra grande.

Considerar la secuencia de variables aleatorias $\{X_n: n=1, 2, \dots\}$ y que X sea una variable aleatoria de valor real en un espacio de probabilidad bien definido.

Definición 1 (Convergencia en probabilidad). Se dice que X_n converge en probabilidad a X si:

$$P(|X_n - X| > \epsilon) \rightarrow 0, \quad \text{cuando } n \rightarrow \infty, \quad (1)$$

para todo $\epsilon > 0$.

Intuitivamente, la probabilidad de que la diferencia $|X_n - X|$ tome un valor grande es muy pequeña a medida que aumenta el tamaño de la muestra n . Si $X_n \rightarrow \beta$, donde β es una constante, se dice que X_n es consistente y, a menudo, se denota por $\text{plim}_{n \rightarrow \infty} X_n = \beta$.

¿Por qué los conceptos de convergencia son importantes? Se necesita una noción de “cercanía” a parámetros desconocidos. Recordar que se tiene una muestra aleatoria i.i.d. (distribuida de forma independiente e idéntica) $X_1, X_2, \dots$, con realizaciones $x_1, x_2, \dots$. La distribución conjunta puede obtenerse multiplicando la distribución marginal. Se supone también que se está interesado en dos parámetros, la media poblacional $E(X) = \mu$ y la varianza poblacional $\text{Var}(X) = \sigma^2$. Se pueden estimar con:

$$\begin{aligned} \bar{X}_n &= T_x(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i. \\ S^2 &= T_s(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2. \end{aligned}$$

¿Cuán “cercano” es $\bar{X}_n$ a μ y S^2 a σ^2 . Si el tamaño de la muestra es, suficientemente, grande, se espera que $(\bar{X}_n, S^2)$ esté cerca de (μ, σ^2) . Ahora, se supone que se tiene un experimento aleatorio y se obtienen resultados básicos s del espacio muestral S . Se observa $x_i = X_i(s)$ y se puede obtener:

$$\bar{x}_n = \bar{X}_n(s). \quad (2)$$

Tener en cuenta que los diferentes resultados crearán diferentes números reales $\{\bar{x}_n = \bar{X}_n(s): n = 1, 2, \dots\}$. La Figura 1 ilustra el rendimiento de $\bar{X}_n(s)$ y $S^2(s)$ para tres resultados diferentes s_1, s_2 y s_3 de S .

Ejemplo 3. Se supone que $Y_1, Y_2, \dots, Y_n$ es una muestra aleatoria i.i.d. de una distribución uniforme $U(0, \theta)$, donde θ es un parámetro desconocido. Es natural estimar θ considerando el estadístico de orden más grande, es decir, $X_n = \max_{1 \leq i \leq n} \{Y_i\}$. ¿Este estimador es consistente? Tener en cuenta que, para una pequeña constante $\epsilon > 0$, se tiene que $\{|X_n - \theta| > \epsilon\} = \{X_n - \theta > \epsilon\} \cup \{X_n - \theta < -\epsilon\}$. Por lo tanto:

$$\begin{aligned} P(|X_n - \theta| > \epsilon) &= P(X_n - \theta > \epsilon) + P(X_n - \theta < -\epsilon) \\ P(|X_n - \theta| > \epsilon) &= P(X_n > \theta + \epsilon) + P(X_n < \theta - \epsilon) \\ P(|X_n - \theta| > \epsilon) &= 0 + P(\max_{1 \leq i \leq n} \{Y_i\} < \theta - \epsilon) \\ P(|X_n - \theta| > \epsilon) &= P(Y_1 < \theta - \epsilon, Y_2 < \theta - \epsilon, \dots, Y_n < \theta - \epsilon) \\ P(|X_n - \theta| > \epsilon) &= P(Y_1 < \theta - \epsilon) P(Y_2 < \theta - \epsilon) \dots P(Y_n < \theta - \epsilon) \\ P(|X_n - \theta| > \epsilon) &= \prod_{i=1}^n P(Y_i < \theta - \epsilon) \\ P(|X_n - \theta| > \epsilon) &= \left(\frac{\theta - \epsilon}{\theta}\right)^n \\ P(|X_n - \theta| > \epsilon) &= \left(1 - \frac{\epsilon}{\theta}\right)^n \rightarrow 0, \quad \text{cuando } n \rightarrow \infty. \end{aligned}$$

Definición 2 (Convergencia casi segura). Se dice que X_n converge con probabilidad 1, o casi seguramente, a X si:

$$P(\lim_{n \rightarrow \infty} X_n = X) = 1. \quad (3)$$

Definición 3 (Convergencia en media q^{th}). Se dice que X_n converge en media q^{th} a X si:

$$\lim_{n \rightarrow \infty} E |X_n - X|^q = 0. \quad (4)$$

Definición 4 (Convergencia en distribución). Se dice que X_n converge en distribución a X si:

$$\lim_{n \rightarrow \infty} F_n(X) = F(X). \quad (5)$$

En cada punto de continuidad de F , se denota esto como $X_n \rightarrow^d X$.

Teorema 1. Si $X_n \xrightarrow{como} X_1$, entonces, $X_n \xrightarrow{p} X$, que dice que la convergencia casi segura implica convergencia en probabilidad.

Teorema 2. Si $X_n \xrightarrow{rth} X$, entonces, $X_n \xrightarrow{p} X$.

Prueba.

$$E |X_n - X|^r \geq E \{|X_n - X|^r I(|X_n - X|^r > \epsilon)\} \geq \epsilon^r P(|X_n - X| > \epsilon). \quad (6)$$

$$P(|X_n - X| > \epsilon) \leq \epsilon^{-r} E |X_n - X|^r \rightarrow 0, \quad \text{cuando } n \rightarrow \infty. \quad (7)$$

Corolario 1. La convergencia en probabilidad $X_n \xrightarrow{p} X$ implica la convergencia en distribución $X_n \rightarrow^d X$.

Corolario 2. La convergencia en probabilidad a una constante es equivalente a la convergencia en distribución a una constante dada.

Teorema 3 (Equivalencia asintótica). Considerar una muestra aleatoria (Y_n, X_n) con $Y_n \rightarrow^d y$ y $|Z_n| \rightarrow^p 0$, donde $Z_n = Y_n - X_n$. Se deduce que $X_n \rightarrow^d y$.

Prueba. Para $\epsilon > 0$, se puede escribir $P(X_n < v) = P(Y_n < v + Z_n) = P(Y_n < v + Z_n, Z_n < \epsilon) + P(Y_n < v + Z_n, Z_n \geq \epsilon)$. Tener en cuenta también que $P(Y_n < v + Z_n, Z_n < \epsilon) \leq P(Y_n < v + \epsilon)$. Entonces, se deduce que:

$$\begin{aligned} P(X_n < v) &\leq P(Y_n < v + \epsilon) + P(Y_n < v + Z_n, Z_n \geq \epsilon) \\ P(X_n < v) &\leq P(Y_n < v + \epsilon) + [P(Z_n \geq \epsilon) P(Y_n < v + Z_n, Z_n \geq \epsilon)] \\ P(X_n < v) &\leq P(Y_n < v + \epsilon) + P(Z_n \geq \epsilon). \end{aligned}$$

Tener en cuenta que se puede escribir, de manera similar, $P(X_n < v) = P(Y_n < v + Z_n) = P(Y_n < v + Z_n, Z_n > -\epsilon) + P(Y_n < v + Z_n, Z_n \leq -\epsilon)$, lo que lleva a:

$$P(X_n < v) \geq P(Y_n < v - \epsilon) + P(Z_n \leq -\epsilon).$$

Suponiendo que $|Z_n| \rightarrow^p 0$, el último término tiende a 0 cuando $n \rightarrow \infty$, por lo que puede ser ignorado. Se puede escribir:

$$P(Y_n < v - \epsilon) \leq P(X_n < v) \leq P(Y_n < v + \epsilon).$$

Al elegir ϵ , arbitrariamente, pequeño, se tiene que $F_X = F_Y$ cuando $n \rightarrow \infty$.

Se puede interpretar este resultado como que muestra la equivalencia asintótica cuando dos variables aleatorias están muy cerca la una de la otra. Como ejemplo ilustrativo, considerar $Y_n = \sqrt{n} \frac{\bar{X}_n}{S_n}$ y $Z_n = \sqrt{n} \frac{\bar{X}_n}{\sigma}$, donde σ es un parámetro desconocido. Tratar con un denominador aleatorio S_n es complicado, pero, primero, se puede mostrar que $Y_n - Z_n \rightarrow^p 0$ y, luego, obtener la distribución de Y_n usando el resultado que $Y_n \rightarrow^d Z$.

Teorema 4 (Slutsky). Se tiene $X_n \rightarrow^d x$ y $Y_n \rightarrow y$, una constante real. Entonces:

1. $X_n + Y_n \rightarrow^d x + y$.
2. $X_n Y_n \rightarrow^d yx$.
3. $\frac{X_n}{Y_n} \rightarrow^d \frac{x}{c}$ si $c \neq 0$.

Teorema 5 (Mapeo continuo). Si $X_n \rightarrow^d X$ y g es continua, $g(X_n) \rightarrow^d g(X)$.

Ejemplo 4. Si $X_n \rightarrow^d \mathcal{N}(0, 1)$, entonces, $X_n^2 \rightarrow^d \chi_1^2$.

Ejemplo 5. Si $(X_n, Y_n) \rightarrow^d \mathcal{N}(0, I_2)$, entonces, $\frac{X_n}{Y_n} \rightarrow^d z$, una variable aleatoria de Cauchy.

Ejemplo 6. Cuando g no es continuo, es posible que se tenga que tener cuidado. Considerar el siguiente ejemplo:

$$g(t) = \begin{cases} t - 1, & t \leq 0 \\ t + 1, & t > 0 \end{cases}$$

Se tiene $X_n = \frac{1}{n}$, luego, $X_n \rightarrow X = 0$, $g(X_n) \rightarrow 1$, pero $g(X) = -1$.

2.2) Relaciones de orden y tasas de convergencia.

Ahora, se examinan las relaciones de orden y las tasas de convergencia. En esta sección, los términos $O(\cdot)$ (“o grande”) y $o(\cdot)$ (“o pequeña”) se usan para determinar el orden de magnitud de las secuencias determinísticas y estocásticas.

Considerar las secuencias deterministas positivas $\{a_n\}$ y $\{b_n\}$.

Definición 5. $a_n = o(b_n)$ cuando $n \rightarrow \infty$ si $\frac{a_n}{b_n} \rightarrow 0$.

Quizás, ahora, sea bueno tener una definición más completa.

Definición 6 (Órdenes de magnitud). Una secuencia $\{a_n\}$ es de un orden más pequeño que n^λ , que es denotado por $a_n = o(n^\lambda)$ o $n^{-\lambda}a_n = o(1)$, si, para $n \geq N$, se tiene que:

$$|n^{-\lambda}a_n| < \epsilon,$$

para $\epsilon > 0$.

Definición 7 (Órdenes de magnitud). Una secuencia $\{b_n\}$ es de un orden mayor que n^λ , que es denotado por $b_n = O(n^\lambda)$ o $n^{-\lambda}b_n = O(1)$, si, para $n \geq N$, se tiene que:

$$|n^{-\lambda}a_n| < K,$$

donde $K < \infty$ es un número real muy grande.

Observación 1. Si a_n y b_n tiende a infinito, esto indica que a_n tiende a infinito más lentamente que b_n . Si a_n y b_n tiende a cero, esto indica que a_n tiende a cero más rápido que b_n .

Ejemplo 7. $\frac{1}{n^2} = o(\frac{1}{n})$ cuando $n \rightarrow \infty$, porque $\frac{\frac{1}{n^2}}{\frac{1}{n}} = \frac{n}{n^2} = \frac{1}{n} \rightarrow 0$.

Observación 2. Hace una gran diferencia si una secuencia tiende a cero a velocidad $\frac{1}{n^2}$ o $\frac{1}{n}$.

Suponer:

$$a_n = \frac{1}{n} - \frac{2}{n^2} + \frac{4}{n^3}. \quad (8)$$

Se va a aproximar a_n por $b_n = \frac{1}{n}$. Por lo tanto:

$$a_n = \frac{1}{n} + R_n = \frac{1}{n} + o\left(\frac{1}{n}\right), \quad (9)$$

donde $R_n = \frac{2}{n^2} + \frac{4}{n^3} = o\left(\frac{1}{n}\right)$. O, si se aproxima a_n por $\frac{1}{n} - \frac{2}{n^2}$, se escribe:

$$a_n = \frac{1}{n} - \frac{2}{n^2} + o\left(\frac{1}{n^2}\right). \quad (10)$$

Lema 1.

- (a) $a_n = o(1)$ si $a_n \rightarrow 0$.
- (b) Si $a_n = o(b_n)$ y $b_n = o(c_n)$, entonces, $a_n = o(c_n)$.
- (c) Para cualquier constante $c \neq 0$, $a_n = o(b_n)$ implica que $ca_n = o(b_n)$.
- (d) Para cualquier secuencia de números $c_n \neq 0$, $a_n = o(b_n)$ implica que $c_n a_n = o(c_n b_n)$.
- (e) Si $d_n = o(b_n)$ y $e_n = o(c_n)$, entonces, $d_n e_n = o(b_n c_n)$.

Ejemplo 8. Sea $a_n = \log n$ y $b_n = n^k$. Entonces:

$$a_n = o(b_n) \text{ para cada } k > 0. \quad (11)$$

Definición 8. Si a_n es de orden n menor o igual a b_n , se dice que:

$$a_n = O(b_n). \quad (12)$$

Si hay un $\Delta < \infty$, tal que $\frac{a_n}{b_n} \leq \Delta$ para n suficientemente grande, se dice que $a_n = O(b_n)$. Tener en cuenta que, en particular, $a_n = O(1)$ si la secuencia a_n está limitada.

Lema 2. Si $a_n = O(n^r)$ y $b_n = O(n^s)$, entonces:

- (a) $a_n b_n = O(n^{r+s})$.
- (b) $a_n + b_n = O(n^{\max\{r,s\}})$.

Los términos $O_p(\cdot)$ ("oh grande") y $o_p(\cdot)$ (oh chica) son para secuencias estocásticas. Intuitivamente, se puede decir que una secuencia $\{X_n: n = 1, 2, \dots\}$ es de un orden de magnitud menor que n^λ si converge en probabilidad $\frac{X_n}{n^\lambda} \rightarrow 0$ cuando $n \rightarrow \infty$. Se denota por $X_n = O_p(n^\lambda)$.

De manera similar, se puede decir que una secuencia $\{X_n: n = 1, 2, \dots\}$ es, a lo sumo, de orden de magnitud n^λ si $P\left(\left|\frac{X_n}{n^\lambda}\right| > M\right) < \delta$, donde $\delta > 0$. Se denota por $X_n = O_p(n^\lambda)$ e implica que X_n está limitada en probabilidad.

Ahora, considerar las secuencias $\{X_n\}$ y $\{Y_n\}$ en el espacio de probabilidad (Ω, A, P) y cualquier $\epsilon > 0$.

Definición 9.

- (a) Si $\exists \Delta < \infty$ tal que $P(|X_n| \geq \Delta |Y_n|) < \epsilon$, para n lo suficientemente grande, se escribe:

$$X_n = O_p(Y_n). \quad (13)$$

Si Y_n no es estocástico, se dice que X_n está limitada en probabilidad y $X_n = O_p(1)$.

(b) Si $P(|X_n| \geq \epsilon |X_n|) \rightarrow 0$, se escribe $X_n = O_p(Y_n)$. Se dice que está tendiendo a cero en probabilidad, es decir:

$$\frac{X_n}{Y_n} \rightarrow 0. \quad (14)$$

3) Unos cuantos LGNs y TLCs.

La ley de los grandes números (LGN) y el teorema del límite central (TLC) desempeñan un papel clave en la econometría. Para una extensa discusión, ver White (2000) y Davidson (1994). En esta sección, se repasarán algunos resultados con particular énfasis en las variaciones relacionadas con la distribución de una secuencia de variables aleatorias.

Teorema 6 (Khinchine LGN). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu$. Entonces:

$$\hat{X} = \frac{1}{n} \sum_{i=1}^n X_i - \mu \rightarrow^p 0. \quad (15)$$

Teorema 7 (Chebyshev LGN). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu_i$ y $\text{Var}(X_i) = \sigma_i^2$. Si $n^{-1} \sum_{i=1}^n \sigma_i^2 \leq K < \infty$ cuando $n \rightarrow \infty$, entonces:

$$\hat{X}_n - \mu_n = \frac{1}{n} \sum_{i=1}^n \mu_i \rightarrow^p 0. \quad (16)$$

Teorema 8 (Kolmogorov LGN). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu_i$ y $\text{Var}(X_i) = \sigma_i^2$. Si $n^{-1} \sum_{i=1}^n \sigma_i^2 < \infty$ cuando $n \rightarrow \infty$, entonces, $\bar{X}_n - \mu_n \rightarrow 0$ con probabilidad 1.

La literatura sobre TCL es extensa, por lo que sólo se discutirán algunos resultados.

Teorema 9 (Lindberg-Levy TLC). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2$. Entonces:

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \rightarrow^d \mathcal{N}(0, 1).$$

Teorema 10. Sea $\{X_i\}$ una secuencia de variables aleatorias independientes con $E(X_i) = \mu_i$, $\text{Var}(X_i) = \sigma_i^2$ y $E(|X_i - \mu_i|^{2+\delta}) < \infty$ para algunos $\delta > 0$. Si $\lim_{n \rightarrow \infty} n^{-1} \sum_{i=1}^n \sigma_i^2 < \infty$, entonces:

$$\frac{\sqrt{n}(\bar{X}_n - \bar{\mu}_n)}{\bar{\sigma}_n} \rightarrow^d \mathcal{N}(0, 1). \quad (18)$$

4) La Teoría Asintótica de MCO.

4.1) Consistencia.

Definición 10. Un estimador consistente $\hat{\theta}$ es uno que converge a θ_0 en probabilidad:

$$\hat{\theta} \rightarrow \theta_0 \quad (19)$$

a medida que el tamaño de la muestra n va al infinito, para todos los valores verdaderos posibles. Con esta definición en mente, ahora, se investiga la consistencia de MCO en el ajuste concebible más simple. Considerar un modelo de regresión lineal de la forma:

$$y_i = x_i' \beta + u_i, \quad (20)$$

donde $E(u_i | x_i) = E(u_i) = 0$. Se puede asumir, provisionalmente, que los términos de error u están i.i.d. aleatoriamente con distribución F . El estimador MCO para el parámetro desconocido β es $\hat{\beta} = (X'X)^{-1}X'y$ y puede ser escrito como:

$$\begin{aligned} \hat{\beta} - \beta &= (X'X)^{-1}X'u \\ \hat{\beta} - \beta &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right), \end{aligned} \quad (22)$$

donde X es una matriz de $(n \times p)$ y u es un vector de $(n \times 1)$. Si las x_i son consideradas fijas o no estocásticas, se tiene que el primer término del lado derecho de la ecuación:

$$\frac{1}{n} \sum_{i=1}^n x_i x_i' \rightarrow Q_0$$

y

$$\frac{1}{n} \sum_{i=1}^n x_i u_i \rightarrow 0.$$

Notar que:

$$E\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) = 0, \quad (23)$$

porque $E(u_i | x_i) = 0$ y los u_i son independientes. Además:

$$\begin{aligned} \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n x_i u_i\right) \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(x_i u_i) \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \sum_{i=1}^n x_i \text{Var}(u_i) x_i' \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \sum_{i=1}^n x_i \sigma^2 x_i' \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{\sigma^2}{n^2} \sum_{i=1}^n x_i x_i' \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{\sigma^2}{n} \frac{1}{n} \sum_{i=1}^n x_i x_i' \rightarrow 0 * E(X'X) \rightarrow 0. \end{aligned} \quad (26)$$

Entonces:

$$\hat{\beta} \rightarrow \beta, \quad (27)$$

siguiendo con una simple aplicación de Chebyshev y el teorema de Slutsky (el caso de las x estocásticas requiere el uso de LGN, pero el argumento es similar).

Observación 3 (Inconsistencia 1). Tener en cuenta que, si $x_i = i$ en un modelo sin interceptación y $p = 1$, entonces:

$$\hat{\beta} - \beta = \left(\frac{1}{n} \sum_{i=1}^n i^2 \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n i u_i \right).$$

Es, inmediatamente, evidente que:

$$\frac{1}{n} \sum_{i=1}^n i^2,$$

no converge a una constante (Q_0 como antes) y la inversa no existe. Tener en cuenta que dividir por n^2 tampoco funcionará. Sin embargo, si:

$$n (\hat{\beta} - \beta) = \left(\frac{1}{n^3} \sum_{i=1}^n i^2 \right)^{-1} \left(\frac{1}{n^2} \sum_{i=1}^n i u_i \right),$$

el primer término en el lado derecho converge a $\frac{1}{3}$ cuando $n \rightarrow \infty$ y la varianza del último término converge a cero.

Observación 4 (Súper consistencia). El estimador súper consistente es:

$$n (\hat{\beta} - \beta) = O_p n^{-\frac{3}{2}},$$

mientras que el estimador MCO estándar cuando u_i no es una tendencia determinista es:

$$n (\hat{\beta} - \beta) = O_p n^{-\frac{1}{2}}.$$

Observación 5 (Inconsistencia 2). Si la ecuación principal omite una variable, dígame la variable v_i , entonces:

$$\hat{\beta} - \beta = \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \left[\frac{1}{n} \sum_{i=1}^n x_i (v_i + u_i) \right].$$

Siguiendo los pasos anteriores, se tiene:

$$\hat{\beta} - \beta \rightarrow Q_0^{-1} Q_{xv} \neq 0,$$

donde Q_{xv} es la matriz de covarianza de x_i y v_i , que no es cero si las variables están correlacionadas.

4.2) Normalidad asintótica.

Considerar (de nuevo) un modelo de regresión lineal:

$$y_i = x_i' \beta + u_i. \quad (28)$$

Recordar que $\hat{\beta} - \beta = (X'X)^{-1} X'u$. Se puede escribir:

$$\begin{aligned} \sqrt{n} (\hat{\beta} - \beta) &= \left(\frac{X'X}{n} \right)^{-1} \frac{1}{\sqrt{n}} X'u \\ \sqrt{n} (\hat{\beta} - \beta) &= n \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \frac{1}{\sqrt{n}} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i \right) \\ \sqrt{n} (\hat{\beta} - \beta) &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \right). \end{aligned}$$

Si se aplica el Corolario 1, se tiene que:

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \rightarrow^d \mathcal{N}(0, \sigma^2 Q_0). \quad (29)$$

Por el teorema de Slutsky, se tiene que:

$$\sqrt{n} (\hat{\beta} - \beta) \rightarrow^d Q_0^{-1} \mathcal{N}(0, \sigma^2 Q_0) = \mathcal{N}(0, \sigma^2 Q_0^{-1}). \quad (30)$$

Tener en cuenta que se aplica, de nuevo, el teorema de Slutsky. En resumen, la normalidad asintótica se deriva de (i) la convergencia en distribución de la puntuación, (ii) la convergencia en probabilidad del Hessiano y (iii) el teorema de Slutsky.

Observación 6 (Inconsistencia 2). La clave para los resultados obtenidos antes es el hecho de que:

$$\begin{aligned} S &= E(x_i x_i' u_i^2) \\ S &= E[E(x_i x_i' u_i^2 | x_i)] \\ S &= E[x_i x_i' E(u_i^2 | x_i)] \\ S &= E(x_i x_i' \sigma^2) \\ S &= \sigma^2 E(x_i x_i') \\ S &= \sigma^2 Q_0 \end{aligned}$$

y, si $E(u_i^2 | x_i) \neq \sigma^2$, no se pueden simplificar las expresiones como en los últimos pasos.

5) El Modelo Delta.

Para el método, el primer resultado que se necesita es la consistencia: si la función g es agradable y lisa, entonces, $g(\hat{\theta}) \rightarrow g(\theta)$. Asumiendo que $\hat{\theta}$ es consistente y asintóticamente normal con varianza Ω y que $g(\cdot)$ es suave:

$$\sqrt{n} [g(\hat{\theta}) - g(\theta)] \rightsquigarrow \mathcal{N}(0, G' \Omega G),$$

donde:

$$G = \nabla_{\theta} g(\theta) \big|_{\hat{\theta}=\theta} = \begin{bmatrix} \frac{\partial g(\theta)}{\partial \theta_1} \\ \frac{\partial g(\theta)}{\partial \theta_2} \\ \vdots \\ \frac{\partial g(\theta)}{\partial \theta_p} \end{bmatrix}.$$

¿Por qué? Porque la expansión de Taylor reclamará que, para $g(\theta)$ alrededor de $\hat{\theta} = \theta$:

$$g(\hat{\theta}) = g(\theta) + (\hat{\theta} - \theta) \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta} + (\theta^* - \hat{\theta})' \nabla_{\theta}^2 g(\hat{\theta}) \big|_{\hat{\theta}=\theta} (\theta^* - \hat{\theta}),$$

donde $\theta_j^* \in (\hat{\theta}_j, \theta_j)$, $\forall j$. Notar que, si el estimador $\hat{\theta}$ es consistente, entonces, el término de segundo orden desaparece asintóticamente porque:

$$\hat{\theta}_i \rightarrow \theta_j \Rightarrow \theta_i^* \rightarrow \theta_j, \forall j.$$

Por lo tanto, asintóticamente, se tiene que:

$$\begin{aligned} V[g(\hat{\theta})] &= V[g(\theta) + (\hat{\theta} - \theta) \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] \\ V[g(\hat{\theta})] &= V[g(\theta) + \hat{\theta} \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta} - \theta \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] \\ V[g(\hat{\theta})] &= V[g(\theta)] + V[(\hat{\theta} \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta})] + V[-\theta \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] \\ V[g(\hat{\theta})] &= 0 + V[\hat{\theta} \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] + 0 \\ V[g(\hat{\theta})] &= (\nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta})' V(\hat{\theta}) (\nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}). \end{aligned}$$

6) Introducción a los Procesos Empíricos.

En la econometría moderna, la convergencia punto a punto es, a veces, demasiado débil para mostrar que el estimador $\hat{\theta}$ es consistente para θ . Se usa un concepto que está relacionado con la convergencia “funcional” o la convergencia uniforme de funciones de criterio. En esta sección, se presentará una introducción a algunos resultados que se utilizan con frecuencia.

6.1) Antecedentes y definiciones.

Considerar $X_1, \dots, X_n$ estando i.i.d. con distribución F definida F_n como una función aleatoria.

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{(-\infty, x)}(X_i),$$

para $X \in \mathbb{R}$. Recordar que, para una x fija, $F_n(x) \rightarrow F(X)$ por LGN y:

$$Z_n(x) = \sqrt{n} [F_n(x) - F(x)] \rightarrow Z \sim \mathcal{N}(0, 1).$$

Los resultados de convergencia uniformes más generales en el proceso empírico son:

Teorema 11 [Glivenko - Cantelli (1993)].

$$\|F_n - F\|_{\infty} = \sup_x |F_n(x) - F(x)| \rightarrow 0.$$

6.1.1) Estimadores M (y Z).

Un método popular para encontrar estimadores es maximizar una función de criterio del tipo:

$$M_n(\theta) = \frac{1}{n} \sum_{i=1}^n m_\theta(X_i).$$

Para funciones conocidas $m_\theta: \mathcal{X} \rightarrow \mathbb{R}$. Por ejemplo, $m_\theta(x_i) = (x - \theta)^2$, $m_\theta(x_i) = |x - \theta|$ o $m_\theta = -\log P_\theta$. Considerar las siguientes definiciones:

$$\theta_0 = \arg \max_{\theta \in \Theta} M(\theta).$$

$$\theta_n = \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n m_\theta(X_i) = \arg \max_{\theta \in \Theta} M_n(\theta).$$

Otra forma de pensar este problema es considerar encontrar la solución de:

$$\psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n m'_\theta(X_i) = \frac{1}{n} \sum_{i=1}^n \psi_\theta(X_i) = 0.$$

La solución de esta ecuación de estimación es $\hat{\theta}$, se llaman estimadores Z. Sin embargo, tener en cuenta que las ecuaciones de estimación pueden no necesitar corresponder a un problema de maximización.

6.2) Consistencia uniforme.

Ahora, se investiga la consistencia para los estimadores M. Siendo $\hat{\theta}_n$ un estimador de θ . Se llama asintóticamente consistente si la secuencia $\hat{\theta}_n$ converge en probabilidad para θ para cada valor posible de θ [por ejemplo, $\bar{X}$ para la población media $E(X)$].

Sea d un espacio métrico que incluya el conjunto de parámetros posibles. Se quiere demostrar que $d(\hat{\theta}_n, \theta_0) \rightarrow 0$.

El punto básico de la cuestión de la convergencia punto a punto versus a funcional es que, aunque:

$$M_n(\theta) \rightarrow M(\theta) \text{ para todo } \theta$$

y

$$\arg \max M_n(\theta) \rightarrow \arg \max M(\theta),$$

no se puede asegurar la convergencia de $\hat{\theta}_n$. Se necesita una convergencia “funcional” de M_n a M , para reforzar la convergencia punto a punto. Se usa, comúnmente, la noción de convergencia uniforme de las funciones de criterio.

Considerar un estimador $\hat{\theta}_n$ que casi maximiza M_n :

$$M_n(\hat{\theta}_n) \geq \sup_{\theta \in \Theta} M_n(\theta) - o_p(1),$$

que, por supuesto, implica que:

$$M_n(\hat{\theta}) \geq M_n(\theta_0) - o_p(1).$$

Teorema 12. Para $\epsilon > 0$,

1. $\sup |M_n(\theta) - M(\theta)| \rightarrow 0$.
2. $\sup_{\theta: d(\theta, \theta_0) \geq \epsilon} M(\theta) < M(\theta_0)$.

Entonces:

$$\hat{\theta}_n \rightarrow \theta_0.$$

Prueba. Considerar que $\hat{\theta}_n$ satisface $M_n(\hat{\theta}_n) \geq M_n(\theta_0) - o_p(1)$. Por la convergencia uniforme de M_n a M por la Suposición 1, se tiene que $M_n(\hat{\theta}_n) \geq M(\theta_0) - o_p(1)$. Entonces:

$$M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \geq M(\theta_0) - M(\hat{\theta}_n) + o_p(1)$$

$$\sup_{\theta} |M_n(\hat{\theta}) - M(\theta)| \geq M(\theta_0) - M(\hat{\theta}_n) + o_p(1).$$

Por lo tanto:

$$M(\theta_0) - M(\hat{\theta}_n) \leq \sup_{\theta} |M_n(\hat{\theta}) - M(\theta)| + o_p(1) \rightarrow 0.$$

Para cada θ , se tiene, por la Suposición 2, que:

$$M(\theta) < M(\theta_0) - \eta.$$

Por lo tanto, el evento $\{d(\hat{\theta}_n, \theta) \geq \epsilon\}$ está contenido en el evento $\{M(\hat{\theta}_n) < M(\theta_0) - \eta\}$. Se puede escribir:

$$P[d(\hat{\theta}_n, \theta) \geq \epsilon] \leq P[M(\hat{\theta}_n) - M(\theta_0) > \eta] \rightarrow 0,$$

cuando $n \rightarrow \infty$.

Observación 7. La convergencia uniforme de $M_n(\theta)$ requerida por la condición estocástica es equivalente al conjunto de funciones $\{m_{\theta}: \theta \in \Theta\}$ siendo Glivenko, Cantelli. Un conjunto simple de condiciones suficientes es Θ compacto, m_{θ} continuo para cada x y la función está dominada por una función integrable.

6.3) Normalidad asintótica.

Sin perder la generalidad, se consideran, ahora, los estimadores Z en lugar de los estimadores M . Siendo una muestra simple $X_1, \dots, X_n$ de una distribución P y dejando que la función del criterio “verdadero” sea de la forma:

$$\psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n \psi_{\theta}(X_i)$$

$$\psi(\theta) = E(\psi_{\theta}).$$

Se supone que $\hat{\theta}_n$ es cero de ψ_n y converge en probabilidad a cero θ_0 en ψ . Se expande $\psi_n(\hat{\theta}_n)$ usando la serie de Taylor alrededor de θ_0 :

$$0 = \psi_n(\hat{\theta}_n) = \psi_n(\theta_0) + (\hat{\theta}_n - \theta_0) \psi'_n(\theta_0) + \frac{1}{2} (\hat{\theta}_n - \theta_0)^2 \psi''_n(\theta_n^*),$$

donde $\theta_n^* \in (\theta_0, \hat{\theta}_n)$. Así:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{-\sqrt{n}\psi_n(\theta_0)}{\psi'_n(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)\psi''_n(\theta_n^*)}. \quad (31)$$

Suponiendo que $V_\psi = E(\psi_{\theta_0}^2)$ es finito y considerando que $E(\psi_{\theta_0}) = 0$:

$$-\sqrt{n}\psi_n(\theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi_{\theta_0}(X_i) \sim \mathcal{N}(0, V_\psi).$$

Ahora, se considera el denominador de la ecuación (31). El primer término $\psi'_n(\theta_0) \rightarrow E(\psi'_{\theta_0})$ por LLN. El segundo término es:

$$o_p(1) \psi''_n(\theta_n^*) = o_p(1) O_p(1) = o_p(1),$$

porque $\hat{\theta}_n - \theta_0 \rightarrow 0$. Por lo tanto, usando el teorema de Slutsky:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \sim \mathcal{N}(0, [E(\psi'_{\theta_0})]^{-2} V_\psi).$$

Observación 8. Se supone que la función $\theta \rightarrow \psi_\theta(X)$ posee dos derivadas continuas con respecto a θ , para cada X . Esto no siempre es cierto (por ejemplo, la mediana). La condición puede ser reemplazada por una condición de Lipschitz.