

Lectura 5: **Heterocedasticidad y Errores Estándar Agrupados.**

Recordar que, en un modelo de regresión:

$$y = x' \beta + u,$$

se asume que $E(u | x) = 0$ y $\text{Var}(u | x) = \sigma^2$. La heterocedasticidad se produce cuando $\text{Var}(u_i | x) = \sigma_i^2$.

Si se usa un estimador para $V(\hat{\beta})$ en el caso homocedasticidad, se obtiene una estimación sesgada de la varianza verdadera. Luego, las inferencias clásicas, incluidas las pruebas t y F, se invalidan, ya que utilizan estimaciones de la varianza del estimador.

1) Mínimos Cuadrados Generalizados.

Suponer que $E(uu') = \Omega \neq \sigma^2 I_n$ y Ω es desconocido. Considerar una descomposición de la matriz $\Omega^{-1} = CC' = P\Lambda^{-1}P$, donde P es una matriz ortogonal y Λ es una matriz diagonal que incluye las raíces características de Ω . Resulta que se puede escribir:

$$E(uu') = \Omega$$

$$E(uu') = (C')^{-1}C^{-1}.$$

Entonces, se puede transformar la regresión como:

$$C'y = C'X\beta + C'u$$

$$\tilde{y} = \tilde{X}\beta + \tilde{u}.$$

El término de error vector $\tilde{u}$ tiene media cero y varianza I [por ejemplo, $\tilde{u} \sim N(0, I)$] porque la transformación logra:

$$V(\tilde{u}) = V(C'u)$$

$$V(\tilde{u}) = C' V(u) C$$

$$V(\tilde{u}) = C'(C')^{-1}C^{-1}C$$

$$V(\tilde{u}) = I$$

$$V(\tilde{u}) = I.$$

Por lo tanto, el estimador de mínimos cuadrados generalizados es:

$$\hat{\beta} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y},$$

o, equivalentemente:

$$\hat{\beta} = \arg \min \|y - X\beta\|_{\Omega^{-1}}^2.$$

El estimador MCG es insesgado, con varianza condicional igual a:

$$V(\hat{\beta}) = V[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}]$$

$$\begin{aligned}
 V(\hat{\beta}) &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}' V(\tilde{y}) \tilde{X}(\tilde{X}'\tilde{X})^{-1} \\
 V(\hat{\beta}) &= (X'CC'X)^{-1}X'C V(C'y) C'X(X'CC'X)^{-1} \\
 V(\hat{\beta}) &= (X'CC'X)^{-1}X'CC' V(y) CC'X(X'CC'X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1} V(u) \Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}\Omega\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}IX(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}I \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1},
 \end{aligned}$$

que es más pequeña que la matriz de varianza-covarianza del estimador MCO en un modelo de errores no esféricos.

Teorema 1. $V(\hat{\beta}_{MCO}) - V(\hat{\beta}_{MCG})$ es una matriz semidefinida positiva.

Prueba. Por simplicidad, C es simétrica. En primer lugar, tener en cuenta que la varianza condicional del MCO es igual a:

$$\begin{aligned}
 V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'y] \\
 V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'(X\beta + u)] \\
 V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= V[I\beta + (X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= V[\beta + (X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= V(\beta) + V[(X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= 0 + (X'X)^{-1}X' V(u) X(X'X)^{-1} \\
 V(\hat{\beta}_{MCO}) &= (X'X)^{-1}X'\Omega X(X'X)^{-1}.
 \end{aligned}$$

Considerar la descomposición:

$$\begin{aligned}
 X'\Omega^{-1}X &= X'CC'X = W'W. \\
 X'\Omega X &= X'(C')^{-1}C^{-1}X = S'S. \\
 X'X &= X'\Omega^{-1}\Omega X = X'CC'(C')^{-1}C^{-1}X = X'CC^{-1}X = W'S.
 \end{aligned}$$

Entonces, se tiene que:

$$\begin{aligned}
 (X'X)(X'\Omega X)^{-1}(X'X) &= W'S(S'S)^{-1}S'W \\
 (X'X)(X'\Omega X)^{-1}(X'X) &= W'P_S W \leq W'W.
 \end{aligned}$$

El estimador MCG es el estimador de mínimos cuadrados ponderados (MCP) cuando sólo se tiene heterocedasticidad:

$$\begin{aligned}
 C^{-1} &= \Omega^{\frac{1}{2}} \\
 C^{-1} &= \text{diag}(\sigma_i).
 \end{aligned}$$

Por lo tanto, se puede reponderar por $\Omega^{\frac{-1}{2}}$ en lugar de C .

1.1) Estimación.

El estimador MCG es inviable, lo que significa que no se puede implementar en la práctica. La matriz Ω es, típicamente, desconocida, por lo que nos gustaría implementar un método para estimarla. Se puede considerar, en su lugar, $\Omega(\gamma)$ y, después de establecer una relación entre la varianza condicional y el parámetro γ , se puede implementar el método.

Considerar, por simplicidad:

$$y_i = x_i\beta + (z_i'\gamma)^{-\frac{1}{2}}u_i,$$

lo que implica que el elemento i_{th} en la diagonal de Ω es $\Omega_{ii} = (z_i'\gamma)$. Tener en cuenta que, si se estima γ , se puede estimar Ω . Un simple procedimiento de estimación considera:

1. Obtener el estimador MCO ejecutando:

$$(y_i - x_i\hat{\beta})^2 = z_i'\gamma + v_i.$$

2. Colocar $\hat{\gamma}$ en Ω y obtener:

$$\begin{aligned}\hat{\beta} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} \\ \hat{\beta} &= (X'CC'X)^{-1}X'CC'y \\ \hat{\beta} &= (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y \\ \hat{\beta} &= (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y.\end{aligned}$$

En la literatura, existen otros primeros pasos convenientes para los modelos multiplicativos, cuadráticos, etc. de heterocedasticidad. Por ejemplo, podría suponerse que la varianza condicional de u es $e^{\gamma x}$.

Para completar, se revisan las consecuencias de ignorar la heterocedasticidad:

- El estimador MCO es insesgado, pero no eficiente.
- La estimación de la varianza del estimador MCO es un estimador sesgado de la varianza verdadera. Los procedimientos de prueba clásicos están invalidados.

2) Mínimos Cuadrados Ponderados: Un ejemplo simple.

Considerar el modelo de regresión simple sin intercepción:

$$y_i = \beta'x_i + u_i, \tag{1}$$

donde la varianza condicional es:

$$V(u_i | x_i) = \sigma_i^2.$$

Por simplicidad, se asume que:

$$V(u_i | x_i) = \sigma_i^2 = \sigma^2 x_i.$$

Se utiliza el modelo simple presentado anteriormente para ilustrar los efectos de la heterocedasticidad. El estimador MCO de β es:

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}.$$

La varianza del estimador MCO es, en este caso:

$$V(\hat{\beta}) = \frac{\sum_{i=1}^n x_i^2 \sigma_i^2}{(\sum_{i=1}^n x_i^2)^2}.$$

Ahora, se considera un estimador que pondera cada observación por $\frac{1}{\sqrt{x_i}}$:

$$\frac{y_i}{\sqrt{x_i}} = \beta' \frac{x_i}{\sqrt{x_i}} + \frac{u_i}{\sqrt{x_i}} \Rightarrow y_i^* = \beta' x_i^* + u_i^*, \quad (2)$$

porque $V(\frac{u_i}{\sqrt{x_i}} | x_i) = x_i^{-1} V(u_i | x_i) = x_i^{-1} \sigma^2 x_i = \sigma^2$. Consecuentemente, el estimador del parámetro de la pendiente es:

$$\tilde{\beta} = \frac{\sum_{i=1}^n x_i^* y_i^*}{\sum_{i=1}^n (x_i^*)^2}$$

y la varianza de $\tilde{\beta}$ es:

$$\begin{aligned} \text{Var}(\tilde{\beta}) &= \text{Var}\left[\frac{\sum_{i=1}^n x_i^* y_i^*}{\sum_{i=1}^n (x_i^*)^2}\right] \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \text{Var}(\sum_{i=1}^n x_i^* y_i^*) \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sum_{i=1}^n \text{Var}(x_i^* y_i^*) \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sum_{i=1}^n (x_i^*)^2 \text{Var}(y_i^*) \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sum_{i=1}^n (x_i^*)^2 \sigma^2 \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sigma^2 \sum_{i=1}^n (x_i^*)^2 \\ \text{Var}(\tilde{\beta}) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i^*)^2} \\ \text{Var}(\tilde{\beta}) &= \frac{\sigma^2}{\sum_{i=1}^n (\frac{x_i}{\sqrt{x_i}})^2}. \end{aligned}$$

Ahora, se puede comparar la varianza de los dos estimadores para ver si, bajo heterocedasticidad, el estimador MCO es MELI (ya que no está sesgado, sólo se tiene que verificar si es la varianza mínima). Tomando la relación de los dos estimadores:

$$\begin{aligned} \frac{\text{Var}(\hat{\beta})}{\text{Var}(\tilde{\beta})} &= \frac{\frac{\sum_{i=1}^n x_i^2 \sigma_i^2}{(\sum_{i=1}^n x_i^2)^2}}{\frac{\sigma^2}{\sum_{i=1}^n (\frac{x_i}{\sqrt{x_i}})^2}} \\ \frac{\text{Var}(\hat{\beta})}{\text{Var}(\tilde{\beta})} &= \frac{\sum_{i=1}^n x_i^2 \sigma_i^2 \sum_{i=1}^n (\frac{x_i}{\sqrt{x_i}})^2}{\sigma^2 (\sum_{i=1}^n x_i^2)^2} \end{aligned}$$

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sum_{i=1}^n x_i^2 x_i \sigma^2 \sum_{i=1}^n x_i}{\sigma^2 (\sum_{i=1}^n x_i^2)^2}$$

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sigma^2 \sum_{i=1}^n x_i^3 \sum_{i=1}^n x_i}{\sigma^2 (\sum_{i=1}^n x_i^2)^2}$$

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sum_{i=1}^n x_i^3 \sum_{i=1}^n x_i}{(\sum_{i=1}^n x_i^2)^2}.$$

Recordar que el coeficiente de correlación al cuadrado entre a y b es:

$$r^2 = \frac{(\sum ab)^2}{\sum a^2 \sum b^2} \leq 1 \Rightarrow (\sum ab)^2 \leq \sum a^2 \sum b^2.$$

La última expresión es una versión de la desigualdad de Cauchy-Schwarz. Tener en cuenta que, en nuestro caso, $a^2 = x^3$ y $b^2 = x$. Entonces:

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} \geq 1,$$

lo que implica que el estimador MCO es ineficiente bajo heteroscedasticidad.

3) Prueba de Heterocedasticidad.

Se comienza asumiendo un modelo de regresión multivariable:

$$y_i = x_i' \beta + u_i.$$

Se supone que la hipótesis nula es:

$$H_0: V(u | x) = \sigma^2,$$

es decir, nuestra hipótesis nula es no heteroscedasticidad. Como $E(u | x) = 0$, se escribe H_0 como:

$$H_0: E(u^2 | x) = E(u^2) = \sigma^2.$$

Tener en cuenta que se debe evaluar la esperanza condicional (en las variables independientes) del cuadrado del término de error:

$$u^2 = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_p x_p + \varepsilon.$$

El caso homocedástico implica que $\alpha_1 = \alpha_2 = \dots = \alpha_p = 0$, por lo tanto:

$$E(u^2 | x_1, \dots, x_p) = \alpha_0.$$

Sin embargo, tener en cuenta que esto es inviable porque no se conoce el término de error u^2 . Un enfoque simple es reemplazarlo por $\hat{u}^2$ y estimar:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \dots + \alpha_p x_{pi} + \varepsilon,$$

y probar si los coeficientes de pendiente son todos iguales a cero:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_p = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

utilizando una prueba de F. Si $F > c$, donde c está determinada por un valor de significancia estadística, se rechaza la hipótesis nula de no heterocedasticidad.

La versión del multiplicador de Lagrange (LM) es muy fácil de calcular, ya que:

$$LM = nR_{\hat{u}}^2,$$

que se distribuye como χ_p^2 bajo la hipótesis nula de homocedasticidad. Ésta es la prueba de Breusch-Pagan (1980) para la heterocedasticidad.

Una variación de la prueba fue desarrollada por White (1980). Para simplificar la presentación, suponer que $p = 2$:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i.$$

La prueba de White se basa en la estimación de:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_3 x_{1i}^2 + \alpha_4 x_{2i}^2 + \alpha_5 x_{1i} x_{2i} + \varepsilon_i.$$

La hipótesis nula, en este caso, es:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_5 = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

el cual puede ser evaluado con un estadístico de prueba LM o F.

4) Una Matriz Robusta a Heterocedasticidad.

La matriz de covarianza del término de error, bajo heterocedasticidad, es igual a:

$$\Sigma = E(uu') = E(uu' | x) = E[\text{diag}(u_1^2, u_2^2, \dots, u_n^2) | x]$$

o, alternativamente:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix}.$$

Por lo tanto, bajo heteroscedasticidad, la varianza del estimador es:

$$\begin{aligned} V(\hat{\beta} | X) &= V[(X'X)^{-1}X'y | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'(X\beta + u) | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[I\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + V[(X'X)^{-1}X'u | X] \end{aligned}$$

$$V(\hat{\beta} | X) = V(\beta | X) + (X'X)^{-1}X' V(u | X) X(X'X)^{-1}$$

$$V(\hat{\beta} | X) = 0 + (X'X)^{-1}X' \Sigma X(X'X)^{-1}$$

$$V(\hat{\beta} | X) = (X'X)^{-1}X' \Sigma X(X'X)^{-1}.$$

Si se conoce el término de error, se nota que $(uu')_{ii}^2 = u_{ii}^2$ y el valor esperado condicional de la varianza es:

$$E[V(\hat{\beta} | X)] = E[(X'X)^{-1}X' \Sigma X(X'X)^{-1}]$$

$$E[V(\hat{\beta} | X)] = (X'X)^{-1}X' E(\Sigma) X(X'X)^{-1}$$

$$E[V(\hat{\beta} | X)] = (X'X)^{-1}X' \Sigma X(X'X)^{-1}.$$

En la práctica, se obtienen los residuos mínimos cuadrados, $\hat{u}_i^2 = (y_i - x_i'\hat{\beta})^2$, donde $\hat{\beta}$ es el estimador mínimo cuadrático de β . Entonces, se puede formar una matriz:

$$\hat{\Sigma} = \begin{bmatrix} \hat{u}_1^2 & 0 & \dots & 0 \\ 0 & \hat{u}_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{u}_n^2 \end{bmatrix}$$

y construir un estimador factible:

$$\hat{V}(\hat{\beta} | X) = (X'X)^{-1}X' \hat{\Sigma} X(X'X)^{-1}.$$

Este estimador se denomina estimador de “heterocedasticidad-robusto” de la matriz de covarianza. Fue introducido en la literatura de econometría en un artículo influyente de White (1980). Existen otras alternativas implementadas, normalmente, en paquetes estadísticos para $\hat{u}^2$ (por ejemplo, Andrews 1991). Para simplificar esto, si $p = 1$, White (1980) sugiere obtener el error estándar del estimador MCO:

$$\widehat{se}(\hat{\beta}_1) = \left\{ \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} \right\}^{\frac{1}{2}}.$$

Notar que el estimador representa un estimador consistente de la covarianza desconocida. En muestras pequeñas, desafortunadamente, el estimador podría estar sesgado. Para ver esto, recordar que $\hat{u}'\hat{u} = u'Mu = y'My$. Entonces:

$$\hat{u}_i^2 = (y_i - x_i'\hat{\beta})^2$$

$$\hat{u}_i^2 = (y_i - x_i'\beta + x_i'\beta - x_i'\hat{\beta})^2$$

$$\hat{u}_i^2 = [(y_i - x_i'\beta) - x_i'(\hat{\beta} - \beta)]^2$$

$$\hat{u}_i^2 = [u_i + x_i'(X'X)^{-1}X'u]^2$$

$$\hat{u}_i^2 = u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i.$$

Bajo homocedasticidad y denotando el llamado punto de apalancamiento $h_{ii} = x_i'(X'X)^{-1}x_i$, se tiene que:

$$E(\hat{u}_i^2) = E[u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i]$$

$$E(\hat{u}_i^2) = E(u_i^2) - E[2u_i x_i'(X'X)^{-1}X'u] + E[x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i]$$

$$E(\hat{u}_i^2) = \sigma^2 - 2 E[u_i x_i'(X'X)^{-1}x_i u_i] + x_i'(X'X)^{-1}X' E(uu') X(X'X)^{-1}x_i$$

$$\begin{aligned}
 E(\hat{u}_i^2) &= \sigma^2 - 2 E(u_i h_{ii} u_i) + x_i' (X'X)^{-1} X' \sigma^2 X (X'X)^{-1} x_i \\
 E(\hat{u}_i^2) &= \sigma^2 - 2 h_{ii} E(u_i u_i) + \sigma^2 x_i' (X'X)^{-1} X' X (X'X)^{-1} x_i \\
 E(\hat{u}_i^2) &= \sigma^2 - 2 h_{ii} E(u_i^2) + \sigma^2 x_i' I (X'X)^{-1} x_i \\
 E(\hat{u}_i^2) &= \sigma^2 - 2 h_{ii} \sigma^2 + \sigma^2 x_i' (X'X)^{-1} x_i \\
 E(\hat{u}_i^2) &= \sigma^2 - 2 \sigma^2 h_{ii} + \sigma^2 h_{ii} \\
 E(\hat{u}_i^2) &= \sigma^2 - \sigma^2 h_{ii} \\
 E(\hat{u}_i^2) &= \sigma^2 (1 - h_{ii}) < \sigma^2 = E(u_i^2).
 \end{aligned}$$

Luego, insistiendo con el ejemplo simple cuando $p = 1$, se tiene que:

$$\begin{aligned}
 E[\hat{V}(\hat{\beta} | X)] &= E\left\{ \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} \right\} \\
 E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} E\left[\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2 \right] \\
 E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} \sum_{i=1}^n E[(x_i - \bar{x})^2 \hat{u}_i^2] \\
 E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 E(\hat{u}_i^2) \\
 E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 (1 - h_{ii}) \\
 E[\hat{V}(\hat{\beta} | X)] &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} - \frac{\sum_{i=1}^n (x_i - \bar{x})^2 h_{ii} \sigma^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2},
 \end{aligned}$$

lo que indica que $\hat{V}(\hat{\beta} | X)$ está sesgada hacia abajo (tener en cuenta que el primer término es la varianza del estimador de mínimos cuadrados bajo homocedasticidad). Una corrección estándar es dividir $\hat{u}_i^2$ por $(1 - h_{ii})$.

5) Estimación Consistente de S.

Definir:

$$\hat{S} = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i x_i',$$

donde $\hat{u} = y - x_i \hat{\beta}$ y $\hat{\beta}$ es un estimador consistente de β .

Para mostrar la consistencia de $\hat{S}$ para $S = E(u_i^2 x_i x_i')$, se necesita una condición en el cuarto momento de x_i como se indicó, anteriormente, en el supuesto A5.

Teorema 2 (Consistencia de $\hat{S}$). Se supone que S existe y es finito y $\hat{\beta}$ es un estimador consistente para β . Entonces, $\hat{S} \rightarrow S$.

La prueba formal se discutirá más adelante, pero me gustaría proporcionar una breve ilustración considerando $p = 1$. Por definición:

$$\begin{aligned}
 \hat{u}_i^2 &= (y_i - x_i \hat{\beta})^2 \\
 \hat{u}_i^2 &= (y_i - x_i \beta + x_i \beta - x_i \hat{\beta})^2 \\
 \hat{u}_i^2 &= [u_i + x_i (\hat{\beta} - \beta)]^2 \\
 \hat{u}_i^2 &= u_i^2 - 2u_i x_i (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^2,
 \end{aligned}$$

y, por lo tanto:

$$\hat{u}_i^2 - u_i^2 = -2u_i x_i (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^2.$$

Resulta que:

$$\begin{aligned}\hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i^2 - \frac{1}{n} \sum_{i=1}^n u_i^2 x_i^2 \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n (\hat{u}_i^2 - u_i^2) x_i^2 \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n [-2u_i x_i (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^2] x_i^2 \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n [-2u_i x_i^3 (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^4] \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n -2u_i x_i^3 (\hat{\beta} - \beta) + \frac{1}{n} \sum_{i=1}^n (\hat{\beta} - \beta)^2 x_i^4 \\ \hat{S}_n - S_n &= -2 (\hat{\beta} - \beta) \frac{1}{n} \sum_{i=1}^n u_i x_i^3 + (\hat{\beta} - \beta)^2 \frac{1}{n} \sum_{i=1}^n x_i^4.\end{aligned}$$

Por lo tanto, bajo los supuestos existentes:

$$\hat{S}_n = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i^2 \rightarrow E(u_i^2 x_i^2) = S.$$

porque los momentos están limitados y el estimador $\hat{\beta}$ es consistente para β bajo los supuestos A1-A5.

6) Errores Estándar Agrupados.

Esta sección presenta algunas ideas sobre la estimación de errores estándar en presencia de efectos de “grupo”. La mayoría de las correcciones que se encontrarán a continuación están disponibles en paquetes estadísticos, pero pensé que podría ser una buena idea tener una lectura que discuta los temas, potencialmente, específicos de la investigación empírica.

Se supone que se tiene:

$$y_i = x_i' \beta + u_i, \quad (3)$$

y se usa MCO para estimar el parámetro desconocido β . Se sabe que, si $\text{Var}(u_i) = \sigma^2$:

$$\hat{\beta} = (X'X)^{-1} X'y. \quad (4)$$

$$\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1}. \quad (5)$$

Si $\text{Var}(u_i) = \sigma_i^2$, se tiene que:

$$\text{Var}(\hat{\beta}) = (X'X)^{-1} X' \Omega X (X'X)^{-1}, \quad (6)$$

donde $\Omega = E(uu')$. En términos de estimación, se sabe que los parámetros desconocidos pueden estimarse por:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 \quad (7)$$

$$\hat{\Omega} = \text{diag}(\hat{u}_i^2), \quad (8)$$

donde $\hat{u}_i = y_i - x_i \hat{\beta}$ es un residuo. Tener en cuenta que $\hat{\Omega} \rightarrow \Omega$ si $\hat{\beta} \rightarrow \beta$. Por lo tanto, los errores estándar robustos se basan en una aproximación asintótica y pueden estar sesgados en muestras pequeñas.

Se supone, ahora, que se tiene $\{(y_i, x_i)\}_{i=1}^n$, pero se sabe que el modelo puede variar según los grupos $c = 1, \dots, C$:

$$y_{ic} = x'_{ic} \beta_c + u_{ic}. \quad (9)$$

Aunque es razonable pensar que $\text{Cov}(u_{ic}, u_{jc}) = 0$, puede darse el caso de que:

$$\text{Cov}(u_{ic}, u_{jc}) \neq 0. \quad (10)$$

Se comienza suponiendo que el término de error u_{ic} no es independiente de x_{ic} . Por ejemplo, si $u_{ic} = \alpha_c + v_{ic}$, entonces, $\text{Cov}(x_{ic}, \alpha_c) \neq 0$. En este caso, los grupos introducen sesgos si el modelo no condiciona en α_c . Por lo tanto, uno podría estar interesado en estimar:

$$E(y_{ic} | X_{ic}, \alpha_c) = x'_{ic} \beta_c + \alpha_c \quad (11)$$

cuando el número de grupos es grande. El modelo puede ser estimado por transformaciones clásicas de mínimos cuadrados.

En el caso de efectos aleatorios, se puede considerar apilar observaciones dentro de grupos:

$$y_c = X_c \beta_c + \alpha_c, \quad (12)$$

donde y_c es un vector de dimensión $(n_c \times 1)$ y X_c es una matriz de $(n_c \times p)$. Escribir $n = \sum_c n_c$. Entonces:

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1} X'y \\ \hat{\beta} &= (\sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic} x'_{ic})^{-1} \sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic} y_{ic}. \end{aligned} \quad (13)$$

Observar que $\text{Var}(\hat{\beta}) \neq \sigma^2 (X'X)^{-1}$. El error estándar robusto agrupado es:

$$\begin{aligned} \hat{V}(\hat{\beta}) &= (X'X)^{-1} X' \hat{\Omega} X (X'X)^{-1} \\ \hat{V}(\hat{\beta}) &= (\sum_{c=1}^C X'_c X_c)^{-1} \sum_{c=1}^C X'_c \hat{u}_c \hat{u}'_c X_c (\sum_{c=1}^C X'_c X_c)^{-1}, \end{aligned} \quad (14)$$

donde los residuos son $\hat{u}_c = y_c - X_c \hat{\beta}$. El problema con esta corrección es que se necesita $C \rightarrow \infty$ para consistencia.

Si se asume que $u_{ic} = \alpha_c + v_{ic}$, se puede adoptar el marco de efectos aleatorios asumiendo que α y v son independientes. Darse cuenta de:

$$\begin{aligned} E(u_{ic}u_{jc}) &= E[(\alpha_c + v_{ic})(\alpha_c + v_{jc})] \\ E(u_{ic}u_{jc}) &= E(\alpha_c^2 + \alpha_c v_{jc} + v_{ic}\alpha_c + v_{ic}v_{jc}) \end{aligned} \quad (15)$$

y, luego, si $i=j$:

$$\begin{aligned} E(u_{ic}u_{jc}) &= \sigma_\alpha^2 + \sigma_v^2 \\ E(u_{ic}u_{jc}) &= \sigma^2, \end{aligned} \quad (16)$$

y, si $i \neq j$:

$$\begin{aligned} E(u_{ic}u_{jc}) &= \sigma_\alpha^2 \\ E(u_{ic}u_{jc}) &= \rho\sigma^2, \end{aligned} \quad (17)$$

donde $\rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_v^2}$. Por resultados similares al estimador Balesta-Nerlove, se tiene que:

$$\begin{aligned} \Sigma_c &= E(u_c u_c') \\ \Sigma_c &= \sigma^2 [(1 - \rho) I_c + \rho 1_c' 1_c]. \end{aligned} \quad (18)$$

Luego, se sigue que la varianza de $\hat{\beta}$ es:

$$\begin{aligned} V(\hat{\beta}) &= (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C X_c' \sigma^2 [(1 - \rho) I_c + \rho 1_c' 1_c] X_c (\sum_{c=1}^C X_c' X_c)^{-1} \\ V(\hat{\beta}) &= (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C \sigma^2 X_c' [(1 - \rho) I_c + \rho 1_c' 1_c] X_c (\sum_{c=1}^C X_c' X_c)^{-1}. \end{aligned} \quad (19)$$

Un caso útil para arreglar ideas es un modelo con variables invariantes individuales. Se supone, ahora, que el modelo es:

$$y_{ig} = \beta_0 + \beta_1 x_g + u_{ig}, \quad (20)$$

Es posible demostrar que:

$$V(\hat{\beta}_1) = [1 + (M - 1) \rho] V(\tilde{\beta}_1), \quad (21)$$

donde $V(\tilde{\beta}_1)$ es la varianza del estimador estándar MCO. Tener en cuenta que el sesgo del MCO podría ser servido.

Es posible probar los efectos de los grupos después de Moulton (1997). La hipótesis nula es:

$$H_0: \rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_v^2} = 0. \quad (22)$$

$$H_a: \rho > 0. \quad (23)$$

Una prueba LM de un lado se puede formular de la siguiente manera:

$$LM = \frac{\sum_c (N_c \bar{u}_c)^2 - \sum_c \sum_i \hat{u}_{ic}^2}{\hat{\sigma}^2 [2 \sum_c (N_c^2 - N)]^{\frac{1}{2}}}, \quad (24)$$

donde $\hat{\sigma}^2 = \frac{\sum_c \sum_i \hat{u}_{ic}^2}{N}$, $\hat{u}_{ic}$ el residuo de mínimos cuadrados y $\bar{u}_c$ es el residuo promedio para el grupo C.

Ejemplo 1. Moulton (1986) considera regresiones salariales con datos de CPS. El número de individuos en la muestra fue $n \approx 18.000$ en $c = 49$ estados. Aunque la estimación del coeficiente de correlación intraclase $\hat{\rho}$ fue de 0,03, el sesgo fue grande porque los grupos eran grandes ($M \approx 380$). El factor de Moulton, que es $[1 + (M - 1)\rho]^{\frac{1}{2}}$, fue de 3,7, lo que lleva a sesgos considerables en los errores estándar.