

Lectura 6: **Modelos con Regresores Endógenos.**

1) Esencial.

Se supone que el verdadero modelo es:

$$y = X\beta + u. \quad (1)$$

Si $E(u | X) = 0$, se puede mostrar que el estimador MCO:

$$\hat{\beta} = \beta + (X'X)^{-1}X'u$$

es insesgado y consistente. La consistencia puede mostrarse demostrando que el segundo término converge a cero en probabilidad. Primero, se escribe el segundo término como:

$$(n^{-1}X'X)^{-1}n^{-1}X'u$$

y, luego, aplicar el teorema de Slutsky, para encontrar que $\hat{\beta} - \beta \rightarrow 0$. Sin embargo, a veces, incluso en muestras grandes, el estimador puede no estar “cerca” (en cierto sentido) del parámetro verdadero. En presencia de variables endógenas independientes [por ejemplo, $E(u | X) \neq 0$], el estimador $\hat{\beta}$ es sesgado e inconsistente:

$$\hat{\beta} \rightarrow \beta + Q_{xx}^{-1}Q_{xu} \neq 0$$

donde las matrices Q son formas limitantes de $X'X$ y $X'u$. Tener en cuenta que la falta de ortogonalidad entre el término de error y las variables independientes hace que el MCO sea inconsistente.

1.1) Ejemplo: Errores en variables.

Muchas variables (PBI, ingresos permanentes, depreciación de capital, inteligencia, etc.) se miden con errores. Considerar el modelo:

$$y_i = x_i^* \beta + \varepsilon_i,$$

donde x_i^* no se observa y es independiente de ε_i . La variable que observa el investigador es x_i , que se puede expresar como:

$$x_i = x_i^* + u_i.$$

La estimación MCO del modelo:

$$\begin{aligned} y_i &= x_i^* \beta + \varepsilon_i \\ y_i &= (x_i - u_i) \beta + \varepsilon_i \\ y_i &= x_i \beta - u_i \beta + \varepsilon_i \\ y_i &= x_i \beta + (\varepsilon_i - u_i \beta) \\ y_i &= x_i \beta + v_i \end{aligned}$$

puede ser sesgada e inconsistente porque x y v no son ortogonales:

$$\begin{aligned} E(x_i v_i) &= E[(x_i^* + u_i) v_i] \\ E(x_i v_i) &= E[(x_i^* + u_i)(\varepsilon_i - u_i \beta)] \\ E(x_i v_i) &= E[(x_i^* \varepsilon_i - x_i^* u_i \beta + u_i \varepsilon_i - u_i u_i \beta)] \\ E(x_i v_i) &= E(x_i^* \varepsilon_i) - E(x_i^* u_i \beta) + E(u_i \varepsilon_i) - E(u_i u_i \beta) \\ E(x_i v_i) &= 0 - E(x_i^* u_i) \beta + 0 - E(u_i u_i) \beta \\ E(x_i v_i) &= -0 * \beta - E(u_i u_i) \beta \\ E(x_i v_i) &= 0 - E(u_i u_i) \beta \\ E(x_i v_i) &= -E(u_i u_i) \beta \neq 0. \end{aligned}$$

Tener en cuenta que:

$$\begin{aligned} E(\hat{\beta} | X) &= E[(\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i | x_i] \\ E(\hat{\beta} | X) &= E\{\beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i v_i | x_i\} \\ E(\hat{\beta} | X) &= E(\beta | X) + E[(\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i v_i | x_i] \\ E(\hat{\beta} | X) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i E(v_i | x_i) \\ E(\hat{\beta} | X) &= \beta + \text{sesgo}. \end{aligned}$$

Además, en grandes muestras:

$$\begin{aligned} \hat{\beta} &= \beta + (n^{-1} \sum_{i=1}^n x_i x_i')^{-1} n^{-1} \sum_{i=1}^n x_i v_i \\ \hat{\beta} &= \beta + (n^{-1} \sum_{i=1}^n x_i x_i')^{-1} n^{-1} \sum_{i=1}^n (x_i^* + u_i)(\varepsilon_i - u_i \beta) \\ \hat{\beta} &= \beta + (n^{-1} \sum_{i=1}^n x_i x_i')^{-1} n^{-1} \sum_{i=1}^n (x_i^* \varepsilon_i - x_i^* u_i \beta + u_i \varepsilon_i - u_i u_i \beta). \end{aligned}$$

Ya que las perturbaciones ε_i y u_i y la variable no observada x_i^* son independientes:

$$\begin{aligned} \hat{\beta} &= \beta + \{n^{-1} \sum_{i=1}^n [(x_i^* + u_i)(x_i^* + u_i)']\}^{-1} n^{-1} \sum_{i=1}^n -u_i u_i' \beta \\ \hat{\beta} &= \beta - [n^{-1} \sum_{i=1}^n (x_i^* x_i^* + x_i^* u_i + u_i x_i^* + u_i u_i)]^{-1} n^{-1} \sum_{i=1}^n u_i u_i' \beta \\ \hat{\beta} &= \beta - [n^{-1} (\sum_{i=1}^n x_i^* x_i^* + \sum_{i=1}^n x_i^* u_i + \sum_{i=1}^n u_i x_i^* + \sum_{i=1}^n u_i u_i)]^{-1} n^{-1} \sum_{i=1}^n u_i u_i' \beta \\ \hat{\beta} &= \beta - [n^{-1} (\sum_{i=1}^n x_i^* x_i^* + \sum_{i=1}^n u_i u_i)]^{-1} n^{-1} \sum_{i=1}^n u_i u_i' \beta \\ \hat{\beta} &= \beta - [E(x_i^* x_i^*) + E(u_i u_i)]^{-1} E(u_i u_i') \beta. \end{aligned}$$

$$\hat{\beta} \rightarrow \beta - (Q_{x^*} + Q_u)^{-1} Q_u \beta \neq \beta,$$

donde $Q_{x^*} = \lim_{n \rightarrow \infty} \sum_{i=1}^n x_i^* x_i^{*'} y$ y $Q_u = \lim_{n \rightarrow \infty} \sum_{i=1}^n u_i u_i'$. Primero, tener en cuenta que, si una variable independiente se mide con un error, entonces, en general, todas las estimaciones son sesgadas e inconsistentes (¿por qué?). Segundo, si $p = 1$ (por ejemplo, una variable independiente):

$$\hat{\beta} \rightarrow \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_u^2} \beta,$$

sugiriendo que, cuanto mayor sea el error de medición, peor será el sesgo.

1.2) Ejemplo: Variables omitidas.

El sesgo por variable omitida se crea cuando no se introduce una variable no observada. Por ejemplo, ya que la habilidad es una variable latente, no se pueden estimar los verdaderos rendimientos del modelo al modelo educativo. Por otro lado, hay variables relacionadas con la variable no observada, llamadas *proxies*. Por ejemplo, la puntuación de IQ es un *proxy* de la capacidad (por ejemplo, a mayor IQ de la persona, mayor es el nivel de habilidad).

Ahora, la pregunta es: ¿cuáles son las consecuencias en la estimación de usar una variable *proxy*? Se considera el modelo de retorno a la educación para ilustrar y para discutir las lecciones principales.

$$\log(wage_i) = \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 abil_i + u_i. \quad (2)$$

$$abil_i = \alpha_0 + \alpha_3 IQ_i + \varepsilon_i. \quad (3)$$

Reemplazando la ecuación (3) en (2), se tiene el siguiente modelo:

$$\begin{aligned} \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 (\alpha_0 + \alpha_3 IQ_i + \varepsilon_i) + u_i \\ \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 \alpha_0 + \beta_3 \alpha_3 IQ_i + \beta_3 \varepsilon_i + u_i \\ \log(wage_i) &= (\beta_0 + \beta_3 \alpha_0) + \beta_1 educ_i + \beta_2 exp_i + \beta_3 \alpha_3 IQ_i + (\beta_3 \varepsilon_i + u_i) \\ \log(wage_i) &= \delta_0 + \beta_1 educ_i + \beta_2 exp_i + \delta_3 IQ_i + v_i, \end{aligned}$$

$$\text{donde } \delta_0 = \beta_0 + \beta_3 \alpha_0, \delta_3 = \beta_3 \alpha_3 \text{ y } v_i = \beta_3 \varepsilon_i + u_i.$$

Por el método de mínimos cuadrados, se pueden obtener estimaciones insesgadas de β_1 y β_2 , ya que el término de error y las variables independientes *educ* y *exp* son independientes. Además, los estimadores MCO son consistentes, es decir, convergen en probabilidad al valor del parámetro verdadero a medida que aumenta el tamaño de la muestra. Sin embargo, esta conclusión puede ser alterada drásticamente. Se supone que, en lugar de la ecuación (3), el modelo verdadero asume que habilidad también está relacionada con la educación, por ejemplo:

$$abil_i = \alpha_0 + \alpha_1 educ_i + \alpha_3 IQ_i + \varepsilon_i. \quad (4)$$

Ahora, el modelo es:

$$\begin{aligned} \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 (\alpha_0 + \alpha_1 educ_i + \alpha_3 IQ_i + \varepsilon_i) + u_i \\ \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 \alpha_0 + \beta_3 \alpha_1 educ_i + \beta_3 \alpha_3 IQ_i + \beta_3 \varepsilon_i + u_i \\ \log(wage_i) &= (\beta_0 + \beta_3 \alpha_0) + (\beta_1 + \beta_3 \alpha_1) educ_i + \beta_2 exp_i + \beta_3 \alpha_3 IQ_i + (\beta_3 \varepsilon_i + u_i) \\ \log(wage_i) &= \delta_0 + \delta_1 educ_i + \beta_2 exp_i + \delta_3 IQ_i + v_i, \end{aligned}$$

$$\text{donde } \delta_0, \delta_3 \text{ y } v_i \text{ se definen como antes y } \delta_1 = \beta_1 + \beta_3 \alpha_1.$$

Se puede demostrar que, a medida que aumenta el tamaño de la muestra, el estimador del retorno a la educación tenderá a:

$$\hat{\delta}_1 = \beta_1 + \beta_3 \alpha_1 \neq \beta_1,$$

que es diferente al verdadero parámetro β_1 ya que $\alpha_1 = 0$. Por lo tanto, aunque se introduce una variable para explicar el efecto de la habilidad no observada, se tiene un estimador inconsistente del parámetro de retorno a la educación. Por ejemplo, si los años de educación se relacionan, positivamente, con la habilidad ($\alpha_1 > 0$) y la habilidad se relaciona, positivamente, con los salarios ($\beta_3 > 0$), el sesgo asintótico es positivo.

2) Estimación VI.

Se puede considerar reemplazar x con otra variable, digamos z . La nueva variable, llamada variable instrumental, tiene que satisfacer ciertas condiciones¹:

1. La variable instrumental z no debe estar correlacionada con el término de error u , $E(zu) = 0$.
2. La variable instrumental z tiene que estar correlacionada con la variable endógena x , $E(zx) \neq 0$.

Considerar el siguiente modelo de regresión lineal:

$$y = X_1\beta_1 + X_2\beta_2 + u.$$

$$y = X\beta + u,$$

donde X_1 son variables exógenas [por ejemplo, $E(u | X_1) = 0$] y X_2 son variables (observables) endógenas [por ejemplo, $E(u | X_2) \neq 0$]. Se supone también que hay una matriz de instrumentos Z . La idea es la siguiente: multiplicar cada lado de la ecuación por la matriz de variables instrumentales Z :

$$Z'y = Z'X\beta + Z'u,$$

donde Z puede incluir X_1 como instrumento para X_1 y Z_2 como instrumento para X_2 . Dividiendo por n y aplicando la Ley de los Grandes Números en $n^{-1}Z'u$, se obtiene una expresión que nos lleva al estimador VI (¿por qué?)². El estimador de variables instrumentales es:

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y.$$

Bajo errores esféricos, la varianza del estimador es:

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'y]$$

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'(X\beta + u)]$$

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'X\beta + (Z'X)^{-1}Z'u]$$

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'X\beta] + V[(Z'X)^{-1}Z'u]$$

$$V(\hat{\beta}_{VI}) = 0 + (Z'X)^{-1}Z' V(u) Z(Z'X)^{-1}$$

¹ ¿Por qué la VI tiene que satisfacer estas dos condiciones? La primera condición puede ser intuitiva. La primera condición requiere que z y u no estén correlacionados, lo que implica que, si vamos a usar otra variable, al menos, tiene que resolver el problema original, $Cov(x, u) \neq 0$. ¿Podría explicar la segunda condición?

² Surge de minimizar: $\min_{\beta} E[(Z'u)^2] = \min_{\beta} E[(Z'y - Z'X\beta)^2] = \min_{\beta} E[(Z'y - Z'X\beta)'(Z'y - Z'X\beta)]$. Y, considerando la LGN, se tiene que: $\frac{1}{n} Z'u = \frac{1}{n} \sum_{i=1}^n z_i' u_i \rightarrow E(Z'u)$.

$$V(\hat{\beta}_{VI}) = (Z'X)^{-1}Z'\sigma_{VI}^2IZ(Z'X)^{-1}$$

$$V(\hat{\beta}_{VI}) = (Z'X)^{-1}Z'\sigma_{VI}^2Z(Z'X)^{-1}$$

$$V(\hat{\beta}_{VI}) = \sigma_{VI}^2(Z'X)^{-1}Z'Z(Z'X)^{-1}.$$

Tener en cuenta que el estimador $\hat{\beta}_{VI}$ también se puede obtener a partir de la condición del momento:

$$(Z'X)'(Z'y - Z'X\beta) = 0$$

$$X'Z(Z'y - Z'X\beta) = 0$$

$$X'ZZ'y - X'ZZ'X\beta = 0$$

$$X'ZZ'X\beta = X'ZZ'y$$

$$\beta = (X'ZZ'X)^{-1}X'ZZ'y$$

$$\beta = (Z'X)^{-1}(X'Z)^{-1}X'ZZ'y$$

$$\beta = (Z'X)^{-1}IZ'y$$

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y$$

o, análogamente:

$$Z'(y - X\beta) = 0$$

$$Z'y - Z'X\beta = 0$$

$$Z'X\beta = Z'y$$

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y,$$

que implica p ecuaciones y p incógnitas.

El estimador VI es insesgado según los supuestos A1 y A2 (¿por qué?). Tener en cuenta que:

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'y]$$

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'y]$$

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'(X\beta + u)]$$

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'X\beta + (Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = E[I\beta + (Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = E[\beta + (Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = E(\beta) + E[(Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = \beta + (Z'X)^{-1}E(Z'u)$$

$$E(\hat{\beta}_{VI}) = \beta + (Z'X)^{-1} * 0$$

$$E(\hat{\beta}_{VI}) = \beta + 0$$

$$E(\hat{\beta}_{VI}) = \beta,$$

porque $E(Z'u) = 0$. También es consistente:

$$\hat{\beta}_{VI} - \beta = (n^{-1}Z'X)^{-1}(n^{-1}Z'u) \rightarrow 0,$$

siempre que la forma limitante de $Z'X$ sea determinista y no singular (condiciones necesarias para la identificación asintótica). Los errores no están correlacionados asintóticamente con los instrumentos, que se desprende de la condición 1 de la ley de los

grandes números. Tener en cuenta que esta condición puede durar, incluso, si la condición 1 no lo hace.

¿Cuáles son los instrumentos Z? Primero, desde $X_1 \perp u$, X_1 puede ser (trivialmente) usado como VI por sí misma. Luego, se necesitan instrumentos adicionales que satisfagan 1 y 2 para identificar el modelo. El vector Z_2 son VI para X_2 , a menudo denotadas como variables exógenas excluidas (del modelo).

El estimador VI tiene la siguiente representación asintótica:

$$\sqrt{n} (\hat{\beta}_{VI} - \beta) \rightarrow^d Q_{zx}^{-1} \mathcal{N}(0, \sigma^2 Q_{zz}) = \mathcal{N}(0, \sigma^2 Q_{zx}^{-1} Q_{zz} Q_{zx}^{-1}),$$

donde $Q_{zx} = \lim_{n \rightarrow \infty} n^{-1} Z'X$. Si $Z = X$, el estimador VI es, trivialmente, el estimador MCO.

Por último, tener en cuenta que la relación entre Z y X en muestras grandes coloca un papel clave para determinar la varianza asintótica.

2.1) Ejemplo: Estimador Wald VI.

Considerar el modelo de regresión simple:

$$y_i = \beta_0 + \beta_1 x_i + u_i,$$

donde $E(u_i | x_i) \neq 0$. Las suposiciones de nuestro modelo son (a) el término de error tiene un valor esperado de cero y (b) la correlación entre la variable instrumental y el término de error es cero. Estas condiciones de población imponen una condición sobre la contraparte de datos que se puede declarar como:

$$E(u) = 0 \quad \Rightarrow \quad \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (5)$$

$$E(zu) = 0 \quad \Rightarrow \quad \sum_{i=1}^n z_i (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (6)$$

De la primera ecuación, se obtiene $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Reemplazando esta expresión en la segunda ecuación, se obtiene el estimador de Wald:

$$\begin{aligned} \sum_{i=1}^n [z_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)] &= 0 \\ \sum_{i=1}^n \{z_i [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]\} &= 0 \\ \sum_{i=1}^n [z_i (y_i - \bar{y}) - \hat{\beta}_1 z_i (x_i - \bar{x})] &= 0 \\ \sum_{i=1}^n z_i (y_i - \bar{y}) - \sum_{i=1}^n \hat{\beta}_1 z_i (x_i - \bar{x}) &= 0 \\ \sum_{i=1}^n z_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n z_i (x_i - \bar{x}) &= 0 \\ \hat{\beta}_1 \sum_{i=1}^n z_i (x_i - \bar{x}) &= \sum_{i=1}^n z_i (y_i - \bar{y}) \\ \hat{\beta}_1 &= [\sum_{i=1}^n z_i (x_i - \bar{x})]^{-1} \sum_{i=1}^n z_i (y_i - \bar{y}). \end{aligned}$$

La variable $z_i = \{0, 1\}$ es una variable dummy, por lo tanto, se puede escribir:

$$\begin{aligned} \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 (\bar{y}_1 - \bar{y}) \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left(\frac{N_0 \bar{y}_1 + N_1 \bar{y}_1}{N} - \frac{N_0 \bar{y}_0 + N_1 \bar{y}_1}{N} \right) \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left(\frac{N_0 \bar{y}_1 + N_1 \bar{y}_1 - N_0 \bar{y}_0 - N_1 \bar{y}_1}{N} \right) \end{aligned}$$

$$\begin{aligned}\sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left(\frac{N_0 \bar{y}_1 - N_0 \bar{y}_0}{N} \right) \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left[\frac{N_0 (\bar{y}_1 - \bar{y}_0)}{N} \right] \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= \frac{N_1 N_0}{N} (\bar{y}_1 - \bar{y}_0).\end{aligned}$$

En consecuencia, se puede escribir el estimador como:

$$\begin{aligned}\hat{\beta}_{Wald} &= \frac{\frac{N_1 N_0}{N} (\bar{y}_1 - \bar{y}_0)}{\frac{N_1 N_0}{N} (\bar{x}_1 - \bar{x}_0)} \\ \hat{\beta}_{Wald} &= \frac{\bar{y}_1 - \bar{y}_0}{\bar{x}_1 - \bar{x}_0}.\end{aligned}$$

3) Variable Instrumental Generalizada.

Tener en cuenta que, para que $Z'X$ sea invertible, se debe tener una matriz Z con p instrumentos. Cuando el número de VI es igual al número de parámetros a estimar, se dice que el modelo está, exactamente, identificado. A menudo, el número de VI es mayor que el número de parámetros, por lo que se puede considerar la siguiente matriz:

$$W = P_Z X$$

para lograr una transformación. Se dice que el modelo está sobreidentificado y, en este caso, la condición de momento es:

$$W' (y - X\beta) = 0,$$

dando el estimador generalizado de la variable instrumental:

$$\hat{\beta}_{VIG} = (W'X)^{-1} W'y.$$

El estimador generalizado VI se conoce, generalmente, como el estimador de mínimos cuadrados en dos etapas (MC2E):

$$\hat{\beta}_{MC2E} = (X'P_Z X)^{-1} X'P_Z y,$$

que se basa en dos proyecciones³:

1. Regresar X en Z para obtener:

$$\hat{X} = Z(Z'Z)^{-1} Z'X$$

³ La idea principal del estimador MC2E es la siguiente. En un modelo de regresión binaria, considerar que la variable independiente es endógena:

$$y_i = x_i' \beta + u_i; \quad x_i = z_i' \pi + v_i.$$

La segunda ecuación es interesante, ya que contiene dos partes que proporcionan la descomposición necesaria para resolver la endogeneidad en la ecuación principal: $\pi_0 + \pi_1 z_i$, que no está correlacionada con u , y v_i , que sí está correlacionada con u . La idea de MC2E es usar sólo la primera parte, la parte de la descomposición que es independiente del término de error. El problema es que $z_i' \pi$ no se observa, pero se puede predecir mediante la simple regresión MCO $\hat{x}_i = z_i' \hat{\pi}$.

$$\hat{X} = P_Z X.$$

Es importante ver los componentes de la matriz de proyección $\hat{X} = [P_Z X_1, P_Z X_2]$. Recordar que $Z = [X_1, Z_2]$, por lo tanto:

$$\hat{X} = [X_1, \hat{X}_2].$$

2. Luego, regresar y sobre $\hat{X}$, obteniendo el estimador MC2E:

$$\hat{\beta}_{MC2E} = (\hat{X}'\hat{X})^{-1}\hat{X}'y.$$

Si los errores son homocedásticos, las condiciones anteriores (1)-(2) se satisfacen y la condición de rango (tantas VI como variables independientes) se satisface, se tiene el siguiente resultado.

Teorema 1. El estimador MC2E está distribuido de manera asintóticamente normal con media cero y matriz de varianza:

$$p \lim_{n \rightarrow \infty} [n^{-1} \sigma^2 (X' P_Z X)]^{-1}.$$

Prueba. Escribir el estimador VI como:

$$\hat{\beta} = \beta + (X' P_Z X)^{-1} X' P_Z u.$$

Luego, se multiplica cada término por $\sqrt{n}$ y se escribe como:

$$\sqrt{n} (\hat{\beta} - \beta) = (n^{-1} X' P_Z X)^{-1} n^{\frac{-1}{2}} X' P_Z u + o_p(1).$$

El resultado sigue pasando con n tendiendo a ∞ y aplicando el teorema de Slutsky (¿se puede modificar el resultado para el caso de errores no esféricos?).

3.1) Una tercera derivación.

Una interpretación interesante del MC2E es la siguiente. Se definen los residuos de X en Z :

$$R = X - \hat{X}$$

$$R = X - P_Z X$$

$$R = (I - P_Z) X$$

$$R = M_Z X.$$

Considerar, ahora, el estimador de mínimos cuadrados de un modelo que incluye los residuos:

$$y = X\beta + R\gamma + u,$$

que es igual a:

$$\hat{\beta}_{vc} = (X'M_R X)^{-1} X'M_R Y,$$

donde vc significa variable de control. Este estimador es idéntico al estimador MC2E porque:

$$\begin{aligned} X'M_R &= X' (I - P_R) \\ X'M_R &= X' [I - R(R'R)^{-1}R'] \\ X'M_R &= X' [I - M_Z X(X'M_Z M_Z X)^{-1} X'M_Z'] \\ X'M_R &= X' [I - M_Z X(X'M_Z M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' [I - M_Z X(X'M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' - X'M_Z X(X'M_Z X)^{-1} X'M_Z \\ X'M_R &= X' - IX'M_Z \\ X'M_R &= X' - X'M_Z \\ X'M_R &= X' - X' (I - P_Z) \\ X'M_R &= X' - X' + X'P_Z \\ X'M_R &= X'P_Z. \end{aligned}$$

Por lo tanto, el “sesgo por endogeneidad” se puede ver como un sesgo por variable omitida.

4) Test.

4.1) Una prueba de especificación incorrecta.

Por supuesto, en situaciones prácticas, no se sabe si las variables independientes están correlacionadas con el término de error. Se puede usar la teoría económica para guiarnos, pero la verdadera pregunta estadística es simplemente: ¿es el problema de la endogeneidad lo suficientemente serio? Por ejemplo, si la respuesta es no, se puede ignorar el problema y, simplemente, estimar el modelo utilizando MCO.

La pregunta anterior se puede examinar con una prueba propuesta por J. Hausman en 1978. La prueba sobre modelos específicos en econometría tiene una amplia aplicabilidad a diferentes modelos. En datos de panel, como quedará claro en futuras lecturas, ayuda a decidir entre los modelos de efectos fijos y los modelos de efectos aleatorios mediante la prueba de la hipótesis supuesta de independencia entre los efectos específicos individuales y las variables independientes.

En nuestra configuración de sección transversal, la hipótesis nula y la hipótesis alternativa se pueden formular como:

$$H_0: E(X'u) = 0; \quad H_a: E(X'u) \neq 0.$$

Bajo H_0 , los estimadores MCO y VI son consistentes, aunque el MCO es eficiente. Bajo H_a , el estimador VI sigue siendo consistente, pero el MCO es inconsistente.

Por lo tanto, una prueba basada en la diferencia entre estos dos estimadores puede indicar si la endogeneidad afecta la consistencia del estimador MCO. La idea es evaluar si la distancia entre los dos estimadores es, asintóticamente, cero:

$$\hat{q} = \tilde{\beta} - \hat{\beta} \rightarrow 0,$$

donde $\tilde{\beta}$ es el estimador VI y $\hat{\beta}$ es el estimador MCO. ¿Cuál es la distribución de $\hat{q}$? Se espera que sea, asintóticamente, normal con varianza asintótica:

$$V(\hat{q}) = V(\tilde{\beta} - \hat{\beta})$$

$$V(\hat{q}) = V(\tilde{\beta}) - V(\hat{\beta}).$$

Lema 1. Bajo H_0 , $V(\tilde{\beta} - \hat{\beta}) = V(\tilde{\beta}) - V(\hat{\beta})$.

Prueba. Escribir:

$$\Delta = \tilde{\beta} - \hat{\beta}$$

$$\Delta = [\beta + (X'P_ZX)^{-1}X'P_Zu] - [\beta + (X'X)^{-1}X'u]$$

$$\Delta = \beta + (X'P_ZX)^{-1}X'P_Zu - \beta - (X'X)^{-1}X'u$$

$$\Delta = (X'P_ZX)^{-1}X'P_Zu - (X'X)^{-1}X'u$$

$$\Delta = [(X'P_ZX)^{-1}X'P_Z - (X'X)^{-1}X']u$$

$$\Delta = (A - B)u.$$

Entonces:

$$E(\Delta\Delta') = E\{[(A - B)u][(A - B)u']\}$$

$$E(\Delta\Delta') = E[(A - B)uu'(A - B)']$$

$$E(\Delta\Delta') = (A - B)E(uu')(A - B)'$$

$$E(\Delta\Delta') = (A - B)\sigma_u^2(A - B)'$$

$$E(\Delta\Delta') = \sigma_u^2(A - B)(A - B)'$$

$$E(\Delta\Delta') = \sigma_u^2(A - B)(A' - B')$$

$$E(\Delta\Delta') = \sigma_u^2(AA' + AB' - BA' + BB').$$

Tener en cuenta que:

$$AB' = (X'P_ZX)^{-1}X'P_Z[(X'X)^{-1}X']'$$

$$AB' = (X'P_ZX)^{-1}X'P_ZX(X'X)^{-1}$$

$$AB' = I(X'X)^{-1}$$

$$AB' = (X'X)^{-1}.$$

$$BA' = (X'X)^{-1}X'[(X'P_ZX)^{-1}X'P_Z]'$$

$$BA' = (X'X)^{-1}X'P_ZX(X'P_ZX)^{-1}$$

$$BA' = (X'X)^{-1}I$$

$$BA' = (X'X)^{-1}.$$

$$BB' = (X'X)^{-1}X'[(X'X)^{-1}X']'$$

$$BB' = (X'X)^{-1}X'X(X'X)^{-1}$$

$$BB' = I(X'X)^{-1}$$

$$BB' = (X'X)^{-1}.$$

Así que:

$$E(\Delta\Delta') = \sigma_u^2(AA' - BB')$$

$$E(\Delta\Delta') = \sigma_u^2AA' - \sigma_u^2BB'$$

$$E(\Delta\Delta') = \sigma_u^2(X'P_ZX)^{-1} - \sigma_u^2(X'X)^{-1}$$

$$V(\tilde{\beta} - \hat{\beta}) = V(\tilde{\beta}) - V(\hat{\beta}).$$

Un estadístico de prueba natural es, entonces:

$$h = \hat{q}'[V(\tilde{\beta}) - V(\hat{\beta})]^{-1}\hat{q},$$

que se distribuye asintóticamente como χ^2 . Si h es bajo, digamos menos de 2 valores críticos, no se rechaza la hipótesis nula y se concluye que la endogeneidad no afecta la consistencia del estimador MCO. Si h es alto, digamos más de 2 valores críticos, se rechaza la hipótesis nula y se concluye que la endogeneidad es un problema para el estimador MCO. Por lo tanto, se debe utilizar el estimador VI.

4.2) Restricciones sobreidentificadas.

Considerar que el modelo de regresión está bien especificado, $y = X\beta + u$. Un candidato Z debe satisfacer:

$$E(u | Z) = 0 \quad \text{o} \quad E(Z'u) = 0.$$

Tener en cuenta que, en el caso de los modelos recién identificados, se tiene que:

$$Z'\hat{u} = 0,$$

así que no se pueden probar las condiciones anteriores. Sin embargo, si se tienen más instrumentos (digamos k) que variables endógenas (digamos q), se puede considerar la siguiente prueba:

$$T = \hat{\sigma}^{-2}\hat{u}'Z(Z'Z)^{-1}Z'\hat{u}$$

$$T = \hat{\sigma}^{-2}\hat{u}'P_Z\hat{u} \sim \chi_{k-q}^2,$$

bajo la hipótesis nula. Si se rechaza la nula, esto debe interpretarse como evidencia de que los instrumentos son endógenos. Permítame presentar una manera simple de implementar la prueba:

1. Estimar la ecuación estructural por MC2E para obtener los residuos, $\hat{u}_i$.
2. Regresar $\hat{u}_i$ en las variables exógenas (las VI, $z_1, \dots, z_k$, y las covariables incluidas $x_{q+1}, \dots, x_p$).
3. Con el R^2 de la última regresión, construir el estadístico de prueba nR^2 para evaluar la hipótesis nula.

5) Instrumentos Débiles.

Déjeme decir una palabra sobre las consecuencias de elegir un instrumento “débil”, es decir, una variable que no satisface ninguna de las condiciones (1) o (2). Se supone, por ejemplo, que z infringe (1), es decir, la variable instrumental no es independiente del término de error. Considerando un modelo con un regresor (endógeno):

$$y = x\beta + u,$$

se puede demostrar que:

$$\hat{\beta} \rightarrow \beta + \frac{\text{Cor}(z,u)\sigma_u}{\text{Cor}(z,x)\sigma_x},$$

donde $\text{Cor}(\cdot)$ significa correlación.

Ésta es una fórmula interesante. Incluso si la correlación entre z y u es pequeña, el sesgo asintótico puede ser muy grande si (a) z y x están, apenas, correlacionados y si (b) la relación ruido-senal ($\frac{\sigma_u}{\sigma_x}$) es grande.

Si se compara el sesgo asintótico del estimador de la variable instrumental pobre con el estimador MCO en el caso de que x no sea exógena:

$$\hat{\beta} \rightarrow \beta + \frac{\text{Cov}(x,u)}{V(x)} = \beta + \frac{\sigma_x \sigma_u \text{Cor}(x,u)}{\sigma_x^2} = \beta + \text{Cor}(x,u) \frac{\sigma_u}{\sigma_x},$$

se puede concluir que el estimador MCO se prefiere al estimador MC2E si:

$$\frac{\text{Cor}(z,u)}{\text{Cor}(z,x)} > \text{Cor}(x,u).$$

No es sorprendente, entonces, que, a menudo, se indique que una VI débil se puede detectar usando la regresión de la primera etapa (por ejemplo, simplemente, mirando la prueba de F o R^2). La práctica estándar es verificar si los instrumentos están correlacionados con la variable endógena ejecutando la endógena en las VI y en las variables exógenas. Una prueba de F en los coeficientes en las VI proporciona una medida del contenido de información de las VI⁴.

Desafortunadamente, el problema de las VI débiles es, típicamente, más complejo, ya que incluye otros parámetros. Considerar, por ejemplo:

$$\begin{aligned} y_1 &= y_2 \beta + u \\ y_2 &= z\pi + v, \end{aligned}$$

donde z es un vector k dimensional y $E(uv) = \sigma_{uv}$. El estimador MC2E es:

$$\begin{aligned} \hat{\beta} &= \frac{y_2' P_z y_1}{y_2' P_z y_2} \\ \hat{\beta} &= \beta + \frac{y_2' P_z u}{y_2' P_z y_2}. \end{aligned}$$

Dejar $q_2 = \frac{y_2' P_z y_2}{n}$ y tener en cuenta que $y_2' P_z u = \text{tr}(y_2' P_z u) = \text{tr}(P_z y_2' u) = \text{tr}(P_z) y_2' u = \text{tr}(I_k) y_2' u = k y_2' u$. Entonces, se puede expresar el sesgo del estimador MC2E como:

⁴ Una regla de oro, tomada de Stock and Watson (2003), sugiere que 10 es el valor del estadístico F que divide los instrumentos débiles y válidos. Por ejemplo, si el estadístico F excede de 10, se rechaza la hipótesis nula, concluyendo que las z son instrumentos válidos para nuestras variables endógenas.

$$\hat{\beta} - \beta \approx \frac{k}{n} \frac{\sigma_{uv}}{q_2} \approx \frac{k}{nR^2} \frac{\sigma_{uv}}{\sigma_{y_2}^2}.$$

Esto implica que k , el coeficiente de determinación de la regresión R^2 de la primera etapa y la correlación entre los errores en las ecuaciones σ_{uv} desempeñan un papel en la determinación del sesgo del MC2E en muestras pequeñas. Tener en cuenta que, como $n \rightarrow \infty$, si k es fijo, se tiende a tener (asintóticamente) sesgo cero. La literatura ofrece pruebas y estimadores con corrección de sesgo (véase, por ejemplo, Stock 2002, Hahn y Hausman 2003).

Otro problema está relacionado con la inferencia cuando la correlación entre la variable endógena y el instrumento es muy pequeña. De nuevo, considerar el siguiente modelo:

$$\begin{aligned} y_1 &= y_2 \beta + u \\ y_2 &= z' \pi + v, \end{aligned}$$

donde, ahora, $k = 1$. En otras palabras, el modelo está, exactamente, identificado y los instrumentos son endógenos utilizando un instrumento. Recordar que $\pi = \frac{E(z_i y_{2i})}{E(z_i^2)}$ y considerar que $\pi = \frac{\gamma}{\sqrt{n}}$. En este caso:

$$\hat{\beta} - \beta = \frac{\frac{1}{\sqrt{n}} \sum_i z_i u_i}{\frac{1}{\sqrt{n}} \sum_i z_i y_{2i}} \rightsquigarrow \frac{\mathcal{N}(0, V_u)}{Q_Z \gamma + \mathcal{N}(0, V_v)},$$

distribuido como no normal para $\gamma \neq 0$ y Cauchy cuando $\gamma = 0$. Por lo tanto, el estimador VI converge en probabilidad a una variable aleatoria no degenerada. Su distribución no es normal y, por lo tanto, los procedimientos de inferencia también son inconsistentes (ver, por ejemplo, Choi y Phillips 1992).

6) Estimación VI en Modelos no Lineales.

Casos de error de medición (EM) en las variables independientes:

1. Sesgo e inconsistencia en la estimación de parámetros para modelos econométricos.
2. Pérdida de potencia para detectar una relación estocástica significativa entre las variables de interés.

Las técnicas para abordar el problema del error de medición se pueden clasificar en dos grupos: (a) métodos para modelos de error en variables lineales y (b) métodos para modelos de error en variables no lineales.

6.1) Errores clásicos.

Esto se refiere a una situación en la que la verdadera variable latente no está correlacionada con el error de medición. Considerar:

$$Y = \alpha + \beta X^* + \epsilon \tag{7}$$

$$X = X^* + u \tag{8}$$

y, por lo tanto:

$$\begin{aligned} Y &= \alpha + \beta (X - u) + \epsilon \\ Y &= \alpha + \beta X - \beta u + \epsilon \\ Y &= \alpha + \beta X + v, \end{aligned} \quad (9)$$

donde $v = \epsilon - \beta u$. Recordar que el estimador sesgado e inconsistente para la pendiente es:

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X}) Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2} \quad (10)$$

y la intercepción es:

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}. \quad (11)$$

Tener en cuenta que:

$$\begin{aligned} \hat{\alpha} &\rightarrow E(\alpha + \beta X^* + \epsilon) - \frac{\beta \sigma_{X^*}^2}{\sigma_{X^*}^2 + \sigma_u^2} E(X^* + u) \\ \hat{\alpha} &\rightarrow \alpha + \frac{\beta \sigma_{X^*}^2}{\sigma_{X^*}^2 + \sigma_u^2} E(X^*). \end{aligned} \quad (12)$$

Observación 1.

Es interesante ejecutar una regresión para X en Y para encontrar los límites de los coeficientes verdaderos α y β . Escribir:

$$X = \frac{-\alpha}{\beta} + \frac{1}{\beta} Y - \frac{v}{\beta} \quad (13)$$

y, por lo tanto:

$$\tilde{b} = \frac{\sum_{i=1}^n (X_i - \bar{X}) Y_i}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (14)$$

$$\tilde{\alpha} = \bar{Y} - \tilde{\beta} \bar{X}, \quad (15)$$

donde $\tilde{\beta} = \tilde{b}^{-1}$. Ahora, se escribe:

$$\begin{aligned} \tilde{\alpha} &\rightarrow E(\alpha + \beta X^* + \epsilon) - (\beta + \frac{\sigma_u^2}{\beta \sigma_{X^*}^2}) E(X^*) \\ \tilde{\alpha} &\rightarrow \alpha - \frac{\sigma_u^2}{\beta \sigma_{X^*}^2} E(X^*). \end{aligned} \quad (16)$$

Ejemplo 1: Tener en cuenta que el *plim* de $\tilde{b} = \frac{Cov(x,y)}{V(y)}$. Es posible demostrar que:

$$plim \tilde{\beta} = \beta + \frac{\sigma_u^2}{\beta \sigma_{X^*}^2}.$$

Como se discutió anteriormente, el modelo con errores clásicos puede verse como un problema de regresores endógenos. Por lo tanto, VI se convierte en un enfoque popular para estimar tales modelos.

Las pruebas de tipo Hausman también se pueden utilizar en este tipo de modelos. Un VI válido podría tener la forma $Z = X^* + v_Z$, siendo v_Z un error independiente: $E[Z(\epsilon, u)] = 0$.

Ejemplo 2. Considerar el modelo anterior y suponer que $\alpha = 0$, $\beta = 1$, $\sigma_\epsilon^2 = 0,25$, $\sigma_u^2 = 1$ y $X^* \in \mathcal{N}(0, 1)$. Se puede ilustrar el sesgo de atenuación usando los siguientes dos gráficos.

Ejemplo 3. Cuando se tienen muchas columnas en X y se observa sólo una covariable con error de medición, la fórmula para el sesgo de atenuación es:

$$\hat{\beta} \rightarrow \beta \left[1 - \frac{\sigma_u^2}{\sigma_{X^*}^2(1 - R_{X^*, Z}^2) + \sigma_u^2} \right], \quad (17)$$

donde R^2 es el verdadero R^2 .

Ejemplo 4. Se supone que se observan mediciones repetidas para individuos a lo largo del tiempo. Por ejemplo, suponer:

$$Y_{it} = \alpha + \beta X_{it}^* + \mu_i + \epsilon_{it}. \quad (18)$$

$$X_{it} = X_{it}^* + u_{it}. \quad (19)$$

Para eliminar esa heterogeneidad no observada, simplemente, se obtienen las primeras diferencias:

$$\begin{aligned} \Delta Y_{it} &= \beta \Delta X_{it}^* + \Delta \epsilon_{it} \\ \Delta Y_{it} &= \beta \Delta(X_{it} - u_{it}) + \Delta \epsilon_{it} \\ \Delta Y_{it} &= \beta \Delta X_{it} - \beta \Delta u_{it} + \Delta \epsilon_{it} \\ \Delta Y_{it} &= \beta \Delta X_{it} + \Delta v_{it}. \end{aligned} \quad (20)$$

Por lo tanto:

$$\begin{aligned} \hat{\beta} &= \frac{\sum_{i=1}^N \Delta X_{it} \Delta Y_{it}}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \frac{\sum_{i=1}^N \Delta X_{it} [\beta \Delta X_{it} + (\Delta \epsilon_{it} - \beta \Delta u_{it})]}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \frac{\sum_{i=1}^N [\beta \Delta X_{it}^2 + \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})]}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \frac{\sum_{i=1}^N \beta \Delta X_{it}^2 + \sum_{i=1}^N \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \beta + \frac{\sum_{i=1}^N \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \beta + \frac{\frac{1}{N} \sum_{i=1}^N \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})}{\frac{1}{N} \sum_{i=1}^N \Delta X_{it}^2}. \end{aligned} \quad (21)$$

Tener en cuenta que:

$$\begin{aligned}
E[(\Delta X_{it})^2] &= E[(X_{it} - X_{it-1})^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^* + u_{it}) - (X_{it-1}^* + u_{it-1})]^2 \\
E[(\Delta X_{it})^2] &= E[(X_{it}^* + u_{it})^2 - 2(X_{it}^* + u_{it})(X_{it-1}^* + u_{it-1}) + (X_{it-1}^* + u_{it-1})^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^* + u_{it})^2] - E[2(X_{it}^* + u_{it})(X_{it-1}^* + u_{it-1})] + E[(X_{it-1}^* + u_{it-1})^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^*)^2 + 2X_{it}^*u_{it} + u_{it}^2] - 2E[(X_{it}^* + u_{it})(X_{it-1}^* + u_{it-1})] + E[(X_{it-1}^*)^2 + 2X_{it-1}^*u_{it-1} + u_{it-1}^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^*)^2] + E(2X_{it}^*u_{it}) + E(u_{it}^2) - 2E(X_{it}^*X_{it-1}^* + X_{it}^*u_{it-1} + u_{it}X_{it-1}^* + u_{it}u_{it-1}) + E[(X_{it-1}^*)^2] + E(2X_{it-1}^*u_{it-1}) + E(u_{it-1}^2) \\
E[(\Delta X_{it})^2] &= \sigma_{X^*}^2 + 2E(X_{it}^*u_{it}) + \sigma_u^2 - 2[E(X_{it}^*X_{it-1}^*) + E(X_{it}^*u_{it-1}) + E(u_{it}X_{it-1}^*) + E(u_{it}u_{it-1})] + \sigma_{X^*}^2 + 2E(X_{it-1}^*u_{it-1}) + \sigma_u^2 \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 2E(X_{it}^*u_{it}) - 2E(X_{it}^*X_{it-1}^*) - 2E(X_{it}^*u_{it-1}) - 2E(u_{it}X_{it-1}^*) - 2E(u_{it}u_{it-1}) + 2E(X_{it-1}^*u_{it-1}) \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 2\text{Cov}(X_{it}^*, u_{it}) - 2\text{Cov}(X_{it}^*, X_{it-1}^*) - 2\text{Cov}(X_{it}^*, u_{it-1}) - 2\text{Cov}(X_{it-1}^*, u_{it}) - 2\text{Cov}(u_{it}, u_{it-1}) + 2\text{Cov}(X_{it-1}^*, u_{it-1}) \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 2 * 0 - 2\text{Cov}(X_{it}^*, X_{it-1}^*) - 2 * 0 - 2 * 0 - 2 * 0 + 2 * 0 \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 0 - 2\sigma_{X^*}^2 \text{Cor}(X_{it}^*, X_{it-1}^*) - 0 - 0 - 0 - 0 \\
E[(\Delta X_{it})^2] &= 2(1 - \rho) \sigma_{X^*}^2 + 2\sigma_u^2, \tag{22}
\end{aligned}$$

donde $\rho = \text{Cor}(X_{it}^*, X_{it-1}^*)$. Del mismo modo, se puede demostrar que:

$$\begin{aligned}
\hat{\beta} &\rightarrow \beta - \frac{2\beta\sigma_u^2}{2(1-\rho)\sigma_{X^*}^2 + 2\sigma_u^2} \\
\hat{\beta} &\rightarrow \beta - \frac{2\beta\sigma_u^2}{2[(1-\rho)\sigma_{X^*}^2 + \sigma_u^2]} \\
\hat{\beta} &\rightarrow \beta - \frac{\beta\sigma_u^2}{(1-\rho)\sigma_{X^*}^2 + \sigma_u^2} \\
\hat{\beta} &\rightarrow \frac{\beta(1-\rho)\sigma_{X^*}^2 + \beta\sigma_u^2 - \beta\sigma_u^2}{(1-\rho)\sigma_{X^*}^2 + \sigma_u^2} \\
\hat{\beta} &\rightarrow \frac{\beta(1-\rho)\sigma_{X^*}^2}{(1-\rho)\sigma_{X^*}^2 + \sigma_u^2}. \tag{23}
\end{aligned}$$

6.2) Modelos no lineales.

Es bien sabido que las suposiciones VI estándar no son suficientes para la identificación de modelos no lineales de error en variables. Amemiya (1985) demostró que el estimador clásico de la variable instrumental puede ser inconsistente sin una estructura adicional. La literatura ofrece una variedad de estas restricciones, por ejemplo, desde distribuciones conocidas de errores de medición hasta formas más fuertes de VI.

Para ilustrar los problemas detrás de la VI clásica en entornos no lineales, se considera un ejemplo presentado en la página 912 de Cameron y Trivedi (2005). Considerar:

$$Y = \alpha + \beta f(X^*) + \epsilon \tag{24}$$

$$X = X^* + u, \tag{25}$$

donde $f(\cdot)$ es una función suave de una variable latente, X^* . Expansión de Taylor de $X^* = (X - u)$ alrededor de X produce:

$$\begin{aligned}
 f(X^*) &= f(X - u) \\
 f(X^*) &= f(X) + \frac{\partial f}{\partial X}(X^* - X) + \frac{1}{2!} \frac{\partial^2 f}{\partial^2 X}(X^* - X)^2 + \dots + \frac{1}{n!} \frac{\partial^n f}{\partial^n X}(X^* - X)^n + \dots \\
 f(X^*) &= f(X) - f' u + \frac{1}{2} f'' (-u)^2 + \dots + \frac{1}{n!} f^n (-u)^n + \dots
 \end{aligned} \tag{26}$$

Se supone, por simplicidad, que $f = \gamma X + X^2$ es cuadrática. En este caso, la aproximación es exacta (por ejemplo, no se tiene un término recordatorio R). Tener en cuenta que $f' = 2X + \gamma$ y $f'' = 2$. Reemplazando, se tiene que:

$$\begin{aligned}
 Y &= \alpha + \beta f(\gamma X + X^2) + \epsilon \\
 Y &= \alpha + \beta [(\gamma X + X^2) - (2X + \gamma) u + \frac{1}{2} * 2 u^2] + \epsilon \\
 Y &= \alpha + \beta (\gamma X + X^2 - 2Xu - \gamma u + u^2) + \epsilon \\
 Y &= \alpha + \beta \gamma X + \beta X^2 - 2\beta Xu - \beta \gamma u + \beta u^2 + \epsilon \\
 Y &= \alpha + \beta \gamma X + \beta X^2 + (\epsilon - 2\beta Xu - \beta \gamma u + \beta u^2).
 \end{aligned} \tag{27}$$

Por lo tanto, VI necesita satisfacer:

1. $E(Z_1 X) \neq 0$ y $E(Z_2 X^2) \neq 0$,
2. $E[Z_j (\epsilon - 2\beta Xu - \beta \gamma u + \beta u^2)] = 0$,

que, obviamente, no es equivalente a $E(Z_j \epsilon) = E(Z_j u) = 0$.