

Lectura 7: **MGM, EMV y Pruebas para Restricciones no Lineales.**

Esta lectura presenta el Método Generalizado de Momentos (MGM), la Estimación de Máxima Verosimilitud (EMV) en una configuración de regresión y analiza las pruebas de restricciones no lineales. Como se verá más adelante, el método de máxima verosimilitud es conveniente para tratar con modelos no lineales y, en algunos casos, con hipótesis no lineales. Por ejemplo, si tiene un resultado binario (por ejemplo, $y_i = 1$ si el gobernador fue elegido y $y_i = 0$ de lo contrario) y variables observables (por ejemplo, impuestos, tasa de desempleo del estado, etc.), se puede mostrar que el modelo de media condicional es:

$$E(y | x) = P(y = 1 | x) = F(x'\beta).$$

En las siguientes secciones, se discutirá el método y los procedimientos de prueba asociados.

1) Método Generalizado de Momentos (MGM).

Antes de presentar el enfoque de MGM, se repasarán, brevemente, algunos ejemplos simples del Método de Momentos. Considerar $\{y_i\}$ extraído de una distribución i.i.d., cuyo primer momento existe (por ejemplo, y no se distribuye como Cauchy). En la población:

$$E(y - \mu) = 0,$$

así que se puede utilizar la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}.$$

Otro ejemplo que ya se analizó es el estimador VI, que se puede definir en términos de la condición del momento:

$$\begin{aligned} E(z_i u_i) &= E[E(z_i u_i | z)] \\ E(z_i u_i) &= E[z_i E(u_i | z)] \\ E(z_i u_i) &= E(z_i * 0) \\ E(z_i u_i) &= E(0) \\ E(z_i u_i) &= 0 \end{aligned}$$

o, alternativamente:

$$E[z_i (y_i - x_i'\beta)] = 0.$$

El estimador VI podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n z_i (y_i - x_i'\beta) = 0,$$

obteniendo el estimador de variable instrumental presentado en la lectura anterior:

$$\hat{\beta}_{VI} = (\sum_{i=1}^n z_i x_i')^{-1} \sum_{i=1}^n z_i y_i$$

$$\hat{\beta}_{VI} = (Z'X)^{-1} Z'y.$$

Se generaliza el procedimiento, directamente, considerando modelos que satisfacen la condición:

$$E [g (w_i, \theta_0)] = 0,$$

donde $g (.)$ es una función en $\mathbb{R}^l$ y el parámetro $\theta_0 \in \Theta \subset \mathbb{R}^p$. Por ejemplo, $g (w_i, \theta_0)$ tiene la siguiente forma lineal:

$$z_i (y_i - x_i' \beta) = 0,$$

con el requisito mínimo de p condiciones de momento (por ejemplo, $l = p$).

Ahora, se supone que se tienen condiciones de momento con $l > p$. La contraparte del momento de la muestra:

$$g_n = \frac{1}{n} \sum_{i=1}^n g (w_i, \theta_0)$$

no tiene solución, pero se puede seleccionar p combinaciones lineales de los momentos de muestra para obtener el estimador. Por lo tanto, dado $g_n (\theta)$, se puede elegir una matriz semidefinida positiva W_n y definir el estimador que minimiza:

$$\hat{\theta}_{MGM} = \arg \min_{\theta \in \Theta} \|g_n (\theta)\|_{W_n}^2$$

$$\hat{\theta}_{MGM} = \arg \min_{\theta \in \Theta} g_n (\theta)' W_n g_n (\theta)$$

La matriz $W_n \rightarrow W$ a medida que el tamaño de la muestra se va a infinito, con W siendo definida positiva. Por supuesto, la matriz W_n es importante para la estimación.

1.1) Ejemplo: Mínimos Cuadrados Ordinarios.

Considerar el caso donde los errores y las variables independientes son independientes. Para el estimador MCO, las condiciones son:

$$E [x_i (y_i - x_i' \beta)] = 0.$$

Las condiciones de los momentos de muestra son:

$$g_n = \frac{1}{n} \sum_{i=1}^n x_i (y_i - x_i' \beta).$$

El número de condiciones de momento es igual al número de parámetros desconocidos. En este caso, se dice que el modelo se identifica de manera justa o exacta. El caso VI, ilustrado arriba, también representa un caso en el que el modelo está, exactamente, identificado.

1.2) Ejemplo: Mínimos Cuadrados de Dos Etapas.

Para MC2E, se pueden tener más condiciones de momento que parámetros [por ejemplo, $\dim(z_i) > \dim(x_i)$], pero una matriz W adecuada será suficiente para obtener el estimador:

$$\arg \min g_n(\beta)' W_n g_n(\beta),$$

con $W_n = (Z'Z)^{-1}$ y $g_n = Z'(y - X\beta)$. Tener en cuenta que:

$$X'ZWZ'(y - X\beta) = 0$$

implica:

$$\hat{\beta} = (X'ZWZ'X)^{-1}X'ZWZ'y$$

$$\hat{\beta} = [X'Z(Z'Z)^{-1}Z'X]^{-1}X'Z(Z'Z)^{-1}Z'y$$

$$\hat{\beta} = (X'P_ZX)^{-1}X'P_Zy.$$

La solución depende de la matriz W y, por supuesto, la solución del problema de minimización es la misma para las W que difieren en una constante de proporcionalidad. Tener en cuenta que esto se relaciona con el supuesto de errores homocedásticos. ¿Cuál debería ser la matriz de ponderación bajo heterocedasticidad? Sea S la matriz de covarianza del momento g :

$$S = \frac{1}{n} E(Z'uu'Z)$$

$$S = \frac{1}{n} Z'\Omega Z.$$

Para obtener el estimador MGM óptimo, en este caso, se necesita:

1. Estimar $\hat{\beta}$ por el método VI para obtener $\hat{u}$.
2. Usar $\hat{u}$ para encontrar:

$$\hat{W} = \hat{S}^{-1} = n (Z'\hat{\Omega}Z)^{-1}, \text{ donde } \hat{\Omega} = \text{diag}(\hat{u}_i^2).$$

3. Encontrar el MGM óptimo y viable como:

$$\hat{\beta} = [X'Z(Z'\hat{\Omega}Z)^{-1}Z'X]^{-1}X'Z(Z'\hat{\Omega}Z)^{-1}Z'y.$$

2) Consideraciones Adicionales.

Si el modelo está identificado, el estimador es consistente y tiene distribución asintóticamente normal bajo condiciones de regularidad:

1. La primera condición de regularidad asume que:

$$\frac{\partial g_n(\theta)'}{\partial \theta'} \rightarrow \frac{\partial E[g(\theta)]}{\partial \theta'} = G.$$

2. También se asume la consistencia estándar de la raíz cuadrada:

$$\sqrt{n} g_n(\theta) \rightsquigarrow \mathcal{N}(0, S^{-1}).$$

Entonces, el estimador tiene distribución asintóticamente normal:

$$\sqrt{n}(\hat{\theta} - \theta) \rightsquigarrow \mathcal{N}(0, (G'WG)^{-1}G'WSW'G(G'WG)^{-1}).$$

Si se elige W_n tal que $W_n \rightarrow S^{-1} = W$, se tiene que la varianza asintótica es, simplemente:

$$\begin{aligned} & (G'S^{-1}G)^{-1}G'S^{-1}SS^{-1}G(G'S^{-1}G)^{-1} \\ & (G'S^{-1}G)^{-1}G'IS^{-1}G(G'S^{-1}G)^{-1} \\ & (G'S^{-1}G)^{-1}G'S^{-1}G(G'S^{-1}G)^{-1} \\ & I(G'S^{-1}G)^{-1} \\ & (G'S^{-1}G)^{-1}, \end{aligned}$$

el caso que se conoce como MGM eficiente (Hansen 1982) cuando se conoce a S . Esto es, quizás, una desventaja del estimador, ya que requiere conocer la matriz de covarianza asintótica. La solución es estimarlo, pero esta idea puede fallar en muestras pequeñas e intermedias. Si el tamaño de la muestra no es lo suficientemente grande o si las condiciones del momento son grandes, la estimación de la matriz de covarianza asintótica en el primer paso puede dar como resultado estimaciones erróneas en el segundo paso. El problema se ha documentado en la literatura y se han propuesto varias soluciones (por ejemplo, estimación simultánea).

3) Estimación MV.

Sea $\{(y_i, x_i): i = 1, \dots, n\}$ una muestra distribuida de forma independiente e idéntica (i.i.d.) de la respuesta y y las variables independientes x .

Se puede definir la función de probabilidad como:

$$\mathcal{L}(\theta) = f(y, x | \theta),$$

pero, dado que nuestro objetivo es modelar el comportamiento de y en términos de x , se considera, directamente, la densidad condicional de y_i :

$$f(y_i | x_i, \theta_0).$$

Entonces, se puede definir la función de log-verosimilitud condicional como:

$$\ell(\theta; y_i | x_i) \equiv \log[f(y_i | x_i, \theta)].$$

Considerando una muestra i.i.d. de n observaciones $\{(y_i, x_i)\}$, la función de densidad condicional conjunta es, básicamente:

$$\prod_{i=1}^n f(y_i | x_i, \theta) = f(y_1 | x_1, \theta) \dots f(y_n | x_n, \theta)$$

y, en consecuencia, la función log-verosimilitud es:

$$\begin{aligned}\ell(\theta; y | x) &= \log \left[\prod_{i=1}^n f(y_i | x_i, \theta) \right] \\ \ell(\theta; y | x) &= \sum_{i=1}^n \log[f(y_i | x_i, \theta)].\end{aligned}$$

Ejemplo 1 (Escala de ubicación normal). Suponer que u_i se distribuye como $\mathcal{N}(\beta_0, \sigma^2)$. Entonces, la función de densidad de probabilidad es:

$$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(u_i - \beta_0)^2}{2\sigma^2}}.$$

Si las observaciones son independientes, se tiene:

$$(2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (u_i - \beta_0)^2},$$

y, en consecuencia, la probabilidad de registro como:

$$\ell(\beta_0, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (u_i - \beta_0)^2.$$

Ejemplo 2 (El modelo de regresión). Considerar el modelo de regresión clásico:

$$y_i = x_i' \beta + u_i,$$

donde y y x son i.i.d., variables aleatorias distribuidas conjuntamente. Las variables de transformación obtendrán el log-verosimilitud como:

$$\sum_{i=1}^n \log[f(y_i | x_i, \theta)] = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i' \beta)^2,$$

donde $\theta = (\beta, \sigma^2)$.

Ejemplo 3 (Densidad de Poisson). Considerar, ahora, que la variable dependiente y_i toma un valor discreto no negativo (por ejemplo, número de visitas al médico). La función de densidad de Poisson puede ser una dirección natural:

$$f(y | \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}; \quad y = 0, 1, 2, \dots$$

La especificación habitual en el análisis de regresión es $\lambda = e^{x'\beta}$, lo que lleva a una función de verosimilitud de la forma:

$$\sum_{i=1}^n \log[f(y_i | x_i, \theta)] = -\sum_{i=1}^n e^{x_i' \beta} + \sum_{i=1}^n y_i x_i' \beta - \sum_{i=1}^n \log y_i!.$$

3.1) Estimador de Máxima Verosimilitud.

Considerar los siguientes supuestos:

1. El modelo $y_i = m(x_i, u_i, \theta)$ se especifica correctamente, donde $m(\cdot)$ es una función conocida que puede ser lineal (por ejemplo, $y = x'\beta + u$).
2. $\{(y_i, x_i): i = 1, \dots, n\}$ es una muestra i.i.d.
3. Θ es un subespacio compacto en $\mathbb{R}^p$ que contiene θ_0 .

4. La función de densidad $f(y_1 | x, \theta)$ es continua y tiene derivadas continuas de segundo orden sobre un conjunto compacto.
5. La función de probabilidad tiene una solución única.

El principio MLE es elegir un estimador de un parámetro de la distribución condicional de y , θ_0 , que maximice la probabilidad de observar la muestra real. El estimador de máxima verosimilitud (MLE) es el estimador que maximiza la función de (log)verosimilitud:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \ell(\theta; y | x),$$

donde Θ es un subespacio compacto en $\mathbb{R}^p$ que contiene θ .

Ejemplo 4 (Regresión Lineal). La función de log-verosimilitud que se obtuvo antes de usar la notación matricial:

$$\text{const} - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)' (y - X\beta).$$

Tomando la condición de primer orden:

$$\frac{\partial \ell}{\partial \beta} = \frac{1}{\sigma^2} X' (y - X\beta) = 0.$$

$$\frac{\partial \ell}{\partial \sigma^2} = \frac{-n}{2\sigma^2} + \frac{1}{2\sigma^4} (y - X\beta)' (y - X\beta) = 0.$$

Resolviendo el sistema de ecuaciones, se encuentra que los estimadores MLE son:

$$\frac{1}{\sigma^2} X' (y - X\beta) = 0$$

$$X' (y - X\beta) = 0 * \sigma^2$$

$$X'y - X'X\beta = 0$$

$$X'X\beta = X'y$$

$$\hat{\beta} = \frac{X'y}{X'X}$$

$$\hat{\beta} = (X'X)^{-1} X'y.$$

$$\frac{-n}{2\sigma^2} + \frac{1}{2\sigma^4} (y - X\beta)' (y - X\beta) = 0$$

$$\frac{-n\sigma^2 + (y - X\beta)' (y - X\beta)}{2\sigma^4} = 0$$

$$-n\sigma^2 + (y - X\beta)' (y - X\beta) = 0 * 2\sigma^4$$

$$-n\sigma^2 + (y - X\beta)' (y - X\beta) = 0$$

$$n\sigma^2 = (y - X\beta)' (y - X\beta)$$

$$\hat{\sigma}^2 = \frac{1}{n} (y - X\hat{\beta})' (y - X\hat{\beta}).$$

Se sabe que el estimador $\hat{\beta}$ es insesgado porque es idéntico al estimador OLS. En contraste, el estimador del parámetro de varianza $\hat{\sigma}^2$ está sesgado (¿Por qué?). También:

$$\frac{\partial^2 \ell}{\partial \beta \partial \beta'} = \frac{-X'X}{\sigma^2}.$$

$$\frac{\partial^2 \ell}{\partial \beta \partial \sigma^2} = \frac{-X'(y - X\beta)}{\sigma^4}.$$

$$\frac{\partial^2 \ell}{\partial \sigma^2 \partial \beta'} = \frac{-(y - X\beta)' X}{\sigma^4},$$

$$\frac{\partial^2 \ell}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} + \frac{1}{\sigma^6} (y - X\beta)' (y - X\beta).$$

La esperanza de la matriz (p x p) de segundas derivadas se llama matriz de información:

$$I(\theta_0 | X) = -E \left(\frac{\partial^2 \ell}{\partial \theta \partial \theta'} | X \right)$$

$$I(\theta_0 | X) = - \begin{bmatrix} E \left(\frac{\partial^2 \ell}{\partial \beta \partial \beta'} \right) & E \left(\frac{\partial^2 \ell}{\partial \beta \partial \sigma^2} \right) \\ E \left(\frac{\partial^2 \ell}{\partial \sigma^2 \partial \beta'} \right) & E \left(\frac{\partial^2 \ell}{\partial^2 \sigma^2} \right) \end{bmatrix}$$

$$I(\theta_0 | X) = \begin{bmatrix} \frac{-X'X}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{bmatrix}.$$

Tener en cuenta que los elementos fuera de la diagonal de la matriz de información $I(\theta)$ son cero, lo que sugiere que $\hat{\beta}$ y $\hat{\sigma}^2$ son “independientes”. La matriz de segundas derivadas es n.s.d.

Ejemplo 5 (Densidad de Poisson). El caso de Poisson no tiene una solución explícita, por lo que los métodos numéricos son útiles en este caso. Al diferenciar la función de probabilidad, se obtiene $\hat{\beta}$ como la solución de:

$$\sum_{i=1}^n y_i x_i - \sum_{i=1}^n e^{x_i \hat{\beta}} x_i = 0.$$

El caso anterior es común en el análisis empírico. A veces, obtener el estimador MLE se complica al no proporcionar soluciones analíticas. A continuación, se analizarán, brevemente, las alternativas para superar el problema.

3.2) Eficiencia.

Se deja definir la función de puntuación como:

$$S_i = \frac{\partial \ell_i(\theta)}{\partial \theta}$$

$$S_i = \left[\frac{\partial \ell_i(\theta)}{\partial \theta_1}, \dots, \frac{\partial \ell_i(\theta)}{\partial \theta_p} \right],$$

con $E[S_i(\theta_0)] = 0$ y la matriz de Hessiana:

$$H_i = \frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'}$$

$$H_i = \frac{\partial S_i}{\partial \theta},$$

una matriz simétrica (p x p) de segundas derivadas. Evaluado en el verdadero parámetro θ_0 , se tiene que:

$$-E[H(\theta)] = -E \left[\frac{\partial^2 \ell(\theta)}{\partial \theta \partial \theta'} \right]$$

$$-E [H(\theta)] = E \left\{ \left[\frac{\partial \ell(\theta)}{\partial \theta} \right] \left[\frac{\partial \ell(\theta)}{\partial \theta} \right]' \right\}$$

$$-E [H(\theta)] = I(\theta_0).$$

Esta propiedad es importante para el análisis empírico. Calcula la segunda derivada de una función de probabilidad, pero la expresión anterior sugiere una alternativa, tal vez más fácil: calcular el producto de las dos funciones de puntuación. Sin embargo, se debe ser cauteloso. El análisis anterior se cumple cuando se conoce la distribución condicional de y .

En el caso de muestras i.i.d.:

$$-\sum_{i=1}^n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right] = -n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right]$$

$$-\sum_{i=1}^n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right] = n E \left\{ \left[\frac{\partial \ell_i(\theta)}{\partial \theta} \right] \left[\frac{\partial \ell_i(\theta)}{\partial \theta} \right]' \right\}$$

$$-\sum_{i=1}^n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right] = n \Omega(\theta),$$

indicando que la matriz de información es n veces la información contenida en una observación. Tener en cuenta que Ω es la varianza de la función de puntuación.

Se puede demostrar que el estimador MLE es consistente, lo que significa que:

$$\hat{\theta} \rightarrow \theta,$$

y, asintóticamente, normal:

$$\sqrt{n}(\hat{\theta} - \theta_0) \rightsquigarrow \mathcal{N}(0, (\Omega(\theta))^{-1}).$$

Si el número de observaciones es, suficientemente, grande, el estimador tiene una varianza asintótica que puede ser aproximada por el inverso de la información contenida en una observación. Este resultado muestra la eficiencia del estimador MLE, que alcanza el límite inferior de Cramer-Rao (el límite inferior de la varianza de los estimadores insesgados):

$$V(\tilde{\theta}) \geq [n I(\theta)]^{-1},$$

para cualquier estimador $\tilde{\theta}$ insesgado de θ_0 , siempre que la matriz de información no sea singular. Tener en cuenta que MLE es atractivo para la estimación de modelos paramétricos, ya que alcanza el límite inferior.

4) Procedimientos de Prueba.

Esta sección considera las pruebas de hipótesis lineal y no lineal. Se revisan tres pruebas basadas en el principio de probabilidad y se proporciona la base para considerar las pruebas cuando los métodos clásicos fallan. Se supone que se tiene una muestra i.i.d. de n observaciones $\{(y_i, x_i); i = 1, \dots, n\}$. Se considera prueba de hipótesis de la forma:

$$h(\theta) = 0,$$

donde $h(\cdot)$ es una función vectorial ($r \times 1$) de θ con $r \leq p$. Se supone que $H(\theta) = \frac{\partial h(\theta)}{\partial \theta}$ es una matriz ($p \times r$), está bien definida y tiene rango de columna completo:

$$\text{rango}(H(\theta)) = r,$$

lo que significa que las restricciones impuestas son independientes. Antes de considerar la prueba, permítanme definir un par de conceptos importantes. Se denota el espacio de parámetro restringido:

$$\Theta_0 = \{\theta \in \Theta \mid h(\theta) = 0\},$$

lo que implica que $\Theta_0 \subset \Theta$. Recordar que el estimador MLE se define como:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \ell(\theta).$$

Además, se puede definir el estimador MLE restringido como el argumento que maximiza la función de log-verosimilitud restringida:

$$\hat{\theta} = \arg \max_{\theta \in \Theta_0} \ell(\theta)$$

o equivalente:

$$\max_{\theta \in \Theta_0} \ell(\theta) \quad \text{sujeto a} \quad h(\theta) = 0.$$

4.1) Prueba de relación de verosimilitud.

La prueba se define como:

$$LR = 2 [\ell(\hat{\theta}) - \ell(\tilde{\theta})].$$

La intuición detrás de la prueba es que, si la hipótesis nula es verdadera, las funciones de probabilidad deberían ser similares. Por lo tanto, los valores más altos de LR implican mayores posibilidades de rechazar la hipótesis nula H_0 .

4.2) Prueba multiplicador de Lagrange.

$$LM = \frac{\partial \ell(\tilde{\theta})}{\partial \theta'} [I(\tilde{\theta})]^{-1} \frac{\partial \ell(\tilde{\theta})}{\partial \theta},$$

que está motivado por el hecho de que la función de puntuación $\frac{\partial \ell(\tilde{\theta})}{\partial \theta} = 0$. Por lo tanto, si la hipótesis nula H_0 es verdadera, se espera que el máximo que ocurre en $\frac{\partial \ell(\tilde{\theta})}{\partial \theta} \approx 0$ no rechace la nula.

4.3) Test Wald.

La prueba se define como:

$$W = [h(\hat{\theta})]' \{ [H(\hat{\theta})]' [I(\hat{\theta})]^{-1} H(\hat{\theta}) \}^{-1} h(\hat{\theta}).$$

Si H_0 es verdadera, $h(\hat{\theta})$ está cerca de cero. El estadístico de prueba es, asintóticamente, χ_r^2 , donde r denota el rango de la matriz H (es decir, $r = \text{rango}(H)$ -el número de restricciones impuestas por H_0 -).

Ejemplo 6 (Pruebas de restricciones no lineales). Considerar probar:

$$H_0: h(\theta) = \frac{\theta_1}{\theta_2} - c = 0.$$

Entonces, los estadísticos de Wald son:

$$W = \left(\frac{\theta_1}{\theta_2} - c \right) \left\{ \begin{bmatrix} \frac{1}{\theta_2} & -\frac{\hat{\theta}_1}{\hat{\theta}_2^2} & 0 \end{bmatrix} \begin{bmatrix} \hat{v}_{11} & \hat{v}_{12} & \hat{v}_{13} \\ \hat{v}_{21} & \hat{v}_{22} & \hat{v}_{23} \\ \hat{v}_{31} & \hat{v}_{32} & \hat{v}_{33} \end{bmatrix} \begin{bmatrix} \frac{1}{\hat{\theta}_2} \\ -\frac{\hat{\theta}_1}{\hat{\theta}_2^2} \\ 0 \end{bmatrix} \right\}^{-1} \left(\frac{\theta_1}{\theta_2} - c \right),$$

donde 0 es una matriz de ceros $((r - 2) \times r)$ y v_{jj} denota el elemento j -ésimo de la matriz de covarianza asintótica estimada. Bajo la nula, W se distribuye, asintóticamente, como χ_1^2 .

El problema con esta prueba es que depende de la matriz de covarianza asintótica estimada. Hay alternativas para las restricciones no lineales que se discutirán en los próximos cursos (por ejemplo, Método Delta, Bootstrap).

Ejemplo 7 (MLE restringido). Considerar, ahora, una probabilidad de largo plazo de la forma:

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)' (y - X\beta) + 2\lambda' (R\beta - \delta),$$

donde λ es un vector potencialmente $(p \times 1)$. Suponiendo que se conoce el valor de σ^2 , la solución se puede escribir como:

$$\frac{\partial \ell}{\partial \beta} = 0 \Rightarrow -2X'y + 2X'X\tilde{\beta} + 2R'\lambda = 0.$$

$$\frac{\partial \ell}{\partial \lambda} = 0 \Rightarrow R\tilde{\beta} = \delta.$$

En otras palabras:

$$\begin{bmatrix} X'X & R' \\ R & 0 \end{bmatrix} \begin{bmatrix} \tilde{\beta} \\ \lambda \end{bmatrix} = \begin{bmatrix} X'y \\ \delta \end{bmatrix}.$$

Por lo tanto:

$$(\tilde{\beta}', \tilde{\lambda}')' = \begin{bmatrix} X'X & R' \\ R & 0 \end{bmatrix}^{-1} \begin{bmatrix} X'y \\ \delta \end{bmatrix}.$$

Aplicando fórmulas de matriz con particiones inversas, se obtiene:

$$\begin{aligned}\tilde{\beta} &= (X'X)^{-1}X'y - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1}X'y + \\ & (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\beta} &= \hat{\beta} - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R\hat{\beta} + (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\beta} &= \hat{\beta} - D(R\hat{\beta} - \delta),\end{aligned}$$

donde $D = (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}$. Tener en cuenta que:

$$\begin{aligned}E(\tilde{\beta}) &= E[\hat{\beta} - D(R\hat{\beta} - \delta)] \\ E(\tilde{\beta}) &= E(\hat{\beta}) - E[D(R\hat{\beta} - \delta)] \\ E(\tilde{\beta}) &= \beta - D(R\beta - \delta) \\ E(\tilde{\beta}) &= \beta.\end{aligned}$$

si $R\beta - \delta = 0$ (la hipótesis nula es verdadera). Si es falsa, $\tilde{\beta}$ está sesgado.

En términos de la varianza de $\tilde{\beta}$, se tiene que:

$$\begin{aligned}V(\tilde{\beta}) &= V[\hat{\beta} - D(R\hat{\beta} - \delta)] \\ V(\tilde{\beta}) &= V(\hat{\beta} - DR\hat{\beta} + D\delta) \\ V(\tilde{\beta}) &= V[(I - DR)\hat{\beta}] + V(D\delta) \\ V(\tilde{\beta}) &= (I - DR)V(\hat{\beta})(I - DR)' + 0 \\ V(\tilde{\beta}) &= (I - DR)\sigma^2(X'X)^{-1}(I - DR)' \\ V(\tilde{\beta}) &= \sigma^2(I - DR)(X'X)^{-1}(I - DR)' \\ V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} - \sigma^2[DR(X'X)^{-1} + (X'X)^{-1}R'D' - DR(X'X)^{-1}R'D'].\end{aligned}$$

Tener en cuenta que:

$$\begin{aligned}DR(X'X)^{-1} &= (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1} \\ DR(X'X)^{-1} &= (X'X)^{-1}R'D'\end{aligned}$$

y:

$$\begin{aligned}DR(X'X)^{-1}R'D' &= (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1} \\ DR(X'X)^{-1}R'D' &= (X'X)^{-1}R'ID' \\ DR(X'X)^{-1}R'D' &= (X'X)^{-1}R'D'.\end{aligned}$$

Por lo tanto:

$$\begin{aligned}V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} - \sigma^2[DR(X'X)^{-1} + (X'X)^{-1}R'D' - (X'X)^{-1}R'D'] \\ V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} - \sigma^2DR(X'X)^{-1} \\ V(\tilde{\beta}) &= \sigma^2(X'X)^{-1}(I - DR) \leq V(\hat{\beta}).\end{aligned}$$

La solución para el multiplicador Lagrange es:

$$\begin{aligned}\tilde{\lambda} &= [R(X'X)^{-1}R']^{-1}R(X'X)^{-1}X'y - [R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\lambda} &= [R(X'X)^{-1}R']^{-1}R\hat{\beta} - [R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\lambda} &= WR\hat{\beta} - W\delta \\ \tilde{\lambda} &= W(R\hat{\beta} - \delta).\end{aligned}$$

Es fácil ver que $E(\tilde{\lambda}) = 0$ bajo la nula (*) y $V(\tilde{\lambda}) = \sigma^2 W$ (**).

$$(*) E(\tilde{\lambda}) = E[W(R\hat{\beta} - \delta)]$$

$$E(\tilde{\lambda}) = E(W * 0)$$

$$E(\tilde{\lambda}) = E(0)$$

$$E(\tilde{\lambda}) = 0.$$

$$(**) V(\tilde{\lambda}) = V[W(R\hat{\beta} - \delta)]$$

$$V(\tilde{\lambda}) = V(WR\hat{\beta} - W\delta)$$

$$V(\tilde{\lambda}) = V(WR\hat{\beta}) - V(W\delta)$$

$$V(\tilde{\lambda}) = WR V(\hat{\beta}) R'W' + 0$$

$$V(\tilde{\lambda}) = WR\sigma^2(X'X)^{-1}R'W'$$

$$V(\tilde{\lambda}) = \sigma^2 WR(X'X)^{-1}R'W'$$

$$V(\tilde{\lambda}) = \sigma^2 [R(X'X)^{-1}R']^{-1}R(X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}$$

$$V(\tilde{\lambda}) = \sigma^2 WI$$

$$V(\tilde{\lambda}) = \sigma^2 W.$$

5) Selección de Modelo.

En algunas situaciones, típicamente series de tiempo, es posible que no se conozca la dimensión del modelo (por ejemplo, cuántos parámetros debería tener nuestro modelo lineal). Akaike (1969) y Schwartz (1978) abordaron este aspecto importante de la modelización en estadística y en econometría.

En una configuración de regresión, la probabilidad se puede escribir como:

$$\ell(\beta, \sigma^2) = \frac{-n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta).$$

Al conectar $\hat{\beta}$ y $\hat{\sigma}^2 = \frac{S}{n}$, se obtiene la función de probabilidad concentrada:

$$\ell(\hat{\sigma}^2) = \frac{-n}{2} \log(2\pi) - \frac{n}{2} - \frac{n}{2} \log \hat{\sigma}^2,$$

sugiriendo que, para un tamaño de muestra dado, la probabilidad se puede aumentar agregando covariables al modelo para reducir la suma de cuadrados residual S.

Akaike (1969) propuso elegir un modelo de un conjunto que funcione bien en función de los pronósticos. Su propuesta se basa en la siguiente función:

$$AIC(j) = \ell_j(\hat{\theta}) - p_j,$$

donde $\ell_j(\hat{\theta})$ es la probabilidad correspondiente al modelo j^{th} maximizado sobre j (típicamente, se tiene $p_1 < p_2 < \dots < p_n$). AIC significa Criterios de Información de Akaike. La idea básica del término adicional en AIC, llamado término de penalización, es traer una regla sobre el ajuste de varias especificaciones “penalizando” un aumento en el número de regresiones. La regla de selección de modelo de Akaike fue evaluar AIC(j) sobre j modelos, eligiendo el modelo j^* que maximiza AIC(j).

Un último criterio, conocido como criterio de información de Schwarz, se basa en un enfoque bayesiano del problema analizado en Akaike (1969). Schwarz propuso:

$$SIC(j) = \ell_j(\hat{\theta}) - \frac{1}{2} p_j \log n.$$

Tener en cuenta que maximizar SIC:

$$\ell_j(\hat{\theta}) - \frac{1}{2} p_j \log n$$

es equivalente a minimizar:

$$\log \hat{\sigma}_j^2 - \frac{p_j}{n} \log n.$$

Es posible mostrar que los estadísticos de prueba:

$$T_n = 2 [\ell_j(\hat{\theta}_j) - \ell_i(\hat{\theta}_i)] \rightsquigarrow \chi_{p_j - p_i}^2,$$

para $p_j > p_i = p$ (tener en cuenta que el modelo i es el modelo verdadero). Las pruebas de hipótesis clásicas sugerirían rechazar la hipótesis nula de que el modelo más pequeño i es el modelo verdadero si y sólo si el valor de T_n excede un valor crítico de $\chi_{p_j - p_i}^2$. Por otro lado, SIC puede elegir j sobre i si:

$$2 \frac{\ell_j - \ell_i}{p_j - p_i} > \log n \quad (1)$$

porque:

$$0 = [\ell_j(\hat{\theta}) - \frac{p_j}{2} \log n] - [\ell_i(\hat{\theta}) - \frac{p_i}{2} \log n]$$

$$0 = [\ell_j(\hat{\theta}) - \ell_i(\hat{\theta})] - \frac{1}{2} (p_j - p_i) \log n.$$

Tener en cuenta que el número de observaciones está actuando como el valor crítico de la prueba. Esto está estrechamente relacionado con la prueba F clásica, ya que es posible demostrar que, considerando la simplicidad $p_j - p_i = 1$:

$$2 (\ell_i - \ell_j) = -n (\log \hat{\sigma}_i^2 - \log \hat{\sigma}_j^2)$$

$$2 (\ell_i - \ell_j) = n (\log \hat{\sigma}_j^2 - \log \hat{\sigma}_i^2)$$

$$2 (\ell_i - \ell_j) = n \log \frac{\hat{\sigma}_j^2}{\hat{\sigma}_i^2}$$

$$2 (\ell_i - \ell_j) = n \log \left(1 + \frac{\hat{\sigma}_j^2}{\hat{\sigma}_i^2} - 1 \right)$$

$$2 (\ell_i - \ell_j) = n \log (1 + a),$$

donde $a = \frac{\hat{\sigma}_j^2}{\hat{\sigma}_i^2} - 1$. Usando $\log (1 + a) \approx a$ para un a pequeño, se tiene:

$$2(\ell_i - \ell_j) \approx \frac{n(\hat{\sigma}_j^2 - \hat{\sigma}_i^2)}{\hat{\sigma}_i^2} > \log n. \quad (2)$$

El LHS de la ecuación (2) puede interpretarse como una prueba F, ya que puede escribirse, aproximadamente, como:

$$\frac{SSR_r - SSR_u}{SSR_u}.$$

Se utilizará AIC y BIC como dispositivos de selección de modelos para modelos de series temporales. Se puede encontrar un ejemplo preliminar en el tutorial de las notas de esta conferencia.

6) Una Digresión (Final).

El marco anterior se conecta muy bien con el análisis de Big Data. Considerar el siguiente estimador:

$$\hat{\beta} = \arg \min [\sum_{i=1}^n (y_i - x_i' \beta)^2 + P(\beta, \lambda)], \quad (3)$$

donde $P(\beta, \lambda)$ es una función de penalización y es un parámetro de ajuste. Por ejemplo, la función de penalización puede ser:

$$P(\beta, \lambda) = \lambda \sum_{j=1}^p |\beta_j|^q, \quad (4)$$

para $q = \{1, 2\}$. El modelo aquí es escaso en los coeficientes y la solución del problema de optimización depende del valor del parámetro de contracción y de la función de penalización.

Para funciones de penalización, fácilmente, diferenciables, por ejemplo, se tiene que:

$$\begin{aligned} u'u + \lambda \beta' \beta &= (y - X\beta)'(y - X\beta) + \lambda \beta' \beta \\ u'u + \lambda \beta' \beta &= (y' - \beta' X') (y - X\beta) + \lambda \beta' \beta \\ u'u + \lambda \beta' \beta &= y'y - 2\beta' X'y + \beta' X' X \beta + \lambda \beta' \beta. \end{aligned} \quad (*) \text{ y } (**)$$

$$\begin{aligned} (*) \quad (X\beta)^2 &= (X\beta)'(X\beta) \\ (X\beta)^2 &= \beta' X' X \beta. \end{aligned}$$

(**) $\beta' X'y$ es un escalar, por lo que es, trivialmente, igual a su transpuesto, $y' X \beta$.

Suponiendo $\frac{\lambda}{2}$ dado, la CPO $-X'y + X'X\beta + \lambda\beta = 0$. Por lo tanto:

$$\begin{aligned} -2X'y + 2X'X\beta + 2\lambda\beta &= 0 \\ 2(-X'y + X'X\beta + \lambda\beta) &= 0 \\ -X'y + X'X\beta + \lambda\beta &= \frac{0}{2} \\ -X'y + X'X\beta + \lambda\beta &= 0 \\ (X'X + \lambda I) \beta &= X'y \\ \hat{\beta} &= \frac{X'y}{X'X + \lambda I} \end{aligned}$$

$$\hat{\beta} = (X'X + \lambda I)^{-1} X'y.$$

Se puede demostrar que:

$$\begin{aligned} E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'y] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'(X\beta + u)] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta + (X'X + \lambda I)^{-1} X'u] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + E[(X'X + \lambda I)^{-1} X'u] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + (X'X + \lambda I)^{-1} X' E(u) \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + (X'X + \lambda I)^{-1} X' * 0 \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + 0 \\ E(\hat{\beta}) &= (X'X + \lambda I)^{-1} X'X\beta. \end{aligned}$$

$$\begin{aligned} V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'y] \\ V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'(X\beta + u)] \\ V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'X\beta + (X'X + \lambda I)^{-1} X'u] \\ V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'X\beta] + V[(X'X + \lambda I)^{-1} X'u] \\ V(\hat{\beta}) &= 0 + (X'X + \lambda I)^{-1} X' V(u) X(X'X + \lambda I)^{-1} \\ V(\hat{\beta}) &= (X'X + \lambda I)^{-1} X' \sigma^2 X (X'X + \lambda I)^{-1} \\ V(\hat{\beta}) &= (X'X + \lambda I)^{-1} \sigma^2 X'X (X'X + \lambda I)^{-1}. \end{aligned}$$

7) Apéndice.

Se recuerda que $1 = \int f(x) dx$. Diferenciando ambos lados:

$$\begin{aligned} 0 &= \int \frac{1}{f} f_{\theta}(x) f dx \\ 0 &= \int \frac{\partial \log f}{\partial \theta} f dx \end{aligned}$$

Se sabe:

$$\begin{aligned} 0 &= \int \frac{\partial \log f}{\partial \theta} f dx \\ 0 &= \int \left(\frac{\partial^2 \log f}{\partial \theta \partial \theta'} + \frac{\partial \log f}{\partial \theta} \frac{\partial f}{\partial \theta'} \right) dx \\ 0 &= \int \left(\frac{\partial^2 \log f}{\partial \theta \partial \theta'} + \frac{\partial \log f}{\partial \theta} \frac{\partial \log f}{\partial \theta'} f \right) dx \\ 0 &= \int \frac{\partial^2 \log f}{\partial \theta \partial \theta'} dx + \int \frac{\partial \log f}{\partial \theta} \frac{\partial \log f}{\partial \theta'} f dx. \end{aligned}$$