

Lectura 1: **El Modelo de Regresión Lineal.**

El plan de esta lectura es ofrecer una revisión del análisis de regresión para la función media condicional $E(y | x_j, x_{-j})$. Se introducirá el modelo de regresión básico y, luego, nos concentraremos en el caso simple de una regresión bivariada. Al final de la lectura, se discuten las propiedades estadísticas del estimador de Mínimos Cuadrados Ordinarios (MCO).

1) Análisis de Regresión Multivariable.

Se comienza asumiendo un modelo lineal con p variables independientes:

$$\underset{1 \times 1}{y} = \underset{1 \times p}{x'} \underset{p \times 1}{\beta} + \underset{1 \times 1}{u}, \quad (1)$$

donde y es la respuesta o variable dependiente y β son los coeficientes asociados con las variables independientes x' . En el núcleo de la econometría, está el concepto de efectos causales o relaciones causales. Obviamente, no se refiere a la noción de correlación entre x_j e y desde $\text{Corr}(x_j, y) = \text{Corr}(y, x_j)$.

Se define x_j como una variable independiente, y pasa a ser una variable dependiente y se podrían tener otras variables (independientes) que se mantienen en un nivel constante, x_{-j} . Para investigar las relaciones causales, se emplean modelos y el modelo clásico de interés es el valor esperado condicional de la variable dependiente condicional en las variables independientes:

$$E(y | x_j, x_{-j}) = E(y | x) = \int y f_{Y|X=x} dx.$$

También se puede definir:

$$\frac{\partial E(y | x_j, x_{-j})}{\partial x_j} = \text{efecto parcial.}$$

obtenido manteniendo x_{-j} igual a una constante. Tener en cuenta que esto está bien definido si x_j es una variable continua.

Para estimar los efectos causales, una suposición crucial es que todos los factores observables (las variables independientes $x_1, x_2, \dots, x_p$) que afectan a la variable dependiente y no están correlacionados con el término de error.

$$E(u | x_1, x_2, \dots, x_p) = 0. \quad (2)$$

Si se cumple la condición (2), se dice que las variables $\{x_1, x_2, \dots, x_p\}$ son estrictamente exógenas. Como se explica a continuación, la implicación es que el término de error tiene una media igual a cero.

$$E(u | x) = E(u) = 0.$$

Para resumir, los primeros dos supuestos del modelo de regresión clásico son:

- A1 (Linealidad): El modelo es lineal como en (1).
- A2 (Exogeneidad estricta): Se supone que $E(u | x_1, x_2, \dots, x_p) = 0$.

Más adelante, se utilizará un modelo con p variables independientes como en la ecuación (1). Concentrémonos, ahora, en un caso particular, suponiendo que se tiene una variable independiente, $p = 2$.

2) Expectativas Condicionales.

El modelo de regresión simple es:

$$y = \beta_0 + \beta_1 x + u, \quad (3)$$

donde y es la variable dependiente, x es la variable independiente y u es el término de error o perturbación. El modelo sugiere que los cambios en y son inducidos por cambios en x y u . Se quiere saber cuánto y se puede explicar en términos de x .

Ejemplo 1. Se supone que se quiere saber el efecto de la educación en los salarios y los salarios y la educación están relacionados linealmente. Entonces, se puede escribir:

$$\text{wages} = \beta_0 + \beta_1 \text{educ} + u. \quad (4)$$

En este ejemplo, se supone que la relación entre la variable de respuesta y la variable independiente es lineal en los parámetros β_0 y β_1 . Puede ser que el modelo sea:

$$\ln(\text{wages}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{educ}^2 + u,$$

que no es lineal en las variables.

Se puede definir la función de regresión de la población (FRP) o, en este caso, la línea de regresión de la población (LRP) de la ecuación (3) como:

$$\begin{aligned} E(y | x) &= E(\beta_0 + \beta_1 x + u | x) \\ E(y | x) &= E(\beta_0 | x) + E(\beta_1 x | x) + E(u | x) \\ E(y | x) &= \beta_0 + \beta_1 x + 0 \\ E(y | x) &= \beta_0 + \beta_1 x. \end{aligned} \quad (5)$$

por las suposiciones A1 y A2. Dice que el valor esperado de la variable dependiente para un valor dado de las variables independientes es igual al parámetro β_0 más β_1 multiplicado por la variable independiente. En el caso de la LRP con un parámetro de pendiente, el modelo contiene dos parámetros desconocidos β_0 (la intersección) y β_1 (la pendiente).

Nuestro interés radica en estimar la FRP, lo que implica estimar las dos incógnitas, es decir, el intercepto y la pendiente.

Ahora, se discuten las implicaciones de las condiciones previas A1 y A2. Se puede escribir el modelo como:

$$y = E(y | x) + u.$$

(6)

$$E(u | x) = 0. \quad (7)$$

La ecuación (7) implica:

$$E(u) = 0. \quad (8)$$

$$\text{Cov}(u, x_j) = 0, \quad \text{para } j = 1, \dots, p. \quad (9)$$

$$\text{Cov}(u, h(x_j)) = 0, \quad \text{para } j = 1, \dots, p. \quad (10)$$

donde Cov denota covarianza y $h(\cdot)$ es una función conocida [por ejemplo, $h(x_1) = x_1^2$, $h(x_1, x_2) = x_1 x_1^2$, $h(x_2) = e^{x_2 x_2^2}$, etc.]. Para ver estos resultados, primero, tener en cuenta que, por definición, $u = y - E(y | x)$. Entonces:

$$E(u) = E[y - E(y | x)]$$

$$E(u) = E(y) - E[E(y | x)]$$

$$E(u) = E(y) - E(y)$$

$$E(u) = 0. \quad (11)$$

Para mostrar que también implica independencia entre el término de error y las covariables, se tiene que demostrar que:

$$E(ux) = E[E(ux | x)]$$

$$E(ux) = E[x E(u | x)]$$

$$E(ux) = E(x * 0)$$

$$E(ux) = E(0)$$

$$E(ux) = 0. \quad (12)$$

Por lo tanto, las condiciones (11) y (12) implican, para $j = 1, \dots, p$:

$$\text{Cov}(u, x_j) = E(ux_j) - E(x_j) E(u)$$

$$\text{Cov}(u, x_j) = 0 - E(x_j) * 0$$

$$\text{Cov}(u, x_j) = 0 - 0$$

$$\text{Cov}(u, x_j) = 0. \quad (13)$$

3) Mejor Predictor Lineal.

Se define una función de pérdida de una forma genérica, $L(u) = L[y - m(x)]$, donde $m(x)$ es el predictor en términos de x y u es el error de predicción. Naturalmente, un tomador de decisiones intenta resolver el siguiente problema:

$$\min_{m \in M} E \{L[y - m(x)] | x\},$$

es decir, le gustaría elegir un predictor de y que minimice la pérdida esperada.

Es conveniente asumir una pérdida cuadrática [por ejemplo, $L(u) = u^2$]. Por lo tanto, el problema puede ser transformado para minimizar el error cuadrático medio de $m(x)$ para y :

$$\begin{aligned} E\{[y - m(x)]^2 | x\} &= E\{[y - \mu(x) + \mu(x) - m(x)]^2 | x\} \\ E\{[y - m(x)]^2 | x\} &= E\{[y - \mu(x)]^2 + [\mu(x) - m(x)]^2 + 2[(y - \mu(x))(\mu(x) - m(x))] | x\} \\ E\{[y - m(x)]^2 | x\} &= E\{[y - \mu(x)]^2 | x\} + E\{[\mu(x) - m(x)]^2 | x\} + 2E\{[(y - \mu(x))(\mu(x) - m(x))] | x\} \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + E\{[\mu(x) - m(x)]^2\} + 2[\mu(x) - m(x)] E[(y - \mu(x))] \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 2[\mu(x) - m(x)] \{E(y) - E[\mu(x)]\} \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 2[\mu(x) - m(x)] [\mu(x) - \mu(x)] \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 2[\mu(x) - m(x)] * 0 \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2 + 0 \\ E\{[y - m(x)]^2 | x\} &= V(y | x) + [\mu(x) - m(x)]^2, \end{aligned}$$

donde $V(y | x)$ es la varianza condicional de y .

Si los primeros dos momentos condicionales de y existen [por ejemplo, $E(y | x) < \infty$ y $V(y | x) < \infty$], el error cuadrático medio (incondicional) se minimiza a la varianza condicional de y cuando $m(x)$ es igual a la media condicional $\mu = E(y | x)$:

$$E\{[y - m(x)]^2\} = V(y | x).$$

Se supone, ahora, que se conoce la forma funcional de m . Por ejemplo, considerar, ahora, que es un modelo lineal en parámetros:

$$\begin{aligned} \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y - x'\beta)'(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y' - \beta'x)(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[y^2 - y'x'\beta - \beta'xy + (x'\beta)^2] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y - 2\beta'xy + \beta'xx'\beta) \quad (*) \text{ y } (**) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - E(2\beta'xy) + E(\beta'xx'\beta) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - 2\beta' E(xy) + \beta' E(xx') \beta. \end{aligned}$$

$$\begin{aligned} (*) \quad (x'\beta)^2 &= (x'\beta)'(x'\beta) \\ (x'\beta)^2 &= \beta'xx'\beta. \end{aligned}$$

(**) $\beta'xy$ es un escalar, por lo que es, trivialmente, igual a su transpuesto, $y'x'\beta$.

Tomando la condición de primer orden, se tiene:

$$\begin{aligned} -2 E(xy) + 2 E(xx') \beta &= 0 \quad (***) \text{ y } (****) \\ 2 E(xx') \beta &= 2 E(xy) \\ \beta &= \frac{2E(xy)}{2E(xx')} \\ \beta &= [E(xx')]^{-1} E(xy). \end{aligned}$$

(***) $\frac{\partial(b'a)}{\partial b} = a$, donde a y b son dos vectores de dimensiones $(p \times 1)$.

(****) $\frac{\partial(b'Ab)}{\partial b} = 2Ab$, donde b es un vector de dimensión $(p \times 1)$ y A es una matriz simétrica de dimensión $(p \times p)$.

Por lo tanto, el parámetro β se puede interpretar como el mejor predictor lineal bajo la pérdida de error al cuadrado.

Tener en cuenta que, para que exista, se necesita la dimensión $(p \times p)$ de la matriz $E(xx')$ para ser invertible. También se necesita que $E(y^2) < \infty$ y $E(\sum_j x_j^2) < \infty$ [ver Hansen (2017), Teorema 2.18.1]. Si no se incluyen variables redundantes en el vector x , entonces, la matriz de diseño $E(xx')$ es invertible y se puede decir que β es único e identificado. Un requisito es que $E(xx')$ sea definida positiva. La identificación, en esta clase de modelos lineales, significa que se puede escribir el parámetro de interés en términos de condiciones de momento que son funciones de variables observadas tales como y y $x_1, x_2, \dots, x_p$.

Esto está relacionado con otra suposición del modelo lineal. La condición:

- A3 (Matriz de diseño de rango completo): El rango de $E(xx') = p$.

Esta condición descarta la colinealidad perfecta o, en otras palabras, descarta relaciones lineales exactas entre las variables independientes.

4) Efectos Parciales y Elasticidades.

Considerar que se tiene el siguiente modelo de regresión de la población:

$$E(y | x) = \beta_0 + \sum_{j=1}^p \beta_j x_j,$$

y se está interesado en el efecto marginal de la j -ésima variable independiente sobre el valor esperado condicional de y :

$$\frac{\partial E(y | x)}{\partial x_j} = \beta_j.$$

Esto dice el aumento en el valor medio de y cuando la variable independiente se incrementa en 1 unidad, manteniendo todo lo demás constante. Esta interpretación es equivalente a la noción de *ceteris paribus*: el efecto de x sobre y , manteniendo todo lo demás constante. Notar que, si x_i y x_j están relacionados, encontrar el efecto marginal es algo más complicado, pero la linealidad del modelo de regresión tiene una implicación simple y, a veces, útil para el análisis empírico.

Considerar el siguiente modelo con $p=4$ y $x_3 = x_1 x_2$:

$$E(y | x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2,$$

donde $x' = (1, x_1, x_2, x_3)$. El efecto parcial de x_1 en el valor esperado condicional de la variable dependiente es:

$$\frac{\partial E(y | x)}{\partial x_1} = \beta_1 + \beta_3 x_2$$

y

$$\frac{\partial E(y | x)}{\partial x_2} = \beta_2 + \beta_3 x_1.$$

A veces, se está interesado en la elasticidad de y con respecto a x_j :

$$\frac{\partial \log(y)}{\partial \log(x_j)} = \frac{\partial y}{\partial x_j} \frac{x_j}{y}.$$

Nuestra elasticidad parcial es:

$$\frac{\partial E(y | x)}{\partial x_j} \frac{x_j}{E(y | x)} = \frac{\partial \log[E(y | x)]}{\partial \log(x_j)}.$$

Por ejemplo, la elasticidad parcial con respecto a x_1 en nuestro ejemplo anterior es:

$$\frac{\partial E(y | x)}{\partial x_1} \frac{x_1}{E(y | x)} = \frac{(\beta_2 + \beta_3 x_2)x_1}{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2}.$$

Cuando y y x no están correlacionados, como es el caso en los modelos anteriores, se puede tener una definición alternativa de elasticidad que es más conveniente:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)}.$$

Tener en cuenta que $E(y | x) = e^{x'\beta}$ implica:

$$\log[E(y | x)] = x'\beta.$$

Si $y = e^{x'\beta + u}$, entonces, $\log(y) = x'\beta + u$ y, por suposiciones previas, $E[\log(y)] = x'\beta$, ya que $E(u | x) = 0$.

Por lo tanto, el parámetro β_j se debe interpretar como una elasticidad si el modelo está en una forma “log-log”:

$$\log(y) = \beta_0 + \beta_1 \log(x_1) + \beta_2 \log(x_2) + u,$$

o como una semielasticidad si el modelo es un modelo “log-lineal”:

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u.$$

Lo que implica que el efecto parcial es:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)} = \beta_j.$$

Por último, se puede introducir el concepto de efectos parciales promedio (para más detalles, ver Blundell y Powell 2003). Se supone que se tiene el siguiente modelo:

$$E(y | x, z) = g(x, z),$$

donde x es una variable observada y z es una variable latente. El efecto parcial es:

$$\frac{\partial E(y | x, z)}{\partial x_j} = \frac{\partial g(x, z)}{\partial x_j}.$$

Tener en cuenta que el efecto parcial depende de una variable latente que puede tomar diferentes valores de una distribución subyacente. El efecto parcial promedio en $x = x_0$ es:

$$\delta_j(x_0) = E\left[\frac{\partial g(x_0, z)}{\partial x_j}\right] = \int \frac{\partial g(x_0, z)}{\partial x_j} f(z) dz.$$

¿Se puede estimar el efecto parcial promedio si no se observa z ? Se tienen, esencialmente, dos casos importantes. Si x y z son independientes, el efecto parcial promedio es, simplemente, el efecto parcial con respecto a x_j :

$$\frac{\partial E(y | x)}{\partial x_j}.$$

Alternativamente, si se quiere modelar la heterogeneidad no observada, se puede encontrar $E(y | x)$ integrándola sobre la distribución de la variable latente z .

Ejemplo 2. Suponer:

$$y = \beta_0 + \beta_1 x_1 + \gamma_1 x_1 z_1 + u,$$

donde $E(u | x_1, z_1) = 0$. El modelo de media condicional es:

$$E(y | x, z) = \beta_0 + \beta_1 x_1 + \gamma_1 x_1 z_1$$

y

$$\frac{\partial E(y | x, z)}{\partial x_1} = \beta_1 + \gamma_1 z_1.$$

Si $E(z_1) = E(z_1 | x_1) = 0$, entonces, el efecto parcial promedio es:

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1 + \gamma_1 z_1)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1) + E(\gamma_1 z_1)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \gamma_1 E(z_1)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \gamma_1 * 0$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + 0$$

$$E \left[\frac{\partial E(y | x, z)}{\partial x_1} \right] = \beta_1.$$

Si x y z no son independientes, pero son, condicionalmente, independientes en una variable *proxy* w , es posible mostrar que el efecto parcial promedio es:

$$\delta_j(x_0) = E_z \left[\frac{\partial E(y | x_0, z)}{\partial x_j} \right] = E_z \left[\frac{\partial E(y | x_0, w)}{\partial x_j} \right].$$

5) Estimación.

Considerar una muestra aleatoria $\{y_i, x_i\}$ del tamaño n de la población. El par de puntos de datos (y_i, x_i) representa la i -ésima observación. El tamaño de la muestra n denota el número total de observaciones. Como cada punto de datos proviene del modelo (1):

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad (14)$$

donde $i = 1, \dots, n$. El objetivo es estimar los parámetros β_0 y β_1 .

5.1) Método de Momentos.

Primero, se revisa un método de estimación llamado Método de Momentos usando el siguiente ejemplo.

Ejemplo 3. Se supone que se quiere estimar el primer momento de una variable aleatoria. El método de momentos (MM) se puede usar para estimar la media de la población. Considerar que $\{y_i\}$ es una variable aleatoria distribuida de forma independiente e idéntica (i.i.d.) extraída de una distribución cuyo primer momento existe (por ejemplo, y no se distribuye como Cauchy). En la población:

$$E(y - \mu) = 0,$$

para que se pueda usar la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}.$$

Para obtener el estimador MM para el modelo lineal, recordar la condición de momento:

$$E(x_i u_i) = E[E(x_i u_i | x)]$$

$$E(x_i u_i) = E[x_i E(u_i | x)]$$

$$E(x_i u_i) = E(x_i * 0)$$

$$E(x_i u_i) = E(0)$$

$$E(x_i u_i) = 0,$$

o, alternativamente:

$$E[x_i (y_i - x_i' \beta)] = 0,$$

donde $x'_i = [1 \quad x_{i1}]$ y $\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$. El estimador MM podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x'_i \beta)] = 0,$$

resolviendo:

$$\sum_{i=1}^n [x_i (y_i - x'_i \beta)] = 0 * n$$

$$\sum_{i=1}^n (x_i y_i - x_i x'_i \beta) = 0$$

$$\sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x'_i \beta = 0$$

$$\sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x'_i = 0$$

$$\beta \sum_{i=1}^n x_i x'_i = \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = (\sum_{i=1}^n x_i x'_i)^{-1} \sum_{i=1}^n x_i y_i.$$

Se pasa, ahora, a algunos modelos básicos de regresión lineal.

5.2) Estimación de Mínimos Cuadrados Ordinarios (MCO).

Las suposiciones del modelo fueron:

- $E(u) = E(y - \beta_0 - \beta_1 x) = 0.$
- $Cov(x, u) = E(xu) - E(x)E(u) = 0 - E(x) \cdot 0 = 0.$

Estas dos ecuaciones son restricciones impuestas a los datos sobre la distribución de probabilidad conjunta de x e y . Hay dos incógnitas y dos ecuaciones, lo que sugiere que se puede resolver para β_0 y β_1 . La contraparte de la muestra de estas ecuaciones es:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (15)$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \beta_0 - \beta_1 x_i)] = 0. \quad (16)$$

El Estimador de Mínimos Cuadrados Ordinarios es el argumento que minimiza la siguiente función de criterio:

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2, \quad (17)$$

con respecto a las incógnitas β_0 y β_1 . Es fácil ver que las ecuaciones normales correspondientes a este problema son idénticas a las dos ecuaciones anteriores (15) y (16). Por lo tanto, el estimador MCO es un estimador MM en este caso.

De la ecuación (15), se obtiene:

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 * n$$

$$\sum_{i=1}^n y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 x_i = 0$$

$$n\bar{y} - n\beta_0 - n\beta_1 \bar{x} = 0$$

$$n(\bar{y} - \beta_0 - \beta_1 \bar{x}) = 0$$

$$\begin{aligned}
\bar{y} - \beta_0 - \beta_1 \bar{x} &= \frac{0}{n} \\
\bar{y} - \beta_0 - \beta_1 \bar{x} &= 0 \\
\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x},
\end{aligned} \tag{18}$$

donde $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$. Por lo tanto, si se conoce el estimador de mínimos cuadrados ordinarios de la pendiente β_1 , se puede obtener una estimación de la intersección. ¿Cómo se puede obtener $\hat{\beta}_1$? Conectar el último resultado en la ecuación (16) para obtener:

$$\begin{aligned}
\sum_{i=1}^n \{x_i [y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i]\} &= 0 * n \\
\sum_{i=1}^n [x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)] &= 0 \\
\sum_{i=1}^n \{x_i [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]\} &= 0 \\
\sum_{i=1}^n [x_i (y_i - \bar{y}) - \hat{\beta}_1 x_i (x_i - \bar{x})] &= 0 \\
\sum_{i=1}^n x_i (y_i - \bar{y}) - \sum_{i=1}^n \hat{\beta}_1 x_i (x_i - \bar{x}) &= 0 \\
\sum_{i=1}^n x_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= 0 \\
\hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= \sum_{i=1}^n x_i (y_i - \bar{y}) \\
\hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})}.
\end{aligned}$$

Se puede demostrar (*) que la última ecuación es igual a:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \tag{19}$$

el cual resulta el estimador para el parámetro β_1 .

Por lo tanto, $\hat{\beta}_0$ y $\hat{\beta}_1$ son los estimadores de mínimos cuadrados ordinarios (MCO) para los parámetros de intersección y de pendiente del modelo de regresión lineal simple.

$$\begin{aligned}
(*) \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n \bar{x} y_i + \sum_{i=1}^n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y}) - \bar{x} \sum_{i=1}^n y_i + n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i (y_i - \bar{y}) - n \bar{x} \bar{y} + n \bar{x} \bar{y} \\
\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i (y_i - \bar{y}).
\end{aligned}$$

$$\begin{aligned}
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i^2 - 2x_i \bar{x} + \bar{x}^2) \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2x_i \bar{x} + \sum_{i=1}^n \bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x} \bar{x} + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i x_i - \sum_{i=1}^n x_i \bar{x} \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i x_i - x_i \bar{x}) \\
\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i (x_i - \bar{x}).
\end{aligned}$$

5.3) Propiedades aritméticas de MCO.

Es útil discutir, brevemente, las propiedades de los estimadores MCO. Considerar las siguientes cuatro propiedades:

1. La suma de los residuos $\hat{u}_i$ es cero, ya que $\hat{\beta}_0$ y $\hat{\beta}_1$ se eligen de forma que:

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = \sum_{i=1}^n \hat{u}_i = 0.$$

2. La covarianza muestral entre la variable independiente y los residuos es cero. Para ver esto, es crucial encontrar ver:

$$\begin{aligned} \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n [x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)] \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n [x_i (y_i - x_i \hat{\beta})] \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n (x_i y_i - x_i x_i' \hat{\beta}) \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \hat{\beta} \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - 1 * \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i \hat{u}_i &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i \hat{u}_i &= 0. \end{aligned}$$

3. El promedio de muestra de los valores ajustados es igual al promedio de muestra de las observaciones:

$$\begin{aligned} y_i &= \hat{y}_i + \hat{u}_i \\ \sum_{i=1}^n y_i &= \sum_{i=1}^n \hat{y}_i + \sum_{i=1}^n \hat{u}_i \\ \frac{1}{n} \sum_{i=1}^n y_i &= \frac{1}{n} \sum_{i=1}^n \hat{y}_i + \frac{1}{n} \sum_{i=1}^n \hat{u}_i \\ \bar{y} &= \bar{\hat{y}} + \frac{1}{n} * 0 \\ \bar{y} &= \bar{\hat{y}} + 0 \\ \bar{y} &= \bar{\hat{y}}. \end{aligned}$$

4. El punto $(\bar{x}, \bar{y})$ siempre está en la línea MCO de regresión:

$$\begin{aligned} \bar{y} &= \bar{\hat{y}} \\ \bar{y} &= \frac{1}{n} \sum_{i=1}^n \hat{y}_i \\ \bar{y} &= \frac{1}{n} \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i) \\ \bar{y} &= \frac{1}{n} (\sum_{i=1}^n \hat{\beta}_0 + \sum_{i=1}^n \hat{\beta}_1 x_i) \\ \bar{y} &= \frac{1}{n} (n \hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i) \\ \bar{y} &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x}. \end{aligned}$$

5.4) Sesgo del estimador MCO.

Bajo las condiciones A1 y A2, el estimador MCO es insesgado, es decir, el valor esperado del estimador MCO es igual al parámetro desconocido.

Se puede mostrar el resultado de la siguiente manera. Recordar que:

$$\begin{aligned}
 \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) y_i \quad (*) \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i) \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n [\beta_0 (x_i - \bar{x}) + \beta_1 (x_i - \bar{x}) x_i + (x_i - \bar{x}) u_i] \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\sum_{i=1}^n \beta_0 (x_i - \bar{x}) + \sum_{i=1}^n \beta_1 (x_i - \bar{x}) x_i + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \quad (**) \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_0 * 0 + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \quad (***) \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [0 + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\
 \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i].
 \end{aligned}$$

$$\begin{aligned}
 (*) \quad \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\
 \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n \bar{x} y_i + \sum_{i=1}^n \bar{x} \bar{y} \\
 \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - \bar{x} y_i) - \bar{y} \sum_{i=1}^n x_i + n \bar{x} \bar{y} \\
 \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x}) y_i - n \bar{y} \bar{x} + n \bar{x} \bar{y} \\
 \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x}) y_i.
 \end{aligned}$$

$$\begin{aligned}
 (**) \quad \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i^2 - 2x_i \bar{x} + \bar{x}^2) \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2x_i \bar{x} + \sum_{i=1}^n \bar{x}^2 \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x} \bar{x} + n\bar{x}^2 \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i x_i - \sum_{i=1}^n x_i \bar{x} \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i x_i - x_i \bar{x}) \\
 \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i - \bar{x}) x_i.
 \end{aligned}$$

$$\begin{aligned}
 (***) \quad \sum_{i=1}^n (x_i - \bar{x}) &= \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \\
 \sum_{i=1}^n (x_i - \bar{x}) &= n\bar{x} - n\bar{x} \\
 \sum_{i=1}^n (x_i - \bar{x}) &= 0.
 \end{aligned}$$

Por lo tanto, el estimador MCO de la pendiente se puede escribir como:

$$\hat{\beta}_1 = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i. \quad (20)$$

Tomando esperanza:

$$\begin{aligned}
 E(\hat{\beta}_1) &= E\left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\
 E(\hat{\beta}_1) &= E(\beta_1) + E\left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right]
 \end{aligned}$$

$$\begin{aligned}
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n E[(x_i - \bar{x}) u_i] \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) E(u_i) \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) * 0 \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} * \sum_{i=1}^n 0 \\
 E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} n * 0 \\
 E(\hat{\beta}_1) &= \beta_1 + 0 \\
 E(\hat{\beta}_1) &= \beta_1.
 \end{aligned}$$

Ya que $E(u | x) = E(u) = 0$, $E(\hat{\beta}_1) = \beta_1$. Además, recordar que:

$$\begin{aligned}
 \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \\
 \hat{\beta}_0 &= \beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}.
 \end{aligned}$$

$$\begin{aligned}
 E(\hat{\beta}_0) &= E(\beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}) \\
 E(\hat{\beta}_0) &= E(\beta_0) + E(\beta_1 \bar{x}) + E(\bar{u}) - E(\hat{\beta}_1 \bar{x}) \\
 E(\hat{\beta}_0) &= \beta_0 + \bar{x} \beta_1 + E\left(\frac{1}{n} \sum_{i=1}^n u_i\right) - \bar{x} E(\hat{\beta}_1) \\
 E(\hat{\beta}_0) &= \beta_0 + \bar{x} \beta_1 + \frac{1}{n} \sum_{i=1}^n E(u_i) - \bar{x} \beta_1 \\
 E(\hat{\beta}_0) &= \beta_0 + \frac{1}{n} \sum_{i=1}^n 0 \\
 E(\hat{\beta}_0) &= \beta_0 + \frac{1}{n} n * 0 \\
 E(\hat{\beta}_0) &= \beta_0 + 0 \\
 E(\hat{\beta}_0) &= \beta_0.
 \end{aligned}$$

Por lo tanto, los estimadores de MCO son insesgados:

$$E(\hat{\beta}_0) = \beta_0; \quad E(\hat{\beta}_1) = \beta_1. \quad (21)$$

5.5) Varianza del estimador MCO.

Se va a obtener la varianza de los estimadores de MCO, pero, primero, se debe establecer una de las suposiciones del modelo de regresión lineal simple:

- A4 (Homocedasticidad): $\text{Var}(u | x) = \sigma^2$.
- A5 (Errores no correlacionados): $\text{Cov}(u_i, u_j) = 0$ para $i, j = 1, \dots, i-1, i+1, \dots, n$.

En otras palabras, la varianza del término de error es constante (no cambia con x) y el error u_i es independiente de u_j para $i \neq j$. Las suposiciones A4 y A5 juntas implican errores esféricos o, más precisamente, varianza de error esférico.

¿Cuál es la varianza de $\hat{\beta}_1$? Lo que se sabe:

$$\hat{\beta}_1 = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i.$$

Considerando A4 y A5, se obtiene la varianza de la siguiente manera:

$$\begin{aligned}
 \text{Var}(\hat{\beta}_1) &= \text{Var} \left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i \right] \\
 \text{Var}(\hat{\beta}_1) &= \text{Var}(\beta_1) + \text{Var} \left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i \right] \\
 \text{Var}(\hat{\beta}_1) &= 0 + \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \text{Var} \left[\sum_{i=1}^n (x_i - \bar{x}) u_i \right] \\
 \text{Var}(\hat{\beta}_1) &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \left[\sum_{i=1}^n \text{Var} \left[(x_i - \bar{x}) u_i \right] \right] \\
 \text{Var}(\hat{\beta}_1) &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(u_i) \\
 \text{Var}(\hat{\beta}_1) &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 \\
 \text{Var}(\hat{\beta}_1) &= \sigma^2 \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \\
 \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.
 \end{aligned}$$

Del mismo modo, para obtener la varianza de la intersección, bajo los supuestos establecidos, se escribe:

$$\begin{aligned}
 \text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{y} - \hat{\beta}_1 \bar{x}) \\
 \text{Var}(\hat{\beta}_0) &= \text{Var} \left(\bar{y} - \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \bar{x} \right) \\
 \text{Var}(\hat{\beta}_0) &= \text{Var} \left\{ \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] y_i \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \text{Var} \left\{ \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] y_i \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 \text{Var}(y_i) \\
 \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 \sigma^2 \quad (*** \text{ y } ****) \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \sum_{i=1}^n \left\{ \frac{1}{n^2} + \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 - \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \sum_{i=1}^n \frac{1}{n^2} + \sum_{i=1}^n \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]^2 - \sum_{i=1}^n \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \frac{n}{n^2} + \sum_{i=1}^n \frac{\bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \frac{1}{n} + \frac{\sum_{i=1}^n \bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} * 0 \right\} \quad (*****) \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{ \frac{1}{n} + \frac{\bar{x}^2 \sum_{i=1}^n (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - 0 \right\} \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n (x_i^2 + \bar{x}^2 - 2x_i \bar{x}) + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^n \bar{x}^2 - \sum_{i=1}^n 2x_i \bar{x} + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n \bar{x}^2 - 2n \bar{x} \bar{x} + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right] \\
 \text{Var}(\hat{\beta}_0) &= \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n \bar{x}^2 - 2n \bar{x}^2 + n \bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]
 \end{aligned}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right],$$

que es la varianza de la intersección estimada.

$$\begin{aligned} (***) \text{Var}(y_i) &= \text{Var}(\beta_0 + \beta_1 x_i + u_i) \\ \text{Var}(y_i) &= \text{Var}(\beta_0) + \text{Var}(\beta_1 x_i) + \text{Var}(u_i) \\ \text{Var}(y_i) &= 0 + 0 + \text{Var}(u_i) \\ \text{Var}(y_i) &= \text{Var}(u_i) \\ \text{Var}(y_i) &= \sigma^2. \end{aligned}$$

$$\begin{aligned} (****) \text{Cov}(y_i, y_j) &= E\{[y_i - E(y_i)][y_j - E(y_j)]\} \\ \text{Cov}(y_i, y_j) &= E(u_i u_j) \\ \text{Cov}(y_i, y_j) &= \text{Cov}(u_i, u_j) + E(u_i) E(u_j) \\ \text{Cov}(y_i, y_j) &= 0 + 0 * 0 \\ \text{Cov}(y_i, y_j) &= 0. \end{aligned}$$

$$\begin{aligned} (*****) \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{n\bar{x} - n\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{0}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= 0. \end{aligned}$$

Aunque no se conoce el parámetro σ^2 , se puede agregar su estimador $\hat{\sigma}^2$.

Observación 1. La varianza del término de error es otro parámetro desconocido de la población, pero se puede estimar usando el principio analógico. Recordar que u se distribuye como una variable normal con media cero y varianza σ^2 .

$$E(u) = 0.$$

$$\begin{aligned} V(u) &= E(u^2) - [E(u)]^2 \\ V(u) &= E(u^2) - 0^2 \\ V(u) &= E(u^2) - 0 \\ V(u) &= E(u^2) \\ V(u) &= \sigma^2. \end{aligned}$$

Lo que implica que se puede usar (de la contraparte de la muestra):

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i^2,$$

como un estimador de σ^2 .

Desafortunadamente, éste es un estimador sesgado, pero se puede corregir, fácilmente, para tener un estimador insesgado de la varianza del término de error:

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2, \quad (22)$$

donde $(n - 2)$ son los grados de libertad.

Por lo tanto, los estimadores de la varianza de los estimadores MCO serían:

$$\widehat{Var}(\hat{\beta}_0) = \hat{\sigma}^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]; \quad \widehat{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (23)$$

Entonces, se puede definir el error estándar del coeficiente de la pendiente como:

$$\begin{aligned} \widehat{se}(\hat{\beta}_1) &= \sqrt{\widehat{Var}(\hat{\beta}_1)} \\ \widehat{se}(\hat{\beta}_1) &= \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \\ \widehat{se}(\hat{\beta}_1) &= \frac{\hat{\sigma}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}. \end{aligned} \quad (24)$$

6) Modelos Lineales Multivariados.

Hasta ahora, se ha estudiado el modelo de regresión simple, que incluye sólo una covariable. Tiene sentido extender el modelo anterior a un modelo con p variables independientes:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + u = \beta_0 + \sum_{j=1}^p \beta_j x_j + u, \quad (25)$$

donde β_0 es el intercepto, β_1 es el coeficiente asociado con la variable independiente x_1 , β_2 con la variable x_2 y β_p con la variable x_p . La variable aleatoria u es el término de error, que contiene otros factores además de $x_1, x_2, \dots, x_p$.

La suposición crucial es que todos los factores observables (las variables independientes $x_1, x_2, \dots, x_p$) que afectan a la variable dependiente y no están correlacionados con el término de error: $E(u | x_1, x_2, \dots, x_p) = 0$.

6.1) Método de Momentos.

La idea básica, aquí, es aplicar las restricciones en la población a los datos. Por ejemplo, recordar que se tienen las suposiciones:

$$\begin{aligned} E(u_i) &= 0. \\ E(x_{i1} u_i) &= 0. \\ E(x_{ip} u_i) &= 0. \end{aligned}$$

Por lo tanto, se deben encontrar las estimaciones de coeficientes que resuelven el siguiente sistema de ecuaciones:

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{i1} \hat{u}_i = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{ip} \hat{u}_i = 0.$$

De nuevo, se tiene $(p + 1)$ ecuaciones y $(p + 1)$ incógnitas. Las soluciones se llaman estimadores del método de momentos para los parámetros de regresión $\beta_0, \dots, \beta_p$.

Por ejemplo, considerar el modelo con dos variables independientes. Las condiciones serán:

$$E(u_i) = 0.$$

$$E(x_{i1}u_i) = 0.$$

$$E(x_{i2}u_i) = 0.$$

Por consiguiente:

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{i1} \hat{u}_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n x_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.$$

$$\frac{1}{n} \sum_{i=1}^n x_{i2} \hat{u}_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n x_{i2} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.$$

Como se verá a continuación, el método de momentos proporciona coeficientes estimados que son idénticos a las estimaciones de mínimos cuadrados.

6.2) MCO.

El procedimiento de mínimos cuadrados es similar al que se discutió anteriormente. Calcula los coeficientes estimados como minimizadores de la suma de residuales al cuadrado:

$$S = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

La diferencia es que, ahora:

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + u_i,$$

en lugar de la muestra $y_i = \beta_0 + \beta_1 x_i$. Por ejemplo, el valor predicho de y_i es:

$$\hat{y}_i = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j x_{ij},$$

bajo los supuestos estándar. Para obtener la solución de este problema, se utilizan las derivadas parciales para desarrollar un conjunto de $(p + 1)$ ecuaciones normales simultáneas:

$$\frac{\partial S}{\partial \hat{\beta}_0} = 0$$

$$\frac{\partial S}{\partial \hat{\beta}_1} = 0$$

$$\vdots$$

$$\frac{\partial S}{\partial \hat{\beta}_p} = 0,$$

que tiene $(p + 1)$ incógnitas $\hat{\beta}_0, \dots, \hat{\beta}_p$. Por simplicidad, nos enfocamos en el problema de minimizar:

$$S = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2})^2,$$

con derivadas parciales:

$$\begin{aligned}\frac{\partial S}{\partial \hat{\beta}_0} &= -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0. \\ \frac{\partial S}{\partial \hat{\beta}_1} &= -2 \sum_{i=1}^n x_{i1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0. \\ \frac{\partial S}{\partial \hat{\beta}_2} &= -2 \sum_{i=1}^n x_{i2} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2}) = 0.\end{aligned}$$

Estas ecuaciones se pueden escribir como:

$$\begin{aligned}n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_{i1} + \hat{\beta}_2 \sum_{i=1}^n x_{i2} &= \sum_{i=1}^n y_i. \\ \hat{\beta}_0 \sum_{i=1}^n x_{i1} + \hat{\beta}_1 \sum_{i=1}^n x_{i1}^2 + \hat{\beta}_2 \sum_{i=1}^n x_{i1} x_{i2} &= \sum_{i=1}^n x_{i1} y_i. \\ \hat{\beta}_0 \sum_{i=1}^n x_{i2} + \hat{\beta}_1 \sum_{i=1}^n x_{i1} x_{i2} + \hat{\beta}_2 \sum_{i=1}^n x_{i2}^2 &= \sum_{i=1}^n x_{i2} y_i.\end{aligned}$$

Se puede demostrar que la estimación del coeficiente de intercepción β_0 es:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2.$$

Es algo más tedioso encontrar esto:

$$\begin{aligned}\hat{\beta}_1 &= \frac{S_y(r_{x_1 y} - r_{x_1 x_2} r_{x_2 y})}{S_{x_1}(1 - r_{x_1 x_2}^2)} \\ \hat{\beta}_2 &= \frac{S_y(r_{x_2 y} - r_{x_1 x_2} r_{x_1 y})}{S_{x_2}(1 - r_{x_1 x_2}^2)}.\end{aligned}$$

Donde $r_{x_j y}$ es la correlación muestral entre x_j e y , $r_{x_1 x_2}$ es la correlación muestral entre x_1 y x_2 , S_{x_j} es la desviación estándar muestral para x_j y S_y es la desviación estándar muestral para y .

Lo que se puede aprender de estos estimadores es que, en el modelo de regresión múltiple, la estimación del coeficiente de regresión β_1 depende de la correlación entre x_1 y x_2 y entre x_2 e y . Si no hay correlación entre x_1 y x_2 (por ejemplo, $r_{x_1 x_2} = 0$), la estimación del coeficiente es:

$$\begin{aligned}\hat{\beta}_1 &= \frac{S_y r_{x_1 y}}{S_{x_1}} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (y_i - \bar{y})(x_{i1} - \bar{x}_1)}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}} \frac{\sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}}}{\sqrt{\frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}{n-1}}} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (y_i - \bar{y})(x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}.\end{aligned}$$

Si $r_{x_1x_2} = 1$, la estimación del coeficiente β_1 no será definida. Se podrían obtener las mismas conclusiones sobre $\hat{\beta}_2$. En el análisis empírico, siempre es importante explorar la correlación entre las variables independientes.

7) Análisis de Varianza y R^2 .

Considerar:

$$\begin{aligned} y_i &= \hat{y}_i + \hat{u}_i \\ y_i - \bar{y} &= \hat{y}_i - \bar{y} + \hat{u}_i \\ (y_i - \bar{y})^2 &= (\hat{y}_i - \bar{y} + \hat{u}_i)^2 \\ (y_i - \bar{y})^2 &= (\hat{y}_i - \bar{y})^2 + 2\hat{u}_i(\hat{y}_i - \bar{y}) + \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n [(\hat{y}_i - \bar{y})^2 + 2\hat{u}_i(\hat{y}_i - \bar{y}) + \hat{u}_i^2] \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n 2\hat{u}_i(\hat{y}_i - \bar{y}) + \sum_{i=1}^n \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) + \sum_{i=1}^n \hat{u}_i^2. \end{aligned}$$

Tener en cuenta que, al usar las propiedades aritméticas de los estimadores MCO:

$$\begin{aligned} \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i[(\hat{\beta}_0 + \hat{\beta}_1 x_i) - (\hat{\beta}_0 + \hat{\beta}_1 \bar{x})] \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i(\hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i(\hat{\beta}_1 x_i - \hat{\beta}_1 \bar{x}) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \sum_{i=1}^n \hat{u}_i[\hat{\beta}_1(x_i - \bar{x})] \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 \sum_{i=1}^n \hat{u}_i(x_i - \bar{x}) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 \sum_{i=1}^n (\hat{u}_i x_i - \hat{u}_i \bar{x}) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (\sum_{i=1}^n \hat{u}_i x_i - \sum_{i=1}^n \hat{u}_i \bar{x}) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (\sum_{i=1}^n \hat{u}_i x_i - \bar{x} \sum_{i=1}^n \hat{u}_i) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (0 - \bar{x} * 0) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 (0 - 0) \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= \hat{\beta}_1 * 0 \\ \sum_{i=1}^n \hat{u}_i(\hat{y}_i - \bar{y}) &= 0. \end{aligned}$$

Por lo tanto:

$$\begin{aligned} \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 * 0 + \sum_{i=1}^n \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 0 + \sum_{i=1}^n \hat{u}_i^2 \\ \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2. \end{aligned} \tag{26}$$

Si se divide esta expresión por la variable del lado izquierdo:

$$\begin{aligned} \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} &= \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \\ 1 &= \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} + \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \end{aligned}$$

que indica una proporción que se explica por el modelo lineal estimado (primer término) y una que no se explica por el modelo lineal (segundo término). El R^2 de una regresión se define como:

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Tener en cuenta que una suma pequeña de residuos al cuadrado significa que el modelo explica muy bien y una suma grande de residuos al cuadrado significa que el modelo no produce un buen ajuste a los datos. Por lo tanto, un R^2 cercano a 1 nos dice que el modelo produce un buen ajuste a los datos y un R^2 cercano a 0 nos dice que el modelo no produce un buen ajuste a los datos. Tener en cuenta, también, que $0 \leq R^2 \leq 1$, ya que $0 \leq \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \leq 1$.

Un estadístico alternativo es el R^2 ajustado, que se define como:

$$\bar{R}^2 = 1 - \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

y proporciona una compensación entre la bondad de ajuste y la parsimonia. La bondad de ajuste se mide por R^2 y la parsimonia del modelo se mide por los grados de libertad ($n - p$). Tener en cuenta que el R^2 puede no estar bien definido y también puede ser negativo.

Es, inmediatamente, evidente que:

$$1 - \bar{R}^2 = 1 - \left[1 - \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \right]$$

$$1 - \bar{R}^2 = 1 - 1 + \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$1 - \bar{R}^2 = \frac{n-1}{n-p} \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$1 - \bar{R}^2 = \frac{n-1}{n-p} (1 - R^2).$$

Lectura 2: Proyecciones Ortogonales.

Se comienza asumiendo un modelo lineal:

$$\underset{1 \times 1}{y_i} = \underset{1 \times p}{x_i'} \underset{p \times 1}{\beta} + \underset{1 \times 1}{u_i}, \quad \text{para } i = 1, 2, \dots, n, \quad (1)$$

donde y es la variable de respuesta para el sujeto i y x_i' es un vector de p variables independientes que incluye una intersección. El modelo se puede escribir en una notación de matriz, más conveniente, como:

$$\underset{n \times 1}{y} = \underset{n \times p}{X} \underset{p \times 1}{\beta} + \underset{n \times 1}{u}, \quad (2)$$

donde y , ahora, se define como un vector de $(n \times 1)$, la matriz X es $(n \times p)$, el vector de parámetros es $(p \times 1)$ y el vector aleatorio u es $(n \times 1)$. En otras palabras:

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p-1} \\ 1 & x_{21} & x_{22} & \dots & x_{2p-1} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np-1} \end{bmatrix}; \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_n \end{bmatrix}; \quad u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}.$$

Resulta que:

$$\sum_{i=1}^n x_i x_i' = X'X.$$

$$\sum_{i=1}^n x_i y_i = X'y.$$

1) Estimación.

Se puede estimar el parámetro usando el Método de Momentos o, alternativamente, el método tradicional llamado Mínimos Cuadrados Ordinarios (MCO). La derivación del estimador MCO se basa en minimizar la suma de los errores al cuadrado:

$$\|u\|^2 = \|y - X\beta\|^2,$$

donde $\|\cdot\|$ es la norma euclidiana definida como $(z'z)^{\frac{1}{2}} = (\sum_{i=1}^n z_i^2)^{\frac{1}{2}}$ para un vector genérico z . Por lo tanto, la función objetivo es:

$$\begin{aligned} \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} [(y - X\beta)'(y - X\beta)] \\ \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} [(y' - \beta'X')(y - X\beta)] \\ \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} (y'y - \beta'X'y - y'X\beta + \beta'X'X\beta) \\ \min_{\beta} \|y - X\beta\|^2 &= \min_{\beta} (y'y - 2\beta'X'y + \beta'X'X\beta), \end{aligned}$$

porque $\beta'X'y = y'X\beta$. La condición de primer orden es:

$$-2X'y + 2X'X\beta = 0,$$

lo que implica que $X'(y - X\beta) = 0$ y, en consecuencia, bajo los supuestos A1, A2 y A3:

$$\hat{\beta} = (X'X)^{-1}X'y. \quad (3)$$

Alternativamente, se define el estimador como:

$$\hat{\beta} = \arg \min \|y - X\beta\|^2. \quad (4)$$

El estimador MCO $\hat{\beta}$ da el vector $X\beta$ más cercano, en términos de la norma euclidiana, a y entre todos los vectores que se encuentran en el espacio abarcado por el vector X .

También se puede obtener la varianza del estimador bajo homocedasticidad y errores independientes (supuestos A4 y A5). Tener en cuenta que:

$$\begin{aligned} V(\hat{\beta} | X) &= V[(X'X)^{-1}X'y | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'(X\beta + u) | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[I\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + V[(X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + (X'X)^{-1}X' V(u | X) X(X'X)^{-1} \\ V(\hat{\beta} | X) &= 0 + (X'X)^{-1}X' \sigma_u^2 I_n X(X'X)^{-1} \\ V(\hat{\beta} | X) &= (X'X)^{-1}X' \sigma_u^2 X(X'X)^{-1} \\ V(\hat{\beta} | X) &= \sigma_u^2 (X'X)^{-1}X'X(X'X)^{-1} \\ V(\hat{\beta} | X) &= \sigma_u^2 I(X'X)^{-1} \\ V(\hat{\beta} | X) &= \sigma_u^2 (X'X)^{-1}, \end{aligned}$$

bajo el supuesto de que la varianza del término de error es “esférica”, es decir, $V(u | X) = \sigma_u^2 I$. La varianza depende de σ_u^2 , que es desconocida y necesita ser estimada. Como en la Lectura 1, se estima usando $\frac{\hat{u}'\hat{u}}{n-p}$.

Nótese también que la suposición de homocedasticidad simplifica la expresión de la varianza de MCO.

2) Propiedades de Muestra Finita.

El estimador MCO $\hat{\beta}$ es insesgado cuando las variables independientes son independientes del término de error (supuesto A2):

$$\begin{aligned} E(\hat{\beta} | X) &= E[(X'X)^{-1}X'y | X] \\ E(\hat{\beta} | X) &= E[(X'X)^{-1}X'(X\beta + u) | X] \\ E(\hat{\beta} | X) &= E\{[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u] | X\} \\ E(\hat{\beta} | X) &= E[I\beta + (X'X)^{-1}X'u | X] \\ E(\hat{\beta} | X) &= E[\beta + (X'X)^{-1}X'u | X] \\ E(\hat{\beta} | X) &= E(\beta | X) + E[(X'X)^{-1}X'u | X] \end{aligned}$$

$$E(\hat{\beta} | X) = \beta + (X'X)^{-1}X' E(u | X)$$

$$E(\hat{\beta} | X) = \beta + (X'X)^{-1}X' * 0$$

$$E(\hat{\beta} | X) = \beta + 0$$

$$E(\hat{\beta} | X) = \beta.$$

Por la ley de las esperanzas iteradas, también se tiene que:

$$E(\hat{\beta}) = E[E(\hat{\beta} | X)]$$

$$E(\hat{\beta}) = E(\beta)$$

$$E(\hat{\beta}) = \beta.$$

El estimador MCO es insesgado y lineal, lo que significa que se puede escribir $\hat{\beta}$ como una función lineal de la variable de respuesta y, por ejemplo:

$$\hat{\beta} = Ay,$$

donde $A = (X'X)^{-1}X'$. Ahora, considerar otro estimador lineal insesgado:

$$\tilde{\beta} = (A + B)y.$$

Por lo tanto, debe ser el caso de $E(\tilde{\beta}) = \beta$ porque $BX = 0$. Además, la varianza del estimador $\tilde{\beta}$ es:

$$V(\tilde{\beta} | X) = E\{[\tilde{\beta} - E(\tilde{\beta})][\tilde{\beta} - E(\tilde{\beta})]' | X\}$$

$$V(\tilde{\beta} | X) = E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)' | X]$$

$$V(\tilde{\beta} | X) = E\{[(A + B)u][(A + B)u]' | X\} \quad (*)$$

$$V(\tilde{\beta} | X) = E[(A + B)uu'(A + B)' | X]$$

$$V(\tilde{\beta} | X) = (A + B)E(uu' | X)(A + B)'$$

$$V(\tilde{\beta} | X) = (A + B)V(u | X)(A + B)'$$

$$V(\tilde{\beta} | X) = (A + B)\sigma^2 I(A' + B')$$

$$V(\tilde{\beta} | X) = (A + B)\sigma^2(A' + B')$$

$$V(\tilde{\beta} | X) = \sigma^2(A + B)(A' + B')$$

$$V(\tilde{\beta} | X) = \sigma^2(AA' + AB' + BA' + BB')$$

$$V(\tilde{\beta} | X) = \sigma^2[(X'X)^{-1}X'X(X'X)^{-1} + (X'X)^{-1}X'B' + BX(X'X)^{-1} + BB']$$

$$V(\tilde{\beta} | X) = \sigma^2[I(X'X)^{-1} + (X'X)^{-1} * 0 + 0 * (X'X)^{-1} + BB'] \quad (**)$$

$$V(\tilde{\beta} | X) = \sigma^2[(X'X)^{-1} + 0 + 0 + BB']$$

$$V(\tilde{\beta} | X) = \sigma^2[(X'X)^{-1} + BB']$$

$$V(\tilde{\beta} | X) = \sigma^2(X'X)^{-1} + \sigma^2 BB'$$

$$V(\tilde{\beta} | X) = V(\hat{\beta} | X) + \sigma^2 BB'.$$

$$(*) \tilde{\beta} = (A + B)y$$

$$\tilde{\beta} = (A + B)(X\beta + u)$$

$$\tilde{\beta} = AX\beta + BX\beta + (A + B)u$$

$$\tilde{\beta} = (X'X)^{-1}X'X\beta + 0 * \beta + (A + B)u \quad (**)$$

$$\tilde{\beta} = I\beta + 0 + (A + B)u$$

$$\tilde{\beta} = \beta + (A + B)u$$

$$\tilde{\beta} - \beta = (A + B)u.$$

$$\begin{aligned}
(**) E(\tilde{\beta}) &= \beta \\
E[\beta + BX\beta + (A + B)u] &= \beta \\
E(\beta) + E(BX\beta) + E[(A + B)u] &= \beta \\
\beta + BX\beta + (A + B)E(u) &= \beta \\
\beta + BX\beta + (A + B) \cdot 0 &= \beta \\
\beta + BX\beta + 0 &= \beta \\
\beta + BX\beta &= \beta \\
\beta(1 + BX) &= \beta \\
1 + BX &= \frac{\beta}{\beta} \\
1 + BX &= 1 \\
BX &= 1 - 1 \\
BX &= 0.
\end{aligned}$$

La última ecuación sugiere que la varianza del estimador $\tilde{\beta}$ es mayor que la varianza del estimador $\hat{\beta}$. Esto se puede establecer en el siguiente importante teorema.

Teorema 1 (Gauss-Markov). Si $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I$, en un modelo de regresión lineal, entonces, el estimador MCO es eficiente, por ejemplo:

$$V(\tilde{\beta} | X) \geq V(\hat{\beta} | X)$$

ó

$$V(\tilde{\beta} | X) - V(\hat{\beta} | X) \text{ es semidefinida positiva.}$$

Tener en cuenta que el teorema es para varianzas condicionales. ¿Se puede afirmar también que $V(\tilde{\beta}) \geq V(\hat{\beta})$? Se necesita un poco más de trabajo. Considerar, primero, la definición:

$$V(\hat{\beta}) = E[V(\hat{\beta} | X)] + V[E(\hat{\beta} | X)].$$

Primero, notar que el segundo término es igual a cero porque el estimador es insesgado y, por lo tanto, $V(\beta) = 0$. Por lo tanto:

$$\begin{aligned}
V(\hat{\beta}) &= E[V(\hat{\beta} | X)] + V[E(\hat{\beta} | X)] \\
V(\hat{\beta}) &= E[V(\hat{\beta} | X)] + V(\beta) \\
V(\hat{\beta}) &= E[\sigma^2(X'X)^{-1}] + 0 \\
V(\hat{\beta}) &= \sigma^2 E[(X'X)^{-1}] \\
V(\hat{\beta}) &= \sigma^2(X'X)^{-1}.
\end{aligned}$$

Similarmente:

$$\begin{aligned}
V(\tilde{\beta}) &= E[V(\tilde{\beta} | X)] + V[E(\tilde{\beta} | X)] \\
V(\tilde{\beta}) &= E[V(\tilde{\beta} | X)] + V(\beta) \\
V(\tilde{\beta}) &= E[\sigma^2(X'X)^{-1} + \sigma^2 BB'] + 0 \\
V(\tilde{\beta}) &= E[\sigma^2(X'X)^{-1}] + E(\sigma^2 BB') \\
V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} + \sigma^2 BB'.
\end{aligned}$$

Por lo tanto, se concluye que:

$$V(\tilde{\beta}) \geq V(\hat{\beta}),$$

porque $E(BB')$ es semidefinida positiva.

3) Proyecciones.

Se define la matriz de proyección:

$$P = X(X'X)^{-1}X'$$

El i -ésimo elemento diagonal de P se denomina punto de apalancamiento y se define como $h_i = x_i'(X'X)^{-1}x_i$. La matriz P es simétrica e idempotente y su traza es igual al número de variables independientes. La simetría implica:

$$P' = [X(X'X)^{-1}X']'$$

$$P' = X(X'X)^{-1}X'$$

$$P' = P.$$

La idempotencia implica:

$$PP = X(X'X)^{-1}X'X(X'X)^{-1}X'$$

$$PP = XI(X'X)^{-1}X'$$

$$PP = X(X'X)^{-1}X'$$

$$PP = P.$$

Finalmente:

$$\text{tr}(P) = \text{tr}[X(X'X)^{-1}X']$$

$$\text{tr}(P) = \text{tr}[X'X(X'X)^{-1}] \quad (*)$$

$$\text{tr}(P) = \text{tr}(I_p)$$

$$\text{tr}(P) = p.$$

$$(*) \text{tr}(AB) = \text{tr}(BA).$$

El vector de valores ajustados, definido como:

$$\hat{y} = X\hat{\beta},$$

representa la proyección ortogonal de y sobre el espacio de columna de X . Tener en cuenta que:

$$\hat{y} = X(X'X)^{-1}X'y$$

$$\hat{y} = Py,$$

donde la matriz P es la matriz de proyección. Por otro lado, el vector residual:

$$\hat{u} = y - \hat{y}$$

$$\hat{u} = y - Py$$

$$\hat{u} = (I - P)y$$

$$\hat{u} = My,$$

donde $M = I - P$, que es una matriz que produce “residuos”. Tener en cuenta que también se puede escribir el vector de residuos como:

$$\hat{u} = My$$

$$\hat{u} = M(X\beta + u)$$

$$\hat{u} = MX\beta + Mu$$

$$\hat{u} = 0 * \beta + Mu \quad (**)$$

$$\hat{u} = 0 + Mu$$

$$\hat{u} = Mu.$$

$$(**) MX = (I - P)X$$

$$MX = IX - PX$$

$$MX = X - X(X'X)^{-1}X'X$$

$$MX = X - XI$$

$$MX = X - X$$

$$MX = 0.$$

porque $PX = X$. Esto implica que los residuos de la regresión y las variables independientes son ortogonales:

$$X'\hat{u} = X'Mu$$

$$X'\hat{u} = X'(I - P)u$$

$$X'\hat{u} = (X'I - X'P)u$$

$$X'\hat{u} = (X' - X')u \quad (***)$$

$$X'\hat{u} = 0 * u$$

$$X'\hat{u} = 0.$$

$$(***) X'P = X'X(X'X)^{-1}X'$$

$$X'P = IX'$$

$$X'P = X'.$$




Figure 1: OLS fitting and projections

Observación 1. La geometría básica de MCO se puede ver en la Figura 1. Sea y y $X = [X_1 : X_2]$ vectores, se define el espacio abarcado por las columnas de X como:

$$S(X) = \{z \in \mathbb{R}^n \mid z = Xc, c \in \mathbb{R}^p\}.$$

El ajuste MCO proporciona el vector más cercano a y en el espacio abarcado por las X .




Figure 2: OLS fitting with two observations

Ejemplo 1. Para ilustrar la geometría básica de MCO, se presenta un ejemplo simple (Figura 2). Sean $y = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ y $X = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ vectores y considerar el modelo de regresión $y_i = X_i\beta + u_i$. El estimador MCO es:

$$\arg \min \{(y_1 - 1 * \beta)^2 + (y_2 - 1 * \beta)^2\}$$

$$\arg \min \{(y_1 - \beta)^2 + (y_2 - \beta)^2\}.$$

Y la condición de primer orden asociada es:

$$2(y_1 - \beta)(-1) + 2(y_2 - \beta)(-1) = 0$$

$$-2(y_1 - \beta) - 2(y_2 - \beta) = 0$$

$$-2[(y_1 - \beta) + (y_2 - \beta)] = 0$$

$$(y_1 - \beta) + (y_2 - \beta) = 0$$

$$y_1 - \beta + y_2 - \beta = 0$$

$$-2\beta + y_1 + y_2 = 0$$

$$2\beta = y_1 + y_2$$

$$\hat{\beta} = \frac{y_1 + y_2}{2}$$

$$\hat{\beta} = \frac{1+3}{2}$$

$$\hat{\beta} = \frac{4}{2}$$

$$\hat{\beta} = 2.$$

Por lo tanto, se obtiene $\hat{y} = X\hat{\beta} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} * 2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$ y $\hat{u} = y - \hat{y} = \begin{bmatrix} 1 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$, con $X'\hat{u} = \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = 0$. Como está claro en la figura, también es interesante obtener la longitud de los siguientes vectores usando la norma euclidiana:

$$\|y\| = \sqrt{1^2 + 3^2}$$

$$\|y\| = \sqrt{1 + 9}$$

$$\|y\| = \sqrt{10}.$$

$$\|\hat{y}\| = \sqrt{2^2 + 2^2}$$

$$\|\hat{y}\| = \sqrt{4 + 4}$$

$$\|\hat{y}\| = \sqrt{8}.$$

$$\|u\| = \|y - \hat{y}\|$$

$$\|u\| = \sqrt{(1 - 2)^2 + (3 - 2)^2}$$

$$\|u\| = \sqrt{(-1)^2 + 1^2}$$

$$\|u\| = \sqrt{1 + 1}$$

$$\|u\| = \sqrt{2}.$$

4) Ajuste Particionado (Teorema de Frisch-Waugh-Lovell).

Considerar un modelo de regresión particionado:

$$y = X\beta + Z\gamma + u \quad (5)$$

y el estimador correspondiente $\hat{\beta}$. Además, considerar el modelo de regresión alternativo:

$$\tilde{y} = \tilde{X}\beta + \tilde{u}, \quad (6)$$

con el correspondiente estimador $\tilde{\beta}$, con $\tilde{Z} = M_Z Z$ para un vector genérico Z .

Teorema 2. Los estimadores $\hat{\beta}$ y $\tilde{\beta}$ son, numéricamente, idénticos.

Prueba. Las fórmulas estándar de MCO en el modelo (5) dan las siguientes ecuaciones normales:

$$X'y = X'X\hat{\beta} + X'Z\hat{\gamma}.$$

$$Z'y = Z'X\hat{\beta} + Z'Z\hat{\gamma}.$$

Resolviendo para $\hat{\gamma}$ en la segunda ecuación y reemplazando en la primera ecuación, se obtiene:

$$Z'Z\hat{\gamma} = Z'y - Z'X\hat{\beta}$$

$$\hat{\gamma} = (Z'Z)^{-1} (Z'y - Z'X\hat{\beta})$$

$$\hat{\gamma} = (Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}.$$

$$X'y = X'X\hat{\beta} + X'Z [(Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}]$$

$$X'y = X'X\hat{\beta} + X'Z(Z'Z)^{-1} Z'y - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X'y - X'Z(Z'Z)^{-1} Z'y = X'X\hat{\beta} - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X' [I - Z(Z'Z)^{-1} Z'] y = X' [I - Z(Z'Z)^{-1} Z'] X\hat{\beta}$$

$$X' (I - P_Z) y = X' (I - P_Z) X\hat{\beta}$$

$$X'M_Z y = X'M_Z X\hat{\beta}.$$

Por lo tanto:

$$\hat{\beta} = (X'M_Z X)^{-1} X'M_Z y$$

$$\hat{\beta} = (X'M'_Z M_Z X)^{-1} X'M'_Z M_Z y$$

$$\hat{\beta} = (\tilde{X}'\tilde{X})^{-1} \tilde{X}'\tilde{y}$$

$$\hat{\beta} = \tilde{\beta}.$$

Además de las estimaciones puntuales, los residuos son idénticos. Para ver esto, considerar:

$$y = \hat{y} + \hat{u}$$

$$y = X\hat{\beta} + Z\hat{\gamma} + \hat{u}$$

y multiplicar por M_Z :

$$M_Z y = M_Z X\hat{\beta} + M_Z Z\hat{\gamma} + M_Z \hat{u}$$

$$\tilde{y} = \tilde{X}\hat{\beta} + 0 * \hat{\gamma} + (I - P_Z) \hat{u} \quad (*)$$

$$\tilde{y} = \tilde{X}\hat{\beta} + 0 + I\hat{u} - P_Z \hat{u}$$

$$\tilde{y} = \tilde{X}\hat{\beta} + \hat{u} - 0 \quad (**)$$

$$\tilde{y} = \tilde{X}\hat{\beta} + \hat{u},$$

donde $M_Z \hat{u} = \hat{u}$ porque $P_Z \hat{u} = 0$.

$$(*) M_Z Z = (I - P_Z) Z$$

$$\begin{aligned}M_Z Z &= IZ - P_Z Z \\M_Z Z &= Z - Z(Z'Z)^{-1}Z'Z \\M_Z Z &= Z - ZI \\M_Z Z &= Z - Z \\M_Z Z &= 0.\end{aligned}$$

$$\begin{aligned}(**) P_Z \hat{u} &= P_Z My \\P_Z \hat{u} &= P_Z M_Z My \\P_Z \hat{u} &= 0 * My \quad (***) \\P_Z \hat{u} &= 0.\end{aligned}$$

$$\begin{aligned}(***) P_Z M_Z &= P_Z (I - P_Z) \\P_Z M_Z &= P_Z I - P_Z P_Z \\P_Z M_Z &= P_Z - P_Z \\P_Z M_Z &= 0.\end{aligned}$$

Otra forma es viendo que este resultado está considerando el siguiente argumento. Recordar que:

$$\begin{aligned}y &= \hat{y} + \hat{u} \\y &= Py + My \\y &= X\hat{\beta} + Z\hat{y} + My.\end{aligned} \quad (7)$$

Tener en cuenta que M es una matriz de proyección que usa $[X : Z]$. Aplicando fórmula particionada, se puede mostrar que $M = I - P_{xz} = I - [P_Z + M_Z X(X' M_Z X)^{-1} X' M_Z]$.

Si se multiplica (7) por M_Z , se tiene:

$$M_Z y = M_Z X\hat{\beta} + M_Z Z\hat{y} + M_Z My. \quad (8)$$

Por lo tanto, se necesita mostrar que $M_Z M = M$ o, en palabras, que los últimos términos en las ecuaciones (7) y (8) son iguales. Tener en cuenta que:

$$\begin{aligned}M_Z M &= (I - P_Z)(I - P_{xz}) \\M_Z M &= I - P_{xz} - P_Z + P_Z P_{xz} \\M_Z M &= I - P_{xz} - P_Z + P_Z [P_Z + M_Z X(X' M_Z X)^{-1} X' M_Z] \\M_Z M &= I - P_{xz} - P_Z + P_Z P_Z + P_Z M_Z X(X' M_Z X)^{-1} X' M_Z \\M_Z M &= I - P_{xz} - P_Z + P_Z + 0 * X(X' M_Z X)^{-1} X' M_Z \\M_Z M &= I - P_{xz} + 0 \\M_Z M &= I - P_{xz} \\M_Z M &= M,\end{aligned}$$

que da los resultados desde $My = Mu = \hat{u}$.

Notar también que, en el caso de $Z'X = 0$, los elementos “fuera de la diagonal” de la matriz inversa en la fórmula particionada son cero, entonces, $M = I - P_{xz} = I - (P_Z + P_x)$. De nuevo, se tiene que $P_Z (P_Z + P_x) = P_Z$ y el resultado continúa manteniéndose.

El teorema implica que las estimaciones MCO del parámetro de pendiente se pueden obtener de la siguiente manera:

1. Regresando y en Z y obteniendo los residuos $\tilde{y}$.
2. Regresando X en Z y obteniendo los residuos $\tilde{X}$.
3. Regresando $\tilde{y}$ en $\tilde{X}$ y obteniendo el estimador MCO $\hat{\beta}$.

Ejemplo 2. Considerar un modelo simple bivariado:

$$y = \gamma + \beta x_i + u_i,$$

donde, en este caso, $X = x_i$ y $Z = 1$. Antes de pasar a la aplicación del teorema FWL, se puede usar el método de momentos para derivar el estimador de pendiente. Nuestras suposiciones de modelo fueron:

- $E(u) = E(y - \gamma - \beta x) = 0$.
- $Cov(x, u) = E(xu) - E(x)E(u) = 0 - E(x) \cdot 0 = 0 - 0 = 0$.

Estas dos ecuaciones son restricciones impuestas a los datos sobre la distribución de probabilidad conjunta de x e y . Hay dos incógnitas y dos ecuaciones, lo que sugiere que se puede resolver por y . La muestra homóloga de estas ecuaciones es:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \gamma - \beta x_i) = 0. \quad (9)$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \gamma - \beta x_i)] = 0. \quad (10)$$

De la ecuación (9), se obtiene $\hat{\gamma} = \bar{y} - \hat{\beta} \bar{x}$ y, reemplazando en (10), se obtiene:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \hat{\beta} \sum_{i=1}^n (x_i - \bar{x})^2,$$

lo que implica que el estimador para el parámetro es:

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (11)$$

Siguiendo el teorema de FWL, primero, se tienen que obtener los residuos en la regresión:

$$x_i = \alpha + \epsilon_i \quad \Rightarrow \quad \tilde{x}_i = x_i - \hat{\alpha} = x_i - \bar{x}.$$

Similarmente:

$$y_i = \delta + v_i \quad \Rightarrow \quad \tilde{y}_i = y_i - \hat{\delta} = y_i - \bar{y}.$$

Finalmente, se tienen que regresar los residuos de la variable de respuesta sobre los residuos de la variable de interés:

$$\tilde{y}_i = \pi \tilde{x}_i + \omega_i.$$

Resultando:

$$\begin{aligned}\hat{\pi} &= \frac{\sum_{i=1}^n \tilde{x}_i \tilde{y}_i}{\sum_{i=1}^n \tilde{x}_i^2} \\ \hat{\pi} &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \hat{\pi} &= \hat{\beta}.\end{aligned}\tag{12}$$

Se va a verificar, ahora, que los residuos en las dos ecuaciones son iguales, entonces, los errores estándar de $\hat{\beta}$ y $\hat{\pi}$ son iguales. Nuevamente, por definición:

$$y_i = \hat{\gamma} + \hat{\beta}x_i + \hat{u}_i\tag{13}$$

y

$$\tilde{y}_i = \hat{\pi}\tilde{x}_i + \hat{\omega}_i.\tag{14}$$

Se puede escribir la última ecuación como:

$$\begin{aligned}y_i - \bar{y} &= \hat{\pi}(x_i - \bar{x}) + \hat{\omega}_i \\ y_i - \bar{y} &= \hat{\beta}(x_i - \bar{x}) + \hat{\omega}_i \\ y_i &= \bar{y} + \hat{\beta}x_i - \hat{\beta}\bar{x} + \hat{\omega}_i \\ y_i &= (\bar{y} - \hat{\beta}\bar{x}) + \hat{\beta}x_i + \hat{\omega}_i \\ y_i &= \hat{\gamma} + \hat{\beta}x_i + \hat{\omega}_i,\end{aligned}$$

usando la definición de la intersección $\hat{\gamma}$ (recordar lo que se discutió en la Lectura 1). Notar que los valores ajustados son iguales y, por lo tanto, el residuo en la ecuación (13) es igual al residuo en la ecuación (14).

Ejemplo 3. Se supone que se quieren estimar los rendimientos de la educación teniendo en cuenta el siguiente modelo:

$$lw_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i,\tag{15}$$

donde lw_i es el registro de los salarios del i-ésimo trabajador y x_{1i} , x_{2i} y x_{3i} son el nivel de educación, los años de experiencia y los años con el empleador real del i-ésimo trabajador, respectivamente. La variable de interés es educación, por lo tanto, se puede reescribir el modelo usando nuestra notación anterior:

$$y = Z'\gamma + X\beta + u,$$

donde $y = (lw)$, $Z' = (x_2, x_3)$ y $X = (x_1)$.

Se usa el conjunto de datos de Wooldridge (2002) para estimar el modelo anterior. El conjunto de datos contiene observaciones para 500 individuos (la Figura 1 muestra la relación bivalente entre variables dependientes e independientes). El último gráfico muestra la pendiente obtenida usando parcelas residuales parciales. El retorno a la educación es del 9 por ciento con un error estándar de 0,0075.

5) Error de Especificación y Trade-Offs.

Bajo los supuestos clásicos, el estimador MCO es insesgado, $E(\hat{\beta}) = \beta$. Sin embargo, el estimador puede estar sesgado si se omite una variable en el modelo de regresión. La introducción de variables en el modelo para “corregir” el problema de sesgo no funciona porque la varianza de los estimadores de la versión “larga” del modelo (por ejemplo, el modelo que incluye la variable explicativa adicional) puede ser mayor que la varianza de los estimadores de la versión “corta” del modelo (por ejemplo, el modelo que no incluye la variable explicativa).

Bajo los supuestos discutidos hasta ahora, considerar:

$$y_i = x_i' \beta + z_i' \gamma + u_i.$$

$$y_i = x_i' b + v_i.$$

Tener en cuenta que la segunda ecuación proporciona una proyección de y en x_1 . En este caso, se tiene:

$$E(\hat{b}) = E[(x_i x_i')^{-1} x_i y_i]$$

$$E(\hat{b}) = E[(x_i x_i')^{-1} x_i (x_i' \beta + z_i' \gamma + u_i)]$$

$$E(\hat{b}) = E[(x_i x_i')^{-1} x_i x_i' \beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = E[\beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = E[\beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = E(\beta) + E[(x_i x_i')^{-1} x_i z_i' \gamma] + E[(x_i x_i')^{-1} x_i u_i]$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i E(u_i)$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma + (x_i x_i')^{-1} x_i * 0$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma + 0$$

$$E(\hat{b}) = \beta + (x_i x_i')^{-1} x_i z_i' \gamma,$$

lo que, obviamente, implica que la proyección en la segunda ecuación no identifica un coeficiente de interés β a menos que $x_i z_i' = 0$.

Se analiza, ahora, la disyuntiva que, a menudo, se enfrenta en la econometría aplicada cuando no se observan algunas variables independientes. Se supone, ahora, que el verdadero modelo es:

$$y = X\beta + Z\gamma + u, \quad (16)$$

pero, en cambio, se estima el modelo:

$$y = X\beta + \epsilon. \quad (17)$$

El estimador MCO del parámetro de interés β es:

$$\hat{\beta}_s = \arg \min \|y - X\beta\|^2$$

$$\hat{\beta}_s = (X'X)^{-1} X'y.$$

Podría estar sesgado si cualquier $\gamma \neq 0$ o si las variables independientes observables X y Z no son independientes:

$$E(\hat{\beta}_s) = \beta + (X'X)^{-1}X'Z\gamma$$

$$E(\hat{\beta}_s) = \beta + \Gamma\gamma,$$

donde $\Gamma = (X'X)^{-1}X'Z$. Tener en cuenta que Γ es el estimador de una regresión de Z en X .

Ejemplo 4. Se comienza a estudiar el efecto de sesgo al omitir una variable relevante en el modelo de regresión. Considerar que el verdadero modelo de población es:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u, \quad (18)$$

pero se obtienen estimadores MCO de un modelo similar:

$$y = \beta_0 + \beta_1 x_1 + u, \quad (19)$$

que excluye la variable relevante x_2 . Se supone que se está interesado en el parámetro de pendiente β_1 . En este caso:

$$E(\tilde{\beta}_1) = \beta_1 + \beta_2 \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)x_{i2}}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}$$

$$E(\tilde{\beta}_1) = \beta_1 + \beta_2 \tilde{\alpha}_1.$$

¿Cuál es la interpretación de $\tilde{\alpha}_1$? Tener en cuenta que, si se tiene un modelo de regresión simple de la forma:

$$x_2 = \alpha_0 + \alpha_1 x_1 + \epsilon,$$

y se obtiene el estimador MCO para el parámetro de pendiente α_1 , éste es igual a:

$$\tilde{\alpha}_1 = \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}.$$

Por lo tanto, el sesgo de variable omitida es:

$$E(\tilde{\beta}_1) - \beta_1 = \beta_2 \tilde{\alpha}_1. \quad (20)$$

El sesgo es cero si $\beta_2 = 0$, lo que significa que la variable independiente x_2 no tiene un efecto sobre la variable dependiente y , o si $\tilde{\alpha}_1 = 0$, lo que significa que las variables independientes x_1 y x_2 no están correlacionadas. Si $\beta_2 \approx 0$ o $\tilde{\alpha}_1 \approx 0$, el tamaño del sesgo sería pequeño y, por lo tanto, puede no ser motivo de preocupación.

Algunas veces, es posible inferir el signo del sesgo. Si el signo del parámetro desconocido β_2 es igual al signo de la correlación entre las variables independientes x_1 y x_2 , el sesgo es positivo. En este caso, se dice que $\tilde{\beta}_1$ tiene sesgo ascendente. Por otro lado, si el signo de β_2 es diferente al signo de la correlación entre las variables independientes, el sesgo es negativo. En este caso, se dice que $\tilde{\beta}_1$ tiene sesgo descendente.

Ejemplo 5. Tener en cuenta que y es el logaritmo de los salarios, x_1 indica años de educación y x_2 es la capacidad o “agallas” de algunos trabajadores. Se puede creer que β_2 es positivo y diferente de cero porque hay evidencia que sugiere que las personas con

más talento reciben salarios más altos. Por otro lado, se sospecha que $\text{Corr}(x_1, x_2) \neq 0$. La gente talentosa tiende a pasar más años en la escuela, por lo que se infiere que la relación entre educación y capacidad es positiva. En consecuencia, el sesgo puede ser positivo, por lo que puede ser el caso de la estimación MCO de β_1 .

Aunque $\hat{\beta}_s$ es sesgado, es eficiente en comparación con el estimador de β_1 del modelo largo:

$$\hat{\beta}_l = (X' M_z X)^{-1} X' M_z y.$$

Para ver esto, primero, se escribe el estimador a partir de un modelo corto como:

$$\begin{aligned}\hat{\beta}_s &= (X' X)^{-1} X' y \\ \hat{\beta}_s &= (X' X)^{-1} X' (\hat{y}_l + \hat{u}),\end{aligned}$$

donde $\hat{y}_l$ y $\hat{u}$ son los vectores de los valores ajustados y residuales del modelo largo. Así:

$$\begin{aligned}\hat{\beta}_s &= (X' X)^{-1} X' \hat{y}_l + (X' X)^{-1} X' \hat{u} \\ \hat{\beta}_s &= (X' X)^{-1} X' (X \hat{\beta}_l + Z \hat{\gamma}) + (X' X)^{-1} * 0 \\ \hat{\beta}_s &= (X' X)^{-1} X' X \hat{\beta}_l + (X' X)^{-1} X' Z \hat{\gamma} + 0 \\ \hat{\beta}_s &= I \hat{\beta}_l + \Gamma \hat{\gamma} \\ \hat{\beta}_s &= \hat{\beta}_l + \Gamma \hat{\gamma}.\end{aligned}$$

Por lo tanto, la varianza del estimador en el modelo largo es:

$$\begin{aligned}V(\hat{\beta}_l) &= V(\hat{\beta}_s - \Gamma \hat{\gamma}) \\ V(\hat{\beta}_l) &= V(\hat{\beta}_s) + \Gamma V(\hat{\gamma}) \Gamma', \\ (21)\end{aligned}$$

lo que implica que:

$$V(\hat{\beta}_l) \geq V(\hat{\beta}_s),$$

ya que el término cuadrático es semidefinido positivo. El resultado en la ecuación (21) se cumple si el término de covarianza (faltante) es cero. Se verifican las condiciones bajo las cuales la ecuación (21) se cumple en el siguiente teorema.

Teorema 3. $\text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) = 0$.

Prueba. Primero, recordar esto:

$$\begin{aligned}\hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x y \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x (X \beta + Z \gamma + u) \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x X \beta + (Z' M_x Z)^{-1} Z' M_x Z \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' * 0 * \beta + I \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= 0 + \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= \gamma + (Z' M_x Z)^{-1} Z' M_x u.\end{aligned}$$

Además, recordar que:

$$\begin{aligned}
\hat{\beta} &= (X'M_z X)^{-1} X' M_z y \\
\hat{\beta} &= (X'M_z X)^{-1} X' M_z (X\beta + Z\gamma + u) \\
\hat{\beta} &= (X'M_z X)^{-1} X' M_z X\beta + (X'M_z X)^{-1} X' M_z Z\gamma + (X'M_z X)^{-1} X' M_z u \\
\hat{\beta} &= I\beta + (X'M_z X)^{-1} X' * 0 * \gamma + (X'M_z X)^{-1} X' M_z u \\
\hat{\beta} &= \beta + 0 + (X'M_z X)^{-1} X' M_z u \\
\hat{\beta} &= \beta + (X'M_z X)^{-1} X' M_z u.
\end{aligned}$$

Por definición, se tiene esto:

$$\begin{aligned}
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [\hat{\beta}_s - E(\hat{\beta}_s)] [\Gamma\hat{\gamma} - E(\Gamma\hat{\gamma})]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [\Gamma\hat{\gamma} - \Gamma E(\hat{\gamma})]' \} \quad (*) \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [\Gamma(\hat{\gamma} - \gamma)]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [(\hat{\gamma} - \gamma)' \Gamma]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [(Z'M_x Z)^{-1} Z'M_x u]' \Gamma' \},
\end{aligned}$$

$$\begin{aligned}
(*) \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - E[\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - \{E(\beta) + E[(X'X)^{-1} X'Z\gamma] + E[(X'X)^{-1} X'u]\} \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X' E(u)] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X' * 0] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + 0] \\
\hat{\beta}_s - E(\hat{\beta}_s) &= \beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u - \beta - (X'X)^{-1} X'Z\gamma \\
\hat{\beta}_s - E(\hat{\beta}_s) &= (X'X)^{-1} X'u.
\end{aligned}$$

reemplazando por definiciones. La última expresión se puede escribir como:

$$\begin{aligned}
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [u'M_x Z(Z'M_x Z)^{-1} \Gamma]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'uu'M_x Z(Z'M_x Z)^{-1} \Gamma]' \} \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' E(uu') M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' V(u) M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' \sigma^2 I M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= (X'X)^{-1} X' \sigma^2 M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= \sigma^2 (X'X)^{-1} X' M_x Z(Z'M_x Z)^{-1} \Gamma' \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= \sigma^2 (X'X)^{-1} * 0 * Z(Z'M_x Z)^{-1} \Gamma' \quad (**) \\
\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= 0,
\end{aligned}$$

$$\begin{aligned}
(**) X'M_x &= X'(I - P_x) \\
X'M_x &= X'[I - X(X'X)^{-1} X'] \\
X'M_x &= X'I - X'X(X'X)^{-1} X' \\
X'M_x &= X' - IX' \\
X'M_x &= X' - X' \\
X'M_x &= 0.
\end{aligned}$$

porque $V(u) = \sigma^2 I$. Tener en cuenta que $M_x X = 0$, por lo tanto, la covarianza es igual a cero bajo homocedasticidad.

Ahora, se resumen los puntos principales. Ya que, en la economía aplicada, generalmente, las variables independientes están correlacionadas y hay variables que se omiten debido a que son difíciles de medir:

1. Omitir variables independientes introduce sesgo.
2. Agregar variables independientes “infla” la varianza.

Observación 2. Se supone, ahora, que se está interesado en el efecto de omitir una variable que está correlacionada con X_1 . Se supone, ahora, que hay una matriz de variables Z y se considera descomponer X como:

$$X\beta = X_1\beta_1 + X_2\beta_2$$

$$X\beta = P_Z X_1\beta_1 + M_Z X_1\beta_1 + X_2\beta_2.$$

Para $\gamma = 0$, se tiene esto:

$$X\beta = P_Z X_1 (\beta_1 + \gamma) + M_Z X_1\beta_1 + X_2\beta_2$$

$$X\beta = P_Z X_1\beta_1 + P_Z X_1\gamma + M_Z X_1\beta_1 + X_2\beta_2$$

$$X\beta = (P_Z + M_Z) X_1\beta_1 + X_2\beta_2 + P_Z X_1\gamma$$

$$X\beta = I X_1\beta_1 + X_2\beta_2 + P_Z X_1\gamma$$

$$X\beta = X_1\beta_1 + X_2\beta_2 + P_Z X_1\gamma.$$

Por lo tanto, ahora, se puede usar una prueba F con $H_0: \gamma = 0$ usando la siguiente regresión:

$$y = X\beta + \hat{X}_1\gamma + u.$$

Esto está relacionado con la versión de regresión auxiliar de la célebre prueba de Hausman (1978) [véase también Wu (1973)]. Tener en cuenta que, si reemplaza $\hat{X}_1$ por una matriz que contenga potencias de $\hat{y}$ (por ejemplo, $\hat{y}^2$, $\hat{y}^3$, etc.), se tiene la prueba de Ramsey para error de especificación.

6) Implicaciones Prácticas.

Si X y Z en la ecuación (16) no están correlacionados, entonces, no hay un sesgo de variable omitida y, si la LRP está especificada correctamente, el parámetro β_1 en (17) puede tener una interpretación causal. Sin embargo, los experimentos no son comunes, por lo que los investigadores se basan en variables de control para eliminar los sesgos.

Esto está conectado con lo que se conoce como el *supuesto de independencia condicional* o CIA [como en Angrist y Pischke (2009)]. Ésta es una condición que se quiere satisfacer para la estimación y para la inferencia y aquí está el por qué. Considerar un modelo simple bivariado:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$

donde β_1 es un parámetro o efecto causal constante. Por ejemplo, y_i es ganancias y x_i tiene un título universitario o un indicador de estado de veterano. El término de error ϵ_i captura otros factores que afectan las ganancias. Si:

$$\epsilon_i = \delta_0 + \delta_1 z_i + v_i,$$

donde z_i denota una variable “observable” o, simplemente, un vector de observables. Como se supone que v_i no está correlacionado con z_i , se tiene que $E(\epsilon_i | x_i) \neq 0$ pero $E(v_i | x_i, z_i) = 0$. Por lo tanto, se estima un modelo “aumentado” con control z_i :

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + v_i,$$

por MCO, obteniendo una estimación no sesgada de β_1 . Tener en cuenta que esto no sería posible si se usa MCO para estimar (17).

Ejemplo 6. El papel de las covariables se puede ver en la ilustración presentada en la Tabla 1. Se usan datos de la Seguridad Social y datos administrativos de Angrist (1998), que estudió el efecto del servicio militar voluntario sobre las ganancias de los soldados. Se utilizan trabajadores que solicitaron el servicio militar entre 1976 y 1981 y se estima el modelo antes del servicio militar y después (es decir, para los años 1974 y 1985, como se muestra en la tabla). El servicio militar voluntario, obviamente, no es aleatorio y, probablemente, esté correlacionado con la educación, la edad, los puntajes de las pruebas, los efectos de cohorte, etc. También se sabe que estos observables afectan las ganancias. Por lo tanto, es probable que la omisión de estas variables introduzca sesgos.

El punto es que, después de controlar todas estas diferencias “observables” (usando también interacciones), los veteranos y los no veteranos son comparables. Si no se cree en esta premisa, los resultados que se muestran en la Tabla 1 apuntan al hecho de que el modelo estimado sin controles arroja resultados que parecen engañosos.

Observación 3. Nos referimos a los controles como variables exógenas u observables, no a variables que están determinadas por la variable de interés. Estos controles no son, potencialmente, variables del lado derecho para otras ecuaciones (o variables endógenas en general). Por ejemplo, en la ecuación de Mincer:

$$\log(wage)_i = \beta_0 + \beta_1 educ_i + \alpha_i + u_i,$$

α_i mide la capacidad del trabajador i y no se observa (parte del término de error). Tiene sentido suponer que $Cov(\alpha_i, educ_i) \neq 0$. En el mundo de la CIA, es tentador incluir variables para satisfacer esta condición y, a veces, estas variables están disponibles para los profesionales. Por ejemplo, es posible que se tengan puntajes de prueba utilizados para evaluar a los solicitantes de empleo. El verdadero problema es que el rendimiento en la prueba, probablemente, se correlacione con la educación también.

Para simplificar, considerar que los puntajes de las pruebas se modelan como $score_i = \pi_0 + \pi_1 educ_i + \alpha_i + \epsilon_i$. Si se usan los puntajes de las pruebas como una variable de control, se estima:

$$\log(wage)_i = \gamma_0 + \gamma_1 educ_i + \gamma_2 score_i + v_i,$$

donde $\gamma_1 = \beta_1 - \pi_1 \neq \beta_1$. Angrist y Pischke (2009) llaman a estas variables, incluida la puntuación de la prueba utilizada en este ejemplo, “controles malos”.

Lectura 3: **Teoría de Muestra Grande.**

Las suposiciones mantenidas, hasta ahora, han sido:

- A1: El modelo es lineal y está dado por $y_i = x_i' \beta + u_i$.
- A2: El rango de la matriz X es p .
- A3: El valor esperado condicional de y es igual a $E(y_i | X) = x_i' \beta$ para todos los sujetos i en la muestra de tamaño n .
- A4: La varianza condicional de y es igual a $V(y | X) = V(X\beta + u | X) = V(u) = \sigma^2 I$, donde $\sigma^2 > 0$ y I es la matriz identidad.

A menudo, se supone que $u_i \sim \mathcal{N}(0, 1)$, pero esta condición es muy fuerte. Se puede reemplazar por una condición más débil en los momentos de las variables aleatorias:

- A5: Las observaciones $\{(y_i, x_i); i = 1, 2, \dots, n\}$ están i.i.d. a través de i y sus cuartos momentos existen, es decir, $E(z_i^4) < \infty$ para una variable genérica z . También $E(x_i x_i')$ es una matriz no singular.

Se supone que y_i y x_i se distribuyen conjuntamente y su cuarto momento existe (por ejemplo, $E(z^4) < \infty$ para $z = \{x, y\}$). Una implicación es que el término de error u_i no necesita ser distribuido normalmente, pero su cuarto momento debería existir: $E(u^4) < \infty$.

1) Asintóticos como Herramienta.

Varios resultados obtenidos en econometría se basan en el supuesto de normalidad. Esto, ciertamente, no es una suposición leve y no se cumple en la práctica.

Asintótica es una herramienta que ayuda a aproximar la distribución de los estimadores o estadísticos de prueba sin asumir una distribución paramétrica, por supuesto siempre que el número de observaciones n (es decir, el tamaño de la muestra) es, suficientemente, “grande”. La mayoría de los métodos econométricos utilizados en economía aplicada funcionan bien cuando el tamaño de la muestra es grande. Además, a veces, es muy difícil obtener el error estándar de los estimadores no lineales en modelos lineales como en los ejemplos siguientes. Se usa una aproximación asintótica de la distribución del estimador, llamada “método delta” (ver el Lema 3.9 en Wooldridge 2010 y la Sección 5 a continuación).

Ejemplo 1. Considerar el modelo $y_t = x_t' \beta + u_t$, con t que denota el tiempo, y el interés está en estimar el parámetro de elasticidad, $\eta_j = \frac{\partial E(y | x)}{\partial x_j} \frac{x_j}{E(y | x)}$. Un estimador es:

$$\hat{\eta}_j = \hat{\beta}_j \frac{\bar{x}_j}{\bar{y}},$$

pero el error estándar de $\hat{\eta}_j$ es difícil de obtener porque $\hat{y}$ y $\bar{x}_j$ son variables aleatorias. Se puede aplicar el método delta y obtener el error estándar de $\hat{\eta}_j$. (Se necesita aplicar la regla de la cadena desde $\beta_j \frac{x_j}{x' \beta}$).

Ejemplo 2. Considerar un modelo dinámico de la forma, $y_t = \gamma y_{t-1} + x_t' \beta + u_t$, con variables en logaritmos. La elasticidad a largo plazo de un cambio en x_j es, en este caso, $\eta_j = \frac{\beta_j}{1-\gamma}$. De nuevo, el estimador no es lineal en los parámetros:

$$\hat{\eta}_j = \frac{\hat{\beta}_j}{1-\hat{\gamma}},$$

entonces, el error estándar de $\hat{\eta}_j$ se puede obtener aplicando el método delta.

2) Antecedentes.

2.1) Resultados de muestra grande.

Considerar la secuencia de variables aleatorias $\{X_n: n=1, 2, \dots\}$ y que X sea una variable aleatoria de valor real en un espacio de probabilidad bien definido.

Definición 1 (Convergencia en probabilidad). Se dice que X_n converge en probabilidad a X si:

$$P(|X_n - X| > \epsilon) \rightarrow 0, \quad \text{cuando } n \rightarrow \infty, \quad (1)$$

para todo $\epsilon > 0$.

Intuitivamente, la probabilidad de que la diferencia $|X_n - X|$ tome un valor grande es muy pequeña a medida que aumenta el tamaño de la muestra n . Si $X_n \rightarrow \beta$, donde β es una constante, se dice que X_n es consistente y, a menudo, se denota por $\text{plim}_{n \rightarrow \infty} X_n = \beta$.

¿Por qué los conceptos de convergencia son importantes? Se necesita una noción de “cercanía” a parámetros desconocidos. Recordar que se tiene una muestra aleatoria i.i.d. (distribuida de forma independiente e idéntica) $X_1, X_2, \dots$, con realizaciones $x_1, x_2, \dots$. La distribución conjunta puede obtenerse multiplicando la distribución marginal. Se supone también que se está interesado en dos parámetros, la media poblacional $E(X) = \mu$ y la varianza poblacional $\text{Var}(X) = \sigma^2$. Se pueden estimar con:

$$\begin{aligned} \bar{X}_n &= T_x(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i. \\ S^2 &= T_s(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2. \end{aligned}$$

¿Cuán “cercano” es $\bar{X}_n$ a μ y S^2 a σ^2 . Si el tamaño de la muestra es, suficientemente, grande, se espera que $(\bar{X}_n, S^2)$ esté cerca de (μ, σ^2) . Ahora, se supone que se tiene un experimento aleatorio y se obtienen resultados básicos s del espacio muestral S . Se observa $x_i = X_i(s)$ y se puede obtener:

$$\bar{x}_n = \bar{X}_n(s). \quad (2)$$

Tener en cuenta que los diferentes resultados crearán diferentes números reales $\{\bar{x}_n = \bar{X}_n(s): n = 1, 2, \dots\}$. La Figura 1 ilustra el rendimiento de $\bar{X}_n(s)$ y $S^2(s)$ para tres resultados diferentes s_1, s_2 y s_3 de S .

Ejemplo 3. Se supone que $Y_1, Y_2, \dots, Y_n$ es una muestra aleatoria i.i.d. de una distribución uniforme $U(0, \theta)$, donde θ es un parámetro desconocido. Es natural estimar θ considerando el estadístico de orden más grande, es decir, $X_n = \max_{1 \leq i \leq n} \{Y_i\}$. ¿Este estimador es consistente? Tener en cuenta que, para una pequeña constante $\epsilon > 0$, se tiene que $\{|X_n - \theta| > \epsilon\} = \{X_n - \theta > \epsilon\} \cup \{X_n - \theta < -\epsilon\}$. Por lo tanto:

$$P(|X_n - \theta| > \epsilon) = P(X_n - \theta > \epsilon) + P(X_n - \theta < -\epsilon)$$

$$P(|X_n - \theta| > \epsilon) = P(X_n > \theta + \epsilon) + P(X_n < \theta - \epsilon)$$

$$P(|X_n - \theta| > \epsilon) = 0 + P(\max_{1 \leq i \leq n} \{Y_i\} < \theta - \epsilon)$$

$$P(|X_n - \theta| > \epsilon) = P(Y_1 < \theta - \epsilon, Y_2 < \theta - \epsilon, \dots, Y_n < \theta - \epsilon)$$

$$P(|X_n - \theta| > \epsilon) = P(Y_1 < \theta - \epsilon) P(Y_2 < \theta - \epsilon) \dots P(Y_n < \theta - \epsilon)$$

$$P(|X_n - \theta| > \epsilon) = \prod_{i=1}^n P(Y_i < \theta - \epsilon)$$

$$P(|X_n - \theta| > \epsilon) = \left(\frac{\theta - \epsilon}{\theta}\right)^n$$

$$P(|X_n - \theta| > \epsilon) = \left(1 - \frac{\epsilon}{\theta}\right)^n \rightarrow 0, \quad \text{cuando } n \rightarrow \infty.$$

Definición 2 (Convergencia casi segura). Se dice que X_n converge con probabilidad 1, o casi seguramente, a X si:

$$P(\lim_{n \rightarrow \infty} X_n = X) = 1. \quad (3)$$

Definición 3 (Convergencia en media q^{th}). Se dice que X_n converge en media q^{th} a X si:

$$\lim_{n \rightarrow \infty} E |X_n - X|^q = 0. \quad (4)$$

Definición 4 (Convergencia en distribución). Se dice que X_n converge en distribución a X si:

$$\lim_{n \rightarrow \infty} F_n(X) = F(X). \quad (5)$$

En cada punto de continuidad de F , se denota esto como $X_n \rightarrow^d X$.

Teorema 1. Si $X_n \xrightarrow{como} X_1$, entonces, $X_n \xrightarrow{p} X$, que dice que la convergencia casi segura implica convergencia en probabilidad.

Teorema 2. Si $X_n \xrightarrow{rth} X$, entonces, $X_n \xrightarrow{p} X$.

Prueba.

$$E |X_n - X|^r \geq E \{|X_n - X|^r I(|X_n - X|^r > \epsilon)\} \geq \epsilon^r P(|X_n - X| > \epsilon). \quad (6)$$

$$P(|X_n - X| > \epsilon) \leq \epsilon^{-r} E |X_n - X|^r \rightarrow 0, \quad \text{cuando } n \rightarrow \infty. \quad (7)$$

Corolario 1. La convergencia en probabilidad $X_n \xrightarrow{p} X$ implica la convergencia en distribución $X_n \rightarrow^d X$.

Corolario 2. La convergencia en probabilidad a una constante es equivalente a la convergencia en distribución a una constante dada.

Teorema 3 (Equivalencia asintótica). Considerar una muestra aleatoria (Y_n, X_n) con $Y_n \rightarrow^d y$ y $|Z_n| \rightarrow^p 0$, donde $Z_n = Y_n - X_n$. Se deduce que $X_n \rightarrow^d y$.

Prueba. Para $\epsilon > 0$, se puede escribir $P(X_n < v) = P(Y_n < v + Z_n) = P(Y_n < v + Z_n, Z_n < \epsilon) + P(Y_n < v + Z_n, Z_n \geq \epsilon)$. Tener en cuenta también que $P(Y_n < v + Z_n, Z_n < \epsilon) \leq P(Y_n < v + \epsilon)$. Entonces, se deduce que:

$$\begin{aligned} P(X_n < v) &\leq P(Y_n < v + \epsilon) + P(Y_n < v + Z_n, Z_n \geq \epsilon) \\ P(X_n < v) &\leq P(Y_n < v + \epsilon) + [P(Z_n \geq \epsilon) P(Y_n < v + Z_n, Z_n \geq \epsilon)] \\ P(X_n < v) &\leq P(Y_n < v + \epsilon) + P(Z_n \geq \epsilon). \end{aligned}$$

Tener en cuenta que se puede escribir, de manera similar, $P(X_n < v) = P(Y_n < v + Z_n) = P(Y_n < v + Z_n, Z_n > -\epsilon) + P(Y_n < v + Z_n, Z_n \leq -\epsilon)$, lo que lleva a:

$$P(X_n < v) \geq P(Y_n < v - \epsilon) + P(Z_n \leq -\epsilon).$$

Suponiendo que $|Z_n| \rightarrow^p 0$, el último término tiende a 0 cuando $n \rightarrow \infty$, por lo que puede ser ignorado. Se puede escribir:

$$P(Y_n < v - \epsilon) \leq P(X_n < v) \leq P(Y_n < v + \epsilon).$$

Al elegir ϵ , arbitrariamente, pequeño, se tiene que $F_X = F_Y$ cuando $n \rightarrow \infty$.

Se puede interpretar este resultado como que muestra la equivalencia asintótica cuando dos variables aleatorias están muy cerca la una de la otra. Como ejemplo ilustrativo, considerar $Y_n = \sqrt{n} \frac{\bar{X}_n}{S_n}$ y $Z_n = \sqrt{n} \frac{\bar{X}_n}{\sigma}$, donde σ es un parámetro desconocido. Tratar con un denominador aleatorio S_n es complicado, pero, primero, se puede mostrar que $Y_n - Z_n \rightarrow^p 0$ y, luego, obtener la distribución de Y_n usando el resultado que $Y_n \rightarrow^d Z$.

Teorema 4 (Slutsky). Se tiene $X_n \rightarrow^d x$ y $Y_n \rightarrow y$, una constante real. Entonces:

1. $X_n + Y_n \rightarrow^d x + y$.
2. $X_n Y_n \rightarrow^d yx$.
3. $\frac{X_n}{Y_n} \rightarrow^d \frac{x}{c}$ si $c \neq 0$.

Teorema 5 (Mapeo continuo). Si $X_n \rightarrow^d X$ y g es continua, $g(X_n) \rightarrow g(X)$.

Ejemplo 4. Si $X_n \rightarrow^d \mathcal{N}(0, 1)$, entonces, $X_n^2 \rightarrow^d \chi_1^2$.

Ejemplo 5. Si $(X_n, Y_n) \rightarrow^d \mathcal{N}(0, I_2)$, entonces, $\frac{X_n}{Y_n} \rightarrow^d z$, una variable aleatoria de Cauchy.

Ejemplo 6. Cuando g no es continuo, es posible que se tenga que tener cuidado. Considerar el siguiente ejemplo:

$$g(t) = \begin{cases} t - 1, & t \leq 0 \\ t + 1, & t > 0 \end{cases}$$

Se tiene $X_n = \frac{1}{n}$, luego, $X_n \rightarrow X = 0$, $g(X_n) \rightarrow 1$, pero $g(X) = -1$.

2.2) Relaciones de orden y tasas de convergencia.

Ahora, se examinan las relaciones de orden y las tasas de convergencia. En esta sección, los términos $O(\cdot)$ (“o grande”) y $o(\cdot)$ (“o pequeña”) se usan para determinar el orden de magnitud de las secuencias determinísticas y estocásticas.

Considerar las secuencias deterministas positivas $\{a_n\}$ y $\{b_n\}$.

Definición 5. $a_n = o(b_n)$ cuando $n \rightarrow \infty$ si $\frac{a_n}{b_n} \rightarrow 0$.

Quizás, ahora, sea bueno tener una definición más completa.

Definición 6 (Órdenes de magnitud). Una secuencia $\{a_n\}$ es de un orden más pequeño que n^λ , que es denotado por $a_n = o(n^\lambda)$ o $n^{-\lambda}a_n = o(1)$, si, para $n \geq N$, se tiene que:

$$|n^{-\lambda}a_n| < \epsilon,$$

para $\epsilon > 0$.

Definición 7 (Órdenes de magnitud). Una secuencia $\{b_n\}$ es de un orden mayor que n^λ , que es denotado por $b_n = O(n^\lambda)$ o $n^{-\lambda}b_n = O(1)$, si, para $n \geq N$, se tiene que:

$$|n^{-\lambda}a_n| < K,$$

donde $K < \infty$ es un número real muy grande.

Observación 1. Si a_n y b_n tiende a infinito, esto indica que a_n tiende a infinito más lentamente que b_n . Si a_n y b_n tiende a cero, esto indica que a_n tiende a cero más rápido que b_n .

Ejemplo 7. $\frac{1}{n^2} = o(\frac{1}{n})$ cuando $n \rightarrow \infty$, porque $\frac{\frac{1}{n^2}}{\frac{1}{n}} = \frac{n}{n^2} = \frac{1}{n} \rightarrow 0$.

Observación 2. Hace una gran diferencia si una secuencia tiende a cero a velocidad $\frac{1}{n^2}$ o $\frac{1}{n}$.

Suponer:

$$a_n = \frac{1}{n} - \frac{2}{n^2} + \frac{4}{n^3}. \quad (8)$$

Se va a aproximar a_n por $b_n = \frac{1}{n}$. Por lo tanto:

$$a_n = \frac{1}{n} + R_n = \frac{1}{n} + o\left(\frac{1}{n}\right), \quad (9)$$

donde $R_n = \frac{2}{n^2} + \frac{4}{n^3} = o\left(\frac{1}{n}\right)$. O, si se aproxima a_n por $\frac{1}{n} - \frac{2}{n^2}$, se escribe:

$$a_n = \frac{1}{n} - \frac{2}{n^2} + o\left(\frac{1}{n^2}\right). \quad (10)$$

Lema 1.

- (a) $a_n = o(1)$ si $a_n \rightarrow 0$.
- (b) Si $a_n = o(b_n)$ y $b_n = o(c_n)$, entonces, $a_n = o(c_n)$.
- (c) Para cualquier constante $c \neq 0$, $a_n = o(b_n)$ implica que $ca_n = o(b_n)$.
- (d) Para cualquier secuencia de números $c_n \neq 0$, $a_n = o(b_n)$ implica que $c_n a_n = o(c_n b_n)$.
- (e) Si $d_n = o(b_n)$ y $e_n = o(c_n)$, entonces, $d_n e_n = o(b_n c_n)$.

Ejemplo 8. Sea $a_n = \log n$ y $b_n = n^k$. Entonces:

$$a_n = o(b_n) \text{ para cada } k > 0. \quad (11)$$

Definición 8. Si a_n es de orden n menor o igual a b_n , se dice que:

$$a_n = O(b_n). \quad (12)$$

Si hay un $\Delta < \infty$, tal que $\frac{a_n}{b_n} \leq \Delta$ para n suficientemente grande, se dice que $a_n = O(b_n)$. Tener en cuenta que, en particular, $a_n = O(1)$ si la secuencia a_n está limitada.

Lema 2. Si $a_n = O(n^r)$ y $b_n = O(n^s)$, entonces:

- (a) $a_n b_n = O(n^{r+s})$.
- (b) $a_n + b_n = O(n^{\max\{r,s\}})$.

Los términos $O_p(\cdot)$ ("oh grande") y $o_p(\cdot)$ (oh chica) son para secuencias estocásticas. Intuitivamente, se puede decir que una secuencia $\{X_n: n = 1, 2, \dots\}$ es de un orden de magnitud menor que n^λ si converge en probabilidad $\frac{X_n}{n^\lambda} \rightarrow 0$ cuando $n \rightarrow \infty$. Se denota por $X_n = O_p(n^\lambda)$.

De manera similar, se puede decir que una secuencia $\{X_n: n = 1, 2, \dots\}$ es, a lo sumo, de orden de magnitud n^λ si $P\left(\left|\frac{X_n}{n^\lambda}\right| > M\right) < \delta$, donde $\delta > 0$. Se denota por $X_n = O_p(n^\lambda)$ e implica que X_n está limitada en probabilidad.

Ahora, considerar las secuencias $\{X_n\}$ y $\{Y_n\}$ en el espacio de probabilidad (Ω, A, P) y cualquier $\epsilon > 0$.

Definición 9.

- (a) Si $\exists \Delta < \infty$ tal que $P(|X_n| \geq \Delta |Y_n|) < \epsilon$, para n lo suficientemente grande, se escribe:

$$X_n = O_p(Y_n). \quad (13)$$

Si Y_n no es estocástico, se dice que X_n está limitada en probabilidad y $X_n = O_p(1)$.

(b) Si $P(|X_n| \geq \epsilon |X_n|) \rightarrow 0$, se escribe $X_n = O_p(Y_n)$. Se dice que está tendiendo a cero en probabilidad, es decir:

$$\frac{X_n}{Y_n} \rightarrow 0. \quad (14)$$

3) Unos cuantos LGNs y TLCs.

La ley de los grandes números (LGN) y el teorema del límite central (TLC) desempeñan un papel clave en la econometría. Para una extensa discusión, ver White (2000) y Davidson (1994). En esta sección, se repasarán algunos resultados con particular énfasis en las variaciones relacionadas con la distribución de una secuencia de variables aleatorias.

Teorema 6 (Khinchine LGN). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu$. Entonces:

$$\hat{X} = \frac{1}{n} \sum_{i=1}^n X_i - \mu \rightarrow^p 0. \quad (15)$$

Teorema 7 (Chebyshev LGN). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu_i$ y $\text{Var}(X_i) = \sigma_i^2$. Si $n^{-1} \sum_{i=1}^n \sigma_i^2 \leq K < \infty$ cuando $n \rightarrow \infty$, entonces:

$$\hat{X}_n - \mu_n = \frac{1}{n} \sum_{i=1}^n \mu_i \rightarrow^p 0. \quad (16)$$

Teorema 8 (Kolmogorov LGN). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu_i$ y $\text{Var}(X_i) = \sigma_i^2$. Si $n^{-1} \sum_{i=1}^n \sigma_i^2 < \infty$ cuando $n \rightarrow \infty$, entonces, $\bar{X}_n - \mu_n \rightarrow 0$ con probabilidad 1.

La literatura sobre TCL es extensa, por lo que sólo se discutirán algunos resultados.

Teorema 9 (Lindberg-Levy TLC). Sea $\{X_i\}$ una secuencia de variables aleatorias i.i.d. con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2$. Entonces:

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \rightarrow^d \mathcal{N}(0, 1).$$

Teorema 10. Sea $\{X_i\}$ una secuencia de variables aleatorias independientes con $E(X_i) = \mu_i$, $\text{Var}(X_i) = \sigma_i^2$ y $E(|X_i - \mu_i|^{2+\delta}) < \infty$ para algunos $\delta > 0$. Si $\lim_{n \rightarrow \infty} n^{-1} \sum_{i=1}^n \sigma_i^2 < \infty$, entonces:

$$\frac{\sqrt{n}(\bar{X}_n - \bar{\mu}_n)}{\bar{\sigma}_n} \rightarrow^d \mathcal{N}(0, 1). \quad (18)$$

4) La Teoría Asintótica de MCO.

4.1) Consistencia.

Definición 10. Un estimador consistente $\hat{\theta}$ es uno que converge a θ_0 en probabilidad:

$$\hat{\theta} \rightarrow \theta_0 \quad (19)$$

a medida que el tamaño de la muestra n va al infinito, para todos los valores verdaderos posibles. Con esta definición en mente, ahora, se investiga la consistencia de MCO en el ajuste concebible más simple. Considerar un modelo de regresión lineal de la forma:

$$y_i = x_i' \beta + u_i, \quad (20)$$

donde $E(u_i | x_i) = E(u_i) = 0$. Se puede asumir, provisionalmente, que los términos de error u están i.i.d. aleatoriamente con distribución F . El estimador MCO para el parámetro desconocido β es $\hat{\beta} = (X'X)^{-1}X'y$ y puede ser escrito como:

$$\begin{aligned} \hat{\beta} - \beta &= (X'X)^{-1}X'u \\ \hat{\beta} - \beta &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right), \end{aligned} \quad (22)$$

donde X es una matriz de $(n \times p)$ y u es un vector de $(n \times 1)$. Si las x_i son consideradas fijas o no estocásticas, se tiene que el primer término del lado derecho de la ecuación:

$$\frac{1}{n} \sum_{i=1}^n x_i x_i' \rightarrow Q_0$$

y

$$\frac{1}{n} \sum_{i=1}^n x_i u_i \rightarrow 0.$$

Notar que:

$$E\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) = 0, \quad (23)$$

porque $E(u_i | x_i) = 0$ y los u_i son independientes. Además:

$$\begin{aligned} \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n x_i u_i\right) \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(x_i u_i) \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \sum_{i=1}^n x_i \text{Var}(u_i) x_i' \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n^2} \sum_{i=1}^n x_i \sigma^2 x_i' \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{\sigma^2}{n^2} \sum_{i=1}^n x_i x_i' \\ \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) &= \frac{\sigma^2}{n} \frac{1}{n} \sum_{i=1}^n x_i x_i' \rightarrow 0 * E(X'X) \rightarrow 0. \end{aligned} \quad (26)$$

Entonces:

$$\hat{\beta} \rightarrow \beta, \quad (27)$$

siguiendo con una simple aplicación de Chebyshev y el teorema de Slutsky (el caso de las x estocásticas requiere el uso de LGN, pero el argumento es similar).

Observación 3 (Inconsistencia 1). Tener en cuenta que, si $x_i = i$ en un modelo sin interceptación y $p = 1$, entonces:

$$\hat{\beta} - \beta = \left(\frac{1}{n} \sum_{i=1}^n i^2 \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n i u_i \right).$$

Es, inmediatamente, evidente que:

$$\frac{1}{n} \sum_{i=1}^n i^2,$$

no converge a una constante (Q_0 como antes) y la inversa no existe. Tener en cuenta que dividir por n^2 tampoco funcionará. Sin embargo, si:

$$n(\hat{\beta} - \beta) = \left(\frac{1}{n^3} \sum_{i=1}^n i^2 \right)^{-1} \left(\frac{1}{n^2} \sum_{i=1}^n i u_i \right),$$

el primer término en el lado derecho converge a $\frac{1}{3}$ cuando $n \rightarrow \infty$ y la varianza del último término converge a cero.

Observación 4 (Súper consistencia). El estimador súper consistente es:

$$n(\hat{\beta} - \beta) = O_p n^{-\frac{3}{2}},$$

mientras que el estimador MCO estándar cuando u_i no es una tendencia determinista es:

$$n(\hat{\beta} - \beta) = O_p n^{-\frac{1}{2}}.$$

Observación 5 (Inconsistencia 2). Si la ecuación principal omite una variable, dígame la variable v_i , entonces:

$$\hat{\beta} - \beta = \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \left[\frac{1}{n} \sum_{i=1}^n x_i (v_i + u_i) \right].$$

Siguiendo los pasos anteriores, se tiene:

$$\hat{\beta} - \beta \rightarrow Q_0^{-1} Q_{xv} \neq 0,$$

donde Q_{xv} es la matriz de covarianza de x_i y v_i , que no es cero si las variables están correlacionadas.

4.2) Normalidad asintótica.

Considerar (de nuevo) un modelo de regresión lineal:

$$y_i = x_i' \beta + u_i. \quad (28)$$

Recordar que $\hat{\beta} - \beta = (X'X)^{-1} X'u$. Se puede escribir:

$$\begin{aligned} \sqrt{n} (\hat{\beta} - \beta) &= \left(\frac{X'X}{n} \right)^{-1} \frac{1}{\sqrt{n}} X'u \\ \sqrt{n} (\hat{\beta} - \beta) &= n \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \frac{1}{\sqrt{n}} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i \right) \\ \sqrt{n} (\hat{\beta} - \beta) &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i' \right)^{-1} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \right). \end{aligned}$$

Si se aplica el Corolario 1, se tiene que:

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \rightarrow^d \mathcal{N}(0, \sigma^2 Q_0). \quad (29)$$

Por el teorema de Slutsky, se tiene que:

$$\sqrt{n} (\hat{\beta} - \beta) \rightarrow^d Q_0^{-1} \mathcal{N}(0, \sigma^2 Q_0) = \mathcal{N}(0, \sigma^2 Q_0^{-1}). \quad (30)$$

Tener en cuenta que se aplica, de nuevo, el teorema de Slutsky. En resumen, la normalidad asintótica se deriva de (i) la convergencia en distribución de la puntuación, (ii) la convergencia en probabilidad del Hessiano y (iii) el teorema de Slutsky.

Observación 6 (Inconsistencia 2). La clave para los resultados obtenidos antes es el hecho de que:

$$\begin{aligned} S &= E(x_i x_i' u_i^2) \\ S &= E[E(x_i x_i' u_i^2 | x_i)] \\ S &= E[x_i x_i' E(u_i^2 | x_i)] \\ S &= E(x_i x_i' \sigma^2) \\ S &= \sigma^2 E(x_i x_i') \\ S &= \sigma^2 Q_0 \end{aligned}$$

y, si $E(u_i^2 | x_i) \neq \sigma^2$, no se pueden simplificar las expresiones como en los últimos pasos.

5) El Modelo Delta.

Para el método, el primer resultado que se necesita es la consistencia: si la función g es agradable y lisa, entonces, $g(\hat{\theta}) \rightarrow g(\theta)$. Asumiendo que $\hat{\theta}$ es consistente y asintóticamente normal con varianza Ω y que $g(\cdot)$ es suave:

$$\sqrt{n} [g(\hat{\theta}) - g(\theta)] \rightsquigarrow \mathcal{N}(0, G' \Omega G),$$

donde:

$$G = \nabla_{\theta} g(\theta) \big|_{\hat{\theta}=\theta} = \begin{bmatrix} \frac{\partial g(\theta)}{\partial \theta_1} \\ \frac{\partial g(\theta)}{\partial \theta_2} \\ \vdots \\ \frac{\partial g(\theta)}{\partial \theta_p} \end{bmatrix}.$$

¿Por qué? Porque la expansión de Taylor reclamará que, para $g(\theta)$ alrededor de $\hat{\theta} = \theta$:

$$g(\hat{\theta}) = g(\theta) + (\hat{\theta} - \theta)' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta} + (\theta^* - \hat{\theta})' \nabla_{\theta}^2 g(\hat{\theta}) \big|_{\hat{\theta}=\theta} (\theta^* - \hat{\theta}),$$

donde $\theta_j^* \in (\hat{\theta}_j, \theta_j)$, $\forall j$. Notar que, si el estimador $\hat{\theta}$ es consistente, entonces, el término de segundo orden desaparece asintóticamente porque:

$$\hat{\theta}_i \rightarrow \theta_j \Rightarrow \theta_i^* \rightarrow \theta_j, \forall j.$$

Por lo tanto, asintóticamente, se tiene que:

$$\begin{aligned} V[g(\hat{\theta})] &= V[g(\theta) + (\hat{\theta} - \theta)' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] \\ V[g(\hat{\theta})] &= V[g(\theta) + \hat{\theta}' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta} - \theta' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] \\ V[g(\hat{\theta})] &= V[g(\theta)] + V[(\hat{\theta} - \theta)' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] + V[\theta' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] \\ V[g(\hat{\theta})] &= 0 + V[\hat{\theta}' \nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}] + 0 \\ V[g(\hat{\theta})] &= (\nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta})' V(\hat{\theta}) (\nabla_{\theta} g(\hat{\theta}) \big|_{\hat{\theta}=\theta}). \end{aligned}$$

6) Introducción a los Procesos Empíricos.

En la econometría moderna, la convergencia punto a punto es, a veces, demasiado débil para mostrar que el estimador $\hat{\theta}$ es consistente para θ . Se usa un concepto que está relacionado con la convergencia “funcional” o la convergencia uniforme de funciones de criterio. En esta sección, se presentará una introducción a algunos resultados que se utilizan con frecuencia.

6.1) Antecedentes y definiciones.

Considerar $X_1, \dots, X_n$ estando i.i.d. con distribución F definida F_n como una función aleatoria.

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{(-\infty, x)}(X_i),$$

para $X \in \mathbb{R}$. Recordar que, para una x fija, $F_n(x) \rightarrow F(X)$ por LGN y:

$$Z_n(x) = \sqrt{n} [F_n(x) - F(x)] \rightarrow Z \sim \mathcal{N}(0, 1).$$

Los resultados de convergencia uniformes más generales en el proceso empírico son:

Teorema 11 [Glivenko - Cantelli (1993)].

$$\|F_n - F\|_{\infty} = \sup_x |F_n(x) - F(x)| \rightarrow 0.$$

6.1.1) Estimadores M (y Z).

Un método popular para encontrar estimadores es maximizar una función de criterio del tipo:

$$M_n(\theta) = \frac{1}{n} \sum_{i=1}^n m_\theta(X_i).$$

Para funciones conocidas $m_\theta: \mathcal{X} \rightarrow \mathbb{R}$. Por ejemplo, $m_\theta(x_i) = (x - \theta)^2$, $m_\theta(x_i) = |x - \theta|$ o $m_\theta = -\log P_\theta$. Considerar las siguientes definiciones:

$$\theta_0 = \arg \max_{\theta \in \Theta} M(\theta).$$

$$\theta_n = \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n m_\theta(X_i) = \arg \max_{\theta \in \Theta} M_n(\theta).$$

Otra forma de pensar este problema es considerar encontrar la solución de:

$$\psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n m'_\theta(X_i) = \frac{1}{n} \sum_{i=1}^n \psi_\theta(X_i) = 0.$$

La solución de esta ecuación de estimación es $\hat{\theta}$, se llaman estimadores Z. Sin embargo, tener en cuenta que las ecuaciones de estimación pueden no necesitar corresponder a un problema de maximización.

6.2) Consistencia uniforme.

Ahora, se investiga la consistencia para los estimadores M. Siendo $\hat{\theta}_n$ un estimador de θ . Se llama asintóticamente consistente si la secuencia $\hat{\theta}_n$ converge en probabilidad para θ para cada valor posible de θ [por ejemplo, $\bar{X}$ para la población media $E(X)$].

Sea d un espacio métrico que incluya el conjunto de parámetros posibles. Se quiere demostrar que $d(\hat{\theta}_n, \theta_0) \rightarrow 0$.

El punto básico de la cuestión de la convergencia punto a punto versus a funcional es que, aunque:

$$M_n(\theta) \rightarrow M(\theta) \text{ para todo } \theta$$

y

$$\arg \max M_n(\theta) \rightarrow \arg \max M(\theta),$$

no se puede asegurar la convergencia de $\hat{\theta}_n$. Se necesita una convergencia “funcional” de M_n a M , para reforzar la convergencia punto a punto. Se usa, comúnmente, la noción de convergencia uniforme de las funciones de criterio.

Considerar un estimador $\hat{\theta}_n$ que casi maximiza M_n :

$$M_n(\hat{\theta}_n) \geq \sup_{\theta \in \Theta} M_n(\theta) - o_p(1),$$

que, por supuesto, implica que:

$$M_n(\hat{\theta}) \geq M_n(\theta_0) - o_p(1).$$

Teorema 12. Para $\epsilon > 0$,

1. $\sup |M_n(\theta) - M(\theta)| \rightarrow 0$.
2. $\sup_{\theta: d(\theta, \theta_0) \geq \epsilon} M(\theta) < M(\theta_0)$.

Entonces:

$$\hat{\theta}_n \rightarrow \theta_0.$$

Prueba. Considerar que $\hat{\theta}_n$ satisface $M_n(\hat{\theta}_n) \geq M_n(\theta_0) - o_p(1)$. Por la convergencia uniforme de M_n a M por la Suposición 1, se tiene que $M_n(\hat{\theta}_n) \geq M(\theta_0) - o_p(1)$. Entonces:

$$M_n(\hat{\theta}_n) - M(\hat{\theta}_n) \geq M(\theta_0) - M(\hat{\theta}_n) + o_p(1)$$

$$\sup_{\theta} |M_n(\hat{\theta}) - M(\theta)| \geq M(\theta_0) - M(\hat{\theta}_n) + o_p(1).$$

Por lo tanto:

$$M(\theta_0) - M(\hat{\theta}_n) \leq \sup_{\theta} |M_n(\hat{\theta}) - M(\theta)| + o_p(1) \rightarrow 0.$$

Para cada θ , se tiene, por la Suposición 2, que:

$$M(\theta) < M(\theta_0) - \eta.$$

Por lo tanto, el evento $\{d(\hat{\theta}_n, \theta) \geq \epsilon\}$ está contenido en el evento $\{M(\hat{\theta}_n) < M(\theta_0) - \eta\}$. Se puede escribir:

$$P[d(\hat{\theta}_n, \theta) \geq \epsilon] \leq P[M(\hat{\theta}_n) - M(\theta_0) > \eta] \rightarrow 0,$$

cuando $n \rightarrow \infty$.

Observación 7. La convergencia uniforme de $M_n(\theta)$ requerida por la condición estocástica es equivalente al conjunto de funciones $\{m_{\theta}: \theta \in \Theta\}$ siendo Glivenko, Cantelli. Un conjunto simple de condiciones suficientes es Θ compacto, m_{θ} continuo para cada x y la función está dominada por una función integrable.

6.3) Normalidad asintótica.

Sin perder la generalidad, se consideran, ahora, los estimadores Z en lugar de los estimadores M . Siendo una muestra simple $X_1, \dots, X_n$ de una distribución P y dejando que la función del criterio “verdadero” sea de la forma:

$$\psi_n(\theta) = \frac{1}{n} \sum_{i=1}^n \psi_{\theta}(X_i)$$

$$\psi(\theta) = E(\psi_{\theta}).$$

Se supone que $\hat{\theta}_n$ es cero de ψ_n y converge en probabilidad a cero θ_0 en ψ . Se expande $\psi_n(\hat{\theta}_n)$ usando la serie de Taylor alrededor de θ_0 :

$$0 = \psi_n(\hat{\theta}_n) = \psi_n(\theta_0) + (\hat{\theta}_n - \theta_0) \psi'_n(\theta_0) + \frac{1}{2} (\hat{\theta}_n - \theta_0)^2 \psi''_n(\theta_n^*),$$

donde $\theta_n^* \in (\theta_0, \hat{\theta}_n)$. Así:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{-\sqrt{n}\psi_n(\theta_0)}{\psi'_n(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)\psi''_n(\theta_n^*)}. \quad (31)$$

Suponiendo que $V_\psi = E(\psi_{\theta_0}^2)$ es finito y considerando que $E(\psi_{\theta_0}) = 0$:

$$-\sqrt{n}\psi_n(\theta_0) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi_{\theta_0}(X_i) \sim \mathcal{N}(0, V_\psi).$$

Ahora, se considera el denominador de la ecuación (31). El primer término $\psi'_n(\theta_0) \rightarrow E(\psi'_{\theta_0})$ por LLN. El segundo término es:

$$o_p(1) \psi''_n(\theta_n^*) = o_p(1) O_p(1) = o_p(1),$$

porque $\hat{\theta}_n - \theta_0 \rightarrow 0$. Por lo tanto, usando el teorema de Slutsky:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \sim \mathcal{N}(0, [E(\psi'_{\theta_0})]^{-2} V_\psi).$$

Observación 8. Su supone que la función $\theta \rightarrow \psi_\theta(X)$ posee dos derivadas continuas con respecto a θ , para cada X . Esto no siempre es cierto (por ejemplo, la mediana). La condición puede ser reemplazada por una condición de Lipschitz.

Lectura 4:

Prueba de Hipótesis en el Modelo de Regresión Lineal.

Esta lectura introduce pruebas clásicas para el modelo de regresión lineal. Siendo consistente con las lecturas anteriores, se asume que el modelo es:

$$y = X\beta + u, \quad (1)$$

donde la variable de respuesta y es un vector n dimensional, X es una matriz $(n \times p)$, β es un vector p dimensional y u es un término de error n dimensional. Se está interesado en la inferencia sobre el parámetro de interés, β .

Recordar los siguientes supuestos:

- A1: El modelo es lineal y viene dado por la ecuación (1).
- A2: El rango de la matriz es p .
- A3: El valor esperado condicional de y es igual a $E(y_i | X) = x_i' \beta$ para todas las observaciones i en la muestra de tamaño n .
- A4: La varianza condicional de y es igual a $V(y | X) = V(X\beta + u | X) = V(u) = \sigma^2 I$, donde $\sigma^2 > 0$ e I es la matriz identidad.

El supuesto A1 implica que el modelo está, correctamente, especificado y A2 implica que la matriz de proyección $P = X(X'X)^{-1}X'$ existe. Tener en cuenta que esto también implica que el estimador MCO, $\hat{\beta} = (X'X)^{-1}X'y$, existe también. A3 implica que el término de error u y las variables independientes no están correlacionadas:

$$\begin{aligned} E(u_i | X) &= E(y_i - x_i' \beta | X) \\ E(u_i | X) &= E(y_i | X) - E(x_i' \beta | X) \\ E(u_i | X) &= x_i' \beta - x_i' \beta \\ E(u_i | X) &= 0. \end{aligned}$$

Tener en cuenta que esto también implica que $E(u_i) = E[E(u_i | X)] = 0$ y la covarianza entre las variables independientes y el término de error es cero. Por último, A4 implica que el término de error u tiene una variación constante, σ^2 , y u_i y u_j no están correlacionados.

Se agrega una suposición más que se relajará en la Lectura 5:

- A5: La distribución condicional de y es normal con media $X\beta$ y varianza $\sigma^2 I$.

En esta lectura, se va a discutir cómo evaluar diferentes hipótesis sobre los coeficientes en el siguiente modelo de regresión:

$$\begin{aligned} y_i &= x_i' \beta + u_i \\ y_i &= \beta_0 + \sum_{j=1}^p \beta_j x_j + u_i. \end{aligned}$$

Por ejemplo, las hipótesis que se podrían evaluar son:

$$H_0: \beta_1 = 0.$$

$$H_0: \beta_1 = \beta_2.$$

$$H_0: \beta_p + \beta_{p-1} = c.$$

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0.$$

1) Prueba de Hipótesis Lineal.

Una expresión general para hipótesis lineal es de la siguiente forma:

$$H_0: R\beta = \delta.$$

$$H_a: R\beta \neq \delta.$$

donde H_0 es la hipótesis nula, H_a es la hipótesis alternativa, R es una matriz ($r \times p$) conocida con rango r y δ es un vector ($r \times 1$). Aquí, r indica el número de restricciones aplicadas a p parámetros.

Ejemplo 1. Suponer que $\beta = (\beta_1, \beta_2, \beta_3)$ en la ecuación (1). Por lo tanto:

$$r_{11}\beta_1 + r_{12}\beta_2 + r_{13}\beta_3 = \delta_1.$$

$$r_{21}\beta_1 + r_{22}\beta_2 + r_{23}\beta_3 = \delta_2.$$

Se supone que se quiere probar $\beta_1 + \beta_2 = 1$ y $\beta_1 - \beta_3 = 0$. Entonces:

$$R = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & -1 \end{bmatrix}.$$

$$\delta = \begin{bmatrix} \delta_1 \\ \delta_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Notar que el rango de R es 2.

Ejemplo 2. El caso concebible más simple es $r = 1$, luego $R = [1, 1, 0]$, $\delta = 1$ y, luego, se prueba:

$$H_0: \beta_1 + \beta_2 = 1.$$

¿Cómo se puede probar la hipótesis nula anterior? Bajo el supuesto A5, se tiene que:

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(X'X)^{-1}).$$

$$\hat{\beta} - \beta \sim \mathcal{N}(0, \sigma^2(X'X)^{-1}).$$

$$\sigma^{-1} (X'X)^{\frac{1}{2}} (\hat{\beta} - \beta) \sim \mathcal{N}(0, I_p).$$

Se puede mostrar, entonces, que:

$$R\hat{\beta} \sim \mathcal{N}(R\beta, \sigma^2 R(X'X)^{-1} R').$$

Por lo tanto, en el caso de que $r = 1$:

$$\frac{R\hat{\beta} - R\beta}{\sqrt{\sigma^2 R(X'X)^{-1}R'}} \sim \mathcal{N}(0, 1).$$

Bajo la hipótesis nula, es igual a:

$$\frac{R\hat{\beta} - \delta}{\sqrt{\sigma^2 R(X'X)^{-1}R'}} \sim \mathcal{N}(0, 1).$$

Sin embargo, tener en cuenta que este estadístico de prueba es inviable porque σ^2 es desconocido. Se reemplaza σ^2 por $\hat{\sigma}^2$, definido como:

$$\hat{\sigma}^2 = \frac{\hat{u}'\hat{u}}{n-p}.$$

¿Por qué? Tener en cuenta que el estimador $\hat{\sigma}^2$ es un estimador insesgado y consistente para σ^2 . Se escribe, primero, la matriz $P = X(X'X)^{-1}X'$ y $M = I - P$, M es simétrica e idempotente:

$$MM = M^2$$

$$MM = M$$

y

$$MX = [I - X(X'X)^{-1}X']X$$

$$MX = X - X(X'X)^{-1}X'X$$

$$MX = X - XI$$

$$MX = X - X$$

$$MX = 0.$$

Notar que:

$$E(\hat{u}'\hat{u}) = E[(y - X\hat{\beta})'(y - X\hat{\beta})]$$

$$E(\hat{u}'\hat{u}) = E[(y - Py)'(y - Py)]$$

$$E(\hat{u}'\hat{u}) = E\{[(I - P)y]'[(I - P)y]\}$$

$$E(\hat{u}'\hat{u}) = E[(My)'My]$$

$$E(\hat{u}'\hat{u}) = E[(Mu)'Mu]$$

$$E(\hat{u}'\hat{u}) = E(u'M'Mu)$$

$$E(\hat{u}'\hat{u}) = E(u'Mu)$$

$$E(\hat{u}'\hat{u}) = E[\text{tr}(u'Mu)]$$

$$E(\hat{u}'\hat{u}) = \text{tr}[E(u'Mu)]$$

$$E(\hat{u}'\hat{u}) = \text{tr}[E(u'u)M]$$

$$E(\hat{u}'\hat{u}) = \text{tr}(\sigma^2 IM)$$

$$E(\hat{u}'\hat{u}) = \text{tr}(\sigma^2 M)$$

$$E(\hat{u}'\hat{u}) = \sigma^2 \text{tr}(M)$$

$$E(\hat{u}'\hat{u}) = \sigma^2 \text{tr}[I - X(X'X)^{-1}X']$$

$$E(\hat{u}'\hat{u}) = \sigma^2 \{\text{tr}(I) - \text{tr}[X(X'X)^{-1}X']\}$$

$$E(\hat{u}'\hat{u}) = \sigma^2 \{n - \text{tr}[X'X(X'X)^{-1}]\}$$

$$E(\hat{u}'\hat{u}) = \sigma^2 [n - \text{tr}(I_p)]$$

$$E(\hat{u}'\hat{u}) = \sigma^2 (n - p).$$

Por lo tanto, $E\left(\frac{\hat{u}'\hat{u}}{n-p}\right) = \sigma^2$.

También es consistente:

$$\begin{aligned}\hat{\sigma}^2 &= \frac{u'M'Mu}{n-p} \\ \hat{\sigma}^2 &= \frac{u'Mu}{n-p} \\ \hat{\sigma}^2 &= \frac{u'(I-P)u}{n-p} \\ \hat{\sigma}^2 &= \frac{u'u - u'Pu}{n-p} \\ \hat{\sigma}^2 &= \frac{u'u - u'X(X'X)^{-1}X'u}{n-p} \\ \hat{\sigma}^2 &= \frac{u'u}{n-p} - \frac{u'X(X'X)^{-1}X'u}{n-p}.\end{aligned}$$

El primer término, bajo el supuesto A4:

$$\frac{\sum_{i=1}^n u_i^2}{n-p} \rightarrow \sigma^2.$$

El segundo término, bajo el supuesto A3:

$$\frac{\sum_{i=1}^n x_i u_i}{n-p} \rightarrow 0.$$

Se sabe que $\frac{1}{n}(X'X) \rightarrow Q_0$ y, luego, por continuidad de operación inversa, se tiene que:

$$\left[\frac{1}{n}(X'X)\right]^{-1} \rightarrow Q_0^{-1}.$$

Por Slutsky, se tiene que:

$$\begin{aligned}\lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \lim_{n \rightarrow \infty} \left[\frac{u'u}{n-p} - \frac{u'X(X'X)^{-1}X'u}{n-p} \right] \\ \lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \lim_{n \rightarrow \infty} \frac{u'u}{n-p} - \lim_{n \rightarrow \infty} \frac{u'[\frac{1}{n}(X'X)]^{-1}\frac{1}{n}X'u}{n-p} \\ \lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \lim_{n \rightarrow \infty} \frac{\frac{1}{n}u'u}{n-p} - \lim_{n \rightarrow \infty} \frac{u'[\frac{1}{n}(X'X)]^{-1}\frac{1}{n}X'u}{n-p} \\ \lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \lim_{n \rightarrow \infty} \frac{nE(u'u)}{n-p} - \lim_{n \rightarrow \infty} \frac{u'[E(X'X)]^{-1}E(X'u)}{n-p} \\ \lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \lim_{n \rightarrow \infty} \frac{n}{n-p} \sigma^2 - \frac{u'}{n-p} Q_0^{-1} * 0 \\ \lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \sigma^2 - 0 \\ \lim_{n \rightarrow \infty} \hat{\sigma}^2 &= \sigma^2.\end{aligned}$$

La distribución del estadístico de prueba es T-Student con (n - r) grados de libertad. Notar que:

$$\frac{R\hat{\beta} - \delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} = [\hat{\sigma}^2 R(X'X)^{-1}R']^{-\frac{1}{2}} (R\hat{\beta} - \delta)$$

$$\begin{aligned}\frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \left[\frac{\hat{u}'\hat{u}}{n-p} R(X'X)^{-1}R' \right]^{-\frac{1}{2}} (R\hat{\beta} - \delta) \\ \frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \left[\frac{\hat{u}'\hat{u}}{(n-p)\sigma^2} \sigma^2 R(X'X)^{-1}R' \right]^{-\frac{1}{2}} (R\hat{\beta} - \delta) \\ \frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \left[\frac{\hat{u}'\hat{u}}{(n-p)\sigma^2} \right]^{-\frac{1}{2}} [\sigma^2 R(X'X)^{-1}R']^{-\frac{1}{2}} (R\hat{\beta} - \delta) \\ \frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \left[\frac{\hat{u}'\hat{u}}{(n-p)\sigma^2} \right]^{-\frac{1}{2}} \mathcal{N}(0, 1) \\ \frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \frac{\mathcal{N}(0,1)}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}} \\ \frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \frac{\mathcal{N}(0,1)}{\sqrt{\frac{(n-r)\hat{\sigma}^2}{\sigma^2}}} \\ \frac{R\hat{\beta}-\delta}{\sqrt{\hat{\sigma}^2 R(X'X)^{-1}R'}} &= \frac{\mathcal{N}(0,1)}{\sqrt{\frac{\chi^2_{n-r}}{n-r}}},\end{aligned}$$

porque $\hat{\sigma}^2$ y $\hat{\beta}$ son independientes.

Ejemplo 3. Suponer $R = (1, 0, \dots, 0)$ y $\delta = 0$.

$$R\hat{\beta} - \delta = \hat{\beta}_1$$

y $R(X'X)^{-1}R' = (X'X)^{-1}_{11}$. Por lo tanto, se prueba $H_0: \beta_1 = 0$ por:

$$\frac{\hat{\beta}_1}{\sqrt{\hat{\sigma}^2 (X'X)^{-1}_{11}}} = \frac{\hat{\beta}_1}{\hat{\sigma} \sqrt{(X'X)^{-1}_{11}}} = \frac{\hat{\beta}_1}{se(\hat{\beta}_1)} \sim t_{n-1},$$

donde se $(.)$ denota error estándar. La hipótesis nula $H_0: \beta_j = 0$ se puede probar considerando:

$$\frac{\hat{\beta}_j}{se(\hat{\beta}_j)}.$$

Ejemplo 4. Considerar el modelo:

$$wages_i = \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 tenure_i + u_i.$$

Considerar el ejemplo en el libro de Wooldridge:

$$\begin{array}{ccccccc} \log(wage) = & 0,284 & + & 0,092 & educ & + & 0,0041 & exp & + & 0,022 & tenure \\ & (0,104) & & (0,007) & & & (0,0017) & & & (0,003) \end{array}$$

Nos gustaría probar si la experiencia es un factor importante para explicar los salarios. Considerar:

$$H_0: \beta_{exp} = 0; \quad H_a: \beta_{exp} > 0.$$

Nuestro estadístico t es:

$$\hat{t} = \frac{\hat{\beta}_{exp}}{se(\hat{\beta}_{exp})} = \frac{0,0041}{0,0017} = 2,4.$$

Como los grados de libertad son $(n - p - 1) = 526 - 3 - 1 = 522$, se pueden usar los valores críticos normales estándar. Entonces, $\hat{t} = 2,4 > 1,64 = c$, se rechaza la hipótesis nula y se concluye que la experiencia es estadísticamente significativa diferente de cero al 5 por ciento. También se concluye que $2\frac{1}{2}$ años de experiencia aumentarían los salarios en un 1 por ciento.

Alternativamente, se consideran las hipótesis nula y alternativa:

$$H_0: \beta = 0; \quad H_a: \beta \neq 0.$$

En este caso, la teoría económica no ayuda a determinar si el parámetro debe ser positivo o negativo, por lo que la hipótesis alternativa refleja la falta de información. La regla de rechazo es:

$$|t| > c.$$

Tener en cuenta que se está considerando el valor absoluto del estadístico t. Si se rechaza la hipótesis nula, se dice que x es estadísticamente significativo diferente de cero. Si no se puede rechazar la hipótesis nula de que $\beta = 0$, se dice que x no es estadísticamente significativo diferente de cero. Nunca se dice que se acepta la hipótesis nula.

Ejemplo 5. Se supone que se obtiene que la ecuación de demanda de un bien es $Q = \frac{c}{P}$, donde Q es cantidad, P es precio y c es una constante positiva. En este caso, la elasticidad de la demanda es -1. Se puede formular una versión de regresión de la demanda a probar:

$$\log(Q) = \log(c) + \beta \log(P) + u.$$

La hipótesis nula es $H_0: \beta = -1$. Bajo la hipótesis nula, el estadístico t apropiado es:

$$\hat{t} = \frac{\hat{\beta} + 1}{se(\hat{\beta})}.$$

Observación 1 (P-valores). Se define como el nivel de significación más pequeño en el que se rechazaría la hipótesis nula. Por ejemplo, si el estadístico t es $\hat{t} = \frac{0,0039}{0,0022} = 1,77$, se puede calcular el p-valor como:

$$p\text{-valor} = P(T > 1,77)$$

$$p\text{-valor} = 1 - P(T \leq 1,77)$$

$$p\text{-valor} = 1 - 0,9616$$

$$p\text{-valor} = 0,0384.$$

Por lo tanto, se concluye que se rechaza la hipótesis nula en el 10 y en el 5 por ciento, pero no se puede rechazar la hipótesis nula en el nivel de significación del 1 por ciento.

¿Y si se tienen r restricciones independientes? Considerar, primero, los siguientes dos resultados:

- Si $Z \sim \mathcal{N}(M, \Omega)$ y $k = \text{rango}(\Omega)$, entonces:

$$(Z - M)' \Omega^{-1} (Z - M) \sim \chi_k^2.$$

- Si χ_1^2 tiene $(n - 1)$ grados de libertad y χ_2^2 tiene $(n - 2)$ grados de libertad, entonces:

$$\frac{\frac{\chi_1^2}{n_1}}{\frac{\chi_2^2}{n_2}} \sim F_{n_1, n_2}.$$

Por resultado 1, ya que $R\hat{\beta} \sim \mathcal{N}(R\beta, \sigma^2 R(X'X)^{-1}R')$, se tiene que:

$$(R\hat{\beta} - \delta)' \sigma^{-2} [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - \delta) \sim \chi_r^2.$$

La versión factible del estadístico de prueba incluye $\hat{\sigma}^2$ y, por lo tanto, puede escribirse como:

$$\begin{aligned} (R\hat{\beta} - \delta)' \frac{1}{\hat{\sigma}^2} [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - \delta) &\sim F_{r, n-p} \\ \frac{(R\hat{\beta} - \delta)' \frac{1}{\hat{\sigma}^2} [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - \delta)}{r} &\sim F_{r, n-p} \\ \frac{(R\hat{\beta} - \delta)' \frac{1}{\hat{\sigma}^2} [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - \delta)}{\frac{r}{\frac{u'Mu}{\hat{\sigma}^2}}} &\sim F_{r, n-p} \\ \frac{(R\hat{\beta} - \delta)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - \delta)}{r\hat{\sigma}^2} &\sim F_{r, n-p} \end{aligned}$$

El estadístico de prueba es:

$$F = \frac{(R\hat{\beta} - \delta)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - \delta)}{r\hat{\sigma}^2}. \quad (2)$$

Ejemplo 6. Considerar que se quiere imponer q restricciones, por ejemplo $\beta_1 = \beta_2 = \dots = \beta_q = 0$. En otras palabras, se quiere evaluar si el grupo de variables $x_1, x_2, \dots, x_q$ no tiene ningún efecto significativo en la variable dependiente. Nuestra hipótesis nula será:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_q; \quad H_a: \text{al menos, un } \beta_j \neq 0,$$

lo que sugiere que, bajo la hipótesis nula, el verdadero modelo es:

$$y = \beta_0 + \beta_{q+1}x_{q+1} + \dots + \beta_p x_p + u, \quad (3)$$

en lugar del modelo:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q + \dots + \beta_p x_p + u. \quad (4)$$

El primer modelo es el modelo restringido porque se está imponiendo q restricciones. El segundo modelo es el modelo no restringido, ya que no se está imponiendo una restricción. Para evaluar la hipótesis nula, se utiliza la prueba F, que se define como:

$$F \equiv \frac{\frac{SSR_r - SSR_u}{q}}{\frac{SSR_u}{n-p-1}},$$

donde SSR_r es la suma de los residuos al cuadrado del modelo restringido y SSR_u es la suma de los residuos al cuadrado del modelo sin restricciones. El estadístico F y el R^2 de una regresión tienen una relación estrecha, ya que ambos estadísticos dependen de la suma de los residuos al cuadrado. La derivación de la relación exacta se deja como ejercicio.

$$F = \frac{\frac{(1-R_r^2) - (1-R_u^2)}{q}}{\frac{1-R_u^2}{n-p-1}}$$

$$F = \frac{\frac{1-R_r^2 - 1 + R_u^2}{q}}{\frac{1-R_u^2}{n-p-1}}$$

$$F = \frac{\frac{R_u^2 - R_r^2}{q}}{\frac{1-R_u^2}{n-p-1}}$$

Ejemplo 7. Es útil evaluar si el grupo de variables $x_1, x_2, \dots, x_q$ no tiene efecto en la variable dependiente, que es, básicamente, una evaluación del modelo de regresión. Éste es el caso donde ninguna de las variables explicativas tiene un efecto significativo en la variable dependiente:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0; \quad H_a: \text{al menos, un } \beta_j \neq 0.$$

Cuando se rechaza la hipótesis nula utilizando una prueba F, se dice que el grupo de variables es estadísticamente significativo en el nivel de significación apropiado.

2) Realización de Pruebas bajo Supuestos no Gaussianos.

Los estadísticos t y F clásicos se pueden usar en condiciones no normales. Sin embargo, como quedará claro en los casos a continuación, una condición necesaria es que la muestra debe ser, razonablemente, grande. Otro cambio importante está asociado con los valores críticos. En lugar de observar la distribución t y la distribución F para los valores críticos, se considera la distribución normal estándar para la prueba t y la distribución chi-cuadrado para la prueba F.

Se supone que se está interesado en la j_{th} covarianza en una regresión multivariada. Nos interesa la hipótesis $\beta_j = 0$ es:

$$t = \frac{\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 (X'X)^{-1}_{jj}}}$$

$$t = \frac{\sqrt{n}\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 n(X'X)^{-1}_{jj}}},$$

donde $(X'X)^{-1}_{jj}$ denota el $(j, j)_{th}$ elemento de la matriz $(X'X)^{-1}$. Bajo la hipótesis nula que $\beta_{0j} = 0$, se tiene:

$$\sqrt{n}\hat{\beta}_j \rightarrow \mathcal{N}(0, \sigma_0^2 Q_{0jj}^{-1}),$$

donde Q_0 es la forma limitante de la $X'X$. Entonces, como $\hat{\sigma}^2$ es un estimador consistente para el parámetro σ_0^2 y $\frac{X'X}{n}$ es un estimador consistente para la matriz Q_0 desconocida, se puede aplicar el teorema de Slutsky y obtener:

$$t = \frac{\sqrt{n}\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 n(X'X)^{-1}_{jj}}} \rightarrow \mathcal{N}(0, 1).$$

El argumento para la prueba F es similar. Bajo la hipótesis nula $R\beta_0 = r$, se tiene que:

$$\begin{aligned} \sqrt{n}(R\hat{\beta} - r) &= \sqrt{n}(R\hat{\beta} - R\beta_0) \\ \sqrt{n}(R\hat{\beta} - r) &= \sqrt{n}R(\hat{\beta} - \beta_0) \rightarrow \mathcal{N}(0, \sigma_0^2 RQ_0^{-1}R'). \end{aligned}$$

Lectura 5: **Heterocedasticidad y Errores Estándar Agrupados.**

Recordar que, en un modelo de regresión:

$$y = x'\beta + u,$$

se asume que $E(u | x) = 0$ y $\text{Var}(u | x) = \sigma^2$. La heterocedasticidad se produce cuando $\text{Var}(u_i | x) = \sigma_i^2$.

Si se usa un estimador para $V(\hat{\beta})$ en el caso homocedasticidad, se obtiene una estimación sesgada de la varianza verdadera. Luego, las inferencias clásicas, incluidas las pruebas t y F, se invalidan, ya que utilizan estimaciones de la varianza del estimador.

1) Mínimos Cuadrados Generalizados.

Suponer que $E(uu') = \Omega \neq \sigma^2 I_n$ y Ω es desconocido. Considerar una descomposición de la matriz $\Omega^{-1} = CC' = P\Lambda^{-1}P$, donde P es una matriz ortogonal y Λ es una matriz diagonal que incluye las raíces características de Ω . Resulta que se puede escribir:

$$E(uu') = \Omega$$

$$E(uu') = (C')^{-1}C^{-1}.$$

Entonces, se puede transformar la regresión como:

$$C'y = C'X\beta + C'u$$

$$\tilde{y} = \tilde{X}\beta + \tilde{u}.$$

El término de error vector $\tilde{u}$ tiene media cero y varianza I [por ejemplo, $\tilde{u} \sim N(0, I)$] porque la transformación logra:

$$V(\tilde{u}) = V(C'u)$$

$$V(\tilde{u}) = C'V(u)C$$

$$V(\tilde{u}) = C'(C')^{-1}C^{-1}C$$

$$V(\tilde{u}) = I$$

$$V(\tilde{u}) = I.$$

Por lo tanto, el estimador de mínimos cuadrados generalizados es:

$$\hat{\beta} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y},$$

o, equivalentemente:

$$\hat{\beta} = \arg \min \|y - X\beta\|_{\Omega^{-1}}^2.$$

El estimador MCG es insesgado, con varianza condicional igual a:

$$V(\hat{\beta}) = V[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}]$$

$$\begin{aligned}
 V(\hat{\beta}) &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}' V(\tilde{y}) \tilde{X}(\tilde{X}'\tilde{X})^{-1} \\
 V(\hat{\beta}) &= (X'CC'X)^{-1}X'C V(C'y) C'X(X'CC'X)^{-1} \\
 V(\hat{\beta}) &= (X'CC'X)^{-1}X'CC' V(y) CC'X(X'CC'X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1} V(u) \Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}\Omega\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}IX(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1}I \\
 V(\hat{\beta}) &= (X'\Omega^{-1}X)^{-1},
 \end{aligned}$$

que es más pequeña que la matriz de varianza-covarianza del estimador MCO en un modelo de errores no esféricos.

Teorema 1. $V(\hat{\beta}_{MCO}) - V(\hat{\beta}_{MCG})$ es una matriz semidefinida positiva.

Prueba. Por simplicidad, C es simétrica. En primer lugar, tener en cuenta que la varianza condicional del MCO es igual a:

$$\begin{aligned}
 V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'y] \\
 V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'(X\beta + u)] \\
 V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= V[I\beta + (X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= V[\beta + (X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= V(\beta) + V[(X'X)^{-1}X'u] \\
 V(\hat{\beta}_{MCO}) &= 0 + (X'X)^{-1}X' V(u) X(X'X)^{-1} \\
 V(\hat{\beta}_{MCO}) &= (X'X)^{-1}X'\Omega X(X'X)^{-1}.
 \end{aligned}$$

Considerar la descomposición:

$$\begin{aligned}
 X'\Omega^{-1}X &= X'CC'X = W'W. \\
 X'\Omega X &= X'(C')^{-1}C^{-1}X = S'S. \\
 X'X &= X'\Omega^{-1}\Omega X = X'CC'(C')^{-1}C^{-1}X = X'CC^{-1}X = W'S.
 \end{aligned}$$

Entonces, se tiene que:

$$\begin{aligned}
 (X'X)(X'\Omega X)^{-1}(X'X) &= W'S(S'S)^{-1}S'W \\
 (X'X)(X'\Omega X)^{-1}(X'X) &= W'P_S W \leq W'W.
 \end{aligned}$$

El estimador MCG es el estimador de mínimos cuadrados ponderados (MCP) cuando sólo se tiene heterocedasticidad:

$$\begin{aligned}
 C^{-1} &= \Omega^{\frac{1}{2}} \\
 C^{-1} &= \text{diag}(\sigma_i).
 \end{aligned}$$

Por lo tanto, se puede reponderar por $\Omega^{\frac{-1}{2}}$ en lugar de C .

1.1) Estimación.

El estimador MCG es inviable, lo que significa que no se puede implementar en la práctica. La matriz Ω es, típicamente, desconocida, por lo que nos gustaría implementar un método para estimarla. Se puede considerar, en su lugar, $\Omega(\gamma)$ y, después de establecer una relación entre la varianza condicional y el parámetro γ , se puede implementar el método.

Considerar, por simplicidad:

$$y_i = x_i\beta + (z_i'\gamma)^{-\frac{1}{2}}u_i,$$

lo que implica que el elemento i_{th} en la diagonal de Ω es $\Omega_{ii} = (z_i'\gamma)$. Tener en cuenta que, si se estima γ , se puede estimar Ω . Un simple procedimiento de estimación considera:

1. Obtener el estimador MCO ejecutando:

$$(y_i - x_i\hat{\beta})^2 = z_i'\gamma + v_i.$$

2. Colocar $\hat{\gamma}$ en Ω y obtener:

$$\begin{aligned}\hat{\beta} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} \\ \hat{\beta} &= (X'CC'X)^{-1}X'CC'y \\ \hat{\beta} &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y \\ \hat{\beta} &= (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y.\end{aligned}$$

En la literatura, existen otros primeros pasos convenientes para los modelos multiplicativos, cuadráticos, etc. de heterocedasticidad. Por ejemplo, podría suponerse que la varianza condicional de u es $e^{\gamma x}$.

Para completar, se revisan las consecuencias de ignorar la heterocedasticidad:

- El estimador MCO es insesgado, pero no eficiente.
- La estimación de la varianza del estimador MCO es un estimador sesgado de la varianza verdadera. Los procedimientos de prueba clásicos están invalidados.

2) Mínimos Cuadrados Ponderados: Un ejemplo simple.

Considerar el modelo de regresión simple sin intercepción:

$$y_i = \beta'x_i + u_i, \tag{1}$$

donde la varianza condicional es:

$$V(u_i | x_i) = \sigma_i^2.$$

Por simplicidad, se asume que:

$$V(u_i | x_i) = \sigma_i^2 = \sigma^2 x_i.$$

Se utiliza el modelo simple presentado anteriormente para ilustrar los efectos de la heterocedasticidad. El estimador MCO de β es:

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}.$$

La varianza del estimador MCO es, en este caso:

$$V(\hat{\beta}) = \frac{\sum_{i=1}^n x_i^2 \sigma_i^2}{(\sum_{i=1}^n x_i^2)^2}.$$

Ahora, se considera un estimador que pondera cada observación por $\frac{1}{\sqrt{x_i}}$:

$$\frac{y_i}{\sqrt{x_i}} = \beta' \frac{x_i}{\sqrt{x_i}} + \frac{u_i}{\sqrt{x_i}} \Rightarrow y_i^* = \beta' x_i^* + u_i^*, \quad (2)$$

porque $V(\frac{u_i}{\sqrt{x_i}} | x_i) = x_i^{-1} V(u_i | x_i) = x_i^{-1} \sigma^2 x_i = \sigma^2$. Consecuentemente, el estimador del parámetro de la pendiente es:

$$\tilde{\beta} = \frac{\sum_{i=1}^n x_i^* y_i^*}{\sum_{i=1}^n (x_i^*)^2}$$

y la varianza de $\tilde{\beta}$ es:

$$\begin{aligned} \text{Var}(\tilde{\beta}) &= \text{Var}\left[\frac{\sum_{i=1}^n x_i^* y_i^*}{\sum_{i=1}^n (x_i^*)^2}\right] \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \text{Var}(\sum_{i=1}^n x_i^* y_i^*) \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sum_{i=1}^n \text{Var}(x_i^* y_i^*) \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sum_{i=1}^n (x_i^*)^2 \text{Var}(y_i^*) \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sum_{i=1}^n (x_i^*)^2 \sigma^2 \\ \text{Var}(\tilde{\beta}) &= \frac{1}{[\sum_{i=1}^n (x_i^*)^2]^2} \sigma^2 \sum_{i=1}^n (x_i^*)^2 \\ \text{Var}(\tilde{\beta}) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i^*)^2} \\ \text{Var}(\tilde{\beta}) &= \frac{\sigma^2}{\sum_{i=1}^n (\frac{x_i}{\sqrt{x_i}})^2}. \end{aligned}$$

Ahora, se puede comparar la varianza de los dos estimadores para ver si, bajo heterocedasticidad, el estimador MCO es MELI (ya que no está sesgado, sólo se tiene que verificar si es la varianza mínima). Tomando la relación de los dos estimadores:

$$\begin{aligned} \frac{\text{Var}(\hat{\beta})}{\text{Var}(\tilde{\beta})} &= \frac{\frac{\sum_{i=1}^n x_i^2 \sigma_i^2}{(\sum_{i=1}^n x_i^2)^2}}{\frac{\sigma^2}{\sum_{i=1}^n (\frac{x_i}{\sqrt{x_i}})^2}} \\ \frac{\text{Var}(\hat{\beta})}{\text{Var}(\tilde{\beta})} &= \frac{\sum_{i=1}^n x_i^2 \sigma_i^2 \sum_{i=1}^n (\frac{x_i}{\sqrt{x_i}})^2}{\sigma^2 (\sum_{i=1}^n x_i^2)^2} \end{aligned}$$

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sum_{i=1}^n x_i^2 x_i \sigma^2 \sum_{i=1}^n x_i}{\sigma^2 (\sum_{i=1}^n x_i^2)^2}$$

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sigma^2 \sum_{i=1}^n x_i^3 \sum_{i=1}^n x_i}{\sigma^2 (\sum_{i=1}^n x_i^2)^2}$$

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} = \frac{\sum_{i=1}^n x_i^3 \sum_{i=1}^n x_i}{(\sum_{i=1}^n x_i^2)^2}.$$

Recordar que el coeficiente de correlación al cuadrado entre a y b es:

$$r^2 = \frac{(\sum ab)^2}{\sum a^2 \sum b^2} \leq 1 \Rightarrow (\sum ab)^2 \leq \sum a^2 \sum b^2.$$

La última expresión es una versión de la desigualdad de Cauchy-Schwarz. Tener en cuenta que, en nuestro caso, $a^2 = x^3$ y $b^2 = x$. Entonces:

$$\frac{\text{Var}(\hat{\beta})}{\text{Var}(\hat{\beta})} \geq 1,$$

lo que implica que el estimador MCO es ineficiente bajo heteroscedasticidad.

3) Prueba de Heterocedasticidad.

Se comienza asumiendo un modelo de regresión multivariable:

$$y_i = x_i' \beta + u_i.$$

Se supone que la hipótesis nula es:

$$H_0: V(u | x) = \sigma^2,$$

es decir, nuestra hipótesis nula es no heteroscedasticidad. Como $E(u | x) = 0$, se escribe H_0 como:

$$H_0: E(u^2 | x) = E(u^2) = \sigma^2.$$

Tener en cuenta que se debe evaluar la esperanza condicional (en las variables independientes) del cuadrado del término de error:

$$u^2 = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_p x_p + \varepsilon.$$

El caso homocedástico implica que $\alpha_1 = \alpha_2 = \dots = \alpha_p = 0$, por lo tanto:

$$E(u^2 | x_1, \dots, x_p) = \alpha_0.$$

Sin embargo, tener en cuenta que esto es inviable porque no se conoce el término de error u^2 . Un enfoque simple es reemplazarlo por $\hat{u}^2$ y estimar:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \dots + \alpha_p x_{pi} + \varepsilon,$$

y probar si los coeficientes de pendiente son todos iguales a cero:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_p = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

utilizando una prueba de F. Si $F > c$, donde c está determinada por un valor de significancia estadística, se rechaza la hipótesis nula de no heterocedasticidad.

La versión del multiplicador de Lagrange (LM) es muy fácil de calcular, ya que:

$$LM = nR_{\hat{u}}^2,$$

que se distribuye como χ_p^2 bajo la hipótesis nula de homocedasticidad. Ésta es la prueba de Breusch-Pagan (1980) para la heterocedasticidad.

Una variación de la prueba fue desarrollada por White (1980). Para simplificar la presentación, suponer que $p = 2$:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i.$$

La prueba de White se basa en la estimación de:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_3 x_{1i}^2 + \alpha_4 x_{2i}^2 + \alpha_5 x_{1i} x_{2i} + \varepsilon_i.$$

La hipótesis nula, en este caso, es:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_5 = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

el cual puede ser evaluado con un estadístico de prueba LM o F.

4) Una Matriz Robusta a Heterocedasticidad.

La matriz de covarianza del término de error, bajo heterocedasticidad, es igual a:

$$\Sigma = E(uu') = E(uu' | x) = E[\text{diag}(u_1^2, u_2^2, \dots, u_n^2) | x]$$

o, alternativamente:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix}.$$

Por lo tanto, bajo heteroscedasticidad, la varianza del estimador es:

$$\begin{aligned} V(\hat{\beta} | X) &= V[(X'X)^{-1}X'y | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'(X\beta + u) | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[I\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + V[(X'X)^{-1}X'u | X] \end{aligned}$$

$$V(\hat{\beta} | X) = V(\beta | X) + (X'X)^{-1}X' V(u | X) X(X'X)^{-1}$$

$$V(\hat{\beta} | X) = 0 + (X'X)^{-1}X' \Sigma X(X'X)^{-1}$$

$$V(\hat{\beta} | X) = (X'X)^{-1}X' \Sigma X(X'X)^{-1}.$$

Si se conoce el término de error, se nota que $(uu')_{ii}^2 = u_{ii}^2$ y el valor esperado condicional de la varianza es:

$$E[V(\hat{\beta} | X)] = E[(X'X)^{-1}X' \Sigma X(X'X)^{-1}]$$

$$E[V(\hat{\beta} | X)] = (X'X)^{-1}X' E(\Sigma) X(X'X)^{-1}$$

$$E[V(\hat{\beta} | X)] = (X'X)^{-1}X' \Sigma X(X'X)^{-1}.$$

En la práctica, se obtienen los residuos mínimos cuadrados, $\hat{u}_i^2 = (y_i - x_i'\hat{\beta})^2$, donde $\hat{\beta}$ es el estimador mínimo cuadrático de β . Entonces, se puede formar una matriz:

$$\hat{\Sigma} = \begin{bmatrix} \hat{u}_1^2 & 0 & \dots & 0 \\ 0 & \hat{u}_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{u}_n^2 \end{bmatrix}$$

y construir un estimador factible:

$$\hat{V}(\hat{\beta} | X) = (X'X)^{-1}X'\hat{\Sigma}X(X'X)^{-1}.$$

Este estimador se denomina estimador de “heterocedasticidad-robusto” de la matriz de covarianza. Fue introducido en la literatura de econometría en un artículo influyente de White (1980). Existen otras alternativas implementadas, normalmente, en paquetes estadísticos para $\hat{u}^2$ (por ejemplo, Andrews 1991). Para simplificar esto, si $p = 1$, White (1980) sugiere obtener el error estándar del estimador MCO:

$$\widehat{se}(\hat{\beta}_1) = \left\{ \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2 \right]^2} \right\}^{\frac{1}{2}}.$$

Notar que el estimador representa un estimador consistente de la covarianza desconocida. En muestras pequeñas, desafortunadamente, el estimador podría estar sesgado. Para ver esto, recordar que $\hat{u}'\hat{u} = u'Mu = y'My$. Entonces:

$$\hat{u}_i^2 = (y_i - x_i'\hat{\beta})^2$$

$$\hat{u}_i^2 = (y_i - x_i'\beta + x_i'\beta - x_i'\hat{\beta})^2$$

$$\hat{u}_i^2 = [(y_i - x_i'\beta) - x_i'(\hat{\beta} - \beta)]^2$$

$$\hat{u}_i^2 = [u_i + x_i'(X'X)^{-1}X'u]^2$$

$$\hat{u}_i^2 = u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i.$$

Bajo homocedasticidad y denotando el llamado punto de apalancamiento $h_{ii} = x_i'(X'X)^{-1}x_i$, se tiene que:

$$E(\hat{u}_i^2) = E[u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i]$$

$$E(\hat{u}_i^2) = E(u_i^2) - E[2u_i x_i'(X'X)^{-1}X'u] + E[x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i]$$

$$E(\hat{u}_i^2) = \sigma^2 - 2 E[u_i x_i'(X'X)^{-1}x_i u_i] + x_i'(X'X)^{-1}X' E(uu') X(X'X)^{-1}x_i$$

$$\begin{aligned}
E(\hat{u}_i^2) &= \sigma^2 - 2 E(u_i h_{ii} u_i) + x_i' (X'X)^{-1} X' \sigma^2 X (X'X)^{-1} x_i \\
E(\hat{u}_i^2) &= \sigma^2 - 2 h_{ii} E(u_i u_i) + \sigma^2 x_i' (X'X)^{-1} X' X (X'X)^{-1} x_i \\
E(\hat{u}_i^2) &= \sigma^2 - 2 h_{ii} E(u_i^2) + \sigma^2 x_i' I (X'X)^{-1} x_i \\
E(\hat{u}_i^2) &= \sigma^2 - 2 h_{ii} \sigma^2 + \sigma^2 x_i' (X'X)^{-1} x_i \\
E(\hat{u}_i^2) &= \sigma^2 - 2 \sigma^2 h_{ii} + \sigma^2 h_{ii} \\
E(\hat{u}_i^2) &= \sigma^2 - \sigma^2 h_{ii} \\
E(\hat{u}_i^2) &= \sigma^2 (1 - h_{ii}) < \sigma^2 = E(u_i^2).
\end{aligned}$$

Luego, insistiendo con el ejemplo simple cuando $p = 1$, se tiene que:

$$\begin{aligned}
E[\hat{V}(\hat{\beta} | X)] &= E\left\{ \frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \right\} \\
E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} E\left[\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2\right] \\
E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n E[(x_i - \bar{x})^2 \hat{u}_i^2] \\
E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 E(\hat{u}_i^2) \\
E[\hat{V}(\hat{\beta} | X)] &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 (1 - h_{ii}) \\
E[\hat{V}(\hat{\beta} | X)] &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} - \frac{\sum_{i=1}^n (x_i - \bar{x})^2 h_{ii} \sigma^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2},
\end{aligned}$$

lo que indica que $\hat{V}(\hat{\beta} | X)$ está sesgada hacia abajo (tener en cuenta que el primer término es la varianza del estimador de mínimos cuadrados bajo homocedasticidad). Una corrección estándar es dividir $\hat{u}_i^2$ por $(1 - h_{ii})$.

5) Estimación Consistente de S.

Definir:

$$\hat{S} = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i x_i',$$

donde $\hat{u} = y - x_i \hat{\beta}$ y $\hat{\beta}$ es un estimador consistente de β .

Para mostrar la consistencia de $\hat{S}$ para $S = E(u_i^2 x_i x_i')$, se necesita una condición en el cuarto momento de x_i como se indicó, anteriormente, en el supuesto A5.

Teorema 2 (Consistencia de $\hat{S}$). Se supone que S existe y es finito y $\hat{\beta}$ es un estimador consistente para β . Entonces, $\hat{S} \rightarrow S$.

La prueba formal se discutirá más adelante, pero me gustaría proporcionar una breve ilustración considerando $p = 1$. Por definición:

$$\begin{aligned}
\hat{u}_i^2 &= (y_i - x_i \hat{\beta})^2 \\
\hat{u}_i^2 &= (y_i - x_i \beta + x_i \beta - x_i \hat{\beta})^2 \\
\hat{u}_i^2 &= [u_i + x_i (\hat{\beta} - \beta)]^2 \\
\hat{u}_i^2 &= u_i^2 - 2u_i x_i (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^2,
\end{aligned}$$

y, por lo tanto:

$$\hat{u}_i^2 - u_i^2 = -2u_i x_i (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^2.$$

Resulta que:

$$\begin{aligned}\hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i^2 - \frac{1}{n} \sum_{i=1}^n u_i^2 x_i^2 \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n (\hat{u}_i^2 - u_i^2) x_i^2 \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n [-2u_i x_i (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^2] x_i^2 \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n [-2u_i x_i^3 (\hat{\beta} - \beta) + (\hat{\beta} - \beta)^2 x_i^4] \\ \hat{S}_n - S_n &= \frac{1}{n} \sum_{i=1}^n -2u_i x_i^3 (\hat{\beta} - \beta) + \frac{1}{n} \sum_{i=1}^n (\hat{\beta} - \beta)^2 x_i^4 \\ \hat{S}_n - S_n &= -2(\hat{\beta} - \beta) \frac{1}{n} \sum_{i=1}^n u_i x_i^3 + (\hat{\beta} - \beta)^2 \frac{1}{n} \sum_{i=1}^n x_i^4.\end{aligned}$$

Por lo tanto, bajo los supuestos existentes:

$$\hat{S}_n = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 x_i^2 \rightarrow E(u_i^2 x_i^2) = S.$$

porque los momentos están limitados y el estimador $\hat{\beta}$ es consistente para β bajo los supuestos A1-A5.

6) Errores Estándar Agrupados.

Esta sección presenta algunas ideas sobre la estimación de errores estándar en presencia de efectos de “grupo”. La mayoría de las correcciones que se encontrarán a continuación están disponibles en paquetes estadísticos, pero pensé que podría ser una buena idea tener una lectura que discuta los temas, potencialmente, específicos de la investigación empírica.

Se supone que se tiene:

$$y_i = x_i' \beta + u_i, \quad (3)$$

y se usa MCO para estimar el parámetro desconocido β . Se sabe que, si $\text{Var}(u_i) = \sigma^2$:

$$\hat{\beta} = (X'X)^{-1} X'y. \quad (4)$$

$$\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1}. \quad (5)$$

Si $\text{Var}(u_i) = \sigma_i^2$, se tiene que:

$$\text{Var}(\hat{\beta}) = (X'X)^{-1} X' \Omega X (X'X)^{-1}, \quad (6)$$

donde $\Omega = E(uu')$. En términos de estimación, se sabe que los parámetros desconocidos pueden estimarse por:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{u}_i^2 \quad (7)$$

$$\hat{\Omega} = \text{diag}(\hat{u}_i^2), \quad (8)$$

donde $\hat{u}_i = y_i - x_i \hat{\beta}$ es un residuo. Tener en cuenta que $\hat{\Omega} \rightarrow \Omega$ si $\hat{\beta} \rightarrow \beta$. Por lo tanto, los errores estándar robustos se basan en una aproximación asintótica y pueden estar sesgados en muestras pequeñas.

Se supone, ahora, que se tiene $\{(y_i, x_i)\}_{i=1}^n$, pero se sabe que el modelo puede variar según los grupos $c = 1, \dots, C$:

$$y_{ic} = x'_{ic} \beta_c + u_{ic}. \quad (9)$$

Aunque es razonable pensar que $\text{Cov}(u_{ic}, u_{jc}) = 0$, puede darse el caso de que:

$$\text{Cov}(u_{ic}, u_{jc}) \neq 0. \quad (10)$$

Se comienza suponiendo que el término de error u_{ic} no es independiente de x_{ic} . Por ejemplo, si $u_{ic} = \alpha_c + v_{ic}$, entonces, $\text{Cov}(x_{ic}, \alpha_c) \neq 0$. En este caso, los grupos introducen sesgos si el modelo no condiciona en α_c . Por lo tanto, uno podría estar interesado en estimar:

$$E(y_{ic} | X_{ic}, \alpha_c) = x'_{ic} \beta_c + \alpha_c \quad (11)$$

cuando el número de grupos es grande. El modelo puede ser estimado por transformaciones clásicas de mínimos cuadrados.

En el caso de efectos aleatorios, se puede considerar apilar observaciones dentro de grupos:

$$y_c = X_c \beta_c + \alpha_c, \quad (12)$$

donde y_c es un vector de dimensión $(n_c \times 1)$ y X_c es una matriz de $(n_c \times p)$. Escribir $n = \sum_c n_c$. Entonces:

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1} X'y \\ \hat{\beta} &= (\sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic} x'_{ic})^{-1} \sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic} y_{ic}. \end{aligned} \quad (13)$$

Observar que $\text{Var}(\hat{\beta}) \neq \sigma^2 (X'X)^{-1}$. El error estándar robusto agrupado es:

$$\begin{aligned} \hat{V}(\hat{\beta}) &= (X'X)^{-1} X' \hat{\Omega} X (X'X)^{-1} \\ \hat{V}(\hat{\beta}) &= (\sum_{c=1}^C X'_c X_c)^{-1} \sum_{c=1}^C X'_c \hat{u}_c \hat{u}'_c X_c (\sum_{c=1}^C X'_c X_c)^{-1}, \end{aligned} \quad (14)$$

donde los residuos son $\hat{u}_c = y_c - X_c \hat{\beta}$. El problema con esta corrección es que se necesita $C \rightarrow \infty$ para consistencia.

Si se asume que $u_{ic} = \alpha_c + v_{ic}$, se puede adoptar el marco de efectos aleatorios asumiendo que α y v son independientes. Darse cuenta de:

$$\begin{aligned} E(u_{ic}u_{jc}) &= E[(\alpha_c + v_{ic})(\alpha_c + v_{jc})] \\ E(u_{ic}u_{jc}) &= E(\alpha_c^2 + \alpha_c v_{jc} + v_{ic}\alpha_c + v_{ic}v_{jc}) \end{aligned} \quad (15)$$

y, luego, si $i = j$:

$$\begin{aligned} E(u_{ic}u_{jc}) &= \sigma_\alpha^2 + \sigma_v^2 \\ E(u_{ic}u_{jc}) &= \sigma^2, \end{aligned} \quad (16)$$

y, si $i \neq j$:

$$\begin{aligned} E(u_{ic}u_{jc}) &= \sigma_\alpha^2 \\ E(u_{ic}u_{jc}) &= \rho\sigma^2, \end{aligned} \quad (17)$$

donde $\rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_v^2}$. Por resultados similares al estimador Balesta-Nerlove, se tiene que:

$$\begin{aligned} \Sigma_c &= E(u_c u_c') \\ \Sigma_c &= \sigma^2 [(1 - \rho) I_c + \rho 1_c 1_c']. \end{aligned} \quad (18)$$

Luego, se sigue que la varianza de $\hat{\beta}$ es:

$$\begin{aligned} V(\hat{\beta}) &= (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C X_c' \sigma^2 [(1 - \rho) I_c + \rho 1_c 1_c'] X_c (\sum_{c=1}^C X_c' X_c)^{-1} \\ V(\hat{\beta}) &= (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C \sigma^2 X_c' [(1 - \rho) I_c + \rho 1_c 1_c'] X_c (\sum_{c=1}^C X_c' X_c)^{-1}. \end{aligned} \quad (19)$$

Un caso útil para arreglar ideas es un modelo con variables invariantes individuales. Se supone, ahora, que el modelo es:

$$y_{ig} = \beta_0 + \beta_1 x_{ig} + u_{ig}, \quad (20)$$

Es posible demostrar que:

$$V(\hat{\beta}_1) = [1 + (M - 1) \rho] V(\tilde{\beta}_1), \quad (21)$$

donde $V(\tilde{\beta}_1)$ es la varianza del estimador estándar MCO. Tener en cuenta que el sesgo del MCO podría ser servido.

Es posible probar los efectos de los grupos después de Moulton (1997). La hipótesis nula es:

$$H_0: \rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_v^2} = 0. \quad (22)$$

$$H_a: \rho > 0. \quad (23)$$

Una prueba LM de un lado se puede formular de la siguiente manera:

$$LM = \frac{\sum_c (N_c \bar{u}_c)^2 - \sum_c \sum_i \hat{u}_{ic}^2}{\hat{\sigma}^2 [2 \sum_c (N_c^2 - N)]^{\frac{1}{2}}}, \quad (24)$$

donde $\hat{\sigma}^2 = \frac{\sum_c \sum_i \hat{u}_{ic}^2}{N}$, $\hat{u}_{ic}$ el residuo de mínimos cuadrados y $\bar{u}_c$ es el residuo promedio para el grupo C.

Ejemplo 1. Moulton (1986) considera regresiones salariales con datos de CPS. El número de individuos en la muestra fue $n \approx 18.000$ en $c = 49$ estados. Aunque la estimación del coeficiente de correlación intraclase $\hat{\rho}$ fue de 0,03, el sesgo fue grande porque los grupos eran grandes ($M \approx 380$). El factor de Moulton, que es $[1 + (M - 1)\rho]^{\frac{1}{2}}$, fue de 3,7, lo que lleva a sesgos considerables en los errores estándar.

Lectura 6: **Modelos con Regresores Endógenos.**

1) Esencial.

Se supone que el verdadero modelo es:

$$y = X\beta + u. \quad (1)$$

Si $E(u | X) = 0$, se puede mostrar que el estimador MCO:

$$\hat{\beta} = \beta + (X'X)^{-1}X'u$$

es insesgado y consistente. La consistencia puede mostrarse demostrando que el segundo término converge a cero en probabilidad. Primero, se escribe el segundo término como:

$$(n^{-1}X'X)^{-1}n^{-1}X'u$$

y, luego, aplicar el teorema de Slutsky, para encontrar que $\hat{\beta} - \beta \rightarrow 0$. Sin embargo, a veces, incluso en muestras grandes, el estimador puede no estar “cerca” (en cierto sentido) del parámetro verdadero. En presencia de variables endógenas independientes [por ejemplo, $E(u | X) \neq 0$], el estimador $\hat{\beta}$ es sesgado e inconsistente:

$$\hat{\beta} \rightarrow \beta + Q_{xx}^{-1}Q_{xu} \neq 0$$

donde las matrices Q son formas limitantes de $X'X$ y $X'u$. Tener en cuenta que la falta de ortogonalidad entre el término de error y las variables independientes hace que el MCO sea inconsistente.

1.1) Ejemplo: Errores en variables.

Muchas variables (PBI, ingresos permanentes, depreciación de capital, inteligencia, etc.) se miden con errores. Considerar el modelo:

$$y_i = x_i^* \beta + \varepsilon_i,$$

donde x_i^* no se observa y es independiente de ε_i . La variable que observa el investigador es x_i , que se puede expresar como:

$$x_i = x_i^* + u_i.$$

La estimación MCO del modelo:

$$y_i = x_i^* \beta + \varepsilon_i$$

$$y_i = (x_i - u_i) \beta + \varepsilon_i$$

$$y_i = x_i \beta - u_i \beta + \varepsilon_i$$

$$y_i = x_i \beta + (\varepsilon_i - u_i \beta)$$

$$y_i = x_i \beta + v_i$$

puede ser sesgada e inconsistente porque x y v no son ortogonales:

$$\begin{aligned} E(x_i v_i) &= E[(x_i^* + u_i) v_i] \\ E(x_i v_i) &= E[(x_i^* + u_i)(\varepsilon_i - u_i \beta)] \\ E(x_i v_i) &= E[(x_i^* \varepsilon_i - x_i^* u_i \beta + u_i \varepsilon_i - u_i u_i \beta)] \\ E(x_i v_i) &= E(x_i^* \varepsilon_i) - E(x_i^* u_i \beta) + E(u_i \varepsilon_i) - E(u_i u_i \beta) \\ E(x_i v_i) &= 0 - E(x_i^* u_i) \beta + 0 - E(u_i u_i) \beta \\ E(x_i v_i) &= -0 * \beta - E(u_i u_i) \beta \\ E(x_i v_i) &= 0 - E(u_i u_i) \beta \\ E(x_i v_i) &= -E(u_i u_i) \beta \neq 0. \end{aligned}$$

Tener en cuenta que:

$$\begin{aligned} E(\hat{\beta} | X) &= E[(\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i | x_i] \\ E(\hat{\beta} | X) &= E\{\beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i v_i | x_i\} \\ E(\hat{\beta} | X) &= E(\beta | X) + E[(\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i v_i | x_i] \\ E(\hat{\beta} | X) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i E(v_i | x_i) \\ E(\hat{\beta} | X) &= \beta + \text{sesgo}. \end{aligned}$$

Además, en grandes muestras:

$$\begin{aligned} \hat{\beta} &= \beta + (n^{-1} \sum_{i=1}^n x_i x_i')^{-1} n^{-1} \sum_{i=1}^n x_i v_i \\ \hat{\beta} &= \beta + (n^{-1} \sum_{i=1}^n x_i x_i')^{-1} n^{-1} \sum_{i=1}^n (x_i^* + u_i)(\varepsilon_i - u_i \beta) \\ \hat{\beta} &= \beta + (n^{-1} \sum_{i=1}^n x_i x_i')^{-1} n^{-1} \sum_{i=1}^n (x_i^* \varepsilon_i - x_i^* u_i \beta + u_i \varepsilon_i - u_i u_i \beta). \end{aligned}$$

Ya que las perturbaciones ε_i y u_i y la variable no observada x_i^* son independientes:

$$\begin{aligned} \hat{\beta} &= \beta + \{n^{-1} \sum_{i=1}^n [(x_i^* + u_i)(x_i^* + u_i)']\}^{-1} n^{-1} \sum_{i=1}^n -u_i u_i' \beta \\ \hat{\beta} &= \beta - [n^{-1} \sum_{i=1}^n (x_i^* x_i^* + x_i^* u_i + u_i x_i^* + u_i u_i)]^{-1} n^{-1} \sum_{i=1}^n u_i u_i' \beta \\ \hat{\beta} &= \beta - [n^{-1} (\sum_{i=1}^n x_i^* x_i^* + \sum_{i=1}^n x_i^* u_i + \sum_{i=1}^n u_i x_i^* + \sum_{i=1}^n u_i u_i)]^{-1} n^{-1} \sum_{i=1}^n u_i u_i' \beta \\ \hat{\beta} &= \beta - [n^{-1} (\sum_{i=1}^n x_i^* x_i^* + \sum_{i=1}^n u_i u_i)]^{-1} n^{-1} \sum_{i=1}^n u_i u_i' \beta \\ \hat{\beta} &= \beta - [E(x_i^* x_i^*) + E(u_i u_i)]^{-1} E(u_i u_i') \beta. \end{aligned}$$

$$\hat{\beta} \rightarrow \beta - (Q_{x^*} + Q_u)^{-1} Q_u \beta \neq \beta,$$

donde $Q_{x^*} = \lim_{n \rightarrow \infty} \sum_{i=1}^n x_i^* x_i^{*'} y$ y $Q_u = \lim_{n \rightarrow \infty} \sum_{i=1}^n u_i u_i'$. Primero, tener en cuenta que, si una variable independiente se mide con un error, entonces, en general, todas las estimaciones son sesgadas e inconsistentes (¿por qué?). Segundo, si $p = 1$ (por ejemplo, una variable independiente):

$$\hat{\beta} \rightarrow \frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_u^2} \beta,$$

sugiriendo que, cuanto mayor sea el error de medición, peor será el sesgo.

1.2) Ejemplo: Variables omitidas.

El sesgo por variable omitida se crea cuando no se introduce una variable no observada. Por ejemplo, ya que la habilidad es una variable latente, no se pueden estimar los verdaderos rendimientos del modelo al modelo educativo. Por otro lado, hay variables relacionadas con la variable no observada, llamadas *proxies*. Por ejemplo, la puntuación de IQ es un *proxy* de la capacidad (por ejemplo, a mayor IQ de la persona, mayor es el nivel de habilidad).

Ahora, la pregunta es: ¿cuáles son las consecuencias en la estimación de usar una variable *proxy*? Se considera el modelo de retorno a la educación para ilustrar y para discutir las lecciones principales.

$$\log(wage_i) = \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 abil_i + u_i. \quad (2)$$

$$abil_i = \alpha_0 + \alpha_3 IQ_i + \varepsilon_i. \quad (3)$$

Reemplazando la ecuación (3) en (2), se tiene el siguiente modelo:

$$\begin{aligned} \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 (\alpha_0 + \alpha_3 IQ_i + \varepsilon_i) + u_i \\ \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 \alpha_0 + \beta_3 \alpha_3 IQ_i + \beta_3 \varepsilon_i + u_i \\ \log(wage_i) &= (\beta_0 + \beta_3 \alpha_0) + \beta_1 educ_i + \beta_2 exp_i + \beta_3 \alpha_3 IQ_i + (\beta_3 \varepsilon_i + u_i) \\ \log(wage_i) &= \delta_0 + \beta_1 educ_i + \beta_2 exp_i + \delta_3 IQ_i + v_i, \end{aligned}$$

$$\text{donde } \delta_0 = \beta_0 + \beta_3 \alpha_0, \delta_3 = \beta_3 \alpha_3 \text{ y } v_i = \beta_3 \varepsilon_i + u_i.$$

Por el método de mínimos cuadrados, se pueden obtener estimaciones insesgadas de β_1 y β_2 , ya que el término de error y las variables independientes *educ* y *exp* son independientes. Además, los estimadores MCO son consistentes, es decir, convergen en probabilidad al valor del parámetro verdadero a medida que aumenta el tamaño de la muestra. Sin embargo, esta conclusión puede ser alterada drásticamente. Se supone que, en lugar de la ecuación (3), el modelo verdadero asume que habilidad también está relacionada con la educación, por ejemplo:

$$abil_i = \alpha_0 + \alpha_1 educ_i + \alpha_3 IQ_i + \varepsilon_i. \quad (4)$$

Ahora, el modelo es:

$$\begin{aligned} \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 (\alpha_0 + \alpha_1 educ_i + \alpha_3 IQ_i + \varepsilon_i) + u_i \\ \log(wage_i) &= \beta_0 + \beta_1 educ_i + \beta_2 exp_i + \beta_3 \alpha_0 + \beta_3 \alpha_1 educ_i + \beta_3 \alpha_3 IQ_i + \beta_3 \varepsilon_i + u_i \\ \log(wage_i) &= (\beta_0 + \beta_3 \alpha_0) + (\beta_1 + \beta_3 \alpha_1) educ_i + \beta_2 exp_i + \beta_3 \alpha_3 IQ_i + (\beta_3 \varepsilon_i + u_i) \\ \log(wage_i) &= \delta_0 + \delta_1 educ_i + \beta_2 exp_i + \delta_3 IQ_i + v_i, \end{aligned}$$

$$\text{donde } \delta_0, \delta_3 \text{ y } v_i \text{ se definen como antes y } \delta_1 = \beta_1 + \beta_3 \alpha_1.$$

Se puede demostrar que, a medida que aumenta el tamaño de la muestra, el estimador del retorno a la educación tenderá a:

$$\hat{\delta}_1 = \beta_1 + \beta_3 \alpha_1 \neq \beta_1,$$

que es diferente al verdadero parámetro β_1 ya que $\alpha_1 = 0$. Por lo tanto, aunque se introduce una variable para explicar el efecto de la habilidad no observada, se tiene un estimador inconsistente del parámetro de retorno a la educación. Por ejemplo, si los años de educación se relacionan, positivamente, con la habilidad ($\alpha_1 > 0$) y la habilidad se relaciona, positivamente, con los salarios ($\beta_3 > 0$), el sesgo asintótico es positivo.

2) Estimación VI.

Se puede considerar reemplazar x con otra variable, digamos z . La nueva variable, llamada variable instrumental, tiene que satisfacer ciertas condiciones¹:

1. La variable instrumental z no debe estar correlacionada con el término de error u , $E(zu) = 0$.
2. La variable instrumental z tiene que estar correlacionada con la variable endógena x , $E(zx) \neq 0$.

Considerar el siguiente modelo de regresión lineal:

$$y = X_1\beta_1 + X_2\beta_2 + u.$$

$$y = X\beta + u,$$

donde X_1 son variables exógenas [por ejemplo, $E(u | X_1) = 0$] y X_2 son variables (observables) endógenas [por ejemplo, $E(u | X_2) \neq 0$]. Se supone también que hay una matriz de instrumentos Z . La idea es la siguiente: multiplicar cada lado de la ecuación por la matriz de variables instrumentales Z :

$$Z'y = Z'X\beta + Z'u,$$

donde Z puede incluir X_1 como instrumento para X_1 y Z_2 como instrumento para X_2 . Dividiendo por n y aplicando la Ley de los Grandes Números en $n^{-1}Z'u$, se obtiene una expresión que nos lleva al estimador VI (¿por qué?)². El estimador de variables instrumentales es:

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y.$$

Bajo errores esféricos, la varianza del estimador es:

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'y]$$

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'(X\beta + u)]$$

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'X\beta + (Z'X)^{-1}Z'u]$$

$$V(\hat{\beta}_{VI}) = V[(Z'X)^{-1}Z'X\beta] + V[(Z'X)^{-1}Z'u]$$

$$V(\hat{\beta}_{VI}) = 0 + (Z'X)^{-1}Z' V(u) Z(Z'X)^{-1}$$

¹ ¿Por qué la VI tiene que satisfacer estas dos condiciones? La primera condición puede ser intuitiva. La primera condición requiere que z y u no estén correlacionados, lo que implica que, si vamos a usar otra variable, al menos, tiene que resolver el problema original, $Cov(x, u) \neq 0$. ¿Podría explicar la segunda condición?

² Surge de minimizar: $\min_{\beta} E[(Z'u)^2] = \min_{\beta} E[(Z'y - Z'X\beta)^2] = \min_{\beta} E[(Z'y - Z'X\beta)'(Z'y - Z'X\beta)]$. Y, considerando la LGN, se tiene que: $\frac{1}{n} Z'u = \frac{1}{n} \sum_{i=1}^n z_i' u_i \rightarrow E(Z'u)$.

$$V(\hat{\beta}_{VI}) = (Z'X)^{-1}Z'\sigma_{VI}^2IZ(Z'X)^{-1}$$

$$V(\hat{\beta}_{VI}) = (Z'X)^{-1}Z'\sigma_{VI}^2Z(Z'X)^{-1}$$

$$V(\hat{\beta}_{VI}) = \sigma_{VI}^2(Z'X)^{-1}Z'Z(Z'X)^{-1}.$$

Tener en cuenta que el estimador $\hat{\beta}_{VI}$ también se puede obtener a partir de la condición del momento:

$$(Z'X)'(Z'y - Z'X\beta) = 0$$

$$X'Z(Z'y - Z'X\beta) = 0$$

$$X'ZZ'y - X'ZZ'X\beta = 0$$

$$X'ZZ'X\beta = X'ZZ'y$$

$$\beta = (X'ZZ'X)^{-1}X'ZZ'y$$

$$\beta = (Z'X)^{-1}(X'Z)^{-1}X'ZZ'y$$

$$\beta = (Z'X)^{-1}IZ'y$$

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y$$

o, análogamente:

$$Z'(y - X\beta) = 0$$

$$Z'y - Z'X\beta = 0$$

$$Z'X\beta = Z'y$$

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y,$$

que implica p ecuaciones y p incógnitas.

El estimador VI es insesgado según los supuestos A1 y A2 (¿por qué?). Tener en cuenta que:

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'y]$$

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'y]$$

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'(X\beta + u)]$$

$$E(\hat{\beta}_{VI}) = E[(Z'X)^{-1}Z'X\beta + (Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = E[I\beta + (Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = E[\beta + (Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = E(\beta) + E[(Z'X)^{-1}Z'u]$$

$$E(\hat{\beta}_{VI}) = \beta + (Z'X)^{-1}E(Z'u)$$

$$E(\hat{\beta}_{VI}) = \beta + (Z'X)^{-1} * 0$$

$$E(\hat{\beta}_{VI}) = \beta + 0$$

$$E(\hat{\beta}_{VI}) = \beta,$$

porque $E(Z'u) = 0$. También es consistente:

$$\hat{\beta}_{VI} - \beta = (n^{-1}Z'X)^{-1}(n^{-1}Z'u) \rightarrow 0,$$

siempre que la forma limitante de $Z'X$ sea determinista y no singular (condiciones necesarias para la identificación asintótica). Los errores no están correlacionados asintóticamente con los instrumentos, que se desprende de la condición 1 de la ley de los

grandes números. Tener en cuenta que esta condición puede durar, incluso, si la condición 1 no lo hace.

¿Cuáles son los instrumentos Z? Primero, desde $X_1 \perp u$, X_1 puede ser (trivialmente) usado como VI por sí misma. Luego, se necesitan instrumentos adicionales que satisfagan 1 y 2 para identificar el modelo. El vector Z_2 son VI para X_2 , a menudo denotadas como variables exógenas excluidas (del modelo).

El estimador VI tiene la siguiente representación asintótica:

$$\sqrt{n} (\hat{\beta}_{VI} - \beta) \rightarrow^d Q_{zx}^{-1} \mathcal{N}(0, \sigma^2 Q_{zz}) = \mathcal{N}(0, \sigma^2 Q_{zx}^{-1} Q_{zz} Q_{zx}^{-1}),$$

donde $Q_{zx} = \lim_{n \rightarrow \infty} n^{-1} Z'X$. Si $Z = X$, el estimador VI es, trivialmente, el estimador MCO.

Por último, tener en cuenta que la relación entre Z y X en muestras grandes coloca un papel clave para determinar la varianza asintótica.

2.1) Ejemplo: Estimador Wald VI.

Considerar el modelo de regresión simple:

$$y_i = \beta_0 + \beta_1 x_i + u_i,$$

donde $E(u_i | x_i) \neq 0$. Las suposiciones de nuestro modelo son (a) el término de error tiene un valor esperado de cero y (b) la correlación entre la variable instrumental y el término de error es cero. Estas condiciones de población imponen una condición sobre la contraparte de datos que se puede declarar como:

$$E(u) = 0 \quad \Rightarrow \quad \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (5)$$

$$E(zu) = 0 \quad \Rightarrow \quad \sum_{i=1}^n z_i (y_i - \beta_0 - \beta_1 x_i) = 0. \quad (6)$$

De la primera ecuación, se obtiene $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Reemplazando esta expresión en la segunda ecuación, se obtiene el estimador de Wald:

$$\begin{aligned} \sum_{i=1}^n [z_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)] &= 0 \\ \sum_{i=1}^n \{z_i [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]\} &= 0 \\ \sum_{i=1}^n [z_i (y_i - \bar{y}) - \hat{\beta}_1 z_i (x_i - \bar{x})] &= 0 \\ \sum_{i=1}^n z_i (y_i - \bar{y}) - \sum_{i=1}^n \hat{\beta}_1 z_i (x_i - \bar{x}) &= 0 \\ \sum_{i=1}^n z_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n z_i (x_i - \bar{x}) &= 0 \\ \hat{\beta}_1 \sum_{i=1}^n z_i (x_i - \bar{x}) &= \sum_{i=1}^n z_i (y_i - \bar{y}) \\ \hat{\beta}_1 &= [\sum_{i=1}^n z_i (x_i - \bar{x})]^{-1} \sum_{i=1}^n z_i (y_i - \bar{y}). \end{aligned}$$

La variable $z_i = \{0, 1\}$ es una variable dummy, por lo tanto, se puede escribir:

$$\begin{aligned} \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 (\bar{y}_1 - \bar{y}) \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left(\frac{N_0 \bar{y}_1 + N_1 \bar{y}_1}{N} - \frac{N_0 \bar{y}_0 + N_1 \bar{y}_1}{N} \right) \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left(\frac{N_0 \bar{y}_1 + N_1 \bar{y}_1 - N_0 \bar{y}_0 - N_1 \bar{y}_1}{N} \right) \end{aligned}$$

$$\begin{aligned}\sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left(\frac{N_0 \bar{y}_1 - N_0 \bar{y}_0}{N} \right) \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= N_1 \left[\frac{N_0 (\bar{y}_1 - \bar{y}_0)}{N} \right] \\ \sum_{i=1}^n z_i (y_i - \bar{y}) &= \frac{N_1 N_0}{N} (\bar{y}_1 - \bar{y}_0).\end{aligned}$$

En consecuencia, se puede escribir el estimador como:

$$\begin{aligned}\hat{\beta}_{Wald} &= \frac{\frac{N_1 N_0}{N} (\bar{y}_1 - \bar{y}_0)}{\frac{N_1 N_0}{N} (\bar{x}_1 - \bar{x}_0)} \\ \hat{\beta}_{Wald} &= \frac{\bar{y}_1 - \bar{y}_0}{\bar{x}_1 - \bar{x}_0}.\end{aligned}$$

3) Variable Instrumental Generalizada.

Tener en cuenta que, para que $Z'X$ sea invertible, se debe tener una matriz Z con p instrumentos. Cuando el número de VI es igual al número de parámetros a estimar, se dice que el modelo está, exactamente, identificado. A menudo, el número de VI es mayor que el número de parámetros, por lo que se puede considerar la siguiente matriz:

$$W = P_Z X$$

para lograr una transformación. Se dice que el modelo está sobreidentificado y, en este caso, la condición de momento es:

$$W' (y - X\beta) = 0,$$

dando el estimador generalizado de la variable instrumental:

$$\hat{\beta}_{VIG} = (W'X)^{-1} W'y.$$

El estimador generalizado VI se conoce, generalmente, como el estimador de mínimos cuadrados en dos etapas (MC2E):

$$\hat{\beta}_{MC2E} = (X'P_Z X)^{-1} X'P_Z y,$$

que se basa en dos proyecciones³:

1. Regresar X en Z para obtener:

$$\hat{X} = Z(Z'Z)^{-1} Z'X$$

³ La idea principal del estimador MC2E es la siguiente. En un modelo de regresión binaria, considerar que la variable independiente es endógena:

$$y_i = x_i' \beta + u_i; \quad x_i = z_i' \pi + v_i.$$

La segunda ecuación es interesante, ya que contiene dos partes que proporcionan la descomposición necesaria para resolver la endogeneidad en la ecuación principal: $\pi_0 + \pi_1 z_i$, que no está correlacionada con u , y v_i , que sí está correlacionada con u . La idea de MC2E es usar sólo la primera parte, la parte de la descomposición que es independiente del término de error. El problema es que $z_i' \pi$ no se observa, pero se puede predecir mediante la simple regresión MCO $\hat{x}_i = z_i' \hat{\pi}$.

$$\hat{X} = P_Z X.$$

Es importante ver los componentes de la matriz de proyección $\hat{X} = [P_Z X_1, P_Z X_2]$.
Recordar que $Z = [X_1, Z_2]$, por lo tanto:

$$\hat{X} = [X_1, \hat{X}_2].$$

2. Luego, regresar y sobre $\hat{X}$, obteniendo el estimador MC2E:

$$\hat{\beta}_{MC2E} = (\hat{X}'\hat{X})^{-1}\hat{X}'y.$$

Si los errores son homocedásticos, las condiciones anteriores (1)-(2) se satisfacen y la condición de rango (tantas VI como variables independientes) se satisface, se tiene el siguiente resultado.

Teorema 1. El estimador MC2E está distribuido de manera asintóticamente normal con media cero y matriz de varianzas:

$$p \lim_{n \rightarrow \infty} [n^{-1} \sigma^2 (X' P_Z X)]^{-1}.$$

Prueba. Escribir el estimador VI como:

$$\hat{\beta} = \beta + (X' P_Z X)^{-1} X' P_Z u.$$

Luego, se multiplica cada término por $\sqrt{n}$ y se escribe como:

$$\sqrt{n} (\hat{\beta} - \beta) = (n^{-1} X' P_Z X)^{-1} n^{\frac{-1}{2}} X' P_Z u + o_p(1).$$

El resultado sigue pasando con n tendiendo a ∞ y aplicando el teorema de Slutsky (¿se puede modificar el resultado para el caso de errores no esféricos?).

3.1) Una tercera derivación.

Una interpretación interesante del MC2E es la siguiente. Se definen los residuos de X en Z :

$$R = X - \hat{X}$$

$$R = X - P_Z X$$

$$R = (I - P_Z) X$$

$$R = M_Z X.$$

Considerar, ahora, el estimador de mínimos cuadrados de un modelo que incluye los residuos:

$$y = X\beta + R\gamma + u,$$

que es igual a:

$$\hat{\beta}_{vc} = (X'M_R X)^{-1} X'M_R Y,$$

donde vc significa variable de control. Este estimador es idéntico al estimador MC2E porque:

$$\begin{aligned} X'M_R &= X' (I - P_R) \\ X'M_R &= X' [I - R(R'R)^{-1}R'] \\ X'M_R &= X' [I - M_Z X(X'M_Z M_Z X)^{-1} X'M_Z'] \\ X'M_R &= X' [I - M_Z X(X'M_Z M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' [I - M_Z X(X'M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' - X'M_Z X(X'M_Z X)^{-1} X'M_Z \\ X'M_R &= X' - IX'M_Z \\ X'M_R &= X' - X'M_Z \\ X'M_R &= X' - X' (I - P_Z) \\ X'M_R &= X' - X' + X'P_Z \\ X'M_R &= X'P_Z. \end{aligned}$$

Por lo tanto, el “sesgo por endogeneidad” se puede ver como un sesgo por variable omitida.

4) Test.

4.1) Una prueba de especificación incorrecta.

Por supuesto, en situaciones prácticas, no se sabe si las variables independientes están correlacionadas con el término de error. Se puede usar la teoría económica para guiarnos, pero la verdadera pregunta estadística es simplemente: ¿es el problema de la endogeneidad lo suficientemente serio? Por ejemplo, si la respuesta es no, se puede ignorar el problema y, simplemente, estimar el modelo utilizando MCO.

La pregunta anterior se puede examinar con una prueba propuesta por J. Hausman en 1978. La prueba sobre modelos específicos en econometría tiene una amplia aplicabilidad a diferentes modelos. En datos de panel, como quedará claro en futuras lecturas, ayuda a decidir entre los modelos de efectos fijos y los modelos de efectos aleatorios mediante la prueba de la hipótesis supuesta de independencia entre los efectos específicos individuales y las variables independientes.

En nuestra configuración de sección transversal, la hipótesis nula y la hipótesis alternativa se pueden formular como:

$$H_0: E(X'u) = 0; \quad H_a: E(X'u) \neq 0.$$

Bajo H_0 , los estimadores MCO y VI son consistentes, aunque el MCO es eficiente. Bajo H_a , el estimador VI sigue siendo consistente, pero el MCO es inconsistente.

Por lo tanto, una prueba basada en la diferencia entre estos dos estimadores puede indicar si la endogeneidad afecta la consistencia del estimador MCO. La idea es evaluar si la distancia entre los dos estimadores es, asintóticamente, cero:

$$\hat{q} = \tilde{\beta} - \hat{\beta} \rightarrow 0,$$

donde $\tilde{\beta}$ es el estimador VI y $\hat{\beta}$ es el estimador MCO. ¿Cuál es la distribución de $\hat{q}$? Se espera que sea, asintóticamente, normal con varianza asintótica:

$$V(\hat{q}) = V(\tilde{\beta} - \hat{\beta})$$

$$V(\hat{q}) = V(\tilde{\beta}) - V(\hat{\beta}).$$

Lema 1. Bajo H_0 , $V(\tilde{\beta} - \hat{\beta}) = V(\tilde{\beta}) - V(\hat{\beta})$.

Prueba. Escribir:

$$\Delta = \tilde{\beta} - \hat{\beta}$$

$$\Delta = [\beta + (X'P_ZX)^{-1}X'P_Zu] - [\beta + (X'X)^{-1}X'u]$$

$$\Delta = \beta + (X'P_ZX)^{-1}X'P_Zu - \beta - (X'X)^{-1}X'u$$

$$\Delta = (X'P_ZX)^{-1}X'P_Zu - (X'X)^{-1}X'u$$

$$\Delta = [(X'P_ZX)^{-1}X'P_Z - (X'X)^{-1}X']u$$

$$\Delta = (A - B)u.$$

Entonces:

$$E(\Delta\Delta') = E\{[(A - B)u][(A - B)u']\}$$

$$E(\Delta\Delta') = E[(A - B)uu'(A - B)']$$

$$E(\Delta\Delta') = (A - B)E(uu')(A - B)'$$

$$E(\Delta\Delta') = (A - B)\sigma_u^2(A - B)'$$

$$E(\Delta\Delta') = \sigma_u^2(A - B)(A - B)'$$

$$E(\Delta\Delta') = \sigma_u^2(A - B)(A' - B')$$

$$E(\Delta\Delta') = \sigma_u^2(AA' + AB' - BA' + BB').$$

Tener en cuenta que:

$$AB' = (X'P_ZX)^{-1}X'P_Z[(X'X)^{-1}X']'$$

$$AB' = (X'P_ZX)^{-1}X'P_ZX(X'X)^{-1}$$

$$AB' = I(X'X)^{-1}$$

$$AB' = (X'X)^{-1}.$$

$$BA' = (X'X)^{-1}X'[(X'P_ZX)^{-1}X'P_Z]'$$

$$BA' = (X'X)^{-1}X'P_ZX(X'P_ZX)^{-1}$$

$$BA' = (X'X)^{-1}I$$

$$BA' = (X'X)^{-1}.$$

$$BB' = (X'X)^{-1}X'[(X'X)^{-1}X']'$$

$$BB' = (X'X)^{-1}X'X(X'X)^{-1}$$

$$BB' = I(X'X)^{-1}$$

$$BB' = (X'X)^{-1}.$$

Así que:

$$E(\Delta\Delta') = \sigma_u^2(AA' - BB')$$

$$E(\Delta\Delta') = \sigma_u^2AA' - \sigma_u^2BB'$$

$$E(\Delta\Delta') = \sigma_u^2(X'P_ZX)^{-1} - \sigma_u^2(X'X)^{-1}$$

$$V(\tilde{\beta} - \hat{\beta}) = V(\tilde{\beta}) - V(\hat{\beta}).$$

Un estadístico de prueba natural es, entonces:

$$h = \hat{q}'[V(\tilde{\beta}) - V(\hat{\beta})]^{-1}\hat{q},$$

que se distribuye asintóticamente como χ^2 . Si h es bajo, digamos menos de 2 valores críticos, no se rechaza la hipótesis nula y se concluye que la endogeneidad no afecta la consistencia del estimador MCO. Si h es alto, digamos más de 2 valores críticos, se rechaza la hipótesis nula y se concluye que la endogeneidad es un problema para el estimador MCO. Por lo tanto, se debe utilizar el estimador VI.

4.2) Restricciones sobreidentificadas.

Considerar que el modelo de regresión está bien especificado, $y = X\beta + u$. Un candidato Z debe satisfacer:

$$E(u | Z) = 0 \quad \text{o} \quad E(Z'u) = 0.$$

Tener en cuenta que, en el caso de los modelos recién identificados, se tiene que:

$$Z'\hat{u} = 0,$$

así que no se pueden probar las condiciones anteriores. Sin embargo, si se tienen más instrumentos (digamos k) que variables endógenas (digamos q), se puede considerar la siguiente prueba:

$$T = \hat{\sigma}^{-2}\hat{u}'Z(Z'Z)^{-1}Z'\hat{u}$$

$$T = \hat{\sigma}^{-2}\hat{u}'P_Z\hat{u} \sim \chi_{k-q}^2,$$

bajo la hipótesis nula. Si se rechaza la nula, esto debe interpretarse como evidencia de que los instrumentos son endógenos. Permítame presentar una manera simple de implementar la prueba:

1. Estimar la ecuación estructural por MC2E para obtener los residuos, $\hat{u}_i$.
2. Regresar $\hat{u}_i$ en las variables exógenas (las VI, $z_1, \dots, z_k$, y las covariables incluidas $x_{q+1}, \dots, x_p$).
3. Con el R^2 de la última regresión, construir el estadístico de prueba nR^2 para evaluar la hipótesis nula.

5) Instrumentos Débiles.

Déjeme decir una palabra sobre las consecuencias de elegir un instrumento “débil”, es decir, una variable que no satisface ninguna de las condiciones (1) o (2). Se supone, por ejemplo, que z infringe (1), es decir, la variable instrumental no es independiente del término de error. Considerando un modelo con un regresor (endógeno):

$$y = x\beta + u,$$

se puede demostrar que:

$$\hat{\beta} \rightarrow \beta + \frac{Cor(z,u)\sigma_u}{Cor(z,x)\sigma_x},$$

donde $Cor(.)$ significa correlación.

Ésta es una fórmula interesante. Incluso si la correlación entre z y u es pequeña, el sesgo asintótico puede ser muy grande si (a) z y x están, apenas, correlacionados y si (b) la relación ruido-senal ($\frac{\sigma_u}{\sigma_x}$) es grande.

Si se compara el sesgo asintótico del estimador de la variable instrumental pobre con el estimador MCO en el caso de que x no sea exógena:

$$\hat{\beta} \rightarrow \beta + \frac{Cov(x,u)}{V(x)} = \beta + \frac{\sigma_x \sigma_u Cor(x,u)}{\sigma_x^2} = \beta + Cor(x,u) \frac{\sigma_u}{\sigma_x},$$

se puede concluir que el estimador MCO se prefiere al estimador MC2E si:

$$\frac{Cor(z,u)}{Cor(z,x)} > Cor(x,u).$$

No es sorprendente, entonces, que, a menudo, se indique que una VI débil se puede detectar usando la regresión de la primera etapa (por ejemplo, simplemente, mirando la prueba de F o R^2). La práctica estándar es verificar si los instrumentos están correlacionados con la variable endógena ejecutando la endógena en las VI y en las variables exógenas. Una prueba de F en los coeficientes en las VI proporciona una medida del contenido de información de las VI⁴.

Desafortunadamente, el problema de las VI débiles es, típicamente, más complejo, ya que incluye otros parámetros. Considerar, por ejemplo:

$$\begin{aligned} y_1 &= y_2 \beta + u \\ y_2 &= z\pi + v, \end{aligned}$$

donde z es un vector k dimensional y $E(uv) = \sigma_{uv}$. El estimador MC2E es:

$$\begin{aligned} \hat{\beta} &= \frac{y_2' P_z y_1}{y_2' P_z y_2} \\ \hat{\beta} &= \beta + \frac{y_2' P_z u}{y_2' P_z y_2}. \end{aligned}$$

Dejar $q_2 = \frac{y_2' P_z y_2}{n}$ y tener en cuenta que $y_2' P_z u = \text{tr}(y_2' P_z u) = \text{tr}(P_z y_2' u) = \text{tr}(P_z) y_2' u = \text{tr}(I_k) y_2' u = k y_2' u$. Entonces, se puede expresar el sesgo del estimador MC2E como:

⁴ Una regla de oro, tomada de Stock and Watson (2003), sugiere que 10 es el valor del estadístico F que divide los instrumentos débiles y válidos. Por ejemplo, si el estadístico F excede de 10, se rechaza la hipótesis nula, concluyendo que las z son instrumentos válidos para nuestras variables endógenas.

$$\hat{\beta} - \beta \approx \frac{k}{n} \frac{\sigma_{uv}}{q_2} \approx \frac{k}{nR^2} \frac{\sigma_{uv}}{\sigma_{y_2}^2}.$$

Esto implica que k , el coeficiente de determinación de la regresión R^2 de la primera etapa y la correlación entre los errores en las ecuaciones σ_{uv} desempeñan un papel en la determinación del sesgo del MC2E en muestras pequeñas. Tener en cuenta que, como $n \rightarrow \infty$, si k es fijo, se tiende a tener (asintóticamente) sesgo cero. La literatura ofrece pruebas y estimadores con corrección de sesgo (véase, por ejemplo, Stock 2002, Hahn y Hausman 2003).

Otro problema está relacionado con la inferencia cuando la correlación entre la variable endógena y el instrumento es muy pequeña. De nuevo, considerar el siguiente modelo:

$$\begin{aligned} y_1 &= y_2 \beta + u \\ y_2 &= z' \pi + v, \end{aligned}$$

donde, ahora, $k = 1$. En otras palabras, el modelo está, exactamente, identificado y los instrumentos son endógenos utilizando un instrumento. Recordar que $\pi = \frac{E(z_i y_{2i})}{E(z_i^2)}$ y considerar que $\pi = \frac{\gamma}{\sqrt{n}}$. En este caso:

$$\hat{\beta} - \beta = \frac{\frac{1}{\sqrt{n}} \sum_i z_i u_i}{\frac{1}{\sqrt{n}} \sum_i z_i y_{2i}} \rightsquigarrow \frac{\mathcal{N}(0, V_u)}{Q_Z \gamma + \mathcal{N}(0, V_v)},$$

distribuido como no normal para $\gamma \neq 0$ y Cauchy cuando $\gamma = 0$. Por lo tanto, el estimador VI converge en probabilidad a una variable aleatoria no degenerada. Su distribución no es normal y, por lo tanto, los procedimientos de inferencia también son inconsistentes (ver, por ejemplo, Choi y Phillips 1992).

6) Estimación VI en Modelos no Lineales.

Casos de error de medición (EM) en las variables independientes:

1. Sesgo e inconsistencia en la estimación de parámetros para modelos econométricos.
2. Pérdida de potencia para detectar una relación estocástica significativa entre las variables de interés.

Las técnicas para abordar el problema del error de medición se pueden clasificar en dos grupos: (a) métodos para modelos de error en variables lineales y (b) métodos para modelos de error en variables no lineales.

6.1) Errores clásicos.

Esto se refiere a una situación en la que la verdadera variable latente no está correlacionada con el error de medición. Considerar:

$$Y = \alpha + \beta X^* + \epsilon \tag{7}$$

$$X = X^* + u \tag{8}$$

y, por lo tanto:

$$\begin{aligned} Y &= \alpha + \beta (X - u) + \epsilon \\ Y &= \alpha + \beta X - \beta u + \epsilon \\ Y &= \alpha + \beta X + v, \end{aligned} \quad (9)$$

donde $v = \epsilon - \beta u$. Recordar que el estimador sesgado e inconsistente para la pendiente es:

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X}) Y_i}{\sum_{i=1}^n (X_i - \bar{X})^2} \quad (10)$$

y la intercepción es:

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}. \quad (11)$$

Tener en cuenta que:

$$\begin{aligned} \hat{\alpha} &\rightarrow E(\alpha + \beta X^* + \epsilon) - \frac{\beta \sigma_{X^*}^2}{\sigma_{X^*}^2 + \sigma_u^2} E(X^* + u) \\ \hat{\alpha} &\rightarrow \alpha + \frac{\beta \sigma_{X^*}^2}{\sigma_{X^*}^2 + \sigma_u^2} E(X^*). \end{aligned} \quad (12)$$

Observación 1.

Es interesante ejecutar una regresión para X en Y para encontrar los límites de los coeficientes verdaderos α y β . Escribir:

$$X = \frac{-\alpha}{\beta} + \frac{1}{\beta} Y - \frac{v}{\beta} \quad (13)$$

y, por lo tanto:

$$\tilde{b} = \frac{\sum_{i=1}^n (X_i - \bar{X}) Y_i}{\sum_{i=1}^n (Y_i - \bar{Y})^2} \quad (14)$$

$$\tilde{\alpha} = \bar{Y} - \tilde{\beta} \bar{X}, \quad (15)$$

donde $\tilde{\beta} = \tilde{b}^{-1}$. Ahora, se escribe:

$$\begin{aligned} \tilde{\alpha} &\rightarrow E(\alpha + \beta X^* + \epsilon) - (\beta + \frac{\sigma_u^2}{\beta \sigma_{X^*}^2}) E(X^*) \\ \tilde{\alpha} &\rightarrow \alpha - \frac{\sigma_u^2}{\beta \sigma_{X^*}^2} E(X^*). \end{aligned} \quad (16)$$

Ejemplo 1: Tener en cuenta que el *plim* de $\tilde{b} = \frac{Cov(x,y)}{V(y)}$. Es posible demostrar que:

$$plim \tilde{\beta} = \beta + \frac{\sigma_u^2}{\beta \sigma_{X^*}^2}.$$

Como se discutió anteriormente, el modelo con errores clásicos puede verse como un problema de regresores endógenos. Por lo tanto, VI se convierte en un enfoque popular para estimar tales modelos.

Las pruebas de tipo Hausman también se pueden utilizar en este tipo de modelos. Un VI válido podría tener la forma $Z = X^* + v_Z$, siendo v_Z un error independiente: $E[Z(\epsilon, u)] = 0$.

Ejemplo 2. Considerar el modelo anterior y suponer que $\alpha = 0$, $\beta = 1$, $\sigma_\epsilon^2 = 0,25$, $\sigma_u^2 = 1$ y $X^* \in \mathcal{N}(0, 1)$. Se puede ilustrar el sesgo de atenuación usando los siguientes dos gráficos.

Ejemplo 3. Cuando se tienen muchas columnas en X y se observa sólo una covariable con error de medición, la fórmula para el sesgo de atenuación es:

$$\hat{\beta} \rightarrow \beta \left[1 - \frac{\sigma_u^2}{\sigma_{X^*}^2(1 - R_{X^*, Z}^2) + \sigma_u^2} \right], \quad (17)$$

donde R^2 es el verdadero R^2 .

Ejemplo 4. Se supone que se observan mediciones repetidas para individuos a lo largo del tiempo. Por ejemplo, suponer:

$$Y_{it} = \alpha + \beta X_{it}^* + \mu_i + \epsilon_{it}. \quad (18)$$

$$X_{it} = X_{it}^* + u_{it}. \quad (19)$$

Para eliminar esa heterogeneidad no observada, simplemente, se obtienen las primeras diferencias:

$$\begin{aligned} \Delta Y_{it} &= \beta \Delta X_{it}^* + \Delta \epsilon_{it} \\ \Delta Y_{it} &= \beta \Delta(X_{it} - u_{it}) + \Delta \epsilon_{it} \\ \Delta Y_{it} &= \beta \Delta X_{it} - \beta \Delta u_{it} + \Delta \epsilon_{it} \\ \Delta Y_{it} &= \beta \Delta X_{it} + \Delta v_{it}. \end{aligned} \quad (20)$$

Por lo tanto:

$$\begin{aligned} \hat{\beta} &= \frac{\sum_{i=1}^N \Delta X_{it} \Delta Y_{it}}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \frac{\sum_{i=1}^N \Delta X_{it} [\beta \Delta X_{it} + (\Delta \epsilon_{it} - \beta \Delta u_{it})]}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \frac{\sum_{i=1}^N [\beta \Delta X_{it}^2 + \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})]}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \frac{\sum_{i=1}^N \beta \Delta X_{it}^2 + \sum_{i=1}^N \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \beta + \frac{\sum_{i=1}^N \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})}{\sum_{i=1}^N \Delta X_{it}^2} \\ \hat{\beta} &= \beta + \frac{\frac{1}{N} \sum_{i=1}^N \Delta X_{it} (\Delta \epsilon_{it} - \beta \Delta u_{it})}{\frac{1}{N} \sum_{i=1}^N \Delta X_{it}^2}. \end{aligned} \quad (21)$$

Tener en cuenta que:

$$\begin{aligned}
E[(\Delta X_{it})^2] &= E[(X_{it} - X_{it-1})^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^* + u_{it}) - (X_{it-1}^* + u_{it-1})]^2 \\
E[(\Delta X_{it})^2] &= E[(X_{it}^* + u_{it})^2 - 2(X_{it}^* + u_{it})(X_{it-1}^* + u_{it-1}) + (X_{it-1}^* + u_{it-1})^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^* + u_{it})^2] - E[2(X_{it}^* + u_{it})(X_{it-1}^* + u_{it-1})] + E[(X_{it-1}^* + u_{it-1})^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^*)^2 + 2X_{it}^*u_{it} + u_{it}^2] - 2E[(X_{it}^* + u_{it})(X_{it-1}^* + u_{it-1})] + E[(X_{it-1}^*)^2 + 2X_{it-1}^*u_{it-1} + u_{it-1}^2] \\
E[(\Delta X_{it})^2] &= E[(X_{it}^*)^2] + E(2X_{it}^*u_{it}) + E(u_{it}^2) - 2E(X_{it}^*X_{it-1}^* + X_{it}^*u_{it-1} + u_{it}X_{it-1}^* + u_{it}u_{it-1}) + E[(X_{it-1}^*)^2] + E(2X_{it-1}^*u_{it-1}) + E(u_{it-1}^2) \\
E[(\Delta X_{it})^2] &= \sigma_{X^*}^2 + 2E(X_{it}^*u_{it}) + \sigma_u^2 - 2[E(X_{it}^*X_{it-1}^*) + E(X_{it}^*u_{it-1}) + E(u_{it}X_{it-1}^*) + E(u_{it}u_{it-1})] + \sigma_{X^*}^2 + 2E(X_{it-1}^*u_{it-1}) + \sigma_u^2 \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 2E(X_{it}^*u_{it}) - 2E(X_{it}^*X_{it-1}^*) - 2E(X_{it}^*u_{it-1}) - 2E(u_{it}X_{it-1}^*) - 2E(u_{it}u_{it-1}) + 2E(X_{it-1}^*u_{it-1}) \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 2\text{Cov}(X_{it}^*, u_{it}) - 2\text{Cov}(X_{it}^*, X_{it-1}^*) - 2\text{Cov}(X_{it}^*, u_{it-1}) - 2\text{Cov}(X_{it-1}^*, u_{it}) - 2\text{Cov}(u_{it}, u_{it-1}) + 2\text{Cov}(X_{it-1}^*, u_{it-1}) \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 2 * 0 - 2\text{Cov}(X_{it}^*, X_{it-1}^*) - 2 * 0 - 2 * 0 - 2 * 0 + 2 * 0 \\
E[(\Delta X_{it})^2] &= 2\sigma_{X^*}^2 + 2\sigma_u^2 + 0 - 2\sigma_{X^*}^2 \text{Cor}(X_{it}^*, X_{it-1}^*) - 0 - 0 - 0 - 0 \\
E[(\Delta X_{it})^2] &= 2(1 - \rho) \sigma_{X^*}^2 + 2\sigma_u^2, \tag{22}
\end{aligned}$$

donde $\rho = \text{Cor}(X_{it}^*, X_{it-1}^*)$. Del mismo modo, se puede demostrar que:

$$\begin{aligned}
\hat{\beta} &\rightarrow \beta - \frac{2\beta\sigma_u^2}{2(1-\rho)\sigma_{X^*}^2 + 2\sigma_u^2} \\
\hat{\beta} &\rightarrow \beta - \frac{2\beta\sigma_u^2}{2[(1-\rho)\sigma_{X^*}^2 + \sigma_u^2]} \\
\hat{\beta} &\rightarrow \beta - \frac{\beta\sigma_u^2}{(1-\rho)\sigma_{X^*}^2 + \sigma_u^2} \\
\hat{\beta} &\rightarrow \frac{\beta(1-\rho)\sigma_{X^*}^2 + \beta\sigma_u^2 - \beta\sigma_u^2}{(1-\rho)\sigma_{X^*}^2 + \sigma_u^2} \\
\hat{\beta} &\rightarrow \frac{\beta(1-\rho)\sigma_{X^*}^2}{(1-\rho)\sigma_{X^*}^2 + \sigma_u^2}. \tag{23}
\end{aligned}$$

6.2) Modelos no lineales.

Es bien sabido que las suposiciones VI estándar no son suficientes para la identificación de modelos no lineales de error en variables. Amemiya (1985) demostró que el estimador clásico de la variable instrumental puede ser inconsistente sin una estructura adicional. La literatura ofrece una variedad de estas restricciones, por ejemplo, desde distribuciones conocidas de errores de medición hasta formas más fuertes de VI.

Para ilustrar los problemas detrás de la VI clásica en entornos no lineales, se considera un ejemplo presentado en la página 912 de Cameron y Trivedi (2005). Considerar:

$$Y = \alpha + \beta f(X^*) + \epsilon \tag{24}$$

$$X = X^* + u, \tag{25}$$

donde $f(\cdot)$ es una función suave de una variable latente, X^* . Expansión de Taylor de $X^* = (X - u)$ alrededor de X produce:

$$\begin{aligned}
 f(X^*) &= f(X - u) \\
 f(X^*) &= f(X) + \frac{\partial f}{\partial X}(X^* - X) + \frac{1}{2!} \frac{\partial^2 f}{\partial^2 X}(X^* - X)^2 + \dots + \frac{1}{n!} \frac{\partial^n f}{\partial^n X}(X^* - X)^n + \dots \\
 f(X^*) &= f(X) - f' u + \frac{1}{2} f'' (-u)^2 + \dots + \frac{1}{n!} f^n (-u)^n + \dots
 \end{aligned} \tag{26}$$

Se supone, por simplicidad, que $f = \gamma X + X^2$ es cuadrática. En este caso, la aproximación es exacta (por ejemplo, no se tiene un término recordatorio R). Tener en cuenta que $f' = 2X + \gamma$ y $f'' = 2$. Reemplazando, se tiene que:

$$\begin{aligned}
 Y &= \alpha + \beta f(\gamma X + X^2) + \epsilon \\
 Y &= \alpha + \beta [(\gamma X + X^2) - (2X + \gamma) u + \frac{1}{2} * 2 u^2] + \epsilon \\
 Y &= \alpha + \beta (\gamma X + X^2 - 2Xu - \gamma u + u^2) + \epsilon \\
 Y &= \alpha + \beta \gamma X + \beta X^2 - 2\beta Xu - \beta \gamma u + \beta u^2 + \epsilon \\
 Y &= \alpha + \beta \gamma X + \beta X^2 + (\epsilon - 2\beta Xu - \beta \gamma u + \beta u^2).
 \end{aligned} \tag{27}$$

Por lo tanto, VI necesita satisfacer:

1. $E(Z_1 X) \neq 0$ y $E(Z_2 X^2) \neq 0$,
2. $E[Z_j (\epsilon - 2\beta Xu - \beta \gamma u + \beta u^2)] = 0$,

que, obviamente, no es equivalente a $E(Z_j \epsilon) = E(Z_j u) = 0$.

Lectura 7: **MGM, EMV y Pruebas para Restricciones no Lineales.**

Esta lectura presenta el Método Generalizado de Momentos (MGM), la Estimación de Máxima Verosimilitud (EMV) en una configuración de regresión y analiza las pruebas de restricciones no lineales. Como se verá más adelante, el método de máxima verosimilitud es conveniente para tratar con modelos no lineales y, en algunos casos, con hipótesis no lineales. Por ejemplo, si tiene un resultado binario (por ejemplo, $y_i = 1$ si el gobernador fue elegido y $y_i = 0$ de lo contrario) y variables observables (por ejemplo, impuestos, tasa de desempleo del estado, etc.), se puede mostrar que el modelo de media condicional es:

$$E(y | x) = P(y = 1 | x) = F(x'\beta).$$

En las siguientes secciones, se discutirá el método y los procedimientos de prueba asociados.

1) Método Generalizado de Momentos (MGM).

Antes de presentar el enfoque de MGM, se repasarán, brevemente, algunos ejemplos simples del Método de Momentos. Considerar $\{y_i\}$ extraído de una distribución i.i.d., cuyo primer momento existe (por ejemplo, y no se distribuye como Cauchy). En la población:

$$E(y - \mu) = 0,$$

así que se puede utilizar la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{y}.$$

Otro ejemplo que ya se analizó es el estimador VI, que se puede definir en términos de la condición del momento:

$$\begin{aligned} E(z_i u_i) &= E[E(z_i u_i | z)] \\ E(z_i u_i) &= E[z_i E(u_i | z)] \\ E(z_i u_i) &= E(z_i * 0) \\ E(z_i u_i) &= E(0) \\ E(z_i u_i) &= 0 \end{aligned}$$

o, alternativamente:

$$E[z_i (y_i - x_i'\beta)] = 0.$$

El estimador VI podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n z_i (y_i - x_i'\beta) = 0,$$

obteniendo el estimador de variable instrumental presentado en la lectura anterior:

$$\hat{\beta}_{VI} = (\sum_{i=1}^n z_i x_i')^{-1} \sum_{i=1}^n z_i y_i$$

$$\hat{\beta}_{VI} = (Z'X)^{-1} Z'y.$$

Se generaliza el procedimiento, directamente, considerando modelos que satisfacen la condición:

$$E [g (w_i, \theta_0)] = 0,$$

donde $g (.)$ es una función en $\mathbb{R}^l$ y el parámetro $\theta_0 \in \Theta \subset \mathbb{R}^p$. Por ejemplo, $g (w_i, \theta_0)$ tiene la siguiente forma lineal:

$$z_i (y_i - x_i' \beta) = 0,$$

con el requisito mínimo de p condiciones de momento (por ejemplo, $l = p$).

Ahora, se supone que se tienen condiciones de momento con $l > p$. La contraparte del momento de la muestra:

$$g_n = \frac{1}{n} \sum_{i=1}^n g (w_i, \theta_0)$$

no tiene solución, pero se puede seleccionar p combinaciones lineales de los momentos de muestra para obtener el estimador. Por lo tanto, dado $g_n (\theta)$, se puede elegir una matriz semidefinida positiva W_n y definir el estimador que minimiza:

$$\hat{\theta}_{MGM} = \arg \min_{\theta \in \Theta} \|g_n (\theta)\|_{W_n}^2$$

$$\hat{\theta}_{MGM} = \arg \min_{\theta \in \Theta} g_n (\theta)' W_n g_n (\theta)$$

La matriz $W_n \rightarrow W$ a medida que el tamaño de la muestra se va a infinito, con W siendo definida positiva. Por supuesto, la matriz W_n es importante para la estimación.

1.1) Ejemplo: Mínimos Cuadrados Ordinarios.

Considerar el caso donde los errores y las variables independientes son independientes. Para el estimador MCO, las condiciones son:

$$E [x_i (y_i - x_i' \beta)] = 0.$$

Las condiciones de los momentos de muestra son:

$$g_n = \frac{1}{n} \sum_{i=1}^n x_i (y_i - x_i' \beta).$$

El número de condiciones de momento es igual al número de parámetros desconocidos. En este caso, se dice que el modelo se identifica de manera justa o exacta. El caso VI, ilustrado arriba, también representa un caso en el que el modelo está, exactamente, identificado.

1.2) Ejemplo: Mínimos Cuadrados de Dos Etapas.

Para MC2E, se pueden tener más condiciones de momento que parámetros [por ejemplo, $\dim(z_i) > \dim(x_i)$], pero una matriz W adecuada será suficiente para obtener el estimador:

$$\arg \min g_n(\beta)' W_n g_n(\beta),$$

con $W_n = (Z'Z)^{-1}$ y $g_n = Z'(y - X\beta)$. Tener en cuenta que:

$$X'ZWZ'(y - X\beta) = 0$$

implica:

$$\hat{\beta} = (X'ZWZ'X)^{-1}X'ZWZ'y$$

$$\hat{\beta} = [X'Z(Z'Z)^{-1}Z'X]^{-1}X'Z(Z'Z)^{-1}Z'y$$

$$\hat{\beta} = (X'P_ZX)^{-1}X'P_Zy.$$

La solución depende de la matriz W y, por supuesto, la solución del problema de minimización es la misma para las W que difieren en una constante de proporcionalidad. Tener en cuenta que esto se relaciona con el supuesto de errores homocedásticos. ¿Cuál debería ser la matriz de ponderación bajo heterocedasticidad? Sea S la matriz de covarianza del momento g :

$$S = \frac{1}{n} E(Z'uu'Z)$$

$$S = \frac{1}{n} Z'\Omega Z.$$

Para obtener el estimador MGM óptimo, en este caso, se necesita:

1. Estimar $\hat{\beta}$ por el método VI para obtener $\hat{u}$.
2. Usar $\hat{u}$ para encontrar:

$$\hat{W} = \hat{S}^{-1} = n (Z'\hat{\Omega}Z)^{-1}, \text{ donde } \hat{\Omega} = \text{diag}(\hat{u}_i^2).$$

3. Encontrar el MGM óptimo y viable como:

$$\hat{\beta} = [X'Z(Z'\hat{\Omega}Z)^{-1}Z'X]^{-1}X'Z(Z'\hat{\Omega}Z)^{-1}Z'y.$$

2) Consideraciones Adicionales.

Si el modelo está identificado, el estimador es consistente y tiene distribución asintóticamente normal bajo condiciones de regularidad:

1. La primera condición de regularidad asume que:

$$\frac{\partial g_n(\theta)'}{\partial \theta'} \rightarrow \frac{\partial E[g(\theta)]}{\partial \theta'} = G.$$

2. También se asume la consistencia estándar de la raíz cuadrada:

$$\sqrt{n} g_n(\theta) \rightsquigarrow \mathcal{N}(0, S^{-1}).$$

Entonces, el estimador tiene distribución asintóticamente normal:

$$\sqrt{n}(\hat{\theta} - \theta) \rightsquigarrow \mathcal{N}(0, (G'WG)^{-1}G'WSW'G(G'WG)^{-1}).$$

Si se elige W_n tal que $W_n \rightarrow S^{-1} = W$, se tiene que la varianza asintótica es, simplemente:

$$\begin{aligned} & (G'S^{-1}G)^{-1}G'S^{-1}SS^{-1}G(G'S^{-1}G)^{-1} \\ & (G'S^{-1}G)^{-1}G'IS^{-1}G(G'S^{-1}G)^{-1} \\ & (G'S^{-1}G)^{-1}G'S^{-1}G(G'S^{-1}G)^{-1} \\ & I(G'S^{-1}G)^{-1} \\ & (G'S^{-1}G)^{-1}, \end{aligned}$$

el caso que se conoce como MGM eficiente (Hansen 1982) cuando se conoce a S . Esto es, quizás, una desventaja del estimador, ya que requiere conocer la matriz de covarianza asintótica. La solución es estimarlo, pero esta idea puede fallar en muestras pequeñas e intermedias. Si el tamaño de la muestra no es lo suficientemente grande o si las condiciones del momento son grandes, la estimación de la matriz de covarianza asintótica en el primer paso puede dar como resultado estimaciones erróneas en el segundo paso. El problema se ha documentado en la literatura y se han propuesto varias soluciones (por ejemplo, estimación simultánea).

3) Estimación MV.

Sea $\{(y_i, x_i): i = 1, \dots, n\}$ una muestra distribuida de forma independiente e idéntica (i.i.d.) de la respuesta y y las variables independientes x .

Se puede definir la función de probabilidad como:

$$\mathcal{L}(\theta) = f(y, x | \theta),$$

pero, dado que nuestro objetivo es modelar el comportamiento de y en términos de x , se considera, directamente, la densidad condicional de y_i :

$$f(y_i | x_i, \theta_0).$$

Entonces, se puede definir la función de log-verosimilitud condicional como:

$$\ell(\theta; y_i | x_i) \equiv \log[f(y_i | x_i, \theta)].$$

Considerando una muestra i.i.d. de n observaciones $\{(y_i, x_i)\}$, la función de densidad condicional conjunta es, básicamente:

$$\prod_{i=1}^n f(y_i | x_i, \theta) = f(y_1 | x_1, \theta) \dots f(y_n | x_n, \theta)$$

y, en consecuencia, la función log-verosimilitud es:

$$\begin{aligned}\ell(\theta; y | x) &= \log \left[\prod_{i=1}^n f(y_i | x_i, \theta) \right] \\ \ell(\theta; y | x) &= \sum_{i=1}^n \log[f(y_i | x_i, \theta)].\end{aligned}$$

Ejemplo 1 (Escala de ubicación normal). Suponer que u_i se distribuye como $\mathcal{N}(\beta_0, \sigma^2)$. Entonces, la función de densidad de probabilidad es:

$$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(u_i - \beta_0)^2}{2\sigma^2}}.$$

Si las observaciones son independientes, se tiene:

$$(2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (u_i - \beta_0)^2},$$

y, en consecuencia, la probabilidad de registro como:

$$\ell(\beta_0, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (u_i - \beta_0)^2.$$

Ejemplo 2 (El modelo de regresión). Considerar el modelo de regresión clásico:

$$y_i = x_i' \beta + u_i,$$

donde y y x son i.i.d., variables aleatorias distribuidas conjuntamente. Las variables de transformación obtendrán el log-verosimilitud como:

$$\sum_{i=1}^n \log[f(y_i | x_i, \theta)] = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - x_i' \beta)^2,$$

donde $\theta = (\beta, \sigma^2)$.

Ejemplo 3 (Densidad de Poisson). Considerar, ahora, que la variable dependiente y_i toma un valor discreto no negativo (por ejemplo, número de visitas al médico). La función de densidad de Poisson puede ser una dirección natural:

$$f(y | \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}; \quad y = 0, 1, 2, \dots$$

La especificación habitual en el análisis de regresión es $\lambda = e^{x' \beta}$, lo que lleva a una función de verosimilitud de la forma:

$$\sum_{i=1}^n \log[f(y_i | x_i, \theta)] = -\sum_{i=1}^n e^{x_i' \beta} + \sum_{i=1}^n y_i x_i' \beta - \sum_{i=1}^n \log y_i!.$$

3.1) Estimador de Máxima Verosimilitud.

Considerar los siguientes supuestos:

1. El modelo $y_i = m(x_i, u_i, \theta)$ se especifica correctamente, donde $m(\cdot)$ es una función conocida que puede ser lineal (por ejemplo, $y = x' \beta + u$).
2. $\{(y_i, x_i): i = 1, \dots, n\}$ es una muestra i.i.d.
3. Θ es un subespacio compacto en $\mathbb{R}^p$ que contiene θ_0 .

4. La función de densidad $f(y_1 | x, \theta)$ es continua y tiene derivadas continuas de segundo orden sobre un conjunto compacto.
5. La función de probabilidad tiene una solución única.

El principio MLE es elegir un estimador de un parámetro de la distribución condicional de y , θ_0 , que maximice la probabilidad de observar la muestra real. El estimador de máxima verosimilitud (MLE) es el estimador que maximiza la función de (log)verosimilitud:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \ell(\theta; y | x),$$

donde Θ es un subespacio compacto en $\mathbb{R}^p$ que contiene θ .

Ejemplo 4 (Regresión Lineal). La función de log-verosimilitud que se obtuvo antes de usar la notación matricial:

$$\text{const} - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)' (y - X\beta).$$

Tomando la condición de primer orden:

$$\begin{aligned} \frac{\partial \ell}{\partial \beta} &= \frac{1}{\sigma^2} X' (y - X\beta) = 0. \\ \frac{\partial \ell}{\partial \sigma^2} &= \frac{-n}{2\sigma^2} + \frac{1}{2\sigma^4} (y - X\beta)' (y - X\beta) = 0. \end{aligned}$$

Resolviendo el sistema de ecuaciones, se encuentra que los estimadores MLE son:

$$\begin{aligned} \frac{1}{\sigma^2} X' (y - X\beta) &= 0 \\ X' (y - X\beta) &= 0 * \sigma^2 \\ X'y - X'X\beta &= 0 \\ X'X\beta &= X'y \\ \hat{\beta} &= \frac{X'y}{X'X} \\ \hat{\beta} &= (X'X)^{-1} X'y. \\ \frac{-n}{2\sigma^2} + \frac{1}{2\sigma^4} (y - X\beta)' (y - X\beta) &= 0 \\ \frac{-n\sigma^2 + (y - X\beta)' (y - X\beta)}{2\sigma^4} &= 0 \\ -n\sigma^2 + (y - X\beta)' (y - X\beta) &= 0 * 2\sigma^4 \\ -n\sigma^2 + (y - X\beta)' (y - X\beta) &= 0 \\ n\sigma^2 &= (y - X\beta)' (y - X\beta) \\ \hat{\sigma}^2 &= \frac{1}{n} (y - X\hat{\beta})' (y - X\hat{\beta}). \end{aligned}$$

Se sabe que el estimador $\hat{\beta}$ es insesgado porque es idéntico al estimador OLS. En contraste, el estimador del parámetro de varianza $\hat{\sigma}^2$ está sesgado (¿Por qué?). También:

$$\begin{aligned} \frac{\partial^2 \ell}{\partial \beta \partial \beta'} &= \frac{-X'X}{\sigma^2}. \\ \frac{\partial^2 \ell}{\partial \beta \partial \sigma^2} &= \frac{-X'(y - X\beta)}{\sigma^4}. \end{aligned}$$

$$\frac{\partial^2 \ell}{\partial \sigma^2 \partial \beta'} = \frac{-(y - X\beta)' X}{\sigma^4},$$

$$\frac{\partial^2 \ell}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} + \frac{1}{\sigma^6} (y - X\beta)' (y - X\beta).$$

La esperanza de la matriz (p x p) de segundas derivadas se llama matriz de información:

$$I(\theta_0 | X) = -E \left(\frac{\partial^2 \ell}{\partial \theta \partial \theta'} | X \right)$$

$$I(\theta_0 | X) = - \begin{bmatrix} E \left(\frac{\partial^2 \ell}{\partial \beta \partial \beta'} \right) & E \left(\frac{\partial^2 \ell}{\partial \beta \partial \sigma^2} \right) \\ E \left(\frac{\partial^2 \ell}{\partial \sigma^2 \partial \beta'} \right) & E \left(\frac{\partial^2 \ell}{\partial^2 \sigma^2} \right) \end{bmatrix}$$

$$I(\theta_0 | X) = \begin{bmatrix} \frac{-X'X}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{bmatrix}.$$

Tener en cuenta que los elementos fuera de la diagonal de la matriz de información $I(\theta)$ son cero, lo que sugiere que $\hat{\beta}$ y $\hat{\sigma}^2$ son “independientes”. La matriz de segundas derivadas es n.s.d.

Ejemplo 5 (Densidad de Poisson). El caso de Poisson no tiene una solución explícita, por lo que los métodos numéricos son útiles en este caso. Al diferenciar la función de probabilidad, se obtiene $\hat{\beta}$ como la solución de:

$$\sum_{i=1}^n y_i x_i - \sum_{i=1}^n e^{x_i \hat{\beta}} x_i = 0.$$

El caso anterior es común en el análisis empírico. A veces, obtener el estimador MLE se complica al no proporcionar soluciones analíticas. A continuación, se analizarán, brevemente, las alternativas para superar el problema.

3.2) Eficiencia.

Se deja definir la función de puntuación como:

$$S_i = \frac{\partial \ell_i(\theta)}{\partial \theta}$$

$$S_i = \left[\frac{\partial \ell_i(\theta)}{\partial \theta_1}, \dots, \frac{\partial \ell_i(\theta)}{\partial \theta_p} \right],$$

con $E[S_i(\theta_0)] = 0$ y la matriz de Hessiana:

$$H_i = \frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'}$$

$$H_i = \frac{\partial S_i}{\partial \theta},$$

una matriz simétrica (p x p) de segundas derivadas. Evaluado en el verdadero parámetro θ_0 , se tiene que:

$$-E[H(\theta)] = -E \left[\frac{\partial^2 \ell(\theta)}{\partial \theta \partial \theta'} \right]$$

$$-E [H(\theta)] = E \left\{ \left[\frac{\partial \ell(\theta)}{\partial \theta} \right] \left[\frac{\partial \ell(\theta)}{\partial \theta} \right]' \right\}$$

$$-E [H(\theta)] = I(\theta_0).$$

Esta propiedad es importante para el análisis empírico. Calcula la segunda derivada de una función de probabilidad, pero la expresión anterior sugiere una alternativa, tal vez más fácil: calcular el producto de las dos funciones de puntuación. Sin embargo, se debe ser cauteloso. El análisis anterior se cumple cuando se conoce la distribución condicional de y .

En el caso de muestras i.i.d.:

$$-\sum_{i=1}^n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right] = -n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right]$$

$$-\sum_{i=1}^n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right] = n E \left\{ \left[\frac{\partial \ell_i(\theta)}{\partial \theta} \right] \left[\frac{\partial \ell_i(\theta)}{\partial \theta} \right]' \right\}$$

$$-\sum_{i=1}^n E \left[\frac{\partial^2 \ell_i(\theta)}{\partial \theta \partial \theta'} \right] = n \Omega(\theta),$$

indicando que la matriz de información es n veces la información contenida en una observación. Tener en cuenta que Ω es la varianza de la función de puntuación.

Se puede demostrar que el estimador MLE es consistente, lo que significa que:

$$\hat{\theta} \rightarrow \theta,$$

y, asintóticamente, normal:

$$\sqrt{n}(\hat{\theta} - \theta_0) \rightsquigarrow \mathcal{N}(0, (\Omega(\theta))^{-1}).$$

Si el número de observaciones es, suficientemente, grande, el estimador tiene una varianza asintótica que puede ser aproximada por el inverso de la información contenida en una observación. Este resultado muestra la eficiencia del estimador MLE, que alcanza el límite inferior de Cramer-Rao (el límite inferior de la varianza de los estimadores insesgados):

$$V(\tilde{\theta}) \geq [n I(\theta)]^{-1},$$

para cualquier estimador $\tilde{\theta}$ insesgado de θ_0 , siempre que la matriz de información no sea singular. Tener en cuenta que MLE es atractivo para la estimación de modelos paramétricos, ya que alcanza el límite inferior.

4) Procedimientos de Prueba.

Esta sección considera las pruebas de hipótesis lineal y no lineal. Se revisan tres pruebas basadas en el principio de probabilidad y se proporciona la base para considerar las pruebas cuando los métodos clásicos fallan. Se supone que se tiene una muestra i.i.d. de n observaciones $\{(y_i, x_i); i = 1, \dots, n\}$. Se considera prueba de hipótesis de la forma:

$$h(\theta) = 0,$$

donde $h(\cdot)$ es una función vectorial ($r \times 1$) de θ con $r \leq p$. Se supone que $H(\theta) = \frac{\partial h(\theta)}{\partial \theta}$ es una matriz ($p \times r$), está bien definida y tiene rango de columna completo:

$$\text{rango}(H(\theta)) = r,$$

lo que significa que las restricciones impuestas son independientes. Antes de considerar la prueba, permítanme definir un par de conceptos importantes. Se denota el espacio de parámetro restringido:

$$\Theta_0 = \{\theta \in \Theta \mid h(\theta) = 0\},$$

lo que implica que $\Theta_0 \subset \Theta$. Recordar que el estimador MLE se define como:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \ell(\theta).$$

Además, se puede definir el estimador MLE restringido como el argumento que maximiza la función de log-verosimilitud restringida:

$$\hat{\theta} = \arg \max_{\theta \in \Theta_0} \ell(\theta)$$

o equivalente:

$$\max_{\theta \in \Theta_0} \ell(\theta) \quad \text{sujeto a} \quad h(\theta) = 0.$$

4.1) Prueba de relación de verosimilitud.

La prueba se define como:

$$LR = 2 [\ell(\hat{\theta}) - \ell(\tilde{\theta})].$$

La intuición detrás de la prueba es que, si la hipótesis nula es verdadera, las funciones de probabilidad deberían ser similares. Por lo tanto, los valores más altos de LR implican mayores posibilidades de rechazar la hipótesis nula H_0 .

4.2) Prueba multiplicador de Lagrange.

$$LM = \frac{\partial \ell(\tilde{\theta})}{\partial \theta'} [I(\tilde{\theta})]^{-1} \frac{\partial \ell(\tilde{\theta})}{\partial \theta},$$

que está motivado por el hecho de que la función de puntuación $\frac{\partial \ell(\tilde{\theta})}{\partial \theta} = 0$. Por lo tanto, si la hipótesis nula H_0 es verdadera, se espera que el máximo que ocurre en $\frac{\partial \ell(\tilde{\theta})}{\partial \theta} \approx 0$ no rechace la nula.

4.3) Test Wald.

La prueba se define como:

$$W = [h(\hat{\theta})]' \{ [H(\hat{\theta})]' [I(\hat{\theta})]^{-1} H(\hat{\theta}) \}^{-1} h(\hat{\theta}).$$

Si H_0 es verdadera, $h(\hat{\theta})$ está cerca de cero. El estadístico de prueba es, asintóticamente, χ_r^2 , donde r denota el rango de la matriz H (es decir, $r = \text{rango}(H)$ -el número de restricciones impuestas por H_0 -).

Ejemplo 6 (Pruebas de restricciones no lineales). Considerar probar:

$$H_0: h(\theta) = \frac{\theta_1}{\theta_2} - c = 0.$$

Entonces, los estadísticos de Wald son:

$$W = \left(\frac{\theta_1}{\theta_2} - c \right) \left\{ \begin{bmatrix} \frac{1}{\theta_2} & -\frac{\hat{\theta}_1}{\hat{\theta}_2^2} & 0 \end{bmatrix} \begin{bmatrix} \hat{v}_{11} & \hat{v}_{12} & \hat{v}_{13} \\ \hat{v}_{21} & \hat{v}_{22} & \hat{v}_{23} \\ \hat{v}_{31} & \hat{v}_{32} & \hat{v}_{33} \end{bmatrix} \begin{bmatrix} \frac{1}{\hat{\theta}_2} \\ -\frac{\hat{\theta}_1}{\hat{\theta}_2^2} \\ 0 \end{bmatrix} \right\}^{-1} \left(\frac{\theta_1}{\theta_2} - c \right),$$

donde 0 es una matriz de ceros $((r - 2) \times r)$ y v_{jj} denota el elemento j -ésimo de la matriz de covarianza asintótica estimada. Bajo la nula, W se distribuye, asintóticamente, como χ_1^2 .

El problema con esta prueba es que depende de la matriz de covarianza asintótica estimada. Hay alternativas para las restricciones no lineales que se discutirán en los próximos cursos (por ejemplo, Método Delta, Bootstrap).

Ejemplo 7 (MLE restringido). Considerar, ahora, una probabilidad de largo plazo de la forma:

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)' (y - X\beta) + 2\lambda' (R\beta - \delta),$$

donde λ es un vector potencialmente $(p \times 1)$. Suponiendo que se conoce el valor de σ^2 , la solución se puede escribir como:

$$\frac{\partial \ell}{\partial \beta} = 0 \Rightarrow -2X'y + 2X'X\tilde{\beta} + 2R'\lambda = 0.$$

$$\frac{\partial \ell}{\partial \lambda} = 0 \Rightarrow R\tilde{\beta} = \delta.$$

En otras palabras:

$$\begin{bmatrix} X'X & R' \\ R & 0 \end{bmatrix} \begin{bmatrix} \tilde{\beta} \\ \lambda \end{bmatrix} = \begin{bmatrix} X'y \\ \delta \end{bmatrix}.$$

Por lo tanto:

$$(\tilde{\beta}', \tilde{\lambda}')' = \begin{bmatrix} X'X & R' \\ R & 0 \end{bmatrix}^{-1} \begin{bmatrix} X'y \\ \delta \end{bmatrix}.$$

Aplicando fórmulas de matriz con particiones inversas, se obtiene:

$$\begin{aligned}\tilde{\beta} &= (X'X)^{-1}X'y - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1}X'y + \\ & (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\beta} &= \hat{\beta} - (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R\hat{\beta} + (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\beta} &= \hat{\beta} - D(R\hat{\beta} - \delta),\end{aligned}$$

donde $D = (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}$. Tener en cuenta que:

$$\begin{aligned}E(\tilde{\beta}) &= E[\hat{\beta} - D(R\hat{\beta} - \delta)] \\ E(\tilde{\beta}) &= E(\hat{\beta}) - E[D(R\hat{\beta} - \delta)] \\ E(\tilde{\beta}) &= \beta - D(R\beta - \delta) \\ E(\tilde{\beta}) &= \beta.\end{aligned}$$

si $R\beta - \delta = 0$ (la hipótesis nula es verdadera). Si es falsa, $\tilde{\beta}$ está sesgado.

En términos de la varianza de $\tilde{\beta}$, se tiene que:

$$\begin{aligned}V(\tilde{\beta}) &= V[\hat{\beta} - D(R\hat{\beta} - \delta)] \\ V(\tilde{\beta}) &= V(\hat{\beta} - DR\hat{\beta} + D\delta) \\ V(\tilde{\beta}) &= V[(I - DR)\hat{\beta}] + V(D\delta) \\ V(\tilde{\beta}) &= (I - DR)V(\hat{\beta})(I - DR)' + 0 \\ V(\tilde{\beta}) &= (I - DR)\sigma^2(X'X)^{-1}(I - DR)' \\ V(\tilde{\beta}) &= \sigma^2(I - DR)(X'X)^{-1}(I - DR)' \\ V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} - \sigma^2[DR(X'X)^{-1} + (X'X)^{-1}R'D' - DR(X'X)^{-1}R'D'].\end{aligned}$$

Tener en cuenta que:

$$\begin{aligned}DR(X'X)^{-1} &= (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1} \\ DR(X'X)^{-1} &= (X'X)^{-1}R'D'\end{aligned}$$

y:

$$\begin{aligned}DR(X'X)^{-1}R'D' &= (X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}R(X'X)^{-1} \\ DR(X'X)^{-1}R'D' &= (X'X)^{-1}R'ID' \\ DR(X'X)^{-1}R'D' &= (X'X)^{-1}R'D'.\end{aligned}$$

Por lo tanto:

$$\begin{aligned}V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} - \sigma^2[DR(X'X)^{-1} + (X'X)^{-1}R'D' - (X'X)^{-1}R'D'] \\ V(\tilde{\beta}) &= \sigma^2(X'X)^{-1} - \sigma^2DR(X'X)^{-1} \\ V(\tilde{\beta}) &= \sigma^2(X'X)^{-1}(I - DR) \leq V(\hat{\beta}).\end{aligned}$$

La solución para el multiplicador Lagrange es:

$$\begin{aligned}\tilde{\lambda} &= [R(X'X)^{-1}R']^{-1}R(X'X)^{-1}X'y - [R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\lambda} &= [R(X'X)^{-1}R']^{-1}R\hat{\beta} - [R(X'X)^{-1}R']^{-1}\delta \\ \tilde{\lambda} &= WR\hat{\beta} - W\delta \\ \tilde{\lambda} &= W(R\hat{\beta} - \delta).\end{aligned}$$

Es fácil ver que $E(\tilde{\lambda}) = 0$ bajo la nula (*) y $V(\tilde{\lambda}) = \sigma^2 W$ (**).

$$(*) E(\tilde{\lambda}) = E[W(R\hat{\beta} - \delta)]$$

$$E(\tilde{\lambda}) = E(W * 0)$$

$$E(\tilde{\lambda}) = E(0)$$

$$E(\tilde{\lambda}) = 0.$$

$$(**) V(\tilde{\lambda}) = V[W(R\hat{\beta} - \delta)]$$

$$V(\tilde{\lambda}) = V(WR\hat{\beta} - W\delta)$$

$$V(\tilde{\lambda}) = V(WR\hat{\beta}) - V(W\delta)$$

$$V(\tilde{\lambda}) = WR V(\hat{\beta}) R'W' + 0$$

$$V(\tilde{\lambda}) = WR\sigma^2(X'X)^{-1}R'W'$$

$$V(\tilde{\lambda}) = \sigma^2 WR(X'X)^{-1}R'W'$$

$$V(\tilde{\lambda}) = \sigma^2 [R(X'X)^{-1}R']^{-1}R(X'X)^{-1}R'[R(X'X)^{-1}R']^{-1}$$

$$V(\tilde{\lambda}) = \sigma^2 WI$$

$$V(\tilde{\lambda}) = \sigma^2 W.$$

5) Selección de Modelo.

En algunas situaciones, típicamente series de tiempo, es posible que no se conozca la dimensión del modelo (por ejemplo, cuántos parámetros debería tener nuestro modelo lineal). Akaike (1969) y Schwartz (1978) abordaron este aspecto importante de la modelización en estadística y en econometría.

En una configuración de regresión, la probabilidad se puede escribir como:

$$\ell(\beta, \sigma^2) = \frac{-n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta).$$

Al conectar $\hat{\beta}$ y $\hat{\sigma}^2 = \frac{S}{n}$, se obtiene la función de probabilidad concentrada:

$$\ell(\hat{\sigma}^2) = \frac{-n}{2} \log(2\pi) - \frac{n}{2} - \frac{n}{2} \log \hat{\sigma}^2,$$

sugiriendo que, para un tamaño de muestra dado, la probabilidad se puede aumentar agregando covariables al modelo para reducir la suma de cuadrados residual S.

Akaike (1969) propuso elegir un modelo de un conjunto que funcione bien en función de los pronósticos. Su propuesta se basa en la siguiente función:

$$AIC(j) = \ell_j(\hat{\theta}) - p_j,$$

donde $\ell_j(\hat{\theta})$ es la probabilidad correspondiente al modelo j^{th} maximizado sobre j (típicamente, se tiene $p_1 < p_2 < \dots < p_n$). AIC significa Criterios de Información de Akaike. La idea básica del término adicional en AIC, llamado término de penalización, es traer una regla sobre el ajuste de varias especificaciones “penalizando” un aumento en el número de regresiones. La regla de selección de modelo de Akaike fue evaluar AIC(j) sobre j modelos, eligiendo el modelo j^* que maximiza AIC(j).

Un último criterio, conocido como criterio de información de Schwarz, se basa en un enfoque bayesiano del problema analizado en Akaike (1969). Schwarz propuso:

$$\text{SIC}(j) = \ell_j(\hat{\theta}) - \frac{1}{2} p_j \log n.$$

Tener en cuenta que maximizar SIC:

$$\ell_j(\hat{\theta}) - \frac{1}{2} p_j \log n$$

es equivalente a minimizar:

$$\log \hat{\sigma}_j^2 - \frac{p_j}{n} \log n.$$

Es posible mostrar que los estadísticos de prueba:

$$T_n = 2 [\ell_j(\hat{\theta}_j) - \ell_i(\hat{\theta}_i)] \rightsquigarrow \chi_{p_j - p_i}^2,$$

para $p_j > p_i = p$ (tener en cuenta que el modelo i es el modelo verdadero). Las pruebas de hipótesis clásicas sugerirían rechazar la hipótesis nula de que el modelo más pequeño i es el modelo verdadero si y sólo si el valor de T_n excede un valor crítico de $\chi_{p_j - p_i}^2$. Por otro lado, SIC puede elegir j sobre i si:

$$2 \frac{\ell_j - \ell_i}{p_j - p_i} > \log n \quad (1)$$

porque:

$$0 = [\ell_j(\hat{\theta}) - \frac{p_j}{2} \log n] - [\ell_i(\hat{\theta}) - \frac{p_i}{2} \log n]$$

$$0 = [\ell_j(\hat{\theta}) - \ell_i(\hat{\theta})] - \frac{1}{2} (p_j - p_i) \log n.$$

Tener en cuenta que el número de observaciones está actuando como el valor crítico de la prueba. Esto está estrechamente relacionado con la prueba F clásica, ya que es posible demostrar que, considerando la simplicidad $p_j - p_i = 1$:

$$2 (\ell_i - \ell_j) = -n (\log \hat{\sigma}_i^2 - \log \hat{\sigma}_j^2)$$

$$2 (\ell_i - \ell_j) = n (\log \hat{\sigma}_j^2 - \log \hat{\sigma}_i^2)$$

$$2 (\ell_i - \ell_j) = n \log \frac{\hat{\sigma}_j^2}{\hat{\sigma}_i^2}$$

$$2 (\ell_i - \ell_j) = n \log \left(1 + \frac{\hat{\sigma}_j^2}{\hat{\sigma}_i^2} - 1 \right)$$

$$2 (\ell_i - \ell_j) = n \log (1 + a),$$

donde $a = \frac{\hat{\sigma}_j^2}{\hat{\sigma}_i^2} - 1$. Usando $\log (1 + a) \approx a$ para un a pequeño, se tiene:

$$2(\ell_i - \ell_j) \approx \frac{n(\hat{\sigma}_j^2 - \hat{\sigma}_i^2)}{\hat{\sigma}_i^2} > \log n. \quad (2)$$

El LHS de la ecuación (2) puede interpretarse como una prueba F, ya que puede escribirse, aproximadamente, como:

$$\frac{SSR_r - SSR_u}{SSR_u}.$$

Se utilizará AIC y BIC como dispositivos de selección de modelos para modelos de series temporales. Se puede encontrar un ejemplo preliminar en el tutorial de las notas de esta conferencia.

6) Una Digresión (Final).

El marco anterior se conecta muy bien con el análisis de Big Data. Considerar el siguiente estimador:

$$\hat{\beta} = \arg \min [\sum_{i=1}^n (y_i - x_i' \beta)^2 + P(\beta, \lambda)], \quad (3)$$

donde $P(\beta, \lambda)$ es una función de penalización y es un parámetro de ajuste. Por ejemplo, la función de penalización puede ser:

$$P(\beta, \lambda) = \lambda \sum_{j=1}^p |\beta_j|^q, \quad (4)$$

para $q = \{1, 2\}$. El modelo aquí es escaso en los coeficientes y la solución del problema de optimización depende del valor del parámetro de contracción y de la función de penalización.

Para funciones de penalización, fácilmente, diferenciables, por ejemplo, se tiene que:

$$\begin{aligned} u'u + \lambda \beta' \beta &= (y - X\beta)'(y - X\beta) + \lambda \beta' \beta \\ u'u + \lambda \beta' \beta &= (y' - \beta' X') (y - X\beta) + \lambda \beta' \beta \\ u'u + \lambda \beta' \beta &= y'y - 2\beta' X'y + \beta' X' X \beta + \lambda \beta' \beta. \end{aligned} \quad (*) \text{ y } (**)$$

$$\begin{aligned} (*) \quad (X\beta)^2 &= (X\beta)'(X\beta) \\ (X\beta)^2 &= \beta' X' X \beta. \end{aligned}$$

(**) $\beta' X'y$ es un escalar, por lo que es, trivialmente, igual a su transpuesto, $y' X \beta$.

Suponiendo $\frac{\lambda}{2}$ dado, la CPO $-X'y + X'X\beta + \lambda\beta = 0$. Por lo tanto:

$$\begin{aligned} -2X'y + 2X'X\beta + 2\lambda\beta &= 0 \\ 2(-X'y + X'X\beta + \lambda\beta) &= 0 \\ -X'y + X'X\beta + \lambda\beta &= \frac{0}{2} \\ -X'y + X'X\beta + \lambda\beta &= 0 \\ (X'X + \lambda I) \beta &= X'y \\ \hat{\beta} &= \frac{X'y}{X'X + \lambda I} \end{aligned}$$

$$\hat{\beta} = (X'X + \lambda I)^{-1} X'y.$$

Se puede demostrar que:

$$\begin{aligned} E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'y] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'(X\beta + u)] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta + (X'X + \lambda I)^{-1} X'u] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + E[(X'X + \lambda I)^{-1} X'u] \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + (X'X + \lambda I)^{-1} X' E(u) \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + (X'X + \lambda I)^{-1} X' * 0 \\ E(\hat{\beta}) &= E[(X'X + \lambda I)^{-1} X'X\beta] + 0 \\ E(\hat{\beta}) &= (X'X + \lambda I)^{-1} X'X\beta. \end{aligned}$$

$$\begin{aligned} V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'y] \\ V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'(X\beta + u)] \\ V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'X\beta + (X'X + \lambda I)^{-1} X'u] \\ V(\hat{\beta}) &= V[(X'X + \lambda I)^{-1} X'X\beta] + V[(X'X + \lambda I)^{-1} X'u] \\ V(\hat{\beta}) &= 0 + (X'X + \lambda I)^{-1} X' V(u) X(X'X + \lambda I)^{-1} \\ V(\hat{\beta}) &= (X'X + \lambda I)^{-1} X' \sigma^2 X (X'X + \lambda I)^{-1} \\ V(\hat{\beta}) &= (X'X + \lambda I)^{-1} \sigma^2 X'X (X'X + \lambda I)^{-1}. \end{aligned}$$

7) Apéndice.

Se recuerda que $1 = \int f(x) dx$. Diferenciando ambos lados:

$$\begin{aligned} 0 &= \int \frac{1}{f} f_{\theta}(x) f dx \\ 0 &= \int \frac{\partial \log f}{\partial \theta} f dx \end{aligned}$$

Se sabe:

$$\begin{aligned} 0 &= \int \frac{\partial \log f}{\partial \theta} f dx \\ 0 &= \int \left(\frac{\partial^2 \log f}{\partial \theta \partial \theta'} + \frac{\partial \log f}{\partial \theta} \frac{\partial f}{\partial \theta'} \right) dx \\ 0 &= \int \left(\frac{\partial^2 \log f}{\partial \theta \partial \theta'} + \frac{\partial \log f}{\partial \theta} \frac{\partial \log f}{\partial \theta'} f \right) dx \\ 0 &= \int \frac{\partial^2 \log f}{\partial \theta \partial \theta'} dx + \int \frac{\partial \log f}{\partial \theta} \frac{\partial \log f}{\partial \theta'} f dx. \end{aligned}$$