

Análisis de regresión en Stata

Jessica Bracco

Econometría Avanzada
Maestría en Economía - FCE- UNLP

Agosto, 2019

En esta clase

- 1 El modelo de regresión lineal
- 2 Efectos marginales
- 3 Forma funcional del modelo
- 4 Interpretación económica
- 5 Interpretación estadística
- 6 Opciones útiles

El modelo de regresión lineal

Modelo lineal:

$$Y = X\beta + \mu$$

donde X es un vector de K regresores y β son K parámetros (incluyendo el de la constante)

- El término μ representa todo lo que explica a Y y que no se ha incluido en el modelo.
- El supuesto de exogeneidad es $E(\mu | X) = 0$, lo que implica que $E(X'\mu) = 0$
- Intuición: ningún potencial factor omitido tiene correlación con las variables explicativas, X .

Mínimos Cuadrados Ordinarios (MCO)

- Definiendo $e = Y - X\hat{\beta}$, el método de MCO resuelve el siguiente problema:

$$\min_{\hat{\beta}} \sum_{i=1}^n e_i^2 = \min_{\hat{\beta}} e'e$$

- Las CPO son:

$$X'e = 0$$

- Este es un sistema de K ecuaciones que define K estimadores de β , cuya solución es:

$$\hat{\beta}_{MCO} = (X'X)^{-1}X'Y$$

Efectos marginales

- Supongamos el siguiente modelo:

$$hrstrt_i = \beta_0 + \beta_1 aedu_i + \beta_2 edad_i + \beta_3 edad_i^2 + \beta_4 hombre_i + \mu$$

$$E(hrstrt_i) = E(\beta_0 + \beta_1 aedu_i + \beta_2 edad_i + \beta_3 edad_i^2 + \beta_4 hombre_i + \mu)$$

$$E(hrstrt_i) = \beta_0 + \beta_1 E(aedu_i) + \beta_2 E(edad_i) + \beta_3 E(edad_i^2) + \beta_4 E(hombre_i) + \underbrace{E(\mu)}_{=0}$$

$$E(hrstrt_i) = \beta_0 + \beta_1 aedu_i + \beta_2 edad_i + \beta_3 edad_i^2 + \beta_4 hombre_i$$

- Efecto marginal para **variables continuas**:

$$\frac{\delta E(hstrt)}{\delta aedu} = \beta_1$$

*al aumentar en un año la educación formal, las horas trabajadas varían **en promedio** β_1 horas, **ceteris paribus***

$$\frac{\delta E(hstrt)}{\delta edad} = \beta_2 + 2\beta_3 edad$$

*al aumentar en un año la edad, las horas trabajadas varían **en promedio** $(\beta_2 + 2\beta_3 edad)$ horas, **ceteris paribus** (el efecto marginal no es constante!)*

- Efecto marginal para **variables discretas**:

$$\begin{aligned}
 & E(hstrt \mid hombre = 1) - E(hstrt \mid hombre = 0) \\
 &= \beta_0 + \beta_1 aedu + \beta_2 edad + \beta_3 edad^2 + \beta_4 \underbrace{hombre}_{=1} \\
 &\quad - \beta_0 - \beta_1 aedu - \beta_2 edad - \beta_3 edad^2 - \beta_4 \underbrace{hombre}_{=0} \\
 &= \beta_4
 \end{aligned}$$

los hombres trabajan **en promedio** β_4 horas más (o menos) que las mujeres, **ceteris paribus**

Distintas especificaciones

- Formas funcionales del modelo:

Model	Dependent Variable	Independent Variable	Interpretation of β_1
level-level	y	x	$\Delta y = \beta_1 \Delta x$
level-log	y	$\log(x)$	$\Delta y = (\beta_1/100)\% \Delta x$
log-level	$\log(y)$	x	$\% \Delta y = (100\beta_1) \Delta x$
log-log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$

Fuente: Wooldridge (2006).

Ejemplo 1

- Supongamos el siguiente modelo:

$$hrstrt = \beta_0 + \beta_1 aedu + \beta_2 edad + \beta_3 edad^2 + \beta_4 hombre + \beta_5 pampeana + \beta_6 cuyo + \beta_7 noa + \beta_8 patagonia + \beta_9 nea + \mu$$

donde *hrstrt* es la cantidad de horas trabajadas, *aedu* es la cantidad de años de educación formal, *edad* es la edad en años del individuo, *hombre* indica si el individuo es hombre, *pampeana*, *cuyo*, *noa*, *patagonia* y *nea* son *dummies* que indican la región de residencia. Gba es la categoría omitida.

- ¿Por qué no está *GBA* en la regresión?

```
. regress hstrt aedu edad edad2 hombre pampa cuyo noa pata nea
```

Source	SS	df	MS	Number of obs	=	52,640
				F(9, 52630)	=	2257.00
Model	3193039.97	9	354782.219	Prob > F	=	0.0000
Residual	8273010.62	52,630	157.191918	R-squared	=	0.2785
				Adj R-squared	=	0.2784
Total	11466050.6	52,639	217.824248	Root MSE	=	12.538

hstrt	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
aedu	-1.299379	.0268576	-48.38	0.000	-1.35202	-1.246738
edad	1.614118	.0182544	88.42	0.000	1.578339	1.649897
edad2	9.34e-37	5.11e-38	18.27	0.000	8.34e-37	1.03e-36
hombre	3.94599	.1096284	35.99	0.000	3.731117	4.160862
pampa	-1.102824	.1690833	-6.52	0.000	-1.434229	-.7714192
cuyo	-1.048271	.2173725	-4.82	0.000	-1.474323	-.6222187
noa	-1.488385	.1743227	-8.54	0.000	-1.83006	-1.146711
pata	-.9203688	.2021129	-4.55	0.000	-1.316512	-.5242257
nea	-2.007613	.2157175	-9.31	0.000	-2.430421	-1.584805
_cons	-8.591361	.1762867	-48.74	0.000	-8.936885	-8.245838

Fuente: Encuesta Permanente de Hogares, semestre I, 2015.

Ejemplo 2

- Consideremos ahora:

$$lwage = \beta_0 + \beta_1 aedu + \beta_2 edad + \beta_3 edad^2 + \beta_4 hombre + \beta_5 pampeana + \beta_6 cuyo + \beta_7 noa + \beta_8 patagonia + \beta_9 nea + \mu$$

donde *lwage* es el logaritmo del salario horario, *aedu* es la cantidad de años de educación formal, *edad* es la edad en años del individuo, *hombre* indica si el individuo es hombre, *pampeana*, *cuyo*, *noa*, *patagonia* y *nea* son *dummies* que indican la región de residencia.

```
. regress lwage aedu edad edad2 hombre pampa cuyo noa pata nea
```

Source	SS	df	MS	Number of obs	=	7,394
				F(9, 7384)	=	217.38
Model	709.479078	9	78.8310086	Prob > F	=	0.0000
Residual	2677.71096	7,384	.362636912	R-squared	=	0.2095
				Adj R-squared	=	0.2085
Total	3387.19004	7,393	.458161779	Root MSE	=	.60219

lwage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
aedu	.0620636	.0026721	23.23	0.000	.0568255	.0673016
edad	.031612	.0033647	9.40	0.000	.0250162	.0382078
edad2	8.60e-40	3.78e-39	0.23	0.820	-6.55e-39	8.27e-39
hombre	.1290003	.0152681	8.45	0.000	.0990704	.1589302
pampa	-.0348356	.0205099	-1.70	0.089	-.0750408	.0053696
cuyo	-.2700147	.0272211	-9.92	0.000	-.3233758	-.2166536
noa	-.455294	.0220835	-20.62	0.000	-.498584	-.412004
pata	.2318312	.0256452	9.04	0.000	.1815593	.2821031
nea	-.3986235	.02867	-13.90	0.000	-.4548249	-.3424221
_cons	2.004	.0763382	26.25	0.000	1.854356	2.153645

Fuente: Encuesta Permanente de Hogares, semestre I, 2015.

¿Qué pasa con las *dummies* en un modelo log-lin?

$$E[\ln(wage) \mid hombre = 1] - E[\ln(wage) \mid hombre = 0]$$

$$\ln(wage)^H - \ln(wage)^M = \beta_4$$

$$\ln\left(\frac{wage^H}{wage^M}\right) = \beta_4$$

$$\frac{wage^H}{wage^M} = e^{\beta_4}$$

$$\frac{wage^H - wage^M}{wage^M} = e^{\beta_4} - 1$$

- Cuando el modelo es semi logaritmico (log-lin), cuidado con las *dummies*!
- Si $\beta_4 < 0,2 \rightarrow \beta_4 \neq e^{\beta_4} - 1$

Ejemplo 3

- Consideremos ahora:

$$lwage = \beta_0 + \beta_1 laedu + \beta_2 edad + \beta_3 edad^2 + \beta_4 hombre + \beta_5 pampeana + \beta_6 cuyo + \beta_7 noa + \beta_8 patagonia + \beta_9 nea + \mu$$

donde *lwage* es el logaritmo del salario horario, *laedu* es el logaritmo de la cantidad de años de educación formal, *edad* es la edad en años del individuo, *hombre* indica si el individuo es hombre, *pampeana*, *cuyo*, *noa*, *patagonia* y *nea* son *dummies* que indican la región de residencia.

```
. regress lwage laedu edad edad2 hombre pampa cuyo noa pata nea
```

Source	SS	df	MS	Number of obs	=	7,391
				F(9, 7381)	=	203.66
Model	673.033092	9	74.7814547	Prob > F	=	0.0000
Residual	2710.15067	7,381	.367179335	R-squared	=	0.1989
				Adj R-squared	=	0.1980
Total	3383.18376	7,390	.457805651	Root MSE	=	.60595

lwage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
laedu	.5296275	.0253634	20.88	0.000	.479908	.579347
edad	.0354316	.0033638	10.53	0.000	.0288376	.0420256
edad2	1.03e-39	3.81e-39	0.27	0.786	-6.43e-39	8.50e-39
hombre	.1116656	.0152779	7.31	0.000	.0817166	.1416146
pampa	-.0305349	.0206473	-1.48	0.139	-.0710096	.0099398
cuyo	-.2730815	.0273929	-9.97	0.000	-.3267793	-.2193836
noa	-.4590843	.0222244	-20.66	0.000	-.5026504	-.4155182
pata	.2225578	.025795	8.63	0.000	.1719923	.2731234
nea	-.4015015	.0288507	-13.92	0.000	-.458057	-.3449459
_cons	1.365876	.0891053	15.33	0.000	1.191204	1.540548

Fuente: Encuesta Permanente de Hogares, semestre I, 2015.

Inferencia

- Se puede testear la significatividad individual de una variable.
Supongamos que queremos evaluar la significatividad de *aedu*:

$$H_0 : \beta_1 = 0$$

$$H_a : \beta_1 \neq 0$$

- ¿Cómo lo hacemos en la salida de regresión?
 - Intervalos de confianza
 - p-valor
 - Comparando el estadístico t observado con el crítico
- test *aedu*

```
. regress lwage aedu edad edad2 hombre pampa cuyo noa pata nea
```

Source	SS	df	MS	Number of obs	=	7,394
				F(9, 7384)	=	217.38
Model	709.479078	9	78.8310086	Prob > F	=	0.0000
Residual	2677.71096	7,384	.362636912	R-squared	=	0.2095
				Adj R-squared	=	0.2085
Total	3387.19004	7,393	.458161779	Root MSE	=	.60219

lwage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
aedu	.0620636	.0026721	23.23	0.000	.0568255	.0673016
edad	.031612	.0033647	9.40	0.000	.0250162	.0382078
edad2	8.60e-40	3.78e-39	0.23	0.820	-6.55e-39	8.27e-39
hombre	.1290003	.0152681	8.45	0.000	.0990704	.1589302
pampa	-.0348356	.0205099	-1.70	0.089	-.0750408	.0053696
cuyo	-.2700147	.0272211	-9.92	0.000	-.3233758	-.2166536
noa	-.455294	.0220835	-20.62	0.000	-.498584	-.412004
pata	.2318312	.0256452	9.04	0.000	.1815593	.2821031
nea	-.3986235	.02867	-13.90	0.000	-.4548249	-.3424221
_cons	2.004	.0763382	26.25	0.000	1.854356	2.153645

Fuente: Encuesta Permanente de Hogares, semestre I, 2015.

- Se puede testear la significatividad global de las variables del modelo. En este caso, querríamos testear:

$$H_0 : \beta_1 = 0 \wedge \beta_2 = 0 \wedge \dots \wedge \beta_9 = 0$$

$$H_a : \beta_1 \neq 0 \vee \beta_2 \neq 0 \vee \dots \vee \beta_9 \neq 0$$

- En Stata
 - miramos en la parte superior derecha de la regresión
 - usamos `test aedu edad edad2 hombre pampa cuyo noa pata nea`

- Se puede testear la significatividad de un conjunto de variables del modelo. Si quisiéramos saber, por ejemplo, si la edad es una variable significativa para explicar el salario:

$$H_0 : \beta_2 = 0 \wedge \beta_3 = 0$$

$$H_a : \beta_2 \neq 0 \vee \beta_3 \neq 0$$

- En **Stata** usamos `test edad edad2`

Extensión `xi` y el comando `regress`

- `xi` es una extensión que admite el comando `regress`
- La misma permite aplicar opciones que son muy prácticas:
 - Usar dummies desde una variable categórica.
 - Usar dummies e interacciones de variables.

Outreg2

- Stata permite agregar comandos que son diseñados por otros usuarios (ado-files).
- Uno de ellos es el comando `outreg2`, que permite exportar resultados de las regresiones a una hoja de excel.
- La forma de incorporar estos comandos a Stata es copiando los ado-files a una carpeta particular.
- Una opción es instalarlo mediante el comando `ssc install`

Export excel

- Una opción muy útil es la que ofrece el comando `export excel`
- Permite exportar a excel la base de datos que tenemos en Stata.
 - Exportar tablas;
 - Exportar matrices;
 - etc.
- La sintaxis es `"export excel using ejemplo.xlsx , sheet("Hoja1") cell("B7") sheetmodify"`

Econometría para datos en panel en Stata

Jessica Bracco

Econometría Avanzada
Maestría en Economía - FCE- UNLP

Agosto, 2019

Modelo de regresión lineal

- Modelo lineal visto en clase:

$$y_{it} = x'_{it}\beta + u_{it}$$

$$u_{it} = \mu_i + \delta_t + \epsilon_{it}$$

donde $i = 1, \dots, n$; $t = 1, \dots, T$ y x_{it} es un vector de K regresores (incluyendo una constante).

- El error u_{it} se descompone en tres fuentes (aditivas) de variabilidad no observable.
- Al igual que en clase, supondremos $\delta_t = 0$ y que ϵ_{it} cumple con todos los supuestos clásicos.

Estructura de panel

- Un panel es un seguimiento de unidades de corte transversal (i) a lo largo del tiempo (t).
- Las unidades pueden ser personas, empresas, provincias, países, clases, etc.
- La econometría para datos en paneles trata de aprovechar esta dimensionalidad en los datos.

Estimación por Mínimos Cuadrados Ordinarios

- Supongamos que $\mu_i = 0$
- Por lo tanto se cumplen todos los supuestos clásicos y MCO es MELI (POLS)
- El comando regress funcionaría adecuadamente en esta situación hipotética

- Otra especificación que arroja estimaciones consistentes (bajo el supuesto anterior) es la **transformación between**:

$$\bar{y}_i = \bar{x}_i' \beta + \bar{\epsilon}_{it}$$

donde $\bar{h}_i = T^{-1} \sum_{t=1}^T h_{it}$, con $h = y, x, \epsilon$.

- En **Stata** es simple implementarla:
 - Comando **regress** (del modelo transformado)
 - Comando **xtreg**, con la opción **be**

Efectos fijos

- Modelo lineal

$$y_{it} = x'_{it}\beta + \mu_i + \epsilon_{it}$$

- Notar que puede interpretarse como un modelo lineal donde cada individuo i tiene su propia ordenada al origen:

$$y_{it} = \underbrace{\beta_1 + \mu_i}_{\text{ordenada al origen}} + \beta_2 x_{2,it} + \dots + \beta_k x_{k,it} + \epsilon_{it}$$

- Equivale a incluir una *dummy* por cada individuo.

- En términos matriciales:

$$Y = X\beta + D\mu + \epsilon$$

donde D es una matriz de N-1 variables binarias.

- $\hat{\beta}_{EF}$ se obtiene estimando esta especificación por MCO.

- Incluir N-1 *dummies* puede ser costoso computacionalmente.
- Por ello, una forma equivalente de obtener $\hat{\beta}_{EF}$ es estimar mediante MCO a la **transformación within**

$$y_{it} - \bar{y}_i = (x_{it} - \bar{x}_i)' \beta + (\epsilon_{it} - \bar{\epsilon})$$

$$\tilde{y}_{it} = \tilde{x}_{it}' \beta + \tilde{\epsilon}$$

donde $\tilde{h}_{it} = h_{it} - \bar{h}_i$, con $h = y, x, \epsilon$.

- En **Stata**, todas estas alternativas pueden ser implementadas usando:
 - **regress** (con el modelo transformado)
 - **xtreg**, con la opción **fe**.

Efectos aleatorios

Otra vez, el modelo lineal es:

$$y_{it} = x'_{it}\beta + \underbrace{\mu_i + \epsilon_{it}}_{\nu_{it}}$$

Diferencia en el tratamiento de μ_i

- Sigue siendo inobservable
- En lugar de ser fijo lo suponemos aleatorio

En términos matriciales el modelo es

$$Y = X\beta + \underbrace{D\mu + \epsilon}_{\nu}$$

- Esto induce una estructura de autocorrelación en el término

$$\nu_i = \mu_i + \epsilon_{it}$$

- Plantear el modelo de efectos aleatorios (EA) como un estimador de MCG:

$$\hat{\beta}_{EA} = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}Y$$

donde Ω es la varianza del término de error ν , tal que $\Omega(\sigma_\mu^2, \sigma_\epsilon^2)$

- Dado que σ_μ^2 y σ_ϵ^2 son parámetros desconocidos, deben estimarse.
- Por lo tanto, el estimador de EA es un estimador de MCG factible (MCGF)
- En Stata, esto puede ser implementado mediante la opción `re` del comando `xtreg`.

Ejercicio empírico

Vamos a ver un ejemplo en el trabajo de Cornwell y Trumbull (1994)

- Estiman un modelo de crimen, en el que la unidad de panel es el condado.
- La disponibilidad de datos en panel permite controlar por características específicas e inobservables a nivel condado que podrían estar correlacionadas con las variables de justicia en el modelo.
- En general, no condicionar por estas características inobservables resultará en estimadores inconsistentes de los coeficientes de estas variables.

Estructura de panel. Stata

- En esta clase vamos a utilizar la base de datos cornwell.dta
- Veamos algunos comandos...

	Between	Within	2SLS (fixed effects)	2SLS (no fixed effects)
CONSTANT	-2.097 (2.822)			-3.719 (8.189)
P_A	-0.648 (0.088)	-0.355 (0.032)	-0.455 (0.618)	-0.507 (0.251)
P_C	-0.528 (0.067)	-0.282 (0.021)	-0.336 (0.371)	-0.530 (0.110)
P_P	0.297 (0.231)	-0.173 (0.032)	-0.196 (0.200)	0.200 (0.343)
S	-0.236 (0.174)	-0.00245 (0.02612)	-0.0298 (0.0300)	-0.218 (0.185)
<i>POLICE</i>	0.364 (0.060)	0.413 (0.027)	0.504 (0.617)	0.419 (0.218)
<i>DENSITY</i>	0.168 (0.077)	0.414 (0.283)	0.291 (0.785)	0.226 (0.103)
<i>PERCENT</i> <i>YOUNG MALE</i>	-0.0951 (0.1576)	0.627 (0.364)	0.888 (0.139)	-0.145 (0.336)
<i>WCON</i>	0.195 (0.210)	-0.0378 (0.0391)	-0.0358 (0.0467)	0.329 (0.279)
<i>WTUC</i>	-0.196 (0.170)	0.0455 (0.0190)	0.0398 (0.0282)	-0.197 (0.197)
<i>WTRD</i>	0.129 (0.278)	-0.0205 (0.0405)	-0.0196 (0.0426)	0.0293 (0.3240)
<i>WFIR</i>	0.113 (0.220)	-0.00390 (0.02806)	-0.00700 (0.03270)	0.0506 (0.3224)

	Between	Within	2SLS (fixed effects)	2SLS (no fixed effects)
CONSTANT	-2.097 (2.822)			-3.719 (8.189)
P_A	-0.648 (0.088)	-0.355 (0.032)	-0.455 (0.618)	-0.507 (0.251)
P_C	-0.528 (0.067)	-0.282 (0.021)	-0.336 (0.371)	-0.530 (0.110)
P_P	0.297 (0.231)	-0.173 (0.032)	-0.196 (0.200)	0.200 (0.343)
S	-0.236 (0.174)	-0.00245 (0.02612)	-0.0298 (0.0300)	-0.218 (0.185)
$POLICE$	0.364 (0.060)	0.413 (0.027)	0.504 (0.617)	0.419 (0.218)
$DENSITY$	0.168 (0.077)	0.414 (0.283)	0.291 (0.785)	0.226 (0.103)

Fuente: Cornwell y Trumbull (1994).