

Modelos para datos en panel

Mariana Marchionni
marchionni.mariana@gmail.com

Econometría Avanzada
Maestría en Economía - FCE - UNLP

Temario de la clase

- 1 Los datos en panel
- 2 Estimador de efectos fijos
- 3 Estimador de efectos aleatorios

Datos en panel

- Una base de datos en panel contiene información para varios individuos (empresas, países, etc.) a lo largo del tiempo.
- Rasgo fundamental: los datos tienen *dos dimensiones*
 - corte transversal: muestra de N individuos en cada $t = 1, \dots, T$.
 - corte longitudinal: series de T periodos para cada $i = 1, \dots, N$.

Ejemplo

para cada año $t = 1, \dots, 4$ tenemos un corte transversal $i = 1, \dots, 3$

Total de observaciones $N \times T = 3 \times 4$

i	t	edad	sexo	nivel_edu	trabaja
1	2005	15	1	seci	0
2	2005	23	2	supi	0
3	2005	42	2	secc	1
1	2006	16	1	seci	0
2	2006	24	2	supi	1
3	2006	43	2	secc	0
1	2007	17	1	seci	0
2	2007	25	2	supc	1
3	2007	44	2	secc	1
1	2008	18	1	secc	0
2	2008	26	2	supc	1
3	2008	45	2	secc	0

Ejemplo

Mismos datos pero ordenados distinto: individuos apilados previamente ordenados en el tiempo.

Para cada $i = 1, \dots, 3$ tenemos una serie de tiempo con $T = 4$ obs.

i	t	edad	sexo	nivel_edu	trabaja
1	2005	15	1	seci	0
1	2006	16	1	seci	0
1	2007	17	1	seci	0
1	2008	18	1	secc	0
2	2005	23	2	supi	0
2	2006	24	2	supi	1
2	2007	25	2	supc	1
2	2008	26	2	supc	1
3	2005	42	2	secc	1
3	2006	43	2	secc	0
3	2007	44	2	secc	1
3	2008	45	2	secc	0

Paneles en el mundo

- En Estados Unidos: *Panel Study of Income Dynamics (PSID)* desde 1968. Empezó con 4.800 familias y ahora supera las 9.000. Información sobre 70.000 individuos a lo largo de 4 décadas.
Otro ejemplo para USA: *National Longitudinal Survey of Youth (NLSY)*, ej. en el TP)
- Algunos paneles en América Latina:
 - Chile: CASEN 2006-2009
 - Perú: panel ENAHO, 5 años consecutivos desde 2007
 - Algunas encuestas de hogares tienen estructura de paneles rotativos (por ej. EPH en Argentina).

¿Por qué paneles?

Cornwell y Trumbull (C&T, 1994, Rev Econ Stat): determinantes de la tasa de criminalidad.

- La Economía del Crimen (Becker y otros) supone que los individuos deciden si participar o no de actividades delictivas en función de los beneficios y costos esperados.
- Se consideran los beneficios monetarios y los costos dependen de la eficacia de la justicia penal (probabilidad de arresto, severidad de las penas, etc.).
- La teoría predice efectos negativos de la eficacia de la justicia sobre la tasa de criminalidad. Determinar la magnitud de los efectos requiere de un análisis empírico.

¿Por qué paneles?

- Hasta C&T la evidencia provenía de estimaciones MCO basadas en información cross-section para distintas jurisdicciones (por ej. provincias). Los efectos estimados eran muy grandes.
- Crítica de C&T: esos resultados sobreestiman el verdadero efecto de la justicia penal ya que no logran controlar por diferencias inobservables entre jurisdicciones.
- En jerga econométrica: hay variables omitidas que están correlacionada con la justicia penal $\implies$ sesgo e inconsistencia de los estimadores MCO.

¿Por qué paneles?

- Ejemplo:
 - 2 jurisdicciones A y B idénticas, pero en A la policía registra la mitad de los delitos denunciados mientras en B se registran todos.
 - Entonces, la tasa de crimen en A resulta menor y la probabilidad de arresto mayor que en B.
 - Si este patrón de sub-registro de delitos se repite en la muestra, los estimadores MCO sobreestimarán el efecto disuasivo de la probabilidad de arresto sobre la tasa de criminalidad.
- ¿Solución? “controlar” por esta variable omitida.
- ¿Y si es inobservable? → paneles.

Ventajas de los paneles

- Permiten controlar *heterogeneidades no observables* $\Rightarrow$ evitan sesgos
- Permiten mayor eficiencia en la estimación
Con N individuos y T observaciones temporales de cada uno podríamos estimar
 - N modelos de series de tiempo
 - T modelos de corte transversal
 - Un único modelo usando las $N \times T$ observaciones del panel (*pooled data*) $\Rightarrow$ mayor eficiencia.

Otras ventajas de los paneles

- **Permiten estudiar la dinámica de los efectos de interés.**

Por ejemplo, al observar los mismos individuos/hogares a lo largo del tiempo, puede estudiarse si un shock sobre los ingresos tiene efectos permanentes o transitorios (Sosa-Escudero, Marchionni & Arias, 2011).

Otras ventajas de los paneles

- **Permiten identificar transiciones que no sería posible con otro tipo de datos.**

Por ejemplo, la observación de “la tasa de participación laboral entre las mujeres es del 50 %” es compatible con dos realidades muy distintas:

- (a) que cada mujer tiene una probabilidad de 50 % de ser económicamente activa en cada periodo (alta rotación entre la actividad y la inactividad) o
- (b) la mitad de las mujeres siempre está inactiva y la otra mitad siempre trabajando o buscando trabajo (persistencia total de la condición de actividad).
- Solo con paneles podemos distinguir entre las dos situaciones.
- Ver Cap. 1 de Baltagi 2008 para más ejemplos.

Desventajas de los paneles

- No siempre es posible agregar información temporal y de corte transversal (cambios estructurales, poblaciones muy heterogéneas)
- Administrativamente: los paneles son muy costosos e implican una logística compleja.
- Problemas de muestreo: auto-selección, *attrition*.
- Dimensión temporal breve (T chico).

El modelo básico de componente de errores

Para una observación cross-section i , tenemos el modelo

$$y_{it} = x'_{it}\beta + u_{it} \quad i = 1, \dots, N; \quad t = 1, \dots, T$$

$$\text{con } u_{it} = \mu_i + \varepsilon_{it}$$

- x_{it} : vector $K \times 1$ de variables explicativas (incluye constante).
- β : vector $K \times 1$ de parámetros de interés.
- u_{it} : término aleatorio del modelo con dos componentes:
 - μ_i : efecto inobservable específico del individuo (firma, familia, escuela, provincia, etc.). Distintos nombres: heterogeneidad inobservable, componente inobservable, efecto individual, etc.
 - ε_{it} : error idiosincrático de cada observación it . En general, vamos a suponer que satisface los supuestos clásicos.
 - Un caso más general agrega otro componente que cambia solo en el tiempo (δ_t). No lo veremos.

El caso más simple: sin heterogeneidad inobservable ($\mu_i = 0$)

El modelo se simplifica: $y_{it} = x'_{it}\beta + \varepsilon_{it}$

- Podemos estimarlo por MCO usando las $N \times T$ observaciones (*pooled data*): **pooled OLS (POLS)**
- POLS es consistente si (1) $E[x'_{it}.u_{it}] = 0 \rightarrow$ **exogeneidad contemporánea** en términos de correlaciones. Cuando $\mu_i = 0$, la condición suficiente para (1) es (2) $E[x'_{it}.\varepsilon_{it}] = 0$
- Para insesgamiento de POLS se requiere un supuesto algo más fuerte: (1') $E[u_{it}|x_{it}] = 0 \rightarrow$ **exogeneidad contemporánea en medias**, que también implica (1).
- Importante: ni (1) ni (1') imponen ortogonalidad entre x_{is} y u_{it} (o ε_{it}) para $s \neq t$.
- La estructura de panel no cambia la forma de estimar $\beta \Rightarrow$ lo que motiva buscar otro estimador es la presencia de μ_i .

Si hay heterogeneidad inobservable

El término de error ahora tiene dos componentes: $u_{it} = \mu_i + \varepsilon_{it}$

- Ya no alcanza con suponer (2) $E[x'_{it} \cdot \varepsilon_{it}] = 0$. Para consistencia de POLS también se requiere que (3) $E[x'_{it} \cdot \mu_i] = 0$, es decir, que la heterogeneidad inobservable sea ortogonal a todos los elementos de x_{it} .
- Si se cumplen (2) y (3) POLS es consistente pero tenemos que ocuparnos de otros problemas...veamos

Si hay heterogeneidad inobservable

- Aunque cada uno de los dos componente del término de error (μ_i y ε_{it}) cumpliera los supuestos clásicos (exogeneidad, homocedasticidad, no autocorrelación) y además fueran ortogonales entre sí, el error compuesto $u_{it} = \mu_i + \varepsilon_{it}$ sufre de autocorrelación para cada i en el tiempo.
- Intuición: notar que $u_{it} = \mu_i + \varepsilon_{it}$, mientras que $u_{it-1} = \mu_i + \varepsilon_{it-1}$: u_{it} comparte el mismo μ_i en distintos momentos del tiempo $\Rightarrow$ es necesario recurrir al estimador robusto de la matriz de varianzas y covarianzas de $\hat{\beta}_{POLS}$.

Si hay heterogeneidad inobservable

En resumen:

- Si se satisfacen los supuestos (2) y (3) (las x_{it} son exógenas respecto de ambos componentes del término de error), POLS es consistente pero para inferencia se requieren estimadores robustos a autocorrelación.
- Si (3) no se cumple, POLS es sesgado e inconsistente → los paneles pueden contribuir a solucionar el problema

Antes de avanzar veamos algo de notación matricial...

Si hay heterogeneidad inobservable

En resumen:

- Si se satisfacen los supuestos (2) y (3) (las x_{it} son exógenas respecto de ambos componentes del término de error), POLS es consistente pero para inferencia se requieren estimadores robustos a autocorrelación.
- Si (3) no se cumple, POLS es sesgado e inconsistente → los paneles pueden contribuir a solucionar el problema

Antes de avanzar veamos algo de notación matricial...

Notación matricial para paneles

Si apilamos las observaciones de cada uno de los N individuos, previamente ordenadas en el tiempo, tenemos:

		$Y_{NT \times 1}$	$X_{NT \times K}$	
i	t	y	cons.	x
1	1	$y_{1,1}$	1	$x_{1,1}$
1	2	$y_{1,2}$	1	$x_{1,2}$
1	3	$y_{1,3}$	1	$x_{1,3}$
2	1	$y_{2,1}$	1	$x_{2,1}$
2	2	$y_{2,2}$	1	$x_{2,2}$
2	3	$y_{2,3}$	1	$x_{2,3}$
...	...	...	...	...
N-1	1	$y_{N-1,1}$	1	$x_{N-1,1}$
N-1	2	$y_{N-1,2}$	1	$x_{N-1,2}$
N-1	3	$y_{N-1,3}$	1	$x_{N-1,3}$
N	1	$y_{N,1}$	1	$x_{N,1}$
N	2	$y_{N,2}$	1	$x_{N,2}$
N	3	$y_{N,3}$	1	$x_{N,3}$

Notación matricial para paneles

Entonces podemos escribir el modelo como:

$$Y = X\beta + u$$

con $Y_{NT \times 1}$, $X_{NT \times K}$ y $u_{NT \times 1}$.

- El estimador POLS es el MCO usando las $N \times T$ observaciones (pool data), entonces:

$$\hat{\beta}_{POLS} = (X'X)^{-1}X'Y$$

- Cuando no hay heterogeneidad inobservable el vector $u_{NT \times 1}$ satisface todos los supuestos clásicos $\Rightarrow \hat{\beta}_{POLS}$ es MELI.
- Entonces, lo que justifica buscar métodos de estimación alternativos es la presencia de heterogeneidad inobservable.

Modelo de efectos fijos

- Supongamos que μ_i es un **valor fijo** en el tiempo:

$$y_{it} = x'_{it}\beta + \mu_i + \varepsilon_{it}$$

- Notar: puede interpretarse como un modelo lineal donde cada individuo i tiene su propia ordenada al origen:

$$y_{it} = \underbrace{\beta_1 + \mu_i}_{\text{ordenada al origen}} + \beta_2 x_{2,it} + \dots + \beta_K x_{K,it} + \varepsilon_{it}$$

- Equivale a incluir una *dummy* por cada individuo ($N - 1$ para evitar multicolinealidad perfecta con la constante).
- Importante: las μ_i pasaron a ser parámetros a estimar.

Las variables *dummy* por individuo en la base de datos

		$X_{NT \times K}$		$D_{NT \times (N-1)}$			
i	t	cons.	x	d1	d2	...	dN-1
1	1	1	$x_{1,1}$	1	0	0	0
1	2	1	$x_{1,2}$	1	0	0	0
1	3	1	$x_{1,3}$	1	0	0	0
2	1	1	$x_{2,1}$	0	1	0	0
2	2	1	$x_{2,2}$	0	1	0	0
2	3	1	$x_{2,3}$	0	1	0	0
...	...	...	...	...	...	...	...
N-1	1	1	$x_{N-1,1}$	0	0	0	1
N-1	2	1	$x_{N-1,2}$	0	0	0	1
N-1	3	1	$x_{N-1,3}$	0	0	0	1
N	1	1	$x_{N,1}$	0	0	0	0
N	2	1	$x_{N,2}$	0	0	0	0
N	3	1	$x_{N,3}$	0	0	0	0

Modelo de efectos fijos

En notación matricial

$$Y = X\beta + D\mu + \varepsilon$$

D es una matriz $(N \times T) \times (N - 1)$, donde:

- En las $N \times T$ filas están las observaciones apiladas por individuo, previamente ordenadas en el tiempo.
- En las columnas, las $N - 1$ variables binarias, una por cada individuo menos el “individuo base”.

$$D_{NT \times (N-1)} = \begin{bmatrix} 1_T & 0 & \cdots & 0 \\ 0 & 1_T & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1_T \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad \text{con} \quad 1_T = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

$$\Rightarrow D\mu = \begin{bmatrix} \mu_{1,T} & 0 & \cdots & 0 \\ 0 & \mu_{2,T} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \mu_{N-1,T} \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad \text{con} \quad \mu_{i,T} = \begin{bmatrix} \mu_i \\ \mu_i \\ \vdots \\ \mu_i \end{bmatrix}$$

Estimador de efectos fijos (EF)

Entonces, el modelo de efectos fijos con dummies viene dado por:

$$Y = X\beta + D\mu + \varepsilon = \tilde{X}\theta + \varepsilon$$

donde $\tilde{X} = [X \ D]$ y $\theta = \begin{bmatrix} \beta \\ \mu \end{bmatrix}$.

El estimador de efectos fijos (EF) viene dado por:

$$\hat{\theta}_{EF} = \begin{bmatrix} \hat{\beta}_{EF} \\ \hat{\mu}_{EF} \end{bmatrix} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y$$

El estimador EF es el estimador de MCO del modelo con variables *dummy* por individuo.

Estimador de efectos fijos (EF)

Entonces, el modelo de efectos fijos con dummies viene dado por:

$$Y = X\beta + D\mu + \varepsilon = \tilde{X}\theta + \varepsilon$$

donde $\tilde{X} = [X \ D]$ y $\theta = \begin{bmatrix} \beta \\ \mu \end{bmatrix}$.

El estimador de efectos fijos (EF) viene dado por:

$$\hat{\theta}_{EF} = \begin{bmatrix} \hat{\beta}_{EF} \\ \hat{\mu}_{EF} \end{bmatrix} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y$$

El estimador EF es el estimador de MCO del modelo con variables *dummy* por individuo.

Transformación *within*

El estimador de EF con dummies exige invertir la matriz $(\tilde{X}'\tilde{X})$ de dimensión $(N-1+K)$. Es enorme! Veamos otra opción...

- Partiendo del modelo con efectos fijos

$$y_{it} = x'_{it}\beta + \mu_i + \varepsilon_{it}$$

- Calculemos el promedio para cada i a lo largo de los T periodos (**modelo *Between***):

$$\bar{y}_i = \bar{x}'_i\beta + \mu_i + \bar{\varepsilon}_i$$

- Restando del modelo original, se obtiene el **modelo *Within***:

$$\begin{aligned} \underbrace{y_{it} - \bar{y}_i}_{y_{it}^*} &= \underbrace{(x'_{it} - \bar{x}'_i)}_{x_{it}^{*'}} \beta + \underbrace{(\varepsilon_{it} - \bar{\varepsilon}_i)}_{\varepsilon_{it}^*} \\ y_{it}^* &= x_{it}^{*'} \beta + \varepsilon_{it}^* \end{aligned}$$

Notar que en el modelo *within*

$$y_{it}^* = x_{it}^{*'} \beta + \varepsilon_{it}^*$$

- Las variables están expresadas en desvíos: capturan variaciones en el tiempo para cada individuo (*within* individuo).
- El vector de coeficientes β del modelo Within permite responder cómo la variabilidad de las x en el tiempo para cada individuo explica la variabilidad de y
- *Importante*: hemos eliminado el componente μ_i , heterogeneidad inobservable y fuente potencial de sesgo.
- También hemos eliminado cualquier otro componente de x constante en el tiempo (ej. ordenada al origen): el modelo *within* no permite estimar el efecto de variables constantes en el tiempo (el modelo con dummies tampoco!).

Resultado:

- Regresar y_{it}^* en x_{it}^* por MCO es *matemáticamente equivalente* a obtener $\hat{\beta}_{EF}$ a partir del modelo con dummies por individuo.
- En forma matricial:

$$\hat{\beta}_{EF} = (X^{*'} X^*)^{-1} X^{*'} Y^*$$

Existen 2 formas idénticas de computar $\hat{\beta}_{EF}$:

- Regresar por MCO y en x y en las variables binarias por individuo. $\hat{\beta}_{EF}$ son los coeficientes estimados para las x .
- En 2 pasos:
 - 1 expresar las variables en desvíos respecto a la media por individuo
 - 2 regresar las variables en desvíos.

Resultado:

- Regresar y_{it}^* en x_{it}^* por MCO es *matemáticamente equivalente* a obtener $\hat{\beta}_{EF}$ a partir del modelo con dummies por individuo.
- En forma matricial:


$$\hat{\beta}_{EF} = (X^{*'} X^*)^{-1} X^{*'} Y^*$$

Existen 2 formas idénticas de computar $\hat{\beta}_{EF}$:

- Regresar por MCO y en x y en las variables binarias por individuo. $\hat{\beta}_{EF}$ son los coeficientes estimados para las x .
- En 2 pasos:
 - 1 expresar las variables en desvíos respecto a la media por individuo
 - 2 regresar las variables en desvíos.


Un ejemplo gráfico de EF (C&T)

y: tasa de criminalidad, x: ineficiencia de la justicia penal (ej. % de delincuentes que se escapan)




Un ejemplo gráfico de EF (C&T)

y: tasa de criminalidad, x: ineficiencia de la justicia penal (ej. % de delincuentes que se escapan)




Un ejemplo gráfico de EF (C&T)

MCO de y en x con pooled data: $\hat{\beta}_{POLS}$ es sesgado e inconsistente si la het. inobservable está correlacionada con x



Un ejemplo gráfico de EF (C&T)

Corregimos el sesgo agregando dummies por región
(estimador de EF)



Propiedades del estimador EF

- Se conoce como **modelo en primeras diferencias**. Notar similitud con modelo Within.

$$\Delta y_i = \Delta x_i' \beta + \Delta \varepsilon_i$$

- Consistencia de MCO de Δy en Δx requiere que $E[\Delta x_i' \cdot \Delta \varepsilon_i] = 0$. Con algo de álgebra:

$$E[\Delta x_i' \cdot \Delta \varepsilon_i] = E[x_{i1}' \cdot \varepsilon_{i1}] + E[x_{i2}' \cdot \varepsilon_{i2}] - E[x_{i1}' \cdot \varepsilon_{i2}] - E[x_{i2}' \cdot \varepsilon_{i1}]$$

- Los dos primeros términos son $= 0$ si se cumple **exogeneidad contemporánea** (supuesto 2).
- Para que los últimos dos términos sean nulos necesitamos además que ε_{it} no esté correlacionado con x_{is} para $s \neq t$;
- Esto es **exogeneidad estricta**.

Propiedades del estimador EF

Resumiendo, ¿qué se requiere para consistencia de $\hat{\beta}_{EF}$?

- EF no requiere el supuesto (3) $E[x'_{it} \cdot \mu_i] = 0$ (¿por qué?)
- Pero exogeneidad contemporánea (2) $E[x'_{it} \cdot \varepsilon_{it}] = 0$ ya no alcanza
- Necesitamos un supuesto más fuerte:
(4) $E[x'_{it} \cdot \varepsilon_{it}] = 0 \quad s, t = 1, \dots, T \rightarrow$ **exogeneidad estricta.**
- Si se cumple (4) $\Rightarrow \hat{\beta}_{EF}$ es consistente cuando N o $T \rightarrow \infty$
- Sin embargo, el estimador de los efectos individuales del modelo con dummies ($\hat{\mu}_{EF}$) no es consistente porque el número de parámetros tiende a infinito junto con N .

Otro modelo: efectos aleatorios

El modelo es, en apariencia, el mismo

$$y_{it} = x'_{it}\beta + \underbrace{\mu_i}_{\text{efecto aleatorio}} + \varepsilon_{it}$$

La diferencia es el tratamiento de μ_i :

- sigue siendo inobservable
- pero en lugar de ser fijo lo suponemos *aleatorio*

EF vs. EA

Volviendo a la notación matricial, el modelo con dummies por individuo es:

$$Y = X\beta + D\mu + \varepsilon$$

- EF: trata a D como regresores y a μ como un vector de parámetros a estimar. El término aleatorio es ε

$$Y = X\beta + D\mu + \underbrace{\varepsilon}$$

- EA: trata a $D\mu$ como variables aleatorias omitidas, que quedan incluidas en el término aleatorio del modelo.

$$Y = X\beta + \underbrace{D\mu + \varepsilon}$$

Estimador de EA

$$y_{it} = x'_{it}\beta + \underbrace{\mu_i + \varepsilon_{it}}$$

- Para la consistencia del estimador de EA se requiere
 - exogeneidad estricta (supuesto 4)
 - ortogonalidad entre la heterogeneidad inobservable y los regresores (supuesto 3).
 - Para inferencia y propiedades de eficiencia se necesitan supuestos algo más fuertes (por ej. exogeneidad estricta en términos de medias condicionales).
- Notar que son supuestos similares pero más fuertes que los que se requerían para consistencia de POLS, donde en vez del sup. 4 bastaba con exogeneidad contemporánea (sup. 2).
- ¿Por qué no usar POLS entonces? Veremos que EA permitiría ganar eficiencia.

Estimador de EA

- Suponer que cada componente del error cumple los supuestos clásicos y son ortogonales entre sí:
 - $V(\mu_i) = \sigma_\mu^2$ y $V(\varepsilon_{it}) = \sigma_\varepsilon^2$: homocedasticidad
 - $E[\mu_i \cdot \mu_j] = 0$ $i \neq j$: no correlación entre individuos
 - $E[\varepsilon_{it} \cdot \varepsilon_{js}] = 0$ $i \neq j$ y $t \neq s$: no correlación entre individuos ni en el tiempo
 - $E[\mu_i \cdot \varepsilon_{it}] = 0$: los dos componentes son ortogonales
- Puede mostrarse que el error compuesto $u_{it} = \mu_i + \varepsilon_{it}$
 - Es homocedástico: $V(u_{it}) = \sigma_\mu^2 + \sigma_\varepsilon^2$
 - Pero sufre de autocorrelación para el mismo individuo:
 $E[u_{it} \cdot u_{is}] = \sigma_\mu^2$ para $t \neq s$
- Si bien POLS es consistente no es eficiente
- El estimador más eficiente bajo autocorrelación es el de Mínimos Cuadrados Generalizados (MCG)

Mínimos cuadrados generalizados (MCG)

- Volvamos a la notación matricial

$$Y = X\beta + u$$

- Supongamos que hay exogeneidad estricta y ortogonalidad entre μ_i y los regresores, pero hay autocorrelación del error compuesto:

$$V[u] = \Omega \neq cte. I_{N \times T}$$

- El estimador más eficiente de β es el de Mínimos Cuadrados Generalizados:

$$\hat{\beta}_{MCG} = (X' \Omega^{-1} X)^{-1} X' \Omega^{-1} Y$$

MCG Factibles para efectos aleatorios

En el caso de EA:

$$V[u] = \Omega(\sigma_{\mu}^2, \sigma_{\varepsilon}^2)$$

- $(\sigma_{\mu}^2, \sigma_{\varepsilon}^2)$ son parámetros desconocidos y deben estimarse: Mínimos Cuadrados Generalizados Factibles (MCGF)
- Por lo tanto, el **estimador de EA es un estimador de MCGF.**
- Para estimar $(\sigma_{\mu}^2, \sigma_{\varepsilon}^2)$ se pueden usar los estimadores de la varianza de los residuos de los modelos Within y Between:
 - $y_{it} - \bar{y}_i = (x'_{it} - \bar{x}'_i) \hat{\beta} + \text{residuo} \rightarrow S_W^2$
 - $\bar{y}_i = \bar{x}'_i \hat{\beta} + \text{residuo} \rightarrow S_B^2$
- Y resolver el siguiente sistema $\hat{\sigma}_{\mu}^2 \cong S_W^2$ y $\hat{\sigma}_{\mu}^2 + \frac{1}{T} \hat{\sigma}_{\varepsilon}^2 \cong S_B^2$ (Swamy-Arora)

¿EF o EA?

- Naive pensar que EF considera fija la heterogeneidad inobservable.
- En la Econometría moderna la distinción entre EF y EA se resume en si estamos o no dispuestos a suponer ortogonalidad entre la heterogeneidad inobservable y los regresores.
- En este sentido, EA es sinónimo de ortogonalidad.
- En la Econometría aplicada, EF no se usa como equivalente de “no aleatorio” sino como la relajación de ese supuesto.

¿EF o EA?

$$Y = X\beta + D\mu + \varepsilon$$

- Si X es ortogonal a $D\mu$: MCO, EF, EA son todos consistentes para β . EA es eficiente.
- Si X no es ortogonal a $D\mu$: sólo EF es consistente para β .
- La práctica gravita mayormente en EF.

Test de Hausman

El test de Hausman (1978) se concentra en comparar 2 estimadores:

- un estimador que es siempre consistente
- otro estimador que es consistente solo bajo la H_0
- Intuición: ambos estimadores deberían ser parecidos si H_0 es cierta.

En nuestro caso:

- el estimador EF es siempre consistente
- el estimador EA es consistente sólo si X y $D\mu$ son ortogonales

Test de Hausman

Formalmente:

$$H_0 : X \perp D\mu \quad H_A : X \sim \perp D\mu$$

El estadístico de prueba es:

$$h = (\hat{\beta}_{EA} - \hat{\beta}_{EF})'(\hat{\Omega}_{EF} - \hat{\Omega}_{EA})^{-1}(\hat{\beta}_{EA} - \hat{\beta}_{EF}) \stackrel{H_0}{\sim} \chi^2_{(dim.\beta)}$$

Regla: rechazar H_0 si h es significativamente distinto de cero.

- *Intuición:* bajo H_0 , $\hat{\beta}_{EA}$ y $\hat{\beta}_{EF}$ son consistentes, h debería ser pequeño.
- Permitiría, bajo H_0 , explotar las ganancias de eficiencia de estimar por EA.
- Podemos concentrarnos sólo en algunos parámetros de interés.

Bibliografía

- Libros:

- Baltagi, B. H. 2005. *Econometric Analysis of Panel Data*. 3rd. ed. New York: Wiley. Caps. 1 y 2
- Wooldridge, J. M. 2010. *Econometric Analysis of Cross Section and Panel Data*. 2nd ed. Cambridge, MA: MIT Press. Cap. 10.

- Papers con aplicaciones:

- Cornwell, C. and W.N. Trumbull (1994). "Estimating the Economic Model of Crime with Panel Data". *The Review of Economics and Statistics*, Vol. 76, No. 2, pp. 360-366.
- Rockoff, J. (2004) "The Impact of Individual Teachers on Student Achievement: Evidence from Panel Data" (*American Economic Review*, 94(2), pp. 247-252).
- Sosa Escudero, W.; M. Marchionni, and O. Arias (2011). "Sources of Income Persistence: Evidence from Rural El Salvador". *Journal of Income Distribution*, Volume 20, Number 1, March, pp. 3-28 (ISSN: 1874-6322).