

Variable Dependiente Limitada

Javier Alejo

Maestría en Economía

FCE-UNLP

Agosto 2019

Temario de la clase

- Introducción
- Estimación MV
 - ① Censura
 - ② Truncamiento
 - ③ Y binaria
- Modelo lineal y MCO



Variables aleatorias

- **Discretas:** los valores del soporte pueden ocurrir con probabilidad no nula. Ejemplos: ocupado o desocupado, numero de hijos, etc. (Bernoulli, Poisson, etc.)
- **Continuas:** si bien cada punto del soporte ocurre con probabilidad cero, intervalos del soporte ocurren con probabilidad no nula. Ejemplos: ingresos, llegada a clase, etc. (normal, chi2, etc.)
- **Parcialmente continuas:** ciertos valores pueden ocurrir con probabilidad no nula. Ejemplos: gasto en seguro de vida, re-financiamiento de deuda, ingresos de fuentes tributarias, etc.

¿Por qué?

En Economía es usual trabajar con variables Y cuya carácter continuo ha sido modificado por alguna razón:

- *Razones administrativas*: existe algún mecanismo institucional que altera la información (encuestas de ingresos, datos tributarios, etc.).
- *Soluciones de esquina*: típicas de los modelos de agentes optimizadores (gasto en bienes durables, horas de trabajo, restricciones de capacidad, liquidez, etc.).
- *Resultados cualitativos*: que no necesariamente son medibles en un continuo (estar desocupado, decisión de estudiar, quiebra de un banco, etc.)

Modelo latente para Y^* y tres casos para Y

Vamos considerar el siguiente modelo lineal

$$y_i^* = x_i' \beta + u_i$$

donde y_i^* es una variable latente (inobservable) y en su lugar contaremos con otra variable y_i

Clave: y_i es una versión alterada de y_i^* . Veremos tres casos:

- 1 **Censura:** $y_i = \max(c, y_i^*)$, con c un escalar no aleatorio (cota inferior para y_i^*).
- 2 **Truncamiento:** solo contamos con una submuestra de datos tales que $y_i^* > c$ (nos faltan aquellos que $y_i = c$)
- 3 **Variable binaria:** $y_i = 1$ si $y_i^* > c$ y $y_i = 0$ en $y_i^* \leq c$

Sin pérdida de generalidad, haremos $c = 0$.

Ilustración: variable latente






Ilustración: datos censurados



Importante: x_i es observable tanto para los casos ($y_i = c$) y como para ($y_i > c$)

Ilustración: datos truncados



Importante: x_i solo es observable para los casos ($y_i > c$)


Ilustración: estimación MCO (si observáramos y^*)

Ilustración: estimación MCO, datos censurados




Ilustración: estimación MCO, muestra truncada





Ilustración: estimación MCO, Y binaria

Modelo lineal con errores normales

Modelo lineal:

$$y_i = x_i' \beta + u_i, \text{ con } u_i | x_i \sim N(0, \sigma^2)$$

De aquí: $y_i | x_i \sim N(x_i' \beta, \sigma^2)$. Parámetros: $\theta = (\beta, \sigma^2)$

Densidad condicional:

$$f(y_i | x_i, \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i' \beta)^2}{2\sigma^2}\right)$$

Verosimilitud condicional:

$$L(\theta, \tilde{Y}) \equiv \prod_{i=1}^n f(y_i | x_i, \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i' \beta)^2}{2\sigma^2}\right)$$

con $\tilde{Y} = \{y_i, x_i\}_{i=1}^n$ una muestra i.i.d.

Método de Máxima Verosimilitud (MV)

Es aquel vector $\hat{\theta}_n$ que soluciona el siguiente problema:

$$\max_{\theta} L(\theta; \tilde{y}|X)$$

Intuición: MV trata de reconstruir el camino inverso al proceso generador de los datos.

Problema equivalente:

$$\hat{\theta}_n \equiv \operatorname{argmax}_{\theta} \ln L(\theta; \tilde{y}|X)$$

A esto se le denomina **Log-verosimilitud** (*log-likelihood*).

Ejercicio: mostrar que $\hat{\beta}_n$ por MV del slide anterior coincide con MCO!

Propiedades de MV

Computacionales:

- No siempre se puede aplicar cálculo para encontrar a $\hat{\theta}_n$.
- No siempre $\hat{\theta}_n$ es una solución es explícita.

Estadísticas: bajo ciertos supuestos de regularidad

- Consistencia

$$\hat{\theta}_n \xrightarrow{P} \theta_0$$

- Normalidad asintótica

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, AV(\hat{\theta}_n))$$

donde $AV(\hat{\theta}_n)$ es la varianza asintótica de $\hat{\theta}_n$.

Modelo Tobit

Modelo lineal $y_i^* = x_i' \beta + u_i$, con:

$$y_i = \begin{cases} 0 & \text{si } y_i^* \leq 0 \\ y_i^* & \text{si } y_i^* > 0 \end{cases}$$

Supuesto extra: $u_i | x_i \sim N(0, \sigma^2)$

¿Cómo usar esta información? Veremos que:

Tramo	Tipo de VA	Probabilidad/Densidad
$y_i = 0$	<i>Discreta</i>	$1 - \Phi(x_i' \beta / \sigma)$
$y_i > 0$	<i>Continua</i>	$(1/\sigma) \phi((y_i - x_i' \beta) / \sigma)$

- $\phi(\cdot)$: densidad en una distribución normal estándar.
- $\Phi(\cdot)$: prob. acumulada (desde la izq.) en una normal estándar.

Probabilidad/Densidad

Notar que:

$$u_i|x_i \sim N(0, \sigma^2) \implies y_i^*|x_i \sim N(x_i'\beta, \sigma^2)$$

Luego,

① Probabilidad de censura:

$$\begin{aligned} Pr(y_i = 0|x_i) &= Pr(y_i^* \leq 0|x_i) \\ &= Pr(x_i'\beta + u_i \leq 0|x_i) \\ &= Pr(u_i/\sigma \leq -x_i'\beta/\sigma|x_i) \\ &= \Phi\left(-\frac{x_i'\beta}{\sigma}\right) \\ &= 1 - \Phi\left(\frac{x_i'\beta}{\sigma}\right) \end{aligned}$$

② La densidad en el tramo continuo es obvia [¿por qué?]

Tobit: estimación MV

Construyamos la verosimilitud condicional:

$$\begin{aligned} L(\beta, \sigma) &= \prod_{i: y_i=0} [1 - \Phi(x'_i \beta / \sigma)] \cdot \prod_{i: y_i > 0} (1/\sigma) \phi((y_i - x'_i \beta) / \sigma) \\ &= \prod_{i=1}^n [1 - \Phi(x'_i \beta / \sigma)]^{(1-w_i)} \cdot [(1/\sigma) \phi((y_i - x'_i \beta) / \sigma)]^{w_i} \end{aligned}$$

donde $w_i \equiv 1(y_i > 0)$. (*)

Luego, la log-verosimilitud es:

$$\ell(\beta, \sigma) = \sum_{i=1}^n (1 - w_i) \ln[1 - \Phi(x'_i \beta / \sigma)] + w_i \ln[(1/\sigma) \phi((y_i - x'_i \beta) / \sigma)]$$

que bajo condiciones regulares produce un máximo único utilizando métodos numéricos simples. De aquí salen $(\hat{\beta}, \hat{\sigma}) \xrightarrow{P} (\beta, \sigma)$ y asintóticamente normales.

(*) *Función indicadora*: $1(Q)$ vale 1 si el argumento Q es verdadero y 0 si es falso.

Regresión truncada

- **Situación:** no hay observaciones cuando $y_i^* \leq c$. Por lo tanto, no es posible incluirlas en la regresión.
- ¿Cómo afecta el truncamiento a una distribución?
- En términos generales, si Y es una variable aleatoria, la densidad de la distribución truncada es:


$$f(y|y > c) = \frac{f(y)}{\Pr(y > c)}$$

c es el punto de truncamiento y $f(y)$ es la densidad de Y .

- **Caso particular:** $Y \sim N(\mu, \sigma^2)$

$$f(y|y > c) = \frac{(1/\sigma)\phi\left(\frac{y-\mu}{\sigma}\right)}{1-\Phi\left(\frac{c-\mu}{\sigma}\right)} = \frac{(1/\sigma)\phi(z)}{1-\Phi(\alpha)}$$

Distribución Normal truncada



Regresión truncada

Modelo lineal para la variable latente:

$$y_i^* = x_i' \beta + u_i$$

Vimos que:

$$u_i | x_i \sim N(0, \sigma^2) \Rightarrow y_i^* | x_i \sim N(x_i' \beta, \sigma^2)$$

Luego, la verosimilitud condicional utiliza la densidad de $y_i^* | x_i$ truncada en $y_i^* > 0$:

$$L(\beta, \sigma) = \prod_{i=1}^n \left[\frac{(1/\sigma) \phi((y_i - x_i' \beta)/\sigma)}{\Phi(x_i' \beta/\sigma)} \right]$$

MV nos dará estimadores consistentes y asintóticamente normales de los parámetros β y σ .

Variable dependiente binaria

Supongamos el siguiente modelo lineal latente:

$$y_i^* = x_i' \beta + u_i$$

donde y_i^* es continua pero no se observa. En su lugar se observa:

$$y_i = \begin{cases} 1 & y_i^* > 0 \\ 0 & y_i^* \leq 0 \end{cases}$$

(x_i es observable!).

No siempre y_i^* es interpretable. Algunos ejemplos:

- 1 y_i^* utilidad neta de un individuo i por trabajar; y_i indica con 1 si observamos que trabaja y 0 en caso contrario.
- 2 y_i^* beneficios potenciales de una firma i ; y_i indica con 1 si opera en el mercado y 0 no entra.

Probabilidad condicional

Supongamos que $u_i \sim N(0, \sigma^2)$ y computemos la probabilidad de que observemos $y_i = 1$, dado x_i :

$$\begin{aligned} P(y_i = 1|x_i) &= P(y_i^* > 0|x_i) \\ &= P(x_i'\beta + u_i > 0|x_i) \\ &= P(u_i/\sigma > -x_i'\beta/\sigma|x_i) \quad (1) \\ &= \Phi(x_i'\theta) \quad (2) \end{aligned}$$

donde hemos definido a $\theta \equiv \beta/\sigma$.

- ¿Qué modelo es este?
- **Ejercicio:** completar los pasos intermedios de (1) a (2).

En general $P(y_i = 1|x_i) = F(x_i'\theta)$, donde $F(\cdot)$ es una función monótona creciente y cumple $F(-\infty) = 0$ y $F(+\infty) = 1$

Estimador MV

Dado x_i, y_i es una VA Bernoulli con $p_i = P(y_i = 1|x_i)$. Luego,

$$L(\theta) = \prod_{i:y_i=1} p_i \cdot \prod_{i:y_i=0} (1 - p_i) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$$


y su logaritmo

$$\begin{aligned} \ell(\theta) &= \sum_{i=1}^n [y_i \ln p_i + (1 - y_i) \ln (1 - p_i)] \\ &= \sum_{i=1}^n \{y_i \ln F(x_i' \theta) + (1 - y_i) \ln [1 - F(x_i' \theta)]\} \end{aligned}$$

- La solución $\hat{\theta}_{MV}$ existe siempre que las x_i sean linealmente independientes y no contengan un clasificador perfecto de y_i .
- **Identificación:** no es posible estimar a β y σ , solo al cociente.

¿Logit o Probit?

- Si $F(z) = \Lambda(z) = \frac{e^z}{1+e^z}$ el modelo binario se denomina Logit.
- Ambas son muy similares: $\Lambda(z/\sqrt{(2/3)}) \approx \Phi(z)$.
- En general, $\hat{\beta}_{logit} \approx 1,8\hat{\beta}_{probit}$
- Elegir cualquiera de las dos especificaciones.



Tobit y Probit

Notar que si multiplicamos y dividimos $\Phi(x'_i\beta/\sigma)^{w_i}$ en la $L(\beta, \sigma)$ del modelo Tobit obtenemos lo siguiente:

$$L(\beta, \sigma) = \prod_{i=1}^n \underbrace{[1 - \Phi(x'_i\beta/\sigma)]^{(1-w_i)}}_{(1)} \cdot \underbrace{\Phi(x'_i\beta/\sigma)^{w_i} \cdot \left[\frac{(1/\sigma)\phi(x'_i\beta/\sigma)}{\Phi(x'_i\beta/\sigma)} \right]^{w_i}}_{(2)}$$

donde $w_i \equiv I(y_i > 0)$.

Luego, el Tobit es una suerte de combinación de dos modelos:

- **Probit:** para la probabilidad de observar a y sin censura, dado por el segmento (1).
- **Regresión truncada:** solo con datos no censurados, dado por el segmento (2).

MCO y el modelo lineal

Consideremos el modelo lineal para y

$$y_i = x_i' \beta + \varepsilon_i$$

La insesgadez de MCO depende del supuesto de que $E(\varepsilon_i | x_i) = 0$, o bien, que

$$E(y_i | x_i) = x_i' \beta$$

Pensemos:

- La variable latente sigue un modelo lineal: $y_i^* = x_i' \beta + u_i$
- Sin embargo, sólo observamos a y_i (una versión alterada de y_i^*)
- En los tres casos, la transformación de y_i a y_i^* es no lineal.
- ¿Debemos esperar que y_i siga una modelo lineal?

¿Por qué falla el modelo lineal?

Situación: los tres casos analizados generan un problema de especificación para y_i sesgando potencialmente a MCO.



Formalmente: $E(y_i|x) = m(x_i, \theta)$, donde $m(\cdot)$ es alguna función (no lineal) conocida que depende de los parámetros θ .

Resultado: si $u_i|x_i \sim N(0, \sigma^2)$, no es muy difícil mostrar que

Caso (Modelo)	Esperanza condicional
1. Censura (Tobit)	$E(y_i x_i) = [x_i'\beta + \sigma\lambda(x_i'\beta/\sigma)] \Phi\left(\frac{x_i'\beta}{\sigma}\right)$
2. Truncamiento	$E(y_i x_i, y_i > 0) = x_i'\beta + \sigma\lambda(x_i'\beta/\sigma)$
3. Variable binaria (Probit)	$E(y_i x_i) = \Phi(x_i'\theta)$, con $\theta = \beta/\sigma$

donde $\lambda(z) \equiv \frac{\phi(z)}{\Phi(z)}$ (inversa del ratio de Mills)

Esperanza condicional: censura y truncamiento




$$(1) = \text{MCO}$$

$$(2) = x_i' \beta + \sigma \lambda(x_i' \beta / \sigma)$$

$$(3) = [x_i' \beta + \sigma \lambda(x_i' \beta / \sigma)] \Phi(x_i' \beta / \sigma)$$

Esperanza condicional: variables binarias



¿Interpretación de coeficientes?

Media condicional: el caso general es $E(y_i|x) = m(x_i, \beta)$, donde $m(\cdot)$ es una función no lineal conocida.

Efecto parcial: tomemos algún regresor x_k continuo

$$\frac{\partial E(y_i|x)}{\partial x_k} = \frac{\partial m(x_i, \beta)}{\partial x_k}$$

- El efecto parcial de x_k no es constante, sino que depende de x_i . Problema: ¿dónde evaluar a x_i ?
- A priori, el valor de los β no brinda información cuantitativa del efecto parcial sobre $E(y|x)$.
- En algunos modelos, el signo de β indica la dirección del efecto (Probit/Logit).

Estas conclusiones se mantienen para el caso donde x_k es binario.

Caso 1: modelo lineal de probabilidad (MPL)

Es el caso de y_i binaria (Bernoulli) con $p_i = P(y_i = 1|x_i)$:

$$E(y_i|x_i) = P(y_i = 1|x_i) = \underbrace{x_i'\beta}_{\text{MPL}}$$

donde $\hat{\beta}$ se obtiene por MCO.

Desventajas:

- ① *Heterocedástico*: $V[y_i|x_i] = p_i(1 - p_i) = x_i'\beta \cdot (1 - x_i'\beta)$
- ② *Predicciones incoherentes*: $x_i'\hat{\beta} < 0$ y/o $x_i'\hat{\beta} > 1$ para algún i .
- ③ *Efectos parciales constantes*: $\partial E(y_i|x)/\partial x_k = \beta_k$

Ventajas: (Angrist y Pischke, 2009)

- ① Los coeficientes tienen una interpretación cuantitativa.
- ② El modelo lineal tiene más variantes teóricas (VI, paneles, modelos dinámicos, etc.)

Caso 2: modelos no lineales de probabilidad

Son los Probit/Logit, que en general se escriben:

$$p_i = P(y_i = 1|x_i) = F(x_i'\beta)$$

donde $F(\cdot)$ es una distribución acumulada (normal o logística) y $\hat{\beta}$ se obtiene por MV.

Variables continuas:

$$\frac{\partial p_i}{\partial x_k} = f(x_i'\beta)\beta_k$$

Variables dummy: sea el modelo $F(x_i'\beta + \delta D)$, con D binario

$$\Delta p_i = F(x_i'\beta + \delta) - F(x_i'\beta)$$

El signo del coeficiente es informativo de la dirección del efecto parcial, no así su magnitud.

Caso 3: modelo Tobit

El modelo Tobit da estimaciones consistentes de:

$$\beta = \frac{\partial E(y^*|x)}{\partial x}$$

- Esto nos provee una interpretación de las derivadas parciales de la variable latente.
- No siempre la variable latente es interpretable (o interesante) y puede que el objetivo sea computar los efectos parciales sobre el promedio de la variable observada (censurada o truncada).

Caso 3: modelo Tobit

Esperanza de y truncada: en el caso de que $u_i \sim N(0, \sigma^2)$, vimos que:

$$E(y|x, y > 0) = x'\beta + \sigma\lambda (x'\beta/\sigma)$$

Esperanza de y censurada:

$$E(y|x) = E(y|x, y > 0)Pr(y > 0|x)$$

Que bajo normalidad, esta expresión queda:

$$E(y|x) = \Phi(x'\beta/\sigma)[x'\beta + \sigma\lambda (x'\beta/\sigma)]$$

Caso 3: modelo Tobit

Efectos parciales (regresores continuos)

- Noten que las derivadas parciales de $E(y|x)$ y $E(y|x, y > 0)$ no son constantes.
- Supongamos un x_k continuo. En el caso de la esperanza con censura:

$$\frac{\partial E(y|x)}{\partial x_k} = \Phi(x'\beta/\sigma)\beta_k$$

- Mientras que para la esperanza truncada:

$$\frac{\partial E(y|x, y > 0)}{\partial x_k} = \{1 - \lambda(x'\beta/\sigma)[x'\beta + \sigma\lambda(x'\beta/\sigma)]\}\beta_k$$

Caso 3: modelo Tobit

Descomposición de McDonald y Moffitt

Retomando el resultado anterior:

$$E(y|x) = Pr(y > 0|x)E(y|x, y > 0)$$

Derivemos usando la regla del producto:

$$\frac{\partial E(y|x)}{\partial x_k} = \frac{\partial Pr(y > 0|x)}{\partial x_k} E(y|x, y > 0) + Pr(y > 0|x) \frac{\partial E(y|x, y > 0)}{\partial x_k}$$

Es decir, el efecto sobre variable censurada tiene dos componentes:

- 1 $\frac{\partial Pr(y > 0|x)}{\partial x_k} E(y|x, y > 0)$: efecto de los que cambian de estado.
- 2 $Pr(y > 0|x) \frac{\partial E(y|x, y > 0)}{\partial x_k}$: efecto de la distribución truncada.

Comentarios finales

- En general, podemos pensar una Y limitada como una transformación no lineal de una variable latente Y^* .
- Esto involucra el caso de censura, truncamiento y variables categóricas.
- El modelo estimable (utilizando Y y X) resulta no lineal induciendo una mala especificación al estimador MCO.
- ¿Qué tan malo es usar MCO?
 - Es adaptable (VI, datos en panel, etc.)
 - Ofrece la mejor aproximación lineal a $E(y|x)$.
- **En la práctica:** depende mucho del contexto. Por ejemplo: Pobit/Logit (predicciones coherentes *versus* efectos parciales complicados). Pregunta: ¿qué necesito?

Bibliografía

- Wooldridge, J. (2002) Econometric Analysis of Cross Section and Panel Data, MIT Press. 1a. Edición. Capítulos 15, 16 y 17.
- Cameron y Trivedi (2009), Microeconometrics Using Stata, Stata Press. Capítulos 14 (14.1 a 14.5) y 16 (16.1, 16.2 y 16.3).
- Gasparini, L., Marchionni, M. y Sosa Escudero, W. (2004) Characterization of inequality changes through microeconomic decompositions. The case of Greater Buenos Aires, en Bourguignon, F., Lustig, N y Ferreira, F. (eds.), 2004 (pp. 47- 82).
- Sosa Escudero (2015), "To probit or not to probit? Esa es la cuestión" en El Lado Oscuro de la Econometría (Capítulo 3).