

Selección muestral

Javier Alejo

Maestría en Economía

UNLP

Agosto 2019

Temario de la clase

- 1 Cuestiones preliminares.
- 2 Selección muestral.
- 3 Estimador de Heckman.
- 4 Ejemplo empírico.



La normal truncada

Vimos que si $Y \sim f(y)$, entonces la distribución truncada por izquierda es:

$$f(y|Y > a) = \frac{f(y)}{\Pr(Y > a)}$$

Caso particular: $Y \sim N(\mu, \sigma^2)$

$$f(y|Y > a) = \frac{(1/\sigma)\phi\left(\frac{y-\mu}{\sigma}\right)}{1-\Phi\left(\frac{a-\mu}{\sigma}\right)} = \frac{(1/\sigma)\phi(z)}{1-\Phi(\alpha)}$$

con $z \equiv (y - \mu)/\sigma$ y $\alpha \equiv (a - \mu)/\sigma$.

Algunos resultados útiles

Alteración en la esperanza:

$$\begin{aligned} E(Y|Y > a) &= \mu + \sigma \frac{\phi(\alpha)}{1 - \Phi(\alpha)} \\ &= \mu + \sigma \lambda(\alpha) \end{aligned}$$


Inversa del ratio de Mills: $\lambda(\alpha)$, donde $\alpha \equiv (a - \mu)/\sigma$.

De la misma manera, la varianza también se ve afectada:

$$V(Y|Y > a) = \sigma^2 [1 - \delta(\alpha)] \neq \sigma^2$$

con $\delta(\alpha) = \lambda(\alpha)[\lambda(\alpha) - \alpha]$ (ver Greene, 2003, pag. 759.)

Ejemplo: $Y \sim N(0,1)$ vs. $Y|Y > -1$



Variables latentes y Probits

Recuerden el modelo Probit:

$$P(y_i = 1|x_i) = \Phi(x_i'\beta)$$

Los parámetros β pueden ser estimados consistentemente por el método de MV.

Consideren el modelo lineal:

$$y_i^* = x_i'\beta^* + u_i^*, \quad u_i^* \sim N(0, \sigma^2)$$

donde y_i^* no es observable (variable latente) y en su lugar se cuenta con $y_i = 1(y_i^* > 0)$.

¿Qué parámetros pueden ser estimados consistentemente?

Variables latentes y Probits

$$\begin{aligned}P(y_i = 1|x_i) &= P(y_i^* > 0|x_i) \\&= P(x_i'\beta^* + u_i^* > 0|x_i) \\&= P(u_i^*/\sigma > -x_i'\beta^*/\sigma|x_i) \\&= 1 - P(u_i^*/\sigma < -x_i'\beta^*/\sigma|x_i)\end{aligned}$$

Dado que $u_i^*/\sigma \sim N(0, 1)$, sigue que:

$$\begin{aligned}P(y_i = 1|x_i) &= 1 - \Phi(-x_i'\beta) \\&= \Phi(x_i'\beta) \quad [\text{¿por qué?}]\end{aligned}$$

Dando como resultado un modelo Probit, donde hemos definido a $\beta \equiv \beta^*/\sigma$.

Problema de identificación

En el modelo lineal para la variable latente:

- No es posible identificar a β^* y σ^2 por separado mediante una muestra aleatoria (y_i, x_i) , $i = 1, \dots, n$.
- ¿Qué significa?: los datos generados por un modelo con $\beta^* = 2$ y $\sigma^2 = 1$ son observacionalmente iguales que los generados por otro con $\beta^* = 6$ y $\sigma^2 = 9$.
- Sin embargo, es posible identificar a $\beta = \beta^* / \sigma$.

Selección muestral

Consideremos el siguiente modelo:

$$y_i = x_i' \beta + u_i$$

Proceso de selección: supongamos además una dummy s_i que nos indica con 1 si y_i es observable y 0 en caso contrario.

Ejemplo: oferta salarial

- Solo es posible estimar una ecuación de salarios con datos de individuos ocupados ($s_i = 1$). [¿por qué?]
- No podemos observar cuanto están dispuestos a percibir como salario aquellos que están desocupados ($s_i = 0$).

MCO bajo selección muestral

Con una muestra aleatoria (y_i, x_i) , la consistencia de MCO depende del supuesto:

$$E(u_i|x_i) = 0$$

lo cual implica que $E(y_i|x_i) = x_i'\beta$.

- **Importante:** solo es posible utilizar la información seleccionada, es decir condicional en que $s_i = 1$.

Tomando esperanza condicional en la selección:

$$E(y_i|x_i, s_i = 1) = x_i'\beta + E(u_i|x_i, s_i = 1)$$

¿Cuándo MCO es consistente bajo la selección muestral?

MCO bajo selección muestral

Si $E(u_i|x_i) = 0$, ¿podemos decir que $E(u_i|x_i, s_i = 1) = 0$?

Mecanismo de selección: no todos generan sesgo en MCO

- Si es independiente de (x_i, u_i) :

$$E(u_i|x_i, s_i) = E(u_i|x_i) = 0$$

por lo tanto MCO seguirá siendo insesgado y consistente.

- Si tiene una relación determinista con x , del tipo $s_i = g(x_i)$:

$$E(u_i|x_i, s_i) = E[u_i|x_i, g(x_i)] = E(u_i|x_i) = 0$$

por lo tanto MCO seguirá siendo insesgado y consistente.

MCO bajo selección muestral

Resumen:

- ¿Cuándo genera sesgo?: si s_i y u_i están correlacionados.
- Es decir, cuando el truncamiento en y_i está generado por un mecanismo endógeno.

Algunos ejemplos:

- Decisiones laborales (trabajar, ser formal, migrar, etc.) en función de sus pretensiones salariales.
- Elección/Abandono de los beneficiarios de un programa.
- Datos con empresas que entran y salen del mercado.

Un modelo con selección muestral

- ¿Cómo se elige los valores de s_i ? necesitamos un modelo!

Supongamos las siguientes ecuaciones:

$$\begin{cases} y_{1i} = x'_{1i}\beta_1 + u_{1i} & \text{(regresión)} \\ y_{2i}^* = x'_{2i}\beta_2 + u_{2i} & \text{(selección)} \end{cases}$$

donde y_{2i}^* es una variable latente que gobierna la selección:

$$y_{2i} = \begin{cases} 1 & \text{si } y_{2i}^* > 0 \\ 0 & \text{si } y_{2i}^* \leq 0 \end{cases} \quad \begin{matrix} (i \text{ tiene datos de } y_{1i}) \\ (i \text{ no tiene datos de } y_{1i}) \end{matrix}$$

Es decir: $y_{2i} = 1(y_{2i}^* > 0)$, donde $1(\cdot)$ es la función indicadora.

- **Importante:** (y_{2i}, x_{2i}) son observados, sin importar si hay información sobre y_{1i} .

Siguiendo con el ejemplo...

Oferta salarial

Ecuación de salarios:

$$\text{salario}_i = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_i + \beta_3 \text{mujer}_i + u_i$$

Podemos repensar este modelo de la siguiente manera:

- **Ecuación de regresión:** salarios (y_{1i}) en función de características individuales (x_{1i}).
- **Ecuación de selección:** utilidad neta del trabajo (y_{2i}^*) en función de sus determinantes (x_{2i})

Notar que los valores de y_{2i}^* no se observan, pero sabemos si el individuo i trabaja (o no) mediante la variable $y_{2i} = 1[y_{2i}^* > 0]$.

Supuestos del modelo de selección

$$\begin{cases} y_{1i} &= x'_{1i}\beta_1 + u_{1i} \\ y_{2i}^* &= x'_{2i}\beta_2 + u_{2i} \\ y_{2i} &= 1(y_{2i}^* > 0) \end{cases}$$

- ❶ (y_{1i}, x_{1i}) se observan sólo si $y_{2i} = 1$ (muestra con selección).
- ❷ (y_{2i}, x_{2i}) se observan para todos.
- ❸ (u_{1i}, u_{2i}) son independientes de x_{2i} y tienen media cero.
- ❹ $u_{2i} \sim N(0; \sigma_2^2)$.
- ❺ $E(u_{1i}|u_{2i}) = \gamma u_{2i}$

Sesgo por selección

Computemos la esperanza condicional en la selección:

$$\begin{aligned} E(y_{1i}|x_{1i}, y_{2i} = 1) &= x'_{1i}\beta_1 + E(u_{1i}|x_{1i}, y_{2i} = 1) \\ &= x'_{1i}\beta_1 + E[E(u_{1i}|u_{2i})|x_{1i}, y_{2i} = 1)] \\ &= x'_{1i}\beta_1 + E(\gamma u_{2i}|x_{1i}, y_{2i} = 1) \\ &= x'_{1i}\beta_1 + \gamma E(u_{2i}|x_{1i}, y_{2i}^* > 0) \\ &= x'_{1i}\beta_1 + \gamma E(u_{2i}|x_{1i}, u_{2i} > -x'_{2i}\beta_2) \\ &= x'_{1i}\beta_1 + \gamma\sigma_2\lambda(x'_{2i}\beta_2/\sigma_2) \end{aligned}$$

donde $\lambda(\cdot)$ es la *inversa del ratio de Mills*.

Sesgo por selección

$$E(y_{1i}|x_{1i}, y_{2i} = 1) = x'_{1i}\beta_1 + \gamma\sigma_2\lambda(x'_{2i}\beta_2/\sigma_2)$$

Notar que si $\gamma \neq 0$, entonces:

$$E(y_{1i}|x_{1i}, y_{2i} = 1) \neq x'_{1i}\beta_1$$

Luego, el sesgo aparece por la correlación entre u_2 y u_1 .

Intuición: oferta salarial

- Los inobservables que afectan a los salarios están relacionados con los que afectan a la decisión de trabajar.
- El mecanismo de selección hace que esos factores inobservables se cuelen en el término de error del modelo de regresión.

Heckman (1979)



- 1 Sesgo de selección como un problema de variable relevante omitida.
- 2 Al estimar por MCO usando la muestra seleccionada, $\lambda(\cdot)$ es una variable omitida.
- 3 ¿Cuándo omitir una variable induce un sesgo en los estimadores de MCO?

Estimación consistente

Pensemos a la ecuación de regresión como:

$$y_{1i} = x'_{1i}\beta_1 + \gamma^*\lambda_i + u_{1i}^*$$

donde $\gamma^* \equiv \gamma\sigma_2$; $\lambda_i \equiv \lambda(x'_{2i}\beta_2/\sigma_2)$ y $u_{1i}^* \equiv u_{1i} - \gamma^*\lambda_i$.

Por construcción:

$$E(u_{1i}^*|x_{1i}, y_{2i} = 1) = E(u_{1i}|x_{1i}, y_{2i} = 1) - \gamma^*\lambda(x'_{2i}\beta_2) = 0$$

Notar:

- Si contamos con la variable λ_i podemos estimar a β_1 de manera insesgada [¿cómo?].
- **Problema:** λ_i no es observable! [¿por qué?]

Estimación auxiliar de m_i

- Es posible identificar a $\beta_2^* = \beta_2/\sigma_2$.
- Notar que $u_{2i} \sim N(0; \sigma_2^2)$, luego la probabilidad de selección es:

$$\begin{aligned} P(y_{2i} = 1|x_i) &= P(y_{2i}^* > 0|x_i) \\ &= P(x_{2i}'\beta_2 + u_{2i} > 0|x_{2i}) \\ &\vdots \\ &= \Phi(x_{2i}'\beta_2^*) \end{aligned}$$

con $\beta_2^* = \beta_2/\sigma_2$.

- Recordar que tenemos (y_{2i}, x_{2i}) para toda la muestra!.

Método de Heckman en 2 etapas

El modelo con selección es:

$$y_{1i} = x'_{1i}\beta_1 + \gamma^*\lambda_i + u_{1i}^*$$

Heckman (1979) propone estimarlo en 2 etapas:

- **Etapa 1:** obtener un $\hat{\beta}_2^*$ usando un Probit usando la muestra completa y estimar a m_i haciendo $\hat{\lambda}_i = \lambda(x'_{2i}\hat{\beta}_2^*)$.
- **Etapa 2:** obtener $(\hat{\beta}_1, \hat{\gamma}^*)$ haciendo una regresión de MCO de y_{1i} en función de x_{1i} y $\hat{\lambda}_i$.

Propiedades estadísticas:

- El método proporciona estimadores consistentes.
- Son asintóticamente normales $\rightarrow$ los métodos estándar de inferencia funcionan bien.

Test de sesgo por selección muestral

- Noten que si $\gamma = 0$, entonces no hay sesgo por selección.
- Método de Heckman: $\hat{\gamma}^* \xrightarrow{P} \gamma^* \equiv \gamma \sigma_2$.
- Dado que $\sigma_2 > 0$, podemos evaluar la presencia de sesgo de selección mediante las hipótesis:

$$H_0 : \gamma^* = 0$$

$$H_1 : \gamma^* \neq 0$$

- Luego, bajo H_0 :

$$\frac{\hat{\gamma}^*}{SE(\hat{\gamma}^*)} \xrightarrow{d} N(0, 1)$$

Errores estándar

- Por diferentes motivos, los SE computados por MCO son incorrectos.
- Por un lado, si $\gamma \neq 0$, la segunda etapa (con la muestra seleccionada) es heterocedástica.
- *Intuición*: el truncamiento también afecta a la varianza

$$\begin{aligned} V(u_{1i}|x_{1i}, y_{2i} = 1) &= V(u_{1i}|x_{1i}, u_{2i} > -x'_{2i}\beta_2) \\ &\neq \sigma_1^2 \end{aligned}$$

- Además se utiliza a $\hat{\beta}_2$ en lugar de β_2 .
- Hay correcciones disponibles (Stata implementa una de ellas).

Otras cuestiones prácticas

Test de sesgo por selección:

- La hipótesis nula dice que $\gamma = 0$ (no hay efectos de la selección).
- Luego, bajo la H_0 la segunda etapa es homocedástica.
- Por lo tanto los SE de MCO son correctos.

Inferencia:

- Baja potencia cuando x_1 y x_2 son similares.
- Necesidad práctica de que las variables incluidas x_1 sean un subconjunto de las incluidas en x_2 (*restricción de exclusión*).

Estimación MV

Se utiliza el mismo modelo:

$$\begin{cases} y_{1i} &= x'_{1i}\beta_1 + u_{1i} \\ y_{2i}^* &= x'_{2i}\beta_2 + u_{2i} \\ y_{2i} &= 1(y_{2i}^* > 0) \end{cases}$$

Pero ahora se requiere normalidad bivariada en los errores para computar la verosimilitud.

$$\begin{pmatrix} u_{1i} \\ u_{2i} \end{pmatrix} \sim N \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1 \\ \rho\sigma_1 & 1 \end{pmatrix} \right]$$

¿Es un supuesto más fuerte o más débil?

Función de log-verosimilitud

Con todos estos supuestos:

$$\begin{aligned} \ell(\beta_1, \beta_2, \sigma_1^2, \rho) = & \sum_{i=1}^n \{ (1 - y_{2i}) \ln [1 - \Phi(x'_{2i}\beta_2)] + \dots \\ & \dots + y_{2i} \left[\ln \sigma_1^2 + \ln \phi \left(\frac{y_{1i} - x'_{1i}\beta_1}{\sigma_1} \right) \right] + \dots \\ & \dots + y_{2i} \ln \left[\Phi \left(\frac{x'_{2i}\beta_2 + \rho \sigma_1 (y_{1i} - x'_{1i}\beta_1)}{\sqrt{1 - \rho^2} \sigma_1} \right) \right] \} \end{aligned}$$

- Las condiciones de primer orden de este problema definen implícitamente los estimadores MV.
- Bajo todos los supuestos mencionados, es una alternativa consistente y eficiente.

En la práctica

El estimador de Heckman por MV tiene algunos problemas de implementación:

- Requiere supuestos demasiado estrictos sobre (u_{1i}, u_{2i}) .
- La función de verosimilitud es complicada.
- Problemas de convergencia en la maximización numérica.

Rara vez se usa.

(1) Modelo Tobit en la selección

Supongamos el siguiente modelo con los supuestos (2) a (5)

$$\begin{cases} y_{1i} &= x'_{1i}\beta_1 + u_{1i} \\ y_{2i} &= \max(x'_{2i}\beta_2 + u_{2i}, 0) \end{cases}$$

donde y_{1i} se observa solo cuando $y_{2i} > 0$. Luego,

$$E(y_{1i} | x_{1i}, y_{2i} > 0, u_2) = x'_{1i}\beta_1 + \gamma u_2$$

- Seguimos en la lógica de sesgo por variable omitida.
- ¿Es posible observar a u_2 ?
- ¿Cómo implementar un estimador factible?

(1) Modelo Tobit en la selección

$$E(y_{1i}|x_{1i}, y_{2i} > 0, u_2) = x'_{1i}\beta_1 + \gamma u_2$$

Es posible computar un estimador en dos etapas (Vella, 1992, 1998; Wooldridge, 1994):

- 1 Estimar $\hat{\beta}_2$ con un Tobit con (y_{2i}, x_{2i}) y computar los residuos $\hat{u}_{2i} = y_{2i} - x'_{2i}\hat{\beta}_2$ para la muestra con $y_{2i} > 0$.
- 2 Obtener $(\hat{\beta}_1, \hat{\gamma})$ haciendo un MCO de y_{1i} en función de x_{1i} y $\hat{u}_{2i}$.

A esto se le llama modelo **Tobit tipo III** (Amemiya, 1985).

¿Este modelo es mejor que el de Heckman en dos etapas?

(2) Estimador semi-paramétrico

Si la distribución de (u_{1i}, u_{2i}) es desconocida, es razonable decir

$$E(u_{1i}|x_{1i}, y_{2i} = 1) = g(x'_{2i}\beta_2)$$

donde $g(\cdot)$ es una función desconocida. Luego,

$$E(y_{1i}|x_{1i}, y_{2i} = 1) = x'_{1i}\beta_1 + g(x'_{2i}\beta_2)$$

Esto se corresponde con un modelo semi-paramétrico que puede estimar mediante métodos estándar (Wooldridge, 1994).

- También requiere dos etapas (para estimar a β_2).
- Restricción de exclusión: ahora es estrictamente necesaria.

(3) Otras extensiones

Montes Rojas (2011): test robusto para evaluar si u_{1i} es normal y la linealidad de su esperanza condicional. Es un test LM modificado usando una expansión de Edgeworth.

Tauchmann (2010): analiza la selección multivariada

$$\begin{cases} y_i = & x_i' \beta + u_i \\ d_i = & 1(z_i' \alpha + v_i > 0) \\ y_i & \text{se observa si } d_i = 1 \end{cases}$$

donde y_i , d_i , u_i y v_i son vectores de $(m \times 1)$. Resultado:

- En general, Heckman en dos etapas ecuación por ecuación será inconsistente.
- Propone una versión modificada que incorpora el patrón completo de selección en la inversa del ratio de Mills.

Ejemplo: ecuación de salario para las mujeres

- **Motivación:** dado un conjunto de características observables para un individuo, su decisión de trabajar no es independiente del salario.
- **Problema latente:** sesgo por selección al usar MCO para estimar los β de una ecuación de salarios.
- **Solución:** usar el método de Heckman (máximo verosímil o en dos etapas).
- **Datos:** provenientes de la EPH 2014 para los aglomerados de la Patagonia.
- **Muestra:** 5327 mujeres entre 15 y 60 años de edad, de las cuales 2663 trabajan.

Variables a utilizar

Ecuación de regresión:

- *Variable dependiente* (y_{1i}): logaritmo natural del salario por hora.
- *Regresores* (x_{1i}): la edad y su cuadrado, años de educación y su cuadrado.

Ecuación de selección:

- *Variable dependiente* (y_{2i}): vale 1 si trabaja, 0 en caso contrario.
- *Regresores* (x_{2i}): edad, años de educación, estado conyugal, asistencia a la educación formal, cantidad de hijos menores a 12 y una dummy que vale 1 si es jefa de hogar.

```
. heckman lwage edad* aedu*, select(trabaja = edad aedu casada asiste hijos jefe) twostep
```

```
Heckman selection model -- two-step estimates      Number of obs   =      5,327
(regression model with sample selection)           Censored obs    =      2,664
                                                    Uncensored obs   =      2,663

                                                    Wald chi2(4)     =      450.31
                                                    Prob > chi2      =      0.0000
```

		Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
-----+-----							
lwage							
	edad	.0405814	.0083559	4.86	0.000	.0242041	.0569586
	edad2	-.0004261	.0001046	-4.08	0.000	-.000631	-.0002212
	aedu	-.0101681	.0174333	-0.58	0.560	-.0443368	.0240005
	aedu2	.0041218	.0007604	5.42	0.000	.0026315	.005612
	_cons	2.518422	.2077165	12.12	0.000	2.111305	2.925539
-----+-----							
trabaja							
	edad	.0050184	.001887	2.66	0.008	.00132	.0087169
	aedu	.0877533	.0056247	15.60	0.000	.0767291	.0987775
	casada	-.0256304	.0463482	-0.55	0.580	-.1164712	.0652104
	asiste	-1.007769	.0604728	-16.66	0.000	-1.126293	-.889244
	hijos12	-.1109985	.0222329	-4.99	0.000	-.1545742	-.0674228
	jefe	.6394699	.0480152	13.32	0.000	.5453619	.7335779
	_cons	-1.082192	.1005422	-10.76	0.000	-1.279251	-.8851329
-----+-----							
mills							
	lambda	-.094057	.0515752	-1.82	0.068	-.1951426	.0070285
-----+-----							

Resumen

	MCO	Heckman		Máximo
		"manual"	comando	Verosimil
edad	0.0431*** (0.0084)	0.0406*** (0.0085)	0.0406*** (0.0084)	0.0401*** (0.0084)
aedu	-0.0064 (0.0230)	-0.0102 (0.0232)	-0.0102 (0.0174)	-0.0111 (0.0175)
edad2	-0.0004*** (0.0001)	-0.0004*** (0.0001)	-0.0004*** (0.0001)	-0.0004*** (0.0001)
aedu2	0.0041*** (0.0010)	0.0041*** (0.0010)	0.0041*** (0.0008)	0.0041*** (0.0008)
lambda		-0.0941* (0.0513)	-0.0941* (0.0516)	-0.1118 (0.0665)
Constant	2.3427*** (0.2051)	2.5184*** (0.2234)	2.5184*** (0.2077)	2.5530*** (0.2232)
Observations	2,663	2,663	5,327	5,327
R-squared	0.2084	0.2094		

Robust standard errors in parentheses *** p<0.01, ** p<0.05, * p<0.1

Referencias

- Greene (2003), *Econometric Analysis*. Prentice Hall. 5a. Edición. Capítulo 22 (22.4.1-22.4.3).
- Cameron y Trivedi (2005), *Microeconometrics*. Capítulo 16 (16.5).
- Cameron y Trivedi (2009), *Microeconometrics Using Stata*, Stata Press. Capítulo 16.
- Gasparini, L., Marchionni, M. y Sosa Escudero, W. (2004) "Characterization of inequality changes through microeconomic decompositions. The case of Greater Buenos Aires", en Bourguignon, F., Lustig, N y Ferreira, F. (eds.), 2004 (pp. 47- 82).