

Estimación no paramétrica de densidades

-Econometría Avanzada-

Mariana Marchionni
marchionni.mariana@gmail.com

- 1 Introducción: modelos paramétricos versus no paramétricos
- 2 Estimación no paramétrica de densidades
 - 1 Estimadores no paramétricos rudimentarios
 - 2 Estimador de promedios ponderados o Kernels
 - 3 Propiedades: sesgo, varianza, consistencia, ancho de banda óptimo
- 3 Extensiones:
 - 1 Estimadores con ancho de banda variable
 - 2 Estimación de densidades conjuntas, la maldición de la dimensionalidad
- 4 Ejemplos

Los modelos paramétricos

- Supongamos que nos interesa estudiar la relación entre Y y X
- Un modelo paramétrico hace todos los supuestos necesarios para que nuestra ignorancia se limite solo a algunos parámetros.
- Ejemplo: $Y = X\beta + \varepsilon$ con $\varepsilon | X \sim N(0, \sigma^2)$
 $\Rightarrow$ todo lo que no conocemos de la relación entre Y y X se resume en β y en el parámetro σ^2 .
- Hay muchísimos modelos paramétricos y fundamentalmente 2 métodos de estimación: MCO y MV .
- La *consistencia* de los estimadores MCO y MV descansa en la *correcta especificación del modelo*.

Los modelos no paramétricos


- Los modelos no paramétricos no suponen ninguna estructura particular para describir la relación entre las variables de interés.
- Se recurre al menor número posible de supuestos para **"dejar hablar a los datos"**.
- Levantar supuestos tiene sus pros y sus contras. Ya veremos...

¿Por qué concentrarnos en la estimación de densidades?

- ① Razones didácticas: insumo para la estimación de regresiones no paramétricas
- ② Descripción de hecho estilizados:
 - evolución de la distribución del ingreso de una región
 - distribución del rendimiento de activos
 - distribución del peso de los niños al nacer
- ③ Como parte de la inspección de los datos, para evaluar el cumplimiento de ciertos supuestos paramétricos.

Objetivo: estimar el **valor de la función de densidad en un punto particular del soporte, $f(x_0)$** . Sean:

- $f = f(\cdot)$ la función de densidad de la variable aleatoria continua X .
- $x_1, x_2, \dots, x_N$ una muestra aleatoria de X : $x_i \sim f(\cdot)$, iid.
- x_0 un punto cualquiera del soporte de la distribución de X .



- Se supone una forma funcional particular para $f(\cdot)$.
- Ejemplo: distribución Normal

$$f(x_0) = \phi(x_0) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x_0 - \mu}{\sigma} \right)^2 \right]$$

- La ignorancia sobre $f(x_0)$ se limita al desconocimiento de los dos parámetros μ y σ .
- Estimadores consistentes (MV) son:

$$\hat{\mu} = \bar{X} = \frac{\sum_{i=1}^N x_i}{N} \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N}$$


Estimación no paramétrica de una densidad

- Se busca estimar $f(x_0)$ sin suponer una forma funcional particular
- Único supuesto: $f(\cdot)$ es una función suave (continua, diferenciable).
- ¿Cómo se interpreta la información muestral?
Si observamos más datos “cerca” de x_0 que de x' inferimos que $f(x_0) > f(x')$




Un estimador no paramétrico rudimentario: el histograma

- Se estima la probabilidad dentro de intervalos mediante la frecuencia relativa.
- Los intervalos se determinan a partir de un punto inicial a y un ancho de banda W





Un estimador no paramétrico rudimentario: el histograma



- Superficie de las barras = frec. rel. en el intervalo
= $\text{nro.obs.en el intervalo} / N$
- Altura de las barras = estimador de la densidad
= $\text{nro.obs.en el intervalo} / (N \times W)$



(1) Depende del punto inicial:




(2) Depende del ancho de banda:



(3) Es discontinuo en los extremos del intervalo

Notar que $\hat{f}(x_1) = \hat{f}(x_2)$, pero $\hat{f}(x_2 + \varepsilon) = 1/4 \hat{f}(x_1)$ para cualquier $\varepsilon > 0$, contradiciendo que $f(\cdot)$ es continua.



Caso discreto:

- X es una VA discreta, muestra x_i iid, $i = 1, 2, \dots, N$
- Objetivo: estimar $\Pr(X = x_0) = f(x_0)$
- El estimador naive viene dado por:


$$\hat{f}(x_0) = \frac{\# \text{ obs. con } x_i = x_0}{N} = \frac{1}{N} \sum_{i=1}^N I(x_i = x_0)$$

donde $I(\cdot) = 1$ si su argumento es verdadero, $= 0$ en caso contrario.

- El estimador naive para el caso discreto es la frecuencia relativa en el punto x_0

Caso continuo

- X es una VA continua $\Rightarrow \Pr(X = x_0) = 0$
 $\Rightarrow$ evaluamos la probabilidad de que X esté “cerca” de x_0 .
- Decimos que x_i está cerca de x_0 si $x_i \in (x_0 - h, x_0 + h)$.



$$\begin{aligned}
 2h \times f(x_0) &\cong \int_{x_0-h}^{x_0+h} f(z) dz = \Pr[x_0 - h < X < x_0 + h] \\
 &\cong \frac{1}{N} \# x_i \in (x_0 - h, x_0 + h) \\
 &= \frac{1}{N} \sum_{i=1}^N I[x_i \in (x_0 - h, x_0 + h)] \\
 &= \frac{1}{N} \sum_{i=1}^N I[x_0 - h < x_i < x_0 + h] \\
 &= \frac{1}{N} \sum_{i=1}^N I\left[-1 < \frac{x_i - x_0}{h} < 1\right]
 \end{aligned}$$


$$\Rightarrow f(x_0) \cong \frac{1}{2h \times N} \sum_{i=1}^N I\left[-1 < \frac{x_i - x_0}{h} < 1\right] \equiv \hat{f}(x_0)$$

$$\hat{f}(x_0) \equiv \frac{1}{h \times N} \sum_{i=1}^N \frac{1}{2} I\left[-1 < \frac{x_i - x_0}{h} < 1\right]$$

Características del estimador naïve

Notar:

- Para cada punto de estimación se define el centro de un intervalo.
- Las observaciones que están dentro de ese intervalo (a menos de un h de distancia de x_0) se ponderan por $\frac{1}{2}$.




- La densidad estimada es el cociente entre la suma de los ponderadores y $h \times N$ (tamaño de la muestra local):

$$\hat{f}(x_0) = \frac{1}{12 \times h} \times \frac{9}{2} = \frac{3}{8 \times h}$$


(1) Depende de h

- A mayor h observaciones más lejanas de x_0 se usan para estimar $f(x_0)$.
- A mayor h , al unir las estimaciones puntuales obtenemos una función más suave (h =smoothing parameter)



(2) Los ponderadores son discontinuos

- El ponderador $\frac{1}{2}I(\cdot)$ es discontinuo en los límites de cada intervalo, generando discontinuidades en la densidad estimada.
- Además, dentro del intervalo, trata igual a todas las observaciones independientemente de su distancia respecto de x_0 .



Generalización del estimador naive:

- Reemplaza el ponderador $\frac{1}{2}I(.)$ por una función ponderadora o Kernel $K(.)$:

$$\hat{f}(x_0) = \frac{1}{N \times h} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

- Los kernels $K(.)$ son funciones conocidas que se eligen para satisfacer ciertas propiedades deseables:

$$(1) K(\varphi) \geq 0; (2) \int_{-\infty}^{\infty} K(\varphi) d\varphi = 1 \text{ y } (3) K(\varphi) = K(-\varphi)$$

- Enfoque de Rosenblatt-Parzen (1957 y 1962, respect.).


Distintos kernels: rectangular o uniforme

$$K(\varphi_i) = \begin{cases} \frac{1}{2} & \text{si } |\varphi_i| < 1 \\ 0 & \text{en caso contrario} \end{cases}$$

donde $\varphi_i = \frac{x_i - x_0}{h}$, es la distancia estandarizada en unidades de h .

- En este caso el estimador de Kernels coincide con el estimador naïve.
- Notar: el ponderador es similar a una función de densidad uniforme en el intervalo $(-1, 1)$.

Estos son los **ponderadores** para estimar la densidad en x_0 si se usa un kernel rectangular




- La función kernel tiene la forma de una densidad normal estándar.

$$K(\varphi_i) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\varphi^2}{2}\right)$$

- Importante:** no se está suponiendo la distribución normal para ninguna variable. Sólo se usa la forma funcional para ponderar las observaciones en la fórmula del estimador.
- El estimador de la densidad usando el kernel gaussiano viene dado por:

$$\hat{f}(x_0) = \frac{1}{N \times h} \sum_{i=1}^N \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2} \left(\frac{x_i - x_0}{h}\right)^2\right]$$




- Consideremos al Kernel como una función de x_i , para x_0 y h dados.
- $K(\cdot)$ es una función decreciente de $|x_i - x_0|$: observaciones más cercanas a x_0 reciben mayor ponderación.
- A diferencia del estimador naíve, las ponderaciones decrecen suavemente.


Para estimar la densidad en el punto x_0 el estimador de kernels “promedia” las ponderaciones de todas las observaciones alrededor de x_0 :

$$\hat{f}(x_0) = \frac{1}{N \times h} \sum_{i=1}^N \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x_i - x_0}{h} \right)^2 \right]$$

Cada término de la sumatoria corresponde a la ponderación de una observación x_i .



El ancho de banda h sigue definiendo qué se entiende por “cerca” de x_0 .



- Cuanto más chico es h , más concentrados están los ponderadores y ...
 - menor deberá ser la distancia entre x_i y x_0 para que x_i sea considerado cercano a x_0 .
 - más rápidamente decrecen los ponderadores al alejarnos de x_0 .
- h se conoce también como parámetro de suavizamiento.


Tipo de Kernel	Fórmula	Soporte
Gaussiano o normal	$\frac{1}{\sqrt{2\pi}} \exp(-\varphi^2 / 2)$	$\varphi \in (-\infty, \infty)$
Epanechnikov	$\frac{3}{4\sqrt{5}} (1 - \frac{1}{5}\varphi^2) I(\varphi < \sqrt{5})$	$\varphi \in (-\sqrt{5}, \sqrt{5})$
Epanechnikov modificado	$\frac{3}{4} (1 - \varphi^2) I(\varphi < 1)$	$\varphi \in (-1, 1)$
Triangular	$(1 - \varphi) I(\varphi < 1)$	$\varphi \in (-1, 1)$
Uniforme o rectangular	$\frac{1}{2} I(\varphi < 1)$	$\varphi \in (-1, 1)$

- El estimador de kernels es generalmente sesgado.
- Puede demostrarse que para kernels que satisfacen las propiedades (1), (2) y (3), la expresión aproximada para el sesgo viene dada por:

$$\text{Sesgo} \left[\hat{f}(x_0) \right] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{\infty} K(\varphi) \varphi^2 d\varphi$$

$$\text{Sesgo} [\hat{f}(x_0)] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{\infty} K(\varphi) \varphi^2 d\varphi$$

- El sesgo crece con h . A mayor es h , observaciones más lejanas de x_0 se tienen en cuenta para estimar $f(x_0)$.
- El sesgo crece con la curvatura de la verdadera densidad. Si $f''(x_0)$ tiende a cero el sesgo desaparece:



- El sesgo depende del kernel.

La expresión aproximada para la varianza asintótica del estimador de kernels viene dada por:

$$\text{Varianza} \left[\hat{f}(x_0) \right] \cong \frac{1}{N \times h} f(x_0) \int_{-\infty}^{\infty} K^2(\varphi) d\varphi$$

- A mayor h menor es la varianza (mayor eficiencia)
- A mayor N menor es la varianza
- La varianza también depende del kernel

Trade-off entre insesgamiento y eficiencia

- A mayor h , menos sesgo pero más varianza.
- Asintóticamente se alivia el trade-off porque, para h dado, la varianza cae cuando $N \rightarrow \infty$.
- ¿Cómo se resuelve este *trade-off* para un N dado? Se elige h haciendo un balance entre los dos objetivos: h óptimo.

Ancho de banda óptimo y consistencia

Recordemos: es suficiente para consistencia que sesgo y varianza desaparezcan cuando $N \rightarrow \infty$.

Según las expresiones anteriores:

- El sesgo desaparece si $h \rightarrow 0$
- La varianza desaparece si $N \times h \rightarrow \infty$

Para la consistencia del estimador de kernels se requiere

- Que h decrezca con el tamaño muestral N .
- Que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N (para que $N \times h \rightarrow \infty$).
- El h que satisface este criterio se conoce como ancho de banda óptimo.

Ancho de banda óptimo y consistencia

Recordemos: es suficiente para consistencia que sesgo y varianza desaparezcan cuando $N \rightarrow \infty$.

Según las expresiones anteriores:

- El sesgo desaparece si $h \rightarrow 0$
- La varianza desaparece si $N \times h \rightarrow \infty$

Para la consistencia del estimador de kernels se requiere

- Que h decrezca con el tamaño muestral N .
- Que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N (para que $N \times h \rightarrow \infty$).
- El h que satisface este criterio se conoce como ancho de banda óptimo.

Elección del ancho de banda óptimo

Elegir el h^* que minimiza el **Error Cuadrático Medio Integrado (ECMI)**:

$$ECMI = \int E \left[\hat{f}(x) - f(x) \right]^2 dx = \int \{ [\text{sesgo } \hat{f}(x)]^2 + V[\hat{f}(x)] \} dx$$

- El ECMI promedia los ECM a lo largo de todos los posibles puntos de estimación.
- En la práctica se usan las expresiones aproximadas del sesgo y varianza que vimos antes.
- Si $f(x)$ fuera normal y con un $K(\cdot)$ gaussiano, $h^* = 1,06 \sigma N^{-1/5}$. Esta regla (*rule of thumb*) funciona bastante bien para otras distribuciones unimodales distintas a la normal, mientras no sean muy asimétricas.
- Otros métodos de elección de h^* : **métodos de validación cruzada.**

Consistencia paramétrica versus no paramétrica

- La consistencia del estimador no paramétrico sólo requiere ajustar adecuadamente la elección del ancho de banda.
- En cambio, se requieren fuertes supuestos para la consistencia de los estimadores en los modelos paramétricos.
- El problema es que los estimadores no paramétricos convergen más lento que los paramétricos:
 - Cuando $N \rightarrow \infty$ y h se ajusta óptimamente $\Rightarrow N \times h \rightarrow \infty$ y la varianza $\rightarrow 0$. Entonces, el estimador no paramétrico converge a la tasa $\sqrt{N \times h}$
 - Recordar que la tasa de convergencia paramétrica es $\sqrt{N}$ ($> \sqrt{N \times h}$), pero...a dónde convergen?

Los estimadores no paramétricos son siempre consistentes pero convergen más lentamente. Por eso requieren tamaños muestrales mayores.

Consistencia paramétrica versus no paramétrica

- La consistencia del estimador no paramétrico sólo requiere ajustar adecuadamente la elección del ancho de banda.
- En cambio, se requieren fuertes supuestos para la consistencia de los estimadores en los modelos paramétricos.
- El problema es que los estimadores no paramétricos convergen más lento que los paramétricos:
 - Cuando $N \rightarrow \infty$ y h se ajusta óptimamente $\Rightarrow N \times h \rightarrow \infty$ y la varianza $\rightarrow 0$. Entonces, el estimador no paramétrico converge a la tasa $\sqrt{N \times h}$
 - Recordar que la tasa de convergencia paramétrica es $\sqrt{N}$ ($> \sqrt{N \times h}$), pero...a dónde convergen?

Los estimadores no paramétricos son siempre consistentes pero convergen más lentamente. Por eso requieren tamaños muestrales mayores.

- $\hat{f}(x)$ es asintóticamente normal (por TCL, ya que $\hat{f}(x)$ es un promedio de VA iid)

$$\frac{\hat{f}(x) - E[\hat{f}(x)]}{\sqrt{V[\hat{f}(x)]}} \xrightarrow{d} N(0, 1)$$

$$\sqrt{N \times h} \hat{f}(x) \xrightarrow{d} N\left(f(x), N \times h V[\hat{f}(x)]\right)$$

- Intervalo asintótico al 95 % de confianza

$$\hat{f}(x) \pm 1,96(N \times h)^{-1/2} \left(f(x) \int K^2(\varphi) d\varphi \right)^{1/2}$$


- Como se trata de resultados asintóticos y vimos que $\hat{f}$ converge lento, en la práctica suelen usarse intervalos de confianza empíricos obtenidos por *bootstrap*.


Intervalos de confianza empíricos

- Pueden usarse en reemplazo de los intervalos de confianza asintóticos.
- Se construyen a partir de una distribución empírica del estimador, que se obtiene mediante técnicas de *bootstrap* (Hall 1992)
- Los pasos:
 - Datos originales: $x_1, \dots, x_N$
 - Obtención de las muestras bootstrap: remuestreo a partir de los datos: $x_1^j, \dots, x_N^j$ para $j = 1, \dots, J$.
 - Obtención del estimador para cada una de las J muestras bootstrap: $\hat{f}^j(x) = \frac{1}{N \times h} \sum K(\frac{x_i^j - x}{h})$
 - Estimación de la distribución empírica del estimador: usando las J realizaciones, estimamos no paramétricamente la distribución de $\hat{f}$
 - Intervalos de confianza empíricos: se construyen en base a los percentiles de la distribución empírica

- El estimador de promedios ponderados o Kernels es generalmente sesgado. El sesgo desaparece cuando $h \rightarrow 0$.
- Pero para consistencia requerimos que $h \rightarrow 0$ a un ritmo menor al que aumenta N . Esta es la única condición para consistencia.
- La velocidad de convergencia del estimador de Kernels es $\sqrt{N \times h}$ mientras $h \rightarrow 0$, más lenta que la velocidad paramétrica $\sqrt{N}$
- Además, la distribución del estimador de Kernels es asintóticamente normal, por lo que se pueden utilizar los procedimientos habituales de inferencia.


Ejemplo 1: la distribución del ingreso






- Más suave que el histograma, no tanto como una normal.
- Cierta grado de asimetría, apartamientos de la normal.
- Kernel Epanechnikov y el ancho de banda óptimo


Cambios en el ancho de banda



Cambios en el Kernel




Ejemplo 2: Desigualdad y salarios mínimos




Fuente: Di Nardo y Tobias (2001)

Ejemplo 2: Desigualdad y salarios mínimos



Fuente: Di Nardo y Tobias (2001)


Ejemplo 3: Evolución de la distribución del ingreso en Italia



Fuente: Li y Racine (2007), pp. 48. Basado en Baiocchi (2006).

Extensión 1: estimadores con ancho de banda flexible

Supongamos que queremos estimar $f(a)$ y $f(b)$




- Candidatos: $\hat{f}(a) = \frac{1}{N \times h} \sum_{i=1}^N K\left(\frac{x_i - a}{h}\right)$ y $\hat{f}(b) = \frac{1}{N \times h} \sum_{i=1}^N K\left(\frac{x_i - b}{h}\right)$
- Al usar el mismo h , sobresuavizamos la estimación en zonas como a y subsuavizamos la estimación en zonas como b .
- ¿Y si en vez de un único h usamos $h_a \neq h_b$? Por ejemplo, con $h_b > h_a$ garantizamos un número mínimo de obs. para cada estimación.
- ¿Y qué hay del sesgo, será mayor el de $\hat{f}(b)$?
No necesariamente, porque la densidad suele ser más plana en las colas; es decir, es probable que $f''(b) < f''(a)$.

Extensión 1: estimadores con ancho de banda flexible

Un ejemplo: estimador del vecino más cercano (NN, por *nearest neighbor*)

$$\hat{f}_{NN}(x_0) = \frac{1}{N \times h(x_0)} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

- donde $h(x_0) \equiv d_k(x_0)$ y $d_k(x_0)$ es la distancia euclídea entre x_0 y su k -ésimo vecino más cercano (k -NN).
- En la práctica, suele fijarse $k \cong \sqrt{N}$
- Ejemplo: $N = 12$ y $k = 3$



- Consistencia requiere que cuando $N \rightarrow \infty$, $k \rightarrow \infty$ (rol similar a $N \times h$) y $k/N \rightarrow 0$ (rol similar a h)

Extensión 2: estimación no paramétrica de densidades conjuntas

Generalizamos el estimador de promedios ponderados para estimar densidades conjuntas:

$$\hat{f}(x_0) = \frac{1}{N \times h^q} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

- donde $x_i = (x_{1i}, x_{2i}, \dots, x_{qi})$ es la i -ésima observación muestral de las q variables aleatorias y el punto de estimación es $x_0 \in \mathbb{R}^q$
- La distancia entre x_i y x_0 ahora involucra q dimensiones: h^q . Necesario estandarizar las variables para usar un mismo h .
- $\underline{K}(\cdot)$ es un kernel multivariado, usualmente multiplicativo:
$$\underline{K}\left(\frac{x_i - x_0}{h}\right) = \prod_{j=1}^q K\left(\frac{x_{ji} - x_{j0}}{h}\right)$$

La maldición de la dimensionalidad

- Recordemos: para la consistencia del estimador de la densidad univariada se requería que $N \times h \rightarrow \infty$ mientras $h \rightarrow 0$.
- Con q variables se requiere que $N \times h^q \rightarrow \infty$ mientras $h \rightarrow 0$.
 - Es decir, h tiene que tender a cero mucho más lento
 - Intuitivamente: el tamaño de la muestra local decrece exponencialmente cuando aumenta q (pensar en las celdas definidas por el cruce de variables y cómo cae el número de observaciones por celda cuando aumenta el número de cruces).
- Los estimadores de la densidad conjunta convergen mucho más lento: $\sqrt{N \times h^q} \left(< \sqrt{N \times h} < \sqrt{N} \right)$
- Para una aplicación de estimación no paramétrica de densidades conjuntas, ver Deaton (1997), desde página 182.

- Li, Q. and J. S. Racine (2007). Nonparametric Econometrics. Princeton University Press. Cap. 1.
- Pagan, A. and Ullah (1999). Nonparametric Econometrics. Cambridge University Press. Cap. 2.