

Regresiones no paramétricas

-Econometría Avanzada-

Mariana Marchionni
marchionni.mariana@gmail.com

Hoy: regresiones no paramétricas y semiparamétricas

- 1 Estimador Nadaraya-Watson
- 2 Polinomios locales
- 3 Modelo de regresión parcialmente lineal

$$Y = m(X) + \mu \quad \text{con } E[\mu|X] = 0$$

$$\Rightarrow E[Y|X] = m(X)$$

- usualmente hacemos supuestos paramétricos como $m(x) = \alpha + \beta x$, $m(x) = \alpha + \beta x + \gamma x^2$, $m(x) = \alpha + \beta \ln(x)$ o $m(x) = f(\beta x)$ con $f(\cdot)$ conocida
- ¿Cómo estimamos $m(\cdot)$ sin hacer supuestos paramétricos?
- La estrategia será estimar el valor de $m(\cdot)$ en cada punto de interés x , es decir, $m(X = x) = m(x)$

- Surge de aplicar el método de Kernels a la estimación de una esperanza condicional
- Intuición:
 - aprendimos a estimar no paramétricamente la densidad por medio de una especie de **frecuencia relativa ponderada local**
 - entonces podemos estimar $E[Y|X = x] = m(x)$ haciendo un **promedio ponderado local** de Y (o sea, en la vecindad de x).


El caso más simple:

- estimamos $E[Y|X = x] = m(x)$ promediando los valores de Y para observaciones con valores de X cercanos a x
- en este caso simple, definimos 'cercano' como 'a menos de un h de distancia de x '

$$\hat{m}(x) = \frac{\sum_{i=1}^N y_i I[-1 < (x_i - x)/h < 1]}{\sum_{i=1}^N I[-1 < (x_i - x)/h < 1]}$$

- Notar que estamos ponderando las observaciones mediante un Kernel uniforme.

Queremos estimar $m(0)$. Promediamos los valores de Y de las observaciones en el intervalo $(-h, h)$



Generalizando:

- reemplazamos la función ponderadora $l(\cdot)$ por Kernels suaves y decrecientes en $[(x_i - x)/h] = \varphi_i$

$$\hat{m}(x) = \frac{\sum_{i=1}^N y_i K(\varphi_i)}{\sum_{i=1}^N K(\varphi_i)} = \sum_{i=1}^N y_i \omega_i$$

- **Estimador Naradaya-Watson** (Naradaya, 1964; Watson, 1964)
- Notar: el estimador NW es un promedio ponderado de las y_i , donde los ponderadores ω_i son funciones *no lineales* de la distancia entre x_i y el punto de estimación x .

- Implícitamente estamos suponiendo que la regresión poblacional $m(\cdot)$ es suave, lo que justifica usar como criterio de ponderación la distancia alrededor de x .
- h sigue indicando qué significa estar lejos o cerca de x :
 - $h \rightarrow \infty, \hat{m}(x) = \sum y_i / N = \bar{Y}$
 - $h \rightarrow 0, \hat{m}(x) = y_i$ si $\exists x_i = x$

Generalizando para q variables explicativas

$$\hat{m}(x) = \frac{\sum_{i=1}^N y_i \underline{K}[(x_i - x)/h]}{\sum_{i=1}^N \underline{K}[(x_i - x)/h]}$$

- Ahora x y $x_i \in \mathbb{R}^q$ y $\underline{K}(\cdot)$ es un kernel multivariado, que pondera la distancia de x_i respecto de x considerando cada una de las q dimensiones
- Una forma usual es $\underline{K}(\cdot) = \prod_{j=1}^q K[(x_i^j - x^j)/h]$
- Notar que para trabajar con un mismo h para todas las dimensiones es necesario estandarizar las variables previamente.

Propiedades del estimador Nadaraya-Watson

- Consistencia requiere $h \rightarrow 0$ y $N \times h^q \rightarrow \infty$ cuando $N \rightarrow \infty$
- Convergencia a la tasa $\sqrt{N \times h^q}$ ($\sqrt{N \times h} < \sqrt{N}$)
- Maldición de la dimensionalidad: si queremos tener estimadores 'razonables' necesitamos mantener acotado el número de variables o muestras muy grandes.
- NW es asintóticamente normal

Estimadores de polinomios locales


- El estimador Naradaya-Watson es un caso particular de la familia de estimadores de polinomios locales
- Puede mostrarse que el estimador NW es la solución del problema:

$$\underset{a}{\text{Min}} \sum_{i=1}^N K\left(\frac{x_i - x}{h}\right) (y_i - a)^2$$

- a es la constante que minimiza la suma de los desvíos cuadráticos ponderados. Es decir, NW aproxima la función $m(\cdot)$ en el punto x mediante una constante a .
- De aquí que el estimador Naradaya-Watson también sea conocido como **estimador local constante**.

Ejemplo estimador local constante

Se ilustra la estimación de $E[Y|X = 2/3]$ mediante un estimador local constante (NW). La estimación es la línea (constante) horizontal, la zona sombreada representa el intervalo y los ponderadores *biweight* se representan por la campana.



Fuente Schucany, W. R (2004). "Kernel Smoothers: An Overview of Curve Estimators for the First Graduate Course in Nonparametric Statistics". Statistical Science, Vol. 19, No. 4, pp. 663-675

- El estimador local constante (NW) tiene sesgos potencialmente grandes en los límites del soporte.
- El estimador local lineal (Stone 1977, Cleveland 1979) permite corregir estos sesgos.
- El estimador local lineal surge de aproximar $m(x)$ mediante una función localmente lineal:

$$\underset{\{a,b\}}{\text{Min}} \sum_{i=1}^N K\left(\frac{x_i - x}{h}\right) \{y_i - [a + b(x_i - x)]\}^2$$

$$\underset{\{a,b\}}{\text{Min}} \sum_{i=1}^N K \left(\frac{x_i - x}{h} \right) \{y_i - [a + b(x_i - x)]\}^2$$


- Intuición: para x_i en un entorno pequeño alrededor de x

$$m(x_i) \cong \underbrace{m(x)}_a + \underbrace{m'(x)}_b (x_i - x)$$

- Es como estimar un modelo de regresión lineal en un entorno de x . La solución puede encontrarse por *NLLS* de Y en una constante y en $(x_i - x)$ con ponderadores $\sqrt{K_i}$
- Notar que $\hat{a}$ estima $m(x)$ y $\hat{b}$ estima la derivada $m'(x)$, es decir, el efecto marginal local.

Ejemplo estimador local lineal

La línea continua muestra la estimación local lineal de $E[Y|X]$ en 100 puntos del soporte. Sombreada se muestra la estimación en tres lugares con el ajuste lineal en rojo.



Fuente Schucany, W. R (2004). "Kernel Smoothers: An Overview of Curve Estimators for the First Graduate Course in Nonparametric Statistics". Statistical Science, Vol. 19, No. 4, pp. 663-675

Generalizando a un polinomio local de orden P :

$$\underset{\{b_0, b_1, \dots, b_P\}}{\text{Min}} \sum_{i=1}^N K \left(\frac{x_i - x}{h} \right) \left\{ y_i - \left[b_0 + b_1(x_i - x) + \dots + b_P(x_i - x)^P \right] \right\}^2$$

- Donde la aproximación local viene dada por:

$$m(x_i) \cong \underbrace{m(x)}_{b_0} + \underbrace{m'(x)}_{b_1} (x_i - x) + \dots + \underbrace{\frac{1}{P!} m^P(x)}_{b_P} (x_i - x)^P$$

- $\hat{b}_0$ estima $m(x)$, $\hat{b}_1$ estima $m'(x)$, ..., $p! \hat{b}_p$ estima a $m^p(x)$

¿Cómo elegir el grado del polinomio?

- Para estimar la media local $m(x)$, elegir un polinomio de orden impar
- Los polinomios de orden par son dominados por los de orden impar siguiente, porque el parámetro extra reduce el sesgo sin aumentar la varianza
- Para estimar la derivada $m^d(x)$, elegir el orden del polinomio de forma que $(P - d)$ sea impar.


Ejemplo con *motorcycle data* de Fan & Gijbels (1996)

- Fuente:
Fan and Gijbels (1996). *Local Polynomial Modelling and Its Applications*. Monographs on Statistics and Applied Probability, Chapman & Hall CRC.
- Datos en STATA:
use <http://www.stata-press.com/data/r11/motorcycle>
- 133 observaciones sobre la aceleración ($g = cm/seg^2$) de la cabeza del maniquí en tests de choques de motos.


Variable	Obs	Mean	Std. Dev.	Min	Max
time	133	25.17895	13.13206	2.4	57.6
accel	133	-25.54586	48.32205	-134	75

Los datos: la aceleración en el tiempo

- scatter accel time




- regress accel time




Modelo cuadrático, MCO

- regress accel time time^2




- regress accel time time^2 time^3



Estimación no paramétrica:


Local constante (grado 0 = Nadaraya-Watson)

- lpolynomial accel time, degree(0)



Estimación no paramétrica: Local lineal (grado 1)


- lpoly accel time, degree(1)



Estimación no paramétrica:


Local polinómico grado impar siguiente (grado 3)

- lpoly accel time, degree(3)




Mejoramos el ajuste con un kernel diferente

- `lpoly accel time, degree(3) k(epan2)`



Agregamos intervalos de confianza

- `lpoly accel time, degree(3) k(epan2) ci`



- Blundell and Duncan (1998). “Kernel Regression in Empirical Microeconomics”. *The Journal of Human Resources*, Vol. 33, No. 1, pp. 62-87.
- Ley de Engel: a medida que crece el presupuesto de las familias, el porcentaje gastado en alimentos tiende a caer
- Relación entre el *share* del gasto en alimentos y el logaritmo del gasto total de las familias:
 - La ley sugiere una relación negativa
 - ¿Forma funcional?

Curva de Engel: share del gasto en alimentos




Figure 3
Nonparametric Engel Curve: Food Share
Source: Banks, Blundell, and Lewbel (1997).

Curva de Engel: share del gasto en alcohol




Figure 4

Nonparametric Engel Curve: Alcohol Share

Source: Banks, Blundell, and Lewbel (1997).

Sensibilidad a la elección del ancho de banda: curva de Engel del share de alcohol




Figure 5
Sensitivity to Bandwidth Selection: Alcohol Engel Curve

Otros estimadores no paramétricos: método de series

- Hasta ahora vimos estimadores de carácter local
- Los estimadores de series (o de forma flexible) parten de una lógica distinta: buscan ajustar **globalmente** una función desconocida $m(\cdot)$
- ¿Cómo hacerlo sin recurrir a supuestos paramétricos?
- Hay ciertas funciones (llamadas 'funciones base') que, combinadas linealmente, permiten aproximar bien cualquier otra función suave.
- La combinación de estas funciones base es una **serie**, de ahí el nombre **método de series**

Ejemplo: forma flexible de Fourier

Combina series de potencias y de funciones trigonométricas

$$m(x_i) \cong \underbrace{a}_{\text{nivel}} + \underbrace{b \cdot x_i}_{\text{tendencia}} + \underbrace{c \cdot x_i^2}_{\text{curvatura}} +$$

$$\underbrace{d \cdot \cos(x_i) + e \cdot \sin(x_i) + f \cdot \cos(2x_i) + g \cdot \sin(2x_i) + \dots}_{\text{sintonía fina}}$$

- Para cierto valor de los parámetros, cuando el número de términos tiende a infinito la serie converge a $m(\cdot)$
- Esto es una **propiedad matemática de la serie**, NO es un supuesto sobre la forma funcional de $m(\cdot)$
- En este sentido es un método no paramétrico
- Estimación: por MCO, regresando y_i en todos los términos de la serie

Propiedades de los estimadores de series

- La consistencia depende únicamente de que el número de términos en la serie tienda a infinito cuando $N \rightarrow \infty$
- Convergen a la tasa paramétrica $\sqrt{N}$
- Son asintóticamente normales
- La aplicación se hace algo más complicada cuando hay múltiples regresores

Testeando la validez de una especificación paramétrica

- Un poco de historia: test de Hausman (1978)
- Vimos aplicación en paneles para evaluar EF vs. EA.
- Aquí vamos a usarlo para comparar dos especificaciones paramétricas
 - H_0 : el modelo 0 (paramétrico) es cierto
 - H_1 : el modelo 1 (paramétrico) es cierto

- Supongamos que hay 2 estimadores de un parámetro del modelo
 - $\hat{\beta}_0$: consistente y eficiente bajo H_0 , inconsistente bajo H_1 .
 - $\hat{\beta}_1$: siempre consistente (H_0 o H_1) pero no eficiente.
- Intuición de la estrategia:
 - si H_0 es cierta, los dos estimadores deberían ser parecidos.
 - Diferencias grandes sugieren rechazar H_0 .
- Estadístico de Hausman

$$H = (\hat{\beta}_1 - \hat{\beta}_0)'(\hat{\Omega}_1 - \hat{\Omega}_0)^{-1}(\hat{\beta}_1 - \hat{\beta}_0) \stackrel{H_0}{\sim} \chi^2_{(dim.\beta)}$$

Testeando la validez de una especificación paramétrica

- Problema: tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ son inconsistentes si los dos modelos paramétricos son inválidos
- Sería mejor comparar un modelo paramétrico contra una alternativa no paramétrica
 - $H_0 : E[Y|x] = f(x, \beta_0)$ para algún β_0 y $f(\cdot)$ conocida
 - $H_1 : E[Y|x] \neq f(x, \beta)$, para cualquier β (involucra cualquier desviación respecto de H_0)
- Zheng (1996, Journal of Econometrics): propone usar el método de Kernels para construir un estimador de la condición de momento que permite distinguir H_0 de H_1

- Estadístico de Zheng

$$T_N = \frac{\sum_{i=1}^N \sum_{j(\neq i)=1}^N K[(x_i - x_j)/h] e_i e_j}{\left\{ \sum_{i=1}^N \sum_{j(\neq i)=1}^N 2 [K[(x_i - x_j)/h]]^2 e_i^2 e_j^2 \right\}^{1/2}} \xrightarrow{H_0} N(0, 1)$$

- donde e son los residuos de estimar el modelo paramétrico de la H_0 , es decir, $e_i = y_i - f(x_i, \hat{\beta})$.
- Si $f(\cdot)$ es lineal en β , $\hat{\beta}$ se obtiene por OLS; si es no lineal, $\hat{\beta}$ se obtiene por NLLS.
- Si $|T_N|$ es grande, se rechaza la validez de la especificación paramétrica.
- Blundell y Duncan (1998) usan una notación más simplificada (ver pág. 74)

- Las especificaciones no paramétricas garantizan consistencia de los estimadores
- Pero tienen contras:
 - la convergencia es lenta, necesitamos muestras muy grandes.
 - además, el problema se agrava exponencialmente cuando aumenta el número de regresores.
 - los resultados suelen ser difíciles de comunicar (resumir).
 - como no hay un modelo, no se pueden extrapolar los resultados para otros valores de las x .
- Los modelos semiparamétricos permiten superar algunas de estas limitaciones

Un modelo semiparamétrico:

- es una opción intermedia entre un modelo totalmente paramétrico y otro no paramétrico totalmente flexible.
- es decir, hace algunos supuestos sobre la forma funcional, sin llegar a parametrizar todos los elementos de la esperanza condicional.
- Entonces, un modelo semiparamétrico implica una solución de compromiso entre los objetivos de consistencia y eficiencia:
 - permitiría reducir el riesgo de error de especificación respecto de los modelos paramétricos
 - y aumentar la precisión de la estimación respecto de las alternativas no paramétricas

Modelos semiparamétricos de índices lineales

- Un modelo de índices lineales viene dado por

$$E[Y|X = x] = g(X\beta)$$

donde $g(\cdot)$ es una función desconocida, β es un vector desconocido y $X\beta$ es el índice lineal simple

- ¿Conocen algún un modelo paramétrico de índices lineales?
- Ventaja de la versión semiparamétrica:
 - cuando $g(\cdot)$ es desconocida tenemos más flexibilidad que en los casos paramétricos
 - al agregar todas las dimensiones de $X \in \mathbb{R}^q$ en un índice lineal $X\beta \in \mathbb{R}$ no tenemos los altos costos de eficiencia de los estimadores no paramétricos.

- Resultado:
 - la función desconocida $g(\cdot)$ puede estimarse a la misma velocidad de convergencia que obtendríamos si $X\beta$ fuera observable.
 - β también puede estimarse consistentemente a la tasa $\sqrt{N}$ pese a que $g(\cdot)$ no se conoce.
- Hay varias condiciones de identificación importantes a tener en cuenta. Ej. $g(\cdot)$ no puede ser constante.

Otro modelo semiparamétrico: esperanza condicional parcialmente lineal

- Considerar el siguiente modelo:

$$Y = X\beta + g(Z) + \varepsilon$$

- donde $X_{N \times p}$ y $\beta_{p \times 1}$ es un vector de coeficientes con significado económico y
- $Z_{N \times 1}$ y $g(\cdot)$ es una función desconocida
- Alternativas:
 - Omitir Z : $\hat{\beta}$ se obtiene por OLS regresando Y en X ; inconsistencia si X y Z están correlacionadas.
 - Especificar $g(\cdot)$ paramétricamente y estimar por OLS o NLLS; inconsistencia si el supuesto paramétrico es incorrecto.
- **Método de Robinson (1988)**: se puede estimar consistentemente β a la tasa de convergencia paramétrica $\sqrt{N}$ a pesar de la presencia del término no paramétrico $g(\cdot)$.

- Considerar nuevamente el modelo:

$$Y = X\beta + g(Z) + \varepsilon$$

con $E[\varepsilon|X, Z] = 0$, $V[\varepsilon|X, Z] = \sigma_\varepsilon^2$; Z y X no son totalmente dependientes; tampoco son independientes (por qué?).

- Computar la esperanza condicional en Z :

$$E[Y|Z] = E[X|Z]\beta + g(Z) + \underbrace{E[\varepsilon|Z]}_{=0}$$

- Restando del modelo original:

$$\underbrace{Y - E[Y|Z]}_{Y^*} = \underbrace{[X - E[X|Z]]}_{X^*}\beta + \varepsilon$$

- Este modelo no es estimable. ¿Por qué?

- El modelo transformado

$$\underbrace{Y - E[Y|Z]}_{Y^*} = \underbrace{[X - E[X|Z]]}_{X^*} \beta + \varepsilon$$

- Estimador en dos etapas de Robinson:

- 1 Estimar $E[Y|Z]$ y $E[X|Z]$ usando un estimador no paramétrico (por ejemplo, local polinómico)
- 2 Obtener $\hat{\beta}_{Rob}$ regresando por OLS $\hat{Y}^* = Y - \hat{E}[Y|Z]$ en $\hat{X}^* = X - \hat{E}[X|Z]$

- Propiedades:

- $\hat{\beta}_{Rob}$ es consistente y converge a la tasa paramétrica $\sqrt{N}$
- Asintóticamente normal: $\sqrt{N}(\hat{\beta}_{Rob} - \beta) \xrightarrow{d} N(0, V(\hat{\beta}_{Rob}))$

- Otras cuestiones a tener en cuenta:
 - el vector β no está identificado si contiene alguna constante
 - Z puede incluir más de una variable, pero todas deben ser continuas (condición de suavidad de las densidades f_z , ver pág. 939 de Robinson '88)
- Estimación no paramétrica de $g(\cdot)$ una vez estimado $\hat{\beta}_{Rob}$:
regresar no paramétricamente $Y - X\hat{\beta}_{Rob}$ en Z para obtener estimaciones puntuales de $g(\cdot)$

- Li, Q. and J. S. Racine (2007). Nonparametric Econometrics. Princeton University Press. Cap. 2 y 6. En Cap. 7 está el último tema.
- Pagan, A. and Ullah (1999). Nonparametric Econometrics. Cambridge University Press. Cap. 3. En capítulo 5.2 está el último tema.