

Modelos para datos en panel

Mariana Marchionni
marchionni.mariana@gmail.com

Econometría Avanzada
Maestría en Economía - FCE - UNLP

Temario de la clase

- 1 Los datos en panel
- 2 Estimador de efectos fijos
- 3 Estimador de efectos aleatorios

Datos en panel

- Una base de datos en panel contiene información para varios individuos (empresas, países, etc.) a lo largo del tiempo.
- Rasgo fundamental: los datos tienen *dos dimensiones*
 - corte transversal: muestra de N individuos en cada $t = 1, \dots, T$.
 - corte longitudinal: series de T periodos para cada $i = 1, \dots, N$.

Ejemplo

para cada año $t = 1, \dots, 4$ tenemos un corte transversal $i = 1, \dots, 3$

Total de observaciones $N \times T = 3 \times 4$

i	t	edad	sexo	nivel_edu	trabaja
1	2005	15	1	seci	0
2	2005	23	2	supi	0
3	2005	42	2	secc	1
1	2006	16	1	seci	0
2	2006	24	2	supi	1
3	2006	43	2	secc	0
1	2007	17	1	seci	0
2	2007	25	2	supc	1
3	2007	44	2	secc	1
1	2008	18	1	secc	0
2	2008	26	2	supc	1
3	2008	45	2	secc	0

Ejemplo

Mismos datos pero ordenados distinto: individuos apilados previamente ordenados en el tiempo.

Para cada $i = 1, \dots, 3$ tenemos una serie de tiempo con $T = 4$ obs.

i	t	edad	sexo	nivel_edu	trabaja
1	2005	15	1	seci	0
1	2006	16	1	seci	0
1	2007	17	1	seci	0
1	2008	18	1	secc	0
2	2005	23	2	supi	0
2	2006	24	2	supi	1
2	2007	25	2	supc	1
2	2008	26	2	supc	1
3	2005	42	2	secc	1
3	2006	43	2	secc	0
3	2007	44	2	secc	1
3	2008	45	2	secc	0

Paneles en el mundo

- En Estados Unidos: *Panel Study of Income Dynamics (PSID)* desde 1968. Empezó con 4.800 familias y ahora supera las 9.000. Información sobre 70.000 individuos a lo largo de 4 décadas.
Otro ejemplo para USA: *National Longitudinal Survey of Youth (NLSY)*, ej. en el TP)
- Algunos paneles en América Latina:
 - Chile: CASEN 2006-2009
 - Perú: panel ENAHO, 5 años consecutivos desde 2007
 - Algunas encuestas de hogares tienen estructura de paneles rotativos (por ej. EPH en Argentina).

¿Por qué paneles?

Cornwell y Trumbull (C&T, 1994, Rev Econ Stat): determinantes de la tasa de criminalidad.

- La Economía del Crimen (Becker y otros) supone que los individuos deciden si participar o no de actividades delictivas en función de los beneficios y costos esperados.
- Se consideran los beneficios monetarios y los costos dependen de la eficacia de la justicia penal (probabilidad de arresto, severidad de las penas, etc.).
- La teoría predice efectos negativos de la eficacia de la justicia sobre la tasa de criminalidad. Determinar la magnitud de los efectos requiere de un análisis empírico.

¿Por qué paneles?

- Hasta C&T la evidencia provenía de estimaciones MCO basadas en información cross-section para distintas jurisdicciones (por ej. provincias). Los efectos estimados eran muy grandes.
- Crítica de C&T: esos resultados sobreestiman el verdadero efecto de la justicia penal ya que no logran controlar por diferencias inobservables entre jurisdicciones.
- En jerga econométrica: hay variables omitidas que están correlacionada con la justicia penal $\implies$ sesgo e inconsistencia de los estimadores MCO.

¿Por qué paneles?

- **Ejemplo:**
 - 2 jurisdicciones A y B idénticas, pero en A la policía registra la mitad de los delitos denunciados mientras en B se registran todos.
 - Entonces, la tasa de crimen en A resulta menor y la probabilidad de arresto mayor que en B.
 - Si este patrón de sub-registro de delitos se repite en la muestra, los estimadores MCO sobreestimarán el efecto disuasivo de la probabilidad de arresto sobre la tasa de criminalidad.
- **¿Solución? “controlar” por esta variable omitida.**
- **¿Y si es inobservable? → paneles.**

Ventajas de los paneles

- Permiten controlar *heterogeneidades no observables* $\Rightarrow$ evitan sesgos
- Permiten mayor eficiencia en la estimación
Con N individuos y T observaciones temporales de cada uno podríamos estimar
 - N modelos de series de tiempo
 - T modelos de corte transversal
 - Un único modelo usando las $N \times T$ observaciones del panel (*pooled data*) $\Rightarrow$ mayor eficiencia.

Otras ventajas de los paneles

- **Permiten estudiar la dinámica de los efectos de interés.**

Por ejemplo, al observar los mismos individuos/hogares a lo largo del tiempo, puede estudiarse si un shock sobre los ingresos tiene efectos permanentes o transitorios (Sosa-Escudero, Marchionni & Arias, 2011).

Otras ventajas de los paneles

- **Permiten identificar transiciones que no sería posible con otro tipo de datos.**

Por ejemplo, la observación de “la tasa de participación laboral entre las mujeres es del 50 %” es compatible con dos realidades muy distintas:

- (a) que cada mujer tiene una probabilidad de 50 % de ser económicamente activa en cada periodo (alta rotación entre la actividad y la inactividad) o
- (b) la mitad de las mujeres siempre está inactiva y la otra mitad siempre trabajando o buscando trabajo (persistencia total de la condición de actividad).
- Solo con paneles podemos distinguir entre las dos situaciones.
- Ver Cap. 1 de Baltagi 2008 para más ejemplos.

Desventajas de los paneles

- No siempre es posible agregar información temporal y de corte transversal (cambios estructurales, poblaciones muy heterogéneas)
- Administrativamente: los paneles son muy costosos e implican una logística compleja.
- Problemas de muestreo: auto-selección, *attrition*.
- Dimensión temporal breve (T chico).

El modelo básico de componente de errores

Para una observación cross-section i , tenemos el modelo

$$y_{it} = x'_{it}\beta + u_{it} \quad i = 1, \dots, N; \quad t = 1, \dots, T$$

$$\text{con } u_{it} = \mu_i + \varepsilon_{it}$$

- x_{it} : vector $K \times 1$ de variables explicativas (incluye constante).
- β : vector $K \times 1$ de parámetros de interés.
- u_{it} : término aleatorio del modelo con dos componentes:
 - μ_i : efecto inobservable específico del individuo (firma, familia, escuela, provincia, etc.). Distintos nombres: heterogeneidad inobservable, componente inobservable, efecto individual, etc.
 - ε_{it} : error idiosincrático de cada observación it . En general, vamos a suponer que satisface los supuestos clásicos.
 - Un caso más general agrega otro componente que cambia solo en el tiempo (δ_t). No lo veremos.

El caso más simple: sin heterogeneidad inobservable ($\mu_i = 0$)

El modelo se simplifica: $y_{it} = x'_{it}\beta + \varepsilon_{it}$

- Podemos estimarlo por MCO usando las $N \times T$ observaciones (*pooled data*): **pooled OLS (POLS)**
- POLS es consistente si (1) $E[x'_{it}.u_{it}] = 0 \rightarrow$ **exogeneidad contemporánea** en términos de correlaciones. Cuando $\mu_i = 0$, la condición suficiente para (1) es (2) $E[x'_{it}.\varepsilon_{it}] = 0$
- Para insesgamiento de POLS se requiere un supuesto algo más fuerte: (1') $E[u_{it}|x_{it}] = 0 \rightarrow$ **exogeneidad contemporánea en medias**, que también implica (1).
- Importante: ni (1) ni (1') imponen ortogonalidad entre x_{is} y u_{it} (o ε_{it}) para $s \neq t$.
- La estructura de panel no cambia la forma de estimar $\beta \Rightarrow$ lo que motiva buscar otro estimador es la presencia de μ_i .

Si hay heterogeneidad inobservable

El término de error ahora tiene dos componentes: $u_{it} = \mu_i + \varepsilon_{it}$

- Ya no alcanza con suponer (2) $E[x'_{it} \cdot \varepsilon_{it}] = 0$. Para consistencia de POLS también se requiere que (3) $E[x'_{it} \cdot \mu_i] = 0$, es decir, que la heterogeneidad inobservable sea ortogonal a todos los elementos de x_{it} .
- Si se cumplen (2) y (3) POLS es consistente pero tenemos que ocuparnos de otros problemas...veamos

Si hay heterogeneidad inobservable

- Aunque cada uno de los dos componente del término de error (μ_i y ε_{it}) cumpliera los supuestos clásicos (exogeneidad, homocedasticidad, no autocorrelación) y además fueran ortogonales entre sí, el error compuesto $u_{it} = \mu_i + \varepsilon_{it}$ sufre de autocorrelación para cada i en el tiempo.
- Intuición: notar que $u_{it} = \mu_i + \varepsilon_{it}$, mientras que $u_{it-1} = \mu_i + \varepsilon_{it-1}$: u_{it} comparte el mismo μ_i en distintos momentos del tiempo $\Rightarrow$ es necesario recurrir al estimador robusto de la matriz de varianzas y covarianzas de $\hat{\beta}_{POLS}$.

Si hay heterogeneidad inobservable

En resumen:

- Si se satisfacen los supuestos (2) y (3) (las x_{it} son exógenas respecto de ambos componentes del término de error), POLS es consistente pero para inferencia se requieren estimadores robustos a autocorrelación.
- Si (3) no se cumple, POLS es sesgado e inconsistente → los paneles pueden contribuir a solucionar el problema

Antes de avanzar veamos algo de notación matricial...

Si hay heterogeneidad inobservable

En resumen:

- Si se satisfacen los supuestos (2) y (3) (las x_{it} son exógenas respecto de ambos componentes del término de error), POLS es consistente pero para inferencia se requieren estimadores robustos a autocorrelación.
- Si (3) no se cumple, POLS es sesgado e inconsistente → los paneles pueden contribuir a solucionar el problema

Antes de avanzar veamos algo de notación matricial...

Notación matricial para paneles

Si apilamos las observaciones de cada uno de los N individuos, previamente ordenadas en el tiempo, tenemos:

		$Y_{NT \times 1}$	$X_{NT \times K}$	
i	t	y	cons.	x
1	1	$y_{1,1}$	1	$x_{1,1}$
1	2	$y_{1,2}$	1	$x_{1,2}$
1	3	$y_{1,3}$	1	$x_{1,3}$
2	1	$y_{2,1}$	1	$x_{2,1}$
2	2	$y_{2,2}$	1	$x_{2,2}$
2	3	$y_{2,3}$	1	$x_{2,3}$
...	...	...	...	...
N-1	1	$y_{N-1,1}$	1	$x_{N-1,1}$
N-1	2	$y_{N-1,2}$	1	$x_{N-1,2}$
N-1	3	$y_{N-1,3}$	1	$x_{N-1,3}$
N	1	$y_{N,1}$	1	$x_{N,1}$
N	2	$y_{N,2}$	1	$x_{N,2}$
N	3	$y_{N,3}$	1	$x_{N,3}$

Notación matricial para paneles

Entonces podemos escribir el modelo como:

$$Y = X\beta + u$$

con $Y_{NT \times 1}$, $X_{NT \times K}$ y $u_{NT \times 1}$.

- El estimador POLS es el MCO usando las $N \times T$ observaciones (pool data), entonces:

$$\hat{\beta}_{POLS} = (X'X)^{-1}X'Y$$

- Cuando no hay heterogeneidad inobservable el vector $u_{NT \times 1}$ satisface todos los supuestos clásicos $\Rightarrow \hat{\beta}_{POLS}$ es MELI.
- Entonces, lo que justifica buscar métodos de estimación alternativos es la presencia de heterogeneidad inobservable.

Modelo de efectos fijos

- Supongamos que μ_i es un **valor fijo** en el tiempo:

$$y_{it} = x'_{it}\beta + \mu_i + \varepsilon_{it}$$

- Notar: puede interpretarse como un modelo lineal donde cada individuo i tiene su propia ordenada al origen:

$$y_{it} = \underbrace{\beta_1 + \mu_i}_{\text{ordenada al origen}} + \beta_2 x_{2,it} + \dots + \beta_K x_{K,it} + \varepsilon_{it}$$

- Equivale a incluir una *dummy* por cada individuo ($N - 1$ para evitar multicolinealidad perfecta con la constante).
- Importante: las μ_i pasaron a ser parámetros a estimar.

Las variables *dummy* por individuo en la base de datos

		$X_{NT \times K}$		$D_{NT \times (N-1)}$			
i	t	cons.	x	d1	d2	...	dN-1
1	1	1	$x_{1,1}$	1	0	0	0
1	2	1	$x_{1,2}$	1	0	0	0
1	3	1	$x_{1,3}$	1	0	0	0
2	1	1	$x_{2,1}$	0	1	0	0
2	2	1	$x_{2,2}$	0	1	0	0
2	3	1	$x_{2,3}$	0	1	0	0
...	...	...	...	...	...	...	...
N-1	1	1	$x_{N-1,1}$	0	0	0	1
N-1	2	1	$x_{N-1,2}$	0	0	0	1
N-1	3	1	$x_{N-1,3}$	0	0	0	1
N	1	1	$x_{N,1}$	0	0	0	0
N	2	1	$x_{N,2}$	0	0	0	0
N	3	1	$x_{N,3}$	0	0	0	0

Modelo de efectos fijos

En notación matricial

$$Y = X\beta + D\mu + \varepsilon$$

D es una matriz $(N \times T) \times (N - 1)$, donde:

- En las $N \times T$ filas están las observaciones apiladas por individuo, previamente ordenadas en el tiempo.
- En las columnas, las $N - 1$ variables binarias, una por cada individuo menos el “individuo base”.

$$D_{NT \times (N-1)} = \begin{bmatrix} 1_T & 0 & \cdots & 0 \\ 0 & 1_T & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1_T \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad \text{con} \quad 1_T = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

$$\Rightarrow D\mu = \begin{bmatrix} \mu_{1,T} & 0 & \cdots & 0 \\ 0 & \mu_{2,T} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \mu_{N-1,T} \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad \text{con} \quad \mu_{i,T} = \begin{bmatrix} \mu_i \\ \mu_i \\ \vdots \\ \mu_i \end{bmatrix}$$

Estimador de efectos fijos (EF)

Entonces, el modelo de efectos fijos con dummies viene dado por:

$$Y = X\beta + D\mu + \varepsilon = \tilde{X}\theta + \varepsilon$$

donde $\tilde{X} = [X \ D]$ y $\theta = \begin{bmatrix} \beta \\ \mu \end{bmatrix}$.

El estimador de efectos fijos (EF) viene dado por:

$$\hat{\theta}_{EF} = \begin{bmatrix} \hat{\beta}_{EF} \\ \hat{\mu}_{EF} \end{bmatrix} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y$$

El estimador EF es el estimador de MCO del modelo con variables *dummy* por individuo.

Estimador de efectos fijos (EF)

Entonces, el modelo de efectos fijos con dummies viene dado por:

$$Y = X\beta + D\mu + \varepsilon = \tilde{X}\theta + \varepsilon$$

donde $\tilde{X} = [X \ D]$ y $\theta = \begin{bmatrix} \beta \\ \mu \end{bmatrix}$.

El estimador de efectos fijos (EF) viene dado por:

$$\hat{\theta}_{EF} = \begin{bmatrix} \hat{\beta}_{EF} \\ \hat{\mu}_{EF} \end{bmatrix} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y$$

El estimador EF es el estimador de MCO del modelo con variables *dummy* por individuo.

Transformación *within*

El estimador de EF con dummies exige invertir la matriz $(\tilde{X}'\tilde{X})$ de dimensión $(N-1+K)$. Es enorme! Veamos otra opción...

- Partiendo del modelo con efectos fijos

$$y_{it} = x'_{it}\beta + \mu_i + \varepsilon_{it}$$

- Calculemos el promedio para cada i a lo largo de los T periodos (**modelo *Between***):

$$\bar{y}_i = \bar{x}_i' \beta + \mu_i + \bar{\varepsilon}_i$$

- Restando del modelo original, se obtiene el **modelo *Within***:

$$\begin{aligned} \underbrace{y_{it} - \bar{y}_i}_{y_{it}^*} &= \underbrace{(x'_{it} - \bar{x}'_i)}_{x_{it}^{*'}} \beta + \underbrace{(\varepsilon_{it} - \bar{\varepsilon}_i)}_{\varepsilon_{it}^*} \end{aligned}$$

Notar que en el modelo *within*

$$y_{it}^* = x_{it}^{*'} \beta + \varepsilon_{it}^*$$

- Las variables están expresadas en desvíos: capturan variaciones en el tiempo para cada individuo (*within* individuo).
- El vector de coeficientes β del modelo Within permite responder cómo la variabilidad de las x en el tiempo para cada individuo explica la variabilidad de y
- *Importante*: hemos eliminado el componente μ_i , heterogeneidad inobservable y fuente potencial de sesgo.
- También hemos eliminado cualquier otro componente de x constante en el tiempo (ej. ordenada al origen): el modelo *within* no permite estimar el efecto de variables constantes en el tiempo (el modelo con dummies tampoco!).

Resultado:

- Regresar y_{it}^* en x_{it}^* por MCO es *matemáticamente equivalente* a obtener $\hat{\beta}_{EF}$ a partir del modelo con dummies por individuo.
- En forma matricial:

$$\hat{\beta}_{EF} = (X^{*'} X^*)^{-1} X^{*'} Y^*$$

Existen 2 formas idénticas de computar $\hat{\beta}_{EF}$:

- Regresar por MCO y en x y en las variables binarias por individuo. $\hat{\beta}_{EF}$ son los coeficientes estimados para las x .
- En 2 pasos:
 - 1 expresar las variables en desvíos respecto a la media por individuo
 - 2 regresar las variables en desvíos.

Resultado:

- Regresar y_{it}^* en x_{it}^* por MCO es *matemáticamente equivalente* a obtener $\hat{\beta}_{EF}$ a partir del modelo con dummies por individuo.
- En forma matricial:


$$\hat{\beta}_{EF} = (X^{*'} X^*)^{-1} X^{*'} Y^*$$

Existen 2 formas idénticas de computar $\hat{\beta}_{EF}$:

- Regresar por MCO y en x y en las variables binarias por individuo. $\hat{\beta}_{EF}$ son los coeficientes estimados para las x .
- En 2 pasos:
 - 1 expresar las variables en desvíos respecto a la media por individuo
 - 2 regresar las variables en desvíos.


Un ejemplo gráfico de EF (C&T)

y: tasa de criminalidad, x: ineficiencia de la justicia penal (ej. % de delincuentes que se escapan)




Un ejemplo gráfico de EF (C&T)

y: tasa de criminalidad, x: ineficiencia de la justicia penal (ej. % de delincuentes que se escapan)




Un ejemplo gráfico de EF (C&T)

MCO de y en x con pooled data: $\hat{\beta}_{POLS}$ es sesgado e inconsistente si la het. inobservable está correlacionada con x



Un ejemplo gráfico de EF (C&T)

Corregimos el sesgo agregando dummies por región
(estimador de EF)



Propiedades del estimador EF

- ¿Cuáles son las condiciones para consistencia de $\hat{\beta}_{EF}$? Veremos que ya no es suficiente con exogeneidad contemporánea
(2) $E[x'_{it} \cdot \varepsilon_{it}] = 0$.
- Veámoslo con un ejemplo: supongamos un panel con solo dos periodos

$$y_{it} = x'_{it}\beta + \mu_i + \varepsilon_{it} \text{ para } t = 1, 2$$

- Restemos el modelo en $t = 1$ del modelo en $t = 2$:

$$\begin{aligned} \underbrace{y_{i2} - y_{i1}}_{\Delta y_i} &= \underbrace{(x'_{i2} - x'_{i1})}_{\Delta x'_i} \beta + \underbrace{(\varepsilon_{i2} - \varepsilon_{i1})}_{\Delta \varepsilon_i} \\ \Delta y_i &= \Delta x'_i \beta + \Delta \varepsilon_i \end{aligned}$$

Propiedades del estimador EF

- Se conoce como **modelo en primeras diferencias**. Notar similitud con modelo Within.

$$\Delta y_i = \Delta x_i' \beta + \Delta \varepsilon_i$$

- Consistencia de MCO de Δy en Δx requiere que $E[\Delta x_i' \cdot \Delta \varepsilon_i] = 0$. Con algo de álgebra:

$$E[\Delta x_i' \cdot \Delta \varepsilon_i] = E[x_{i1}' \cdot \varepsilon_{i1}] + E[x_{i2}' \cdot \varepsilon_{i2}] - E[x_{i1}' \cdot \varepsilon_{i2}] - E[x_{i2}' \cdot \varepsilon_{i1}]$$

- Los dos primeros términos son $= 0$ si se cumple **exogeneidad contemporánea** (supuesto 2).
- Para que los últimos dos términos sean nulos necesitamos además que ε_{it} no esté correlacionado con x_{is} para $s \neq t$;
- Esto es **exogeneidad estricta**.

Propiedades del estimador EF

Resumiendo, ¿qué se requiere para consistencia de $\hat{\beta}_{EF}$?

- EF no requiere el supuesto (3) $E[x'_{it} \cdot \mu_i] = 0$ (¿por qué?)
- Pero exogeneidad contemporánea (2) $E[x'_{it} \cdot \varepsilon_{it}] = 0$ ya no alcanza
- Necesitamos un supuesto más fuerte:
(4) $E[x'_{it} \cdot \varepsilon_{it}] = 0 \quad s, t = 1, \dots, T \rightarrow$ **exogeneidad estricta.**
- Si se cumple (4) $\Rightarrow \hat{\beta}_{EF}$ es consistente cuando N o $T \rightarrow \infty$
- Sin embargo, el estimador de los efectos individuales del modelo con dummies ($\hat{\mu}_{EF}$) no es consistente porque el número de parámetros tiende a infinito junto con N .

Otro modelo: efectos aleatorios

El modelo es, en apariencia, el mismo

$$y_{it} = x'_{it}\beta + \underbrace{\mu_i}_{\text{efecto aleatorio}} + \varepsilon_{it}$$

La diferencia es el tratamiento de μ_i :

- sigue siendo inobservable
- pero en lugar de ser fijo lo suponemos *aleatorio*

EF vs. EA

Volviendo a la notación matricial, el modelo con dummies por individuo es:

$$Y = X\beta + D\mu + \varepsilon$$

- EF: trata a D como regresores y a μ como un vector de parámetros a estimar. El término aleatorio es ε

$$Y = X\beta + D\mu + \underbrace{\varepsilon}$$

- EA: trata a $D\mu$ como variables aleatorias omitidas, que quedan incluidas en el término aleatorio del modelo.

$$Y = X\beta + \underbrace{D\mu + \varepsilon}$$

Estimador de EA

$$y_{it} = x'_{it}\beta + \underbrace{\mu_i + \varepsilon_{it}}$$

- Para la consistencia del estimador de EA se requiere
 - exogeneidad estricta (supuesto 4)
 - ortogonalidad entre la heterogeneidad inobservable y los regresores (supuesto 3).
 - Para inferencia y propiedades de eficiencia se necesitan supuestos algo más fuertes (por ej. exogeneidad estricta en términos de medias condicionales).
- Notar que son supuestos similares pero más fuertes que los que se requerían para consistencia de POLS, donde en vez del sup. 4 bastaba con exogeneidad contemporánea (sup. 2).
- ¿Por qué no usar POLS entonces? Veremos que EA permitiría ganar eficiencia.

Estimador de EA

- Suponer que cada componente del error cumple los supuestos clásicos y son ortogonales entre sí:
 - $V(\mu_i) = \sigma_\mu^2$ y $V(\varepsilon_{it}) = \sigma_\varepsilon^2$: homocedasticidad
 - $E[\mu_i \cdot \mu_j] = 0$ $i \neq j$: no correlación entre individuos
 - $E[\varepsilon_{it} \cdot \varepsilon_{js}] = 0$ $i \neq j$ y $t \neq s$: no correlación entre individuos ni en el tiempo
 - $E[\mu_i \cdot \varepsilon_{it}] = 0$: los dos componentes son ortogonales
- Puede mostrarse que el error compuesto $u_{it} = \mu_i + \varepsilon_{it}$
 - Es homocedástico: $V(u_{it}) = \sigma_\mu^2 + \sigma_\varepsilon^2$
 - Pero sufre de autocorrelación para el mismo individuo:
 $E[u_{it} \cdot u_{is}] = \sigma_\mu^2$ para $t \neq s$
- Si bien POLS es consistente no es eficiente
- El estimador más eficiente bajo autocorrelación es el de Mínimos Cuadrados Generalizados (MCG)

Mínimos cuadrados generalizados (MCG)

- Volvamos a la notación matricial

$$Y = X\beta + u$$

- Supongamos que hay exogeneidad estricta y ortogonalidad entre μ_i y los regresores, pero hay autocorrelación del error compuesto:

$$V[u] = \Omega \neq cte. I_{N \times T}$$

- El estimador más eficiente de β es el de Mínimos Cuadrados Generalizados:

$$\hat{\beta}_{MCG} = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}Y$$

MCG Factibles para efectos aleatorios

En el caso de EA:

$$V[u] = \Omega(\sigma_{\mu}^2, \sigma_{\varepsilon}^2)$$

- $(\sigma_{\mu}^2, \sigma_{\varepsilon}^2)$ son parámetros desconocidos y deben estimarse: Mínimos Cuadrados Generalizados Factibles (MCGF)
- Por lo tanto, el **estimador de EA es un estimador de MCGF.**
- Para estimar $(\sigma_{\mu}^2, \sigma_{\varepsilon}^2)$ se pueden usar los estimadores de la varianza de los residuos de los modelos Within y Between:
 - $y_{it} - \bar{y}_i = (x'_{it} - \bar{x}'_i) \hat{\beta} + \text{residuo} \rightarrow S_W^2$
 - $\bar{y}_i = \bar{x}'_i \hat{\beta} + \text{residuo} \rightarrow S_B^2$
- Y resolver el siguiente sistema $\hat{\sigma}_{\mu}^2 \cong S_W^2$ y $\hat{\sigma}_{\mu}^2 + \frac{1}{T} \hat{\sigma}_{\varepsilon}^2 \cong S_B^2$ (Swamy-Arora)

¿EF o EA?

- Naive pensar que EF considera fija la heterogeneidad inobservable.
- En la Econometría moderna la distinción entre EF y EA se resume en si estamos o no dispuestos a suponer ortogonalidad entre la heterogeneidad inobservable y los regresores.
- En este sentido, EA es sinónimo de ortogonalidad.
- En la Econometría aplicada, EF no se usa como equivalente de “no aleatorio” sino como la relajación de ese supuesto.

¿EF o EA?

$$Y = X\beta + D\mu + \varepsilon$$

- Si X es ortogonal a $D\mu$: MCO, EF, EA son todos consistentes para β . EA es eficiente.
- Si X no es ortogonal a $D\mu$: sólo EF es consistente para β .
- La práctica gravita mayormente en EF.

Test de Hausman

El test de Hausman (1978) se concentra en comparar 2 estimadores:

- un estimador que es siempre consistente
- otro estimador que es consistente solo bajo la H_0
- Intuición: ambos estimadores deberían ser parecidos si H_0 es cierta.

En nuestro caso:

- el estimador EF es siempre consistente
- el estimador EA es consistente sólo si X y $D\mu$ son ortogonales

Test de Hausman

Formalmente:

$$H_0 : X \perp D\mu \quad H_A : X \sim \perp D\mu$$

El estadístico de prueba es:

$$h = (\hat{\beta}_{EA} - \hat{\beta}_{EF})'(\hat{\Omega}_{EF} - \hat{\Omega}_{EA})^{-1}(\hat{\beta}_{EA} - \hat{\beta}_{EF}) \stackrel{H_0}{\sim} \chi^2_{(dim.\beta)}$$

Regla: rechazar H_0 si h es significativamente distinto de cero.

- *Intuición:* bajo H_0 , $\hat{\beta}_{EA}$ y $\hat{\beta}_{EF}$ son consistentes, h debería ser pequeño.
- Permitiría, bajo H_0 , explotar las ganancias de eficiencia de estimar por EA.
- Podemos concentrarnos sólo en algunos parámetros de interés.

Bibliografía

● Libros:

- Baltagi, B. H. 2005. *Econometric Analysis of Panel Data*. 3rd. ed. New York: Wiley. Caps. 1 y 2
- Wooldridge, J. M. 2010. *Econometric Analysis of Cross Section and Panel Data*. 2nd ed. Cambridge, MA: MIT Press. Cap. 10.

● Papers con aplicaciones:

- Cornwell, C. and W.N. Trumbull (1994). "Estimating the Economic Model of Crime with Panel Data". *The Review of Economics and Statistics*, Vol. 76, No. 2, pp. 360-366.
- Rockoff, J. (2004) "The Impact of Individual Teachers on Student Achievement: Evidence from Panel Data" (*American Economic Review*, 94(2), pp. 247-252).
- Sosa Escudero, W.; M. Marchionni, and O. Arias (2011). "Sources of Income Persistence: Evidence from Rural El Salvador". *Journal of Income Distribution*, Volume 20, Number 1, March, pp. 3-28 (ISSN: 1874-6322).

Variable Dependiente Limitada

Javier Alejo

Maestría en Economía

FCE-UNLP

Agosto 2019

Temario de la clase

- Introducción
- Estimación MV
 - ① Censura
 - ② Truncamiento
 - ③ Y binaria
- Modelo lineal y MCO



Variables aleatorias

- **Discretas:** los valores del soporte pueden ocurrir con probabilidad no nula. Ejemplos: ocupado o desocupado, numero de hijos, etc. (Bernoulli, Poisson, etc.)
- **Continuas:** si bien cada punto del soporte ocurre con probabilidad cero, intervalos del soporte ocurren con probabilidad no nula. Ejemplos: ingresos, llegada a clase, etc. (normal, chi2, etc.)
- **Parcialmente continuas:** ciertos valores pueden ocurrir con probabilidad no nula. Ejemplos: gasto en seguro de vida, re-financiamiento de deuda, ingresos de fuentes tributarias, etc.

¿Por qué?

En Economía es usual trabajar con variables Y cuya carácter continuo ha sido modificado por alguna razón:

- *Razones administrativas*: existe algún mecanismo institucional que altera la información (encuestas de ingresos, datos tributarios, etc.).
- *Soluciones de esquina*: típicas de los modelos de agentes optimizadores (gasto en bienes durables, horas de trabajo, restricciones de capacidad, liquidez, etc.).
- *Resultados cualitativos*: que no necesariamente son medibles en un continuo (estar desocupado, decisión de estudiar, quiebra de un banco, etc.)

Modelo latente para Y^* y tres casos para Y

Vamos considerar el siguiente modelo lineal

$$y_i^* = x_i' \beta + u_i$$

donde y_i^* es una variable latente (inobservable) y en su lugar contaremos con otra variable y_i

Clave: y_i es una versión alterada de y_i^* . Veremos tres casos:

- 1 **Censura:** $y_i = \max(c, y_i^*)$, con c un escalar no aleatorio (cota inferior para y_i^*).
- 2 **Truncamiento:** solo contamos con una submuestra de datos tales que $y_i^* > c$ (nos faltan aquellos que $y_i = c$)
- 3 **Variable binaria:** $y_i = 1$ si $y_i^* > c$ y $y_i = 0$ en $y_i^* \leq c$

Sin pérdida de generalidad, haremos $c = 0$.

Ilustración: variable latente






Ilustración: datos censurados



Importante: x_i es observable tanto para los casos ($y_i = c$) y como para ($y_i > c$)

Ilustración: datos truncados



Importante: x_i solo es observable para los casos ($y_i > c$)


Ilustración: estimación MCO (si observáramos y^*)

Ilustración: estimación MCO, datos censurados




Ilustración: estimación MCO, muestra truncada





Ilustración: estimación MCO, Y binaria

Modelo lineal con errores normales

Modelo lineal:

$$y_i = x_i' \beta + u_i, \text{ con } u_i | x_i \sim N(0, \sigma^2)$$

De aquí: $y_i | x_i \sim N(x_i' \beta, \sigma^2)$. Parámetros: $\theta = (\beta, \sigma^2)$

Densidad condicional:

$$f(y_i | x_i, \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i' \beta)^2}{2\sigma^2}\right)$$

Verosimilitud condicional:

$$L(\theta, \tilde{Y}) \equiv \prod_{i=1}^n f(y_i | x_i, \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - x_i' \beta)^2}{2\sigma^2}\right)$$

con $\tilde{Y} = \{y_i, x_i\}_{i=1}^n$ una muestra i.i.d.

Método de Máxima Verosimilitud (MV)

Es aquel vector $\hat{\theta}_n$ que soluciona el siguiente problema:

$$\max_{\theta} L(\theta; \tilde{y}|X)$$

Intuición: MV trata de reconstruir el camino inverso al proceso generador de los datos.

Problema equivalente:

$$\hat{\theta}_n \equiv \operatorname{argmax}_{\theta} \ln L(\theta; \tilde{y}|X)$$

A esto se le denomina **Log-verosimilitud** (*log-likelihood*).

Ejercicio: mostrar que $\hat{\beta}_n$ por MV del slide anterior coincide con MCO!

Propiedades de MV

Computacionales:

- No siempre se puede aplicar cálculo para encontrar a $\hat{\theta}_n$.
- No siempre $\hat{\theta}_n$ es una solución es explícita.

Estadísticas: bajo ciertos supuestos de regularidad

- Consistencia

$$\hat{\theta}_n \xrightarrow{P} \theta_0$$

- Normalidad asintótica

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, AV(\hat{\theta}_n))$$

donde $AV(\hat{\theta}_n)$ es la varianza asintótica de $\hat{\theta}_n$.

Modelo Tobit

Modelo lineal $y_i^* = x_i'\beta + u_i$, con:

$$y_i = \begin{cases} 0 & \text{si } y_i^* \leq 0 \\ y_i^* & \text{si } y_i^* > 0 \end{cases}$$

Supuesto extra: $u_i|x_i \sim N(0, \sigma^2)$

¿Cómo usar esta información? Veremos que:

Tramo	Tipo de VA	Probabilidad/Densidad
$y_i = 0$	<i>Discreta</i>	$1 - \Phi(x_i'\beta/\sigma)$
$y_i > 0$	<i>Continua</i>	$(1/\sigma)\phi((y_i - x_i'\beta)/\sigma)$

- $\phi(\cdot)$: densidad en una distribución normal estándar.
- $\Phi(\cdot)$: prob. acumulada (desde la izq.) en una normal estándar.

Probabilidad/Densidad

Notar que:

$$u_i|x_i \sim N(0, \sigma^2) \implies y_i^*|x_i \sim N(x_i'\beta, \sigma^2)$$

Luego,

① Probabilidad de censura:

$$\begin{aligned} Pr(y_i = 0|x_i) &= Pr(y_i^* \leq 0|x_i) \\ &= Pr(x_i'\beta + u_i \leq 0|x_i) \\ &= Pr(u_i/\sigma \leq -x_i'\beta/\sigma|x_i) \\ &= \Phi\left(-\frac{x_i'\beta}{\sigma}\right) \\ &= 1 - \Phi\left(\frac{x_i'\beta}{\sigma}\right) \end{aligned}$$

② La densidad en el tramo continuo es obvia [¿por qué?]

Tobit: estimación MV

Construyamos la verosimilitud condicional:

$$\begin{aligned} L(\beta, \sigma) &= \prod_{i: y_i=0} [1 - \Phi(x'_i \beta / \sigma)] \cdot \prod_{i: y_i > 0} (1/\sigma) \phi((y_i - x'_i \beta) / \sigma) \\ &= \prod_{i=1}^n [1 - \Phi(x'_i \beta / \sigma)]^{(1-w_i)} \cdot [(1/\sigma) \phi((y_i - x'_i \beta) / \sigma)]^{w_i} \end{aligned}$$

donde $w_i \equiv 1(y_i > 0)$. (*)

Luego, la log-verosimilitud es:

$$\ell(\beta, \sigma) = \sum_{i=1}^n (1 - w_i) \ln[1 - \Phi(x'_i \beta / \sigma)] + w_i \ln[(1/\sigma) \phi((y_i - x'_i \beta) / \sigma)]$$

que bajo condiciones regulares produce un máximo único utilizando métodos numéricos simples. De aquí salen $(\hat{\beta}, \hat{\sigma}) \xrightarrow{P} (\beta, \sigma)$ y asintóticamente normales.

(*) *Función indicadora*: $1(Q)$ vale 1 si el argumento Q es verdadero y 0 si es falso.

Regresión truncada

- **Situación:** no hay observaciones cuando $y_i^* \leq c$. Por lo tanto, no es posible incluirlas en la regresión.
- ¿Cómo afecta el truncamiento a una distribución?
- En términos generales, si Y es una variable aleatoria, la densidad de la distribución truncada es:


$$f(y|y > c) = \frac{f(y)}{\Pr(y > c)}$$

c es el punto de truncamiento y $f(y)$ es la densidad de Y .

- **Caso particular:** $Y \sim N(\mu, \sigma^2)$

$$f(y|y > c) = \frac{(1/\sigma)\phi\left(\frac{y-\mu}{\sigma}\right)}{1-\Phi\left(\frac{c-\mu}{\sigma}\right)} = \frac{(1/\sigma)\phi(z)}{1-\Phi(\alpha)}$$

Distribución Normal truncada



Regresión truncada

Modelo lineal para la variable latente:

$$y_i^* = x_i' \beta + u_i$$

Vimos que:

$$u_i | x_i \sim N(0, \sigma^2) \Rightarrow y_i^* | x_i \sim N(x_i' \beta, \sigma^2)$$

Luego, la verosimilitud condicional utiliza la densidad de $y_i^* | x_i$ truncada en $y_i^* > 0$:

$$L(\beta, \sigma) = \prod_{i=1}^n \left[\frac{(1/\sigma) \phi((y_i - x_i' \beta)/\sigma)}{\Phi(x_i' \beta/\sigma)} \right]$$

MV nos dará estimadores consistentes y asintóticamente normales de los parámetros β y σ .

Variable dependiente binaria

Supongamos el siguiente modelo lineal latente:

$$y_i^* = x_i' \beta + u_i$$

donde y_i^* es continua pero no se observa. En su lugar se observa:

$$y_i = \begin{cases} 1 & y_i^* > 0 \\ 0 & y_i^* \leq 0 \end{cases}$$

(x_i es observable!).

No siempre y_i^* es interpretable. Algunos ejemplos:

- 1 y_i^* utilidad neta de un individuo i por trabajar; y_i indica con 1 si observamos que trabaja y 0 en caso contrario.
- 2 y_i^* beneficios potenciales de una firma i ; y_i indica con 1 si opera en el mercado y 0 no entra.

Probabilidad condicional

Supongamos que $u_i \sim N(0, \sigma^2)$ y computemos la probabilidad de que observemos $y_i = 1$, dado x_i :

$$\begin{aligned} P(y_i = 1|x_i) &= P(y_i^* > 0|x_i) \\ &= P(x_i'\beta + u_i > 0|x_i) \\ &= P(u_i/\sigma > -x_i'\beta/\sigma|x_i) \quad (1) \\ &= \Phi(x_i'\theta) \quad (2) \end{aligned}$$

donde hemos definido a $\theta \equiv \beta/\sigma$.

- ¿Qué modelo es este?
- **Ejercicio:** completar los pasos intermedios de (1) a (2).

En general $P(y_i = 1|x_i) = F(x_i'\theta)$, donde $F(\cdot)$ es una función monótona creciente y cumple $F(-\infty) = 0$ y $F(+\infty) = 1$

Estimador MV

Dado x_i, y_i es una VA Bernoulli con $p_i = P(y_i = 1|x_i)$. Luego,

$$L(\theta) = \prod_{i:y_i=1} p_i \cdot \prod_{i:y_i=0} (1 - p_i) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$$


y su logaritmo

$$\begin{aligned} \ell(\theta) &= \sum_{i=1}^n [y_i \ln p_i + (1 - y_i) \ln (1 - p_i)] \\ &= \sum_{i=1}^n \{y_i \ln F(x_i' \theta) + (1 - y_i) \ln [1 - F(x_i' \theta)]\} \end{aligned}$$

- La solución $\hat{\theta}_{MV}$ existe siempre que las x_i sean linealmente independientes y no contengan un clasificador perfecto de y_i .
- **Identificación:** no es posible estimar a β y σ , solo al cociente.

¿Logit o Probit?

- Si $F(z) = \Lambda(z) = \frac{e^z}{1+e^z}$ el modelo binario se denomina Logit.
- Ambas son muy similares: $\Lambda(z/\sqrt{(2/3)}) \approx \Phi(z)$.
- En general, $\hat{\beta}_{logit} \approx 1,8\hat{\beta}_{probit}$
- Elegir cualquiera de las dos especificaciones.



MCO y el modelo lineal

Consideremos el modelo lineal para y

$$y_i = x_i' \beta + \varepsilon_i$$

La insesgadez de MCO depende del supuesto de que $E(\varepsilon_i | x_i) = 0$, o bien, que

$$E(y_i | x_i) = x_i' \beta$$

Pensemos:

- La variable latente sigue un modelo lineal: $y_i^* = x_i' \beta + u_i$
- Sin embargo, sólo observamos a y_i (una versión alterada de y_i^*)
- En los tres casos, la transformación de y_i a y_i^* es no lineal.
- ¿Debemos esperar que y_i siga una modelo lineal?

¿Por qué falla el modelo lineal?

Situación: los tres casos analizados generan un problema de especificación para y_i sesgando potencialmente a MCO.



Formalmente: $E(y_i|x) = m(x_i, \theta)$, donde $m(\cdot)$ es alguna función (no lineal) conocida que depende de los parámetros θ .

Resultado: si $u_i|x_i \sim N(0, \sigma^2)$, no es muy difícil mostrar que

Caso (Modelo)	Esperanza condicional
1. Censura (Tobit)	$E(y_i x_i) = [x_i'\beta + \sigma\lambda(x_i'\beta/\sigma)] \Phi\left(\frac{x_i'\beta}{\sigma}\right)$
2. Truncamiento	$E(y_i x_i, y_i > 0) = x_i'\beta + \sigma\lambda(x_i'\beta/\sigma)$
3. Variable binaria (Probit)	$E(y_i x_i) = \Phi(x_i'\theta)$, con $\theta = \beta/\sigma$

donde $\lambda(z) \equiv \frac{\phi(z)}{\Phi(z)}$ (inversa del ratio de Mills)

Esperanza condicional: censura y truncamiento




$$(1) = \text{MCO}$$

$$(2) = x_i' \beta + \sigma \lambda(x_i' \beta / \sigma)$$

$$(3) = [x_i' \beta + \sigma \lambda(x_i' \beta / \sigma)] \Phi(x_i' \beta / \sigma)$$

Esperanza condicional: variables binarias



¿Interpretación de coeficientes?

Media condicional: el caso general es $E(y_i|x) = m(x_i, \beta)$, donde $m(\cdot)$ es una función no lineal conocida.

Efecto parcial: tomemos algún regresor x_k continuo

$$\frac{\partial E(y_i|x)}{\partial x_k} = \frac{\partial m(x_i, \beta)}{\partial x_k}$$

- El efecto parcial de x_k no es constante, sino que depende de x_i . Problema: ¿dónde evaluar a x_i ?
- A priori, el valor de los β no brinda información cuantitativa del efecto parcial sobre $E(y|x)$.
- En algunos modelos, el signo de β indica la dirección del efecto (Probit/Logit).

Estas conclusiones se mantienen para el caso donde x_k es binario.

Caso 1: modelo lineal de probabilidad (MPL)

Es el caso de y_i binaria (Bernoulli) con $p_i = P(y_i = 1|x_i)$:

$$E(y_i|x_i) = P(y_i = 1|x_i) = \underbrace{x_i'\beta}_{\text{MPL}}$$

donde $\hat{\beta}$ se obtiene por MCO.

Desventajas:

- ① *Heterocedástico*: $V[y_i|x_i] = p_i(1 - p_i) = x_i'\beta \cdot (1 - x_i'\beta)$
- ② *Predicciones incoherentes*: $x_i'\hat{\beta} < 0$ y/o $x_i'\hat{\beta} > 1$ para algún i .
- ③ *Efectos parciales constantes*: $\partial E(y_i|x)/\partial x_k = \beta_k$

Ventajas: (Angrist y Pischke, 2009)

- ① Los coeficientes tienen una interpretación cuantitativa.
- ② El modelo lineal tiene más variantes teóricas (VI, paneles, modelos dinámicos, etc.)

Caso 2: modelos no lineales de probabilidad

Son los Probit/Logit, que en general se escriben:

$$p_i = P(y_i = 1|x_i) = F(x_i'\beta)$$

donde $F(\cdot)$ es una distribución acumulada (normal o logística) y $\hat{\beta}$ se obtiene por MV.

Variables continuas:

$$\frac{\partial p_i}{\partial x_k} = f(x_i'\beta)\beta_k$$

Variables dummy: sea el modelo $F(x_i'\beta + \delta D)$, con D binario

$$\Delta p_i = F(x_i'\beta + \delta) - F(x_i'\beta)$$

El signo del coeficiente es informativo de la dirección del efecto parcial, no así su magnitud.

Caso 3: modelo Tobit

El modelo Tobit da estimaciones consistentes de:

$$\beta = \frac{\partial E(y^*|x)}{\partial x}$$

- Esto nos provee una interpretación de las derivadas parciales de la variable latente.
- No siempre la variable latente es interpretable (o interesante) y puede que el objetivo sea computar los efectos parciales sobre el promedio de la variable observada (censurada o truncada).

Caso 3: modelo Tobit

Esperanza de y truncada: en el caso de que $u_i \sim N(0, \sigma^2)$, vimos que:

$$E(y|x, y > 0) = x'\beta + \sigma\lambda (x'\beta/\sigma)$$

Esperanza de y censurada:

$$E(y|x) = E(y|x, y > 0)Pr(y > 0|x)$$

Que bajo normalidad, esta expresión queda:

$$E(y|x) = \Phi(x'\beta/\sigma)[x'\beta + \sigma\lambda (x'\beta/\sigma)]$$

Caso 3: modelo Tobit

Efectos parciales (regresores continuos)

- Noten que las derivadas parciales de $E(y|x)$ y $E(y|x, y > 0)$ no son constantes.
- Supongamos un x_k continuo. En el caso de la esperanza con censura:

$$\frac{\partial E(y|x)}{\partial x_k} = \Phi(x'\beta/\sigma)\beta_k$$

- Mientras que para la esperanza truncada:

$$\frac{\partial E(y|x, y > 0)}{\partial x_k} = \{1 - \lambda(x'\beta/\sigma)[x'\beta + \sigma\lambda(x'\beta/\sigma)]\}\beta_k$$

Caso 3: modelo Tobit

Descomposición de McDonald y Moffitt

Retomando el resultado anterior:

$$E(y|x) = Pr(y > 0|x)E(y|x, y > 0)$$

Derivemos usando la regla del producto:

$$\frac{\partial E(y|x)}{\partial x_k} = \frac{\partial Pr(y > 0|x)}{\partial x_k} E(y|x, y > 0) + Pr(y > 0|x) \frac{\partial E(y|x, y > 0)}{\partial x_k}$$

Es decir, el efecto sobre variable censurada tiene dos componentes:

- 1 $\frac{\partial Pr(y > 0|x)}{\partial x_k} E(y|x, y > 0)$: efecto de los que cambian de estado.
- 2 $Pr(y > 0|x) \frac{\partial E(y|x, y > 0)}{\partial x_k}$: efecto de la distribución truncada.

Comentarios finales

- En general, podemos pensar una Y limitada como una transformación no lineal de una variable latente Y^* .
- Esto involucra el caso de censura, truncamiento y variables categóricas.
- El modelo estimable (utilizando Y y X) resulta no lineal induciendo una mala especificación al estimador MCO.
- ¿Qué tan malo es usar MCO?
 - Es adaptable (VI, datos en panel, etc.)
 - Ofrece la mejor aproximación lineal a $E(y|x)$.
- **En la práctica:** depende mucho del contexto. Por ejemplo: Pobit/Logit (predicciones coherentes *versus* efectos parciales complicados). Pregunta: ¿qué necesito?

Bibliografía

- Wooldridge, J. (2002) *Econometric Analysis of Cross Section and Panel Data*, MIT Press. 1a. Edición. Capítulos 15, 16 y 17.
- Cameron y Trivedi (2009), *Microeconometrics Using Stata*, Stata Press. Capítulos 14 (14.1 a 14.5) y 16 (16.1, 16.2 y 16.3).
- Gasparini, L., Marchionni, M. y Sosa Escudero, W. (2004) *Characterization of inequality changes through microeconomic decompositions. The case of Greater Buenos Aires*, en Bourguignon, F., Lustig, N y Ferreira, F. (eds.), 2004 (pp. 47- 82).
- Sosa Escudero (2015), "To probit or not to probit? Esa es la cuestión" en *El Lado Oscuro de la Econometría* (Capítulo 3).

Selección muestral

Javier Alejo

Maestría en Economía

UNLP

Agosto 2019

Temario de la clase

- 1 Cuestiones preliminares.
- 2 Selección muestral.
- 3 Estimador de Heckman.
- 4 Ejemplo empírico.



La normal truncada

Vimos que si $Y \sim f(y)$, entonces la distribución truncada por izquierda es:

$$f(y|Y > a) = \frac{f(y)}{\Pr(Y > a)}$$

Caso particular: $Y \sim N(\mu, \sigma^2)$

$$f(y|Y > a) = \frac{(1/\sigma)\phi\left(\frac{y-\mu}{\sigma}\right)}{1-\Phi\left(\frac{a-\mu}{\sigma}\right)} = \frac{(1/\sigma)\phi(z)}{1-\Phi(\alpha)}$$

con $z \equiv (y - \mu)/\sigma$ y $\alpha \equiv (a - \mu)/\sigma$.

Algunos resultados útiles

Alteración en la esperanza:

$$\begin{aligned} E(Y|Y > a) &= \mu + \sigma \frac{\phi(\alpha)}{1 - \Phi(\alpha)} \\ &= \mu + \sigma \lambda(\alpha) \end{aligned}$$


Inversa del ratio de Mills: $\lambda(\alpha)$, donde $\alpha \equiv (a - \mu)/\sigma$.

De la misma manera, la varianza también se ve afectada:

$$V(Y|Y > a) = \sigma^2 [1 - \delta(\alpha)] \neq \sigma^2$$

con $\delta(\alpha) = \lambda(\alpha)[\lambda(\alpha) - \alpha]$ (ver Greene, 2003, pag. 759.)

Ejemplo: $Y \sim N(0,1)$ vs. $Y|Y > -1$



Variables latentes y Probits

Recuerden el modelo Probit:

$$P(y_i = 1|x_i) = \Phi(x_i'\beta)$$

Los parámetros β pueden ser estimados consistentemente por el método de MV.

Consideren el modelo lineal:

$$y_i^* = x_i'\beta^* + u_i^*, \quad u_i^* \sim N(0, \sigma^2)$$

donde y_i^* no es observable (variable latente) y en su lugar se cuenta con $y_i = 1(y_i^* > 0)$.

¿Qué parámetros pueden ser estimados consistentemente?

Variables latentes y Probits

$$\begin{aligned}P(y_i = 1|x_i) &= P(y_i^* > 0|x_i) \\&= P(x_i'\beta^* + u_i^* > 0|x_i) \\&= P(u_i^*/\sigma > -x_i'\beta^*/\sigma|x_i) \\&= 1 - P(u_i^*/\sigma < -x_i'\beta^*/\sigma|x_i)\end{aligned}$$

Dado que $u_i^*/\sigma \sim N(0, 1)$, sigue que:

$$\begin{aligned}P(y_i = 1|x_i) &= 1 - \Phi(-x_i'\beta) \\&= \Phi(x_i'\beta) \quad [\text{¿por qué?}]\end{aligned}$$

Dando como resultado un modelo Probit, donde hemos definido a $\beta \equiv \beta^*/\sigma$.

Problema de identificación

En el modelo lineal para la variable latente:

- No es posible identificar a β^* y σ^2 por separado mediante una muestra aleatoria (y_i, x_i) , $i = 1, \dots, n$.
- ¿Qué significa?: los datos generados por un modelo con $\beta^* = 2$ y $\sigma^2 = 1$ son observacionalmente iguales que los generados por otro con $\beta^* = 6$ y $\sigma^2 = 9$.
- Sin embargo, es posible identificar a $\beta = \beta^* / \sigma$.

Selección muestral

Consideremos el siguiente modelo:

$$y_i = x_i' \beta + u_i$$

Proceso de selección: supongamos además una dummy s_i que nos indica con 1 si y_i es observable y 0 en caso contrario.

Ejemplo: oferta salarial

- Solo es posible estimar una ecuación de salarios con datos de individuos ocupados ($s_i = 1$). [¿por qué?]
- No podemos observar cuanto están dispuestos a percibir como salario aquellos que están desocupados ($s_i = 0$).

MCO bajo selección muestral

Con una muestra aleatoria (y_i, x_i) , la consistencia de MCO depende del supuesto:

$$E(u_i|x_i) = 0$$

lo cual implica que $E(y_i|x_i) = x_i'\beta$.

- **Importante:** solo es posible utilizar la información seleccionada, es decir condicional en que $s_i = 1$.

Tomando esperanza condicional en la selección:

$$E(y_i|x_i, s_i = 1) = x_i'\beta + E(u_i|x_i, s_i = 1)$$

¿Cuándo MCO es consistente bajo la selección muestral?

MCO bajo selección muestral

Si $E(u_i|x_i) = 0$, ¿podemos decir que $E(u_i|x_i, s_i = 1) = 0$?

Mecanismo de selección: no todos generan sesgo en MCO

- Si es independiente de (x_i, u_i) :

$$E(u_i|x_i, s_i) = E(u_i|x_i) = 0$$

por lo tanto MCO seguirá siendo insesgado y consistente.

- Si tiene una relación determinista con x , del tipo $s_i = g(x_i)$:

$$E(u_i|x_i, s_i) = E[u_i|x_i, g(x_i)] = E(u_i|x_i) = 0$$

por lo tanto MCO seguirá siendo insesgado y consistente.

MCO bajo selección muestral

Resumen:

- ¿Cuándo genera sesgo?: si s_i y u_i están correlacionados.
- Es decir, cuando el truncamiento en y_i está generado por un mecanismo endógeno.

Algunos ejemplos:

- Decisiones laborales (trabajar, ser formal, migrar, etc.) en función de sus pretensiones salariales.
- Elección/Abandono de los beneficiarios de un programa.
- Datos con empresas que entran y salen del mercado.

Un modelo con selección muestral

- ¿Cómo se elige los valores de s_i ? necesitamos un modelo!

Supongamos las siguientes ecuaciones:

$$\begin{cases} y_{1i} = x'_{1i}\beta_1 + u_{1i} & \text{(regresión)} \\ y_{2i}^* = x'_{2i}\beta_2 + u_{2i} & \text{(selección)} \end{cases}$$

donde y_{2i}^* es una variable latente que gobierna la selección:

$$y_{2i} = \begin{cases} 1 & \text{si } y_{2i}^* > 0 \\ 0 & \text{si } y_{2i}^* \leq 0 \end{cases} \quad \begin{matrix} (i \text{ tiene datos de } y_{1i}) \\ (i \text{ no tiene datos de } y_{1i}) \end{matrix}$$

Es decir: $y_{2i} = 1(y_{2i}^* > 0)$, donde $1(\cdot)$ es la función indicadora.

- **Importante:** (y_{2i}, x_{2i}) son observados, sin importar si hay información sobre y_{1i} .

Siguiendo con el ejemplo...

Oferta salarial

Ecuación de salarios:

$$\text{salario}_i = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_i + \beta_3 \text{mujer}_i + u_i$$

Podemos repensar este modelo de la siguiente manera:

- **Ecuación de regresión:** salarios (y_{1i}) en función de características individuales (x_{1i}) .
- **Ecuación de selección:** utilidad neta del trabajo (y_{2i}^*) en función de sus determinantes (x_{2i})

Notar que los valores de y_{2i}^* no se observan, pero sabemos si el individuo i trabaja (o no) mediante la variable $y_{2i} = 1[y_{2i}^* > 0]$.

Supuestos del modelo de selección

$$\begin{cases} y_{1i} &= x'_{1i}\beta_1 + u_{1i} \\ y_{2i}^* &= x'_{2i}\beta_2 + u_{2i} \\ y_{2i} &= 1(y_{2i}^* > 0) \end{cases}$$

- ❶ (y_{1i}, x_{1i}) se observan sólo si $y_{2i} = 1$ (muestra con selección).
- ❷ (y_{2i}, x_{2i}) se observan para todos.
- ❸ (u_{1i}, u_{2i}) son independientes de x_{2i} y tienen media cero.
- ❹ $u_{2i} \sim N(0; \sigma_2^2)$.
- ❺ $E(u_{1i}|u_{2i}) = \gamma u_{2i}$

Sesgo por selección

Computemos la esperanza condicional en la selección:

$$\begin{aligned} E(y_{1i}|x_{1i}, y_{2i} = 1) &= x'_{1i}\beta_1 + E(u_{1i}|x_{1i}, y_{2i} = 1) \\ &= x'_{1i}\beta_1 + E[E(u_{1i}|u_{2i})|x_{1i}, y_{2i} = 1)] \\ &= x'_{1i}\beta_1 + E(\gamma u_{2i}|x_{1i}, y_{2i} = 1) \\ &= x'_{1i}\beta_1 + \gamma E(u_{2i}|x_{1i}, y_{2i}^* > 0) \\ &= x'_{1i}\beta_1 + \gamma E(u_{2i}|x_{1i}, u_{2i} > -x'_{2i}\beta_2) \\ &= x'_{1i}\beta_1 + \gamma\sigma_2\lambda(x'_{2i}\beta_2/\sigma_2) \end{aligned}$$

donde $\lambda(\cdot)$ es la *inversa del ratio de Mills*.

Sesgo por selección

$$E(y_{1i}|x_{1i}, y_{2i} = 1) = x'_{1i}\beta_1 + \gamma\sigma_2\lambda(x'_{2i}\beta_2/\sigma_2)$$

Notar que si $\gamma \neq 0$, entonces:

$$E(y_{1i}|x_{1i}, y_{2i} = 1) \neq x'_{1i}\beta_1$$

Luego, el sesgo aparece por la correlación entre u_2 y u_1 .

Intuición: oferta salarial

- Los inobservables que afectan a los salarios están relacionados con los que afectan a la decisión de trabajar.
- El mecanismo de selección hace que esos factores inobservables se cuelen en el término de error del modelo de regresión.

Heckman (1979)



- 1 Sesgo de selección como un problema de variable relevante omitida.
- 2 Al estimar por MCO usando la muestra seleccionada, $\lambda(\cdot)$ es una variable omitida.
- 3 ¿Cuándo omitir una variable induce un sesgo en los estimadores de MCO?

Estimación consistente

Pensemos a la ecuación de regresión como:

$$y_{1i} = x'_{1i}\beta_1 + \gamma^*\lambda_i + u_{1i}^*$$

donde $\gamma^* \equiv \gamma\sigma_2$; $\lambda_i \equiv \lambda(x'_{2i}\beta_2/\sigma_2)$ y $u_{1i}^* \equiv u_{1i} - \gamma^*\lambda_i$.

Por construcción:

$$E(u_{1i}^*|x_{1i}, y_{2i} = 1) = E(u_{1i}|x_{1i}, y_{2i} = 1) - \gamma^*\lambda(x'_{2i}\beta_2) = 0$$

Notar:

- Si contamos con la variable λ_i podemos estimar a β_1 de manera insesgada [¿cómo?].
- **Problema:** λ_i no es observable! [¿por qué?]

Estimación auxiliar de m_i

- Es posible identificar a $\beta_2^* = \beta_2/\sigma_2$.
- Notar que $u_{2i} \sim N(0; \sigma_2^2)$, luego la probabilidad de selección es:

$$\begin{aligned} P(y_{2i} = 1|x_i) &= P(y_{2i}^* > 0|x_i) \\ &= P(x_{2i}'\beta_2 + u_{2i} > 0|x_{2i}) \\ &\vdots \\ &= \Phi(x_{2i}'\beta_2^*) \end{aligned}$$

con $\beta_2^* = \beta_2/\sigma_2$.

- Recordar que tenemos (y_{2i}, x_{2i}) para toda la muestra!.

Método de Heckman en 2 etapas

El modelo con selección es:

$$y_{1i} = x'_{1i}\beta_1 + \gamma^*\lambda_i + u_{1i}^*$$

Heckman (1979) propone estimarlo en 2 etapas:

- **Etapa 1:** obtener un $\hat{\beta}_2^*$ usando un Probit usando la muestra completa y estimar a m_i haciendo $\hat{\lambda}_i = \lambda(x'_{2i}\hat{\beta}_2^*)$.
- **Etapa 2:** obtener $(\hat{\beta}_1, \hat{\gamma}^*)$ haciendo una regresión de MCO de y_{1i} en función de x_{1i} y $\hat{\lambda}_i$.

Propiedades estadísticas:

- El método proporciona estimadores consistentes.
- Son asintóticamente normales $\rightarrow$ los métodos estándar de inferencia funcionan bien.

Test de sesgo por selección muestral

- Noten que si $\gamma = 0$, entonces no hay sesgo por selección.
- Método de Heckman: $\hat{\gamma}^* \xrightarrow{P} \gamma^* \equiv \gamma \sigma_2$.
- Dado que $\sigma_2 > 0$, podemos evaluar la presencia de sesgo de selección mediante las hipótesis:

$$H_0 : \gamma^* = 0$$

$$H_1 : \gamma^* \neq 0$$

- Luego, bajo H_0 :

$$\frac{\hat{\gamma}^*}{SE(\hat{\gamma}^*)} \xrightarrow{d} N(0, 1)$$

Errores estándar

- Por diferentes motivos, los SE computados por MCO son incorrectos.
- Por un lado, si $\gamma \neq 0$, la segunda etapa (con la muestra seleccionada) es heterocedástica.
- *Intuición*: el truncamiento también afecta a la varianza

$$V(u_{1i}|x_{1i}, y_{2i} = 1) \neq V(u_{1i}|x_{1i}, u_{2i} > -x'_{2i}\beta_2) \sigma_1^2$$

- Además se utiliza a $\hat{\beta}_2$ en lugar de β_2 .
- Hay correcciones disponibles (Stata implementa una de ellas).

Otras cuestiones prácticas

Test de sesgo por selección:

- La hipótesis nula dice que $\gamma = 0$ (no hay efectos de la selección).
- Luego, bajo la H_0 la segunda etapa es homocedástica.
- Por lo tanto los SE de MCO son correctos.

Inferencia:

- Baja potencia cuando x_1 y x_2 son similares.
- Necesidad práctica de que las variables incluidas x_1 sean un subconjunto de las incluidas en x_2 (*restricción de exclusión*).

Estimación MV

Se utiliza el mismo modelo:

$$\begin{cases} y_{1i} &= x'_{1i}\beta_1 + u_{1i} \\ y_{2i}^* &= x'_{2i}\beta_2 + u_{2i} \\ y_{2i} &= 1(y_{2i}^* > 0) \end{cases}$$

Pero ahora se requiere normalidad bivariada en los errores para computar la verosimilitud.

$$\begin{pmatrix} u_{1i} \\ u_{2i} \end{pmatrix} \sim N \left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1 \\ \rho\sigma_1 & 1 \end{pmatrix} \right]$$

¿Es un supuesto más fuerte o más débil?

Función de log-verosimilitud

Con todos estos supuestos:

$$\begin{aligned} \ell(\beta_1, \beta_2, \sigma_1^2, \rho) = & \sum_{i=1}^n \{ (1 - y_{2i}) \ln [1 - \Phi(x'_{2i}\beta_2)] + \dots \\ & \dots + y_{2i} \left[\ln \sigma_1^2 + \ln \phi \left(\frac{y_{1i} - x'_{1i}\beta_1}{\sigma_1} \right) \right] + \dots \\ & \dots + y_{2i} \ln \left[\Phi \left(\frac{x'_{2i}\beta_2 + \rho \sigma_1 (y_{1i} - x'_{1i}\beta_1)}{\sqrt{1 - \rho^2} \sigma_1} \right) \right] \} \end{aligned}$$

- Las condiciones de primer orden de este problema definen implícitamente los estimadores MV.
- Bajo todos los supuestos mencionados, es una alternativa consistente y eficiente.

En la práctica

El estimador de Heckman por MV tiene algunos problemas de implementación:

- Requiere supuestos demasiado estrictos sobre (u_{1i}, u_{2i}) .
- La función de verosimilitud es complicada.
- Problemas de convergencia en la maximización numérica.

Rara vez se usa.

(1) Modelo Tobit en la selección

Supongamos el siguiente modelo con los supuestos (2) a (5)

$$\begin{cases} y_{1i} &= x'_{1i}\beta_1 + u_{1i} \\ y_{2i} &= \max(x'_{2i}\beta_2 + u_{2i}, 0) \end{cases}$$

donde y_{1i} se observa solo cuando $y_{2i} > 0$. Luego,

$$E(y_{1i} | x_{1i}, y_{2i} > 0, u_2) = x'_{1i}\beta_1 + \gamma u_2$$

- Seguimos en la lógica de sesgo por variable omitida.
- ¿Es posible observar a u_2 ?
- ¿Cómo implementar un estimador factible?

(1) Modelo Tobit en la selección

$$E(y_{1i}|x_{1i}, y_{2i} > 0, u_2) = x'_{1i}\beta_1 + \gamma u_2$$

Es posible computar un estimador en dos etapas (Vella, 1992, 1998; Wooldridge, 1994):

- 1 Estimar $\hat{\beta}_2$ con un Tobit con (y_{2i}, x_{2i}) y computar los residuos $\hat{u}_{2i} = y_{2i} - x'_{2i}\hat{\beta}_2$ para la muestra con $y_{2i} > 0$.
- 2 Obtener $(\hat{\beta}_1, \hat{\gamma})$ haciendo un MCO de y_{1i} en función de x_{1i} y $\hat{u}_{2i}$.

A esto se le llama modelo **Tobit tipo III** (Amemiya, 1985).

¿Este modelo es mejor que el de Heckman en dos etapas?

(2) Estimador semi-paramétrico

Si la distribución de (u_{1i}, u_{2i}) es desconocida, es razonable decir

$$E(u_{1i}|x_{1i}, y_{2i} = 1) = g(x'_{2i}\beta_2)$$

donde $g(\cdot)$ es una función desconocida. Luego,

$$E(y_{1i}|x_{1i}, y_{2i} = 1) = x'_{1i}\beta_1 + g(x'_{2i}\beta_2)$$

Esto se corresponde con un modelo semi-paramétrico que puede estimar mediante métodos estándar (Wooldridge, 1994).

- También requiere dos etapas (para estimar a β_2).
- Restricción de exclusión: ahora es estrictamente necesaria.

(3) Otras extensiones

Montes Rojas (2011): test robusto para evaluar si u_{1i} es normal y la linealidad de su esperanza condicional. Es un test LM modificado usando una expansión de Edgeworth.

Tauchmann (2010): analiza la selección multivariada

$$\begin{cases} y_i = & x_i' \beta + u_i \\ d_i = & 1(z_i' \alpha + v_i > 0) \\ y_i & \text{se observa si } d_i = 1 \end{cases}$$

donde y_i , d_i , u_i y v_i son vectores de $(m \times 1)$. Resultado:

- En general, Heckman en dos etapas ecuación por ecuación será inconsistente.
- Propone una versión modificada que incorpora el patrón completo de selección en la inversa del ratio de Mills.

Ejemplo: ecuación de salario para las mujeres

- **Motivación:** dado un conjunto de características observables para un individuo, su decisión de trabajar no es independiente del salario.
- **Problema latente:** sesgo por selección al usar MCO para estimar los β de una ecuación de salarios.
- **Solución:** usar el método de Heckman (máximo verosímil o en dos etapas).
- **Datos:** provenientes de la EPH 2014 para los aglomerados de la Patagonia.
- **Muestra:** 5327 mujeres entre 15 y 60 años de edad, de las cuales 2663 trabajan.

Variables a utilizar

Ecuación de regresión:

- *Variable dependiente* (y_{1i}): logaritmo natural del salario por hora.
- *Regresores* (x_{1i}): la edad y su cuadrado, años de educación y su cuadrado.

Ecuación de selección:

- *Variable dependiente* (y_{2i}): vale 1 si trabaja, 0 en caso contrario.
- *Regresores* (x_{2i}): edad, años de educación, estado conyugal, asistencia a la educación formal, cantidad de hijos menores a 12 y una dummy que vale 1 si es jefa de hogar.

```
. heckman lwage edad* aedu*, select(trabaja = edad aedu casada asiste hijos jefe) twostep
```

```
Heckman selection model -- two-step estimates      Number of obs   =      5,327
(regression model with sample selection)           Censored obs    =      2,664
                                                    Uncensored obs  =      2,663

                                                    Wald chi2(4)    =      450.31
                                                    Prob > chi2     =      0.0000
```

		Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
-----+-----							
lwage							
	edad	.0405814	.0083559	4.86	0.000	.0242041	.0569586
	edad2	-.0004261	.0001046	-4.08	0.000	-.000631	-.0002212
	aedu	-.0101681	.0174333	-0.58	0.560	-.0443368	.0240005
	aedu2	.0041218	.0007604	5.42	0.000	.0026315	.005612
	_cons	2.518422	.2077165	12.12	0.000	2.111305	2.925539
-----+-----							
trabaja							
	edad	.0050184	.001887	2.66	0.008	.00132	.0087169
	aedu	.0877533	.0056247	15.60	0.000	.0767291	.0987775
	casada	-.0256304	.0463482	-0.55	0.580	-.1164712	.0652104
	asiste	-1.007769	.0604728	-16.66	0.000	-1.126293	-.889244
	hijos12	-.1109985	.0222329	-4.99	0.000	-.1545742	-.0674228
	jefe	.6394699	.0480152	13.32	0.000	.5453619	.7335779
	_cons	-1.082192	.1005422	-10.76	0.000	-1.279251	-.8851329
-----+-----							
mills							
	lambda	-.094057	.0515752	-1.82	0.068	-.1951426	.0070285
-----+-----							

Resumen

	MCO	Heckman		Máximo
		"manual"	comando	Verosimil
edad	0.0431*** (0.0084)	0.0406*** (0.0085)	0.0406*** (0.0084)	0.0401*** (0.0084)
aedu	-0.0064 (0.0230)	-0.0102 (0.0232)	-0.0102 (0.0174)	-0.0111 (0.0175)
edad2	-0.0004*** (0.0001)	-0.0004*** (0.0001)	-0.0004*** (0.0001)	-0.0004*** (0.0001)
aedu2	0.0041*** (0.0010)	0.0041*** (0.0010)	0.0041*** (0.0008)	0.0041*** (0.0008)
lambda		-0.0941* (0.0513)	-0.0941* (0.0516)	-0.1118 (0.0665)
Constant	2.3427*** (0.2051)	2.5184*** (0.2234)	2.5184*** (0.2077)	2.5530*** (0.2232)
Observations	2,663	2,663	5,327	5,327
R-squared	0.2084	0.2094		

Robust standard errors in parentheses *** p<0.01, ** p<0.05, * p<0.1

Referencias

- Greene (2003), *Econometric Analysis*. Prentice Hall. 5a. Edición. Capítulo 22 (22.4.1-22.4.3).
- Cameron y Trivedi (2005), *Microeconometrics*. Capítulo 16 (16.5).
- Cameron y Trivedi (2009), *Microeconometrics Using Stata*, Stata Press. Capítulo 16.
- Gasparini, L., Marchionni, M. y Sosa Escudero, W. (2004) "Characterization of inequality changes through microeconomic decompositions. The case of Greater Buenos Aires", en Bourguignon, F., Lustig, N y Ferreira, F. (eds.), 2004 (pp. 47- 82).

Estimación no paramétrica de densidades

-Econometría Avanzada-

Mariana Marchionni
marchionni.mariana@gmail.com

- 1 Introducción: modelos paramétricos versus no paramétricos
- 2 Estimación no paramétrica de densidades
 - 1 Estimadores no paramétricos rudimentarios
 - 2 Estimador de promedios ponderados o Kernels
 - 3 Propiedades: sesgo, varianza, consistencia, ancho de banda óptimo
- 3 Extensiones:
 - 1 Estimadores con ancho de banda variable
 - 2 Estimación de densidades conjuntas, la maldición de la dimensionalidad
- 4 Ejemplos

Los modelos paramétricos

- Supongamos que nos interesa estudiar la relación entre Y y X
- Un modelo paramétrico hace todos los supuestos necesarios para que nuestra ignorancia se limite solo a algunos parámetros.
- Ejemplo: $Y = X\beta + \varepsilon$ con $\varepsilon | X \sim N(0, \sigma^2)$
 $\Rightarrow$ todo lo que no conocemos de la relación entre Y y X se resume en β y en el parámetro σ^2 .
- Hay muchísimos modelos paramétricos y fundamentalmente 2 métodos de estimación: MCO y MV .
- La *consistencia* de los estimadores MCO y MV descansa en la *correcta especificación del modelo*.

Los modelos no paramétricos


- Los modelos no paramétricos no suponen ninguna estructura particular para describir la relación entre las variables de interés.
- Se recurre al menor número posible de supuestos para **"dejar hablar a los datos"**.
- Levantar supuestos tiene sus pros y sus contras. Ya veremos...

¿Por qué concentrarnos en la estimación de densidades?

- 1 Razones didácticas: insumo para la estimación de regresiones no paramétricas
- 2 Descripción de hecho estilizados:
 - evolución de la distribución del ingreso de una región
 - distribución del rendimiento de activos
 - distribución del peso de los niños al nacer
- 3 Como parte de la inspección de los datos, para evaluar el cumplimiento de ciertos supuestos paramétricos.

Objetivo: estimar el **valor de la función de densidad en un punto particular del soporte, $f(x_0)$** . Sean:

- $f = f(\cdot)$ la función de densidad de la variable aleatoria continua X .
- $x_1, x_2, \dots, x_N$ una muestra aleatoria de X : $x_i \sim f(\cdot)$, iid.
- x_0 un punto cualquiera del soporte de la distribución de X .



- Se supone una forma funcional particular para $f(\cdot)$.
- Ejemplo: distribución Normal

$$f(x_0) = \phi(x_0) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x_0 - \mu}{\sigma} \right)^2 \right]$$

- La ignorancia sobre $f(x_0)$ se limita al desconocimiento de los dos parámetros μ y σ .
- Estimadores consistentes (MV) son:

$$\hat{\mu} = \bar{X} = \frac{\sum_{i=1}^N x_i}{N} \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{N}$$


Estimación no paramétrica de una densidad

- Se busca estimar $f(x_0)$ sin suponer una forma funcional particular
- Único supuesto: $f(\cdot)$ es una función suave (continua, diferenciable).
- ¿Cómo se interpreta la información muestral?
Si observamos más datos “cerca” de x_0 que de x' inferimos que $f(x_0) > f(x')$




Un estimador no paramétrico rudimentario: el histograma

- Se estima la probabilidad dentro de intervalos mediante la frecuencia relativa.
- Los intervalos se determinan a partir de un punto inicial a y un ancho de banda W





Un estimador no paramétrico rudimentario: el histograma



- Superficie de las barras = frec. rel. en el intervalo
= $\text{nro.obs.en el intervalo} / N$
- Altura de las barras = estimador de la densidad
= $\text{nro.obs.en el intervalo} / (N \times W)$



(1) Depende del punto inicial:




(2) Depende del ancho de banda:



(3) Es discontinuo en los extremos del intervalo

Notar que $\hat{f}(x_1) = \hat{f}(x_2)$, pero $\hat{f}(x_2 + \varepsilon) = 1/4 \hat{f}(x_1)$ para cualquier $\varepsilon > 0$, contradiciendo que $f(\cdot)$ es continua.



Caso discreto:

- X es una VA discreta, muestra x_i iid, $i = 1, 2, \dots, N$
- Objetivo: estimar $\Pr(X = x_0) = f(x_0)$
- El estimador naive viene dado por:


$$\hat{f}(x_0) = \frac{\# \text{ obs. con } x_i = x_0}{N} = \frac{1}{N} \sum_{i=1}^N I(x_i = x_0)$$

donde $I(\cdot) = 1$ si su argumento es verdadero, $= 0$ en caso contrario.

- El estimador naive para el caso discreto es la frecuencia relativa en el punto x_0

Caso continuo

- X es una VA continua $\Rightarrow \Pr(X = x_0) = 0$
 $\Rightarrow$ evaluamos la probabilidad de que X esté “cerca” de x_0 .
- Decimos que x_i está cerca de x_0 si $x_i \in (x_0 - h, x_0 + h)$.



$$\begin{aligned}
 2h \times f(x_0) &\cong \int_{x_0-h}^{x_0+h} f(z) dz = \Pr[x_0 - h < X < x_0 + h] \\
 &\cong \frac{1}{N} \# x_i \in (x_0 - h, x_0 + h) \\
 &= \frac{1}{N} \sum_{i=1}^N I[x_i \in (x_0 - h, x_0 + h)] \\
 &= \frac{1}{N} \sum_{i=1}^N I[x_0 - h < x_i < x_0 + h] \\
 &= \frac{1}{N} \sum_{i=1}^N I\left[-1 < \frac{x_i - x_0}{h} < 1\right]
 \end{aligned}$$


$$\Rightarrow f(x_0) \cong \frac{1}{2h \times N} \sum_{i=1}^N I\left[-1 < \frac{x_i - x_0}{h} < 1\right] \equiv \hat{f}(x_0)$$

$$\hat{f}(x_0) \equiv \frac{1}{h \times N} \sum_{i=1}^N \frac{1}{2} I\left[-1 < \frac{x_i - x_0}{h} < 1\right]$$

Características del estimador naïve

Notar:

- Para cada punto de estimación se define el centro de un intervalo.
- Las observaciones que están dentro de ese intervalo (a menos de un h de distancia de x_0) se ponderan por $\frac{1}{2}$.




- La densidad estimada es el cociente entre la suma de los ponderadores y $h \times N$ (tamaño de la muestra local):

$$\hat{f}(x_0) = \frac{1}{12 \times h} \times \frac{9}{2} = \frac{3}{8 \times h}$$


Características del estimador naïve

- Para estimar la densidad en los puntos a , b y c construimos intervalos alrededor de cada uno.
- Notar que los intervalos pueden superponerse $\implies$ se rompe la dependencia respecto al punto inicial.
- Obtenemos 3 estimadores puntuales $\hat{f}(a)$, $\hat{f}(b)$ y $\hat{f}(c)$. Podemos unirlos para visualizar la forma estimada de $f(\cdot)$.




(1) Depende de h

- A mayor h observaciones más lejanas de x_0 se usan para estimar $f(x_0)$.
- A mayor h , al unir las estimaciones puntuales obtenemos una función más suave (h =smoothing parameter)



(2) Los ponderadores son discontinuos

- El ponderador $\frac{1}{2}I(\cdot)$ es discontinuo en los límites de cada intervalo, generando discontinuidades en la densidad estimada.
- Además, dentro del intervalo, trata igual a todas las observaciones independientemente de su distancia respecto de x_0 .



Generalización del estimador naive:

- Reemplaza el ponderador $\frac{1}{2}I(.)$ por una función ponderadora o Kernel $K(.)$:

$$\hat{f}(x_0) = \frac{1}{N \times h} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

- Los kernels $K(.)$ son funciones conocidas que se eligen para satisfacer ciertas propiedades deseables:

$$(1) K(\varphi) \geq 0; (2) \int_{-\infty}^{\infty} K(\varphi) d\varphi = 1 \text{ y } (3) K(\varphi) = K(-\varphi)$$

- Enfoque de Rosenblatt-Parzen (1957 y 1962, respect.).


Distintos kernels: rectangular o uniforme

$$K(\varphi_i) = \begin{cases} \frac{1}{2} & \text{si } |\varphi_i| < 1 \\ 0 & \text{en caso contrario} \end{cases}$$

donde $\varphi_i = \frac{x_i - x_0}{h}$, es la distancia estandarizada en unidades de h .

- En este caso el estimador de Kernels coincide con el estimador naïve.
- Notar: el ponderador es similar a una función de densidad uniforme en el intervalo $(-1, 1)$.

Estos son los **ponderadores** para estimar la densidad en x_0 si se usa un kernel rectangular




- La función kernel tiene la forma de una densidad normal estándar.

$$K(\varphi_i) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{\varphi^2}{2}\right)$$

- Importante:** no se está suponiendo la distribución normal para ninguna variable. Sólo se usa la forma funcional para ponderar las observaciones en la fórmula del estimador.
- El estimador de la densidad usando el kernel gaussiano viene dado por:

$$\hat{f}(x_0) = \frac{1}{N \times h} \sum_{i=1}^N \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2} \left(\frac{x_i - x_0}{h}\right)^2\right]$$




- Consideremos al Kernel como una función de x_i , para x_0 y h dados.
- $K(\cdot)$ es una función decreciente de $|x_i - x_0|$: observaciones más cercanas a x_0 reciben mayor ponderación.
- A diferencia del estimador naíve, las ponderaciones decrecen suavemente.


Para estimar la densidad en el punto x_0 el estimador de kernels “promedia” las ponderaciones de todas las observaciones alrededor de x_0 :

$$\hat{f}(x_0) = \frac{1}{N \times h} \sum_{i=1}^N \frac{1}{\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x_i - x_0}{h} \right)^2 \right]$$

Cada término de la sumatoria corresponde a la ponderación de una observación x_i .



El ancho de banda h sigue definiendo qué se entiende por “cerca” de x_0 .



- Cuanto más chico es h , más concentrados están los ponderadores y ...
 - menor deberá ser la distancia entre x_i y x_0 para que x_i sea considerado cercano a x_0 .
 - más rápidamente decrecen los ponderadores al alejarnos de x_0 .
- h se conoce también como parámetro de suavizamiento.


Tipo de Kernel	Fórmula	Soporte
Gaussiano o normal	$\frac{1}{\sqrt{2\pi}} \exp(-\varphi^2 / 2)$	$\varphi \in (-\infty, \infty)$
Epanechnikov	$\frac{3}{4\sqrt{5}} (1 - \frac{1}{5}\varphi^2) I(\varphi < \sqrt{5})$	$\varphi \in (-\sqrt{5}, \sqrt{5})$
Epanechnikov modificado	$\frac{3}{4} (1 - \varphi^2) I(\varphi < 1)$	$\varphi \in (-1, 1)$
Triangular	$(1 - \varphi) I(\varphi < 1)$	$\varphi \in (-1, 1)$
Uniforme o rectangular	$\frac{1}{2} I(\varphi < 1)$	$\varphi \in (-1, 1)$

- El estimador de kernels es generalmente sesgado.
- Puede demostrarse que para kernels que satisfacen las propiedades (1), (2) y (3), la expresión aproximada para el sesgo viene dada por:

$$\text{Sesgo} \left[\hat{f}(x_0) \right] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{\infty} K(\varphi) \varphi^2 d\varphi$$

$$\text{Sesgo} [\hat{f}(x_0)] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{\infty} K(\varphi) \varphi^2 d\varphi$$

- El sesgo crece con h . A mayor es h , observaciones más lejanas de x_0 se tienen en cuenta para estimar $f(x_0)$.
- El sesgo crece con la curvatura de la verdadera densidad. Si $f''(x_0)$ tiende a cero el sesgo desaparece:



- El sesgo depende del kernel.

La expresión aproximada para la varianza asintótica del estimador de kernels viene dada por:

$$\text{Varianza} \left[\hat{f}(x_0) \right] \cong \frac{1}{N \times h} f(x_0) \int_{-\infty}^{\infty} K^2(\varphi) d\varphi$$

- A mayor h menor es la varianza (mayor eficiencia)
- A mayor N menor es la varianza
- La varianza también depende del kernel

Trade-off entre insesgamiento y eficiencia

- A mayor h , menos sesgo pero más varianza.
- Asintóticamente se alivia el trade-off porque, para h dado, la varianza cae cuando $N \rightarrow \infty$.
- ¿Cómo se resuelve este *trade-off* para un N dado? Se elige h haciendo un balance entre los dos objetivos: h óptimo.

Ancho de banda óptimo y consistencia

Recordemos: es suficiente para consistencia que sesgo y varianza desaparezcan cuando $N \rightarrow \infty$.

Según las expresiones anteriores:

- El sesgo desaparece si $h \rightarrow 0$
- La varianza desaparece si $N \times h \rightarrow \infty$

Para la consistencia del estimador de kernels se requiere

- Que h decrezca con el tamaño muestral N .
- Que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N (para que $N \times h \rightarrow \infty$).
- El h que satisface este criterio se conoce como ancho de banda óptimo.

Ancho de banda óptimo y consistencia

Recordemos: es suficiente para consistencia que sesgo y varianza desaparezcan cuando $N \rightarrow \infty$.

Según las expresiones anteriores:

- El sesgo desaparece si $h \rightarrow 0$
- La varianza desaparece si $N \times h \rightarrow \infty$

Para la consistencia del estimador de kernels se requiere

- Que h decrezca con el tamaño muestral N .
- Que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N (para que $N \times h \rightarrow \infty$).
- El h que satisface este criterio se conoce como ancho de banda óptimo.

Elección del ancho de banda óptimo

Elegir el h^* que minimiza el **Error Cuadrático Medio Integrado (ECMI)**:

$$ECMI = \int E \left[\hat{f}(x) - f(x) \right]^2 dx = \int \{ [\text{sesgo } \hat{f}(x)]^2 + V[\hat{f}(x)] \} dx$$

- El ECMI promedia los ECM a lo largo de todos los posibles puntos de estimación.
- En la práctica se usan las expresiones aproximadas del sesgo y varianza que vimos antes.
- Si $f(x)$ fuera normal y con un $K(\cdot)$ gaussiano, $h^* = 1,06 \sigma N^{-1/5}$. Esta regla (*rule of thumb*) funciona bastante bien para otras distribuciones unimodales distintas a la normal, mientras no sean muy asimétricas.
- Otros métodos de elección de h^* : **métodos de validación cruzada.**

Consistencia paramétrica versus no paramétrica

- La consistencia del estimador no paramétrico sólo requiere ajustar adecuadamente la elección del ancho de banda.
- En cambio, se requieren fuertes supuestos para la consistencia de los estimadores en los modelos paramétricos.
- El problema es que los estimadores no paramétricos convergen más lento que los paramétricos:
 - Cuando $N \rightarrow \infty$ y h se ajusta óptimamente $\Rightarrow N \times h \rightarrow \infty$ y la varianza $\rightarrow 0$. Entonces, el estimador no paramétrico converge a la tasa $\sqrt{N \times h}$
 - Recordar que la tasa de convergencia paramétrica es $\sqrt{N}$ ($> \sqrt{N \times h}$), pero...a dónde convergen?

Los estimadores no paramétricos son siempre consistentes pero convergen más lentamente. Por eso requieren tamaños muestrales mayores.

Consistencia paramétrica versus no paramétrica

- La consistencia del estimador no paramétrico sólo requiere ajustar adecuadamente la elección del ancho de banda.
- En cambio, se requieren fuertes supuestos para la consistencia de los estimadores en los modelos paramétricos.
- El problema es que los estimadores no paramétricos convergen más lento que los paramétricos:
 - Cuando $N \rightarrow \infty$ y h se ajusta óptimamente $\Rightarrow N \times h \rightarrow \infty$ y la varianza $\rightarrow 0$. Entonces, el estimador no paramétrico converge a la tasa $\sqrt{N \times h}$
 - Recordar que la tasa de convergencia paramétrica es $\sqrt{N}$ ($> \sqrt{N \times h}$), pero...a dónde convergen?

Los estimadores no paramétricos son siempre consistentes pero convergen más lentamente. Por eso requieren tamaños muestrales mayores.

- $\hat{f}(x)$ es asintóticamente normal (por TCL, ya que $\hat{f}(x)$ es un promedio de VA iid)

$$\frac{\hat{f}(x) - E[\hat{f}(x)]}{\sqrt{V[\hat{f}(x)]}} \xrightarrow{d} N(0, 1)$$

$$\sqrt{N \times h} \hat{f}(x) \xrightarrow{d} N\left(f(x), N \times h V[\hat{f}(x)]\right)$$

- Intervalo asintótico al 95 % de confianza

$$\hat{f}(x) \pm 1,96(N \times h)^{-1/2} \left(f(x) \int K^2(\varphi) d\varphi \right)^{1/2}$$


- Como se trata de resultados asintóticos y vimos que $\hat{f}$ converge lento, en la práctica suelen usarse intervalos de confianza empíricos obtenidos por *bootstrap*.


Intervalos de confianza empíricos

- Pueden usarse en reemplazo de los intervalos de confianza asintóticos.
- Se construyen a partir de una distribución empírica del estimador, que se obtiene mediante técnicas de *bootstrap* (Hall 1992)
- Los pasos:
 - Datos originales: $x_1, \dots, x_N$
 - Obtención de las muestras bootstrap: remuestreo a partir de los datos: $x_1^j, \dots, x_N^j$ para $j = 1, \dots, J$.
 - Obtención del estimador para cada una de las J muestras bootstrap: $\hat{f}^j(x) = \frac{1}{N \times h} \sum K(\frac{x_i^j - x}{h})$
 - Estimación de la distribución empírica del estimador: usando las J realizaciones, estimamos no paramétricamente la distribución de $\hat{f}$
 - Intervalos de confianza empíricos: se construyen en base a los percentiles de la distribución empírica

- El estimador de promedios ponderados o Kernels es generalmente sesgado. El sesgo desaparece cuando $h \rightarrow 0$.
- Pero para consistencia requerimos que $h \rightarrow 0$ a un ritmo menor al que aumenta N . Esta es la única condición para consistencia.
- La velocidad de convergencia del estimador de Kernels es $\sqrt{N \times h}$ mientras $h \rightarrow 0$, más lenta que la velocidad paramétrica $\sqrt{N}$
- Además, la distribución del estimador de Kernels es asintóticamente normal, por lo que se pueden utilizar los procedimientos habituales de inferencia.


Ejemplo 1: la distribución del ingreso






- Más suave que el histograma, no tanto como una normal.
- Cierta grado de asimetría, apartamientos de la normal.
- Kernel Epanechnikov y el ancho de banda óptimo


Cambios en el ancho de banda



Cambios en el Kernel




Ejemplo 2: Desigualdad y salarios mínimos




Fuente: Di Nardo y Tobias (2001)

Ejemplo 2: Desigualdad y salarios mínimos



Fuente: Di Nardo y Tobias (2001)


Ejemplo 3: Evolución de la distribución del ingreso en Italia



Fuente: Li y Racine (2007), pp. 48. Basado en Baiocchi (2006).

Extensión 1: estimadores con ancho de banda flexible

Supongamos que queremos estimar $f(a)$ y $f(b)$




- Candidatos: $\hat{f}(a) = \frac{1}{N \times h} \sum_{i=1}^N K\left(\frac{x_i - a}{h}\right)$ y $\hat{f}(b) = \frac{1}{N \times h} \sum_{i=1}^N K\left(\frac{x_i - b}{h}\right)$
- Al usar el mismo h , sobresuavizamos la estimación en zonas como a y subsuavizamos la estimación en zonas como b .
- ¿Y si en vez de un único h usamos $h_a \neq h_b$? Por ejemplo, con $h_b > h_a$ garantizamos un número mínimo de obs. para cada estimación.
- ¿Y qué hay del sesgo, será mayor el de $\hat{f}(b)$?
No necesariamente, porque la densidad suele ser más plana en las colas; es decir, es probable que $f''(b) < f''(a)$.

Extensión 1: estimadores con ancho de banda flexible

Un ejemplo: estimador del vecino más cercano (NN, por *nearest neighbor*)

$$\hat{f}_{NN}(x_0) = \frac{1}{N \times h(x_0)} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

- donde $h(x_0) \equiv d_k(x_0)$ y $d_k(x_0)$ es la distancia euclídea entre x_0 y su k -ésimo vecino más cercano (k -NN).
- En la práctica, suele fijarse $k \cong \sqrt{N}$
- Ejemplo: $N = 12$ y $k = 3$



- Consistencia requiere que cuando $N \rightarrow \infty$, $k \rightarrow \infty$ (rol similar a $N \times h$) y $k/N \rightarrow 0$ (rol similar a h)

Extensión 2: estimación no paramétrica de densidades conjuntas

Generalizamos el estimador de promedios ponderados para estimar densidades conjuntas:

$$\hat{f}(x_0) = \frac{1}{N \times h^q} \sum_{i=1}^N K\left(\frac{x_i - x_0}{h}\right)$$

- donde $x_i = (x_{1i}, x_{2i}, \dots, x_{qi})$ es la i -ésima observación muestral de las q variables aleatorias y el punto de estimación es $x_0 \in \mathbb{R}^q$
- La distancia entre x_i y x_0 ahora involucra q dimensiones: h^q . Necesario estandarizar las variables para usar un mismo h .
- $\underline{K}(\cdot)$ es un kernel multivariado, usualmente multiplicativo:
$$\underline{K}\left(\frac{x_i - x_0}{h}\right) = \prod_{j=1}^q K\left(\frac{x_{ji} - x_{j0}}{h}\right)$$

La maldición de la dimensionalidad

- Recordemos: para la consistencia del estimador de la densidad univariada se requería que $N \times h \rightarrow \infty$ mientras $h \rightarrow 0$.
- Con q variables se requiere que $N \times h^q \rightarrow \infty$ mientras $h \rightarrow 0$.
 - Es decir, h tiene que tender a cero mucho más lento
 - Intuitivamente: el tamaño de la muestra local decrece exponencialmente cuando aumenta q (pensar en las celdas definidas por el cruce de variables y cómo cae el número de observaciones por celda cuando aumenta el número de cruces).
- Los estimadores de la densidad conjunta convergen mucho más lento: $\sqrt{N \times h^q} \left(< \sqrt{N \times h} < \sqrt{N} \right)$
- Para una aplicación de estimación no paramétrica de densidades conjuntas, ver Deaton (1997), desde página 182.

- Li, Q. and J. S. Racine (2007). Nonparametric Econometrics. Princeton University Press. Cap. 1.
- Pagan, A. and Ullah (1999). Nonparametric Econometrics. Cambridge University Press. Cap. 2.

Regresiones no paramétricas

-Econometría Avanzada-

Mariana Marchionni
marchionni.mariana@gmail.com

Hoy: regresiones no paramétricas y semiparamétricas

- 1 Estimador Nadaraya-Watson
- 2 Polinomios locales
- 3 Modelo de regresión parcialmente lineal

$$Y = m(X) + \mu \quad \text{con } E[\mu|X] = 0$$

$$\Rightarrow E[Y|X] = m(X)$$

- usualmente hacemos supuestos paramétricos como $m(x) = \alpha + \beta x$, $m(x) = \alpha + \beta x + \gamma x^2$, $m(x) = \alpha + \beta \ln(x)$ o $m(x) = f(\beta x)$ con $f(\cdot)$ conocida
- ¿Cómo estimamos $m(\cdot)$ sin hacer supuestos paramétricos?
- La estrategia será estimar el valor de $m(\cdot)$ en cada punto de interés x , es decir, $m(X = x) = m(x)$

- Surge de aplicar el método de Kernels a la estimación de una esperanza condicional
- Intuición:
 - aprendimos a estimar no paramétricamente la densidad por medio de una especie de **frecuencia relativa ponderada local**
 - entonces podemos estimar $E[Y|X = x] = m(x)$ haciendo un **promedio ponderado local** de Y (o sea, en la vecindad de x).


El caso más simple:

- estimamos $E[Y|X = x] = m(x)$ promediando los valores de Y para observaciones con valores de X cercanos a x
- en este caso simple, definimos 'cercano' como 'a menos de un h de distancia de x '

$$\hat{m}(x) = \frac{\sum_{i=1}^N y_i I[-1 < (x_i - x)/h < 1]}{\sum_{i=1}^N I[-1 < (x_i - x)/h < 1]}$$

- Notar que estamos ponderando las observaciones mediante un Kernel uniforme.

Queremos estimar $m(0)$. Promediamos los valores de Y de las observaciones en el intervalo $(-h, h)$



Generalizando:

- reemplazamos la función ponderadora $l(\cdot)$ por Kernels suaves y decrecientes en $[(x_i - x)/h] = \varphi_i$

$$\hat{m}(x) = \frac{\sum_{i=1}^N y_i K(\varphi_i)}{\sum_{i=1}^N K(\varphi_i)} = \sum_{i=1}^N y_i \omega_i$$

- **Estimador Naradaya-Watson** (Naradaya, 1964; Watson, 1964)
- Notar: el estimador NW es un promedio ponderado de las y_i , donde los ponderadores ω_i son funciones *no lineales* de la distancia entre x_i y el punto de estimación x .

- Implícitamente estamos suponiendo que la regresión poblacional $m(\cdot)$ es suave, lo que justifica usar como criterio de ponderación la distancia alrededor de x .
- h sigue indicando qué significa estar lejos o cerca de x :
 - $h \rightarrow \infty, \hat{m}(x) = \sum y_i / N = \bar{Y}$
 - $h \rightarrow 0, \hat{m}(x) = y_i$ si $\exists x_i = x$

Generalizando para q variables explicativas

$$\hat{m}(x) = \frac{\sum_{i=1}^N y_i \underline{K}[(x_i - x)/h]}{\sum_{i=1}^N \underline{K}[(x_i - x)/h]}$$

- Ahora x y $x_i \in \mathbb{R}^q$ y $\underline{K}(\cdot)$ es un kernel multivariado, que pondera la distancia de x_i respecto de x considerando cada una de las q dimensiones
- Una forma usual es $\underline{K}(\cdot) = \prod_{j=1}^q K[(x_i^j - x^j)/h]$
- Notar que para trabajar con un mismo h para todas las dimensiones es necesario estandarizar las variables previamente.

Propiedades del estimador Nadaraya-Watson

- Consistencia requiere $h \rightarrow 0$ y $N \times h^q \rightarrow \infty$ cuando $N \rightarrow \infty$
- Convergencia a la tasa $\sqrt{N \times h^q}$ ($\sqrt{N \times h} < \sqrt{N}$)
- Maldición de la dimensionalidad: si queremos tener estimadores 'razonables' necesitamos mantener acotado el número de variables o muestras muy grandes.
- NW es asintóticamente normal

Estimadores de polinomios locales


- El estimador Naradaya-Watson es un caso particular de la familia de estimadores de polinomios locales
- Puede mostrarse que el estimador NW es la solución del problema:

$$\underset{a}{\text{Min}} \sum_{i=1}^N K\left(\frac{x_i - x}{h}\right) (y_i - a)^2$$

- a es la constante que minimiza la suma de los desvíos cuadráticos ponderados. Es decir, NW aproxima la función $m(\cdot)$ en el punto x mediante una constante a .
- De aquí que el estimador Naradaya-Watson también sea conocido como **estimador local constante**.

Ejemplo estimador local constante

Se ilustra la estimación de $E[Y|X = 2/3]$ mediante un estimador local constante (NW). La estimación es la línea (constante) horizontal, la zona sombreada representa el intervalo y los ponderadores *biweight* se representan por la campana.



Fuente Schucany, W. R (2004). "Kernel Smoothers: An Overview of Curve Estimators for the First Graduate Course in Nonparametric Statistics". Statistical Science, Vol. 19, No. 4, pp. 663-675

- El estimador local constante (NW) tiene sesgos potencialmente grandes en los límites del soporte.
- El estimador local lineal (Stone 1977, Cleveland 1979) permite corregir estos sesgos.
- El estimador local lineal surge de aproximar $m(x)$ mediante una función localmente lineal:

$$\underset{\{a,b\}}{\text{Min}} \sum_{i=1}^N K\left(\frac{x_i - x}{h}\right) \{y_i - [a + b(x_i - x)]\}^2$$

$$\underset{\{a,b\}}{\text{Min}} \sum_{i=1}^N K \left(\frac{x_i - x}{h} \right) \{y_i - [a + b(x_i - x)]\}^2$$


- Intuición: para x_i en un entorno pequeño alrededor de x

$$m(x_i) \cong \underbrace{m(x)}_a + \underbrace{m'(x)}_b (x_i - x)$$

- Es como estimar un modelo de regresión lineal en un entorno de x . La solución puede encontrarse por *NLLS* de Y en una constante y en $(x_i - x)$ con ponderadores $\sqrt{K_i}$
- Notar que $\hat{a}$ estima $m(x)$ y $\hat{b}$ estima la derivada $m'(x)$, es decir, el efecto marginal local.

Ejemplo estimador local lineal

La línea continua muestra la estimación local lineal de $E[Y|X]$ en 100 puntos del soporte. Sombreada se muestra la estimación en tres lugares con el ajuste lineal en rojo.



Fuente Schucany, W. R (2004). "Kernel Smoothers: An Overview of Curve Estimators for the First Graduate Course in Nonparametric Statistics". Statistical Science, Vol. 19, No. 4, pp. 663-675

Generalizando a un polinomio local de orden P :

$$\underset{\{b_0, b_1, \dots, b_P\}}{\text{Min}} \sum_{i=1}^N K \left(\frac{x_i - x}{h} \right) \left\{ y_i - \left[b_0 + b_1(x_i - x) + \dots + b_P(x_i - x)^P \right] \right\}^2$$

- Donde la aproximación local viene dada por:

$$m(x_i) \cong \underbrace{m(x)}_{b_0} + \underbrace{m'(x)}_{b_1} (x_i - x) + \dots + \underbrace{\frac{1}{P!} m^P(x)}_{b_P} (x_i - x)^P$$

- $\hat{b}_0$ estima $m(x)$, $\hat{b}_1$ estima $m'(x)$, ..., $p! \hat{b}_p$ estima a $m^p(x)$

¿Cómo elegir el grado del polinomio?

- Para estimar la media local $m(x)$, elegir un polinomio de orden impar
- Los polinomios de orden par son dominados por los de orden impar siguiente, porque el parámetro extra reduce el sesgo sin aumentar la varianza
- Para estimar la derivada $m^d(x)$, elegir el orden del polinomio de forma que $(P - d)$ sea impar.


Ejemplo con *motorcycle data* de Fan & Gijbels (1996)

- Fuente:
Fan and Gijbels (1996). *Local Polynomial Modelling and Its Applications*. Monographs on Statistics and Applied Probability, Chapman & Hall CRC.
- Datos en STATA:
use <http://www.stata-press.com/data/r11/motorcycle>
- 133 observaciones sobre la aceleración ($g = cm/seg^2$) de la cabeza del maniquí en tests de choques de motos.


Variable	Obs	Mean	Std. Dev.	Min	Max
time	133	25.17895	13.13206	2.4	57.6
accel	133	-25.54586	48.32205	-134	75

Los datos: la aceleración en el tiempo

- scatter accel time




- regress accel time




Modelo cuadrático, MCO

- regress accel time time^2




- regress accel time time^2 time^3



Estimación no paramétrica:


Local constante (grado 0 = Nadaraya-Watson)

- lpoly accel time, degree(0)




Estimación no paramétrica: Local lineal (grado 1)

- lpoly accel time, degree(1)




Estimación no paramétrica: Local polinómico grado impar siguiente (grado 3)

- lpoly accel time, degree(3)




Mejoramos el ajuste con un kernel diferente

- `lpoly accel time, degree(3) k(epan2)`



Agregamos intervalos de confianza

- `lpoly accel time, degree(3) k(epan2) ci`



- Blundell and Duncan (1998). “Kernel Regression in Empirical Microeconomics”. *The Journal of Human Resources*, Vol. 33, No. 1, pp. 62-87.
- Ley de Engel: a medida que crece el presupuesto de las familias, el porcentaje gastado en alimentos tiende a caer
- Relación entre el *share* del gasto en alimentos y el logaritmo del gasto total de las familias:
 - La ley sugiere una relación negativa
 - ¿Forma funcional?

Curva de Engel: share del gasto en alimentos




Figure 3

Nonparametric Engel Curve: Food Share

Source: Banks, Blundell, and Lewbel (1997).

Curva de Engel: share del gasto en alcohol




Figure 4

Nonparametric Engel Curve: Alcohol Share

Source: Banks, Blundell, and Lewbel (1997).

Sensibilidad a la elección del ancho de banda: curva de Engel del share de alcohol




Figure 5
Sensitivity to Bandwidth Selection: Alcohol Engel Curve

Otros estimadores no paramétricos: método de series

- Hasta ahora vimos estimadores de carácter local
- Los estimadores de series (o de forma flexible) parten de una lógica distinta: buscan ajustar **globalmente** una función desconocida $m(\cdot)$
- ¿Cómo hacerlo sin recurrir a supuestos paramétricos?
- Hay ciertas funciones (llamadas 'funciones base') que, combinadas linealmente, permiten aproximar bien cualquier otra función suave.
- La combinación de estas funciones base es una **serie**, de ahí el nombre **método de series**

Ejemplo: forma flexible de Fourier

Combina series de potencias y de funciones trigonométricas

$$m(x_i) \cong \underbrace{a}_{\text{nivel}} + \underbrace{b \cdot x_i}_{\text{tendencia}} + \underbrace{c \cdot x_i^2}_{\text{curvatura}} +$$

$$\underbrace{d \cdot \cos(x_i) + e \cdot \sin(x_i) + f \cdot \cos(2x_i) + g \cdot \sin(2x_i) + \dots}_{\text{sintonía fina}}$$

- Para cierto valor de los parámetros, cuando el número de términos tiende a infinito la serie converge a $m(\cdot)$
- Esto es una **propiedad matemática de la serie**, NO es un supuesto sobre la forma funcional de $m(\cdot)$
- En este sentido es un método no paramétrico
- Estimación: por MCO, regresando y_i en todos los términos de la serie

Propiedades de los estimadores de series

- La consistencia depende únicamente de que el número de términos en la serie tienda a infinito cuando $N \rightarrow \infty$
- Convergen a la tasa paramétrica $\sqrt{N}$
- Son asintóticamente normales
- La aplicación se hace algo más complicada cuando hay múltiples regresores

Testeando la validez de una especificación paramétrica

- Un poco de historia: test de Hausman (1978)
- Vimos aplicación en paneles para evaluar EF vs. EA.
- Aquí vamos a usarlo para comparar dos especificaciones paramétricas
 - H_0 : el modelo 0 (paramétrico) es cierto
 - H_1 : el modelo 1 (paramétrico) es cierto

- Supongamos que hay 2 estimadores de un parámetro del modelo
 - $\hat{\beta}_0$: consistente y eficiente bajo H_0 , inconsistente bajo H_1 .
 - $\hat{\beta}_1$: siempre consistente (H_0 o H_1) pero no eficiente.
- Intuición de la estrategia:
 - si H_0 es cierta, los dos estimadores deberían ser parecidos.
 - Diferencias grandes sugieren rechazar H_0 .
- Estadístico de Hausman

$$H = (\hat{\beta}_1 - \hat{\beta}_0)'(\hat{\Omega}_1 - \hat{\Omega}_0)^{-1}(\hat{\beta}_1 - \hat{\beta}_0) \stackrel{H_0}{\sim} \chi^2_{(dim.\beta)}$$

Testeando la validez de una especificación paramétrica

- Problema: tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ son inconsistentes si los dos modelos paramétricos son inválidos
- Sería mejor comparar un modelo paramétrico contra una alternativa no paramétrica
 - $H_0 : E[Y|x] = f(x, \beta_0)$ para algún β_0 y $f(\cdot)$ conocida
 - $H_1 : E[Y|x] \neq f(x, \beta)$, para cualquier β (involucra cualquier desviación respecto de H_0)
- Zheng (1996, Journal of Econometrics): propone usar el método de Kernels para construir un estimador de la condición de momento que permite distinguir H_0 de H_1

- Estadístico de Zheng

$$T_N = \frac{\sum_{i=1}^N \sum_{j(\neq i)=1}^N K[(x_i - x_j)/h] e_i e_j}{\left\{ \sum_{i=1}^N \sum_{j(\neq i)=1}^N 2 [K[(x_i - x_j)/h]]^2 e_i^2 e_j^2 \right\}^{1/2}} \xrightarrow{H_0} N(0, 1)$$

- donde e son los residuos de estimar el modelo paramétrico de la H_0 , es decir, $e_i = y_i - f(x_i, \hat{\beta})$.
- Si $f(\cdot)$ es lineal en β , $\hat{\beta}$ se obtiene por OLS; si es no lineal, $\hat{\beta}$ se obtiene por NLLS.
- Si $|T_N|$ es grande, se rechaza la validez de la especificación paramétrica.
- Blundell y Duncan (1998) usan una notación más simplificada (ver pág. 74)

- Las especificaciones no paramétricas garantizan consistencia de los estimadores
- Pero tienen contras:
 - la convergencia es lenta, necesitamos muestras muy grandes.
 - además, el problema se agrava exponencialmente cuando aumenta el número de regresores.
 - los resultados suelen ser difíciles de comunicar (resumir).
 - como no hay un modelo, no se pueden extrapolar los resultados para otros valores de las x .
- Los modelos semiparamétricos permiten superar algunas de estas limitaciones

Un modelo semiparamétrico:

- es una opción intermedia entre un modelo totalmente paramétrico y otro no paramétrico totalmente flexible.
- es decir, hace algunos supuestos sobre la forma funcional, sin llegar a parametrizar todos los elementos de la esperanza condicional.
- Entonces, un modelo semiparamétrico implica una solución de compromiso entre los objetivos de consistencia y eficiencia:
 - permitiría reducir el riesgo de error de especificación respecto de los modelos paramétricos
 - y aumentar la precisión de la estimación respecto de las alternativas no paramétricas

Modelos semiparamétricos de índices lineales

- Un modelo de índices lineales viene dado por

$$E[Y|X = x] = g(X\beta)$$

donde $g(\cdot)$ es una función desconocida, β es un vector desconocido y $X\beta$ es el índice lineal simple

- ¿Conocen algún un modelo paramétrico de índices lineales?
- Ventaja de la versión semiparamétrica:
 - cuando $g(\cdot)$ es desconocida tenemos más flexibilidad que en los casos paramétricos
 - al agregar todas las dimensiones de $X \in \mathbb{R}^q$ en un índice lineal $X\beta \in \mathbb{R}$ no tenemos los altos costos de eficiencia de los estimadores no paramétricos.

- Resultado:
 - la función desconocida $g(\cdot)$ puede estimarse a la misma velocidad de convergencia que obtendríamos si $X\beta$ fuera observable.
 - β también puede estimarse consistentemente a la tasa $\sqrt{N}$ pese a que $g(\cdot)$ no se conoce.
- Hay varias condiciones de identificación importantes a tener en cuenta. Ej. $g(\cdot)$ no puede ser constante.

Otro modelo semiparamétrico: esperanza condicional parcialmente lineal

- Considerar el siguiente modelo:

$$Y = X\beta + g(Z) + \varepsilon$$

- donde $X_{N \times p}$ y $\beta_{p \times 1}$ es un vector de coeficientes con significado económico y
- $Z_{N \times 1}$ y $g(\cdot)$ es una función desconocida
- Alternativas:
 - Omitir Z : $\hat{\beta}$ se obtiene por OLS regresando Y en X ; inconsistencia si X y Z están correlacionadas.
 - Especificar $g(\cdot)$ paramétricamente y estimar por OLS o NLLS; inconsistencia si el supuesto paramétrico es incorrecto.
- Método de Robinson (1988):** se puede estimar consistentemente β a la tasa de convergencia paramétrica $\sqrt{N}$ a pesar de la presencia del término no paramétrico $g(\cdot)$.

- Considerar nuevamente el modelo:

$$Y = X\beta + g(Z) + \varepsilon$$

con $E[\varepsilon|X, Z] = 0$, $V[\varepsilon|X, Z] = \sigma_\varepsilon^2$; Z y X no son totalmente dependientes; tampoco son independientes (por qué?).

- Computar la esperanza condicional en Z :

$$E[Y|Z] = E[X|Z]\beta + g(Z) + \underbrace{E[\varepsilon|Z]}_{=0}$$

- Restando del modelo original:

$$\underbrace{Y - E[Y|Z]}_{Y^*} = \underbrace{[X - E[X|Z]]}_{X^*}\beta + \varepsilon$$

- Este modelo no es estimable. ¿Por qué?

- El modelo transformado

$$\underbrace{Y - E[Y|Z]}_{Y^*} = \underbrace{[X - E[X|Z]]}_{X^*} \beta + \varepsilon$$

- Estimador en dos etapas de Robinson:

- 1 Estimar $E[Y|Z]$ y $E[X|Z]$ usando un estimador no paramétrico (por ejemplo, local polinómico)
- 2 Obtener $\hat{\beta}_{Rob}$ regresando por OLS $\hat{Y}^* = Y - \hat{E}[Y|Z]$ en $\hat{X}^* = X - \hat{E}[X|Z]$

- Propiedades:

- $\hat{\beta}_{Rob}$ es consistente y converge a la tasa paramétrica $\sqrt{N}$
- Asintóticamente normal: $\sqrt{N}(\hat{\beta}_{Rob} - \beta) \xrightarrow{d} N(0, V(\hat{\beta}_{Rob}))$

- Otras cuestiones a tener en cuenta:
 - el vector β no está identificado si contiene alguna constante
 - Z puede incluir más de una variable, pero todas deben ser continuas (condición de suavidad de las densidades f_z , ver pág. 939 de Robinson '88)
- Estimación no paramétrica de $g(\cdot)$ una vez estimado $\hat{\beta}_{Rob}$:
regresar no paramétricamente $Y - X\hat{\beta}_{Rob}$ en Z para obtener estimaciones puntuales de $g(\cdot)$

- Li, Q. and J. S. Racine (2007). Nonparametric Econometrics. Princeton University Press. Cap. 2 y 6. En Cap. 7 está el último tema.
- Pagan, A. and Ullah (1999). Nonparametric Econometrics. Cambridge University Press. Cap. 3. En capítulo 5.2 está el último tema.