

Practique Exam Questions

Ejercicio 1.

Considerar un modelo de regresión lineal bivariado con una intersección:

$$y_i = \beta_0 + \beta_1 x_i + u_i.$$

(a) Escribir el modelo en notación vectorial. Ser claro sobre la dimensión de los vectores, etc.

$$\underset{1 \times 1}{y_i} = \underset{1 \times 2}{x_i'} \underset{2 \times 1}{\beta} + \underset{1 \times 1}{u_i}, \quad \text{para } i = 1, 2, \dots, n,$$

donde y es la variable de respuesta para el sujeto i y x_i' es un vector de 2 variables independientes que incluye una intersección. En notación matricial, el modelo se puede escribir como:

$$\underset{n \times 1}{y} = \underset{n \times 2}{X} \underset{2 \times 1}{\beta} + \underset{n \times 1}{u},$$

donde y es un vector de $(n \times 1)$, X es una matriz de $(n \times 2)$, β es un vector de (2×1) y u es un vector de $(n \times 1)$. Es decir:

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; \quad X = \begin{bmatrix} 1 & x_{11} \\ 1 & x_{21} \\ \vdots & \vdots \\ 1 & x_{n1} \end{bmatrix}; \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}; \quad u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}.$$

(b) Mostrar que el modelo de media condicional lineal $x'\beta$ minimiza la pérdida de error cuadrática esperada y, por lo tanto, β puede interpretarse como el mejor predictor lineal. Obtener una fórmula para β basada en los momentos de x_i y y_i .

$$\begin{aligned} \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y - x'\beta)'(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y' - \beta'x)(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[y^2 - y'x'\beta - \beta'xy + (x'\beta)^2] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y - 2\beta'xy + \beta'xx'\beta) \quad (*) \text{ y } (**) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - E(2\beta'xy) + E(\beta'xx'\beta) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - 2\beta' E(xy) + \beta' E(xx') \beta. \end{aligned}$$

$$\begin{aligned} (*) \quad (x'\beta)^2 &= (x'\beta)'(x'\beta) \\ (x'\beta)^2 &= \beta'xx'\beta. \end{aligned}$$

(**) $\beta'xy$ es un escalar, por lo que es, trivialmente, igual a su transpuesto, $y'x'\beta$.

Tomando la condición de primer orden, se tiene:

$$-2 E(xy) + 2 E(xx') \beta = 0 \quad (***) \text{ y } (****)$$

$$2 E(xx') \beta = 2 E(xy)$$

$$\beta = \frac{2E(xy)}{2E(xx')}$$

$$\hat{\beta} = [E(xx')]^{-1} E(xy)$$

$$\hat{\beta} = \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \frac{1}{n} \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = \left(\sum_{i=1}^n x_i x_i'\right)^{-1} \sum_{i=1}^n x_i y_i$$

$$(***) \frac{\partial(b'a)}{\partial b} = a, \quad \text{donde } a \text{ y } b \text{ son dos vectores de dimensiones } (2 \times 1).$$

$$(***) \frac{\partial(b'Ab)}{\partial b} = 2Ab, \quad \text{donde } b \text{ es un vector de dimensión } (2 \times 1) \text{ y } A \text{ es una matriz simétrica de dimensión } (2 \times 2).$$

Por lo tanto, el parámetro $\hat{\beta}$ se puede interpretar como el mejor predictor lineal bajo la pérdida de error al cuadrado. Tener en cuenta que, para que exista, se necesita la dimensión (2×2) de la matriz $E(xx')$ para ser invertible. También se necesita que $E(y^2) < \infty$ y $E(\sum_j x_j^2) < \infty$.

(c) Usando el método de momentos, demostrar que, según algunas suposiciones, se puede obtener un estimador insesgado para β . Enunciar los supuestos.

Se tienen las siguientes suposiciones:

- $E(u) = E(y - \beta_0 - \beta_1 x) = 0$.
- $\text{Cov}(x, u) = E(xu) - E(x)E(u) = xE(u) - E(x) \cdot 0 = x \cdot 0 - 0 = 0 - 0 = 0$.

Estas dos ecuaciones son restricciones impuestas a los datos sobre la distribución de probabilidad conjunta de x e y . Hay dos incógnitas y dos ecuaciones, lo que sugiere que se puede resolver para β_0 y β_1 . La contraparte de la muestra de estas ecuaciones es:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0.$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \beta_0 - \beta_1 x_i)] = 0.$$

De la primera ecuación, se obtiene:

$$\begin{aligned} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) &= 0 * n \\ \sum_{i=1}^n y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 x_i &= 0 \\ n\bar{y} - n\beta_0 - n\beta_1 \bar{x} &= 0 \\ n(\bar{y} - \beta_0 - \beta_1 \bar{x}) &= 0 \\ \bar{y} - \beta_0 - \beta_1 \bar{x} &= 0 * n \\ \bar{y} - \beta_0 - \beta_1 \bar{x} &= 0 \end{aligned}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

De la segunda ecuación y considerando el resultado anterior, se obtiene:

$$\begin{aligned} \sum_{i=1}^n \{x_i [y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i]\} &= 0 * n \\ \sum_{i=1}^n [x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)] &= 0 \\ \sum_{i=1}^n \{x_i [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]\} &= 0 \\ \sum_{i=1}^n [x_i (y_i - \bar{y}) - \hat{\beta}_1 x_i (x_i - \bar{x})] &= 0 \\ \sum_{i=1}^n x_i (y_i - \bar{y}) - \sum_{i=1}^n \hat{\beta}_1 x_i (x_i - \bar{x}) &= 0 \\ \sum_{i=1}^n x_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= 0 \\ \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= \sum_{i=1}^n x_i (y_i - \bar{y}) \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned}$$

Por lo tanto, se tiene que, utilizando el método de momentos, $\hat{\beta}_0$ y $\hat{\beta}_1$ son los estimadores para los parámetros de la intersección y de la pendiente del modelo de regresión lineal simple.

Se puede demostrar que, bajo los siguientes supuestos:

- A1 (Linealidad): El modelo es lineal y
- A2 (Exogeneidad estricta): $E(u | x_1, x_2, \dots, x_p) = 0$,

los estimadores son insesgados, es decir, los valores esperados de los estimadores son iguales a los parámetros desconocidos.

Para demostrar que el estimador del parámetro de la pendiente es insesgado, se parte de:

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) y_i \quad (*) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n [\beta_0 (x_i - \bar{x}) + \beta_1 (x_i - \bar{x}) x_i + (x_i - \bar{x}) u_i] \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\sum_{i=1}^n \beta_0 (x_i - \bar{x}) + \sum_{i=1}^n \beta_1 (x_i - \bar{x}) x_i + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \quad (**) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\ \hat{\beta}_1 &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i. \end{aligned}$$

$$\begin{aligned} (*) \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n \bar{x} y_i + \sum_{i=1}^n \bar{x} \bar{y} \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - \bar{x} y_i) - \bar{y} \sum_{i=1}^n x_i + n \bar{x} \bar{y} \end{aligned}$$

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x}) y_i - n\bar{y}\bar{x} + n\bar{x}\bar{y}$$

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x}) y_i.$$

$$(**) \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2)$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2x_i\bar{x} + \sum_{i=1}^n \bar{x}^2$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - 2n\bar{x}\bar{x} + n\bar{x}^2$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i x_i - \sum_{i=1}^n x_i \bar{x}$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i x_i - x_i \bar{x})$$

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x}) x_i.$$

Tomando esperanza, se tiene:

$$E(\hat{\beta}_1) = E\left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right]$$

$$E(\hat{\beta}_1) = E(\beta_1) + E\left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right]$$

$$E(\hat{\beta}_1) = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n E[(x_i - \bar{x}) u_i]$$

$$E(\hat{\beta}_1) = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) E(u_i)$$

$$E(\hat{\beta}_1) = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) * 0$$

$$E(\hat{\beta}_1) = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n 0$$

$$E(\hat{\beta}_1) = \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} n * 0$$

$$E(\hat{\beta}_1) = \beta_1 + 0$$

$$E(\hat{\beta}_1) = \beta_1.$$

Y, para demostrar que el estimador del parámetro de la intersección es insesgado, se parte de:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_0 = \beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}.$$

Tomando esperanza, se tiene:

$$E(\hat{\beta}_0) = E(\beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x})$$

$$E(\hat{\beta}_0) = E(\beta_0) + E(\beta_1 \bar{x}) + E(\bar{u}) - E(\hat{\beta}_1 \bar{x})$$

$$E(\hat{\beta}_0) = \beta_0 + \bar{x} \beta_1 + E\left(\frac{1}{n} \sum_{i=1}^n u_i\right) - \bar{x} E(\hat{\beta}_1)$$

$$E(\hat{\beta}_0) = \beta_0 + \bar{x} \beta_1 + \frac{1}{n} \sum_{i=1}^n E(u_i) - \bar{x} \beta_1$$

$$E(\hat{\beta}_0) = \beta_0 + \frac{1}{n} \sum_{i=1}^n 0$$

$$E(\hat{\beta}_0) = \beta_0 + \frac{1}{n} n * 0$$

$$E(\hat{\beta}_0) = \beta_0 + 0$$

$$E(\hat{\beta}_0) = \beta_0.$$

Esto se puede observar también de la siguiente manera. Para obtener el estimador del método de momentos para el modelo lineal, recordar la condición de momento:

$$\begin{aligned} E(x_i u_i) &= E[E(x_i u_i | x)] \\ E(x_i u_i) &= E[x_i E(u_i | x)] \\ E(x_i u_i) &= E(x_i * 0) \\ E(x_i u_i) &= E(0) \\ E(x_i u_i) &= 0, \end{aligned}$$

o, alternativamente:

$$E[x_i (y_i - x_i' \beta)] = 0,$$

donde $x_i' = [1 \quad x_{i1}]$ y $\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$. El estimador MM podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] = 0.$$

Resolviendo, se tiene:

$$\begin{aligned} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 * n \\ \sum_{i=1}^n (x_i y_i - x_i x_i' \beta) &= 0 \\ \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \beta &= 0 \\ \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x_i' &= 0 \\ \beta \sum_{i=1}^n x_i x_i' &= \sum_{i=1}^n x_i y_i \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i. \end{aligned}$$

También se puede escribir como:

$$\begin{aligned} \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i (x_i' \beta + u_i) \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n (x_i x_i' \beta + x_i u_i) \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} (\sum_{i=1}^n x_i x_i' \beta + \sum_{i=1}^n x_i u_i) \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} (\sum_{i=1}^n x_i x_i' \beta + \sum_{i=1}^n x_i u_i) \\ \hat{\beta} &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i u_i. \end{aligned}$$

Tomando esperanza, se tiene:

$$\begin{aligned} E(\hat{\beta}) &= E[\beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i u_i] \\ E(\hat{\beta}) &= E(\beta) + E[(\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i u_i] \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i E(u_i) \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i * 0 \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n 0 \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} * n * 0 \\ E(\hat{\beta}) &= \beta + 0 \\ E(\hat{\beta}) &= \beta. \end{aligned}$$

Por lo tanto, usando el método de momentos y bajo las suposiciones A1 y A2, se puede obtener un estimador insesgado para β , ya que $E(\hat{\beta}) = \beta$.

(d) Suponer que la varianza del término de error es constante, digamos $V(u_i) = \sigma^2$. Derivar la varianza de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Se establecen los siguientes supuestos:

- A4 (Homocedasticidad): $\text{Var}(u_i | x) = \sigma^2$.
- A5 (Errores no correlacionados): $\text{Cov}(u_i, u_j) = 0$ para $i, j = 1, \dots, i-1, i+1, \dots, n$.

En otras palabras, la varianza del término de error es constante (no cambia con x) y el error u_i es independiente de u_j para $i \neq j$. Las suposiciones A4 y A5 juntas implican errores esféricos o, más precisamente, varianza de error esférico.

Considerando A4 y A5, las varianzas de los estimadores se obtienen de la siguiente manera:

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \text{Var}\left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ \text{Var}(\hat{\beta}_1) &= \text{Var}(\beta_1) + \text{Var}\left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ \text{Var}(\hat{\beta}_1) &= 0 + \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \text{Var}\left[\sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ \text{Var}(\hat{\beta}_1) &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \left[\sum_{i=1}^n \text{Var}[(x_i - \bar{x}) u_i]\right] \\ \text{Var}(\hat{\beta}_1) &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(u_i) \\ \text{Var}(\hat{\beta}_1) &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 \\ \text{Var}(\hat{\beta}_1) &= \sigma^2 \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \\ \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned} \quad \text{Varianza de } \hat{\beta}_1.$$

$$\begin{aligned} \text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{y} - \hat{\beta}_1 \bar{x}) \\ \text{Var}(\hat{\beta}_0) &= \text{Var}\left(\bar{y} - \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \bar{x}\right) \\ \text{Var}(\hat{\beta}_0) &= \text{Var}\left\{\sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right] y_i\right\} \\ \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \text{Var}\left\{\left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right] y_i\right\} \\ \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 \text{Var}(y_i) \\ \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 \sigma^2 \quad \text{(***) y (***)} \\ \text{Var}(\hat{\beta}_0) &= \sigma^2 \sum_{i=1}^n \left\{\frac{1}{n^2} + \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 - \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right\} \\ \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{\sum_{i=1}^n \frac{1}{n^2} + \sum_{i=1}^n \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 - \sum_{i=1}^n \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right\} \end{aligned}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left\{ \frac{n}{n^2} + \sum_{i=1}^n \frac{\bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left\{ \frac{1}{n} + \frac{\sum_{i=1}^n \bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} * 0 \right\} \quad (*****)$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left\{ \frac{1}{n} + \frac{\bar{x}^2 \sum_{i=1}^n (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - 0 \right\}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n (x_i^2 + \bar{x}^2 - 2x_i\bar{x}) + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^n \bar{x}^2 - \sum_{i=1}^n 2x_i\bar{x} + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n\bar{x}^2 - 2n\bar{x}\bar{x} + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n\bar{x}^2 - 2n\bar{x}^2 + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]. \quad \text{Varianza de } \hat{\beta}_0.$$

$$\begin{aligned} (***) \text{Var}(y_i) &= \text{Var}(\beta_0 + \beta_1 x_i + u_i) \\ \text{Var}(y_i) &= \text{Var}(\beta_0) + \text{Var}(\beta_1 x_i) + \text{Var}(u_i) \\ \text{Var}(y_i) &= 0 + 0 + \text{Var}(u_i) \\ \text{Var}(y_i) &= \text{Var}(u_i) \\ \text{Var}(y_i) &= \sigma^2. \end{aligned}$$

$$\begin{aligned} (****) \text{Cov}(y_i, y_j) &= E\{[y_i - E(y_i)][y_j - E(y_j)]\} \\ \text{Cov}(y_i, y_j) &= E(u_i u_j) \\ \text{Cov}(y_i, y_j) &= \text{Cov}(u_i, u_j) + E(u_i) E(u_j) \\ \text{Cov}(y_i, y_j) &= 0 + 0 * 0 \\ \text{Cov}(y_i, y_j) &= 0. \end{aligned}$$

$$\begin{aligned} (*****) \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{n\bar{x} - n\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{0}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= 0. \end{aligned}$$

Ejercicio 2.

Considerar, nuevamente, el modelo de regresión lineal bivariado:

$$y_i = \beta_0 + \beta_1 x_i + u_i.$$

(a) Suponiendo que x_i es una variable independiente continua, definir β_1 como una función del modelo de media condicional y proporcionar una interpretación.

$$E(y | x) = E(\beta_0 + \beta_1 x + u | x)$$

$$E(y | x) = E(\beta_0 | x) + E(\beta_1 x | x) + E(u | x)$$

$$E(y | x) = \beta_0 + \beta_1 x + 0$$

$$E(y | x) = \beta_0 + \beta_1 x.$$

$$\frac{\partial E(y | x)}{\partial x} = \beta_1.$$

Por lo tanto, β_1 es el efecto parcial de x en el valor esperado condicional de la variable dependiente y . Es la pendiente del modelo.

(b) ¿Cuál es la definición de β_0 ?

β_0 es el valor esperado condicional de la variable dependiente y cuando x es igual a 0. Es el intercepto del modelo.

(c) Suponiendo que $x_i = \{0, 1\}$ es una variable binaria discreta, definir β_1 como una función del modelo de media condicional y proporciona una interpretación.

$$E(y | x=1) = \beta_0 + \beta_1 * 1$$

$$E(y | x=1) = \beta_0 + \beta_1.$$

$$E(y | x=0) = \beta_0 + \beta_1 * 0$$

$$E(y | x=0) = \beta_0 + 0$$

$$E(y | x=0) = \beta_0.$$

$$E(y | x=1) - E(y | x=0) = \beta_0 + \beta_1 - \beta_0$$

$$E(y | x=1) - E(y | x=0) = \beta_1.$$

Por lo tanto, β_1 es la diferencia entre el valor esperado condicional de la variable dependiente y cuando $x=1$ y el valor esperado condicional de la variable dependiente y cuando $x=0$, es decir, mide el efecto diferencial sobre y de que $x=1$ comparado con que $x=0$.

Ejercicio 3.

Se supone que la demanda de café de Colombia en los Estados Unidos está determinada por la siguiente función:

$$q = \beta_0 + \beta_1 p_c + \beta_2 p_b + \beta_3 p_d + u,$$

donde q denota importaciones de café colombiano en los Estados Unidos, p_c denota el precio del café colombiano, p_b representa el precio del café brasileño y p_d es el precio del café italiano. Todas las variables están en logaritmo natural.

(a) Se supone que se estima la ecuación usando MCO considerando $n = 200$ observaciones:

$$\hat{E}(q | p_c, p_b, p_d) = 2,837 - 1,481p_c + 1,181p_b + 0,186p_d$$

$$(2,000) \quad (0,987) \quad (0,650) \quad (0,134)$$

con la suma de los residuos cuadrados $SSR = 0,4277$. También:

$$\hat{E}(q | p_c, p_b, p_d) = -0,738 - p_c + 0,199p_d.$$

$$(0,820) \quad (1,011) \quad (0,155)$$

con $SSR = 0,4485$. Probar las siguientes hipótesis utilizando un nivel de significación del 5%.

$$(i) H_0: \beta_1 = -1; \quad H_a: \beta_1 \neq -1.$$

Económicamente, la hipótesis nula significa que hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c), por lo cual, ante una variación del precio del café colombiano en un 1%, la importación de café colombiano en EE.UU. varía, en promedio, en un -1%, manteniendo todo lo demás constante.

Estadístico de prueba:

$$T = \frac{\hat{\beta}_1 - \beta_1}{se(\hat{\beta}_1)} = \frac{\hat{\beta}_1 - (-1)}{se(\hat{\beta}_1)} = \frac{\hat{\beta}_1 + 1}{se(\hat{\beta}_1)} \sim t_{196}.$$

Regla de decisión:

Si $t_{obs} < -1,96$ o $t_{obs} > 1,96$, se rechaza H_0 .

Si $-1,96 < t_{obs} < 1,96$, no se rechaza H_0 .

Valores observados:

$$t_{obs} = \frac{-1,481 + 1}{0,987}$$

$$t_{obs} = \frac{-0,481}{0,987}$$

$$t_{obs} = 0,487.$$

Conclusión:

Por lo tanto, con un nivel de significatividad del 5%, estos datos no proporcionan evidencia suficiente para indicar que no hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c), ya que t_{obs} se encuentra en el intervalo $[-1,96; 1,96]$.

$$(ii) H_0: \beta_2 = 0; \quad H_a: \beta_2 \neq 0.$$

Económicamente, la hipótesis nula significa que hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b), por lo cual p_b no es un determinante de q .

Estadístico de prueba:

$$T = \frac{\hat{\beta}_2 - \beta_2}{se(\hat{\beta}_2)} = \frac{\hat{\beta}_2 - 0 - \hat{\beta}_2}{se(\hat{\beta}_2)} \sim t_{196}.$$

Regla de decisión:

Si $t_{obs} < -1,96$ o $t_{obs} > 1,96$, se rechaza H_0 .

Si $-1,96 < t_{obs} < 1,96$, no se rechaza H_0 .

Valores observados:

$$t_{obs} = \frac{1,181}{0,65}$$

$$t_{obs} = 1,817.$$

Conclusión:

Por lo tanto, con un nivel de significatividad del 5%, estos datos no proporcionan evidencia suficiente para indicar que no hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b), ya que $t_{obs} > 1,96$.

$$(iii) H_0: \beta_1 = -1 \wedge \beta_2 = 0; \quad H_a: \beta_1 \neq -1 \wedge \beta_2 \neq 0.$$

Económicamente, la hipótesis nula significa que hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c) y, conjuntamente, hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b).

Estadístico de prueba:

$$F = \frac{\frac{SSR_T - SSR_U}{q}}{\frac{SSR_U}{n-p-1}} \sim f_{2,196}.$$

Regla de decisión:

Si $f_{obs} < -2,99$ o $f_{obs} > 2,99$, se rechaza H_0 .

Si $-2,99 < f_{obs} < 2,99$, no se rechaza H_0 .

Valores observados:

$$f_{obs} = \frac{\frac{0,4485 - 0,4277}{2}}{\frac{0,4277}{196}}$$

$$f_{obs} = \frac{0,0208}{0,4277}$$

$$f_{obs} = 4,766.$$

Conclusión:

Por lo tanto, con un nivel de significatividad del 5%, estos datos proporcionan evidencia suficiente para indicar que no hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c) y, conjuntamente, que no hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b), ya que $f_{obs} > 2,99$.

(b) Un árbitro argumenta que el error u podría ser heterocedástico. Explicar cómo se respondería a su pregunta. Ser explícito sobre la prueba, la hipótesis nula y la hipótesis alternativa. Si el R -cuadrado de una regresión de $\hat{u}^2$ en covariables es 0,1, ¿te preocuparías por errores heterocedásticos?

Para responder a la pregunta sobre si el error u podría ser heterocedástico, analizaría los siguientes test de heterocedasticidad:

- Test de Breusch-Pagan (1980).

Se comienza asumiendo un modelo de regresión multivariable:

$$y_i = x_i' \beta + u_i.$$

Se supone que la hipótesis nula es:

$$H_0: V(u | x) = \sigma^2,$$

es decir, la hipótesis nula es no heteroscedasticidad. Como $E(u | x) = 0$, se escribe H_0 como:

$$H_0: E(u^2 | x) = E(u^2) = \sigma^2.$$

Tener en cuenta que se debe evaluar la esperanza condicional (en las variables independientes) del cuadrado del término de error:

$$u^2 = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_p x_p + \varepsilon.$$

El caso homocedástico implica que $\alpha_1 = \alpha_2 = \dots = \alpha_p = 0$, por lo que:

$$E(u^2 | x_1, \dots, x_p) = \alpha_0.$$

Sin embargo, tener en cuenta que esto es inviable porque no se conoce el término de error u^2 . Un enfoque simple es reemplazarlo por $\hat{u}^2$ y estimar:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \dots + \alpha_p x_{pi} + \varepsilon,$$

y probar si los coeficientes de pendiente son todos iguales a cero:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_p = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

utilizando una prueba de F. Si $F > c$, donde c está determinada por un valor de significancia estadística, se rechaza la hipótesis nula de no heterocedasticidad.

La versión del multiplicador de Lagrange (LM) es muy fácil de calcular, ya que:

$$LM = nR_{\hat{u}^2}^2,$$

que se distribuye como χ_p^2 bajo la hipótesis nula de homocedasticidad.

- Test de White (1980).

Para simplificar la presentación, suponer que $p = 2$:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i.$$

La prueba de White se basa en la estimación de:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_3 x_{1i}^2 + \alpha_4 x_{2i}^2 + \alpha_5 x_{1i} x_{2i} + \varepsilon.$$

La hipótesis nula, en este caso, es:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_5 = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

el cual puede ser evaluado con un estadístico de prueba LM o F.

Si el R^2 de una regresión de $\hat{u}^2$ en covariables es 0,1, no me preocuparía por errores heterocedásticos, ya que los errores estimados cuadráticos no se encuentran bien explicados por las variables explicativas del modelo, por lo que este modelo no produce un buen ajuste a los datos y esto sería un indicio de homocedasticidad.

(c) Se supone que se rechaza la hipótesis nula en (b) y se observa que p_c es 10 veces más grande que p_b en un mes (pero no en los otros meses). Explicar cómo se estimaría el modelo. Explicar también cuáles son las advertencias prácticas asociadas con la implementación de su(s) método(s).

La matriz de covarianza del término de error, bajo heterocedasticidad, es igual a:

$$\Sigma = E(uu') = E(uu' | x) = E[\text{diag}(u_1^2, u_2^2, \dots, u_n^2) | x],$$

o, alternativamente:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix}.$$

Por lo tanto, bajo heteroscedasticidad, la varianza del estimador es:

$$\begin{aligned} V(\hat{\beta} | X) &= V[(X'X)^{-1}X'y | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'(X\beta + u) | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[I\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + V[(X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + (X'X)^{-1}X' V(u | X) X(X'X)^{-1} \\ V(\hat{\beta} | X) &= 0 + (X'X)^{-1}X'\Sigma X(X'X)^{-1} \\ V(\hat{\beta} | X) &= (X'X)^{-1}X'\Sigma X(X'X)^{-1}. \end{aligned}$$

Si se conoce el término de error, se nota que $(uu')_{ii} = u_{ii}^2$ y el valor esperado condicional de la varianza es:

$$\begin{aligned} E[V(\hat{\beta} | X)] &= E[(X'X)^{-1}X'\Sigma X(X'X)^{-1}] \\ E[V(\hat{\beta} | X)] &= (X'X)^{-1}X' E(\Sigma) X(X'X)^{-1} \\ E[V(\hat{\beta} | X)] &= (X'X)^{-1}X'\Sigma X(X'X)^{-1}. \end{aligned}$$

En la práctica, se obtienen los residuos mínimos cuadrados, $\hat{u}_i^2 = (y_i - x_i'\hat{\beta})^2$, donde $\hat{\beta}$ es el estimador mínimo cuadrático de β . Entonces, se puede formar una matriz:

$$\hat{\Sigma} = \begin{bmatrix} \hat{u}_1^2 & 0 & \dots & 0 \\ 0 & \hat{u}_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{u}_n^2 \end{bmatrix}$$

y construir un estimador factible:

$$\hat{V}(\hat{\beta} | X) = (X'X)^{-1}X'\hat{\Sigma}X(X'X)^{-1}.$$

Este estimador se denomina estimador de “heterocedasticidad-robusto” de la matriz de covarianza.

Notar que el estimador representa un estimador consistente de la covarianza desconocida. En muestras pequeñas, desafortunadamente, el estimador podría estar sesgado. Para ver esto, recordar que $\hat{u}'\hat{u} = u'Mu = y'My$. Entonces:

$$\begin{aligned} \hat{u}_i^2 &= (y_i - x_i'\hat{\beta})^2 \\ \hat{u}_i^2 &= (y_i - x_i'\beta + x_i'\beta - x_i'\hat{\beta})^2 \end{aligned}$$

$$\begin{aligned}\hat{u}_i^2 &= [(y_i - x_i'\beta) - x_i'(\hat{\beta} - \beta)]^2 \\ \hat{u}_i^2 &= [u_i + x_i'(X'X)^{-1}X'u]^2 \\ \hat{u}_i^2 &= u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i.\end{aligned}$$

Bajo homocedasticidad y denotando el llamado punto de apalancamiento $h_{ii} = x_i'(X'X)^{-1}x_i$, se tiene que:

$$\begin{aligned}E(\hat{u}_i^2) &= E[u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i] \\ E(\hat{u}_i^2) &= E(u_i^2) - E[2u_i x_i'(X'X)^{-1}X'u] + E[x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i] \\ E(\hat{u}_i^2) &= \sigma^2 - 2E[u_i x_i'(X'X)^{-1}X'u] + x_i'(X'X)^{-1}X'E(uu')X(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2E(u_i h_{ii} u_i) + x_i'(X'X)^{-1}X'\sigma^2 X(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2h_{ii}E(u_i u_i) + \sigma^2 x_i'(X'X)^{-1}X'X(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2h_{ii}E(u_i^2) + \sigma^2 x_i'I(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2h_{ii}\sigma^2 + \sigma^2 x_i'(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2\sigma^2 h_{ii} + \sigma^2 h_{ii} \\ E(\hat{u}_i^2) &= \sigma^2 - \sigma^2 h_{ii} \\ E(\hat{u}_i^2) &= \sigma^2 (1 - h_{ii}) < \sigma^2 = E(u_i^2).\end{aligned}$$

Luego, insistiendo con el ejemplo simple cuando $p=1$, se tiene que:

$$\begin{aligned}E[V(\hat{\beta} | X)] &= E\left\{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2}\right\} \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} E[\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2] \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n E[(x_i - \bar{x})^2 \hat{u}_i^2] \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 E(\hat{u}_i^2) \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 (1 - h_{ii}) \\ E[V(\hat{\beta} | X)] &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} - \frac{\sum_{i=1}^n (x_i - \bar{x})^2 h_{ii} \sigma^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2},\end{aligned}$$

lo que indica que $V(\hat{\beta} | X)$ está sesgada hacia abajo (tener en cuenta que el primer término es la varianza del estimador de mínimos cuadrados en la homocedasticidad). Una corrección estándar es dividir $\hat{u}_i^2$ por $(1 - h_{ii})$.

Ejercicio 4.

Considerar el siguiente modelo lineal:

$$E(y | x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2,$$

donde x_1 y x_2 tienen medias iguales a cero.

(a) *Escribir una ecuación para la variable dependiente y e indicar las suposiciones para el término de error u como lo indica el modelo de media condicional anterior.*

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + u.$$

El supuesto de u que está implícito en el modelo de media condicional es $E(u | x_1, x_2) = E(u) = 0$.

(b) *Encontrar el efecto parcial de $E(y | x_1, x_2)$ con respecto a x_1 . ¿Cuál es la interpretación de β_1 ?*

$$\frac{\partial E(y | x_1, x_2)}{\partial x_1} = \beta_1 + \beta_3 x_2.$$

Si $E(x_2) = E(x_2 | x_1) = 0$, entonces, el efecto parcial promedio es:

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1 + \beta_3 x_2)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1) + E(\beta_3 x_2)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \beta_3 E(x_2)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \beta_3 * 0$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + 0$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1.$$

Por lo tanto, el efecto parcial de x_1 sobre $E(y | x_1, x_2)$ es $(\beta_1 + \beta_3 x_2)$ y β_1 es el efecto parcial promedio de x_1 sobre $E(y | x_1, x_2)$.

(c) *Construir una elasticidad con respecto a un cambio en x_j .*

Considerar que se tiene el siguiente modelo de regresión de la población:

$$E(y | x) = \beta_0 + \sum_{j=1}^p \beta_j x_j,$$

y que se está interesado en el efecto marginal de la j -ésima variable independiente sobre el valor esperado condicional de y :

$$\frac{\partial E(y | x)}{\partial x_j} = \beta_j.$$

Esto nos dice el aumento en el valor medio de y cuando la variable independiente se incrementa en 1 unidad, manteniendo todo lo demás constante. Esta interpretación es equivalente a la noción de *ceteris paribus*: el efecto de x sobre y , manteniendo todo lo demás constante. Notar que, si x_i y x_j están relacionados, encontrar el efecto marginal es algo más complicado, pero la linealidad del modelo de regresión tiene una implicación simple y, a veces, útil para el análisis empírico.

Por lo tanto, se tiene que la elasticidad de la media condicional de y es:

$$\frac{\partial E(y | x_j)}{\partial x_j} \frac{x_j}{E(y | x_j)} = \beta_j \frac{x_j}{\beta_0 + \sum_{j=1}^p \beta_j x_j}.$$

(d) Explicar cómo se estimaría la elasticidad que se construyó antes e indicar las suposiciones necesarias para obtener un resultado insesgado y consistente.

Cuando u y x no están correlacionados, $E(u | x) = 0$, como es el caso en los modelos anteriores, se puede tener una definición alternativa de elasticidad:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)}.$$

Tener en cuenta que $E(y | x) = e^{x'\beta}$ implica:

$$\log[E(y | x)] = x'\beta.$$

Si $y = e^{x'\beta + u}$, entonces, $\log(y) = x'\beta + u$ y, por suposiciones previas, $E[\log(y)] = x'\beta$, ya que $E(u | x) = 0$.

Por lo tanto, el parámetro β_j se debe interpretar como una elasticidad si el modelo está en una forma “log-log”:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)} = \beta_j.$$

El supuesto necesario para obtener un resultado insesgado y consistente es $E(u | x) = 0$.

Ejercicio 5.

Considerar un modelo de ubicación:

$$\begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}.$$

donde u_1 y u_2 están i.i.d. con distribución $\mathcal{N}(0, \sigma^2)$. Demostrar que agrupar los datos y estimar $\hat{\beta} = \hat{\beta}_1 = \hat{\beta}_2$ reduce la variabilidad de $\hat{\beta}_j$.

$$\underset{2 \times 1}{y} = \underset{2 \times 1}{\beta} + \underset{2 \times 1}{u}.$$

$$\hat{\beta} = (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n 1 \cdot y_i}{\sum_{i=1}^n 1^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n y_i}{\sum_{i=1}^n 1}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n y_i}{n \cdot 1}$$

$$\hat{\beta} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$\hat{\beta} = \bar{y}.$$

$$E(\hat{\beta}) = E(\bar{y})$$

$$E(\hat{\beta}) = E\left(\frac{1}{n} \sum_{i=1}^n y_i\right)$$

$$E(\hat{\beta}) = \frac{1}{n} E\left(\sum_{i=1}^n y_i\right)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n E(y_i)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n E(\beta + u)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n [E(\beta) + E(u)]$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n (\beta + 0)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \beta$$

$$E(\hat{\beta}) = \frac{1}{n} n\beta$$

$$E(\hat{\beta}) = \beta.$$

$$V(\hat{\beta}) = V(\bar{y})$$

$$V(\hat{\beta}) = V\left(\frac{1}{n} \sum_{i=1}^n y_i\right)$$

$$V(\hat{\beta}) = \frac{1}{n^2} V\left(\sum_{i=1}^n y_i\right)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n V(y_i)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n V(\beta + u)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n [V(\beta) + V(u)]$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n (0 + \sigma^2)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2$$

$$V(\hat{\beta}) = \frac{1}{n^2} n\sigma^2$$

$$V(\hat{\beta}) = \frac{\sigma^2}{n}.$$

Por lo tanto, agrupar los datos y estimar $\hat{\beta} = \hat{\beta}_1 = \hat{\beta}_2$ reduce la variabilidad de $\hat{\beta}_j$, ya que, en este caso, n aumenta y se reduce $V(\hat{\beta}_j)$.

Ejercicio 6.

Demostrar que $M = I - X(X'X)^{-1}X'$ es una matriz de proyección ortogonal. Demostrar que el vector residual $\hat{u} = Mu$ es ortogonal al vector $\hat{y}$.

$$\hat{u} = y - \hat{y}$$

$$\hat{u} = y - Py$$

$$\hat{u} = (I - P)y$$

$$\hat{u} = My$$

$$\hat{u} = M(X\beta + u)$$

$$\hat{u} = MX\beta + Mu$$

$$\hat{u} = 0 * \beta + Mu \quad (*)$$

$$\hat{u} = 0 + Mu$$

$$\hat{u} = Mu.$$

$$(*) \quad MX = (I - P)X$$

$$MX = IX - PX$$

$$MX = X - X(X'X)^{-1}X'X$$

$$MX = X - XI$$

$$MX = X - X$$

$$MX = 0.$$

Por lo tanto, $M = I - P$ es una matriz que produce “residuos”, donde $P = X(X'X)^{-1}X'$ (matriz que proyecta los valores ajustados de y ($\hat{y}$) en el espacio vectorial de X), es decir, M es una matriz que proyecta los errores estimados ($\hat{u}$) en el espacio de los errores (u).

$$\hat{y}'\hat{u} = (Py)'My$$

$$\hat{y}'\hat{u} = y'P'My$$

$$\hat{y}'\hat{u} = y'PM y$$

$$\hat{y}'\hat{u} = y' * 0 * y \quad (**)$$

$$\hat{y}'\hat{u} = 0.$$

$$(**) \quad PM = P(I - P)$$

$$PM = P - PP$$

$$PM = P - P$$

$$PM = 0.$$

Por lo tanto, el vector residual $\hat{u}$ es ortogonal al vector $\hat{y}$.

Ejercicio 7.

Considerar:

$$y = X_1\beta_1 + X_2\beta_2 + u,$$

donde $E(uu') = \sigma^2 I$. Suponer que se tiene:

$$\tilde{\beta}_1^s = (X_1'X_1)^{-1}X_1'y.$$

$$\hat{\beta}_1^l = (X_1'M_2X_1)^{-1}X_1'M_2y.$$

(a) Explicar la diferencia entre los estimadores.

La diferencia entre los estimadores $\tilde{\beta}_1^s$ y $\hat{\beta}_1^l$ radica, principalmente, en que el primero es el estimador MCO de β_1 de un modelo “corto” de la forma $y = X_1\beta_1 + u$, en tanto que el segundo es el estimador MCO de β_1 de un modelo “largo” de la forma $y = X_1\beta_1 + X_2\beta_2 + u$.

Por lo tanto, se tiene:

$$\tilde{\beta}_1^s = \arg \min \|y - X_1\beta_1\|^2.$$

$$\hat{\beta}_1^l = \arg \min \|y - X_1\beta_1 - X_2\beta_2\|^2.$$

(b) Definir M_2 y comprobar si es idempotente. ¿Son $\tilde{\beta}_1^s$ y $\hat{\beta}_1^l$ sesgados? Explicar.

$M_2 = I - P_2$ es una matriz que produce “residuos”, donde $P_2 = X_2(X_2'X_2)^{-1}X_2'$ [matriz que proyecta los valores ajustados de X_1 ($\hat{X}_1$) en el espacio vectorial de X_2], es decir, M_2 es una matriz que proyecta los errores estimados ($\hat{v}$) en el espacio vectorial de los errores (v) del siguiente modelo:

$$X_1 = X_2\gamma + v.$$

Es decir:

$$\hat{v} = M_2v.$$

$$M_2M_2 = (I - P_2)(I - P_2)$$

$$M_2M_2 = I - P_2 - P_2 + P_2P_2$$

$$M_2M_2 = I - P_2 - P_2 + P_2 \quad (*)$$

$$M_2M_2 = I - P_2$$

$$M_2M_2 = M_2.$$

$$(*) P_2P_2 = X_2(X_2'X_2)^{-1}X_2'X_2(X_2'X_2)^{-1}X_2'$$

$$P_2P_2 = X_2I(X_2'X_2)^{-1}X_2'$$

$$P_2P_2 = X_2(X_2'X_2)^{-1}X_2'$$

$$P_2 P_2 = P_2.$$

Por lo tanto, M_2 es idempotente, ya que $M_2 M_2 = M_2$.

$$\begin{aligned}\tilde{\beta}_1^s &= (X_1' X_1)^{-1} X_1' (X_1 \beta_1 + X_2 \beta_2 + u) \\ \tilde{\beta}_1^s &= (X_1' X_1)^{-1} X_1' X_1 \beta_1 + (X_1' X_1)^{-1} X_1' X_2 \beta_2 + (X_1' X_1)^{-1} X_1' u \\ \tilde{\beta}_1^s &= I \beta_1 + (X_1' X_1)^{-1} X_1' X_2 \beta_2 + (X_1' X_1)^{-1} X_1' u \\ \tilde{\beta}_1^s &= \beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' u.\end{aligned}$$

$$\begin{aligned}E(\tilde{\beta}_1^s) &= E[\beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' u] \\ E(\tilde{\beta}_1^s) &= E(\beta_1) + E(\Gamma \beta_2) + E[(X_1' X_1)^{-1} X_1' u] \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' E(u) \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' * 0 \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2 + 0 \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2.\end{aligned}$$

Donde $\Gamma = (X_1' X_1)^{-1} X_1' X_2$ es el estimador de una regresión de X_2 en X_1 . Se puede observar que $\tilde{\beta}_1^s$ podría estar sesgado si $\beta_2 \neq 0$ o si las variables independientes observables X_1 y X_2 no son independientes.

$$\begin{aligned}\tilde{\beta}_1^l &= (X_1' M_2 X_1)^{-1} X_1' M_2 (X_1 \beta_1 + X_2 \beta_2 + u) \\ \tilde{\beta}_1^l &= (X_1' M_2 X_1)^{-1} X_1' M_2 X_1 \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 X_2 \beta_2 + (X_1' M_2 X_1)^{-1} X_1' M_2 u \\ \tilde{\beta}_1^l &= I \beta_1 + (X_1' M_2 X_1)^{-1} X_1' * 0 * \beta_2 + (X_1' M_2 X_1)^{-1} X_1' M_2 u \\ \tilde{\beta}_1^l &= \beta_1 + 0 + (X_1' M_2 X_1)^{-1} X_1' M_2 u \\ \tilde{\beta}_1^l &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 u.\end{aligned}$$

$$\begin{aligned}E(\tilde{\beta}_1^l) &= E[\beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 u] \\ E(\tilde{\beta}_1^l) &= E(\beta_1) + E[(X_1' M_2 X_1)^{-1} X_1' M_2 u] \\ E(\tilde{\beta}_1^l) &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 E(u) \\ E(\tilde{\beta}_1^l) &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 * 0 \\ E(\tilde{\beta}_1^l) &= \beta_1 + 0 \\ E(\tilde{\beta}_1^l) &= \beta_1.\end{aligned}$$

Por lo tanto, $\tilde{\beta}_1^s$ es sesgado y $\tilde{\beta}_1^l$ es insesgado, ya que $E(\tilde{\beta}_1^s) \neq \beta_1$ y $E(\tilde{\beta}_1^l) = \beta_1$.

(c) Encontrar la expresión para $\hat{\beta}_1^l = \tilde{\beta}_1^s - B \hat{\beta}_2^l$.

$$\begin{aligned}\hat{\beta}_1^l &= \tilde{\beta}_1^s - B \hat{\beta}_2^l \\ \hat{\beta}_1^l &= [(X_1' X_1)^{-1} X_1' - B(X_2' M_1 X_2)^{-1} X_2' M_1] y.\end{aligned}$$

Donde $B = (X_1' X_1)^{-1} X_1' X_2$ es el estimador de una regresión de X_2 en X_1 y $M_1 = I - P_1$ es una matriz que produce “residuos”, donde $P_1 = X_1 (X_1' X_1)^{-1} X_1'$ [matriz que proyecta los valores ajustados de X_2 ($\hat{X}_2$) en el espacio vectorial de X_1], es decir, M_1 es una matriz que proyecta los errores estimados ($\hat{\kappa}$) en el espacio vectorial de los errores (κ) del siguiente modelo:

$$X_2 = X_1\delta + \kappa.$$

Es decir:

$$\hat{\kappa} = M_1\kappa.$$

(d) Demostrar que una aplicación del teorema de FWL da un estimador que es, numéricamente, equivalente a $\hat{\beta}_1^l$ y el error estándar de $\hat{\beta}_1^l$.

$$\begin{aligned}\tilde{\beta}_1^s &= (\tilde{X}_1'\tilde{X}_1)^{-1}\tilde{X}_1'\tilde{y} \\ \tilde{\beta}_1^s &= (X_1'M_2'M_2X_1)^{-1}X_1'M_2'M_2y \\ \tilde{\beta}_1^s &= (X_1'M_2X_1)^{-1}X_1'M_2y \\ \tilde{\beta}_1^s &= \hat{\beta}_1^l.\end{aligned}$$

$$\begin{aligned}\hat{\beta}_1^l &= (X_1'M_2X_1)^{-1}X_1'M_2y \\ \hat{\beta}_1^l &= (X_1'M_2'M_2X_1)^{-1}X_1'M_2'M_2y \\ \hat{\beta}_1^l &= (\tilde{X}_1'\tilde{X}_1)^{-1}\tilde{X}_1'\tilde{y} \\ \hat{\beta}_1^l &= \tilde{\beta}_1^s.\end{aligned}$$

Por lo tanto, el estimador que surge de aplicar el teorema de FWL es, numéricamente, equivalente a $\hat{\beta}_1^l$.

Además, los residuos de ambos modelos son idénticos. Considerar:

$$\begin{aligned}y &= \hat{y} + \hat{u} \\ y &= X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{u}\end{aligned}$$

y multiplicar por M_2 :

$$\begin{aligned}M_2y &= M_2X_1\hat{\beta}_1 + M_2X_2\hat{\beta}_2 + M_2\hat{u} \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + 0 * \hat{\beta}_2 + (I - P_2) \hat{u} & (*) \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + 0 + I\hat{u} - P_2\hat{u} \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + \hat{u} - 0 & (**) \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + \hat{u},\end{aligned}$$

donde $M_2\hat{u} = \hat{u}$ porque $P_2\hat{u} = 0$.

$$\begin{aligned}(*) \quad M_2X_2 &= (I - P_2) X_2 \\ M_2X_2 &= IX_2 - P_2X_2 \\ M_2X_2 &= X_2 - X_2(X_2'X_2)^{-1}X_2'X_2 \\ M_2X_2 &= X_2 - X_2I \\ M_2X_2 &= X_2 - X_2 \\ M_2X_2 &= 0.\end{aligned}$$

$$(**) \quad P_2\hat{u} = P_2My$$

$$\begin{aligned} P_2 \hat{u} &= P_2 M_2 My \\ P_2 \hat{u} &= 0 * My \\ P_2 \hat{u} &= 0. \end{aligned} \quad (***)$$

$$\begin{aligned} (***) \quad P_2 M_2 &= P_2 (I - P_2) \\ P_2 M_2 &= P_2 I - P_2 P_2 \\ P_2 M_2 &= P_2 - P_2 \\ P_2 M_2 &= 0. \end{aligned}$$

Por lo tanto, ya que los residuos de ambos modelos son idénticos, los errores estándar de $\hat{\beta}_1^l$ y $\tilde{\beta}_1^s$ también son idénticos.

(e) Si el error u no es homocedástico, ¿la covarianza entre $\tilde{\beta}_1^s$ y $B\hat{\beta}_1^l$ sería cero? ¿Por qué es importante este resultado?

Considerando:

$$\hat{\beta}_1^l = \tilde{\beta}_1^s - B\hat{\beta}_2^l,$$

se tiene:

$$\begin{aligned} V(\hat{\beta}_1^l) &= V(\tilde{\beta}_1^s - B\hat{\beta}_2^l) \\ V(\hat{\beta}_1^l) &= V(\tilde{\beta}_1^s) + V(B\hat{\beta}_2^l) \\ V(\hat{\beta}_1^l) &= V(\tilde{\beta}_1^s) + B V(\hat{\beta}_2^l) B', \end{aligned}$$

lo que implica que:

$$V(\hat{\beta}_1^l) \geq V(\tilde{\beta}_1^s),$$

ya que el término cuadrático es semidefinido positivo. Este resultado se cumple si el término de $\text{Cov}(\tilde{\beta}_1^s, B\hat{\beta}_2^l)$ es cero, lo cual se satisface si el error u es homocedástico.

Teorema. $\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = 0$.

Prueba. Primero, recordar esto:

$$\begin{aligned} \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x y \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x (X\beta + Z\gamma + u) \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x X\beta + (Z' M_x Z)^{-1} Z' M_x Z\gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' * 0 * \beta + I\gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= 0 + \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= \gamma + (Z' M_x Z)^{-1} Z' M_x u. \end{aligned}$$

Además, recordar que:

$$\begin{aligned} \hat{\beta} &= (X' M_z X)^{-1} X' M_z y \\ \hat{\beta} &= (X' M_z X)^{-1} X' M_z (X\beta + Z\gamma + u) \end{aligned}$$

$$\hat{\beta} = (X'M_z X)^{-1} X'M_z X \beta + (X'M_z X)^{-1} X'M_z Z \gamma + (X'M_z X)^{-1} X'M_z u$$

$$\hat{\beta} = I\beta + (X'M_z X)^{-1} X' * 0 * \gamma + (X'M_z X)^{-1} X'M_z u$$

$$\hat{\beta} = \beta + 0 + (X'M_z X)^{-1} X'M_z u$$

$$\hat{\beta} = \beta + (X'M_z X)^{-1} X'M_z u.$$

Por definición, se tiene esto:

$$\begin{aligned} \text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [\hat{\beta}_s - E(\hat{\beta}_s)] [\Gamma\hat{\gamma} - E(\Gamma\hat{\gamma})]' \} \\ \text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) &= E \{ [(X'X)^{-1} X'u] [\Gamma\hat{\gamma} - \Gamma E(\hat{\gamma})]' \} \end{aligned} \quad (*)$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = E \{ [(X'X)^{-1} X'u] [\Gamma(\hat{\gamma} - \gamma)]' \}$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = E \{ [(X'X)^{-1} X'u] [(\hat{\gamma} - \gamma)' \Gamma']' \}$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = E \{ [(X'X)^{-1} X'u] [(Z'M_x Z)^{-1} Z'M_x u]' \Gamma']' \},$$

$$(*) \hat{\beta}_s - E(\hat{\beta}_s) = [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - E[\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u]$$

$$\hat{\beta}_s - E(\hat{\beta}_s) = [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - \{E(\beta) + E[(X'X)^{-1} X'Z\gamma] + E[(X'X)^{-1} X'u]\}$$

$$\hat{\beta}_s - E(\hat{\beta}_s) = [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X' E(u)]$$

$$\hat{\beta}_s - E(\hat{\beta}_s) = [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X' * 0]$$

$$\hat{\beta}_s - E(\hat{\beta}_s) = [\beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u] - [\beta + (X'X)^{-1} X'Z\gamma + 0]$$

$$\hat{\beta}_s - E(\hat{\beta}_s) = \beta + (X'X)^{-1} X'Z\gamma + (X'X)^{-1} X'u - \beta - (X'X)^{-1} X'Z\gamma$$

$$\hat{\beta}_s - E(\hat{\beta}_s) = (X'X)^{-1} X'u.$$

reemplazando por definiciones. La última expresión se puede escribir como:

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = E \{ [(X'X)^{-1} X'u] [u'M_x Z(Z'M_x Z)^{-1} \Gamma']' \}$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = E \{ [(X'X)^{-1} X'uu'M_x Z(Z'M_x Z)^{-1} \Gamma']' \}$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = (X'X)^{-1} X' E(uu') M_x Z(Z'M_x Z)^{-1} \Gamma'$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = (X'X)^{-1} X' V(u) M_x Z(Z'M_x Z)^{-1} \Gamma'$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = (X'X)^{-1} X' \sigma^2 I M_x Z(Z'M_x Z)^{-1} \Gamma'$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = (X'X)^{-1} X' \sigma^2 M_x Z(Z'M_x Z)^{-1} \Gamma'$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = \sigma^2 (X'X)^{-1} X' M_x Z(Z'M_x Z)^{-1} \Gamma'$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = \sigma^2 (X'X)^{-1} * 0 * Z(Z'M_x Z)^{-1} \Gamma' \quad (**)$$

$$\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = 0,$$

$$(**) X'M_x = X' (I - P_x)$$

$$X'M_x = X' [I - X(X'X)^{-1} X']$$

$$X'M_x = X'I - X'X(X'X)^{-1} X'$$

$$X'M_x = X' - IX'$$

$$X'M_x = X' - X'$$

$$X'M_x = 0.$$

porque $V(u) = \sigma^2 I$. Tener en cuenta que $M_x X = 0$, por lo que la covarianza es igual a cero bajo homocedasticidad.

Por lo tanto, si el error u no es homocedástico, la covarianza entre $\tilde{\beta}_1^s$ y $B\hat{\beta}_2^l$ no sería cero. Este resultado es importante porque, de lo contrario, no se puede determinar cuál de los estimadores ($\tilde{\beta}_1^s$ y $\hat{\beta}_1^l$) es más eficiente o, mejor dicho, no se puede afirmar que $\tilde{\beta}_1^s$ es eficiente comparado con $\hat{\beta}_1^l$.

Ejercicio 8.

Sea A una matriz singular de la forma:

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}.$$

(a) Derivar la forma inversa particionada:

$$A^{-1} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}^{-1} = \begin{bmatrix} W^{-1} & -W^{-1}A_{12}A_{22}^{-1} \\ -A_{22}^{-1}A_{21}W^{-1} & A_{22}^{-1}A_{21}W^{-1}A_{11}A_{21}^{-1} \end{bmatrix},$$

donde $W = A_{11} - A_{12}A_{22}^{-1}A_{21}$ (insinuación: resolver para los elementos particionados de B de la fórmula $AB = I$).

$$AB = I$$

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

$$A_{11}B_{11} + A_{12}B_{21} = 1. \quad (1)$$

$$A_{21}B_{11} + A_{22}B_{21} = 0. \quad (2)$$

$$A_{11}B_{12} + A_{12}B_{22} = 0. \quad (3)$$

$$A_{21}B_{12} + A_{22}B_{22} = 1. \quad (4)$$

De (2), se obtiene:

$$B_{21} = -A_{22}^{-1}A_{21}B_{11}. \quad (2')$$

De (3), se obtiene:

$$B_{12} = -A_{11}^{-1}A_{12}B_{22}. \quad (3')$$

Reemplazando (2') en (1), se tiene:

$$\begin{aligned} A_{11}B_{11} + A_{12}(-A_{22}^{-1}A_{21}B_{11}) &= 1 \\ A_{11}B_{11} - A_{12}A_{22}^{-1}A_{21}B_{11} &= 1 \\ B_{11}(A_{11} - A_{12}A_{22}^{-1}A_{21}) &= 1 \\ B_{11} &= (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} = W^{-1}. \end{aligned} \quad (2'')$$

Reemplazando (3') en (4), se tiene:

$$\begin{aligned} A_{21}(-A_{11}^{-1}A_{12}B_{22}) + A_{22}B_{22} &= 1 \\ -A_{21}A_{11}^{-1}A_{12}B_{22} + A_{22}B_{22} &= 1 \\ B_{22}(A_{22} - A_{21}A_{11}^{-1}A_{12}) &= 1 \\ B_{22} &= (A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} \\ B_{22} &= A_{22}^{-1} - A_{12}^{-1}A_{11}A_{21}^{-1} = A_{22}^{-1}A_{21}W^{-1}A_{11}A_{21}^{-1}. \end{aligned} \quad (3'')$$

Reemplazando (2'') en (2), se tiene:

$$B_{21} = -A_{22}^{-1} A_{21} (A_{11} - A_{12} A_{22}^{-1} A_{21})^{-1} = -A_{22}^{-1} A_{21} W^{-1}.$$

Reemplazando (3'') en (3'), se tiene:

$$\begin{aligned} B_{12} &= -A_{11}^{-1} A_{12} (A_{22}^{-1} - A_{12}^{-1} A_{11} A_{21}^{-1}) \\ B_{12} &= -A_{11}^{-1} A_{12} A_{22}^{-1} + A_{11}^{-1} A_{12} A_{12}^{-1} A_{11} A_{21}^{-1} \\ B_{12} &= -A_{11}^{-1} A_{12} A_{22}^{-1} + A_{21}^{-1} \\ B_{12} &= -(A_{11}^{-1} - A_{11}^{-1} A_{12} A_{22}^{-1}) A_{12} A_{22}^{-1} \\ B_{12} &= -(A_{11} - A_{12} A_{22}^{-1} A_{21})^{-1} A_{12} A_{22}^{-1} = -W^{-1} A_{12} A_{22}^{-1}. \end{aligned}$$

Por lo tanto, se obtiene:

$$A^{-1} = \begin{bmatrix} W^{-1} & -W^{-1} A_{12} A_{22}^{-1} \\ -A_{22}^{-1} A_{21} W^{-1} & A_{22}^{-1} A_{21} W^{-1} A_{11} A_{21}^{-1} \end{bmatrix}.$$

(b) Usar las fórmulas anteriores para derivar el estimador MCO para $\hat{\beta}_1$ de forma constructiva a partir de la fórmula de ajuste:

$$\hat{\beta} = (X'X)^{-1} X'y = \begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix}^{-1} \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix}.$$

$$\begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix}^{-1} \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix}.$$

$$\begin{aligned} \hat{\beta}_1 &= W^{-1} X_1'y - W^{-1} A_{12} A_{22}^{-1} X_2'y \\ \hat{\beta}_1 &= W^{-1} (X_1' - A_{12} A_{22}^{-1} X_2') y \\ \hat{\beta}_1 &= [X_1'X_1 - X_1'X_2 (X_2'X_2)^{-1} X_2'X_1]^{-1} [X_1' - X_1'X_2 (X_2'X_2)^{-1} X_2'] y \\ \hat{\beta}_1 &= \{X_1'[I - X_2 (X_2'X_2)^{-1} X_2'] X_1\}^{-1} \{X_1' [I - X_2 (X_2'X_2)^{-1} X_2']\} y \\ \hat{\beta}_1 &= [X_1'(I - P_2) X_1]^{-1} [X_1' (I - P_2)] y \\ \hat{\beta}_1 &= (X_1' M_2 X_1)^{-1} X_1' M_2 y \\ \hat{\beta}_1 &= (X_1' M_2 M_2 X_1)^{-1} X_1' M_2 M_2 y \\ \hat{\beta}_1 &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \tilde{y}. \end{aligned}$$

(c) Encontrar la varianza condicional de $\hat{\beta}_1$ suponiendo que el término de error $u \equiv y - X\hat{\beta}$ se distribuye normalmente, digamos $u \sim \mathcal{N}(0, \sigma^2)$.

$$\begin{aligned} V(\hat{\beta}_1 | X) &= V[(\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \tilde{y} | X] \\ V(\hat{\beta}_1 | X) &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' V(\tilde{y} | X) \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1} \\ V(\hat{\beta}_1 | X) &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' V(u | X) \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1} \\ V(\hat{\beta}_1 | X) &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \sigma^2 I \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1} \end{aligned}$$

$$V(\hat{\beta}_1 | X) = (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \sigma^2 \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1}$$

$$V(\hat{\beta}_1 | X) = \sigma^2 (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1}$$

$$V(\hat{\beta}_1 | X) = \sigma^2 I (\tilde{X}_1' \tilde{X}_1)^{-1}$$

$$V(\hat{\beta}_1 | X) = \sigma^2 (\tilde{X}_1' \tilde{X}_1)^{-1}.$$

Ejercicio 9.

Teniendo en cuenta el siguiente modelo de regresión:

$$y = X\beta + Z\alpha + u,$$

con $X \perp Z$. Se supone que se estima el modelo utilizando métodos de mínimos cuadrados. Demostrar que:

(i) $\hat{\alpha}$ no depende de X .

Se parte de la condición de momento:

$$\begin{aligned} Z'u &= 0 \\ Z'(y - X\beta - Z\alpha) &= 0 \\ Z'y - Z'X\beta - Z'Z\alpha &= 0 \\ Z'y - 0 * \beta - Z'Z\alpha &= 0 \\ Z'y - Z'Z\alpha &= 0 \\ Z'Z\alpha &= Z'y \\ \hat{\alpha} &= (Z'Z)^{-1}Z'y. \end{aligned}$$

Por lo tanto, $\hat{\alpha}$ no depende de X .

(ii) $Cov(\hat{\beta}, \hat{\alpha}) = 0$.

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1}X'y \\ \hat{\beta} &= \beta + (X'X)^{-1}X'u; \quad E(\hat{\beta}) = \beta. \end{aligned}$$

$$\begin{aligned} \hat{\alpha} &= (Z'Z)^{-1}Z'y \\ \hat{\alpha} &= \alpha + (Z'Z)^{-1}Z'u; \quad E(\hat{\alpha}) = \alpha, \end{aligned}$$

$$\begin{aligned} Cov(\hat{\beta}, \hat{\alpha}) &= E\{[\hat{\beta} - E(\hat{\beta})][\hat{\alpha} - E(\hat{\alpha})]'\} \\ Cov(\hat{\beta}, \hat{\alpha}) &= E[(\hat{\beta} - \beta)(\hat{\alpha} - \alpha)'] \\ Cov(\hat{\beta}, \hat{\alpha}) &= E\{[(X'X)^{-1}X'u][(Z'Z)^{-1}Z'u]'\} \\ Cov(\hat{\beta}, \hat{\alpha}) &= E[(X'X)^{-1}X'uu'Z(Z'Z)^{-1}] \\ Cov(\hat{\beta}, \hat{\alpha}) &= (X'X)^{-1}X'E(uu')Z(Z'Z)^{-1} \\ Cov(\hat{\beta}, \hat{\alpha}) &= (X'X)^{-1}X'\sigma^2IZ(Z'Z)^{-1} \\ Cov(\hat{\beta}, \hat{\alpha}) &= (X'X)^{-1}X'\sigma^2Z(Z'Z)^{-1} \\ Cov(\hat{\beta}, \hat{\alpha}) &= \sigma^2(X'X)^{-1}X'Z(Z'Z)^{-1} \\ Cov(\hat{\beta}, \hat{\alpha}) &= \sigma^2(X'X)^{-1} * 0 * (Z'Z)^{-1} \\ Cov(\hat{\beta}, \hat{\alpha}) &= 0. \end{aligned}$$

Ejercicio 10.

Sea $\hat{\beta}$ el estimador MCO y $\tilde{\beta}$ cualquier otro estimador lineal insesgado. Mostrar que, si $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I$ en un modelo de regresión lineal, entonces, el estimador MCO es eficiente, por ejemplo $V(\tilde{\beta} | X) \geq V(\hat{\beta} | X)$ o $V(\tilde{\beta} | X) - V(\hat{\beta} | X)$ es semidefinida positiva.

El estimador MCO es insesgado y lineal, lo que significa que se puede escribir $\hat{\beta}$ como una función lineal de la variable de respuesta y, por ejemplo:

$$\hat{\beta} = Ay,$$

donde $A = (X'X)^{-1}X'$. Ahora, considerar otro estimador lineal insesgado:

$$\tilde{\beta} = (A + B)y.$$

Por lo tanto, debe ser el caso de $E(\tilde{\beta}) = \beta$ porque $BX = 0$. Además, la varianza del estimador $\tilde{\beta}$ es:

$$\begin{aligned} V(\tilde{\beta} | X) &= E\{[\tilde{\beta} - E(\tilde{\beta})][\tilde{\beta} - E(\tilde{\beta})]' | X\} \\ V(\tilde{\beta} | X) &= E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)' | X] \\ V(\tilde{\beta} | X) &= E\{[(A + B)u][(A + B)u]' | X\} \end{aligned} \quad (*)$$

$$\begin{aligned} V(\tilde{\beta} | X) &= E[(A + B)uu'(A + B)' | X] \\ V(\tilde{\beta} | X) &= (A + B)E(uu' | X)(A + B)' \\ V(\tilde{\beta} | X) &= (A + B)V(u | X)(A + B)' \\ V(\tilde{\beta} | X) &= (A + B)\sigma^2 I(A' + B') \\ V(\tilde{\beta} | X) &= (A + B)\sigma^2(A' + B') \\ V(\tilde{\beta} | X) &= \sigma^2(A + B)(A' + B') \\ V(\tilde{\beta} | X) &= \sigma^2(AA' + AB' + BA' + BB') \\ V(\tilde{\beta} | X) &= \sigma^2[(X'X)^{-1}X'X(X'X)^{-1} + (X'X)^{-1}X'B' + BX(X'X)^{-1} + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2[I(X'X)^{-1} + (X'X)^{-1} * 0 + 0 * (X'X)^{-1} + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2[(X'X)^{-1} + 0 + 0 + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2[(X'X)^{-1} + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2(X'X)^{-1} + \sigma^2 BB' \\ V(\tilde{\beta} | X) &= V(\hat{\beta} | X) + \sigma^2 BB'. \end{aligned} \quad (**)$$

$$\begin{aligned} (*) \quad \tilde{\beta} &= (A + B)y \\ \tilde{\beta} &= (A + B)(X\beta + u) \\ \tilde{\beta} &= AX\beta + BX\beta + (A + B)u \\ \tilde{\beta} &= (X'X)^{-1}X'X\beta + 0 * \beta + (A + B)u \\ \tilde{\beta} &= I\beta + 0 + (A + B)u \\ \tilde{\beta} &= \beta + (A + B)u \\ \tilde{\beta} - \beta &= (A + B)u. \end{aligned} \quad (**)$$

$$\begin{aligned} (**) \quad E(\tilde{\beta}) &= \beta \\ E[\beta + BX\beta + (A + B)u] &= \beta \end{aligned}$$

$$\begin{aligned}
 E(\beta) + E(BX\beta) + E[(A+B)u] &= \beta \\
 \beta + BX\beta + (A+B)E(u) &= \beta \\
 \beta + BX\beta + (A+B) \cdot 0 &= \beta \\
 \beta + BX\beta + 0 &= \beta \\
 \beta + BX\beta &= \beta \\
 \beta(1 + BX) &= \beta \\
 1 + BX &= \frac{\beta}{\beta} \\
 1 + BX &= 1 \\
 BX &= 1 - 1 \\
 BX &= 0.
 \end{aligned}$$

La última ecuación sugiere que la varianza del estimador $\tilde{\beta}$ es mayor que la varianza del estimador $\hat{\beta}$. Esto se puede establecer en el siguiente importante teorema.

Teorema de Gauss-Markov. Si $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I$, en un modelo de regresión lineal, entonces, el estimador MCO es eficiente, por ejemplo $V(\tilde{\beta} | X) \geq V(\hat{\beta} | X)$ o $V(\tilde{\beta} | X) - V(\hat{\beta} | X)$ es semidefinida positiva.

Ejercicio 11.

Indicar, demostrar matemáticamente y explicar las implicaciones prácticas del teorema de Frish-Waugh-Lovell.

Este teorema nos dice que el estimador MCO $\hat{\beta}$, que se obtiene de regresar y en X y Z (modelo particionado) es igual al estimador MCO $\tilde{\beta}$, que se obtiene de regresar los residuos obtenidos de la regresión de y en Z ($\tilde{y}$) en los residuos obtenidos de la regresión de X en Z ($\tilde{X}$) (modelo alternativo).

- Modelo particionado: $y = X\beta + Z\gamma + u$.
- Modelo alternativo: $\tilde{y} = \tilde{X}\beta + \tilde{u}$.

Demostración matemática.

Considerar un modelo de regresión particionado:

$$y = X\beta + Z\gamma + u$$

y el estimador correspondiente $\hat{\beta}$. Además, considerar el modelo de regresión alternativo:

$$\tilde{y} = \tilde{X}\beta + \tilde{u},$$

con el correspondiente estimador $\tilde{\beta}$, con $\tilde{Z} = M_Z Z$ para un vector genérico Z.

Se puede demostrar que los estimadores $\hat{\beta}$ y $\tilde{\beta}$ son, numéricamente, idénticos.

Las fórmulas estándar de MCO en el modelo particionado dan las siguientes ecuaciones normales:

$$X'y = X'X\hat{\beta} + X'Z\hat{\gamma}.$$

$$Z'y = Z'X\hat{\beta} + Z'Z\hat{\gamma}.$$

Resolviendo para $\hat{\gamma}$ en la segunda ecuación y reemplazando en la primera ecuación, se obtiene:

$$Z'Z\hat{\gamma} = Z'y - Z'X\hat{\beta}$$

$$\hat{\gamma} = (Z'Z)^{-1} (Z'y - Z'X\hat{\beta})$$

$$\hat{\gamma} = (Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}.$$

$$X'y = X'X\hat{\beta} + X'Z [(Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}]$$

$$X'y = X'X\hat{\beta} + X'Z(Z'Z)^{-1} Z'y - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X'y - X'Z(Z'Z)^{-1} Z'y = X'X\hat{\beta} - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X' [I - Z(Z'Z)^{-1} Z'] y = X' [I - Z(Z'Z)^{-1} Z'] X\hat{\beta}$$

$$X' (I - P_Z) y = X' (I - P_Z) X\hat{\beta}$$

$$X'M_Z y = X'M_Z X\hat{\beta}.$$

Por lo tanto:

$$\begin{aligned}\hat{\beta} &= (X' M_z X)^{-1} X' M_z y \\ \hat{\beta} &= (X' M_z' M_z X)^{-1} X' M_z' M_z y \\ \hat{\beta} &= (\tilde{X}' \tilde{X})^{-1} \tilde{X}' \tilde{y} \\ \hat{\beta} &= \tilde{\beta}.\end{aligned}$$

Además de las estimaciones puntuales, los residuos son idénticos. Para ver esto, considerar:

$$\begin{aligned}y &= \hat{y} + \hat{u} \\ y &= X\hat{\beta} + Z\hat{\gamma} + \hat{u}\end{aligned}$$

y multiplicar por M_z :

$$\begin{aligned}M_z y &= M_z X \hat{\beta} + M_z Z \hat{\gamma} + M_z \hat{u} \\ \tilde{y} &= \tilde{X} \hat{\beta} + 0 * \hat{\gamma} + (I - P_z) \hat{u} & (*) \\ \tilde{y} &= \tilde{X} \hat{\beta} + 0 + I \hat{u} - P_z \hat{u} \\ \tilde{y} &= \tilde{X} \hat{\beta} + \hat{u} - 0 & (**) \\ \tilde{y} &= \tilde{X} \hat{\beta} + \hat{u},\end{aligned}$$

donde $M_z \hat{u} = \hat{u}$ porque $P_z \hat{u} = 0$.

$$\begin{aligned} (*) \quad M_z Z &= (I - P_z) Z \\ M_z Z &= IZ - P_z Z \\ M_z Z &= Z - Z(Z'Z)^{-1}Z'Z \\ M_z Z &= Z - ZI \\ M_z Z &= Z - Z \\ M_z Z &= 0.\end{aligned}$$

$$\begin{aligned} (**) \quad P_z \hat{u} &= P_z M_y \\ P_z \hat{u} &= P_z M_z M_y \\ P_z \hat{u} &= 0 * M_y & (***) \\ P_z \hat{u} &= 0.\end{aligned}$$

$$\begin{aligned} (***) \quad P_z M_z &= P_z (I - P_z) \\ P_z M_z &= P_z I - P_z P_z \\ P_z M_z &= P_z - P_z \\ P_z M_z &= 0.\end{aligned}$$

Implicaciones prácticas.

Las implicaciones prácticas de este teorema son que el estimador MCO se puede obtener de la siguiente manera:

1. Regresando y en Z y obteniendo los residuos $\tilde{y}$.
2. Regresando X en Z y obteniendo los residuos $\tilde{X}$.
3. Regresando $\tilde{y}$ en $\tilde{X}$ y obteniendo el estimador MCO $\hat{\beta}$.

Ejercicio 12.

Considerar el siguiente modelo:

$$y = X\beta + u,$$

donde la media del término de error es cero y la covarianza entre x_i y u_i es cero.

(a) Suponiendo que el término de error u_i esté correlacionado con u_j , ¿cómo estimaría el parámetro β y el error estándar de $\hat{\beta}$? ¿Por qué?

Se supone que se tiene $\{(y_i, x_i)\}_{i=1}^n$, pero se sabe que el modelo puede variar según los grupos $c = 1, \dots, C$:

$$y_{ic} = x'_{ic}\beta_c + u_{ic}.$$

Aunque es razonable pensar que $\text{Cov}(u_{ic}, u_{jc}) = 0$, puede darse el caso de que:

$$\text{Cov}(u_{ic}, u_{jc}) \neq 0.$$

Se comienza suponiendo que el término de error u_{ic} no es independiente de x_{ic} . Por ejemplo, si $u_{ic} = \alpha_c + v_{ic}$, entonces, $\text{Cov}(x_{ic}, \alpha_c) \neq 0$. En este caso, los grupos introducen sesgos si el modelo no condiciona en c . Por lo tanto, uno podría estar interesado en estimar:

$$E(y_{ic} | X_{ic}, \alpha_c) = x'_{ic}\beta_c + \alpha_c,$$

cuando el número de grupos es grande. El modelo puede ser estimado por transformaciones clásicas de mínimos cuadrados:

En el caso de efectos aleatorios, se puede considerar apilar observaciones dentro de grupos:

$$y_c = X_c\beta_c + \alpha_c,$$

donde y_c es un vector de dimensión $(n_c \times 1)$ y X_c es una matriz de $(n_c \times p)$. Escribir $n = \sum_c n_c$.

Por lo tanto, la estimación del parámetro β es:

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\hat{\beta} = \left(\sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic}x'_{ic}\right)^{-1} \sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic}y_{ic}.$$

Observar que $V(\hat{\beta}) \neq \sigma^2(X'X)^{-1}$.

Y el error estándar robusto agrupado de $\hat{\beta}$ es:

$$\hat{V}(\hat{\beta}) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

$$\hat{V}(\hat{\beta}) = (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C X_c' \hat{u}_c \hat{u}_c X_c (\sum_{c=1}^C X_c' X_c)^{-1},$$

donde los residuos son $\hat{u}_c = y_c - X_c \hat{\beta}$. El problema con esta corrección es que se necesita $C \rightarrow \infty$ para consistencia.

(b) Explicar cuáles son los problemas de estimar el error estándar de $\hat{\beta}$ por MCO.

Si se asume que $u_{ic} = \alpha_c + v_{ic}$, se puede adoptar el marco de efectos aleatorios asumiendo que α y v son independientes. Darse cuenta de:

$$E(u_{ic} u_{jc}) = E[(\alpha_c + v_{ic})(\alpha_c + v_{jc})]$$

$$E(u_{ic} u_{jc}) = E(\alpha_c^2 + \alpha_c v_{jc} + v_{ic} \alpha_c + v_{ic} v_{jc})$$

y, luego, si $i = j$:

$$E(u_{ic} u_{jc}) = \sigma_\alpha^2 + \sigma_v^2$$

$$E(u_{ic} u_{jc}) = \sigma^2,$$

y, si $i \neq j$:

$$E(u_{ic} u_{jc}) = \sigma_\alpha^2$$

$$E(u_{ic} u_{jc}) = \rho \sigma^2,$$

donde $\rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_v^2}$. Por resultados similares al estimador Balesta-Nerlove, se tiene que:

$$\Sigma_c = E(u_c u_c')$$

$$\Sigma_c = \sigma^2 [(1 - \rho) I_c + \rho 1_c 1_c'].$$

Luego, se sigue que la varianza de $\hat{\beta}$ es:

$$V(\hat{\beta}) = (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C X_c' \sigma^2 [(1 - \rho) I_c + \rho 1_c 1_c'] X_c (\sum_{c=1}^C X_c' X_c)^{-1}$$

$$V(\hat{\beta}) = (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C \sigma^2 X_c' [(1 - \rho) I_c + \rho 1_c 1_c'] X_c (\sum_{c=1}^C X_c' X_c)^{-1}.$$

Es posible demostrar que:

$$V(\hat{\beta}_1) = [1 + (M - 1) \rho] V(\tilde{\beta}_1),$$

donde $V(\tilde{\beta}_1)$ es la varianza del estimador estándar MCO.

Por lo tanto, el problema de estimar el error estándar de $\hat{\beta}$ por MCO es que éste tiene sesgos considerables (en general, se nota una sobrestimación del error estándar).

(c) Se supone, ahora, que $\text{Cov}(u_i, u_j) = 0$ para todos i y j y la varianza condicional es $E(uu' | X) \equiv \Omega$. Obtener el mejor estimador lineal insesgado y su varianza. Demostrar que el término de error del modelo transformado tiene una variación constante.

Suponer que $E(uu') = \Omega \neq \sigma^2 I_n$ y Ω es desconocido. Considerar una descomposición de la matriz $\Omega^{-1} = CC' = P\Lambda^{-1}P$, donde P es una matriz ortogonal y Λ es una matriz diagonal que incluye las raíces características de Ω . Resulta que se puede escribir:

$$E(uu') = \Omega$$

$$E(uu') = (C')^{-1}C^{-1}.$$

Entonces, se puede transformar la regresión como:

$$C'y = C'X\beta + C'u$$

$$\tilde{y} = \tilde{X}\beta + \tilde{u}.$$

El término de error vector $\tilde{u}$ tiene media cero y varianza I [por ejemplo, $\tilde{u} \sim N(0, I)$] porque la transformación logra:

$$E(\tilde{u}) = E(C'u)$$

$$E(\tilde{u}) = C' E(u)$$

$$E(\tilde{u}) = C' * 0$$

$$E(\tilde{u}) = 0.$$

$$V(\tilde{u}) = V(C'u)$$

$$V(\tilde{u}) = C' V(u) C$$

$$V(\tilde{u}) = C'(C')^{-1}C^{-1}C$$

$$V(\tilde{u}) = I$$

$$V(\tilde{u}) = I.$$

El estimador MCG es:

$$\hat{\beta} = \arg \min \|y - X\beta\|_{\Omega^{-1}}^2$$

$$\hat{\beta} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}.$$

Y se puede ver lo siguiente:

$$E(\hat{\beta} | X) = E[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} | X]$$

$$E(\hat{\beta} | X) = E\{[\beta + (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{u}] | X\}$$

$$E(\hat{\beta} | X) = E(\beta | X) + E[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{u} | X]$$

$$E(\hat{\beta} | X) = \beta + (\tilde{X}'\tilde{X})^{-1}\tilde{X}' E(\tilde{u} | X)$$

$$E(\hat{\beta} | X) = \beta + (\tilde{X}'\tilde{X})^{-1}\tilde{X}' * 0$$

$$E(\hat{\beta} | X) = \beta + 0$$

$$E(\hat{\beta} | X) = \beta.$$

$$V(\hat{\beta} | X) = V[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} | X]$$

$$V(\hat{\beta} | X) = (\tilde{X}'\tilde{X})^{-1}\tilde{X}' V(\tilde{y} | X) \tilde{X}(\tilde{X}'\tilde{X})^{-1}$$

$$\begin{aligned}
V(\hat{\beta} | X) &= (X'CC'X)^{-1}X'C V(C'y | X) C'X(X'CC'X)^{-1} \\
V(\hat{\beta} | X) &= (X'CC'X)^{-1}X'CC' V(y | X) CC'X(X'CC'X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1} V(u | X) \Omega^{-1}X(X'CC'X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}\Omega\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}IX(X'\Omega^{-1}X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}I \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}.
\end{aligned}$$

Por lo tanto, el estimador MCG es insesgado y tiene varianza condicional más pequeña que la del estimador MCO en un modelo heterocedástico.

(d) Explicar los pasos necesarios para implementar el método sugerido en (c).

El estimador MCG es inviable, lo que significa que no se puede implementar en la práctica. La matriz Ω es, típicamente, desconocida, por lo que nos gustaría implementar un método para estimarla. Se puede considerar, en su lugar, $\Omega(\gamma)$ y, después de establecer una relación entre la varianza condicional y el parámetro γ , se puede implementar el método.

Considerar, por simplicidad:

$$y_i = x_i\beta + (z_i'\gamma)^{\frac{-1}{2}}u_i,$$

lo que implica que el elemento i_{th} en la diagonal de Ω es $\Omega_{ii} = (z_i'\gamma)$. Tener en cuenta que, si se estima γ , se puede estimar Ω . Un simple procedimiento de estimación considera:

1. Obtener el estimador MCO ejecutando:

$$(y_i - x_i\hat{\beta})^2 = z_i'\gamma + v_i.$$

2. Colocar $\hat{\gamma}$ en Ω y obtener:

$$\begin{aligned}
\hat{\beta} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} \\
\hat{\beta} &= (X'CC'X)^{-1}X'CC'y \\
\hat{\beta} &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y \\
\hat{\beta} &= (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y.
\end{aligned}$$

En la literatura, existen otros primeros pasos convenientes para los modelos multiplicativos, cuadráticos, etc. de heterocedasticidad. Por ejemplo, podría suponerse que la varianza condicional de u es $e^{\gamma x}$.

(e) Demostrar que la diferencia entre la varianza del estimador MCO y la varianza del estimador que se propuso en (c) es semidefinida positiva.

Teorema. $V(\hat{\beta}_{MCO}) - V(\hat{\beta}_{MCG})$ es una matriz semidefinida positiva.

Prueba. Por simplicidad, C es simétrica. En primer lugar, tener en cuenta que la varianza condicional del MCO es igual a:

$$\begin{aligned} V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'y] \\ V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'(X\beta + u)] \\ V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= V[I\beta + (X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= V[\beta + (X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= V(\beta) + V[(X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= 0 + (X'X)^{-1}X' V(u) X(X'X)^{-1} \\ V(\hat{\beta}_{MCO}) &= (X'X)^{-1}X'\Omega X(X'X)^{-1}. \end{aligned}$$

Considerar la descomposición:

$$\begin{aligned} X'\Omega^{-1}X &= X'CC'X = W'W. \\ X'\Omega X &= X'(C')^{-1}C^{-1}X = S'S. \\ X'X &= X'\Omega^{-1}\Omega X = X'CC'(C')^{-1}C^{-1}X = X'CC^{-1}X = W'S. \end{aligned}$$

Entonces, se tiene que:

$$\begin{aligned} (X'X)(X'\Omega X)^{-1}(X'X) &= W'S(S'S)^{-1}S'W \\ (X'X)(X'\Omega X)^{-1}(X'X) &= W'P_S W \leq W'W. \end{aligned}$$

Por lo tanto:

$$\begin{aligned} (X'X)(X'\Omega X)^{-1}(X'X) &\leq X'\Omega^{-1}X \\ [(X'X)(X'\Omega X)^{-1}(X'X)]^{-1} &\geq (X'\Omega X)^{-1} \\ (X'X)^{-1}X'\Omega X(X'X)^{-1} &\geq (X'\Omega X)^{-1} \\ V(\hat{\beta}_{MCO}) &\geq V(\hat{\beta}_{MCG}) \\ V(\hat{\beta}_{MCO}) - V(\hat{\beta}_{MCG}) &\geq 0. \end{aligned}$$

Ejercicio 13.

Considerar una muestra aleatoria $Z_1, Z_2, \dots, Z_m$ distribuida independientemente de manera uniforme $U[0, \theta]$.

(a) Obtener un estimador consistente de θ .

Es natural estimar θ considerando el estadístico de orden más grande, es decir, $\hat{\theta} = \max_{1 \leq i \leq m} \{Z_i\}$. Tener en cuenta que, para una pequeña constante $\epsilon > 0$, se tiene que $\{|X_m - \theta| > \epsilon\} = \{X_m - \theta > \epsilon\} \cup \{X_m - \theta < -\epsilon\}$. Por lo tanto:

$$\begin{aligned} P(|\hat{\theta} - \theta| > \epsilon) &= P(\hat{\theta} - \theta > \epsilon) + P(\hat{\theta} - \theta < -\epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= P(\hat{\theta} > \theta + \epsilon) + P(\hat{\theta} < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= 0 + P(\max_{1 \leq i \leq m} \{Z_i\} < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= P(Z_1 < \theta - \epsilon, Z_2 < \theta - \epsilon, \dots, Z_m < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= P(Z_1 < \theta - \epsilon) P(Z_2 < \theta - \epsilon) \dots P(Z_m < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= \prod_{i=1}^m P(Z_i < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= \left(\frac{\theta - \epsilon}{\theta}\right)^m \\ P(|\hat{\theta} - \theta| > \epsilon) &= \left(1 - \frac{\epsilon}{\theta}\right)^m \rightarrow 0, \text{ cuando } m \rightarrow \infty. \end{aligned}$$

Por lo tanto, $\hat{\theta}$ es un estimador consistente de θ .

(b) Demostrar que el estimador es consistente, explicando el papel de los supuestos necesarios para establecer la consistencia.

Los supuestos necesarios para establecer la consistencia son que la muestra debe estar distribuida aleatoriamente, uniformemente y se encuentra acotada.

Ejercicio 14.

Indicar las condiciones bajo las cuales el estimador MCO para un modelo lineal $y = X\beta + u$ es consistente y asintóticamente normal. Probar la consistencia del estimador y obtener la varianza de la distribución asintótica.

Un estimador consistente $\hat{\theta}$ es uno que converge a θ en probabilidad:

$$\hat{\theta} \rightarrow \theta$$

a medida que el tamaño de la muestra n va al infinito, para todos los valores verdaderos posibles. Con esta definición, se investiga la consistencia de MCO.

Considerar un modelo de regresión lineal de la forma:

$$y_i = x_i' \beta + u_i,$$

donde $E(u_i | x_i) = E(u_i) = 0$. Se puede asumir, provisionalmente, que los términos de error u están i.i.d. aleatoriamente con distribución F . El estimador MCO para el parámetro desconocido β es $\hat{\beta} = (X'X)^{-1}X'y$ y puede ser escrito como:

$$\begin{aligned} \hat{\beta} - \beta &= (X'X)^{-1}X'u \\ \hat{\beta} - \beta &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right), \end{aligned}$$

donde X es una matriz de $(n \times p)$ y u es un vector de $(n \times 1)$. Si las x_i son consideradas fijas o no estocásticas, se tiene que:

$$\frac{1}{n} \sum_{i=1}^n x_i x_i' \rightarrow^p E(X'X) = Q_0 \quad \text{y} \quad \frac{1}{n} \sum_{i=1}^n x_i u_i \rightarrow^p E(X'u) = 0.$$

Entonces, aplicando Chebyshev y el teorema de Slutsky, se tiene que $\hat{\beta}$ converge en probabilidad a β :

$$\begin{aligned} \hat{\beta} - \beta &\rightarrow^p Q_0^{-1} * 0 \\ \hat{\beta} - \beta &\rightarrow^p 0 \\ \hat{\beta} &\rightarrow^p \beta. \end{aligned}$$

Por otra parte, recordando que $\hat{\beta} - \beta = (X'X)^{-1}X'u$, se puede escribir:

$$\begin{aligned} \sqrt{n}(\hat{\beta} - \beta) &= \left(\frac{X'X}{n}\right)^{-1} \frac{1}{\sqrt{n}} X'u \\ \sqrt{n}(\hat{\beta} - \beta) &= n \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \frac{1}{\sqrt{n}} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) \\ \sqrt{n}(\hat{\beta} - \beta) &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right). \end{aligned}$$

Considerando el segundo término y dado que $E(u | X) = E(u) = 0$, se tiene:

$$E\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) = E\left(\sqrt{n} \frac{1}{n} \sum_{i=1}^n x_i u_i\right)$$

$$E\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) = \sqrt{n} E\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) \xrightarrow{p} \sqrt{\infty} E[E(X'u)] = \sqrt{\infty} E[X' E(u)] = \sqrt{\infty} E(X' * 0) = \sqrt{\infty} E(0) = \sqrt{\infty} * 0 = 0.$$

Y, dado que $E(uu') = \sigma^2$ y $\text{Cov}(u_i, u_j) = 0$, se tiene:

$$\begin{aligned} \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \text{Var}\left(\sum_{i=1}^n x_i u_i\right) \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \sum_{i=1}^n \text{Var}(x_i u_i) \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \sum_{i=1}^n x_i \text{Var}(u_i) x_i' \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \sum_{i=1}^n x_i \sigma^2 x_i' \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{\sigma^2}{n} \sum_{i=1}^n x_i x_i' \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \sigma^2 \frac{1}{n} \sum_{i=1}^n x_i x_i' \xrightarrow{p} \sigma^2 E(X'X) = \sigma^2 Q_0. \end{aligned}$$

Entonces, considerando que la convergencia en probabilidad a una constante es equivalente a la convergencia en distribución, se tiene:

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \xrightarrow{d} \mathcal{N}(0, \sigma^2 Q_0).$$

Entonces, considerando el teorema de Slutsky, se tiene:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} Q_0^{-1} \mathcal{N}(0, \sigma^2 Q_0) = \mathcal{N}(0, \sigma^2 Q_0^{-1}). \quad (*)$$

$$\begin{aligned} V[\sqrt{n}(\hat{\beta} - \beta)] &= V(Q_0^{-1} X^*) && \text{donde } X^* = \mathcal{N}(0, \sigma^2 Q_0) \\ V[\sqrt{n}(\hat{\beta} - \beta)] &= Q_0^{-1} V(X^*) Q_0^{-1} \\ V[\sqrt{n}(\hat{\beta} - \beta)] &= Q_0^{-1} \sigma^2 Q_0 Q_0^{-1} \\ V[\sqrt{n}(\hat{\beta} - \beta)] &= \sigma^2 Q_0^{-1}. \end{aligned}$$

En resumen, la normalidad asintótica se deriva de: (i) la convergencia en distribución de la puntuación, (ii) la convergencia en probabilidad del Hessiano y (iii) el teorema de Slutsky.

Por lo tanto, se pudo observar que, para un modelo lineal $y = X\beta + u$, el estimador MCO es consistente y asintóticamente normal.

Ejercicio 15.

Considerar la primera ecuación en un sistema lineal de ecuaciones:

$$y_1 = \alpha_1 Y_2 + x' \beta + u_1,$$

donde Y_2 es la variable endógena (sospechada). Demostrar que el estimador MCO de la siguiente ecuación:

$$y_1 = \alpha_1 Y_2 + x' \beta + \gamma \hat{r} + v_1$$

es idéntico al estimador MC2E ($\hat{r}$ denota los residuos de $Y_2 = z_i' \pi + r_i$, donde las variables z son exógenas).

El estimador de mínimos cuadrados en dos etapas (MC2E) es:

$$\hat{\beta}_{MC2E} = (X' P_Z X)^{-1} X' P_Z y.$$

Este estimador se basa en dos proyecciones:

1. Regresar X en Z para obtener:

$$\hat{X} = Z(Z'Z)^{-1}Z'X$$

$$\hat{X} = P_Z X.$$

Es importante ver los componentes de la matriz de proyección $\hat{X} = [P_Z x', P_Z Y_2]$.

Recordar que $Z = [x', Z_2]$, por lo que:

$$\hat{X} = [x', \hat{Y}_2].$$

2. Luego, regresar y sobre $\hat{X}$, obteniendo el estimador MC2E:

$$\hat{\beta}_{MC2E} = (\hat{X}' \hat{X})^{-1} \hat{X}' y$$

$$\hat{\beta}_{MC2E} = (X' P_Z' P_Z X)^{-1} X' P_Z y$$

$$\hat{\beta}_{MC2E} = (X' P_Z P_Z X)^{-1} X' P_Z y$$

$$\hat{\beta}_{MC2E} = (X' P_Z X)^{-1} X' P_Z y.$$

Por otra parte, se definen los residuos de X en Z :

$$R = X - \hat{X}$$

$$R = X - P_Z X$$

$$R = (I - P_Z) X$$

$$R = M_Z X.$$

Considerar, ahora, el estimador de mínimos cuadrados de un modelo que incluye los residuos:

$$y = X\beta + R\gamma + u,$$

que es igual a:

$$\hat{\beta}_{vc} = (X'M_R X)^{-1} X'M_R y,$$

donde vc significa variable de control. Este estimador es idéntico al estimador MC2E porque:

$$\begin{aligned} X'M_R &= X' (I - P_R) \\ X'M_R &= X' [I - R(R'R)^{-1}R'] \\ X'M_R &= X' [I - M_Z X(X'M_Z' M_Z X)^{-1} X'M_Z'] \\ X'M_R &= X' [I - M_Z X(X'M_Z M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' [I - M_Z X(X'M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' - X'M_Z X(X'M_Z X)^{-1} X'M_Z \\ X'M_R &= X' - IX'M_Z \\ X'M_R &= X' - X'M_Z \\ X'M_R &= X' - X' (I - P_Z) \\ X'M_R &= X' - X' + X'P_Z \\ X'M_R &= X'P_Z. \end{aligned}$$

$$\hat{\beta}_{vc} = (X'P_Z X)^{-1} X'P_Z y.$$

Por lo tanto, el estimador MCO de la siguiente ecuación $y_1 = \alpha_1 Y_2 + x'\beta + \gamma\hat{r} + v_1$ es idéntico al estimador MC2E $y_1 = \alpha_1 Y_2 + x'\beta + u_1$, por lo que el “sesgo por endogeneidad” se puede ver como un “sesgo por variable omitida”.

Ejercicio 16.

Teniendo en cuenta el siguiente modelo de regresión:

$$y_i = x_i' \beta + \epsilon_i,$$

con $E(\epsilon_i | x_i) = 0$ y se sabe $E(\epsilon_i^2 | x_i) = \sigma^2$.

(a) Mostrar que el estimador de mínimos cuadrados generalizados se puede escribir como un estimador de variable instrumental.

El estimador de mínimos cuadrados generalizados es:

$$\begin{aligned}\hat{\beta}_{MCG} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} \\ \hat{\beta}_{MCG} &= (X'CC'X)^{-1}X'CC'y \\ \hat{\beta}_{MCG} &= (X'C'C'X)^{-1}X'C'C'y \\ \hat{\beta}_{MCG} &= (X'C'X)^{-1}X'Cy.\end{aligned}$$

Un estimador de variable instrumental puede ser el siguiente:

$$\hat{\beta}_{MC2E} = (X'P_ZX)^{-1}X'P_Zy.$$

Si se llama $C' = P_Z$, se tiene:

$$\hat{\beta}_{MCG} = (X'P_ZX)^{-1}X'P_Zy.$$

Por lo tanto, el estimador de mínimos cuadrados generalizados se puede escribir como un estimador de variable instrumental.

(b) Escribir la expresión para la variable instrumental.

$$\hat{\beta}_{MC2E} = (X'P_ZX)^{-1}X'P_Zy.$$

Ejercicio 17.

(a) Demostrar que la siguiente suposición implica ortogonalidad entre la variable aleatoria en x_i y la variable aleatoria $y_i - x_i'\beta$:

$$E [x_i (y_i - x_i'\beta)] = 0.$$

$$E [x_i (y_i - x_i'\beta)] = E (x_i u_i)$$

$$E [x_i (y_i - x_i'\beta)] = E [E (x_i u_i | x_i)]$$

$$E [x_i (y_i - x_i'\beta)] = E [x_i E (u_i | x_i)]$$

$$E [x_i (y_i - x_i'\beta)] = E (x_i * 0)$$

$$E [x_i (y_i - x_i'\beta)] = E (0)$$

$$E [x_i (y_i - x_i'\beta)] = 0.$$

Esto implica:

$$\text{Cov} (x_i, u_i) = E (x_i u_i) - E (x_i) E (u_i)$$

$$\text{Cov} (x_i, u_i) = 0 - E (x_i) * 0$$

$$\text{Cov} (x_i, u_i) = 0 - 0$$

$$\text{Cov} (x_i, u_i) = 0.$$

Por lo tanto, esta suposición implica ortogonalidad entre la variable aleatoria x_i y la variable aleatoria u_i .

Ofrecer condiciones adicionales sobre la distribución conjunta de x_i e y_i que hacen de β_0 la solución única para:

$$E [x_i (y_i - x_i'\beta)] = 0.$$

Las condiciones adicionales sobre la distribución conjunta de x_i e y_i que hacen de β_0 la solución única para este problema son:

- $E (u) = E (y - \beta_0 - \beta_1 x) = 0.$
- $\text{Cov} (x, u) = E (xu) - E (x) E (u) = x E (u) - E (x) * 0 = x * 0 = 0 - 0 = 0.$
- $r (x) = p$, es decir, el rango de x [$r (x)$] tiene que ser igual el número de variables independientes (p).

(b) Demostrar que el estimador MCO $\hat{\beta}$ es análogo a β_0 en el sentido de que es la única solución para:

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i'\beta)] = 0,$$

donde los momentos de muestra han reemplazado a los momentos poblacionales. Este es un ejemplo de un estimador de método de momentos, que construye estimadores de parámetros que equiparan los momentos empíricos con las contrapartes de la población.

El estimador de método de momentos podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 \\ \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 * n \\ \sum_{i=1}^n (x_i y_i - x_i x_i' \beta) &= 0 \\ \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \beta &= 0 \\ \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x_i' &= 0 \\ \beta \sum_{i=1}^n x_i x_i' &= \sum_{i=1}^n x_i y_i \\ \beta_0 &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i.\end{aligned}$$

Por otra parte, el estimador de mínimos cuadrados ordinarios es el argumento que minimiza la siguiente función de criterio:

$$\sum_{i=1}^n (y_i - x_i' \beta)^2,$$

Entonces, se tiene que la ecuación normal correspondiente a este problema:

$$\sum_{i=1}^n [x_i (y_i - x_i' \beta)] = 0$$

es idéntica a la ecuación de la estimación del método de momentos.

Por lo tanto, el estimador MCO $\hat{\beta}$ es análogo a β_0 , es decir, el estimador MCO es un estimador MM.

Ejercicio 18.

Considerar un modelo de regresión:

$$y_i = x_i' \beta + \epsilon_i, \quad i = 1, \dots, n,$$

donde ϵ_i es una variable aleatoria latente que se correlaciona con la variable explicativa en x_i . Dejar que los elementos de x_i incluyan la constante 1. Se supone un muestreo i.i.d. y que:

$$E(\epsilon_i) = 0$$

$$\text{Var}(\epsilon_i) = \sigma_0^2$$

y

$$E(x_i x_i') = D_{xx},$$

donde D_{xx} es una matriz definida positiva. Además, dejar que $\text{Cov}(x_i, \epsilon_i) = \rho$.

(a) Considerar los momentos de muestra de (x_i, y_i) : $\bar{x} \equiv \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{y} \equiv \frac{1}{n} \sum_{i=1}^n y_i$, $\frac{1}{n} X'X$, $\frac{1}{n} y'y$, $\frac{1}{n} X'y$. Encontrar sus valores esperados en términos de los parámetros desconocidos.

Las contrapartes de $E(\epsilon)$ y de $\text{Cov}(x, \epsilon) = 0$ en la muestra son:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \epsilon_i &= 0 \\ \frac{1}{n} \sum_{i=1}^n (y_i - x_i' \beta) &= 0 \\ \frac{1}{n} \sum_{i=1}^n y_i - \frac{1}{n} \sum_{i=1}^n x_i' \beta &= 0 \\ \frac{1}{n} \sum_{i=1}^n y_i &= \frac{1}{n} \sum_{i=1}^n x_i' \beta \\ \bar{y} &= \bar{x} \beta_0. \end{aligned}$$

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n x_i \epsilon_i &= 0 \\ \frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 \\ \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 * n \\ \sum_{i=1}^n (x_i y_i - x_i x_i' \beta) &= 0 \\ \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \beta &= 0 \\ \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x_i' &= 0 \\ \beta \sum_{i=1}^n x_i x_i' &= \sum_{i=1}^n x_i y_i \\ \beta_0 &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i. \end{aligned}$$

Por lo tanto, se tiene:

$$\begin{aligned} \bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i \\ \bar{y} &= E(y_i) \end{aligned}$$

$$\bar{y} = E(x_i' \beta + \epsilon_i)$$

$$\bar{y} = E(x_i' \beta) + E(\epsilon_i)$$

$$\bar{y} = \beta E(x_i') + 0$$

$$\bar{y} = \bar{x} \beta_0.$$

$$\bar{x} = \bar{y} \beta_0^{-1}.$$

$$\frac{1}{n} X'X = \frac{1}{n} \sum_{i=1}^n x_i x_i'$$

$$\frac{1}{n} X'X = E(x_i x_i')$$

$$\frac{1}{n} X'X = \beta_0^{-1} \frac{1}{n} \sum_{i=1}^n x_i y_i.$$

$$\frac{1}{n} y'y = \frac{1}{n} \sum_{i=1}^n y_i y_i$$

$$\frac{1}{n} y'y = E(y_i y_i)$$

$$\frac{1}{n} y'y = .$$

$$\frac{1}{n} X'y = \frac{1}{n} \sum_{i=1}^n x_i y_i.$$

$$\frac{1}{n} X'y = E(x_i y_i)$$

$$\frac{1}{n} X'y = \frac{1}{n} \sum_{i=1}^n x_i x_i' \beta_0.$$

(b) Suponer que hay K variables instrumentales, z_{ik} ($k = 1, \dots, K$) que no están correlacionadas con ϵ_i :

$$\text{Cov}(z_i, \epsilon_i) = 0,$$

pero correlacionado con x_i

$$E(z_i x_i') = D_{zx}.$$

donde D_{zx} tampoco es singular. Encontrar los valores esperados de los momentos de muestra adicionales $\frac{1}{n} \sum_{i=1}^n z_i, \frac{1}{n} Z'Z y, \frac{1}{n} Z'X$ en términos de los parámetros desconocidos.

(c) Al equiparar todos los momentos de la primera y de la segunda muestra arriba con sus valores de población, encontrar un estimador del método de momentos para todos los parámetros desconocidos. Mostrar, en particular, que el estimador de β_0 es el estimador VI $(Z'X)^{-1}Z'y$.

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y.$$

Ejercicio 19.

Encontrar el estimador de máxima verosimilitud para el parámetro desconocido considerando las siguientes distribuciones:

(a) $f(x, \theta) = \theta e^{-\theta x}$, con $x \geq 0$ y $\theta > 0$.

(b) $f(x, \theta) = \theta c^\theta x^{-(\theta+1)}$, con $x \geq c$ y $\theta > 0$.

(c) $f(x, \theta) = x\theta^{-2} e^{\frac{-x^2}{2\sigma^2}}$, con $x > 0$ y $\theta > 0$.

(d) $f(x, \theta) = \sigma^{-1} e^{\frac{-(x-\mu)}{\sigma}}$, con $x \geq \mu$, donde $\theta = (\mu, \sigma)$.

(e) $x_1, \dots, x_n$ de una distribución $u(\theta - \frac{1}{2}, \theta + \frac{1}{2})$.

(f) $x_1, \dots, x_n$ de $\mathcal{N}(\mu_1, \sigma^2)$ y $Y_1, \dots, Y_n$ i.i.d. de $\mathcal{N}(\mu_2, \sigma^2)$. Tener en cuenta que $\theta = (\mu_1, \mu_2, \sigma^2)$.

Ejercicio 20.

Suponer que X es una variable aleatoria continua con función de densidad de probabilidad $f(x, \theta_0)$. Se supone derivadas continuas de segundo orden.

(a) Demostrar que $E \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right] = 0$.

$$f_{\theta}(y) = \{f(x, \theta), \theta \in \Theta, \theta \in \mathbb{R}^p\}.$$

$$f(x, \theta) = f_{\theta}(x), \forall x \in X.$$

$$E \{ \log [f(x_i, \theta_0)] \} \geq E \{ \log [f(x_i, \theta)] \}.$$

$$\max_{\theta \in \Theta} E [l(\theta_0)], \text{ donde } l(\theta) = \log [f(x, \theta)].$$

Por lo tanto, se tiene:

$$E \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right] = 0.$$

(b) Suponiendo que $\text{Var} \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right]$ existe, mostrar que: $E \left[\frac{\partial^2 l(\theta_0 | x)}{\partial \theta \partial \theta'} \right] = -\text{Var} \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right]$.

$$E \left[\frac{\partial^2 l(\theta_0 | x)}{\partial \theta \partial \theta'} \right] = -E \left\{ \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right] \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right]' \right\}$$

$$E \left[\frac{\partial^2 l(\theta_0 | x)}{\partial \theta \partial \theta'} \right] = -\text{Var} \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right].$$