

Evaluación Domiciliaria N° 1: **Modelos para Datos en Panel.**

Parte I.

Una herramienta para estudiar, empíricamente, la relación entre los salarios de los trabajadores y sus características son las llamadas ecuaciones de ingresos o ecuaciones de Mincer (Mincer, 1974). Considerar el siguiente modelo:

$$\ln \text{salario}_{it} = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_{it} + \beta_3 \text{casado}_{it} + \beta_4 \text{sindicato}_{it} + \beta_5 \text{afro}_i + \beta_6 \text{hispano}_i + u_{it}, \quad (1)$$

donde $\ln$ salario es el logaritmo de los salarios por hora; educ son los años de educación formal; exper son los años de experiencia laboral; casado es una dummy que indica si el trabajador es casado; sindicato es una dummy que indica si el trabajador pertenece a un sindicato; afro e hispano son dummies que indican si el individuo es de origen afroamericano o hispano, respectivamente (la categoría base es blanco no hispano); y u es un término aleatorio que varía entre individuos y en el tiempo.

En este ejercicio, se va a estimar este modelo utilizando la base de datos nls8087.dta, que cuenta con información extraída de la National Longitudinal Survey (Youth Sample) para el período 1980-1987. La muestra comprende 545 hombres jóvenes (17 a 30 años de edad) que trabajan a tiempo completo y que, para 1980, ya habían finalizado su escolaridad.

(1) *Mostrar estadísticas descriptivas de las variables incluidas en el modelo teniendo en cuenta la estructura de panel (variabilidad total, between y within). Describirlas brevemente y discutir por qué, para ciertas variables, la variabilidad within es cero, mientras que la between no lo es.*

En la tabla 1, se pueden observar estadísticas descriptivas de las variables incluidas en el modelo (1) teniendo en cuenta la estructura de panel (variabilidad total, *between*, *within*). La cantidad de observaciones para calcular los estadísticos descriptivos de las variables del modelo en sus tres formas (*overall*, *between* y *within*) es 4.360 (individuos x años), en donde se calculan sobre un total de $n = 545$ individuos durante $T = 8$ años.

El promedio de **salario** de los trabajadores de la muestra en el período de estudio es de USD 5,92 por hora, oscilando entre USD 0,028 y USD 57,5. El promedio de esta variable para cada individuo en el tiempo (*between*) se situó en un rango entre USD 1,5 y USD 28,36, mientras que la desviación con respecto a su promedio (*within*) varió entre -16,42 y 35,07. Esto último indica que hay individuos que, en algunos períodos, obtuvieron un salario por debajo de su promedio en el período bajo análisis. Con respecto al desvío estándar, se observa que la variabilidad en el promedio de salario entre los individuos (*between*) es mayor a la observada en un individuo a lo largo del tiempo (*within*). Es decir, el salario tiene una mayor variabilidad entre individuos que la que tiene para un individuo a lo largo de los años.

El promedio de años de **educación** de los trabajadores de la muestra en el período de estudio es de 11,77 años, oscilando entre los 3 y 16 años.

El promedio de años de **experiencia** de los trabajadores de la muestra en el período de estudio es de 6,51 años, oscilando entre 0 y 18 años. El promedio de esta variable en el tiempo para cada individuo se situó entre 3,5 y 14,5 años de experiencia laboral, mientras que la desviación con respecto a su promedio (*within*) varió entre 3,01 y 10,01 años. Con respecto al desvío estándar, se observa que la variabilidad en el promedio de años de experiencia entre los individuos (*between*) es menor a la observada en un individuo a lo largo del tiempo (*within*). Es decir, los años de experiencia tienen una mayor variabilidad para un individuo a lo largo de los años que la que tienen entre individuos.

Para el caso de las variables binarias, se observa que, en promedio, en el período analizado, el 43,9% de los individuos están casados, el 24,4% está afiliado a un sindicato, el 11,6% son afroamericanos y el 15,6% son hispanoamericanos. En el caso de las variables **casado** y **sindicato**, la variabilidad es relativamente baja, tanto la observada en el promedio entre los individuos (*between*) como en un individuo a lo largo del tiempo (*within*), pero distinta de cero, por lo que hay individuos que cambiaron de estado a lo largo del período analizado.

Si una variable no varía con el tiempo, es decir, que mantiene su valor a lo largo del período analizado, la desviación estándar *within* será igual a cero, ya que la misma mide la variabilidad en un individuo a lo largo del tiempo y, lógicamente, si su valor es el mismo en cada período de tiempo, este indicador será cero. Las variables **educ**, **afro** e **hispano**, que indican los años de educación y la raza (características que no cambian en el tiempo para los individuos de la muestra), tienen una desviación estándar *within* igual a cero, ya que no varían en el tiempo. En estos mismos casos, la desviación estándar *between* no es igual a cero, ya que la misma mide la variabilidad entre los individuos y, por lo tanto, será distinta de cero; sólo será igual a cero cuando, en cada período de tiempo, la variable tome el mismo valor para cada individuo (como es el caso de la variable *años*).

Tabla 1. Estadísticas descriptivas de las variables del modelo (1).

Variable		Media	Desvío estándar	Mínimo	Máximo	Observaciones
salario	<i>Overall</i>	5,919175	3,202225	0,0279014	57,50431	N = 4.360
	<i>Between</i>	-	2,455819	1,503564	28,35696	n = 545
	<i>Within</i>	-	2,057397	-16,42349	35,06653	T = 8
educ	<i>Overall</i>	11,76697	1,746181	3	16	N = 4.360
	<i>Between</i>	-	1,747585	3	16	n = 545
	<i>Within</i>	-	0	11,76697	11,76697	T = 8
exper	<i>Overall</i>	6,514679	2,825873	0	18	N = 4.360
	<i>Between</i>	-	1,654918	3,5	3,5	n = 545
	<i>Within</i>	-	2,291551	3,014679	10,01468	T = 8
casado	<i>Overall</i>	0,4389908	0,4963208	0	1	N = 4.360
	<i>Between</i>	-	0,3766116	0	1	n = 545
	<i>Within</i>	-	0,3236137	-0,4360092	1,313991	T = 8
sindicato	<i>Overall</i>	0,2440367	0,4295639	0	1	N = 4.360
	<i>Between</i>	-	0,3294467	0	1	n = 545
	<i>Within</i>	-	0,2759787	-0,6309633	1,119037	T = 8
afro	<i>Overall</i>	0,1155963	0,3197769	0	1	N = 4.360
	<i>Between</i>	-	0,320034	0	1	n = 545
	<i>Within</i>	-	0	0,1155963	0,1155963	T = 8
hispano	<i>Overall</i>	0,1559633	0,3628622	0	1	N = 4.360
	<i>Between</i>	-	0,3631539	0	1	n = 545
	<i>Within</i>	-	0	0,1559633	0,1559633	T = 8

Fuente: Elaboración propia.

(2) Estimar la ecuación (1) por Pooled OLS (POLS). Interpretar estadística y económicamente los coeficientes obtenidos. Explicar por qué es muy posible que la presencia de heterogeneidad no observable a nivel de trabajador haga que las estimaciones anteriores sean inconsistentes. ¿Por qué el modelo Within con efectos fijos por trabajador permitiría resolver este problema?

En esta estimación por POLS del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *hispano*, que no es estadísticamente significativa. En la tabla 2, se muestran los resultados de esta estimación (conjuntamente con las estimaciones *between*, *within*, primeras diferencias y efectos aleatorios), que expresan que, en promedio y manteniendo todo lo demás constante:

- Al aumentar en un año la educación del individuo, el salario por hora de los trabajadores aumenta en un 10,4%.
- Al aumentar en un año la experiencia laboral del individuo, el salario por hora aumenta en un 5%.
- Un individuo casado tiene un salario por hora un 11,3% mayor que uno que no está casado.
- Un individuo afiliado a un sindicato tiene un salario por hora un 18,4% mayor que uno que no está afiliado.
- Un hombre afroamericano tiene un salario por hora un 14,2% menor que un individuo blanco.
- Un individuo hispano tiene un salario por hora un 1,3% mayor que un individuo no hispano (esta variable no es estadísticamente significativa).

A pesar de que los signos de los coeficientes obtenidos son consistentes con lo que indica la literatura económica relacionada, es muy posible que la presencia de heterogeneidad no observable a nivel trabajador haga que las estimaciones anteriores sean sesgadas e inconsistentes. Un problema que surge, regularmente, en los estudios que evalúan la relación entre estas variables es que es difícil aislar el impacto causal de un año adicional de educación en los salarios. El retorno a un año adicional de educación puede estar siendo distorsionado por el efecto de otros factores relevantes, pero no observados, que pueden estar relacionados con los años de educación. Por ejemplo, es muy probable que la habilidad, la inteligencia o el talento de los individuos estén relacionados con los salarios que reciben y, al mismo tiempo, con el nivel de escolaridad alcanzado. Tanto la habilidad como otros factores característicos de los individuos no son observables y, por lo tanto, ignorar el vínculo mencionado conduciría a estimaciones inconsistentes y a inferencias no válidas con respecto al efecto causal de los años de educación.

El modelo *within* con efectos fijos por trabajador permitiría resolver este problema porque, al “eliminar” el efecto de la heterogeneidad inobservable (fuente potencial de sesgo) que afecta a los regresores del modelo, se obtienen estimadores insesgados y consistentes para evaluar la relación entre las variables analizadas.

(3) *Estimar, nuevamente, el modelo 1 mediante los siguientes estimadores alternativos: between, within, primeras diferencias y efectos aleatorios. Interpretar cuidadosamente el coeficiente estimado de la variable *exper* para cada uno de los modelos. Para la interpretación, prestar especial atención a cuál es la dimensión del panel (corte transversal o longitudinal) relevante para identificar el efecto en cada caso. Luego, comentar por qué, en el modelo de efectos fijos y de primeras diferencias, se omiten las variables *educ*, *afro* e *hispano*.*

En estas cuatro estimaciones alternativas (*between*, *within*, primeras diferencias y efectos aleatorios) del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *hispano*, que no es estadísticamente significativa en ninguna de estas estimaciones. En la tabla 2, se muestran los resultados de estas estimaciones (conjuntamente con los resultados de la estimación por POLS).

La variable *exper* resulta estadísticamente significativa en las cuatro estimaciones y, en todos los casos, se observa una relación positiva entre esta variable y los salarios. La interpretación bajo cada modelo, en promedio y manteniendo todo lo más constante, es la siguiente:

- *Between*: Un año adicional de experiencia laboral del individuo *en comparación con la experiencia laboral promedio del resto de los individuos* aumenta el salario por hora en un 2,8%.
- *Within*: Un año adicional de experiencia laboral del individuo *en comparación con la propia experiencia laboral promedio del individuo* aumenta el salario por hora en un 6%.
- *Primeras Diferencias*: Un año adicional de experiencia laboral de un año *en comparación a otro año* aumenta el salario por hora en un 6,5%.

- Efectos Aleatorios: Un año adicional de experiencia laboral del individuo *en comparación con la propia experiencia laboral promedio del individuo* aumenta el salario por hora en un 5,8%.

En el modelo de efectos fijos y en el de primeras diferencias, se omiten las variables *educ*, *afro* e *hispano* porque son variables que no varían con el tiempo, es decir, que mantienen su valor para cada individuo a lo largo del período analizado, por lo que no aparecen en estos modelos por ser iguales a cero.

En el modelo *within*, se usan las desviaciones de las variables de su promedio a través del tiempo y, en el caso de las variables mencionadas, su valor en cada momento *t* es igual a su promedio, es decir, su desvío respecto de la media es igual a cero.

En el modelo de primeras diferencias, sucede algo similar, sólo que, en lugar de usar desvíos de las variables respecto de su promedio a través del tiempo, se utiliza la diferencia entre los valores de las variables en *t* y en *t-1*, por lo cual, en este modelo, también se eliminan las variables mencionadas, que no varían con el tiempo para un mismo individuo.

En el caso de la variable *educ*, que hace referencia a los años de educación formal del individuo, en esta muestra, no existen variaciones en el tiempo, ya que comprende a hombres jóvenes que trabajan a tiempo completo y que, para 1980, ya habían finalizado su escolaridad, por lo que no siguieron educándose formalmente en el período de análisis (1980-1987).

En el caso de las variables *afro* e *hispano*, son dummies que hacen referencia a características innatas del individuo, que, sin duda, no varían con el tiempo.

Tabla 2. Estimaciones del modelo (1).

Variables	(1) POLS	(2) <i>Between</i>	(3) <i>Within</i>	(4) Primeras Diferencias	(5) Efectos Aleatorios
<i>educ</i>	0,104*** (0,005)	0,091*** (0,011)	- -	- -	0,108*** (0,009)
<i>exper</i>	0,050*** (0,003)	0,028** (0,011)	0,060*** (0,003)	0,065*** (0,007)	0,058*** (0,003)
<i>casado</i>	0,113*** (0,016)	0,142*** (0,041)	0,061*** (0,018)	0,043* (0,023)	0,076*** (0,017)
<i>sindicato</i>	0,184*** (0,017)	0,259*** (0,046)	0,084*** (0,019)	0,042** (0,020)	0,110*** (0,018)
<i>afro</i>	-0,142 (0,024)	-0,141*** (0,049)	- -	- -	-0,141*** (0,048)
<i>hispano</i>	0,013 (0,021)	0,010 (0,043)	- -	- -	0,016 (0,043)
constante	0,023 (0,063)	0,284 (0,178)	1,212*** (0,017)	- -	-0,048 (0,111)
Observaciones	4.360	4.360	4.360	3.815	4.360
<i>R</i> ²	0,184	0,169	0,051	0,025	0,178
Número de id	-	545	545	-	545

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(4) A partir de las estimaciones anteriores:

a. Para cada uno de los estimadores del inciso anterior, explicar cuáles son los supuestos que se requieren para consistencia.

Los supuestos que se requieren para consistencia de los estimadores del inciso anterior son:

➤ POLS:

Para que el estimador sea consistente, se requiere del supuesto (1) $E(x'_{it}u_{it})=0$, es decir, exogeneidad contemporánea.

Cuando $\mu_i=0$, es decir, en ausencia de heterogeneidad inobservable, (2) $E(x'_{it}\varepsilon_{it})=0$ es condición suficiente para la consistencia del estimador.

Cuando $\mu_i \neq 0$, es decir, con presencia de heterogeneidad inobservable, el término de error estará compuesto por dos componentes ($u_{it}=\mu_i + \varepsilon_{it}$), por lo que, para la consistencia del estimador, se requerirá, además de (2), que la heterogeneidad inobservable sea ortogonal a todos los elementos de x_{it} , es decir, (3) $E(x'_{it}\mu_i)=0$.

➤ Within y Primeras Diferencias:

Para que el estimador sea consistente, se requiere del supuesto (4) $E(x'_{is}\varepsilon_{it})=0$, s, $t=1, \dots, T$, es decir, exogeneidad estricta, un supuesto más fuerte que el supuesto (2), que ya no es suficiente para garantizar estimadores consistentes.

➤ Between y Efectos Aleatorios:

Para que el estimador sea consistente, se requiere del supuesto (3) $E(x'_{it}\mu_i)=0$ (ortogonalidad entre los regresores y la heterogeneidad inobservable) y (4) $E(x'_{is}\varepsilon_{it})=0$, s, $t=1, \dots, T$ (exogeneidad estricta).

En la tabla 3, se resumen las condiciones descriptas para la consistencia de los estimadores de los modelos para datos en panel.

Tabla 3. Condiciones para consistencia de los estimadores.

Condiciones para consistencia	(1)	(2)	(3)	(4)	(5)
	POLS	<i>Between</i>	<i>Within</i>	Primeras Diferencias	Efectos Aleatorios
(1) Exogeneidad contemporánea $E(\mathbf{x}_{it}'\mathbf{u}_{it})=0$	X				
(2) Exogeneidad contemporánea (*) $E(\mathbf{x}_{it}'\boldsymbol{\varepsilon}_{it})=0$	X				
(3) Ortogonalidad entre regresores y heterogeneidad inobservable $E(\mathbf{x}_{it}'\boldsymbol{\mu}_i)=0$	X	X			X
(4) Exogeneidad estricta $E(\mathbf{x}_{is}'\boldsymbol{\varepsilon}_{it})=0$ (**)		X	X	X	X

(*) Esta condición es suficiente para la consistencia de POLS cuando $\mu_i=0$. (**) Esta condición es suficiente para la consistencia de *Between* cuando $\mu_i=0$. Fuente: Elaboración propia.

b. Implementar un test para evaluar la hipótesis nula de ausencia de efectos fijos. Proveer una interpretación del resultado.

Teniendo en cuenta que el modelo POLS es un modelo restringido con respecto al modelo de efectos fijos, en donde se asume que existe un intercepto común para todos los individuos de la muestra, puede realizarse una prueba F para evaluar la significancia estadística de los efectos fijos.

La hipótesis nula es $\mu_i=0, \forall i$, es decir, que el intercepto es común para todos los individuos de la muestra y, por lo tanto, que no existen efectos fijos asociados a cada individuo. Si la prueba se rechaza, se podría afirmar que el modelo de efectos fijos es preferible al modelo POLS.

En esta muestra, se obtiene el siguiente resultado:

$F(544, 3812)=10,08$; p-valor= 0,0000.

Por lo tanto, dado que el p-valor es muy pequeño, se rechaza la hipótesis nula y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que existen efectos fijos asociados a cada individuo y, en consecuencia, el modelo de efectos fijos es preferible al modelo POLS.

c. Implementar un test de Hausman para comparar los estimadores de efectos fijos y de efectos aleatorios y comentar los resultados obtenidos.

El test de Hausman evalúa la posible correlación entre el componente de error individual μ_i y las variables exógenas del modelo. Si, efectivamente, existe esta correlación, entonces, no incluir μ_i en el modelo producirá un sesgo de variable omitida

en los coeficientes de las variables explicativas. Hausman demostró que la diferencia entre los coeficientes de efectos fijos y de efectos aleatorios ($\hat{\beta}_{EF} - \hat{\beta}_{EA}$) puede ser usada para probar la hipótesis nula de que μ_i y las variables explicativas no están correlacionadas.

La hipótesis nula de la prueba de Hausman es que los estimadores de efectos aleatorios y de efectos fijos no difieren sustancialmente y, en consecuencia, bajo H_0 , tanto el estimador de efectos fijos como el de efectos aleatorios son consistentes, mientras que, bajo H_a , sólo el estimador de efectos fijos es consistente.

En esta muestra, se obtiene el siguiente resultado:

$$\chi^2 (3) = 22,69; \quad p\text{-valor} = 0,0000.$$

Por lo tanto, dado que el p-valor es muy pequeño, se rechaza la hipótesis nula y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que los efectos individuales están correlacionados con las variables explicativas y, en consecuencia, el modelo de efectos fijos es preferible al modelo de efectos aleatorios.

Parte II.

Este ejercicio se basa en el artículo de Rockoff, J. (2004) “The Impact of Individual Teachers on Student Achievement: Evidence from Panel Data” (American Economic Review, 94(2), pp. 247-252). El objetivo es ilustrar con un ejemplo cómo los datos en panel permiten responder a preguntas que no podrían responderse con otro tipo de datos. Como primera consigna, se pide leer, detenidamente, el artículo de Rockoff (2004). Luego, responder las siguientes preguntas.

(1) *Explicar cuál es la crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes. ¿De qué se vale Rockoff para superar esa limitación de la literatura previa?*

El trabajo de Rockoff (2004) presenta evidencia sobre los efectos que tiene la calidad de los docentes en el rendimiento académico de los estudiantes, utilizando un análisis de datos en panel. El autor, por un lado, busca identificar la varianza de la distribución de los efectos fijos del maestro, la cual captura la heterogeneidad de la fuerza laboral docente, y, por otro lado, muestra que elevar la calidad del maestro mejora los resultados de los estudiantes.

La crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes refiere a la calidad de los datos utilizados. La información que recogen no permite obtener datos coincidentes entre alumnos y docentes, en los que tanto el rendimiento del alumno como el de los maestros se observe en múltiples años. Este tipo de datos es necesario para la correcta identificación de los efectos fijos del maestro. Sin embargo, no está disponible para los investigadores, en gran parte porque los distritos escolares no utilizan datos en panel para fines de evaluación y, generalmente, la información utilizada en la literatura proviene, directamente, de los distritos escolares o de instituciones de investigación que han recopilado estos datos. Así, los trabajos previos a Rockoff (2004) presentan estimaciones inconsistentes, ya que, al no considerar las características inobservables relevantes para el resultado de las pruebas, sobreestiman el efecto de las características observables en el logro de los estudiantes.

Para poder superar esa limitación de la literatura previa, Rockoff (2004) utiliza un conjunto de datos en panel con información de puntajes de las pruebas de los estudiantes y de la asignación de maestros en las clases, para estimar, con mayor precisión, cuánto afectan los maestros al rendimiento de los estudiantes. Los datos sobre los puntajes permiten enfocarse en las diferencias en el desempeño de un mismo alumno con diferentes maestros y, así, distinguir la variación en la calidad del maestro de la variación en las habilidades cognitivas de los estudiantes y otras características. Observar al mismo maestro en varias aulas le permite diferenciar la calidad del maestro de factores como el tamaño de la clase. Vale aclarar que la identificación de los efectos fijos es posible gracias a que se observa a un mismo maestro dando clases a estudiantes en diferentes cursos.

Rockoff (2004) dispone de un panel con datos sobre estudiantes y maestros de dos distritos contiguos ubicados en un solo condado de New Jersey entre 1989 y 2001, evaluados entre pre-escolar y 6to. grado con pruebas estandarizadas y donde es posible identificar qué maestro da clases a cada estudiante. Esto último permite identificar el

efecto de cada maestro en sus alumnos y, al mismo tiempo, al contar con un panel, puede controlar por efectos fijos a nivel de cada estudiante para tener en cuenta el valor agregado que proporciona el maestro, lo cual no era posible realizar con los datos que disponían los estudios previos, cuestionados por el autor. Además, la longitud del panel posibilita que incluya la experiencia del docente como una variable explicativa.

(2) *A continuación, se reproduce el modelo propuesto por Rockoff (2004):*

$$A_{it} = \alpha_i + \gamma X_{it} + \sum_j [\theta^{(j)} + f(\text{Exp}_t^{(j)}) + \eta C_t^{(j)}] D_{it}^{(j)} + \sum_s \pi_{st} S_{it}^{(s)} + \varepsilon_{it}.$$

Explicar qué tipo de variables podrían estar siendo capturadas por el término α_i y por qué el autor incorpora el término no lineal $f(\text{Exp}_t^{(j)})$.

El modelo propuesto por Rockoff (2004) consiste en estimar el efecto sobre el puntaje de la prueba del estudiante i en el año t (A_{it}) de: efectos fijos del estudiante (α_i), características observables de los estudiantes que varían con el tiempo (X_{it}), efecto fijo del maestro ($\theta^{(j)}$), experiencia del docente ($\text{Exp}_t^{(j)}$), características observables del aula ($C_t^{(j)}$) y efecto del año escolar (π_{st}), en donde ε_{it} es el término de error del modelo. Las variables $D_{it}^{(j)}$ y $S_{it}^{(s)}$ son indicadoras de si el estudiante tuvo, respectivamente, al maestro j en la escuela s durante el año t .

Las variables que podrían estar siendo capturadas por el término α_i (características no observables de los estudiantes que podrían estar correlacionadas con el resultado de las pruebas) son: las capacidades cognitivas, las características socioeconómicas, la inteligencia, la educación en el hogar, la habilidad en general, la habilidad particular para la comprensión de textos y para las matemáticas, las motivaciones personales, entre otras cosas.

El autor incorpora el término no lineal $f(\text{Exp}_t^{(j)})$ para estimar el efecto de la experiencia de los docentes en las pruebas de los estudiantes. Lo hace de manera no lineal porque la experiencia y el año t son colineales para los maestros y, por lo tanto, la identificación de los efectos fijos de estos y de los efectos de la experiencia requiere una suposición con respecto a la forma de $f(\text{Exp}_t^{(j)})$. El autor asume que la experiencia adicional del maestro no afecta los resultados de las pruebas de los estudiantes después de un cierto punto de corte $\overline{\text{Exp}}$, lo cual es respaldado por investigaciones previas que sugieren que cualquier ganancia de experiencia se logra en los primeros años de enseñanza (Rivkin *et al.*, 2001). Al suponer que la experiencia no impacta después de alcanzados los 10 años, el autor acota el efecto de la experiencia y asume que éste es representable por un polinomio cúbico.

Parte III (Bonus).

El uso de efectos fijos cuando se trabaja con datos de panel ¿resuelve por completo el problema de endogeneidad? ¿Por qué? ¿Qué otro método se podría usar? Se puede encontrar una pista en el paper de Cornwell y Trumbull (1994) que se vio en clase.

En primer lugar, se dice que existe endogeneidad cuando hay correlación entre los regresores del modelo y el término de error, por lo que no se cumple el supuesto clásico de exogeneidad estricta:

$$E(u_i|x_i) \neq 0.$$

La existencia de endogeneidad puede darse por varias razones:

- Autocorrelación de los errores.
- Errores de medición.
- Variables omitidas.
- Simultaneidad.

Dadas las diversas razones por las cuales puede haber endogeneidad, no existe una única solución a este problema. Por lo tanto, cuando se trabaja con datos de panel, al considerarse sólo el caso de endogeneidad causada por la “heterogeneidad inobservable” (que puede ser considerada como una variable omitida), la utilización de efectos fijos no resuelve por completo el problema de endogeneidad, en el caso de que existan otras causas.

En el contexto de datos de panel, la utilización de efectos fijos es útil para resolver el problema de endogeneidad. Los datos de panel combinan cortes transversales (información de varios individuos en un momento dado) durante varios períodos de tiempo. El disponer de datos de panel constituye una ventaja porque se dispone de una mayor cantidad de datos y se puede hacer un seguimiento de cada individuo a través del tiempo, pero, al mismo tiempo, un inconveniente porque, si todas las cualidades relevantes del individuo no son observables, entonces, los errores individuales estarán correlacionados con los regresores y los estimadores de OLS serán inconsistentes.

Si no se disponen de todas las variables de influencia, entonces, $E(x'_{it}u_{it}) \neq 0$, es decir, los regresores no son ortogonales al término de error (presencia de heterogeneidad inobservable). En este caso, POLS será inconsistente y la utilización de efectos fijos permitiría resolver este problema, al incorporar variables *dummy* por individuo.

Sin embargo, cuando el modelo presenta variables independientes endógenas, los estimadores de OLS serán inconsistentes, ya que $E(x'_i u_i) \neq 0$, es decir, no existe ortogonalidad entre los regresores y el término de error. Como se mencionó anteriormente, esto puede ocurrir cuando las variables explicativas están sujetas a errores de medición, cuando hay variables explicativas relevantes que se han omitido en el modelo o cuando existe simultaneidad.

Para resolver este problema de endogeneidad, se utiliza el método de variables instrumentales (2SLS o 3SLS), cuando se dispone de “buenos instrumentos”, es decir,

variables que no pertenecen al modelo, no están correlacionadas con el término de error y están correlacionadas con las variables explicativas endógenas, condicionando por las variables explicativas exógenas.

En el *paper* de Cornwell y Trumbull (1994), se utiliza una estrategia empírica que permite resolver dos fuentes de endogeneidad: presencia de heterogeneidad inobservable y simultaneidad. Los autores presentan evidencia respecto de que el efecto de la habilidad del sistema de justicia criminal para disminuir el crimen es mucho más débil que lo que indicaban estudios previos. La utilización de datos de panel, donde la unidad de observación es el condado, permite a los autores controlar por aquellas características específicas a nivel condado que son inobservables y que podrían estar relacionadas con las variables de justicia criminal del modelo que estiman. Esto es un avance respecto de la literatura previa que ignoraba esta fuente de endogeneidad al hacer estimaciones de tipo *cross-section*, concentrándose en resolver la endogeneidad convencional (por simultaneidad), que surge de la dependencia entre la probabilidad de arresto o el tamaño de la fuerza policial con la tasa de criminalidad. Concretamente, los autores utilizan una estrategia empírica que combina el uso de variables instrumentales para resolver la endogeneidad proveniente de la simultaneidad y la utilización de datos de panel para resolver la endogeneidad que surge de la presencia de heterogeneidad inobservable, condicionando por los efectos del condado en las estimaciones.

Referencias.

Cornwell, C. y Trumbull, W. N. (1994). Estimating the Economic Model of Crime with Panel Data. *The Review of Economics and Statistics*, 76(2), 360-366. Recuperado de <https://www.jstor.org/stable/2109893>

Rockoff, J. E. (2004). The Impact of Individual Teachers on Student Achievement Evidence from Panel Data. *The American Economic Review*, 94(2), 247-252. Recuperado de <https://www.jstor.org/stable/3592891>