

Evaluación Domiciliaria N° 2: **Selección Muestral y Censura.**

Modelo para el Salario Horario.

Considerar un modelo para el logaritmo del ingreso laboral horario en función de la edad y su cuadrado, junto con una serie de dummies por máximo nivel educativo alcanzado.

$$lilaho_i = \beta_0 + \beta_1 edad_i + \beta_2 edad_i^2 + \beta_3 pric_i + \beta_4 seci_i + \beta_5 secc_i + \beta_6 supi_i + \beta_7 supc_i + u_i. \quad (1)$$

(1) *Estimar los parámetros del modelo mediante el método de MCO. Dar una interpretación económica de los resultados y explicar, brevemente, sobre la inconsistencia de sus estimaciones como consecuencia de un posible sesgo de selección en la muestra utilizada.*

En esta estimación por MCO del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *pric*, que es estadísticamente significativa al 5%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación de Heckman en dos etapas y de la estimación de Heckman por máxima verosimilitud), que expresan que, en promedio y manteniendo todo lo demás constante:

- Al aumentar en un año la edad de la mujer, el ingreso laboral horario varía en 100 (0,041 - 0,00072 edad) %. Se puede observar que el efecto parcial de la edad comienza a ser negativo a partir de, aproximadamente, los 57 años de edad¹.
- Considerando que los retornos a la educación son iguales a 100 ($e^{\beta_j} - 1$) %, con $j = 3, 4, 5, 6, 7$, y comparado con una mujer con primaria incompleta: una mujer con primaria completa, secundaria incompleta, secundaria completa, superior incompleta y superior completo tiene un ingreso laboral horario un 12,4%, 41,6%, 93,9%, 130,3% y 241,4% mayor, respectivamente. Se puede observar que la brecha salarial por hora entre niveles educativos aumenta con la educación.

Debido a la existencia de un sesgo de selección en la muestra utilizada, que acontece cuando las muestras no son “aleatorias”, es decir, que no representan, adecuadamente, la población que se desea estudiar, es posible que las estimaciones sean inconsistentes. El caso de muestras de participantes del mercado laboral no es un caso de una selección aleatoria, sino de la autoselección de los individuos derivada de un proceso de maximización de utilidad. Al mismo tiempo, como el estudio sólo considera a los individuos que trabajan, se obtiene una muestra incompleta de la población (“autoseleccionada” de acuerdo con la decisión de los individuos por educarse), lo cual conduce a conclusiones erróneas (estimaciones inconsistentes y sesgadas) del efecto de la educación sobre el ingreso laboral. En este caso, al haber una “sobrerrepresentación” de la población educada en la muestra, se tiende a subestimar el efecto de la educación

¹ $\frac{\partial E(lilaho_i | x_1, \dots, x_p)}{\partial edad_i} = 0 \Leftrightarrow \beta_1 + 2\beta_2 edad_i = 0 \Leftrightarrow 2\beta_2 edad_i = -\beta_1 \Leftrightarrow edad_i^* = \frac{-\beta_1}{2\beta_2} = \frac{-0,041214}{2(-0,0003595)} = \frac{-0,041214}{-0,000719} \cong 57,32$; donde x_k , $k = 1, \dots, p$, son las variables independientes del modelo (1).

sobre el ingreso laboral, lo cual se puede observar en la menor magnitud (en comparación con las siguientes estimaciones) de los coeficientes estimados de las *dummies* por máximo nivel educativo alcanzado.

(2) Estimar, nuevamente, la ecuación de regresión del punto anterior implementando el método de Heckman en dos etapas utilizando a la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años como regresores de la ecuación de selección. Justificar cada una de las etapas del método indicando los supuestos en los que se basa.

En esta estimación de Heckman en dos etapas del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman por máxima verosimilitud).

Para resolver el problema de selección muestral, Heckman (1979) propone tratar el sesgo de selección como un problema de variable relevante omitida. En particular, al estimar por MCO usando la muestra seleccionada, λ (.) es una variable omitida. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman por máxima verosimilitud).

Para computar el estimador de Heckman en dos etapas, se consideran los siguientes supuestos del modelo de selección: (1) (y_{1i}, x_{1i}) se observa sólo si $y_{2i} = 1$; (2) (y_{2i}, x_{2i}) se observa para todos los individuos; (3) (u_{1i}, u_{2i}) son independientes de x_{2i} y tienen media cero (exogeneidad estricta); (4) $u_{2i} \sim \mathcal{N}(0, \sigma_2^2)$; (5) $E(u_{1i} | u_{2i}) = \gamma u_{2i}$; y se consideran las siguientes ecuaciones:

- Ecuación de regresión: $y_{1i} = x_{1i}'\beta_1 + u_{1i}$.
- Ecuación de selección: $y_{2i}^* = x_{2i}'\beta_2 + u_{2i}$.
- Variable observada: $y_{2i} = 1 (y_{2i}^* > 0)$.

En la primera etapa del método, se estima la ecuación de selección mediante un modelo Probit. En el caso del modelo (1), se estima una ecuación de participación en el mercado laboral, donde la variable dependiente es binaria, del tipo “participa” o “no participa”, en términos de ser o no ser observado un ingreso laboral (mujeres que estarán en la muestra). Esta ecuación se interpreta como la forma reducida de un modelo en el cual la decisión de participación en el mercado laboral (que es una variable binaria) depende de características personales y del nivel educativo del individuo y, a su vez, permite estimar la probabilidad predicha de la participación en el mercado laboral de una mujer con ciertas características, lo cual permite obtener una estimación consistente para λ . Se supone que el error de la ecuación de selección se distribuye bajo una distribución normal con media cero y varianza constante σ^2 .

En la segunda etapa del método, se estima por MCO una ecuación del logaritmo del ingreso laboral horario como función de la edad, del nivel educativo y de λ (probabilidad de participar en el mercado laboral). Éste es un modelo de determinación de ingresos a la Mincer, corregido por la presencia de sesgo de selección (λ).

Este método proporciona estimadores consistentes y asintóticamente normales, por lo que los métodos estándar de inferencia funcionan correctamente.

(3) *Implementar un test que ponga a prueba la hipótesis de ausencia de selección muestral indicando, claramente, las hipótesis, el estadístico de prueba, su distribución asintótica y el resultado del test. ¿Cuál es la utilidad de dicho test?*

La presencia de sesgo de selección puede ser evaluada mediante un test de significatividad de λ , donde se evalúa $\gamma^* \equiv \gamma\sigma_2$, con σ_2 desvío estándar del estimador de la ecuación de selección. Ya que σ_2 es mayor que cero, se puede evaluar la presencia de sesgo de selección mediante las siguientes hipótesis:

$$H_0: \gamma^* = 0; \quad H_a: \gamma^* \neq 0.$$

Bajo la hipótesis nula, γ^* es igual a cero, indicando que no existe sesgo de selección, en tanto que, bajo la hipótesis alternativa, γ^* es distinto de cero, indicando que existe sesgo de selección. Así, bajo H_0 , el estadístico de prueba es $\frac{\hat{\gamma}^*}{SE(\hat{\gamma}^*)} \rightarrow^d \mathcal{N}(0, 1)$, que tiene una distribución asintótica normal con media igual a cero y varianza constante igual a uno.

La utilidad de este test es que permite determinar si los errores estándar computados por MCO en la segunda etapa son correctos. Por lo tanto, considerando la segunda etapa, bajo la hipótesis nula, los errores serán homocedásticos, en tanto que, en el caso de rechazar la hipótesis nula, los errores serán heterocedásticos, ya que la varianza se altera por la censura/el truncamiento.

En el caso del modelo (1), ya que el p-valor es muy pequeño, se rechaza la hipótesis de nula (ver tabla 1) y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que existe sesgo de selección y que, por lo tanto, λ es estadísticamente significativo para explicar el logaritmo del ingreso laboral horario, es decir, la estimación por MCO es sesgada.

(4) *Computar el estimador de Heckman por máxima verosimilitud e indicar cuáles son los supuestos sobre los que se construye dicho estimador. Discutir sus ventajas y desventajas con respecto al método en dos etapas.*

En esta estimación de Heckman por máxima verosimilitud del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman en dos etapas).

Para computar el estimador de Heckman por máxima verosimilitud, se consideran las mismas ecuaciones mencionadas anteriormente y los mismos supuestos, excepto el supuesto (4), que se reemplaza por un supuesto más fuerte para poder computar la verosimilitud, que es distribución normal bivariada de los errores:

$$\begin{bmatrix} u_{1i} \\ u_{2i} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1 \\ \rho\sigma_1 & 1 \end{bmatrix} \right).$$

Una de las ventajas del estimador de Heckman por máxima verosimilitud con respecto al método en dos etapas es que es eficiente, considerando que la segunda etapa de este último, debido a la selección, es heterocedástica.

Sin embargo, si bien el estimador por máxima verosimilitud no tendría este problema, tiene dificultades prácticas de implementación: en primer lugar, requiere de supuestos demasiado estrictos sobre la distribución de los errores, ya que, mientras que, en el método en dos etapas, se requiere el supuesto de normalidad sobre u_{2i} , en el método por máxima verosimilitud, también se requiere este supuesto sobre u_{1i} ; la función de verosimilitud es complicada de calcular; y existen problemas de convergencia en la maximización numérica.

Tabla 1. Estimaciones del modelo (1).

		(1)	(2)	(3)
Variable		MCO	Heckman en dos etapas	Heckman por máxima verosimilitud
lilaho	edad	0,041*** (0,003)	0,064*** (0,007)	0,043*** (0,003)
	edad2	-0,000*** (0,000)	-0,001*** (0,000)	-0,000*** (0,000)
	pric	0,117** (0,046)	0,169*** (0,046)	0,122*** (0,042)
	seci	0,348*** (0,044)	0,440*** (0,048)	0,357*** (0,040)
	secc	0,662*** (0,045)	0,790*** (0,055)	0,674*** (0,042)
	supi	0,834*** (0,045)	0,973*** (0,057)	0,847*** (0,042)
	supc	1,228*** (0,044)	1,395*** (0,060)	1,244*** (0,041)
	_cons	4,396*** (0,069)	3,676*** (0,199)	4,328*** (0,078)
	edad	-	0,113*** (0,008)	0,112*** (0,008)
	edad2	-	-0,001*** (0,000)	-0,001*** (0,000)
trabaja	pric	-	0,2851*** (0,099)	0,285*** (0,099)
	seci	-	0,554*** (0,095)	0,553*** (0,099)
	secc	-	0,782*** (0,103)	0,784*** (0,103)
	supi	-	0,862*** (0,106)	0,869*** (0,105)
	supc	-	1,251*** (0,106)	1,254*** (0,106)
	asiste	-	-0,088 (0,054)	-0,096* (0,054)
	hijos12	-	-0,048** (0,021)	-0,047** (0,021)
	_cons	-	-1,790*** (0,174)	-1,774*** (0,174)
	lambda	-	0,618*** (0,158)	-
	/athrho	-	-	0,100* (0,060)
/mills	/lnsigma	-	-	-0,537*** (0,006)
	Observaciones	13,522	14,837	14,837
	R ²	0,341	-	-

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

Modelo para las Horas Trabajadas.

(5) Considerar un modelo para las horas trabajadas en función de la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años. Estimar los parámetros utilizando un modelo Tobit y compararlos con la estimación de MCO. Discutir sobre lo adecuado de una y otra estrategia focalizando el análisis en el tipo de variable dependiente de este modelo.

$$hstrt_i = \beta_0 + \beta_1 edad_i + \beta_2 edad_i^2 + \beta_3 pric_i + \beta_4 secc_i + \beta_5 secc_i + \beta_6 sup_i + \beta_7 sup_i + \beta_8 asiste_i + \beta_9 hijos12_i + u_i. \quad (2)$$

En estas estimaciones (MCO y Tobit) del modelo (2), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 2, se muestran los resultados de estas estimaciones.

Para discutir lo adecuado de una y otra estrategia, se debe considerar un rasgo inherente a la variable dependiente (horas trabajadas), el cual es la censura. La muestra excluye información de aquellas mujeres que, por ejemplo, poseen un elevado ingreso laboral de reserva y que, por lo tanto, no participan en el mercado de trabajo, lo cual configura un sesgo de selección.

La estimación por MCO impone una relación lineal entre la variable dependiente censurada y las variables explicativas, pero el hecho de que la variable dependiente latente (inobservable) siga un modelo lineal no implica que la variable dependiente censurada (observada) siga este mismo modelo. En concreto, la variable censurada será una transformación no lineal de la variable latente y, por lo tanto, seguirá un modelo no lineal. Así, la estimación por MCO supone un problema de especificación para las horas trabajadas observadas, sesgando, potencialmente, a los estimadores. En el caso del modelo (2), el sesgo se debe al hecho de no poder observar a las mujeres que poseen altos ingresos laborales de reserva o un menor costo de oportunidad de permanecer desempleadas o cuyas características de capital humano les dificulta acceder a un puesto de trabajo. La estimación de un modelo Tobit permitiría resolver este sesgo, obteniendo estimadores consistentes.

Por un lado, si las características de las mujeres que no trabajan (excluidas de la muestra) no difieren de aquellas que trabajan (incluidas en la muestra), la exclusión no es un problema y, por lo tanto, la estimación por MCO será consistente; sin embargo, es muy probable que esto no se cumpla en el caso de las horas trabajadas, en particular considerando que el desempleo, en parte, se debe a la falta de capital humano. Por otro lado, si las características de las mujeres que trabajan (incluidas en la muestra) difieren de aquellas que no lo hacen, la exclusión es un problema y, por lo tanto, la estimación por MCO será inconsistente. En este caso, es necesario tener en cuenta estas diferencias al momento de querer estimar consistentemente el modelo (2). En el caso contrario (diferencias inexistentes o poco importantes), la estimación por MCO de este modelo puede resultar conveniente, ya que el sesgo de selección desaparece o se reduce y, por lo tanto, las estimaciones se asemejan a las del modelo Tobit, aprovechándose una de las ventajas de utilizar MCO, que es la interpretación directa de los coeficientes como efectos parciales.

Tabla 2. *Estimaciones del modelo (2).*

Variable	(1)	(2)
	MCO	Tobit
edad	1,737*** (0,082)	1,984*** (0,085)
edad2	-0,020*** (0,001)	-0,023*** (0,001)
pric	3,186** (1,284)	3,680*** (1,191)
seci	7,600*** (1,222)	8,484*** (1,137)
secc	9,560*** (1,245)	10,750*** (1,182)
supi	8,820*** (1,264)	10,195*** (1,205)
supc	10,723*** (1,223)	12,122*** (1,153)
asiste	-3,355*** (0,504)	-3,508*** (0,558)
hijos12	-2,250*** (0,200)	-2,379*** (0,214)
_cons	-6,647*** (1,978)	-13,671*** (1,970)
var (e.hstrt)	-	328,52*** (4,106)
Observaciones	14.837	14.837
R ²	0,0787	-

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(6) *Utilizando el modelo Tobit, computar los efectos parciales de la edad y de la cantidad de hijos sobre: (a) el valor esperado de la variable censurada y (b) el valor esperado de la variable truncada. Dar una interpretación económica de los resultados.*

En la tabla 3, se muestran los resultados de las estimaciones de los efectos parciales de la edad y de la cantidad de hijos menores a 12 años en el hogar sobre el valor esperado de las horas trabajadas. Para el caso de una mujer con edad promedio (aproximadamente, 40 años)², con secundaria completa y con dos hijos menores de 12 años en el hogar, se tienen los siguientes casos:

- Variable dependiente censurada: Al aumentar en un año la edad, las horas trabajadas aumentan, en promedio, en 1,67 y, al aumentar en un hijo la cantidad de hijos, las horas trabajadas disminuyen, en promedio, en 2,01.
- Variable dependiente truncada: Al aumentar en un año la edad, las horas trabajadas aumentan, en promedio, en 1,51 y, al aumentar en un hijo la cantidad de hijos, las horas trabajadas disminuyen, en promedio, en 1,81.

² Específicamente, la edad promedio de las mujeres de la muestra es 39,69897 años.

Tabla 3. *Estimaciones de efectos parciales del modelo (2).*

Variable	Efecto parcial	
	Censura	Truncamiento
edad	1,674*** (0,056)	1,512*** (0,056)
hijos12	-2,007*** (0,172)	-1,813*** (0,155)
Observaciones	14.387	14.387

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.