

Evaluación domiciliaria 3: Métodos no paramétricos

Prof. Mariana Marchionni
(marchionni.mariana@gmail.com)

Ayudantes: Jessica Bracco (braccojessica@gmail.com) e Ivana Benzaquen (ivanabenzaquen@gmail.com)

Fecha de entrega: miércoles 18 de septiembre; entregar impreso.

Reglas: se puede trabajar en grupos, pero la **elaboración y entrega deben ser individuales**.

PARTE I. Desigualdad y salarios mínimos en México y Argentina

El objetivo de este ejercicio es comenzar a familiarizarse con algunos comandos de STATA que se usan para la estimación no paramétrica de densidades. Para ello se buscará replicar ciertos resultados del paper de Bosch y Manacorda (2008)¹ usando datos de México y Argentina. En dicho trabajo se explora la contribución del salario mínimo sobre el aumento en la desigualdad de los salarios que tuvo lugar en México entre fines de los '80 y fines de los '90, analizando diferencias entre el sector formal e informal.

La base de datos *base_Bosch&Manacorda.dta* contiene información del ingreso laboral mensual en la actividad principal para una muestra de trabajadores asalariados de entre 16 y 60 años, extraída de encuestas de hogares de Argentina y México. En el caso de Argentina se utilizó la *Encuesta Permanente de Hogares* (EPH) del año 1993 y del segundo semestre de 2004. Para México se utilizó la *Encuesta Nacional de Empleo Urbano* (ENEU) para el primer trimestre de los años 1989 y 2001², agrupando los datos como Bosch y Manacorda (2008) en 3 zonas: de ingresos altos (Zona A), medios (Zona B) y bajos (Zona C).

Para cada año (y zona, en el caso de México) se tiene un salario mínimo distinto³. Además, para facilitar el trabajo, la base contiene la mediana de los salarios y los salarios mínimos de cada año. Utilizando estos datos se pide:

- a) Estimar la función de densidad del logaritmo del salario estandarizado⁴ correspondiente a Argentina para el segundo semestre del año 2004, mediante el estimador de kernels empleando

¹ Bosch, M. y M. Manacorda (2008). Minimum wages and earnings inequality in urban Mexico: Revisiting the evidence. CEP Discussion Paper 880, Centre for Economic Performance, London.

² Los datos son públicos y se encuentran disponibles en el sitio web del INDEC <https://www.indec.gob.ar/bases-de-datos.asp> (Argentina) y del INEGI <http://www.beta.inegi.org.mx/datos/> (México)

³ La evolución del salario mínimo en Argentina puede consultarse en el sitio web del Ministerio de Trabajo Nacional <http://www.trabajo.gob.ar/estadisticas/Bel/ingresos.asp>; en el caso de México, el salario mínimo diario por zona puede consultarse en el sitio web del Servicio de Administración Tributaria (SAT): http://omawww.sat.gob.mx/informacion_fiscal/tablas_indicadores/Paginas/salarios_minimos.aspx

un kernel Epanechnikov. Experimentar con tres anchos de banda alternativos: ancho de banda óptimo, mitad del óptimo y doble del óptimo. Mostrar gráficos reportando los parámetros de suavizamiento h utilizados en cada caso. Describir el comportamiento observado de la densidad estimada. Justificar. Explicar el criterio de optimalidad que se usó para computar el h óptimo.

Nota computacional: el comando `kdensity` de STATA estima no paramétricamente la densidad usando el método de promedios ponderados o Kernels. Por defecto, utiliza un kernel Epanechnikov y un ancho de banda óptimo.

- b) Ídem inciso (a), pero experimentar con distintos tipos de funciones de Kernel. Mostrar gráficos y discutir.
- c) Una manera gráfica de ver el alcance del salario mínimo es a través de las funciones de densidad de la distribución de los salarios. Permiten visualizar más claramente cuán operativo es el salario mínimo en diferentes períodos y si el mismo afecta sólo a los trabajadores formales o tiene efectos derrame hacia el sector informal. En este inciso el objetivo es replicar las figuras del paper de Bosch y Manacorda (2008) usando los datos de México y Argentina. En los ejercicios que siguen, para el caso de México usar solamente la zona B (municipios de ingresos medios).
 - c1. Graficar las funciones de densidad de los salarios estandarizados estimadas por kernels, comparando los dos años disponibles para cada país (Argentina 1993 vs 2004 por un lado, México 1989 vs 2001 por el otro), junto con líneas verticales indicando el salario mínimo correspondiente a cada año (gráficos similares a la figura 2 del paper).
 - c2. Construir para cada año y cada país por separado, gráficos análogos a la figura 5 del paper, comparando las funciones de densidad del salario estandarizado para asalariados formales e informales. Describa los gráficos, analizando si el salario mínimo es operativo para el total de los asalariados, como así también para el sector formal e informal. Compare los resultados para los diferentes años y entre ambos países.

PARTE II. Estimación no paramétrica de curvas de Engel para Argentina

El análisis de la curva de Engel provee una aplicación particularmente útil sobre las ventajas que tiene la utilización de regresiones no-paramétricas. Las curvas de Engel describen cómo cambia la participación de un bien en el gasto total cuando varía el nivel de gasto total de un individuo u hogar. En 1857, Ernst Engel observó que manteniendo constantes los precios, la demanda de ciertos bienes, como los

⁴ Al trabajar con datos de diferentes años se debe tener en cuenta que los ingresos están expresados en moneda corriente. Una forma de corregir esto es expresarlos en pesos constantes deflactando por algún índice de precios. Alternativamente, Bosch y Manacorda (2008) estandarizan el salario por el salario mediano contemporáneo de cada zona. Esto es,
 $\log(\text{salario}/\text{salario_mediano}) = \log(\text{salario}) - \log(\text{salario_mediano})$.

Para estandarizar el salario mínimo siguen el mismo procedimiento.

alimentos, pierde participación en el gasto total a medida que el ingreso del consumidor aumenta (Ley de Engel).

Blundell y Duncan (1998) realizan un análisis de curvas de Engel del consumo alimentario y el gasto en alcohol para ilustrar la implementación de varias alternativas de estimación de regresiones no-paramétricas y semiparamétricas, utilizando la encuesta de gastos de hogares *British Family Expenditure Survey* (FES)⁵.

El objetivo de este ejercicio es estimar las curvas de Engel para los gastos en alimentos y en transporte para el caso argentino utilizando la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005. La ENGH es una encuesta de alcance nacional, que releva detalladamente los gastos de las familias en las principales áreas urbanas de la Argentina, así como varias características socioeconómicas y demográficas de los hogares. La base *ENGH0405_Engel.dta* contiene información a nivel hogar de los gastos en alimentos y transporte, así como de los gastos totales, para hogares formados por una pareja sin hijos que habitan en la Ciudad de Buenos Aires⁶.

La primera tarea consiste en leer las secciones I, II y III del artículo de Blundell y Duncan (1998). Después se pide:

- a) Estimar paramétricamente por mínimos cuadrados la relación entre la *participación o share del gasto en alimentos* (*sh_g_alim*) y el *logaritmo del gasto total* (*lgastot*) familiar usando: i) una especificación lineal y ii) una especificación cuadrática (es decir, donde se incluya un término lineal y otro cuadrático en la variable explicativa *lgastot*). Reportar los resultados de las estimaciones en una tabla. Comparar los resultados.
- b) Estimar un modelo no paramétrico usando el estimador de Nadaraya-Watson (NW) para ajustar la relación entre *sh_g_alim* y *lgastot*. Utilizar un kernel Gaussiano y parámetro de suavizamiento $h = 0.18$. Graficar la regresión estimada no paramétricamente.

Ayuda: en STATA, el comando *lpoly* con la opción *degree(0)*, estima un modelo no paramétrico usando NW. Para más detalles consultar el help de STATA.

- c) El objetivo de este inciso es comparar las estimaciones paramétricas del inciso (a) con la estimación no paramétrica del inciso (b). Se pide graficar todas las estimaciones en un mismo

⁵ Blundell, R. and A. Duncan (1998). "Kernel Regression in Empirical Microeconomics", *The Journal of Human Resources*, Vol. 33, No. 1, pp. 62-87. Es un resumen compacto y didáctico que recorre varios métodos de estimación no paramétrica, ejemplificando su aplicación con la estimación de curvas de Engel.

⁶ Esta restricción impuesta sobre la muestra de estimación responde al objetivo de aislar los factores demográficos (tamaño y composición familiar) que pueden afectar el gasto en ciertos bienes más allá del presupuesto total del hogar. Por esta razón, Blundell y Duncan (1998) también trabajan con una muestra que sólo incluye hogares conformados por parejas sin hijos.

gráfico, y superponer los intervalos de confianza del estimador no paramétrico. Sin hacer un test formal, ¿puede rechazarse la especificación del modelo paramétrico lineal? ¿y la del cuadrático?

Ayudas:

i) Notar que el comando *lpoly* admite la opción *ci* mediante la cual obtiene los intervalos de confianza asintóticos alrededor de la estimación no paramétrica. Los intervalos vienen dados por:

$$\hat{m}(x) \pm z_{\left(\frac{1-\alpha}{2}\right)} \hat{\sigma}(\hat{m}(x))$$

donde z es el valor crítico de una distribución normal estándar correspondiente a un nivel de significatividad α , y $\hat{\sigma}(\hat{m}(x))$ es la estimación del error estándar asintótico, que puede obtenerse con la opción *se* del comando *lpoly*.

ii) Para poder graficar las estimaciones paramétricas lineal y cuadrática junto con la no paramétrica, el comando *lpoly* acepta la opción *addplot(line yhat lgastot || line yhat2 lgastot)*, donde la variable *yhat* se obtiene de aplicar el comando *predict* luego de las regresiones estimadas en el punto (a).

- d) Repetir los incisos a), b) y c) usando el *share del gasto en transporte* (*sh_g_transp*) en lugar de *sh_g_alim*. Comentar los resultados.
- e) Bonus. Aplicar el test de Zheng (1996) para evaluar la validez de las especificaciones paramétricas lineal y cuadrática contra la alternativa no paramétrica, tanto para el modelo del *share del gasto en alimentos* como para el del *share del gasto en transporte*.⁷ Reportar los resultados y comentar. ¿Se rechaza la especificación paramétrica lineal para un nivel de significatividad del 10%? ¿Y para un nivel del 5%? Para esos mismos niveles de significatividad ¿se rechaza la especificación paramétrica cuadrática?

Ayuda:

El programa *zheng.do* (ver archivo adjunto) realiza el test de Zheng (1996) para un Kernel gaussiano y ancho de banda óptimo. Para poder realizar el test es necesario correr el programa *zheng.do*, y luego utilizar la siguiente sintaxis.


- Para una especificación lineal: *zheng varname1 varname2*, donde *varname1* corresponde a la variable dependiente y *varname2* a la variable independiente.
- Para una especificación cuadrática: *zheng varname1 varname2 varname3*, donde *varname3* corresponde al término cuadrático.

⁷ Zheng, J. X. (1996). "A consistent test of functional form via nonparametric estimation techniques". *Journal of Econometrics* 75, pp. 263-289.

Parte III. Estimación de una regresión semiparamétrica parcialmente lineal (Robinson, 1988)

En el ejercicio anterior se estimaron curvas de Engel para los gastos en alimentos de hogares constituidos por parejas sin hijos. La motivación de este nuevo ejercicio es evaluar cómo las características demográficas de los hogares (tamaño familiar) pueden afectar a las curvas de Engel y, eventualmente, incorporar esas variables al análisis.

En la siguiente figura se muestran las regresiones estimadas del *share* del gasto en alimentos (*sh_alim*) en el logaritmo del gasto total familiar (*lgastot*) usando un estimador local-constante. Los datos utilizados están en la base *ENGH0405_Engel_semipar.dta*. Cada línea surge de estimar la curva de Engel para una sub-muestra de los hogares de esa base: (i) sólo parejas sin hijos, (ii) sólo parejas con 1 hijo, (iii) sólo parejas con 2 hijos y (iv) sólo parejas con al menos 3 hijos. Las diferencias que se observan entre las regresiones sugieren que el tamaño familiar explica cambios del *share* en alimentos más allá del gasto total familiar.



El objetivo de este ejercicio será estimar la esperanza del *share* de los gastos en alimentos condicional en el logaritmo del gasto familiar, controlando por el número de hijos, a partir de la muestra total de hogares. A tal fin adoptaremos una especificación semiparamétrica parcialmente lineal para el nuevo modelo, donde el número de hijos se incorpora de manera completamente paramétrica suponiendo una función lineal, mientras que seguimos adoptando una especificación no paramétrica para el logaritmo del gasto total:

$$sh_g_alim = g(lgastot) + \beta nhijos + U$$

donde $g(\cdot)$ es una función desconocida, $nhijos$ es el número de hijos, β es un parámetro desconocido y U es un término aleatorio que suponemos que satisface las condiciones requeridas para aplicar el método de Robinson (1988).

Como primera tarea se recomienda leer la sección IV de Blundell y Duncan (1998). Luego se pide:

- a) Estimar β mediante el método de Robinson (1988) usando un kernel gaussiano. Explicar los pasos seguidos para la estimación. Dar la interpretación económica y estadística (significatividad) del coeficiente estimado.
Ayuda: Para esta estimación utilizar el comando *semipar* con las opciones requeridas en el inciso.
- b) Partiendo de la estimación de β obtenida en el inciso (a), estimar la parte no paramétrica del modelo, es decir, $g(lgastot)$. Usar el estimador de Naradaya-Watson con kernel gaussiano y parámetro de suavizamiento $h = 0.22$. Explicar detalladamente los pasos seguidos.
- c) Considerar nuevamente un modelo totalmente no paramétrico que tenga como único regresor al $lgastot$ (es decir, se excluye la variable explicativa $nhijos$), y estimarlo por Naradaya-Watson para la muestra completa de hogares de la base de datos (usar otra vez un kernel gaussiano y parámetro de suavizamiento $h = 0.22$). En un mismo gráfico se pide mostrar esta estimación junto con la estimación de $g(lgastot)$ hallada en el inciso (b). Incluir también los intervalos de confianza al 95% de esta última. ¿Qué observa? Justificar.