

Evaluación Domiciliaria N° 3: **Métodos No Paramétricos.**

Parte I: Desigualdad y Salarios Mínimos en México y Argentina.

En este ejercicio, se buscará replicar ciertos resultados del paper de Bosch y Manacorda (2008) usando datos de México y de Argentina. En dicho trabajo, se explora la contribución del salario mínimo sobre el aumento en la desigualdad de los salarios que tuvo lugar en México entre fines de los '80 y fines de los '90, analizando diferencias entre el sector formal e informal. La base de datos `base_Bosch&Manacorda.dta` contiene información del ingreso laboral mensual en la actividad principal para una muestra de trabajadores asalariados de entre 16 y 60 años, extraída de encuestas de hogares de Argentina y de México. En el caso de Argentina, se utilizó la Encuesta Permanente de Hogares (EPH) del año 1993 y del segundo semestre de 2004. Para México, se utilizó la Encuesta Nacional de Empleo Urbano (ENEU) para el primer trimestre de los años 1989 y 2001¹, agrupando los datos como Bosch y Manacorda (2008) en 3 zonas: de ingresos altos (Zona A), medios (Zona B) y bajos (Zona C). Para cada año (y zona, en el caso de México), se tiene un salario mínimo distinto². Además, para facilitar el trabajo, la base contiene la mediana de los salarios y los salarios mínimos de cada año.

(a) *Estimar la función de densidad del logaritmo del salario estandarizado correspondiente a Argentina para el segundo semestre del año 2004, mediante el estimador de kernels empleando un kernel Epanechnikov. Experimentar con tres anchos de banda alternativos: ancho de banda óptimo, mitad del óptimo y doble del óptimo. Mostrar gráficos reportando los parámetros de suavizamiento h utilizados en cada caso. Describir el comportamiento observado de la densidad estimada. Justificar. Explicar el criterio de optimalidad que se usó para computar el h óptimo.*

En la figura 1, a partir de la Encuesta Permanente de Hogares (EPH), se presenta la distribución estimada del logaritmo del salario estandarizado para Argentina para el segundo semestre de 2004, utilizando tres anchos de banda distintos y un kernel Epanechnikov.

En la primera figura, se observa la distribución estimada con un ancho de banda óptimo ($h = 0,1049$). Ésta presenta una forma suave con algo de ruido (en particular, en la cola izquierda), donde se observa una marcada concentración de las observaciones en el centro de la distribución y un mayor número de observaciones a la izquierda de la misma, lo cual indica que existe un mayor número de individuos con salarios menores al promedio que aquellos con salarios mayores al promedio. Además, la distancia entre el salario más bajo de la muestra y el salario medio es mayor a la distancia entre el salario medio y el salario más alto.

¹ Los datos son públicos y se encuentran disponibles en el sitio web del INDEC <https://www.indec.gob.ar/bases-de-datos.asp> (Argentina) y del INEGI <http://www.beta.inegi.org.mx/datos/> (México).

² La evolución del salario mínimo en Argentina puede consultarse en el sitio web del Ministerio de Trabajo Nacional <http://www.trabajo.gob.ar/estadisticas/Bel/ingresos.asp>; en el caso de México, el salario mínimo diario por zona puede consultarse en el sitio web del Servicio de Administración Tributaria (SAT) http://omawww.sat.gob.mx/informacion_fiscal/tablas_indicadores/Paginas/salarios_minimos.aspx.

En la segunda figura, se observa la distribución estimada con un ancho de banda igual a la mitad del óptimo ($h = 0,0525$). Ésta presenta una forma no tan suave con mucho más ruido (también en la cola izquierda) y más alta que la anterior, donde se observa más claramente la asimetría de la distribución con mayores observaciones hacia la izquierda.

En la tercera figura, se observa la distribución estimada con un ancho de banda igual al doble del óptimo ($h = 0,2098$). Ésta presenta una forma muy suave con muy poco ruido, donde no se aprecia con tanta claridad la asimetría de la distribución con mayores observaciones hacia la izquierda.

Como se puede observar, cuanto más chico es el h utilizado, más ruidosa será la función de densidad, por lo que la elección de la amplitud del ancho de banda determina las características cualitativas de la densidad estimada. Para N fijo, existe un *trade-off* entre sesgo y eficiencia de los estimadores de kernels³, ya que ambas propiedades dependen de la elección de h , pero de manera inversa: a menor h , menor sesgo y mayor varianza (menor eficiencia); a mayor h , mayor sesgo y menor varianza (mayor eficiencia). La elección óptima del ancho de banda hará un balance entre ambos para resolver el *trade-off*.


Por otra parte, para consistencia de la estimación, es suficiente con que sesgo y varianza tiendan a cero cuando $N \rightarrow \infty$. El sesgo lo hará si $h \rightarrow 0$ y la varianza cuando $N \times h \rightarrow 0$. Entonces, por un lado, se requiere que h decrezca con el tamaño muestral N y, por otro lado, que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N , así $N \times h \rightarrow \infty$. Este criterio lo cumplirá el h que minimiza el Error Cuadrático Medio Integrado (ECMI), que es una de las formas de elección de h que permiten resolver el *trade-off* entre sesgo y eficiencia para N fijo:

$$\text{ECMI} = \int E [\hat{f}(x) - f(x)]^2 dx = \int \{[\text{Sesgo } \hat{f}(x)]^2 + \text{Var} [\hat{f}(x)]\} dx.$$

Así, el ECMI promedia los ECM a lo largo de todos los posibles puntos de estimación, utilizando las expresiones aproximadas del sesgo y de la varianza.

³ La expresión aproximada para el sesgo del estimador de kernels viene dada por: $\text{Sesgo} [\hat{f}(x_0)] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{+\infty} K(\varphi) \varphi^2 d\varphi$. Y la expresión aproximada para la varianza asintótica del estimador de kernels viene dada por: $\text{Var} [\hat{f}(x_0)] \cong \frac{1}{N \times h} f(x_0) \int_{-\infty}^{+\infty} K^2(\varphi) d\varphi$.

Figura 1. Estimaciones de la función de densidad (utilizando Kernel Epanechnikov) del logaritmo del salario para Argentina (segundo semestre de 2004).




Fuente: Elaboración propia.

(b) Ídem inciso (a), pero experimentar con distintos tipos de funciones de Kernel. Mostrar gráficos y discutir.

En la figura 2, se presenta la distribución estimada del logaritmo del salario estandarizado para Argentina para el segundo semestre del año 2004, utilizando distintos kernels (Epanechnikov, Epanechnikov Modificado, Gaussiano y Triangular) y un ancho de banda óptimo ($h=0,1049$).

Se puede observar que no hay diferencias significativas entre la estimación de la función de densidad mediante un kernel Epanechnikov y un kernel Gaussiano, la cuales resultan suaves y con cierta concentración en el centro de la distribución, con colas con poca densidad. En cambio, también se puede ver que el kernel Epanechnikov Modificado y el kernel Triangular presentan mucho más ruido que los mencionados anteriormente.

Figura 2. Estimaciones de la función densidad (utilizando distintos kernels) del logaritmo del salario para Argentina (segundo semestre de 2004).



Fuente: Elaboración propia.

(c) Una manera gráfica de ver el alcance del salario mínimo es a través de las funciones de densidad de la distribución de los salarios. Permiten visualizar más claramente cuán operativo es el salario mínimo en diferentes períodos y si el mismo afecta sólo a los trabajadores formales o si tiene efectos derrame hacia el sector informal. En este inciso, el objetivo es replicar las figuras del paper de Bosch y Manacorda (2008) usando los datos de México y de Argentina. En los ejercicios que siguen, para el caso de México, usar sólo la zona B (municipios de ingresos medios).


(c.1) Graficar las funciones de densidad de los salarios estandarizados estimadas por kernels, comparando los dos años disponibles para cada país (Argentina 1993 vs. 2004, por un lado, y México 1989 vs. 2001, por el otro), junto con líneas verticales indicando el salario mínimo correspondiente a cada año (gráficos similares a la figura 2 del paper).

En la figura 3, a partir de la Encuesta Permanente de Hogares (EPH) y de la Encuesta Nacional de Empleo Urbano (ENEU), se presentan las distribuciones estimadas del logaritmo del salario estandarizado para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001). Las líneas verticales indican el valor real del salario mínimo para cada país en los años considerados.

En el caso de Argentina, no se observan muchos cambios en la distribución de los salarios entre 1993 y el segundo semestre de 2004. Por un lado, en relación a 1993, en 2004, la distribución presenta un mayor número de observaciones en la cola izquierda, lo que indica que un mayor número de trabajadores reciben salarios menores que el promedio. Por otro lado, la concentración en el centro de la distribución se redujo marginalmente. Además, entre 1993 y 2004, el salario mínimo aumenta (representado por el movimiento de la línea vertical hacia la derecha) y pareciera no ser muy operativo.

En el caso de México, se observan algunos cambios en la distribución de los salarios entre 1989 y 2001. Entre estos años, el salario mínimo disminuye significativamente (representado por el movimiento de la línea vertical hacia la izquierda) y pareciera ser bastante operativo, lo cual se observa en que la distribución “engorda” a la izquierda del salario mínimo de 1989.

Figura 3. Estimaciones de la función de densidad del logaritmo del salario para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001)⁴.



Fuente: Elaboración propia.

(c.2) Construir, para cada año y cada país por separado, gráficos análogos a la figura 5 del paper, comparando las funciones de densidad del salario estandarizado para asalariados formales e informales. Describir los gráficos, analizando si el salario mínimo es operativo para el total de los asalariados, como así también para el sector formal e informal. Comparar los resultados para los diferentes años y entre ambos países.

En la figura 4, se presentan las distribuciones estimadas del logaritmo del salario estandarizado para asalariados formales e informales para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001). Las líneas verticales indican el valor real del salario mínimo para cada país en los años considerados.

En el caso de Argentina, se puede observar que:

- La distribución de los salarios de los trabajadores informales es más desigual en 2004 respecto de lo que era en 1993.

⁴ Para el caso de México, sólo se incluyen datos de la zona de municipios de ingresos medios.


- En 1993, la distribución de los salarios de los trabajadores formales y de los informales resulta similar, con la distribución de estos últimos ubicada un poco más “hacia la izquierda”, es decir, con niveles salariales menores que los que reciben los trabajadores formales.
- En 2004, la distribución de los salarios de trabajadores formales e informales difiere significativamente. Mientras que la distribución de los salarios de los trabajadores informales está más “aplanada” o con una marcada asimetría hacia la izquierda (es decir, con un mayor número de trabajadores que reciben salarios muy por debajo del promedio y del salario mínimo), la distribución de los salarios de los trabajadores formales tiene una mayor concentración en el centro y colas ligeramente densas.
- Respecto al salario mínimo, el mismo es operativo tanto para los trabajadores formales como para los informales. Se observa un agrupamiento de los salarios de los trabajadores informales en torno al mismo.

En el caso de México, se puede observar que:

- La distribución de los salarios de los trabajadores informales es más desigual en 2001 respecto de lo que era en 1989.
- En 1989, la distribución de los salarios de los trabajadores informales muestra un engrosamiento en el lado derecho (es decir, un mayor número de trabajadores que reciben salarios mayores al promedio), mientras que, en 2001, esto se invierte y esta distribución muestra un “engrosamiento” en el lado izquierdo (es decir, un mayor número de trabajadores que reciben salarios menores al promedio). Esto no sucede en el caso de la distribución de los salarios de los trabajadores formales.
- Respecto al salario mínimo, en 1989, el mismo es operativo tanto para los trabajadores formales como para los informales, con una mayor proporción de trabajadores informales en torno a este nivel salarial en relación a los trabajadores formales, en tanto que también hay un mayor número de trabajadores informales por debajo de este nivel para ese año; en 2001, el salario mínimo disminuye en relación con el de 1989, mostrando una mayor relevancia en el caso de los trabajadores informales, en tanto que sólo unos pocos trabajadores formales reciben salarios por debajo del salario mínimo.

En conclusión, los salarios de los trabajadores informales, tanto en Argentina como en México, parecen verse afectados por el salario mínimo. En Bosch y Manacorda (2008), se señala que este resultado no debería sorprendernos, ya que, en estos países (como en muchos de América Latina), el salario mínimo se ha utilizado como un índice de inflación, afectando a los trabajadores informales de manera directa. Al mismo tiempo, la dispersión de los salarios que se observa en ambos países hace que el salario mínimo afecte al salario de reserva del conjunto de los trabajadores (Freeman, 2007; Bosch y Manacorda, 2008), lo que explica la concentración de trabajadores en torno al nivel del salario mínimo.

Figura 4. Estimaciones de la función de densidad del logaritmo del salario estandarizado para trabajadores formales e informales para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2004)⁵.



Fuente: Elaboración propia.

⁵ Ídem nota al pie número 4.

Parte II: Estimación no Paramétrica de Curvas de Engel para Argentina.

(a) Estimar paramétricamente por mínimos cuadrados la relación entre la participación o share del gasto en alimentos (sh_g_alim) y el logaritmo del gasto total familiar ($lgastot$) usando: (i) una especificación lineal y (ii) una especificación cuadrática (es decir, donde se incluya un término lineal y otro cuadrático en la variable explicativa $lgastot$). Reportar los resultados de las estimaciones en una tabla. Comparar los resultados.

En la tabla 1, a partir de la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005, se presentan las estimaciones paramétricas por MCO de la relación entre la participación del gasto en alimentos y el logaritmo del gasto total familiar, utilizando una especificación lineal y una cuadrática.

En el caso de la especificación lineal, el coeficiente del gasto total familiar es negativo y esta variable es estadísticamente significativa, indicando que, ante un aumento de un 1% en el gasto total familiar, la participación del gasto en alimentos en éste disminuye, en promedio y *ceteris paribus*, en 0,0766 puntos porcentuales, en consonancia con lo indicado por la teoría económica (Ley de Engel). En el caso de la especificación cuadrática, las variables explicativas resultan estadísticamente no significativas para explicar esta relación. Por último, se puede mencionar que el poder explicativo de la estimación no varía con el cambio de especificación (el R^2 , prácticamente, no se altera).

Tabla 1. Estimaciones paramétricas (lineal y cuadrática).

Variables	(1)	(2)
	Especificación lineal	Especificación cuadrática
$lgastot$	-0,0766*** (0,0080)	-0,1360 (0,1240)
$lgastot^2$	- (0,0081)	0,0040 (0,0081)
constante	0,8722*** (0,0614)	1,0895*** (0,4723)
Observaciones	573	573
R^2	0,1669	0,1674


Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(b) Estimar un modelo no paramétrico usando el estimador de Nadaraya-Watson (NW) para ajustar la relación entre sh_g_alim y $lgastot$. Utilizar un kernel Gaussiano y parámetro de suavizamiento $h = 0,18$. Graficar la regresión estimada no paramétricamente.

En la figura 5, se presenta una estimación no paramétrica de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar, utilizando el estimador de Nadaraya-Watson (NW), un kernel Gaussiano y un parámetro de suavizamiento $h = 0,18$.

Se puede observar una relación inversa entre ambas variables, en línea con lo observado por Engel. A medida que el gasto total familiar aumenta, la participación del gasto en alimentos en éste disminuye, lo cual estaría indicando que el aumento del gasto en alimentos es menor que el aumento del gasto total familiar.

Figura 5. Estimación no paramétrica (estimador de Naradaya-Watson).




Fuente: Elaboración propia.

(c) El objetivo de este inciso es comparar las estimaciones paramétricas del inciso (a) con la estimación no paramétrica del inciso (b). Se pide graficar todas las estimaciones en un mismo gráfico y superponer los intervalos de confianza del estimador no paramétrico. Sin hacer un test formal, ¿puede rechazarse la especificación del modelo paramétrico lineal? ¿y la del cuadrático?

En la figura 6, se presentan las estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador NW) de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar.

Se puede observar que las estimaciones paramétricas de esta relación se encuentran dentro del intervalo de confianza de la estimación no paramétrica. Por lo tanto, sin hacer un test formal, se puede expresar que no es posible rechazar la especificación del modelo paramétrico lineal y la del modelo cuadrático (aunque ésta resulta no significativa), ya que no pareciera haber evidencia de diferencias significativas entre los resultados obtenidos por los dos tipos de estimaciones (paramétrica y no paramétrica).

Figura 6. Estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

(d) Repetir los incisos (a), (b) y (c) usando el share del gasto en transporte (*sh_g_transp*) en lugar de *sh_g_alim*. Comentar los resultados.

En la tabla 2, a partir de la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005, se presentan las estimaciones paramétricas por MCO de la relación entre el share del gasto en transporte y el logaritmo del gasto total familiar, utilizando una especificación lineal y una cuadrática.


En el caso de la especificación lineal, el coeficiente del gasto total familiar es positivo y esta variable es estadísticamente significativa (pero sólo al 10%). En el caso de la especificación cuadrática, el coeficiente del gasto total familiar es negativo y el del gasto total familiar al cuadrado es positivo, en tanto que ambas son estadísticamente significativas, indicando que, a medida que el gasto total familiar aumenta, la participación del gasto en transporte en éste disminuye hasta un nivel determinado de gasto, a partir del cual la participación del mismo comienza a aumentar. Por último, se puede mencionar que el poder explicativo de la estimación varía significativamente con el cambio de especificación (el R^2 pasa de 0,0075 a 0,0224), aunque se encuentra en un nivel muy bajo.

Tabla 2. Estimaciones paramétricas (lineal y cuadrática).

Variables	(1)	(2)
	Especificación lineal	Especificación cuadrática
lgastot	0,0133* (0,0071)	-0,2540*** (0,0915)
lgastot2	-	0,0180*** (0,0062)
constante	0,0472 (0,0528)	1,027*** (0,3414)
Observaciones	563	563
R^2	0,0075	0,0224

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

En la figura 7, se presenta una estimación no paramétrica de la relación entre la participación del gasto en transporte en el gasto total familiar y el gasto total familiar, utilizando el estimador de Naradaya-Watson (NW). Se puede observar una concentración de las observaciones en los niveles bajos de la participación del gasto en transporte y mayor dispersión a medida que la participación del gasto en transporte en el gasto total familiar aumenta.

Figura 7. Estimación no paramétrica (estimador de Naradaya-Watson).


Fuente: Elaboración propia.

En la figura 8, se presentan las estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador NW) de la relación entre la participación del gasto en transporte en el gasto total familiar y el gasto total familiar.

A diferencia de los resultados obtenidos anteriormente para el gasto en alimentos, los dos tipos de estimaciones (paramétrica y no paramétrica) difieren considerablemente. La estimación del modelo paramétrico lineal no se encuentra dentro de los intervalos de confianza de la estimación no paramétrica a lo largo de toda la distribución y, además, los intervalos de confianza de ambas estimaciones no coinciden. Respecto de la estimación del modelo paramétrico cuadrático, se observa un mejor ajuste que para el caso de la del paramétrico lineal y se encuentra dentro de los intervalos de confianza de la estimación no paramétrica, prácticamente, a lo largo de toda la distribución; sin embargo, esta estimación tiene importantes diferencias con la no paramétrica a medida que nos alejamos (por izquierda y por derecha) del centro.

Por lo tanto, sin hacer un test formal, se puede expresar que es posible rechazar la especificación del modelo paramétrico lineal y la del modelo cuadrático, ya que hay evidencia de diferencias significativas entre los resultados obtenidos por los dos tipos de estimaciones (paramétrica y no paramétrica).

Figura 8. Estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

(e) Bonus. Aplicar el test de Zheng (1996) para evaluar la validez de las especificaciones paramétricas lineal y cuadrática contra la alternativa no paramétrica, tanto para el modelo del share del gasto en alimentos como para el del share del gasto en transporte. Reportar los resultados y comentar. ¿Se rechaza la especificación paramétrica lineal para un nivel de significatividad del 10%? ¿Y para un nivel del 5%? Para esos mismos niveles de significatividad, ¿se rechaza la especificación paramétrica cuadrática?

En la tabla 3, se presentan los resultados del test de Zheng, que contrasta la hipótesis nula de validez de la especificación paramétrica (lineal o cuadrática).

En el caso de la participación del gasto en alimentos en el gasto total familiar, para niveles de significatividad de 10% y 5%, estos datos no proporcionan evidencia suficiente para rechazar la hipótesis nula tanto de validez de la especificación paramétrica lineal como de la especificación paramétrica cuadrática. Respecto a la participación del gasto en transporte en el gasto total familiar, para el caso de la especificación paramétrica lineal, la hipótesis nula se rechaza para un nivel de significatividad de 10%, pero no para un nivel del 5%; y, para el caso de la estimación paramétrica cuadrática, la hipótesis nula no se rechaza para niveles de significatividad de 10% y 5%.

Tabla 3. *Test de Zheng (1996).*

Estimación		Share del gasto en alimentos	Share del gasto en transporte
No Paramétrica vs. Paramétrica (lineal)	Estadístico	0,9246	1,9078
	$T_n \rightarrow^d \mathcal{N}(0, 1)$		
	P-valor	0,3556	0,0569
H_0 : forma paramétrica lineal (basado en Zheng (1996))			
No Paramétrica vs. Paramétrica (cuadrática)	Estadístico	1,0717	0,2979
	$T_n \rightarrow^d \mathcal{N}(0, 1)$		
	P-valor	0,2843	0,7659
H_0 : forma paramétrica cuadrática (basado en Zheng (1996))			

Fuente: Elaboración propia.

Parte III.

El objetivo de este ejercicio será estimar la esperanza del share de los gastos en alimentos condicional en el logaritmo del gasto familiar, controlando por el número de hijos, a partir de la muestra total de hogares. A tal fin, se adoptará una especificación semiparamétrica parcialmente lineal para el nuevo modelo, donde el número de hijos se incorpora de manera completamente paramétrica suponiendo una función lineal, mientras que se sigue adoptando una especificación no paramétrica para el logaritmo del gasto total:

$$sh_g_alim = g(lgastot) + \beta nhijos + U,$$

donde $g(.)$ es una función desconocida, $nhijos$ es el número de hijos, β es un parámetro desconocido y U es un término aleatorio que se supone que satisface las condiciones requeridas para aplicar el método de Robinson (1988).

(a) *Estimar β mediante el método de Robinson (1988) usando un kernel Gaussiano. Explicar los pasos seguidos para la estimación. Dar la interpretación económica y estadística (significatividad) del coeficiente estimado.*

En la tabla 4, se presenta la estimación semiparamétrica de este modelo mediante el método de Robinson (1988), utilizando un kernel Gaussiano y un parámetro de suavizamiento $h = 0,22$.

Robinson (1988) propone transformar el modelo de manera tal de poder estimar consistentemente a β , a la tasa de convergencia $\sqrt{N}$, a pesar de la presencia del término no paramétrico, dado por $g(.)$. Para esto, se computa la esperanza condicional de sh_g_alim en $lgastot$ y, luego, se le resta al modelo original, obteniendo:

$$sh_g_alim - E(sh_g_alim | lgastot) = [nhijos - E(nhijos | lgastot)] \beta + U.$$

Ya que no se conocen los momentos condicionados de esta expresión, Robinson propone estimar en dos etapas (método residual):

1. Se estima $E(sh_g_alim | lgastot)$ y $E(nhijos | lgastot)$ mediante regresiones no paramétricas de sh_g_alim sobre $lgastot$ y $nhijos$ sobre $lgastot$, respectivamente, y se reservan los residuos parciales de ambas regresiones.
2. Se estima β mediante una regresión paramétrica por MCO entre ambos residuos parciales (sin constante, para que β se encuentre identificado).

El coeficiente β estimado mediante este método es positivo e igual a 0,0218, siendo la variable $nhijos$ estadísticamente significativa, indicando que un hijo adicional en comparación con el número promedio de hijos en el hogar aumenta la participación del gasto en alimentos en el gasto total familiar, con respecto al promedio, en 0,0218 puntos porcentuales.

Tabla 4. Estimación semiparamétrica (Método de Robinson, 1988).


Variable	sh_g_alim
nhijos	0,0218*** (0,0025)
Observaciones	1575
R^2	0,0463

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(b) Partiendo de la estimación de β obtenida en el inciso (a), estimar la parte no paramétrica del modelo, es decir, $g(\lgastot)$. Usar el estimador de Naradaya-Watson con kernel Gaussiano y parámetro de suavizamiento $h= 0,22$. Explicar, detalladamente, los pasos seguidos.

En la figura 9, se presenta una estimación no paramétrica de la relación entre la variable $s_g_alim_hijo$ y el gasto total familiar, utilizando el estimador de Naradaya-Watson (NW), un kernel Gaussiano y un parámetro de suavizamiento $h= 0,22$.

Utilizando el estimador β ($\hat{\beta}$) obtenido en el inciso anterior mediante el método de Robinson (1988), se estima la parte no paramétrica del modelo. Para esto, se genera la variable $s_g_alim_hijo$ de la siguiente manera: $s_g_alim_hijo = s_g_alim - \hat{\beta} \text{ nhijos}$.

Figura 9. Estimación no paramétrica (estimador de Naradaya-Watson).


Fuente: Elaboración propia.

(c) Considerar, nuevamente, un modelo totalmente no paramétrico que tenga como único regresor al $\lgastot$ (es decir, se excluye la variable explicativa $nhijos$) y estimarlo por Nadaraya-Watson para la muestra completa de hogares de la base de datos (usar otra vez un kernel Gaussiano y parámetro de suavizamiento $h=0,22$). En un mismo gráfico, se pide mostrar esta estimación junto con la estimación de $g(\lgastot)$ hallada en el inciso (b). Incluir también los intervalos de confianza al 95% de esta última. ¿Qué se observa? Justificar.

En la figura 10, se presentan la estimación semiparamétrica (inciso (b)) y no paramétrica (estimador NW) de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar, utilizando un kernel Gaussiano y un parámetro de suavizamiento $h=0,22$.

Se puede observar que ambas estimaciones no difieren sustancialmente, notándose un movimiento similar entre ambas. No obstante, la estimación no paramétrica no se encuentra dentro del intervalo de confianza de la estimación semiparamétrica, siendo la amplitud de este intervalo sumamente estrecha. Esto se puede deber al hecho de que el número de hijos en el hogar es una variable relevante para explicar la participación del gasto en alimentos en el gasto total familiar y, al mismo tiempo, el gasto total familiar no es independiente del número de hijos en el hogar.

Figura 10. Estimación semiparamétrica y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

Referencias.

- Blundell, R. y Duncan, A. (1998). Kernel Regressions and Empirical Microeconomics. *The Journal of Human Resources*, 33(1), 62-87. Recuperado de <https://www.jstor.org/stable/146315>
- Bosch, M. y Manacorda, M. (2008). Minimum Wages and Earnings Inequality in Urban Mexico. Revisiting the Evidence. *CEP Discussion Paper*, 880. Recuperado de <http://cep.lse.ac.uk/pubs/download/dp0880.pdf>