

Evaluación Domiciliaria N° 1: **Modelos para Datos en Panel.**

Parte I.

Una herramienta para estudiar, empíricamente, la relación entre los salarios de los trabajadores y sus características son las llamadas ecuaciones de ingresos o ecuaciones de Mincer (Mincer, 1974). Considerar el siguiente modelo:

$$\ln \text{salario}_{it} = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_{it} + \beta_3 \text{casado}_{it} + \beta_4 \text{sindicato}_{it} + \beta_5 \text{afro}_i + \beta_6 \text{hispano}_i + u_{it}, \quad (1)$$

donde $\ln$ salario es el logaritmo de los salarios por hora; educ son los años de educación formal; exper son los años de experiencia laboral; casado es una dummy que indica si el trabajador es casado; sindicato es una dummy que indica si el trabajador pertenece a un sindicato; afro e hispano son dummies que indican si el individuo es de origen afroamericano o hispano, respectivamente (la categoría base es blanco no hispano); y u es un término aleatorio que varía entre individuos y en el tiempo.

En este ejercicio, se va a estimar este modelo utilizando la base de datos nls8087.dta, que cuenta con información extraída de la National Longitudinal Survey (Youth Sample) para el período 1980-1987. La muestra comprende 545 hombres jóvenes (17 a 30 años de edad) que trabajan a tiempo completo y que, para 1980, ya habían finalizado su escolaridad.

(1) Mostrar estadísticas descriptivas de las variables incluidas en el modelo teniendo en cuenta la estructura de panel (variabilidad total, between y within). Describirlas brevemente y discutir por qué, para ciertas variables, la variabilidad within es cero, mientras que la between no lo es.

En la tabla 1, se pueden observar estadísticas descriptivas de las variables incluidas en el modelo (1) teniendo en cuenta la estructura de panel (variabilidad total, between, within). La cantidad de observaciones para calcular los estadísticos descriptivos de las variables del modelo en sus tres formas (overall, between y within) es 4.360 (individuos x años), en donde se calculan sobre un total de $n = 545$ individuos durante $T = 8$ años.

El promedio de **salario** de los trabajadores de la muestra en el período de estudio es de USD 5,92 por hora, oscilando entre USD 0,028 y USD 57,5. El promedio de esta variable para cada individuo en el tiempo (between) se situó en un rango entre USD 1,5 y USD 28,36, mientras que la desviación con respecto a su promedio (within) varió entre -16,42 y 35,07. Esto último indica que hay individuos que, en algunos períodos, obtuvieron un salario por debajo de su promedio en el período bajo análisis. Con respecto al desvío estándar, se observa que la variabilidad en el promedio de salario entre los individuos (between) es mayor a la observada en un individuo a lo largo del tiempo (within). Es decir, el salario tiene una mayor variabilidad entre individuos que la que tiene para un individuo a lo largo de los años.

El promedio de años de **educación** de los trabajadores de la muestra en el período de estudio es de 11,77 años, oscilando entre los 3 y 16 años.

El promedio de años de **experiencia** de los trabajadores de la muestra en el período de estudio es de 6,51 años, oscilando entre 0 y 18 años. El promedio de esta variable en el tiempo para cada individuo se situó entre 3,5 y 14,5 años de experiencia laboral, mientras que la desviación con respecto a su promedio (*within*) varió entre 3,01 y 10,01 años. Con respecto al desvío estándar, se observa que la variabilidad en el promedio de años de experiencia entre los individuos (*between*) es menor a la observada en un individuo a lo largo del tiempo (*within*). Es decir, los años de experiencia tienen una mayor variabilidad para un individuo a lo largo de los años que la que tienen entre individuos.

Para el caso de las variables binarias, se observa que, en promedio, en el período analizado, el 43,9% de los individuos están casados, el 24,4% está afiliado a un sindicato, el 11,6% son afroamericanos y el 15,6% son hispanoamericanos. En el caso de las variables **casado** y **sindicato**, la variabilidad es relativamente baja, tanto la observada en el promedio entre los individuos (*between*) como en un individuo a lo largo del tiempo (*within*), pero distinta de cero, por lo que hay individuos que cambiaron de estado a lo largo del período analizado.

Si una variable no varía con el tiempo, es decir, que mantiene su valor a lo largo del período analizado, la desviación estándar *within* será igual a cero, ya que la misma mide la variabilidad en un individuo a lo largo del tiempo y, lógicamente, si su valor es el mismo en cada período de tiempo, este indicador será cero. Las variables **educ**, **afro** e **hispano**, que indican los años de educación y la raza (características que no cambian en el tiempo para los individuos de la muestra), tienen una desviación estándar *within* igual a cero, ya que no varían en el tiempo. En estos mismos casos, la desviación estándar *between* no es igual a cero, ya que la misma mide la variabilidad entre los individuos y, por lo tanto, será distinta de cero; sólo será igual a cero cuando, en cada período de tiempo, la variable tome el mismo valor para cada individuo (como es el caso de la variable *años*).

Tabla 1. Estadísticas descriptivas de las variables del modelo (1).

Variable		Media	Desvío estándar	Mínimo	Máximo	Observaciones
salario	Overall	5,919175	3,202225	0,0279014	57,50431	N = 4.360
	Between	-	2,455819	1,503564	28,35696	n = 545
	Within	-	2,057397	-16,42349	35,06653	T = 8
educ	Overall	11,76697	1,746181	3	16	N = 4.360
	Between	-	1,747585	3	16	n = 545
	Within	-	0	11,76697	11,76697	T = 8
exper	Overall	6,514679	2,825873	0	18	N = 4.360
	Between	-	1,654918	3,5	3,5	n = 545
	Within	-	2,291551	3,014679	10,01468	T = 8
casado	Overall	0,4389908	0,4963208	0	1	N = 4.360
	Between	-	0,3766116	0	1	n = 545
	Within	-	0,3236137	-0,4360092	1,313991	T = 8
sindicato	Overall	0,2440367	0,4295639	0	1	N = 4.360
	Between	-	0,3294467	0	1	n = 545
	Within	-	0,2759787	-0,6309633	1,119037	T = 8
afro	Overall	0,1155963	0,3197769	0	1	N = 4.360
	Between	-	0,320034	0	1	n = 545
	Within	-	0	0,1155963	0,1155963	T = 8
hispano	Overall	0,1559633	0,3628622	0	1	N = 4.360
	Between	-	0,3631539	0	1	n = 545
	Within	-	0	0,1559633	0,1559633	T = 8

Fuente: Elaboración propia.

(2) Estimar la ecuación (1) por Pooled OLS (POLS). Interpretar estadística y económicamente los coeficientes obtenidos. Explicar por qué es muy posible que la presencia de heterogeneidad no observable a nivel de trabajador haga que las estimaciones anteriores sean inconsistentes. ¿Por qué el modelo Within con efectos fijos por trabajador permitiría resolver este problema?

En esta estimación por POLS del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *hispano*, que no es estadísticamente significativa. En la tabla 2, se muestran los resultados de esta estimación (conjuntamente con las estimaciones *between*, *within*, primeras diferencias y efectos aleatorios), que expresan que, en promedio y manteniendo todo lo demás constante:

- Al aumentar en un año la educación del individuo, el salario por hora de los trabajadores aumenta en un 10,4%.
- Al aumentar en un año la experiencia laboral del individuo, el salario por hora aumenta en un 5%.
- Un individuo casado tiene un salario por hora un 11,3% mayor que uno que no está casado.
- Un individuo afiliado a un sindicato tiene un salario por hora un 18,4% mayor que uno que no está afiliado.
- Un hombre afroamericano tiene un salario por hora un 14,2% menor que un individuo blanco.
- Un individuo hispano tiene un salario por hora un 1,3% mayor que un individuo no hispano (esta variable no es estadísticamente significativa).

A pesar de que los signos de los coeficientes obtenidos son consistentes con lo que indica la literatura económica relacionada, es muy posible que la presencia de heterogeneidad no observable a nivel trabajador haga que las estimaciones anteriores sean sesgadas e inconsistentes. Un problema que surge, regularmente, en los estudios que evalúan la relación entre estas variables es que es difícil aislar el impacto causal de un año adicional de educación en los salarios. El retorno a un año adicional de educación puede estar siendo distorsionado por el efecto de otros factores relevantes, pero no observados, que pueden estar relacionados con los años de educación. Por ejemplo, es muy probable que la habilidad, la inteligencia o el talento de los individuos estén relacionados con los salarios que reciben y, al mismo tiempo, con el nivel de escolaridad alcanzado. Tanto la habilidad como otros factores característicos de los individuos no son observables y, por lo tanto, ignorar el vínculo mencionado conduciría a estimaciones inconsistentes y a inferencias no válidas con respecto al efecto causal de los años de educación.

El modelo *within* con efectos fijos por trabajador permitiría resolver este problema porque, al “eliminar” el efecto de la heterogeneidad inobservable (fuente potencial de sesgo) que afecta a los regresores del modelo, se obtienen estimadores insesgados y consistentes para evaluar la relación entre las variables analizadas.

(3) Estimar, nuevamente, el modelo 1 mediante los siguientes estimadores alternativos: *between*, *within*, primeras diferencias y efectos aleatorios. Interpretar cuidadosamente el coeficiente estimado de la variable *exper* para cada uno de los modelos. Para la interpretación, prestar especial atención a cuál es la dimensión del panel (corte transversal o longitudinal) relevante para identificar el efecto en cada caso. Luego, comentar por qué, en el modelo de efectos fijos y de primeras diferencias, se omiten las variables *educ*, *afro* e *hispano*.

En estas cuatro estimaciones alternativas (*between*, *within*, primeras diferencias y efectos aleatorios) del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *hispano*, que no es estadísticamente significativa en ninguna de estas estimaciones. En la tabla 2, se muestran los resultados de estas estimaciones (conjuntamente con los resultados de la estimación por POLS).

La variable *exper* resulta estadísticamente significativa en las cuatro estimaciones y, en todos los casos, se observa una relación positiva entre esta variable y los salarios. La interpretación bajo cada modelo, en promedio y manteniendo todo lo más constante, es la siguiente:

- ***Between*:** Un año adicional de experiencia laboral del individuo *en comparación con la experiencia laboral promedio del resto de los individuos* aumenta el salario por hora en un 2,8%.
- ***Within*:** Un año adicional de experiencia laboral del individuo *en comparación con la propia experiencia laboral promedio del individuo* aumenta el salario por hora en un 6%.
- ***Primeras Diferencias*:** Un año adicional de experiencia laboral de un año *en comparación a otro año* aumenta el salario por hora en un 6,5%.

- Efectos Aleatorios: Un año adicional de experiencia laboral del individuo en comparación con la propia experiencia laboral promedio del individuo aumenta el salario por hora en un 5,8%.

En el modelo de efectos fijos y en el de primeras diferencias, se omiten las variables *educ*, *afro* e *hispano* porque son variables que no varían con el tiempo, es decir, que mantienen su valor para cada individuo a lo largo del período analizado, por lo que no aparecen en estos modelos por ser iguales a cero.

En el modelo *within*, se usan las desviaciones de las variables de su promedio a través del tiempo y, en el caso de las variables mencionadas, su valor en cada momento *t* es igual a su promedio, es decir, su desvío respecto de la media es igual a cero.

En el modelo de primeras diferencias, sucede algo similar, sólo que, en lugar de usar desvíos de las variables respecto de su promedio a través del tiempo, se utiliza la diferencia entre los valores de las variables en *t* y en *t*-1, por lo cual, en este modelo, también se eliminan las variables mencionadas, que no varían con el tiempo para un mismo individuo.

En el caso de la variable *educ*, que hace referencia a los años de educación formal del individuo, en esta muestra, no existen variaciones en el tiempo, ya que comprende a hombres jóvenes que trabajan a tiempo completo y que, para 1980, ya habían finalizado su escolaridad, por lo que no siguieron educándose formalmente en el período de análisis (1980-1987).

En el caso de las variables *afro* e *hispano*, son dummies que hacen referencia a características innatas del individuo, que, sin duda, no varían con el tiempo.

Tabla 2. Estimaciones del modelo (1).

Variables	(1) POLS	(2) <i>Between</i>	(3) <i>Within</i>	(4) Primeras Diferencias	(5) Efectos Aleatorios
<i>educ</i>	0,104*** (0,005)	0,091*** (0,011)	- -	- -	0,108*** (0,009)
<i>exper</i>	0,050*** (0,003)	0,028** (0,011)	0,060*** (0,003)	0,065*** (0,007)	0,058*** (0,003)
<i>casado</i>	0,113*** (0,016)	0,142*** (0,041)	0,061*** (0,018)	0,043* (0,023)	0,076*** (0,017)
<i>sindicato</i>	0,184*** (0,017)	0,259*** (0,046)	0,084*** (0,019)	0,042** (0,020)	0,110*** (0,018)
<i>afro</i>	-0,142 (0,024)	-0,141*** (0,049)	- -	- -	-0,141*** (0,048)
<i>hispano</i>	0,013 (0,021)	0,010 (0,043)	- -	- -	0,016 (0,043)
constante	0,023 (0,063)	0,284 (0,178)	1,212*** (0,017)	- -	-0,048 (0,111)
Observaciones	4.360	4.360	4.360	3.815	4.360
<i>R</i> ²	0,184	0,169	0,051	0,025	0,178
Número de id	-	545	545	-	545

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(4) A partir de las estimaciones anteriores:

a. Para cada uno de los estimadores del inciso anterior, explicar cuáles son los supuestos que se requieren para consistencia.

Los supuestos que se requieren para consistencia de los estimadores del inciso anterior son:

➤ POLS:

Para que el estimador sea consistente, se requiere del supuesto (1) $E(x'_{it}u_{it}) = 0$, es decir, exogeneidad contemporánea.

Cuando $\mu_i = 0$, es decir, en ausencia de heterogeneidad inobservable, (2) $E(x'_{it}\varepsilon_{it}) = 0$ es condición suficiente para la consistencia del estimador.

Cuando $\mu_i \neq 0$, es decir, con presencia de heterogeneidad inobservable, el término de error estará compuesto por dos componentes ($u_{it} = \mu_i + \varepsilon_{it}$), por lo que, para la consistencia del estimador, se requerirá, además de (2), que la heterogeneidad inobservable sea ortogonal a todos los elementos de x_{it} , es decir, (3) $E(x'_{it}\mu_i) = 0$.

➤ Within y Primeras Diferencias:

Para que el estimador sea consistente, se requiere del supuesto (4) $E(x'_{it}\varepsilon_{it}) = 0$, s, $t = 1, \dots, T$, es decir, exogeneidad estricta, un supuesto más fuerte que el supuesto (2), que ya no es suficiente para garantizar estimadores consistentes.

➤ Between y Efectos Aleatorios:

Para que el estimador sea consistente, se requiere del supuesto (3) $E(x'_{it}\mu_i) = 0$ (ortogonalidad entre los regresores y la heterogeneidad inobservable) y (4) $E(x'_{it}\varepsilon_{it}) = 0$, s, $t = 1, \dots, T$ (exogeneidad estricta).

En la tabla 3, se resumen las condiciones descriptas para la consistencia de los estimadores de los modelos para datos en panel.

Tabla 3. Condiciones para consistencia de los estimadores.

Condiciones para consistencia	(1) POLS	(2) <i>Between</i>	(3) <i>Within</i>	(4) Primeras Diferencias	(5) Efectos Aleatorios
(1) Exogeneidad contemporánea $E(\mathbf{x}_{it}'\mathbf{u}_{it})=0$	X				
(2) Exogeneidad contemporánea (*) $E(\mathbf{x}_{it}'\boldsymbol{\varepsilon}_{it})=0$	X				
(3) Ortogonalidad entre regresores y heterogeneidad inobservable $E(\mathbf{x}_{it}'\boldsymbol{\mu}_i)=0$	X	X			X
(4) Exogeneidad estricta $E(\mathbf{x}_{is}'\boldsymbol{\varepsilon}_{it})=0$ (**)		X	X	X	X

(*) Esta condición es suficiente para la consistencia de POLS cuando $\mu_i=0$. (**) Esta condición es suficiente para la consistencia de *Between* cuando $\mu_i=0$. Fuente: Elaboración propia.

b. Implementar un test para evaluar la hipótesis nula de ausencia de efectos fijos. Proveer una interpretación del resultado.

Teniendo en cuenta que el modelo POLS es un modelo restringido con respecto al modelo de efectos fijos, en donde se asume que existe un intercepto común para todos los individuos de la muestra, puede realizarse una prueba F para evaluar la significancia estadística de los efectos fijos.

La hipótesis nula es $\mu_i=0, \forall i$, es decir, que el intercepto es común para todos los individuos de la muestra y, por lo tanto, que no existen efectos fijos asociados a cada individuo. Si la prueba se rechaza, se podría afirmar que el modelo de efectos fijos es preferible al modelo POLS.

En esta muestra, se obtiene el siguiente resultado:

$F(544, 3812)=10,08$; $p\text{-valor}=0,0000$.

Por lo tanto, dado que el p-valor es muy pequeño, se rechaza la hipótesis nula y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que existen efectos fijos asociados a cada individuo y, en consecuencia, el modelo de efectos fijos es preferible al modelo POLS.

c. Implementar un test de Hausman para comparar los estimadores de efectos fijos y de efectos aleatorios y comentar los resultados obtenidos.

El test de Hausman evalúa la posible correlación entre el componente de error individual μ_i y las variables exógenas del modelo. Si, efectivamente, existe esta correlación, entonces, no incluir μ_i en el modelo producirá un sesgo de variable omitida

en los coeficientes de las variables explicativas. Hausman demostró que la diferencia entre los coeficientes de efectos fijos y de efectos aleatorios ($\hat{\beta}_{EF} - \hat{\beta}_{EA}$) puede ser usada para probar la hipótesis nula de que μ_i y las variables explicativas no están correlacionadas.

La hipótesis nula de la prueba de Hausman es que los estimadores de efectos aleatorios y de efectos fijos no difieren sustancialmente y, en consecuencia, bajo H_0 , tanto el estimador de efectos fijos como el de efectos aleatorios son consistentes, mientras que, bajo H_a , sólo el estimador de efectos fijos es consistente.

En esta muestra, se obtiene el siguiente resultado:

$$\chi^2 (3) = 22,69; \quad p\text{-valor} = 0,0000.$$

Por lo tanto, dado que el p-valor es muy pequeño, se rechaza la hipótesis nula y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que los efectos individuales están correlacionados con las variables explicativas y, en consecuencia, el modelo de efectos fijos es preferible al modelo de efectos aleatorios.

Parte II.

Este ejercicio se basa en el artículo de Rockoff, J. (2004) “The Impact of Individual Teachers on Student Achievement: Evidence from Panel Data” (American Economic Review, 94(2), pp. 247-252). El objetivo es ilustrar con un ejemplo cómo los datos en panel permiten responder a preguntas que no podrían responderse con otro tipo de datos. Como primera consigna, se pide leer, detenidamente, el artículo de Rockoff (2004). Luego, responder las siguientes preguntas.

(1) *Explicar cuál es la crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes. ¿De qué se vale Rockoff para superar esa limitación de la literatura previa?*

El trabajo de Rockoff (2004) presenta evidencia sobre los efectos que tiene la calidad de los docentes en el rendimiento académico de los estudiantes, utilizando un análisis de datos en panel. El autor, por un lado, busca identificar la varianza de la distribución de los efectos fijos del maestro, la cual captura la heterogeneidad de la fuerza laboral docente, y, por otro lado, muestra que elevar la calidad del maestro mejora los resultados de los estudiantes.

La crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes refiere a la calidad de los datos utilizados. La información que recogen no permite obtener datos coincidentes entre alumnos y docentes, en los que tanto el rendimiento del alumno como el de los maestros se observe en múltiples años. Este tipo de datos es necesario para la correcta identificación de los efectos fijos del maestro. Sin embargo, no está disponible para los investigadores, en gran parte porque los distritos escolares no utilizan datos en panel para fines de evaluación y, generalmente, la información utilizada en la literatura proviene, directamente, de los distritos escolares o de instituciones de investigación que han recopilado estos datos. Así, los trabajos previos a Rockoff (2004) presentan estimaciones inconsistentes, ya que, al no considerar las características inobservables relevantes para el resultado de las pruebas, sobreestiman el efecto de las características observables en el logro de los estudiantes.

Para poder superar esa limitación de la literatura previa, Rockoff (2004) utiliza un conjunto de datos en panel con información de puntajes de las pruebas de los estudiantes y de la asignación de maestros en las clases, para estimar, con mayor precisión, cuánto afectan los maestros al rendimiento de los estudiantes. Los datos sobre los puntajes permiten enfocarse en las diferencias en el desempeño de un mismo alumno con diferentes maestros y, así, distinguir la variación en la calidad del maestro de la variación en las habilidades cognitivas de los estudiantes y otras características. Observar al mismo maestro en varias aulas le permite diferenciar la calidad del maestro de factores como el tamaño de la clase. Vale aclarar que la identificación de los efectos fijos es posible gracias a que se observa a un mismo maestro dando clases a estudiantes en diferentes cursos.

Rockoff (2004) dispone de un panel con datos sobre estudiantes y maestros de dos distritos contiguos ubicados en un solo condado de New Jersey entre 1989 y 2001, evaluados entre pre-escolar y 6to. grado con pruebas estandarizadas y donde es posible identificar qué maestro da clases a cada estudiante. Esto último permite identificar el

efecto de cada maestro en sus alumnos y, al mismo tiempo, al contar con un panel, puede controlar por efectos fijos a nivel de cada estudiante para tener en cuenta el valor agregado que proporciona el maestro, lo cual no era posible realizar con los datos que disponían los estudios previos, cuestionados por el autor. Además, la longitud del panel posibilita que incluya la experiencia del docente como una variable explicativa.

(2) A continuación, se reproduce el modelo propuesto por Rockoff (2004):

$$A_{it} = \alpha_i + \gamma X_{it} + \sum_j [\theta^{(j)} + f(Exp_t^{(j)}) + \eta C_t^{(j)}] D_{it}^{(j)} + \sum_s \pi_{st} S_{it}^{(s)} + \varepsilon_{it}.$$

Explicar qué tipo de variables podrían estar siendo capturadas por el término α_i y por qué el autor incorpora el término no lineal $f(Exp_t^{(j)})$.

El modelo propuesto por Rockoff (2004) consiste en estimar el efecto sobre el puntaje de la prueba del estudiante i en el año t (A_{it}) de: efectos fijos del estudiante (α_i), características observables de los estudiantes que varían con el tiempo (X_{it}), efecto fijo del maestro ($\theta^{(j)}$), experiencia del docente ($Exp_t^{(j)}$), características observables del aula ($C_t^{(j)}$) y efecto del año escolar (π_{st}), en donde ε_{it} es el término de error del modelo. Las variables $D_{it}^{(j)}$ y $S_{it}^{(s)}$ son indicadoras de si el estudiante tuvo, respectivamente, al maestro j en la escuela s durante el año t .

Las variables que podrían estar siendo capturadas por el término α_i (características no observables de los estudiantes que podrían estar correlacionadas con el resultado de las pruebas) son: las capacidades cognitivas, las características socioeconómicas, la inteligencia, la educación en el hogar, la habilidad en general, la habilidad particular para la comprensión de textos y para las matemáticas, las motivaciones personales, entre otras cosas.

El autor incorpora el término no lineal $f(Exp_t^{(j)})$ para estimar el efecto de la experiencia de los docentes en las pruebas de los estudiantes. Lo hace de manera no lineal porque la experiencia y el año t son colineales para los maestros y, por lo tanto, la identificación de los efectos fijos de estos y de los efectos de la experiencia requiere una suposición con respecto a la forma de $f(Exp_t^{(j)})$. El autor asume que la experiencia adicional del maestro no afecta los resultados de las pruebas de los estudiantes después de un cierto punto de corte $\overline{Exp}$, lo cual es respaldado por investigaciones previas que sugieren que cualquier ganancia de experiencia se logra en los primeros años de enseñanza (Rivkin *et al.*, 2001). Al suponer que la experiencia no impacta después de alcanzados los 10 años, el autor acota el efecto de la experiencia y asume que éste es representable por un polinomio cúbico.

Parte III (Bonus).

El uso de efectos fijos cuando se trabaja con datos de panel ¿resuelve por completo el problema de endogeneidad? ¿Por qué? ¿Qué otro método se podría usar? Se puede encontrar una pista en el paper de Cornwell y Trumbull (1994) que se vio en clase.

En primer lugar, se dice que existe endogeneidad cuando hay correlación entre los regresores del modelo y el término de error, por lo que no se cumple el supuesto clásico de exogeneidad estricta:

$$E(u_i|x_i) \neq 0.$$

La existencia de endogeneidad puede darse por varias razones:

- Autocorrelación de los errores.
- Errores de medición.
- Variables omitidas.
- Simultaneidad.

Dadas las diversas razones por las cuales puede haber endogeneidad, no existe una única solución a este problema. Por lo tanto, cuando se trabaja con datos de panel, al considerarse sólo el caso de endogeneidad causada por la “heterogeneidad inobservable” (que puede ser considerada como una variable omitida), la utilización de efectos fijos no resuelve por completo el problema de endogeneidad, en el caso de que existan otras causas.

En el contexto de datos de panel, la utilización de efectos fijos es útil para resolver el problema de endogeneidad. Los datos de panel combinan cortes transversales (información de varios individuos en un momento dado) durante varios períodos de tiempo. El disponer de datos de panel constituye una ventaja porque se dispone de una mayor cantidad de datos y se puede hacer un seguimiento de cada individuo a través del tiempo, pero, al mismo tiempo, un inconveniente porque, si todas las cualidades relevantes del individuo no son observables, entonces, los errores individuales estarán correlacionados con los regresores y los estimadores de OLS serán inconsistentes.

Si no se disponen de todas las variables de influencia, entonces, $E(x'_{it}u_{it}) \neq 0$, es decir, los regresores no son ortogonales al término de error (presencia de heterogeneidad inobservable). En este caso, POLS será inconsistente y la utilización de efectos fijos permitiría resolver este problema, al incorporar variables *dummy* por individuo.

Sin embargo, cuando el modelo presenta variables independientes endógenas, los estimadores de OLS serán inconsistentes, ya que $E(x'_i u_i) \neq 0$, es decir, no existe ortogonalidad entre los regresores y el término de error. Como se mencionó anteriormente, esto puede ocurrir cuando las variables explicativas están sujetas a errores de medición, cuando hay variables explicativas relevantes que se han omitido en el modelo o cuando existe simultaneidad.

Para resolver este problema de endogeneidad, se utiliza el método de variables instrumentales (2SLS o 3SLS), cuando se dispone de “buenos instrumentos”, es decir,

variables que no pertenecen al modelo, no están correlacionadas con el término de error y están correlacionadas con las variables explicativas endógenas, condicionando por las variables explicativas exógenas.

En el *paper* de Cornwell y Trumbull (1994), se utiliza una estrategia empírica que permite resolver dos fuentes de endogeneidad: presencia de heterogeneidad inobservable y simultaneidad. Los autores presentan evidencia respecto de que el efecto de la habilidad del sistema de justicia criminal para disminuir el crimen es mucho más débil que lo que indicaban estudios previos. La utilización de datos de panel, donde la unidad de observación es el condado, permite a los autores controlar por aquellas características específicas a nivel condado que son inobservables y que podrían estar relacionadas con las variables de justicia criminal del modelo que estiman. Esto es un avance respecto de la literatura previa que ignoraba esta fuente de endogeneidad al hacer estimaciones de tipo *cross-section*, concentrándose en resolver la endogeneidad convencional (por simultaneidad), que surge de la dependencia entre la probabilidad de arresto o el tamaño de la fuerza policial con la tasa de criminalidad. Concretamente, los autores utilizan una estrategia empírica que combina el uso de variables instrumentales para resolver la endogeneidad proveniente de la simultaneidad y la utilización de datos de panel para resolver la endogeneidad que surge de la presencia de heterogeneidad inobservable, condicionando por los efectos del condado en las estimaciones.

Referencias.

Cornwell, C. y Trumbull, W. N. (1994). Estimating the Economic Model of Crime with Panel Data. *The Review of Economics and Statistics*, 76(2), 360-366. Recuperado de <https://www.jstor.org/stable/2109893>

Rockoff, J. E. (2004). The Impact of Individual Teachers on Student Achievement Evidence from Panel Data. *The American Economic Review*, 94(2), 247-252. Recuperado de <https://www.jstor.org/stable/3592891>

Evaluación Domiciliaria N° 2: **Selección Muestral y Censura.**

Modelo para el salario horario.

Considerar un modelo para el logaritmo del ingreso laboral horario en función de la edad y su cuadrado, junto con una serie de dummies por máximo nivel educativo alcanzado.

$$lilaho_i = \beta_0 + \beta_1 edad_i + \beta_2 edad_i^2 + \beta_3 pric_i + \beta_4 seci_i + \beta_5 secc_i + \beta_6 supi_i + \beta_7 supc_i + u_i. \quad (1)$$

(1) Estimar los parámetros del modelo mediante el método de MCO. Dar una interpretación económica de los resultados y explicar, brevemente, sobre la inconsistencia de sus estimaciones como consecuencia de un posible sesgo de selección en la muestra utilizada.

En esta estimación por MCO del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *pric*, que es estadísticamente significativa al 5%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación de Heckman en dos etapas y de la estimación de Heckman por máxima verosimilitud), que expresan que, en promedio y manteniendo todo lo demás constante:

- Al aumentar en un año la edad de la mujer, el ingreso laboral horario varía en 100 (0,041 - 0,00072 edad) %. Se puede observar que el efecto parcial de la edad comienza a ser negativo a partir de, aproximadamente, los 57 años de edad¹.
- Considerando que los retornos a la educación son iguales a 100 ($e^{\beta_j} - 1$) %, con $j = 3, 4, 5, 6, 7$, y comparado con una mujer con primaria incompleta: una mujer con primaria completa, secundaria incompleta, secundaria completa, superior incompleto y superior completo tiene un ingreso laboral horario un 12,4%, 41,6%, 93,9%, 130,3% y 241,4% mayor, respectivamente. Se puede observar que la brecha salarial por hora entre niveles educativos aumenta con la educación.

Debido a la existencia de un sesgo de selección en la muestra utilizada, que acontece cuando las muestras no son “aleatorias”, es decir, que no representan, adecuadamente, la población que se desea estudiar, es posible que las estimaciones sean inconsistentes. El caso de muestras de participantes del mercado laboral no es un caso de una selección aleatoria, sino de la autoselección de los individuos derivada de un proceso de maximización de utilidad. Al mismo tiempo, como el estudio sólo considera a los individuos que trabajan, se obtiene una muestra incompleta de la población (“autoseleccionada” de acuerdo con la decisión de los individuos por educarse), lo cual conduce a conclusiones erróneas (estimaciones inconsistentes y sesgadas) del efecto de la educación sobre el ingreso laboral. En este caso, al haber una “sobrerrepresentación” de la población educada en la muestra, se tiende a subestimar el efecto de la educación

¹ $\frac{\partial E(lilaho_i | x_1, \dots, x_p)}{\partial edad_i} = 0 \Leftrightarrow \beta_1 + 2\beta_2 edad_i = 0 \Leftrightarrow 2\beta_2 edad_i = -\beta_1 \Leftrightarrow edad_i^* = \frac{-\beta_1}{2\beta_2} = \frac{-0,041214}{2(-0,0003595)} = \frac{-0,041214}{-0,000719} \cong 57,32$; donde x_k , $k = 1, \dots, p$, son las variables independientes del modelo (1).

sobre el ingreso laboral, lo cual se puede observar en la menor magnitud (en comparación con las siguientes estimaciones) de los coeficientes estimados de las *dummies* por máximo nivel educativo alcanzado.

(2) Estimar, nuevamente, la ecuación de regresión del punto anterior implementando el método de Heckman en dos etapas utilizando a la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años como regresores de la ecuación de selección. Justificar cada una de las etapas del método indicando los supuestos en los que se basa.

En esta estimación de Heckman en dos etapas del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman por máxima verosimilitud).

Para resolver el problema de selección muestral, Heckman (1979) propone tratar el sesgo de selección como un problema de variable relevante omitida. En particular, al estimar por MCO usando la muestra seleccionada, λ (.) es una variable omitida. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman por máxima verosimilitud).

Para computar el estimador de Heckman en dos etapas, se consideran los siguientes supuestos del modelo de selección: (1) (y_{1i}, x_{1i}) se observa sólo si $y_{2i} = 1$; (2) (y_{2i}, x_{2i}) se observa para todos los individuos; (3) (u_{1i}, u_{2i}) son independientes de x_{2i} y tienen media cero (exogeneidad estricta); (4) $u_{2i} \sim \mathcal{N}(0, \sigma_2^2)$; (5) $E(u_{1i} | u_{2i}) = \gamma u_{2i}$; y se consideran las siguientes ecuaciones:

- Ecuación de regresión: $y_{1i} = x_{1i}'\beta_1 + u_{1i}$.
- Ecuación de selección: $y_{2i}^* = x_{2i}'\beta_2 + u_{2i}$.
- Variable observada: $y_{2i} = 1 (y_{2i}^* > 0)$.

En la primera etapa del método, se estima la ecuación de selección mediante un modelo Probit. En el caso del modelo (1), se estima una ecuación de participación en el mercado laboral, donde la variable dependiente es binaria, del tipo “participa” o “no participa”, en términos de ser o no ser observado un ingreso laboral (mujeres que estarán en la muestra). Esta ecuación se interpreta como la forma reducida de un modelo en el cual la decisión de participación en el mercado laboral (que es una variable binaria) depende de características personales y del nivel educativo del individuo y, a su vez, permite estimar la probabilidad predicha de la participación en el mercado laboral de una mujer con ciertas características, lo cual permite obtener una estimación consistente para λ . Se supone que el error de la ecuación de selección se distribuye bajo una distribución normal con media cero y varianza constante σ^2 .

En la segunda etapa del método, se estima por MCO una ecuación del logaritmo del ingreso laboral horario como función de la edad, del nivel educativo y de λ (probabilidad de participar en el mercado laboral). Éste es un modelo de determinación de ingresos a la Mincer, corregido por la presencia de sesgo de selección (λ).

Este método proporciona estimadores consistentes y asintóticamente normales, por lo que los métodos estándar de inferencia funcionan correctamente.

(3) *Implementar un test que ponga a prueba la hipótesis de ausencia de selección muestral indicando, claramente, las hipótesis, el estadístico de prueba, su distribución asintótica y el resultado del test. ¿Cuál es la utilidad de dicho test?*

La presencia de sesgo de selección puede ser evaluada mediante un test de significatividad de λ , donde se evalúa $\gamma^* \equiv \gamma\sigma_2$, con σ_2 desvío estándar del estimador de la ecuación de selección. Ya que σ_2 es mayor que cero, se puede evaluar la presencia de sesgo de selección mediante las siguientes hipótesis:

$$H_0: \gamma^* = 0; \quad H_a: \gamma^* \neq 0.$$

Bajo la hipótesis nula, γ^* es igual a cero, indicando que no existe sesgo de selección, en tanto que, bajo la hipótesis alternativa, γ^* es distinto de cero, indicando que existe sesgo de selección. Así, bajo H_0 , el estadístico de prueba es $\frac{\hat{\gamma}^*}{SE(\hat{\gamma}^*)} \rightarrow^d \mathcal{N}(0, 1)$, que tiene una distribución asintótica normal con media igual a cero y varianza constante igual a uno.

La utilidad de este test es que permite determinar si los errores estándar computados por MCO en la segunda etapa son correctos. Por lo tanto, considerando la segunda etapa, bajo la hipótesis nula, los errores serán homocedásticos, en tanto que, en el caso de rechazar la hipótesis nula, los errores serán heterocedásticos, ya que la varianza se altera por la censura/el truncamiento.

En el caso del modelo (1), ya que el p-valor es muy pequeño, se rechaza la hipótesis de nula (ver tabla 1) y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que existe sesgo de selección y que, por lo tanto, λ es estadísticamente significativo para explicar el logaritmo del ingreso laboral horario, es decir, la estimación por MCO es sesgada.

(4) *Computar el estimador de Heckman por máxima verosimilitud e indicar cuáles son los supuestos sobre los que se construye dicho estimador. Discutir sus ventajas y desventajas con respecto al método en dos etapas.*

En esta estimación de Heckman por máxima verosimilitud del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman en dos etapas).

Para computar el estimador de Heckman por máxima verosimilitud, se consideran las mismas ecuaciones mencionadas anteriormente y los mismos supuestos, excepto el supuesto (4), que se reemplaza por un supuesto más fuerte para poder computar la verosimilitud, que es distribución normal bivariada de los errores:

$$\begin{bmatrix} u_{1i} \\ u_{2i} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1 \\ \rho\sigma_1 & 1 \end{bmatrix} \right).$$

Una de las ventajas del estimador de Heckman por máxima verosimilitud con respecto al método en dos etapas es que es eficiente, considerando que la segunda etapa de este último, debido a la selección, es heterocedástica.

Sin embargo, si bien el estimador por máxima verosimilitud no tendría este problema, tiene dificultades prácticas de implementación: en primer lugar, requiere de supuestos demasiado estrictos sobre la distribución de los errores, ya que, mientras que, en el método en dos etapas, se requiere el supuesto de normalidad sobre u_{2i} , en el método por máxima verosimilitud, también se requiere este supuesto sobre u_{1i} ; la función de verosimilitud es complicada de calcular; y existen problemas de convergencia en la maximización numérica.

Tabla 1. Estimaciones del modelo (1).

		(1)	(2)	(3)
Variables		MCO	Heckman en dos etapas	Heckman por máxima verosimilitud
lilaho	edad	0,041*** (0,003)	0,064*** (0,007)	0,043*** (0,003)
	edad2	-0,000*** (0,000)	-0,001*** (0,000)	-0,000*** (0,000)
	pric	0,117** (0,046)	0,169*** (0,046)	0,122*** (0,042)
	seci	0,348*** (0,044)	0,440*** (0,048)	0,357*** (0,040)
	secc	0,662*** (0,045)	0,790*** (0,055)	0,674*** (0,042)
	supi	0,834*** (0,045)	0,973*** (0,057)	0,847*** (0,042)
	supc	1,228*** (0,044)	1,395*** (0,060)	1,244*** (0,041)
	_cons	4,396*** (0,069)	3,676*** (0,199)	4,328*** (0,078)
trabaja	edad	-	0,113*** (0,008)	0,112*** (0,008)
	edad2	-	-0,001*** (0,000)	-0,001*** (0,000)
	pric	-	0,2851*** (0,099)	0,285*** (0,099)
	seci	-	0,554*** (0,095)	0,553*** (0,099)
	secc	-	0,782*** (0,103)	0,784*** (0,103)
	supi	-	0,862*** (0,106)	0,869*** (0,105)
	supc	-	1,251*** (0,106)	1,254*** (0,106)
	asiste	-	-0,088 (0,054)	-0,096* (0,054)
	hijos12	-	-0,048** (0,021)	-0,047** (0,021)
	_cons	-	-1,790*** (0,174)	-1,774*** (0,174)
	/mills	-	0,618*** (0,158)	-
	/athrho	-	-	0,100* (0,060)
	/lnsigma	-	-	-0,537*** (0,006)
Observaciones		13,522	14,837	14,837
R^2		0,341	-	-

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

Modelo para las horas trabajadas.

(5) Considerar un modelo para las horas trabajadas en función de la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años. Estimar los parámetros utilizando un modelo Tobit y compararlos con la estimación de MCO. Discutir sobre lo adecuado de una y otra estrategia focalizando el análisis en el tipo de variable dependiente de este modelo.

$$hstrt_i = \beta_0 + \beta_1 edad_i + \beta_2 edad_i^2 + \beta_3 pric_i + \beta_4 seci_i + \beta_5 secc_i + \beta_6 supi_i + \beta_7 supc_i + \beta_8 asiste_i + \beta_9 hijos12_i + u_i. \quad (2)$$

En estas estimaciones (MCO y Tobit) del modelo (2), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 2, se muestran los resultados de estas estimaciones.

Para discutir lo adecuado de una y otra estrategia, se debe considerar un rasgo inherente a la variable dependiente (horas trabajadas), el cual es la censura. La muestra excluye información de aquellas mujeres que, por ejemplo, poseen un elevado ingreso laboral de reserva y que, por lo tanto, no participan en el mercado de trabajo, lo cual configura un sesgo de selección.

La estimación por MCO impone una relación lineal entre la variable dependiente censurada y las variables explicativas, pero el hecho de que la variable dependiente latente (inobservable) siga un modelo lineal no implica que la variable dependiente censurada (observada) siga este mismo modelo. En concreto, la variable censurada será una transformación no lineal de la variable latente y, por lo tanto, seguirá un modelo no lineal. Así, la estimación por MCO supone un problema de especificación para las horas trabajadas observadas, sesgando, potencialmente, a los estimadores. En el caso del modelo (2), el sesgo se debe al hecho de no poder observar a las mujeres que poseen altos ingresos laborales de reserva o un menor costo de oportunidad de permanecer desempleadas o cuyas características de capital humano les dificulta acceder a un puesto de trabajo. La estimación de un modelo Tobit permitiría resolver este sesgo, obteniendo estimadores consistentes.

Por un lado, si las características de las mujeres que no trabajan (excluidas de la muestra) no difieren de aquellas que trabajan (incluidas en la muestra), la exclusión no es un problema y, por lo tanto, la estimación por MCO será consistente; sin embargo, es muy probable que esto no se cumpla en el caso de las horas trabajadas, en particular considerando que el desempleo, en parte, se debe a la falta de capital humano. Por otro lado, si las características de las mujeres que trabajan (incluidas en la muestra) difieren de aquellas que no lo hacen, la exclusión es un problema y, por lo tanto, la estimación por MCO será inconsistente. En este caso, es necesario tener en cuenta estas diferencias al momento de querer estimar consistentemente el modelo (2). En el caso contrario (diferencias inexistentes o poco importantes), la estimación por MCO de este modelo puede resultar conveniente, ya que el sesgo de selección desaparece o se reduce y, por lo tanto, las estimaciones se asemejan a las del modelo Tobit, aprovechándose una de las ventajas de utilizar MCO, que es la interpretación directa de los coeficientes como efectos parciales.

Tabla 2. Estimaciones del modelo (2).

Variables	(1)	(2)
	MCO	Tobit
edad	1,737*** (0,082)	1,984*** (0,085)
edad2	-0,020*** (0,001)	-0,023*** (0,001)
pric	3,186** (1,284)	3,680*** (1,191)
seci	7,600*** (1,222)	8,484*** (1,137)
secc	9,560*** (1,245)	10,750*** (1,182)
supi	8,820*** (1,264)	10,195*** (1,205)
supc	10,723*** (1,223)	12,122*** (1,153)
asiste	-3,355*** (0,504)	-3,508*** (0,558)
hijos12	-2,250*** (0,200)	-2,379*** (0,214)
_cons	-6,647*** (1,978)	-13,671*** (1,970)
var (e.hstrt)	-	328,52*** (4,106)
Observaciones	14.837	14.837
R ²	0,0787	-

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(6) Utilizando el modelo Tobit, computar los efectos parciales de la edad y de la cantidad de hijos sobre: (a) el valor esperado de la variable censurada y (b) el valor esperado de la variable truncada. Dar una interpretación económica de los resultados.

En la tabla 3, se muestran los resultados de las estimaciones de los efectos parciales de la edad y de la cantidad de hijos menores a 12 años en el hogar sobre el valor esperado de las horas trabajadas. Para el caso de una mujer con edad promedio (aproximadamente, 40 años)², con secundaria completa y con dos hijos menores de 12 años en el hogar, se tienen los siguientes casos:

- Variable dependiente censurada: Al aumentar en un año la edad, las horas trabajadas aumentan, en promedio, en 1,67 y, al aumentar en un hijo la cantidad de hijos, las horas trabajadas disminuyen, en promedio, en 2,01.
- Variable dependiente truncada: Al aumentar en un año la edad, las horas trabajadas aumentan, en promedio, en 1,51 y, al aumentar en un hijo la cantidad de hijos, las horas trabajadas disminuyen, en promedio, en 1,81.

² Específicamente, la edad promedio de las mujeres de la muestra es 39,69897 años.

Tabla 3. *Estimaciones de efectos parciales del modelo (2).*

Variable	Efecto parcial	
	Censura	Truncamiento
edad	1,674*** (0,056)	1,512*** (0,056)
hijos12	-2,007*** (0,172)	-1,813*** (0,155)
Observaciones	14.387	14.387

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

Evaluación Domiciliaria N° 3: **Métodos no Paramétricos.**

Parte I: Desigualdad y salarios mínimos en México y Argentina.

En este ejercicio, se buscará replicar ciertos resultados del paper de Bosch y Manacorda (2008) usando datos de México y de Argentina. En dicho trabajo, se explora la contribución del salario mínimo sobre el aumento en la desigualdad de los salarios que tuvo lugar en México entre fines de los '80 y fines de los '90, analizando diferencias entre el sector formal e informal. La base de datos `base_Bosch&Manacorda.dta` contiene información del ingreso laboral mensual en la actividad principal para una muestra de trabajadores asalariados de entre 16 y 60 años, extraída de encuestas de hogares de Argentina y de México. En el caso de Argentina, se utilizó la Encuesta Permanente de Hogares (EPH) del año 1993 y del segundo semestre de 2004. Para México, se utilizó la Encuesta Nacional de Empleo Urbano (ENEU) para el primer trimestre de los años 1989 y 2001¹, agrupando los datos como Bosch y Manacorda (2008) en 3 zonas: de ingresos altos (Zona A), medios (Zona B) y bajos (Zona C). Para cada año (y zona, en el caso de México), se tiene un salario mínimo distinto². Además, para facilitar el trabajo, la base contiene la mediana de los salarios y los salarios mínimos de cada año.

(a) *Estimar la función de densidad del logaritmo del salario estandarizado correspondiente a Argentina para el segundo semestre del año 2004, mediante el estimador de kernels empleando un kernel Epanechnikov. Experimentar con tres anchos de banda alternativos: ancho de banda óptimo, mitad del óptimo y doble del óptimo. Mostrar gráficos reportando los parámetros de suavizamiento h utilizados en cada caso. Describir el comportamiento observado de la densidad estimada. Justificar. Explicar el criterio de optimalidad que se usó para computar el h óptimo.*

En la figura 1, a partir de la Encuesta Permanente de Hogares (EPH), se presenta la distribución estimada del logaritmo del salario estandarizado para Argentina para el segundo semestre de 2004, utilizando tres anchos de banda distintos y un kernel Epanechnikov.

En la primera figura, se observa la distribución estimada con un ancho de banda óptimo ($h = 0,1049$). Ésta presenta una forma suave con algo de ruido (en particular, en la cola izquierda), donde se observa una marcada concentración de las observaciones en el centro de la distribución y un mayor número de observaciones a la izquierda de la misma, lo cual indica que existe un mayor número de individuos con salarios menores al promedio que aquellos con salarios mayores al promedio. Además, la distancia entre el salario más bajo de la muestra y el salario medio es mayor a la distancia entre el salario medio y el salario más alto.

¹ Los datos son públicos y se encuentran disponibles en el sitio web del INDEC <https://www.indec.gob.ar/bases-de-datos.asp> (Argentina) y del INEGI <http://www.beta.inegi.org.mx/datos/> (México).

² La evolución del salario mínimo en Argentina puede consultarse en el sitio web del Ministerio de Trabajo Nacional <http://www.trabajo.gob.ar/estadisticas/Bel/ingresos.asp>; en el caso de México, el salario mínimo diario por zona puede consultarse en el sitio web del Servicio de Administración Tributaria (SAT) http://omawww.sat.gob.mx/informacion_fiscal/tablas_indicadores/Paginas/salarios_minimos.aspx.

En la segunda figura, se observa la distribución estimada con un ancho de banda igual a la mitad del óptimo ($h = 0,0525$). Ésta presenta una forma no tan suave con mucho más ruido (también en la cola izquierda) y más alta que la anterior, donde se observa más claramente la asimetría de la distribución con mayores observaciones hacia la izquierda.

En la tercera figura, se observa la distribución estimada con un ancho de banda igual al doble del óptimo ($h = 0,2098$). Ésta presenta una forma muy suave con muy poco ruido, donde no se aprecia con tanta claridad la asimetría de la distribución con mayores observaciones hacia la izquierda.

Como se puede observar, cuanto más chico es el h utilizado, más ruidosa será la función de densidad, por lo que la elección de la amplitud del ancho de banda determina las características cualitativas de la densidad estimada. Para N fijo, existe un *trade-off* entre sesgo y eficiencia de los estimadores de kernels³, ya que ambas propiedades dependen de la elección de h , pero de manera inversa: a menor h , menor sesgo y mayor varianza (menor eficiencia); a mayor h , mayor sesgo y menor varianza (mayor eficiencia). La elección óptima del ancho de banda hará un balance entre ambos para resolver el *trade-off*.


Por otra parte, para consistencia de la estimación, es suficiente con que sesgo y varianza tiendan a cero cuando $N \rightarrow \infty$. El sesgo lo hará si $h \rightarrow 0$ y la varianza cuando $N \times h \rightarrow 0$. Entonces, por un lado, se requiere que h decrezca con el tamaño muestral N y, por otro lado, que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N , así $N \times h \rightarrow \infty$. Este criterio lo cumplirá el h que minimiza el Error Cuadrático Medio Integrado (ECMI), que es una de las formas de elección de h que permiten resolver el *trade-off* entre sesgo y eficiencia para N fijo:

$$\text{ECMI} = \int E [\hat{f}(x) - f(x)]^2 dx = \int \{[\text{Sesgo } \hat{f}(x)]^2 + \text{Var} [\hat{f}(x)]\} dx.$$

Así, el ECMI promedia los ECM a lo largo de todos los posibles puntos de estimación, utilizando las expresiones aproximadas del sesgo y de la varianza.

³ La expresión aproximada para el sesgo del estimador de kernels viene dada por: $\text{Sesgo} [\hat{f}(x_0)] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{+\infty} K(\varphi) \varphi^2 d\varphi$. Y la expresión aproximada para la varianza asintótica del estimador de kernels viene dada por: $\text{Var} [\hat{f}(x_0)] \cong \frac{1}{N \times h} f(x_0) \int_{-\infty}^{+\infty} K^2(\varphi) d\varphi$.

Figura 1. Estimaciones de la función de densidad (utilizando Kernel Epanechnikov) del logaritmo del salario para Argentina (segundo semestre de 2004).




Fuente: Elaboración propia.

(b) Ídem inciso (a), pero experimentar con distintos tipos de funciones de Kernel. Mostrar gráficos y discutir.

En la figura 2, se presenta la distribución estimada del logaritmo del salario estandarizado para Argentina para el segundo semestre del año 2004, utilizando distintos kernels (Epanechnikov, Epanechnikov Modificado, Gaussiano y Triangular) y un ancho de banda óptimo ($h = 0,1049$).

Se puede observar que no hay diferencias significativas entre la estimación de la función de densidad mediante un kernel Epanechnikov y un kernel Gaussiano, la cuales resultan suaves y con cierta concentración en el centro de la distribución, con colas con poca densidad. En cambio, también se puede ver que el kernel Epanechnikov Modificado y el kernel Triangular presentan mucho más ruido que los mencionados anteriormente.

Figura 2. Estimaciones de la función densidad (utilizando distintos kernels) del logaritmo del salario para Argentina (segundo semestre de 2004).



Fuente: Elaboración propia.

(c) Una manera gráfica de ver el alcance del salario mínimo es a través de las funciones de densidad de la distribución de los salarios. Permiten visualizar más claramente cuán operativo es el salario mínimo en diferentes períodos y si el mismo afecta sólo a los trabajadores formales o si tiene efectos derrame hacia el sector informal. En este inciso, el objetivo es replicar las figuras del paper de Bosch y Manacorda (2008) usando los datos de México y de Argentina. En los ejercicios que siguen, para el caso de México, usar sólo la zona B (municipios de ingresos medios).


(c.1) Graficar las funciones de densidad de los salarios estandarizados estimadas por kernels, comparando los dos años disponibles para cada país (Argentina 1993 vs. 2004, por un lado, y México 1989 vs. 2001, por el otro), junto con líneas verticales indicando el salario mínimo correspondiente a cada año (gráficos similares a la figura 2 del paper).

En la figura 3, a partir de la Encuesta Permanente de Hogares (EPH) y de la Encuesta Nacional de Empleo Urbano (ENEU), se presentan las distribuciones estimadas del logaritmo del salario estandarizado para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001). Las líneas verticales indican el valor real del salario mínimo para cada país en los años considerados.

En el caso de Argentina, no se observan muchos cambios en la distribución de los salarios entre 1993 y el segundo semestre de 2004. Por un lado, en relación a 1993, en 2004, la distribución presenta un mayor número de observaciones en la cola izquierda, lo que indica que un mayor número de trabajadores reciben salarios menores que el promedio. Por otro lado, la concentración en el centro de la distribución se redujo marginalmente. Además, entre 1993 y 2004, el salario mínimo aumenta (representado por el movimiento de la línea vertical hacia la derecha) y pareciera no ser muy operativo.

En el caso de México, se observan algunos cambios en la distribución de los salarios entre 1989 y 2001. Entre estos años, el salario mínimo disminuye significativamente (representado por el movimiento de la línea vertical hacia la izquierda) y pareciera ser bastante operativo, lo cual se observa en que la distribución “engorda” a la izquierda del salario mínimo de 1989.

Figura 3. Estimaciones de la función de densidad del logaritmo del salario para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001)⁴.



Fuente: Elaboración propia.

(c.2) Construir, para cada año y cada país por separado, gráficos análogos a la figura 5 del paper, comparando las funciones de densidad del salario estandarizado para asalariados formales e informales. Describir los gráficos, analizando si el salario mínimo es operativo para el total de los asalariados, como así también para el sector formal e informal. Comparar los resultados para los diferentes años y entre ambos países.

En la figura 4, se presentan las distribuciones estimadas del logaritmo del salario estandarizado para asalariados formales e informales para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001). Las líneas verticales indican el valor real del salario mínimo para cada país en los años considerados.

En el caso de Argentina, se puede observar que:

- La distribución de los salarios de los trabajadores informales es más desigual en 2004 respecto de lo que era en 1993.

⁴ Para el caso de México, sólo se incluyen datos de la zona de municipios de ingresos medios.


- En 1993, la distribución de los salarios de los trabajadores formales y de los informales resulta similar, con la distribución de estos últimos ubicada un poco más “hacia la izquierda”, es decir, con niveles salariales menores que los que reciben los trabajadores formales.
- En 2004, la distribución de los salarios de trabajadores formales e informales difiere significativamente. Mientras que la distribución de los salarios de los trabajadores informales está más “aplanada” o con una marcada asimetría hacia la izquierda (es decir, con un mayor número de trabajadores que reciben salarios muy por debajo del promedio y del salario mínimo), la distribución de los salarios de los trabajadores formales tiene una mayor concentración en el centro y colas ligeramente densas.
- Respecto al salario mínimo, el mismo es operativo tanto para los trabajadores formales como para los informales. Se observa un agrupamiento de los salarios de los trabajadores informales en torno al mismo.

En el caso de México, se puede observar que:

- La distribución de los salarios de los trabajadores informales es más desigual en 2001 respecto de lo que era en 1989.
- En 1989, la distribución de los salarios de los trabajadores informales muestra un engrosamiento en el lado derecho (es decir, un mayor número de trabajadores que reciben salarios mayores al promedio), mientras que, en 2001, esto se invierte y esta distribución muestra un “engrosamiento” en el lado izquierdo (es decir, un mayor número de trabajadores que reciben salarios menores al promedio). Esto no sucede en el caso de la distribución de los salarios de los trabajadores formales.
- Respecto al salario mínimo, en 1989, el mismo es operativo tanto para los trabajadores formales como para los informales, con una mayor proporción de trabajadores informales en torno a este nivel salarial en relación a los trabajadores formales, en tanto que también hay un mayor número de trabajadores informales por debajo de este nivel para ese año; en 2001, el salario mínimo disminuye en relación con el de 1989, mostrando una mayor relevancia en el caso de los trabajadores informales, en tanto que sólo unos pocos trabajadores formales reciben salarios por debajo del salario mínimo.

En conclusión, los salarios de los trabajadores informales, tanto en Argentina como en México, parecen verse afectados por el salario mínimo. En Bosch y Manacorda (2008), se señala que este resultado no debería sorprendernos, ya que, en estos países (como en muchos de América Latina), el salario mínimo se ha utilizado como un índice de inflación, afectando a los trabajadores informales de manera directa. Al mismo tiempo, la dispersión de los salarios que se observa en ambos países hace que el salario mínimo afecte al salario de reserva del conjunto de los trabajadores (Freeman, 2007; Bosch y Manacorda, 2008), lo que explica la concentración de trabajadores en torno al nivel del salario mínimo.

Figura 4. Estimaciones de la función de densidad del logaritmo del salario estandarizado para trabajadores formales e informales para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2004)⁵.



Fuente: Elaboración propia.

⁵ Ídem nota al pie número 4.

Parte II: Estimación no paramétrica de curvas de Engel para Argentina.

(a) Estimar paramétricamente por mínimos cuadrados la relación entre la participación o share del gasto en alimentos (sh_g_alim) y el logaritmo del gasto total familiar ($lgastot$) usando: (i) una especificación lineal y (ii) una especificación cuadrática (es decir, donde se incluya un término lineal y otro cuadrático en la variable explicativa $lgastot$). Reportar los resultados de las estimaciones en una tabla. Comparar los resultados.

En la tabla 1, a partir de la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005, se presentan las estimaciones paramétricas por MCO de la relación entre la participación del gasto en alimentos y el logaritmo del gasto total familiar, utilizando una especificación lineal y una cuadrática.

En el caso de la especificación lineal, el coeficiente del gasto total familiar es negativo y esta variable es estadísticamente significativa, indicando que, ante un aumento de un 1% en el gasto total familiar, la participación del gasto en alimentos en éste disminuye, en promedio y ceteris paribus, en 0,0766 puntos porcentuales, en consonancia con lo indicado por la teoría económica (Ley de Engel). En el caso de la especificación cuadrática, las variables explicativas resultan estadísticamente no significativas para explicar esta relación. Por último, se puede mencionar que el poder explicativo de la estimación no varía con el cambio de especificación (el R^2 , prácticamente, no se altera).

Tabla 1. Estimaciones paramétricas (lineal y cuadrática).

Variables	(1)	(2)
	Especificación lineal	Especificación cuadrática
$lgastot$	-0,0766*** (0,0080)	-0,1360 (0,1240)
$lgastot^2$	- (0,0081)	0,0040 (0,0081)
constante	0,8722*** (0,0614)	1,0895*** (0,4723)
Observaciones	573	573
R^2	0,1669	0,1674

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.


(b) Estimar un modelo no paramétrico usando el estimador de Nadaraya-Watson (NW) para ajustar la relación entre sh_g_alim y $lgastot$. Utilizar un kernel Gaussiano y parámetro de suavizamiento $h = 0,18$. Graficar la regresión estimada no paramétricamente.

En la figura 5, se presenta una estimación no paramétrica de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar, utilizando el estimador de Nadaraya-Watson (NW), un kernel Gaussiano y un parámetro de suavizamiento $h = 0,18$.

Se puede observar una relación inversa entre ambas variables, en línea con lo observado por Engel. A medida que el gasto total familiar aumenta, la participación del

gasto en alimentos en éste disminuye, lo cual estaría indicando que el aumento del gasto en alimentos es menor que el aumento del gasto total familiar.

Figura 5. Estimación no paramétrica (estimador de Nadaraya-Watson).




Fuente: Elaboración propia.

(c) El objetivo de este inciso es comparar las estimaciones paramétricas del inciso (a) con la estimación no paramétrica del inciso (b). Se pide graficar todas las estimaciones en un mismo gráfico y superponer los intervalos de confianza del estimador no paramétrico. Sin hacer un test formal, ¿puede rechazarse la especificación del modelo paramétrico lineal? ¿y la del cuadrático?

En la figura 6, se presentan las estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador NW) de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar.

Se puede observar que las estimaciones paramétricas de esta relación se encuentran dentro del intervalo de confianza de la estimación no paramétrica. Por lo tanto, sin hacer un test formal, se puede expresar que no es posible rechazar la especificación del modelo paramétrico lineal y la del modelo cuadrático (aunque ésta resulta no significativa), ya que no pareciera haber evidencia de diferencias significativas entre los resultados obtenidos por los dos tipos de estimaciones (paramétrica y no paramétrica).

Figura 6. Estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

(d) Repetir los incisos (a), (b) y (c) usando el share del gasto en transporte (*sh_g_transp*) en lugar de *sh_g_alim*. Comentar los resultados.

En la tabla 2, a partir de la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005, se presentan las estimaciones paramétricas por MCO de la relación entre el share del gasto en transporte y el logaritmo del gasto total familiar, utilizando una especificación lineal y una cuadrática.


En el caso de la especificación lineal, el coeficiente del gasto total familiar es positivo y esta variable es estadísticamente significativa (pero sólo al 10%). En el caso de la especificación cuadrática, el coeficiente del gasto total familiar es negativo y el del gasto total familiar al cuadrado es positivo, en tanto que ambas son estadísticamente significativas, indicando que, a medida que el gasto total familiar aumenta, la participación del gasto en transporte en éste disminuye hasta un nivel determinado de gasto, a partir del cual la participación del mismo comienza a aumentar. Por último, se puede mencionar que el poder explicativo de la estimación varía significativamente con el cambio de especificación (el R^2 pasa de 0,0075 a 0,0224), aunque se encuentra en un nivel muy bajo.

Tabla 2. Estimaciones paramétricas (lineal y cuadrática).

Variables	(1)	(2)
	Especificación lineal	Especificación cuadrática
lgastot	0,0133* (0,0071)	-0,2540*** (0,0915)
lgastot2	-	0,0180*** (0,0062)
constante	0,0472 (0,0528)	1,027*** (0,3414)
Observaciones	563	563
R^2	0,0075	0,0224

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

En la figura 7, se presenta una estimación no paramétrica de la relación entre la participación del gasto en transporte en el gasto total familiar y el gasto total familiar, utilizando el estimador de Naradaya-Watson (NW). Se puede observar una concentración de las observaciones en los niveles bajos de la participación del gasto en transporte y mayor dispersión a medida que la participación del gasto en transporte en el gasto total familiar aumenta.

Figura 7. Estimación no paramétrica (estimador de Naradaya-Watson).


Fuente: Elaboración propia.

En la figura 8, se presentan las estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador NW) de la relación entre la participación del gasto en transporte en el gasto total familiar y el gasto total familiar.

A diferencia de los resultados obtenidos anteriormente para el gasto en alimentos, los dos tipos de estimaciones (paramétrica y no paramétrica) difieren considerablemente. La estimación del modelo paramétrico lineal no se encuentra dentro de los intervalos de confianza de la estimación no paramétrica a lo largo de toda la distribución y, además, los intervalos de confianza de ambas estimaciones no coinciden. Respecto de la estimación del modelo paramétrico cuadrático, se observa un mejor ajuste que para el caso de la del paramétrico lineal y se encuentra dentro de los intervalos de confianza de la estimación no paramétrica, prácticamente, a lo largo de toda la distribución; sin embargo, esta estimación tiene importantes diferencias con la no paramétrica a medida que nos alejamos (por izquierda y por derecha) del centro.

Por lo tanto, sin hacer un test formal, se puede expresar que es posible rechazar la especificación del modelo paramétrico lineal y la del modelo cuadrático, ya que hay evidencia de diferencias significativas entre los resultados obtenidos por los dos tipos de estimaciones (paramétrica y no paramétrica).

Figura 8. Estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

(e) Bonus. Aplicar el test de Zheng (1996) para evaluar la validez de las especificaciones paramétricas lineal y cuadrática contra la alternativa no paramétrica, tanto para el modelo del share del gasto en alimentos como para el del share del gasto en transporte. Reportar los resultados y comentar. ¿Se rechaza la especificación paramétrica lineal para un nivel de significatividad del 10%? ¿Y para un nivel del 5%? Para esos mismos niveles de significatividad, ¿se rechaza la especificación paramétrica cuadrática?

En la tabla 3, se presentan los resultados del test de Zheng, que contrasta la hipótesis nula de validez de la especificación paramétrica (lineal o cuadrática).

En el caso de la participación del gasto en alimentos en el gasto total familiar, para niveles de significatividad de 10% y 5%, estos datos no proporcionan evidencia suficiente para rechazar la hipótesis nula tanto de validez de la especificación paramétrica lineal como de la especificación paramétrica cuadrática. Respecto a la participación del gasto en transporte en el gasto total familiar, para el caso de la especificación paramétrica lineal, la hipótesis nula se rechaza para un nivel de significatividad de 10%, pero no para un nivel del 5%; y, para el caso de la estimación paramétrica cuadrática, la hipótesis nula no se rechaza para niveles de significatividad de 10% y 5%.

Tabla 3. *Test de Zheng (1996).*

Estimación		Share del gasto en alimentos	Share del gasto en transporte
No Paramétrica vs. Paramétrica (lineal)	Estadístico	0,9246	1,9078
	$T_n \rightarrow^d \mathcal{N}(0, 1)$		
	P-valor	0,3556	0,0569
H_0 : forma paramétrica lineal (basado en Zheng (1996))			
No Paramétrica vs. Paramétrica (cuadrática)	Estadístico	1,0717	0,2979
	$T_n \rightarrow^d \mathcal{N}(0, 1)$		
	P-valor	0,2843	0,7659
H_0 : forma paramétrica cuadrática (basado en Zheng (1996))			

Fuente: Elaboración propia.

Parte III.

El objetivo de este ejercicio será estimar la esperanza del share de los gastos en alimentos condicional en el logaritmo del gasto familiar, controlando por el número de hijos, a partir de la muestra total de hogares. A tal fin, se adoptará una especificación semiparamétrica parcialmente lineal para el nuevo modelo, donde el número de hijos se incorpora de manera completamente paramétrica suponiendo una función lineal, mientras que se sigue adoptando una especificación no paramétrica para el logaritmo del gasto total:

$$sh_g_alim = g(lgastot) + \beta nhijos + U,$$

donde $g(.)$ es una función desconocida, $nhijos$ es el número de hijos, β es un parámetro desconocido y U es un término aleatorio que se supone que satisface las condiciones requeridas para aplicar el método de Robinson (1988).

(a) *Estimar β mediante el método de Robinson (1988) usando un kernel Gaussiano. Explicar los pasos seguidos para la estimación. Dar la interpretación económica y estadística (significatividad) del coeficiente estimado.*

En la tabla 4, se presenta la estimación semiparamétrica de este modelo mediante el método de Robinson (1988), utilizando un kernel Gaussiano y un parámetro de suavizamiento $h = 0,22$.

Robinson (1988) propone transformar el modelo de manera tal de poder estimar consistentemente a β , a la tasa de convergencia $\sqrt{N}$, a pesar de la presencia del término no paramétrico, dado por $g(.)$. Para esto, se computa la esperanza condicional de sh_g_alim en $lgastot$ y, luego, se le resta al modelo original, obteniendo:

$$sh_g_alim - E(sh_g_alim | lgastot) = [nhijos - E(nhijos | lgastot)] \beta + U.$$

Ya que no se conocen los momentos condicionados de esta expresión, Robinson propone estimar en dos etapas (método residual):

1. Se estima $E(sh_g_alim | lgastot)$ y $E(nhijos | lgastot)$ mediante regresiones no paramétricas de sh_g_alim sobre $lgastot$ y $nhijos$ sobre $lgastot$, respectivamente, y se reservan los residuos parciales de ambas regresiones.
2. Se estima β mediante una regresión paramétrica por MCO entre ambos residuos parciales (sin constante, para que β se encuentre identificado).

El coeficiente β estimado mediante este método es positivo e igual a 0,0218, siendo la variable $nhijos$ estadísticamente significativa, indicando que un hijo adicional en comparación con el número promedio de hijos en el hogar aumenta la participación del gasto en alimentos en el gasto total familiar, con respecto al promedio, en 0,0218 puntos porcentuales.

Tabla 4. Estimación semiparamétrica (Método de Robinson, 1988).


Variable	sh_g_alim
nhijos	0,0218*** (0,0025)
Observaciones	1575
R^2	0,0463

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(b) Partiendo de la estimación de β obtenida en el inciso (a), estimar la parte no paramétrica del modelo, es decir, $g(\lgastot)$. Usar el estimador de Naradaya-Watson con kernel Gaussiano y parámetro de suavizamiento $h= 0,22$. Explicar, detalladamente, los pasos seguidos.

En la figura 9, se presenta una estimación no paramétrica de la relación entre la variable $s_g_alim_hijo$ y el gasto total familiar, utilizando el estimador de Naradaya-Watson (NW), un kernel Gaussiano y un parámetro de suavizamiento $h= 0,22$.

Utilizando el estimador β ($\hat{\beta}$) obtenido en el inciso anterior mediante el método de Robinson (1988), se estima la parte no paramétrica del modelo. Para esto, se genera la variable $s_g_alim_hijo$ de la siguiente manera: $s_g_alim_hijo = s_g_alim - \hat{\beta} \text{ nhijos}$.

Figura 9. Estimación no paramétrica (estimador de Naradaya-Watson).


Fuente: Elaboración propia.

(c) Considerar, nuevamente, un modelo totalmente no paramétrico que tenga como único regresor al $\lgastot$ (es decir, se excluye la variable explicativa $nhijos$) y estimarlo por Nadaraya-Watson para la muestra completa de hogares de la base de datos (usar otra vez un kernel Gaussiano y parámetro de suavizamiento $h = 0,22$). En un mismo gráfico, se pide mostrar esta estimación junto con la estimación de $g(\lgastot)$ hallada en el inciso (b). Incluir también los intervalos de confianza al 95% de esta última. ¿Qué se observa? Justificar.

En la figura 10, se presentan la estimación semiparamétrica (inciso (b)) y no paramétrica (estimador NW) de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar, utilizando un kernel Gaussiano y un parámetro de suavizamiento $h = 0,22$.

Se puede observar que ambas estimaciones no difieren sustancialmente, notándose un movimiento similar entre ambas. No obstante, la estimación no paramétrica no se encuentra dentro del intervalo de confianza de la estimación semiparamétrica, siendo la amplitud de este intervalo sumamente estrecha. Esto se puede deber al hecho de que el número de hijos en el hogar es una variable relevante para explicar la participación del gasto en alimentos en el gasto total familiar y, al mismo tiempo, el gasto total familiar no es independiente del número de hijos en el hogar.

Figura 10. Estimación semiparamétrica y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

Referencias.

- Blundell, R. y Duncan, A. (1998). Kernel Regressions and Empirical Microeconomics. *The Journal of Human Resources*, 33(1), 62-87. Recuperado de <https://www.jstor.org/stable/146315>
- Bosch, M. y Manacorda, M. (2008). Minimum Wages and Earnings Inequality in Urban Mexico. Revisiting the Evidence. *CEP Discussion Paper*, 880. Recuperado de <http://cep.lse.ac.uk/pubs/download/dp0880.pdf>