

Practice Exam Questions

June 14 - July 5, 2019

1. Consider a linear bivariate regression model with an intercept: $y_i = \beta_0 + \beta_1 x_i + u_i$.
 - (a) Write the model in vector notation. Be clear about the dimension of the vectors, etc.
 - (b) Show that the linear conditional mean model $x'\beta$ minimizes the expected quadratic error loss, and therefore, β can be interpreted as the best linear predictor. Obtain a formula for β based on the moments of x_i and y_i .
 - (c) Using the method of moments, show that under some assumptions, we can obtain an unbiased estimator for β . State the assumptions.
 - (d) Assume that the variance of the error term is constant, say $V(u_i) = \sigma^2$. Derive the variance of $\hat{\beta}_0$ and $\hat{\beta}_1$.
2. Consider again the linear bivariate regression model: $y_i = \beta_0 + \beta_1 x_i + u_i$.
 - (a) Assuming that x_i is a continuous independent variable, define β_1 as a function of the conditional mean model and provide an interpretation.
 - (b) What is the definition of β_0 ?
 - (c) Assuming that $x_i = \{0, 1\}$ is a binary discrete variable, define β_1 as a function of the conditional mean model and provide an interpretation.
3. The demand for Colombia coffee in the US is assumed to be determined by the following function

$$q = \beta_0 + \beta_1 p_c + \beta_2 p_b + \beta_3 p_d + u$$

where q denotes imports of Colombian coffee in the US, p_c denotes the price of Colombian coffee, p_b stands for the price of Brazilian coffee, and p_d is the price of Italian coffee. All variables are in natural log.

- (a) Suppose you estimate the equation using OLS considering $n = 200$ observations,

$$\begin{aligned} \hat{E}(q|p_c, p_b, p_d) &= 2.837 - 1.481p_c + 1.181p_b + 0.186p_d \\ &\quad (2.000) \quad (0.987) \quad (0.650) \quad (0.134) \end{aligned}$$

with the sum of square residuals $RSS = 0.4277$. Also,

$$\hat{E}(q|p_c, p_b, p_d) = -0.738 - p_c + 0.199p_d$$

(0.820) (1.011) (0.155)

with $RSS = 0.4485$. Test the following hypothesis using a 5 % level of significance: (i) $H_0 : \beta_1 = -1$; (ii) $H_0 : \beta_2 = 0$. Then test the null hypothesis that $H_0 : \beta_1 = -1$ and $\beta_2 = 0$. What do you conclude? (Critical values: 1.96 for the t distribution; 2.99 for the F distribution; 5.99 for the χ^2_2).

- (b) A referee argues that the error u might be heteroskedastic. Explain how you would answer her/his question. Be explicit about the test, null hypothesis and alternative hypothesis. If the R-square of a regression of $\hat{u}^2$ on covariates is 0.1, would you worry about heteroskedastic errors?
- (c) Suppose you reject the null hypothesis in (b) and you note that p_c is 10 times larger than p_b in one month (but not in the other months). Explain how you would estimate the model. Explain also what are the practical caveats associated with the implementation of your method(s).

4. Consider the following linear model:

$$E(y|x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2, \quad (1)$$

where x_1 and x_2 have zero means.

- (a) Write an equation for the dependent variable y and state the assumptions for the error term u as implied by the conditional mean model (1).
- (b) Find the partial effect of $E(y|x_1, x_2)$ with respect to x_1 . What is the interpretation of β_1 ?
- (c) Construct an elasticity with respect to a change in x_j .
- (d) Explain how you will estimate the elasticity you constructed before and state the assumptions needed for obtaining an unbiased and consistent result.

5. Consider a location model,

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$$

where the *iid* variable $u_1 \sim u_2(0, \sigma^2)$. Show that pooling the data and estimating $\beta = \beta_1 = \beta_2$ reduces the variability of $\hat{\beta}_j$.

6. Show that $M \equiv I - X(X'X)^{-1}X'$ is an orthogonal projection matrix. Show that the residual vector $\hat{u} = Mu$ is orthogonal to the fitted vector $\hat{y}$.

7. Consider,

$$y = X_1\beta_1 + X_2\beta_2 + u$$

where $Euu' = \sigma^2 I$. Suppose you have

$$\tilde{\beta}_1 = (X_1'X_1)^{-1}X_1'y$$

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$$

- (a) Explain the difference between the estimators.
 - (b) Define M_2 and check if it is idempotent. Are $\tilde{\beta}_1$ and $\hat{\beta}_1$ biased? Explain.
 - (c) Find the expression for $\hat{\beta}_1 = \tilde{\beta}_1 - B\hat{\beta}_2$.
 - (d) Show that an application of the FWL theorem gives an estimator that is numerically equivalent to $\hat{\beta}_1$ and the standard error of $\hat{\beta}_1$.
 - (e) If the error u is not homocedastic, would the covariance between $\tilde{\beta}_1$ and $B\hat{\beta}_2$ be zero? Why is this result important?
8. Let A be a nonsingular matrix of the form,

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \quad (2)$$

- (a) Derive the partitioned inverse formula

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}^{-1} = \begin{bmatrix} W^{-1} & -W^{-1}A_{12}A_{22}^{-1} \\ -A_{22}^{-1}A_{21}W^{-1} & A_{22}^{-1} + A_{22}^{-1}A_{21}W^{-1}A_{12}A_{22}^{-1} \end{bmatrix}$$

where $W = A_{11} - A_{12}A_{22}^{-1}A_{21}$ (HINT: solve for the partitioned elements of B from the formula $AB = I$)

- (b) Use the previous formulae to derive the OLS estimator for $\hat{\beta}_1$ constructively from the fitting formula

$$\hat{\beta} = (X'X)^{-1}X'y = \begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix}^{-1} \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix}$$

- (c) Find the conditional variance of $\hat{\beta}_1$ assuming that the error term $u \equiv y - X\beta$ is normally distributed, say $u \sim \mathcal{N}(0, \sigma^2)$
9. Considering the following regression model,

$$y = X\beta + Z\alpha + u$$

with $X \perp Z$. Suppose you estimate the model with using least squares methods. Show that (i) $\hat{\alpha}$ does not depend on X and (ii) $Cov(\hat{\beta}, \hat{\alpha}) = 0$.

10. Let $\hat{\beta}$ be the OLS estimator and $\tilde{\beta}$ any other linear unbiased estimator. Show that if $E(u|X) = 0$ and $E(uu'|X) = \sigma^2 I$ in a linear regression model, then the OLS estimator is efficient e.g. $V(\tilde{\beta}|X) \geq V(\hat{\beta}|X)$ or

$$V(\tilde{\beta}|X) - V(\hat{\beta}|X) \text{ is positive semi-definite}$$

11. State, demonstrate mathematically, and explain the practical implications of the Frish-Waugh-Lovell Theorem.
12. Consider the following model

$$y = X\beta + u$$

where the mean of the error term is zero and the covariance between x_i and u_i is zero.

- Assuming that the error term u_i is correlated with u_j , how you would estimate the parameter β and the standard error of $\hat{\beta}$? Why?
 - Explain what are the issues of estimating the standard error of $\hat{\beta}$ by OLS.
 - Suppose now that the $Cov(u_j, u_i) = 0$ for all i and j and the conditional variance is $E(uu'|X) \equiv \Omega$. Obtain the best linear unbiased estimator and its variance. Show that the error term of the transformed model has constant variance.
 - Explain the steps needed to implement the method suggested in (c).
 - Show that the difference between the variance of the OLS estimator and the variance of the estimator you proposed in (c) is positive-semi definite.
13. Consider a random sample $Z_1, Z_2, \dots, Z_m$ distributed independently from a uniform distribution $\mathcal{U}[0, \theta]$.
- Obtain a consistent estimator of θ .
 - Show that the estimator is consistent, explaining the role of the assumptions needed to establish consistency.
14. State the conditions under which the OLS estimator for a linear model $y = X\beta + u$ is consistent and asymptotically normal. Prove the consistency of the estimator and obtain the variance of the asymptotic distribution.
15. Consider the first equation in a linear system of equations,

$$y_1 = \alpha_1 Y_2 + x' \beta + u_1 \tag{3}$$

where Y_2 is the (suspected) endogenous variable. Show that the OLS estimator of the following equation,

$$y_1 = \alpha_1 Y_2 + x' \beta + \gamma \hat{r} + v_1 \quad (4)$$

is identical to the 2SLS estimator. ($\hat{r}$ denotes the residuals from $Y_2 = z'_i \pi + r_i$, where the variable z 's are exogenous).

16. Considering the following regression model,

$$y_i = x'_i \beta + \epsilon_i \quad (5)$$

with $\mathbb{E}(\epsilon_i | x_i) = 0$ and known $\mathbb{E}(\epsilon_i^2 | X_i) = \sigma^2$.

- (a) Show that the generalized least squares estimator can be written as an instrumental variable estimator.
 - (b) Write the expression for the instrumental variable.
17. (a) Show that the following assumption implies orthogonality between the random variable in x_i and the random variable $y_i - x'_i \beta$:

$$\mathbb{E}[x_i(y_i - x'_i \beta_0)] = 0 \quad (6)$$

Give additional conditions on the joint distribution of x_i and y_i that make β_0 the unique solution to

$$\mathbb{E}[x_i(y_i - x'_i \beta)] = 0 \quad (7)$$

- (b) Show that the OLS estimator $\hat{\beta}$ is analogous to β_0 in the sense that it is the unique solution to

$$\frac{1}{n} \sum x_i(y_i - x'_i \beta) = 0 \quad (8)$$

where sample moments have replaced population moments. This is an example of a method-of-moments estimator, which constructs parameter estimators that equate empirical moments with population counterparts.

18. Consider a regression model

$$y_i = x'_i \beta + \epsilon_i \quad i = 1, \dots, n$$

in which ϵ_i is a latent random variable that is correlated with the explanatory variable in x_i . Let the elements of x_i include the constant 1. Assume *iid* sampling and that

$$\begin{aligned} \mathbb{E}[\epsilon_i] &= 0 \\ \text{Var}[\epsilon_i] &= \sigma_0^2 \end{aligned}$$

and

$$\mathbb{E}[x_i x_i'] = D_{xx}$$

where D_{xx} is a positive-definite matrix. In addition, let $Cov[x_i, \epsilon_i] = \rho_0$.

- (a) Consider the sample moments of (x_i, y_i) : $\bar{x} \equiv (1/n) \sum_{i=1}^n x_i$, $\bar{y} \equiv (1/n) \sum_{i=1}^n y_i$, $(1/n)X'X$, $(1/n)y'y$, and $(1/n)X'y$. Find their expected values in terms of the unknown parameters
- (b) Suppose that there are K instrumental variables, z_{ik} ($k = 1, \dots, K$) that are uncorrelated with ϵ_i ,

$$Cov[z_i, \epsilon_i] = 0$$

yet correlated with x_i ,

$$\mathbb{E}[z_i x_i'] = D_{zx}$$

where D_{zx} is also nonsingular. Find the expected values of the additional sample moments $(1/n) \sum_{i=1}^n z_i$, $(1/n)Z'Z$, and $(1/n)Z'X$ in terms of the unknown parameters.

- (c) By equating all the first and second sample moments above to their population values, find a method-of-moments estimator for all of the unknown parameters. Show in particular that the estimator of β_0 is the IV estimator $(Z'X)^{-1}Z'y$
19. Find the maximum likelihood estimator for the unknown parameter θ considering the following distributions:
- (a) $f(x, \theta) = \theta \exp\{-\theta x\}$, with $x \geq 0$ and $\theta > 0$
 - (b) $f(x, \theta) = \theta c^\theta x^{-(\theta+1)}$, with $x \geq c$, $\theta > 0$
 - (c) $f(x, \theta) = x\theta^{-2} \exp\{-x^2/2\sigma^2\}$, $x > 0$, $\theta > 0$
 - (d) $f(x, \theta) = \sigma^{-1} \exp\{-(x - \mu)/\sigma\}$, $x \geq \mu$ where $\theta = (\mu, \sigma)$
 - (e) $x_1, \dots, x_n$ from a distribution $u[\theta - 1/2, \theta + 1/2]$.
 - (f) $x_1, \dots, x_n$ from $\mathcal{N}(\mu_1, \sigma^2)$ and $Y_1, \dots, Y_n$ iid from $\mathcal{N}(\mu_2, \sigma^2)$. Note that $\theta = (\mu_1, \mu_2, \sigma^2)$
20. Suppose X is a continuous random variable with probability density function $f(x, \theta_0)$. Assume continuous second order derivatives. Show that $\mathbb{E}(\partial l(\theta_0|x)/\partial \theta) = 0$. Assuming that $Var(\partial l(\theta_0|x)/\partial \theta) \exists$, show that:

$$\mathbb{E}\left(\frac{\partial^2 l(\theta_0|x)}{\partial \theta \partial \theta'}\right) = -Var\left(\frac{\partial l(\theta_0|x)}{\partial \theta}\right)$$

Evaluación domiciliaria 1: Modelos para datos en panel

Prof. Mariana Marchionni
(marchionni.mariana@gmail.com)

Ayudantes: Jessica Bracco (braccojessica@gmail.com) e Ivana Benzaquen
(ivanabenzaquen@gmail.com)

Fecha y forma de entrega: miércoles 21 de agosto; entregar impreso.

Reglas: se puede trabajar en grupos, pero **la elaboración y entrega deben ser individuales**.

PARTE I

Una herramienta para estudiar empíricamente la relación entre los salarios de los trabajadores y sus características son las llamadas ecuaciones de ingresos o ecuaciones de Mincer (Mincer, 1974). Considere el siguiente modelo:

$$(1) \ln \text{salario}_{it} = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_{it} + \beta_3 \text{casado}_{it} + \beta_4 \text{sindicato}_{it} + \beta_5 \text{afro}_i + \beta_6 \text{hispano}_i + u_{it}$$

donde *lnsalario* es el logaritmo de los salarios por hora; *educ* son los años de educación formal; *exper* son los años de experiencia laboral; *casado* es una dummy que indica si el trabajador es casado; *sindicato* es una dummy que indica si el trabajador pertenece a un sindicato; *afro* e *hispano* son dummies que indican si el individuo es de origen afroamericano o hispano, respectivamente (la categoría base es blanco no hispano); y *u* es un término aleatorio que varía entre individuos y en el tiempo.

En este ejercicio vamos a estimar este modelo utilizando la base de datos *nls8087.dta*, que cuenta con información extraída de la National Longitudinal Survey (Youth Sample) para el periodo 1980-1987. La muestra comprende 545 hombres jóvenes (17 a 30 años de edad) que trabajan a tiempo completo y que para 1980 ya habían finalizado su escolaridad.

El objetivo es que los alumnos se familiaricen con la situación de realizar un análisis empírico con datos de panel. El análisis requiere que adopten cierta tecnología computacional específica (ver la nota computacional al final del TP) y realicen un análisis de los resultados a la luz de los conocimientos teóricos discutidos en clase.

Se pide:

1. Muestre estadísticas descriptivas de las variables incluidas en el modelo teniendo en cuenta la estructura de panel (variabilidad total, between y within). Descríbalas brevemente y discuta por qué para ciertas variables la variabilidad within es cero, mientras que la between no lo es.
2. Estime la ecuación (1) por pooled OLS (POLS). Interprete estadística y económicamente los coeficientes obtenidos. Explique por qué es muy posible que la presencia de heterogeneidad no observable a nivel de trabajador haga que las estimaciones

anteriores sean inconsistentes. ¿Por qué el modelo Within con efectos fijos por trabajador permitiría resolver este problema?

3. Estime nuevamente el modelo 1 mediante los siguientes estimadores alternativos: between, within, primeras diferencias y efectos aleatorios. Interprete cuidadosamente el coeficiente estimado de la variable *exper* para cada uno de los modelos. Para la interpretación, preste especial atención a cuál es la dimensión del panel (corte transversal o longitudinal) relevante para identificar el efecto en cada caso. Luego, comente por qué en el modelo de efectos fijos y de primeras diferencias se omiten la variables *educ*, *afro* e *hispano*.
4. A partir de las estimaciones anteriores:
 - a. Para cada uno de los estimadores del inciso anterior, explique cuáles son los supuestos que se requieren para consistencia.
 - b. Implemente un test para evaluar la hipótesis nula de ausencia de efectos fijos. Provea una interpretación del resultado.
 - c. Implemente un test de Hausman para comparar los estimadores de efectos fijos y de efectos aleatorios y comente los resultados obtenidos.

PARTE II

Este ejercicio se basa en el artículo de Rockoff, J. (2004) "The Impact of Individual Teachers on Student Achievement: Evidence from Panel Data" (American Economic Review, 94(2), pp. 247-252). El objetivo es ilustrar con un ejemplo cómo los datos en panel permiten responder a preguntas que no podrían responderse con otro tipo de datos. Como primera consigna se pide que lea detenidamente el artículo de Rockoff (2004); luego responda las siguientes preguntas.

- a. Explique cuál es la crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes. ¿De qué se vale Rockoff para superar esa limitación de la literatura previa?
- b. A continuación se reproduce el modelo propuesto por Rockoff (2004).

$$A_{it} = \alpha_i + \gamma X_{it} + \sum_j (\theta^{(j)} + f(\text{Exp}_t^{(j)}) + \eta C_t^{(j)}) D_{it}^{(j)} + \sum_s \pi_{st} S_{it}^{(s)} + \varepsilon_{it}$$

Explique qué tipo de variables podrían estar siendo capturadas por el término α , y por qué el autor incorpora el término no lineal $f(\text{Exp}_t^{(j)})$.

PARTE III (bonus no obligatorio)

El uso de efectos fijos cuando se trabaja con datos de panel ¿resuelve por completo el problema de endogeneidad? ¿Por qué? ¿Qué otro método se podría usar? Puede encontrar una pista en el paper de Cornwell y Trumbull (1994) que vimos en clase.

Nota computacional

Estos son algunos comandos útiles en Stata 13. Ver el help para más detalles.

El comando **xtsum** se utiliza para realizar estadísticas descriptivas de datos en formato de panel. El comando **xtreg** permite estimar modelos de regresión para datos en paneles. Combinado con las opciones **fe** o **re** permite estimar el modelo de efectos fijos o de efectos aleatorios, respectivamente.

Luego de estimar un modelo de efectos aleatorios es posible implementar un test de Hausman usando el comando **hausman**, de la siguiente forma:

```
xtreg yvar xlist, fe
estimates store fixed
xtreg yvar $xlist, re
estimates store random
hausman fixed random
```

Trabajo Práctico: Selección muestral y Censura

Prof. Javier Alejo
(javieralejo@gmail.com)

Ayudantes: Jessica Bracco (braccojessica@gmail.com) e Ivana Benzaquen
(ivanabenzaquen@gmail.com)

Fecha de entrega: miércoles 4 de septiembre.

Reglas: ver al final del trabajo práctico.

El objetivo de este trabajo práctico es revisar algunas los tópicos de selección muestral y censura, ambos muy utilizados en la literatura de Economía Laboral. En particular, vamos a considerar una ecuación de Mincer junto con un modelo de oferta laboral.¹ Los datos se encuentran en el archivo *ech-laboral-mujeres.dta*, el cual contiene una detallada descripción de los mismos en las etiquetas de las variables. Se trata de una muestra de mujeres entre 15 y 65 años de edad que viven en Montevideo. Los datos fueron extraídos de la Encuesta Continua de Hogares de Uruguay para el año 2014. El trabajo consiste en desarrollar los siguientes puntos:

Modelo para el salario horario

Considere un modelo para el logaritmo del ingreso laboral horario en función de la edad y su cuadrado, junto con una serie de dummies por máximo nivel educativo alcanzado.

1. Estime los parámetros del modelo mediante el método de MCO. Dé una interpretación económica de sus resultados y explique brevemente sobre la inconsistencia de sus estimaciones como consecuencia de un posible sesgo de selección en la muestra utilizada.
2. Estime nuevamente la ecuación de regresión del punto anterior implemente el método de Heckman en dos etapas utilizando a la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años como regresores de la ecuación de selección. Justifique cada una de las etapas del método indicando los supuestos en los que se basa.
3. Implemente un test que ponga a prueba la hipótesis de ausencia de selección muestral indicando claramente las hipótesis, el estadístico de prueba, su distribución asintótica y el resultado del test. ¿Cuál es la utilidad de dicho test?

¹ El práctico está inspirado en los modelos utilizados en el trabajo de Gasparini, L., Marchionni, M. y Sosa Escudero, W. (2004) "Characterization of inequality changes through microeconomic decompositions. The case of Greater Buenos Aires", en Bourguignon, F., Lustig, N y Ferreira, F. (eds.), 2004 (pp. 47- 82).

4. Compute el estimador de Heckman por máximo verosimilitud e indique cuales son los supuestos sobre los que se construye dicho estimador. Discuta sus ventajas y desventajas con respecto al método en dos etapas.

Modelo para las horas trabajadas

5. Considere un modelo para las horas trabajadas en función de la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años. Estime los parámetros utilizando un modelo Tobit y compárelos con la estimación de MCO. Discuta sobre lo adecuado de una y otra estrategia focalizando su análisis en el tipo de variable dependiente de este modelo.
6. Utilizando el modelo Tobit, compute los efectos parciales de la edad y la cantidad de hijos sobre: (a) el valor esperado de la variable censurada y (b) el valor esperado de la variable truncada. Dé una interpretación económica a sus resultados.

Reglas de presentación

- La entrega es en formato impreso y debe seguir todas las reglas de presentación y respetar el formato de incisos del enunciado.
- La extensión máxima del trabajo es 5 páginas tamaño A4, escrito en computadora con letra no menor a 11pt, espaciado simple y márgenes normales (no menos de 3 cm de lado y 2.5 cm de espacio superior e inferior). No incluir apéndices de ningún tipo, todo el material relevante tiene que estar incluido en las 5 páginas (tablas, gráficos, ecuaciones, notas al pie, etc.). Es factible que se descuenten puntos por no seguir este formato.
- Se espera un análisis serio y meticuloso así como una redacción correcta y bien cuidada. Es decir, no se aceptan salidas de regresión copiadas desde Stata y/o fragmentos de código pegados en el cuerpo del texto. Utilicen tablas bien descritas y ordenadas, como las que encuentran en los papers sugeridos en el curso.
- Se puede trabajar en grupos, pero la elaboración y entrega deben ser individuales.

Nota computacional

Estos son algunos comandos útiles en Stata 13. Ver el help para más detalles.

El comando **Heckman** permite estimar un modelo con selección mediante el uso del método de Heckman. La opción *twostep* especifica que el procedimiento de estimación es el correspondiente a las dos etapas mientras que el default implementa el estimador de máxima verosimilitud.

El comando **tobit**, por otra parte, permite estimar un modelo tobit de datos censurados.

Evaluación domiciliaria 3: Métodos no paramétricos

Prof. Mariana Marchionni
(marchionni.mariana@gmail.com)

Ayudantes: Jessica Bracco (braccojessica@gmail.com) e Ivana Benzaquen (ivanabenzaquen@gmail.com)

Fecha de entrega: miércoles 18 de septiembre; entregar impreso.

Reglas: se puede trabajar en grupos, pero la **elaboración y entrega deben ser individuales**.

PARTE I. Desigualdad y salarios mínimos en México y Argentina

El objetivo de este ejercicio es comenzar a familiarizarse con algunos comandos de STATA que se usan para la estimación no paramétrica de densidades. Para ello se buscará replicar ciertos resultados del paper de Bosch y Manacorda (2008)¹ usando datos de México y Argentina. En dicho trabajo se explora la contribución del salario mínimo sobre el aumento en la desigualdad de los salarios que tuvo lugar en México entre fines de los '80 y fines de los '90, analizando diferencias entre el sector formal e informal.

La base de datos *base_Bosch&Manacorda.dta* contiene información del ingreso laboral mensual en la actividad principal para una muestra de trabajadores asalariados de entre 16 y 60 años, extraída de encuestas de hogares de Argentina y México. En el caso de Argentina se utilizó la *Encuesta Permanente de Hogares* (EPH) del año 1993 y del segundo semestre de 2004. Para México se utilizó la *Encuesta Nacional de Empleo Urbano* (ENEU) para el primer trimestre de los años 1989 y 2001², agrupando los datos como Bosch y Manacorda (2008) en 3 zonas: de ingresos altos (Zona A), medios (Zona B) y bajos (Zona C).

Para cada año (y zona, en el caso de México) se tiene un salario mínimo distinto³. Además, para facilitar el trabajo, la base contiene la mediana de los salarios y los salarios mínimos de cada año. Utilizando estos datos se pide:

- a) Estimar la función de densidad del logaritmo del salario estandarizado⁴ correspondiente a Argentina para el segundo semestre del año 2004, mediante el estimador de kernels empleando

¹ Bosch, M. y M. Manacorda (2008). Minimum wages and earnings inequality in urban Mexico: Revisiting the evidence. CEP Discussion Paper 880, Centre for Economic Performance, London.

² Los datos son públicos y se encuentran disponibles en el sitio web del INDEC <https://www.indec.gob.ar/bases-de-datos.asp> (Argentina) y del INEGI <http://www.beta.inegi.org.mx/datos/> (México)

³ La evolución del salario mínimo en Argentina puede consultarse en el sitio web del Ministerio de Trabajo Nacional <http://www.trabajo.gob.ar/estadisticas/Bel/ingresos.asp>; en el caso de México, el salario mínimo diario por zona puede consultarse en el sitio web del Servicio de Administración Tributaria (SAT): http://omawww.sat.gob.mx/informacion_fiscal/tablas_indicadores/Paginas/salarios_minimos.aspx

un kernel Epanechnikov. Experimentar con tres anchos de banda alternativos: ancho de banda óptimo, mitad del óptimo y doble del óptimo. Mostrar gráficos reportando los parámetros de suavizamiento h utilizados en cada caso. Describir el comportamiento observado de la densidad estimada. Justificar. Explicar el criterio de optimalidad que se usó para computar el h óptimo.

Nota computacional: el comando `kdensity` de STATA estima no paramétricamente la densidad usando el método de promedios ponderados o Kernels. Por defecto, utiliza un kernel Epanechnikov y un ancho de banda óptimo.

- b) Ídem inciso (a), pero experimentar con distintos tipos de funciones de Kernel. Mostrar gráficos y discutir.
- c) Una manera gráfica de ver el alcance del salario mínimo es a través de las funciones de densidad de la distribución de los salarios. Permiten visualizar más claramente cuán operativo es el salario mínimo en diferentes períodos y si el mismo afecta sólo a los trabajadores formales o tiene efectos derrame hacia el sector informal. En este inciso el objetivo es replicar las figuras del paper de Bosch y Manacorda (2008) usando los datos de México y Argentina. En los ejercicios que siguen, para el caso de México usar solamente la zona B (municipios de ingresos medios).
 - c1. Graficar las funciones de densidad de los salarios estandarizados estimadas por kernels, comparando los dos años disponibles para cada país (Argentina 1993 vs 2004 por un lado, México 1989 vs 2001 por el otro), junto con líneas verticales indicando el salario mínimo correspondiente a cada año (gráficos similares a la figura 2 del paper).
 - c2. Construir para cada año y cada país por separado, gráficos análogos a la figura 5 del paper, comparando las funciones de densidad del salario estandarizado para asalariados formales e informales. Describa los gráficos, analizando si el salario mínimo es operativo para el total de los asalariados, como así también para el sector formal e informal. Compare los resultados para los diferentes años y entre ambos países.

PARTE II. Estimación no paramétrica de curvas de Engel para Argentina

El análisis de la curva de Engel provee una aplicación particularmente útil sobre las ventajas que tiene la utilización de regresiones no-paramétricas. Las curvas de Engel describen cómo cambia la participación de un bien en el gasto total cuando varía el nivel de gasto total de un individuo u hogar. En 1857, Ernst Engel observó que manteniendo constantes los precios, la demanda de ciertos bienes, como los

⁴ Al trabajar con datos de diferentes años se debe tener en cuenta que los ingresos están expresados en moneda corriente. Una forma de corregir esto es expresarlos en pesos constantes deflactando por algún índice de precios. Alternativamente, Bosch y Manacorda (2008) estandarizan el salario por el salario mediano contemporáneo de cada zona. Esto es,
 $\log(\text{salario}/\text{salario_mediano}) = \log(\text{salario}) - \log(\text{salario_mediano})$.

Para estandarizar el salario mínimo siguen el mismo procedimiento.

alimentos, pierde participación en el gasto total a medida que el ingreso del consumidor aumenta (Ley de Engel).

Blundell y Duncan (1998) realizan un análisis de curvas de Engel del consumo alimentario y el gasto en alcohol para ilustrar la implementación de varias alternativas de estimación de regresiones no-paramétricas y semiparamétricas, utilizando la encuesta de gastos de hogares *British Family Expenditure Survey* (FES)⁵.

El objetivo de este ejercicio es estimar las curvas de Engel para los gastos en alimentos y en transporte para el caso argentino utilizando la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005. La ENGH es una encuesta de alcance nacional, que releva detalladamente los gastos de las familias en las principales áreas urbanas de la Argentina, así como varias características socioeconómicas y demográficas de los hogares. La base *ENGH0405_Engel.dta* contiene información a nivel hogar de los gastos en alimentos y transporte, así como de los gastos totales, para hogares formados por una pareja sin hijos que habitan en la Ciudad de Buenos Aires⁶.

La primera tarea consiste en leer las secciones I, II y III del artículo de Blundell y Duncan (1998). Después se pide:

- a) Estimar paramétricamente por mínimos cuadrados la relación entre la *participación o share del gasto en alimentos* (*sh_g_alim*) y el *logaritmo del gasto total* (*lgastot*) familiar usando: i) una especificación lineal y ii) una especificación cuadrática (es decir, donde se incluya un término lineal y otro cuadrático en la variable explicativa *lgastot*). Reportar los resultados de las estimaciones en una tabla. Comparar los resultados.
- b) Estimar un modelo no paramétrico usando el estimador de Nadaraya-Watson (NW) para ajustar la relación entre *sh_g_alim* y *lgastot*. Utilizar un kernel Gaussiano y parámetro de suavizamiento $h = 0.18$. Graficar la regresión estimada no paramétricamente.

Ayuda: en STATA, el comando *lpoly* con la opción *degree(0)*, estima un modelo no paramétrico usando NW. Para más detalles consultar el help de STATA.

- c) El objetivo de este inciso es comparar las estimaciones paramétricas del inciso (a) con la estimación no paramétrica del inciso (b). Se pide graficar todas las estimaciones en un mismo

⁵ Blundell, R. and A. Duncan (1998). "Kernel Regression in Empirical Microeconomics", *The Journal of Human Resources*, Vol. 33, No. 1, pp. 62-87. Es un resumen compacto y didáctico que recorre varios métodos de estimación no paramétrica, ejemplificando su aplicación con la estimación de curvas de Engel.

⁶ Esta restricción impuesta sobre la muestra de estimación responde al objetivo de aislar los factores demográficos (tamaño y composición familiar) que pueden afectar el gasto en ciertos bienes más allá del presupuesto total del hogar. Por esta razón, Blundell y Duncan (1998) también trabajan con una muestra que sólo incluye hogares conformados por parejas sin hijos.

gráfico, y superponer los intervalos de confianza del estimador no paramétrico. Sin hacer un test formal, ¿puede rechazarse la especificación del modelo paramétrico lineal? ¿y la del cuadrático?

Ayudas:

i) Notar que el comando *lpoly* admite la opción *ci* mediante la cual obtiene los intervalos de confianza asintóticos alrededor de la estimación no paramétrica. Los intervalos vienen dados por:

$$\hat{m}(x) \pm z_{\left(\frac{1-\alpha}{2}\right)} \hat{\sigma}(\hat{m}(x))$$

donde z es el valor crítico de una distribución normal estándar correspondiente a un nivel de significatividad α , y $\hat{\sigma}(\hat{m}(x))$ es la estimación del error estándar asintótico, que puede obtenerse con la opción *se* del comando *lpoly*.

ii) Para poder graficar las estimaciones paramétricas lineal y cuadrática junto con la no paramétrica, el comando *lpoly* acepta la opción *addplot(line yhat lgastot || line yhat2 lgastot)*, donde la variable *yhat* se obtiene de aplicar el comando *predict* luego de las regresiones estimadas en el punto (a).

- d) Repetir los incisos a), b) y c) usando el *share del gasto en transporte* (*sh_g_transp*) en lugar de *sh_g_alim*. Comentar los resultados.
- e) Bonus. Aplicar el test de Zheng (1996) para evaluar la validez de las especificaciones paramétricas lineal y cuadrática contra la alternativa no paramétrica, tanto para el modelo del *share del gasto en alimentos* como para el del *share del gasto en transporte*.⁷ Reportar los resultados y comentar. ¿Se rechaza la especificación paramétrica lineal para un nivel de significatividad del 10%? ¿Y para un nivel del 5%? Para esos mismos niveles de significatividad ¿se rechaza la especificación paramétrica cuadrática?

Ayuda:

El programa *zheng.do* (ver archivo adjunto) realiza el test de Zheng (1996) para un Kernel gaussiano y ancho de banda óptimo. Para poder realizar el test es necesario correr el programa *zheng.do*, y luego utilizar la siguiente sintaxis.


- Para una especificación lineal: *zheng varname1 varname2*, donde *varname1* corresponde a la variable dependiente y *varname2* a la variable independiente.
- Para una especificación cuadrática: *zheng varname1 varname2 varname3*, donde *varname3* corresponde al término cuadrático.

⁷ Zheng, J. X. (1996). "A consistent test of functional form via nonparametric estimation techniques". *Journal of Econometrics* 75, pp. 263-289.

Parte III. Estimación de una regresión semiparamétrica parcialmente lineal (Robinson, 1988)

En el ejercicio anterior se estimaron curvas de Engel para los gastos en alimentos de hogares constituidos por parejas sin hijos. La motivación de este nuevo ejercicio es evaluar cómo las características demográficas de los hogares (tamaño familiar) pueden afectar a las curvas de Engel y, eventualmente, incorporar esas variables al análisis.

En la siguiente figura se muestran las regresiones estimadas del *share* del gasto en alimentos (*sh_alim*) en el logaritmo del gasto total familiar (*lgastot*) usando un estimador local-constante. Los datos utilizados están en la base *ENGH0405_Engel_semipar.dta*. Cada línea surge de estimar la curva de Engel para una sub-muestra de los hogares de esa base: (i) sólo parejas sin hijos, (ii) sólo parejas con 1 hijo, (iii) sólo parejas con 2 hijos y (iv) sólo parejas con al menos 3 hijos. Las diferencias que se observan entre las regresiones sugieren que el tamaño familiar explica cambios del *share* en alimentos más allá del gasto total familiar.



El objetivo de este ejercicio será estimar la esperanza del *share* de los gastos en alimentos condicional en el logaritmo del gasto familiar, controlando por el número de hijos, a partir de la muestra total de hogares. A tal fin adoptaremos una especificación semiparamétrica parcialmente lineal para el nuevo modelo, donde el número de hijos se incorpora de manera completamente paramétrica suponiendo una función lineal, mientras que seguimos adoptando una especificación no paramétrica para el logaritmo del gasto total:

$$sh_g_alim = g(lgastot) + \beta nhijos + U$$

donde $g(\cdot)$ es una función desconocida, $nhijos$ es el número de hijos, β es un parámetro desconocido y U es un término aleatorio que suponemos que satisface las condiciones requeridas para aplicar el método de Robinson (1988).

Como primera tarea se recomienda leer la sección IV de Blundell y Duncan (1998). Luego se pide:

- a) Estimar β mediante el método de Robinson (1988) usando un kernel gaussiano. Explicar los pasos seguidos para la estimación. Dar la interpretación económica y estadística (significatividad) del coeficiente estimado.
Ayuda: Para esta estimación utilizar el comando *semipar* con las opciones requeridas en el inciso.
- b) Partiendo de la estimación de β obtenida en el inciso (a), estimar la parte no paramétrica del modelo, es decir, $g(lgastot)$. Usar el estimador de Naradaya-Watson con kernel gaussiano y parámetro de suavizamiento $h = 0.22$. Explicar detalladamente los pasos seguidos.
- c) Considerar nuevamente un modelo totalmente no paramétrico que tenga como único regresor al $lgastot$ (es decir, se excluye la variable explicativa $nhijos$), y estimarlo por Naradaya-Watson para la muestra completa de hogares de la base de datos (usar otra vez un kernel gaussiano y parámetro de suavizamiento $h = 0.22$). En un mismo gráfico se pide mostrar esta estimación junto con la estimación de $g(lgastot)$ hallada en el inciso (b). Incluir también los intervalos de confianza al 95% de esta última. ¿Qué observa? Justificar.