

Practique Exam Questions

Ejercicio 1.

Considerar un modelo de regresión lineal bivariado con una intersección:

$$y_i = \beta_0 + \beta_1 x_i + u_i.$$

(a) Escribir el modelo en notación vectorial. Ser claro sobre la dimensión de los vectores, etc.

$$\underset{1 \times 1}{y_i} = \underset{1 \times 2}{x_i'} \underset{2 \times 1}{\beta} + \underset{1 \times 1}{u_i}, \quad \text{para } i = 1, 2, \dots, n,$$

donde y es la variable de respuesta para el sujeto i y x_i' es un vector de 2 variables independientes que incluye una intersección. En notación matricial, el modelo se puede escribir como:

$$\underset{n \times 1}{y} = \underset{n \times 2}{X} \underset{2 \times 1}{\beta} + \underset{n \times 1}{u},$$

donde y es un vector de $(n \times 1)$, X es una matriz de $(n \times 2)$, β es un vector de (2×1) y u es un vector de $(n \times 1)$. Es decir:

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}; \quad X = \begin{bmatrix} 1 & x_{11} \\ 1 & x_{21} \\ \vdots & \vdots \\ 1 & x_{n1} \end{bmatrix}; \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}; \quad u = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}.$$

(b) Mostrar que el modelo de media condicional lineal $x'\beta$ minimiza la pérdida de error cuadrática esperada y, por lo tanto, β puede interpretarse como el mejor predictor lineal. Obtener una fórmula para β basada en los momentos de x_i y y_i .

$$\begin{aligned} \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y - x'\beta)'(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[(y' - \beta'x)(y - x'\beta)] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E[y^2 - y'x'\beta - \beta'xy + (x'\beta)^2] \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y - 2\beta'xy + \beta'xx'\beta) \quad (*) \text{ y } (**) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - E(2\beta'xy) + E(\beta'xx'\beta) \\ \min_{\beta} E[(y - x'\beta)^2] &= \min_{\beta} E(y'y) - 2\beta' E(xy) + \beta' E(xx') \beta. \end{aligned}$$

$$\begin{aligned} (*) \quad (x'\beta)^2 &= (x'\beta)'(x'\beta) \\ (x'\beta)^2 &= \beta'xx'\beta. \end{aligned}$$

(**) $\beta'xy$ es un escalar, por lo que es, trivialmente, igual a su transpuesto, $y'x'\beta$.

Tomando la condición de primer orden, se tiene:

$$-2 E(xy) + 2 E(xx') \beta = 0 \quad (***) \text{ y } (****)$$

$$2 E(xx') \beta = 2 E(xy)$$

$$\beta = \frac{2E(xy)}{2E(xx')}$$

$$\hat{\beta} = [E(xx')]^{-1} E(xy)$$

$$\hat{\beta} = \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \frac{1}{n} \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = \left(\sum_{i=1}^n x_i x_i'\right)^{-1} \sum_{i=1}^n x_i y_i$$

$$(***) \frac{\partial(b'a)}{\partial b} = a, \quad \text{donde } a \text{ y } b \text{ son dos vectores de dimensiones } (2 \times 1).$$

$$(***) \frac{\partial(b'Ab)}{\partial b} = 2Ab, \quad \text{donde } b \text{ es un vector de dimensión } (2 \times 1) \text{ y } A \text{ es una matriz simétrica de dimensión } (2 \times 2).$$

Por lo tanto, el parámetro $\hat{\beta}$ se puede interpretar como el mejor predictor lineal bajo la pérdida de error al cuadrado. Tener en cuenta que, para que exista, se necesita la dimensión (2×2) de la matriz $E(xx')$ para ser invertible. También se necesita que $E(y^2) < \infty$ y $E(\sum_j x_j^2) < \infty$.

(c) Usando el método de momentos, demostrar que, según algunas suposiciones, se puede obtener un estimador insesgado para β . Enunciar los supuestos.

Se tienen las siguientes suposiciones:

- $E(u) = E(y - \beta_0 - \beta_1 x) = 0$.
- $\text{Cov}(x, u) = E(xu) - E(x)E(u) = xE(u) - E(x) \cdot 0 = x \cdot 0 - 0 = 0 - 0 = 0$.

Estas dos ecuaciones son restricciones impuestas a los datos sobre la distribución de probabilidad conjunta de x e y . Hay dos incógnitas y dos ecuaciones, lo que sugiere que se puede resolver para β_0 y β_1 . La contraparte de la muestra de estas ecuaciones es:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0.$$

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - \beta_0 - \beta_1 x_i)] = 0.$$

De la primera ecuación, se obtiene:

$$\begin{aligned} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) &= 0 * n \\ \sum_{i=1}^n y_i - \sum_{i=1}^n \beta_0 - \sum_{i=1}^n \beta_1 x_i &= 0 \\ n\bar{y} - n\beta_0 - n\beta_1 \bar{x} &= 0 \\ n(\bar{y} - \beta_0 - \beta_1 \bar{x}) &= 0 \\ \bar{y} - \beta_0 - \beta_1 \bar{x} &= 0 * n \\ \bar{y} - \beta_0 - \beta_1 \bar{x} &= 0 \end{aligned}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

De la segunda ecuación y considerando el resultado anterior, se obtiene:

$$\begin{aligned} \sum_{i=1}^n \{x_i [y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) - \hat{\beta}_1 x_i]\} &= 0 * n \\ \sum_{i=1}^n [x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i)] &= 0 \\ \sum_{i=1}^n \{x_i [(y_i - \bar{y}) - \hat{\beta}_1 (x_i - \bar{x})]\} &= 0 \\ \sum_{i=1}^n [x_i (y_i - \bar{y}) - \hat{\beta}_1 x_i (x_i - \bar{x})] &= 0 \\ \sum_{i=1}^n x_i (y_i - \bar{y}) - \sum_{i=1}^n \hat{\beta}_1 x_i (x_i - \bar{x}) &= 0 \\ \sum_{i=1}^n x_i (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= 0 \\ \hat{\beta}_1 \sum_{i=1}^n x_i (x_i - \bar{x}) &= \sum_{i=1}^n x_i (y_i - \bar{y}) \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i (y_i - \bar{y})}{\sum_{i=1}^n x_i (x_i - \bar{x})} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned}$$

Por lo tanto, se tiene que, utilizando el método de momentos, $\hat{\beta}_0$ y $\hat{\beta}_1$ son los estimadores para los parámetros de la intersección y de la pendiente del modelo de regresión lineal simple.

Se puede demostrar que, bajo los siguientes supuestos:

- A1 (Linealidad): El modelo es lineal y
- A2 (Exogeneidad estricta): $E(u | x_1, x_2, \dots, x_p) = 0$,

los estimadores son insesgados, es decir, los valores esperados de los estimadores son iguales a los parámetros desconocidos.

Para demostrar que el estimador del parámetro de la pendiente es insesgado, se parte de:

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) y_i \quad (*) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x})(\beta_0 + \beta_1 x_i + u_i) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n [\beta_0 (x_i - \bar{x}) + \beta_1 (x_i - \bar{x}) x_i + (x_i - \bar{x}) u_i] \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\sum_{i=1}^n \beta_0 (x_i - \bar{x}) + \sum_{i=1}^n \beta_1 (x_i - \bar{x}) x_i + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_0 \sum_{i=1}^n (x_i - \bar{x}) + \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \quad (**) \\ \hat{\beta}_1 &= \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} [\beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (x_i - \bar{x}) u_i] \\ \hat{\beta}_1 &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i. \end{aligned}$$

$$\begin{aligned} (*) \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y} - \sum_{i=1}^n \bar{x} y_i + \sum_{i=1}^n \bar{x} \bar{y} \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i y_i - \bar{x} y_i) - \bar{y} \sum_{i=1}^n x_i + n \bar{x} \bar{y} \end{aligned}$$

$$\begin{aligned}\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x}) y_i - n\bar{y}\bar{x} + n\bar{x}\bar{y} \\ \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \sum_{i=1}^n (x_i - \bar{x}) y_i.\end{aligned}$$

$$\begin{aligned}(**) \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - \sum_{i=1}^n 2x_i\bar{x} + \sum_{i=1}^n \bar{x}^2 \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x}\bar{x} + n\bar{x}^2 \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n x_i x_i - \sum_{i=1}^n x_i \bar{x} \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i x_i - x_i \bar{x}) \\ \sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i - \bar{x}) x_i.\end{aligned}$$

Tomando esperanza, se tiene:

$$\begin{aligned}E(\hat{\beta}_1) &= E\left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ E(\hat{\beta}_1) &= E(\beta_1) + E\left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n E[(x_i - \bar{x}) u_i] \\ E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) E(u_i) \\ E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) * 0 \\ E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n 0 \\ E(\hat{\beta}_1) &= \beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} n * 0 \\ E(\hat{\beta}_1) &= \beta_1 + 0 \\ E(\hat{\beta}_1) &= \beta_1.\end{aligned}$$

Y, para demostrar que el estimador del parámetro de la intersección es insesgado, se parte de:

$$\begin{aligned}\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_0 &= \beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}.\end{aligned}$$

Tomando esperanza, se tiene:

$$\begin{aligned}E(\hat{\beta}_0) &= E(\beta_0 + \beta_1 \bar{x} + \bar{u} - \hat{\beta}_1 \bar{x}) \\ E(\hat{\beta}_0) &= E(\beta_0) + E(\beta_1 \bar{x}) + E(\bar{u}) - E(\hat{\beta}_1 \bar{x}) \\ E(\hat{\beta}_0) &= \beta_0 + \bar{x} \beta_1 + E\left(\frac{1}{n} \sum_{i=1}^n u_i\right) - \bar{x} E(\hat{\beta}_1) \\ E(\hat{\beta}_0) &= \beta_0 + \bar{x} \beta_1 + \frac{1}{n} \sum_{i=1}^n E(u_i) - \bar{x} \beta_1 \\ E(\hat{\beta}_0) &= \beta_0 + \frac{1}{n} \sum_{i=1}^n 0 \\ E(\hat{\beta}_0) &= \beta_0 + \frac{1}{n} n * 0 \\ E(\hat{\beta}_0) &= \beta_0 + 0 \\ E(\hat{\beta}_0) &= \beta_0.\end{aligned}$$

Esto se puede observar también de la siguiente manera. Para obtener el estimador del método de momentos para el modelo lineal, recordar la condición de momento:

$$\begin{aligned} E(x_i u_i) &= E[E(x_i u_i | x)] \\ E(x_i u_i) &= E[x_i E(u_i | x)] \\ E(x_i u_i) &= E(x_i * 0) \\ E(x_i u_i) &= E(0) \\ E(x_i u_i) &= 0, \end{aligned}$$

o, alternativamente:

$$E[x_i (y_i - x_i' \beta)] = 0,$$

donde $x_i' = [1 \quad x_{i1}]$ y $\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}$. El estimador MM podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] = 0.$$

Resolviendo, se tiene:

$$\begin{aligned} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 * n \\ \sum_{i=1}^n (x_i y_i - x_i x_i' \beta) &= 0 \\ \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \beta &= 0 \\ \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x_i' &= 0 \\ \beta \sum_{i=1}^n x_i x_i' &= \sum_{i=1}^n x_i y_i \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i. \end{aligned}$$

También se puede escribir como:

$$\begin{aligned} \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i (x_i' \beta + u_i) \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n (x_i x_i' \beta + x_i u_i) \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} (\sum_{i=1}^n x_i x_i' \beta + \sum_{i=1}^n x_i u_i) \\ \hat{\beta} &= (\sum_{i=1}^n x_i x_i')^{-1} (\sum_{i=1}^n x_i x_i' \beta + \sum_{i=1}^n x_i u_i) \\ \hat{\beta} &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i u_i. \end{aligned}$$

Tomando esperanza, se tiene:

$$\begin{aligned} E(\hat{\beta}) &= E[\beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i u_i] \\ E(\hat{\beta}) &= E(\beta) + E[(\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i u_i] \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i E(u_i) \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i * 0 \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n 0 \\ E(\hat{\beta}) &= \beta + (\sum_{i=1}^n x_i x_i')^{-1} * n * 0 \\ E(\hat{\beta}) &= \beta + 0 \\ E(\hat{\beta}) &= \beta. \end{aligned}$$

Por lo tanto, usando el método de momentos y bajo las suposiciones A1 y A2, se puede obtener un estimador insesgado para β , ya que $E(\hat{\beta}) = \beta$.

(d) Suponer que la varianza del término de error es constante, digamos $V(u_i) = \sigma^2$. Derivar la varianza de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Se establecen los siguientes supuestos:

- A4 (Homocedasticidad): $\text{Var}(u_i | x) = \sigma^2$.
- A5 (Errores no correlacionados): $\text{Cov}(u_i, u_j) = 0$ para $i, j = 1, \dots, i-1, i+1, \dots, n$.

En otras palabras, la varianza del término de error es constante (no cambia con x) y el error u_i es independiente de u_j para $i \neq j$. Las suposiciones A4 y A5 juntas implican errores esféricos o, más precisamente, varianza de error esférico.

Considerando A4 y A5, las varianzas de los estimadores se obtienen de la siguiente manera:

$$\begin{aligned} \text{Var}(\hat{\beta}_1) &= \text{Var}\left[\beta_1 + \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ \text{Var}(\hat{\beta}_1) &= \text{Var}(\beta_1) + \text{Var}\left[\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ \text{Var}(\hat{\beta}_1) &= 0 + \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \text{Var}\left[\sum_{i=1}^n (x_i - \bar{x}) u_i\right] \\ \text{Var}(\hat{\beta}_1) &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \left[\sum_{i=1}^n \text{Var}[(x_i - \bar{x}) u_i]\right] \\ \text{Var}(\hat{\beta}_1) &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}(u_i) \\ \text{Var}(\hat{\beta}_1) &= \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 \\ \text{Var}(\hat{\beta}_1) &= \sigma^2 \frac{1}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \\ \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned} \quad \text{Varianza de } \hat{\beta}_1.$$

$$\begin{aligned} \text{Var}(\hat{\beta}_0) &= \text{Var}(\bar{y} - \hat{\beta}_1 \bar{x}) \\ \text{Var}(\hat{\beta}_0) &= \text{Var}\left(\bar{y} - \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} \bar{x}\right) \\ \text{Var}(\hat{\beta}_0) &= \text{Var}\left\{\sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right] y_i\right\} \\ \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \text{Var}\left\{\left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right] y_i\right\} \\ \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 \text{Var}(y_i) \\ \text{Var}(\hat{\beta}_0) &= \sum_{i=1}^n \left[\frac{1}{n} - \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 \sigma^2 \quad (***) \text{ y } (****) \\ \text{Var}(\hat{\beta}_0) &= \sigma^2 \sum_{i=1}^n \left\{\frac{1}{n^2} + \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 - \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right\} \\ \text{Var}(\hat{\beta}_0) &= \sigma^2 \left\{\sum_{i=1}^n \frac{1}{n^2} + \sum_{i=1}^n \left[\frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right]^2 - \sum_{i=1}^n \frac{2}{n} \frac{\bar{x}(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}\right\} \end{aligned}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left\{ \frac{n}{n^2} + \sum_{i=1}^n \frac{\bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left\{ \frac{1}{n} + \frac{\sum_{i=1}^n \bar{x}^2 (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - \frac{2}{n} \bar{x} * 0 \right\} \quad (*****)$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left\{ \frac{1}{n} + \frac{\bar{x}^2 \sum_{i=1}^n (x_i - \bar{x})^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} - 0 \right\}$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n (x_i^2 + \bar{x}^2 - 2x_i\bar{x}) + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + \sum_{i=1}^n \bar{x}^2 - \sum_{i=1}^n 2x_i\bar{x} + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n\bar{x}^2 - 2n\bar{x}\bar{x} + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2 + n\bar{x}^2 - 2n\bar{x}^2 + n\bar{x}^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]$$

$$\text{Var}(\hat{\beta}_0) = \sigma^2 \left[\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right]. \quad \text{Varianza de } \hat{\beta}_0.$$

$$\begin{aligned} (***) \text{Var}(y_i) &= \text{Var}(\beta_0 + \beta_1 x_i + u_i) \\ \text{Var}(y_i) &= \text{Var}(\beta_0) + \text{Var}(\beta_1 x_i) + \text{Var}(u_i) \\ \text{Var}(y_i) &= 0 + 0 + \text{Var}(u_i) \\ \text{Var}(y_i) &= \text{Var}(u_i) \\ \text{Var}(y_i) &= \sigma^2. \end{aligned}$$

$$\begin{aligned} (****) \text{Cov}(y_i, y_j) &= E\{[y_i - E(y_i)][y_j - E(y_j)]\} \\ \text{Cov}(y_i, y_j) &= E(u_i u_j) \\ \text{Cov}(y_i, y_j) &= \text{Cov}(u_i, u_j) + E(u_i) E(u_j) \\ \text{Cov}(y_i, y_j) &= 0 + 0 * 0 \\ \text{Cov}(y_i, y_j) &= 0. \end{aligned}$$

$$\begin{aligned} (*****) \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{\sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{n\bar{x} - n\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= \frac{0}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \sum_{i=1}^n \frac{(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} &= 0. \end{aligned}$$

Ejercicio 2.

Considerar, nuevamente, el modelo de regresión lineal bivariado:

$$y_i = \beta_0 + \beta_1 x_i + u_i.$$

(a) Suponiendo que x_i es una variable independiente continua, definir β_1 como una función del modelo de media condicional y proporcionar una interpretación.

$$E(y | x) = E(\beta_0 + \beta_1 x + u | x)$$

$$E(y | x) = E(\beta_0 | x) + E(\beta_1 x | x) + E(u | x)$$

$$E(y | x) = \beta_0 + \beta_1 x + 0$$

$$E(y | x) = \beta_0 + \beta_1 x.$$

$$\frac{\partial E(y | x)}{\partial x} = \beta_1.$$

Por lo tanto, β_1 es el efecto parcial de x en el valor esperado condicional de la variable dependiente y . Es la pendiente del modelo.

(b) ¿Cuál es la definición de β_0 ?

β_0 es el valor esperado condicional de la variable dependiente y cuando x es igual a 0. Es el intercepto del modelo.

(c) Suponiendo que $x_i = \{0, 1\}$ es una variable binaria discreta, definir β_1 como una función del modelo de media condicional y proporciona una interpretación.

$$E(y | x=1) = \beta_0 + \beta_1 * 1$$

$$E(y | x=1) = \beta_0 + \beta_1.$$

$$E(y | x=0) = \beta_0 + \beta_1 * 0$$

$$E(y | x=0) = \beta_0 + 0$$

$$E(y | x=0) = \beta_0.$$

$$E(y | x=1) - E(y | x=0) = \beta_0 + \beta_1 - \beta_0$$

$$E(y | x=1) - E(y | x=0) = \beta_1.$$

Por lo tanto, β_1 es la diferencia entre el valor esperado condicional de la variable dependiente y cuando $x=1$ y el valor esperado condicional de la variable dependiente y cuando $x=0$, es decir, mide el efecto diferencial sobre y de que $x=1$ comparado con que $x=0$.

Ejercicio 3.

Se supone que la demanda de café de Colombia en los Estados Unidos está determinada por la siguiente función:

$$q = \beta_0 + \beta_1 p_c + \beta_2 p_b + \beta_3 p_d + u,$$

donde q denota importaciones de café colombiano en los Estados Unidos, p_c denota el precio del café colombiano, p_b representa el precio del café brasileño y p_d es el precio del café italiano. Todas las variables están en logaritmo natural.

(a) Se supone que se estima la ecuación usando MCO considerando $n = 200$ observaciones:

$$\hat{E}(q | p_c, p_b, p_d) = 2,837 - 1,481p_c + 1,181p_b + 0,186p_d$$

$$(2,000) \quad (0,987) \quad (0,650) \quad (0,134)$$

con la suma de los residuos cuadrados $SSR = 0,4277$. También:

$$\hat{E}(q | p_c, p_b, p_d) = -0,738 - p_c + 0,199p_d.$$

$$(0,820) \quad (1,011) \quad (0,155)$$

con $SSR = 0,4485$. Probar las siguientes hipótesis utilizando un nivel de significación del 5%.

(i) $H_0: \beta_1 = -1; \quad H_a: \beta_1 \neq -1.$

Económicamente, la hipótesis nula significa que hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c), por lo cual, ante una variación del precio del café colombiano en un 1%, la importación de café colombiano en EE.UU. varía, en promedio, en un -1%, manteniendo todo lo demás constante.

Estadístico de prueba:

$$T = \frac{\hat{\beta}_1 - \beta_1}{se(\hat{\beta}_1)} = \frac{\hat{\beta}_1 - (-1)}{se(\hat{\beta}_1)} = \frac{\hat{\beta}_1 + 1}{se(\hat{\beta}_1)} \sim t_{196}.$$

Regla de decisión:

Si $t_{obs} < -1,96$ o $t_{obs} > 1,96$, se rechaza H_0 .

Si $-1,96 < t_{obs} < 1,96$, no se rechaza H_0 .

Valores observados:

$$t_{obs} = \frac{-1,481 + 1}{0,987}$$

$$t_{obs} = \frac{-0,481}{0,987}$$

$$t_{obs} = 0,487.$$

Conclusión:

Por lo tanto, con un nivel de significatividad del 5%, estos datos no proporcionan evidencia suficiente para indicar que no hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c), ya que t_{obs} se encuentra en el intervalo $[-1,96; 1,96]$.

$$(ii) H_0: \beta_2 = 0; \quad H_a: \beta_2 \neq 0.$$

Económicamente, la hipótesis nula significa que hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b), por lo cual p_b no es un determinante de q.

Estadístico de prueba:

$$T = \frac{\hat{\beta}_2 - \beta_2}{se(\hat{\beta}_2)} = \frac{\hat{\beta}_2 - 0 - \hat{\beta}_2}{se(\hat{\beta}_2)} \sim t_{196}.$$

Regla de decisión:

Si $t_{obs} < -1,96$ o $t_{obs} > 1,96$, se rechaza H_0 .

Si $-1,96 < t_{obs} < 1,96$, no se rechaza H_0 .

Valores observados:

$$t_{obs} = \frac{1,181}{0,65}$$

$$t_{obs} = 1,817.$$

Conclusión:

Por lo tanto, con un nivel de significatividad del 5%, estos datos no proporcionan evidencia suficiente para indicar que no hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b), ya que $t_{obs} > 1,96$.

$$(iii) H_0: \beta_1 = -1 \wedge \beta_2 = 0; \quad H_a: \beta_1 \neq -1 \wedge \beta_2 \neq 0.$$

Económicamente, la hipótesis nula significa que hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c) y, conjuntamente, hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b).

Estadístico de prueba:

$$F = \frac{\frac{SSR_T - SSR_U}{q}}{\frac{SSR_U}{n-p-1}} \sim f_{2,196}.$$

Regla de decisión:

Si $f_{obs} < -2,99$ o $f_{obs} > 2,99$, se rechaza H_0 .

Si $-2,99 < f_{obs} < 2,99$, no se rechaza H_0 .

Valores observados:

$$f_{obs} = \frac{\frac{0,4485 - 0,4277}{2}}{\frac{0,4277}{196}}$$

$$f_{obs} = \frac{0,0208}{0,4277}$$

$$f_{obs} = 4,766.$$

Conclusión:

Por lo tanto, con un nivel de significatividad del 5%, estos datos proporcionan evidencia suficiente para indicar que no hay una correlación lineal negativa perfecta entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café colombiano (p_c) y, conjuntamente, que no hay ausencia de correlación lineal entre el log de la importación de café colombiano en EE.UU. (q) y el log del precio del café brasileño (p_b), ya que $f_{obs} > 2,99$.

(b) Un árbitro argumenta que el error u podría ser heterocedástico. Explicar cómo se respondería a su pregunta. Ser explícito sobre la prueba, la hipótesis nula y la hipótesis alternativa. Si el R -cuadrado de una regresión de $\hat{u}^2$ en covariables es 0,1, ¿te preocuparías por errores heterocedásticos?

Para responder a la pregunta sobre si el error u podría ser heterocedástico, analizaría los siguientes test de heterocedasticidad:

- Test de Breusch-Pagan (1980).

Se comienza asumiendo un modelo de regresión multivariable:

$$y_i = x_i' \beta + u_i.$$

Se supone que la hipótesis nula es:

$$H_0: V(u | x) = \sigma^2,$$

es decir, la hipótesis nula es no heteroscedasticidad. Como $E(u | x) = 0$, se escribe H_0 como:

$$H_0: E(u^2 | x) = E(u^2) = \sigma^2.$$

Tener en cuenta que se debe evaluar la esperanza condicional (en las variables independientes) del cuadrado del término de error:

$$u^2 = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_p x_p + \varepsilon.$$

El caso homocedástico implica que $\alpha_1 = \alpha_2 = \dots = \alpha_p = 0$, por lo que:

$$E(u^2 | x_1, \dots, x_p) = \alpha_0.$$

Sin embargo, tener en cuenta que esto es inviable porque no se conoce el término de error u^2 . Un enfoque simple es reemplazarlo por $\hat{u}^2$ y estimar:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \dots + \alpha_p x_{pi} + \varepsilon,$$

y probar si los coeficientes de pendiente son todos iguales a cero:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_p = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

utilizando una prueba de F. Si $F > c$, donde c está determinada por un valor de significancia estadística, se rechaza la hipótesis nula de no heterocedasticidad.

La versión del multiplicador de Lagrange (LM) es muy fácil de calcular, ya que:

$$LM = nR_{\hat{u}^2}^2,$$

que se distribuye como χ_p^2 bajo la hipótesis nula de homocedasticidad.

- Test de White (1980).

Para simplificar la presentación, suponer que $p = 2$:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i.$$

La prueba de White se basa en la estimación de:

$$\hat{u}_i^2 = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_3 x_{1i}^2 + \alpha_4 x_{2i}^2 + \alpha_5 x_{1i} x_{2i} + \varepsilon.$$

La hipótesis nula, en este caso, es:

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_5 = 0; \quad H_a: \text{al menos, un } \alpha_j \neq 0,$$

el cual puede ser evaluado con un estadístico de prueba LM o F.

Si el R^2 de una regresión de $\hat{u}^2$ en covariables es 0,1, no me preocuparía por errores heterocedásticos, ya que los errores estimados cuadráticos no se encuentran bien explicados por las variables explicativas del modelo, por lo que este modelo no produce un buen ajuste a los datos y esto sería un indicio de homocedasticidad.

(c) Se supone que se rechaza la hipótesis nula en (b) y se observa que p_c es 10 veces más grande que p_b en un mes (pero no en los otros meses). Explicar cómo se estimaría el modelo. Explicar también cuáles son las advertencias prácticas asociadas con la implementación de su(s) método(s).

La matriz de covarianza del término de error, bajo heterocedasticidad, es igual a:

$$\Sigma = E(uu') = E(uu' | x) = E[\text{diag}(u_1^2, u_2^2, \dots, u_n^2) | x],$$

o, alternativamente:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix}.$$

Por lo tanto, bajo heteroscedasticidad, la varianza del estimador es:

$$\begin{aligned} V(\hat{\beta} | X) &= V[(X'X)^{-1}X'y | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'(X\beta + u) | X] \\ V(\hat{\beta} | X) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[I\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V[\beta + (X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + V[(X'X)^{-1}X'u | X] \\ V(\hat{\beta} | X) &= V(\beta | X) + (X'X)^{-1}X' V(u | X) X(X'X)^{-1} \\ V(\hat{\beta} | X) &= 0 + (X'X)^{-1}X'\Sigma X(X'X)^{-1} \\ V(\hat{\beta} | X) &= (X'X)^{-1}X'\Sigma X(X'X)^{-1}. \end{aligned}$$

Si se conoce el término de error, se nota que $(uu')_{ii} = u_{ii}^2$ y el valor esperado condicional de la varianza es:

$$\begin{aligned} E[V(\hat{\beta} | X)] &= E[(X'X)^{-1}X'\Sigma X(X'X)^{-1}] \\ E[V(\hat{\beta} | X)] &= (X'X)^{-1}X' E(\Sigma) X(X'X)^{-1} \\ E[V(\hat{\beta} | X)] &= (X'X)^{-1}X'\Sigma X(X'X)^{-1}. \end{aligned}$$

En la práctica, se obtienen los residuos mínimos cuadrados, $\hat{u}_i^2 = (y_i - x_i'\hat{\beta})^2$, donde $\hat{\beta}$ es el estimador mínimo cuadrático de β . Entonces, se puede formar una matriz:

$$\hat{\Sigma} = \begin{bmatrix} \hat{u}_1^2 & 0 & \dots & 0 \\ 0 & \hat{u}_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \hat{u}_n^2 \end{bmatrix}$$

y construir un estimador factible:

$$\hat{V}(\hat{\beta} | X) = (X'X)^{-1}X'\hat{\Sigma}X(X'X)^{-1}.$$

Este estimador se denomina estimador de “heterocedasticidad-robusto” de la matriz de covarianza.

Notar que el estimador representa un estimador consistente de la covarianza desconocida. En muestras pequeñas, desafortunadamente, el estimador podría estar sesgado. Para ver esto, recordar que $\hat{u}'\hat{u} = u'Mu = y'My$. Entonces:

$$\begin{aligned} \hat{u}_i^2 &= (y_i - x_i'\hat{\beta})^2 \\ \hat{u}_i^2 &= (y_i - x_i'\beta + x_i'\beta - x_i'\hat{\beta})^2 \end{aligned}$$

$$\begin{aligned}\hat{u}_i^2 &= [(y_i - x_i'\beta) - x_i'(\hat{\beta} - \beta)]^2 \\ \hat{u}_i^2 &= [u_i + x_i'(X'X)^{-1}X'u]^2 \\ \hat{u}_i^2 &= u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i.\end{aligned}$$

Bajo homocedasticidad y denotando el llamado punto de apalancamiento $h_{ii} = x_i'(X'X)^{-1}x_i$, se tiene que:

$$\begin{aligned}E(\hat{u}_i^2) &= E[u_i^2 - 2u_i x_i'(X'X)^{-1}X'u + x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i] \\ E(\hat{u}_i^2) &= E(u_i^2) - E[2u_i x_i'(X'X)^{-1}X'u] + E[x_i'(X'X)^{-1}X'uu'X(X'X)^{-1}x_i] \\ E(\hat{u}_i^2) &= \sigma^2 - 2E[u_i x_i'(X'X)^{-1}X'u] + x_i'(X'X)^{-1}X'E(uu')X(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2E(u_i h_{ii} u_i) + x_i'(X'X)^{-1}X'\sigma^2 X(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2h_{ii}E(u_i u_i) + \sigma^2 x_i'(X'X)^{-1}X'X(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2h_{ii}E(u_i^2) + \sigma^2 x_i'I(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2h_{ii}\sigma^2 + \sigma^2 x_i'(X'X)^{-1}x_i \\ E(\hat{u}_i^2) &= \sigma^2 - 2\sigma^2 h_{ii} + \sigma^2 h_{ii} \\ E(\hat{u}_i^2) &= \sigma^2 - \sigma^2 h_{ii} \\ E(\hat{u}_i^2) &= \sigma^2 (1 - h_{ii}) < \sigma^2 = E(u_i^2).\end{aligned}$$

Luego, insistiendo con el ejemplo simple cuando $p=1$, se tiene que:

$$\begin{aligned}E[V(\hat{\beta} | X)] &= E\left\{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2}\right\} \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} E[\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2] \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n E[(x_i - \bar{x})^2 \hat{u}_i^2] \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 E(\hat{u}_i^2) \\ E[V(\hat{\beta} | X)] &= \frac{1}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sigma^2 (1 - h_{ii}) \\ E[V(\hat{\beta} | X)] &= \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} - \frac{\sum_{i=1}^n (x_i - \bar{x})^2 h_{ii} \sigma^2}{[\sum_{i=1}^n (x_i - \bar{x})^2]^2},\end{aligned}$$

lo que indica que $V(\hat{\beta} | X)$ está sesgada hacia abajo (tener en cuenta que el primer término es la varianza del estimador de mínimos cuadrados en la homocedasticidad). Una corrección estándar es dividir $\hat{u}_i^2$ por $(1 - h_{ii})$.

Ejercicio 4.

Considerar el siguiente modelo lineal:

$$E(y | x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2,$$

donde x_1 y x_2 tienen medias iguales a cero.

(a) Escribir una ecuación para la variable dependiente y e indicar las suposiciones para el término de error u como lo indica el modelo de media condicional anterior.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + u.$$

El supuesto de u que está implícito en el modelo de media condicional es $E(u | x_1, x_2) = E(u) = 0$.

(b) Encontrar el efecto parcial de $E(y | x_1, x_2)$ con respecto a x_1 . ¿Cuál es la interpretación de β_1 ?

$$\frac{\partial E(y | x_1, x_2)}{\partial x_1} = \beta_1 + \beta_3 x_2.$$

Si $E(x_2) = E(x_2 | x_1) = 0$, entonces, el efecto parcial promedio es:

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1 + \beta_3 x_2)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = E(\beta_1) + E(\beta_3 x_2)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \beta_3 E(x_2)$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + \beta_3 * 0$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1 + 0$$

$$E\left[\frac{\partial E(y | x, z)}{\partial x_1}\right] = \beta_1.$$

Por lo tanto, el efecto parcial de x_1 sobre $E(y | x_1, x_2)$ es $(\beta_1 + \beta_3 x_2)$ y β_1 es el efecto parcial promedio de x_1 sobre $E(y | x_1, x_2)$.

(c) Construir una elasticidad con respecto a un cambio en x_j .

Considerar que se tiene el siguiente modelo de regresión de la población:

$$E(y | x) = \beta_0 + \sum_{j=1}^p \beta_j x_j,$$

y que se está interesado en el efecto marginal de la j -ésima variable independiente sobre el valor esperado condicional de y :

$$\frac{\partial E(y | x)}{\partial x_j} = \beta_j.$$

Esto nos dice el aumento en el valor medio de y cuando la variable independiente se incrementa en 1 unidad, manteniendo todo lo demás constante. Esta interpretación es equivalente a la noción de *ceteris paribus*: el efecto de x sobre y , manteniendo todo lo demás constante. Notar que, si x_i y x_j están relacionados, encontrar el efecto marginal es algo más complicado, pero la linealidad del modelo de regresión tiene una implicación simple y, a veces, útil para el análisis empírico.

Por lo tanto, se tiene que la elasticidad de la media condicional de y es:

$$\frac{\partial E(y | x_j)}{\partial x_j} \frac{x_j}{E(y | x_j)} = \beta_j \frac{x_j}{\beta_0 + \sum_{j=1}^p \beta_j x_j}.$$

(d) Explicar cómo se estimaría la elasticidad que se construyó antes e indicar las suposiciones necesarias para obtener un resultado insesgado y consistente.

Cuando u y x no están correlacionados, $E(u | x) = 0$, como es el caso en los modelos anteriores, se puede tener una definición alternativa de elasticidad:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)}.$$

Tener en cuenta que $E(y | x) = e^{x'\beta}$ implica:

$$\log[E(y | x)] = x'\beta.$$

Si $y = e^{x'\beta + u}$, entonces, $\log(y) = x'\beta + u$ y, por suposiciones previas, $E[\log(y)] = x'\beta$, ya que $E(u | x) = 0$.

Por lo tanto, el parámetro β_j se debe interpretar como una elasticidad si el modelo está en una forma “log-log”:

$$\frac{\partial E[\log(y) | x]}{\partial \log(x_j)} = \beta_j.$$

El supuesto necesario para obtener un resultado insesgado y consistente es $E(u | x) = 0$.

Ejercicio 5.

Considerar un modelo de ubicación:

$$\begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}.$$

donde u_1 y u_2 están i.i.d. con distribución $\mathcal{N}(0, \sigma^2)$. Demostrar que agrupar los datos y estimar $\hat{\beta} = \hat{\beta}_1 = \hat{\beta}_2$ reduce la variabilidad de $\hat{\beta}_j$.

$$\underset{2 \times 1}{y} = \underset{2 \times 1}{\beta} + \underset{2 \times 1}{u}.$$

$$\hat{\beta} = (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i$$

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n 1 \cdot y_i}{\sum_{i=1}^n 1^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n y_i}{\sum_{i=1}^n 1}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n y_i}{n \cdot 1}$$

$$\hat{\beta} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$\hat{\beta} = \bar{y}.$$

$$E(\hat{\beta}) = E(\bar{y})$$

$$E(\hat{\beta}) = E\left(\frac{1}{n} \sum_{i=1}^n y_i\right)$$

$$E(\hat{\beta}) = \frac{1}{n} E\left(\sum_{i=1}^n y_i\right)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n E(y_i)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n E(\beta + u)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n [E(\beta) + E(u)]$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n (\beta + 0)$$

$$E(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \beta$$

$$E(\hat{\beta}) = \frac{1}{n} n\beta$$

$$E(\hat{\beta}) = \beta.$$

$$V(\hat{\beta}) = V(\bar{y})$$

$$V(\hat{\beta}) = V\left(\frac{1}{n} \sum_{i=1}^n y_i\right)$$

$$V(\hat{\beta}) = \frac{1}{n^2} V\left(\sum_{i=1}^n y_i\right)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n V(y_i)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n V(\beta + u)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n [V(\beta) + V(u)]$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n (0 + \sigma^2)$$

$$V(\hat{\beta}) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2$$

$$V(\hat{\beta}) = \frac{1}{n^2} n\sigma^2$$

$$V(\hat{\beta}) = \frac{\sigma^2}{n}.$$

Por lo tanto, agrupar los datos y estimar $\hat{\beta} = \hat{\beta}_1 = \hat{\beta}_2$ reduce la variabilidad de $\hat{\beta}_j$, ya que, en este caso, n aumenta y se reduce $V(\hat{\beta}_j)$.

Ejercicio 6.

Demostrar que $M = I - X(X'X)^{-1}X'$ es una matriz de proyección ortogonal. Demostrar que el vector residual $\hat{u} = Mu$ es ortogonal al vector $\hat{y}$.

$$\hat{u} = y - \hat{y}$$

$$\hat{u} = y - Py$$

$$\hat{u} = (I - P)y$$

$$\hat{u} = My$$

$$\hat{u} = M(X\beta + u)$$

$$\hat{u} = MX\beta + Mu$$

$$\hat{u} = 0 * \beta + Mu \quad (*)$$

$$\hat{u} = 0 + Mu$$

$$\hat{u} = Mu.$$

$$(*) MX = (I - P)X$$

$$MX = IX - PX$$

$$MX = X - X(X'X)^{-1}X'X$$

$$MX = X - XI$$

$$MX = X - X$$

$$MX = 0.$$

Por lo tanto, $M = I - P$ es una matriz que produce “residuos”, donde $P = X(X'X)^{-1}X'$ (matriz que proyecta los valores ajustados de y ($\hat{y}$) en el espacio vectorial de X), es decir, M es una matriz que proyecta los errores estimados ($\hat{u}$) en el espacio de los errores (u).

$$\hat{y}'\hat{u} = (Py)'My$$

$$\hat{y}'\hat{u} = y'P'My$$

$$\hat{y}'\hat{u} = y'PM y$$

$$\hat{y}'\hat{u} = y' * 0 * y \quad (**)$$

$$\hat{y}'\hat{u} = 0.$$

$$(**) PM = P(I - P)$$

$$PM = P - PP$$

$$PM = P - P$$

$$PM = 0.$$

Por lo tanto, el vector residual $\hat{u}$ es ortogonal al vector $\hat{y}$.

Ejercicio 7.

Considerar:

$$y = X_1\beta_1 + X_2\beta_2 + u,$$

donde $E(uu') = \sigma^2 I$. Suponer que se tiene:

$$\tilde{\beta}_1^s = (X_1'X_1)^{-1}X_1'y.$$

$$\hat{\beta}_1^l = (X_1'M_2X_1)^{-1}X_1'M_2y.$$

(a) Explicar la diferencia entre los estimadores.

La diferencia entre los estimadores $\tilde{\beta}_1^s$ y $\hat{\beta}_1^l$ radica, principalmente, en que el primero es el estimador MCO de β_1 de un modelo “corto” de la forma $y = X_1\beta_1 + u$, en tanto que el segundo es el estimador MCO de β_1 de un modelo “largo” de la forma $y = X_1\beta_1 + X_2\beta_2 + u$.

Por lo tanto, se tiene:

$$\tilde{\beta}_1^s = \arg \min \|y - X_1\beta_1\|^2.$$

$$\hat{\beta}_1^l = \arg \min \|y - X_1\beta_1 - X_2\beta_2\|^2.$$

(b) Definir M_2 y comprobar si es idempotente. ¿Son $\tilde{\beta}_1^s$ y $\hat{\beta}_1^l$ sesgados? Explicar.

$M_2 = I - P_2$ es una matriz que produce “residuos”, donde $P_2 = X_2(X_2'X_2)^{-1}X_2'$ [matriz que proyecta los valores ajustados de X_1 ($\hat{X}_1$) en el espacio vectorial de X_2], es decir, M_2 es una matriz que proyecta los errores estimados ($\hat{v}$) en el espacio vectorial de los errores (v) del siguiente modelo:

$$X_1 = X_2\gamma + v.$$

Es decir:

$$\hat{v} = M_2v.$$

$$M_2M_2 = (I - P_2)(I - P_2)$$

$$M_2M_2 = I - P_2 - P_2 + P_2P_2$$

$$M_2M_2 = I - P_2 - P_2 + P_2 \quad (*)$$

$$M_2M_2 = I - P_2$$

$$M_2M_2 = M_2.$$

$$(*) P_2P_2 = X_2(X_2'X_2)^{-1}X_2'X_2(X_2'X_2)^{-1}X_2'$$

$$P_2P_2 = X_2I(X_2'X_2)^{-1}X_2'$$

$$P_2P_2 = X_2(X_2'X_2)^{-1}X_2'$$

$$P_2 P_2 = P_2.$$

Por lo tanto, M_2 es idempotente, ya que $M_2 M_2 = M_2$.

$$\begin{aligned}\tilde{\beta}_1^s &= (X_1' X_1)^{-1} X_1' (X_1 \beta_1 + X_2 \beta_2 + u) \\ \tilde{\beta}_1^s &= (X_1' X_1)^{-1} X_1' X_1 \beta_1 + (X_1' X_1)^{-1} X_1' X_2 \beta_2 + (X_1' X_1)^{-1} X_1' u \\ \tilde{\beta}_1^s &= I \beta_1 + (X_1' X_1)^{-1} X_1' X_2 \beta_2 + (X_1' X_1)^{-1} X_1' u \\ \tilde{\beta}_1^s &= \beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' u.\end{aligned}$$

$$\begin{aligned}E(\tilde{\beta}_1^s) &= E[\beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' u] \\ E(\tilde{\beta}_1^s) &= E(\beta_1) + E(\Gamma \beta_2) + E[(X_1' X_1)^{-1} X_1' u] \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' E(u) \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2 + (X_1' X_1)^{-1} X_1' * 0 \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2 + 0 \\ E(\tilde{\beta}_1^s) &= \beta_1 + \Gamma \beta_2.\end{aligned}$$

Donde $\Gamma = (X_1' X_1)^{-1} X_1' X_2$ es el estimador de una regresión de X_2 en X_1 . Se puede observar que $\tilde{\beta}_1^s$ podría estar sesgado si $\beta_2 \neq 0$ o si las variables independientes observables X_1 y X_2 no son independientes.

$$\begin{aligned}\tilde{\beta}_1^l &= (X_1' M_2 X_1)^{-1} X_1' M_2 (X_1 \beta_1 + X_2 \beta_2 + u) \\ \tilde{\beta}_1^l &= (X_1' M_2 X_1)^{-1} X_1' M_2 X_1 \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 X_2 \beta_2 + (X_1' M_2 X_1)^{-1} X_1' M_2 u \\ \tilde{\beta}_1^l &= I \beta_1 + (X_1' M_2 X_1)^{-1} X_1' * 0 * \beta_2 + (X_1' M_2 X_1)^{-1} X_1' M_2 u \\ \tilde{\beta}_1^l &= \beta_1 + 0 + (X_1' M_2 X_1)^{-1} X_1' M_2 u \\ \tilde{\beta}_1^l &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 u.\end{aligned}$$

$$\begin{aligned}E(\tilde{\beta}_1^l) &= E[\beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 u] \\ E(\tilde{\beta}_1^l) &= E(\beta_1) + E[(X_1' M_2 X_1)^{-1} X_1' M_2 u] \\ E(\tilde{\beta}_1^l) &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 E(u) \\ E(\tilde{\beta}_1^l) &= \beta_1 + (X_1' M_2 X_1)^{-1} X_1' M_2 * 0 \\ E(\tilde{\beta}_1^l) &= \beta_1 + 0 \\ E(\tilde{\beta}_1^l) &= \beta_1.\end{aligned}$$

Por lo tanto, $\tilde{\beta}_1^s$ es sesgado y $\tilde{\beta}_1^l$ es insesgado, ya que $E(\tilde{\beta}_1^s) \neq \beta_1$ y $E(\tilde{\beta}_1^l) = \beta_1$.

(c) Encontrar la expresión para $\hat{\beta}_1^l = \tilde{\beta}_1^s - B \hat{\beta}_2^l$.

$$\begin{aligned}\hat{\beta}_1^l &= \tilde{\beta}_1^s - B \hat{\beta}_2^l \\ \hat{\beta}_1^l &= [(X_1' X_1)^{-1} X_1' - B(X_2' M_1 X_2)^{-1} X_2' M_1] y.\end{aligned}$$

Donde $B = (X_1' X_1)^{-1} X_1' X_2$ es el estimador de una regresión de X_2 en X_1 y $M_1 = I - P_1$ es una matriz que produce “residuos”, donde $P_1 = X_1 (X_1' X_1)^{-1} X_1'$ [matriz que proyecta los valores ajustados de X_2 ($\hat{X}_2$) en el espacio vectorial de X_1], es decir, M_1 es una matriz que proyecta los errores estimados ($\hat{\kappa}$) en el espacio vectorial de los errores (κ) del siguiente modelo:

$$X_2 = X_1\delta + \kappa.$$

Es decir:

$$\hat{\kappa} = M_1\kappa.$$

(d) Demostrar que una aplicación del teorema de FWL da un estimador que es, numéricamente, equivalente a $\hat{\beta}_1^l$ y el error estándar de $\hat{\beta}_1^l$.

$$\begin{aligned}\tilde{\beta}_1^s &= (\tilde{X}_1'\tilde{X}_1)^{-1}\tilde{X}_1'\tilde{y} \\ \tilde{\beta}_1^s &= (X_1'M_2'M_2X_1)^{-1}X_1'M_2'M_2y \\ \tilde{\beta}_1^s &= (X_1'M_2X_1)^{-1}X_1'M_2y \\ \tilde{\beta}_1^s &= \hat{\beta}_1^l.\end{aligned}$$

$$\begin{aligned}\hat{\beta}_1^l &= (X_1'M_2X_1)^{-1}X_1'M_2y \\ \hat{\beta}_1^l &= (X_1'M_2'M_2X_1)^{-1}X_1'M_2'M_2y \\ \hat{\beta}_1^l &= (\tilde{X}_1'\tilde{X}_1)^{-1}\tilde{X}_1'\tilde{y} \\ \hat{\beta}_1^l &= \tilde{\beta}_1^s.\end{aligned}$$

Por lo tanto, el estimador que surge de aplicar el teorema de FWL es, numéricamente, equivalente a $\hat{\beta}_1^l$.

Además, los residuos de ambos modelos son idénticos. Considerar:

$$\begin{aligned}y &= \hat{y} + \hat{u} \\ y &= X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{u}\end{aligned}$$

y multiplicar por M_2 :

$$\begin{aligned}M_2y &= M_2X_1\hat{\beta}_1 + M_2X_2\hat{\beta}_2 + M_2\hat{u} \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + 0 * \hat{\beta}_2 + (I - P_2) \hat{u} & (*) \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + 0 + I\hat{u} - P_2\hat{u} \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + \hat{u} - 0 & (**) \\ \tilde{y} &= \tilde{X}_1\hat{\beta}_1 + \hat{u},\end{aligned}$$

donde $M_2\hat{u} = \hat{u}$ porque $P_2\hat{u} = 0$.

$$\begin{aligned}(*) \quad M_2X_2 &= (I - P_2) X_2 \\ M_2X_2 &= IX_2 - P_2X_2 \\ M_2X_2 &= X_2 - X_2(X_2'X_2)^{-1}X_2'X_2 \\ M_2X_2 &= X_2 - X_2I \\ M_2X_2 &= X_2 - X_2 \\ M_2X_2 &= 0.\end{aligned}$$

$$(**) \quad P_2\hat{u} = P_2My$$

$$\begin{aligned} P_2 \hat{u} &= P_2 M_2 M y \\ P_2 \hat{u} &= 0 * M y \\ P_2 \hat{u} &= 0. \end{aligned} \quad (***)$$

$$\begin{aligned} (***) \quad P_2 M_2 &= P_2 (I - P_2) \\ P_2 M_2 &= P_2 I - P_2 P_2 \\ P_2 M_2 &= P_2 - P_2 \\ P_2 M_2 &= 0. \end{aligned}$$

Por lo tanto, ya que los residuos de ambos modelos son idénticos, los errores estándar de $\hat{\beta}_1^l$ y $\tilde{\beta}_1^s$ también son idénticos.

(e) Si el error u no es homocedástico, ¿la covarianza entre $\tilde{\beta}_1^s$ y $B\hat{\beta}_1^l$ sería cero? ¿Por qué es importante este resultado?

Considerando:

$$\hat{\beta}_1^l = \tilde{\beta}_1^s - B\hat{\beta}_2^l,$$

se tiene:

$$\begin{aligned} V(\hat{\beta}_1^l) &= V(\tilde{\beta}_1^s - B\hat{\beta}_2^l) \\ V(\hat{\beta}_1^l) &= V(\tilde{\beta}_1^s) + V(B\hat{\beta}_2^l) \\ V(\hat{\beta}_1^l) &= V(\tilde{\beta}_1^s) + B V(\hat{\beta}_2^l) B', \end{aligned}$$

lo que implica que:

$$V(\hat{\beta}_1^l) \geq V(\tilde{\beta}_1^s),$$

ya que el término cuadrático es semidefinido positivo. Este resultado se cumple si el término de $\text{Cov}(\tilde{\beta}_1^s, B\hat{\beta}_2^l)$ es cero, lo cual se satisface si el error u es homocedástico.

Teorema. $\text{Cov}(\hat{\beta}_s, \Gamma\hat{\gamma}) = 0$.

Prueba. Primero, recordar esto:

$$\begin{aligned} \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x y \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x (X\beta + Z\gamma + u) \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' M_x X\beta + (Z' M_x Z)^{-1} Z' M_x Z\gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= (Z' M_x Z)^{-1} Z' * 0 * \beta + I\gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= 0 + \gamma + (Z' M_x Z)^{-1} Z' M_x u \\ \hat{\gamma} &= \gamma + (Z' M_x Z)^{-1} Z' M_x u. \end{aligned}$$

Además, recordar que:

$$\begin{aligned} \hat{\beta} &= (X' M_z X)^{-1} X' M_z y \\ \hat{\beta} &= (X' M_z X)^{-1} X' M_z (X\beta + Z\gamma + u) \end{aligned}$$

$$\begin{aligned}\hat{\beta} &= (X'M_z X)^{-1} X' M_z X \beta + (X'M_z X)^{-1} X' M_z Z \gamma + (X'M_z X)^{-1} X' M_z u \\ \hat{\beta} &= I\beta + (X'M_z X)^{-1} X' * 0 * \gamma + (X'M_z X)^{-1} X' M_z u \\ \hat{\beta} &= \beta + 0 + (X'M_z X)^{-1} X' M_z u \\ \hat{\beta} &= \beta + (X'M_z X)^{-1} X' M_z u.\end{aligned}$$

Por definición, se tiene esto:

$$\begin{aligned}\text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [\hat{\beta}_s - E(\hat{\beta}_s)] [\Gamma \hat{\gamma} - E(\Gamma \hat{\gamma})]' \} \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [(X'X)^{-1} X' u] [\Gamma \hat{\gamma} - \Gamma E(\hat{\gamma})]' \} \quad (*) \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [(X'X)^{-1} X' u] [\Gamma (\hat{\gamma} - \gamma)]' \} \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [(X'X)^{-1} X' u] [(\hat{\gamma} - \gamma)' \Gamma]' \} \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [(X'X)^{-1} X' u] [(Z'M_x Z)^{-1} Z' M_x u]' \Gamma' \},\end{aligned}$$

$$\begin{aligned} (*) \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u] - E[\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u] \\ \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u] - \{E(\beta) + E[(X'X)^{-1} X' Z \gamma] + E[(X'X)^{-1} X' u]\} \\ \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u] - [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' E(u)] \\ \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u] - [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' * 0] \\ \hat{\beta}_s - E(\hat{\beta}_s) &= [\beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u] - [\beta + (X'X)^{-1} X' Z \gamma + 0] \\ \hat{\beta}_s - E(\hat{\beta}_s) &= \beta + (X'X)^{-1} X' Z \gamma + (X'X)^{-1} X' u - \beta - (X'X)^{-1} X' Z \gamma \\ \hat{\beta}_s - E(\hat{\beta}_s) &= (X'X)^{-1} X' u.\end{aligned}$$

reemplazando por definiciones. La última expresión se puede escribir como:

$$\begin{aligned}\text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [(X'X)^{-1} X' u] [u' M_x Z (Z' M_x Z)^{-1} \Gamma]' \} \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= E \{ [(X'X)^{-1} X' u u' M_x Z (Z' M_x Z)^{-1} \Gamma]' \} \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= (X'X)^{-1} X' E(u u') M_x Z (Z' M_x Z)^{-1} \Gamma' \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= (X'X)^{-1} X' V(u) M_x Z (Z' M_x Z)^{-1} \Gamma' \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= (X'X)^{-1} X' \sigma^2 I M_x Z (Z' M_x Z)^{-1} \Gamma' \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= (X'X)^{-1} X' \sigma^2 M_x Z (Z' M_x Z)^{-1} \Gamma' \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= \sigma^2 (X'X)^{-1} X' M_x Z (Z' M_x Z)^{-1} \Gamma' \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= \sigma^2 (X'X)^{-1} * 0 * Z (Z' M_x Z)^{-1} \Gamma' \quad (**) \\ \text{Cov}(\hat{\beta}_s, \Gamma \hat{\gamma}) &= 0,\end{aligned}$$

$$\begin{aligned}(**) X' M_x &= X' (I - P_x) \\ X' M_x &= X' [I - X(X'X)^{-1} X'] \\ X' M_x &= X' I - X' X (X'X)^{-1} X' \\ X' M_x &= X' - IX' \\ X' M_x &= X' - X' \\ X' M_x &= 0.\end{aligned}$$

porque $V(u) = \sigma^2 I$. Tener en cuenta que $M_x X = 0$, por lo que la covarianza es igual a cero bajo homocedasticidad.

Por lo tanto, si el error u no es homocedástico, la covarianza entre $\tilde{\beta}_1^s$ y $B\hat{\beta}_2^l$ no sería cero. Este resultado es importante porque, de lo contrario, no se puede determinar cuál de los estimadores ($\tilde{\beta}_1^s$ y $\hat{\beta}_1^l$) es más eficiente o, mejor dicho, no se puede afirmar que $\tilde{\beta}_1^s$ es eficiente comparado con $\hat{\beta}_1^l$.

Ejercicio 8.

Sea A una matriz singular de la forma:

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}.$$

(a) Derivar la forma inversa particionada:

$$A^{-1} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}^{-1} = \begin{bmatrix} W^{-1} & -W^{-1}A_{12}A_{22}^{-1} \\ -A_{22}^{-1}A_{21}W^{-1} & A_{22}^{-1}A_{21}W^{-1}A_{11}A_{21}^{-1} \end{bmatrix},$$

donde $W = A_{11} - A_{12}A_{22}^{-1}A_{21}$ (insinuación: resolver para los elementos particionados de B de la fórmula $AB = I$).

$$AB = I$$

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

$$A_{11}B_{11} + A_{12}B_{21} = 1. \quad (1)$$

$$A_{21}B_{11} + A_{22}B_{21} = 0. \quad (2)$$

$$A_{11}B_{12} + A_{12}B_{22} = 0. \quad (3)$$

$$A_{21}B_{12} + A_{22}B_{22} = 1. \quad (4)$$

De (2), se obtiene:

$$B_{21} = -A_{22}^{-1}A_{21}B_{11}. \quad (2')$$

De (3), se obtiene:

$$B_{12} = -A_{11}^{-1}A_{12}B_{22}. \quad (3')$$

Reemplazando (2') en (1), se tiene:

$$\begin{aligned} A_{11}B_{11} + A_{12}(-A_{22}^{-1}A_{21}B_{11}) &= 1 \\ A_{11}B_{11} - A_{12}A_{22}^{-1}A_{21}B_{11} &= 1 \\ B_{11}(A_{11} - A_{12}A_{22}^{-1}A_{21}) &= 1 \\ B_{11} &= (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} = W^{-1}. \end{aligned} \quad (2'')$$

Reemplazando (3') en (4), se tiene:

$$\begin{aligned} A_{21}(-A_{11}^{-1}A_{12}B_{22}) + A_{22}B_{22} &= 1 \\ -A_{21}A_{11}^{-1}A_{12}B_{22} + A_{22}B_{22} &= 1 \\ B_{22}(A_{22} - A_{21}A_{11}^{-1}A_{12}) &= 1 \\ B_{22} &= (A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} \\ B_{22} &= A_{22}^{-1} - A_{12}^{-1}A_{11}A_{21}^{-1} = A_{22}^{-1}A_{21}W^{-1}A_{11}A_{21}^{-1}. \end{aligned} \quad (3'')$$

Reemplazando (2'') en (2), se tiene:

$$B_{21} = -A_{22}^{-1} A_{21} (A_{11} - A_{12} A_{22}^{-1} A_{21})^{-1} = -A_{22}^{-1} A_{21} W^{-1}.$$

Reemplazando (3'') en (3'), se tiene:

$$\begin{aligned} B_{12} &= -A_{11}^{-1} A_{12} (A_{22}^{-1} - A_{12}^{-1} A_{11} A_{21}^{-1}) \\ B_{12} &= -A_{11}^{-1} A_{12} A_{22}^{-1} + A_{11}^{-1} A_{12} A_{12}^{-1} A_{11} A_{21}^{-1} \\ B_{12} &= -A_{11}^{-1} A_{12} A_{22}^{-1} + A_{21}^{-1} \\ B_{12} &= -(A_{11}^{-1} - A_{11}^{-1} A_{12} A_{22}^{-1}) A_{12} A_{22}^{-1} \\ B_{12} &= -(A_{11} - A_{12} A_{22}^{-1} A_{21})^{-1} A_{12} A_{22}^{-1} = -W^{-1} A_{12} A_{22}^{-1}. \end{aligned}$$

Por lo tanto, se obtiene:

$$A^{-1} = \begin{bmatrix} W^{-1} & -W^{-1} A_{12} A_{22}^{-1} \\ -A_{22}^{-1} A_{21} W^{-1} & A_{22}^{-1} A_{21} W^{-1} A_{11} A_{21}^{-1} \end{bmatrix}.$$

(b) Usar las fórmulas anteriores para derivar el estimador MCO para $\hat{\beta}_1$ de forma constructiva a partir de la fórmula de ajuste:

$$\hat{\beta} = (X'X)^{-1} X'y = \begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix}^{-1} \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix}.$$

$$\begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{bmatrix}^{-1} \begin{bmatrix} X_1'y \\ X_2'y \end{bmatrix}.$$

$$\begin{aligned} \hat{\beta}_1 &= W^{-1} X_1'y - W^{-1} A_{12} A_{22}^{-1} X_2'y \\ \hat{\beta}_1 &= W^{-1} (X_1' - A_{12} A_{22}^{-1} X_2') y \\ \hat{\beta}_1 &= [X_1'X_1 - X_1'X_2 (X_2'X_2)^{-1} X_2'X_1]^{-1} [X_1' - X_1'X_2 (X_2'X_2)^{-1} X_2'] y \\ \hat{\beta}_1 &= \{X_1'[I - X_2 (X_2'X_2)^{-1} X_2'] X_1\}^{-1} \{X_1' [I - X_2 (X_2'X_2)^{-1} X_2']\} y \\ \hat{\beta}_1 &= [X_1'(I - P_2) X_1]^{-1} [X_1' (I - P_2)] y \\ \hat{\beta}_1 &= (X_1' M_2 X_1)^{-1} X_1' M_2 y \\ \hat{\beta}_1 &= (X_1' M_2 M_2 X_1)^{-1} X_1' M_2 M_2 y \\ \hat{\beta}_1 &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \tilde{y}. \end{aligned}$$

(c) Encontrar la varianza condicional de $\hat{\beta}_1$ suponiendo que el término de error $u \equiv y - X\hat{\beta}$ se distribuye normalmente, digamos $u \sim \mathcal{N}(0, \sigma^2)$.

$$\begin{aligned} V(\hat{\beta}_1 | X) &= V[(\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \tilde{y} | X] \\ V(\hat{\beta}_1 | X) &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' V(\tilde{y} | X) \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1} \\ V(\hat{\beta}_1 | X) &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' V(u | X) \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1} \\ V(\hat{\beta}_1 | X) &= (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \sigma^2 I \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1} \end{aligned}$$

$$V(\hat{\beta}_1 | X) = (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \sigma^2 \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1}$$

$$V(\hat{\beta}_1 | X) = \sigma^2 (\tilde{X}_1' \tilde{X}_1)^{-1} \tilde{X}_1' \tilde{X}_1 (\tilde{X}_1' \tilde{X}_1)^{-1}$$

$$V(\hat{\beta}_1 | X) = \sigma^2 I (\tilde{X}_1' \tilde{X}_1)^{-1}$$

$$V(\hat{\beta}_1 | X) = \sigma^2 (\tilde{X}_1' \tilde{X}_1)^{-1}.$$

Ejercicio 9.

Teniendo en cuenta el siguiente modelo de regresión:

$$y = X\beta + Z\alpha + u,$$

con $X \perp Z$. Se supone que se estima el modelo utilizando métodos de mínimos cuadrados. Demostrar que:

(i) $\hat{\alpha}$ no depende de X .

Se parte de la condición de momento:

$$\begin{aligned} Z'u &= 0 \\ Z'(y - X\beta - Z\alpha) &= 0 \\ Z'y - Z'X\beta - Z'Z\alpha &= 0 \\ Z'y - 0 * \beta - Z'Z\alpha &= 0 \\ Z'y - Z'Z\alpha &= 0 \\ Z'Z\alpha &= Z'y \\ \hat{\alpha} &= (Z'Z)^{-1}Z'y. \end{aligned}$$

Por lo tanto, $\hat{\alpha}$ no depende de X .

(ii) $\text{Cov}(\hat{\beta}, \hat{\alpha}) = 0$.

$$\begin{aligned} \hat{\beta} &= (X'X)^{-1}X'y \\ \hat{\beta} &= \beta + (X'X)^{-1}X'u; \quad E(\hat{\beta}) = \beta. \end{aligned}$$

$$\begin{aligned} \hat{\alpha} &= (Z'Z)^{-1}Z'y \\ \hat{\alpha} &= \alpha + (Z'Z)^{-1}Z'u; \quad E(\hat{\alpha}) = \alpha, \end{aligned}$$

$$\begin{aligned} \text{Cov}(\hat{\beta}, \hat{\alpha}) &= E\{[\hat{\beta} - E(\hat{\beta})][\hat{\alpha} - E(\hat{\alpha})]'\} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= E[(\hat{\beta} - \beta)(\hat{\alpha} - \alpha)'] \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= E\{[(X'X)^{-1}X'u][(Z'Z)^{-1}Z'u]'\} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= E[(X'X)^{-1}X'uu'Z(Z'Z)^{-1}] \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= (X'X)^{-1}X'E(uu')Z(Z'Z)^{-1} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= (X'X)^{-1}X'\sigma^2IZ(Z'Z)^{-1} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= (X'X)^{-1}X'\sigma^2Z(Z'Z)^{-1} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= \sigma^2(X'X)^{-1}X'Z(Z'Z)^{-1} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= \sigma^2(X'X)^{-1} * 0 * (Z'Z)^{-1} \\ \text{Cov}(\hat{\beta}, \hat{\alpha}) &= 0. \end{aligned}$$

Ejercicio 10.

Sea $\hat{\beta}$ el estimador MCO y $\tilde{\beta}$ cualquier otro estimador lineal insesgado. Mostrar que, si $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I$ en un modelo de regresión lineal, entonces, el estimador MCO es eficiente, por ejemplo $V(\tilde{\beta} | X) \geq V(\hat{\beta} | X)$ o $V(\tilde{\beta} | X) - V(\hat{\beta} | X)$ es semidefinida positiva.

El estimador MCO es insesgado y lineal, lo que significa que se puede escribir $\hat{\beta}$ como una función lineal de la variable de respuesta y, por ejemplo:

$$\hat{\beta} = Ay,$$

donde $A = (X'X)^{-1}X'$. Ahora, considerar otro estimador lineal insesgado:

$$\tilde{\beta} = (A + B)y.$$

Por lo tanto, debe ser el caso de $E(\tilde{\beta}) = \beta$ porque $BX = 0$. Además, la varianza del estimador $\tilde{\beta}$ es:

$$\begin{aligned} V(\tilde{\beta} | X) &= E\{[\tilde{\beta} - E(\tilde{\beta})][\tilde{\beta} - E(\tilde{\beta})]' | X\} \\ V(\tilde{\beta} | X) &= E[(\tilde{\beta} - \beta)(\tilde{\beta} - \beta)' | X] \\ V(\tilde{\beta} | X) &= E\{[(A + B)u][(A + B)u]' | X\} \end{aligned} \quad (*)$$

$$\begin{aligned} V(\tilde{\beta} | X) &= E[(A + B)uu'(A + B)' | X] \\ V(\tilde{\beta} | X) &= (A + B)E(uu' | X)(A + B)' \\ V(\tilde{\beta} | X) &= (A + B)V(u | X)(A + B)' \\ V(\tilde{\beta} | X) &= (A + B)\sigma^2 I(A' + B') \\ V(\tilde{\beta} | X) &= (A + B)\sigma^2(A' + B') \\ V(\tilde{\beta} | X) &= \sigma^2(A + B)(A' + B') \\ V(\tilde{\beta} | X) &= \sigma^2(AA' + AB' + BA' + BB') \\ V(\tilde{\beta} | X) &= \sigma^2[(X'X)^{-1}X'X(X'X)^{-1} + (X'X)^{-1}X'B' + BX(X'X)^{-1} + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2[I(X'X)^{-1} + (X'X)^{-1} * 0 + 0 * (X'X)^{-1} + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2[(X'X)^{-1} + 0 + 0 + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2[(X'X)^{-1} + BB'] \\ V(\tilde{\beta} | X) &= \sigma^2(X'X)^{-1} + \sigma^2 BB' \\ V(\tilde{\beta} | X) &= V(\hat{\beta} | X) + \sigma^2 BB'. \end{aligned} \quad (**)$$

$$\begin{aligned} (*) \tilde{\beta} &= (A + B)y \\ \tilde{\beta} &= (A + B)(X\beta + u) \\ \tilde{\beta} &= AX\beta + BX\beta + (A + B)u \\ \tilde{\beta} &= (X'X)^{-1}X'X\beta + 0 * \beta + (A + B)u \\ \tilde{\beta} &= I\beta + 0 + (A + B)u \\ \tilde{\beta} &= \beta + (A + B)u \\ \tilde{\beta} - \beta &= (A + B)u. \end{aligned} \quad (**)$$

$$\begin{aligned} (**) E(\tilde{\beta}) &= \beta \\ E[\beta + BX\beta + (A + B)u] &= \beta \end{aligned}$$

$$\begin{aligned}
 E(\beta) + E(BX\beta) + E[(A+B)u] &= \beta \\
 \beta + BX\beta + (A+B)E(u) &= \beta \\
 \beta + BX\beta + (A+B) \cdot 0 &= \beta \\
 \beta + BX\beta + 0 &= \beta \\
 \beta + BX\beta &= \beta \\
 \beta(1 + BX) &= \beta \\
 1 + BX &= \frac{\beta}{\beta} \\
 1 + BX &= 1 \\
 BX &= 1 - 1 \\
 BX &= 0.
 \end{aligned}$$

La última ecuación sugiere que la varianza del estimador $\tilde{\beta}$ es mayor que la varianza del estimador $\hat{\beta}$. Esto se puede establecer en el siguiente importante teorema.

Teorema de Gauss-Markov. Si $E(u | X) = 0$ y $E(uu' | X) = \sigma^2 I$, en un modelo de regresión lineal, entonces, el estimador MCO es eficiente, por ejemplo $V(\tilde{\beta} | X) \geq V(\hat{\beta} | X)$ o $V(\tilde{\beta} | X) - V(\hat{\beta} | X)$ es semidefinida positiva.

Ejercicio 11.

Indicar, demostrar matemáticamente y explicar las implicaciones prácticas del teorema de Frish-Waugh-Lovell.

Este teorema nos dice que el estimador MCO $\hat{\beta}$, que se obtiene de regresar y en X y Z (modelo particionado) es igual al estimador MCO $\tilde{\beta}$, que se obtiene de regresar los residuos obtenidos de la regresión de y en Z ($\tilde{y}$) en los residuos obtenidos de la regresión de X en Z ($\tilde{X}$) (modelo alternativo).

- Modelo particionado: $y = X\beta + Z\gamma + u$.
- Modelo alternativo: $\tilde{y} = \tilde{X}\beta + \tilde{u}$.

Demostración matemática.

Considerar un modelo de regresión particionado:

$$y = X\beta + Z\gamma + u$$

y el estimador correspondiente $\hat{\beta}$. Además, considerar el modelo de regresión alternativo:

$$\tilde{y} = \tilde{X}\beta + \tilde{u},$$

con el correspondiente estimador $\tilde{\beta}$, con $\tilde{Z} = M_Z Z$ para un vector genérico Z .

Se puede demostrar que los estimadores $\hat{\beta}$ y $\tilde{\beta}$ son, numéricamente, idénticos.

Las fórmulas estándar de MCO en el modelo particionado dan las siguientes ecuaciones normales:

$$X'y = X'X\hat{\beta} + X'Z\hat{\gamma}.$$

$$Z'y = Z'X\hat{\beta} + Z'Z\hat{\gamma}.$$

Resolviendo para $\hat{\gamma}$ en la segunda ecuación y reemplazando en la primera ecuación, se obtiene:

$$Z'Z\hat{\gamma} = Z'y - Z'X\hat{\beta}$$

$$\hat{\gamma} = (Z'Z)^{-1} (Z'y - Z'X\hat{\beta})$$

$$\hat{\gamma} = (Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}.$$

$$X'y = X'X\hat{\beta} + X'Z [(Z'Z)^{-1} Z'y - (Z'Z)^{-1} Z'X\hat{\beta}]$$

$$X'y = X'X\hat{\beta} + X'Z(Z'Z)^{-1} Z'y - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X'y - X'Z(Z'Z)^{-1} Z'y = X'X\hat{\beta} - X'Z(Z'Z)^{-1} Z'X\hat{\beta}$$

$$X' [I - Z(Z'Z)^{-1} Z'] y = X' [I - Z(Z'Z)^{-1} Z'] X\hat{\beta}$$

$$X' (I - P_Z) y = X' (I - P_Z) X\hat{\beta}$$

$$X'M_Z y = X'M_Z X\hat{\beta}.$$

Por lo tanto:

$$\begin{aligned}\hat{\beta} &= (X' M_z X)^{-1} X' M_z y \\ \hat{\beta} &= (X' M_z' M_z X)^{-1} X' M_z' M_z y \\ \hat{\beta} &= (\tilde{X}' \tilde{X})^{-1} \tilde{X}' \tilde{y} \\ \hat{\beta} &= \tilde{\beta}.\end{aligned}$$

Además de las estimaciones puntuales, los residuos son idénticos. Para ver esto, considerar:

$$\begin{aligned}y &= \hat{y} + \hat{u} \\ y &= X\hat{\beta} + Z\hat{\gamma} + \hat{u}\end{aligned}$$

y multiplicar por M_z :

$$\begin{aligned}M_z y &= M_z X \hat{\beta} + M_z Z \hat{\gamma} + M_z \hat{u} \\ \tilde{y} &= \tilde{X} \hat{\beta} + 0 * \hat{\gamma} + (I - P_z) \hat{u} & (*) \\ \tilde{y} &= \tilde{X} \hat{\beta} + 0 + I \hat{u} - P_z \hat{u} \\ \tilde{y} &= \tilde{X} \hat{\beta} + \hat{u} - 0 & (**) \\ \tilde{y} &= \tilde{X} \hat{\beta} + \hat{u},\end{aligned}$$

donde $M_z \hat{u} = \hat{u}$ porque $P_z \hat{u} = 0$.

$$\begin{aligned} (*) \quad M_z Z &= (I - P_z) Z \\ M_z Z &= IZ - P_z Z \\ M_z Z &= Z - Z(Z'Z)^{-1}Z'Z \\ M_z Z &= Z - ZI \\ M_z Z &= Z - Z \\ M_z Z &= 0.\end{aligned}$$

$$\begin{aligned} (**) \quad P_z \hat{u} &= P_z M y \\ P_z \hat{u} &= P_z M_z M y \\ P_z \hat{u} &= 0 * M y & (***) \\ P_z \hat{u} &= 0.\end{aligned}$$

$$\begin{aligned} (***) \quad P_z M_z &= P_z (I - P_z) \\ P_z M_z &= P_z I - P_z P_z \\ P_z M_z &= P_z - P_z \\ P_z M_z &= 0.\end{aligned}$$

Implicaciones prácticas.

Las implicaciones prácticas de este teorema son que el estimador MCO se puede obtener de la siguiente manera:

1. Regresando y en Z y obteniendo los residuos $\tilde{y}$.
2. Regresando X en Z y obteniendo los residuos $\tilde{X}$.
3. Regresando $\tilde{y}$ en $\tilde{X}$ y obteniendo el estimador MCO $\hat{\beta}$.

Ejercicio 12.

Considerar el siguiente modelo:

$$y = X\beta + u,$$

donde la media del término de error es cero y la covarianza entre x_i y u_i es cero.

(a) Suponiendo que el término de error u_i esté correlacionado con u_j , ¿cómo estimaría el parámetro β y el error estándar de $\hat{\beta}$? ¿Por qué?

Se supone que se tiene $\{(y_i, x_i)\}_{i=1}^n$, pero se sabe que el modelo puede variar según los grupos $c = 1, \dots, C$:

$$y_{ic} = x'_{ic}\beta_c + u_{ic}.$$

Aunque es razonable pensar que $\text{Cov}(u_{ic}, u_{jc}) = 0$, puede darse el caso de que:

$$\text{Cov}(u_{ic}, u_{jc}) \neq 0.$$

Se comienza suponiendo que el término de error u_{ic} no es independiente de x_{ic} . Por ejemplo, si $u_{ic} = \alpha_c + v_{ic}$, entonces, $\text{Cov}(x_{ic}, \alpha_c) \neq 0$. En este caso, los grupos introducen sesgos si el modelo no condiciona en c . Por lo tanto, uno podría estar interesado en estimar:

$$E(y_{ic} | X_{ic}, \alpha_c) = x'_{ic}\beta_c + \alpha_c,$$

cuando el número de grupos es grande. El modelo puede ser estimado por transformaciones clásicas de mínimos cuadrados:

En el caso de efectos aleatorios, se puede considerar apilar observaciones dentro de grupos:

$$y_c = X_c\beta_c + \alpha_c,$$

donde y_c es un vector de dimensión $(n_c \times 1)$ y X_c es una matriz de $(n_c \times p)$. Escribir $n = \sum_c n_c$.

Por lo tanto, la estimación del parámetro β es:

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\hat{\beta} = \left(\sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic}x'_{ic}\right)^{-1} \sum_{c=1}^C \sum_{i=1}^{n_c} x_{ic}y_{ic}.$$

Observar que $V(\hat{\beta}) \neq \sigma^2(X'X)^{-1}$.

Y el error estándar robusto agrupado de $\hat{\beta}$ es:

$$\hat{V}(\hat{\beta}) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

$$\hat{V}(\hat{\beta}) = (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C X_c' \hat{u}_c \hat{u}_c X_c (\sum_{c=1}^C X_c' X_c)^{-1},$$

donde los residuos son $\hat{u}_c = y_c - X_c \hat{\beta}$. El problema con esta corrección es que se necesita $C \rightarrow \infty$ para consistencia.

(b) Explicar cuáles son los problemas de estimar el error estándar de $\hat{\beta}$ por MCO.

Si se asume que $u_{ic} = \alpha_c + v_{ic}$, se puede adoptar el marco de efectos aleatorios asumiendo que α y v son independientes. Darse cuenta de:

$$E(u_{ic} u_{jc}) = E[(\alpha_c + v_{ic})(\alpha_c + v_{jc})]$$

$$E(u_{ic} u_{jc}) = E(\alpha_c^2 + \alpha_c v_{jc} + v_{ic} \alpha_c + v_{ic} v_{jc})$$

y, luego, si $i = j$:

$$E(u_{ic} u_{jc}) = \sigma_\alpha^2 + \sigma_v^2$$

$$E(u_{ic} u_{jc}) = \sigma^2,$$

y, si $i \neq j$:

$$E(u_{ic} u_{jc}) = \sigma_\alpha^2$$

$$E(u_{ic} u_{jc}) = \rho \sigma^2,$$

donde $\rho = \frac{\sigma_\alpha^2}{\sigma_\alpha^2 + \sigma_v^2}$. Por resultados similares al estimador Balesta-Nerlove, se tiene que:

$$\Sigma_c = E(u_c u_c')$$

$$\Sigma_c = \sigma^2 [(1 - \rho) I_c + \rho 1_c' 1_c].$$

Luego, se sigue que la varianza de $\hat{\beta}$ es:

$$V(\hat{\beta}) = (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C X_c' \sigma^2 [(1 - \rho) I_c + \rho 1_c' 1_c] X_c (\sum_{c=1}^C X_c' X_c)^{-1}$$

$$V(\hat{\beta}) = (\sum_{c=1}^C X_c' X_c)^{-1} \sum_{c=1}^C \sigma^2 X_c' [(1 - \rho) I_c + \rho 1_c' 1_c] X_c (\sum_{c=1}^C X_c' X_c)^{-1}.$$

Es posible demostrar que:

$$V(\hat{\beta}_1) = [1 + (M - 1) \rho] V(\tilde{\beta}_1),$$

donde $V(\tilde{\beta}_1)$ es la varianza del estimador estándar MCO.

Por lo tanto, el problema de estimar el error estándar de $\hat{\beta}$ por MCO es que éste tiene sesgos considerables (en general, se nota una sobrestimación del error estándar).

(c) Se supone, ahora, que $\text{Cov}(u_i, u_j) = 0$ para todos i y j y la varianza condicional es $E(uu' | X) \equiv \Omega$. Obtener el mejor estimador lineal insesgado y su varianza. Demostrar que el término de error del modelo transformado tiene una variación constante.

Suponer que $E(uu') = \Omega \neq \sigma^2 I_n$ y Ω es desconocido. Considerar una descomposición de la matriz $\Omega^{-1} = CC' = P\Lambda^{-1}P$, donde P es una matriz ortogonal y Λ es una matriz diagonal que incluye las raíces características de Ω . Resulta que se puede escribir:

$$E(uu') = \Omega$$

$$E(uu') = (C')^{-1}C^{-1}.$$

Entonces, se puede transformar la regresión como:

$$C'y = C'X\beta + C'u$$

$$\tilde{y} = \tilde{X}\beta + \tilde{u}.$$

El término de error vector $\tilde{u}$ tiene media cero y varianza I [por ejemplo, $\tilde{u} \sim N(0, I)$] porque la transformación logra:

$$E(\tilde{u}) = E(C'u)$$

$$E(\tilde{u}) = C' E(u)$$

$$E(\tilde{u}) = C' * 0$$

$$E(\tilde{u}) = 0.$$

$$V(\tilde{u}) = V(C'u)$$

$$V(\tilde{u}) = C' V(u) C$$

$$V(\tilde{u}) = C'(C')^{-1}C^{-1}C$$

$$V(\tilde{u}) = I$$

$$V(\tilde{u}) = I.$$

El estimador MCG es:

$$\hat{\beta} = \arg \min \|y - X\beta\|_{\Omega^{-1}}^2$$

$$\hat{\beta} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}.$$

Y se puede ver lo siguiente:

$$E(\hat{\beta} | X) = E[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} | X]$$

$$E(\hat{\beta} | X) = E\{[\beta + (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{u}] | X\}$$

$$E(\hat{\beta} | X) = E(\beta | X) + E[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{u} | X]$$

$$E(\hat{\beta} | X) = \beta + (\tilde{X}'\tilde{X})^{-1}\tilde{X}' E(\tilde{u} | X)$$

$$E(\hat{\beta} | X) = \beta + (\tilde{X}'\tilde{X})^{-1}\tilde{X}' * 0$$

$$E(\hat{\beta} | X) = \beta + 0$$

$$E(\hat{\beta} | X) = \beta.$$

$$V(\hat{\beta} | X) = V[(\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} | X]$$

$$V(\hat{\beta} | X) = (\tilde{X}'\tilde{X})^{-1}\tilde{X}' V(\tilde{y} | X) \tilde{X}(\tilde{X}'\tilde{X})^{-1}$$

$$\begin{aligned}
V(\hat{\beta} | X) &= (X'CC'X)^{-1}X'C V(C'y | X) C'X(X'CC'X)^{-1} \\
V(\hat{\beta} | X) &= (X'CC'X)^{-1}X'CC' V(y | X) CC'X(X'CC'X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1} V(u | X) \Omega^{-1}X(X'CC'X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}\Omega\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}IX(X'\Omega^{-1}X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}X(X'\Omega^{-1}X)^{-1} \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}I \\
V(\hat{\beta} | X) &= (X'\Omega^{-1}X)^{-1}.
\end{aligned}$$

Por lo tanto, el estimador MCG es insesgado y tiene varianza condicional más pequeña que la del estimador MCO en un modelo heterocedástico.

(d) Explicar los pasos necesarios para implementar el método sugerido en (c).

El estimador MCG es inviable, lo que significa que no se puede implementar en la práctica. La matriz Ω es, típicamente, desconocida, por lo que nos gustaría implementar un método para estimarla. Se puede considerar, en su lugar, $\Omega(\gamma)$ y, después de establecer una relación entre la varianza condicional y el parámetro γ , se puede implementar el método.

Considerar, por simplicidad:

$$y_i = x_i\beta + (z_i'\gamma)^{\frac{-1}{2}}u_i,$$

lo que implica que el elemento i_{th} en la diagonal de Ω es $\Omega_{ii} = (z_i'\gamma)$. Tener en cuenta que, si se estima γ , se puede estimar Ω . Un simple procedimiento de estimación considera:

1. Obtener el estimador MCO ejecutando:

$$(y_i - x_i\hat{\beta})^2 = z_i'\gamma + v_i.$$

2. Colocar $\hat{\gamma}$ en Ω y obtener:

$$\begin{aligned}
\hat{\beta} &= (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y} \\
\hat{\beta} &= (X'CC'X)^{-1}X'CC'y \\
\hat{\beta} &= (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y \\
\hat{\beta} &= (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}^{-1}y.
\end{aligned}$$

En la literatura, existen otros primeros pasos convenientes para los modelos multiplicativos, cuadráticos, etc. de heterocedasticidad. Por ejemplo, podría suponerse que la varianza condicional de u es $e^{\gamma x}$.

(e) Demostrar que la diferencia entre la varianza del estimador MCO y la varianza del estimador que se propuso en (c) es semidefinida positiva.

Teorema. $V(\hat{\beta}_{MCO}) - V(\hat{\beta}_{MCG})$ es una matriz semidefinida positiva.

Prueba. Por simplicidad, C es simétrica. En primer lugar, tener en cuenta que la varianza condicional del MCO es igual a:

$$\begin{aligned} V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'y] \\ V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'(X\beta + u)] \\ V(\hat{\beta}_{MCO}) &= V[(X'X)^{-1}X'X\beta + (X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= V[I\beta + (X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= V[\beta + (X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= V(\beta) + V[(X'X)^{-1}X'u] \\ V(\hat{\beta}_{MCO}) &= 0 + (X'X)^{-1}X' V(u) X(X'X)^{-1} \\ V(\hat{\beta}_{MCO}) &= (X'X)^{-1}X'\Omega X(X'X)^{-1}. \end{aligned}$$

Considerar la descomposición:

$$\begin{aligned} X'\Omega^{-1}X &= X'CC'X = W'W. \\ X'\Omega X &= X'(C')^{-1}C^{-1}X = S'S. \\ X'X &= X'\Omega^{-1}\Omega X = X'CC'(C')^{-1}C^{-1}X = X'CC^{-1}X = W'S. \end{aligned}$$

Entonces, se tiene que:

$$\begin{aligned} (X'X)(X'\Omega X)^{-1}(X'X) &= W'S(S'S)^{-1}S'W \\ (X'X)(X'\Omega X)^{-1}(X'X) &= W'P_S W \leq W'W. \end{aligned}$$

Por lo tanto:

$$\begin{aligned} (X'X)(X'\Omega X)^{-1}(X'X) &\leq X'\Omega^{-1}X \\ [(X'X)(X'\Omega X)^{-1}(X'X)]^{-1} &\geq (X'\Omega X)^{-1} \\ (X'X)^{-1}X'\Omega X(X'X)^{-1} &\geq (X'\Omega X)^{-1} \\ V(\hat{\beta}_{MCO}) &\geq V(\hat{\beta}_{MCG}) \\ V(\hat{\beta}_{MCO}) - V(\hat{\beta}_{MCG}) &\geq 0. \end{aligned}$$

Ejercicio 13.

Considerar una muestra aleatoria $Z_1, Z_2, \dots, Z_m$ distribuida independientemente de manera uniforme $U[0, \theta]$.

(a) Obtener un estimador consistente de θ .

Es natural estimar θ considerando el estadístico de orden más grande, es decir, $\hat{\theta} = \max_{1 \leq i \leq m} \{Z_i\}$. Tener en cuenta que, para una pequeña constante $\epsilon > 0$, se tiene que $\{|X_m - \theta| > \epsilon\} = \{X_m - \theta > \epsilon\} \cup \{X_m - \theta < -\epsilon\}$. Por lo tanto:

$$\begin{aligned} P(|\hat{\theta} - \theta| > \epsilon) &= P(\hat{\theta} - \theta > \epsilon) + P(\hat{\theta} - \theta < -\epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= P(\hat{\theta} > \theta + \epsilon) + P(\hat{\theta} < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= 0 + P(\max_{1 \leq i \leq m} \{Z_i\} < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= P(Z_1 < \theta - \epsilon, Z_2 < \theta - \epsilon, \dots, Z_m < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= P(Z_1 < \theta - \epsilon) P(Z_2 < \theta - \epsilon) \dots P(Z_m < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= \prod_{i=1}^m P(Z_i < \theta - \epsilon) \\ P(|\hat{\theta} - \theta| > \epsilon) &= \left(\frac{\theta - \epsilon}{\theta}\right)^m \\ P(|\hat{\theta} - \theta| > \epsilon) &= \left(1 - \frac{\epsilon}{\theta}\right)^m \rightarrow 0, \text{ cuando } m \rightarrow \infty. \end{aligned}$$

Por lo tanto, $\hat{\theta}$ es un estimador consistente de θ .

(b) Demostrar que el estimador es consistente, explicando el papel de los supuestos necesarios para establecer la consistencia.

Los supuestos necesarios para establecer la consistencia son que la muestra debe estar distribuida aleatoriamente, uniformemente y se encuentra acotada.

Ejercicio 14.

Indicar las condiciones bajo las cuales el estimador MCO para un modelo lineal $y = X\beta + u$ es consistente y asintóticamente normal. Probar la consistencia del estimador y obtener la varianza de la distribución asintótica.

Un estimador consistente $\hat{\theta}$ es uno que converge a θ en probabilidad:

$$\hat{\theta} \rightarrow \theta$$

a medida que el tamaño de la muestra n va al infinito, para todos los valores verdaderos posibles. Con esta definición, se investiga la consistencia de MCO.

Considerar un modelo de regresión lineal de la forma:

$$y_i = x_i' \beta + u_i,$$

donde $E(u_i | x_i) = E(u_i) = 0$. Se puede asumir, provisionalmente, que los términos de error u están i.i.d. aleatoriamente con distribución F . El estimador MCO para el parámetro desconocido β es $\hat{\beta} = (X'X)^{-1}X'y$ y puede ser escrito como:

$$\begin{aligned} \hat{\beta} - \beta &= (X'X)^{-1}X'u \\ \hat{\beta} - \beta &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right), \end{aligned}$$

donde X es una matriz de $(n \times p)$ y u es un vector de $(n \times 1)$. Si las x_i son consideradas fijas o no estocásticas, se tiene que:

$$\frac{1}{n} \sum_{i=1}^n x_i x_i' \rightarrow^p E(X'X) = Q_0 \quad \text{y} \quad \frac{1}{n} \sum_{i=1}^n x_i u_i \rightarrow^p E(X'u) = 0.$$

Entonces, aplicando Chebyshev y el teorema de Slutsky, se tiene que $\hat{\beta}$ converge en probabilidad a β :

$$\begin{aligned} \hat{\beta} - \beta &\rightarrow^p Q_0^{-1} * 0 \\ \hat{\beta} - \beta &\rightarrow^p 0 \\ \hat{\beta} &\rightarrow^p \beta. \end{aligned}$$

Por otra parte, recordando que $\hat{\beta} - \beta = (X'X)^{-1}X'u$, se puede escribir:

$$\begin{aligned} \sqrt{n}(\hat{\beta} - \beta) &= \left(\frac{X'X}{n}\right)^{-1} \frac{1}{\sqrt{n}} X'u \\ \sqrt{n}(\hat{\beta} - \beta) &= n \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \frac{1}{\sqrt{n}} \left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) \\ \sqrt{n}(\hat{\beta} - \beta) &= \left(\frac{1}{n} \sum_{i=1}^n x_i x_i'\right)^{-1} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right). \end{aligned}$$

Considerando el segundo término y dado que $E(u | X) = E(u) = 0$, se tiene:

$$E\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) = E\left(\sqrt{n} \frac{1}{n} \sum_{i=1}^n x_i u_i\right)$$

$$E\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) = \sqrt{n} E\left(\frac{1}{n} \sum_{i=1}^n x_i u_i\right) \xrightarrow{p} \sqrt{\infty} E[E(X'u)] = \sqrt{\infty} E[X' E(u)] = \sqrt{\infty} E(X' * 0) = \sqrt{\infty} E(0) = \sqrt{\infty} * 0 = 0.$$

Y, dado que $E(uu') = \sigma^2$ y $\text{Cov}(u_i, u_j) = 0$, se tiene:

$$\begin{aligned} \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \text{Var}\left(\sum_{i=1}^n x_i u_i\right) \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \sum_{i=1}^n \text{Var}(x_i u_i) \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \sum_{i=1}^n x_i \text{Var}(u_i) x_i' \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{1}{n} \sum_{i=1}^n x_i \sigma^2 x_i' \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \frac{\sigma^2}{n} \sum_{i=1}^n x_i x_i' \\ \text{Var}\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i\right) &= \sigma^2 \frac{1}{n} \sum_{i=1}^n x_i x_i' \xrightarrow{p} \sigma^2 E(X'X) = \sigma^2 Q_0. \end{aligned}$$

Entonces, considerando que la convergencia en probabilidad a una constante es equivalente a la convergencia en distribución, se tiene:

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n x_i u_i \xrightarrow{d} \mathcal{N}(0, \sigma^2 Q_0).$$

Entonces, considerando el teorema de Slutsky, se tiene:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} Q_0^{-1} \mathcal{N}(0, \sigma^2 Q_0) = \mathcal{N}(0, \sigma^2 Q_0^{-1}). \quad (*)$$

$$\begin{aligned} V[\sqrt{n}(\hat{\beta} - \beta)] &= V(Q_0^{-1} X^*) && \text{donde } X^* = \mathcal{N}(0, \sigma^2 Q_0) \\ V[\sqrt{n}(\hat{\beta} - \beta)] &= Q_0^{-1} V(X^*) Q_0^{-1} \\ V[\sqrt{n}(\hat{\beta} - \beta)] &= Q_0^{-1} \sigma^2 Q_0 Q_0^{-1} \\ V[\sqrt{n}(\hat{\beta} - \beta)] &= \sigma^2 Q_0^{-1}. \end{aligned}$$

En resumen, la normalidad asintótica se deriva de: (i) la convergencia en distribución de la puntuación, (ii) la convergencia en probabilidad del Hessiano y (iii) el teorema de Slutsky.

Por lo tanto, se pudo observar que, para un modelo lineal $y = X\beta + u$, el estimador MCO es consistente y asintóticamente normal.

Ejercicio 15.

Considerar la primera ecuación en un sistema lineal de ecuaciones:

$$y_1 = \alpha_1 Y_2 + x' \beta + u_1,$$

donde Y_2 es la variable endógena (sospechada). Demostrar que el estimador MCO de la siguiente ecuación:

$$y_1 = \alpha_1 Y_2 + x' \beta + \gamma \hat{r} + v_1$$

es idéntico al estimador MC2E ($\hat{r}$ denota los residuos de $Y_2 = z_i' \pi + r_i$, donde las variables z son exógenas).

El estimador de mínimos cuadrados en dos etapas (MC2E) es:

$$\hat{\beta}_{MC2E} = (X' P_Z X)^{-1} X' P_Z y.$$

Este estimador se basa en dos proyecciones:

1. Regresar X en Z para obtener:

$$\hat{X} = Z(Z'Z)^{-1}Z'X$$

$$\hat{X} = P_Z X.$$

Es importante ver los componentes de la matriz de proyección $\hat{X} = [P_Z x', P_Z Y_2]$.
Recordar que $Z = [x', Z_2]$, por lo que:

$$\hat{X} = [x', \hat{Y}_2].$$

2. Luego, regresar y sobre $\hat{X}$, obteniendo el estimador MC2E:

$$\hat{\beta}_{MC2E} = (\hat{X}' \hat{X})^{-1} \hat{X}' y$$

$$\hat{\beta}_{MC2E} = (X' P_Z' P_Z X)^{-1} X' P_Z y$$

$$\hat{\beta}_{MC2E} = (X' P_Z P_Z X)^{-1} X' P_Z y$$

$$\hat{\beta}_{MC2E} = (X' P_Z X)^{-1} X' P_Z y.$$

Por otra parte, se definen los residuos de X en Z :

$$R = X - \hat{X}$$

$$R = X - P_Z X$$

$$R = (I - P_Z) X$$

$$R = M_Z X.$$

Considerar, ahora, el estimador de mínimos cuadrados de un modelo que incluye los residuos:

$$y = X\beta + R\gamma + u,$$

que es igual a:

$$\hat{\beta}_{vc} = (X'M_R X)^{-1} X'M_R y,$$

donde vc significa variable de control. Este estimador es idéntico al estimador MC2E porque:

$$\begin{aligned} X'M_R &= X' (I - P_R) \\ X'M_R &= X' [I - R(R'R)^{-1}R'] \\ X'M_R &= X' [I - M_Z X(X'M_Z' M_Z X)^{-1} X'M_Z'] \\ X'M_R &= X' [I - M_Z X(X'M_Z M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' [I - M_Z X(X'M_Z X)^{-1} X'M_Z] \\ X'M_R &= X' - X'M_Z X(X'M_Z X)^{-1} X'M_Z \\ X'M_R &= X' - IX'M_Z \\ X'M_R &= X' - X'M_Z \\ X'M_R &= X' - X' (I - P_Z) \\ X'M_R &= X' - X' + X'P_Z \\ X'M_R &= X'P_Z. \end{aligned}$$

$$\hat{\beta}_{vc} = (X'P_Z X)^{-1} X'P_Z y.$$

Por lo tanto, el estimador MCO de la siguiente ecuación $y_1 = \alpha_1 Y_2 + x'\beta + \gamma\hat{r} + v_1$ es idéntico al estimador MC2E $y_1 = \alpha_1 Y_2 + x'\beta + u_1$, por lo que el “sesgo por endogeneidad” se puede ver como un “sesgo por variable omitida”.

Ejercicio 16.

Teniendo en cuenta el siguiente modelo de regresión:

$$y_i = x_i' \beta + \epsilon_i,$$

con $E(\epsilon_i | x_i) = 0$ y se sabe $E(\epsilon_i^2 | x_i) = \sigma^2$.

(a) Mostrar que el estimador de mínimos cuadrados generalizados se puede escribir como un estimador de variable instrumental.

El estimador de mínimos cuadrados generalizados es:

$$\hat{\beta}_{MCG} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'\tilde{y}$$

$$\hat{\beta}_{MCG} = (X'CC'X)^{-1}X'CC'y$$

$$\hat{\beta}_{MCG} = (X'C'C'X)^{-1}X'C'C'y$$

$$\hat{\beta}_{MCG} = (X'C'X)^{-1}X'C'y.$$

Un estimador de variable instrumental puede ser el siguiente:

$$\hat{\beta}_{MC2E} = (X'P_ZX)^{-1}X'P_Zy.$$

Si se llama $C' = P_Z$, se tiene:

$$\hat{\beta}_{MCG} = (X'P_ZX)^{-1}X'P_Zy.$$

Por lo tanto, el estimador de mínimos cuadrados generalizados se puede escribir como un estimador de variable instrumental.

(b) Escribir la expresión para la variable instrumental.

$$\hat{\beta}_{MC2E} = (X'P_ZX)^{-1}X'P_Zy.$$

Ejercicio 17.

(a) Demostrar que la siguiente suposición implica ortogonalidad entre la variable aleatoria en x_i y la variable aleatoria $y_i - x_i'\beta$:

$$E [x_i (y_i - x_i'\beta)] = 0.$$

$$\begin{aligned} E [x_i (y_i - x_i'\beta)] &= E (x_i u_i) \\ E [x_i (y_i - x_i'\beta)] &= E [E (x_i u_i | x_i)] \\ E [x_i (y_i - x_i'\beta)] &= E [x_i E (u_i | x_i)] \\ E [x_i (y_i - x_i'\beta)] &= E (x_i * 0) \\ E [x_i (y_i - x_i'\beta)] &= E (0) \\ E [x_i (y_i - x_i'\beta)] &= 0. \end{aligned}$$

Esto implica:

$$\begin{aligned} \text{Cov} (x_i, u_i) &= E (x_i u_i) - E (x_i) E (u_i) \\ \text{Cov} (x_i, u_i) &= 0 - E (x_i) * 0 \\ \text{Cov} (x_i, u_i) &= 0 - 0 \\ \text{Cov} (x_i, u_i) &= 0. \end{aligned}$$

Por lo tanto, esta suposición implica ortogonalidad entre la variable aleatoria x_i y la variable aleatoria u_i .

Ofrecer condiciones adicionales sobre la distribución conjunta de x_i e y_i que hacen de β_0 la solución única para:

$$E [x_i (y_i - x_i'\beta)] = 0.$$

Las condiciones adicionales sobre la distribución conjunta de x_i e y_i que hacen de β_0 la solución única para este problema son:

- $E (u) = E (y - \beta_0 - \beta_1 x) = 0$.
- $\text{Cov} (x, u) = E (xu) - E (x) E (u) = x E (u) - E (x) * 0 = x * 0 = 0 - 0 = 0$.
- $r (x) = p$, es decir, el rango de x [$r (x)$] tiene que ser igual el número de variables independientes (p).

(b) Demostrar que el estimador MCO $\hat{\beta}$ es análogo a β_0 en el sentido de que es la única solución para:

$$\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i'\beta)] = 0,$$

donde los momentos de muestra han reemplazado a los momentos poblacionales. Este es un ejemplo de un estimador de método de momentos, que construye estimadores de parámetros que equiparan los momentos empíricos con las contrapartes de la población.

El estimador de método de momentos podría obtenerse como la solución de la condición de momento de muestra correspondiente:

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 \\ \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 * n \\ \sum_{i=1}^n (x_i y_i - x_i x_i' \beta) &= 0 \\ \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \beta &= 0 \\ \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x_i' &= 0 \\ \beta \sum_{i=1}^n x_i x_i' &= \sum_{i=1}^n x_i y_i \\ \beta_0 &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i.\end{aligned}$$

Por otra parte, el estimador de mínimos cuadrados ordinarios es el argumento que minimiza la siguiente función de criterio:

$$\sum_{i=1}^n (y_i - x_i' \beta)^2,$$

Entonces, se tiene que la ecuación normal correspondiente a este problema:

$$\sum_{i=1}^n [x_i (y_i - x_i' \beta)] = 0$$

es idéntica a la ecuación de la estimación del método de momentos.

Por lo tanto, el estimador MCO $\hat{\beta}$ es análogo a β_0 , es decir, el estimador MCO es un estimador MM.

Ejercicio 18.

Considerar un modelo de regresión:

$$y_i = x_i' \beta + \epsilon_i, \quad i = 1, \dots, n,$$

donde ϵ_i es una variable aleatoria latente que se correlaciona con la variable explicativa en x_i . Dejar que los elementos de x_i incluyan la constante 1. Se supone un muestreo i.i.d. y que:

$$E(\epsilon_i) = 0$$

$$\text{Var}(\epsilon_i) = \sigma_0^2$$

y

$$E(x_i x_i') = D_{xx},$$

donde D_{xx} es una matriz definida positiva. Además, dejar que $\text{Cov}(x_i, \epsilon_i) = \rho$.

(a) Considerar los momentos de muestra de (x_i, y_i) : $\bar{x} \equiv \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{y} \equiv \frac{1}{n} \sum_{i=1}^n y_i$, $\frac{1}{n} X'X$, $\frac{1}{n} y'y$, $\frac{1}{n} X'y$. Encontrar sus valores esperados en términos de los parámetros desconocidos.

Las contrapartes de $E(\epsilon)$ y de $\text{Cov}(x, \epsilon) = 0$ en la muestra son:

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \epsilon_i &= 0 \\ \frac{1}{n} \sum_{i=1}^n (y_i - x_i' \beta) &= 0 \\ \frac{1}{n} \sum_{i=1}^n y_i - \frac{1}{n} \sum_{i=1}^n x_i' \beta &= 0 \\ \frac{1}{n} \sum_{i=1}^n y_i &= \frac{1}{n} \sum_{i=1}^n x_i' \beta \\ \bar{y} &= \bar{x} \beta_0. \end{aligned}$$

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n x_i \epsilon_i &= 0 \\ \frac{1}{n} \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 \\ \sum_{i=1}^n [x_i (y_i - x_i' \beta)] &= 0 * n \\ \sum_{i=1}^n (x_i y_i - x_i x_i' \beta) &= 0 \\ \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i x_i' \beta &= 0 \\ \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i x_i' &= 0 \\ \beta \sum_{i=1}^n x_i x_i' &= \sum_{i=1}^n x_i y_i \\ \beta_0 &= (\sum_{i=1}^n x_i x_i')^{-1} \sum_{i=1}^n x_i y_i. \end{aligned}$$

Por lo tanto, se tiene:

$$\begin{aligned} \bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i \\ \bar{y} &= E(y_i) \end{aligned}$$

$$\bar{y} = E(x_i' \beta + \epsilon_i)$$

$$\bar{y} = E(x_i' \beta) + E(\epsilon_i)$$

$$\bar{y} = \beta E(x_i') + 0$$

$$\bar{y} = \bar{x} \beta_0.$$

$$\bar{x} = \bar{y} \beta_0^{-1}.$$

$$\frac{1}{n} X'X = \frac{1}{n} \sum_{i=1}^n x_i x_i'$$

$$\frac{1}{n} X'X = E(x_i x_i')$$

$$\frac{1}{n} X'X = \beta_0^{-1} \frac{1}{n} \sum_{i=1}^n x_i y_i.$$

$$\frac{1}{n} y'y = \frac{1}{n} \sum_{i=1}^n y_i y_i$$

$$\frac{1}{n} y'y = E(y_i y_i)$$

$$\frac{1}{n} y'y = .$$

$$\frac{1}{n} X'y = \frac{1}{n} \sum_{i=1}^n x_i y_i.$$

$$\frac{1}{n} X'y = E(x_i y_i)$$

$$\frac{1}{n} X'y = \frac{1}{n} \sum_{i=1}^n x_i x_i' \beta_0.$$

(b) Suponer que hay K variables instrumentales, z_{ik} ($k = 1, \dots, K$) que no están correlacionadas con ϵ_i :

$$\text{Cov}(z_i, \epsilon_i) = 0,$$

pero correlacionado con x_i

$$E(z_i x_i') = D_{zx}.$$

donde D_{zx} tampoco es singular. Encontrar los valores esperados de los momentos de muestra adicionales $\frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} Z'Z y, \frac{1}{n} Z'X$ en términos de los parámetros desconocidos.

(c) Al equiparar todos los momentos de la primera y de la segunda muestra arriba con sus valores de población, encontrar un estimador del método de momentos para todos los parámetros desconocidos. Mostrar, en particular, que el estimador de β_0 es el estimador VI $(Z'X)^{-1}Z'y$.

$$\hat{\beta}_{VI} = (Z'X)^{-1}Z'y.$$

Ejercicio 19.

Encontrar el estimador de máxima verosimilitud para el parámetro desconocido considerando las siguientes distribuciones:

(a) $f(x, \theta) = \theta e^{-\theta x}$, con $x \geq 0$ y $\theta > 0$.

(b) $f(x, \theta) = \theta c^\theta x^{-(\theta+1)}$, con $x \geq c$ y $\theta > 0$.

(c) $f(x, \theta) = x\theta^{-2} e^{\frac{-x^2}{2\sigma^2}}$, con $x > 0$ y $\theta > 0$.

(d) $f(x, \theta) = \sigma^{-1} e^{\frac{-(x-\mu)}{\sigma}}$, con $x \geq \mu$, donde $\theta = (\mu, \sigma)$.

(e) $x_1, \dots, x_n$ de una distribución $u(\theta - \frac{1}{2}, \theta + \frac{1}{2})$.

(f) $x_1, \dots, x_n$ de $\mathcal{N}(\mu_1, \sigma^2)$ y $Y_1, \dots, Y_n$ i.i.d. de $\mathcal{N}(\mu_2, \sigma^2)$. Tener en cuenta que $\theta = (\mu_1, \mu_2, \sigma^2)$.

Ejercicio 20.

Suponer que X es una variable aleatoria continua con función de densidad de probabilidad $f(x, \theta_0)$. Se supone derivadas continuas de segundo orden.

(a) Demostrar que $E \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right] = 0$.

$$f_{\theta}(y) = \{f(x, \theta), \theta \in \Theta, \theta \in \mathbb{R}^p\}.$$

$$f(x, \theta) = f_{\theta}(x), \forall x \in X.$$

$$E \{ \log [f(x_i, \theta_0)] \} \geq E \{ \log [f(x_i, \theta)] \}.$$

$$\max_{\theta \in \Theta} E [l(\theta_0)], \text{ donde } l(\theta) = \log [f(x, \theta)].$$

Por lo tanto, se tiene:

$$E \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right] = 0.$$

(b) Suponiendo que $\text{Var} \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right]$ existe, mostrar que: $E \left[\frac{\partial^2 l(\theta_0 | x)}{\partial \theta \partial \theta'} \right] = -\text{Var} \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right]$.

$$E \left[\frac{\partial^2 l(\theta_0 | x)}{\partial \theta \partial \theta'} \right] = -E \left\{ \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right] \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right]' \right\}$$

$$E \left[\frac{\partial^2 l(\theta_0 | x)}{\partial \theta \partial \theta'} \right] = -\text{Var} \left[\frac{\partial l(\theta_0 | x)}{\partial \theta} \right].$$

Evaluación Domiciliaria N° 1: **Modelos para Datos en Panel.**

Parte I.

Una herramienta para estudiar, empíricamente, la relación entre los salarios de los trabajadores y sus características son las llamadas ecuaciones de ingresos o ecuaciones de Mincer (Mincer, 1974). Considerar el siguiente modelo:

$$\ln \text{salario}_{it} = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{exper}_{it} + \beta_3 \text{casado}_{it} + \beta_4 \text{sindicato}_{it} + \beta_5 \text{afro}_i + \beta_6 \text{hispano}_i + u_{it}, \quad (1)$$

donde $\ln$ salario es el logaritmo de los salarios por hora; educ son los años de educación formal; exper son los años de experiencia laboral; casado es una dummy que indica si el trabajador es casado; sindicato es una dummy que indica si el trabajador pertenece a un sindicato; afro e hispano son dummies que indican si el individuo es de origen afroamericano o hispano, respectivamente (la categoría base es blanco no hispano); y u es un término aleatorio que varía entre individuos y en el tiempo.

En este ejercicio, se va a estimar este modelo utilizando la base de datos nls8087.dta, que cuenta con información extraída de la National Longitudinal Survey (Youth Sample) para el período 1980-1987. La muestra comprende 545 hombres jóvenes (17 a 30 años de edad) que trabajan a tiempo completo y que, para 1980, ya habían finalizado su escolaridad.

(1) *Mostrar estadísticas descriptivas de las variables incluidas en el modelo teniendo en cuenta la estructura de panel (variabilidad total, between y within). Describirlas brevemente y discutir por qué, para ciertas variables, la variabilidad within es cero, mientras que la between no lo es.*

En la tabla 1, se pueden observar estadísticas descriptivas de las variables incluidas en el modelo (1) teniendo en cuenta la estructura de panel (variabilidad total, *between*, *within*). La cantidad de observaciones para calcular los estadísticos descriptivos de las variables del modelo en sus tres formas (*overall*, *between* y *within*) es 4.360 (individuos x años), en donde se calculan sobre un total de $n = 545$ individuos durante $T = 8$ años.

El promedio de **salario** de los trabajadores de la muestra en el período de estudio es de USD 5,92 por hora, oscilando entre USD 0,028 y USD 57,5. El promedio de esta variable para cada individuo en el tiempo (*between*) se situó en un rango entre USD 1,5 y USD 28,36, mientras que la desviación con respecto a su promedio (*within*) varió entre -16,42 y 35,07. Esto último indica que hay individuos que, en algunos períodos, obtuvieron un salario por debajo de su promedio en el período bajo análisis. Con respecto al desvío estándar, se observa que la variabilidad en el promedio de salario entre los individuos (*between*) es mayor a la observada en un individuo a lo largo del tiempo (*within*). Es decir, el salario tiene una mayor variabilidad entre individuos que la que tiene para un individuo a lo largo de los años.

El promedio de años de **educación** de los trabajadores de la muestra en el período de estudio es de 11,77 años, oscilando entre los 3 y 16 años.

El promedio de años de **experiencia** de los trabajadores de la muestra en el período de estudio es de 6,51 años, oscilando entre 0 y 18 años. El promedio de esta variable en el tiempo para cada individuo se situó entre 3,5 y 14,5 años de experiencia laboral, mientras que la desviación con respecto a su promedio (*within*) varió entre 3,01 y 10,01 años. Con respecto al desvío estándar, se observa que la variabilidad en el promedio de años de experiencia entre los individuos (*between*) es menor a la observada en un individuo a lo largo del tiempo (*within*). Es decir, los años de experiencia tienen una mayor variabilidad para un individuo a lo largo de los años que la que tienen entre individuos.

Para el caso de las variables binarias, se observa que, en promedio, en el período analizado, el 43,9% de los individuos están casados, el 24,4% está afiliado a un sindicato, el 11,6% son afroamericanos y el 15,6% son hispanoamericanos. En el caso de las variables **casado** y **sindicato**, la variabilidad es relativamente baja, tanto la observada en el promedio entre los individuos (*between*) como en un individuo a lo largo del tiempo (*within*), pero distinta de cero, por lo que hay individuos que cambiaron de estado a lo largo del período analizado.

Si una variable no varía con el tiempo, es decir, que mantiene su valor a lo largo del período analizado, la desviación estándar *within* será igual a cero, ya que la misma mide la variabilidad en un individuo a lo largo del tiempo y, lógicamente, si su valor es el mismo en cada período de tiempo, este indicador será cero. Las variables **educ**, **afro** e **hispano**, que indican los años de educación y la raza (características que no cambian en el tiempo para los individuos de la muestra), tienen una desviación estándar *within* igual a cero, ya que no varían en el tiempo. En estos mismos casos, la desviación estándar *between* no es igual a cero, ya que la misma mide la variabilidad entre los individuos y, por lo tanto, será distinta de cero; sólo será igual a cero cuando, en cada período de tiempo, la variable tome el mismo valor para cada individuo (como es el caso de la variable *años*).

Tabla 1. Estadísticas descriptivas de las variables del modelo (1).

Variable		Media	Desvío estándar	Mínimo	Máximo	Observaciones
salario	<i>Overall</i>	5,919175	3,202225	0,0279014	57,50431	N = 4.360
	<i>Between</i>	-	2,455819	1,503564	28,35696	n = 545
	<i>Within</i>	-	2,057397	-16,42349	35,06653	T = 8
educ	<i>Overall</i>	11,76697	1,746181	3	16	N = 4.360
	<i>Between</i>	-	1,747585	3	16	n = 545
	<i>Within</i>	-	0	11,76697	11,76697	T = 8
exper	<i>Overall</i>	6,514679	2,825873	0	18	N = 4.360
	<i>Between</i>	-	1,654918	3,5	3,5	n = 545
	<i>Within</i>	-	2,291551	3,014679	10,01468	T = 8
casado	<i>Overall</i>	0,4389908	0,4963208	0	1	N = 4.360
	<i>Between</i>	-	0,3766116	0	1	n = 545
	<i>Within</i>	-	0,3236137	-0,4360092	1,313991	T = 8
sindicato	<i>Overall</i>	0,2440367	0,4295639	0	1	N = 4.360
	<i>Between</i>	-	0,3294467	0	1	n = 545
	<i>Within</i>	-	0,2759787	-0,6309633	1,119037	T = 8
afro	<i>Overall</i>	0,1155963	0,3197769	0	1	N = 4.360
	<i>Between</i>	-	0,320034	0	1	n = 545
	<i>Within</i>	-	0	0,1155963	0,1155963	T = 8
hispano	<i>Overall</i>	0,1559633	0,3628622	0	1	N = 4.360
	<i>Between</i>	-	0,3631539	0	1	n = 545
	<i>Within</i>	-	0	0,1559633	0,1559633	T = 8

Fuente: Elaboración propia.

(2) Estimar la ecuación (1) por Pooled OLS (POLS). Interpretar estadística y económicamente los coeficientes obtenidos. Explicar por qué es muy posible que la presencia de heterogeneidad no observable a nivel de trabajador haga que las estimaciones anteriores sean inconsistentes. ¿Por qué el modelo Within con efectos fijos por trabajador permitiría resolver este problema?

En esta estimación por POLS del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *hispano*, que no es estadísticamente significativa. En la tabla 2, se muestran los resultados de esta estimación (conjuntamente con las estimaciones *between*, *within*, primeras diferencias y efectos aleatorios), que expresan que, en promedio y manteniendo todo lo demás constante:

- Al aumentar en un año la educación del individuo, el salario por hora de los trabajadores aumenta en un 10,4%.
- Al aumentar en un año la experiencia laboral del individuo, el salario por hora aumenta en un 5%.
- Un individuo casado tiene un salario por hora un 11,3% mayor que uno que no está casado.
- Un individuo afiliado a un sindicato tiene un salario por hora un 18,4% mayor que uno que no está afiliado.
- Un hombre afroamericano tiene un salario por hora un 14,2% menor que un individuo blanco.
- Un individuo hispano tiene un salario por hora un 1,3% mayor que un individuo no hispano (esta variable no es estadísticamente significativa).

A pesar de que los signos de los coeficientes obtenidos son consistentes con lo que indica la literatura económica relacionada, es muy posible que la presencia de heterogeneidad no observable a nivel trabajador haga que las estimaciones anteriores sean sesgadas e inconsistentes. Un problema que surge, regularmente, en los estudios que evalúan la relación entre estas variables es que es difícil aislar el impacto causal de un año adicional de educación en los salarios. El retorno a un año adicional de educación puede estar siendo distorsionado por el efecto de otros factores relevantes, pero no observados, que pueden estar relacionados con los años de educación. Por ejemplo, es muy probable que la habilidad, la inteligencia o el talento de los individuos estén relacionados con los salarios que reciben y, al mismo tiempo, con el nivel de escolaridad alcanzado. Tanto la habilidad como otros factores característicos de los individuos no son observables y, por lo tanto, ignorar el vínculo mencionado conduciría a estimaciones inconsistentes y a inferencias no válidas con respecto al efecto causal de los años de educación.

El modelo *within* con efectos fijos por trabajador permitiría resolver este problema porque, al “eliminar” el efecto de la heterogeneidad inobservable (fuente potencial de sesgo) que afecta a los regresores del modelo, se obtienen estimadores insesgados y consistentes para evaluar la relación entre las variables analizadas.

(3) *Estimar, nuevamente, el modelo 1 mediante los siguientes estimadores alternativos: between, within, primeras diferencias y efectos aleatorios. Interpretar cuidadosamente el coeficiente estimado de la variable *exper* para cada uno de los modelos. Para la interpretación, prestar especial atención a cuál es la dimensión del panel (corte transversal o longitudinal) relevante para identificar el efecto en cada caso. Luego, comentar por qué, en el modelo de efectos fijos y de primeras diferencias, se omiten las variables *educ*, *afro* e *hispano*.*

En estas cuatro estimaciones alternativas (*between*, *within*, primeras diferencias y efectos aleatorios) del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *hispano*, que no es estadísticamente significativa en ninguna de estas estimaciones. En la tabla 2, se muestran los resultados de estas estimaciones (conjuntamente con los resultados de la estimación por POLS).

La variable *exper* resulta estadísticamente significativa en las cuatro estimaciones y, en todos los casos, se observa una relación positiva entre esta variable y los salarios. La interpretación bajo cada modelo, en promedio y manteniendo todo lo más constante, es la siguiente:

- *Between*: Un año adicional de experiencia laboral del individuo *en comparación con la experiencia laboral promedio del resto de los individuos* aumenta el salario por hora en un 2,8%.
- *Within*: Un año adicional de experiencia laboral del individuo *en comparación con la propia experiencia laboral promedio del individuo* aumenta el salario por hora en un 6%.
- *Primeras Diferencias*: Un año adicional de experiencia laboral de un año *en comparación a otro año* aumenta el salario por hora en un 6,5%.

- Efectos Aleatorios: Un año adicional de experiencia laboral del individuo *en comparación con la propia experiencia laboral promedio del individuo* aumenta el salario por hora en un 5,8%.

En el modelo de efectos fijos y en el de primeras diferencias, se omiten las variables *educ*, *afro* e *hispano* porque son variables que no varían con el tiempo, es decir, que mantienen su valor para cada individuo a lo largo del período analizado, por lo que no aparecen en estos modelos por ser iguales a cero.

En el modelo *within*, se usan las desviaciones de las variables de su promedio a través del tiempo y, en el caso de las variables mencionadas, su valor en cada momento *t* es igual a su promedio, es decir, su desvío respecto de la media es igual a cero.

En el modelo de primeras diferencias, sucede algo similar, sólo que, en lugar de usar desvíos de las variables respecto de su promedio a través del tiempo, se utiliza la diferencia entre los valores de las variables en *t* y en *t-1*, por lo cual, en este modelo, también se eliminan las variables mencionadas, que no varían con el tiempo para un mismo individuo.

En el caso de la variable *educ*, que hace referencia a los años de educación formal del individuo, en esta muestra, no existen variaciones en el tiempo, ya que comprende a hombres jóvenes que trabajan a tiempo completo y que, para 1980, ya habían finalizado su escolaridad, por lo que no siguieron educándose formalmente en el período de análisis (1980-1987).

En el caso de las variables *afro* e *hispano*, son dummies que hacen referencia a características innatas del individuo, que, sin duda, no varían con el tiempo.

Tabla 2. Estimaciones del modelo (1).

Variables	(1) POLS	(2) <i>Between</i>	(3) <i>Within</i>	(4) Primeras Diferencias	(5) Efectos Aleatorios
<i>educ</i>	0,104*** (0,005)	0,091*** (0,011)	- -	- -	0,108*** (0,009)
<i>exper</i>	0,050*** (0,003)	0,028** (0,011)	0,060*** (0,003)	0,065*** (0,007)	0,058*** (0,003)
<i>casado</i>	0,113*** (0,016)	0,142*** (0,041)	0,061*** (0,018)	0,043* (0,023)	0,076*** (0,017)
<i>sindicato</i>	0,184*** (0,017)	0,259*** (0,046)	0,084*** (0,019)	0,042** (0,020)	0,110*** (0,018)
<i>afro</i>	-0,142 (0,024)	-0,141*** (0,049)	- -	- -	-0,141*** (0,048)
<i>hispano</i>	0,013 (0,021)	0,010 (0,043)	- -	- -	0,016 (0,043)
constante	0,023 (0,063)	0,284 (0,178)	1,212*** (0,017)	- -	-0,048 (0,111)
Observaciones	4.360	4.360	4.360	3.815	4.360
<i>R</i> ²	0,184	0,169	0,051	0,025	0,178
Número de id	-	545	545	-	545

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(4) A partir de las estimaciones anteriores:

a. Para cada uno de los estimadores del inciso anterior, explicar cuáles son los supuestos que se requieren para consistencia.

Los supuestos que se requieren para consistencia de los estimadores del inciso anterior son:

➤ POLS:

Para que el estimador sea consistente, se requiere del supuesto (1) $E(x'_{it}u_{it})=0$, es decir, exogeneidad contemporánea.

Cuando $\mu_i=0$, es decir, en ausencia de heterogeneidad inobservable, (2) $E(x'_{it}\varepsilon_{it})=0$ es condición suficiente para la consistencia del estimador.

Cuando $\mu_i \neq 0$, es decir, con presencia de heterogeneidad inobservable, el término de error estará compuesto por dos componentes ($u_{it}=\mu_i + \varepsilon_{it}$), por lo que, para la consistencia del estimador, se requerirá, además de (2), que la heterogeneidad inobservable sea ortogonal a todos los elementos de x_{it} , es decir, (3) $E(x'_{it}\mu_i)=0$.

➤ Within y Primeras Diferencias:

Para que el estimador sea consistente, se requiere del supuesto (4) $E(x'_{is}\varepsilon_{it})=0$, s, $t=1, \dots, T$, es decir, exogeneidad estricta, un supuesto más fuerte que el supuesto (2), que ya no es suficiente para garantizar estimadores consistentes.

➤ Between y Efectos Aleatorios:

Para que el estimador sea consistente, se requiere del supuesto (3) $E(x'_{it}\mu_i)=0$ (ortogonalidad entre los regresores y la heterogeneidad inobservable) y (4) $E(x'_{is}\varepsilon_{it})=0$, s, $t=1, \dots, T$ (exogeneidad estricta).

En la tabla 3, se resumen las condiciones descriptas para la consistencia de los estimadores de los modelos para datos en panel.

Tabla 3. Condiciones para consistencia de los estimadores.

Condiciones para consistencia	(1) POLS	(2) <i>Between</i>	(3) <i>Within</i>	(4) Primeras Diferencias	(5) Efectos Aleatorios
(1) Exogeneidad contemporánea $E(\mathbf{x}_{it}'\mathbf{u}_{it})=0$	X				
(2) Exogeneidad contemporánea (*) $E(\mathbf{x}_{it}'\boldsymbol{\varepsilon}_{it})=0$	X				
(3) Ortogonalidad entre regresores y heterogeneidad inobservable $E(\mathbf{x}_{it}'\boldsymbol{\mu}_i)=0$	X	X			X
(4) Exogeneidad estricta $E(\mathbf{x}_{is}'\boldsymbol{\varepsilon}_{it})=0$ (**)		X	X	X	X

(*) Esta condición es suficiente para la consistencia de POLS cuando $\mu_i=0$. (**) Esta condición es suficiente para la consistencia de *Between* cuando $\mu_i=0$. Fuente: Elaboración propia.

b. Implementar un test para evaluar la hipótesis nula de ausencia de efectos fijos. Proveer una interpretación del resultado.

Teniendo en cuenta que el modelo POLS es un modelo restringido con respecto al modelo de efectos fijos, en donde se asume que existe un intercepto común para todos los individuos de la muestra, puede realizarse una prueba F para evaluar la significancia estadística de los efectos fijos.

La hipótesis nula es $\mu_i=0, \forall i$, es decir, que el intercepto es común para todos los individuos de la muestra y, por lo tanto, que no existen efectos fijos asociados a cada individuo. Si la prueba se rechaza, se podría afirmar que el modelo de efectos fijos es preferible al modelo POLS.

En esta muestra, se obtiene el siguiente resultado:

$F(544, 3812)=10,08$; $p\text{-valor}=0,0000$.

Por lo tanto, dado que el p-valor es muy pequeño, se rechaza la hipótesis nula y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que existen efectos fijos asociados a cada individuo y, en consecuencia, el modelo de efectos fijos es preferible al modelo POLS.

c. Implementar un test de Hausman para comparar los estimadores de efectos fijos y de efectos aleatorios y comentar los resultados obtenidos.

El test de Hausman evalúa la posible correlación entre el componente de error individual μ_i y las variables exógenas del modelo. Si, efectivamente, existe esta correlación, entonces, no incluir μ_i en el modelo producirá un sesgo de variable omitida

en los coeficientes de las variables explicativas. Hausman demostró que la diferencia entre los coeficientes de efectos fijos y de efectos aleatorios ($\hat{\beta}_{EF} - \hat{\beta}_{EA}$) puede ser usada para probar la hipótesis nula de que μ_i y las variables explicativas no están correlacionadas.

La hipótesis nula de la prueba de Hausman es que los estimadores de efectos aleatorios y de efectos fijos no difieren sustancialmente y, en consecuencia, bajo H_0 , tanto el estimador de efectos fijos como el de efectos aleatorios son consistentes, mientras que, bajo H_a , sólo el estimador de efectos fijos es consistente.

En esta muestra, se obtiene el siguiente resultado:

$$\chi^2(3) = 22,69; \quad p\text{-valor} = 0,0000.$$

Por lo tanto, dado que el p-valor es muy pequeño, se rechaza la hipótesis nula y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que los efectos individuales están correlacionados con las variables explicativas y, en consecuencia, el modelo de efectos fijos es preferible al modelo de efectos aleatorios.

Parte II.

Este ejercicio se basa en el artículo de Rockoff, J. (2004) “The Impact of Individual Teachers on Student Achievement: Evidence from Panel Data” (American Economic Review, 94(2), pp. 247-252). El objetivo es ilustrar con un ejemplo cómo los datos en panel permiten responder a preguntas que no podrían responderse con otro tipo de datos. Como primera consigna, se pide leer, detenidamente, el artículo de Rockoff (2004). Luego, responder las siguientes preguntas.

(1) *Explicar cuál es la crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes. ¿De qué se vale Rockoff para superar esa limitación de la literatura previa?*

El trabajo de Rockoff (2004) presenta evidencia sobre los efectos que tiene la calidad de los docentes en el rendimiento académico de los estudiantes, utilizando un análisis de datos en panel. El autor, por un lado, busca identificar la varianza de la distribución de los efectos fijos del maestro, la cual captura la heterogeneidad de la fuerza laboral docente, y, por otro lado, muestra que elevar la calidad del maestro mejora los resultados de los estudiantes.

La crítica que hace el autor de los trabajos previos que buscan medir el efecto de la calidad de los docentes sobre el rendimiento académico de los estudiantes refiere a la calidad de los datos utilizados. La información que recogen no permite obtener datos coincidentes entre alumnos y docentes, en los que tanto el rendimiento del alumno como el de los maestros se observe en múltiples años. Este tipo de datos es necesario para la correcta identificación de los efectos fijos del maestro. Sin embargo, no está disponible para los investigadores, en gran parte porque los distritos escolares no utilizan datos en panel para fines de evaluación y, generalmente, la información utilizada en la literatura proviene, directamente, de los distritos escolares o de instituciones de investigación que han recopilado estos datos. Así, los trabajos previos a Rockoff (2004) presentan estimaciones inconsistentes, ya que, al no considerar las características inobservables relevantes para el resultado de las pruebas, sobreestiman el efecto de las características observables en el logro de los estudiantes.

Para poder superar esa limitación de la literatura previa, Rockoff (2004) utiliza un conjunto de datos en panel con información de puntajes de las pruebas de los estudiantes y de la asignación de maestros en las clases, para estimar, con mayor precisión, cuánto afectan los maestros al rendimiento de los estudiantes. Los datos sobre los puntajes permiten enfocarse en las diferencias en el desempeño de un mismo alumno con diferentes maestros y, así, distinguir la variación en la calidad del maestro de la variación en las habilidades cognitivas de los estudiantes y otras características. Observar al mismo maestro en varias aulas le permite diferenciar la calidad del maestro de factores como el tamaño de la clase. Vale aclarar que la identificación de los efectos fijos es posible gracias a que se observa a un mismo maestro dando clases a estudiantes en diferentes cursos.

Rockoff (2004) dispone de un panel con datos sobre estudiantes y maestros de dos distritos contiguos ubicados en un solo condado de New Jersey entre 1989 y 2001, evaluados entre pre-escolar y 6to. grado con pruebas estandarizadas y donde es posible identificar qué maestro da clases a cada estudiante. Esto último permite identificar el

efecto de cada maestro en sus alumnos y, al mismo tiempo, al contar con un panel, puede controlar por efectos fijos a nivel de cada estudiante para tener en cuenta el valor agregado que proporciona el maestro, lo cual no era posible realizar con los datos que disponían los estudios previos, cuestionados por el autor. Además, la longitud del panel posibilita que incluya la experiencia del docente como una variable explicativa.

(2) *A continuación, se reproduce el modelo propuesto por Rockoff (2004):*

$$A_{it} = \alpha_i + \gamma X_{it} + \sum_j [\theta^{(j)} + f(\text{Exp}_t^{(j)}) + \eta C_t^{(j)}] D_{it}^{(j)} + \sum_s \pi_{st} S_{it}^{(s)} + \varepsilon_{it}.$$

Explicar qué tipo de variables podrían estar siendo capturadas por el término α_i y por qué el autor incorpora el término no lineal $f(\text{Exp}_t^{(j)})$.

El modelo propuesto por Rockoff (2004) consiste en estimar el efecto sobre el puntaje de la prueba del estudiante i en el año t (A_{it}) de: efectos fijos del estudiante (α_i), características observables de los estudiantes que varían con el tiempo (X_{it}), efecto fijo del maestro ($\theta^{(j)}$), experiencia del docente ($\text{Exp}_t^{(j)}$), características observables del aula ($C_t^{(j)}$) y efecto del año escolar (π_{st}), en donde ε_{it} es el término de error del modelo. Las variables $D_{it}^{(j)}$ y $S_{it}^{(s)}$ son indicadoras de si el estudiante tuvo, respectivamente, al maestro j en la escuela s durante el año t .

Las variables que podrían estar siendo capturadas por el término α_i (características no observables de los estudiantes que podrían estar correlacionadas con el resultado de las pruebas) son: las capacidades cognitivas, las características socioeconómicas, la inteligencia, la educación en el hogar, la habilidad en general, la habilidad particular para la comprensión de textos y para las matemáticas, las motivaciones personales, entre otras cosas.

El autor incorpora el término no lineal $f(\text{Exp}_t^{(j)})$ para estimar el efecto de la experiencia de los docentes en las pruebas de los estudiantes. Lo hace de manera no lineal porque la experiencia y el año t son colineales para los maestros y, por lo tanto, la identificación de los efectos fijos de estos y de los efectos de la experiencia requiere una suposición con respecto a la forma de $f(\text{Exp}_t^{(j)})$. El autor asume que la experiencia adicional del maestro no afecta los resultados de las pruebas de los estudiantes después de un cierto punto de corte $\overline{\text{Exp}}$, lo cual es respaldado por investigaciones previas que sugieren que cualquier ganancia de experiencia se logra en los primeros años de enseñanza (Rivkin *et al.*, 2001). Al suponer que la experiencia no impacta después de alcanzados los 10 años, el autor acota el efecto de la experiencia y asume que éste es representable por un polinomio cúbico.

Parte III (Bonus).

El uso de efectos fijos cuando se trabaja con datos de panel ¿resuelve por completo el problema de endogeneidad? ¿Por qué? ¿Qué otro método se podría usar? Se puede encontrar una pista en el paper de Cornwell y Trumbull (1994) que se vio en clase.

En primer lugar, se dice que existe endogeneidad cuando hay correlación entre los regresores del modelo y el término de error, por lo que no se cumple el supuesto clásico de exogeneidad estricta:

$$E(u_i|x_i) \neq 0.$$

La existencia de endogeneidad puede darse por varias razones:

- Autocorrelación de los errores.
- Errores de medición.
- Variables omitidas.
- Simultaneidad.

Dadas las diversas razones por las cuales puede haber endogeneidad, no existe una única solución a este problema. Por lo tanto, cuando se trabaja con datos de panel, al considerarse sólo el caso de endogeneidad causada por la “heterogeneidad inobservable” (que puede ser considerada como una variable omitida), la utilización de efectos fijos no resuelve por completo el problema de endogeneidad, en el caso de que existan otras causas.

En el contexto de datos de panel, la utilización de efectos fijos es útil para resolver el problema de endogeneidad. Los datos de panel combinan cortes transversales (información de varios individuos en un momento dado) durante varios períodos de tiempo. El disponer de datos de panel constituye una ventaja porque se dispone de una mayor cantidad de datos y se puede hacer un seguimiento de cada individuo a través del tiempo, pero, al mismo tiempo, un inconveniente porque, si todas las cualidades relevantes del individuo no son observables, entonces, los errores individuales estarán correlacionados con los regresores y los estimadores de OLS serán inconsistentes.

Si no se disponen de todas las variables de influencia, entonces, $E(x'_{it}u_{it}) \neq 0$, es decir, los regresores no son ortogonales al término de error (presencia de heterogeneidad inobservable). En este caso, POLS será inconsistente y la utilización de efectos fijos permitiría resolver este problema, al incorporar variables *dummy* por individuo.

Sin embargo, cuando el modelo presenta variables independientes endógenas, los estimadores de OLS serán inconsistentes, ya que $E(x'_i u_i) \neq 0$, es decir, no existe ortogonalidad entre los regresores y el término de error. Como se mencionó anteriormente, esto puede ocurrir cuando las variables explicativas están sujetas a errores de medición, cuando hay variables explicativas relevantes que se han omitido en el modelo o cuando existe simultaneidad.

Para resolver este problema de endogeneidad, se utiliza el método de variables instrumentales (2SLS o 3SLS), cuando se dispone de “buenos instrumentos”, es decir,

variables que no pertenecen al modelo, no están correlacionadas con el término de error y están correlacionadas con las variables explicativas endógenas, condicionando por las variables explicativas exógenas.

En el *paper* de Cornwell y Trumbull (1994), se utiliza una estrategia empírica que permite resolver dos fuentes de endogeneidad: presencia de heterogeneidad inobservable y simultaneidad. Los autores presentan evidencia respecto de que el efecto de la habilidad del sistema de justicia criminal para disminuir el crimen es mucho más débil que lo que indicaban estudios previos. La utilización de datos de panel, donde la unidad de observación es el condado, permite a los autores controlar por aquellas características específicas a nivel condado que son inobservables y que podrían estar relacionadas con las variables de justicia criminal del modelo que estiman. Esto es un avance respecto de la literatura previa que ignoraba esta fuente de endogeneidad al hacer estimaciones de tipo *cross-section*, concentrándose en resolver la endogeneidad convencional (por simultaneidad), que surge de la dependencia entre la probabilidad de arresto o el tamaño de la fuerza policial con la tasa de criminalidad. Concretamente, los autores utilizan una estrategia empírica que combina el uso de variables instrumentales para resolver la endogeneidad proveniente de la simultaneidad y la utilización de datos de panel para resolver la endogeneidad que surge de la presencia de heterogeneidad inobservable, condicionando por los efectos del condado en las estimaciones.

Referencias.

Cornwell, C. y Trumbull, W. N. (1994). Estimating the Economic Model of Crime with Panel Data. *The Review of Economics and Statistics*, 76(2), 360-366. Recuperado de <https://www.jstor.org/stable/2109893>

Rockoff, J. E. (2004). The Impact of Individual Teachers on Student Achievement Evidence from Panel Data. *The American Economic Review*, 94(2), 247-252. Recuperado de <https://www.jstor.org/stable/3592891>

Evaluación Domiciliaria N° 2: **Selección Muestral y Censura.**

Modelo para el Salario Horario.

Considerar un modelo para el logaritmo del ingreso laboral horario en función de la edad y su cuadrado, junto con una serie de dummies por máximo nivel educativo alcanzado.

$$lilaho_i = \beta_0 + \beta_1 edad_i + \beta_2 edad_i^2 + \beta_3 pric_i + \beta_4 seci_i + \beta_5 secc_i + \beta_6 supi_i + \beta_7 supc_i + u_i. \quad (1)$$

(1) *Estimar los parámetros del modelo mediante el método de MCO. Dar una interpretación económica de los resultados y explicar, brevemente, sobre la inconsistencia de sus estimaciones como consecuencia de un posible sesgo de selección en la muestra utilizada.*

En esta estimación por MCO del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%, a excepción de la variable *pric*, que es estadísticamente significativa al 5%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación de Heckman en dos etapas y de la estimación de Heckman por máxima verosimilitud), que expresan que, en promedio y manteniendo todo lo demás constante:

- Al aumentar en un año la edad de la mujer, el ingreso laboral horario varía en 100 (0,041 - 0,00072 edad) %. Se puede observar que el efecto parcial de la edad comienza a ser negativo a partir de, aproximadamente, los 57 años de edad¹.
- Considerando que los retornos a la educación son iguales a 100 ($e^{\beta_j} - 1$) %, con $j = 3, 4, 5, 6, 7$, y comparado con una mujer con primaria incompleta: una mujer con primaria completa, secundaria incompleta, secundaria completa, superior incompleto y superior completo tiene un ingreso laboral horario un 12,4%, 41,6%, 93,9%, 130,3% y 241,4% mayor, respectivamente. Se puede observar que la brecha salarial por hora entre niveles educativos aumenta con la educación.

Debido a la existencia de un sesgo de selección en la muestra utilizada, que acontece cuando las muestras no son “aleatorias”, es decir, que no representan, adecuadamente, la población que se desea estudiar, es posible que las estimaciones sean inconsistentes. El caso de muestras de participantes del mercado laboral no es un caso de una selección aleatoria, sino de la autoselección de los individuos derivada de un proceso de maximización de utilidad. Al mismo tiempo, como el estudio sólo considera a los individuos que trabajan, se obtiene una muestra incompleta de la población (“autoseleccionada” de acuerdo con la decisión de los individuos por educarse), lo cual conduce a conclusiones erróneas (estimaciones inconsistentes y sesgadas) del efecto de la educación sobre el ingreso laboral. En este caso, al haber una “sobrerrepresentación” de la población educada en la muestra, se tiende a subestimar el efecto de la educación

¹ $\frac{\partial E(lilaho_i | x_1, \dots, x_p)}{\partial edad_i} = 0 \Leftrightarrow \beta_1 + 2\beta_2 edad_i = 0 \Leftrightarrow 2\beta_2 edad_i = -\beta_1 \Leftrightarrow edad_i^* = \frac{-\beta_1}{2\beta_2} = \frac{-0,041214}{2(-0,0003595)} = \frac{-0,041214}{-0,000719} \cong 57,32$; donde x_k , $k = 1, \dots, p$, son las variables independientes del modelo (1).

sobre el ingreso laboral, lo cual se puede observar en la menor magnitud (en comparación con las siguientes estimaciones) de los coeficientes estimados de las *dummies* por máximo nivel educativo alcanzado.

(2) Estimar, nuevamente, la ecuación de regresión del punto anterior implementando el método de Heckman en dos etapas utilizando a la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años como regresores de la ecuación de selección. Justificar cada una de las etapas del método indicando los supuestos en los que se basa.

En esta estimación de Heckman en dos etapas del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman por máxima verosimilitud).

Para resolver el problema de selección muestral, Heckman (1979) propone tratar el sesgo de selección como un problema de variable relevante omitida. En particular, al estimar por MCO usando la muestra seleccionada, λ (.) es una variable omitida. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman por máxima verosimilitud).

Para computar el estimador de Heckman en dos etapas, se consideran los siguientes supuestos del modelo de selección: (1) (y_{1i}, x_{1i}) se observa sólo si $y_{2i} = 1$; (2) (y_{2i}, x_{2i}) se observa para todos los individuos; (3) (u_{1i}, u_{2i}) son independientes de x_{2i} y tienen media cero (exogeneidad estricta); (4) $u_{2i} \sim \mathcal{N}(0, \sigma_2^2)$; (5) $E(u_{1i} | u_{2i}) = \gamma u_{2i}$; y se consideran las siguientes ecuaciones:

- Ecuación de regresión: $y_{1i} = x'_{1i}\beta_1 + u_{1i}$.
- Ecuación de selección: $y_{2i}^* = x'_{2i}\beta_2 + u_{2i}$.
- Variable observada: $y_{2i} = 1 (y_{2i}^* > 0)$.

En la primera etapa del método, se estima la ecuación de selección mediante un modelo Probit. En el caso del modelo (1), se estima una ecuación de participación en el mercado laboral, donde la variable dependiente es binaria, del tipo “participa” o “no participa”, en términos de ser o no ser observado un ingreso laboral (mujeres que estarán en la muestra). Esta ecuación se interpreta como la forma reducida de un modelo en el cual la decisión de participación en el mercado laboral (que es una variable binaria) depende de características personales y del nivel educativo del individuo y, a su vez, permite estimar la probabilidad predicha de la participación en el mercado laboral de una mujer con ciertas características, lo cual permite obtener una estimación consistente para λ . Se supone que el error de la ecuación de selección se distribuye bajo una distribución normal con media cero y varianza constante σ^2 .

En la segunda etapa del método, se estima por MCO una ecuación del logaritmo del ingreso laboral horario como función de la edad, del nivel educativo y de λ (probabilidad de participar en el mercado laboral). Éste es un modelo de determinación de ingresos a la Mincer, corregido por la presencia de sesgo de selección (λ).

Este método proporciona estimadores consistentes y asintóticamente normales, por lo que los métodos estándar de inferencia funcionan correctamente.

(3) *Implementar un test que ponga a prueba la hipótesis de ausencia de selección muestral indicando, claramente, las hipótesis, el estadístico de prueba, su distribución asintótica y el resultado del test. ¿Cuál es la utilidad de dicho test?*

La presencia de sesgo de selección puede ser evaluada mediante un test de significatividad de λ , donde se evalúa $\gamma^* \equiv \gamma\sigma_2$, con σ_2 desvío estándar del estimador de la ecuación de selección. Ya que σ_2 es mayor que cero, se puede evaluar la presencia de sesgo de selección mediante las siguientes hipótesis:

$$H_0: \gamma^* = 0; \quad H_a: \gamma^* \neq 0.$$

Bajo la hipótesis nula, γ^* es igual a cero, indicando que no existe sesgo de selección, en tanto que, bajo la hipótesis alternativa, γ^* es distinto de cero, indicando que existe sesgo de selección. Así, bajo H_0 , el estadístico de prueba es $\frac{\hat{\gamma}^*}{SE(\hat{\gamma}^*)} \xrightarrow{d} \mathcal{N}(0, 1)$, que tiene una distribución asintótica normal con media igual a cero y varianza constante igual a uno.

La utilidad de este test es que permite determinar si los errores estándar computados por MCO en la segunda etapa son correctos. Por lo tanto, considerando la segunda etapa, bajo la hipótesis nula, los errores serán homocedásticos, en tanto que, en el caso de rechazar la hipótesis nula, los errores serán heterocedásticos, ya que la varianza se altera por la censura/el truncamiento.

En el caso del modelo (1), ya que el p-valor es muy pequeño, se rechaza la hipótesis de nula (ver tabla 1) y se puede afirmar que estos datos proporcionan evidencia suficiente para indicar que existe sesgo de selección y que, por lo tanto, λ es estadísticamente significativo para explicar el logaritmo del ingreso laboral horario, es decir, la estimación por MCO es sesgada.

(4) *Computar el estimador de Heckman por máxima verosimilitud e indicar cuáles son los supuestos sobre los que se construye dicho estimador. Discutir sus ventajas y desventajas con respecto al método en dos etapas.*

En esta estimación de Heckman por máxima verosimilitud del modelo (1), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 1, se muestran los resultados de esta estimación (conjuntamente con los resultados de la estimación por MCO y de la estimación de Heckman en dos etapas).

Para computar el estimador de Heckman por máxima verosimilitud, se consideran las mismas ecuaciones mencionadas anteriormente y los mismos supuestos, excepto el supuesto (4), que se reemplaza por un supuesto más fuerte para poder computar la verosimilitud, que es distribución normal bivariada de los errores:

$$\begin{bmatrix} u_{1i} \\ u_{2i} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_1^2 & \rho\sigma_1 \\ \rho\sigma_1 & 1 \end{bmatrix} \right).$$

Una de las ventajas del estimador de Heckman por máxima verosimilitud con respecto al método en dos etapas es que es eficiente, considerando que la segunda etapa de este último, debido a la selección, es heterocedástica.

Sin embargo, si bien el estimador por máxima verosimilitud no tendría este problema, tiene dificultades prácticas de implementación: en primer lugar, requiere de supuestos demasiado estrictos sobre la distribución de los errores, ya que, mientras que, en el método en dos etapas, se requiere el supuesto de normalidad sobre u_{2i} , en el método por máxima verosimilitud, también se requiere este supuesto sobre u_{1i} ; la función de verosimilitud es complicada de calcular; y existen problemas de convergencia en la maximización numérica.

Tabla 1. Estimaciones del modelo (1).

		(1)	(2)	(3)
Variable		MCO	Heckman en dos etapas	Heckman por máxima verosimilitud
lilaho	edad	0,041*** (0,003)	0,064*** (0,007)	0,043*** (0,003)
	edad2	-0,000*** (0,000)	-0,001*** (0,000)	-0,000*** (0,000)
	pric	0,117** (0,046)	0,169*** (0,046)	0,122*** (0,042)
	seci	0,348*** (0,044)	0,440*** (0,048)	0,357*** (0,040)
	secc	0,662*** (0,045)	0,790*** (0,055)	0,674*** (0,042)
	supi	0,834*** (0,045)	0,973*** (0,057)	0,847*** (0,042)
	supc	1,228*** (0,044)	1,395*** (0,060)	1,244*** (0,041)
	_cons	4,396*** (0,069)	3,676*** (0,199)	4,328*** (0,078)
trabaja	edad	- -	0,113*** (0,008)	0,112*** (0,008)
	edad2	- -	-0,001*** (0,000)	-0,001*** (0,000)
	pric	- -	0,2851*** (0,099)	0,285*** (0,099)
	seci	- -	0,554*** (0,095)	0,553*** (0,099)
	secc	- -	0,782*** (0,103)	0,784*** (0,103)
	supi	- -	0,862*** (0,106)	0,869*** (0,105)
	supc	- -	1,251*** (0,106)	1,254*** (0,106)
	asiste	- -	-0,088 (0,054)	-0,096* (0,054)
	hijos12	- -	-0,048** (0,021)	-0,047** (0,021)
	_cons	- -	-1,790*** (0,174)	-1,774*** (0,174)
	/mills	- -	0,618*** (0,158)	- -
	/athrho	- -	- -	0,100* (0,060)
	/lnsigma	- -	- -	-0,537*** (0,006)
Observaciones		13,522	14,837	14,837
R ²		0,341	-	-

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

Modelo para las Horas Trabajadas.

(5) Considerar un modelo para las horas trabajadas en función de la edad (y su cuadrado), las dummies educativas, la asistencia escolar y el número de hijos menores que 12 años. Estimar los parámetros utilizando un modelo Tobit y compararlos con la estimación de MCO. Discutir sobre lo adecuado de una y otra estrategia focalizando el análisis en el tipo de variable dependiente de este modelo.

$$hstrt_i = \beta_0 + \beta_1 edad_i + \beta_2 edad_i^2 + \beta_3 pric_i + \beta_4 secc_i + \beta_5 secc_i + \beta_6 sup_i + \beta_7 sup_i + \beta_8 asiste_i + \beta_9 hijos12_i + u_i. \quad (2)$$

En estas estimaciones (MCO y Tobit) del modelo (2), todas las variables explicativas consideradas resultan estadísticamente significativas al 1%. En la tabla 2, se muestran los resultados de estas estimaciones.

Para discutir lo adecuado de una y otra estrategia, se debe considerar un rasgo inherente a la variable dependiente (horas trabajadas), el cual es la censura. La muestra excluye información de aquellas mujeres que, por ejemplo, poseen un elevado ingreso laboral de reserva y que, por lo tanto, no participan en el mercado de trabajo, lo cual configura un sesgo de selección.

La estimación por MCO impone una relación lineal entre la variable dependiente censurada y las variables explicativas, pero el hecho de que la variable dependiente latente (inobservable) siga un modelo lineal no implica que la variable dependiente censurada (observada) siga este mismo modelo. En concreto, la variable censurada será una transformación no lineal de la variable latente y, por lo tanto, seguirá un modelo no lineal. Así, la estimación por MCO supone un problema de especificación para las horas trabajadas observadas, sesgando, potencialmente, a los estimadores. En el caso del modelo (2), el sesgo se debe al hecho de no poder observar a las mujeres que poseen altos ingresos laborales de reserva o un menor costo de oportunidad de permanecer desempleadas o cuyas características de capital humano les dificulta acceder a un puesto de trabajo. La estimación de un modelo Tobit permitiría resolver este sesgo, obteniendo estimadores consistentes.

Por un lado, si las características de las mujeres que no trabajan (excluidas de la muestra) no difieren de aquellas que trabajan (incluidas en la muestra), la exclusión no es un problema y, por lo tanto, la estimación por MCO será consistente; sin embargo, es muy probable que esto no se cumpla en el caso de las horas trabajadas, en particular considerando que el desempleo, en parte, se debe a la falta de capital humano. Por otro lado, si las características de las mujeres que trabajan (incluidas en la muestra) difieren de aquellas que no lo hacen, la exclusión es un problema y, por lo tanto, la estimación por MCO será inconsistente. En este caso, es necesario tener en cuenta estas diferencias al momento de querer estimar consistentemente el modelo (2). En el caso contrario (diferencias inexistentes o poco importantes), la estimación por MCO de este modelo puede resultar conveniente, ya que el sesgo de selección desaparece o se reduce y, por lo tanto, las estimaciones se asemejan a las del modelo Tobit, aprovechándose una de las ventajas de utilizar MCO, que es la interpretación directa de los coeficientes como efectos parciales.

Tabla 2. *Estimaciones del modelo (2).*

Variable	(1)	(2)
	MCO	Tobit
edad	1,737*** (0,082)	1,984*** (0,085)
edad2	-0,020*** (0,001)	-0,023*** (0,001)
pric	3,186** (1,284)	3,680*** (1,191)
seci	7,600*** (1,222)	8,484*** (1,137)
secc	9,560*** (1,245)	10,750*** (1,182)
supi	8,820*** (1,264)	10,195*** (1,205)
supc	10,723*** (1,223)	12,122*** (1,153)
asiste	-3,355*** (0,504)	-3,508*** (0,558)
hijos12	-2,250*** (0,200)	-2,379*** (0,214)
_cons	-6,647*** (1,978)	-13,671*** (1,970)
var (e.hstrt)	-	328,52*** (4,106)
Observaciones	14.837	14.837
R ²	0,0787	-

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(6) *Utilizando el modelo Tobit, computar los efectos parciales de la edad y de la cantidad de hijos sobre: (a) el valor esperado de la variable censurada y (b) el valor esperado de la variable truncada. Dar una interpretación económica de los resultados.*

En la tabla 3, se muestran los resultados de las estimaciones de los efectos parciales de la edad y de la cantidad de hijos menores a 12 años en el hogar sobre el valor esperado de las horas trabajadas. Para el caso de una mujer con edad promedio (aproximadamente, 40 años)², con secundaria completa y con dos hijos menores de 12 años en el hogar, se tienen los siguientes casos:

- Variable dependiente censurada: Al aumentar en un año la edad, las horas trabajadas aumentan, en promedio, en 1,67 y, al aumentar en un hijo la cantidad de hijos, las horas trabajadas disminuyen, en promedio, en 2,01.
- Variable dependiente truncada: Al aumentar en un año la edad, las horas trabajadas aumentan, en promedio, en 1,51 y, al aumentar en un hijo la cantidad de hijos, las horas trabajadas disminuyen, en promedio, en 1,81.

² Específicamente, la edad promedio de las mujeres de la muestra es 39,69897 años.

Tabla 3. *Estimaciones de efectos parciales del modelo (2).*

Variable	Efecto parcial	
	Censura	Truncamiento
edad	1,674*** (0,056)	1,512*** (0,056)
hijos12	-2,007*** (0,172)	-1,813*** (0,155)
Observaciones	14.387	14.387

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

Evaluación Domiciliaria N° 3: **Métodos No Paramétricos.**

Parte I: Desigualdad y Salarios Mínimos en México y Argentina.

En este ejercicio, se buscará replicar ciertos resultados del paper de Bosch y Manacorda (2008) usando datos de México y de Argentina. En dicho trabajo, se explora la contribución del salario mínimo sobre el aumento en la desigualdad de los salarios que tuvo lugar en México entre fines de los '80 y fines de los '90, analizando diferencias entre el sector formal e informal. La base de datos base_Bosch&Manacorda.dta contiene información del ingreso laboral mensual en la actividad principal para una muestra de trabajadores asalariados de entre 16 y 60 años, extraída de encuestas de hogares de Argentina y de México. En el caso de Argentina, se utilizó la Encuesta Permanente de Hogares (EPH) del año 1993 y del segundo semestre de 2004. Para México, se utilizó la Encuesta Nacional de Empleo Urbano (ENEU) para el primer trimestre de los años 1989 y 2001¹, agrupando los datos como Bosch y Manacorda (2008) en 3 zonas: de ingresos altos (Zona A), medios (Zona B) y bajos (Zona C). Para cada año (y zona, en el caso de México), se tiene un salario mínimo distinto². Además, para facilitar el trabajo, la base contiene la mediana de los salarios y los salarios mínimos de cada año.

(a) *Estimar la función de densidad del logaritmo del salario estandarizado correspondiente a Argentina para el segundo semestre del año 2004, mediante el estimador de kernels empleando un kernel Epanechnikov. Experimentar con tres anchos de banda alternativos: ancho de banda óptimo, mitad del óptimo y doble del óptimo. Mostrar gráficos reportando los parámetros de suavizamiento h utilizados en cada caso. Describir el comportamiento observado de la densidad estimada. Justificar. Explicar el criterio de optimalidad que se usó para computar el h óptimo.*

En la figura 1, a partir de la Encuesta Permanente de Hogares (EPH), se presenta la distribución estimada del logaritmo del salario estandarizado para Argentina para el segundo semestre de 2004, utilizando tres anchos de banda distintos y un kernel Epanechnikov.

En la primera figura, se observa la distribución estimada con un ancho de banda óptimo ($h = 0,1049$). Ésta presenta una forma suave con algo de ruido (en particular, en la cola izquierda), donde se observa una marcada concentración de las observaciones en el centro de la distribución y un mayor número de observaciones a la izquierda de la misma, lo cual indica que existe un mayor número de individuos con salarios menores al promedio que aquellos con salarios mayores al promedio. Además, la distancia entre el salario más bajo de la muestra y el salario medio es mayor a la distancia entre el salario medio y el salario más alto.

¹ Los datos son públicos y se encuentran disponibles en el sitio web del INDEC <https://www.indec.gob.ar/bases-de-datos.asp> (Argentina) y del INEGI <http://www.beta.inegi.org.mx/datos/> (México).

² La evolución del salario mínimo en Argentina puede consultarse en el sitio web del Ministerio de Trabajo Nacional <http://www.trabajo.gob.ar/estadisticas/Bel/ingresos.asp>; en el caso de México, el salario mínimo diario por zona puede consultarse en el sitio web del Servicio de Administración Tributaria (SAT) http://omawww.sat.gob.mx/informacion_fiscal/tablas_indicadores/Paginas/salarios_minimos.aspx.

En la segunda figura, se observa la distribución estimada con un ancho de banda igual a la mitad del óptimo ($h=0,0525$). Ésta presenta una forma no tan suave con mucho más ruido (también en la cola izquierda) y más alta que la anterior, donde se observa más claramente la asimetría de la distribución con mayores observaciones hacia la izquierda.

En la tercera figura, se observa la distribución estimada con un ancho de banda igual al doble del óptimo ($h=0,2098$). Ésta presenta una forma muy suave con muy poco ruido, donde no se aprecia con tanta claridad la asimetría de la distribución con mayores observaciones hacia la izquierda.

Como se puede observar, cuanto más chico es el h utilizado, más ruidosa será la función de densidad, por lo que la elección de la amplitud del ancho de banda determina las características cualitativas de la densidad estimada. Para N fijo, existe un *trade-off* entre sesgo y eficiencia de los estimadores de kernels³, ya que ambas propiedades dependen de la elección de h , pero de manera inversa: a menor h , menor sesgo y mayor varianza (menor eficiencia); a mayor h , mayor sesgo y menor varianza (mayor eficiencia). La elección óptima del ancho de banda hará un balance entre ambos para resolver el *trade-off*.


Por otra parte, para consistencia de la estimación, es suficiente con que sesgo y varianza tiendan a cero cuando $N \rightarrow \infty$. El sesgo lo hará si $h \rightarrow 0$ y la varianza cuando $N \times h \rightarrow 0$. Entonces, por un lado, se requiere que h decrezca con el tamaño muestral N y, por otro lado, que la velocidad a la que se reduce h sea menor que la velocidad a la que aumenta N , así $N \times h \rightarrow \infty$. Este criterio lo cumplirá el h que minimiza el Error Cuadrático Medio Integrado (ECMI), que es una de las formas de elección de h que permiten resolver el *trade-off* entre sesgo y eficiencia para N fijo:

$$ECMI = \int E [\hat{f}(x) - f(x)]^2 dx = \int \{[Sesgo \hat{f}(x)]^2 + Var [\hat{f}(x)]\} dx.$$

Así, el ECMI promedia los ECM a lo largo de todos los posibles puntos de estimación, utilizando las expresiones aproximadas del sesgo y de la varianza.

³ La expresión aproximada para el sesgo del estimador de kernels viene dada por: $Sesgo [\hat{f}(x_0)] \cong \frac{h^2}{2} f''(x_0) \int_{-\infty}^{+\infty} K(\varphi) \varphi^2 d\varphi$. Y la expresión aproximada para la varianza asintótica del estimador de kernels viene dada por: $Var [\hat{f}(x_0)] \cong \frac{1}{N \times h} f(x_0) \int_{-\infty}^{+\infty} K^2(\varphi) d\varphi$.

Figura 1. Estimaciones de la función de densidad (utilizando Kernel Epanechnikov) del logaritmo del salario para Argentina (segundo semestre de 2004).




Fuente: Elaboración propia.

(b) Ídem inciso (a), pero experimentar con distintos tipos de funciones de Kernel. Mostrar gráficos y discutir.

En la figura 2, se presenta la distribución estimada del logaritmo del salario estandarizado para Argentina para el segundo semestre del año 2004, utilizando distintos kernels (Epanechnikov, Epanechnikov Modificado, Gaussiano y Triangular) y un ancho de banda óptimo ($h = 0,1049$).

Se puede observar que no hay diferencias significativas entre la estimación de la función de densidad mediante un kernel Epanechnikov y un kernel Gaussiano, la cuales resultan suaves y con cierta concentración en el centro de la distribución, con colas con poca densidad. En cambio, también se puede ver que el kernel Epanechnikov Modificado y el kernel Triangular presentan mucho más ruido que los mencionados anteriormente.

Figura 2. Estimaciones de la función densidad (utilizando distintos kernels) del logaritmo del salario para Argentina (segundo semestre de 2004).



Fuente: Elaboración propia.

(c) Una manera gráfica de ver el alcance del salario mínimo es a través de las funciones de densidad de la distribución de los salarios. Permiten visualizar más claramente cuán operativo es el salario mínimo en diferentes períodos y si el mismo afecta sólo a los trabajadores formales o si tiene efectos derrame hacia el sector informal. En este inciso, el objetivo es replicar las figuras del paper de Bosch y Manacorda (2008) usando los datos de México y de Argentina. En los ejercicios que siguen, para el caso de México, usar sólo la zona B (municipios de ingresos medios).


(c.1) Graficar las funciones de densidad de los salarios estandarizados estimadas por kernels, comparando los dos años disponibles para cada país (Argentina 1993 vs. 2004, por un lado, y México 1989 vs. 2001, por el otro), junto con líneas verticales indicando el salario mínimo correspondiente a cada año (gráficos similares a la figura 2 del paper).

En la figura 3, a partir de la Encuesta Permanente de Hogares (EPH) y de la Encuesta Nacional de Empleo Urbano (ENEU), se presentan las distribuciones estimadas del logaritmo del salario estandarizado para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001). Las líneas verticales indican el valor real del salario mínimo para cada país en los años considerados.

En el caso de Argentina, no se observan muchos cambios en la distribución de los salarios entre 1993 y el segundo semestre de 2004. Por un lado, en relación a 1993, en 2004, la distribución presenta un mayor número de observaciones en la cola izquierda, lo que indica que un mayor número de trabajadores reciben salarios menores que el promedio. Por otro lado, la concentración en el centro de la distribución se redujo marginalmente. Además, entre 1993 y 2004, el salario mínimo aumenta (representado por el movimiento de la línea vertical hacia la derecha) y pareciera no ser muy operativo.

En el caso de México, se observan algunos cambios en la distribución de los salarios entre 1989 y 2001. Entre estos años, el salario mínimo disminuye significativamente (representado por el movimiento de la línea vertical hacia la izquierda) y pareciera ser bastante operativo, lo cual se observa en que la distribución “engorda” a la izquierda del salario mínimo de 1989.

Figura 3. Estimaciones de la función de densidad del logaritmo del salario para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001)⁴.



Fuente: Elaboración propia.

(c.2) Construir, para cada año y cada país por separado, gráficos análogos a la figura 5 del paper, comparando las funciones de densidad del salario estandarizado para asalariados formales e informales. Describir los gráficos, analizando si el salario mínimo es operativo para el total de los asalariados, como así también para el sector formal e informal. Comparar los resultados para los diferentes años y entre ambos países.

En la figura 4, se presentan las distribuciones estimadas del logaritmo del salario estandarizado para asalariados formales e informales para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2001). Las líneas verticales indican el valor real del salario mínimo para cada país en los años considerados.

En el caso de Argentina, se puede observar que:

- La distribución de los salarios de los trabajadores informales es más desigual en 2004 respecto de lo que era en 1993.

⁴ Para el caso de México, sólo se incluyen datos de la zona de municipios de ingresos medios.


- En 1993, la distribución de los salarios de los trabajadores formales y de los informales resulta similar, con la distribución de estos últimos ubicada un poco más “hacia la izquierda”, es decir, con niveles salariales menores que los que reciben los trabajadores formales.
- En 2004, la distribución de los salarios de trabajadores formales e informales difiere significativamente. Mientras que la distribución de los salarios de los trabajadores informales está más “aplanada” o con una marcada asimetría hacia la izquierda (es decir, con un mayor número de trabajadores que reciben salarios muy por debajo del promedio y del salario mínimo), la distribución de los salarios de los trabajadores formales tiene una mayor concentración en el centro y colas ligeramente densas.
- Respecto al salario mínimo, el mismo es operativo tanto para los trabajadores formales como para los informales. Se observa un agrupamiento de los salarios de los trabajadores informales en torno al mismo.

En el caso de México, se puede observar que:

- La distribución de los salarios de los trabajadores informales es más desigual en 2001 respecto de lo que era en 1989.
- En 1989, la distribución de los salarios de los trabajadores informales muestra un engrosamiento en el lado derecho (es decir, un mayor número de trabajadores que reciben salarios mayores al promedio), mientras que, en 2001, esto se invierte y esta distribución muestra un “engrosamiento” en el lado izquierdo (es decir, un mayor número de trabajadores que reciben salarios menores al promedio). Esto no sucede en el caso de la distribución de los salarios de los trabajadores formales.
- Respecto al salario mínimo, en 1989, el mismo es operativo tanto para los trabajadores formales como para los informales, con una mayor proporción de trabajadores informales en torno a este nivel salarial en relación a los trabajadores formales, en tanto que también hay un mayor número de trabajadores informales por debajo de este nivel para ese año; en 2001, el salario mínimo disminuye en relación con el de 1989, mostrando una mayor relevancia en el caso de los trabajadores informales, en tanto que sólo unos pocos trabajadores formales reciben salarios por debajo del salario mínimo.

En conclusión, los salarios de los trabajadores informales, tanto en Argentina como en México, parecen verse afectados por el salario mínimo. En Bosch y Manacorda (2008), se señala que este resultado no debería sorprendernos, ya que, en estos países (como en muchos de América Latina), el salario mínimo se ha utilizado como un índice de inflación, afectando a los trabajadores informales de manera directa. Al mismo tiempo, la dispersión de los salarios que se observa en ambos países hace que el salario mínimo afecte al salario de reserva del conjunto de los trabajadores (Freeman, 2007; Bosch y Manacorda, 2008), lo que explica la concentración de trabajadores en torno al nivel del salario mínimo.

Figura 4. Estimaciones de la función de densidad del logaritmo del salario estandarizado para trabajadores formales e informales para Argentina (1993 y segundo semestre de 2004) y México (1989 y 2004)⁵.



Fuente: Elaboración propia.

⁵ Ídem nota al pie número 4.

Parte II: Estimación no Paramétrica de Curvas de Engel para Argentina.

(a) *Estimar paramétricamente por mínimos cuadrados la relación entre la participación o share del gasto en alimentos (sh_g_alim) y el logaritmo del gasto total familiar ($lgastot$) usando: (i) una especificación lineal y (ii) una especificación cuadrática (es decir, donde se incluya un término lineal y otro cuadrático en la variable explicativa $lgastot$). Reportar los resultados de las estimaciones en una tabla. Comparar los resultados.*

En la tabla 1, a partir de la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005, se presentan las estimaciones paramétricas por MCO de la relación entre la participación del gasto en alimentos y el logaritmo del gasto total familiar, utilizando una especificación lineal y una cuadrática.

En el caso de la especificación lineal, el coeficiente del gasto total familiar es negativo y esta variable es estadísticamente significativa, indicando que, ante un aumento de un 1% en el gasto total familiar, la participación del gasto en alimentos en éste disminuye, en promedio y *ceteris paribus*, en 0,0766 puntos porcentuales, en consonancia con lo indicado por la teoría económica (Ley de Engel). En el caso de la especificación cuadrática, las variables explicativas resultan estadísticamente no significativas para explicar esta relación. Por último, se puede mencionar que el poder explicativo de la estimación no varía con el cambio de especificación (el R^2 , prácticamente, no se altera).

Tabla 1. *Estimaciones paramétricas (lineal y cuadrática).*

Variable	(1)	(2)
	Especificación lineal	Especificación cuadrática
$lgastot$	-0,0766*** (0,0080)	-0,1360 (0,1240)
$lgastot^2$	- (0,0081)	0,0040 (0,0081)
constante	0,8722*** (0,0614)	1,0895*** (0,4723)
Observaciones	573	573
R^2	0,1669	0,1674


Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(b) *Estimar un modelo no paramétrico usando el estimador de Nadaraya-Watson (NW) para ajustar la relación entre sh_g_alim y $lgastot$. Utilizar un kernel Gaussiano y parámetro de suavizamiento $h=0,18$. Graficar la regresión estimada no paramétricamente.*

En la figura 5, se presenta una estimación no paramétrica de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar, utilizando el estimador de Nadaraya-Watson (NW), un kernel Gaussiano y un parámetro de suavizamiento $h=0,18$.

Se puede observar una relación inversa entre ambas variables, en línea con lo observado por Engel. A medida que el gasto total familiar aumenta, la participación del gasto en alimentos en éste disminuye, lo cual estaría indicando que el aumento del gasto en alimentos es menor que el aumento del gasto total familiar.

Figura 5. Estimación no paramétrica (estimador de Naradaya-Watson).




Fuente: Elaboración propia.

(c) El objetivo de este inciso es comparar las estimaciones paramétricas del inciso (a) con la estimación no paramétrica del inciso (b). Se pide graficar todas las estimaciones en un mismo gráfico y superponer los intervalos de confianza del estimador no paramétrico. Sin hacer un test formal, ¿puede rechazarse la especificación del modelo paramétrico lineal? ¿y la del cuadrático?

En la figura 6, se presentan las estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador NW) de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar.

Se puede observar que las estimaciones paramétricas de esta relación se encuentran dentro del intervalo de confianza de la estimación no paramétrica. Por lo tanto, sin hacer un test formal, se puede expresar que no es posible rechazar la especificación del modelo paramétrico lineal y la del modelo cuadrático (aunque ésta resulta no significativa), ya que no pareciera haber evidencia de diferencias significativas entre los resultados obtenidos por los dos tipos de estimaciones (paramétrica y no paramétrica).

Figura 6. Estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

(d) Repetir los incisos (a), (b) y (c) usando el share del gasto en transporte (*sh_g_transp*) en lugar de *sh_g_alim*. Comentar los resultados.

En la tabla 2, a partir de la Encuesta Nacional de Gasto de los Hogares (ENGH) 2004-2005, se presentan las estimaciones paramétricas por MCO de la relación entre el share del gasto en transporte y el logaritmo del gasto total familiar, utilizando una especificación lineal y una cuadrática.


En el caso de la especificación lineal, el coeficiente del gasto total familiar es positivo y esta variable es estadísticamente significativa (pero sólo al 10%). En el caso de la especificación cuadrática, el coeficiente del gasto total familiar es negativo y el del gasto total familiar al cuadrado es positivo, en tanto que ambas son estadísticamente significativas, indicando que, a medida que el gasto total familiar aumenta, la participación del gasto en transporte en éste disminuye hasta un nivel determinado de gasto, a partir del cual la participación del mismo comienza a aumentar. Por último, se puede mencionar que el poder explicativo de la estimación varía significativamente con el cambio de especificación (el R^2 pasa de 0,0075 a 0,0224), aunque se encuentra en un nivel muy bajo.

Tabla 2. Estimaciones paramétricas (lineal y cuadrática).

Variable	(1)	(2)
	Especificación lineal	Especificación cuadrática
lgastot	0,0133* (0,0071)	-0,2540*** (0,0915)
lgastot2	-	0,0180*** (0,0062)
constante	0,0472 (0,0528)	1,027*** (0,3414)
Observaciones	563	563
R^2	0,0075	0,0224

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

En la figura 7, se presenta una estimación no paramétrica de la relación entre la participación del gasto en transporte en el gasto total familiar y el gasto total familiar, utilizando el estimador de Naradaya-Watson (NW). Se puede observar una concentración de las observaciones en los niveles bajos de la participación del gasto en transporte y mayor dispersión a medida que la participación del gasto en transporte en el gasto total familiar aumenta.

Figura 7. Estimación no paramétrica (estimador de Naradaya-Watson).


Fuente: Elaboración propia.

En la figura 8, se presentan las estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador NW) de la relación entre la participación del gasto en transporte en el gasto total familiar y el gasto total familiar.

A diferencia de los resultados obtenidos anteriormente para el gasto en alimentos, los dos tipos de estimaciones (paramétrica y no paramétrica) difieren considerablemente. La estimación del modelo paramétrico lineal no se encuentra dentro de los intervalos de confianza de la estimación no paramétrica a lo largo de toda la distribución y, además, los intervalos de confianza de ambas estimaciones no coinciden. Respecto de la estimación del modelo paramétrico cuadrático, se observa un mejor ajuste que para el caso de la del paramétrico lineal y se encuentra dentro de los intervalos de confianza de la estimación no paramétrica, prácticamente, a lo largo de toda la distribución; sin embargo, esta estimación tiene importantes diferencias con la no paramétrica a medida que nos alejamos (por izquierda y por derecha) del centro.

Por lo tanto, sin hacer un test formal, se puede expresar que es posible rechazar la especificación del modelo paramétrico lineal y la del modelo cuadrático, ya que hay evidencia de diferencias significativas entre los resultados obtenidos por los dos tipos de estimaciones (paramétrica y no paramétrica).

Figura 8. Estimaciones paramétricas (lineal y cuadrática) y no paramétrica (estimador de Nadaraya-Watson).



Fuente: Elaboración propia.

(e) Bonus. Aplicar el test de Zheng (1996) para evaluar la validez de las especificaciones paramétricas lineal y cuadrática contra la alternativa no paramétrica, tanto para el modelo del share del gasto en alimentos como para el del share del gasto en transporte. Reportar los resultados y comentar. ¿Se rechaza la especificación paramétrica lineal para un nivel de significatividad del 10%? ¿Y para un nivel del 5%? Para esos mismos niveles de significatividad, ¿se rechaza la especificación paramétrica cuadrática?

En la tabla 3, se presentan los resultados del test de Zheng, que contrasta la hipótesis nula de validez de la especificación paramétrica (lineal o cuadrática).

En el caso de la participación del gasto en alimentos en el gasto total familiar, para niveles de significatividad de 10% y 5%, estos datos no proporcionan evidencia suficiente para rechazar la hipótesis nula tanto de validez de la especificación paramétrica lineal como de la especificación paramétrica cuadrática. Respecto a la participación del gasto en transporte en el gasto total familiar, para el caso de la especificación paramétrica lineal, la hipótesis nula se rechaza para un nivel de significatividad de 10%, pero no para un nivel del 5%; y, para el caso de la estimación paramétrica cuadrática, la hipótesis nula no se rechaza para niveles de significatividad de 10% y 5%.

Tabla 3. *Test de Zheng (1996).*

Estimación		Share del gasto en alimentos	Share del gasto en transporte
No Paramétrica vs. Paramétrica (lineal)	Estadístico	0,9246	1,9078
	$T_n \rightarrow^d \mathcal{N}(0, 1)$		
	P-valor	0,3556	0,0569
H_0 : forma paramétrica lineal (basado en Zheng (1996))			
No Paramétrica vs. Paramétrica (cuadrática)	Estadístico	1,0717	0,2979
	$T_n \rightarrow^d \mathcal{N}(0, 1)$		
	P-valor	0,2843	0,7659
H_0 : forma paramétrica cuadrática (basado en Zheng (1996))			

Fuente: Elaboración propia.

Parte III.

El objetivo de este ejercicio será estimar la esperanza del share de los gastos en alimentos condicional en el logaritmo del gasto familiar, controlando por el número de hijos, a partir de la muestra total de hogares. A tal fin, se adoptará una especificación semiparamétrica parcialmente lineal para el nuevo modelo, donde el número de hijos se incorpora de manera completamente paramétrica suponiendo una función lineal, mientras que se sigue adoptando una especificación no paramétrica para el logaritmo del gasto total:

$$sh_g_alim = g(lgastot) + \beta nhijos + U,$$

donde $g(\cdot)$ es una función desconocida, $nhijos$ es el número de hijos, β es un parámetro desconocido y U es un término aleatorio que se supone que satisface las condiciones requeridas para aplicar el método de Robinson (1988).

(a) *Estimar β mediante el método de Robinson (1988) usando un kernel Gaussiano. Explicar los pasos seguidos para la estimación. Dar la interpretación económica y estadística (significatividad) del coeficiente estimado.*

En la tabla 4, se presenta la estimación semiparamétrica de este modelo mediante el método de Robinson (1988), utilizando un kernel Gaussiano y un parámetro de suavizamiento $h = 0,22$.

Robinson (1988) propone transformar el modelo de manera tal de poder estimar consistentemente a β , a la tasa de convergencia $\sqrt{N}$, a pesar de la presencia del término no paramétrico, dado por $g(\cdot)$. Para esto, se computa la esperanza condicional de sh_g_alim en $lgastot$ y, luego, se le resta al modelo original, obteniendo:

$$sh_g_alim - E(sh_g_alim | lgastot) = [nhijos - E(nhijos | lgastot)] \beta + U.$$

Ya que no se conocen los momentos condicionados de esta expresión, Robinson propone estimar en dos etapas (método residual):

1. Se estima $E(sh_g_alim | lgastot)$ y $E(nhijos | lgastot)$ mediante regresiones no paramétricas de sh_g_alim sobre $lgastot$ y $nhijos$ sobre $lgastot$, respectivamente, y se reservan los residuos parciales de ambas regresiones.
2. Se estima β mediante una regresión paramétrica por MCO entre ambos residuos parciales (sin constante, para que β se encuentre identificado).

El coeficiente β estimado mediante este método es positivo e igual a 0,0218, siendo la variable $nhijos$ estadísticamente significativa, indicando que un hijo adicional en comparación con el número promedio de hijos en el hogar aumenta la participación del gasto en alimentos en el gasto total familiar, con respecto al promedio, en 0,0218 puntos porcentuales.

Tabla 4. Estimación semiparamétrica (Método de Robinson, 1988).


Variable	sh_g_alim
nhijos	0,0218*** (0,0025)
Observaciones	1575
R^2	0,0463

Los datos en paréntesis corresponden a los desvíos estándar robustos. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

(b) Partiendo de la estimación de β obtenida en el inciso (a), estimar la parte no paramétrica del modelo, es decir, $g(\lgastot)$. Usar el estimador de Naradaya-Watson con kernel Gaussiano y parámetro de suavizamiento $h=0,22$. Explicar, detalladamente, los pasos seguidos.

En la figura 9, se presenta una estimación no paramétrica de la relación entre la variable $s_g_alim_hijo$ y el gasto total familiar, utilizando el estimador de Naradaya-Watson (NW), un kernel Gaussiano y un parámetro de suavizamiento $h=0,22$.

Utilizando el estimador β ($\hat{\beta}$) obtenido en el inciso anterior mediante el método de Robinson (1988), se estima la parte no paramétrica del modelo. Para esto, se genera la variable $s_g_alim_hijo$ de la siguiente manera: $s_g_alim_hijo = s_g_alim - \hat{\beta} \cdot nhijos$.

Figura 9. Estimación no paramétrica (estimador de Naradaya-Watson).


Fuente: Elaboración propia.

(c) Considerar, nuevamente, un modelo totalmente no paramétrico que tenga como único regresor al $\lgastot$ (es decir, se excluye la variable explicativa $nhijos$) y estimarlo por Naradaya-Watson para la muestra completa de hogares de la base de datos (usar otra vez un kernel Gaussiano y parámetro de suavizamiento $h = 0,22$). En un mismo gráfico, se pide mostrar esta estimación junto con la estimación de $g(\lgastot)$ hallada en el inciso (b). Incluir también los intervalos de confianza al 95% de esta última. ¿Qué se observa? Justificar.

En la figura 10, se presentan la estimación semiparamétrica (inciso (b)) y no paramétrica (estimador NW) de la relación entre la participación del gasto en alimentos en el gasto total familiar y el gasto total familiar, utilizando un kernel Gaussiano y un parámetro de suavizamiento $h = 0,22$.

Se puede observar que ambas estimaciones no difieren sustancialmente, notándose un movimiento similar entre ambas. No obstante, la estimación no paramétrica no se encuentra dentro del intervalo de confianza de la estimación semiparamétrica, siendo la amplitud de este intervalo sumamente estrecha. Esto se puede deber al hecho de que el número de hijos en el hogar es una variable relevante para explicar la participación del gasto en alimentos en el gasto total familiar y, al mismo tiempo, el gasto total familiar no es independiente del número de hijos en el hogar.

Figura 10. Estimación semiparamétrica y no paramétrica (estimador de Naradaya-Watson).



Fuente: Elaboración propia.

Referencias.

- Blundell, R. y Duncan, A. (1998). Kernel Regressions and Empirical Microeconomics. *The Journal of Human Resources*, 33(1), 62-87. Recuperado de <https://www.jstor.org/stable/146315>
- Bosch, M. y Manacorda, M. (2008). Minimum Wages and Earnings Inequality in Urban Mexico. Revisiting the Evidence. *CEP Discussion Paper*, 880. Recuperado de <http://cep.lse.ac.uk/pubs/download/dp0880.pdf>