

Procesos univariados estacionarios

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

- Propiedades de las series temporales
- Repaso de MCO y sus supuestos
- Autocorrelación: tests y soluciones
- Modelos autoregresivos
- Conceptos básicos
- Metodología de Box-Jenkins

Propiedades de las series temporales

- Nos interesa la evolución temporal de series económicas.
- Notación: $\{y_t\}$ con $t = 1, 2, \dots T$.
- Distintos tipos de frecuencias:
 - Anual
 - Semestral
 - Trimestral
 - Mensual
 - Semanal
 - Diaria
 - Intradiaria


Algunas características de series económicas / financieras

- Fuertes tendencias
- Breaks / Cambios estructurales
- Comportamientos estacionales marcados
- Ciclos estocásticos, difíciles de predecir
- Oscilaciones muy erráticas
- Dificultad para distinguir tendencias y ciclos
- Co-movimientos

SIEMPRE: comenzar con un gráfico


(frecuencia anual)

Emisiones de CO2 (en millones de kt)



(frecuencia trimestral)

Consumo privado (en miles de millones de pesos de 2004)



(frecuencia mensual)

Precio de la soja en Chicago (en dólares por MT)



(frecuencia diaria)

U.S. / Euro Foreign Exchange Rate



Propiedades de las series temporales

Propiedad 1: presentan comportamientos dinámicos

- Al estar ordenadas temporalmente, los valores pasados influyen en los valores presentes y futuros.
- Esto usualmente resulta en la violación del supuesto de ausencia de autocorrelación en MCO: $Cov(u_i, u_j) \neq 0 \quad \forall i \neq j$

Propiedades de las series temporales

Propiedad 1: presentan comportamientos dinámicos

- Al estar ordenadas temporalmente, los valores pasados influyen en los valores presentes y futuros.
- Esto usualmente resulta en la violación del supuesto de ausencia de autocorrelación en MCO: $Cov(u_i, u_j) \neq 0 \quad \forall i \neq j$

Propiedad 2: usualmente tienen momentos que dependen del tiempo (p.ej., media, varianza, asimetría, kurtosis, etc.)

- Esto implica que las series usualmente no son estacionarias.
- Granger y Newbold (1974) demostraron que si se regresionan dos variables independientes no estacionarias, la probabilidad de encontrar una relación espuria es muy alta.

Propiedades de las series temporales

Propiedad 3: la naturaleza secuencial de las series temporales permite realizar pronósticos de futuros eventos.

Propiedades de las series temporales

Propiedad 3: la naturaleza secuencial de las series temporales permite realizar pronósticos de futuros eventos.

Propiedad 4: los eventos en las series temporales pueden causar quiebres estructurales en la serie de datos. Se pueden estimar estos cambios mediante *dummies*, modelos de *regime switching/Markov*, etc.

Propiedades de las series temporales

Propiedad 3: la naturaleza secuencial de las series temporales permite realizar pronósticos de futuros eventos.

Propiedad 4: los eventos en las series temporales pueden causar quiebres estructurales en la serie de datos. Se pueden estimar estos cambios mediante *dummies*, modelos de *regime switching*/Markov, etc.

Propiedad 5: muchas series temporales están en una relación de equilibrio de largo plazo (cointegración). Se pueden estimar estas relaciones mediante modelos de corrección de errores (MCE).

Propiedades de las series temporales

Propiedad 6: muchas series temporales están endógenamente relacionadas. Se puede modelar estimando sistemas de ecuaciones, como los vectores autorregresivos (VAR).

Propiedades de las series temporales

Propiedad 6: muchas series temporales están endógenamente relacionadas. Se puede modelar estimando sistemas de ecuaciones, como los vectores autorregresivos (VAR).

Propiedad 7: los efectos de las variables explicativas sobre la variable dependiente pueden variar en el tiempo. Podemos estimar estos efectos dinámicos con modelos que consideren parámetros variantes en el tiempo.

MCO

Repaso de MCO. Regresión en series temporales

- Consideremos el siguiente modelo poblacional:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad t = 1, 2, \dots, T \quad (1)$$

- En términos matriciales:

$$y_t = \mathbf{x}_t' \beta + u_t \quad (2)$$

donde $\mathbf{x}_t = (1, x_{1t}, x_{2t}, \dots, x_{kt})'$ y $\beta = (\beta_0, \beta_1, \dots, \beta_k)'$.

- El estimador de MCO es:

$$\hat{\beta} = \left(\sum_{t=1}^T \mathbf{x}_t \mathbf{x}_t' \right)^{-1} \sum_{t=1}^T \mathbf{x}_t y_t \quad (3)$$

- Reemplazando y_t por (2) obtenemos:

$$\hat{\beta} - \beta = \left(\sum_{t=1}^T \mathbf{x}_t \mathbf{x}_t' \right)^{-1} \sum_{t=1}^T \mathbf{x}_t u_t \quad (4)$$

- Las propiedades estadísticas de $\hat{\beta}$ dependen de $\mathbf{x}_t$, u_t

Los supuestos de MCO

- **TS.1. (linealidad en parámetros)**

$$y_t = \beta_0 + \beta_1 x_{1t} + \dots + \beta_k x_{kt} + u_t$$

- **TS.2. (no multicolinealidad perfecta)** En la muestra, ninguno de los regresores es constante (igual al intercepto) y no hay una relación lineal exacta entre los regresores.
- **TS.3. (exogeneidad estricta)** $E(u_t | \mathbf{X}) = 0$ donde $\mathbf{X}$ denota todas las $\mathbf{x}_t$ e implica:
$$\text{cov}(x_{1t}, u_s) = 0, \dots, \text{cov}(x_{kt}, u_s) = 0 \quad \forall t, s.$$
- **TS.4. (varianza del error homocedástica)** $\text{var}(u_t | \mathbf{X}) = \sigma^2$
- **TS.5. (no correlación serial)** $\text{cov}(u_t, u_s | \mathbf{X}) = 0 \quad \forall t \neq s$

Teorema

Supongan que TS.1-TS.5 se mantienen, entonces los estimadores MCO de $\beta_0, \beta_1, \dots, \beta_k$ son MELI, i.e. los mejores (menor varianza) estimadores lineales insesgados ($E(\hat{\beta}) = \beta$).

La varianza de MCO

- Bajo TS.1-TS.5, la varianza de MCO es:

$$\text{var}(\hat{\beta}|\mathbf{X}) = \sigma^2 \left(\sum_{t=1}^T \mathbf{x}_t \mathbf{x}_t' \right)^{-1} \quad (5)$$

- Una fórmula conveniente de la varianza de $\hat{\beta}_j$ está dada por:

$$\text{var}(\hat{\beta}_j|\mathbf{X}) = \frac{\sigma^2}{\sum_{t=1}^T \hat{r}_{jt}^2} \quad (6)$$

donde $\hat{r}_{jt}$ son los residuos de la regresión de x_{jt} en función del resto de las variables x .

- Entonces, podemos usar los estadísticos t y F usuales para hacer inferencia si además agregamos el supuesto de normalidad del error (o apelando al TCL).

Autocorrelación

¿Qué pasa si se viola el supuesto TS.5?

¿Qué pasa si se viola el supuesto TS.5?

- (1) **TS.5.** (no correlación serial): $cov(u_t, u_s | \mathbf{X}) = 0 \quad \forall t \neq s$.
- (2) Así como en *cross – section* la heterocedasticidad es bastante frecuente, en series de tiempo solemos encontrar autocorrelación.
- (3) Obviamente no observamos los u 's, pero podemos analizar los residuos $(\hat{u})$.

Autocorrelación

Bajo los supuestos de MCO, la matriz de var-cov de los errores era:

$$E(uu'|\mathbf{X}) = \sigma^2.I_T$$

Ahora, bajo autocorrelación:

$$E(uu'|\mathbf{X}) = \Omega_{AC} \neq \sigma^2.I_T$$
$$\Omega_{AC} = \begin{bmatrix} \sigma^2 & \gamma_1 & \gamma_2 & \gamma_3 & \cdots & \gamma_{T-1} \\ \gamma_1 & \sigma^2 & \gamma_1 & \gamma_2 & \cdots & \gamma_{T-2} \\ \gamma_2 & \gamma_1 & \sigma^2 & \gamma_1 & \cdots & \gamma_{T-3} \\ \gamma_3 & \gamma_2 & \gamma_1 & \sigma^2 & \cdots & \gamma_{T-4} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \gamma_{T-1} & \gamma_{T-2} & \gamma_{T-3} & \gamma_{T-4} & \cdots & \sigma^2 \end{bmatrix}$$

- γ_j es la **autocovarianza de los errores** separados j observaciones (constante para cada j).

Si bien lo definiremos más adelante cuando hablemos de **estacionariedad**, noten que le estamos pidiendo a u_t que:

- su media no dependa del tiempo,
- su varianza tampoco,
- y sus covarianzas tampoco!

Autocorrelación

La matriz anterior podemos también re-escribirla como:

$$\Omega_{AC} = \sigma^2 \times \begin{bmatrix} 1 & \rho_1 & \rho_2 & \rho_3 & \cdots & \rho_{T-1} \\ \rho_1 & 1 & \rho_1 & \rho_2 & \cdots & \rho_{T-2} \\ \rho_2 & \rho_1 & 1 & \rho_1 & \cdots & \rho_{T-3} \\ \rho_3 & \rho_2 & \rho_1 & 1 & \cdots & \rho_{T-4} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{T-1} & \rho_{T-2} & \rho_{T-3} & \rho_{T-4} & \cdots & 1 \end{bmatrix}$$

- donde $\rho_j = \gamma_j / \sigma^2$ es el **coeficiente de autocorrelación de los errores** de orden j .
- Como la la matriz completa es difícil de estimar (para ρ_{T-1} sólo tendríamos una observación) algunos autores propusieron inicialmente usar un modelo que simplifique Ω_{AC} notablemente $\rightarrow$ **modelos autorregresivos**

Modelo autorregresivo de primer orden, AR(1)


Si bien volveremos más adelante sobre estos modelos, por ahora haremos una introducción.

Modelo AR(1):

$$u_t = \phi u_{t-1} + v_t, \quad |\phi| < 1, v_t \sim IID(0, \sigma_v^2)$$


Se puede probar (lo haremos más adelante) que en este modelo $\rho_j = \phi^j$, es decir, todos los coeficientes de autocorrelación dependen de uno solo ϕ .

Autocorrelación de primer orden positiva




Patrón cíclico de residuos a lo largo del tiempo.

Autocorrelación de primer orden negativa



Patrón alternante.

No autocorrelación de primer orden



Sin patrón en los residuos.

Detectando la autocorrelación

Test de Durbin-Watson (1950,1951) → old-fashioned.

Limitaciones:

- Sólo sirve para evaluar autocorrelación de orden 1.
- El estadístico no tiene una distribución conocida.
- Existen regiones donde el test no concluye (zonas de indeterminación).
- Si el modelo incluye un rezago de la variable dependiente, sólo sirve si se rechaza H_0 , no en caso contrario (mayor concentración de la distribución $\hat{\rho}$ en torno de su media que sería cero).

Aunque, cuando veamos cointegración nos va a servir como indicador para evaluar si la regresión es espuria.

Detectando la autocorrelación

Test LM de Breusch-Godfrey (1978):

Una vez que estimamos nuestro modelo por MCO:

$$y_t = \mathbf{x}_t' \hat{\beta} + \hat{u}_t$$

Se estima la siguiente regresión auxiliar:

$$\hat{u}_t = \mathbf{x}_t' \hat{\alpha} + \phi_1 \hat{u}_{t-1} + \phi_2 \hat{u}_{t-2} + \cdots + \phi_p \hat{u}_{t-p} + \hat{v}_t$$

Entonces se evalúa:

$$H_0 : \phi_1 = \phi_2 = \cdots = \phi_p = 0$$

$$H_1 : \text{algún } \phi_j \neq 0 \quad \forall j = 1, \dots, p$$

Mediante un estadístico $LM = T.R^2 \sim \chi^2(p)$

Test de Breusch-Godfrey - Softwares

- En **R**: `bgtest` en el paquete `lmtest`
- En **STATA**: `estat bgodfrey`, luego de `regress`
- En **EViews**: en View/Residual Diagnostics/Serial Correlation LM Test... e indicar p
- En **OxMetrics**: por default en la salida de la regresión por MCO (aparece la versión F del test).

Ejemplo en R - Modelo de inflación

```
call:
lm(formula = infln ~ pcwage)

Residuals:
    Min       1Q   Median       3Q      Max
-0.85925 -0.10836 -0.01477  0.12285  0.97427

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.20417    0.02414   8.457 0.000000000000000182 ***
pcwage         0.20159    0.07970   2.529    0.012 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2091 on 267 degrees of freedom
Multiple R-squared:  0.0234,    Adjusted R-squared:  0.01974
F-statistic: 6.398 on 1 and 267 DF, p-value: 0.012
```

- $\text{infln} = [\ln(\text{cpi}_t) - \ln(\text{cpi}_{t-1})] * 100$
- $\text{pcwage} = [\ln(\text{wage}_t) - \ln(\text{wage}_{t-1})] * 100$

Ejemplo en R - Modelo de inflación

```
> bgtest(modelo.infla, order=2)

Breusch-Godfrey test for serial correlation of order up to 2

data: modelo.infla
LM test = 30.866, df = 2, p-value = 1.984e-07

> coeftest(bgtest(modelo.infla, order=2))

z test of coefficients:

              Estimate Std. Error z value Pr(>|z|)
(Intercept)  0.0055554  0.0228266  0.2434  0.807715
pcwage       -0.0217176  0.0753844 -0.2881  0.773277
lag(resid)_1  0.3467378  0.0606279  5.7191 1.071e-08 ***
lag(resid)_2 -0.1752909  0.0607394 -2.8859  0.003902 **
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Prueben evaluar qué sucede para $p = 3$.

Consecuencias de ignorar la autocorrelación

Asumiendo que el resto de los supuestos se mantienen:

- (si el modelo no incluye rezagos de y_t) El estimador de MCO será insesgado y consistente, pero ineficiente, afectando la inferencia.
- (si el modelo incluye rezagos de y_t) El estimador de MCO será inconsistente. **¿Por qué?**

Consecuencias de ignorar la autocorrelación

Asumiendo que el resto de los supuestos se mantienen:

- (si el modelo no incluye rezagos de y_t) El estimador de MCO será insesgado y consistente, pero ineficiente, afectando la inferencia.
- (si el modelo incluye rezagos de y_t) El estimador de MCO será inconsistente. **¿Por qué?**

Porque entonces $E(y_{t-1}, u_t) \neq 0$ ya que si hay autocorrelación de primer orden (u_t depende de u_{t-1}) implica que y_{t-1} está correlacionada con u_t .

“Remedios” para la autocorrelación

- Si la forma de la autocorrelación es conocida, usar MCG - e.g. Cochrane-Orcutt.
- Ojo, que si el supuesto es inválido, el remedio puede ser peor que la enfermedad (Hendry y Mizon, 1978)
- Usar los HACSE (e.g. Newey-West).
- En la visión “moderna”, si hay autocorrelación, es una oportunidad para modificar la regresión. ¡Modelar la dinámica!

Incorporando rezagos de la variable dependiente

¡En estos casos es MUY importante evaluar la autocorrelación!

```
call:
lm(formula = dyn(infln ~ pcwage + lag(infln, -1) + lag(infln,
-2)))

Residuals:
    Min       1Q   Median       3Q      Max
-0.68514 -0.10647 -0.01484  0.11306  0.93344

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.16233    0.02876   5.644 0.0000000429 ***
pcwage         0.18782    0.07608   2.469  0.01419 *
lag(infln, -1) 0.35051    0.05997   5.844 0.0000000150 ***
lag(infln, -2) -0.18128    0.05977  -3.033  0.00266 **
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1957 on 263 degrees of freedom
(2 observations deleted due to missingness)
Multiple R-squared:  0.1402,    Adjusted R-squared:  0.1304
F-statistic: 14.29 on 3 and 263 DF,  p-value: 0.00000001181
```

Vuelvan a testear si hay evidencia de autocorrelación.

Conceptos básicos

Operador rezago (L): $Ly_t = y_{t-1}$

- $L^2 y_t = L(Ly_t) = Ly_{t-1} = y_{t-2} \Rightarrow L^k y_t = y_{t-k}$
- $\alpha(L) = \alpha_0 + \alpha_1 L + \alpha_2 L^2 + \cdots + \alpha_k L^k$ (polinomio de rezagos)
- $\alpha(L)y_t = \alpha_0 y_t + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \cdots + \alpha_k y_{t-k}$

Operador de diferenciación (Δ): $\Delta y_t = y_t - y_{t-1}$

- $\Delta \equiv (1 - L)$
- $\Delta y_t \equiv (1 - L)y_t = y_t - y_{t-1}$
- $\Delta^2 y_t \equiv (1 - L)^2 y_t = (1 - 2L + L^2)y_t$
- $\Delta_2 y_t \neq \Delta^2 y_t$
- $\Delta_2 y_t = y_t - y_{t-2}$

- y_{t-j} es el rezago (lag) j de y_t
- y_{t+j} es el adelanto (lead) j del y_t
- $\Delta y_t = y_t - y_{t-1}$ es la primera diferencia de y_t
- $\Delta \ln(y_t) = \ln(y_t) - \ln(y_{t-1})$ es la diferencia logarítmica de y_t
- El cambio porcentual de una series y_t entre los períodos $t - 1$ y t es aproximadamente $100 \times \Delta \ln(y_t)$, donde la aproximación es más precisa cuanto más pequeña es la variación porcentual.

- A partir del script `clase1.R` replique las estimaciones de los modelos de inflación que hicimos antes. Observe cómo usamos el operador rezago (`lag()`) y diferencia (`diff()`).
- Grafique los residuos del modelo estático (`plot()`). Comente.
- Obtenga el primer rezago de los residuos y haga un scatter-plot entre $\hat{u}_t$ y $\hat{u}_{t-1}$.
- Replique los dos puntos anteriores para el modelo dinámico.
¿Se condice lo que observa con las conclusiones del test LM?

Una **serie de tiempo** es una colección de observaciones indizada por la fecha de cada observación (t). Usualmente, la muestra comienza en $t = 1$ y termina en $t = T$:

$$(y_1, y_2, \dots, y_T)$$

Pero podríamos imaginar que existieron datos anteriores a $t = 1$ y posteriores a $t = T \Rightarrow (y_1, y_2, \dots, y_T)$ es un segmento finito de una secuencia infinita:

$$\{y_t\}_{t=-\infty}^{\infty} = \{\dots, y_{-1}, y_0, \underbrace{y_1, y_2, \dots, y_T}_{\text{muestra observada}}, y_{T+1}, y_{T+2}, \dots\}$$

Proceso Estocástico: $Y_1, Y_2, \dots, Y_T$ (secuencia ordenada)

realización de un

Serie de Tiempo: $y_1, y_2, \dots, y_T$

Momentos de orden 1 y 2

Función de densidad conjunta: $D_{Y_1, Y_2, \dots, Y_T}(y_1, y_2, \dots, y_T)$

Si nos concentramos solamente en m_1 y m_2 de esa función:

- $E(Y_t) = \mu_t$
- $Var(Y_t) = \gamma_{0t}$
- $Cov(Y_t, Y_{t-j}) = \gamma_{jt}$ (j-ésima autocovarianza)

No tendríamos grados de libertad suficientes.


- $E(Y_t) = \mu_t$ (T parámetros)
- $Var(Y_t) = \gamma_{0t}$ (T parámetros)
- $Cov(Y_t, Y_{t-j}) = \gamma_{jt}$ ($\frac{T^2-T}{2}$ parámetros)

El supuesto más simple es el de **ESTACIONARIEDAD DÉBIL** (o en covarianzas).


- $E(Y_t) = \mu$ (1 parámetro)
- $Var(Y_t) = \gamma_0$ (1 parámetro)
- $Cov(Y_t, Y_{t-j}) = \gamma_j$ ($T-1$ parámetros)

La **ESTACIONARIEDAD EN SENTIDO ESTRICTO** es la generalización para el proceso generador de los datos.

Casos de no estacionariedad



No estacionariedad en media



Caso heterocedástico

- Existen otras fuentes de no estacionariedad como los *breaks* o cambios estructurales.

Series temporales en R

- Vuelva sobre el script `clase1.R`.
- Grafique la serie de `cpi` y `infln`. ¿Le parecen estacionarias?
- Realice lo mismo con las series `wage` y `pcwage`.

Ruido Blanco (White Noise)

ε_t es un proceso **ruido blanco** si:


- $E(\varepsilon_t) = 0, \forall t$
- $Var(\varepsilon_t) = E(\varepsilon_t^2) = \sigma^2 < \infty, \forall t$
- $Cov(\varepsilon_t, \varepsilon_{t-j}) = 0, \forall t, \forall j \neq 0$

Entonces, un ruido blanco es débilmente estacionario por definición (lo será en sentido estricto si asumimos, p.ej., que es gaussiano).

Un RB es impredecible respecto de su propio pasado:

$$E(\varepsilon_t / \varepsilon_{t-j}) = E(\varepsilon_t) = 0 \text{ (innovación, en media)}$$

Ruido Blanco (White Noise)



Series temporales en R

- Vuelva sobre el script `clase1.R`.
- Calcule los principales estadísticos descriptivos de la serie de residuos del modelo dinámico.
- Calcule su función de autocorrelación (use `acf()` dentro del paquete "stats"). ¿Qué observa?
- ¿El residuo parece ser ruido blanco?

Metodología de Box-Jenkins

Objetivo

- Desarrollado por Box y Jenkins (1970)
- Enfoque estadístico


Objetivo

- Desarrollado por Box y Jenkins (1970)
- Enfoque estadístico
- **Objetivo:** inferir el proceso estocástico subyacente a una serie temporal
- Es un análisis univariado
- Se deja que los propios datos de la serie temporal nos indiquen las características de la estructura probabilística subyacente.

Objetivo


- Desarrollado por Box y Jenkins (1970)
- Enfoque estadístico
- **Objetivo:** inferir el proceso estocástico subyacente a una serie temporal
- Es un análisis univariado
- Se deja que los propios datos de la serie temporal nos indiquen las características de la estructura probabilística subyacente.
- Se quiere encontrar el modelo (ARMA) **de mejor ajuste** a una serie temporal para que los pronósticos sean lo más acertados
- Implica un modelado **iterativo** en varias etapas.

Etapas




¿Cómo volver estacionaria a una serie temporal?

Si bien veremos más adelante un test para evaluar la estacionariedad de una serie, **¿qué hacer si observo un comportamiento no estacionario?**



No estacionariedad en media



Caso heterocedástico

Muchas veces, cuando la tendencia o la media no es constante a lo largo del tiempo, la **diferenciación** (Δ^d , $d \geq 1$) permite volver estacionaria una serie.

$$\Delta y_t \equiv y_t - y_{t-1}$$

$$\Delta^2 y_t \equiv y_t - 2y_{t-1} + y_{t-2}$$

- En general, d no es mayor a 2

Estabilización de la varianza

Cuando la dispersión de una serie temporal no es constante (p.ej. muchas series financieras en alta frecuencia), la **transformación logarítmica** suele ser razonablemente estable:

$$\dot{y}_t = \ln y_t$$

- Es un caso particular de la **Transformación de Box-Cox**:

$$\dot{y}_t = \frac{y_t^m - 1}{m}, \quad \text{con } |m| \leq 2$$

- Cuando tomamos $\lim_{m \rightarrow 0}$.

Diferenciación estacional

El operador **diferencia estacional** de período s y orden d (Δ_s^d) se puede aplicar a series que presentan tendencia junto con estacionalidad.

$$\Delta_s \equiv y_t - y_{t-s}$$

- Aquí $d = 1$
- Para series estacionales mensuales: $s = 12$, y trimestrales: $s = 4$

Modelos ARMA

MA(1): Procesos de Media Móvil de orden 1

$$y_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}, \quad \mu, \theta < \infty, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Propiedades:

- $E(y_t) = \mu$
- $\gamma_0 = \text{Var}(y_t) = \sigma^2(1 + \theta^2)$
- $\gamma_1 = \theta\sigma^2$
- $\gamma_j = 0, \quad \forall j > 1$
- Entonces, $\rho_1 = \frac{\theta}{1 + \theta^2}$ y $\rho_j = 0 \quad \forall j > 1$

⇒ MA(1) es **siempre estacionario**.

Simulando procesos MA(1)

Simule en el software que elija los siguientes procesos MA(1) para $T = 200$:

- $y_t = 5 + \varepsilon_t + 0,5\varepsilon_{t-1}, \quad \varepsilon \sim N(0, 1)$
- $x_t = -3 + \varepsilon_t + 0,9\varepsilon_{t-1}, \quad \varepsilon \sim N(0, 1)$
- $z_t = 9 + \varepsilon_t - 1,2\varepsilon_{t-1}, \quad \varepsilon \sim N(0, 1)$

Grafique cada serie temporal y su correlograma (gráfico de autocorrelaciones).

MA(q): Procesos de Media Móvil de orden q

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Propiedades:

- $E(y_t) = \mu$
- $\gamma_0 = \text{Var}(y_t) = \sigma^2(1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2)$
- $\gamma_j = \begin{cases} [\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j}]\sigma^2 & j \leq q \\ 0 & j > q \end{cases}$

⇒ MA(q) es estacionario para cualquier $q < \infty$.

La dependencia con el pasado se anula luego del q -ésimo período.

MA(∞): Procesos de Media Móvil de orden ∞

$$y_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}, \quad \varepsilon_t \sim RB(0, \sigma^2), \quad \psi_0 = 1$$

MA(∞) es estacionario si:

1. $\sum_{j=0}^{\infty} \psi_j^2 < \infty$ (varianza finita)
2. $\sum_{j=0}^{\infty} |\psi_j| < \infty$ (sumabilidad absoluta)

2 $\Rightarrow$ 1, pero no a la inversa.

Teorema de Descomposición de Wold

Si $\{y_t\}$ es estacionaria débil, siempre admite una representación dada por:

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + k_t$$

la suma ponderada de términos puramente aleatorios ($\varepsilon_t \sim RB(0, \sigma^2)$) + una función determinística k_t

- Todo proceso estacionario es esencialmente un $MA(\infty)$ estacionario.
- ¡En la práctica implicaría estimar infinitos parámetros!
- **Idea:** buscar alguna representación más **parsimoniosa** del $MA(\infty)$. Un $MA(q)$ con q alto es una aproximación.

Procesos autorregresivos (AR)

AR(1): Proceso autorregresivo de orden 1:

$$y_t = c + \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Es un proceso *derivado* de un RB a través de una recursión:

$$y_t = \frac{c}{1 - \phi} + \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots \text{ si } |\phi| < 1$$

Los shocks van convergiendo $\Rightarrow$ AR(1) es estacionario si $|\phi| < 1$.

Notar que la expresión anterior es MA(∞) con $\psi_i \equiv \phi^i$

Volviendo a la representación $MA(\infty)$ del $AR(1)$

$$y_t = c + \phi y_{t-1} + \varepsilon_t \Leftrightarrow (1 - \phi L)y_t = c + \varepsilon_t$$

Si $|\phi| < 1$, aplicando $(1 - \phi L)^{-1}$ a ambos lados,

$$y_t = \frac{c}{1 - \phi L} + \frac{\varepsilon_t}{1 - \phi L}$$

Si $|\phi| < 1$,

$$\frac{1}{1 - \phi L} = 1 + \phi L + \phi^2 L^2 + \phi^3 L^3 + \dots \quad \text{y} \quad (1 - \phi L)(1 - \phi L)^{-1} y_t = y_t$$

Entonces,

$$y_t = c(1 + \phi L + \phi^2 L^2 + \dots) + \varepsilon_t(1 + \phi L + \phi^2 L^2 + \dots)$$

$$= c + \phi c + \phi^2 c + \dots + \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots$$

$$= \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \Rightarrow \text{Representación } MA(\infty) \text{ del } AR(1)$$

Propiedades del AR(1) estacionario


- $E(y_t) \equiv \mu = \frac{c}{1 - \phi}$
- $Var(y_t) \equiv \gamma_0 = \frac{\sigma^2}{1 - \phi^2}$
- $\gamma_j = \phi^j \gamma_0$
- $\rho_j = \phi^j$

Las autocorrelaciones de un AR(1) estacionario decaen exponencialmente en valor absoluto.

Intuición:

- La posición de y_t depende de dos componentes. Uno que lo ata del pasado (ϕy_{t-1}) y otro que lo mueve en forma aleatoria (ε_t).
- Es más errático cuando $\phi \rightarrow 0$ y más suave cuando $\phi \rightarrow 1$.

Ejemplos de AR(1)



¿Qué está sucediendo a medida que se incrementa ϕ ?

¿Qué pasa con ϕ negativo?

Simulando procesos AR(1)

Simule en el software que elija los siguientes procesos AR(1) para $T = 200$:

- $y_t = 0,1y_{t-1} + \varepsilon_t, \quad y_0 = 0, \varepsilon \sim N(0, 1)$
- $x_t = -0,5y_{t-1} + \varepsilon_t, \quad x_0 = 0, \varepsilon \sim N(0, 1)$
- $z_t = 0,95y_{t-1} + \varepsilon_t, \quad z_0 = 0, \varepsilon \sim N(0, 1)$

Grafique cada serie temporal y su correlograma (gráfico de autocorrelaciones).

Estacionariedad del AR(1) (según las raíces del polinomio de rezagos)

$$y_t = c + \phi y_{t-1} + \varepsilon_t \Leftrightarrow (1 - \phi L)y_t = c + \varepsilon_t$$

es estacionario si $|\phi| < 1$.

Si se considera el polinomio: $(1 - \phi L)$ con raíz $L = 1/\phi$.

Entonces, AR(1) es estacionario si y solo si $|L| > 1$.

$$|L| > 1 \Leftrightarrow |\phi| < 1$$

Proceso autorregresivo de orden p: AR(p)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

En términos del operador rezago,

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = c + \varepsilon_t$$

En forma compacta,

$$\Phi(L) y_t = c + \varepsilon_t$$

El AR(p) será estacionario si cada una de las raíces de $\Phi(L)$ son mayores que 1 en valor absoluto.

Procesos ARMA(p,q)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

En forma compacta,

$$\Phi(L)y_t = \Theta(L)\varepsilon_t$$


El ARMA(p,q) es estacionario si todas las raíces de $\Phi(L)$ son mayores a 1 en valor absoluto (parte AR estacionario).

Simulando procesos ARMA(p,q)

Genere para $T=200$ los siguientes procesos (considere $y_0 = 0$):

- $y_t = 0,8y_{t-1} + \varepsilon_t$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = 0,1y_{t-1} + 0,5y_{t-2} + \varepsilon_t$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = \varepsilon_t + 0,8\varepsilon_{t-1}$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = \varepsilon_t + 0,1\varepsilon_{t-1} - 0,4\varepsilon_{t-2} + 0,5\varepsilon_{t-3}$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = 0,5y_{t-1} + \varepsilon_t - 0,3\varepsilon_{t-1}$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = 0,5y_{t-1} - 0,2y_{t-2} + \varepsilon_t - 0,3\varepsilon_{t-1}$, donde $\varepsilon_t \sim N(0, 1)$

Ejemplos ARMA(p,q)



Es muy difícil identificar procesos ARMA en forma observacional.

Etapa de Identificación

¿Cómo identifico cuál sería el proceso estocástico subyacente?

A partir de los **correlogramas** que son una representación gráfica de la función de autocorrelación del proceso en cuestión.

$$\rho_j = \gamma_j / \gamma_0$$

La versión muestral (estimada) se denomina **correlograma muestral**

$$\hat{\rho}_j = \hat{\gamma}_j / \hat{\gamma}_0 = \frac{1/T \sum_{t=1}^T (y_t - \bar{y})(y_{t-j} - \bar{y})}{1/T \sum_{t=1}^T (y_t - \bar{y})^2}$$

De un $AR(p)$ estacionario:

- Todas las autocorrelaciones son distintas de cero
- Decaen en valor absoluto
- Lo hacen en forma exponencial o sinusoidal

De un $MA(q)$:

- Solo las primeras q autocorrelaciones son distintas de cero

En la práctica,

- Si el correlograma se interrumpe bruscamente luego del rezago q , sugiere un proceso $MA(q)$.
- En caso contrario, puede ser AR o $ARMA$.

Correlograma parcial

La **función de autocorrelación parcial** (PAC, ϕ_{jj}) mide la correlación entre y_t y y_{t-j} , luego de controlar por los rezagos intermedios (todos aquellos rezagos menores a j).

En otras palabras, es la correlación condicional:

$$\phi_{jj} = \text{Corr}(y_t, y_{t-j} | y_{t+1}, y_{t+2}, \dots, y_{t+j-1})$$

- Para $j = 1$, la AC y la PAC van a coincidir ($\rho_1 = \phi_{11}$).
- Para los modelos AR(p) las PAC se anulan luego del rezago p .


Para obtener el estimador muestral de ϕ_{jj} podemos estimar:

$$y_{t+j} = \phi_{j1}y_{t+j-1} + \dots + \phi_{jj}y_t + \varepsilon_{t+j}$$

y así obtener $\hat{\phi}_{jj}$.

	AC	PAC
MA(q)	Se anula para rezagos superiores a q	Decrece rápido sin llegar a anularse
AR(p)	Decrece rápido sin llegar a anularse	Se anula para rezagos superiores a p
ARMA(p, q)	Decrecimiento rápido sin llegar a anularse	Decrecimiento rápido sin llegar a anularse

Figura 1: AR(1) vs MA(1)



- En **STATA**: se pueden usar los comandos `ac` y `pac` o `corrgram`.
- En **R**: usar la función `tsdisplay()` o `acf()` y `pacf()`.
- En **EViews**: desde la serie ir a View/Correlogram..., indicar la cantidad de rezagos.
- En **OxMetrics**: en el módulo de gráficos ir a Time-series properties y seleccionar ACF y PACF.

Etapa de Estimación

Estimación de modelos ARMA

Estimación AR(p):

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

ε_t satisface los supuestos bajo los cuales MCO produce estimaciones consistentes y asintóticamente normales.

Entonces consiste en regresar y_t en función de $y_{t-1}, y_{t-2}, \dots, y_{t-p}$

Estimación MA(q):

En general se utiliza el método de máxima verosimilitud o mínimos cuadrados no lineales.

- En **STATA**: `arima`
- En **R**: `arima()`
- En **EViews**: Quick/Estimate Equation/... poner nombre de la variable y a continuación indicar la cantidad de componentes AR o MA (ej. y AR(1) AR(2)).
- En **OxMetrics**: se puede usar el módulo X12ARIMA, sin habilitar la opción de desestacionalización.

Etapa de Validación

Necesitamos que el residuo del modelo estimado sea un **ruido blanco**. ¿Por qué?

Test de Box-Pierce (Q):

$$Q = T \sum_{\tau=1}^m \hat{\rho}_{\tau}^2$$

- Bajo H_0 : los residuos son RB, todas las correlaciones deberían ser cero.
- El test Q se basa en suma las primeras m autocorrelaciones. La elección de m implica un trade-off.
- Bajo H_0 , $Q \sim \chi^2(m)$

Evaluando si los residuos son RB

Sin embargo, el Test de Box-Pierce (Q) no tiene buenas propiedades para muestras pequeñas. Una variante, en casos de muestras pequeñas, es el **test de Ljung-Box** (1978):


$$Q^* = T(T+2) \sum_{\tau=1}^m \frac{\hat{\rho}_{\tau}^2}{(T-\tau)} \sim \chi_m^2$$

Para $T \rightarrow \infty$, el test de Ljung-Box es equivalente al de Box-Pierce.

Test de Q de Ljung-Box - Softwares

- En **STATA**: aparece cuando se usa `corrgram` y sino usar `wntestq`.
- En **R**: usar la función `Box.test()`.
- En **EViews**: aparece junto con los correlogramas.
- En **OxMetrics**: en la ventana de Test...

Metodología de Box-Jenkins



Metodología de Box-Jenkins

- (1) Garantizar que el proceso es estacionario.
- (2) Mediante los correlogramas proponer un $\text{ARMA}(p,q)$.
- (3) Estimarlos.
- (4) Si el modelo es correcto, los residuos deberían ser ruido blanco. De lo contrario, volver a (2).
- (5) Se puede proceder a realizar pronósticos.

Lo recomendable es seguir la metodología **General-a-Particular**: comenzar con un $\text{ARMA}(p,q)$ lo “suficientemente grande” e ir reduciéndolo buscando el modelo más parsimonioso (con residuos RB).

¿Y si tenemos varios modelos alternativos con residuos RB?

Usar alguno de los **criterios de información** (penalizan la falta de ajuste y la cantidad de parámetros). Ejemplo:

- **Akaike (AIC):** $AIC = -2 \frac{\ln(L(k))}{T} + 2 \frac{k}{T}$
- **Schwarz (SIC):** $SIC = -2 \frac{\ln(L(k))}{T} + k \frac{\ln(T)}{T}$
- **Hannan-Quinn (HQ):** $HQ = -2 \frac{\ln(L(k))}{T} + 2k \frac{\ln(\ln(T))}{T}$

Elegir el modelo que minimice alguno de estos criterios.

Criterios de información - Softwares

- En **STATA**: usar el comando estat ic después de la estimación.
- En **R**: reporta AIC y BIC en la estimación.
- En **EViews**: reporta AIC, SIC y HQ en la estimación.
- En **OxMetrics**: reporta AIC, SIC y HQ en la estimación.

Ventajas de R, de OxMetrics y de EViews 9 en adelante:
tienen la opción de una selección automática del modelo ARMA con mejor fit.

- `auto.arima()` dentro de la librería `forecast`
- (1) Usaremos el dataset: `WWWusage`.
 - (2) Esa serie temporal registra el número de usuarios conectados a Internet en cierto servidor por minuto. $T = 100$ observaciones.
 - (3) Utilice el script `boxjenkins.R`

Aplicación

Para la próxima clase

Utilice la base de datos `soja.csv` que contiene dos series temporales mensuales: el precio spot (s) y precio futuro (f) de la soja en Chicago entre enero de 1979 y mayo de 2012.

A partir de la serie del spot se pide:

- (1) Grafique la serie. ¿Qué observa?
- (2) Si no le parece estacionaria (en unas clases veremos como testearlo) transfórmela para volverla estacionaria.
- (3) Grafique los correlogramas. Identifique cuál(es) sería(n) el(los) proceso(s) estocástico(s) subyacente(s).
- (4) Estime.
- (5) Evalúe que los residuos sean ruido blanco.
- (6) ¿Cuál es el modelo más apropiado?

- Hamilton (1994) - Cap. 3 y 4
- Optativo: Enders (2014) - Cap. 2