

Vectores Autorregresivos

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

Introducción

Modelos de Vectores Autorregresivos (VAR)

- Popularizados por Sims (1980):
“Macroeconomics and reality”, *Econometrica*, 48(1): 1-48.
- Son una generalización natural de los modelos autorregresivos univariados.

El caso más sencillo es el VAR bivariado.

En un **VAR bivariado** hay dos variables y_{1t} y y_{2t} (**estacionarias**) las cuales dependen de los p rezagos de las dos variables.

El caso más simple es el BIVAR(1):

$$\begin{cases} y_{1t} = \phi_{11}y_{1t-1} + \phi_{12}y_{2t-1} + \varepsilon_{1t} \\ y_{2t} = \phi_{21}y_{1t-1} + \phi_{22}y_{2t-1} + \varepsilon_{2t} \end{cases}$$

En términos generales, un $\text{VAR}_m(p)$:

$$y_t = \delta + \Phi_1 y_{t-1} + \Phi_2 y_{t-2} + \dots + \Phi_p y_{t-p} + \varepsilon_t$$

donde m = dimensión del VAR, p = orden del VAR, y_t es un vector de m variables (si $m = 1$, entonces es un AR(p)), δ es un vector de constantes, Φ es una matriz ($m \times m$) de coeficientes, y ε_t es un vector de m errores RB.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.
- A diferencia de los modelos univariados, permite que una variable no dependa sólo de sus propios rezagos y combinaciones lineales de términos de error RB. Un modelo AR se puede pensar como una versión restringida del VAR.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.
- A diferencia de los modelos univariados, permite que una variable no dependa sólo de sus propios rezagos y combinaciones lineales de términos de error RB. Un modelo AR se puede pensar como una versión restringida del VAR.
- En la medida en que no hayan efectos contemporáneos dentro de las variables explicativas, es posible estimar por MCO.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.
- A diferencia de los modelos univariados, permite que una variable no dependa sólo de sus propios rezagos y combinaciones lineales de términos de error RB. Un modelo AR se puede pensar como una versión restringida del VAR.
- En la medida en que no hayan efectos contemporáneos dentro de las variables explicativas, es posible estimar por MCO.
- Frecuentemente, los modelos VAR generan mejores pronósticos que los modelos estructurales (e.g. McNees, 1986).

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).
- ¿Cómo determinar la longitud p de rezagos a seleccionar?

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).
- ¿Cómo determinar la longitud p de rezagos a seleccionar?
- ¡Muchos parámetros a estimar! m ecuaciones con p lags para cada ecuación, $(m + pm^2)$ parámetros deben estimarse (problema para muestras chicas).

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).
- ¿Cómo determinar la longitud p de rezagos a seleccionar?
- ¡Muchos parámetros a estimar! m ecuaciones con p lags para cada ecuación, $(m + pm^2)$ parámetros deben estimarse (problema para muestras chicas).
- TODAS las variables del VAR deben ser estacionarias.

Estimación

Selección de la longitud óptima de rezagos del VAR

En pocas oportunidades la teoría económica o financiera nos dirá algo sobre la cantidad de rezagos apropiada para estimar el VAR.

Hay básicamente dos enfoques para seleccionar la longitud óptima de rezagos del VAR:

- **Restricciones entre ecuaciones**
- **Criterios de información**

Restricciones entre ecuaciones

Comenzar estimando un VAR con varios rezagos y testear la restricción de que los últimos q rezagos son conjuntamente iguales a cero (para todas las ecuaciones).

Esto se puede hacer con un test LR:

$$LR = T[\log|\hat{\Sigma}_r| - \log|\hat{\Sigma}_u|] \sim \chi_r^2$$

donde $|\hat{\Sigma}_r|$ es el determinante de la matriz de var-cov de los residuos del VAR restringido y $|\hat{\Sigma}_u|$ es el determinante de la matriz de var-cov de los residuos del VAR irrestricto; para m ecuaciones, la cantidad de restricciones $r = q \times m^2$.

Criterios de información

La distribución χ^2 del test LR anterior será válida asintóticamente solo si los errores de cada ecuación se distribuyen normalmente (difícil de lograr, sobre todo en finanzas!).

Los criterios de información suelen utilizarse en la práctica aunque en forma **multivariada** (univariadamente podríamos llegar a seleccionar distintos rezagos para cada ecuación).

- $MAIC = -2\log|\hat{\Sigma}| + \frac{2k'}{T}$
- $MSIC = -2\log|\hat{\Sigma}| + \frac{k'}{T}\ln(T)$
- $MHQIC = -2\log|\hat{\Sigma}| + \frac{2k'}{T}\ln(\ln(T))$

donde $\hat{\Sigma}$ es la matriz de var-cov de los residuos, T es la cantidad de observaciones y k' es la cantidad total de regresores en todas las ecuaciones ($k' = m^2k + m$, para m ecuaciones de k rezagos de m variables + una constante en cada ecuación).

Criterios de información - Softwares

- En **STATA**: `varsoc`
- En **R**: `VARselect()` dentro del paquete `vars`
- En **EViews**: Quick/Estimate VAR... poner nombre de las variable endógenas e indicar cantidad de rezagos. Luego de la estimación del VAR ir a View/Lag Structure y se puede hacer Lag Exclusion Tests o Lag Length Criteria...
- En **OxMetrics**: en el módulo de PcGive, en: Models for time-series data / Multiple-equation Dynamic Modelling, luego de la estimación del sistema irrestricto se pueden hacer Exclusion Restrictions y pedir los criterios de información.

Utilice la base de datos `soja.csv` de la clase pasada para estimar un VAR (recuerde volver estacionarias las series). Encuentre el orden apropiado del VAR y estímelo.

- En **STATA**: `var`
- En **R**: `VAR()` dentro del paquete `vars`
- En **EViews**: Quick/Estimate VAR... poner nombre de las variable endógenas e indicar cantidad de rezagos.
- En **OxMetrics**: en el módulo de PcGive, en: Models for time-series data / Multiple-equation Dynamic Modelling

Pruebas de diagnósticos

Al estimar un VAR por MCO, necesitamos que se cumplan los supuestos clásicos. En este contexto, tenemos que preocuparnos fundamentalmente por que no haya autocorrelación en los errores.

¿Por qué?

Pruebas de diagnósticos

Al estimar un VAR por MCO, necesitamos que se cumplan los supuestos clásicos. En este contexto, tenemos que preocuparnos fundamentalmente por que no haya autocorrelación en los errores.

¿Por qué?

Se puede pensar al test de autocorrelación multivariada como otra forma de evaluar la selección de rezagos óptima. ¿Por qué?

Test de Portmanteau de Autocorrelación:

- Versión multivariada del test de Box-Pierce/Ljung-Box
- Para evaluar autocorrelación de orden superior a 1.
- La hipótesis nula es la de no autocorrelación de orden h
- El estadístico se aproxima a una distribución $\chi^2(k^2(h - p))$ donde p es el orden del VAR.

Test de Portmanteau de Autocorrelación - Softwares

- En **STATA**: `varlmar`
- En **R**: `serial.test()`
- En **EViews**: luego de estimar el VAR, ir a View/Residual Tests/Autocorrelation LM Test... e indicar la cantidad de rezagos a evaluar.
- En **OxMetrics**: aparece por default luego de estimar el VAR (en su versión F)

Pruebas de diagnósticos

Existen versiones multivariadas de todas las otras pruebas usuales de diagnóstico que realizamos luego de una estimación por MCO.

Veremos el caso de la prueba multivariada de normalidad de los errores (será sobretodo importante para cuando más adelante veamos cointegración en sistemas).

Usualmente los softwares implementan el **test de Jarque-Bera** en forma multivariada:

- La hipótesis nula es la de normalidad multivariada
- Se reporta el test multivariado y univariado (para cada ecuación del VAR)
- Generalmente se reporta también el test de asimetría y el de curtosis.

- En **STATA**: `varnorm`
- En **R**: `normality.test()`
- En **EViews**: luego de estimar el VAR, ir a View/Residual Tests/Normality Test....
- En **OxMetrics**: aparece por default luego de estimar el VAR.
(Para más detalles ir a la ventana de Test)

VAR estructural

¿Y los efectos contemporáneos?

Hasta ahora hemos especificado modelos VAR que no incluyen, dentro de las variables explicativas, términos contemporáneos.

$$y_t = A_1 y_{t-1} + \cdots + A_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim (0, \Sigma_\varepsilon)$$

(los términos determinísticos se suprimen por simplicidad)

Si pensamos en un BIVAR(1). **¿Cuántos parámetros hay que estimar?**

¿Y los efectos contemporáneos?

Hasta ahora hemos especificado modelos VAR que no incluyen, dentro de las variables explicativas, términos contemporáneos.

$$y_t = A_1 y_{t-1} + \cdots + A_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim (0, \Sigma_\varepsilon)$$

(los términos determinísticos se suprimen por simplicidad)

Si pensamos en un BIVAR(1). **¿Cuántos parámetros hay que estimar?**

- $m \times m = 2 \times 2 = 4$ coeficientes de la matriz A_1
- 2 varianzas: $\sigma_{\varepsilon_1}^2$ y $\sigma_{\varepsilon_2}^2$

¿Y los efectos contemporáneos?

Pero podríamos estar interesados en estudiar un caso del estilo:

$$y_{1t} = \beta_{11}y_{1t-1} + \alpha_{11}y_{2t-1} + \alpha_{12}y_{2t} + \varepsilon_{1t}$$

$$y_{2t} = \beta_{21}y_{2t-1} + \alpha_{21}y_{1t-1} + \alpha_{22}y_{1t} + \varepsilon_{2t}$$

En forma matricial:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \alpha_{12} & 0 \\ 0 & \alpha_{22} \end{pmatrix} \begin{pmatrix} y_{2t} \\ y_{1t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Se conoce como el **VAR estructural**.

Sin embargo, este modelo es inconsistente si se lo estima por MCO, ¿por qué?

¿Y los efectos contemporáneos?

Pero podríamos estar interesados en estudiar un caso del estilo:

$$y_{1t} = \beta_{11}y_{1t-1} + \alpha_{11}y_{2t-1} + \alpha_{12}y_{2t} + \varepsilon_{1t}$$

$$y_{2t} = \beta_{21}y_{2t-1} + \alpha_{21}y_{1t-1} + \alpha_{22}y_{1t} + \varepsilon_{2t}$$

En forma matricial:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \alpha_{12} & 0 \\ 0 & \alpha_{22} \end{pmatrix} \begin{pmatrix} y_{2t} \\ y_{1t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Se conoce como el **VAR estructural**.

Sin embargo, este modelo es inconsistente si se lo estima por MCO, **¿por qué?**

Además, no está identificado.

Noten lo siguiente. Agrupando los términos contemporáneos:

$$\begin{pmatrix} 1 & -\alpha_{12} \\ -\alpha_{22} & 1 \end{pmatrix} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

o

$$By_t = \Gamma_1 y_{t-1} + \varepsilon_t$$

Esta es la representación matricial del *modelo estructural*.

Noten lo siguiente. Agrupando los términos contemporáneos:

$$\begin{pmatrix} 1 & -\alpha_{12} \\ -\alpha_{22} & 1 \end{pmatrix} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

o

$$By_t = \Gamma_1 y_{t-1} + \varepsilon_t$$

Esta es la representación matricial del *modelo estructural*.

Si B admite inversa (lo cual requiere que $\alpha_{12}\alpha_{22} \neq 1$):

$$y_t = B^{-1}\Gamma_1 y_{t-1} + B^{-1}\varepsilon_t$$

o

$$y_t = A_1 y_{t-1} + u_t$$

Pasamos a la forma reducida (modelo VAR), en la cual los coeficientes de y_t son la matriz identidad.

¿Pero cuántos parámetros hay que estimar?

Identificación del VAR estructural

$$y_t = A_1 y_{t-1} + u_t$$

- $m \times m = 2 \times 2 = 4$ coeficientes de la matriz A_1
- 2 varianzas: $\sigma_{u_1}^2$ y $\sigma_{u_2}^2$
- 1 covarianza: σ_{u_1, u_2}

Es un caso de **sobreidentificación** por lo que no podremos estimar el modelo VAR (en su forma reducida) si no imponemos alguna **restricción** de nulidad sobre α_{12} o α_{22} .

Identificación del VAR estructural

La elección de cuál de las 2 restricciones imponer idealmente deberá basarse en cuestiones de teoría económica/financiera.

Ejemplo:

Si la teoría sugiere que y_{1t} debe afectar a y_{2t} , pero no a la inversa, entonces $\alpha_{12} = 0$.

Otra posibilidad es estimar por separado imponiendo primero $\alpha_{12} = 0$ y luego $\alpha_{22} = 0$, para determinar si las características principales de los resultados varían mucho o no.

VAR con variables exógenas

Asimismo, el modelo VAR puede incorporar vectores de variables explicativas exógenas z_t en cada ecuación:

Ejemplo:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \delta_1 \\ \delta_2 \end{pmatrix} \begin{pmatrix} z_{1t} \\ z_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

que también puede aparecer con rezagos de z_t . Dentro del vector de variables exógenas puede haber una tendencia determinística, o variables ficticias estacionales.

Interpretación

Interpretación del VAR

No tiene sentido interpretar los coeficientes estimados.

En la práctica es común basar la interpretación en:

Tests:

- (1) Relevancia de variables
- (2) Significatividad de rezagos
- (3) Relaciones entre ecuaciones
- (4) Causalidad en sentido de Granger

Simulaciones:

- (1) Funciones impulso-respuesta (FIR)
- (2) Descomposición de la varianza (DV)

Pruebas de hipótesis

Supongamos BIVAR(3) (sin constantes, por simplicidad):

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \gamma_{11} & \gamma_{12} \\ \gamma_{21} & \gamma_{22} \end{pmatrix} \begin{pmatrix} y_{1t-2} \\ y_{2t-2} \end{pmatrix} \\ + \begin{pmatrix} \delta_{11} & \delta_{12} \\ \delta_{21} & \delta_{22} \end{pmatrix} \begin{pmatrix} y_{1t-3} \\ y_{2t-3} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Hipótesis que podemos estar interesados en evaluar:

Hipótesis	Restricciones
Rezagos de y_{1t} no explican a y_{2t}	$\beta_{21} = 0 \ \& \ \gamma_{21} = 0 \ \& \ \delta_{21} = 0$
Rezagos de y_{1t} no explican a y_{1t}	$\beta_{11} = 0 \ \& \ \gamma_{11} = 0 \ \& \ \delta_{11} = 0$
Rezagos de y_{2t} no explican a y_{1t}	$\beta_{12} = 0 \ \& \ \gamma_{12} = 0 \ \& \ \delta_{12} = 0$
Rezagos de y_{2t} no explican a y_{2t}	$\beta_{22} = 0 \ \& \ \gamma_{22} = 0 \ \& \ \delta_{22} = 0$

Pruebas de hipótesis

Para cualquiera de los 4 casos, el test consiste en evaluar la validez de las restricciones.

Si $\varepsilon_t \sim RB(0, \Omega)$,

$$(T - c)(\ln|\hat{\Omega}_r| - \ln|\hat{\Omega}_u|) \sim \chi^2(m)$$

asintóticamente bajo H_0 , en donde $\hat{\Omega}_r$ y $\hat{\Omega}_u$ son las matrices de varianzas del modelo restringido y sin restringir, respectivamente, m es el número de restricciones, c es el número de parámetros estimados en cada ecuación en el modelo sin restringir, y T es el número de observaciones.

Causalidad en sentido de Granger - usos y abusos

- Volveremos sobre este concepto más adelante (cuando veamos cointegración).
- Tan solo indica precedencia temporal de una variable respecto de otra.
- Es muy importante (pero no lo único) en un ejercicio de forecasting.
- La H_0 es la de “no-causalidad en sentido de Granger”. **¿Por qué?**

Causalidad en sentido de Granger - usos y abusos

- Volveremos sobre este concepto más adelante (cuando veamos cointegración).
- Tan solo indica precedencia temporal de una variable respecto de otra.
- Es muy importante (pero no lo único) en un ejercicio de forecasting.
- La H_0 es la de “no-causalidad en sentido de Granger”. **¿Por qué?**
- Mucha gente abusa de este test como prueba de causalidad **(NO LO ES)**.

Causalidad en sentido de Granger - Aplicación

Utilice la base de datos `soja.csv` que contiene datos del precio spot y futuro de la soja en Chicago (medidos en dólares por TM). Tome la diferencia logarítmica de dichas variables. Estime un VAR apropiado y evalúe causalidad en sentido de Granger.

- En **STATA**: `vargranger`
- En **R**: `grangertest()`
- En **EViews**: luego de estimar el VAR, ir a View/Lag Structure/Granger Causality....
- En **OxMetrics**: implementar un test de restricciones en la ventana de Test.

Funciones Impulso-Respuesta

Las **Funciones Impulso-Respuesta** (FIR) evalúan la capacidad de respuesta de las variables dependientes del VAR ante variaciones exógenas.

Funciones Impulso-Respuesta

Las **Funciones Impulso-Respuesta** (FIR) evalúan la capacidad de respuesta de las variables dependientes del VAR ante variaciones exógenas.

Un VAR(p) estacionario tiene una representación VMA(∞):

$$Y_t = \sum_{s=0}^{\infty} \Psi_s \varepsilon_{t-s}, \quad \Psi_0 = I_m, \quad \varepsilon_t \sim RBM$$

$$\frac{\partial Y_t}{\partial \varepsilon_{t-j}} = \frac{\partial Y_{t+s}}{\partial \varepsilon_t} = \Psi_s$$

$\Psi_{ij}(s)$: Efecto sobre $Y_{i,t+s}$ de cambiar ε_{jt} en una unidad.

$\Psi_{ij}(s)/\sqrt{V(\varepsilon_{jt})}$: Efecto sobre $Y_{i,t+s}$ de cambiar ε_{jt} en un desvío estándar: **función impulso respuesta simple**.

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,
- la inversión (y_1) se incrementa en 1 unidad en $t = 0$: $\varepsilon_{1,0} = 1$.

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,
- la inversión (y_1) se incrementa en 1 unidad en $t = 0$: $\varepsilon_{1,0} = 1$.
- Ahora podemos rastrear qué pasa con el sistema durante los períodos subsiguientes: $t = 1, 2, \dots$ **si...**

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,
- la inversión (y_1) se incrementa en 1 unidad en $t = 0$: $\varepsilon_{1,0} = 1$.
- Ahora podemos rastrear qué pasa con el sistema durante los períodos subsiguientes: $t = 1, 2, \dots$ **si...**
- **no ocurren más shocks.** Es decir,
 $\varepsilon_{2,0} = \varepsilon_{3,0} = 0, \varepsilon_1 = 0, \varepsilon_2 = 0, \dots$
- Como no estamos interesados en la media del sistema en este ejercicio sino solo en las variaciones de las variables entorno de la media, asumimos que todas las variables tienen media cero. Es decir, $y_t = A_1 y_{t-1} + \varepsilon_t$

Consideremos el siguiente VAR(1) en función del ejemplo anterior:

$$\begin{bmatrix} y_{1,t} \\ y_{2,t} \\ y_{3,t} \end{bmatrix} = \begin{bmatrix} 0,5 & 0 & 0 \\ 0,1 & 0,1 & 0,3 \\ 0 & 0,2 & 0,3 \end{bmatrix} \begin{bmatrix} y_{1,t-1} \\ y_{2,t-1} \\ y_{3,t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \\ \varepsilon_{3,t} \end{bmatrix}$$

Ejemplo

Consideremos ahora el efecto temporal que tiene un shock de 1 unidad en la variable y_1 en $t = 0$:

$$y_0 = \begin{bmatrix} y_{1,0} \\ y_{2,0} \\ y_{3,0} \end{bmatrix} = \begin{bmatrix} \varepsilon_{1,0} \\ \varepsilon_{2,0} \\ \varepsilon_{3,0} \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix},$$

En $t = 1$:

$$y_1 = \begin{bmatrix} y_{1,1} \\ y_{2,1} \\ y_{3,1} \end{bmatrix} = A_1 y_0 = \begin{bmatrix} 0,5 \\ 0,1 \\ 0 \end{bmatrix}$$

Ejemplo

En $t = 2$:










$$y_2 = \begin{bmatrix} y_{1,2} \\ y_{2,1} \\ y_{3,1} \end{bmatrix} = A_1 y_1 = A_1^2 y_0 = \begin{bmatrix} 0,25 \\ 0,06 \\ 0,02 \end{bmatrix}$$

y así continua.

En general, las FIR se grafican para tener una impresión visual de la dinámica de las interrelaciones dentro del sistema.

Ejemplo

(impulso $\rightarrow$ respuesta)



- En **STATA**: `irf`
- En **R**: `irf()` en el paquete `vars`
- En **EViews**: luego de estimar el VAR, ir a View/Impulse Response....
- En **OxMetrics**: luego de estimar el VAR, ir a Test/Simulation and Impulse Responses....

Utilice la base de datos `var.csv` que contiene un ejemplo de Lütkepohl (2007) en el cual se usan series trimestrales (desestacionalizadas) de la inversión fija en Alemania Occidental, el ingreso disponible y el gasto de consumo en miles de millones de marcos alemanes entre 1960Q1 y 1982Q4. Se pide:

- (1) Grafique las 3 variables. ¿Le parecen estacionarias?
Transfórmelas de ser necesario.
- (2) Estime un VAR(2) con constante. Respete el ordenamiento:
`invest, income, cons`.
- (3) Obtenga las FIR (trabajando con shocks ortogonales).
Ejemplo en R:

```
irf(model, impulse="income", response="cons",  
n.ahead=8, ortho=TRUE, runs=1000, seed=12345)
```

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.
- Mide **proporción de los movimientos en las variables dependientes que se deben a shocks “propios” vs. shocks de otras variables.**

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.
- Mide **proporción de los movimientos en las variables dependientes que se deben a shocks “propios” vs. shocks de otras variables.**
- Recordar que la FIR se refiere al shock en el término de error de solo una de las ecuaciones del VAR (los otros errores permanecen constantes).
- Esto no es realista → es común que los errores de las ecuaciones estén **correlacionados.**

¿Qué implica que los errores estén correlacionados?

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.
- Mide **proporción de los movimientos en las variables dependientes que se deben a shocks “propios” vs. shocks de otras variables.**
- Recordar que la FIR se refiere al shock en el término de error de solo una de las ecuaciones del VAR (los otros errores permanecen constantes).
- Esto no es realista → es común que los errores de las ecuaciones estén **correlacionados.**
 - ¿Qué implica que los errores estén correlacionados?
- Queremos ver entonces las respuestas de las variables ante **impulsos ortogonales**

Ortogonalización

El enfoque usual es ortogonalizar las FIR.

En un VAR bivariado, si los errores no son independientes entonces:

$$V(\varepsilon_t) = \Omega = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}$$

- Si Ω es simétrica y definida positiva, existe H no singular, tal que $\Omega = HH'$.
- Si ε_t es un vector aleatorio con $E(\varepsilon_t) = 0$ y $V(\varepsilon_t) = E(\varepsilon_t \varepsilon_t') = \Omega$, existe H tal que $\varepsilon_t = H v_t$, en donde v_t es un vector aleatorio con $E(v_t) = 0$ y $V(v_t) = I$.

v_t son las **innovaciones ortogonales** de ε_t .

¡El problema es que H no es única!

¡El problema es que H no es única!

Si Ω es simétrica y definida positiva, existe una **única** matriz P no singular y triangular inferior tal que $PP' = \Omega$. Donde P es la **matriz de Choleski** de Ω .

Entonces, la idea es utilizar $\varepsilon_t = Pv_t$

Descomposición de Choleski

La descomposición de Choleski (el uso de P) implica cierta arbitrariedad.

Ejemplo: En el caso del VAR bivariado:

$$\begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} = \begin{pmatrix} P_{11} & 0 \\ P_{21} & P_{22} \end{pmatrix} \begin{pmatrix} v_{1t} \\ v_{2t} \end{pmatrix}$$

ε_{1t} depende solo de v_{1t} ; ε_{2t} depende de v_{1t} y v_{2t} .

La dependencia entre ε_{1t} y ε_{2t} es generada por esta estructura recursiva.

Piensen en las implicancias que tendría, por ejemplo, que Y_1 sea la tasa de crecimiento monetario y Y_2 la tasa de inflación.

Una cuestión importante, entonces, es definir el **orden** de las variables de la matriz de Choleski.

Descomposición de Choleski

Notar que si:

$$\Omega = \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix} \Rightarrow P = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 \\ 0 & \sqrt{\sigma_{22}} \end{bmatrix}$$

- Si Ω es diagonal, el orden de la descomposición de Choleski no importa
- Trivialmente, las innovaciones originales son también innovaciones ortogonales
- En la práctica, entonces, es importante evaluar empíricamente la diagonalidad de Ω .

Descomposición de la Varianza (DV)

La **Descomposición de la Varianza** responde a la pregunta: ¿cuánto de la variabilidad total de una variable del VAR es atribuible a movimientos en cada una de las otras variables?

(Idea análoga al R^2 en el modelo lineal).

Un poco de álgebra:

- Si Ω es simétrica y definida positiva, existe una única matriz H triangular inferior con 1's en la diagonal principal, y una matriz diagonal D con todos sus elementos positivos, tal que $\Omega = HDH'$.
- Si ε_t es un vector aleatorio con $E(\varepsilon_t) = 0$ y $V(\varepsilon_t) = \Omega$, entonces ε_t puede escribirse como $\varepsilon_t = Hu_t$, con $E(u_t) = 0$ y $V(u_t) = D$, en donde H y D satisfacen $\Omega = HDH'$.

Descomposición de la Varianza (DV)

Si partimos de la representación $MA(\infty)$ del VAR:

$$y_t = \sum_{s=0}^{\infty} \Psi_s \varepsilon_{t-s}, \quad \Psi_0 = I_m, \quad \varepsilon_t \sim RBM$$

Si vamos s -períodos adelante:

$$y_{t+s} = \sum_{i=0}^{\infty} \Psi_i \varepsilon_{t+s-i}$$

El error de pronóstico será:

$$y_{t+s} - E_t(y_{t+s}) = \sum_{i=0}^{s-1} \Psi_i \varepsilon_{t+s-i}$$

Descomposición de la Varianza (DV)

El error cuadrático medio del pronóstico s -pasos adelante será:

$$\begin{aligned}MSE(\hat{y}_{t+s|t}) &= E[(y_{t+s} - \hat{y}_{t+s|t})(y_{t+s} - \hat{y}_{t+s|t})'] \\&= \Omega + \Psi_1 \Omega \Psi_1' + \Psi_2 \Omega \Psi_2' + \dots + \Psi_{s-1} \Omega \Psi_{s-1}'\end{aligned}$$

donde

$$\Omega = E(\varepsilon_t \varepsilon_t')$$

Descomposición de la Varianza (DV)

Si consideramos cómo los errores ortogonalizados (u_t) contribuyen al MSE, sabiendo que $\varepsilon_t = Hu_t$:

$$\Omega = E(\varepsilon_t \varepsilon_t') = h_1 h_1' V(u_{1t}) + h_2 h_2' V(u_{2t}) + \dots + h_n h_n' V(u_{nt})$$

donde $V(u_{jt})$ es el elemento de la fila j , columna j de la matriz D . Entonces, el MSE s -pasos adelante puede re-escribirse como:

$$MSE(\hat{y}_{t+s|t}) = \sum_{j=1}^n \{ V(u_{jt}) [h_j h_j' + \Psi_1 h_j h_j' \Psi_1' + \Psi_2 h_j h_j' \Psi_2' + \dots + \Psi_{s-1} h_j h_j' \Psi_{s-1}'] \}$$

Descomposición de la Varianza (DV)

Entonces, puede calcularse la contribución de la j -ésima innovación ortogonal del MSE del pronóstico s -pasos adelante:

$$V(u_{jt})[h_{jj}' + \Psi_1 h_{jj} \Psi_1' + \Psi_2 h_{jj} \Psi_2' + \dots + \Psi_{s-1} h_{jj} \Psi_{s-1}']$$

- La magnitud en general depende del ordenamiento de las variables.
- A medida que $s \rightarrow \infty$ para un VAR estacionario, $\text{MSE}(\hat{y}_{t+s|t}) \rightarrow V(y_t)$.

Entonces, la expresión anterior permite calcular la proporción de la varianza de y_t que se debe al error u_j dejando que s sea lo suficientemente grande.

En la práctica: computar la DV para $s = 1, 2, 3, \dots$

Sobre la base de datos anterior (`var.csv`) obtenga la descomposición de la varianza.

- En **STATA**: `irf table fevd`
- En **R**: `fevd()`
- En **EViews**: luego de estimar el VAR, ir a View/Variance Decomposition....

- Lütkepohl (2005) - Cap. 2 a 4
- Hamilton (1994) - Cap. 11