

Procesos No Estacionarios

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata


Introducción

Cuando asumíamos que una serie es **estacionaria (en sentido débil)** esto implicaba que:


- $E(y_t) = \mu$ (1 parámetro)
- $Var(y_t) = \gamma_0$ (1 parámetro)
- $Cov(y_t, y_{t+j}) = \gamma_j$ ($T-1$ parámetros)

¿Qué pasa si m_1 o m_2 varían en el tiempo?

Casos de no estacionariedad



No estacionariedad en media



Caso heterocedástico

Tendencia determinística

Estacionariedad en torno a una tendencia

Consideren el siguiente proceso:

$$y_t = \alpha + \beta t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Si calculan la media y la varianza, ¿qué observan?

Estacionariedad en torno a una tendencia

Consideren el siguiente proceso:

$$y_t = \alpha + \beta t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Si calculan la media y la varianza, ¿qué observan?

- $E(y_t) = \alpha + \beta t$
- $Var(y_t) = \sigma^2$

Si definimos una nueva variable y^* , $y^* = y - (\alpha + \beta t)$, se vuelve estacionaria.

Ejemplo - Enders (2010)

Utilice el archivo “RGDP.xls” que contiene valores trimestrales del PBI real de EE.UU. entre 1947Q1-2008Q1 (en billones de dólares del año 2000).

- Grafique. ¿Qué observa?

Ejemplo - Enders (2010)

Utilice el archivo “RGDP.xls” que contiene valores trimestrales del PBI real de EE.UU. entre 1947Q1-2008Q1 (en billones de dólares del año 2000).

- Grafique. ¿Qué observa?
- Un pronosticador “naive” decide estimar el incremento sostenido en el PBI real con un modelo que sigue una función cúbica (polinómica de grado 3) respecto del tiempo. Esto es,

$$rgdp_t = a + b.t + c.t^2 + d.t^3 + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

- Estime dicho modelo y grafique la serie original junto con la estimada.
- Obtenga la serie sin tendencia.
- ¿Qué implicancias económicas, respecto del largo plazo del PBI real, tiene este modelo?

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**.
Los shocks no se acumulan, no son permanentes. ¿Por qué?

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**.
Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**. Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).
- Una tendencia determinística implica que no existe incertidumbre sobre la evolución futura de la tendencia $\Rightarrow$ **conocido el pasado, el futuro es previsible.**

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**.
Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).
- Una tendencia determinística implica que no existe incertidumbre sobre la evolución futura de la tendencia $\Rightarrow$ **conocido el pasado, el futuro es previsible.**
- ¡POCO REALISTA!

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**.
Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).
- Una tendencia determinística implica que no existe incertidumbre sobre la evolución futura de la tendencia $\Rightarrow$ **conocido el pasado, el futuro es previsible.**
- ¡POCO REALISTA!
- Es más realista el caso de la **tendencia estocástica**, donde hay incertidumbre respecto de la evolución futura del proceso.

¿Qué pasa si trabajamos con series con tendencia?

Ejemplo de Vogelsang, MSU 2017

- Considere el modelo estimado por MCO entre 1900 y 2012:

$$\widehat{temp}_t = -3,51 + 0,368 \log(rpcgdpus_t), \quad R^2 = 0,740$$

(0,193) (0,021)

donde $temp_t$ es la temperatura anual global (en °C) y $rpcgdpus_t$ es el PBI real per cápita anual de USA.

- ¿Qué se observa?
 - La variación en el PBI real de USA explica un 74 % de la variación en la temperatura global.
 - La pendiente del PBI es muy significativa ($t = 17,87$).

¿Qué pasa si trabajamos con series con tendencia?

Ejemplo de Vogelsang, MSU 2017

- Considere el modelo estimado por MCO entre 1900 y 2012:


$$\widehat{temp}_t = -3,51 + 0,368 \log(rpcgdpus_t), \quad R^2 = 0,740$$

(0,193) (0,021)


donde $temp_t$ es la temperatura anual global (en °C) y $rpcgdpus_t$ es el PBI real per cápita anual de USA.

- ¿Qué se observa?
 - La variación en el PBI real de USA explica un 74 % de la variación en la temperatura global.
 - La pendiente del PBI es muy significativa ($t = 17,87$).
- **¿Esto implica que la actividad económica en USA está produciendo cambios en la temperatura global?**


Annual Averaged Global Temperatures (Land and Sea)



Log Real Per Capita GDP: United States



Log Real Per Capita GDP: United Kingdom



Trabajando con datos con tendencia

- ¿Es culpa de la reina?




$$\widehat{temp}_t = -4,18 + 0,452 \log(rpcgdpuk_t), \quad R^2 = 0,784$$

(0,185) (0,020)

- ¡El estadístico t del PBI per capital real de UK es 22,47!

Global Temperatures and Log of Real Per Capita GDP



El problema de la regresión espuria

- Supongan que y_t está dada por:

$$y_t = \alpha_0 + \alpha_1 t + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

Y que la variable x_t está dada por:

$$x_t = \lambda_0 + \lambda_1 t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

- donde $\alpha_1 \neq 0$ y $\lambda_1 \neq 0$ y que v_t y ε_t están incorrelacionadas entre sí.
- Entonces, no existe una relación entre y_t y x_t

El problema de la regresión espuria

- Supongan que y_t está dada por:

$$y_t = \alpha_0 + \alpha_1 t + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

Y que la variable x_t está dada por:

$$x_t = \lambda_0 + \lambda_1 t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

- donde $\alpha_1 \neq 0$ y $\lambda_1 \neq 0$ y que v_t y ε_t están incorrelacionadas entre sí.
- Entonces, no existe una relación entre y_t y x_t
- Sin embargo, la estimación por MCO:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

nos cuenta una historia diferente.

El problema de la regresión espuria

- Es conceptualmente fácil, aunque algebraicamente complicado, mostrar que para:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

Los siguientes resultados se mantienen:

$$p \lim \hat{\beta}_1 = \frac{\alpha_1}{\lambda_1}, \quad |t_{\beta_1=0}| \xrightarrow{d} \infty, \quad p \lim R^2 = 1$$

- Estos resultados sugieren que:
 - Si nuestras variables muestran un comportamiento tendencial sistemático a lo largo del tiempo, **los resultados de la regresión son potencialmente espurios.**
 - No podemos aprender nada sobre la relación entre variables a partir de un modelo simple de regresión en nivel.

El problema de la regresión espuria

- **Alguna intuición sobre los resultados espurios:**

- Cuando y_t y x_t no están relacionados, nuestra regresión:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

se convierte, en la población, en:

$$y_t = \alpha_0 + \alpha_1 t + v_t$$

donde ahora está claro que $\beta_1 = 0, \beta_0 = \alpha_0, u_t = \alpha_1 t + v_t$ en la regresión original.

- Por lo que t puede pensarse como una variable omitida.
- Como t está correlacionada con x_t (ya que x_t depende de una tendencia), aparece el **sesgo por variables omitidas**.

El problema de la regresión espuria - Solución

- (1) Incluir el regresor omitido, t :

$$y_t = \beta_0 + \beta_1 x_t + \beta_2 t + u_t$$

- (2) Alternativamente, nos podemos preguntar si las partes aleatorias de y_t y x_t están relacionadas.

El problema de la regresión espuria - Solución

- El caso (2) implica evaluar si v_t y ε_t están relacionadas.
- **Problema:** v_t y ε_t son inobservables.
- Podemos obtener proxies de v_t y ε_t si:
 - Regresamos y_t en función de una constante y de t y calculamos los residuos:

$$\ddot{y}_t = y_t - \hat{\alpha}_0 - \hat{\alpha}_1 t$$

- Regresamos x_t en función de una constante y de t y calculamos los residuos:

$$\ddot{x}_t = x_t - \hat{\lambda}_0 - \hat{\lambda}_1 t$$

- Las variables $\ddot{y}_t$ y $\ddot{x}_t$ se denominan variables destendenciadas.

El problema de la regresión espuria - Solución

- Se puede re-estimar el modelo a partir de las series destendenciadas:

$$\ddot{y}_t = \beta_0 + \beta_1 \ddot{x}_t + \ddot{u}_t$$

- La estimación del coeficiente de la pendiente indica si existe una relación entre y y x a través de v y ε .
- Ahora el estadístico t de β_1 tiene las propiedades usuales.
- El R^2 de esta regresión ($\ddot{R}^2$) mide la proporción de la variación de y_t **en torno a su tendencia** que es explicada por la variación en x_t **en torno a su tendencia**.

Tendencia estocástica

Tendencia Estocástica

Ok. Pero todo este análisis fue para casos de tendencias determinísticas (¡poco realistas!).

Tendencia Estocástica


Ok. Pero todo este análisis fue para casos de tendencias determinísticas (¡poco realistas!).

- La series financieras y/o económicas pueden presentar a lo largo de su historia **distintas tendencias o medias locales que cambian en el tiempo.**
- Esto implica que no estaríamos ante una serie de crecimiento tendencial, pero tampoco la serie temporal sería estacionaria.
- Los cambios en la media pueden ocurrir con gran frecuencia debido a distintos factores y la tendencia se captaría mejor con un **esquema estocástico.**

Camino Aleatorio (Random Walk)

Un **random walk** es un AR(1) con $\phi = 1$:

$$y_t = y_{t-1} + \varepsilon_t$$



¿Qué implica el RW en términos de pronóstico?

AR(1) vs RW

Sea,

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim IID(0, \sigma^2)$$







AR(1)	RW
$ \phi < 1$	$ \phi = 1$
$\gamma_0 = \frac{\sigma^2}{1-\phi}$	$\gamma_0 = t\sigma^2 \Rightarrow \text{cuando } t \rightarrow \infty \Rightarrow \gamma_0 \rightarrow \infty$
$\rho_j = \phi^j$	$\rho_j = \sqrt{1 - \frac{j}{t}} \Rightarrow \text{cuando } t \rightarrow \infty \Rightarrow \rho_j \rightarrow 1$
Shocks temporarios	Shocks permanentes

Simule las siguientes series de tiempo para $T = 100$:

- $y_t = 0,8y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$
- $y_t = y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$
- $y_t = 1,05y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$

Graficar y observar los correlogramas.


Simulación



Tipos de Random Walk

- RW (puro): $y_t = y_{t-1} + \varepsilon_t$
- RW con constante: $y_t = \alpha + y_{t-1} + \varepsilon$
- RW con tendencia: $y_t = \alpha + \beta t + y_{t-1} + \varepsilon_t$

Calculen sus medias y varianzas.



Formas para remover la tendencia:

- Diferenciación
- Destendenciado

Diferenciar o Destendenciar

Prueben diferenciar y/o destendenciar los siguientes procesos hasta volverlos estacionarios:

- $y_t = y_{t-1} + \varepsilon_t$
- $y_t = \alpha + y_{t-1} + \varepsilon_t$
- $y_t = \alpha + \beta.t + \varepsilon_t$
- $y_t = \alpha + \beta.t + y_{t-1} + \varepsilon_t$

Pruebas de raíz unitaria

Raíces Unitarias

Consideren el siguiente proceso estocástico:

$$y_t = \phi y_{t-1} + \varepsilon_{t-1}, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Es un proceso AR(1) que resulta estacionario si $|\phi| < 1$.

Un **test de raíz unitaria** entonces equivale a evaluar:

$$H_0 : \phi = 1 \Rightarrow H_0 : \phi - 1 = 0$$

Naturalmente, el estadístico que utilizaríamos para evaluar H_0 es:

$$T = \frac{\hat{\phi} - 1}{SE(\hat{\phi})}$$

El problema es que bajo la H_0 **ya no podremos usar la teoría asintótica estándar para estudiar el comportamiento del estadístico.**

Test de Dickey-Fuller (1979)

Existen diversos tests para evaluar la presencia de una raíz unitaria, siendo el **Test de Dickey-Fuller** el más conocido.

$$\text{Sea } y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

$$H_0 : \phi = 1$$

$$H_1 : \phi < 1$$

Se puede reparametrizar de la siguiente manera:

$$\Delta y_t = (\phi - 1)y_{t-1} + \varepsilon_t = \psi y_{t-1} + \varepsilon_t$$

Lo cual equivale a evaluar:

$$H_0 : \psi = 0$$

$$H_1 : \psi < 0$$


Test de Dickey-Fuller

$$H_0 : \psi = 0$$

$$H_1 : \psi < 0$$

$$T = \frac{\hat{\psi}}{SE(\hat{\psi})} = \frac{\hat{\phi} - 1}{SE(\hat{\phi})}$$

Dickey y Fuller (1979) obtuvieron la distribución específica de este estadístico cuyos valores críticos son más negativos que los de una distribución normal.



Test de Dickey-Fuller

Existen tres versiones del test:

(1) Test de raíz unitaria (sin componentes determinísticos):

$$\Delta y_t = \psi y_{t-1} + \varepsilon_t$$

(2) Test de raíz unitaria con constante:

$$\Delta y_t = \alpha + \psi y_{t-1} + \varepsilon_t$$

(3) Test de raíz unitaria con constante y tendencia determinística:

$$\Delta y_t = \alpha + \beta t + \psi y_{t-1} + \varepsilon_t$$

Test de Dickey-Fuller - Softwares

- En **STATA**: `dfuller`
- En **R**: `ur.df()` usar el package `urca`
- En **EViews**: desde la serie ir a View/Unit Root Test....
- En **OxMetrics**: en PcGive/Other Models/Descriptive Statistics using PcGive... seleccionar la variable y seleccionar Unit root tests.

Tabla de Dickey-Fuller

Probability of a Smaller Value	0.01	0.025	0.05	0.10	0.90	0.95	0.975	0.99
Sample Size								
No Constant or Time ($a_0 = a_2 = 0$)								
	τ							
25	-2.66	-2.26	-1.95	-1.60	0.92	1.33	1.70	2.16
50	-2.62	-2.25	-1.95	-1.61	0.91	1.31	1.66	2.08
100	-2.60	-2.24	-1.95	-1.61	0.90	1.29	1.64	2.03
250	-2.58	-2.23	-1.95	-1.62	0.89	1.29	1.63	2.01
300	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
∞	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
Constant ($a_2 = 0$)								
	τ_μ							
25	-3.75	-3.33	-3.00	-2.62	-0.37	0.00	0.34	0.72
50	-3.58	-3.22	-2.93	-2.60	-0.40	-0.03	0.29	0.66
100	-3.51	-3.17	-2.89	-2.58	-0.42	-0.05	0.26	0.63
250	-3.46	-3.14	-2.88	-2.57	-0.42	-0.06	0.24	0.62
500	-3.44	-3.13	-2.87	-2.57	-0.43	-0.07	-0.24	0.61
∞	-3.43	-3.12	-2.86	-2.57	-0.44	-0.07	0.23	0.60
Constant + time								
	τ_t							
25	-4.38	-3.95	-3.60	-3.24	-1.14	-0.80	-0.50	-0.15
50	-4.15	-3.80	-3.50	-3.18	-1.19	-0.87	-0.58	-0.24
100	-4.04	-3.73	-3.45	-3.15	-1.22	-0.90	-0.62	-0.28
250	-3.99	-3.69	-3.43	-3.13	-1.23	-0.92	-0.64	-0.31
500	-3.98	-3.68	-3.42	-3.13	-1.24	-0.93	-0.65	-0.32
∞	-3.96	-3.66	-3.41	-3.12	-1.25	-0.94	-0.66	-0.33

Source: This table was constructed by David A. Dickey using Monte Carlo methods. Standard errors of the estimates vary, but most are less than 0.20. The table is reproduced from Wayne Fuller, *Introduction to Statistical Time Series*. (New York: John Wiley). 1976.

Test de Dickey-Fuller Aumentado

En realidad, asumir que todas las variables pueden ser representadas por un AR(1) es una simplificación muy grande.

¿Qué pasa si ε_t no es IID?

Test de Dickey-Fuller Aumentado

En realidad, asumir que todas las variables pueden ser representadas por un AR(1) es una simplificación muy grande.

¿Qué pasa si ε_t no es IID?

Test de Dickey-Fuller Aumentado (ADF): extensión a un modelo AR(p)

Supongamos que y_t es un AR(2):

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

Si sumamos y restamos $\phi_2 y_{t-1}$:

$$y_t = (\phi_1 + \phi_2) y_{t-1} - \phi_2 \Delta y_{t-1} + \varepsilon_t$$

$$\Delta y_t = (\phi_1 + \phi_2 - 1) y_{t-1} + \delta \Delta y_{t-1} + \varepsilon_t$$

Test de Dickey-Fuller Aumentado

En términos generales:

$$\Delta y_t = \psi y_{t-1} + \sum_{j=1}^t \delta \Delta y_{t-j} + \varepsilon_t, \quad \varepsilon_t \sim IID(0, \sigma^2)$$

$$H_0 : \psi = 0$$

$$H_1 : \psi < 0$$

Para ver cuál es el orden apropiado, hay que ver que ε_t no tenga autocorrelación (se pueden usar criterios de información).

Grafique y realice un test de Dickey-Fuller para evaluar la estacionariedad de las siguientes series temporales:

- `r`: difference between 180-day 90-day bank rates, %. Base: `term.csv`
- `s`: precio spot de la soja en USD/MT. Base: `soja.csv`
- `ipc`: índice de precios al consumidor de Argentina, cobertura nacional, Dic 2016=100. Base: `soja.csv`

Trabaje con las series `s` y `ipc` en logaritmos.

Variables Integradas

Decimos que y_t es $I(1)$ (“integrada de orden 1”) si Δy_t es $I(0)$, estacionaria a través de la diferenciación.

En general,

- y_t es $I(d)$ (“integrada de orden d ”) si $\Delta^d y_t$ es $I(0)$, estacionaria luego de la diferenciación aplicada d veces.

Recomendación: cada vez que apliquen un test de raíz unitaria sobre una variable, háganlo sobre su nivel y sus diferencias (tantas diferencias como sea necesario hasta llegar a una transformación $I(0)$).

Notar que **no toda variable no estacionaria se identifica como integrada**. Existen otras fuentes de no estacionariedad: breaks, heterocedasticidad, etc.

Vuelvan sobre la aplicación anterior y determinen el orden de integración de cada una de las variables.

I(1) vs I(0)

En la práctica puede ser que nos encontremos con que parte de los shocks son permanentes y otra parte no lo sea.

Casos	I(1) $\phi = 1$	I(0) $\phi < 1$
$\Delta y_t = \psi y_{t-1} + \varepsilon_t$ (Estocástico puro)	RW zero growth	$y_t \sim AR(1)$ zero mean
$\Delta y_t = \gamma + \psi y_{t-1} + \varepsilon_t$ (Con constante)	RW with drift trend in y_t +stochastic	$y_t \sim AR(1)$ (mean $\neq 0$)
$\Delta y_t = \gamma_0 + \gamma_1 t + \psi y_{t-1} + \varepsilon_t$ (Con constante y tendencia)	RW + drift + trend quadr. trend in y_t +stochastic	$y_t \sim AR(1)$ with trend

Otros tests de raíz unitaria

A pesar del uso extendido que tiene el test ADF hay muchísimos tests alternativos (debido a la baja potencia del ADF y muchos de estos test).

Estos son algunos de los más usuales:

- Phillips-Perron (PP)
- Kwiatkowski-Phillips-Schmidt-Shin (KPSS)
- entre otros

Phillips-Perron (PP)

Phillips y Perron (1988) propusieron un test alternativo que se basa en el test de DF al evaluar la hipótesis nula de $\rho = 0$ en:

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

Como en el caso del ADF, el test de PP permite que el PGD de y_t tenga autocorrelación de orden superior, pero en lugar de agregar rezagos de Δy_t (como DF), el test de PP realiza una corrección no paramétrica del estadístico t . El test es robusto respecto a HAC en el término de error.

Davidson y MacKinnon (2004) mostraron que PP tiene peor desempeño que ADF en muestra chica.

- En **STATA**: `pperron`
- En **R**: `ur.pp()` usar el package `urca`
- En **EViews**: desde la serie ir a View/Unit Root Test....

Kwiatkowski-Phillips-Schmidt-Shin (KPSS)

Kwiatkowski, Phillips, Schmidt y Shin (1992) proponen un test alternativo cuya hipótesis nula es la de estacionariedad de la serie en torno a una tendencia determinística.

La serie es expresada como una suma de tendencia determinística, RW y error ruido blanco y se utiliza un test LM para evaluar si el RW tiene varianza cero.

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. y Y. Shin, Y.
Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54: 1–3, 1992, 159–178.

- En **STATA**: `kpss`
- En **R**: `ur.kpss()` usar el package `urca`
- En **EViews**: desde la serie ir a View/Unit Root Test....

Aplique los distintos test vistos sobre las series anterior, ¿llega a las mismas conclusiones?

Limitaciones

Problemas con los test de raíz unitaria

- Muy sensibles a la introducción de constantes y tendencias y a la elección del número de rezagos.

Problemas con los test de raíz unitaria


- Muy sensibles a la introducción de constantes y tendencias y a la elección del número de rezagos.
- Hay una suerte de “trade-off” entre consistencia y potencia en la especificación de los componentes determinísticos similar al problema estándar de variables omitidas.
- Incrementar espuriamente el número de rezagos baja la potencia. Usar SIC y metodología General-a-Particular.
- ADF tiene tamaño correcto, pero baja potencia. PP, al revés.
- Importa la extensión del período y NO la frecuencia (Shiller y Perron, 1988).
- **Confunden breaks con unit root** (ver la simulación que está a continuación).

Ejercicio de Monte Carlo en OxMetrics

PGD:


- AR(1):
$$y_t = 0,5y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$$
- Es un AR(1) estacionario con constante nula
- $T=100$
- 1000 replicaciones
- En $t=50$: break en la constante, ahora pasa a ser igual a 4.

Serie simulada (y_t):



La serie por construcción es $I(0)$, pero si miramos la distribución del estadístico asociado a evaluar si $\phi = 1$...

Ejercicio de Monte Carlo en OxMetrics



El efecto de los cambios estructurales (determinísticos) hace que pensemos que la variable es $I(1)$ cuando en realidad es $I(0)$.

- Dividir la muestra en función del break y aplicar un test de raíz unitaria por segmento (requiere T grande en cada sub-muestra)
- Test de Perron (1989) o Zivot-Andrews (1992) o cualquier otra variante de tests de raíz unitaria con quiebres.

Recomendaciones prácticas (en general)

- Empezar con un gráfico (perfil de y_t) y terminar con un gráfico (residuos).
- Mirar los correlogramas de la serie en nivel y en diferencias.
- Si existe estacionalidad, trabajar con el Δ_4 o Δ_{12} .
- Evaluar si resulta conveniente trabajar con las variables en logaritmos.
- Cuando trabajamos con datos desestacionalizados tener cuidado que si la desestacionalización no es adecuada puede que el correlograma de las primeras diferencias arroje coeficientes negativos (¡muy raro!).
- No es recomendable usar datos desestacionalizados si lo que interesa es estudiar la dinámica de corto plazo (en el largo plazo da igual).

Breaks

Quiebres en la media o la tendencia

Simulen para $T = 100$ los siguientes procesos:

$$y_t = 3 + 5D + \varepsilon_t,$$

$$y_t = 10 - 0,2D \times t + \varepsilon_t$$

- donde $D = 1$ para $t > 50$, $= 0$ en caso contrario y $\varepsilon_t \sim N(0, 1)$.

Grafique y aplique el test ADF sobre cada uno. Comente.

- Una regresión que no contemple estos cambios puede llevar a errores de inferencia y pronóstico.
- Un **quiebre** puede aparecer como un cambio discreto en los coeficientes poblacionales de la regresión o una evolución gradual de los coeficientes a lo largo del tiempo.
- Dependiendo del tamaño y ubicación del quiebre, la regresión puede diferir mucho de la verdadera función de regresión.

¿Cómo detectar la presencia de quiebres?

Dos enfoques:

- Para una fecha conocida
- Para una fecha desconocida

Para una fecha conocida:

Ejemplo: en el siguiente modelo autoregresivo, queremos evaluar la existencia de un break en el momento τ . Sea $D(\tau)$ una variable dicotómica que vale 0 antes del break y 1 luego del break:

$$y_t = \beta_0 + \beta_1 y_{t-1} + \beta_2 X_t + \gamma_0 D_t(\tau) + \gamma_1 (D_t(\tau) \times y_{t-1}) + \gamma_2 (D_t(\tau) \times X_t) + u_t$$

Evaluando la presencia de breaks

- Si no existe un break, los términos en los cuáles está la variable binaria no deberían ser significativos.
- La hipótesis nula es la de ausencia de break:

$$\gamma_0 = \gamma_1 = \gamma_2 = 0$$

- Bajo la hipótesis alternativa, existe un break.
- Esto puede evaluarse mediante un estadístico F.
- También se conoce como el **test de Chow (1960)**
- Si hay múltiples rezagos y regresores puede extenderse el test incorporando más interacciones entre la variable binaria y el resto de los rezagos y regresores.

Evaluando la presencia de breaks

Para una fecha desconocida:

- Puede ser que la fecha del quiebre sea desconocida *a priori*.
- Supongamos que creemos que el quiebre se produce entre la fecha τ_0 y τ_1 .
- El test de Chow puede modificarse de tal forma que podamos evaluar todas las posibles fechas entre estos dos puntos y usar el estadístico F más grande.
- Esta modificación del test de Chow se conoce como el **Quandt likelihood ratio (QLR) statistic**.

Evaluando la presencia de breaks

- Como el estadístico QLR es el mayor de todos los estadísticos F , su distribución no es la misma que la del test F individual.
- La distribución depende del: nro de restricciones (q); nro de coeficientes (incluyendo la constante) que se permiten que cambien bajo la hipótesis alternativa; de τ_0/T y de τ_1/T .
- Los puntos τ_0 y τ_1 no deberían ser cercanos al principio o fin de la muestra
- En la práctica, el estadístico QLR se calcula sobre un rango recortado o un subconjunto de la muestra.
- Comúnmente se usa un *trimming* del 15 %: $\tau_0 = 0,15T$ y $\tau_1 = 0,85T$
- Si existe un break significativo, la fecha en la cual el mayor estadístico F ocurre, es un estimador de la fecha del break.

- En **STATA**: ¡hay que programar!
- En **R**: paquete `strucchange`
- En **EViews**: en la ventana de `Stability Diagnostics` hay varias opciones.

Uso de algoritmos para la detección de breaks o outliers

Una posibilidad es regresar la variable en función de un conjunto de dummies impulso:

$$\begin{aligned} y_t &= c_t + \varepsilon_t \\ &= \sum_{i=1}^T c_i l_{it} + \varepsilon_t \end{aligned}$$

donde l_{it} es igual a 1 cuando $t = i$.


Estos modelos tienen que estimarse con la ayuda de algún algoritmo (ya que $k > T$) como **IIS (Indicator Impulse Saturation)**.

¿Cómo funciona IIS?

Supongamos que el PGD de la variable y_t es:

$$y_t = \mu_0 + \varepsilon_t, \quad \varepsilon_t \sim NID(0, \sigma^2)$$


Si hacemos una simulación con $T = 100$, $\mu_0 = 20$ y $\sigma^2 = 1$, estimamos y obtenemos los residuos:



Procedimiento

- (1) Re-estimamos el modelo incluyendo impulse dummies solo para la primera mitad de la muestra.
- (2) Eliminamos las dummies no significativas y retenemos las significativas.
- (3) Repetimos el proceso para la segunda mitad de la muestra.
- (4) Re-estimamos el modelo original incluyendo todas las dummies significativas de los dos bloques.
- (5) Seleccionamos las dummies significativas del conjunto combinado.
- (6) Hendry, Johansen y Santos (2008) y Johansen y Nielsen (2009) probaron que, bajo H_0 de correcta especificación, la fracción de dummies impulso que son retenida es aproximadamente αT , donde α es el *target size*.

Ilustrando el procedimiento con $\alpha = 5\%$



Pero también podría suceder que haya **cambios sistemáticos en la media, pero de corta duración.**

$$y_t = \sum_{i=1}^T c_i S_{it} + \varepsilon_t$$

donde S_{it} es una *step-dummy* ($=1$ para $t \geq i$).

Este modelo nuevamente tiene que estimarse con la ayuda de algún algoritmo (**SIS, Step Indicator Saturation**).

Ejemplo simulado

Supongan que el PGD ahora es:


$$y_t = \mu_0 + \mu_1 S_{76t} + \varepsilon_t, \quad \varepsilon_t \sim NID(0, \sigma^2)$$

donde $S_{76t} = 0$ ($T = 1, \dots, 75$), $S_{76t} = 1$ ($T = 76, \dots, 100$), y el modelo estimado es una regresión de y en función de una constante, ignorando el break que ocurre en el período 76.


El modelo no incorporará el cambio en la media (aka **“location shift”**).

Datos simulados y residuos de la estimación

$$(\mu_0 = 20, \mu_1 = -10, \sigma^2 = 1, T = 100)$$



Si aplicamos IIS



Algunas extensiones de IIS

- **IIS (Impulse Indicator Saturation):** procedimiento propuesto por Hendry (1999) selecciona impulse dummies $\{I_{it}\}$ a lo largo de T .
- **SIS (Step Indicator Saturation):** selecciona step-dummies $\{S_{it}\}$ a lo largo de T .
- **TIS (Trend Indicator Saturation):** selecciona broken trends $\{T_{it} = t - i + 1, t \geq i\}$ a lo largo de T .
- **Super Saturation:** IIS+SIS
- **Ultra Saturation:** IIS+SIS+TIS

Importante: al aumentar el número de potenciales regresores (K) es importante ir disminuyendo el target size (α) $\rightarrow$ regla: $\alpha \leq 1/K$

Todos estos algoritmos están disponibles en R (función `isat()` dentro del paquete `gets`, van a tener que darle formato zoo a las variables) y en OxMetrics.

Para los usuarios de R:

- Apliquen este algoritmo sobre la serie de tipo de cambio nominal (promedio mensual) de la Argentina (`TCN.csv`)

Bibliografía

- Banerjee et al. (1993) - Cap. 3 y 4
- Ericsson (2012) “Detecting crises, jumps and changes in regime”
- Sosa Escudero (1997) “Testing for Unit-Roots and Trend-Breaks in Argentine Real GDP”