

Cointegración

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

Introducción

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.
- Muchos modelos económicos involucran la idea de relaciones de cointegración.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.
- Muchos modelos económicos involucran la idea de relaciones de cointegración.
- El concepto de cointegración fue introducido por Engle y Granger (1987) en forma univariada.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.


- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.
- Muchos modelos económicos involucran la idea de relaciones de cointegración.
- El concepto de cointegración fue introducido por Engle y Granger (1987) en forma univariada.
- Johansen (1991) lo extendió al caso multivariado (tema de la próxima clase).

Regresión Espuria


El problema de la regresión espuria

- En estadística, una relación espuria (o, a veces, correlación espuria) es una relación matemática en la cual dos acontecimientos no tienen conexión lógica (idealmente, causal), aunque se puede implicar que la tienen debido a un tercer factor no considerado aún (llamado “factor de confusión” o “variable escondida”).
- La relación espuria da la impresión de la existencia de un vínculo apreciable entre dos variables (Y y X) que es inválido cuando se examina objetivamente.
- Algunos ejemplos...

El problema de la regresión espuria



El problema de la regresión espuria



Más ejemplos en: tylervigen.com

Spurious Regression (Granger)

Non-Sense Regression (Yule)

Técnicamente lo que sucede es lo siguiente:

- Si tenemos dos variables y_t y x_t tal que:

$$y_t = \alpha + y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

$$x_t = \lambda + x_{t-1} + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

donde v_t y ε_t están incorrelacionadas entre sí.

- Ambas variables, al ser RW, presentan tendencias estocásticas.
- Si hacemos una regresión de y_t en función de x_t , ¿qué esperan observar?

Spurious Regression (Granger)

Non-Sense Regression (Yule)

Técnicamente lo que sucede es lo siguiente:

- Si tenemos dos variables y_t y x_t tal que:

$$y_t = \alpha + y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

$$x_t = \lambda + x_{t-1} + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

donde v_t y ε_t están incorrelacionadas entre sí.

- Ambas variables, al ser RW, presentan tendencias estocásticas.
- Si hacemos una regresión de y_t en función de x_t , ¿qué esperan observar?

$$\beta \rightarrow 0$$


$$R^2 \rightarrow 0$$

Simulando datos

Sin embargo, para $T = 100$ se simularon los siguientes procesos:

$$y_t = 2 + y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$$

$$x_t = -1 + x_{t-1} + v_t, \quad v_t \sim N(0, 1)$$



Simulando datos

Y a través de la estimación por MCO del siguiente modelo:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

```
Call:
lm(formula = y ~ x)

Residuals:
    Min       1Q   Median       3Q      Max
-7.296 -2.786 -1.225  3.259 10.850

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.53258    0.83702   -3.026  0.00317 **
x            -1.48623    0.01123  -132.388 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.181 on 98 degrees of freedom
Multiple R-squared:  0.9944,    Adjusted R-squared:  0.9944
F-statistic: 1.753e+04 on 1 and 98 DF,  p-value: < 2.2e-16
```

Regresión entre variables $I(1)$

- Tanto la variable y_t como x_t son $I(1)$.

Regresión entre variables $I(1)$

- Tanto la variable y_t como x_t son $I(1)$.
- Se simularon en forma independiente, por lo que sabemos que no existe una relación causal entre ellas.

Regresión entre variables $I(1)$

- Tanto la variable y_t como x_t son $I(1)$.
- Se simularon en forma independiente, por lo que sabemos que no existe una relación causal entre ellas.
- Sin embargo, los resultados por MCO muestran que:

$$|t_{\beta_1=0}| \xrightarrow{d} \infty, \quad \lim R^2 = 1, \quad DW \rightarrow 0$$

- Estos resultados sugieren que:
 - Si nuestras variables muestran un comportamiento tendencial (en este caso, de tipo estocástico) a lo largo del tiempo, los resultados de la regresión son potencialmente espurios.
 - No podemos aprender nada sobre la relación entre variables en nivel que son $I(1)$ a partir de un modelo de regresión simple.

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.
- Este problema no desaparece ni aumentando T .

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.
- Este problema no desaparece ni aumentando T .
- El problema está generado por el uso de valores críticos equivocados (Granger dixit).

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.
- Este problema no desaparece ni aumentando T .
- El problema está generado por el uso de valores críticos equivocados (Granger dixit).
- En una regresión espuria los residuos estarán autocorrelacionados y los estadísticos t mal calculados ya que se está usando un estimador inconsistente de la varianza residual.


¿Qué hacemos?

- ¿Cómo detectamos si la regresión es espuria (entre series $I(1)$)?

Analizar los correlogramas y hacer algún test de raíz unitaria sobre los residuos

Estudiando los residuos

Veamos los residuos de la estimación anterior...



Date: 07/22/15 Time: 11:24
Sample: 2 100
Included observations: 99

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.894	0.894	81.558	0.000
		2 0.772	-0.136	142.99	0.000
		3 0.668	0.029	189.49	0.000
		4 0.566	-0.068	223.21	0.000
		5 0.468	-0.039	246.47	0.000
		6 0.379	-0.021	261.91	0.000
		7 0.314	0.052	272.63	0.000
		8 0.262	-0.000	280.17	0.000
		9 0.190	-0.142	284.18	0.000
		10 0.123	-0.013	285.87	0.000
		11 0.078	0.038	286.56	0.000
		12 0.074	0.163	287.19	0.000


```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-3.767 -1.494 -0.131  1.356  4.343
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.112139   0.377093  -0.297   0.767
z.lag.1      -0.070117   0.046871  -1.496   0.138
tt           0.004676   0.006523   0.717   0.475
z.diff.lag   -0.028249   0.104595  -0.270   0.788
```

```
Residual standard error: 1.822 on 94 degrees of freedom
Multiple R-squared:  0.03222,    Adjusted R-squared:  0.001333
F-statistic: 1.043 on 3 and 94 DF,  p-value: 0.3772
```

Value of test-statistic is: -1.496 1.0891 1.3707

Critical values for test statistics:

```
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

¿Qué hacemos?

- **¿Cómo convertimos una regresión espuria en una válida?**
Tomando diferencias en ambos lados de la regresión (Modelo en diferencias) → solución de los años 70'.

$$\Delta y_t = \beta_0 + \beta_1 \Delta x_t + \Delta u_t$$

$I(0)$ $I(0)$ $I(0)$

Modelo en Primeras Diferencias

Una forma de lidiar con el problema de la regresión espuria entre variables $I(1)$ es trabajar con el modelo en primeras diferencias.

- $\Delta y_t = y_t - y_{t-1}$
- $\Delta x_t = x_t - x_{t-1}$
- Si queríamos estimar:

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t$$

- El modelo en diferencias sería:

$$\Delta y_t = \beta_1 + \beta_2 \Delta x_t + u_t, \quad u_t = \Delta \varepsilon_t$$


- Esto se puede extender a un modelo más general.

Modelo en Primeras Diferencias

En nuestro ejemplo anterior en el cual generamos:

$$y_t = 2 + y_{t-1} + \varepsilon_t \Rightarrow \Delta y_t = 2 + \varepsilon_t$$

$$x_t = -1 + x_{t-1} + v_t \Rightarrow \Delta x_t = -1 + v_t$$



```
Call:
lm(formula = Dy ~ Dx)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-2.67358 -0.63637  0.03516  0.73890  2.19442
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.92783   0.16194   11.90  <2e-16 ***
Dx          -0.01294   0.09980   -0.13   0.897
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.033 on 97 degrees of freedom
Multiple R-squared:  0.0001732, Adjusted R-squared:  -0.01013
F-statistic: 0.01681 on 1 and 97 DF,  p-value: 0.8971
```

¿Qué hacemos?

- **¿Resuelve esta transformación el problema?**

*Lo resuelve desde el punto de vista estadístico, pero desde el punto de vista económico **no podríamos modelar la (eventual) relación en niveles.** La información contenida en una regresión en tasas de crecimiento **no** es la misma que en una regresión en niveles.*

¿Qué hacemos?

- ¿Resuelve esta transformación el problema?

*Lo resuelve desde el punto de vista estadístico, pero desde el punto de vista económico **no** podríamos modelar la (eventual) relación en niveles. La información contenida en una regresión en tasas de crecimiento **no** es la misma que en una regresión en niveles.*

- ¿Entonces? ¿Se puede estimar una regresión en niveles entre variables $I(1)$?

*Sí, si los errores son $I(0)$ $\Rightarrow$ **COINTEGRACIÓN***

Cointegración

Definición

Los componentes del vector $x_t = (x_{1t}, x_{2t}, \dots, x_{nt})'$ están cointegrados si:

- Todos los componentes de x_t son integrados de orden d .
- Existe un vector $\beta = (\beta_1, \beta_2, \dots, \beta_n)$ tal que la combinación lineal $\beta x_t = \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_n x_{nt}$ es integrado de orden $(d - b)$, donde $b > 0$.

El vector β se conoce como el **vector de cointegración**.

$x_t \sim CI(d, b)$. Entonces si:

- $x_t \sim CI(1, 1)$: las variables son $I(1)$ y existe una combinación lineal de ellas que es $I(0)$.
- $x_t \sim CI(2, 1)$: las variables son $I(2)$ y existe una combinación lineal de ellas que es $I(1)$.

Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.

Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.
- Una alternativa, es evaluar si las variables en cuestión (ambas con el mismo orden de integración) están **cointegradas**.

Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.
- Una alternativa, es evaluar si las variables en cuestión (ambas con el mismo orden de integración) están **cointegradas**.
- La **cointegración** se da cuando existe una combinación lineal de 2 o más variables $I(1)$ (o de orden superior, pero iguales) que resulta ser estacionaria (o de orden inferior).


Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.
- Una alternativa, es evaluar si las variables en cuestión (ambas con el mismo orden de integración) están **cointegradas**.
- La **cointegración** se da cuando existe una combinación lineal de 2 o más variables $I(1)$ (o de orden superior, pero iguales) que resulta ser estacionaria (o de orden inferior).
- Una **relación de cointegración** se puede interpretar como una relación de equilibrio de largo plazo (estacionaria). Si bien las variables pueden desviarse de su relación en el corto plazo.

Ejemplos (famosos) de cointegración

- La función consumo
- La PPP
- Precios spot y futuros (evaluación de la hipótesis de mercados eficientes)
- Demanda de dinero
- Precios de acciones y dividendos

Precio spot y futuro de la soja - en Chicago



¿Qué observan?

Ejemplo

Demanda de dinero:

$$m_t = \beta_0 + \beta_1 p_t + \beta_2 y_t + \beta_3 r_t + \varepsilon_t$$

donde,

- m_t = demanda de dinero
- p_t = nivel de precios
- y_t = ingreso real
- r_t = tasa de interés
- ε_t = término de error **estacionario**

Todas las variables están en logaritmos, salvo la tasa de interés.

Nota: no hace falta que ε_t sea ruido blanco, sino tan solo que sea estacionario.

Ejemplo

El problema al que nos enfrentamos es que m_t , p_t , y_t y r_t suelen ser variables $I(1)$. La **cointegración** implica una combinación lineal estacionaria de dichas variables:

$$\varepsilon_t = m_t - \beta_0 - \beta_1 p_t - \beta_2 y_t - \beta_3 r_t$$

¡Entonces ε_t debe ser estacionario!

Esto implica una relación de equilibrio (de largo plazo) entre variables no estacionarias, es decir, sus tendencias estocásticas están relacionadas.

Cointegración y tendencias comunes

Una forma útil de entender una relación de cointegración es la observación que hicieron Stock y Watson (1988) sobre variables cointegradas que **comparten tendencias estocásticas**.

Cointegración y tendencias comunes

Una forma útil de entender una relación de cointegración es la observación que hicieron Stock y Watson (1988) sobre variables cointegradas que **comparten tendencias estocásticas**.

Vayamos al caso simple. Ignorando los componentes cíclicos y estacionales, podemos escribir cada una de estas variables en función de un RW + un componente irregular (estacionario, no necesariamente RB):

$$y_t = \mu_{yt} + e_{yt}$$

$$x_t = \mu_{xt} + e_{xt}$$

donde μ_{yt} y μ_{xt} son 2 RW que representan cada tendencia estocástica.

Cointegración y tendencias comunes

Si y_t y x_t son $I(1)$, debe existir valores no nulos de β_1 y β_2 para los cuales la combinación lineal $\beta_1 y_t + \beta_2 x_t$ es estacionaria.

$$\begin{aligned}\beta_1 y_t + \beta_2 x_t &= \beta_1(\mu_{yt} + e_{yt}) + \beta_2(\mu_{xt} + e_{xt}) \\ &= (\beta_1 \mu_{yt} + \beta_2 \mu_{xt}) + (\beta_1 e_{yt} + \beta_2 e_{xt})\end{aligned}$$

Para que $\beta_1 y_t + \beta_2 x_t$ sea estacionario, el término $(\beta_1 \mu_{yt} + \beta_2 \mu_{xt})$ debe desaparecer (se cancelan las tendencias):

$$\beta_1 \mu_{yt} + \beta_2 \mu_{xt} = 0$$

$$\mu_{yt} = -(\beta_2/\beta_1)\mu_{xt}$$

Entonces, para valores no nulos de β_1 y β_2 , la única manera de garantizar la igualdad es que las tendencias estocásticas sean iguales (por un escalar $-\beta_2/\beta_1$) $\Rightarrow$ **tendencias comunes.**

La metodología de Engle & Granger (1987)

Engle & Granger (1987) proponen que la relación de largo plazo puede ser fácilmente obtenida, si:

$$\begin{matrix} y_t & = & K & x_t & + & u_t \\ I(1) & & & I(1) & & I(0) \end{matrix}$$

La metodología de E&G consiste en:

- (1) Estimar la relación anterior
- (2) Obtener el residuo $\hat{u}_t$
- (3) Evaluar si el residuo es $I(0)$ a través de un test de raíz unitaria (con valores críticos tabulados por Engle y Granger, 1987)
- (4) En caso de ser $I(0)$, y_t y x_t están cointegradas.
- (5) ¿Se puede estimar una relación de largo plazo sin caer en el problema de la regresión espuria!

- En **STATA**: `egranger`
- En **R**: `egcm()` usar el package `egcm`
- En **EViews**: seleccionar las variables, abrirlas como grupo e ir a View/Cointegration Test/Single-equation Cointegration Test....

Utilice la base: soja.xls que contiene datos sobre el precio spot y futuro en Chicago entre 1979M01 y 2012M05.

- Exprese ambas variables en logaritmos y grafique conjuntamente. ¿Qué observa?
- Determine el orden de integración de cada variable
- Estime la regresión en niveles. Obtenga los residuos. Gráfíquelos y obtenga los correlogramas. Comente.
- Siguiendo la metodología de Engle y Granger, evalúe si las series están cointegradas.

Modelo de corrección de errores

Modelo de Corrección de Errores (MCE)

- Una vez que se encontró evidencia de cointegración entre dos o más variables, se puede estimar un **modelo de corrección de errores** (MCE).
- Un MCE permite explicar las tasas de crecimiento de y_t (Δy_t) en función de:
 - el crecimiento en x_t (Δx_t), y
 - el desequilibrio pasado entre los niveles de y_t y x_t .
- Estos modelos también son conocidos como **modelos de corrección al equilibrio** (MCEq).

Reparametrización de un modelo ADL

Partimos de un problema de autocorrelación. Sea,

$$y_t = x_t' \beta + u_t$$

$$u_t = \phi u_{t-1} + \varepsilon_t \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Entonces,

$$y_t = x_t' \beta + \phi[y_{t-1} - x_{t-1}' \beta] + \varepsilon_t$$

$$y_t = x_t' \beta + \phi y_{t-1} - x_{t-1}' \beta \phi + \varepsilon_t \quad \text{Modelo AD(1,1)}$$

Un **MCE** es una re-parametrización de un modelo AD(1,1) sin pérdida de información e independientemente de si las variables son integradas o no.

Reparametrización de un modelo ADL

A partir de un AD(1,1):

$$y_t = \beta_1 x_t + \beta_2 x_{t-1} + \beta_3 y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \beta_1 x_t + \beta_2 x_{t-1} + (\beta_3 - 1)y_{t-1}$$

$$\Delta y_t = \beta_1 \Delta x_t + (\beta_1 + \beta_2)x_{t-1} + (\beta_3 - 1)y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \beta_1 \Delta x_t - (1 - \beta_3) \left[y_{t-1} - \frac{\beta_1 + \beta_2}{1 - \beta_3} x_{t-1} \right] + \varepsilon_t \quad \text{(MCE)}$$

donde:

- $\frac{\beta_1 + \beta_2}{1 - \beta_3} = K$ (coeficiente de largo plazo)
- $(1 - \beta_3) = \alpha$ (coeficiente de ajuste, $0 \leq \alpha \leq 1$)

Modelo de Corrección de Errores (MCE)

Notar que:

$$y_t = \beta_1 x_t + \beta_2 x_{t-1} + \beta_3 y_{t-1} + \varepsilon_t$$

$I(1) \quad I(1) \quad I(1) \quad I(1) \quad I(0)$

$$\Delta y_t = \beta_1 \Delta x_t + (\beta_1 + \beta_2) x_{t-1} + (\beta_3 - 1) y_{t-1} + \varepsilon_t$$

$I(0) \quad I(0) \quad I(1) \quad I(1) \quad I(0)$

$$\Delta y_t = \beta_1 \Delta x_t - (1 - \beta_3) \left(y_{t-1} - \frac{\beta_1 + \beta_2}{1 - \beta_3} x_{t-1} \right) + \varepsilon_t$$

$I(0) \quad I(0) \quad I(0)$

Necesitamos que el **término de corrección de errores (TCE)**:

$$\left(y_{t-1} - \frac{\beta_1 + \beta_2}{1 - \beta_3} x_{t-1} \right)$$

sea $I(0)$ para que balancee en el sentido de Granger.

Modelo de Corrección de Errores (MCE)

El MCE es un modelo en diferencias aumentado por el término:

$$[y_{t-1} - Kx_{t-1}]$$

En el largo plazo (estado estacionario):

$$x_t = x_{t-1} \qquad y_t = y_{t-1}$$

$$\Rightarrow y_t = Kx_t$$

donde K es el efecto de largo plazo de x_t sobre y_t .

Entonces, existe una especie de corrección, dada por $-(1 - \beta_3)$, para alcanzar la relación de largo plazo.

Ventaja: el MCE implica una modelación conjunta de la dinámica (corto plazo) y del largo plazo

La metodología de Engle & Granger (1987)

Propiedades:

- Granger mostró que la existencia de COI implica necesariamente un MCE y a su vez, si existe un MCE entre variables integradas, existe una relación de cointegración (Teorema de Representación de Granger).
- Cuando existe COI, la tasa de convergencia de la distribución de los estimadores de OLS es a T y no a $\sqrt{T} \Rightarrow \hat{K}$ es super-consistente ya que converge a una tasa más rápida.
- Si existe COI, la solución es **única**, el K es único.

Retome el ejemplo del precio spot y futuro en Chicago entre 1979M01 y 2012M05.

- Estime un MCE para el precio spot de la soja (únicamente en función del precio futuro)

Aplicación - Enders (2010)

Utilice la base de datos COINT6.XLS del libro de Enders que contiene 3 series ficticias (y , z , w) para ilustrar la metodología de Engle & Granger. Se pide:

- (1) Inspeccione visualmente las series
- (2) Determine el orden de integración de las series.
- (3) Estime una regresión de equilibrio de largo plazo de y_t en función de w_t y z_t . ¿Están cointegradas?
- (4) Los coeficientes estimados NO tienen una distribución asintótica t de Student si el término de error no es IID. Evalúe.
- (5) Estime el siguiente MCE:

$$\Delta y_t = \delta + \alpha TCE_{t-1} + \beta_1 \Delta y_{t-1} + \beta_2 \Delta w_{t-1} + \beta_3 \Delta z_{t-1} + \varepsilon_t$$

- (6) Interprete los coeficientes.

- Ahumada, H. (2006) “Una nota sobre regresiones con variables integradas”, *Ensayos Económicos* 45, 79-94.
- Banerjee et al. (1993) - Cap. 5 a 7
- Hendry, D.F. & Juselius, K. (2000) “Explaining Cointegration Analysis: Part 1”, *The Energy Journal* 21(1): 1-42.