

Cointegración en Sistemas de Ecuaciones

Econometría de Series de Tiempo

Magdalena Cornejo

mcornejo@utdt.edu

Maestrías en Economía y Finanzas, Universidad de San Andrés

Introducción

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.
- Así, la cointegración podría variar de acuerdo a la variable seleccionada en la normalización.

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.
- Así, la cointegración podría variar de acuerdo a la variable seleccionada en la normalización.
- Podría existir más de una relación de cointegración cuando usamos varias variables.

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.
- Así, la cointegración podría variar de acuerdo a la variable seleccionada en la normalización.
- Podría existir más de una relación de cointegración cuando usamos varias variables.
- El procedimiento de E&G implica una estimación en 2 etapas: (1) generar los residuos; (2) usar esos residuos en $t - 1$ en la estimación del MCE.

Alternativamente, podemos usar el enfoque **multivariado** en Johansen (1988, 1991). Metodología: **Johansen-Juselius**.

Enfoque de Johansen-Juselius

El procedimiento de Johansen es una **especie de generalización multivariada del test de Dickey-Fuller.**

En forma univariada vimos que:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t \quad \text{o}$$
$$\Delta y_t = (\phi_1 - 1) y_{t-1} + \varepsilon_t$$

Si $(\phi_1 - 1) = 0$, entonces el proceso $\{y_t\}$ tiene una raíz unitaria.

Un ADF multivariado

Ahora consideren una simple generalización a n variables:

$$x_t = \Phi_1 x_{t-1} + \varepsilon_t$$

Entonces,

$$\begin{aligned}\Delta x_t &= \Phi_1 x_{t-1} - x_{t-1} + \varepsilon_t \\ &= (\Phi_1 - I) x_{t-1} + \varepsilon_t \\ &= \pi x_{t-1} + \varepsilon_t\end{aligned}$$

donde:

- x_t y ε_t son vectores ($n \times 1$).
- Φ_1 es una matriz ($n \times n$) de parámetros.
- I es la matriz ($n \times n$) identidad.
- π se define como $(\Phi_1 - I)$

$$\Delta x_t = \pi x_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim IN(0, \Omega)$$

Para evaluar cointegración tenemos que **analizar el rango de la matriz π .**

Ejemplo - BIVAR(1)

$$\begin{cases} y_t = \phi_{11}y_{t-1} + \phi_{12}x_{t-1} + \varepsilon_{1t} \\ x_t = \phi_{21}y_{t-1} + \phi_{22}x_{t-1} + \varepsilon_{2t} \end{cases}$$

Entonces,

$$\begin{cases} \Delta y_t = (\phi_{11} - 1)y_{t-1} + \phi_{12}x_{t-1} + \varepsilon_{1t} \\ \Delta x_t = \phi_{21}y_{t-1} + (\phi_{22} - 1)x_{t-1} + \varepsilon_{2t} \end{cases}$$

donde:

$$\pi = \begin{bmatrix} \phi_{11} - 1 & \phi_{12} \\ \phi_{21} & \phi_{22} - 1 \end{bmatrix} = \begin{bmatrix} \pi_{11} & \pi_{12} \\ \pi_{21} & \pi_{22} \end{bmatrix}$$

El rango de la matriz π

Nos podemos encontrar con 3 casos:

- $r(\pi) = 0$
- $r(\pi) = n$
- $r(\pi) = r < n$ (cointegración)

En el caso del BIVAR las posibilidades son:

- $r(\pi) = 0$
- $r(\pi) = 2$
- $r(\pi) = 1$ (cointegración)

Si $r(\pi) = 0$

Cada elemento de π debe ser igual a cero por lo que:

$$\Delta x_t = \varepsilon_t$$

Es un VAR en primeras diferencias.

Dado que cada $x_{it} = x_{it-1} + \varepsilon_{it}$, todas las secuencias $\{x_{it}\}$ son procesos random walk (I(1)) y no existe una combinación lineal de las variables que sea estacionaria $\Rightarrow$ **no hay cointegración.**

Si $r(\pi) = n$ (rango completo)

$$\Delta x_t = \pi x_{t-1} + \varepsilon_t$$

Entonces, la solución de largo plazo de la ecuación anterior está dada por n ecuaciones independientes:

$$\pi_{11}x_{1t} + \pi_{12}x_{2t} + \dots + \pi_{1n}x_{nt} = 0$$

$$\pi_{21}x_{1t} + \pi_{22}x_{2t} + \dots + \pi_{2n}x_{nt} = 0$$

$$\vdots$$

$$\pi_{n1}x_{1t} + \pi_{n2}x_{2t} + \dots + \pi_{nn}x_{nt} = 0$$

En este caso, cada una de las n variables contenidas en el vector x_t debe ser estacionaria por lo que dichas variables no cointegran.

Si $r(\pi) < n$

En **casos intermedios**, en los que el rango de π es igual a $r < n$, existen r **vectores de cointegración**.

Con r ecuaciones independientes y n variables, existen $n - r$ **tendencias estocásticas** en el sistema.

Determinando el rango de la matriz π

Entonces el **objetivo** es determinar el rango de la matriz π que nos indicaría el número de vectores cointegrados. Esto puede realizarse evaluando la significatividad de las raíces características de π .

Recordar: el rango de la matriz es igual al nro de sus raíces características diferentes de cero.

Pruebas de cointegración

Test de cointegración

En la práctica, estimamos π y sus raíces características, ordenamos en forma descendente las n raíces características

$(\lambda_1 > \lambda_2 > \dots > \lambda_n)$ y existen dos tests relevantes posibles:

- Test de traza
- Test del máximo autovalor

Test de cointegración

En la práctica, estimamos π y sus raíces características, ordenamos en forma descendente las n raíces características

$(\lambda_1 > \lambda_2 > \dots > \lambda_n)$ y existen dos tests relevantes posibles:

- Test de traza
- Test del máximo autovalor

En ambos casos, la H_0 es la de **ausencia de cointegración**.

Test de cointegración

En la práctica, estimamos π y sus raíces características, ordenamos en forma descendente las n raíces características

$(\lambda_1 > \lambda_2 > \dots > \lambda_n)$ y existen dos tests relevantes posibles:

- Test de traza
- Test del máximo autovalor

En ambos casos, la H_0 es la de **ausencia de cointegración**.

Estimamos $\hat{\pi}$ por máxima verosimilitud y obtenemos $\hat{\lambda}_i$.

Bajo H_0 : $r(\pi)=0 \Rightarrow \lambda_i = 0, i = 1, 2, \dots, n$.

O, de forma equivalente,

$$\ln(1 - \lambda_i) = 0, \quad i = 1, 2, \dots, n$$

$$H_0 : \text{rango}(\pi) \leq r$$

$$H_1 : \text{rango}(\pi) > r$$

$$\lambda_{tr}(r) = -T \sum_{i=r+1}^n \ln(1 - \hat{\lambda}_i)$$

Evalúa si los autovalores $r, r + 1, \dots, n$ son conjuntamente no significativos.

Ejemplo

Si $r = 0$, H_0 es la hipótesis de no-cointegración vs. la alternativa de 'al menos un vector de cointegración'.

$$H_0 : \text{rango}(\pi) = r$$

$$H_1 : \text{rango}(\pi) = r + 1$$

$$\lambda_{\max}(r) = -T \cdot \ln(1 - \hat{\lambda}_{r+1})$$

Evalúa si uno de los autovalores es estadísticamente distinto de cero.

Ejemplo

Si $r = 0$, H_0 es la hipótesis de no-cointegración vs. la alternativa de 'un vector de cointegración'.

- En **STATA**: `vecrank`
- En **R**: `ca.jo()` usar el package `urca`
- En **EViews**: seleccionar las variables, abrirlas como grupo e ir a View/Cointegration Test/Johansen System Cointegration Test....

Prueba de cointegración

Al igual que en un test ADF, ¡los valores críticos dependen de los componentes determinísticos!

$$\Delta y_t = \alpha(\beta y_{t-1} + \mu + \rho t) + \sum_{j=1}^p \Gamma_j \Delta y_{t-j} + \gamma + \tau t + \varepsilon_t$$

- **Caso 1:** $\mu = 0, \rho = 0, \gamma = 0, \tau = 0$
- **Caso 2:** $\rho = 0, \gamma = 0, \tau = 0$
- **Caso 3:** $\gamma = 0, \tau = 0$
- **Caso 4:** $\tau = 0$
- **Caso 5:** todos los componentes determinísticos $\neq 0$ (RARO)

Johansen Cointegration Test X

Cointegration Test Specification

Deterministic trend assumption of test

Assume no deterministic trend in data:

☐ 1) No intercept or trend in CE or test VAR

☐ 2) Intercept (no trend) in CE - no intercept in VAR

Allow for linear deterministic trend in data:

☒ 3) Intercept (no trend) in CE and test VAR

☐ 4) Intercept and trend in CE - no intercept in VAR

Allow for quadratic deterministic trend in data:

☐ 5) Intercept and trend in CE - intercept in VAR

Summary:

☐ 6) Summarize all 5 sets of assumptions

Exog variables*

Lag intervals

1 1

Lag spec for differenced endogenous

Critical Values

☒ MHM

Size

☐ Osterwald-Lenum

* Critical values may not be valid with exogenous variables; do not include C or Trend.

Acceptar Cancelar

La función `ca.jo()` permite indicar si en el espacio de cointegración:

- no hay componentes determinísticos: `ecdet=c("none")`
- se incluye una constante: `ecdet=c("cons")`
- se incluye una tendencia: `ecdet=c("trend")`

Ejemplo. Money demand (Johansen & Juselius, 1990)

Johansen, S. & Juselius, K. (1990). Maximum likelihood estimation and inference on cointegration with applications to the demand for money. *Oxford Bulletin of Economics and Statistics*, 52, 169-210.

Datos trimestrales de Dinamarca entre 1974Q1 y 1987Q3. Utilice la base de datos `danish.xls` donde:

- $m2$ = log of the real money supply as measures by M2 deflated by a price index.
- y = log of real income.
- i^d = deposit rate on money representing a direct return on money holding.
- i^b = bond rate representing the opportunity cost of holding money.

Ejemplo. Money demand (Johansen & Juselius, 1990)

Se pide:

- (1) Grafique, evalúe la estacionariedad de cada una de las series y determine el orden de integración.
- (2) Estime un modelo VAR. Determine la longitud de rezago adecuada.
- (3) Evalúe la normalidad de los residuos (univariada y multivariada)
- (4) Realice un test de cointegración de Johansen. ¿Cuál es la solución de largo plazo?

Dummies estacionales centradas

- Su suma es cero (en lugar de uno) a lo largo del año.
- Si $D_{s,t}$ es una dummy 1-0 para la estación s en el momento t
- Una **dummy centrada** se define como:

$$D_{s,t}^* = D_{s,t} - 1/S$$

donde S es la cantidad de estaciones dentro del año (trimestres, meses, etc).

- Algunos las llaman “*orthogonalised seasonal dummies*”
- Recuerden incluir $S - 1$ dummies, siempre que incluyamos una constante en la regresión, para evitar multicolinealidad exacta.
- La razón por la que se usan es **para evitar afectar la tendencia de las variables en niveles del VAR.**

Para frecuencia trimestral:

- `genr cs1=@seas(1)-.25`
- `genr cs2=@seas(2)-.25`
- `genr cs3=@seas(3)-.25`
- `genr cs4=@seas(4)-.25`

Para frecuencia trimestral:

```
egen quarter=seq(), to(4)
tab quarter, gen(D)
forval i=1/4{
    gen CS'i'=D'i'-1/4
}
```


Generando dummies centradas - En R

Para frecuencia trimestral (a partir de una variable x):

```
CS1 <- rep(c(1, 0, 0, 0), length(x) / 4) - .25
```

```
CS2 <- rep(c(0, 1, 0, 0), length(x) / 4) - .25
```

```
CS3 <- rep(c(0, 0, 1, 0), length(x) / 4) - .25
```

```
CS4 <- rep(c(0, 0, 0, 1), length(x) / 4) - .25
```

Ejemplo. Money demand (Johansen & Juselius, 1990)

Prueben re-estimar el VAR del ejemplo anterior incluyendo dummies centradas.

- ¿Cambia el orden del VAR?
- ¿Resultan estadísticamente significativas?
- ¿Cambian las conclusiones del test de cointegración de Johansen?

VEC

Modelos VEC (Vectores de Corrección de Errores)

Bajo cointegración, un VAR admite una representación VEC.

La matriz π se puede factorizar $\pi = \alpha\beta'$.

$$\left. \begin{matrix} \alpha_{n \times r} \\ \beta_{n \times r} \end{matrix} \right\} \Rightarrow \pi_{n \times n}$$

donde:

- β será el vector de coeficientes de largo plazo
- α será el vector de coeficientes de ajuste

Ejemplo

Volvamos al BIVAR(1) y asumamos que probamos que existe $r = 1$. Entonces,

$$\Delta x_t = \pi x_{t-1} + \varepsilon_t$$

$$\Delta x_t = \alpha \beta' x_{t-1} + \varepsilon_t$$

donde

$$\alpha \beta' = \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} \begin{bmatrix} \beta_1 & \beta_2 \end{bmatrix}$$

Modelos VEC (Vectores de Corrección de Errores)

Si $r = 1$, por lo general normalizamos el largo plazo en función de una de las variables del VAR (y_t o x_t).

En nuestro ejemplo, si normalizamos en función de y_t , esto implica que:

$$\alpha\beta' = \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} \begin{bmatrix} 1 & -K \end{bmatrix}$$

El modelo VEC resulta:

$$\begin{cases} \Delta y_t = \alpha_1[y_{t-1} - Kx_{t-1}] + \varepsilon_{1t} \\ \Delta x_t = \alpha_2[y_{t-1} - Kx_{t-1}] + \varepsilon_{2t} \end{cases}$$

donde $\pi_{11} = \alpha_1$, $\pi_{21} = \alpha_2$, $\pi_{12} = -\alpha_1 K$, $\pi_{22} = -\alpha_2 K$.

Es decir, $-K = \frac{\pi_{12}}{\pi_{11}} = \frac{\pi_{22}}{\pi_{21}}$

Exogeneidad

Exogeneidad

Cuando planteamos al inicio del curso que $E(u_t|\mathbf{X}) = 0$

(**exogeneidad estricta**), esto implicaba que $E(x_t \cdot u_s) = 0 \forall t, s$.

Exogeneidad

Cuando planteamos al inicio del curso que $E(u_t|\mathbf{X}) = 0$

(**exogeneidad estricta**), esto implicaba que $E(x_t \cdot u_s) = 0 \forall t, s$.

Una variable puede estar **predeterminada** si $E(x_t \cdot u_s) = 0 \forall s \geq t$
(ej. uso de variables rezagadas).

Exogeneidad

Cuando planteamos al inicio del curso que $E(u_t|\mathbf{X}) = 0$ (**exogeneidad estricta**), esto implicaba que $E(x_t \cdot u_s) = 0 \forall t, s$.

Una variable puede estar **predeterminada** si $E(x_t \cdot u_s) = 0 \forall s \geq t$ (ej. uso de variables rezagadas).

Engle, Hendry y Richard (1983) definen 3 niveles de exogeneidad:

- **Débil** (para inferir)
- **Fuerte** (para pronosticar)
- **Super** (para evaluación de políticas)

Exogeneidad

En un modelo multivariado, una variable es **exógena respecto del parámetro de interés** (el que queremos estimar).

Modelo de la Telaraña

$$p_t = \alpha + \beta q_t + u_t \quad (\text{Demanda})$$

$$q_t = \gamma + \delta p_{t-1} + \varepsilon_t \quad (\text{Oferta})$$

donde $E(u_t) = 0$, $E(\varepsilon_t) = 0$ y $E(u_t \varepsilon_t) = 0$ (supuesto).

Si queremos estimar uniecuacionalmente la demanda, ¿es q_t exógena para estimar la inversa de β ?

Parámetro de interés: $1/\beta$ (elasticidad)

Exogeneidad (Engle, Hendry & Richard, 1983)

El concepto de **exogeneidad** no es único, hay distintos niveles que dependen del objetivo que persigamos y tienen distintos requisitos:

Exogeneidad	Objetivo	Requisitos
Débil	Inferencia	Parámetros de interés + Variation Free
Fuerte	Pronóstico	Exog. débil + No causalidad en sentido de Granger
Super	Evaluación de políticas	Exogeneidad débil + Invarianza estructural

Invarianza estructural: invarianza de los parámetros del modelo condicional ante cambios en la distribución marginal.

Exogeneidad débil

La pregunta entonces es: **¿cómo hacemos para probar exogeneidad débil?**

Exogeneidad débil

La pregunta entonces es: **¿cómo hacemos para probar exogeneidad débil?**

Volviendo al modelo VEC en el cual normalizábamos respecto de y_t :

$$\begin{cases} \Delta y_t = \alpha_1[y_{t-1} - Kx_{t-1}] + \varepsilon_{1t} \\ \Delta x_t = \alpha_2[y_{t-1} - Kx_{t-1}] + \varepsilon_{2t} \end{cases}$$

Entonces, si $\alpha_2 = 0$ decimos que y_t es la variable que ajusta y x_t es débilmente exógena. Puedo estimar un modelo uniecuacional de y_t condicional a x_t .

Si las dos variables ajustan, entonces el sistema se determina en forma conjunta.

Pulling and Pushing forces

Juselius (2006) dio una interpretación económica a las variables débilmente exógenas y las variables que ajustan en el sistema.

- **Pulling forces:** la(s) variable(s) que ajusta(n) en el sistema. Fuerzas que traccionan hacia el equilibrio de largo plazo, generando un comportamiento estacionario.
- **Pushing forces:** la(s) variable(s) débilmente exógena(s). Fuerzas que generan desvíos respecto del equilibrio.

Causalidad en sentido de Granger

Cuando vimos la metodología VAR hablamos de Causalidad en sentido de Granger.

Recordar que sólo implica precedencia temporal ($\neq$ causalidad económica). En un BIVAR(1):

$$\begin{cases} y_t = \alpha_{11}y_{t-1} + \alpha_{12}x_{t-1} + \varepsilon_{1t} \\ x_t = \alpha_{21}y_{t-1} + \alpha_{22}x_{t-1} + \varepsilon_{2t} \end{cases}$$

Decimos que x_t causa a y_t en sentido de Granger si $\alpha_{12} \neq 0$ y $\alpha_{21} = 0$. Se prueba mediante un test de restricciones.

Si probamos que x_t es débilmente exógena y además y_t no la causa en sentido de Granger, entonces x_t es **fuertemente exógena** (necesario para pronóstico).

- En **STATA**: `vec`
- En **R**: `cajorls()` usando el paquete `urca`
- En **EViews**: seleccionar las variables, abrirlas como VAR y seleccionar Vector Error Correction.

Aplicaciones

Aplicación 1. Money demand (Johansen & Juselius, 1990)

Siguiendo con el ejemplo de la demanda de dinero en Dinamarca.
Se pide:

- Evalúe la exogeneidad débil de las series.
- Evalúe la causalidad en sentido de Granger
- Estime un modelo VEC. Interprete.

Aplicación 2. Spot y futuro de soja

Utilice el archivo soja.xls de la clase pasada.

- Estime un VAR(4) para el $\ln(S)$ y el $\ln(F)$
- Evalué que el modelo no tenga autocorrelación.
- ¿Son normales los residuos?
- Evalúe cointegración (empiece por incluir una tendencia en el largo plazo y evalúe su significatividad)
- ¿Es el futuro débilmente exógeno? ¿Y fuertemente exógeno?
- Estime un modelo VEC apropiado.

Recomendaciones prácticas

- Para datos trimestrales con estacionalidad, estimar un VAR con dummies centradas y hasta 2 lags.
- Si no funcionan las dummies, usar hasta 4/5 lags.
- Si dudamos respecto del comportamiento tendencial de las series, incluir siempre una trend en el espacio de COI y luego testear si resulta significativa.
- Las dummies entran en forma irrestricta en el sistema VAR.
- Step dummies o broken trends en el espacio de cointegración implica que hay que re-calcular los valores críticos (ver Johansen et al., 2000).

- Juselius (2006) - El libro entero!
- Hendry y Juselius (2001) "Explaining Cointegration Analysis: Part II", *The Energy Journal* 22(1), 75-120.