

Modelos de Heterocedasticidad Condicional Univariados

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

Introducción

- Hasta ahora todos los modelos son lineales (en parámetros)




Motivación

- Hasta ahora todos los modelos son lineales (en parámetros)
- En finanzas, muchas relaciones son intrínsecamente no lineales

Motivación

- Hasta ahora todos los modelos son lineales (en parámetros)
- En finanzas, muchas relaciones son intrínsecamente no lineales
- Los enfoques aplicados hasta ahora no suelen ser buenos en explicar casos de:
 - Leptocurtosis (excesos de curtosis)
 - Volatilidad grupal
 - Efectos de apalancamiento
- Los modelos pueden ser: lineales en media y varianza (e.g. ARMA), lineales en media, pero no en varianza (e.g. GARCH), no lineales en media ni varianza.

- (1) Baje de **Yahoo Finance** el precio de cierre ajustado de alguna compañía en frecuencia diaria desde enero de 2006.
- (2) Grafique. ¿Qué observa? ¿Es estacionaria?
- (3) Calcule el retorno diario logarítmico. Grafique. ¿Qué observa?
- (4) Obtenga los principales estadísticos descriptivos. Comente.
- (5) Grafique el histograma. ¿Qué observa?



```
> summary(R)
      Index      Adjusted
Min.   :2006-01-04  Min.   : -12.34015
1st Qu.:2009-06-17  1st Qu.: -0.75789
Median :2012-11-28  Median :  0.04226
Mean   :2012-11-28  Mean    :  0.05045
3rd Qu.:2016-05-11  3rd Qu.:  0.91307
Max.   :2019-10-23  Max.   : 18.22511

> describe(R)
      vars  n mean sd median trimmed mad  min  max range skew kurtosis  se
Adjusted  1 3475 0.05 1.82   0.04   0.07 1.24 -12.34 18.23 30.57 0.43 10.42 0.03
```

Modelos Condicionales vs. No Condicionales

Volvamos al modelo AR(1) estacionario:

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad |\phi| < 1$$

Vimos que la media y la varianza incondicionales son:

- $E(y_t) = 0$ (por no incluir constante)
- $V(y_t) = \sigma^2 / (1 - \phi^2)$

Modelos Condicionales vs. No Condicionales

Volvamos al **modelo AR(1) estacionario**:

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad |\phi| < 1$$

Vimos que **la media y la varianza incondicionales** son:

- $E(y_t) = 0$ (por no incluir constante)
- $V(y_t) = \sigma^2 / (1 - \phi^2)$

La media y la varianza condicionales son:

- $E_t(y_t) = \phi y_{t-1} \rightarrow$ depende de t
- $V_t(y_t) = \sigma^2 \rightarrow$ no depende de t

Sin embargo, muchas series económicas/financieras tienen una varianza condicional que **varía en el tiempo (e.g. inflación, stock returns, etc.)**

Modelos Condicionales vs. No Condicionales

- En muchos casos resulta relevante estimar y pronosticar la volatilidad **condicional** de cierta variable. Consistente con la formación de expectativas racionales.
- Modelar la varianza condicional en forma correcta puede mejorar la precisión de las estimaciones que modelar o pronosticar las medias condicionales.

ARCH

Modelo ARCH (Autoregressive conditionally heteroskedastic)

Desarrollado por Engle (1982) es la forma más simple de modelar la volatilidad.

$$y_t = u_t, \quad u_t \sim N(0, \sigma_t^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 y_{t-1}^2$$

También puede expresarse como:

$$y_t = \varepsilon_t \sqrt{\alpha_0 + \alpha_1 y_{t-1}^2}, \quad \varepsilon_t \sim WN(0, 1)$$

$\{y_t\}$ se conoce como un **ARCH(1) puro**.

ARCH(1) puro

Calculemos los **momentos condicionales**:

- $E_t(y_t) = 0$
- $V_t(y_t) = E_t(y_t^2) \equiv h(t) = \alpha_0 + \alpha_1 y_{t-1}^2$

Los momentos **incondicionales** son:

- $E(y_t) = E(E_t(y_t)) = 0$
- $V(y_t) = E(y_t^2) = E(E_t(y_t^2)) = \alpha_0 + \alpha_1 E(y_{t-1}^2)$

$$\text{Si } |\alpha_1| < 1, \quad V(y_t) = E(y_t^2) = \frac{\alpha_0}{1 - \alpha_1}$$

ARCH(1) puro

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.
- Media condicional constante y nula; varianza condicional *no constante*.

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.
- Media condicional constante y nula; varianza condicional *no constante*.
- La varianza condicional depende de cuán largas fueron las desviaciones respecto de la media (y_{t-1}^2) en los períodos anteriores.

ARCH(1) puro

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.
- Media condicional constante y nula; varianza condicional *no constante*.
- La varianza condicional depende de cuán largas fueron las desviaciones respecto de la media (y_{t-1}^2) en los períodos anteriores.
- Si $\alpha_1 = 0$ es un simple proceso ruido blanco.

Podríamos querer estimar el siguiente modelo:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad u_t \sim N(0, \sigma_t^2)$$


donde:

$$u_t = \varepsilon_t \sigma_t, \quad \varepsilon_t \sim N(0, 1)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2$$

Los errores siguen un proceso ARCH(1).

Ejemplo simulado para $T = 1000$

$$y_t = \varepsilon_t \sqrt{1 + 0,8y_{t-1}^2}, \quad \varepsilon_t \sim N(0, 1)$$



Código para replicar en R

```
#Magdalena Cornejo#  
#UNLP 2019 - Econometria de Series de Tiempo#  
#Simulando procesos ARCH#  
  
library(rugarch)  
arch1.spec = ugarchspec(variance.model=list(garchOrder  
      =c(1,0)), mean.model=list(armaOrder=c(0,0)), fixed  
      .pars=list(mu = 0, omega=1, alpha1=0.8))  
class(arch1.spec)  
arch1.spec  
set.seed(123)  
arch1.sim = ugarchpath(arch1.spec, n.sim=1000)  
class(arch1.sim)  
slotNames(arch1.sim)  
names(arch1.sim@path)  
  
plot.ts(arch1.sim@path$seriesSim)
```

ARCH(q)

Extensión permitiendo que la varianza del error dependa de los q rezagos de los errores al cuadrado.

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad u_t \sim N(0, \sigma_t^2)$$

$$u_t = \varepsilon_t \sigma_t, \quad \varepsilon_t \sim N(0, 1)$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \dots + \alpha_q u_{t-q}^2$$

Muchas veces en la literatura se llama h_t a σ_t^2 , es decir,

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad u_t \sim N(0, h_t)$$

$$h_t = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \dots + \alpha_q u_{t-q}^2$$

Test ARCH

Antes de estimar un modelo ARCH, podemos realizar el test de Engle (1982) para determinar si hay “**efectos ARCH**” presentes en los residuos del modelo estimado siguiendo estos pasos:

(1) Estimar el modelo:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t$$

(2) Obtener $\hat{u}_t$.

(3) Regresar los $\hat{u}_t^2$ en función de sus propios q rezagos:

$$\hat{u}_t^2 = \gamma_0 + \gamma_1 \hat{u}_{t-1}^2 + \gamma_2 \hat{u}_{t-2}^2 + \dots + \gamma_q \hat{u}_{t-q}^2 + \varepsilon_t$$

(4) Obtener el R^2 y construir el estadístico $T.R^2 \sim \chi^2(q)$.

(5) Las hipótesis nula y alternativa son:

$$H_0 : \gamma_1 = \gamma_2 = \dots = \gamma_q = 0$$

$$H_1 : \text{algún } \gamma_i \neq 0 \quad \forall i = 1, \dots, q$$

- En **STATA**: `estat archlm`
- En **R**: `arch.test()` del paquete `aTSA`.
- En **EViews**: luego de la estimación: View/Residual Diagnostics/Heteroskedasticity Tests... ARCH (indicar q).

Utilice la base de datos `currencies.xls` que contiene 1827 observaciones diarias de distintos tipos de cambio. Se pide:

- (1) Grafique la serie `rgbp` que corresponde a las variaciones diarias de la libra respecto dólar.
- (2) Grafique su histograma.
- (3) Realice un test de normalidad de la variable.
- (4) Estime un modelo $AR(1)$. Evalúe que los residuos sean ruido blanco.
- (5) Realice un test sobre los residuos para evaluar efectos ARCH. ¿Qué observa?

Los modelos ARCH en sí mismos han sido poco utilizados dado que conllevan varias dificultades:

- ¿Cómo determina el valor de q ? Una posibilidad es usar el test LR.

Los modelos ARCH en sí mismos han sido poco utilizados dado que conllevan varias dificultades:

- ¿Cómo determina el valor de q ? Una posibilidad es usar el test LR.
- El valor de q eventualmente podría ser muy alto. Modelos no parsimoniosos.

Los modelos ARCH en sí mismos han sido poco utilizados dado que conllevan varias dificultades:

- ¿Cómo determina el valor de q ? Una posibilidad es usar el test LR.
- El valor de q eventualmente podría ser muy alto. Modelos no parsimoniosos.
- Las restricciones de no-negatividad podrían ser violadas.

Estimación del modelo ARCH(q)

En la especificación del modelo ARCH asumimos normalidad residual condicional:

$$Y_t/\Omega_t \sim N(0, h_t)$$

Recordar que para cualquier variable aleatoria normal X:

- Asimetría = $E(X_t - \mu)^3/\sigma^3 = 0$
- Curtosis = $E(X_t - \mu)^4/\sigma^4 = 3$

Estimación del modelo ARCH(q)

En la especificación del modelo ARCH asumimos normalidad residual condicional:

$$Y_t/\Omega_t \sim N(0, h_t)$$

Recordar que para cualquier variable aleatoria normal X:

- Asimetría = $E(X_t - \mu)^3/\sigma^3 = 0$
- Curtosis = $E(X_t - \mu)^4/\sigma^4 = 3$


Para el caso del ARCH:

- Asimetría = $E(Y_t^3) = E(E_t(Y_t)^3) = 0$
- Curtosis = $E(Y_t^4)/\sigma^4 = 3(1 - \alpha_1^2)/(1 - 3\alpha_1^2) > 3$

Colas más pesadas que una distribución normal.

Estimación del modelo ARCH(q)

Si miramos el histograma de los residuos de la aplicación anterior:



Series: Residuals
Sample 7/08/2002 7/07/2007
Observations 1826

Mean	1.38e-06
Median	0.009370
Maximum	1.774710
Minimum	-2.092157
Std. Dev.	0.412764
Skewness	0.050398
Kurtosis	5.141247

Jarque-Bera	349.6103
Probability	0.000000

Estimación del modelo ARCH(q)

Consideremos un proceso ARCH bajo normalidad condicional

$$y_t | \Omega_t \sim N(x_t' \beta, \sigma_t^2), \quad \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2, \quad \varepsilon_t \equiv y_t - x_t' \beta$$

Dado que el modelo es no lineal en los parámetros a estimar de la varianza condicional, el método de estimación será el de **Máxima Verosimilitud**. Se busca maximizar el logaritmo de la función de verosimilitud:

$$L = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log(\sigma_t^2) - \frac{1}{2} \sum_{t=1}^T (y_t - x_t' \beta)^2 / \sigma_t^2$$

- En **STATA**: arch
- En **R**: `ugarchfit()` dentro del paquete `rugarch` o `garchFit()` dentro del paquete `fGarch` (existen otros paquetes) .
- En **EViews**: ir a Quick/Estimation/Method/ARCH

```

Title:
  GARCH Modelling

Call:
  garchFit(formula = RGBP ~ arma(1, 0) + garch(1, 0))

Mean and Variance Equation:
  data ~ arma(1, 0) + garch(1, 0)
<environment: 0x0000000018c14fa0>
  [data = fGarch::dem2gbp]

Conditional Distribution:
  norm

Coefficient(s):
              mu              ar1              omega              alpha1
-0.00163520    0.00080844    0.14652820    0.37080537

Std. Errors:
  based on Hessian

Error Analysis:
      Estimate  Std. Error  t value      Pr(>|t|)
mu      -0.0016352    0.0093710   -0.174      0.861
ar1      0.0008084    0.0296164    0.027      0.978
omega    0.1465282    0.0064137   22.846 <0.0000000000000002 ***
alpha1   0.3708054    0.0438546    8.455 <0.0000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Log Likelihood:
  -1206.532      normalized:  -0.6112118

Description:
  wed Aug 21 13:39:51 2019 by user: mcornejo

```

No-normalidad y máxima verosimilitud

El supuesto de normalidad condicional en los errores es esencial para especificar la función de verosimilitud. Es posible evaluar la no-normalidad siguiendo la siguiente representación:

$$u_t = \varepsilon_t \sigma_t, \quad \varepsilon_t \sim N(0, 1)$$
$$\sigma_t = \sqrt{\alpha_0 + \alpha_1 u_{t-1}^2}$$

Recordemos que u_t es $N(0, \sigma_t^2)$ por lo que no es normal, ya que tiene colas pesadas ($K > 3$). Un método factible para evaluar la normalidad condicional es construir el siguiente estadístico:

$$\varepsilon_t = \frac{u_t}{\sigma_t}$$

Se asume que ε_t se distribuye en forma normal, no u_t .

No-normalidad y máxima verosimilitud

La versión muestral será:

$$\hat{\varepsilon}_t = \frac{\hat{u}_t}{\hat{\sigma}_t}$$

Y se conoce como **residuo estandarizado**. Entonces podemos aplicar los test estándar de normalidad sobre $\hat{\varepsilon}_t$ como el Jarque-Bera.

En la práctica, $\hat{\varepsilon}_t$ probablemente siga siendo aún leptocúrtica, aunque menos que $\hat{u}_t$.



No-normalidad y máxima verosimilitud

Incluso aunque el supuesto de distribución normal condicional no se mantenga, los parámetros estimados serán consistentes si el modelo está bien especificado.

El problema estará en los errores estándares estimados por lo que debería usarse un estimador diferente de la matriz de var-cov robusta a la no normalidad: **quasi-maximum likelihood, QML** (ML con errores estándar de Bollerslev-Wooldridge).

- En **STATA**: con la opción `vce(robust)`.
- En **R**: `uGARCHfit()` arroja la versión robusta de los SE dentro del paquete `rugarch`.
- En **EViews**: en la ventana de especificación del modelo ARCH, ir a la solapa de `Options` y seleccionar `Heteroskedasticity consistent covariance (Bollerslev-Wooldridge)`.

Comparación de los histogramas de $\hat{u}_t$ y $\hat{\varepsilon}_t$



- (1) Volver a usar los datos de retornos diarios del principio de la clase.
- (2) Elevarlos al cuadrado.
- (3) Graficar los correlogramas de los retornos mensuales al cuadrado. Comente.
- (4) Estime un modelo ARCH e identifique el orden apropiado.
- (5) Evalúe la normalidad.

- Una extensión natural de los modelos ARCH son los **GARCH** (muy utilizados en la práctica).
- Los modelos GARCH permiten tanto componentes autorregresivos como de medias móviles en la varianza heterocedástica.
- También veremos extensiones al modelo GARCH como el EGARCH, IGARCH, GARCH-in-mean.

GARCH

Modelo GARCH - Bollerslev (1986) y Taylor (1986)

Permite que la varianza condicional dependa de propios rezagos.

Caso más simple: GARCH(1,1):

$$y_t = u_t, \quad u_t \sim N(0, \sigma^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

Si $\beta_1 = 0$, entonces es un ARCH(1).

σ_t^2 puede interpretarse como un promedio ponderado entre:

- un valor promedio de largo plazo (α_0),
- la volatilidad en períodos anteriores ($\alpha_1 u_{t-1}^2$),
- la varianza predicha por el modelo en períodos anteriores ($\beta \sigma_{t-1}^2$)

Es una especie de modelo ARMA de la varianza condicional.

De forma análoga al modelo ARCH, la varianza condicional cambia en el tiempo, mientras que la incondicional es constante y está dada por:

$$V(u_t) = \frac{\alpha_0}{1 - (\alpha_1 + \beta)}$$

siempre que $\alpha_1 + \beta_1 < 1$.

- Si $\alpha_1 + \beta_1 \geq 1$, la varianza incondicional no está definida (no estacionariedad en varianza). Caso poco relevante.
- Si $\alpha_1 + \beta_1 = 1$ hablamos de una raíz unitaria en la varianza (Modelo IGARCH).

El método de estimación es el de **máxima verosimilitud**. El procedimiento sería:

- (1) Especificar las ecuaciones apropiadas de la media y la varianza:

$$y_t = \mu + \phi y_{t-1} + u_t, \quad u_t \sim N(0, \sigma_t^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

- (2) Especificar el logaritmo de la función de verosimilitud para maximizar bajo el supuesto de normalidad de los residuos:

$$L = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log(\sigma_t^2) - \frac{1}{2} \sum_{t=1}^T (y_t - \mu - \phi y_{t-1})^2 / \sigma_t^2$$

- (3) Maximizar dicha función usando métodos numéricos estándar para obtener los valores de los parámetros que maximizan L .

Nuevamente, recuerden que el supuesto de normalidad se hace respecto de ε_t donde $u_t = \varepsilon_t \sigma_t$, $u_t \sim N(0, \sigma_t^2)$. Por lo tanto u_t tiene colas pesadas, entonces evaluamos la normalidad condicional del residuo estandarizado:

$$\hat{\varepsilon}_t = \frac{\hat{u}_t}{\hat{\sigma}_t}$$

Si bien es probable que el supuesto de distribución normal no se mantenga (por exceso de curtosis), usamos la estimación QML (con errores estándares corregidos por Bollerslev-Wooldridge).

- En **STATA**: `arch` usando la opción `garch(q)` e indicar `q`
- En **R**: `ugarchfit()` dentro del paquete `rugarch` o `garchFit()` dentro del paquete `fGarch`.
- En **EViews**: ir a `Quick/Estimation/Method/ARCH...` y seleccionar el orden de la parte GARCH.

Un modelo GARCH(1,1) puede extenderse fácilmente a un modelo GARCH(p,q):

$$y_t = u_t, \quad u_t \sim N(0, \sigma_t^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \dots + \alpha_p u_{t-p}^2 + \beta_1 \sigma_{t-1}^2 + \dots + \beta_q \sigma_{t-q}^2$$

El archivo `garch.xls` contiene la siguiente serie temporal:

- `fspcom`: índice de precios de las acciones de S&P500.

Se pide:

- (1) Grafique la serie
- (2) Calcule el retorno del S&P500. Grafique.
- (3) Estime un modelo GARCH(1,1). Comente
- (4) Realice los siguientes diagnósticos de los residuos:
 - Ausencia de correlación serial
 - Ausencia de efectos ARCH adicionales
 - Normalidad

Extensiones

Extensiones del modelo GARCH

Desde que se desarrolló el modelo GARCH, se propusieron un gran número de extensiones y variantes como consecuencia de muchos problemas que se percibía con el modelo GARCH(p,q) estándar.

- La condiciones de no-negatividad pueden ser violadas.
- Los modelos GARCH no contemplaban los “leverage effects” .
- No existe feedback directo entre la varianza condicional y la media condicional.

Modelos GARCH asimétricos

Los modelos GARCH fuerzan a que exista una respuesta simétrica de la volatilidad a shocks positivos o negativos.

En las series financieras, un shock negativo probablemente cause una volatilidad mayor que un shock positivo de la misma magnitud.

Existe dos **formulaciones asimétricas** muy populares:

- el modelo GJR o TGARCH
- el modelo EGARCH

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).
- Modelo GARCH con un término adicional que considera posibles asimetrías. Varianza condicional dada por:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma u_{t-1}^2 I_{t-1}$$

- donde $I_{t-1} = 1$ si $u_{t-1} < 0$, vale 0 en caso contrario.

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).
- Modelo GARCH con un término adicional que considera posibles asimetrías. Varianza condicional dada por:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma u_{t-1}^2 I_{t-1}$$

- donde $I_{t-1} = 1$ si $u_{t-1} < 0$, vale 0 en caso contrario.
- Para un **efecto apalancamiento**, veremos que $\gamma > 0$.

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).
- Modelo GARCH con un término adicional que considera posibles asimetrías. Varianza condicional dada por:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma u_{t-1}^2 I_{t-1}$$

- donde $I_{t-1} = 1$ si $u_{t-1} < 0$, vale 0 en caso contrario.
- Para un **efecto apalancamiento**, veremos que $\gamma > 0$.
- Ahora la condición de no-negatividad será $\alpha_0 > 0$, $\alpha_1 > 0$, $\beta \geq 0$, y $\alpha_1 + \gamma \geq 0$. Es decir, el modelo es aún admisible si $\gamma < 0$ siempre que $\alpha_1 + \gamma \geq 0$.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.
- Para ver cómo la volatilidad aumenta más luego de un gran shock negativo que uno positivo, supongan que $\sigma_{t-1}^2 = 0,823$.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.
- Para ver cómo la volatilidad aumenta más luego de un gran shock negativo que uno positivo, supongan que $\sigma_{t-1}^2 = 0,823$.
- Consideren que $\hat{u}_{t-1} = \pm 0,5$.
- Si $\hat{u}_{t-1} = 0,5$, esto implica que $\sigma_t^2 = 1,65$.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.
- Para ver cómo la volatilidad aumenta más luego de un gran shock negativo que uno positivo, supongan que $\sigma_{t-1}^2 = 0,823$.
- Consideren que $\hat{u}_{t-1} = \pm 0,5$.
- Si $\hat{u}_{t-1} = 0,5$, esto implica que $\sigma_t^2 = 1,65$.
- En cambio, un shock de igual magnitud, pero con signo negativo ($\hat{u}_{t-1} = -0,5$) implica una varianza condicional predicha al momento t de $\sigma_t^2 = 1,80$.

- En **STATA**: arch con opciones garch y tarch
- En **R**: garch() con opción leverage=TRUE usar el package tseries o en ugarchspec() indicando submodel=TGARCH.
- En **EViews**: ir a Quick/Estimation/Method/ARCH... y seleccionar el orden de la parte GARCH y poner un 1 donde dice Threshold.

Modelo EGARCH (GARCH exponencial)

Propuesto por Nelson (1991).

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \gamma \frac{u_{t-1}}{\sqrt{\sigma_{t-1}^2}} + \alpha \left[\frac{|u_{t-1}|}{\sqrt{\sigma_{t-1}^2}} - \sqrt{\frac{2}{\pi}} \right]$$

Esta especificación tiene múltiples ventajas respecto del GARCH:

- Como modelamos el logaritmo de la varianza condicional, incluso si los parámetros estimados son negativos, σ_t^2 será positiva.
- Se permite que existan asimetrías ya que si la relación entre la volatilidad y los retornos es negativa, γ será negativa.

- En **STATA**: `arch` con opciones `earch` y `egarch`
- En **R**: `ugarchspec` indicando `model='eGARCH'` en `variance.model`, usando el package `rugarch`
- En **EViews**: ir a `Quick/Estimation/Method/ARCH...` y seleccionar `EGARCH` en `Model`.

Utilice la base de datos `currencies.xls`. A partir de la series `rjpy` (retornos del yen respecto del dólar estadounidense) estime un TGARCH y un EGARCH.

Evalúe si hay evidencia de asimetría en la volatilidad condicional de `rjpy`. ¿Son significativos los términos de asimetría?

Tests de asimetría en la volatilidad

Engle y Ng (1993) propusieron un conjunto de tests para evaluar la asimetría en la volatilidad, conocidos como los **tests de sesgo de signo y tamaño**.

En la práctica, los test de Engle-Ng se aplican sobre los residuos del GARCH estimado.

Tests de asimetría en la volatilidad

Engle y Ng (1993) propusieron un conjunto de tests para evaluar la asimetría en la volatilidad, conocidos como los **tests de sesgo de signo y tamaño**.

En la práctica, los test de Engle-Ng se aplican sobre los residuos del GARCH estimado.

Sea S_{t-1}^- una dummy que vale 1 si $\hat{u}_{t-1} < 0$ y 0 en caso contrario. El **test de sesgo de signo** se basa en la significancia de ϕ_1 en:

$$\hat{u}_t^2 = \phi_0 + \phi_1 S_{t-1}^- + v_t$$

donde v_t es un error IID. Si shocks positivos y negativos en $\hat{u}_{t-1}$ impactan en forma diferente sobre la varianza condicional, entonces ϕ_1 será estadísticamente significativa.

Tests de asimetría en la volatilidad

También podría darse el caso de que la magnitud o el tamaño del shock afecten a si la respuesta de la volatilidad a los shocks es simétrica o no.

Diremos que hay un **sesgo negativo en el tamaño** si ϕ_1 es estadísticamente significativo en la siguiente regresión:

$$\hat{u}_t^2 = \phi_0 + \phi_1 S_{t-1}^- u_{t-1} + v_t$$

Tests de asimetría en la volatilidad

Finalmente, definiendo $S_{t-1}^+ = 1 - S_{t-1}^-$, Engle y Ng proponen evaluar conjuntamente sesgos positivos y negativos en el tamaño basándose en la siguiente regresión:

$$\hat{u}_t^2 = \phi_0 + \phi_1 S_{t-1}^- + \phi_2 S_{t-1}^- u_{t-1} + \phi_3 S_{t-1}^+ u_{t-1} + v_t$$

La significatividad de ϕ_1 indica un **sesgo de signo**, mientras que la significatividad de ϕ_2 y ϕ_3 sugieren presencia de **sesgo de tamaño**. El estadístico para el test conjunto se calcula como $T.R^2$ con distribución $\chi^2(3)$.


Curvas de Impacto de Noticias (NIC) - Pagan y Schwert (1990)

- Representación gráfica del grado de asimetría de la volatilidad a shocks positivos y negativos.
- Grafican la volatilidad del próximo período (σ_t^2) que surgiría a partir de diversos valores positivos y negativos de u_{t-1} dado el modelo estimado.
- Se dibujan utilizando la estimación de la ecuación de la varianza condicional.
- Luego, se utilizan valores sucesivos de u_{t-1} en la ecuación para determinar cuáles serían los valores correspondientes de σ_t^2 derivados del modelo.

Curvas de Impacto de Noticias

Figure 8.3

News impact curves for S&P500 returns using coefficients implied from GARCH and GJR model estimates



Ver programa de EViews `nic.pr` para generar curvas de impacto de noticias a partir de un EGARCH.

GARCH-in-mean - Engle, Lilien y Robins (1987)

La mayoría de los modelos en finanzas suponen que los inversores deben ser recompensados con una mayor rentabilidad cuando toman un riesgo adicional. **El retorno debe depender del riesgo.**

$$y_t = \mu + \delta \sigma_{t-1} + u_t, \quad u_t \sim N(0, \sigma_{t-1}^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2$$

Si δ es positivo y estadísticamente significativo, un incremento en el riesgo (dada por un aumento en la varianza condicional) lleva a un aumento en el retorno promedio. Es decir, δ se puede interpretar como una **prima de riesgo**.

- En **STATA**: arch con opciones garch y archm
- En **R**: ugarchspec indicando model='sGARCH' en variance.model y archm=TRUE, usando el package rugarch
- En **EViews**: ir a Quick/Estimation/Method/ARCH... y seleccionar Std.Dev en ARCH-M.

A partir del retorno calculado sobre el valor de la acción de la compañía que bajaron de **Yahoo Finance** se pide:

- Estime un modelo GARCH. Comente.
- Estime un modelo TGARCH. Comente.
- Estime un modelo EGARCH. Comente.
- Estime un modelo GARCH-M. Comente.

- Tsay (2010) - Cap. 3.
- Tsay (2013) - Cap. 4 (ejemplos en R).