

Procesos univariados estacionarios

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

- Propiedades de las series temporales
- Repaso de MCO y sus supuestos
- Autocorrelación: tests y soluciones
- Modelos autoregresivos
- Conceptos básicos
- Metodología de Box-Jenkins

Propiedades de las series temporales

- Nos interesa la evolución temporal de series económicas.
- Notación: $\{y_t\}$ con $t = 1, 2, \dots T$.
- Distintos tipos de frecuencias:
 - Anual
 - Semestral
 - Trimestral
 - Mensual
 - Semanal
 - Diaria
 - Intradiaria


Algunas características de series económicas / financieras

- Fuertes tendencias
- Breaks / Cambios estructurales
- Comportamientos estacionales marcados
- Ciclos estocásticos, difíciles de predecir
- Oscilaciones muy erráticas
- Dificultad para distinguir tendencias y ciclos
- Co-movimientos

SIEMPRE: comenzar con un gráfico


(frecuencia anual)

Emisiones de CO2 (en millones de kt)




(frecuencia trimestral)

Consumo privado (en miles de millones de pesos de 2004)



(frecuencia mensual)

Precio de la soja en Chicago (en dólares por MT)



(frecuencia diaria)

U.S. / Euro Foreign Exchange Rate



Propiedades de las series temporales

Propiedad 1: presentan comportamientos dinámicos

- Al estar ordenadas temporalmente, los valores pasados influyen en los valores presentes y futuros.
- Esto usualmente resulta en la violación del supuesto de ausencia de autocorrelación en MCO: $Cov(u_i, u_j) \neq 0 \quad \forall i \neq j$

Propiedades de las series temporales

Propiedad 1: presentan comportamientos dinámicos

- Al estar ordenadas temporalmente, los valores pasados influyen en los valores presentes y futuros.
- Esto usualmente resulta en la violación del supuesto de ausencia de autocorrelación en MCO: $Cov(u_i, u_j) \neq 0 \quad \forall i \neq j$

Propiedad 2: usualmente tienen momentos que dependen del tiempo (p.ej., media, varianza, asimetría, kurtosis, etc.)

- Esto implica que las series usualmente no son estacionarias.
- Granger y Newbold (1974) demostraron que si se regresionan dos variables independientes no estacionarias, la probabilidad de encontrar una relación espuria es muy alta.

Propiedades de las series temporales

Propiedad 3: la naturaleza secuencial de las series temporales permite realizar pronósticos de futuros eventos.

Propiedades de las series temporales

Propiedad 3: la naturaleza secuencial de las series temporales permite realizar pronósticos de futuros eventos.

Propiedad 4: los eventos en las series temporales pueden causar quiebres estructurales en la serie de datos. Se pueden estimar estos cambios mediante *dummies*, modelos de *regime switching/Markov*, etc.

Propiedades de las series temporales

Propiedad 3: la naturaleza secuencial de las series temporales permite realizar pronósticos de futuros eventos.

Propiedad 4: los eventos en las series temporales pueden causar quiebres estructurales en la serie de datos. Se pueden estimar estos cambios mediante *dummies*, modelos de *regime switching*/Markov, etc.

Propiedad 5: muchas series temporales están en una relación de equilibrio de largo plazo (cointegración). Se pueden estimar estas relaciones mediante modelos de corrección de errores (MCE).

Propiedades de las series temporales

Propiedad 6: muchas series temporales están endógenamente relacionadas. Se puede modelar estimando sistemas de ecuaciones, como los vectores autorregresivos (VAR).

Propiedades de las series temporales

Propiedad 6: muchas series temporales están endógenamente relacionadas. Se puede modelar estimando sistemas de ecuaciones, como los vectores autorregresivos (VAR).

Propiedad 7: los efectos de las variables explicativas sobre la variable dependiente pueden variar en el tiempo. Podemos estimar estos efectos dinámicos con modelos que consideren parámetros variantes en el tiempo.

MCO

Repaso de MCO. Regresión en series temporales

- Consideremos el siguiente modelo poblacional:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad t = 1, 2, \dots, T \quad (1)$$

- En términos matriciales:

$$y_t = \mathbf{x}_t' \beta + u_t \quad (2)$$

donde $\mathbf{x}_t = (1, x_{1t}, x_{2t}, \dots, x_{kt})'$ y $\beta = (\beta_0, \beta_1, \dots, \beta_k)'$.

- El estimador de MCO es:

$$\hat{\beta} = \left(\sum_{t=1}^T \mathbf{x}_t \mathbf{x}_t' \right)^{-1} \sum_{t=1}^T \mathbf{x}_t y_t \quad (3)$$

- Reemplazando y_t por (2) obtenemos:

$$\hat{\beta} - \beta = \left(\sum_{t=1}^T \mathbf{x}_t \mathbf{x}_t' \right)^{-1} \sum_{t=1}^T \mathbf{x}_t u_t \quad (4)$$

- Las propiedades estadísticas de $\hat{\beta}$ dependen de $\mathbf{x}_t$, u_t

Los supuestos de MCO

- **TS.1. (linealidad en parámetros)**

$$y_t = \beta_0 + \beta_1 x_{1t} + \dots + \beta_k x_{kt} + u_t$$

- **TS.2. (no multicolinealidad perfecta)** En la muestra, ninguno de los regresores es constante (igual al intercepto) y no hay una relación lineal exacta entre los regresores.
- **TS.3. (exogeneidad estricta)** $E(u_t | \mathbf{X}) = 0$ donde $\mathbf{X}$ denota todas las $\mathbf{x}_t$ e implica:
$$\text{cov}(x_{1t}, u_s) = 0, \dots, \text{cov}(x_{kt}, u_s) = 0 \quad \forall t, s.$$
- **TS.4. (varianza del error homocedástica)** $\text{var}(u_t | \mathbf{X}) = \sigma^2$
- **TS.5. (no correlación serial)** $\text{cov}(u_t, u_s | \mathbf{X}) = 0 \quad \forall t \neq s$

Teorema

Supongan que TS.1-TS.5 se mantienen, entonces los estimadores MCO de $\beta_0, \beta_1, \dots, \beta_k$ son MELI, i.e. los mejores (menor varianza) estimadores lineales insesgados ($E(\hat{\beta}) = \beta$).

La varianza de MCO

- Bajo TS.1-TS.5, la varianza de MCO es:

$$\text{var}(\hat{\beta}|\mathbf{X}) = \sigma^2 \left(\sum_{t=1}^T \mathbf{x}_t \mathbf{x}_t' \right)^{-1} \quad (5)$$

- Una fórmula conveniente de la varianza de $\hat{\beta}_j$ está dada por:

$$\text{var}(\hat{\beta}_j|\mathbf{X}) = \frac{\sigma^2}{\sum_{t=1}^T \hat{r}_{jt}^2} \quad (6)$$

donde $\hat{r}_{jt}$ son los residuos de la regresión de x_{jt} en función del resto de las variables x .

- Entonces, podemos usar los estadísticos t y F usuales para hacer inferencia si además agregamos el supuesto de normalidad del error (o apelando al TCL).

Autocorrelación

¿Qué pasa si se viola el supuesto TS.5?

¿Qué pasa si se viola el supuesto TS.5?

- (1) **TS.5.** (no correlación serial): $cov(u_t, u_s | \mathbf{X}) = 0 \quad \forall t \neq s$.
- (2) Así como en *cross – section* la heterocedasticidad es bastante frecuente, en series de tiempo solemos encontrar autocorrelación.
- (3) Obviamente no observamos los u 's, pero podemos analizar los residuos $(\hat{u})$.

Autocorrelación

Bajo los supuestos de MCO, la matriz de var-cov de los errores era:

$$E(uu'|\mathbf{X}) = \sigma^2 \cdot I_T$$

Ahora, bajo autocorrelación:

$$E(uu'|\mathbf{X}) = \Omega_{AC} \neq \sigma^2 \cdot I_T$$
$$\Omega_{AC} = \begin{bmatrix} \sigma^2 & \gamma_1 & \gamma_2 & \gamma_3 & \cdots & \gamma_{T-1} \\ \gamma_1 & \sigma^2 & \gamma_1 & \gamma_2 & \cdots & \gamma_{T-2} \\ \gamma_2 & \gamma_1 & \sigma^2 & \gamma_1 & \cdots & \gamma_{T-3} \\ \gamma_3 & \gamma_2 & \gamma_1 & \sigma^2 & \cdots & \gamma_{T-4} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \gamma_{T-1} & \gamma_{T-2} & \gamma_{T-3} & \gamma_{T-4} & \cdots & \sigma^2 \end{bmatrix}$$

- γ_j es la **autocovarianza de los errores** separados j observaciones (constante para cada j).

Si bien lo definiremos más adelante cuando hablemos de **estacionariedad**, noten que le estamos pidiendo a u_t que:

- su media no dependa del tiempo,
- su varianza tampoco,
- y sus covarianzas tampoco!

Autocorrelación

La matriz anterior podemos también re-escribirla como:

$$\Omega_{AC} = \sigma^2 \times \begin{bmatrix} 1 & \rho_1 & \rho_2 & \rho_3 & \cdots & \rho_{T-1} \\ \rho_1 & 1 & \rho_1 & \rho_2 & \cdots & \rho_{T-2} \\ \rho_2 & \rho_1 & 1 & \rho_1 & \cdots & \rho_{T-3} \\ \rho_3 & \rho_2 & \rho_1 & 1 & \cdots & \rho_{T-4} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{T-1} & \rho_{T-2} & \rho_{T-3} & \rho_{T-4} & \cdots & 1 \end{bmatrix}$$

- donde $\rho_j = \gamma_j / \sigma^2$ es el **coeficiente de autocorrelación de los errores** de orden j .
- Como la la matriz completa es difícil de estimar (para ρ_{T-1} sólo tendríamos una observación) algunos autores propusieron inicialmente usar un modelo que simplifique Ω_{AC} notablemente $\rightarrow$ **modelos autorregresivos**

Modelo autorregresivo de primer orden, AR(1)


Si bien volveremos más adelante sobre estos modelos, por ahora haremos una introducción.

Modelo AR(1):

$$u_t = \phi u_{t-1} + v_t, \quad |\phi| < 1, v_t \sim IID(0, \sigma_v^2)$$


Se puede probar (lo haremos más adelante) que en este modelo $\rho_j = \phi^j$, es decir, todos los coeficientes de autocorrelación dependen de uno solo ϕ .

Autocorrelación de primer orden positiva




Patrón cíclico de residuos a lo largo del tiempo.

Autocorrelación de primer orden negativa



Patrón alternante.

No autocorrelación de primer orden



Sin patrón en los residuos.

Detectando la autocorrelación

Test de Durbin-Watson (1950,1951) → old-fashioned.

Limitaciones:

- Sólo sirve para evaluar autocorrelación de orden 1.
- El estadístico no tiene una distribución conocida.
- Existen regiones donde el test no concluye (zonas de indeterminación).
- Si el modelo incluye un rezago de la variable dependiente, sólo sirve si se rechaza H_0 , no en caso contrario (mayor concentración de la distribución $\hat{\rho}$ en torno de su media que sería cero).

Aunque, cuando veamos cointegración nos va a servir como indicador para evaluar si la regresión es espuria.

Detectando la autocorrelación

Test LM de Breusch-Godfrey (1978):

Una vez que estimamos nuestro modelo por MCO:

$$y_t = \mathbf{x}_t' \hat{\beta} + \hat{u}_t$$

Se estima la siguiente regresión auxiliar:

$$\hat{u}_t = \mathbf{x}_t' \hat{\alpha} + \phi_1 \hat{u}_{t-1} + \phi_2 \hat{u}_{t-2} + \cdots + \phi_p \hat{u}_{t-p} + \hat{v}_t$$

Entonces se evalúa:

$$H_0 : \phi_1 = \phi_2 = \cdots = \phi_p = 0$$

$$H_1 : \text{algún } \phi_j \neq 0 \quad \forall j = 1, \dots, p$$

Mediante un estadístico $LM = T.R^2 \sim \chi^2(p)$

Test de Breusch-Godfrey - Softwares

- En **R**: `bgtest` en el paquete `lmtest`
- En **STATA**: `estat bgodfrey`, luego de `regress`
- En **EViews**: en View/Residual Diagnostics/Serial Correlation LM Test... e indicar p
- En **OxMetrics**: por default en la salida de la regresión por MCO (aparece la versión F del test).

Ejemplo en R - Modelo de inflación

```
call:
lm(formula = infln ~ pcwage)

Residuals:
    Min       1Q   Median       3Q      Max
-0.85925 -0.10836 -0.01477  0.12285  0.97427

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.20417    0.02414   8.457 0.000000000000000182 ***
pcwage         0.20159    0.07970   2.529    0.012 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2091 on 267 degrees of freedom
Multiple R-squared:  0.0234,    Adjusted R-squared:  0.01974
F-statistic: 6.398 on 1 and 267 DF, p-value: 0.012
```

- $\text{infln} = [\ln(\text{cpi}_t) - \ln(\text{cpi}_{t-1})] * 100$
- $\text{pcwage} = [\ln(\text{wage}_t) - \ln(\text{wage}_{t-1})] * 100$

Ejemplo en R - Modelo de inflación

```
> bgtest(modelo.infla, order=2)

Breusch-Godfrey test for serial correlation of order up to 2

data: modelo.infla
LM test = 30.866, df = 2, p-value = 1.984e-07

> coeftest(bgtest(modelo.infla, order=2))

z test of coefficients:

              Estimate Std. Error z value Pr(>|z|)
(Intercept)  0.0055554  0.0228266  0.2434  0.807715
pcwage       -0.0217176  0.0753844 -0.2881  0.773277
lag(resid)_1  0.3467378  0.0606279  5.7191 1.071e-08 ***
lag(resid)_2 -0.1752909  0.0607394 -2.8859  0.003902 **
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Prueben evaluar qué sucede para $p = 3$.

Consecuencias de ignorar la autocorrelación

Asumiendo que el resto de los supuestos se mantienen:

- (si el modelo no incluye rezagos de y_t) El estimador de MCO será insesgado y consistente, pero ineficiente, afectando la inferencia.
- (si el modelo incluye rezagos de y_t) El estimador de MCO será inconsistente. **¿Por qué?**

Consecuencias de ignorar la autocorrelación

Asumiendo que el resto de los supuestos se mantienen:

- (si el modelo no incluye rezagos de y_t) El estimador de MCO será insesgado y consistente, pero ineficiente, afectando la inferencia.
- (si el modelo incluye rezagos de y_t) El estimador de MCO será inconsistente. **¿Por qué?**

Porque entonces $E(y_{t-1}, u_t) \neq 0$ ya que si hay autocorrelación de primer orden (u_t depende de u_{t-1}) implica que y_{t-1} está correlacionada con u_t .

“Remedios” para la autocorrelación

- Si la forma de la autocorrelación es conocida, usar MCG - e.g. Cochrane-Orcutt.
- Ojo, que si el supuesto es inválido, el remedio puede ser peor que la enfermedad (Hendry y Mizon, 1978)
- Usar los HACSE (e.g. Newey-West).
- En la visión “moderna”, si hay autocorrelación, es una oportunidad para modificar la regresión. ¡Modelar la dinámica!

Incorporando rezagos de la variable dependiente

¡En estos casos es MUY importante evaluar la autocorrelación!

```
call:
lm(formula = dyn(infln ~ pcwage + lag(infln, -1) + lag(infln,
-2)))

Residuals:
    Min       1Q   Median       3Q      Max
-0.68514 -0.10647 -0.01484  0.11306  0.93344

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.16233    0.02876   5.644 0.0000000429 ***
pcwage          0.18782    0.07608   2.469  0.01419 *
lag(infln, -1)  0.35051    0.05997   5.844 0.0000000150 ***
lag(infln, -2) -0.18128    0.05977  -3.033  0.00266 **
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1957 on 263 degrees of freedom
(2 observations deleted due to missingness)
Multiple R-squared:  0.1402,    Adjusted R-squared:  0.1304
F-statistic: 14.29 on 3 and 263 DF,  p-value: 0.00000001181
```

Vuelvan a testear si hay evidencia de autocorrelación.

Conceptos básicos

Operador rezago (L): $Ly_t = y_{t-1}$

- $L^2 y_t = L(Ly_t) = Ly_{t-1} = y_{t-2} \Rightarrow L^k y_t = y_{t-k}$
- $\alpha(L) = \alpha_0 + \alpha_1 L + \alpha_2 L^2 + \cdots + \alpha_k L^k$ (polinomio de rezagos)
- $\alpha(L)y_t = \alpha_0 y_t + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \cdots + \alpha_k y_{t-k}$

Operador de diferenciación (Δ): $\Delta y_t = y_t - y_{t-1}$

- $\Delta \equiv (1 - L)$
- $\Delta y_t \equiv (1 - L)y_t = y_t - y_{t-1}$
- $\Delta^2 y_t \equiv (1 - L)^2 y_t = (1 - 2L + L^2)y_t$
- $\Delta_2 y_t \neq \Delta^2 y_t$
- $\Delta_2 y_t = y_t - y_{t-2}$

- y_{t-j} es el rezago (lag) j de y_t
- y_{t+j} es el adelanto (lead) j del y_t
- $\Delta y_t = y_t - y_{t-1}$ es la primera diferencia de y_t
- $\Delta \ln(y_t) = \ln(y_t) - \ln(y_{t-1})$ es la diferencia logarítmica de y_t
- El cambio porcentual de una series y_t entre los períodos $t - 1$ y t es aproximadamente $100 \times \Delta \ln(y_t)$, donde la aproximación es más precisa cuanto más pequeña es la variación porcentual.

- A partir del script `clase1.R` replique las estimaciones de los modelos de inflación que hicimos antes. Observe cómo usamos el operador rezago (`lag()`) y diferencia (`diff()`).
- Grafique los residuos del modelo estático (`plot()`). Comente.
- Obtenga el primer rezago de los residuos y haga un scatter-plot entre $\hat{u}_t$ y $\hat{u}_{t-1}$.
- Replique los dos puntos anteriores para el modelo dinámico.
¿Se condice lo que observa con las conclusiones del test LM?

Una **serie de tiempo** es una colección de observaciones indizada por la fecha de cada observación (t). Usualmente, la muestra comienza en $t = 1$ y termina en $t = T$:

$$(y_1, y_2, \dots, y_T)$$

Pero podríamos imaginar que existieron datos anteriores a $t = 1$ y posteriores a $t = T \Rightarrow (y_1, y_2, \dots, y_T)$ es un segmento finito de una secuencia infinita:

$$\{y_t\}_{t=-\infty}^{\infty} = \{\dots, y_{-1}, y_0, \underbrace{y_1, y_2, \dots, y_T}_{\text{muestra observada}}, y_{T+1}, y_{T+2}, \dots\}$$

Proceso Estocástico: $Y_1, Y_2, \dots, Y_T$ (secuencia ordenada)

realización de un

Serie de Tiempo: $y_1, y_2, \dots, y_T$

Momentos de orden 1 y 2

Función de densidad conjunta: $D_{Y_1, Y_2, \dots, Y_T}(y_1, y_2, \dots, y_T)$

Si nos concentramos solamente en m_1 y m_2 de esa función:

- $E(Y_t) = \mu_t$
- $Var(Y_t) = \gamma_{0t}$
- $Cov(Y_t, Y_{t-j}) = \gamma_{jt}$ (j-ésima autocovarianza)

No tendríamos grados de libertad suficientes.


- $E(Y_t) = \mu_t$ (T parámetros)
- $Var(Y_t) = \gamma_{0t}$ (T parámetros)
- $Cov(Y_t, Y_{t-j}) = \gamma_{jt}$ ($\frac{T^2-T}{2}$ parámetros)

El supuesto más simple es el de **ESTACIONARIEDAD DÉBIL** (o en covarianzas).


- $E(Y_t) = \mu$ (1 parámetro)
- $Var(Y_t) = \gamma_0$ (1 parámetro)
- $Cov(Y_t, Y_{t-j}) = \gamma_j$ ($T-1$ parámetros)

La **ESTACIONARIEDAD EN SENTIDO ESTRICTO** es la generalización para el proceso generador de los datos.

Casos de no estacionariedad



No estacionariedad en media



Caso heterocedástico

- Existen otras fuentes de no estacionariedad como los *breaks* o cambios estructurales.

Series temporales en R

- Vuelva sobre el script `clase1.R`.
- Grafique la serie de `cpi` y `infln`. ¿Le parecen estacionarias?
- Realice lo mismo con las series `wage` y `pcwage`.

Ruido Blanco (White Noise)

ε_t es un proceso **ruido blanco** si:


- $E(\varepsilon_t) = 0, \forall t$
- $Var(\varepsilon_t) = E(\varepsilon_t^2) = \sigma^2 < \infty, \forall t$
- $Cov(\varepsilon_t, \varepsilon_{t-j}) = 0, \forall t, \forall j \neq 0$

Entonces, un ruido blanco es débilmente estacionario por definición (lo será en sentido estricto si asumimos, p.ej., que es gaussiano).

Un RB es impredecible respecto de su propio pasado:

$$E(\varepsilon_t / \varepsilon_{t-j}) = E(\varepsilon_t) = 0 \text{ (innovación, en media)}$$

Ruido Blanco (White Noise)



Series temporales en R

- Vuelva sobre el script `clase1.R`.
- Calcule los principales estadísticos descriptivos de la serie de residuos del modelo dinámico.
- Calcule su función de autocorrelación (use `acf()` dentro del paquete "stats"). ¿Qué observa?
- ¿El residuo parece ser ruido blanco?

Metodología de Box-Jenkins

Objetivo

- Desarrollado por Box y Jenkins (1970)
- Enfoque estadístico


Objetivo

- Desarrollado por Box y Jenkins (1970)
- Enfoque estadístico
- **Objetivo:** inferir el proceso estocástico subyacente a una serie temporal
- Es un análisis univariado
- Se deja que los propios datos de la serie temporal nos indiquen las características de la estructura probabilística subyacente.

Objetivo


- Desarrollado por Box y Jenkins (1970)
- Enfoque estadístico
- **Objetivo:** inferir el proceso estocástico subyacente a una serie temporal
- Es un análisis univariado
- Se deja que los propios datos de la serie temporal nos indiquen las características de la estructura probabilística subyacente.
- Se quiere encontrar el modelo (ARMA) **de mejor ajuste** a una serie temporal para que los pronósticos sean lo más acertados
- Implica un modelado **iterativo** en varias etapas.

Etapas




¿Cómo volver estacionaria a una serie temporal?

Si bien veremos más adelante un test para evaluar la estacionariedad de una serie, **¿qué hacer si observo un comportamiento no estacionario?**



No estacionariedad en media



Caso heterocedástico

Muchas veces, cuando la tendencia o la media no es constante a lo largo del tiempo, la **diferenciación** (Δ^d , $d \geq 1$) permite volver estacionaria una serie.

$$\Delta y_t \equiv y_t - y_{t-1}$$

$$\Delta^2 y_t \equiv y_t - 2y_{t-1} + y_{t-2}$$

- En general, d no es mayor a 2

Estabilización de la varianza

Cuando la dispersión de una serie temporal no es constante (p.ej. muchas series financieras en alta frecuencia), la **transformación logarítmica** suele ser razonablemente estable:

$$\dot{y}_t = \ln y_t$$

- Es un caso particular de la **Transformación de Box-Cox**:

$$\dot{y}_t = \frac{y_t^m - 1}{m}, \quad \text{con } |m| \leq 2$$

- Cuando tomamos $\lim_{m \rightarrow 0}$.

Diferenciación estacional

El operador **diferencia estacional** de período s y orden d (Δ_s^d) se puede aplicar a series que presentan tendencia junto con estacionalidad.

$$\Delta_s \equiv y_t - y_{t-s}$$

- Aquí $d = 1$
- Para series estacionales mensuales: $s = 12$, y trimestrales: $s = 4$

Modelos ARMA

MA(1): Procesos de Media Móvil de orden 1

$$y_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}, \quad \mu, \theta < \infty, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Propiedades:

- $E(y_t) = \mu$
- $\gamma_0 = \text{Var}(y_t) = \sigma^2(1 + \theta^2)$
- $\gamma_1 = \theta\sigma^2$
- $\gamma_j = 0, \quad \forall j > 1$
- Entonces, $\rho_1 = \frac{\theta}{1 + \theta^2}$ y $\rho_j = 0 \quad \forall j > 1$

⇒ MA(1) es **siempre estacionario**.

Simulando procesos MA(1)

Simule en el software que elija los siguientes procesos MA(1) para $T = 200$:

- $y_t = 5 + \varepsilon_t + 0,5\varepsilon_{t-1}, \quad \varepsilon \sim N(0, 1)$
- $x_t = -3 + \varepsilon_t + 0,9\varepsilon_{t-1}, \quad \varepsilon \sim N(0, 1)$
- $z_t = 9 + \varepsilon_t - 1,2\varepsilon_{t-1}, \quad \varepsilon \sim N(0, 1)$

Grafique cada serie temporal y su correlograma (gráfico de autocorrelaciones).

MA(q): Procesos de Media Móvil de orden q

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Propiedades:

- $E(y_t) = \mu$
- $\gamma_0 = \text{Var}(y_t) = \sigma^2(1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2)$
- $\gamma_j = \begin{cases} [\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \dots + \theta_q\theta_{q-j}]\sigma^2 & j \leq q \\ 0 & j > q \end{cases}$

⇒ MA(q) es estacionario para cualquier $q < \infty$.

La dependencia con el pasado se anula luego del q -ésimo período.

MA(∞): Procesos de Media Móvil de orden ∞

$$y_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}, \quad \varepsilon_t \sim RB(0, \sigma^2), \quad \psi_0 = 1$$

MA(∞) es estacionario si:

1. $\sum_{j=0}^{\infty} \psi_j^2 < \infty$ (varianza finita)
2. $\sum_{j=0}^{\infty} |\psi_j| < \infty$ (sumabilidad absoluta)

2 $\Rightarrow$ 1, pero no a la inversa.

Teorema de Descomposición de Wold

Si $\{y_t\}$ es estacionaria débil, siempre admite una representación dada por:

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + k_t$$

la suma ponderada de términos puramente aleatorios ($\varepsilon_t \sim RB(0, \sigma^2)$) + una función determinística k_t

- Todo proceso estacionario es esencialmente un $MA(\infty)$ estacionario.
- ¡En la práctica implicaría estimar infinitos parámetros!
- **Idea:** buscar alguna representación más **parsimoniosa** del $MA(\infty)$. Un $MA(q)$ con q alto es una aproximación.

Procesos autorregresivos (AR)

AR(1): Proceso autorregresivo de orden 1:

$$y_t = c + \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Es un proceso *derivado* de un RB a través de una recursión:

$$y_t = \frac{c}{1 - \phi} + \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots \text{ si } |\phi| < 1$$

Los shocks van convergiendo $\Rightarrow$ AR(1) es estacionario si $|\phi| < 1$.

Notar que la expresión anterior es MA(∞) con $\psi_i \equiv \phi^i$

Volviendo a la representación $MA(\infty)$ del $AR(1)$

$$y_t = c + \phi y_{t-1} + \varepsilon_t \Leftrightarrow (1 - \phi L)y_t = c + \varepsilon_t$$

Si $|\phi| < 1$, aplicando $(1 - \phi L)^{-1}$ a ambos lados,

$$y_t = \frac{c}{1 - \phi L} + \frac{\varepsilon_t}{1 - \phi L}$$

Si $|\phi| < 1$,

$$\frac{1}{1 - \phi L} = 1 + \phi L + \phi^2 L^2 + \phi^3 L^3 + \dots \quad \text{y} \quad (1 - \phi L)(1 - \phi L)^{-1} y_t = y_t$$

Entonces,

$$y_t = c(1 + \phi L + \phi^2 L^2 + \dots) + \varepsilon_t(1 + \phi L + \phi^2 L^2 + \dots)$$

$$= c + \phi c + \phi^2 c + \dots + \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \dots$$

$$= \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \Rightarrow \text{Representación } MA(\infty) \text{ del } AR(1)$$

Propiedades del AR(1) estacionario


- $E(y_t) \equiv \mu = \frac{c}{1 - \phi}$
- $Var(y_t) \equiv \gamma_0 = \frac{\sigma^2}{1 - \phi^2}$
- $\gamma_j = \phi^j \gamma_0$
- $\rho_j = \phi^j$

Las autocorrelaciones de un AR(1) estacionario decaen exponencialmente en valor absoluto.

Intuición:

- La posición de y_t depende de dos componentes. Uno que lo ata del pasado (ϕy_{t-1}) y otro que lo mueve en forma aleatoria (ε_t).
- Es más errático cuando $\phi \rightarrow 0$ y más suave cuando $\phi \rightarrow 1$.

Ejemplos de AR(1)



¿Qué está sucediendo a medida que se incrementa ϕ ?

¿Qué pasa con ϕ negativo?

Simulando procesos AR(1)

Simule en el software que elija los siguientes procesos AR(1) para $T = 200$:

- $y_t = 0,1y_{t-1} + \varepsilon_t, \quad y_0 = 0, \varepsilon \sim N(0, 1)$
- $x_t = -0,5y_{t-1} + \varepsilon_t, \quad x_0 = 0, \varepsilon \sim N(0, 1)$
- $z_t = 0,95y_{t-1} + \varepsilon_t, \quad z_0 = 0, \varepsilon \sim N(0, 1)$

Grafique cada serie temporal y su correlograma (gráfico de autocorrelaciones).

Estacionariedad del AR(1) (según las raíces del polinomio de rezagos)

$$y_t = c + \phi y_{t-1} + \varepsilon_t \Leftrightarrow (1 - \phi L)y_t = c + \varepsilon_t$$

es estacionario si $|\phi| < 1$.

Si se considera el polinomio: $(1 - \phi L)$ con raíz $L = 1/\phi$.

Entonces, AR(1) es estacionario si y solo si $|L| > 1$.

$$|L| > 1 \Leftrightarrow |\phi| < 1$$

Proceso autorregresivo de orden p: AR(p)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

En términos del operador rezago,

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p) y_t = c + \varepsilon_t$$

En forma compacta,

$$\Phi(L) y_t = c + \varepsilon_t$$

El AR(p) será estacionario si cada una de las raíces de $\Phi(L)$ son mayores que 1 en valor absoluto.

Procesos ARMA(p,q)

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}$$

En forma compacta,

$$\Phi(L)y_t = \Theta(L)\varepsilon_t$$


El ARMA(p,q) es estacionario si todas las raíces de $\Phi(L)$ son mayores a 1 en valor absoluto (parte AR estacionario).

Simulando procesos ARMA(p,q)

Genere para $T=200$ los siguientes procesos (considere $y_0 = 0$):

- $y_t = 0,8y_{t-1} + \varepsilon_t$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = 0,1y_{t-1} + 0,5y_{t-2} + \varepsilon_t$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = \varepsilon_t + 0,8\varepsilon_{t-1}$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = \varepsilon_t + 0,1\varepsilon_{t-1} - 0,4\varepsilon_{t-2} + 0,5\varepsilon_{t-3}$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = 0,5y_{t-1} + \varepsilon_t - 0,3\varepsilon_{t-1}$, donde $\varepsilon_t \sim N(0, 1)$
- $y_t = 0,5y_{t-1} - 0,2y_{t-2} + \varepsilon_t - 0,3\varepsilon_{t-1}$, donde $\varepsilon_t \sim N(0, 1)$

Ejemplos ARMA(p,q)



Es muy difícil identificar procesos ARMA en forma observacional.

Etapa de Identificación

¿Cómo identifico cuál sería el proceso estocástico subyacente?

A partir de los **correlogramas** que son una representación gráfica de la función de autocorrelación del proceso en cuestión.

$$\rho_j = \gamma_j / \gamma_0$$

La versión muestral (estimada) se denomina **correlograma muestral**

$$\hat{\rho}_j = \hat{\gamma}_j / \hat{\gamma}_0 = \frac{1/T \sum_{t=1}^T (y_t - \bar{y})(y_{t-j} - \bar{y})}{1/T \sum_{t=1}^T (y_t - \bar{y})^2}$$

De un $AR(p)$ estacionario:

- Todas las autocorrelaciones son distintas de cero
- Decaen en valor absoluto
- Lo hacen en forma exponencial o sinusoidal

De un $MA(q)$:

- Solo las primeras q autocorrelaciones son distintas de cero

En la práctica,

- Si el correlograma se interrumpe bruscamente luego del rezago q , sugiere un proceso $MA(q)$.
- En caso contrario, puede ser AR o $ARMA$.

Correlograma parcial

La **función de autocorrelación parcial** (PAC, ϕ_{jj}) mide la correlación entre y_t y y_{t-j} , luego de controlar por los rezagos intermedios (todos aquellos rezagos menores a j).

En otras palabras, es la correlación condicional:

$$\phi_{jj} = \text{Corr}(y_t, y_{t-j} | y_{t+1}, y_{t+2}, \dots, y_{t+j-1})$$

- Para $j = 1$, la AC y la PAC van a coincidir ($\rho_1 = \phi_{11}$).
- Para los modelos AR(p) las PAC se anulan luego del rezago p .


Para obtener el estimador muestral de ϕ_{jj} podemos estimar:

$$y_{t+j} = \phi_{j1}y_{t+j-1} + \dots + \phi_{jj}y_t + \varepsilon_{t+j}$$

y así obtener $\hat{\phi}_{jj}$.

	AC	PAC
MA(q)	Se anula para rezagos superiores a q	Decrece rápido sin llegar a anularse
AR(p)	Decrece rápido sin llegar a anularse	Se anula para rezagos superiores a p
ARMA(p, q)	Decrecimiento rápido sin llegar a anularse	Decrecimiento rápido sin llegar a anularse

Figura 1: AR(1) vs MA(1)



- En **STATA**: se pueden usar los comandos `ac` y `pac` o `corrgram`.
- En **R**: usar la función `tsdisplay()` o `acf()` y `pacf()`.
- En **EViews**: desde la serie ir a `View/Correlogram...`, indicar la cantidad de rezagos.
- En **OxMetrics**: en el módulo de gráficos ir a `Time-series properties` y seleccionar `ACF` y `PACF`.

Etapa de Estimación

Estimación de modelos ARMA

Estimación AR(p):

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

ε_t satisface los supuestos bajo los cuales MCO produce estimaciones consistentes y asintóticamente normales.

Entonces consiste en regresar y_t en función de $y_{t-1}, y_{t-2}, \dots, y_{t-p}$

Estimación MA(q):

En general se utiliza el método de máxima verosimilitud o mínimos cuadrados no lineales.

- En **STATA**: `arima`
- En **R**: `arima()`
- En **EViews**: Quick/Estimate Equation/... poner nombre de la variable y a continuación indicar la cantidad de componentes AR o MA (ej. y AR(1) AR(2)).
- En **OxMetrics**: se puede usar el módulo X12ARIMA, sin habilitar la opción de desestacionalización.

Etapa de Validación

Necesitamos que el residuo del modelo estimado sea un **ruido blanco**. ¿Por qué?

Test de Box-Pierce (Q):

$$Q = T \sum_{\tau=1}^m \hat{\rho}_{\tau}^2$$

- Bajo H_0 : los residuos son RB, todas las correlaciones deberían ser cero.
- El test Q se basa en suma las primeras m autocorrelaciones. La elección de m implica un trade-off.
- Bajo H_0 , $Q \sim \chi^2(m)$

Evaluando si los residuos son RB

Sin embargo, el Test de Box-Pierce (Q) no tiene buenas propiedades para muestras pequeñas. Una variante, en casos de muestras pequeñas, es el **test de Ljung-Box** (1978):


$$Q^* = T(T+2) \sum_{\tau=1}^m \frac{\hat{\rho}_{\tau}^2}{(T-\tau)} \sim \chi_m^2$$

Para $T \rightarrow \infty$, el test de Ljung-Box es equivalente al de Box-Pierce.

Test de Q de Ljung-Box - Softwares

- En **STATA**: aparece cuando se usa `corrgram` y sino usar `wntestq`.
- En **R**: usar la función `Box.test()`.
- En **EViews**: aparece junto con los correlogramas.
- En **OxMetrics**: en la ventana de Test...

Metodología de Box-Jenkins



Metodología de Box-Jenkins

- (1) Garantizar que el proceso es estacionario.
- (2) Mediante los correlogramas proponer un $\text{ARMA}(p,q)$.
- (3) Estimarlos.
- (4) Si el modelo es correcto, los residuos deberían ser ruido blanco. De lo contrario, volver a (2).
- (5) Se puede proceder a realizar pronósticos.

Lo recomendable es seguir la metodología **General-a-Particular**: comenzar con un $\text{ARMA}(p,q)$ lo “suficientemente grande” e ir reduciéndolo buscando el modelo más parsimonioso (con residuos RB).

¿Y si tenemos varios modelos alternativos con residuos RB?

Usar alguno de los **criterios de información** (penalizan la falta de ajuste y la cantidad de parámetros). Ejemplo:

- **Akaike (AIC):** $AIC = -2 \frac{\ln(L(k))}{T} + 2 \frac{k}{T}$
- **Schwarz (SIC):** $SIC = -2 \frac{\ln(L(k))}{T} + k \frac{\ln(T)}{T}$
- **Hannan-Quinn (HQ):** $HQ = -2 \frac{\ln(L(k))}{T} + 2k \frac{\ln(\ln(T))}{T}$

Elegir el modelo que minimice alguno de estos criterios.

Criterios de información - Softwares

- En **STATA**: usar el comando estat ic después de la estimación.
- En **R**: reporta AIC y BIC en la estimación.
- En **EViews**: reporta AIC, SIC y HQ en la estimación.
- En **OxMetrics**: reporta AIC, SIC y HQ en la estimación.

Ventajas de R, de OxMetrics y de EViews 9 en adelante:
tienen la opción de una selección automática del modelo ARMA con mejor fit.

- `auto.arima()` dentro de la librería `forecast`
- (1) Usaremos el dataset: `WWWusage`.
 - (2) Esa serie temporal registra el número de usuarios conectados a Internet en cierto servidor por minuto. $T = 100$ observaciones.
 - (3) Utilice el script `boxjenkins.R`

Aplicación

Para la próxima clase

Utilice la base de datos `soja.csv` que contiene dos series temporales mensuales: el precio spot (s) y precio futuro (f) de la soja en Chicago entre enero de 1979 y mayo de 2012.

A partir de la serie del spot se pide:

- (1) Grafique la serie. ¿Qué observa?
- (2) Si no le parece estacionaria (en unas clases veremos como testearlo) transfórmela para volverla estacionaria.
- (3) Grafique los correlogramas. Identifique cuál(es) sería(n) el(los) proceso(s) estocástico(s) subyacente(s).
- (4) Estime.
- (5) Evalúe que los residuos sean ruido blanco.
- (6) ¿Cuál es el modelo más apropiado?

- Hamilton (1994) - Cap. 3 y 4
- Optativo: Enders (2014) - Cap. 2

Vectores Autorregresivos

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

Introducción

Modelos de Vectores Autorregresivos (VAR)

- Popularizados por Sims (1980):
“Macroeconomics and reality”, *Econometrica*, 48(1): 1-48.
- Son una generalización natural de los modelos autorregresivos univariados.

El caso más sencillo es el VAR bivariado.

En un **VAR bivariado** hay dos variables y_{1t} y y_{2t} (**estacionarias**) las cuales dependen de los p rezagos de las dos variables.

El caso más simple es el BIVAR(1):

$$\begin{cases} y_{1t} = \phi_{11}y_{1t-1} + \phi_{12}y_{2t-1} + \varepsilon_{1t} \\ y_{2t} = \phi_{21}y_{1t-1} + \phi_{22}y_{2t-1} + \varepsilon_{2t} \end{cases}$$

En términos generales, un $\text{VAR}_m(p)$:

$$y_t = \delta + \Phi_1 y_{t-1} + \Phi_2 y_{t-2} + \dots + \Phi_p y_{t-p} + \varepsilon_t$$

donde m = dimensión del VAR, p = orden del VAR, y_t es un vector de m variables (si $m = 1$, entonces es un AR(p)), δ es un vector de constantes, Φ es una matriz ($m \times m$) de coeficientes, y ε_t es un vector de m errores RB.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.
- A diferencia de los modelos univariados, permite que una variable no dependa sólo de sus propios rezagos y combinaciones lineales de términos de error RB. Un modelo AR se puede pensar como una versión restringida del VAR.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.
- A diferencia de los modelos univariados, permite que una variable no dependa sólo de sus propios rezagos y combinaciones lineales de términos de error RB. Un modelo AR se puede pensar como una versión restringida del VAR.
- En la medida en que no hayan efectos contemporáneos dentro de las variables explicativas, es posible estimar por MCO.

Ventajas de la metodología VAR

- No hace falta especificar a priori cuáles variables son endógenas o exógenas, son **todas endógenas**.
- A diferencia de los modelos univariados, permite que una variable no dependa sólo de sus propios rezagos y combinaciones lineales de términos de error RB. Un modelo AR se puede pensar como una versión restringida del VAR.
- En la medida en que no hayan efectos contemporáneos dentro de las variables explicativas, es posible estimar por MCO.
- Frecuentemente, los modelos VAR generan mejores pronósticos que los modelos estructurales (e.g. McNees, 1986).

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).
- ¿Cómo determinar la longitud p de rezagos a seleccionar?

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).
- ¿Cómo determinar la longitud p de rezagos a seleccionar?
- ¡Muchos parámetros a estimar! m ecuaciones con p lags para cada ecuación, $(m + pm^2)$ parámetros deben estimarse (problema para muestras chicas).

Desventajas de la metodología VAR

- **Principal crítica:** son ateóricos (idem modelos ARMA).
- ¿Cómo determinar la longitud p de rezagos a seleccionar?
- ¡Muchos parámetros a estimar! m ecuaciones con p lags para cada ecuación, $(m + pm^2)$ parámetros deben estimarse (problema para muestras chicas).
- TODAS las variables del VAR deben ser estacionarias.

Estimación

Selección de la longitud óptima de rezagos del VAR

En pocas oportunidades la teoría económica o financiera nos dirá algo sobre la cantidad de rezagos apropiada para estimar el VAR.

Hay básicamente dos enfoques para seleccionar la longitud óptima de rezagos del VAR:

- **Restricciones entre ecuaciones**
- **Criterios de información**

Restricciones entre ecuaciones

Comenzar estimando un VAR con varios rezagos y testear la restricción de que los últimos q rezagos son conjuntamente iguales a cero (para todas las ecuaciones).

Esto se puede hacer con un test LR:

$$LR = T[\log|\hat{\Sigma}_r| - \log|\hat{\Sigma}_u|] \sim \chi_r^2$$

donde $|\hat{\Sigma}_r|$ es el determinante de la matriz de var-cov de los residuos del VAR restringido y $|\hat{\Sigma}_u|$ es el determinante de la matriz de var-cov de los residuos del VAR irrestricto; para m ecuaciones, la cantidad de restricciones $r = q \times m^2$.

Criterios de información

La distribución χ^2 del test LR anterior será válida asintóticamente solo si los errores de cada ecuación se distribuyen normalmente (difícil de lograr, sobre todo en finanzas!).

Los criterios de información suelen utilizarse en la práctica aunque en forma **multivariada** (univariadamente podríamos llegar a seleccionar distintos rezagos para cada ecuación).

- $MAIC = -2\log|\hat{\Sigma}| + \frac{2k'}{T}$
- $MSIC = -2\log|\hat{\Sigma}| + \frac{k'}{T}\ln(T)$
- $MHQIC = -2\log|\hat{\Sigma}| + \frac{2k'}{T}\ln(\ln(T))$

donde $\hat{\Sigma}$ es la matriz de var-cov de los residuos, T es la cantidad de observaciones y k' es la cantidad total de regresores en todas las ecuaciones ($k' = m^2k + m$, para m ecuaciones de k rezagos de m variables + una constante en cada ecuación).

Criterios de información - Softwares

- En **STATA**: varsoc
- En **R**: VARselect() dentro del paquete vars
- En **EViews**: Quick/Estimate VAR... poner nombre de las variable endógenas e indicar cantidad de rezagos. Luego de la estimación del VAR ir a View/Lag Structure y se puede hacer Lag Exclusion Tests o Lag Length Criteria...
- En **OxMetrics**: en el módulo de PcGive, en: Models for time-series data / Multiple-equation Dynamic Modelling, luego de la estimación del sistema irrestricto se pueden hacer Exclusion Restrictions y pedir los criterios de información.

Utilice la base de datos `soja.csv` de la clase pasada para estimar un VAR (recuerde volver estacionarias las series). Encuentre el orden apropiado del VAR y estímelo.

- En **STATA**: `var`
- En **R**: `VAR()` dentro del paquete `vars`
- En **EViews**: Quick/Estimate VAR... poner nombre de las variable endógenas e indicar cantidad de rezagos.
- En **OxMetrics**: en el módulo de PcGive, en: Models for time-series data / Multiple-equation Dynamic Modelling

Pruebas de diagnósticos

Al estimar un VAR por MCO, necesitamos que se cumplan los supuestos clásicos. En este contexto, tenemos que preocuparnos fundamentalmente por que no haya autocorrelación en los errores.

¿Por qué?

Pruebas de diagnósticos

Al estimar un VAR por MCO, necesitamos que se cumplan los supuestos clásicos. En este contexto, tenemos que preocuparnos fundamentalmente por que no haya autocorrelación en los errores.

¿Por qué?

Se puede pensar al test de autocorrelación multivariada como otra forma de evaluar la selección de rezagos óptima. ¿Por qué?

Test de Portmanteau de Autocorrelación:

- Versión multivariada del test de Box-Pierce/Ljung-Box
- Para evaluar autocorrelación de orden superior a 1.
- La hipótesis nula es la de no autocorrelación de orden h
- El estadístico se aproxima a una distribución $\chi^2(k^2(h - p))$ donde p es el orden del VAR.

Test de Portmanteau de Autocorrelación - Softwares

- En **STATA**: `varlmar`
- En **R**: `serial.test()`
- En **EViews**: luego de estimar el VAR, ir a View/Residual Tests/Autocorrelation LM Test... e indicar la cantidad de rezagos a evaluar.
- En **OxMetrics**: aparece por default luego de estimar el VAR (en su versión F)

Pruebas de diagnósticos

Existen versiones multivariadas de todas las otras pruebas usuales de diagnóstico que realizamos luego de una estimación por MCO.

Veremos el caso de la prueba multivariada de normalidad de los errores (será sobretodo importante para cuando más adelante veamos cointegración en sistemas).

Usualmente los softwares implementan el **test de Jarque-Bera** en forma multivariada:

- La hipótesis nula es la de normalidad multivariada
- Se reporta el test multivariado y univariado (para cada ecuación del VAR)
- Generalmente se reporta también el test de asimetría y el de curtosis.

- En **STATA**: `varnorm`
- En **R**: `normality.test()`
- En **EViews**: luego de estimar el VAR, ir a View/Residual Tests/Normality Test....
- En **OxMetrics**: aparece por default luego de estimar el VAR.
(Para más detalles ir a la ventana de Test)

VAR estructural

¿Y los efectos contemporáneos?

Hasta ahora hemos especificado modelos VAR que no incluyen, dentro de las variables explicativas, términos contemporáneos.

$$y_t = A_1 y_{t-1} + \cdots + A_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim (0, \Sigma_\varepsilon)$$

(los términos determinísticos se suprimen por simplicidad)

Si pensamos en un BIVAR(1). **¿Cuántos parámetros hay que estimar?**

¿Y los efectos contemporáneos?

Hasta ahora hemos especificado modelos VAR que no incluyen, dentro de las variables explicativas, términos contemporáneos.

$$y_t = A_1 y_{t-1} + \cdots + A_p y_{t-p} + \varepsilon_t, \quad \varepsilon_t \sim (0, \Sigma_\varepsilon)$$

(los términos determinísticos se suprimen por simplicidad)

Si pensamos en un BIVAR(1). **¿Cuántos parámetros hay que estimar?**

- $m \times m = 2 \times 2 = 4$ coeficientes de la matriz A_1
- 2 varianzas: $\sigma_{\varepsilon_1}^2$ y $\sigma_{\varepsilon_2}^2$

¿Y los efectos contemporáneos?

Pero podríamos estar interesados en estudiar un caso del estilo:

$$y_{1t} = \beta_{11}y_{1t-1} + \alpha_{11}y_{2t-1} + \alpha_{12}y_{2t} + \varepsilon_{1t}$$

$$y_{2t} = \beta_{21}y_{2t-1} + \alpha_{21}y_{1t-1} + \alpha_{22}y_{1t} + \varepsilon_{2t}$$

En forma matricial:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \alpha_{12} & 0 \\ 0 & \alpha_{22} \end{pmatrix} \begin{pmatrix} y_{2t} \\ y_{1t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Se conoce como el **VAR estructural**.

Sin embargo, este modelo es inconsistente si se lo estima por MCO, ¿por qué?

¿Y los efectos contemporáneos?

Pero podríamos estar interesados en estudiar un caso del estilo:

$$y_{1t} = \beta_{11}y_{1t-1} + \alpha_{11}y_{2t-1} + \alpha_{12}y_{2t} + \varepsilon_{1t}$$

$$y_{2t} = \beta_{21}y_{2t-1} + \alpha_{21}y_{1t-1} + \alpha_{22}y_{1t} + \varepsilon_{2t}$$

En forma matricial:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \alpha_{12} & 0 \\ 0 & \alpha_{22} \end{pmatrix} \begin{pmatrix} y_{2t} \\ y_{1t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Se conoce como el **VAR estructural**.

Sin embargo, este modelo es inconsistente si se lo estima por MCO, ¿por qué?

Además, no está identificado.

Noten lo siguiente. Agrupando los términos contemporáneos:

$$\begin{pmatrix} 1 & -\alpha_{12} \\ -\alpha_{22} & 1 \end{pmatrix} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

o

$$By_t = \Gamma_1 y_{t-1} + \varepsilon_t$$

Esta es la representación matricial del *modelo estructural*.

Noten lo siguiente. Agrupando los términos contemporáneos:

$$\begin{pmatrix} 1 & -\alpha_{12} \\ -\alpha_{22} & 1 \end{pmatrix} \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \alpha_{11} \\ \alpha_{21} & \beta_{21} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

o

$$By_t = \Gamma_1 y_{t-1} + \varepsilon_t$$

Esta es la representación matricial del *modelo estructural*.

Si B admite inversa (lo cual requiere que $\alpha_{12}\alpha_{22} \neq 1$):

$$y_t = B^{-1}\Gamma_1 y_{t-1} + B^{-1}\varepsilon_t$$

o

$$y_t = A_1 y_{t-1} + u_t$$

Pasamos a la forma reducida (modelo VAR), en la cual los coeficientes de y_t son la matriz identidad.

¿Pero cuántos parámetros hay que estimar?

Identificación del VAR estructural

$$y_t = A_1 y_{t-1} + u_t$$

- $m \times m = 2 \times 2 = 4$ coeficientes de la matriz A_1
- 2 varianzas: $\sigma_{u_1}^2$ y $\sigma_{u_2}^2$
- 1 covarianza: σ_{u_1, u_2}

Es un caso de **sobreidentificación** por lo que no podremos estimar el modelo VAR (en su forma reducida) si no imponemos alguna **restricción** de nulidad sobre α_{12} o α_{22} .

Identificación del VAR estructural

La elección de cuál de las 2 restricciones imponer idealmente deberá basarse en cuestiones de teoría económica/financiera.

Ejemplo:

Si la teoría sugiere que y_{1t} debe afectar a y_{2t} , pero no a la inversa, entonces $\alpha_{12} = 0$.

Otra posibilidad es estimar por separado imponiendo primero $\alpha_{12} = 0$ y luego $\alpha_{22} = 0$, para determinar si las características principales de los resultados varían mucho o no.

VAR con variables exógenas

Asimismo, el modelo VAR puede incorporar vectores de variables explicativas exógenas z_t en cada ecuación:

Ejemplo:

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \delta_1 \\ \delta_2 \end{pmatrix} \begin{pmatrix} z_{1t} \\ z_{2t} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

que también puede aparecer con rezagos de z_t . Dentro del vector de variables exógenas puede haber una tendencia determinística, o variables ficticias estacionales.

Interpretación

Interpretación del VAR

No tiene sentido interpretar los coeficientes estimados.

En la práctica es común basar la interpretación en:

Tests:

- (1) Relevancia de variables
- (2) Significatividad de rezagos
- (3) Relaciones entre ecuaciones
- (4) Causalidad en sentido de Granger

Simulaciones:

- (1) Funciones impulso-respuesta (FIR)
- (2) Descomposición de la varianza (DV)

Pruebas de hipótesis

Supongamos BIVAR(3) (sin constantes, por simplicidad):

$$\begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix} \begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix} + \begin{pmatrix} \gamma_{11} & \gamma_{12} \\ \gamma_{21} & \gamma_{22} \end{pmatrix} \begin{pmatrix} y_{1t-2} \\ y_{2t-2} \end{pmatrix} \\ + \begin{pmatrix} \delta_{11} & \delta_{12} \\ \delta_{21} & \delta_{22} \end{pmatrix} \begin{pmatrix} y_{1t-3} \\ y_{2t-3} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix}$$

Hipótesis que podemos estar interesados en evaluar:

Hipótesis	Restricciones
Rezagos de y_{1t} no explican a y_{2t}	$\beta_{21} = 0$ & $\gamma_{21} = 0$ & $\delta_{21} = 0$
Rezagos de y_{1t} no explican a y_{1t}	$\beta_{11} = 0$ & $\gamma_{11} = 0$ & $\delta_{11} = 0$
Rezagos de y_{2t} no explican a y_{1t}	$\beta_{12} = 0$ & $\gamma_{12} = 0$ & $\delta_{12} = 0$
Rezagos de y_{2t} no explican a y_{2t}	$\beta_{22} = 0$ & $\gamma_{22} = 0$ & $\delta_{22} = 0$

Pruebas de hipótesis

Para cualquiera de los 4 casos, el test consiste en evaluar la validez de las restricciones.

Si $\varepsilon_t \sim RB(0, \Omega)$,

$$(T - c)(\ln|\hat{\Omega}_r| - \ln|\hat{\Omega}_u|) \sim \chi^2(m)$$

asintóticamente bajo H_0 , en donde $\hat{\Omega}_r$ y $\hat{\Omega}_u$ son las matrices de varianzas del modelo restringido y sin restringir, respectivamente, m es el número de restricciones, c es el número de parámetros estimados en cada ecuación en el modelo sin restringir, y T es el número de observaciones.

Causalidad en sentido de Granger - usos y abusos

- Volveremos sobre este concepto más adelante (cuando veamos cointegración).
- Tan solo indica precedencia temporal de una variable respecto de otra.
- Es muy importante (pero no lo único) en un ejercicio de forecasting.
- La H_0 es la de “no-causalidad en sentido de Granger”. **¿Por qué?**

Causalidad en sentido de Granger - usos y abusos

- Volveremos sobre este concepto más adelante (cuando veamos cointegración).
- Tan solo indica precedencia temporal de una variable respecto de otra.
- Es muy importante (pero no lo único) en un ejercicio de forecasting.
- La H_0 es la de “no-causalidad en sentido de Granger”. **¿Por qué?**
- Mucha gente abusa de este test como prueba de causalidad **(NO LO ES)**.

Causalidad en sentido de Granger - Aplicación

Utilice la base de datos `soja.csv` que contiene datos del precio spot y futuro de la soja en Chicago (medidos en dólares por TM). Tome la diferencia logarítmica de dichas variables. Estime un VAR apropiado y evalúe causalidad en sentido de Granger.

- En **STATA**: `vargranger`
- En **R**: `grangertest()`
- En **EViews**: luego de estimar el VAR, ir a View/Lag Structure/Granger Causality....
- En **OxMetrics**: implementar un test de restricciones en la ventana de Test.

Funciones Impulso-Respuesta

Las **Funciones Impulso-Respuesta** (FIR) evalúan la capacidad de respuesta de las variables dependientes del VAR ante variaciones exógenas.

Funciones Impulso-Respuesta

Las **Funciones Impulso-Respuesta** (FIR) evalúan la capacidad de respuesta de las variables dependientes del VAR ante variaciones exógenas.

Un VAR(p) estacionario tiene una representación VMA(∞):

$$Y_t = \sum_{s=0}^{\infty} \Psi_s \varepsilon_{t-s}, \quad \Psi_0 = I_m, \quad \varepsilon_t \sim RBM$$

$$\frac{\partial Y_t}{\partial \varepsilon_{t-j}} = \frac{\partial Y_{t+s}}{\partial \varepsilon_t} = \Psi_s$$

$\Psi_{ij}(s)$: Efecto sobre $Y_{i,t+s}$ de cambiar ε_{jt} en una unidad.

$\Psi_{ij}(s) / \sqrt{V(\varepsilon_{jt})}$: Efecto sobre $Y_{i,t+s}$ de cambiar ε_{jt} en un desvío estándar: **función impulso respuesta simple**.

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,
- la inversión (y_1) se incrementa en 1 unidad en $t = 0$: $\varepsilon_{1,0} = 1$.

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,
- la inversión (y_1) se incrementa en 1 unidad en $t = 0$: $\varepsilon_{1,0} = 1$.
- Ahora podemos rastrear qué pasa con el sistema durante los períodos subsiguientes: $t = 1, 2, \dots$ **si...**

Ejemplo

Queremos analizar el efecto de un shock de la inversión en un sistema que incluye: inversión (y_1), ingreso (y_2) y consumo (y_3).

Para aislar dicho efecto, supongamos que:

- las 3 variables tienen una media dada por $y_t = \mu$ para $t < 0$,
- la inversión (y_1) se incrementa en 1 unidad en $t = 0$: $\varepsilon_{1,0} = 1$.
- Ahora podemos rastrear qué pasa con el sistema durante los períodos subsiguientes: $t = 1, 2, \dots$ **si...**
- **no ocurren más shocks.** Es decir,
 $\varepsilon_{2,0} = \varepsilon_{3,0} = 0, \varepsilon_1 = 0, \varepsilon_2 = 0, \dots$
- Como no estamos interesados en la media del sistema en este ejercicio sino solo en las variaciones de las variables entorno de la media, asumimos que todas las variables tienen media cero. Es decir, $y_t = A_1 y_{t-1} + \varepsilon_t$

Ejemplo

Consideremos el siguiente VAR(1) en función del ejemplo anterior:

$$\begin{bmatrix} y_{1,t} \\ y_{2,t} \\ y_{3,t} \end{bmatrix} = \begin{bmatrix} 0,5 & 0 & 0 \\ 0,1 & 0,1 & 0,3 \\ 0 & 0,2 & 0,3 \end{bmatrix} \begin{bmatrix} y_{1,t-1} \\ y_{2,t-1} \\ y_{3,t-1} \end{bmatrix} + \begin{bmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \\ \varepsilon_{3,t} \end{bmatrix}$$

Ejemplo

Consideremos ahora el efecto temporal que tiene un shock de 1 unidad en la variable y_1 en $t = 0$:

$$y_0 = \begin{bmatrix} y_{1,0} \\ y_{2,0} \\ y_{3,0} \end{bmatrix} = \begin{bmatrix} \varepsilon_{1,0} \\ \varepsilon_{2,0} \\ \varepsilon_{3,0} \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix},$$

En $t = 1$:

$$y_1 = \begin{bmatrix} y_{1,1} \\ y_{2,1} \\ y_{3,1} \end{bmatrix} = A_1 y_0 = \begin{bmatrix} 0,5 \\ 0,1 \\ 0 \end{bmatrix}$$

Ejemplo

En $t = 2$:










$$y_2 = \begin{bmatrix} y_{1,2} \\ y_{2,1} \\ y_{3,1} \end{bmatrix} = A_1 y_1 = A_1^2 y_0 = \begin{bmatrix} 0,25 \\ 0,06 \\ 0,02 \end{bmatrix}$$

y así continua.

En general, las FIR se grafican para tener una impresión visual de la dinámica de las interrelaciones dentro del sistema.

Ejemplo

(impulso $\rightarrow$ respuesta)



- En **STATA**: `irf`
- En **R**: `irf()` en el paquete `vars`
- En **EViews**: luego de estimar el VAR, ir a View/Impulse Response....
- En **OxMetrics**: luego de estimar el VAR, ir a Test/Simulation and Impulse Responses....

Utilice la base de datos `var.csv` que contiene un ejemplo de Lütkepohl (2007) en el cual se usan series trimestrales (desestacionalizadas) de la inversión fija en Alemania Occidental, el ingreso disponible y el gasto de consumo en miles de millones de marcos alemanes entre 1960Q1 y 1982Q4. Se pide:

- (1) Grafique las 3 variables. ¿Le parecen estacionarias?
Transfórmelas de ser necesario.
- (2) Estime un VAR(2) con constante. Respete el ordenamiento:
`invest, income, cons`.
- (3) Obtenga las FIR (trabajando con shocks ortogonales).
Ejemplo en R:

```
irf(model, impulse="income", response="cons",  
n.ahead=8, ortho=TRUE, runs=1000, seed=12345)
```

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.
- Mide **proporción de los movimientos en las variables dependientes que se deben a shocks “propios” vs. shocks de otras variables.**

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.
- Mide **proporción de los movimientos en las variables dependientes que se deben a shocks “propios” vs. shocks de otras variables.**
- Recordar que la FIR se refiere al shock en el término de error de solo una de las ecuaciones del VAR (los otros errores permanecen constantes).
- Esto no es realista → es común que los errores de las ecuaciones estén **correlacionados.**

¿Qué implica que los errores estén correlacionados?

Descomposición de la Varianza (DV)

- Método alternativo para estudiar la dinámica de un VAR.
- Mide **proporción de los movimientos en las variables dependientes que se deben a shocks “propios” vs. shocks de otras variables.**
- Recordar que la FIR se refiere al shock en el término de error de solo una de las ecuaciones del VAR (los otros errores permanecen constantes).
- Esto no es realista → es común que los errores de las ecuaciones estén **correlacionados**.
 - ¿Qué implica que los errores estén correlacionados?
- Queremos ver entonces las respuestas de las variables ante **impulsos ortogonales**

Ortogonalización

El enfoque usual es ortogonalizar las FIR.

En un VAR bivariado, si los errores no son independientes entonces:

$$V(\varepsilon_t) = \Omega = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}$$

- Si Ω es simétrica y definida positiva, existe H no singular, tal que $\Omega = HH'$.
- Si ε_t es un vector aleatorio con $E(\varepsilon_t) = 0$ y $V(\varepsilon_t) = E(\varepsilon_t \varepsilon_t') = \Omega$, existe H tal que $\varepsilon_t = H v_t$, en donde v_t es un vector aleatorio con $E(v_t) = 0$ y $V(v_t) = I$.

v_t son las **innovaciones ortogonales** de ε_t .

¡El problema es que H no es única!

¡El problema es que H no es única!

Si Ω es simétrica y definida positiva, existe una **única** matriz P no singular y triangular inferior tal que $PP' = \Omega$. Donde P es la **matriz de Choleski** de Ω .

Entonces, la idea es utilizar $\varepsilon_t = Pv_t$

Descomposición de Choleski

La descomposición de Choleski (el uso de P) implica cierta arbitrariedad.

Ejemplo: En el caso del VAR bivariado:

$$\begin{pmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \end{pmatrix} = \begin{pmatrix} P_{11} & 0 \\ P_{21} & P_{22} \end{pmatrix} \begin{pmatrix} v_{1t} \\ v_{2t} \end{pmatrix}$$

ε_{1t} depende solo de v_{1t} ; ε_{2t} depende de v_{1t} y v_{2t} .

La dependencia entre ε_{1t} y ε_{2t} es generada por esta estructura recursiva.

Piensen en las implicancias que tendría, por ejemplo, que Y_1 sea la tasa de crecimiento monetario y Y_2 la tasa de inflación.

Una cuestión importante, entonces, es definir el **orden** de las variables de la matriz de Choleski.

Descomposición de Choleski

Notar que si:

$$\Omega = \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix} \Rightarrow P = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 \\ 0 & \sqrt{\sigma_{22}} \end{bmatrix}$$

- Si Ω es diagonal, el orden de la descomposición de Choleski no importa
- Trivialmente, las innovaciones originales son también innovaciones ortogonales
- En la práctica, entonces, es importante evaluar empíricamente la diagonalidad de Ω .

Descomposición de la Varianza (DV)

La **Descomposición de la Varianza** responde a la pregunta: ¿cuánto de la variabilidad total de una variable del VAR es atribuible a movimientos en cada una de las otras variables?

(Idea análoga al R^2 en el modelo lineal).

Un poco de álgebra:

- Si Ω es simétrica y definida positiva, existe una única matriz H triangular inferior con 1's en la diagonal principal, y una matriz diagonal D con todos sus elementos positivos, tal que $\Omega = HDH'$.
- Si ε_t es un vector aleatorio con $E(\varepsilon_t) = 0$ y $V(\varepsilon_t) = \Omega$, entonces ε_t puede escribirse como $\varepsilon_t = Hu_t$, con $E(u_t) = 0$ y $V(u_t) = D$, en donde H y D satisfacen $\Omega = HDH'$.

Descomposición de la Varianza (DV)

Si partimos de la representación $MA(\infty)$ del VAR:

$$y_t = \sum_{s=0}^{\infty} \Psi_s \varepsilon_{t-s}, \quad \Psi_0 = I_m, \quad \varepsilon_t \sim RBM$$

Si vamos s -períodos adelante:

$$y_{t+s} = \sum_{i=0}^{\infty} \Psi_i \varepsilon_{t+s-i}$$

El error de pronóstico será:

$$y_{t+s} - E_t(y_{t+s}) = \sum_{i=0}^{s-1} \Psi_i \varepsilon_{t+s-i}$$

Descomposición de la Varianza (DV)

El error cuadrático medio del pronóstico s -pasos adelante será:

$$\begin{aligned}MSE(\hat{y}_{t+s|t}) &= E[(y_{t+s} - \hat{y}_{t+s|t})(y_{t+s} - \hat{y}_{t+s|t})'] \\&= \Omega + \Psi_1 \Omega \Psi_1' + \Psi_2 \Omega \Psi_2' + \dots + \Psi_{s-1} \Omega \Psi_{s-1}'\end{aligned}$$

donde

$$\Omega = E(\varepsilon_t \varepsilon_t')$$

Descomposición de la Varianza (DV)

Si consideramos cómo los errores ortogonalizados (u_t) contribuyen al MSE, sabiendo que $\varepsilon_t = Hu_t$:

$$\Omega = E(\varepsilon_t \varepsilon_t') = h_1 h_1' V(u_{1t}) + h_2 h_2' V(u_{2t}) + \dots + h_n h_n' V(u_{nt})$$

donde $V(u_{jt})$ es el elemento de la fila j , columna j de la matriz D . Entonces, el MSE s -pasos adelante puede re-escribirse como:

$$MSE(\hat{y}_{t+s|t}) = \sum_{j=1}^n \{ V(u_{jt}) [h_j h_j' + \Psi_1 h_j h_j' \Psi_1' + \Psi_2 h_j h_j' \Psi_2' + \dots + \Psi_{s-1} h_j h_j' \Psi_{s-1}'] \}$$

Descomposición de la Varianza (DV)

Entonces, puede calcularse la contribución de la j -ésima innovación ortogonal del MSE del pronóstico s -pasos adelante:

$$V(u_{jt})[h_{jj}' + \Psi_1 h_{jj} \Psi_1' + \Psi_2 h_{jj} \Psi_2' + \dots + \Psi_{s-1} h_{jj} \Psi_{s-1}']$$

- La magnitud en general depende del ordenamiento de las variables.
- A medida que $s \rightarrow \infty$ para un VAR estacionario, $\text{MSE}(\hat{y}_{t+s|t}) \rightarrow V(y_t)$.

Entonces, la expresión anterior permite calcular la proporción de la varianza de y_t que se debe al error u_j dejando que s sea lo suficientemente grande.

En la práctica: computar la DV para $s = 1, 2, 3, \dots$

Sobre la base de datos anterior (`var.csv`) obtenga la descomposición de la varianza.

- En **STATA**: `irf table fevd`
- En **R**: `fevd()`
- En **EViews**: luego de estimar el VAR, ir a View/Variance Decomposition....

- Lütkepohl (2005) - Cap. 2 a 4
- Hamilton (1994) - Cap. 11

Procesos No Estacionarios

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata


Introducción

Cuando asumíamos que una serie es **estacionaria (en sentido débil)** esto implicaba que:


- $E(y_t) = \mu$ (1 parámetro)
- $Var(y_t) = \gamma_0$ (1 parámetro)
- $Cov(y_t, y_{t+j}) = \gamma_j$ ($T-1$ parámetros)

¿Qué pasa si m_1 o m_2 varían en el tiempo?

Casos de no estacionariedad



No estacionariedad en media



Caso heterocedástico

Tendencia determinística

Estacionariedad en torno a una tendencia

Consideren el siguiente proceso:

$$y_t = \alpha + \beta t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Si calculan la media y la varianza, ¿qué observan?

Estacionariedad en torno a una tendencia

Consideren el siguiente proceso:

$$y_t = \alpha + \beta t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Si calculan la media y la varianza, ¿qué observan?

- $E(y_t) = \alpha + \beta t$
- $Var(y_t) = \sigma^2$

Si definimos una nueva variable y^* , $y^* = y - (\alpha + \beta t)$, se vuelve estacionaria.

Ejemplo - Enders (2010)

Utilice el archivo “RGDP.xls” que contiene valores trimestrales del PBI real de EE.UU. entre 1947Q1-2008Q1 (en billones de dólares del año 2000).

- Grafique. ¿Qué observa?

Ejemplo - Enders (2010)

Utilice el archivo “RGDP.xls” que contiene valores trimestrales del PBI real de EE.UU. entre 1947Q1-2008Q1 (en billones de dólares del año 2000).

- Grafique. ¿Qué observa?
- Un pronosticador “naive” decide estimar el incremento sostenido en el PBI real con un modelo que sigue una función cúbica (polinómica de grado 3) respecto del tiempo. Esto es,

$$rgdp_t = a + b.t + c.t^2 + d.t^3 + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

- Estime dicho modelo y grafique la serie original junto con la estimada.
- Obtenga la serie sin tendencia.
- ¿Qué implicancias económicas, respecto del largo plazo del PBI real, tiene este modelo?

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**.
Los shocks no se acumulan, no son permanentes. ¿Por qué?

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**. Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**. Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).
- Una tendencia determinística implica que no existe incertidumbre sobre la evolución futura de la tendencia $\Rightarrow$ **conocido el pasado, el futuro es previsible.**

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**.
Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).
- Una tendencia determinística implica que no existe incertidumbre sobre la evolución futura de la tendencia $\Rightarrow$ **conocido el pasado, el futuro es previsible.**
- ¡POCO REALISTA!

Tendencia Determinística

- El caso anterior es un proceso con **tendencia determinística**. Los shocks no se acumulan, no son permanentes. ¿Por qué?
- Son **funciones del tiempo** (polinomios de orden 1 o superior).
- Una tendencia determinística implica que no existe incertidumbre sobre la evolución futura de la tendencia $\Rightarrow$ **conocido el pasado, el futuro es previsible.**
- ¡POCO REALISTA!
- Es más realista el caso de la **tendencia estocástica**, donde hay incertidumbre respecto de la evolución futura del proceso.

¿Qué pasa si trabajamos con series con tendencia?

Ejemplo de Vogelsang, MSU 2017

- Considere el modelo estimado por MCO entre 1900 y 2012:

$$\widehat{temp}_t = -3,51 + 0,368 \log(rpcgdpus_t), \quad R^2 = 0,740$$

(0,193) (0,021)

donde $temp_t$ es la temperatura anual global (en °C) y $rpcgdpus_t$ es el PBI real per cápita anual de USA.

- ¿Qué se observa?
 - La variación en el PBI real de USA explica un 74 % de la variación en la temperatura global.
 - La pendiente del PBI es muy significativa ($t = 17,87$).

¿Qué pasa si trabajamos con series con tendencia?

Ejemplo de Vogelsang, MSU 2017

- Considere el modelo estimado por MCO entre 1900 y 2012:


$$\widehat{temp}_t = -3,51 + 0,368 \log(rpcgdpus_t), \quad R^2 = 0,740$$

(0,193) (0,021)


donde $temp_t$ es la temperatura anual global (en °C) y $rpcgdpus_t$ es el PBI real per cápita anual de USA.

- ¿Qué se observa?
 - La variación en el PBI real de USA explica un 74 % de la variación en la temperatura global.
 - La pendiente del PBI es muy significativa ($t = 17,87$).
- **¿Esto implica que la actividad económica en USA está produciendo cambios en la temperatura global?**


Annual Averaged Global Temperatures (Land and Sea)



Log Real Per Capita GDP: United States



Log Real Per Capita GDP: United Kingdom



Trabajando con datos con tendencia

- ¿Es culpa de la reina?




$$\widehat{temp}_t = -4,18 + 0,452 \log(rpcgdpuk_t), \quad R^2 = 0,784$$

(0,185) (0,020)

- ¡El estadístico t del PBI per capital real de UK es 22,47!

Global Temperatures and Log of Real Per Capita GDP



El problema de la regresión espuria

- Supongan que y_t está dada por:

$$y_t = \alpha_0 + \alpha_1 t + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

Y que la variable x_t está dada por:

$$x_t = \lambda_0 + \lambda_1 t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

- donde $\alpha_1 \neq 0$ y $\lambda_1 \neq 0$ y que v_t y ε_t están incorrelacionadas entre sí.
- Entonces, no existe una relación entre y_t y x_t

El problema de la regresión espuria

- Supongan que y_t está dada por:

$$y_t = \alpha_0 + \alpha_1 t + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

Y que la variable x_t está dada por:

$$x_t = \lambda_0 + \lambda_1 t + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

- donde $\alpha_1 \neq 0$ y $\lambda_1 \neq 0$ y que v_t y ε_t están incorrelacionadas entre sí.
- Entonces, no existe una relación entre y_t y x_t
- Sin embargo, la estimación por MCO:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

nos cuenta una historia diferente.

El problema de la regresión espuria

- Es conceptualmente fácil, aunque algebraicamente complicado, mostrar que para:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

Los siguientes resultados se mantienen:

$$p \lim \hat{\beta}_1 = \frac{\alpha_1}{\lambda_1}, \quad |t_{\beta_1=0}| \xrightarrow{d} \infty, \quad p \lim R^2 = 1$$

- Estos resultados sugieren que:
 - Si nuestras variables muestran un comportamiento tendencial sistemático a lo largo del tiempo, **los resultados de la regresión son potencialmente espurios.**
 - No podemos aprender nada sobre la relación entre variables a partir de un modelo simple de regresión en nivel.

El problema de la regresión espuria

- **Alguna intuición sobre los resultados espurios:**

- Cuando y_t y x_t no están relacionados, nuestra regresión:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

se convierte, en la población, en:

$$y_t = \alpha_0 + \alpha_1 t + v_t$$

donde ahora está claro que $\beta_1 = 0, \beta_0 = \alpha_0, u_t = \alpha_1 t + v_t$ en la regresión original.

- Por lo que t puede pensarse como una variable omitida.
- Como t está correlacionada con x_t (ya que x_t depende de una tendencia), aparece el **sesgo por variables omitidas**.

El problema de la regresión espuria - Solución

- (1) Incluir el regresor omitido, t :

$$y_t = \beta_0 + \beta_1 x_t + \beta_2 t + u_t$$

- (2) Alternativamente, nos podemos preguntar si las partes aleatorias de y_t y x_t están relacionadas.

El problema de la regresión espuria - Solución

- El caso (2) implica evaluar si v_t y ε_t están relacionadas.
- **Problema:** v_t y ε_t son inobservables.
- Podemos obtener proxies de v_t y ε_t si:
 - Regresamos y_t en función de una constante y de t y calculamos los residuos:

$$\ddot{y}_t = y_t - \hat{\alpha}_0 - \hat{\alpha}_1 t$$

- Regresamos x_t en función de una constante y de t y calculamos los residuos:

$$\ddot{x}_t = x_t - \hat{\lambda}_0 - \hat{\lambda}_1 t$$

- Las variables $\ddot{y}_t$ y $\ddot{x}_t$ se denominan variables destendenciadas.

El problema de la regresión espuria - Solución

- Se puede re-estimar el modelo a partir de las series destendenciadas:

$$\ddot{y}_t = \beta_0 + \beta_1 \ddot{x}_t + \ddot{u}_t$$

- La estimación del coeficiente de la pendiente indica si existe una relación entre y y x a través de v y ε .
- Ahora el estadístico t de β_1 tiene las propiedades usuales.
- El R^2 de esta regresión ($\ddot{R}^2$) mide la proporción de la variación de y_t **en torno a su tendencia** que es explicada por la variación en x_t **en torno a su tendencia**.

Tendencia estocástica

Tendencia Estocástica

Ok. Pero todo este análisis fue para casos de tendencias determinísticas (¡poco realistas!).

Tendencia Estocástica


Ok. Pero todo este análisis fue para casos de tendencias determinísticas (¡poco realistas!).

- La series financieras y/o económicas pueden presentar a lo largo de su historia **distintas tendencias o medias locales que cambian en el tiempo.**
- Esto implica que no estaríamos ante una serie de crecimiento tendencial, pero tampoco la serie temporal sería estacionaria.
- Los cambios en la media pueden ocurrir con gran frecuencia debido a distintos factores y la tendencia se captaría mejor con un **esquema estocástico.**

Camino Aleatorio (Random Walk)

Un **random walk** es un AR(1) con $\phi = 1$:

$$y_t = y_{t-1} + \varepsilon_t$$



¿Qué implica el RW en términos de pronóstico?

AR(1) vs RW

Sea,

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim IID(0, \sigma^2)$$





AR(1)	RW
$ \phi < 1$	$ \phi = 1$
$\gamma_0 = \frac{\sigma^2}{1-\phi}$	$\gamma_0 = t\sigma^2 \Rightarrow \text{cuando } t \rightarrow \infty \Rightarrow \gamma_0 \rightarrow \infty$
$\rho_j = \phi^j$	$\rho_j = \sqrt{1 - \frac{j}{t}} \Rightarrow \text{cuando } t \rightarrow \infty \Rightarrow \rho_j \rightarrow 1$
Shocks temporarios	Shocks permanentes

Simule las siguientes series de tiempo para $T = 100$:

- $y_t = 0,8y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$
- $y_t = y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$
- $y_t = 1,05y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$

Graficar y observar los correlogramas.


Simulación



Tipos de Random Walk

- RW (puro): $y_t = y_{t-1} + \varepsilon_t$
- RW con constante: $y_t = \alpha + y_{t-1} + \varepsilon$
- RW con tendencia: $y_t = \alpha + \beta t + y_{t-1} + \varepsilon_t$

Calculen sus medias y varianzas.



Formas para remover la tendencia:

- Diferenciación
- Destendenciado

Diferenciar o Destendenciar

Prueben diferenciar y/o destendenciar los siguientes procesos hasta volverlos estacionarios:

- $y_t = y_{t-1} + \varepsilon_t$
- $y_t = \alpha + y_{t-1} + \varepsilon_t$
- $y_t = \alpha + \beta.t + \varepsilon_t$
- $y_t = \alpha + \beta.t + y_{t-1} + \varepsilon_t$

Pruebas de raíz unitaria

Raíces Unitarias

Consideren el siguiente proceso estocástico:

$$y_t = \phi y_{t-1} + \varepsilon_{t-1}, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Es un proceso AR(1) que resulta estacionario si $|\phi| < 1$.

Un **test de raíz unitaria** entonces equivale a evaluar:

$$H_0 : \phi = 1 \Rightarrow H_0 : \phi - 1 = 0$$

Naturalmente, el estadístico que utilizaríamos para evaluar H_0 es:

$$T = \frac{\hat{\phi} - 1}{SE(\hat{\phi})}$$

El problema es que bajo la H_0 **ya no podremos usar la teoría asintótica estándar para estudiar el comportamiento del estadístico.**

Test de Dickey-Fuller (1979)

Existen diversos tests para evaluar la presencia de una raíz unitaria, siendo el **Test de Dickey-Fuller** el más conocido.

$$\text{Sea } y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2)$$

$$H_0 : \phi = 1$$

$$H_1 : \phi < 1$$

Se puede reparametrizar de la siguiente manera:

$$\Delta y_t = (\phi - 1)y_{t-1} + \varepsilon_t = \psi y_{t-1} + \varepsilon_t$$

Lo cual equivale a evaluar:

$$H_0 : \psi = 0$$

$$H_1 : \psi < 0$$


Test de Dickey-Fuller

$$H_0 : \psi = 0$$

$$H_1 : \psi < 0$$

$$T = \frac{\hat{\psi}}{SE(\hat{\psi})} = \frac{\hat{\phi} - 1}{SE(\hat{\phi})}$$

Dickey y Fuller (1979) obtuvieron la distribución específica de este estadístico cuyos valores críticos son más negativos que los de una distribución normal.



Test de Dickey-Fuller

Existen tres versiones del test:

(1) Test de raíz unitaria (sin componentes determinísticos):

$$\Delta y_t = \psi y_{t-1} + \varepsilon_t$$

(2) Test de raíz unitaria con constante:

$$\Delta y_t = \alpha + \psi y_{t-1} + \varepsilon_t$$

(3) Test de raíz unitaria con constante y tendencia determinística:

$$\Delta y_t = \alpha + \beta t + \psi y_{t-1} + \varepsilon_t$$

Test de Dickey-Fuller - Softwares

- En **STATA**: `dfuller`
- En **R**: `ur.df()` usar el package `urca`
- En **EViews**: desde la serie ir a View/Unit Root Test....
- En **OxMetrics**: en PcGive/Other Models/Descriptive Statistics using PcGive... seleccionar la variable y seleccionar Unit root tests.

Tabla de Dickey-Fuller

Probability of a Smaller Value	0.01	0.025	0.05	0.10	0.90	0.95	0.975	0.99
Sample Size								
No Constant or Time ($a_0 = a_2 = 0$)				τ				
25	-2.66	-2.26	-1.95	-1.60	0.92	1.33	1.70	2.16
50	-2.62	-2.25	-1.95	-1.61	0.91	1.31	1.66	2.08
100	-2.60	-2.24	-1.95	-1.61	0.90	1.29	1.64	2.03
250	-2.58	-2.23	-1.95	-1.62	0.89	1.29	1.63	2.01
300	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
∞	-2.58	-2.23	-1.95	-1.62	0.89	1.28	1.62	2.00
Constant ($a_2 = 0$)				τ_μ				
25	-3.75	-3.33	-3.00	-2.62	-0.37	0.00	0.34	0.72
50	-3.58	-3.22	-2.93	-2.60	-0.40	-0.03	0.29	0.66
100	-3.51	-3.17	-2.89	-2.58	-0.42	-0.05	0.26	0.63
250	-3.46	-3.14	-2.88	-2.57	-0.42	-0.06	0.24	0.62
500	-3.44	-3.13	-2.87	-2.57	-0.43	-0.07	-0.24	0.61
∞	-3.43	-3.12	-2.86	-2.57	-0.44	-0.07	0.23	0.60
Constant + time				τ_t				
25	-4.38	-3.95	-3.60	-3.24	-1.14	-0.80	-0.50	-0.15
50	-4.15	-3.80	-3.50	-3.18	-1.19	-0.87	-0.58	-0.24
100	-4.04	-3.73	-3.45	-3.15	-1.22	-0.90	-0.62	-0.28
250	-3.99	-3.69	-3.43	-3.13	-1.23	-0.92	-0.64	-0.31
500	-3.98	-3.68	-3.42	-3.13	-1.24	-0.93	-0.65	-0.32
∞	-3.96	-3.66	-3.41	-3.12	-1.25	-0.94	-0.66	-0.33

Source: This table was constructed by David A. Dickey using Monte Carlo methods. Standard errors of the estimates vary, but most are less than 0.20. The table is reproduced from Wayne Fuller, *Introduction to Statistical Time Series*. (New York: John Wiley). 1976.

Test de Dickey-Fuller Aumentado

En realidad, asumir que todas las variables pueden ser representadas por un AR(1) es una simplificación muy grande.

¿Qué pasa si ε_t no es IID?

Test de Dickey-Fuller Aumentado

En realidad, asumir que todas las variables pueden ser representadas por un AR(1) es una simplificación muy grande.

¿Qué pasa si ε_t no es IID?

Test de Dickey-Fuller Aumentado (ADF): extensión a un modelo AR(p)

Supongamos que y_t es un AR(2):

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

Si sumamos y restamos $\phi_2 y_{t-1}$:

$$y_t = (\phi_1 + \phi_2) y_{t-1} - \phi_2 \Delta y_{t-1} + \varepsilon_t$$

$$\Delta y_t = (\phi_1 + \phi_2 - 1) y_{t-1} + \delta \Delta y_{t-1} + \varepsilon_t$$

Test de Dickey-Fuller Aumentado

En términos generales:

$$\Delta y_t = \psi y_{t-1} + \sum_{j=1}^t \delta \Delta y_{t-j} + \varepsilon_t, \quad \varepsilon_t \sim IID(0, \sigma^2)$$

$$H_0 : \psi = 0$$

$$H_1 : \psi < 0$$

Para ver cuál es el orden apropiado, hay que ver que ε_t no tenga autocorrelación (se pueden usar criterios de información).

Grafique y realice un test de Dickey-Fuller para evaluar la estacionariedad de las siguientes series temporales:

- `r`: difference between 180-day 90-day bank rates, %. Base: `term.csv`
- `s`: precio spot de la soja en USD/MT. Base: `soja.csv`
- `ipc`: índice de precios al consumidor de Argentina, cobertura nacional, Dic 2016=100. Base: `soja.csv`

Trabaje con las series `s` y `ipc` en logaritmos.

Variables Integradas

Decimos que y_t es $I(1)$ (“integrada de orden 1”) si Δy_t es $I(0)$, estacionaria a través de la diferenciación.

En general,

- y_t es $I(d)$ (“integrada de orden d ”) si $\Delta^d y_t$ es $I(0)$, estacionaria luego de la diferenciación aplicada d veces.

Recomendación: cada vez que apliquen un test de raíz unitaria sobre una variable, háganlo sobre su nivel y sus diferencias (tantas diferencias como sea necesario hasta llegar a una transformación $I(0)$).

Notar que **no toda variable no estacionaria se identifica como integrada**. Existen otras fuentes de no estacionariedad: breaks, heterocedasticidad, etc.

Vuelvan sobre la aplicación anterior y determinen el orden de integración de cada una de las variables.

I(1) vs I(0)

En la práctica puede ser que nos encontremos con que parte de los shocks son permanentes y otra parte no lo sea.

Casos	I(1) $\phi = 1$	I(0) $\phi < 1$
$\Delta y_t = \psi y_{t-1} + \varepsilon_t$ (Estocástico puro)	RW zero growth	$y_t \sim AR(1)$ zero mean
$\Delta y_t = \gamma + \psi y_{t-1} + \varepsilon_t$ (Con constante)	RW with drift trend in y_t +stochastic	$y_t \sim AR(1)$ (mean $\neq 0$)
$\Delta y_t = \gamma_0 + \gamma_1 t + \psi y_{t-1} + \varepsilon_t$ (Con constante y tendencia)	RW + drift + trend quadr. trend in y_t +stochastic	$y_t \sim AR(1)$ with trend

Otros tests de raíz unitaria

A pesar del uso extendido que tiene el test ADF hay muchísimos tests alternativos (debido a la baja potencia del ADF y muchos de estos test).

Estos son algunos de los más usuales:

- Phillips-Perron (PP)
- Kwiatkowski-Phillips-Schmidt-Shin (KPSS)
- entre otros

Phillips-Perron (PP)

Phillips y Perron (1988) propusieron un test alternativo que se basa en el test de DF al evaluar la hipótesis nula de $\rho = 0$ en:

$$\Delta y_t = \rho y_{t-1} + \varepsilon_t$$

Como en el caso del ADF, el test de PP permite que el PGD de y_t tenga autocorrelación de orden superior, pero en lugar de agregar rezagos de Δy_t (como DF), el test de PP realiza una corrección no paramétrica del estadístico t . El test es robusto respecto a HAC en el término de error.

Davidson y MacKinnon (2004) mostraron que PP tiene peor desempeño que ADF en muestra chica.

- En **STATA**: `pperron`
- En **R**: `ur.pp()` usar el package `urca`
- En **EViews**: desde la serie ir a View/Unit Root Test....

Kwiatkowski-Phillips-Schmidt-Shin (KPSS)

Kwiatkowski, Phillips, Schmidt y Shin (1992) proponen un test alternativo cuya hipótesis nula es la de estacionariedad de la serie en torno a una tendencia determinística.

La serie es expresada como una suma de tendencia determinística, RW y error ruido blanco y se utiliza un test LM para evaluar si el RW tiene varianza cero.

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. y Y. Shin, Y.
Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54: 1–3, 1992, 159–178.

- En **STATA**: `kpss`
- En **R**: `ur.kpss()` usar el package `urca`
- En **EViews**: desde la serie ir a View/Unit Root Test....

Aplique los distintos test vistos sobre las series anterior, ¿llega a las mismas conclusiones?

Limitaciones

Problemas con los test de raíz unitaria

- Muy sensibles a la introducción de constantes y tendencias y a la elección del número de rezagos.

Problemas con los test de raíz unitaria


- Muy sensibles a la introducción de constantes y tendencias y a la elección del número de rezagos.
- Hay una suerte de “trade-off” entre consistencia y potencia en la especificación de los componentes determinísticos similar al problema estándar de variables omitidas.
- Incrementar espuriamente el número de rezagos baja la potencia. Usar SIC y metodología General-a-Particular.
- ADF tiene tamaño correcto, pero baja potencia. PP, al revés.
- Importa la extensión del período y NO la frecuencia (Shiller y Perron, 1988).
- **Confunden breaks con unit root** (ver la simulación que está a continuación).

Ejercicio de Monte Carlo en OxMetrics

PGD:


- AR(1):
$$y_t = 0,5y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$$
- Es un AR(1) estacionario con constante nula
- $T=100$
- 1000 replicaciones
- En $t=50$: break en la constante, ahora pasa a ser igual a 4.

Serie simulada (y_t):



La serie por construcción es $I(0)$, pero si miramos la distribución del estadístico asociado a evaluar si $\phi = 1$...

Ejercicio de Monte Carlo en OxMetrics



El efecto de los cambios estructurales (determinísticos) hace que pensemos que la variable es $I(1)$ cuando en realidad es $I(0)$.

- Dividir la muestra en función del break y aplicar un test de raíz unitaria por segmento (requiere T grande en cada sub-muestra)
- Test de Perron (1989) o Zivot-Andrews (1992) o cualquier otra variante de tests de raíz unitaria con quiebres.

Recomendaciones prácticas (en general)

- Empezar con un gráfico (perfil de y_t) y terminar con un gráfico (residuos).
- Mirar los correlogramas de la serie en nivel y en diferencias.
- Si existe estacionalidad, trabajar con el Δ_4 o Δ_{12} .
- Evaluar si resulta conveniente trabajar con las variables en logaritmos.
- Cuando trabajamos con datos desestacionalizados tener cuidado que si la desestacionalización no es adecuada puede que el correlograma de las primeras diferencias arroje coeficientes negativos (¡muy raro!).
- No es recomendable usar datos desestacionalizados si lo que interesa es estudiar la dinámica de corto plazo (en el largo plazo da igual).

Breaks

Quiebres en la media o la tendencia

Simulen para $T = 100$ los siguientes procesos:

$$y_t = 3 + 5D + \varepsilon_t,$$

$$y_t = 10 - 0,2D \times t + \varepsilon_t$$

- donde $D = 1$ para $t > 50$, $= 0$ en caso contrario y $\varepsilon_t \sim N(0, 1)$.

Grafique y aplique el test ADF sobre cada uno. Comente.

- Una regresión que no contemple estos cambios puede llevar a errores de inferencia y pronóstico.
- Un **quiebre** puede aparecer como un cambio discreto en los coeficientes poblacionales de la regresión o una evolución gradual de los coeficientes a lo largo del tiempo.
- Dependiendo del tamaño y ubicación del quiebre, la regresión puede diferir mucho de la verdadera función de regresión.

¿Cómo detectar la presencia de quiebres?

Dos enfoques:

- Para una fecha conocida
- Para una fecha desconocida

Para una fecha conocida:

Ejemplo: en el siguiente modelo autoregresivo, queremos evaluar la existencia de un break en el momento τ . Sea $D(\tau)$ una variable dicotómica que vale 0 antes del break y 1 luego del break:

$$y_t = \beta_0 + \beta_1 y_{t-1} + \beta_2 X_t + \gamma_0 D_t(\tau) + \gamma_1 (D_t(\tau) \times y_{t-1}) + \gamma_2 (D_t(\tau) \times X_t) + u_t$$

Evaluando la presencia de breaks

- Si no existe un break, los términos en los cuáles está la variable binaria no deberían ser significativos.
- La hipótesis nula es la de ausencia de break:

$$\gamma_0 = \gamma_1 = \gamma_2 = 0$$

- Bajo la hipótesis alternativa, existe un break.
- Esto puede evaluarse mediante un estadístico F.
- También se conoce como el **test de Chow (1960)**
- Si hay múltiples rezagos y regresores puede extenderse el test incorporando más interacciones entre la variable binaria y el resto de los rezagos y regresores.

Evaluando la presencia de breaks

Para una fecha desconocida:

- Puede ser que la fecha del quiebre sea desconocida *a priori*.
- Supongamos que creemos que el quiebre se produce entre la fecha τ_0 y τ_1 .
- El test de Chow puede modificarse de tal forma que podamos evaluar todas las posibles fechas entre estos dos puntos y usar el estadístico F más grande.
- Esta modificación del test de Chow se conoce como el **Quandt likelihood ratio (QLR) statistic**.

Evaluando la presencia de breaks

- Como el estadístico QLR es el mayor de todos los estadísticos F , su distribución no es la misma que la del test F individual.
- La distribución depende del: nro de restricciones (q); nro de coeficientes (incluyendo la constante) que se permiten que cambien bajo la hipótesis alternativa; de τ_0/T y de τ_1/T .
- Los puntos τ_0 y τ_1 no deberían ser cercanos al principio o fin de la muestra
- En la práctica, el estadístico QLR se calcula sobre un rango recortado o un subconjunto de la muestra.
- Comúnmente se usa un *trimming* del 15 %: $\tau_0 = 0,15T$ y $\tau_1 = 0,85T$
- Si existe un break significativo, la fecha en la cual el mayor estadístico F ocurre, es un estimador de la fecha del break.

- En **STATA**: ¡hay que programar!
- En **R**: paquete `strucchange`
- En **EViews**: en la ventana de `Stability Diagnostics` hay varias opciones.

Uso de algoritmos para la detección de breaks o outliers

Una posibilidad es regresar la variable en función de un conjunto de dummies impulso:

$$\begin{aligned} y_t &= c_t + \varepsilon_t \\ &= \sum_{i=1}^T c_i l_{it} + \varepsilon_t \end{aligned}$$

donde l_{it} es igual a 1 cuando $t = i$.


Estos modelos tienen que estimarse con la ayuda de algún algoritmo (ya que $k > T$) como **IIS (Indicator Impulse Saturation)**.

¿Cómo funciona IIS?

Supongamos que el PGD de la variable y_t es:

$$y_t = \mu_0 + \varepsilon_t, \quad \varepsilon_t \sim NID(0, \sigma^2)$$


Si hacemos una simulación con $T = 100$, $\mu_0 = 20$ y $\sigma^2 = 1$, estimamos y obtenemos los residuos:



Procedimiento

- (1) Re-estimamos el modelo incluyendo impulse dummies solo para la primera mitad de la muestra.
- (2) Eliminamos las dummies no significativas y retenemos las significativas.
- (3) Repetimos el proceso para la segunda mitad de la muestra.
- (4) Re-estimamos el modelo original incluyendo todas las dummies significativas de los dos bloques.
- (5) Seleccionamos las dummies significativas del conjunto combinado.
- (6) Hendry, Johansen y Santos (2008) y Johansen y Nielsen (2009) probaron que, bajo H_0 de correcta especificación, la fracción de dummies impulso que son retenida es aproximadamente αT , donde α es el *target size*.

Ilustrando el procedimiento con $\alpha = 5\%$



Pero también podría suceder que haya **cambios sistemáticos en la media, pero de corta duración.**

$$y_t = \sum_{i=1}^T c_i S_{it} + \varepsilon_t$$

donde S_{it} es una *step-dummy* (=1 para $t \geq i$).

Este modelo nuevamente tiene que estimarse con la ayuda de algún algoritmo (**SIS, Step Indicator Saturation**).

Ejemplo simulado

Supongan que el PGD ahora es:


$$y_t = \mu_0 + \mu_1 S_{76t} + \varepsilon_t, \quad \varepsilon_t \sim NID(0, \sigma^2)$$

donde $S_{76t} = 0$ ($T = 1, \dots, 75$), $S_{76t} = 1$ ($T = 76, \dots, 100$), y el modelo estimado es una regresión de y en función de una constante, ignorando el break que ocurre en el período 76.


El modelo no incorporará el cambio en la media (aka **“location shift”**).

Datos simulados y residuos de la estimación

$$(\mu_0 = 20, \mu_1 = -10, \sigma^2 = 1, T = 100)$$



Si aplicamos IIS



Algunas extensiones de IIS

- **IIS (Impulse Indicator Saturation):** procedimiento propuesto por Hendry (1999) selecciona impulse dummies $\{I_{it}\}$ a lo largo de T .
- **SIS (Step Indicator Saturation):** selecciona step-dummies $\{S_{it}\}$ a lo largo de T .
- **TIS (Trend Indicator Saturation):** selecciona broken trends $\{T_{it} = t - i + 1, t \geq i\}$ a lo largo de T .
- **Super Saturation:** IIS+SIS
- **Ultra Saturation:** IIS+SIS+TIS

Importante: al aumentar el número de potenciales regresores (K) es importante ir disminuyendo el target size (α) $\rightarrow$ regla: $\alpha \leq 1/K$

Todos estos algoritmos están disponibles en R (función `isat()` dentro del paquete `gets`, van a tener que darle formato zoo a las variables) y en OxMetrics.

Para los usuarios de R:

- Apliquen este algoritmo sobre la serie de tipo de cambio nominal (promedio mensual) de la Argentina (`TCN.csv`)

Bibliografía

- Banerjee et al. (1993) - Cap. 3 y 4
- Ericsson (2012) "Detecting crises, jumps and changes in regime"
- Sosa Escudero (1997) "Testing for Unit-Roots and Trend-Breaks in Argentine Real GDP"

Cointegración

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

mcornejo@utdt.edu

Maestría en Economía, Universidad Nacional de La Plata

Introducción

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.
- Muchos modelos económicos involucran la idea de relaciones de cointegración.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.

- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.
- Muchos modelos económicos involucran la idea de relaciones de cointegración.
- El concepto de cointegración fue introducido por Engle y Granger (1987) en forma univariada.

Motivación

Hasta ahora estuvimos estimando modelos estacionarios o evaluando la no estacionariedad de las series para luego volverlas estacionarias (e.g. diferenciando) y poder estimar.


- La idea de **cointegración** revolucionó el desarrollo de la econometría de series de tiempo.
- Muchos modelos económicos involucran la idea de relaciones de cointegración.
- El concepto de cointegración fue introducido por Engle y Granger (1987) en forma univariada.
- Johansen (1991) lo extendió al caso multivariado (tema de la próxima clase).

Regresión Espuria


El problema de la regresión espuria

- En estadística, una relación espuria (o, a veces, correlación espuria) es una relación matemática en la cual dos acontecimientos no tienen conexión lógica (idealmente, causal), aunque se puede implicar que la tienen debido a un tercer factor no considerado aún (llamado “factor de confusión” o “variable escondida”).
- La relación espuria da la impresión de la existencia de un vínculo apreciable entre dos variables (Y y X) que es inválido cuando se examina objetivamente.
- Algunos ejemplos...

El problema de la regresión espuria



El problema de la regresión espuria



Más ejemplos en: tylervigen.com

Spurious Regression (Granger)

Non-Sense Regression (Yule)

Técnicamente lo que sucede es lo siguiente:

- Si tenemos dos variables y_t y x_t tal que:

$$y_t = \alpha + y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

$$x_t = \lambda + x_{t-1} + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

donde v_t y ε_t están incorrelacionadas entre sí.

- Ambas variables, al ser RW, presentan tendencias estocásticas.
- Si hacemos una regresión de y_t en función de x_t , ¿qué esperan observar?

Spurious Regression (Granger)

Non-Sense Regression (Yule)

Técnicamente lo que sucede es lo siguiente:

- Si tenemos dos variables y_t y x_t tal que:

$$y_t = \alpha + y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma_\varepsilon^2)$$

$$x_t = \lambda + x_{t-1} + v_t, \quad v_t \sim RB(0, \sigma_v^2)$$

donde v_t y ε_t están incorrelacionadas entre sí.

- Ambas variables, al ser RW, presentan tendencias estocásticas.
- Si hacemos una regresión de y_t en función de x_t , ¿qué esperan observar?

$$\beta \rightarrow 0$$


$$R^2 \rightarrow 0$$

Simulando datos

Sin embargo, para $T = 100$ se simularon los siguientes procesos:

$$y_t = 2 + y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim N(0, 1)$$

$$x_t = -1 + x_{t-1} + v_t, \quad v_t \sim N(0, 1)$$



Simulando datos

Y a través de la estimación por MCO del siguiente modelo:

$$y_t = \beta_0 + \beta_1 x_t + u_t$$

```
Call:
lm(formula = y ~ x)

Residuals:
    Min       1Q   Median       3Q      Max
-7.296 -2.786 -1.225  3.259 10.850

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.53258    0.83702   -3.026  0.00317 **
x            -1.48623    0.01123  -132.388 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.181 on 98 degrees of freedom
Multiple R-squared:  0.9944,    Adjusted R-squared:  0.9944
F-statistic: 1.753e+04 on 1 and 98 DF,  p-value: < 2.2e-16
```

Regresión entre variables $I(1)$

- Tanto la variable y_t como x_t son $I(1)$.

Regresión entre variables $I(1)$

- Tanto la variable y_t como x_t son $I(1)$.
- Se simularon en forma independiente, por lo que sabemos que no existe una relación causal entre ellas.

Regresión entre variables $I(1)$

- Tanto la variable y_t como x_t son $I(1)$.
- Se simularon en forma independiente, por lo que sabemos que no existe una relación causal entre ellas.
- Sin embargo, los resultados por MCO muestran que:

$$|t_{\beta_1=0}| \xrightarrow{d} \infty, \quad \lim R^2 = 1, \quad DW \rightarrow 0$$

- Estos resultados sugieren que:
 - Si nuestras variables muestran un comportamiento tendencial (en este caso, de tipo estocástico) a lo largo del tiempo, los resultados de la regresión son potencialmente espurios.
 - No podemos aprender nada sobre la relación entre variables en nivel que son $I(1)$ a partir de un modelo de regresión simple.

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.
- Este problema no desaparece ni aumentando T .

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.
- Este problema no desaparece ni aumentando T .
- El problema está generado por el uso de valores críticos equivocados (Granger dixit).

Regresión espuria

- La regresión de una variable $I(1)$ sobre otra variable $I(1)$ no relacionada está produciendo valores de t del parámetro estimado que indican una relación significativa cuando sabemos que no la hay.
- Este problema no desaparece ni aumentando T .
- El problema está generado por el uso de valores críticos equivocados (Granger dixit).
- En una regresión espuria los residuos estarán autocorrelacionados y los estadísticos t mal calculados ya que se está usando un estimador inconsistente de la varianza residual.


¿Qué hacemos?

- ¿Cómo detectamos si la regresión es espuria (entre series $I(1)$)?

Analizar los correlogramas y hacer algún test de raíz unitaria sobre los residuos

Estudiando los residuos

Veamos los residuos de la estimación anterior...



Date: 07/22/15 Time: 11:24
Sample: 2 100
Included observations: 99

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.894	0.894	81.558	0.000
		2 0.772	-0.136	142.99	0.000
		3 0.668	0.029	189.49	0.000
		4 0.566	-0.068	223.21	0.000
		5 0.468	-0.039	246.47	0.000
		6 0.379	-0.021	261.91	0.000
		7 0.314	0.052	272.63	0.000
		8 0.262	-0.000	280.17	0.000
		9 0.190	-0.142	284.18	0.000
		10 0.123	-0.013	285.87	0.000
		11 0.078	0.038	286.56	0.000
		12 0.074	0.163	287.19	0.000

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression trend

```
call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-3.767 -1.494 -0.131  1.356  4.343
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.112139   0.377093  -0.297   0.767
z.lag.1      -0.070117   0.046871  -1.496   0.138
tt           0.004676   0.006523   0.717   0.475
z.diff.lag   -0.028249   0.104595  -0.270   0.788
```

```
Residual standard error: 1.822 on 94 degrees of freedom
Multiple R-squared:  0.03222,    Adjusted R-squared:  0.001333
F-statistic: 1.043 on 3 and 94 DF,  p-value: 0.3772
```

Value of test-statistic is: -1.496 1.0891 1.3707

Critical values for test statistics:

```
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```


¿Qué hacemos?

- **¿Cómo convertimos una regresión espuria en una válida?**
Tomando diferencias en ambos lados de la regresión (Modelo en diferencias) → solución de los años 70'.

$$\Delta y_t = \beta_0 + \beta_1 \Delta x_t + \Delta u_t$$

$I(0)$ $I(0)$ $I(0)$

Modelo en Primeras Diferencias

Una forma de lidiar con el problema de la regresión espuria entre variables $I(1)$ es trabajar con el modelo en primeras diferencias.

- $\Delta y_t = y_t - y_{t-1}$
- $\Delta x_t = x_t - x_{t-1}$
- Si queríamos estimar:

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t$$

- El modelo en diferencias sería:

$$\Delta y_t = \beta_1 + \beta_2 \Delta x_t + u_t, \quad u_t = \Delta \varepsilon_t$$


- Esto se puede extender a un modelo más general.

Modelo en Primeras Diferencias

En nuestro ejemplo anterior en el cual generamos:

$$y_t = 2 + y_{t-1} + \varepsilon_t \Rightarrow \Delta y_t = 2 + \varepsilon_t$$

$$x_t = -1 + x_{t-1} + v_t \Rightarrow \Delta x_t = -1 + v_t$$



```
Call:
lm(formula = Dy ~ Dx)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-2.67358 -0.63637  0.03516  0.73890  2.19442
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.92783    0.16194   11.90  <2e-16 ***
Dx          -0.01294    0.09980   -0.13   0.897
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.033 on 97 degrees of freedom
Multiple R-squared:  0.0001732, Adjusted R-squared:  -0.01013
F-statistic: 0.01681 on 1 and 97 DF,  p-value: 0.8971
```

¿Qué hacemos?

- **¿Resuelve esta transformación el problema?**

*Lo resuelve desde el punto de vista estadístico, pero desde el punto de vista económico **no** podríamos modelar la (eventual) relación en niveles. La información contenida en una regresión en tasas de crecimiento **no** es la misma que en una regresión en niveles.*

¿Qué hacemos?

- ¿Resuelve esta transformación el problema?

*Lo resuelve desde el punto de vista estadístico, pero desde el punto de vista económico **no** podríamos modelar la (eventual) relación en niveles. La información contenida en una regresión en tasas de crecimiento **no** es la misma que en una regresión en niveles.*

- ¿Entonces? ¿Se puede estimar una regresión en niveles entre variables $I(1)$?

*Sí, si los errores son $I(0)$ $\Rightarrow$ **COINTEGRACIÓN***

Cointegración

Definición

Los componentes del vector $x_t = (x_{1t}, x_{2t}, \dots, x_{nt})'$ están cointegrados si:

- Todos los componentes de x_t son integrados de orden d .
- Existe un vector $\beta = (\beta_1, \beta_2, \dots, \beta_n)$ tal que la combinación lineal $\beta x_t = \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_n x_{nt}$ es integrado de orden $(d - b)$, donde $b > 0$.

El vector β se conoce como el **vector de cointegración**.

$x_t \sim CI(d, b)$. Entonces si:

- $x_t \sim CI(1, 1)$: las variables son $I(1)$ y existe una combinación lineal de ellas que es $I(0)$.
- $x_t \sim CI(2, 1)$: las variables son $I(2)$ y existe una combinación lineal de ellas que es $I(1)$.

Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.

Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.
- Una alternativa, es evaluar si las variables en cuestión (ambas con el mismo orden de integración) están **cointegradas**.

Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.
- Una alternativa, es evaluar si las variables en cuestión (ambas con el mismo orden de integración) están **cointegradas**.
- La **cointegración** se da cuando existe una combinación lineal de 2 o más variables $I(1)$ (o de orden superior, pero iguales) que resulta ser estacionaria (o de orden inferior).


Cointegración

- Si bien la diferenciación es una solución al problema de la regresión espuria, ya no tendremos un modelo en niveles sino en diferencias.
- Una alternativa, es evaluar si las variables en cuestión (ambas con el mismo orden de integración) están **cointegradas**.
- La **cointegración** se da cuando existe una combinación lineal de 2 o más variables $I(1)$ (o de orden superior, pero iguales) que resulta ser estacionaria (o de orden inferior).
- Una **relación de cointegración** se puede interpretar como una relación de equilibrio de largo plazo (estacionaria). Si bien las variables pueden desviarse de su relación en el corto plazo.

Ejemplos (famosos) de cointegración

- La función consumo
- La PPP
- Precios spot y futuros (evaluación de la hipótesis de mercados eficientes)
- Demanda de dinero
- Precios de acciones y dividendos

Precio spot y futuro de la soja - en Chicago



¿Qué observan?

Ejemplo

Demanda de dinero:

$$m_t = \beta_0 + \beta_1 p_t + \beta_2 y_t + \beta_3 r_t + \varepsilon_t$$

donde,

- m_t = demanda de dinero
- p_t = nivel de precios
- y_t = ingreso real
- r_t = tasa de interés
- ε_t = término de error **estacionario**

Todas las variables están en logaritmos, salvo la tasa de interés.

Nota: no hace falta que ε_t sea ruido blanco, sino tan solo que sea estacionario.

Ejemplo

El problema al que nos enfrentamos es que m_t , p_t , y_t y r_t suelen ser variables $I(1)$. La **cointegración** implica una combinación lineal estacionaria de dichas variables:

$$\varepsilon_t = m_t - \beta_0 - \beta_1 p_t - \beta_2 y_t - \beta_3 r_t$$

¡Entonces ε_t debe ser estacionario!

Esto implica una relación de equilibrio (de largo plazo) entre variables no estacionarias, es decir, sus tendencias estocásticas están relacionadas.

Cointegración y tendencias comunes

Una forma útil de entender una relación de cointegración es la observación que hicieron Stock y Watson (1988) sobre variables cointegradas que **comparten tendencias estocásticas**.

Cointegración y tendencias comunes

Una forma útil de entender una relación de cointegración es la observación que hicieron Stock y Watson (1988) sobre variables cointegradas que **comparten tendencias estocásticas**.

Vayamos al caso simple. Ignorando los componentes cíclicos y estacionales, podemos escribir cada una de estas variables en función de un RW + un componente irregular (estacionario, no necesariamente RB):

$$y_t = \mu_{yt} + e_{yt}$$

$$x_t = \mu_{xt} + e_{xt}$$

donde μ_{yt} y μ_{xt} son 2 RW que representan cada tendencia estocástica.

Cointegración y tendencias comunes

Si y_t y x_t son $I(1)$, debe existir valores no nulos de β_1 y β_2 para los cuales la combinación lineal $\beta_1 y_t + \beta_2 x_t$ es estacionaria.

$$\begin{aligned}\beta_1 y_t + \beta_2 x_t &= \beta_1(\mu_{yt} + e_{yt}) + \beta_2(\mu_{xt} + e_{xt}) \\ &= (\beta_1 \mu_{yt} + \beta_2 \mu_{xt}) + (\beta_1 e_{yt} + \beta_2 e_{xt})\end{aligned}$$

Para que $\beta_1 y_t + \beta_2 x_t$ sea estacionario, el término $(\beta_1 \mu_{yt} + \beta_2 \mu_{xt})$ debe desaparecer (se cancelan las tendencias):

$$\beta_1 \mu_{yt} + \beta_2 \mu_{xt} = 0$$

$$\mu_{yt} = -(\beta_2/\beta_1)\mu_{xt}$$

Entonces, para valores no nulos de β_1 y β_2 , la única manera de garantizar la igualdad es que las tendencias estocásticas sean iguales (por un escalar $-\beta_2/\beta_1$) $\Rightarrow$ **tendencias comunes.**

La metodología de Engle & Granger (1987)

Engle & Granger (1987) proponen que la relación de largo plazo puede ser fácilmente obtenida, si:

$$\begin{matrix} y_t & = & K & x_t & + & u_t \\ I(1) & & & I(1) & & I(0) \end{matrix}$$

La metodología de E&G consiste en:

- (1) Estimar la relación anterior
- (2) Obtener el residuo $\hat{u}_t$
- (3) Evaluar si el residuo es $I(0)$ a través de un test de raíz unitaria (con valores críticos tabulados por Engle y Granger, 1987)
- (4) En caso de ser $I(0)$, y_t y x_t están cointegradas.
- (5) ¿Se puede estimar una relación de largo plazo sin caer en el problema de la regresión espuria!

- En **STATA**: `egranger`
- En **R**: `egcm()` usar el package `egcm`
- En **EViews**: seleccionar las variables, abrirlas como grupo e ir a View/Cointegration Test/Single-equation Cointegration Test....

Utilice la base: soja.xls que contiene datos sobre el precio spot y futuro en Chicago entre 1979M01 y 2012M05.

- Exprese ambas variables en logaritmos y grafique conjuntamente. ¿Qué observa?
- Determine el orden de integración de cada variable
- Estime la regresión en niveles. Obtenga los residuos. Gráfíquelos y obtenga los correlogramas. Comente.
- Siguiendo la metodología de Engle y Granger, evalúe si las series están cointegradas.

Modelo de corrección de errores

Modelo de Corrección de Errores (MCE)

- Una vez que se encontró evidencia de cointegración entre dos o más variables, se puede estimar un **modelo de corrección de errores** (MCE).
- Un MCE permite explicar las tasas de crecimiento de y_t (Δy_t) en función de:
 - el crecimiento en x_t (Δx_t), y
 - el desequilibrio pasado entre los niveles de y_t y x_t .
- Estos modelos también son conocidos como **modelos de corrección al equilibrio** (MCEq).

Reparametrización de un modelo ADL

Partimos de un problema de autocorrelación. Sea,

$$y_t = x_t' \beta + u_t$$

$$u_t = \phi u_{t-1} + \varepsilon_t \quad \varepsilon_t \sim RB(0, \sigma^2)$$

Entonces,

$$y_t = x_t' \beta + \phi[y_{t-1} - x_{t-1}' \beta] + \varepsilon_t$$

$$y_t = x_t' \beta + \phi y_{t-1} - x_{t-1}' \beta \phi + \varepsilon_t \quad \text{Modelo AD}(1,1)$$

Un **MCE** es una re-parametrización de un modelo AD(1,1) sin pérdida de información e independientemente de si las variables son integradas o no.

Reparametrización de un modelo ADL

A partir de un AD(1,1):

$$y_t = \beta_1 x_t + \beta_2 x_{t-1} + \beta_3 y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \beta_1 x_t + \beta_2 x_{t-1} + (\beta_3 - 1)y_{t-1}$$

$$\Delta y_t = \beta_1 \Delta x_t + (\beta_1 + \beta_2)x_{t-1} + (\beta_3 - 1)y_{t-1} + \varepsilon_t$$

$$\Delta y_t = \beta_1 \Delta x_t - (1 - \beta_3) \left[y_{t-1} - \frac{\beta_1 + \beta_2}{1 - \beta_3} x_{t-1} \right] + \varepsilon_t \quad \text{(MCE)}$$

donde:

- $\frac{\beta_1 + \beta_2}{1 - \beta_3} = K$ (coeficiente de largo plazo)
- $(1 - \beta_3) = \alpha$ (coeficiente de ajuste, $0 \leq \alpha \leq 1$)

Modelo de Corrección de Errores (MCE)

Notar que:

$$y_t = \beta_1 x_t + \beta_2 x_{t-1} + \beta_3 y_{t-1} + \varepsilon_t$$

$I(1) \quad I(1) \quad I(1) \quad I(1) \quad I(0)$

$$\Delta y_t = \beta_1 \Delta x_t + (\beta_1 + \beta_2) x_{t-1} + (\beta_3 - 1) y_{t-1} + \varepsilon_t$$

$I(0) \quad I(0) \quad I(1) \quad I(1) \quad I(0)$

$$\Delta y_t = \beta_1 \Delta x_t - (1 - \beta_3) \left(y_{t-1} - \frac{\beta_1 + \beta_2}{1 - \beta_3} x_{t-1} \right) + \varepsilon_t$$

$I(0) \quad I(0) \quad I(0)$

Necesitamos que el **término de corrección de errores (TCE)**:

$$\left(y_{t-1} - \frac{\beta_1 + \beta_2}{1 - \beta_3} x_{t-1} \right)$$

sea $I(0)$ para que balancee en el sentido de Granger.

Modelo de Corrección de Errores (MCE)

El MCE es un modelo en diferencias aumentado por el término:

$$[y_{t-1} - Kx_{t-1}]$$

En el largo plazo (estado estacionario):

$$x_t = x_{t-1} \qquad y_t = y_{t-1}$$

$$\Rightarrow y_t = Kx_t$$

donde K es el efecto de largo plazo de x_t sobre y_t .

Entonces, existe una especie de corrección, dada por $-(1 - \beta_3)$, para alcanzar la relación de largo plazo.

Ventaja: el MCE implica una modelación conjunta de la dinámica (corto plazo) y del largo plazo

La metodología de Engle & Granger (1987)

Propiedades:

- Granger mostró que la existencia de COI implica necesariamente un MCE y a su vez, si existe un MCE entre variables integradas, existe una relación de cointegración (Teorema de Representación de Granger).
- Cuando existe COI, la tasa de convergencia de la distribución de los estimadores de OLS es a T y no a $\sqrt{T} \Rightarrow \hat{K}$ es super-consistente ya que converge a una tasa más rápida.
- Si existe COI, la solución es **única**, el K es único.

Retome el ejemplo del precio spot y futuro en Chicago entre 1979M01 y 2012M05.

- Estime un MCE para el precio spot de la soja (únicamente en función del precio futuro)

Aplicación - Enders (2010)

Utilice la base de datos COINT6.XLS del libro de Enders que contiene 3 series ficticias (y , z , w) para ilustrar la metodología de Engle & Granger. Se pide:

- (1) Inspeccione visualmente las series
- (2) Determine el orden de integración de las series.
- (3) Estime una regresión de equilibrio de largo plazo de y_t en función de w_t y z_t . ¿Están cointegradas?
- (4) Los coeficientes estimados NO tienen una distribución asintótica t de Student si el término de error no es IID. Evalúe.
- (5) Estime el siguiente MCE:

$$\Delta y_t = \delta + \alpha TCE_{t-1} + \beta_1 \Delta y_{t-1} + \beta_2 \Delta w_{t-1} + \beta_3 \Delta z_{t-1} + \varepsilon_t$$

- (6) Interprete los coeficientes.

- Ahumada, H. (2006) “Una nota sobre regresiones con variables integradas”, *Ensayos Económicos* 45, 79-94.
- Banerjee et al. (1993) - Cap. 5 a 7
- Hendry, D.F. & Juselius, K. (2000) “Explaining Cointegration Analysis: Part 1”, *The Energy Journal* 21(1): 1-42.

Cointegración en Sistemas de Ecuaciones

Econometría de Series de Tiempo

Magdalena Cornejo

mcornejo@utdt.edu

Maestrías en Economía y Finanzas, Universidad de San Andrés

Introducción

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.
- Así, la cointegración podría variar de acuerdo a la variable seleccionada en la normalización.

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.
- Así, la cointegración podría variar de acuerdo a la variable seleccionada en la normalización.
- Podría existir más de una relación de cointegración cuando usamos varias variables.

Motivación

Si bien el procedimiento de Engle & Granger (1987) es fácil de implementar, tiene varias **desventajas**:

- Nos obliga a decidir qué variable será la dependiente y el resto serán las variables explicativas.
- Así, la cointegración podría variar de acuerdo a la variable seleccionada en la normalización.
- Podría existir más de una relación de cointegración cuando usamos varias variables.
- El procedimiento de E&G implica una estimación en 2 etapas: (1) generar los residuos; (2) usar esos residuos en $t - 1$ en la estimación del MCE.

Alternativamente, podemos usar el enfoque **multivariado** en Johansen (1988, 1991). Metodología: **Johansen-Juselius**.

Enfoque de Johansen-Juselius

El procedimiento de Johansen es una **especie de generalización multivariada del test de Dickey-Fuller.**

En forma univariada vimos que:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t \quad \text{o}$$
$$\Delta y_t = (\phi_1 - 1) y_{t-1} + \varepsilon_t$$

Si $(\phi_1 - 1) = 0$, entonces el proceso $\{y_t\}$ tiene una raíz unitaria.

Un ADF multivariado

Ahora consideren una simple generalización a n variables:

$$x_t = \Phi_1 x_{t-1} + \varepsilon_t$$

Entonces,

$$\begin{aligned}\Delta x_t &= \Phi_1 x_{t-1} - x_{t-1} + \varepsilon_t \\ &= (\Phi_1 - I) x_{t-1} + \varepsilon_t \\ &= \pi x_{t-1} + \varepsilon_t\end{aligned}$$

donde:

- x_t y ε_t son vectores $(n \times 1)$.
- Φ_1 es una matriz $(n \times n)$ de parámetros.
- I es la matriz $(n \times n)$ identidad.
- π se define como $(\Phi_1 - I)$

$$\Delta x_t = \pi x_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim IN(0, \Omega)$$

Para evaluar cointegración tenemos que **analizar el rango de la matriz π .**

Ejemplo - BIVAR(1)

$$\begin{cases} y_t = \phi_{11}y_{t-1} + \phi_{12}x_{t-1} + \varepsilon_{1t} \\ x_t = \phi_{21}y_{t-1} + \phi_{22}x_{t-1} + \varepsilon_{2t} \end{cases}$$

Entonces,

$$\begin{cases} \Delta y_t = (\phi_{11} - 1)y_{t-1} + \phi_{12}x_{t-1} + \varepsilon_{1t} \\ \Delta x_t = \phi_{21}y_{t-1} + (\phi_{22} - 1)x_{t-1} + \varepsilon_{2t} \end{cases}$$

donde:

$$\pi = \begin{bmatrix} \phi_{11} - 1 & \phi_{12} \\ \phi_{21} & \phi_{22} - 1 \end{bmatrix} = \begin{bmatrix} \pi_{11} & \pi_{12} \\ \pi_{21} & \pi_{22} \end{bmatrix}$$

El rango de la matriz π

Nos podemos encontrar con 3 casos:

- $r(\pi) = 0$
- $r(\pi) = n$
- $r(\pi) = r < n$ (cointegración)

En el caso del BIVAR las posibilidades son:

- $r(\pi) = 0$
- $r(\pi) = 2$
- $r(\pi) = 1$ (cointegración)

Si $r(\pi) = 0$

Cada elemento de π debe ser igual a cero por lo que:

$$\Delta x_t = \varepsilon_t$$

Es un VAR en primeras diferencias.

Dado que cada $x_{it} = x_{it-1} + \varepsilon_{it}$, todas las secuencias $\{x_{it}\}$ son procesos random walk (I(1)) y no existe una combinación lineal de las variables que sea estacionaria $\Rightarrow$ **no hay cointegración.**

Si $r(\pi) = n$ (rango completo)

$$\Delta x_t = \pi x_{t-1} + \varepsilon_t$$

Entonces, la solución de largo plazo de la ecuación anterior está dada por n ecuaciones independientes:

$$\pi_{11}x_{1t} + \pi_{12}x_{2t} + \dots + \pi_{1n}x_{nt} = 0$$

$$\pi_{21}x_{1t} + \pi_{22}x_{2t} + \dots + \pi_{2n}x_{nt} = 0$$

$$\vdots$$

$$\pi_{n1}x_{1t} + \pi_{n2}x_{2t} + \dots + \pi_{nn}x_{nt} = 0$$

En este caso, cada una de las n variables contenidas en el vector x_t debe ser estacionaria por lo que dichas variables no cointegran.

Si $r(\pi) < n$

En **casos intermedios**, en los que el rango de π es igual a $r < n$, existen r **vectores de cointegración**.

Con r ecuaciones independientes y n variables, existen $n - r$ **tendencias estocásticas** en el sistema.

Determinando el rango de la matriz π

Entonces el **objetivo** es determinar el rango de la matriz π que nos indicaría el número de vectores cointegrados. Esto puede realizarse evaluando la significatividad de las raíces características de π .

Recordar: el rango de la matriz es igual al nro de sus raíces características diferentes de cero.

Pruebas de cointegración

Test de cointegración

En la práctica, estimamos π y sus raíces características, ordenamos en forma descendente las n raíces características

$(\lambda_1 > \lambda_2 > \dots > \lambda_n)$ y existen dos tests relevantes posibles:

- Test de traza
- Test del máximo autovalor

Test de cointegración

En la práctica, estimamos π y sus raíces características, ordenamos en forma descendente las n raíces características

$(\lambda_1 > \lambda_2 > \dots > \lambda_n)$ y existen dos tests relevantes posibles:

- Test de traza
- Test del máximo autovalor

En ambos casos, la H_0 es la de **ausencia de cointegración**.

Test de cointegración

En la práctica, estimamos π y sus raíces características, ordenamos en forma descendente las n raíces características

$(\lambda_1 > \lambda_2 > \dots > \lambda_n)$ y existen dos tests relevantes posibles:

- Test de traza
- Test del máximo autovalor

En ambos casos, la H_0 es la de **ausencia de cointegración**.

Estimamos $\hat{\pi}$ por máxima verosimilitud y obtenemos $\hat{\lambda}_i$.

Bajo H_0 : $r(\pi)=0 \Rightarrow \lambda_i = 0, i = 1, 2, \dots, n$.

O, de forma equivalente,

$$\ln(1 - \lambda_i) = 0, \quad i = 1, 2, \dots, n$$

$$H_0 : \text{rango}(\pi) \leq r$$

$$H_1 : \text{rango}(\pi) > r$$

$$\lambda_{tr}(r) = -T \sum_{i=r+1}^n \ln(1 - \hat{\lambda}_i)$$

Evalúa si los autovalores $r, r + 1, \dots, n$ son conjuntamente no significativos.

Ejemplo

Si $r = 0$, H_0 es la hipótesis de no-cointegración vs. la alternativa de 'al menos un vector de cointegración'.

Test del máximo autovalor

$$H_0 : \text{rango}(\pi) = r$$

$$H_1 : \text{rango}(\pi) = r + 1$$

$$\lambda_{\max}(r) = -T \cdot \ln(1 - \hat{\lambda}_{r+1})$$

Evalúa si uno de los autovalores es estadísticamente distinto de cero.

Ejemplo

Si $r = 0$, H_0 es la hipótesis de no-cointegración vs. la alternativa de 'un vector de cointegración'.

- En **STATA**: `vecrank`
- En **R**: `ca.jo()` usar el package `urca`
- En **EViews**: seleccionar las variables, abrirlas como grupo e ir a View/Cointegration Test/Johansen System Cointegration Test....

Prueba de cointegración

Al igual que en un test ADF, ¡los valores críticos dependen de los componentes determinísticos!

$$\Delta y_t = \alpha(\beta y_{t-1} + \mu + \rho t) + \sum_{j=1}^p \Gamma_j \Delta y_{t-j} + \gamma + \tau t + \varepsilon_t$$

- **Caso 1:** $\mu = 0, \rho = 0, \gamma = 0, \tau = 0$
- **Caso 2:** $\rho = 0, \gamma = 0, \tau = 0$
- **Caso 3:** $\gamma = 0, \tau = 0$
- **Caso 4:** $\tau = 0$
- **Caso 5:** todos los componentes determinísticos $\neq 0$ (RARO)

Johansen Cointegration Test X

Cointegration Test Specification

Deterministic trend assumption of test

Assume no deterministic trend in data:

☐ 1) No intercept or trend in CE or test VAR

☐ 2) Intercept (no trend) in CE - no intercept in VAR

Allow for linear deterministic trend in data:

☒ 3) Intercept (no trend) in CE and test VAR

☐ 4) Intercept and trend in CE - no intercept in VAR

Allow for quadratic deterministic trend in data:

☐ 5) Intercept and trend in CE - intercept in VAR

Summary:

☐ 6) Summarize all 5 sets of assumptions

Exog variables*

Lag intervals

1 1

Lag spec for differenced endogenous

Critical Values

☒ MHM

Size

0.05

☐ Osterwald-Lenum

* Critical values may not be valid with exogenous variables; do not include C or Trend.

Acceptar

Cancelar

La función `ca.jo()` permite indicar si en el espacio de cointegración:

- no hay componentes determinísticos: `ecdet=c("none")`
- se incluye una constante: `ecdet=c("cons")`
- se incluye una tendencia: `ecdet=c("trend")`

Ejemplo. Money demand (Johansen & Juselius, 1990)

Johansen, S. & Juselius, K. (1990). Maximum likelihood estimation and inference on cointegration with applications to the demand for money. *Oxford Bulletin of Economics and Statistics*, 52, 169-210.

Datos trimestrales de Dinamarca entre 1974Q1 y 1987Q3. Utilice la base de datos `danish.xls` donde:

- $m2$ = log of the real money supply as measures by M2 deflated by a price index.
- y = log of real income.
- i^d = deposit rate on money representing a direct return on money holding.
- i^b = bond rate representing the opportunity cost of holding money.

Ejemplo. Money demand (Johansen & Juselius, 1990)

Se pide:

- (1) Grafique, evalúe la estacionariedad de cada una de las series y determine el orden de integración.
- (2) Estime un modelo VAR. Determine la longitud de rezago adecuada.
- (3) Evalúe la normalidad de los residuos (univariada y multivariada)
- (4) Realice un test de cointegración de Johansen. ¿Cuál es la solución de largo plazo?

Dummies estacionales centradas

- Su suma es cero (en lugar de uno) a lo largo del año.
- Si $D_{s,t}$ es una dummy 1-0 para la estación s en el momento t
- Una **dummy centrada** se define como:

$$D_{s,t}^* = D_{s,t} - 1/S$$

donde S es la cantidad de estaciones dentro del año (trimestres, meses, etc).

- Algunos las llaman “*orthogonalised seasonal dummies*”
- Recuerden incluir $S - 1$ dummies, siempre que incluyamos una constante en la regresión, para evitar multicolinealidad exacta.
- La razón por la que se usan es **para evitar afectar la tendencia de las variables en niveles del VAR.**

Para frecuencia trimestral:

- `genr cs1=@seas(1)-.25`
- `genr cs2=@seas(2)-.25`
- `genr cs3=@seas(3)-.25`
- `genr cs4=@seas(4)-.25`

Para frecuencia trimestral:

```
egen quarter=seq(), to(4)
tab quarter, gen(D)
forval i=1/4{
    gen CS'i'=D'i'-1/4
}
```


Generando dummies centradas - En R

Para frecuencia trimestral (a partir de una variable x):

```
CS1 <- rep(c(1, 0, 0, 0), length(x) / 4) - .25
```

```
CS2 <- rep(c(0, 1, 0, 0), length(x) / 4) - .25
```

```
CS3 <- rep(c(0, 0, 1, 0), length(x) / 4) - .25
```

```
CS4 <- rep(c(0, 0, 0, 1), length(x) / 4) - .25
```

Ejemplo. Money demand (Johansen & Juselius, 1990)

Prueben re-estimar el VAR del ejemplo anterior incluyendo dummies centradas.

- ¿Cambia el orden del VAR?
- ¿Resultan estadísticamente significativas?
- ¿Cambian las conclusiones del test de cointegración de Johansen?

VEC

Modelos VEC (Vectores de Corrección de Errores)

Bajo cointegración, un VAR admite una representación VEC.

La matriz π se puede factorizar $\pi = \alpha\beta'$.

$$\left. \begin{matrix} \alpha_{n \times r} \\ \beta_{n \times r} \end{matrix} \right\} \Rightarrow \pi_{n \times n}$$

donde:

- β será el vector de coeficientes de largo plazo
- α será el vector de coeficientes de ajuste

Ejemplo

Volvamos al BIVAR(1) y asumamos que probamos que existe $r = 1$. Entonces,

$$\Delta x_t = \pi x_{t-1} + \varepsilon_t$$

$$\Delta x_t = \alpha \beta' x_{t-1} + \varepsilon_t$$

donde

$$\alpha \beta' = \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} \begin{bmatrix} \beta_1 & \beta_2 \end{bmatrix}$$

Modelos VEC (Vectores de Corrección de Errores)

Si $r = 1$, por lo general normalizamos el largo plazo en función de una de las variables del VAR (y_t o x_t).

En nuestro ejemplo, si normalizamos en función de y_t , esto implica que:

$$\alpha\beta' = \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} \begin{bmatrix} 1 & -K \end{bmatrix}$$

El modelo VEC resulta:

$$\begin{cases} \Delta y_t = \alpha_1[y_{t-1} - Kx_{t-1}] + \varepsilon_{1t} \\ \Delta x_t = \alpha_2[y_{t-1} - Kx_{t-1}] + \varepsilon_{2t} \end{cases}$$

donde $\pi_{11} = \alpha_1$, $\pi_{21} = \alpha_2$, $\pi_{12} = -\alpha_1 K$, $\pi_{22} = -\alpha_2 K$.

Es decir, $-K = \frac{\pi_{12}}{\pi_{11}} = \frac{\pi_{22}}{\pi_{21}}$

Exogeneidad

Exogeneidad

Cuando planteamos al inicio del curso que $E(u_t|\mathbf{X}) = 0$

(**exogeneidad estricta**), esto implicaba que $E(x_t \cdot u_s) = 0 \forall t, s$.

Exogeneidad

Cuando planteamos al inicio del curso que $E(u_t|\mathbf{X}) = 0$

(**exogeneidad estricta**), esto implicaba que $E(x_t \cdot u_s) = 0 \forall t, s$.

Una variable puede estar **predeterminada** si $E(x_t \cdot u_s) = 0 \forall s \geq t$
(ej. uso de variables rezagadas).

Exogeneidad

Cuando planteamos al inicio del curso que $E(u_t|\mathbf{X}) = 0$ (**exogeneidad estricta**), esto implicaba que $E(x_t \cdot u_s) = 0 \forall t, s$.

Una variable puede estar **predeterminada** si $E(x_t \cdot u_s) = 0 \forall s \geq t$ (ej. uso de variables rezagadas).

Engle, Hendry y Richard (1983) definen 3 niveles de exogeneidad:

- **Débil** (para inferir)
- **Fuerte** (para pronosticar)
- **Super** (para evaluación de políticas)

Exogeneidad

En un modelo multivariado, una variable es **exógena respecto del parámetro de interés** (el que queremos estimar).

Modelo de la Telaraña

$$p_t = \alpha + \beta q_t + u_t \quad (\text{Demanda})$$

$$q_t = \gamma + \delta p_{t-1} + \varepsilon_t \quad (\text{Oferta})$$

donde $E(u_t) = 0$, $E(\varepsilon_t) = 0$ y $E(u_t \varepsilon_t) = 0$ (supuesto).

Si queremos estimar uniecuacionalmente la demanda, ¿es q_t exógena para estimar la inversa de β ?

Parámetro de interés: $1/\beta$ (elasticidad)

Exogeneidad (Engle, Hendry & Richard, 1983)

El concepto de **exogeneidad** no es único, hay distintos niveles que dependen del objetivo que persigamos y tienen distintos requisitos:

Exogeneidad	Objetivo	Requisitos
Débil	Inferencia	Parámetros de interés + Variation Free
Fuerte	Pronóstico	Exog. débil + No causalidad en sentido de Granger
Super	Evaluación de políticas	Exogeneidad débil + Invarianza estructural

Invarianza estructural: invarianza de los parámetros del modelo condicional ante cambios en la distribución marginal.

Exogeneidad débil

La pregunta entonces es: **¿cómo hacemos para probar exogeneidad débil?**

Exogeneidad débil

La pregunta entonces es: **¿cómo hacemos para probar exogeneidad débil?**

Volviendo al modelo VEC en el cual normalizábamos respecto de y_t :

$$\begin{cases} \Delta y_t = \alpha_1[y_{t-1} - Kx_{t-1}] + \varepsilon_{1t} \\ \Delta x_t = \alpha_2[y_{t-1} - Kx_{t-1}] + \varepsilon_{2t} \end{cases}$$

Entonces, si $\alpha_2 = 0$ decimos que y_t es la variable que ajusta y x_t es débilmente exógena. Puedo estimar un modelo uniecuacional de y_t condicional a x_t .

Si las dos variables ajustan, entonces el sistema se determina en forma conjunta.

Pulling and Pushing forces

Juselius (2006) dio una interpretación económica a las variables débilmente exógenas y las variables que ajustan en el sistema.

- **Pulling forces:** la(s) variable(s) que ajusta(n) en el sistema. Fuerzas que traccionan hacia el equilibrio de largo plazo, generando un comportamiento estacionario.
- **Pushing forces:** la(s) variable(s) débilmente exógena(s). Fuerzas que generan desvíos respecto del equilibrio.

Causalidad en sentido de Granger

Cuando vimos la metodología VAR hablamos de Causalidad en sentido de Granger.

Recordar que sólo implica precedencia temporal ($\neq$ causalidad económica). En un BIVAR(1):

$$\begin{cases} y_t = \alpha_{11}y_{t-1} + \alpha_{12}x_{t-1} + \varepsilon_{1t} \\ x_t = \alpha_{21}y_{t-1} + \alpha_{22}x_{t-1} + \varepsilon_{2t} \end{cases}$$

Decimos que x_t causa a y_t en sentido de Granger si $\alpha_{12} \neq 0$ y $\alpha_{21} = 0$. Se prueba mediante un test de restricciones.

Si probamos que x_t es débilmente exógena y además y_t no la causa en sentido de Granger, entonces x_t es **fuertemente exógena** (necesario para pronóstico).

- En **STATA**: `vec`
- En **R**: `cajorls()` usando el paquete `urca`
- En **EViews**: seleccionar las variables, abrirlas como VAR y seleccionar Vector Error Correction.

Aplicaciones

Aplicación 1. Money demand (Johansen & Juselius, 1990)

Siguiendo con el ejemplo de la demanda de dinero en Dinamarca.
Se pide:

- Evalúe la exogeneidad débil de las series.
- Evalúe la causalidad en sentido de Granger
- Estime un modelo VEC. Interprete.

Aplicación 2. Spot y futuro de soja

Utilice el archivo soja.xls de la clase pasada.

- Estime un VAR(4) para el $\ln(S)$ y el $\ln(F)$
- Evalué que el modelo no tenga autocorrelación.
- ¿Son normales los residuos?
- Evalúe cointegración (empiece por incluir una tendencia en el largo plazo y evalúe su significatividad)
- ¿Es el futuro débilmente exógeno? ¿Y fuertemente exógeno?
- Estime un modelo VEC apropiado.

Recomendaciones prácticas

- Para datos trimestrales con estacionalidad, estimar un VAR con dummies centradas y hasta 2 lags.
- Si no funcionan las dummies, usar hasta 4/5 lags.
- Si dudamos respecto del comportamiento tendencial de las series, incluir siempre una trend en el espacio de COI y luego testear si resulta significativa.
- Las dummies entran en forma irrestricta en el sistema VAR.
- Step dummies o broken trends en el espacio de cointegración implica que hay que re-calcular los valores críticos (ver Johansen et al., 2000).

- Juselius (2006) - El libro entero!
- Hendry y Juselius (2001) "Explaining Cointegration Analysis: Part II", *The Energy Journal* 22(1), 75-120.

Modelos de Heterocedasticidad Condicional Univariados

Econometría de Series de Tiempo

Magdalena Cornejo (UTDT-CONICET)

`mcornejo@utdt.edu`

Maestría en Economía, Universidad Nacional de La Plata

Introducción

- Hasta ahora todos los modelos son lineales (en parámetros)




Motivación

- Hasta ahora todos los modelos son lineales (en parámetros)
- En finanzas, muchas relaciones son intrínsecamente no lineales

Motivación

- Hasta ahora todos los modelos son lineales (en parámetros)
- En finanzas, muchas relaciones son intrínsecamente no lineales
- Los enfoques aplicados hasta ahora no suelen ser buenos en explicar casos de:
 - Leptocurtosis (excesos de curtosis)
 - Volatilidad grupal
 - Efectos de apalancamiento
- Los modelos pueden ser: lineales en media y varianza (e.g. ARMA), lineales en media, pero no en varianza (e.g. GARCH), no lineales en media ni varianza.

- (1) Baje de **Yahoo Finance** el precio de cierre ajustado de alguna compañía en frecuencia diaria desde enero de 2006.
- (2) Grafique. ¿Qué observa? ¿Es estacionaria?
- (3) Calcule el retorno diario logarítmico. Grafique. ¿Qué observa?
- (4) Obtenga los principales estadísticos descriptivos. Comente.
- (5) Grafique el histograma. ¿Qué observa?



```
> summary(R)
      Index      Adjusted
Min.   :2006-01-04  Min.   : -12.34015
1st Qu.:2009-06-17  1st Qu.: -0.75789
Median :2012-11-28  Median :  0.04226
Mean   :2012-11-28  Mean    :  0.05045
3rd Qu.:2016-05-11  3rd Qu.:  0.91307
Max.   :2019-10-23  Max.   : 18.22511

> describe(R)
      vars  n mean sd median trimmed mad  min  max range skew kurtosis  se
Adjusted  1 3475 0.05 1.82   0.04   0.07 1.24 -12.34 18.23 30.57 0.43 10.42 0.03
```

Modelos Condicionales vs. No Condicionales

Volvamos al modelo AR(1) estacionario:

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad |\phi| < 1$$

Vimos que la media y la varianza incondicionales son:

- $E(y_t) = 0$ (por no incluir constante)
- $V(y_t) = \sigma^2 / (1 - \phi^2)$

Modelos Condicionales vs. No Condicionales

Volvamos al **modelo AR(1) estacionario**:

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad |\phi| < 1$$

Vimos que **la media y la varianza incondicionales** son:

- $E(y_t) = 0$ (por no incluir constante)
- $V(y_t) = \sigma^2 / (1 - \phi^2)$

La media y la varianza condicionales son:

- $E_t(y_t) = \phi y_{t-1} \rightarrow$ depende de t
- $V_t(y_t) = \sigma^2 \rightarrow$ no depende de t

Sin embargo, muchas series económicas/financieras tienen una varianza condicional que **varía en el tiempo (e.g. inflación, stock returns, etc.)**

Modelos Condicionales vs. No Condicionales

- En muchos casos resulta relevante estimar y pronosticar la volatilidad **condicional** de cierta variable. Consistente con la formación de expectativas racionales.
- Modelar la varianza condicional en forma correcta puede mejorar la precisión de las estimaciones que modelar o pronosticar las medias condicionales.

ARCH

Modelo ARCH (Autoregressive conditionally heteroskedastic)

Desarrollado por Engle (1982) es la forma más simple de modelar la volatilidad.

$$y_t = u_t, \quad u_t \sim N(0, \sigma_t^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 y_{t-1}^2$$

También puede expresarse como:

$$y_t = \varepsilon_t \sqrt{\alpha_0 + \alpha_1 y_{t-1}^2}, \quad \varepsilon_t \sim WN(0, 1)$$

$\{y_t\}$ se conoce como un **ARCH(1) puro**.

ARCH(1) puro

Calculemos los **momentos condicionales**:

- $E_t(y_t) = 0$
- $V_t(y_t) = E_t(y_t^2) \equiv h(t) = \alpha_0 + \alpha_1 y_{t-1}^2$

Los momentos **incondicionales** son:

- $E(y_t) = E(E_t(y_t)) = 0$
- $V(y_t) = E(y_t^2) = E(E_t(y_t^2)) = \alpha_0 + \alpha_1 E(y_{t-1}^2)$

$$\text{Si } |\alpha_1| < 1, \quad V(y_t) = E(y_t^2) = \frac{\alpha_0}{1 - \alpha_1}$$

ARCH(1) puro

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.
- Media condicional constante y nula; varianza condicional *no constante*.

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.
- Media condicional constante y nula; varianza condicional *no constante*.
- La varianza condicional depende de cuán largas fueron las desviaciones respecto de la media (y_{t-1}^2) en los períodos anteriores.

ARCH(1) puro

El ARCH(1) puro tiene:

- Media incondicional constante y nula; varianza incondicional constante.
- Media condicional constante y nula; varianza condicional *no constante*.
- La varianza condicional depende de cuán largas fueron las desviaciones respecto de la media (y_{t-1}^2) en los períodos anteriores.
- Si $\alpha_1 = 0$ es un simple proceso ruido blanco.

Podríamos querer estimar el siguiente modelo:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad u_t \sim N(0, \sigma_t^2)$$


donde:

$$u_t = \varepsilon_t \sigma_t, \quad \varepsilon_t \sim N(0, 1)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2$$

Los errores siguen un proceso ARCH(1).

Ejemplo simulado para $T = 1000$

$$y_t = \varepsilon_t \sqrt{1 + 0,8y_{t-1}^2}, \quad \varepsilon_t \sim N(0, 1)$$



Código para replicar en R

```
#Magdalena Cornejo#  
#UNLP 2019 - Econometria de Series de Tiempo#  
#Simulando procesos ARCH#  
  
library(rugarch)  
arch1.spec = ugarchspec(variance.model=list(garchOrder  
      =c(1,0)), mean.model=list(armaOrder=c(0,0)), fixed  
      .pars=list(mu = 0, omega=1, alpha1=0.8))  
class(arch1.spec)  
arch1.spec  
set.seed(123)  
arch1.sim = ugarchpath(arch1.spec, n.sim=1000)  
class(arch1.sim)  
slotNames(arch1.sim)  
names(arch1.sim@path)  
  
plot.ts(arch1.sim@path$seriesSim)
```

ARCH(q)

Extensión permitiendo que la varianza del error dependa de los q rezagos de los errores al cuadrado.

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad u_t \sim N(0, \sigma_t^2)$$

$$u_t = \varepsilon_t \sigma_t, \quad \varepsilon_t \sim N(0, 1)$$

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \dots + \alpha_q u_{t-q}^2$$

Muchas veces en la literatura se llama h_t a σ_t^2 , es decir,

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t, \quad u_t \sim N(0, h_t)$$

$$h_t = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \dots + \alpha_q u_{t-q}^2$$

Test ARCH

Antes de estimar un modelo ARCH, podemos realizar el test de Engle (1982) para determinar si hay “**efectos ARCH**” presentes en los residuos del modelo estimado siguiendo estos pasos:

(1) Estimar el modelo:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t$$

(2) Obtener $\hat{u}_t$.

(3) Regresar los $\hat{u}_t^2$ en función de sus propios q rezagos:

$$\hat{u}_t^2 = \gamma_0 + \gamma_1 \hat{u}_{t-1}^2 + \gamma_2 \hat{u}_{t-2}^2 + \dots + \gamma_q \hat{u}_{t-q}^2 + \varepsilon_t$$

(4) Obtener el R^2 y construir el estadístico $T.R^2 \sim \chi^2(q)$.

(5) Las hipótesis nula y alternativa son:

$$H_0 : \gamma_1 = \gamma_2 = \dots = \gamma_q = 0$$

$$H_1 : \text{algún } \gamma_i \neq 0 \quad \forall i = 1, \dots, q$$

- En **STATA**: `estat archlm`
- En **R**: `arch.test()` del paquete `aTSA`.
- En **EViews**: luego de la estimación: View/Residual Diagnostics/Heteroskedasticity Tests... ARCH (indicar q).

Utilice la base de datos `currencies.xls` que contiene 1827 observaciones diarias de distintos tipos de cambio. Se pide:

- (1) Grafique la serie `rgbp` que corresponde a las variaciones diarias de la libra respecto dólar.
- (2) Grafique su histograma.
- (3) Realice un test de normalidad de la variable.
- (4) Estime un modelo $AR(1)$. Evalúe que los residuos sean ruido blanco.
- (5) Realice un test sobre los residuos para evaluar efectos ARCH. ¿Qué observa?

Los modelos ARCH en sí mismos han sido poco utilizados dado que conllevan varias dificultades:

- ¿Cómo determina el valor de q ? Una posibilidad es usar el test LR.

Los modelos ARCH en sí mismos han sido poco utilizados dado que conllevan varias dificultades:

- ¿Cómo determina el valor de q ? Una posibilidad es usar el test LR.
- El valor de q eventualmente podría ser muy alto. Modelos no parsimoniosos.

Los modelos ARCH en sí mismos han sido poco utilizados dado que conllevan varias dificultades:

- ¿Cómo determina el valor de q ? Una posibilidad es usar el test LR.
- El valor de q eventualmente podría ser muy alto. Modelos no parsimoniosos.
- Las restricciones de no-negatividad podrían ser violadas.

Estimación del modelo ARCH(q)

En la especificación del modelo ARCH asumimos normalidad residual condicional:

$$Y_t/\Omega_t \sim N(0, h_t)$$

Recordar que para cualquier variable aleatoria normal X:

- Asimetría = $E(X_t - \mu)^3/\sigma^3 = 0$
- Curtosis = $E(X_t - \mu)^4/\sigma^4 = 3$

Estimación del modelo ARCH(q)

En la especificación del modelo ARCH asumimos normalidad residual condicional:

$$Y_t/\Omega_t \sim N(0, h_t)$$

Recordar que para cualquier variable aleatoria normal X:

- Asimetría = $E(X_t - \mu)^3/\sigma^3 = 0$
- Curtosis = $E(X_t - \mu)^4/\sigma^4 = 3$


Para el caso del ARCH:

- Asimetría = $E(Y_t^3) = E(E_t(Y_t)^3) = 0$
- Curtosis = $E(Y_t^4)/\sigma^4 = 3(1 - \alpha_1^2)/(1 - 3\alpha_1^2) > 3$

Colas más pesadas que una distribución normal.

Estimación del modelo ARCH(q)

Si miramos el histograma de los residuos de la aplicación anterior:



Series: Residuals
Sample 7/08/2002 7/07/2007
Observations 1826

Mean	1.38e-06
Median	0.009370
Maximum	1.774710
Minimum	-2.092157
Std. Dev.	0.412764
Skewness	0.050398
Kurtosis	5.141247

Jarque-Bera	349.6103
Probability	0.000000

Estimación del modelo ARCH(q)

Consideremos un proceso ARCH bajo normalidad condicional

$$y_t | \Omega_t \sim N(x_t' \beta, \sigma_t^2), \quad \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2, \quad \varepsilon_t \equiv y_t - x_t' \beta$$

Dado que el modelo es no lineal en los parámetros a estimar de la varianza condicional, el método de estimación será el de **Máxima Verosimilitud**. Se busca maximizar el logaritmo de la función de verosimilitud:

$$L = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log(\sigma_t^2) - \frac{1}{2} \sum_{t=1}^T (y_t - x_t' \beta)^2 / \sigma_t^2$$

- En **STATA**: arch
- En **R**: ugarchfit() dentro del paquete rugarch o garchFit() dentro del paquete fGarch (existen otros paquetes) .
- En **EViews**: ir a Quick/Estimation/Method/ARCH

```

Title:
  GARCH Modelling

Call:
  garchFit(formula = RGBP ~ arma(1, 0) + garch(1, 0))

Mean and Variance Equation:
  data ~ arma(1, 0) + garch(1, 0)
<environment: 0x0000000018c14fa0>
  [data = fGarch::dem2gbp]

Conditional Distribution:
  norm

Coefficient(s):
              mu              ar1              omega              alpha1
-0.00163520    0.00080844    0.14652820    0.37080537

Std. Errors:
  based on Hessian

Error Analysis:
      Estimate  Std. Error  t value      Pr(>|t|)
mu      -0.0016352    0.0093710   -0.174      0.861
ar1      0.0008084    0.0296164    0.027      0.978
omega    0.1465282    0.0064137   22.846 <0.0000000000000002 ***
alpha1   0.3708054    0.0438546    8.455 <0.0000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Log Likelihood:
  -1206.532      normalized:  -0.6112118

Description:
  wed Aug 21 13:39:51 2019 by user: mcornejo

```

No-normalidad y máxima verosimilitud

El supuesto de normalidad condicional en los errores es esencial para especificar la función de verosimilitud. Es posible evaluar la no-normalidad siguiendo la siguiente representación:

$$u_t = \varepsilon_t \sigma_t, \quad \varepsilon_t \sim N(0, 1)$$
$$\sigma_t = \sqrt{\alpha_0 + \alpha_1 u_{t-1}^2}$$

Recordemos que u_t es $N(0, \sigma_t^2)$ por lo que no es normal, ya que tiene colas pesadas ($K > 3$). Un método factible para evaluar la normalidad condicional es construir el siguiente estadístico:

$$\varepsilon_t = \frac{u_t}{\sigma_t}$$

Se asume que ε_t se distribuye en forma normal, no u_t .

No-normalidad y máxima verosimilitud

La versión muestral será:

$$\hat{\varepsilon}_t = \frac{\hat{u}_t}{\hat{\sigma}_t}$$

Y se conoce como **residuo estandarizado**. Entonces podemos aplicar los test estándar de normalidad sobre $\hat{\varepsilon}_t$ como el Jarque-Bera.

En la práctica, $\hat{\varepsilon}_t$ probablemente siga siendo aún leptocúrtica, aunque menos que $\hat{u}_t$.



No-normalidad y máxima verosimilitud

Incluso aunque el supuesto de distribución normal condicional no se mantenga, los parámetros estimados serán consistentes si el modelo está bien especificado.

El problema estará en los errores estándares estimados por lo que debería usarse un estimador diferente de la matriz de var-cov robusta a la no normalidad: **quasi-maximum likelihood, QML** (ML con errores estándar de Bollerslev-Wooldridge).

- En **STATA**: con la opción `vce(robust)`.
- En **R**: `uGARCHfit()` arroja la versión robusta de los SE dentro del paquete `rugarch`.
- En **EViews**: en la ventana de especificación del modelo ARCH, ir a la solapa de `Options` y seleccionar `Heteroskedasticity consistent covariance (Bollerslev-Wooldridge)`.

Comparación de los histogramas de $\hat{u}_t$ y $\hat{\varepsilon}_t$



- (1) Volver a usar los datos de retornos diarios del principio de la clase.
- (2) Elevarlos al cuadrado.
- (3) Graficar los correlogramas de los retornos mensuales al cuadrado. Comente.
- (4) Estime un modelo ARCH e identifique el orden apropiado.
- (5) Evalúe la normalidad.

- Una extensión natural de los modelos ARCH son los **GARCH** (muy utilizados en la práctica).
- Los modelos GARCH permiten tanto componentes autorregresivos como de medias móviles en la varianza heterocedástica.
- También veremos extensiones al modelo GARCH como el EGARCH, IGARCH, GARCH-in-mean.

GARCH

Modelo GARCH - Bollerslev (1986) y Taylor (1986)

Permite que la varianza condicional dependa de propios rezagos.

Caso más simple: GARCH(1,1):

$$y_t = u_t, \quad u_t \sim N(0, \sigma^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

Si $\beta_1 = 0$, entonces es un ARCH(1).

σ_t^2 puede interpretarse como un promedio ponderado entre:

- un valor promedio de largo plazo (α_0),
- la volatilidad en períodos anteriores ($\alpha_1 u_{t-1}^2$),
- la varianza predicha por el modelo en períodos anteriores ($\beta \sigma_{t-1}^2$)

Es una especie de modelo ARMA de la varianza condicional.

De forma análoga al modelo ARCH, la varianza condicional cambia en el tiempo, mientras que la incondicional es constante y está dada por:

$$V(u_t) = \frac{\alpha_0}{1 - (\alpha_1 + \beta)}$$

siempre que $\alpha_1 + \beta_1 < 1$.

- Si $\alpha_1 + \beta_1 \geq 1$, la varianza incondicional no está definida (no estacionariedad en varianza). Caso poco relevante.
- Si $\alpha_1 + \beta_1 = 1$ hablamos de una raíz unitaria en la varianza (Modelo IGARCH).

El método de estimación es el de **máxima verosimilitud**. El procedimiento sería:

- (1) Especificar las ecuaciones apropiadas de la media y la varianza:

$$y_t = \mu + \phi y_{t-1} + u_t, \quad u_t \sim N(0, \sigma_t^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

- (2) Especificar el logaritmo de la función de verosimilitud para maximizar bajo el supuesto de normalidad de los residuos:

$$L = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log(\sigma_t^2) - \frac{1}{2} \sum_{t=1}^T (y_t - \mu - \phi y_{t-1})^2 / \sigma_t^2$$

- (3) Maximizar dicha función usando métodos numéricos estándar para obtener los valores de los parámetros que maximizan L .

Nuevamente, recuerden que el supuesto de normalidad se hace respecto de ε_t donde $u_t = \varepsilon_t \sigma_t$, $u_t \sim N(0, \sigma_t^2)$. Por lo tanto u_t tiene colas pesadas, entonces evaluamos la normalidad condicional del residuo estandarizado:

$$\hat{\varepsilon}_t = \frac{\hat{u}_t}{\hat{\sigma}_t}$$

Si bien es probable que el supuesto de distribución normal no se mantenga (por exceso de curtosis), usamos la estimación QML (con errores estándares corregidos por Bollerslev-Wooldridge).

- En **STATA**: `arch` usando la opción `garch(q)` e indicar `q`
- En **R**: `ugarchfit()` dentro del paquete `rugarch` o `garchFit()` dentro del paquete `fGarch`.
- En **EViews**: ir a `Quick/Estimation/Method/ARCH...` y seleccionar el orden de la parte GARCH.

Un modelo GARCH(1,1) puede extenderse fácilmente a un modelo GARCH(p,q):

$$y_t = u_t, \quad u_t \sim N(0, \sigma_t^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \dots + \alpha_p u_{t-p}^2 + \beta_1 \sigma_{t-1}^2 + \dots + \beta_q \sigma_{t-q}^2$$

El archivo `garch.xls` contiene la siguiente serie temporal:

- `fspcom`: índice de precios de las acciones de S&P500.

Se pide:

- (1) Grafique la serie
- (2) Calcule el retorno del S&P500. Grafique.
- (3) Estime un modelo GARCH(1,1). Comente
- (4) Realice los siguientes diagnósticos de los residuos:
 - Ausencia de correlación serial
 - Ausencia de efectos ARCH adicionales
 - Normalidad

Extensiones

Extensiones del modelo GARCH

Desde que se desarrolló el modelo GARCH, se propusieron un gran número de extensiones y variantes como consecuencia de muchos problemas que se percibía con el modelo GARCH(p,q) estándar.

- La condiciones de no-negatividad pueden ser violadas.
- Los modelos GARCH no contemplaban los “leverage effects” .
- No existe feedback directo entre la varianza condicional y la media condicional.

Modelos GARCH asimétricos

Los modelos GARCH fuerzan a que exista una respuesta simétrica de la volatilidad a shocks positivos o negativos.

En las series financieras, un shock negativo probablemente cause una volatilidad mayor que un shock positivo de la misma magnitud.

Existe dos **formulaciones asimétricas** muy populares:

- el modelo GJR o TGARCH
- el modelo EGARCH

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).
- Modelo GARCH con un término adicional que considera posibles asimetrías. Varianza condicional dada por:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma u_{t-1}^2 I_{t-1}$$

- donde $I_{t-1} = 1$ si $u_{t-1} < 0$, vale 0 en caso contrario.

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).
- Modelo GARCH con un término adicional que considera posibles asimetrías. Varianza condicional dada por:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma u_{t-1}^2 I_{t-1}$$

- donde $I_{t-1} = 1$ si $u_{t-1} < 0$, vale 0 en caso contrario.
- Para un **efecto apalancamiento**, veremos que $\gamma > 0$.

Modelo GJR o TGARCH

- Propuesto por Glosten, Jagannathan y Runkle (1993).
- Modelo GARCH con un término adicional que considera posibles asimetrías. Varianza condicional dada por:

$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma u_{t-1}^2 I_{t-1}$$

- donde $I_{t-1} = 1$ si $u_{t-1} < 0$, vale 0 en caso contrario.
- Para un **efecto apalancamiento**, veremos que $\gamma > 0$.
- Ahora la condición de no-negatividad será $\alpha_0 > 0$, $\alpha_1 > 0$, $\beta \geq 0$, y $\alpha_1 + \gamma \geq 0$. Es decir, el modelo es aún admisible si $\gamma < 0$ siempre que $\alpha_1 + \gamma \geq 0$.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.
- Para ver cómo la volatilidad aumenta más luego de un gran shock negativo que uno positivo, supongan que $\sigma_{t-1}^2 = 0,823$.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.
- Para ver cómo la volatilidad aumenta más luego de un gran shock negativo que uno positivo, supongan que $\sigma_{t-1}^2 = 0,823$.
- Consideren que $\hat{u}_{t-1} = \pm 0,5$.
- Si $\hat{u}_{t-1} = 0,5$, esto implica que $\sigma_t^2 = 1,65$.

Ejemplo

Si se utilizan los retornos mensuales del S&P500 entre Diciembre de 1979 y Junio de 1988 se encuentra que:

$$y_t = 0,172$$

$$\sigma_t^2 = 1,243 + 0,015u_{t-1}^2 + 0,498\sigma_{t-1}^2 + 0,604u_{t-1}^2 I_{t-1}$$

- El coeficiente de asimetría tiene el signo positivo esperado.
- Para ver cómo la volatilidad aumenta más luego de un gran shock negativo que uno positivo, supongan que $\sigma_{t-1}^2 = 0,823$.
- Consideren que $\hat{u}_{t-1} = \pm 0,5$.
- Si $\hat{u}_{t-1} = 0,5$, esto implica que $\sigma_t^2 = 1,65$.
- En cambio, un shock de igual magnitud, pero con signo negativo ($\hat{u}_{t-1} = -0,5$) implica una varianza condicional predicha al momento t de $\sigma_t^2 = 1,80$.

- En **STATA**: arch con opciones garch y tarch
- En **R**: garch() con opción leverage=TRUE usar el package tseries o en ugarchspec() indicando submodel=TGARCH.
- En **EViews**: ir a Quick/Estimation/Method/ARCH... y seleccionar el orden de la parte GARCH y poner un 1 donde dice Threshold.

Modelo EGARCH (GARCH exponencial)

Propuesto por Nelson (1991).

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \gamma \frac{u_{t-1}}{\sqrt{\sigma_{t-1}^2}} + \alpha \left[\frac{|u_{t-1}|}{\sqrt{\sigma_{t-1}^2}} - \sqrt{\frac{2}{\pi}} \right]$$

Esta especificación tiene múltiples ventajas respecto del GARCH:

- Como modelamos el logaritmo de la varianza condicional, incluso si los parámetros estimados son negativos, σ_t^2 será positiva.
- Se permite que existan asimetrías ya que si la relación entre la volatilidad y los retornos es negativa, γ será negativa.

- En **STATA**: `arch` con opciones `earch` y `egarch`
- En **R**: `ugarchspec` indicando `model='eGARCH'` en `variance.model`, usando el package `rugarch`
- En **EViews**: ir a `Quick/Estimation/Method/ARCH...` y seleccionar `EGARCH` en `Model`.

Utilice la base de datos `currencies.xls`. A partir de la series `rjpy` (retornos del yen respecto del dólar estadounidense) estime un TGARCH y un EGARCH.

Evalúe si hay evidencia de asimetría en la volatilidad condicional de `rjpy`. ¿Son significativos los términos de asimetría?

Tests de asimetría en la volatilidad

Engle y Ng (1993) propusieron un conjunto de tests para evaluar la asimetría en la volatilidad, conocidos como los **tests de sesgo de signo y tamaño**.

En la práctica, los test de Engle-Ng se aplican sobre los residuos del GARCH estimado.

Tests de asimetría en la volatilidad

Engle y Ng (1993) propusieron un conjunto de tests para evaluar la asimetría en la volatilidad, conocidos como los **tests de sesgo de signo y tamaño**.

En la práctica, los test de Engle-Ng se aplican sobre los residuos del GARCH estimado.

Sea S_{t-1}^- una dummy que vale 1 si $\hat{u}_{t-1} < 0$ y 0 en caso contrario. El **test de sesgo de signo** se basa en la significancia de ϕ_1 en:

$$\hat{u}_t^2 = \phi_0 + \phi_1 S_{t-1}^- + v_t$$

donde v_t es un error IID. Si shocks positivos y negativos en $\hat{u}_{t-1}$ impactan en forma diferente sobre la varianza condicional, entonces ϕ_1 será estadísticamente significativa.

Tests de asimetría en la volatilidad

También podría darse el caso de que la magnitud o el tamaño del shock afecten a si la respuesta de la volatilidad a los shocks es simétrica o no.

Diremos que hay un **sesgo negativo en el tamaño** si ϕ_1 es estadísticamente significativo en la siguiente regresión:

$$\hat{u}_t^2 = \phi_0 + \phi_1 S_{t-1}^- u_{t-1} + v_t$$

Tests de asimetría en la volatilidad

Finalmente, definiendo $S_{t-1}^+ = 1 - S_{t-1}^-$, Engle y Ng proponen evaluar conjuntamente sesgos positivos y negativos en el tamaño basándose en la siguiente regresión:

$$\hat{u}_t^2 = \phi_0 + \phi_1 S_{t-1}^- + \phi_2 S_{t-1}^- u_{t-1} + \phi_3 S_{t-1}^+ u_{t-1} + v_t$$

La significatividad de ϕ_1 indica un **sesgo de signo**, mientras que la significatividad de ϕ_2 y ϕ_3 sugieren presencia de **sesgo de tamaño**. El estadístico para el test conjunto se calcula como $T.R^2$ con distribución $\chi^2(3)$.


Curvas de Impacto de Noticias (NIC) - Pagan y Schwert (1990)

- Representación gráfica del grado de asimetría de la volatilidad a shocks positivos y negativos.
- Grafican la volatilidad del próximo período (σ_t^2) que surgiría a partir de diversos valores positivos y negativos de u_{t-1} dado el modelo estimado.
- Se dibujan utilizando la estimación de la ecuación de la varianza condicional.
- Luego, se utilizan valores sucesivos de u_{t-1} en la ecuación para determinar cuáles serían los valores correspondientes de σ_t^2 derivados del modelo.

Curvas de Impacto de Noticias

Figure 8.3

News impact curves for S&P500 returns using coefficients implied from GARCH and GJR model estimates



Ver programa de EViews `nic.pr` para generar curvas de impacto de noticias a partir de un EGARCH.

GARCH-in-mean - Engle, Lilien y Robins (1987)

La mayoría de los modelos en finanzas suponen que los inversores deben ser recompensados con una mayor rentabilidad cuando toman un riesgo adicional. **El retorno debe depender del riesgo.**

$$y_t = \mu + \delta \sigma_{t-1} + u_t, \quad u_t \sim N(0, \sigma_{t-1}^2)$$
$$\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \beta \sigma_{t-1}^2$$

Si δ es positivo y estadísticamente significativo, un incremento en el riesgo (dada por un aumento en la varianza condicional) lleva a un aumento en el retorno promedio. Es decir, δ se puede interpretar como una **prima de riesgo**.

- En **STATA**: arch con opciones garch y archm
- En **R**: ugarchspec indicando model='sGARCH' en variance.model y archm=TRUE, usando el package rugarch
- En **EViews**: ir a Quick/Estimation/Method/ARCH... y seleccionar Std.Dev en ARCH-M.

A partir del retorno calculado sobre el valor de la acción de la compañía que bajaron de **Yahoo Finance** se pide:

- Estime un modelo GARCH. Comente.
- Estime un modelo TGARCH. Comente.
- Estime un modelo EGARCH. Comente.
- Estime un modelo GARCH-M. Comente.

- Tsay (2010) - Cap. 3.
- Tsay (2013) - Cap. 4 (ejemplos en R).