

# Modelos básicos de datos en panel

Gabriel Montes-Rojas

# 3 tipos de estructuras de datos

- **Corte transversal (Cross section)** Muestra de individuos, hogares, firmas, países, etc. que se toman en un momento dado del tiempo.

$\{y_i, x_i\}_{i=1}^N$ , donde  $i$  representa individuos.

Ej.: EPH de 2013, datos de PBI en 2013 para muchos países.

- **Series de tiempo** Muestra por varios periodos del mismo individuo, país, firma, etc.

$\{y_t, x_t\}_{t=1}^T$ , donde  $t$  es tiempo.

Ej.: Inflación en la Argentina.

- **Datos en panel** Combinación de las dos anteriores.

$\{y_{it}, x_{it}\}_{i=1, t=1}^{N, T}$ , donde  $i$  representa individuos y  $t$  tiempo.

1. **Cortes transversales independientes**
2. **Muestras longitudinales**

# Modelos

En un panel longitudinal el mismo individuo es observado a lo largo del tiempo.

$i = 1, 2, \dots, N$  es el índice de individuos (firmas, familias, hogares, países),

$t = 1, 2, \dots, T$  es el índice de tiempo.

Supongamos los siguientes modelos:

- 1  $y_{it} = \alpha + X'_{it}\beta + u_{it}$ ,  $\alpha$  es un escalar,  $\beta$  es un vector  $K \times 1$ ,  $X_{it}$  es la observación  $it$  de las  $K$  variables explicativas. **Pooled OLS.**
- 2  $y_{it} = \alpha_{it} + X'_{it}\beta_{it} + u_{it}$ ,  $\alpha_{it}$  es un escalar específico para cada  $it$ ,  $\beta_{it}$  es un vector  $K \times 1$  específico para cada  $it$ ,  $X_{it}$  es la observación  $it$  de las  $K$  variables explicativas. **Modelo imposible de identificar, igual cantidad de parámetros que de observaciones.**
- 3  $y_{it} = \alpha_i + X'_{it}\beta_i + u_{it}$ ,  $\alpha_i$  es un escalar específico para cada  $i$ ,  $\beta_i$  es un vector  $K \times 1$  específico para cada  $i$ ,  $X_{it}$  es la observación  $it$  de las  $K$  variables explicativas. **SUREG, Paneles heterogéneos.**
- 4  $y_{it} = \alpha_t + X'_{it}\beta_t + u_{it}$ ,  $\alpha_t$  es un escalar específico para cada  $t$ ,  $\beta_t$  es un vector  $K \times 1$  específico para cada  $t$ ,  $X_{it}$  es la observación  $it$  de las  $K$  variables explicativas.

# One-way error components model

$$y_{it} = \alpha + X'_{it}\beta + u_{it}$$

$\alpha$  es un escalar,  $\beta$  es  $K \times 1$ ,  $X_{it}$  es la observación  $it$  de las  $K$  variables explicativas.  
El error tiene esta estructura:

$$u_{it} = \mu_i + v_{it}$$

es el **error compuesto**. En inglés: **one-way error components model**.

- $\mu_i$ : efecto individual no observado que captura todos los factores constantes a lo largo del tiempo en  $y_{it}$ ,
- $v_{it}$ : errores idiosincráticos o shocks.

# One-way error components model

En notación matricial

$$y = \alpha \iota_{NT} + X\beta + u = Z\delta + u,$$

donde  $y$  y  $u$  son vectores  $NT \times 1$ ,  $X$  es una matriz  $NT \times K$ ,  $Z = [\iota'_{NT}, X']'$ ,  $\delta' = [\alpha, \beta']$  y  $\iota_{NT}$  es un vector de 1s con dimensión  $NT \times 1$

$$u = Z_{\mu}\mu + v$$

donde  $Z_{\mu} = I_N \otimes \iota_T$  es una matriz  $NT \times N$  de 1s y 0s,  $\otimes$  es el producto de Kronecker,  $\iota_T$  es un vector de 1s de dimensión  $T$ ,  $\mu = [\mu_1, \dots, \mu_N]'$  es un vector  $N \times 1$  que contiene los efectos individuales, y  $v$  es un vector  $NT \times 1$  con los errores. De esta manera  $Z_{\mu}\mu$  es un vector también  $NT \times 1$ .

Notar que  $Z_{\mu}$  es una matriz de dummies para todos los individuos  $i = 1, 2, \dots, N$ . Es decir, contiene una dummy para cada  $i$ .

# Two-way error components model

Consideremos el modelo

$$y_{it} = \alpha + X'_{it}\beta + u_{it}$$

$\alpha$  es un escalar,  $\beta$  es  $K \times 1$ ,  $X_{it}$  es la observación  $it$  de las  $K$  variables explicativas.

$$u_{it} = \mu_i + \lambda_t + v_{it}$$

es el **error compuesto**. En inglés: **two-way error components model**.

- $\mu_i$ : efecto individual no observado que captura todos los factores constantes a lo largo del tiempo en  $y_{it}$ ,
- $\lambda_t$ : efecto temporal no observado que captura todos los factores constantes a lo de los individuos en  $y_{it}$ ,
- $v_{it}$ : errores idiosincráticos o shocks.

# Two-way error components model

En notación matricial

$$u = Z_{\mu}\mu + Z_{\lambda}\lambda + v,$$

donde  $Z_{\lambda} = \iota_N \otimes I_T$  es una matriz  $NT \times T$  de 1s y 0s,  $\iota_N$  es un vector de 1s de dimensión  $N$ ,  $\lambda = [\lambda_1, \dots, \lambda_T]'$  es un vector  $T \times 1$  que contiene los efectos temporales.

# Paneles multi-dimensionales

- Los modelos anteriores se pueden extender a una mayor cantidad de dimensiones.
- Ejemplos de 3 dimensiones ( $i, j, t$ ):
  - 1 Modelos de comercio exterior podrían tener efectos por exportador, importador, tiempo, etc.
  - 2 Modelos de inmigración podrían tener efectos por país de origen, país de destino, año de inmigración, etc.

En ambos casos podríamos tener efectos para cada elemento,

$$u_{ijt} = \mu_i + \alpha_j + \lambda_t + v_{ijt},$$

o efectos bilaterales, donde nos importan los efectos de a pares,

$$u_{ijt} = \mu_{ij} + \lambda_t + v_{ijt}$$

- Un caso particular es el de los modelos anidados. Por ejemplo, si evaluamos políticas educativas, tendríamos un efecto por alumno ( $i$ ), que pertenece a una determinada clase ( $j$ ), de una escuela ( $k$ ) a lo largo del tiempo ( $t$ ). Así podríamos pensar en una estructura de errores:

$$u_{ijk t} = \mu_i + \alpha_j + \gamma_k + \lambda_t + v_{ijk t}$$

- Ver el libro de Laszlo Matyas (<http://www.metrixmdp.eu>)



# Inconsistencia de OLS

Si  $\text{cov}(x_{it}, \mu_i) \neq 0 \Rightarrow$  OLS es sesgado e inconsistente. ¿Por qué?

Supongamos un modelo de regresión simple:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it} \quad i = 1, 2, \dots, N, t = 1, 2, \dots, T,$$

donde  $E[v_{it}|x_{it}] = 0, \forall i, t.$

Probar:


$$1. \hat{\beta}_1^{OLS} = \frac{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})(y_{it} - \bar{y})}{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})^2} = \beta_1 + \frac{\sum_{i=1}^N T \mu_i (\bar{x}_i - \bar{x}) + \sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})(v_{it} - \bar{v})}{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})^2}$$

$$\xrightarrow{p} \beta_1 + \frac{\text{cov}(x_{it}, \mu_i)}{\text{var} x_{it}} \text{ cuando } N, T \rightarrow \infty \text{ y donde } \bar{x}_i = \frac{1}{T} \sum_{t=1}^T x_{it}.$$

$$2. E[\hat{\beta}_1^{OLS}|X] = \beta_1 + \frac{\sum_{i=1}^N \sum_{t=1}^T E[\mu_i|X](x_{it} - \bar{x})}{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})^2}.$$

# Inconsistencia de OLS

## Panel data



Los siguientes estimadores se proponen como soluciones a este problema:

- **Estimador en primeras diferencias**
- **Efectos fijos**

# Estimador en primeras diferencias (first differences, FD)

$$y_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it}$$

$$y_{it-1} = \beta_0 + \beta_1 x_{it-1} + \mu_i + v_{it-1}$$

$$\Rightarrow \Delta y_{it} = \beta_1 \Delta x_{it} + \Delta v_{it}$$

donde  $\Delta$  es el operador de diferencias,  $\Delta y_{it} = y_{it} - y_{it-1}$ .

Definamos  $\hat{\beta}_1^{FD} = \frac{\sum_{i=1}^N \sum_{t=1}^T \Delta x_{it} \Delta y_{it}}{\sum_{i=1}^N \sum_{t=1}^T \Delta x_{it}^2}$ . Probar que es un estimador insesgado y consistente cuando  $N, T \rightarrow \infty$ .

¡Lo que pasa es que  $\mu_i$  desaparece, entonces se acaba el problema!

# Efectos fijos (fixed-effects, FE)

$$y_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it}$$

$$\tilde{y}_i = \beta_0 + \beta_1 \tilde{x}_i + \tilde{\mu}_i + \tilde{v}_i$$

$$\Rightarrow \tilde{y}_{it} = \beta_1 \tilde{x}_{it} + \tilde{v}_{i,t}$$

donde  $\tilde{\cdot}$  es una transformación que se aplica a cada individuo (se usa en inglés **within transformation**),  $\tilde{y}_{it} = y_{it} - \bar{y}_i$ ,  $\tilde{y}_{it} = T^{-1} \sum_{t=1}^T y_{it}$ .

Definamos  $\hat{\beta}_1^{FE} = \frac{\sum_{i=1}^N \sum_{t=1}^T \tilde{x}_{it} \tilde{y}_{it}}{\sum_{i=1}^N \sum_{t=1}^T \tilde{x}_{it}^2}$ . Probar que es un estimador insesgado y consistente cuando  $N, T \rightarrow \infty$ .

¡Otra vez desaparece  $\mu_i$ ! (porque  $\tilde{\mu}_i = T^{-1} \sum_{t=1}^T \mu_i = T^{-1} T \mu_i = \mu_i$ )

# Efectos fijos (fixed-effects, FE)

En los estimadores de efectos fijos  $\mu_i$  se asumen como **parámetros fijos a ser estimados** y  $v_{it} \sim IID(0, \sigma_v^2)$ .  $x_{it} \perp\!\!\!\perp v_{it}, \forall i, t$ .

Otro modo de ver los modelos FE es  $E(v_{it}|x_{it}) \neq 0$  pero que  $E(v_{it}|x_{it}, \mu_i) = 0$ .  
Entonces necesitamos estimar  $\mu_i$ .

# Efectos fijos (fixed-effects, FE)

- En notación matricial

$$y = \alpha \iota_{NT} + X\beta + Z_{\mu}\mu + v = Z\delta + Z_{\mu}\mu + v$$

- Definamos  $P_{\mu} = Z_{\mu}(Z'_{\mu}Z_{\mu})^{-1}Z'_{\mu}$  como la matriz de proyección en  $Z_{\mu}$ , el subespacio de dummies por individuo.  $Z_{\mu}Z'_{\mu} = I_N \otimes J_T$ . Entonces  $P_{\mu} = Z_{\mu}(Z'_{\mu}Z_{\mu})^{-1}Z'_{\mu} = I_N \otimes \overline{J_T}$  donde  $\overline{J_T} = J_T / T$ .
- $P_{\mu}$  es una matriz que promedia las observaciones para los individuos. Así  $P_{\mu}y$  tiene elementos  $\bar{y}_i = 1/T \sum_{t=1}^T y_{it}$  repetido  $T$  veces para cada  $i$ .
- Probar que  $P_{\mu}$  es simétrica ( $P'_{\mu} = P_{\mu}$ ) e idempotente ( $P_{\mu} \times P_{\mu} = P_{\mu}$ ) por lo que  $\text{rank}(P_{\mu}) = \text{tr}(P_{\mu}) = N$ .

# Efectos fijos (fixed-effects, FE)

- Definamos también el complemento  $Q_\mu = I_{NT} - P_\mu$ .  $Q_\mu$  se define entonces como las desviaciones con respecto a las medias (en inglés within-group operator):  $\tilde{y}_{it} = y_{it} - \bar{y}_i$ .
- Probar que  $Q_\mu$  es simétrica e idempotente, y que  $P_\mu Q_\mu = 0_{NT}$ , por lo que  $\text{rank}(Q_\mu) = \text{tr}(Q_\mu) = N(T - 1)$ .
- Entonces,

$$Q_\mu y = Q_\mu X\beta + Q_\mu v, \Rightarrow \hat{\beta}_{FE} = (X' Q_\mu X)^{-1} X' Q_\mu y$$

- ¿Qué tipo de variables quedan excluidas?



# Efectos fijos (fixed-effects, FE)

Notar que  $\hat{\beta}_{FE}$  es equivalente a un modelo OLS con una dummy para cada individuo  $i$ ,  $\hat{\beta}_{LSDV}$ .

La prueba es una aplicación del Teorema de **Frisch-Waugh-Lovell**.

# Teorema de Frisch-Waugh-Lovell

Consideremos los siguientes modelos de regresión:

$$A. y = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K + u$$

$$B. y = \gamma_2 x_2 + \gamma_3 x_3 + \dots + \gamma_K x_K + v$$

$$C. x_1 = \delta_2 x_2 + \delta_3 x_3 + \dots + \delta_K x_K + e$$

- Computar los residuos del modelo B ( $\hat{v}$ ) y C ( $\hat{e}$ ).
- Correr la siguiente regresión auxiliar:  $\hat{v} = \alpha_0 + \alpha_1 \hat{e} + \text{residuo}$
- Chequear que  $\hat{\alpha}_1 = \hat{\beta}_1$
- ¿Cómo se interpreta este resultado?

# Teorema de Frisch-Waugh-Lovell

En notación matricial

$$y = X_1\beta_1 + X_2\beta_2 + u$$

y consideremos  $\hat{\beta} = [\hat{\beta}_1 \ \hat{\beta}_2]'$ .

Ahora construyamos  $M_2y = M_2X_1\beta_1 + M_2u$  donde  $M_2$  es la proyección residual de  $X_2$ . El teorema de FWL muestra que

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$$

Prueba: Consideremos  $y = P_Xy + M_Xy = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + M_Xy$ . Multipliquemos ambos lados por  $X_1'M_2$  y obtenemos  $X_1'M_2y = X_1'M_2X_1\hat{\beta}_1$ . (Usamos el resultado  $M_2X_2 = 0$  y  $M_XM_2X_1 = 0$ ). Resolver por  $\hat{\beta}_1$ ,

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$$

Si tomamos que  $X_2$  es el conjunto de las dummies por individuo y  $X_1$  son las variables de control, se puede demostrar que la matriz  $M_2 = Q_\mu$  realiza la transformación within de las variables. Entonces nos queda una regresión MCO de  $M_2y$  en  $M_2X_1$ .

# Algebra de MCO (nota para la slide anterior)

**Proyección ortogonal:** Definamos la matriz  $P_X \equiv X(X'X)^{-1}X'$  como la matriz que proyecta  $y$  en el espacio generado por  $X$ . Tenemos que  $\hat{y} = P_X y$ , los valores predichos.

**Proyección residual:** Definamos la matriz  $M_X \equiv I_N - X(X'X)^{-1}X'$  como la proyección de  $y$  en el complemento del espacio de  $X$ . Notemos que  $\hat{u} = M_X y$ , residuos de la regresión.

Notar que  $P_X M_X = 0$ . Además ambas matrices son idempotentes:  
 $P_X P_X = P_X, M_X M_X = M_X$ .

# Efectos fijos (fixed-effects, FE)

Probar que el estimador FE es un promedio ponderado de los estimadores OLS individuales. Es decir,  $\hat{\beta}_{FE} = \sum_{i=1}^N \omega_i \hat{\beta}_{OLS}^i$  donde  $\omega_i \geq 0, i = 1, 2, \dots, N$  es un ponderador tal que  $\sum_{i=1}^N \omega_i = 1$  y  $\hat{\beta}_{OLS}^i$  son los estimadores de OLS de cada individuo  $i$  por separado.

Nota: Lo más fácil es verlo en un modelo de regresión simple. Sino también notar que  $\hat{\beta}_{FE} = (\sum_{i=1}^N (X_i'(I_T - \bar{J}_T)X_i))^{-1} \sum_{i=1}^N (X_i'(I_T - \bar{J}_T)y_i)$ .

Pregunta: ¿De qué dependen los ponderadores?

# Efectos fijos (fixed-effects, FE)

- Notar que  $\text{var}(\hat{\beta}_{FE}) = \sigma_v^2 (X' Q_\mu X)^{-1}$ .
- Podemos plantear  $\hat{\mu}_i = \hat{y}_i - \hat{\beta}_{FE} \bar{x}_i$  o  $\hat{\mu}_{FE} = P_\mu y - \hat{\beta}_{FE} P_\mu X$  como el estimador de los "efectos fijos".
- Si  $T \rightarrow \infty$ ,  $(\hat{\mu}_{FE}, \hat{\beta}_{FE})$  son estimadores consistentes e insesgados.
- Pero si  $T$  está fijo y  $N \rightarrow \infty$ , sólo  $\hat{\beta}_{FE}$  es consistente, aunque ambos son insesgados. El problema es conocido como el problema de parámetros incidentales de Neyman y Scott (1948).
- Contraste de efectos fijos: correr el modelo LSDV, y contrastar conjuntamente por la significatividad de las dummies.

# Efectos fijos (fixed-effects, FE)-two-way

Para el modelo two-way tenemos  $Z_{\lambda} Z'_{\lambda} = J_N \otimes I_T$ . Entonces

$$P_{\lambda} = Z_{\lambda} (Z'_{\lambda} Z_{\lambda})^{-1} Z'_{\lambda} = \overline{J_N} \otimes I_T \text{ donde } \overline{J_N} = J_N / N.$$

Definamos la proyección residual

$$Q_{\mu\lambda} = E_N \otimes E_T = I_N \otimes I_T - I_N \otimes \overline{J_T} + \overline{J_N} \otimes I_T + \overline{J_N} \otimes \overline{J_T}$$

donde  $E_N = I_N - \overline{J_N}$  y  $E_T = I_T - \overline{J_T}$ . Esta transformación elimina los efectos de  $\mu_i$  y  $\lambda_t$  simultáneamente. La matriz  $Q_{\mu\lambda}$  hace la siguiente transformación:

$y_{it} - \bar{y}_i - \bar{y}_t + \bar{y}$ . Entonces,

$$Q_{\mu\lambda} y = Q_{\mu\lambda} X \beta + Q_{\mu\lambda} v, \Rightarrow \hat{\beta}_{FE-2} = (X' Q_{\mu\lambda} X)^{-1} X' Q_{\mu\lambda} y$$

¿Qué tipo de variables quedan excluidas?

# Efectos fijos (fixed-effects, FE)

Usar efectos fijos tiene algunas desventajas:

- Hay un costo en comparación con OLS sin controlar por las dummies por individuo. La transformación within es equivalente a estimar una dummy para cada individuo. O sea estimar  $N - 1$  parámetros adicionales (en el modelo one-way). Más parámetros significa menos precisión.
- Entonces eso afecta los grados de libertad y por ende la precisión de lo que estimamos. Los grados de libertad son  $NT - N - K$ , comparado con  $NT - 1 - K$
- También la transformación within (y first-differences) elimina TODO aquello que esta fijo para cada individuo. Entonces no se puede medir por ejemplo el efecto de SEXO, para individuos, o CONTINENTE para países.



# Efectos fijos (fixed-effects, FE)

Comparando FE con FD (Baltagi, p.17):

- FE es más eficiente que FD cuando  $v_{it} \sim iid(0, \sigma_v^2)$ .
- FD es más eficiente que FE cuando  $v_{it}$  es un paseo aleatorio (random walk).

# Efectos aleatorios (random-effects, RE)

Un modelo alternativo es el de efectos aleatorios. Tiene un supuesto MUY importante y restrictivo:  $\text{cov}(X, \mu) = 0$ .

Consideremos el modelo

$$y_{it} = \beta_0 + \beta_1 x_{it} + u_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it}.$$

En este caso hay **correlación serial**:

$\text{Cov}(u_{it}, u_{is}) = \text{Cov}(\mu_i + v_{it}, \mu_i + v_{is}) = \text{Var}(\mu_i) \neq 0$  para  $t \neq s$ . El estimador de efectos aleatorios (RE) tiene en cuenta esta particularidad y produce un estimador eficiente GLS:

$$\hat{\beta}_{RE} = (X' \Omega^{-1} X)^{-1} (X' \Omega^{-1} y),$$

donde  $\Omega = E(uu')$  es la matriz de varianzas-covarianzas de los errores compuestos.

Una de las ventajas de RE es que se pueden reincorporar variables fijas por individuos:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \beta_2 z_i + \mu_i + v_{it},$$

donde  $z$  captura todas las variables que están fijas para cada individuo y que se pueden observar.

# Efectos aleatorios (random-effects, RE)

En el modelo RE  $\mu_i \sim iid(0, \sigma_\mu^2)$ ,  $v_{it} \sim iid(0, \sigma_v^2)$ ,  $\mu_i \perp v_{it}$ . Además tenemos  $X_{it} \perp \mu_i$  y  $X_{it} \perp v_{it}$  para todo  $i$  y  $t$ .

$$\Omega = E(uu') = Z_\mu E(\mu\mu')Z_\mu' + E(vv') = \sigma_\mu^2(I_N \otimes J_T) + \sigma_v^2(I_N \otimes I_T).$$

$\Omega$  tiene esta estructura:

$$\begin{aligned} \text{cov}(u_{it}, u_{js}) &= \sigma_\mu^2 + \sigma_v^2 && \text{para } i = j, t = s \\ &= \sigma_\mu^2 && \text{para } i = j, t \neq s \\ &= 0 && \text{para } i \neq j \end{aligned}$$

Otra forma de verlo es como un modelo de **equicorrelación** intra cluster:

$$\begin{aligned} \text{correl}(u_{it}, u_{js}) &= 1 && \text{para } i = j, t = s \\ &= \sigma_\mu^2 / (\sigma_\mu^2 + \sigma_v^2) := \rho && \text{para } i = j, t \neq s \\ &= 0 && \text{para } i \neq j, t \neq s \end{aligned}$$

# Efectos aleatorios (random-effects, RE)

¿Cuáles serían las consecuencias de ignorar la correlación serial?

Supongamos el siguiente modelo de regresión univariada:  $y_{it} = \beta x_{it} + \mu_i + v_{it}$ , donde  $\mu_i \sim iid(0, \sigma_\mu^2)$ ,

$v_{it} \sim iid(0, \sigma_v^2)$ ,  $\mu_i \perp v_{it}$ . Además tenemos  $x_{it} \perp \mu_i$  y  $x_{it} \perp v_{it}$  para todo  $i$  y  $t$ .

- Por un lado se puede probar que el estimador OLS  $\hat{\beta}_{OLS} = \frac{\sum_{i=1}^N \sum_{t=1}^T y_{it} x_{it}}{\sum_{i=1}^N \sum_{t=1}^T x_{it}^2}$  es insesgado y consistente.
- Sin embargo la varianza de OLS estimada (bajo los supuestos de independencia de los errores que es lo que estaríamos de ignorar la correlación entre observaciones del mismo individuo) es

$$var(\hat{\beta}_{OLS.est}) = (\sigma_\mu^2 + \sigma_v^2) \frac{1}{\sum_{i=1}^N \sum_{t=1}^T x_{it}^2},$$

pero la varianza correcta es

$$var(\hat{\beta}_{OLS}) = (\sigma_\mu^2 + \sigma_v^2) \frac{1}{\sum_{i=1}^N \sum_{t=1}^T x_{it}^2} + \sigma_\mu^2 \frac{\sum_{i=1}^N \sum_{t=1}^T \sum_{s=1, t \neq s}^T x_{it} x_{is}}{(\sum_{i=1}^N \sum_{t=1}^T x_{it}^2)^2}.$$

- El resultado es que los errores estándar que estima STATA por default son incorrectos, por lo que toda la inferencia es incorrecta.
- Esta diferencia se llama el “factor de Moulton”. Notar que depende de la **correlación intra-individuo** de las Xs. En particular si las Xs no están relacionadas entre sí para un mismo individuo, o sea  $Cov(x_{it}, x_{is}) = 0, t \neq s$ , entonces la varianza estándar es correcta.

# Efectos aleatorios (random-effects, RE)

Para estimarlo vamos a tratar el problema como GLS (generalized least squares) donde se estima  $\Omega$ .

- Siguiendo a Wansbeek y Kapteyn (1982,1983), Baltagi p.18, reemplacemos  $J_T$  por  $T\overline{J_T}$ , y  $I_T$  por  $(E_T + \overline{J_T})$ , donde por definición  $E_T = I_T - \overline{J_T}$ . Entonces reagrupando términos tenemos

$$\begin{aligned}\Omega &= T\sigma_\mu^2(I_N \otimes \overline{J_T}) + \sigma_v^2(I_N \otimes E_T) + \sigma_v^2(I_N \otimes \overline{J_T}) \\ &= (T\sigma_\mu^2 + \sigma_v^2)(I_N \otimes \overline{J_T}) + \sigma_v^2(I_N \otimes E_T) = \sigma_1^2 P_\mu + \sigma_v^2 Q_\mu\end{aligned}$$

donde  $\sigma_1^2 = (T\sigma_\mu^2 + \sigma_v^2)$ .

- Esta es la descomposición espectral de  $\Omega$  donde  $\sigma_1^2$  (de multiplicidad  $N$ ) y  $\sigma_v^2$  (de multiplicidad  $N(T-1)$ ) son las raíces características de  $\Omega$ .
- Esto permite hallar  $\Omega^r = \sigma_1^{2r} P + \sigma_v^{2r} Q$  para todo  $r$  (en particular  $r = -1$ ). [¿Por qué? Probar que es cierto.]

# Efectos aleatorios (random-effects, RE)

- Entonces, surgen los siguientes estimadores

$$\hat{\sigma}_1^2 = \frac{u' P_\mu u}{\text{tr}(P_\mu)} = T \sum_{i=1}^N \bar{u}_i^2 / N$$

$$\hat{\sigma}_v^2 = \frac{u' Q_\mu u}{\text{tr}(Q_\mu)} = \frac{\sum_{t=1}^T \sum_{i=1}^N (u_{it} - \bar{u}_i)^2}{N(T-1)}$$

- Notar que  $u$  no es observado... hay diferentes alternativas, todas ellas consistentes: (i) usar los residuos OLS, (ii) los residuos de FE, y (iii) otras.

# Efectos aleatorios (random-effects, RE)

El estimador RE es entonces

$$\begin{aligned}\hat{\beta}_{RE} &= [(X'Q_{\mu}X/\sigma_v^2) + (X'(P_{\mu} - \bar{J}_{NT})X/\sigma_1^2)]^{-1}[(X'Q_{\mu}y/\sigma_v^2) + (X'(P_{\mu} - \bar{J}_{NT})y/\sigma_1^2)] \\ &= [W_{XX} + \phi^2 B_{XX}]^{-1}[W_{Xy} + \phi^2 B_{Xy}]\end{aligned}$$

donde  $W_{XX} = X'Q_{\mu}X$ ,  $B_{XX} = X'(P_{\mu} - \bar{J}_{NT})X$ ,  $\phi^2 = \sigma_v^2/\sigma_1^2$ . También  $\text{var}(\hat{\beta}_{RE}) = \sigma_v^2[W_{XX} + \phi^2 B_{XX}]^{-1}$ .

Por otro lado  $\hat{\beta}_{FE} = W_{XX}^{-1}W_{Xy}$  y  $\hat{\beta}_{BE} = B_{XX}^{-1}B_{Xy}$ , FE: fixed-effects-within; BE: between (regresión de los promedios intra-individuo solamente). Entonces,

$\hat{\beta}_{RE} = W_1\hat{\beta}_{FE} + W_2\hat{\beta}_{BE}$  donde  $W_1 = [W_{XX} + \phi^2 B_{XX}]^{-1}W_{XX}$  y  $W_2 = [W_{XX} + \phi^2 B_{XX}]^{-1}\phi^2 B_{XX} = I - W_1$ , es decir, RE es un promedio ponderado de FE y BE.

Nota: Análisis cuando  $T \rightarrow \infty$ ,  $N \rightarrow \infty$ ,  $(\sigma_v^2, \sigma_{\mu}^2) \rightarrow 0, \infty$ .

# Efectos aleatorios (random-effects, RE)-two-way

En el modelo RE two-way  $\mu_i \sim iid(0, \sigma_\mu^2)$ ,  $\lambda_t \sim iid(0, \sigma_\lambda^2)$ ,  $v_{it} \sim iid(0, \sigma_v^2)$ ,  $\mu_i \perp v_{it}$ ,  $\lambda_t \perp v_{it}$ . Además tenemos  $X_{it} \perp \mu_i$ ,  $X_{it} \perp \lambda_t$  y  $X_{it} \perp v_{it}$  para todo  $i$  y  $t$ .

$$\Omega = E(uu') = Z_\mu E(\mu\mu')Z_\mu' + Z_\mu E(\lambda\lambda')Z_\mu' + E(vv') = \\ \sigma_\mu^2(I_N \otimes J_T) + \sigma_\lambda^2(J_N \otimes I_T) + \sigma_v^2(I_N \otimes I_T).$$

$\Omega$  tiene esta estructura:

$$\begin{aligned} cov(u_{it}, u_{js}) &= \sigma_\mu^2 + \sigma_\lambda^2 + \sigma_v^2 && \text{para } i = j, t = s \\ &= \sigma_\mu^2 && \text{para } i = j, t \neq s \\ &= \sigma_\lambda^2 && \text{para } i \neq j, t = s \\ &= 0 && \text{para } i \neq j \end{aligned}$$



# Efectos aleatorios (random-effects, RE)-two-way

Para estimarlo vamos a tratar el problema como GLS (generalized least squares) donde se estima  $\Omega$ .

- Baltagi p.37, reemplazar  $J_N$  por  $N\overline{J_N}$ ,  $I_N$  por  $E_N + \overline{J_N}$ ,  $J_T$  por  $T\overline{J_T}$ ,  $I_T$  por  $E_T + \overline{J_T}$ , entonces

$$\Omega = \sum_{j=1}^4 \eta_j Q_j$$

donde  $\eta_1 = \sigma_v^2$ ,  $\eta_2 = T\sigma_\mu^2 + \sigma_v^2$ ,  $\eta_3 = N\sigma_\lambda^2 + \sigma_v^2$ , y  $\eta_4 = T\sigma_\mu^2 + N\sigma_\lambda^2 + \sigma_v^2$ ,  $Q_1 = E_N \otimes E_T$ ,  $Q_2 = E_N \otimes \overline{J_T}$ ,  $Q_3 = \overline{J_N} \otimes E_T$ , y  $Q_4 = \overline{J_N} \otimes \overline{J_T}$ . Esta es la descomposición espectral de  $\Omega$  donde  $\eta_j$  son las raíces características. Cada  $Q_j$  es simétrica e idempotente.

- Entonces, surgen los siguientes estimadores

$$\hat{\eta}_j = \frac{u' Q_j u}{\text{tr}(Q_j)}, j = 1, 2, 3, 4$$

# Efectos aleatorios (random-effects, RE)-two-way

El estimador RE es entonces

$$\begin{aligned}\hat{\beta}_{RE} &= [(X'Q_1X/\sigma_v^2) + (X'Q_2X/\eta_2) + (X'Q_3X/\eta_3)]^{-1} \\ &\quad [(X'Q_1y/\sigma_v^2) + (X'Q_2y/\eta_2) + (X'Q_3y/\eta_3)] \\ &= [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} [W_{Xy} + \phi_2^2 B_{Xy} + \phi_3^2 C_{Xy}]\end{aligned}$$

donde  $W_{XX} = X'Q_1X$ ,  $B_{XX} = X'Q_2X$ ,  $C_{XX} = X'Q_3X$ ,  $\phi_j^2 = \sigma_v^2/\eta_j$ ,  $j = 2, 3$ . También  $\text{var}(\hat{\beta}_{RE}) = \sigma_v^2 [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1}$ .

Entonces,  $\hat{\beta}_{RE} = W_1 \hat{\beta}_{FE} + W_2 \hat{\beta}_{BE1} + W_3 \hat{\beta}_{BE2}$  donde  
 $W_1 = [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} W_{XX}$ ,  $W_2 = [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} \phi_2^2 B_{XX}$ , y  
 $W_3 = [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} \phi_3^2 C_{XX}$ .

[Probar que en este caso también el estimador es un promedio ponderado de tres estimadores. Análisis cuando  $T \rightarrow \infty$ ,  $N \rightarrow \infty$ ,  $(\sigma_v^2, \sigma_\mu^2, \sigma_\lambda^2) \rightarrow 0, \infty$ .]

# Contraste de Hausman

- Un contraste de la validez de efectos aleatorios es

$$H_0 : X \perp Z_{\mu}\mu$$

$$H_A : X \not\perp Z_{\mu}\mu$$

La hipótesis nula es que las variables  $X$  no están relacionadas con los efectos individuales,  $\mu$ .

- Para evaluar este contraste se compara  $\hat{\beta}_{FE}$  con  $\hat{\beta}_{RE}$ . El estimador FE es siempre **consistente**. Sin embargo, el de RE es válido si las  $X$ s no están correlacionadas con  $\mu$ .
- Entonces, si la diferencia es aproximadamente 0 no hay evidencia suficiente para que  $H_0$  sea rechazada. Si por el contrario  $\hat{\beta}_{FE} - \hat{\beta}_{RE} \neq 0$  entonces sí hay que rechazar la nula. Este es el llamado **contraste de Hausman**.

# Contraste de Hausman

- Notemos que el estimador RE es GLS, entonces es el de menor varianza. Por lo tanto  $\text{var}(\hat{\beta}_{FE}) - \text{var}(\hat{\beta}_{RE})$  es una matriz definida positiva. Para demostrarlo notemos que tanto  $W_{XX}$  como  $B_{XX}$  son matrices definidas positivas (formas cuadráticas), mientras que  $\phi^2 > 0$ . Entonces  $[W_{XX} + \phi^2 B_{XX}] - W_{XX}$  es definida positiva, por lo que  $[W_{XX} + \phi^2 B_{XX}]^{-1} - W_{XX}^{-1}$  es definida negativa, o  $\text{var}(\hat{\beta}_{RE}) - \text{var}(\hat{\beta}_{FE})$  es definida negativa.
- Se puede probar que  $\text{var}(\hat{\beta}_{FE} - \hat{\beta}_{RE}) = \text{var}(\hat{\beta}_{FE}) - \text{var}(\hat{\beta}_{RE})$ .
- Entonces, definamos

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' [\text{var}(\hat{\beta}_{FE}) - \text{var}(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE})$$

- El estadístico  $H$  una distribución  $\chi_K^2$  bajo la nula. Se rechaza  $H_0$  si  $H > \chi_K^2(1 - \alpha)$  (valor crítico).

# Contraste de Mundlak

(Hsiao, 2003, sec. 3.2; Wooldridge, 2012, sec. 10.7.3)

- Mundlak (1978) propone usar un modelo de regresión que contenga los promedios de individuos  $i$  de las variables que varían en  $i$  y  $t$ :

$$y_{it} = \beta_0 + \beta_1 x_{it} + \beta_2 z_i + \beta_3 \bar{x}_i + \mu_i + \nu_{it}$$

- Entonces un contraste de  $H_0 : \beta_3 = 0$  es un contraste por la validez de RE.

# Contrastes para efectos aleatorios

## Breusch-Pagan (1980)

- Breusch, T.S. and Pagan, A. (1980). "The Lagrange Multiplier Test and its Applications to Model Specification in Econometrics." *Review of Economic Studies* 47(1), 239–253.

(ver Baltagi, pp-63-65)

Supongamos la función de logaritmo de verosimilitud

$$L(\beta, \theta) = \text{constant} - \frac{1}{2} \log |\Omega| - \frac{1}{2} u' \Omega^{-1} u,$$

donde  $u = y - X\beta$ ,  $\theta' = (\sigma_\mu^2, \sigma_\delta^2, \sigma_v^2)$ , y

$$\Omega = \sigma_\mu^2 (I_N \otimes J_T) + \sigma_\delta^2 (J_N \otimes I_T) + \sigma_v^2 (I_N \otimes I_T).$$

Las hipótesis de interés son

- $H_0^{\sigma_\mu^2, \sigma_\delta^2} : \sigma_\mu^2 = \sigma_\delta^2 = 0$ . Contraste por la ausencia de efectos aleatorios en ambos niveles.
- $H_0^{\sigma_\mu^2} : \sigma_\mu^2 = 0$ . Contraste por la ausencia de efectos aleatorios al nivel individual.
- $H_0^{\sigma_\delta^2} : \sigma_\delta^2 = 0$ . Contraste por la ausencia de efectos aleatorios al nivel temporal.

# Contrastes para efectos aleatorios

## Breusch-Pagan (1980)

La matriz de información es diagonal por bloques en cuanto a  $\beta$  y  $\theta$ . Es implica que sólo tenemos que considerar las derivadas con respecto a  $\theta$ .

Consideremos las derivadas

$$\partial L / \partial \theta_r = \frac{1}{2} \text{tr}[\Omega^{-1} \partial \Omega / \partial \theta_r] + \frac{1}{2} [u' \Omega^{-1} \partial \Omega / \partial \theta_r \Omega^{-1} u],$$

para  $r = 1, 2, 3$ .

La matriz de información tiene elementos

$$J_{rs}(\theta) = E\left[\frac{\partial^2 L}{\partial \theta_r \partial \theta_s}\right] = \frac{1}{2} \text{tr}[\Omega^{-1} \partial \Omega / \partial \theta_r \Omega^{-1} \partial \Omega / \partial \theta_s].$$

El contraste de Breusch-Pagan es un contraste LM (multiplicadores de Lagrange), entonces sólo necesita estimar bajo la hipótesis nula conjunta  $\hat{\sigma}_v^2 = \hat{u}' \hat{u} / NT$ ,  $\hat{u}$  los residuos OLS. El contraste es

$$LM = \hat{D}' \hat{J}^{-1} \hat{D}$$

donde  $D$  son los scores (derivadas).  $LM \sim \chi^2_2$  bajo la hipótesis nula  $H_0^{\sigma_\mu^2, \sigma_\delta^2}$ . Por otro lado  $LM = LM_1 + LM_2$  donde  $LM_1$  y  $LM_2$  son los contrastes LM marginales para  $H_0^{\sigma_\mu^2}$  y  $H_0^{\sigma_\delta^2}$ , respectivamente.

# ¿Cómo implementar paneles en STATA?

- Los datos hay que organizarlos:

| id | tiempo | YVAR            | XVAR            |
|----|--------|-----------------|-----------------|
| 1  | 1      | y <sub>11</sub> | x <sub>11</sub> |
| 1  | 2      | y <sub>12</sub> | x <sub>12</sub> |
| 1  | 3      | y <sub>13</sub> | x <sub>13</sub> |
| 2  | 1      | y <sub>21</sub> | x <sub>21</sub> |
| 2  | 2      | y <sub>22</sub> | x <sub>22</sub> |
| 2  | 3      | y <sub>23</sub> | x <sub>23</sub> |

Es muy importante que no haya valores repetidos. En el ejemplo se representa un panel balanceado. Podría ser desbalanceado si tuviera gaps (ej., la obs.  $i = 1, t = 2$  no está).

- Primero STATA tiene que identificar que se trata de datos en paneles. Para eso se necesita una variable numérica, ej. id, que identifica el individuo. Luego, `iis id`
- Pero si se tiene una muestra longitudinal con una estructura de series de tiempo, con una variable tiempo, `tsset id tiempo`
- Nota: la variable de tiempo tiene que ser en números discretos consecutivos. O sea,  $t = -2, -1, 0, 1, \dots$  o  $t = 1980, 1981, 1982, \dots$



# ¿Cómo implementar paneles en STATA?

- Entonces estamos listos para usar datos en paneles:
- `reg D.y D.x1 D.x2 D.x3` (modelo en diferencias, sólo con `tsset`)
- `xtreg y x1 x2 x3, fe` (modelo de efectos fijos)
- `xi: reg y x1 x2 x3 i.id` (lo mismo pero implementado “a mano” con dummies para `id`) [Nota: comparar con una regresión de las variables transformadas within. ¿Cuál sería el problema con este modelo?]
- `areg y x1 x2 x3, abs(id)` (no reporta las dummies)
- `xtreg y x1 x2 x3, re` (modelo de efectos aleatorios)
- `xtreg y x1 x2 x3, be` (modelo between)
- `xi: xtreg y x1 x2 x3 i.tiempo, fe` (modelo de efectos fijos, two-way)

# ¿Cómo implementar paneles en STATA?

- **Contraste de Hausman test**

```
xtreg y x1 x2 x3, fe  
est store fe  
xtreg y x1 x2 x3, re  
est store re  
hausman fe re
```