

Modelos básicos de datos en panel

Gabriel Montes-Rojas

3 tipos de estructuras de datos

- **Corte transversal (Cross section)** Muestra de individuos, hogares, firmas, países, etc. que se toman en un momento dado del tiempo.

$\{y_i, x_i\}_{i=1}^N$, donde i representa individuos.

Ej.: EPH de 2013, datos de PBI en 2013 para muchos países.

- **Series de tiempo** Muestra por varios periodos del mismo individuo, país, firma, etc.

$\{y_t, x_t\}_{t=1}^T$, donde t es tiempo.

Ej.: Inflación en la Argentina.

- **Datos en panel** Combinación de las dos anteriores.

$\{y_{it}, x_{it}\}_{i=1, t=1}^{N, T}$, donde i representa individuos y t tiempo.

1. **Cortes transversales independientes**
2. **Muestras longitudinales**

Modelos

En un panel longitudinal el mismo individuo es observado a lo largo del tiempo.

$i = 1, 2, \dots, N$ es el índice de individuos (firmas, familias, hogares, países),

$t = 1, 2, \dots, T$ es el índice de tiempo.

Supongamos los siguientes modelos:

- 1 $y_{it} = \alpha + X'_{it}\beta + u_{it}$, α es un escalar, β es un vector $K \times 1$, X_{it} es la observación it de las K variables explicativas. **Pooled OLS.**
- 2 $y_{it} = \alpha_{it} + X'_{it}\beta_{it} + u_{it}$, α_{it} es un escalar específico para cada it , β_{it} es un vector $K \times 1$ específico para cada it , X_{it} es la observación it de las K variables explicativas. **Modelo imposible de identificar, igual cantidad de parámetros que de observaciones.**
- 3 $y_{it} = \alpha_i + X'_{it}\beta_i + u_{it}$, α_i es un escalar específico para cada i , β_i es un vector $K \times 1$ específico para cada i , X_{it} es la observación it de las K variables explicativas. **SUREG, Paneles heterogéneos.**
- 4 $y_{it} = \alpha_t + X'_{it}\beta_t + u_{it}$, α_t es un escalar específico para cada t , β_t es un vector $K \times 1$ específico para cada t , X_{it} es la observación it de las K variables explicativas.

One-way error components model

$$y_{it} = \alpha + X'_{it}\beta + u_{it}$$

α es un escalar, β es $K \times 1$, X_{it} es la observación it de las K variables explicativas.
El error tiene esta estructura:

$$u_{it} = \mu_i + v_{it}$$

es el **error compuesto**. En inglés: **one-way error components model**.

- μ_i : efecto individual no observado que captura todos los factores constantes a lo largo del tiempo en y_{it} ,
- v_{it} : errores idiosincráticos o shocks.

One-way error components model

En notación matricial

$$y = \alpha \iota_{NT} + X\beta + u = Z\delta + u,$$

donde y y u son vectores $NT \times 1$, X es una matriz $NT \times K$, $Z = [\iota'_{NT}, X']'$, $\delta' = [\alpha, \beta']$ y ι_{NT} es un vector de 1s con dimensión $NT \times 1$

$$u = Z_{\mu}\mu + v$$

donde $Z_{\mu} = I_N \otimes \iota_T$ es una matriz $NT \times N$ de 1s y 0s, $\otimes$ es el producto de Kronecker, ι_T es un vector de 1s de dimensión T , $\mu = [\mu_1, \dots, \mu_N]'$ es un vector $N \times 1$ que contiene los efectos individuales, y v es un vector $NT \times 1$ con los errores. De esta manera $Z_{\mu}\mu$ es un vector también $NT \times 1$.

Notar que Z_{μ} es una matriz de dummies para todos los individuos $i = 1, 2, \dots, N$. Es decir, contiene una dummy para cada i .

Two-way error components model

Consideremos el modelo

$$y_{it} = \alpha + X'_{it}\beta + u_{it}$$

α es un escalar, β es $K \times 1$, X_{it} es la observación it de las K variables explicativas.

$$u_{it} = \mu_i + \lambda_t + v_{it}$$

es el **error compuesto**. En inglés: **two-way error components model**.

- μ_i : efecto individual no observado que captura todos los factores constantes a lo largo del tiempo en y_{it} ,
- λ_t : efecto temporal no observado que captura todos los factores constantes a lo de los individuos en y_{it} ,
- v_{it} : errores idiosincráticos o shocks.

Two-way error components model

En notación matricial

$$u = Z_{\mu}\mu + Z_{\lambda}\lambda + v,$$

donde $Z_{\lambda} = \iota_N \otimes I_T$ es una matriz $NT \times T$ de 1s y 0s, ι_N es un vector de 1s de dimensión N , $\lambda = [\lambda_1, \dots, \lambda_T]'$ es un vector $T \times 1$ que contiene los efectos temporales.

Paneles multi-dimensionales

- Los modelos anteriores se pueden extender a una mayor cantidad de dimensiones.
- Ejemplos de 3 dimensiones (i, j, t):
 - 1 Modelos de comercio exterior podrían tener efectos por exportador, importador, tiempo, etc.
 - 2 Modelos de inmigración podrían tener efectos por país de origen, país de destino, año de inmigración, etc.

En ambos casos podríamos tener efectos para cada elemento,

$$u_{ijt} = \mu_i + \alpha_j + \lambda_t + v_{ijt},$$

o efectos bilaterales, donde nos importan los efectos de a pares,

$$u_{ijt} = \mu_{ij} + \lambda_t + v_{ijt}$$

- Un caso particular es el de los modelos anidados. Por ejemplo, si evaluamos políticas educativas, tendríamos un efecto por alumno (i), que pertenece a una determinada clase (j), de una escuela (k) a lo largo del tiempo (t). Así podríamos pensar en una estructura de errores:

$$u_{ijk t} = \mu_i + \alpha_j + \gamma_k + \lambda_t + v_{ijk t}$$

- Ver el libro de Laszlo Matyas (<http://www.metrixmdp.eu>)

Inconsistencia de OLS

Si $\text{cov}(x_{it}, \mu_i) \neq 0 \Rightarrow$ OLS es sesgado e inconsistente. ¿Por qué?

Supongamos un modelo de regresión simple:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it} \quad i = 1, 2, \dots, N, t = 1, 2, \dots, T,$$

donde $E[v_{it}|x_{it}] = 0, \forall i, t.$

Probar:


$$1. \hat{\beta}_1^{OLS} = \frac{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})(y_{it} - \bar{y})}{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})^2} = \beta_1 + \frac{\sum_{i=1}^N T \mu_i (\bar{x}_i - \bar{x}) + \sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})(v_{it} - \bar{v})}{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})^2}$$

$$\xrightarrow{p} \beta_1 + \frac{\text{cov}(x_{it}, \mu_i)}{\text{var} x_{it}} \text{ cuando } N, T \rightarrow \infty \text{ y donde } \bar{x}_i = \frac{1}{T} \sum_{t=1}^T x_{it}.$$

$$2. E[\hat{\beta}_1^{OLS}|X] = \beta_1 + \frac{\sum_{i=1}^N \sum_{t=1}^T E[\mu_i|X](x_{it} - \bar{x})}{\sum_{i=1}^N \sum_{t=1}^T (x_{it} - \bar{x})^2}.$$

Inconsistencia de OLS

Panel data



Los siguientes estimadores se proponen como soluciones a este problema:

- **Estimador en primeras diferencias**
- **Efectos fijos**

Estimador en primeras diferencias (first differences, FD)

$$y_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it}$$

$$y_{it-1} = \beta_0 + \beta_1 x_{it-1} + \mu_i + v_{it-1}$$

$$\Rightarrow \Delta y_{it} = \beta_1 \Delta x_{it} + \Delta v_{it}$$

donde Δ es el operador de diferencias, $\Delta y_{it} = y_{it} - y_{it-1}$.

Definamos $\hat{\beta}_1^{FD} = \frac{\sum_{i=1}^N \sum_{t=1}^T \Delta x_{it} \Delta y_{it}}{\sum_{i=1}^N \sum_{t=1}^T \Delta x_{it}^2}$. Probar que es un estimador insesgado y consistente cuando $N, T \rightarrow \infty$.

¡Lo que pasa es que μ_i desaparece, entonces se acaba el problema!

Efectos fijos (fixed-effects, FE)

$$y_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it}$$

$$\tilde{y}_i = \beta_0 + \beta_1 \tilde{x}_i + \tilde{\mu}_i + \tilde{v}_i$$

$$\Rightarrow \tilde{y}_{it} = \beta_1 \tilde{x}_{it} + \tilde{v}_{i,t}$$

donde $\tilde{\cdot}$ es una transformación que se aplica a cada individuo (se usa en inglés **within transformation**), $\tilde{y}_{it} = y_{it} - \bar{y}_i$, $\tilde{y}_{it} = T^{-1} \sum_{t=1}^T y_{it}$.

Definamos $\hat{\beta}_1^{FE} = \frac{\sum_{i=1}^N \sum_{t=1}^T \tilde{x}_{it} \tilde{y}_{it}}{\sum_{i=1}^N \sum_{t=1}^T \tilde{x}_{it}^2}$. Probar que es un estimador insesgado y consistente cuando $N, T \rightarrow \infty$.

¡Otra vez desaparece μ_i ! (porque $\tilde{\mu}_i = T^{-1} \sum_{t=1}^T \mu_i = T^{-1} T \mu_i = \mu_i$)

Efectos fijos (fixed-effects, FE)

En los estimadores de efectos fijos μ_i se asumen como **parámetros fijos a ser estimados** y $v_{it} \sim IID(0, \sigma_v^2)$. $x_{it} \perp\!\!\!\perp v_{it}, \forall i, t$.

Otro modo de ver los modelos FE es $E(v_{it}|x_{it}) \neq 0$ pero que $E(v_{it}|x_{it}, \mu_i) = 0$.
Entonces necesitamos estimar μ_i .

Efectos fijos (fixed-effects, FE)

- En notación matricial

$$y = \alpha \iota_{NT} + X\beta + Z_{\mu}\mu + v = Z\delta + Z_{\mu}\mu + v$$

- Definamos $P_{\mu} = Z_{\mu}(Z'_{\mu}Z_{\mu})^{-1}Z'_{\mu}$ como la matriz de proyección en Z_{μ} , el subespacio de dummies por individuo. $Z_{\mu}Z'_{\mu} = I_N \otimes J_T$. Entonces $P_{\mu} = Z_{\mu}(Z'_{\mu}Z_{\mu})^{-1}Z'_{\mu} = I_N \otimes \overline{J_T}$ donde $\overline{J_T} = J_T / T$.
- P_{μ} es una matriz que promedia las observaciones para los individuos. Así $P_{\mu}y$ tiene elementos $\bar{y}_i = 1/T \sum_{t=1}^T y_{it}$ repetido T veces para cada i .
- Probar que P_{μ} es simétrica ($P'_{\mu} = P_{\mu}$) e idempotente ($P_{\mu} \times P_{\mu} = P_{\mu}$) por lo que $\text{rank}(P_{\mu}) = \text{tr}(P_{\mu}) = N$.

Efectos fijos (fixed-effects, FE)

- Definamos también el complemento $Q_\mu = I_{NT} - P_\mu$. Q_μ se define entonces como las desviaciones con respecto a las medias (en inglés within-group operator): $\tilde{y}_{it} = y_{it} - \bar{y}_i$.
- Probar que Q_μ es simétrica e idempotente, y que $P_\mu Q_\mu = 0_{NT}$, por lo que $\text{rank}(Q_\mu) = \text{tr}(Q_\mu) = N(T - 1)$.
- Entonces,

$$Q_\mu y = Q_\mu X\beta + Q_\mu v, \Rightarrow \hat{\beta}_{FE} = (X' Q_\mu X)^{-1} X' Q_\mu y$$

- ¿Qué tipo de variables quedan excluidas?

Efectos fijos (fixed-effects, FE)

Notar que $\hat{\beta}_{FE}$ es equivalente a un modelo OLS con una dummy para cada individuo i , $\hat{\beta}_{LSDV}$.

La prueba es una aplicación del Teorema de **Frisch-Waugh-Lovell**.

Teorema de Frisch-Waugh-Lovell

Consideremos los siguientes modelos de regresión:

$$A. y = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K + u$$

$$B. y = \gamma_2 x_2 + \gamma_3 x_3 + \dots + \gamma_K x_K + v$$

$$C. x_1 = \delta_2 x_2 + \delta_3 x_3 + \dots + \delta_K x_K + e$$

- Computar los residuos del modelo B ($\hat{v}$) y C ($\hat{e}$).
- Correr la siguiente regresión auxiliar: $\hat{v} = \alpha_0 + \alpha_1 \hat{e} + \text{residuo}$
- Chequear que $\hat{\alpha}_1 = \hat{\beta}_1$
- ¿Cómo se interpreta este resultado?

Teorema de Frisch-Waugh-Lovell

En notación matricial

$$y = X_1\beta_1 + X_2\beta_2 + u$$

y consideremos $\hat{\beta} = [\hat{\beta}_1 \ \hat{\beta}_2]'$.

Ahora construyamos $M_2y = M_2X_1\beta_1 + M_2u$ donde M_2 es la proyección residual de X_2 . El teorema de FWL muestra que

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$$

Prueba: Consideremos $y = P_Xy + M_Xy = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + M_Xy$. Multipliquemos ambos lados por $X_1'M_2$ y obtenemos $X_1'M_2y = X_1'M_2X_1\hat{\beta}_1$. (Usamos el resultado $M_2X_2 = 0$ y $M_XM_2X_1 = 0$). Resolver por $\hat{\beta}_1$,

$$\hat{\beta}_1 = (X_1'M_2X_1)^{-1}X_1'M_2y$$

Si tomamos que X_2 es el conjunto de las dummies por individuo y X_1 son las variables de control, se puede demostrar que la matriz $M_2 = Q_\mu$ realiza la transformación within de las variables. Entonces nos queda una regresión MCO de M_2y en M_2X_1 .

Algebra de MCO (nota para la slide anterior)

Proyección ortogonal: Definamos la matriz $P_X \equiv X(X'X)^{-1}X'$ como la matriz que proyecta y en el espacio generado por X . Tenemos que $\hat{y} = P_X y$, los valores predichos.

Proyección residual: Definamos la matriz $M_X \equiv I_N - X(X'X)^{-1}X'$ como la proyección de y en el complemento del espacio de X . Notemos que $\hat{u} = M_X y$, residuos de la regresión.

Notar que $P_X M_X = 0$. Además ambas matrices son idempotentes:
 $P_X P_X = P_X, M_X M_X = M_X$.

Efectos fijos (fixed-effects, FE)

Probar que el estimador FE es un promedio ponderado de los estimadores OLS individuales. Es decir, $\hat{\beta}_{FE} = \sum_{i=1}^N \omega_i \hat{\beta}_{OLS}^i$ donde $\omega_i \geq 0, i = 1, 2, \dots, N$ es un ponderador tal que $\sum_{i=1}^N \omega_i = 1$ y $\hat{\beta}_{OLS}^i$ son los estimadores de OLS de cada individuo i por separado.

Nota: Lo más fácil es verlo en un modelo de regresión simple. Sino también notar que $\hat{\beta}_{FE} = (\sum_{i=1}^N (X_i'(I_T - \bar{J}_T)X_i))^{-1} \sum_{i=1}^N (X_i'(I_T - \bar{J}_T)y_i)$.

Pregunta: ¿De qué dependen los ponderadores?

Efectos fijos (fixed-effects, FE)

- Notar que $\text{var}(\hat{\beta}_{FE}) = \sigma_v^2 (X' Q_\mu X)^{-1}$.
- Podemos plantear $\hat{\mu}_i = \bar{y}_i - \hat{\beta}_{FE} \bar{x}_i$ o $\hat{\mu}_{FE} = P_\mu y - \hat{\beta}_{FE} P_\mu X$ como el estimador de los "efectos fijos".
- Si $T \rightarrow \infty$, $(\hat{\mu}_{FE}, \hat{\beta}_{FE})$ son estimadores consistentes e insesgados.
- Pero si T está fijo y $N \rightarrow \infty$, sólo $\hat{\beta}_{FE}$ es consistente, aunque ambos son insesgados. El problema es conocido como el problema de parámetros incidentales de Neyman y Scott (1948).
- Contraste de efectos fijos: correr el modelo LSDV, y contrastar conjuntamente por la significatividad de las dummies.

Efectos fijos (fixed-effects, FE)-two-way

Para el modelo two-way tenemos $Z_{\lambda} Z'_{\lambda} = J_N \otimes I_T$. Entonces

$$P_{\lambda} = Z_{\lambda} (Z'_{\lambda} Z_{\lambda})^{-1} Z'_{\lambda} = \overline{J_N} \otimes I_T \text{ donde } \overline{J_N} = J_N / N.$$

Definamos la proyección residual

$$Q_{\mu\lambda} = E_N \otimes E_T = I_N \otimes I_T - I_N \otimes \overline{J_T} + \overline{J_N} \otimes I_T + \overline{J_N} \otimes \overline{J_T}$$

donde $E_N = I_N - \overline{J_N}$ y $E_T = I_T - \overline{J_T}$. Esta transformación elimina los efectos de μ_i y λ_t simultáneamente. La matriz $Q_{\mu\lambda}$ hace la siguiente transformación:

$y_{it} - \bar{y}_i - \bar{y}_t + \bar{y}$. Entonces,

$$Q_{\mu\lambda} y = Q_{\mu\lambda} X \beta + Q_{\mu\lambda} v, \Rightarrow \hat{\beta}_{FE-2} = (X' Q_{\mu\lambda} X)^{-1} X' Q_{\mu\lambda} y$$

¿Qué tipo de variables quedan excluidas?

Efectos fijos (fixed-effects, FE)

Usar efectos fijos tiene algunas desventajas:

- Hay un costo en comparación con OLS sin controlar por las dummies por individuo. La transformación within es equivalente a estimar una dummy para cada individuo. O sea estimar $N - 1$ parámetros adicionales (en el modelo one-way). Más parámetros significa menos precisión.
- Entonces eso afecta los grados de libertad y por ende la precisión de lo que estimamos. Los grados de libertad son $NT - N - K$, comparado con $NT - 1 - K$
- También la transformación within (y first-differences) elimina TODO aquello que esta fijo para cada individuo. Entonces no se puede medir por ejemplo el efecto de SEXO, para individuos, o CONTINENTE para países.

Efectos fijos (fixed-effects, FE)

Comparando FE con FD (Baltagi, p.17):

- FE es más eficiente que FD cuando $v_{it} \sim iid(0, \sigma_v^2)$.
- FD es más eficiente que FE cuando v_{it} es un paseo aleatorio (random walk).

Efectos aleatorios (random-effects, RE)

Un modelo alternativo es el de efectos aleatorios. Tiene un supuesto MUY importante y restrictivo: $\text{cov}(X, \mu) = 0$.

Consideremos el modelo

$$y_{it} = \beta_0 + \beta_1 x_{it} + u_{it} = \beta_0 + \beta_1 x_{it} + \mu_i + v_{it}.$$

En este caso hay **correlación serial**:

$\text{Cov}(u_{it}, u_{is}) = \text{Cov}(\mu_i + v_{it}, \mu_i + v_{is}) = \text{Var}(\mu_i) \neq 0$ para $t \neq s$. El estimador de efectos aleatorios (RE) tiene en cuenta esta particularidad y produce un estimador eficiente GLS:

$$\hat{\beta}_{RE} = (X' \Omega^{-1} X)^{-1} (X' \Omega^{-1} y),$$

donde $\Omega = E(uu')$ es la matriz de varianzas-covarianzas de los errores compuestos.

Una de las ventajas de RE es que se pueden reincorporar variables fijas por individuos:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \beta_2 z_i + \mu_i + v_{it},$$

donde z captura todas las variables que están fijas para cada individuo y que se pueden observar.

Efectos aleatorios (random-effects, RE)

En el modelo RE $\mu_i \sim iid(0, \sigma_\mu^2)$, $v_{it} \sim iid(0, \sigma_v^2)$, $\mu_i \perp\!\!\!\perp v_{it}$. Además tenemos $X_{it} \perp\!\!\!\perp \mu_i$ y $X_{it} \perp\!\!\!\perp v_{it}$ para todo i y t .

$$\Omega = E(uu') = Z_\mu E(\mu\mu')Z_\mu' + E(vv') = \sigma_\mu^2(I_N \otimes J_T) + \sigma_v^2(I_N \otimes I_T).$$

Ω tiene esta estructura:

$$\begin{aligned} \text{cov}(u_{it}, u_{js}) &= \sigma_\mu^2 + \sigma_v^2 && \text{para } i = j, t = s \\ &= \sigma_\mu^2 && \text{para } i = j, t \neq s \\ &= 0 && \text{para } i \neq j \end{aligned}$$

Otra forma de verlo es como un modelo de **equicorrelación** intra cluster:

$$\begin{aligned} \text{correl}(u_{it}, u_{js}) &= 1 && \text{para } i = j, t = s \\ &= \sigma_\mu^2 / (\sigma_\mu^2 + \sigma_v^2) := \rho && \text{para } i = j, t \neq s \\ &= 0 && \text{para } i \neq j, t \neq s \end{aligned}$$

Efectos aleatorios (random-effects, RE)

¿Cuáles serían las consecuencias de ignorar la correlación serial?

Supongamos el siguiente modelo de regresión univariada: $y_{it} = \beta x_{it} + \mu_i + v_{it}$, donde $\mu_i \sim iid(0, \sigma_\mu^2)$,

$v_{it} \sim iid(0, \sigma_v^2)$, $\mu_i \perp v_{it}$. Además tenemos $x_{it} \perp \mu_i$ y $x_{it} \perp v_{it}$ para todo i y t .

- Por un lado se puede probar que el estimador OLS $\hat{\beta}_{OLS} = \frac{\sum_{i=1}^N \sum_{t=1}^T y_{it} x_{it}}{\sum_{i=1}^N \sum_{t=1}^T x_{it}^2}$ es insesgado y consistente.
- Sin embargo la varianza de OLS estimada (bajo los supuestos de independencia de los errores que es lo que estaríamos de ignorar la correlación entre observaciones del mismo individuo) es

$$var(\hat{\beta}_{OLS.est}) = (\sigma_\mu^2 + \sigma_v^2) \frac{1}{\sum_{i=1}^N \sum_{t=1}^T x_{it}^2},$$

pero la varianza correcta es

$$var(\hat{\beta}_{OLS}) = (\sigma_\mu^2 + \sigma_v^2) \frac{1}{\sum_{i=1}^N \sum_{t=1}^T x_{it}^2} + \sigma_\mu^2 \frac{\sum_{i=1}^N \sum_{t=1}^T \sum_{s=1, t \neq s}^T x_{it} x_{is}}{(\sum_{i=1}^N \sum_{t=1}^T x_{it}^2)^2}.$$

- El resultado es que los errores estándar que estima STATA por default son incorrectos, por lo que toda la inferencia es incorrecta.
- Esta diferencia se llama el "factor de Moulton". Notar que depende de la **correlación intra-individuo** de las Xs. En particular si las Xs no están relacionadas entre sí para un mismo individuo, o sea $Cov(x_{it}, x_{is}) = 0, t \neq s$, entonces la varianza estándar es correcta.

Efectos aleatorios (random-effects, RE)

Para estimarlo vamos a tratar el problema como GLS (generalized least squares) donde se estima Ω .

- Siguiendo a Wansbeek y Kapteyn (1982,1983), Baltagi p.18, reemplacemos J_T por $T\overline{J_T}$, y I_T por $(E_T + \overline{J_T})$, donde por definición $E_T = I_T - \overline{J_T}$. Entonces reagrupando términos tenemos

$$\begin{aligned}\Omega &= T\sigma_\mu^2(I_N \otimes \overline{J_T}) + \sigma_v^2(I_N \otimes E_T) + \sigma_v^2(I_N \otimes \overline{J_T}) \\ &= (T\sigma_\mu^2 + \sigma_v^2)(I_N \otimes \overline{J_T}) + \sigma_v^2(I_N \otimes E_T) = \sigma_1^2 P_\mu + \sigma_v^2 Q_\mu\end{aligned}$$

donde $\sigma_1^2 = (T\sigma_\mu^2 + \sigma_v^2)$.

- Esta es la descomposición espectral de Ω donde σ_1^2 (de multiplicidad N) y σ_v^2 (de multiplicidad $N(T-1)$) son las raíces características de Ω .
- Esto permite hallar $\Omega^r = \sigma_1^{2r} P + \sigma_v^{2r} Q$ para todo r (en particular $r = -1$). [¿Por qué? Probar que es cierto.]

Efectos aleatorios (random-effects, RE)

- Entonces, surgen los siguientes estimadores

$$\hat{\sigma}_1^2 = \frac{u' P_\mu u}{\text{tr}(P_\mu)} = T \sum_{i=1}^N \bar{u}_i^2 / N$$

$$\hat{\sigma}_v^2 = \frac{u' Q_\mu u}{\text{tr}(Q_\mu)} = \frac{\sum_{t=1}^T \sum_{i=1}^N (u_{it} - \bar{u}_i)^2}{N(T-1)}$$

- Notar que u no es observado... hay diferentes alternativas, todas ellas consistentes: (i) usar los residuos OLS, (ii) los residuos de FE, y (iii) otras.

Efectos aleatorios (random-effects, RE)

El estimador RE es entonces

$$\begin{aligned}\hat{\beta}_{RE} &= [(X'Q_{\mu}X/\sigma_v^2) + (X'(P_{\mu} - \bar{J}_{NT})X/\sigma_1^2)]^{-1}[(X'Q_{\mu}y/\sigma_v^2) + (X'(P_{\mu} - \bar{J}_{NT})y/\sigma_1^2)] \\ &= [W_{XX} + \phi^2 B_{XX}]^{-1}[W_{Xy} + \phi^2 B_{Xy}]\end{aligned}$$

donde $W_{XX} = X'Q_{\mu}X$, $B_{XX} = X'(P_{\mu} - \bar{J}_{NT})X$, $\phi^2 = \sigma_v^2/\sigma_1^2$. También $\text{var}(\hat{\beta}_{RE}) = \sigma_v^2[W_{XX} + \phi^2 B_{XX}]^{-1}$.

Por otro lado $\hat{\beta}_{FE} = W_{XX}^{-1}W_{Xy}$ y $\hat{\beta}_{BE} = B_{XX}^{-1}B_{Xy}$, **FE: fixed-effects-within; BE: between** (regresión de los promedios intra-individuo solamente). Entonces,

$\hat{\beta}_{RE} = W_1\hat{\beta}_{FE} + W_2\hat{\beta}_{BE}$ donde $W_1 = [W_{XX} + \phi^2 B_{XX}]^{-1}W_{XX}$ y $W_2 = [W_{XX} + \phi^2 B_{XX}]^{-1}\phi^2 B_{XX} = I - W_1$, es decir, RE es un promedio ponderado de FE y BE.

Nota: **Análisis cuando $T \rightarrow \infty$, $N \rightarrow \infty$, $(\sigma_v^2, \sigma_{\mu}^2) \rightarrow 0, \infty$.**

Efectos aleatorios (random-effects, RE)-two-way

En el modelo RE two-way $\mu_i \sim iid(0, \sigma_\mu^2)$, $\lambda_t \sim iid(0, \sigma_\lambda^2)$, $v_{it} \sim iid(0, \sigma_v^2)$, $\mu_i \perp v_{it}$, $\lambda_t \perp v_{it}$. Además tenemos $X_{it} \perp \mu_i$, $X_{it} \perp \lambda_t$ y $X_{it} \perp v_{it}$ para todo i y t .

$$\Omega = E(uu') = Z_\mu E(\mu\mu')Z_\mu' + Z_\mu E(\lambda\lambda')Z_\mu' + E(vv') = \\ \sigma_\mu^2(I_N \otimes J_T) + \sigma_\lambda^2(J_N \otimes I_T) + \sigma_v^2(I_N \otimes I_T).$$

Ω tiene esta estructura:

$$\begin{aligned} cov(u_{it}, u_{js}) &= \sigma_\mu^2 + \sigma_\lambda^2 + \sigma_v^2 && \text{para } i = j, t = s \\ &= \sigma_\mu^2 && \text{para } i = j, t \neq s \\ &= \sigma_\lambda^2 && \text{para } i \neq j, t = s \\ &= 0 && \text{para } i \neq j \end{aligned}$$

Efectos aleatorios (random-effects, RE)-two-way

Para estimarlo vamos a tratar el problema como GLS (generalized least squares) donde se estima Ω .

- Baltagi p.37, reemplazar J_N por $N\overline{J_N}$, I_N por $E_N + \overline{J_N}$, J_T por $T\overline{J_T}$, I_T por $E_T + \overline{J_T}$, entonces

$$\Omega = \sum_{j=1}^4 \eta_j Q_j$$

donde $\eta_1 = \sigma_v^2$, $\eta_2 = T\sigma_\mu^2 + \sigma_v^2$, $\eta_3 = N\sigma_\lambda^2 + \sigma_v^2$, y $\eta_4 = T\sigma_\mu^2 + N\sigma_\lambda^2 + \sigma_v^2$, $Q_1 = E_N \otimes E_T$, $Q_2 = E_N \otimes \overline{J_T}$, $Q_3 = \overline{J_N} \otimes E_T$, y $Q_4 = \overline{J_N} \otimes \overline{J_T}$. Esta es la descomposición espectral de Ω donde η_j son las raíces características. Cada Q_j es simétrica e idempotente.

- Entonces, surgen los siguientes estimadores

$$\hat{\eta}_j = \frac{u' Q_j u}{\text{tr}(Q_j)}, j = 1, 2, 3, 4$$

Efectos aleatorios (random-effects, RE)-two-way

El estimador RE es entonces

$$\begin{aligned}\hat{\beta}_{RE} &= [(X'Q_1X/\sigma_v^2) + (X'Q_2X/\eta_2) + (X'Q_3X/\eta_3)]^{-1} \\ &\quad [(X'Q_1y/\sigma_v^2) + (X'Q_2y/\eta_2) + (X'Q_3y/\eta_3)] \\ &= [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} [W_{Xy} + \phi_2^2 B_{Xy} + \phi_3^2 C_{Xy}]\end{aligned}$$

donde $W_{XX} = X'Q_1X$, $B_{XX} = X'Q_2X$, $C_{XX} = X'Q_3X$, $\phi_j^2 = \sigma_v^2/\eta_j$, $j = 2, 3$. También $\text{var}(\hat{\beta}_{RE}) = \sigma_v^2 [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1}$.

Entonces, $\hat{\beta}_{RE} = W_1 \hat{\beta}_{FE} + W_2 \hat{\beta}_{BE1} + W_3 \hat{\beta}_{BE2}$ donde
 $W_1 = [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} W_{XX}$, $W_2 = [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} \phi_2^2 B_{XX}$, y
 $W_3 = [W_{XX} + \phi_2^2 B_{XX} + \phi_3^2 C_{XX}]^{-1} \phi_3^2 C_{XX}$.

[Probar que en este caso también el estimador es un promedio ponderado de tres estimadores. Análisis cuando $T \rightarrow \infty$, $N \rightarrow \infty$, $(\sigma_v^2, \sigma_\mu^2, \sigma_\lambda^2) \rightarrow 0, \infty$.]

Contraste de Hausman

- Un contraste de la validez de efectos aleatorios es

$$H_0 : X \perp Z_{\mu}\mu$$

$$H_A : X \not\perp Z_{\mu}\mu$$

La hipótesis nula es que las variables X no están relacionadas con los efectos individuales, μ .

- Para evaluar este contraste se compara $\hat{\beta}_{FE}$ con $\hat{\beta}_{RE}$. El estimador FE es siempre **consistente**. Sin embargo, el de RE es válido si las X s no están correlacionadas con μ .
- Entonces, si la diferencia es aproximadamente 0 no hay evidencia suficiente para que H_0 sea rechazada. Si por el contrario $\hat{\beta}_{FE} - \hat{\beta}_{RE} \neq 0$ entonces sí hay que rechazar la nula. Este es el llamado **contraste de Hausman**.

Contraste de Hausman

- Notemos que el estimador RE es GLS, entonces es el de menor varianza. Por lo tanto $var(\hat{\beta}_{FE}) - var(\hat{\beta}_{RE})$ es una matriz definida positiva. Para demostrarlo notemos que tanto W_{XX} como B_{XX} son matrices definidas positivas (formas cuadráticas), mientras que $\phi^2 > 0$. Entonces $[W_{XX} + \phi^2 B_{XX}] - W_{XX}$ es definida positiva, por lo que $[W_{XX} + \phi^2 B_{XX}]^{-1} - W_{XX}^{-1}$ es definida negativa, o $var(\hat{\beta}_{RE}) - var(\hat{\beta}_{FE})$ es definida negativa.
- Se puede probar que $var(\hat{\beta}_{FE} - \hat{\beta}_{RE}) = var(\hat{\beta}_{FE}) - var(\hat{\beta}_{RE})$.
- Entonces, definamos

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' [var(\hat{\beta}_{FE}) - var(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE})$$

- El estadístico H una distribución χ_K^2 bajo la nula. Se rechaza H_0 si $H > \chi_K^2(1 - \alpha)$ (valor crítico).

Contraste de Mundlak

(Hsiao, 2003, sec. 3.2; Wooldridge, 2012, sec. 10.7.3)

- Mundlak (1978) propone usar un modelo de regresión que contenga los promedios de individuos i de las variables que varían en i y t :

$$y_{it} = \beta_0 + \beta_1 x_{it} + \beta_2 z_i + \beta_3 \bar{x}_i + \mu_i + \nu_{it}$$

- Entonces un contraste de $H_0 : \beta_3 = 0$ es un contraste por la validez de RE.

Contrastes para efectos aleatorios

Breusch-Pagan (1980)

- Breusch, T.S. and Pagan, A. (1980). "The Lagrange Multiplier Test and its Applications to Model Specification in Econometrics." *Review of Economic Studies* 47(1), 239–253.

(ver Baltagi, pp-63-65)

Supongamos la función de logaritmo de verosimilitud

$$L(\beta, \theta) = \text{constant} - \frac{1}{2} \log |\Omega| - \frac{1}{2} u' \Omega^{-1} u,$$

donde $u = y - X\beta$, $\theta' = (\sigma_\mu^2, \sigma_\delta^2, \sigma_v^2)$, y

$$\Omega = \sigma_\mu^2 (I_N \otimes J_T) + \sigma_\delta^2 (J_N \otimes I_T) + \sigma_v^2 (I_N \otimes I_T).$$

Las hipótesis de interés son

- $H_0^{\sigma_\mu^2, \sigma_\delta^2} : \sigma_\mu^2 = \sigma_\delta^2 = 0$. Contraste por la ausencia de efectos aleatorios en ambos niveles.
- $H_0^{\sigma_\mu^2} : \sigma_\mu^2 = 0$. Contraste por la ausencia de efectos aleatorios al nivel individual.
- $H_0^{\sigma_\delta^2} : \sigma_\delta^2 = 0$. Contraste por la ausencia de efectos aleatorios al nivel temporal.

Contrastes para efectos aleatorios

Breusch-Pagan (1980)

La matriz de información es diagonal por bloques en cuanto a β y θ . Es implica que sólo tenemos que considerar las derivadas con respecto a θ .

Consideremos las derivadas

$$\partial L / \partial \theta_r = \frac{1}{2} \text{tr}[\Omega^{-1} \partial \Omega / \partial \theta_r] + \frac{1}{2} [u' \Omega^{-1} \partial \Omega / \partial \theta_r \Omega^{-1} u],$$

para $r = 1, 2, 3$.

La matriz de información tiene elementos

$$J_{rs}(\theta) = E\left[\frac{\partial^2 L}{\partial \theta_r \partial \theta_s}\right] = \frac{1}{2} \text{tr}[\Omega^{-1} \partial \Omega / \partial \theta_r \Omega^{-1} \partial \Omega / \partial \theta_s].$$

El contraste de Breusch-Pagan es un contraste LM (multiplicadores de Lagrange), entonces sólo necesita estimar bajo la hipótesis nula conjunta $\hat{\sigma}_v^2 = \hat{u}' \hat{u} / NT$, $\hat{u}$ los residuos OLS. El contraste es

$$LM = \hat{D}' \hat{J}^{-1} \hat{D}$$

donde D son los scores (derivadas). $LM \sim \chi^2$ bajo la hipótesis nula $H_0^{\sigma_\mu^2, \sigma_\delta^2}$. Por otro lado $LM = LM_1 + LM_2$ donde LM_1 y LM_2 son los contrastes LM marginales para $H_0^{\sigma_\mu^2}$ y $H_0^{\sigma_\delta^2}$, respectivamente.

¿Cómo implementar paneles en STATA?

- Los datos hay que organizarlos:

id	tiempo	YVAR	XVAR
1	1	y ₁₁	x ₁₁
1	2	y ₁₂	x ₁₂
1	3	y ₁₃	x ₁₃
2	1	y ₂₁	x ₂₁
2	2	y ₂₂	x ₂₂
2	3	y ₂₃	x ₂₃

Es muy importante que no haya valores repetidos. En el ejemplo se representa un panel balanceado. Podría ser desbalanceado si tuviera gaps (ej., la obs. $i = 1, t = 2$ no está).

- Primero STATA tiene que identificar que se trata de datos en paneles. Para eso se necesita una variable numérica, ej. `id`, que identifica el individuo. Luego, `iis id`
- Pero si se tiene una muestra longitudinal con una estructura de series de tiempo, con una variable `tiempo`, `tsset id tiempo`
- Nota: la variable de tiempo tiene que ser en números discretos consecutivos. O sea, $t = -2, -1, 0, 1, \dots$ o $t = 1980, 1981, 1982, \dots$

¿Cómo implementar paneles en STATA?

- Entonces estamos listos para usar datos en paneles:
- `reg D.y D.x1 D.x2 D.x3` (modelo en diferencias, sólo con `tsset`)
- `xtreg y x1 x2 x3, fe` (modelo de efectos fijos)
- `xi: reg y x1 x2 x3 i.id` (lo mismo pero implementado “a mano” con dummies para `id`) [Nota: comparar con una regresión de las variables transformadas within. ¿Cuál sería el problema con este modelo?]
- `areg y x1 x2 x3, abs(id)` (no reporta las dummies)
- `xtreg y x1 x2 x3, re` (modelo de efectos aleatorios)
- `xtreg y x1 x2 x3, be` (modelo between)
- `xi: xtreg y x1 x2 x3 i.tiempo, fe` (modelo de efectos fijos, two-way)

¿Cómo implementar paneles en STATA?

- **Contraste de Hausman test**

```
xtreg y x1 x2 x3, fe  
est store fe  
xtreg y x1 x2 x3, re  
est store re  
hausman fe re
```

Paneles dinámicos

Gabriel Montes-Rojas

Paneles dinámicos

Dos modelos que dan lugar a paneles dinámicos:

(1) Muestra longitudinal con correlación serial:

$$y_{it} = x'_{it}\beta + \mu_i + \delta_t + v_{it}$$

$$AR(1) : v_{it} = \alpha v_{it-1} + \epsilon_{it}$$

o

$$MA(1) : v_{it} = \epsilon_{it} + \alpha \epsilon_{it-1}$$

$$i = 1, 2, \dots, N; t = 1, 2, \dots, T; |\alpha| < 1$$

(2) Paneles autorregresivos:

$$y_{it} = \alpha y_{it-1} + x'_{it}\beta + \mu_i + \delta_t + v_{it}$$

$$i = 1, 2, \dots, N; t = 1, 2, \dots, T; |\alpha| < 1$$

En el caso (1) nos interesa estimar la estructura de varianzas y covarianzas. En el (2) eliminar el sesgo por paneles dinámicos dinámico.

Paneles dinámicos

Dos fuentes de persistencia:

- 1 Autocorrelación, persistencia dinámica, **state dependence**: α
Ej: costos de ajustes, costos hundidos, shocks económicos (terremotos, guerras).
- 2 Efectos individuales, **individual heterogeneity**: μ
Ej: habilidad, tecnología, instituciones.
- 3 Ver Bera, A., Sosa-Escudero, W., and Yoon, M. (2001), "Tests for the error component model in the presence of local misspecification," *Journal of Econometrics* 101, 1–23, Zincenko, F., Sosa-Escudero, W. and Montes-Rojas, G.V. (2014), "Robust Tests for Time-invariant Individual Heterogeneity vs. Dynamic State Dependence," *Empirical Economics* 47(4), 1365-1387.

Muestras longitudinales con correlación serial

Los errores estándar están mal calculados...

¿Por qué es importante controlar por correlación serial? El modelo de efectos aleatorios es un caso particular de las posibles correlaciones intra-cluster. Este modelo es en realidad uno de *equicorrelación*, donde la correlación entre observaciones del mismo individuo a lo largo del tiempo es constante.

- Bertrand, M., Duflo, E., and Mullainathan, S. (2004). "How much should we trust differences-in-differences estimates?," *Quarterly Journal of Economics* 119(1), 249-275.

Modelo de efectos aleatorios con correlación serial MA(1)

Supongamos el siguiente modelo:

$$y_{it} = x_{it}\beta + \mu_i + v_{it},$$

$$\mu_i \sim i.i.d.(0, \sigma_\mu^2),$$

$$v_{it} = \epsilon_{it} + \alpha\epsilon_{it-1}, 0 < \alpha < 1, \epsilon \sim i.i.d.(0, \sigma_\epsilon^2)$$

$$i = 1, 2, \dots, N, \quad t = 1, 2, \dots, T.$$

Esto es una estructura de efectos aleatorios con MA(1) adicional. Notar que

$$\sigma_v^2 = (1 + \alpha^2)\sigma_\epsilon^2.$$

Para el estimador OLS la **varianza correcta**, $V(\hat{\beta}_{OLS}|X)$, es:

$$\frac{[\sigma_v^2 + \sigma_\mu^2] \sum_{i=1}^N \sum_{t=1}^T x_{it}^2 + 2\sigma_\mu^2 \sum_{i=1}^N \sum_{t=1}^T \sum_{j=t+1}^{T-1} x_{it}x_{ij} + 2\alpha\sigma_\epsilon^2 \sum_{i=1}^N \sum_{t=2}^T x_{it}x_{it-1}}{\left(\sum_{i=1}^N \sum_{t=1}^T x_{it}^2\right)^2}.$$

Modelo de efectos aleatorios con correlación serial AR(1)

Supongamos el siguiente modelo:

$$y_{it} = x_{it}\beta + \mu_i + v_{it},$$

$$\mu_i \sim i.i.d.(0, \sigma_\mu^2),$$

$$v_{it} = \alpha v_{it-1} + \epsilon_{it}, 0 < \alpha < 1, \epsilon \sim i.i.d.(0, \sigma_\epsilon^2)$$

$$i = 1, 2, \dots, N, \quad t = 1, 2, \dots, T.$$

Esto es una estructura de efectos aleatorios con AR(1) adicional. Notar que

$$\sigma_v^2 = \sigma_\epsilon^2 / (1 - \alpha^2).$$

Para el estimador OLS la **varianza correcta**, $V(\hat{\beta}_{OLS}|X)$, es:

$$\frac{[\sigma_v^2 + \sigma_\mu^2] \sum_{i=1}^N \sum_{t=1}^T x_{it}^2 + 2\sigma_\mu^2 \sum_{i=1}^N \sum_{t=1}^T \sum_{j=t+1}^{T-1} x_{it} x_{ij} + 2\sigma_v^2 \sum_{i=1}^N \sum_{t=2}^T \sum_{j=t+1}^{T-1} \alpha^j x_{it} x_{it-j}}{\left(\sum_{i=1}^N \sum_{t=1}^T x_{it}^2 \right)^2}.$$

Cuando la varianza OLS es incorrecta

- Los errores estándar de OLS pueden ser incorrectos porque no toman en cuenta la correlación intra-cluster. (Factor de Moulton)
- Los errores estándar de RE pueden ser incorrectos porque asumen que la correlación es constante intra-cluster (equicorrelación vs. correlación serial).
- Habría entonces que identificar la estructura correcta de la matriz de correlaciones de los errores.
 - 1 Una posibilidad es estimar la autocorrelación (AR o MA) conjuntamente con los efectos aleatorios.
 - 2 Otra alternativa es usar clusters y errores robustos.

Estimadores de clusters de la varianza

Cameron, C., and Miller, D.L. (2015). "A practitioner's guide to cluster-robust inference," *Journal of Human Resources* 50(2), 317-372.

- Consideremos el estimador OLS: $\hat{\beta}_{OLS} = (X'X)^{-1}(X'Y)$. Calculemos la varianza asintótica $Var(\hat{\beta}_{OLS}) = [E(X'X)]^{-1}E[X'uu'X][E(X'X)]^{-1}$.
- El problema con la varianza es en general la estimación de $E[X'uu'X]$. Ej.: para el modelo RE o RE con correlación serial $E[X'\Omega X]$. Esto depende en general de la estructura **intra-cluster**.
- El estimador de la **varianza robusta de cluster** es $\frac{1}{N} \sum_{i=1}^N X'_i \hat{u}_i \hat{u}'_i X_i$. Se puede demostrar que $\frac{1}{N} \sum_{i=1}^N X'_i \hat{u}_i \hat{u}'_i X_i \xrightarrow{P} E[X'uu'X]$, para $N \rightarrow \infty$ (importante N , nro de grupos). En STATA ver la opción cluster.
- Angrist y Pischke (2009) "The clustered variance estimator [...] is consistent as the number of groups gets large under any within-group correlation structure." (p.313)
- Wooldridge (2010) recomienda implementar estimador RE, que es probable que sea más eficiente que OLS, pero "to make the variance estimator of the random effects robust to arbitrary heteroskedasticity and within-group correlation" (p.867).

Contrastes para efectos aleatorios vs. correlación serial

- Baltagi, B. H., and Li, Q. (1991). "A joint test for serial correlation and random individual effects." *Statistics and Probability Letters* 11, 277-280.
- Baltagi, B. H., and Li, Q. (1995). "Testing AR(1) against MA(1) disturbances in an error component model." *Journal of Econometrics* 68, 133-151.
- Bera, A., Sosa-Escudero, W., and Yoon, M. (2001). "Tests for the error component model in the presence of local misspecification." *Journal of Econometrics* 101, 1-23.
- Bera, A., and Sosa-Escudero, W. (2008). "Tests for unbalanced error-components models under local misspecification." *STATA Journal* 8(1), 68-78.
http://www.stata-journal.com/sjpdf.html?articlenum=sg164_1

Estimación

(Baltagi, 2008, cap.5, pp.92-94, Baltagi y Wu, 1999)

- Consideremos un modelo

$$y_{it} = x'_{it}\beta + \mu_i + \delta_t + v_{it},$$

$$AR(1) : v_{it} = \alpha v_{it-1} + \epsilon_{it},$$

$$\epsilon \sim i.i.d.(0, \sigma_\epsilon^2), \mu \sim i.i.d.(0, \sigma_\mu^2),$$

$$v_{i0} \sim iid(0, \sigma_v^2), \sigma_v^2 = \sigma_\epsilon^2 / (1 - \alpha^2),$$

$$i = 1, 2, \dots, N; t = 1, 2, \dots, T; |\alpha| < 1$$

- La estrategia es: (1) obtener un estimador del parámetro de AR(1); (2) transformar los residuos para que queden sin correlación; (3) estimar la varianza.

Estimación

(Baltagi, 2008, cap.5, pp.92-94, Baltagi y Wu, 1999)

1 Construir los residuos de un modelo simple de FE, $\{\tilde{v}\}_{it}$.

2 Estimar

$$\tilde{\alpha} = \frac{NT}{N(T-1)} \frac{\sum_{i=1}^N \sum_{t=2}^T \tilde{v}_{it} \tilde{v}_{it-1}}{\sum_{i=1}^N \sum_{t=1}^T \tilde{v}_{it}^2}.$$

3 Eliminar AR(1) aplicando la transformación C_{α} a los residuos:

$$C_{\alpha} = \begin{bmatrix} (1 - \alpha^2)^{1/2} & 0 & 0 & \cdots & 0 & 0 & 0 \\ -\alpha & 1 & 0 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -\alpha & 1 & 0 \\ 0 & 0 & 0 & \cdots & 0 & -\alpha & 1 \end{bmatrix}.$$

Equivalente a

$$\tilde{a}_{ijt} = \begin{cases} (1 - \tilde{\alpha}^2)^{1/2} a_{ijt} & \text{if } t = 1 \\ (1 - \tilde{\alpha}^2)^{1/2} \left[\left(\frac{1}{1 - \tilde{\alpha}^2} \right)^{1/2} a_{ijt} - \left(\frac{\tilde{\alpha}^2}{1 - \tilde{\alpha}^2} \right)^{1/2} a_{ijt-1} \right] & \text{if } t > 1 \end{cases}.$$

4 Construir descomposición espectral (no tan fácil).

Estimación

Los siguientes comandos implementan distintas alternativas de estimación en STATA:

- 1 xtregar: <http://www.stata.com/manuals13/xtxtregar.pdf>
- 2 xtgls: <https://www.stata.com/manuals13/xtxtgls.pdf>

Paneles autorregresivos

Corto plazo vs. largo plazo

La estructura dinámica permite distinguir corto de largo plazo.

- β es el efecto contemporáneo **corto plazo** de x en y en t ;
- sin embargo el efecto en t tendrá un efecto en $t + 1$, $t + 2$, etc. por el rezago de la variable dependiente;
- el **efecto de largo plazo** se calcula como $\frac{\beta}{1-\alpha}$ (asumiendo $|\alpha| < 1$)

La ventaja de los paneles dinámicos es que permite tener un modelo de la **dinámica de ajuste**.

Paneles autorregresivos

(caracterización general de Arellano, cap.6)

- Supongamos un modelo donde $\{(y_{i0}, y_{i1}, \dots, y_{iT}, \mu_i), i = 1, 2, \dots, N\}$ es una muestra aleatoria con segundos momentos finitos, tal que

$$y_{it} = \alpha y_{it-1} + \mu_i + v_{it}, t = 1, 2, \dots, T, |\alpha| < 1.$$

- Supuesto B1:

$$E(v_{it} | y_i^{t-1}, \mu_i) = 0$$

donde $y_i^{t-1} = (y_{i0}, y_{i1}, \dots, y_{i(t-1)})$ y $E(\mu_i) = 0$, $\text{var}(\mu_i) = \sigma_\mu^2$.

Este supuesto implica que $E(v_{it} v_{i(t-j)} | y_i^{t-1}, \mu_i) = 0, j > 0$ con lo que los errores no están autocorrelacionados.

- Supuesto B2: Homoscedasticidad condicional:

$$E(v_{it}^2 | y_i^{t-1}, \mu_i) = \sigma_t^2$$

- Supuesto B3: Homoscedasticidad de series de tiempo (no condicional):

$$E(v_{it}^2) = \sigma_v^2$$

Paneles autorregresivos

(caracterización general de Arellano, cap.6)

- **Supuesto B4:** (estacionariedad en la media)

$$E(y_{i0}|\mu_i) = \frac{\mu_i}{1 - \alpha}$$

en cuyo caso $E(y_{it}|\mu_i) = E(y_{i0}|\mu_i)$ (media de steady state) para todo t .

- **Supuesto B5:** (estacionariedad en la media)

$$\text{var}(y_{i0}|\mu_i) = \frac{\sigma_v^2}{1 - \alpha}$$

- **Calcular las covarianzas**

$$\text{cov}(y_{it}, y_{i(t-j)}|\mu_i) = \alpha^{2t-j} \text{var}(y_{i0}|\mu_i) + \alpha^j (\sum_{s=0}^{t-j-1} \alpha^{2s}) \sigma_v^2, j \geq 0.$$

Sesgo de paneles dinámicos, OLS

Para obtener el sesgo del estimador OLS

$$\begin{aligned}\hat{\alpha}_{OLS} &= \frac{\sum_{i=1}^N \sum_{t=1}^T y_{i,t} y_{i,t-1}}{\sum_{i=1}^N \sum_{t=1}^T y_{i,t-1}^2} \\ &= \alpha + \frac{\sum_{i=1}^N \sum_{t=1}^T (\mu_i + v_{it}) y_{i,t-1}}{\sum_{i=1}^N \sum_{t=1}^T y_{i,t-1}^2}\end{aligned}$$

Sesgo de paneles dinámicos, OLS

Calculamos el límite en probabilidad de numerador y denominador (Hsiao, 2003, p.74)

$$\begin{aligned}
 & \text{plim}_{N \rightarrow \infty} \frac{1}{NT} \sum_{i=1}^N \sum_{t=1}^T (\mu_i + v_{it}) y_{i,t-1} \\
 &= \frac{1}{T} \frac{1 - \alpha^T}{1 - \alpha} \text{Cov}(\mu_i, y_{i0}) + \frac{1}{T} \frac{\sigma_\mu^2}{(1 - \alpha)^2} [(T - 1) - T\alpha + \alpha^T] \\
 & \text{plim}_{N \rightarrow \infty} \frac{1}{NT} \sum_{i=1}^N \sum_{t=1}^T y_{i,t-1}^2 \\
 &= \frac{1}{T} \frac{1 - \alpha^{2T}}{(1 - \alpha^2)} \frac{\sum_{i=1}^N y_{i0}^2}{N} + \frac{1}{T} \frac{\sigma_\mu^2}{(1 - \alpha)^2} \left[T - 2 \frac{1 - \alpha^T}{1 - \alpha} + \frac{1 - \alpha^{2T}}{1 - \alpha^2} \right] \\
 & \quad + \frac{1}{T} \frac{2}{(1 - \alpha)} \left[\frac{1 - \alpha^T}{1 - \alpha} - \frac{1 - \alpha^{2T}}{1 - \alpha^2} \right] \text{Cov}(\mu_i, y_{i0}) \\
 & \quad + \frac{1}{T} \frac{\sigma_v^2}{(1 - \alpha)^2} [(T - 1) - T\alpha^2 + \alpha^{2T}]
 \end{aligned}$$

Sesgo de paneles dinámicos, OLS

- En general $\hat{\alpha}_{OLS} \geq \alpha$, OLS sobrestima el valor real, bajo muchos supuestos. En particular asumiendo que $Cov(\mu_i, y_{i0}) > 0$.
- El resultado se mantiene con otras variables de control.
- No es tan claro con otro orden de rezagos.

Sesgo de paneles dinámicos, Nickell (1981)

El estimador de efectos fijos producirá la transformación **within** de todas las variables.
En particular,

$$\tilde{y}_{i,t-1} = y_{i,t-1} - \bar{y}_{i,-1}$$

donde $\bar{y}_{i,-1} = \sum_{t=1}^T y_{i,t-1} / T$

El principal problema es que $\tilde{y}_{i,t-1}$ estará correlacionado con $(u_{i,t-1} - \bar{u}_i)$ aún si u_{it} no tiene correlación serial.

Nickel, S. (1981) "Biases in Dynamic Models with Fixed Effects," Econometrica, 49, 1417-1426.

*El estimador de efectos fijos (within) es sesgado de orden $O(1/T)$, o sea, el sesgo desaparece solo cuando $T \rightarrow \infty$. Entonces habrá un gran sesgo para **T** chico (incluso cuando N sea grande).*

Este problema también se aplica a los modelos de primeras diferencias. La razón es que $\Delta y_{i,t-1} = y_{i,t-1} - y_{i,t-2}$ está correlacionado con $\Delta u_{i,t} = u_{i,t} - u_{i,t-1}$.

Sesgo de paneles dinámicos, Nickell (1981)

Para obtener el sesgo del estimador de efectos fijos debemos usar

$$\hat{\alpha}_{FE} = \frac{\sum_{i=1}^N y'_{i,-1} Q_{\mu} y_i}{\sum_{i=1}^N y'_{i,-1} Q_{\mu} y_{i,-1}}$$

donde $y_{i,-1} = \{y_{iT-1}, y_{iT-2}, \dots, y_{i0}\}$, FE:within-group=efectos fijos.
Para cualquier i

$$\begin{aligned} E(y'_{i,-1} Q_{\mu} y_i) &= \alpha E(y'_{i,-1} Q_{\mu} y_{i,-1}) + E(y'_{i,-1} Q_{\mu} v_i) \\ &= \alpha E(y'_{i,-1} Q_{\mu} y_{i,-1}) + E\left(\sum_{t=1}^T [y_{it-1}(v_{it} - \bar{v}_i)]\right) \end{aligned}$$

Sesgo de paneles dinámicos, Nickell (1981)

El sesgo aparece porque

$$E \left(\sum_{t=1}^T [y_{it-1}(v_{it} - \bar{v}_i)] \right) = -E \left(\sum_{t=1}^T [y_{it-1}\bar{v}_i] \right) \neq 0$$

Notemos que

$$\begin{aligned} y_{it-1} &= \alpha y_{it-2} + \mu_i + v_{it-1} = \alpha^2 y_{it-3} + (1 + \alpha)\mu_i + v_{it-1} + \alpha v_{it-2} \\ &= \left(\sum_{j=0}^{t-2} \alpha^j \right) \mu_i + \sum_{j=0}^{t-2} \alpha^j v_{it-1-j} + \alpha^{t-1} y_{i0} \end{aligned}$$

También,

$$\begin{aligned} \bar{v}_i &= \frac{1}{T} \sum_{t=1}^T v_{it} = \frac{1}{T} (v_{iT} + v_{iT-1} + \dots + v_{it-1} + v_{it-2} + \dots + v_{i1}) \\ E[y_{it-1}\bar{v}_i] &= \frac{1}{T} \sigma_v^2 (1 + \alpha + \dots + \alpha^{t-2}) \end{aligned}$$

Sesgo de paneles dinámicos, Nickell (1981)

Nickell (1981) encuentra que

$$E(y'_{i,-1} Q v_i) = -\sigma_v^2 h_T(\alpha)$$

donde $h_T(\alpha) = \frac{1}{1-\alpha} \left[1 - \frac{1}{T} \left(\frac{1-\alpha^T}{1-\alpha} \right) \right]$. Además,

$$E(y'_{i,-1} Q y_{i,-1}) = \frac{\sigma_v^2 (T-1)}{(1-\alpha^2)} \left(1 - \frac{2\alpha h_T(\alpha)}{(T-1)} \right)$$

Entonces,

$$plim_{N \rightarrow \infty} (\hat{\alpha}_{FE} - \alpha) = -\frac{(1-\alpha^2) h_T(\alpha)}{(T-1)} \left(1 - \frac{2\alpha h_T(\alpha)}{(T-1)} \right)^{-1} = O(1/T)$$

Cuando $T = 2$, $plim_{N \rightarrow \infty} (\hat{\alpha}_{FE} - \alpha) = -\frac{1+\alpha}{2}$

Sesgo de paneles dinámicos, Nickell (1981)

- Consideremos ahora el estimador FD (primeras diferencias):

$\Delta y_{it} = \alpha \Delta y_{it-1} + \Delta v_{it}$, $|\alpha| < 1$. Notemos que $\Delta y_{it-1} = \alpha \Delta y_{it-2} + \Delta v_{it-1}$.

- Además, $\text{plim}_{N \rightarrow \infty} \hat{\alpha}_{FD} = \frac{E(\Delta y_{it-1} \Delta y_{it})}{E(\Delta y_{it-1})^2}$.

- $E(\Delta y_{it-1} \Delta y_{it}) = \alpha E[(\Delta y_{it-1})^2] + E(\Delta v_{it-1} \Delta v_{it}) = \alpha E[(\Delta y_{it-1})^2] - \sigma_v^2$
(usando $E(\Delta y_{it-2} \Delta v_{it}) = 0$)

- $E[(\Delta y_{it-1})^2] = \alpha^2 E[(\Delta y_{it-2})^2] + 2\alpha E(\Delta y_{it-2} \Delta v_{it-1}) + E[(\Delta v_{it-1})^2]$

Entonces, asumiendo estacionariedad (ej. $E[(\Delta y_{it-1})^2] = E[(\Delta y_{it-2})^2]$)

$$E[(\Delta y_{it-1})^2] = \frac{2\sigma_v^2(1-\alpha)}{1-\alpha^2} = \frac{2\sigma_v^2}{1+\alpha}$$

- Entonces, $\text{plim}_{N \rightarrow \infty} (\hat{\alpha}_{FD} - \alpha) = -\frac{(1+\alpha)}{2}$. Notar que no depende de T .

Magnitud del sesgo dinámico para estimadores de efectos fijos

$$y_{it} = \alpha y_{it-1} + \mu_i + v_{it}, |\alpha| < 1.$$

	α							
T	0	0.1	0.25	0.5	0.75	0.9	0.95	0.99
2	-0.500	-0.550	-0.625	-0.750	-0.875	-0.950	-0.975	-0.995
3	-0.333	-0.373	-0.433	-0.536	-0.642	-0.706	-0.728	-0.746
5	-0.200	-0.224	-0.261	-0.331	-0.411	-0.463	-0.481	-0.496
10	-0.100	-0.111	-0.129	-0.162	-0.207	-0.243	-0.257	-0.270
15	-0.067	-0.074	-0.085	-0.106	-0.135	-0.162	-0.174	-0.185
20	-0.050	-0.055	-0.063	-0.078	-0.099	-0.120	-0.130	-0.140

Sesgo asintótico de paneles dinámicos

- Aún cuando $T \rightarrow \infty$, puede haber un sesgo si también $N \rightarrow \infty$
- Si $N/T \rightarrow 0$ entonces no hay sesgo de paneles dinámicos. La intuición es que para cada i se puede correr una regresión individual.
- (Alvarez and Arellano, 2003) Pero para $N/T \rightarrow k < \infty$ y $N/T^3 \rightarrow 0$,

$$\sqrt{NT} [\hat{\alpha}_{FE} - (\alpha - 1/T(1 + \alpha))] \xrightarrow{d} N(0, (1 - \alpha^2))$$

- Nickel (1981) propone usar el factor de ajuste $-1/T(1 + \alpha)$ para T grande.

Anderson y Hsiao (1981)

Anderson, T.W. and Hsiao, C. (1981) "Estimation of Dynamic Models with Error Components," *Journal of the American Statistical Association* 76, 598-606.

- Notar que tanto los estimadores FE como FD no son consistentes para T finito.
- Anderson y Hsiao (1981) proponen usar un estimador VI (variables instrumentales) para obtener estimadores consistentes. Su principal idea se resume en:

- 1 Usar primeras diferencias FD del modelo para cancelar μ_i . Sin embargo, este estimador es inconsistente...
- 2 Entonces usar $\Delta y_{i,t-2}$ o $y_{i,t-2}$ como variable instrumental para $\Delta y_{i,t-1}$.
- 3 ¿Por qué?
 1. $E[y_{i,t-2}\Delta v_{i,t}] = E[y_{i,t-2}(v_{i,t} - v_{i,t-1})] = 0$
 2. $E[y_{i,t-2}\Delta y_{i,t-1}] = E[y_{i,t-2}(y_{i,t-1} - y_{i,t-2})] = -\sigma_v^2(1 - \alpha) \left(\frac{1 - \alpha^{2(t-1)}}{1 - \alpha^2} \right) \neq 0$
[Probar que funciona para $\Delta y_{i,t-2}$.]

¿Cómo funciona IV? (revisión)

- Consideremos el modelo $y = X\beta + u$ donde $\text{cov}(X, u) \neq 0$, o sea endogeneidad.

$$\begin{aligned}\text{plim } \hat{\beta}_{OLS} &= E[X'X]^{-1}E[X'y] = E[X'X]^{-1}E[X'(X\beta + u)] \\ &= \beta + E[X'X]^{-1}E[X'u] \neq \beta\end{aligned}$$

- $E[X'X]^{-1}E[X'u]$ es el sesgo asintótico de OLS con endogeneidad.
- Supongamos que Z es una variable instrumental. Tiene que satisfacer dos condiciones:

- 1 $E[Z'u] = 0$, exogeneidad.
- 2 $E[Z'X] \neq 0$, correlación con la variable endógena.

Entonces $\text{plim } \hat{\beta}_{IV} = E[Z'X]^{-1}E[Z'y] = E[Z'X]^{-1}(E[Z'X]\beta + E[Z'u]) = \beta$.

Anderson and Hsiao (1981)

En el modelo simple, $y_{it} = \alpha y_{it-1} + \mu_i + v_{it}$, $|\alpha| < 1$, usando $y_{i,t-2}$ como IV,

$$plim \hat{\alpha}_{IV} = \frac{E(y_{it-2} \Delta y_{it})}{E(y_{it-2} \Delta y_{it-1})}$$

de donde

$$E(y_{it-2} \Delta y_{it}) = \alpha E(y_{it-2} \Delta y_{it-1}) + E(y_{it-2} \Delta v_{it})$$

La clave está en que está correlacionado con $\Delta y_{i,t-1}$ pero no con $\Delta u_{i,t}$.

- 1 $E[y_{i,t-2} \Delta v_{i,t}] = E[(\alpha y_{i,t-3} + v_{i,t-3})(v_{i,t} - v_{i,t-1})] = 0$ (asumiendo que no hay correlación serial en los errores);
- 2 $E[y_{i,t-2} \Delta y_{i,t-1}] = E[y_{i,t-2}(y_{i,t-1} - y_{i,t-2})] \neq 0$.

- Arellano, M. and Bond, S. (1991) "Some tests of specification for panel data: Monte Carlo evidence and an application to employment equations," *Review of Economic Studies* 58, 277–297.
- Blundell, R. and Bond, S. (1998) "Initial conditions and moment restrictions in dynamic panel data models," *Journal of Econometrics* 87, 115–43.
- Roodman, D. (2009), "How to do xtabond2: An introduction to difference and system GMM in Stata," *Stata Journal* 9(1), 86-136.

Arellano and Bond (1991)

- Consideremos el modelo en primeras diferencias
$$\Delta y_{it} = \alpha \Delta y_{it-1} + \Delta v_{it} = y_{it} - y_{it-1} = \alpha(y_{it-1} - y_{it-2}) + (v_{it} - v_{it-1})$$
- Para $t=2$, $y_{i2} - y_{i1} = \alpha(y_{i1} - y_{i0}) + (v_{i2} - v_{i1})$. Notemos que y_{i0} es un instrumento válido ya que está correlacionado con $(y_{i2} - y_{i1})$ pero no con $(v_{i2} - v_{i1})$ (siempre que los errores no estén autocorrelacionados).
- Para $t=3$, $y_{i3} - y_{i2} = \alpha(y_{i2} - y_{i1}) + (v_{i3} - v_{i2})$. Notemos que y_{i1} y y_{i0} son instrumentos válidos para $(y_{i2} - y_{i1})$ (no están correlacionados con $(v_{i3} - v_{i2})$).
- Podemos continuar de esta manera construyendo instrumentos adicionales para cada periodo, tal que para T , el conjunto de instrumentos es $(y_{i0}, y_{i1}, \dots, y_{iT-2})$.
- Entonces tenemos $t - 1$ condiciones de momento a explotar para cada t .
- En total, bajo el supuesto B1 de Arellano (2002) tenemos $T(T - 1)/2$ restricciones de momentos a explotar.
- Más condiciones de momento implica que IV simple (Anderson-Hsiao) es ineficiente, se puede construir un estimador GMM mejor.

Estimadores GMM

(ver notas optativas sobre estimadores M)

- GMM (Generalized Method of Moments) es un método para generar estimadores a partir de condiciones de momento. Supongamos que $g(W, \theta)$ es una condición de momento tal que para θ_0 satisface $E[g(W, \theta)] = 0$ si y solo si $\theta = \theta_0$, para variables aleatorias W (por ejemplo $W = (X, Y, Z)$).
- $\hat{\theta}_{GMM} = \underset{\theta}{\operatorname{argmin}} \left[N^{-1} \sum_{i=1}^N g(w_i, \theta) \right]' \Omega \left[N^{-1} \sum_{i=1}^N g(w_i, \theta) \right]$ para una matriz Ω definida positiva.
- La matriz Ω determina la eficiencia del estimador. La óptima es $\Omega = E[g(W, \theta_0)g(W, \theta_0)']^{-1}$.

Arellano and Bond (1991)

- Construyamos Z como el conjunto de IV. $Z'\Delta y = Z'(\Delta y_{-1})\alpha + Z'\Delta v$

$$Z_i = \begin{bmatrix} [y_{i0}] & 0 & \cdots & 0 \\ 0 & [y_{i0}, y_{i1}] & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & [y_{i0}, \dots, y_{i,T-2}] \end{bmatrix}$$

- $\hat{\alpha} = [(\Delta y_{-1})' Z \Omega Z' (\Delta y_{-1})]^{-1} [(\Delta y_{-1})' Z \Omega Z' (\Delta y)]$

Arellano and Bond (1991)

- **Estimador GLS en una etapa (one-step estimator):** Asumamos que $v_i t \sim iid(0, \sigma_v^2)$ tal que $E(v_i v_i') = \sigma_v^2 I_T$. Entonces, $E(\Delta v_i \Delta v_i') = \sigma_v^2 G$ donde G es una matriz $(T-1) \times (T-1)$ que se basa en $G = DD'$ donde

$$D = \begin{bmatrix} -1 & 1 & 0 & \cdots & 0 \\ 0 & -1 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \quad \text{es la matriz } (T-1) \times T \text{ de operador en}$$

primeras diferencias: $\Delta v_i = Dv_i$.

Entonces, se usa $\hat{\Omega} = \sum_{i=1}^N Z_i' G Z_i$.

- **Estimador GMM en dos etapas (two-step estimator):**

$\hat{\Omega} = \sum_{i=1}^N Z_i' (\widehat{\Delta v_i}) (\widehat{\Delta v_i})' Z_i$ para una estimación preliminar (ej., one-step) de $\widehat{\Delta v}$.

Arellano and Bond (1991)

El modelo también admite otras variables exógenas x que pueden estar relacionadas con μ_i , entonces x s son instrumentos válidos.

Las variables explicativas **exógenas** se pueden separar en dos tipos:

- Las **variables predeterminadas** (weakly exogeneous) donde $E[x_{it}v_{is}] \neq 0$ para $s \leq t$ pero $E[x_{it}v_{is}] = 0$ para $s > t$. Entonces $[x'_{i0}, x'_{i1}, \dots, x'_{i(s-1)}]$ son instrumentos válidos para la ecuación en diferencias en el periodo s .
- Por ejemplo, x'_{i0} y x'_{i1} son instrumentos válidos para $y_{i3} - y_{i2} = \alpha(y_{i2} - y_{i1}) + (x'_{i3} - x'_{i2})\beta + (v_{i3} - v_{i2})$. Tenemos entonces, la matriz de instrumentos Z . $Z'\Delta y = Z'(\Delta y_{-1})\alpha + Z'(\Delta X)\beta + Z'\Delta v$

$$Z_i = \begin{bmatrix} [y_{i0}, x'_{i0}, x'_{i1}] & 0 & \dots & 0 \\ 0 & [y_{i0}, y_{i1}, x'_{i0}, x'_{i1}, x'_{i2}] & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & [y_{i0}, \dots, y_{i,T-2}, x'_{i0}, \dots, x'_{i,T-1}] \end{bmatrix}$$

- Las **variables estrictamente exógenas** se pueden usar $[x'_{i0}, x'_{i1}, \dots, x'_{iT}]$ como un elemento más de la diagonal de Z_i .
- La metodología de Arellano-Bond se puede usar para la presencia de otras **variables endógenas**. Es decir, la estructura de rezagos en paneles dinámicos sirve para resolver casos de endogeneidad general.

Arellano and Bond (1991)

- El estimador de Arellano-Bond depende de la ausencia de correlación serial de segundo orden en los errores de la ecuación en diferencias. O sea, $E[\Delta v_{it} \Delta v_{it-2}] = 0$. AB proponen un contraste para eso que debe ser chequado. Bajo la hipótesis nula los errores no tienen autocorrelación AR(2) (o mayor) o siguen un paseo aleatorio. ¿Qué hacer si este supuesto se rechaza?
- Arellano-Bond también proponen un contraste de Sargan-Hansen (overidentifying restrictions):

$$m = \widehat{\Delta v}' Z \left[\sum_{i=1}^N Z_i' \widehat{\Delta v}_i \widehat{\Delta v}_i' Z_i \right] Z' \widehat{\Delta v} \sim \chi^2_{\#rest - \#par}$$

Contraste para la validez de los instrumentos

Contraste de Sargan-Hansen

Un supuesto crucial de GMM es que los instrumentos son válidos si no están correlacionados con los residuos. Supongamos que queremos armar un contraste para la validez de los instrumentos.

Requerimiento importante: Necesitamos **más** variables instrumentales que variables endógenas. Tomemos el modelo

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + \beta_3 z_2 + u$$

donde y_2 es (potencialmente) endógena; z_1 and z_2 son variables explicativas exógenas; z_3 and z_4 son IV.

- 1 Supongamos que en el modelo anterior usamos 2SLS con z_3 como la **única** variable instrumental.
- 2 Computar $\hat{u}_3 = y_1 - \hat{\beta}_0 - \hat{\beta}_1 y_2 - \hat{\beta}_2 z_1 - \hat{\beta}_3 z_2$.
- 3 Correr la regresión auxiliar $\hat{u}_3 = \delta_0 + \hat{\delta}_1 z_1 + \hat{\delta}_2 z_2 + \delta_4 z_4$.
- 4 Chequer la significancia de z_4 .
- 5 Esto nos da un contraste válido para la validez de z_4 como IV. Pero tenemos que asumir que z_3 es una IV válida.

Contraste para la validez de los instrumentos

Contraste de Sargan-Hansen

- 1 Si tenemos más IVs que variables endógenas, entonces el modelo está sobre-identificado (over-identified).
- 2 Consideremos H_0 : todas las IVs son exógenas. Si rechazamos entonces alguna de las IVs es endógena.
- 3 Estimar el modelo con todos las IVs usando 2SLS. Obtener los residuos $\hat{u}$.
- 4 Correr la regresión de $\hat{u}$ en TODAS las variables exógenas (IVs, X exógenas, constante).
- 5 Computar $NR_u^2 \stackrel{a}{\sim} \chi^2_{L-K}$, donde R_u^2 es el de la última regresión.

Contraste para la validez de los instrumentos

Contraste de Sargan-Hansen

- Supongamos que $\hat{e}$ son los residuos del modelo de 2SLS.
- Si el modelo está sobreidentificado entonces $Z'\hat{e}$ no es exactamente 0, y $\frac{1}{\sqrt{N}}Z'\hat{e} \xrightarrow{d} N(0, V_{Z-e})$.
- Entonces podemos armar $\frac{1}{\sqrt{N}}Z'\hat{e}V_{Z-e}^{-1}\frac{1}{\sqrt{n}}Z'\hat{e}$, donde V_{Z-e} es la varianza de $Z'e$.
- Los contrastes de Sargan y Hansen difieren en como V_{Ze} es estimada.
- Contraste de Sargan: asume homoscedasticidad. Usa estimadores one-step: $V_{Ze} = Z'Z$.
- Contraste de Hansen: permite heteroscedasticidad, usa two-step.

Ahn and Schmidt (1995)

- Ahn y Schmidt (1995) muestran que con supuestos no muy fuertes hay condiciones adicionales que se pueden usar.
- Arellano-Bond usan $T(T-1)/2$ condiciones de momento usando $E(y_{is}\Delta v_{it}) = 0, t = 2, 3, \dots, T, s = 0, \dots, t-2$.
- Sin embargo también están disponibles las condiciones $E(v_{iT}\Delta v_{it}) = 0, t = 2, \dots, T-1$ usando el supuesto de varianza constante $E(v_{it}^2) = \sigma_i^2, t = 1, 2, \dots, T$
- Hay entonces un conjunto de $T(T-1)/2 + (T-1)$ condiciones de momento.

Blundell and Bond (1998)

- Blundell y Bond (1998) encuentran que el estimador de Anderson-Hsiao cumple con la siguiente propiedad. Supongamos que $T = 2$ tal que α está exactamente identificado de $E(y_{i0}\Delta v_{i2}) = 0$.
- En este caso la primera etapa de 2SLS se obtiene de una regresión de Δy_{i1} en y_{i0} : $\Delta y_{i1} = (\alpha - 1)y_{i0} + \mu_i + v_{i1}$ (asumiendo $E(v_{i0} = 0)$). Entonces,

$$plim(\hat{\alpha} - 1) = (\alpha - 1) \frac{c}{c + \sigma_{\mu}^2 / \sigma_v^2},$$

donde $c = (1 - \alpha) / (1 + \alpha)$. El estimador es sesgado hacia abajo (cuanto más grande es $\sigma_{\mu}^2 / \sigma_v^2$).

- También el contraste F se vuelve $F = \frac{(\sigma_v^2 c)^2}{\sigma_{\mu}^2 + \sigma_v^2 c} \rightarrow 0$ cuando $\alpha \rightarrow 1$.
 $E[y_{i,t-2}\Delta y_{i,t-1}] = E[y_{i,t-2}(y_{i,t-1} - y_{i,t-2})] = -\sigma_v^2(1 - \alpha) \left(\frac{1 - \alpha^{2(t-1)}}{1 - \alpha^2} \right) \neq 0$
- Blundell-Bond entonces buscan usar condiciones adicionales: rezagos en diferencias para la ecuación en niveles. El supuesto necesario es que:

$$E[(y_{i0} - \frac{\mu_i}{1 - \alpha})\mu_i] = 0$$

tal que y converge a su media $\frac{\mu_i}{1 - \alpha}$ para cada individuo a partir de $t = 1$.

Blundell and Bond (1998)

- Con el supuesto adicional $E[\Delta v_{it} \mu_i] = 0$ tenemos $T - 2$ restricciones adicionales

$$E[\Delta y_{it}(\mu_i + v_{it})] = 0, t = 2, 3, \dots, T.$$

- Particularidad: $\Delta y_{i,t-1}$ se usan como instrumentos en **niveles**.
- Blundell-Bond desarrollan un estimador GMM que toma las condiciones de Arellano-Bond junto con las $T - 2$ condiciones adicionales.
- El estimador se llama **System GMM**: estima simultáneamente dos ecuaciones, una en niveles y otra en diferencias, usando diferentes instrumentos para cada una.
- Gana eficiencia para T chico.

Motivación: Roodman (2009,p136)

136

Bulletin




Figure 1. Citations of Arellano and Bond (1991) and Blundell and Bond (1998) per year, 1991–2006

Proliferación de instrumentos: muchos instrumentos

Arellano-Bond usan $T(T-1)/2$ condiciones de momento usando $E(y_{is}\Delta v_{it}) = 0, t = 2, 3, \dots, T, s = 0, \dots, t-2$. Alvarez y Arellano (2003) muestran que a menos que $\lim(T/N) = 0$, el estimador tendrá un sesgo de orden $O(1/N)$. Hay dos problemas principales con muchos instrumentos:

- 1 Sobreestimación (overfitting)
- 2 Mala estimación de la matriz de pesos Ω .

Proliferación de instrumentos: muchos instrumentos

- Cuando el nro de IV crece, entonces sobreestima (overfits) la variable endógena.
Ejemplo: Si $\#IV = NT$ (tantas observaciones como IV), entonces en la primera etapa de 2SLS $R^2 = 1$, y por construcción $OLS = 2SLS$.
- Arellano (2003) muestra que el sesgo de overfitting es $O(j/N)$, j es el nro de instrumentos para variables pre-determinadas, y $O(jT/N)$ para variables endógenas.

Proliferación de instrumentos: muchos instrumentos

- Cuando el nro de IV crece, la matriz de pesos Ω se estima de forma imprecisa.
- La matriz óptima Ω depende de $\text{var}(Z'\Delta\nu)$.
- Esta es cuadrática en el nro. de IV, lo que significa cuártica en T , o sea $O(T^4)$.
- Se requieren momentos segundos de $Z'\nu$, que implica momentos cuartos de las distribuciones subyacentes (Hayashi, 2000, p.215).

- 1 La matriz estimada puede ser singular.
- 2 Sesgo hacia abajo en los errores estándar: muestra más significancia de la que verdaderamente hay. El problema es que no se toma en cuenta que Ω es estimada.
- 3 El contraste de Sargan-Hansen (para validez de IV) es no creíble. En general, un alto p-valor del contraste se usa como validez de los IV. Pero el paper de Bowsher (2000) muestra que muchos IV vuelve el test de Sargan-Hansen poco creíble.

"A few calculations were made by the author on the order of magnitude of the errors involved in this approximation. They were found to be proportional to the number of instrumental variables, so that, if the asymptotic approximations are to be used, this number must be small." (Sargan, 1958)

Proliferación de instrumentos: muchos instrumentos

• Soluciones propuestas:

- 1 Regla: El nro de IV no debería ser mayor que N . Es decir, mantener el nro. de IV cercano al nro de individuos. [Nota: Roodman (2009) en realidad dice que esto no tiene ningún valedero estadístico.]
- 2 Probar diferentes especificaciones de IV. El problema de IV no afecta la consistencia de GMM, entonces en muestras chicas es importante analizar su comportamiento. Si el modelo funciona debería dar resultados similares con distintos IV. Probar cortar los rezagos en 1 o 2, que es equivalente a poner 0 en la matriz Z .
- 3 Colapsar/combinar instrumentos. Ventaja que toda la información se usa (todos los IVs). Es equivalente a imponer que ciertos conjuntos de parámetros tienen el mismo coeficiente. Busca minimizar $\sum_t y_{i,t-l} \Delta v_{it}$ para cada l en vez de $y_{i,t-l} \Delta v_{it}$ para cada t, l .

$$Z_i = \begin{bmatrix} y_{i0} & 0 & 0 & \cdots \\ y_{i1} & y_{i0} & 0 & \cdots \\ y_{i2} & y_{i1} & y_{i0} & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Simulation: Roodman (2009,p150)

150

Bulletin

TABLE 1
Simulation results for $N = 100$, $\alpha = 0.8$, varying ρ , T , and instrument set

	$\rho = 0.0$ (system GMM valid)				$\rho = 0.9$ (system GMM invalid)			
Time dimension (T)	5	10	15	20	5	10	15	20
Full instrument set								
Instrument count	10	45	105	190	10	45	105	190
Estimated α mean	0.86	0.84	0.83	0.82	1.03	0.94	0.87	0.84
Estimated α standard dev.	0.12	0.06	0.04	0.03	0.05	0.04	0.03	0.02
Hansen JP average	0.459	0.410	0.608	1.000	0.314	0.107	0.603	1.000
Lag 1 only								
Instrument count	7	17	27	37	7	17	27	37
Estimated α mean	0.87	0.85	0.84	0.85	1.02	0.94	0.91	0.89
Estimated α standard dev.	0.12	0.07	0.06	0.04	0.06	0.04	0.03	0.03
Hansen JP average	0.469	0.462	0.455	0.438	0.284	0.123	0.150	0.199
Collapsed								
Instrument count	5	10	15	20	5	10	15	20
Estimated α mean	0.80	0.80	0.80	0.80	1.04	0.92	0.83	0.80
Estimated α standard dev.	0.17	0.08	0.05	0.04	0.05	0.06	0.06	0.04
Hansen JP average	0.488	0.488	0.467	0.468	0.267	0.060	0.105	0.199
Lag 1 only, collapsed								
Instrument count	3	3	3	3	3	3	3	3
Estimated α mean	0.81	0.80	0.80	0.80	1.04	0.98	0.90	0.84
Estimated α standard dev.	0.18	0.09	0.06	0.05	0.06	0.06	0.08	0.07
Hansen JP average	0.510	0.513	0.488	0.501	0.205	0.018	0.012	0.017
Observations	300	800	1,300	1,800	300	800	1,300	1,800

Note: All instrument sets include the constant term.



www.elsevier.com/locate/worlddev

World Development Vol. 44, pp. 77–87, 2013
© 2012 Elsevier Ltd. All rights reserved.
0305-750X/\$ - see front matter

<http://dx.doi.org/10.1016/j.worlddev.2012.12.006>

Can Poor Countries Lobby for More US Bilateral Aid?

GABRIEL V. MONTES-ROJAS*

City University London, UK

Summary. — This article explores if countries can lobby the US government for the allocation of US bilateral foreign aid. We consider an informational lobby model where lobbying has two effects. First, a direct effect by informing US policymakers about their countries' needs. Second, an indirect effect on policymakers by informing them about common interests in economic or geopolitical terms. The lobbyist thus influences the decisions about the allocation of aid resources. We estimate the effect of the recipient country's lobbying agents in obtaining foreign aid. The econometric results show that lobbying positively affects the amount of bilateral aid received.
© 2012 Elsevier Ltd. All rights reserved.

Key words — foreign aid, lobbying, interest groups

1. INTRODUCTION

Bilateral and multilateral aid is increasingly selective and allocated by donors on the basis of objective criteria. Three-fourths of aid agencies, including Denmark, Norway, Sweden, the United Kingdom, Ireland, and the Netherlands,

(2000) find evidence that the direction of foreign aid is dictated by political and strategic considerations, rather than by the economic needs or performance of the recipients. Alesina and Weder (2002) analyze whether corrupt countries receive more aid. Chong, Gradstein, and Calderon (2001) analyze the effect of foreign aid on inequality and poverty.

University, Department of Government (<http://dvn.iq.harvard.edu/dvn/dv/Voeten/faces/study/StudyPage.xhtml?studyId=38311&versionNumber=1&tab=files>). We compute the proportion of votes where each country coincides with the US in the General Assembly on an annual basis.

Recipient countries' needs are captured by aggregate data for all disasters, all countries on an annual basis, estimated damage costs (US\$), from the Emergency Events Database (<http://www.emdat.be/>). We transform the data to real terms and computed the log value (imputing a value of 1 for the non-existent log of 0). This variable is now defined as *Disaster*.

4. ECONOMETRIC RESULTS

(a) *Econometric models*

Our interest lies in evaluating the link between foreign lobbying and foreign aid for the period 1997–2009. Consider a panel data model of the form

$$\ln(Aid_{it}) = \beta \ln(Lobby_{it-1}) + \gamma X_{it} + \mu_i + \delta_t + \epsilon_{it}, \quad (1)$$

where i denotes country, t year, Aid foreign aid, $Lobby$ represents the FARA lobbying variable, X a set of additional control variables, and (μ, δ, ϵ) an error components model with country- and time-specific effects. Country fixed-effects are in-

this persistence is significant. Second, a recent application of the effect of FARA lobbying in a related context by Gawande *et al.* (2009) proposes to use a dynamic specification to account for the fact that lobbying has both a short-run and long-run effect. Therefore, the proposed dynamic model is

$$\ln(Aid_{it}) = \alpha \ln(Aid_{it-1}) + \beta \ln(Lobby_{it-1}) + \gamma X_{it} + \mu_i + \delta_t + \epsilon_{it}. \quad (2)$$

The long-run effect of *Lobby* on *Aid* is $\frac{\beta}{1-\alpha}$.

In dynamic panel data models with unobserved effects, the treatment of the initial observations is an important theoretical and practical problem. As is well known, the usual within estimator is inconsistent, and can be badly biased. We thus follow the Anderson and Hsiao (1981) and Arellano and Bond (1991) strategy by taking first order differences and using lagged values of the dependent variable and other covariates in levels to instrument the autoregressive dependent variable. These instruments are also valid for other potential endogenous variables. Thus we also use instruments for the lobbying variable while we consider that all other covariates (population, GDP, year dummies) are exogenous. In particular, we implement the Blundell and Bond (1998) System GMM estimator that incorporates information from the levels regression instrumented with lagged differences and has better bias properties. The validity of this econometric method depends on the

Table 3. *Effect of lobbying on total US assistance: different GMM estimators*

Model	$GDPpc \leq \text{US\$5,000}$			$GDPpc \leq \text{US\$10,000}$		
	(1) Collapsed	(2) 1 lag	(3) Full	(4) Collapsed	(5) 1 lag	(6) Full
$\ln(Aid_{it-1})$	0.408*** (0.133)	0.464*** (0.103)	0.216** (0.104)	0.417*** (0.130)	0.437*** (0.0952)	0.220** (0.0930)
$\ln(Lobby_{it-1})$	0.0408* (0.0243)	0.0614** (0.0240)	0.0646** (0.0279)	0.0439** (0.0211)	0.0666*** (0.0214)	0.0608** (0.0263)
$\ln(GDP_{it-1})$	-0.263*** (0.0976)	-0.288*** (0.103)	-0.377*** (0.140)	-0.348*** (0.0912)	-0.377*** (0.0939)	-0.466*** (0.119)
$\ln(Pop_{it-1})$	0.695*** (0.160)	0.645*** (0.145)	0.941*** (0.173)	0.763*** (0.174)	0.748*** (0.146)	1.025*** (0.159)
Observations	1,500	1,500	1,500	1,812	1,812	1,812
Number of countries	117	117	117	141	141	141
Arellano-Bond AR(2) stat	-1.099	-0.984	-1.508	-0.755	-0.690	-1.217
AR(2) p-value	0.272	0.325	0.132	0.450	0.490	0.224
Hansen stat	30.05	55.43	102.1	31.18	52.72	130.7
Hansen p-value	0.148	0.137	1.000	0.118	0.200	0.980
#IV	25	47	168	25	47	168

Notes: Robust standard errors in parentheses. Dependent variable $\ln(Aid_{it})$. All specifications include year dummies. Collapsed is the Roodman (2009) collapsed instruments System GMM estimator. 1 lag is the System GMM estimator where only 1 lag is used in the GMM generation of instruments. Full is the Blundell and Bond (1998) System GMM estimator with all possible instruments.

* $p < 0.1$.

** $p < 0.05$.

*** $p < 0.01$.

¿Cómo implementar paneles en STATA?

- Los datos hay que organizarlos:

id	tiempo	YVAR	XVAR
1	1	y_{11}	x_{11}
1	2	y_{12}	x_{12}
1	3	y_{13}	x_{13}
2	1	y_{21}	x_{21}
2	2	y_{22}	x_{22}
2	3	y_{23}	x_{23}

Es muy importante que no haya valores repetidos. En el ejemplo se representa un panel balanceado. Podría ser desbalanceado si tuviera gaps (ej., la obs. $i = 1, t = 2$ no está).

- Primero STATA tiene que identificar que se trata de datos en paneles. Para eso se necesita una variable numérica, ej. `id`, que identifica el individuo. Luego, `iis id`
- Pero si se tiene una muestra longitudinal con una estructura de series de tiempo, con una variable `tiempo`, `tsset id tiempo`
- Nota: la variable de tiempo tiene que ser en números discretos consecutivos. O sea, $t = -2, -1, 0, 1, \dots$ o $t = 1980, 1981, 1982, \dots$

¿Cómo implementar paneles en STATA?

- Entonces estamos listos para usar datos en paneles:
- `reg D.y D.x1 D.x2 D.x3` (modelo en diferencias, sólo con `tsset`)
- `xtreg y x1 x2 x3, fe` (modelo de efectos fijos)
- `xi: reg y x1 x2 x3 i.id` (lo mismo pero implementado “a mano” con `dummies para id`) [Nota: comparar con una regresión de las variables transformadas within. ¿Cuál sería el problema con este modelo?]
- `xtreg y x1 x2 x3, re` (modelo de efectos aleatorios)
- `xtreg y x1 x2 x3, be` (modelo between)
- `xi: xtreg y x1 x2 x3 i.tiempo, fe` (modelo de efectos fijos, two-way)

Arellano-Bond y Blundell-Bond

- 1 Por default, STATA contiene el comando `xtabond`
<http://www.stata.com/help.cgi?xtabond>
- 2 Pero la mejor opción es `xtabond2` que se explica en Roodman (2009). Para instalarlo:
`ssc install xtabond2, all replace`
- 3 Otra alternativa:
<http://www.stata.com/help.cgi?xtdpdsys>