

Economía Laboral - Práctica

Clase 1

Ma Josefina Baez / Joaquin Varvasino

Lic./Maestría en Economía

Universidad Nacional de La Plata

Modalidad del curso

- Horario: jueves de 10 a 13 hs.
- Lugar: aula posgrado o laboratorio de informática
- Página web: <https://sites.google.com/a/cedlas.org/laboral>
 - Aquí pueden encontrar una lista de las referencias de la parte teórica y práctica
 - En la página se van a poner los enunciados de los prácticos
- Carpeta con bibliografía (libros, manuales y papers)
- Grupos de trabajo (máximo 3 personas)

Tipos de actividades

- **Trabajos prácticos** en el laboratorio
- **Referee Reports:** resumen del paper (máximo dos carillas)
- **Presentación de papers**

Referee Reports

1 Objetivo del paper

- ¿Qué trata de hacer el trabajo?
- ¿Cómo lo hace? ¿Qué datos usan? ¿Resuelve algún problema en especial?

2 Estrategia de identificación y metodología

- ¿Cuál es la estrategia de identificación y los supuestos?
- ¿Cuáles son los métodos de estimación?

3 Descripción de resultados encontrados

4 Críticas, observaciones, posibles extensiones

- ¿Validez interna y externa? ¿Algún supuesto puede ser violado?
- ¿Ejercicios de robustez?
- Contribución
- ¿Datos adecuados? ¿Problemas de atrición o de no respuesta?
- ¿Potenciales mecanismos? ¿Mecanismo relevante no analizado?
- ¿Se explicita alguna implicancia de política?
- Cuestiones formales: fácil de entender, buen uso de tablas y gráficos

La clase en una diapositiva

- ¿Por qué tenemos clases prácticas?
- ¿Cómo abordar una investigación empírica?
 - Preguntas de interés
 - Diseño de la investigación
 - Estimaciones
- Dificultades típicas para responder la pregunta de interés
- Algunas soluciones

¿Por qué tenemos clases prácticas?

- Economía laboral es un campo con gran cantidad de estudios empíricos en economía
- Amplia disponibilidad de datos laborales
 - encuestas de hogares, de trabajo, de firmas, etc.
 - datos administrativos
 - big-data (por ej. google trends)
- Mucho terreno por cubrir: muchos modelos e hipótesis que se pueden evaluar con datos observables
- Las herramientas y el enfoque se pueden extender a otros campos de la microeconomía aplicada (desarrollo, salud, educación, evaluación de impacto).

¿Por qué tenemos clases prácticas?

- Estadística descriptiva
- Estimación de *efectos causales* dentro de un marco teórico.
 - enfoque experimental, métodos forma reducida, identificación basada en datos
 - enfoque estructural, mucha teoría y supuestos, ex ante, identificación basada en formas funcionales
 - enfoques complementarios pero hay especialización
- Algunas preguntas de interés:
 - ¿Cuál es el efecto del ingreso no laboral sobre la decisión de trabajar?
 - ¿Qué efecto tiene el salario mínimo sobre el empleo?
 - Retornos a la educación
 - Participación laboral de las mujeres y el número de hijos
 - Retiro y salud

¿Por qué tenemos clases prácticas?

- Angrist y Pischke (2010) The Credibility Revolution in Empirical Economics, JEP, 24(2)
- Crítica de Leamer (80s): La investigación empírica y el análisis de datos no es creíble
- Soluciones de Leamer: ejercicios de robustez, sensibilidad, extreme bounds analysis
- Solución moderna (90s-2000s) : Diseño de investigación / estrategia de identificación

¿Por qué tenemos clases prácticas?

- El objetivo de las clases es desarrollar la capacidad de análisis de problemas comunes en la investigación empírica
- Ver diseños de investigación y metodologías aplicadas en papers publicados en journals con referato
- Discutir alternativas y descubrir problemas
- Desarrollar la “intuición” sobre cómo encarar un paper empírico

¿Cómo abordar una investigación empírica?

- El punto de partida debe ser una pregunta factible
- Si tenemos en claro cuál es la pregunta a responder, mejor posicionados vamos a estar para comenzar a trabajar con los datos
- Trampas habituales en la investigación:
 - El único objetivo es probar una técnica nueva
 - El único objetivo es usar una base de datos inédita
 - Replicar el trabajo de otro sin fundamentos teóricos
- Idealmente, deberíamos llevar adelante una investigación empírica “responsable e informada”

¿Cómo abordar una investigación empírica?

- Angrist y Pischke (2009) –*Mostly Harmless Econometrics*- definen las bases para un proyecto de investigación exitoso
- Cuatro preguntas claves:
 - 1 ¿Cuál es la relación causal de interés?
 - 2 ¿Cuáles son las condiciones ideales que nos permitirían capturar el efecto de interés? [experimento ideal]
 - 3 ¿Cuál es la estrategia de identificación? [forma en que se usan datos observacionales para aproximarse a un diseño experimental]
 - 4 ¿Qué método de inferencia deberíamos usar? [población y muestra a estudiar, supuestos sobre la construcción de errores estándar]

Ejemplo: Imbens, Rubin y Sacerdote (2001)

- **Pregunta de interés:** ¿Cuál es el efecto del ingreso no laboral en la participación laboral?
- **Experimento ideal:** ¿Cuáles son las condiciones ideales para cuantificar esta relación?
 - Experimento social
 - Experimento natural
- **Estrategia de identificación:** ¿Cómo podemos estimar el efecto con datos observables?
 - Transferencias de dinero o Datos de ganadores de la lotería (IRS, 2001)
- **Método de inferencia:** depende del diseño de la muestra, de la especificación del modelo a estimar, y otros detalles.

Dificultades para responder la pregunta de interés

- **Motivación:** supongamos que queremos responder la pregunta ¿cuál es el efecto de un año adicional de educación sobre el ingreso?
- Proponemos el siguiente modelo estructural de salarios:

$$\log w = \beta_0 + \beta_1 aedu + \beta_2 habilidad + u$$

$$\log w = \beta_0 + \beta_1 aedu + v$$

- u cumple los supuestos clásicos, en particular, el de exogeneidad estricta: $E(u|aedu) = 0 \Rightarrow E(u aedu) = Cov(u, aedu) = 0$
- $Cov(aedu, habilidad) > 0$
- ¿Qué podemos decir sobre $Cov(aedu, v)$?

Dificultades para responder la pregunta de interés

$$\begin{aligned}
 \text{Cov}(aedu, v) &= E[aedu(\beta_2 hab + u)] - E(aedu)E(v) \\
 &= \beta_2 E[aedu * hab] + E[aedu * u] - \\
 &\quad - E[aedu]E[\beta_2 hab + u] \\
 &= \beta_2 \text{Cov}(aedu, hab) \neq 0
 \end{aligned}$$

- La variable *aedu* es endógena en sentido econométrico

Dificultades para responder la pregunta de interés

- **Implicancias:**
 - No podemos estimar consistentemente por MCO
 - No podemos interpretar en términos causales: la clave es “mantener todo lo demás constante” y si $Cov(aedu, hab) \neq 0$ –*aedu* es endógena– no lo vamos a poder hacer
- El criterio para determinar si una variable es endógena no es estadístico, es económico

Dificultades para responder la pregunta de interés

- Fuentes de endogeneidad (Wooldridge, 2002, cap. 3):
 - Variables omitidas
 - Error de medición
 - Ecuaciones simultáneas
- No son mutuamente excluyentes

1. Omisión de variables

- Queremos controlar por una o más variables pero por falta de información no podemos incluirla/s en el modelo
- Ejemplo:
habilidad es una variable no observable omitida en el modelo y *aedu* es endógena

$$y = X\beta + \gamma q + u = X\beta + v$$

- q no observable
- u cumple los supuestos clásicos: $E(u|X, q) = 0$
- $E(q) = 0 \Rightarrow E(v) = 0$
- Si $Cov(x_k, q) = 0 \forall k \Rightarrow E(v|X) = 0$
- Si $Cov(x_k, q) \neq 0$ para algún $k \Rightarrow x_k$ es endógena

1. Omisión de variables

- Suponemos que x_k es la variable endógena: $Cov(x_k, q) \neq 0$
- Escribimos la proyección lineal de q en X

$$q = \delta_0 + \delta_1 x_1 + \dots + \delta_k x_k + r$$

- $E(r) = 0$; $E(r|X) = 0$
- Remplazamos en el modelo para

$$y = (\beta_0 + \gamma\delta_0) + (\beta_1 + \gamma\delta_1)x_1 + \dots + (\beta_k + \gamma\delta_k)x_k + (u + \gamma r)$$

1. Omisión de variables

- Suponemos que $\delta_j = 0 \ \forall j \neq k$

$$y = \beta_0 + \beta_1 x_1 + \dots + (\beta_k + \gamma \delta_k) x_k + (u + \gamma r)$$

$$\hat{\beta}_k^{MCO} \rightarrow \beta_k + \gamma \frac{\text{Cov}(x_k, q)}{\text{Var}(x_k)}$$

1. Omisión de variables

$$\hat{\beta}_{aedu}^{MCO} \rightarrow \beta_{aedu} + \gamma \frac{Cov(aedu, hab)}{Var(aedu)}$$

- $Cov(aedu, hab) > 0$
- Esperamos que $\gamma > 0$: relación positiva entre el salario y la habilidad
- Los retornos a la educación son sobreestimados en muestras grandes
- La magnitud del sesgo es difícil de conocer porque q es inobservable pero podemos tener una idea del signo.

1. Omisión de variables

Tetaz (2006) estimó el retorno a la educación para una muestra de La Plata incluyendo un indicador de inteligencia como variable explicativa

Variables	(1)	(2)
Años de educación	0.0511 [6.84]***	0.0354 [4.67]***
Habilidad		0.2402 [6.19]***

Estadístico t entre paréntesis

Fuente: Tetaz, M., 2006, "*Wages, intelligence and physical appearance, reloaded*", Mimeo, UNLP.

2. Error de medición

- Queremos incluir x_k^* en un modelo pero solo tenemos una medida imperfecta de esa variable: $x_k = x_k^* + e$
- Dependiendo del supuesto sobre la correlación entre (x_k^*, x_k) con el término de error de medición e , x_k (variable incluida en el modelo) va a ser endógena o no.
- Ejemplos: horas trabajadas, salario promedio vs salario marginal, características del último empleo para un desempleado

Caso 1: Error de medición en variable dependiente

- Variable dependiente medida con error

$$y = y^* + e$$

- Modelo que queremos estimar

$$y^* = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$$

- $E(u|X) = E(u) = 0$

- Modelo que estimamos

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u + e$$

- Supuesto: $E(e) = 0$ y $Cov(e, X) = 0$

Caso 1: Error de medición en variable dependiente

- MCO genera estimadores consistentes cuando el error de medición está en la variable explicada del modelo
- Los estimadores tendrán una mayor varianza asintótica

$$V(\hat{\beta}) = \sigma_v^2 (X'X)^{-1}$$

$$V(v) = V(u + e) = \sigma_u^2 + \sigma_e^2 > \sigma_e^2$$

Caso 2: Error de medición en variable explicativa

- Variable explicativa medida con error

$$x_k = x_k^* + e$$

- Modelo que queremos estimar

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k^* + u$$

- $E(u|x_1, \dots, x_k^*) = E(u) = 0$

- Modelo que estimamos

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + (u - \beta_k e)$$

- Supuesto: $E(e) = 0 \implies E(v) = 0$ y $E(u|x_1, \dots, x_k^*, x_k) = 0$ por redundancia.

Caso 2: Error de medición en variable explicativa

- La clave para saber el efecto del error de medición sobre $\hat{\beta}_k^{MCO}$ es el supuesto de correlación entre el error de medición e , x_k^* y x_k . Distinguimos dos casos:
 - $Cov(x_k, e) = 0$. Si esto se cumple, dado que $e = x_k^* - x_k$, se tiene que $Cov(x_k^*, e) \neq 0$. Dados los supuestos sobre los errores, se tiene que $Cov(x_k, v) = 0$ y no hay problema de endogeneidad (pero se puede perder eficiencia, aumenta la varianza de los estimadores).
 - $Cov(x_k^*, e) = 0$. Dado este supuesto calculamos $Cov(x_k, v)$

Caso 2: Error de medición en variable explicativa

Procedemos en dos partes

$$\text{Cov}(x_k, e) = \text{Cov}[(x_k^* + e), e] = E[(x_k^* + e)e] - E(x_k^* + e)E(e)$$

$$\text{Cov}(x_k, e) = E(x_k^* e) + E(e^2)$$

$$\text{Cov}(x_k, e) = \sigma_e^2$$

$$\text{Cov}(x_k, v) = \text{Cov}[x_k, (u - \beta_k e)] = E[x_k u - \beta_k x_k e] - E(x_k)E(u - \beta_k e)$$

$$\text{Cov}(x_k, v) = E(x_k u) - \beta_k E(x_k e) - E(x_k)E(u) + E(x_k)\beta_k E(e)$$

$$\text{Cov}(x_k, v) = -\beta_k \sigma_e^2 \neq 0$$

Bajo el segundo supuesto x_k es una variable endógena y los estimadores MCO son inconsistentes

Sesgo o inconsistencia por error de medición

- Caso de una sola variable explicativa

$$\hat{\beta}^{MCO} \rightarrow \beta \left(\frac{\sigma_{x^*}^2}{\sigma_{x^*}^2 + \sigma_e^2} \right) = \beta \frac{Var(x^*)}{Var(x)}$$

- **Sesgo de atenuación**: en muestras grandes, $\hat{\beta}^{MCO}$ se atenúa por la presencia del error de medición
- El sesgo de atenuación se diluye a medida que la varianza del error de medición cae

Sesgo o inconsistencia por error de medición

- Caso de más de una variable explicativa

$$\hat{\beta}_k^{MCO} \rightarrow \beta_k \left(\frac{\sigma_{r^*}^2}{\sigma_{r^*}^2 + \sigma_e^2} \right)$$

- Lo que importa no es $\sigma_{x^*}^2$, sino la varianza de x_k^* una vez que neteamos el efecto de las restantes variables explicativas
- $x_k^* = \delta_0 + \delta_1 x_1 + \dots + \delta_{k-1} x_{k-1} + r^*$
- $Var(r^*) = V(x_k^*) + \delta_1^2 V(x_1) + \dots + \delta_{k-1}^2 V(x_{k-1}) - 2\delta_1 Cov(x_k^*, x_1) - \dots$

3. Ecuaciones simultáneas

- Al menos una de las variables explicativas se determina de manera simultánea con la variable explicada
- Si x_k es en parte determinada por y , x_k y u generalmente están correlacionadas y, entonces, x_k es una variable endógena
- Ejemplo: equilibrio en el mercado de trabajo

Ejemplo: equilibrio en el mercado de trabajo

(1) Oferta de trabajo: $h_s = \alpha_s w + \beta_s z_s + u_s$

(2) Demanda de trabajo: $h_d = \alpha_d w + \beta_d z_d + u_d$

Problema: no podemos estimar (1) o (2) porque no observamos h_s y h_d , solo observamos las horas que efectivamente se trabajan (equilibrio de mercado):

(3) $h_s = h_d = h$

Combinando (1), (2) y (3) :

- $h = \alpha_s w + \beta_s z_s + u_s$

- $h = \alpha_d w + \beta_d z_d + u_d$

Ejemplo: equilibrio en el mercado de trabajo

Dados (z_s, z_d, u_s, u_d) el modelo determina los valores de equilibrio (h, w)

Se asume que $Cov(z_s, u_s) = Cov(z_d, u_d) = 0$

Sin z_s y z_d no podríamos identificar las funciones de demanda y oferta, respectivamente: $z_s(z_d)$ son variables que desplazan la curva de oferta (demanda) permitiendo identificar la demanda (oferta)

Sesgo o inconsistencia con ecuaciones simultáneas

En el ejemplo anterior, queremos estimar α_s

$$(1) \ h = \alpha_s w + \beta_s z_s + u_s; \text{Cov}(u_s, z_s) = E(u_s) = 0$$

$$(2) \ w = \gamma_d h + e_d; \ E(e_d) = 0$$

Reemplazamos (1) en (2):

$$w = \frac{\gamma_d \beta_s}{1 - \gamma_d \alpha_s} + \frac{1}{1 - \gamma_d \alpha_s} (\gamma_d u_s + e_d) = \pi z_s + v$$

Sesgo o inconsistencia con ecuaciones simultáneas

$$\text{Cov}(w, u_s) = E\{[w - E(w)][u_s - E(u_s)]\}$$

$$\text{Cov}(w, u_s) = E[(w - \pi z_s)u_s]$$

$$\text{Cov}(w, u_s) = E[vu_s] = E\left[\frac{1}{1-\gamma_d\alpha_s}(\gamma_d u_s + e_d)u_s\right]$$

$$\text{Cov}(w, u_s) = \frac{\gamma_d}{1-\gamma_d\alpha_s}E(u_s^2) - \frac{1}{1-\gamma_d\alpha_s}E(e_d u_s)$$

Sesgo o inconsistencia con ecuaciones simultáneas

$$\text{Cov}(w, u_s) = \frac{\gamma_d}{1 - \gamma_d \alpha_s} E(u_s^2) - \frac{1}{1 - \gamma_d \alpha_s} E(e_d u_s)$$

Podemos distinguir tres casos:

$$\gamma_d \neq 0 \text{ y } \text{Cov}(e_d, u_s) = 0 \implies \text{Cov}(w, u_s) \neq 0$$

$$\gamma_d = 0 \text{ y } \text{Cov}(e_d, u_s) \neq 0 \implies \text{Cov}(w, u_s) \neq 0$$

$$\gamma_d = 0 \text{ y } \text{Cov}(e_d, u_s) = 0 \implies \text{Cov}(w, u_s) = 0$$

Lecturas recomendadas

- Angrist, Joshua D. y A. Krueger., 1999. “Empirical strategies in labor economics,” Handbook of Labor Economics
- Angrist, J. y J. Pischke, (2009), Mostly Harmless Econometrics. Capítulos 1 y 2
- Hamermesh, D., 1999, “The Art of Labormetrics”, NBER Working Papers 6927. Publicado en Industrial and Labor Relations Review, 53(3).
- Wooldridge, J., 2002, Econometric Analysis of Cross Section and Panel Data, MIT Press, Cambridge

Resumiendo

- Vimos que el objetivo principal va a ser estimar el efecto causal de una variable x sobre la variable de resultados y
- El principal problema que podemos encontrar es que la variable de interés sea endógena: $Cov(x_k, u) \neq 0$
- En ese caso, los estimadores MCO son inconsistentes y no permiten interpretar el resultado en términos causales
- ¿Qué podemos hacer?

¿Qué podemos hacer?

Las soluciones pueden surgir de

- Conocimiento de los datos
- Diseño del estudio a través de experimentos sociales/controlados
- Diseño del estudio usando nuestro conocimiento de la economía a través de experimentos naturales

1. Variables instrumentales

- Es una de las soluciones disponibles para eliminar o atenuar el sesgo por omisión de variables y otros problemas de endogeneidad
- El modelo que queremos estimar es:

$$y = X\beta + \gamma q + u$$

- pero q es una variable que no podemos incorporar al modelo y se genera un problema de endogeneidad en la variable de interés
 - $X: \text{Cov}(X, u) \neq 0$
- Una variable instrumental nos ayuda a generar en la variable de interés la **variación exógena** que necesitamos, permitiendo aislar el problema de correlación con el término de error del modelo

1. Variables instrumentales

Requisitos que debe cumplir una variable (z) para ser un instrumento válido:

Condición (1). Debe estar **parcialmente correlacionada** con la variable de interés

Condición (2). Debe cumplir con la **restricción de exclusión**

- Esto implica que $Cov(z, u) = 0$

1. Variables instrumentales

(i) Este requisito pide que la correlación parcial entre x_k y z sea no nula

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u ; \quad \text{Cov}(x_k, u) \neq 0$$

$$x_k = \theta_0 + \theta_1 x_1 + \dots + \theta_{k-1} x_{k-1} + \theta_z z + v$$

- El requisito pide que $\theta_z \neq 0$, es decir, que z y x_k estén correlacionadas luego de haber controlado por las restantes variables exógenas
- La validez del instrumento sólo exige correlación no nula. Por el momento no nos interesa la magnitud de la correlación
- ¿Cómo testeamos si este requisito se cumple?

1. Variables instrumentales

En un modelo con K variables explicativas, (i) implica:

$$\frac{\text{Cov}(x_k, \tilde{z})}{\text{Var}(\tilde{z})} = \hat{\theta}_z \neq 0$$

Si x_k es la única variable explicativa, entonces (i) es equivalente a:

$$\frac{\text{Cov}(x_k, z)}{\text{Var}(z)} = \hat{\theta}_z \neq 0$$

- Solo en el caso del modelo bivariado el requisito (i) es equivalente a $\text{Cov}(x_k, z) \neq 0$

1. Variables instrumentales

(ii) Restricción de exclusión: z no debe estar correlacionada con ningún otro determinante no observado de la variable explicada y

- ¿Que implica esto en un modelo bivariado?
 - $Cov(z, u) = 0$
- ¿Qué implica esto en un modelo con variables explicativas?
 - $Cov(z, u) = 0$
 - z afecta la variable de resultado y solo a través de la variable x_k

Estimador de VI con efectos constantes

- Queremos estimar el efecto de la variable x sobre la variable y , pero x es endógena

$$y = \beta_0 + \beta_1 x_1 + u$$

- Sup: $Cov(x, u) \neq 0$
- z es una variable instrumental que cumple los requisitos para ser un instrumento válido

$$Cov(y, z) = \beta_1 Cov(x, z) + Cov(u, z)$$

$$\hat{\beta}_1^{IV} = \frac{\widehat{Cov}(y, z)}{\widehat{Cov}(x, z)}$$

Estimador de VI con efectos constantes

$$\hat{\beta}_1^{IV} = \frac{\widehat{Cov}(y, z)}{\widehat{Cov}(x, z)}$$

- $\widehat{Cov}(x, z)$ es la variación exógena de la variable de interés que genera el método. ¿Por qué podemos garantizar que es exógena?
- El método de IV solo usa una parte de la variabilidad de la variable de interés (variable endógena), aquella que no está correlacionada con el término de error del modelo
- $\hat{\beta}^{IV}$ es consistente pero sesgado; se prefiere hacer estimaciones por variables instrumentales cuando la muestra es grande

Estimador de VI con efectos constantes

Minimos Cuadrados en dos etapas (2SLS)

- Partimos de un modelo con K variables explicativas entre las cuales x_k -la variable de interés- es endógena

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$$

- $\text{Sup: } \text{Cov}(x_k, u) \neq 0$
- Para la estimación por IV necesitamos tantos instrumentos como variables explicativas tenga el modelo
- Disponemos de un vector de P instrumentos válidos con $P > K$
- ¿Qué podemos hacer con los instrumentos que “nos sobran”?

Estimador de VI con efectos constantes

Minimos Cuadrados en dos etapas (2SLS)

- Tenemos dos alternativas:
 - Si el objetivo es estimar consistentemente β_k , podemos descartar $P - K$ instrumentos y utilizar los restantes
 - Si además de estimar consistentemente queremos ser eficientes, estimamos por 2SLS
- El método de 2SLS combina los instrumentos de manera que la estimación sea la más eficiente posible. Intuición: si todos los instrumentos son válidos, la combinación lineal también debería serlo

Estimador de VI con efectos constantes

Minimos Cuadrados en dos etapas (2SLS)

- **Primera etapa:** estimación por MCO de la variable endógena (x_k) en todos los instrumentos

$$x_k = \alpha_0 + \alpha_1 x_1 + \dots + \alpha_{k-1} x_{k-1} + \gamma Z + v$$

- **Segunda etapa:** estimación por MCO de la variable y en $\hat{x}_k$ y las restantes variables explicativas
- El estimador 2SLS es un estimador de IV: la primera etapa es el denominador y la segunda etapa es el numerador en la expresión de $\hat{\beta}^{IV}$
- En la práctica, no construimos por separado las dos etapas (problemas con los errores estándar). Usamos la rutina de algún software (Stata)

Estimador de VI con efectos constantes

Minimos Cuadrados en dos etapas (2SLS)

- **Ejemplo:** Angrist y Krueger (1991) utilizan el trimestre de nacimiento como IV para estimar los retornos a la educación.
- Los instrumentos surgen del experimento natural determinado por la combinación de la legislación educativa y las características del sistema educativo en USA

Table 4.1.1 en Angrist y Pischke – Capítulo 4

	OLS		2SLS	
	(1)	(2)	(1)	(2)
Years of education	0.075 (0.0004)	0.072 (0.0004)	0.112 (0.021)	0.089 (0.016)

- Las estimaciones por 2SLS superan a las estimaciones OLS

Estimador de VI con efectos constantes

Estimador de Wald

- Si usamos un instrumento binario en un modelo bivariado obtenemos el **Estimador de Wald**
- Vimos que

$$\hat{\beta}_1^{IV} = \frac{\widehat{Cov}(y, z)}{\widehat{Cov}(x, z)}$$

- Reexpresamos $Cov(y, z)$ y $Cov(x, z)$ considerando la naturaleza binaria del instrumento: $z = 1$ con probabilidad p

$$Cov(y, z) = [E(y|z = 1) - E(y|z = 0)]p(1 - p)$$

$$Cov(x, z) = [E(x|z = 1) - E(x|z = 0)]p(1 - p)$$

Estimador de VI con efectos constantes

Estimador de Wald

- Reemplazamos y entonces

$$\hat{\beta}_1^{Wald} = \frac{\bar{Y}_{(z=1)} - \bar{Y}_{(z=0)}}{\bar{X}_{(z=1)} - \bar{X}_{(z=0)}}$$

Table 4.1.2: Wald estimates of the returns to schooling using quarter of birth instruments

	(1)	(2)	(3)
	Born in the 1st or 2nd quarter of year	Born in the 3rd or 4th quarter of year	Difference (std. error) (1)-(2)
ln (weekly wage)	5.8916	5.9051	-0.01349 (0.00337)
Years of education	12.6881	12.8394	-0.1514 (0.0162)
Wald estimate of return to education			0.0891 (0.0210)
OLS estimate of return to education			0.0703 (0.0005)

Estimador de VI con efectos heterogéneos

- Vimos que el método de IV usa solo una parte de la variabilidad de la variable de interés: aquella correlacionada con el instrumento
- De acá surge una dificultad para interpretar los resultados de las estimaciones por IV: no todas las observaciones son afectadas por el instrumento
- Ejemplos:
 - A&K (1991): la estimación es válida solo para el subgrupo de individuos cuyo nivel educativo (variable de interés) fue afectado por el instrumento (trimestre de nacimiento)
 - Angrist (1990): usa el número de la lotería como instrumento para estimar el efecto de haber hecho el servicio militar sobre el ingreso. La estimación es válida solo para aquellos que lo hicieron porque salieron sorteados, pero que en caso contrario no lo habrían hecho.

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

- $Y_i(d, z)$ es el resultado potencial del individuo i cuya variable de tratamiento $D_i = d$ y el instrumento $Z_i = z$
- D y Z son variables binarias: $d = \{0, 1\}$ y $z = \{0, 1\}$
- D_{1i} es el valor de la variable de tratamiento cuando $z = 1$; D_{0i} es el valor cuando $z = 0$
- El tratamiento puede expresarse en término de resultados potenciales como

$$D_i = D_{0i} + Z_i(D_{1i} - D_{0i})$$

- $(D_{1i} - D_{0i})$ capta el efecto causal **heterogéneo** del instrumento sobre D_i

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

- Y_{1i} es el valor de la variable de resultado cuando $d = 1$; Y_{0i} es el valor cuando $d = 0$
- Y puede expresarse en término de resultados potenciales como

$$Y_i = Y_{0i} + D_i(Y_{1i} - Y_{0i})$$

$(Y_{1i} - Y_{0i})$ capta el efecto causal **heterogéneo** del tratamiento sobre Y_i

Suponemos:

- Independencia de resultados potenciales:
 $\{Y_{1i}(D_{1i}, 1), Y_{0i}(D_{0i}, 0), D_{1i}, D_{0i}\} \perp Z_i$
- Exclusión: $Y_i(d, 0) = Y_i(d, 1) \equiv Y_{di}$; para $d = 0, 1$
- Primera etapa: $E[D_{1i} - D_{0i}] \neq 0$
- Monotonicidad: $D_{1i} - D_{0i} \geq 0$ para todo i

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

Teorema: Si la variable instrumental Z cumple con los requisitos para ser un instrumento válido y además se verifican las condiciones de monotonicidad e independencia, entonces podemos identificar el efecto causal de la variable de interés D sobre la variable de resultado Y para aquellos individuos afectados por el instrumento

$$LATE = \frac{E[Y|Z = 1] - E[Y|Z = 0]}{E[D|Z = 1] - E[D|Z = 0]} = E[Y_{1i} - Y_{0i} | D_{1i} > D_{0i}]$$

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

Reemplazamos D_i en la expresión para Y_i

$$Y_i = Y_{0i} + D_i(Y_{1i} - Y_{0i})$$

$$Y_i = Y_{0i} + [D_{0i} + Z_i(D_{1i} - D_{0i})](Y_{1i} - Y_{0i})$$

$$Y_i = Y_{0i} + D_{0i}(Y_{1i} - Y_{0i}) + Z_i(D_{1i} - D_{0i})(Y_{1i} - Y_{0i})$$

Calculamos la $E[Y]$ usando el supuesto de independencia

$$E[Y_i|Z_i = 1] = E[Y_{0i}] + E[D_{0i}(Y_{1i} - Y_{0i})] + E[(D_{1i} - D_{0i})(Y_{1i} - Y_{0i})]$$

$$E[Y_i|Z_i = 0] = E[Y_{0i}] + E[D_{0i}(Y_{1i} - Y_{0i})]$$

Restamos las dos expresiones anteriores

$$E[Y_i|Z_i = 1] - E[Y_i|Z_i = 0] = E[(D_{1i} - D_{0i})(Y_{1i} - Y_{0i})]$$

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

Aplicamos LEI en la última expresión

$$E[Y_i|Z_i = 1] - E[Y_i|Z_i = 0] = E\{E[(D_{1i} - D_{0i})(Y_{1i} - Y_{0i})|D_{1i} - D_{0i}]\}$$

$$E[Y_i|Z_i = 1] - E[Y_i|Z_i = 0] = E\{(D_{1i} - D_{0i})E[(Y_{1i} - Y_{0i})|D_{1i} - D_{0i}]\}$$

Existen tres valores posibles para $D_{1i} - D_{0i} = \{-1, 0, 1\}$

$$\begin{aligned} E[Y_i|Z_i = 1] - E[Y_i|Z_i = 0] = & \\ & -1Pr(D_{1i} - D_{0i} = -1)E[(Y_{1i} - Y_{0i})|D_{1i} - D_{0i} = -1] + \\ & 1Pr(D_{1i} - D_{0i} = 1)E[(Y_{1i} - Y_{0i})|D_{1i} - D_{0i} = 1] + \\ & 1Pr(D_{1i} - D_{0i} = 0)E[(Y_{1i} - Y_{0i})|D_{1i} - D_{0i} = 0] \end{aligned}$$

Aplicamos el supuesto de monotonicidad $D_{1i} - D_{0i} \geq 0$ y la expresión anterior se reduce a

$$E[Y_i|Z_i = 1] - E[Y_i|Z_i = 0] = Pr(D_{1i} - D_{0i} = 1)E[(Y_{1i} - Y_{0i})|D_{1i} - D_{0i} = 1]$$

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

Los tres posibles valores para $D_{1i} - D_{0i} = \{-1, 0, 1\}$ nos indican que podemos identificar tres grupos de individuos

- Cuando $D_{1i} - D_{0i} = -1$ el individuo pertenece al grupo de **defiers**
- Cuando $D_{1i} - D_{0i} = 0$ el individuo pertenece al grupo de **always-takers** o **never-takers**
- Cuando $D_{1i} - D_{0i} = 1$ el individuo pertenece al grupo de **compliers**
- Por el supuesto de monotonicidad el LATE identifica el efecto casual para el subgrupo de compliers: aquellos cuyo comportamiento resultó afectado por el instrumento.
- En el ejemplo, aquellos que hicieron la maestría porque recibieron la oferta, pero que en caso contrario no la hubiesen hecho

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

Volviendo a la última expresión, la última parte es la definición del LATE

de acuerdo al teorema $E[Y_i|Z_i = 1] - E[Y_i|Z_i = 0] =$
 $Pr(D_{1i} - D_{0i} = 1) E[(Y_{1i} - Y_{0i})|D_{1i} - D_{0i} = 1]$

$$LATE = E[Y_{1i} - Y_{0i}|D_{1i} - D_{0i} = 1] = \frac{E[Y_i|Z_i=1] - E[Y_i|Z_i=0]}{Pr(D_{1i} - D_{0i}=1)}$$

- Desarrollamos el denominador (probabilidad de ser complier)

$$Pr(D_{1i} - D_{0i} = 1) = E(D_{1i} - D_{0i})$$

$$Pr(D_{1i} - D_{0i} = 1) = E(D_{1i}) - E(D_{0i})$$

$$Pr(D_{1i} - D_{0i} = 1) = E\left[\frac{D_i - (1 - Z_i)D_{0i}}{Z_i}\right] - E\left[\frac{D_i - Z_i D_{1i}}{1 - Z_i}\right]$$

$$Pr(D_{1i} - D_{0i} = 1) = E(D_i|Z_i = 1) - E(D_i|Z_i = 0)$$

Estimador de VI con efectos heterogéneos

Local Average Treatment Effect (LATE)

Sustituyendo el último resultado llegamos a que la expresión del LATE

$$LATE = E[Y_{1i} - Y_{0i} | D_{1i} - D_{0i} = 1] = \frac{E[Y_i | Z_i = 1] - E[Y_i | Z_i = 0]}{E[D_i | Z_i = 1] - E[D_i | Z_i = 0]}$$

- ¿A qué se parece el estimador LATE?
- La limitación del estimador en términos de validez externa es muy clara: el efecto es local y se aplica para el subgrupo de la población cuyo comportamiento fue afectado por el instrumento (compliers)
- Mediante una estimación por IV ganamos validez interna (si el instrumento es válido) pero las posibilidades de generalizar el efecto estimado son bajas

Problemas en las estimaciones por IV

- $\hat{\beta}^{IV}$ es sesgado pero consistente, por eso se prefiere trabajar con muestras grandes para estimar por IV
- Instrumentos débiles: un instrumento es débil cuando está poco correlacionado con la variable endógena. En ese caso el sesgo se aproxima al de MCO
- Instrumentos “marginalmente” inválidos: cuando la correlación entre la variable endógena y el instrumento es baja, una pequeña correlación entre z y u puede causar una inconsistencia muy grande

Problemas en las estimaciones por IV

- En un modelo bivariado la expresión de la inconsistencia de IV usando un instrumento marginalmente inválido es

$$\hat{\beta}^{IV} \rightarrow \beta + \frac{\text{Corr}(z, u)\sigma_u}{\text{Corr}(z, x)\sigma_x}$$

- La inconsistencia de MCO por la endogeneidad no resuelta

$$\hat{\beta}^{OLS} \rightarrow \beta + \text{Corr}(x, u) \frac{\sigma_u}{\sigma_x}$$

- IV sigue siendo conveniente mientras

$$\frac{\text{Corr}(z, u)}{\text{Corr}(z, x)} < \text{Corr}(x, u)$$

Lecturas recomendadas

- Angrist, J. y J. Pischke, (2009), Mostly Harmless Econometrics. Capítulo 4
- Angrist, J. y A. Krueger, 2001, “Instrumental Variables and the Search for Identification: From Supply and Demand to Natural Experiments”, Journal of Economic Perspectives, 15(4).
- Angrist, J. y G. Imbens, 1994, “Identification and Estimation of Local Average Treatment Effects”, Econometrica, 62(2).
- Imbens, G., 2010, “Better LATE Than Nothing: Some Comments on Deaton (2009) and Heckman and Urzua (2009)”, Journal of Economic Literature, 48(2).

2. Experimentos

- El planteo del problema en términos de un experimento facilita la estimación del efecto causal de interés
- La idea es que a través de un experimento podemos obtener una fuente de **variación exógena** para la variable de interés
- La situación ideal es la de un experimento social o controlado donde la asignación aleatoria del tratamiento garantiza que cualquier movimiento en la variable de interés sea exógeno
- Identificamos al grupo que experimenta el cambio en la variable de interés como *grupo de tratamiento* y al otro, como *grupo de control*

2. Experimentos

Ejemplo: estimación del efecto de un año adicional de educación sobre el ingreso

- Definimos dos grupos aleatoriamente: esto garantiza que los grupos sean similares en términos de características observables (género, edad, etc.) e inobservables (habilidad innata) antes de la intervención
- “Asignamos el tratamiento”: el grupo de tratamiento se educa un año más que el grupo de control. Por definición, este cambio en la variable de interés es exógeno
- Podemos obtener el retorno de un año adicional de educación (efecto causal de interés) comparando el valor promedio de la variable de resultado (ingreso, en este caso) para ambos grupos

Distintos tipos de experimentos

- **Experimentos sociales o controlados:** diseñado directamente por el investigador que asigna aleatoriamente la unidad de análisis (individuos, por ejemplo) a un grupo de tratamiento o control para evaluar el efecto de un “tratamiento” (cambio de política, por ejemplo)
- **Ventaja:** por definición, el cambio en la variable de interés es exógeno y estamos seguros de haber eliminado cualquier fuente de sesgo
- **Desventaja:** costo; tiempo; puede haber sesgos si el experimento está mal diseñado (falla en la aleatorización, attrition, efectos del experimento, muestras chicas)
- **Referencia:** Duflo, Glennerster y Kremer, (2006), Using randomization in development economics research: a toolkit

Distintos tipos de experimentos

- **Experimentos sociales o controlados**
- **Desventajas**
 - **Non-compliance:** algunos agentes originalmente asignados al grupo tratamiento terminan no recibiendo el tratamiento, o viceversa
 - **Efecto placebo:** relación positiva entre la respuesta de la unidad al tratamiento y las expectativas de la unidad acerca de estar expuesta al tratamiento. En ciencias sociales es difícil controlar por efectos placebo porque la gente sabe si está siendo tratada
 - **Atrición:** algunas unidades desaparecen de la muestra en algún punto del tiempo entre la encuesta de línea de base y la encuesta final.
¿Cuándo es un problema?
 - **Spillovers o efectos derrame:** algunas unidades que no reciben el tratamiento pueden beneficiarse del hecho que otras unidades estén siendo tratadas.

Distintos tipos de experimentos

- **Experimentos naturales o cuasiexperimentos:** un grupo de la población experimenta un cambio exógeno en la variable de interés por un evento o circunstancia (shock de política, por ejemplo) que permite asimilar la situación a un experimento controlado
- **Ventaja:** si está bien diseñado, al igual que el caso del experimento controlado, se elimina cualquier fuente de sesgo
- **Desventaja:** la validez externa es limitada; la identificación del efecto causal sin sesgo no se da por definición sino que es necesario explicitar por qué los resultados serían válidos
- Ejemplo: Angrist y Krueger (1991), Does compulsory school attendance affect schooling and earnings?, AER

¿Cómo funciona?

Tenemos una población de individuos (unidades), para cada uno de ellos observamos la variable D y la variable Y .

Observamos que D y Y están correlacionadas.

¿Esta **correlación** implica **causalidad**?

En general no, por problemas de endogeneidad:

- variables omitidas relevantes
- errores de medición
- causalidad inversa

Queremos entender en qué sentido y bajo qué hipótesis se puede concluir a partir de la evidencia observacional que D **causa** a Y .

Es útil pensar este problema usando un enfoque experimental.

¿Cómo funciona?

Modelo de resultados potenciales de Rubin

- La variable de resultado es Y
- La variable de interés (o de tratamiento) es $D = \{0, 1\}$
- El objetivo es conocer el efecto causal de D sobre Y

Ejemplos

- Queremos conocer el efecto de un programa de entrenamiento laboral sobre la probabilidad de empleo. El grupo de tratamiento ($D = 1$) es el que recibe el entrenamiento y el grupo de control ($D = 0$) es el que no lo recibe
- Queremos saber el efecto del ingreso no laboral sobre la participación laboral: $D = 1$ para los que reciben grandes premios de la lotería y $D = 0$ para los que reciben montos pequeños (IRS, 2001)
- Queremos identificar el efecto de un cambio en el salario sobre el nivel de empleo. Comparamos el empleo antes de un aumento en el salario mínimo ($D = 0$) y después del aumento ($D = 1$) (C&K, 1994)

Modelo de resultados potenciales de Rubin

- Tenemos una muestra de n individuos: $i = 1, \dots, n$
- D_i es el indicador de tratamiento:
 - $D_i = 1$ si i ha sido expuesta al tratamiento
 - $D_i = 0$ si i no ha sido expuesta al tratamiento
- Y_{Di} indica el resultado potencial de haber sido tratado o no:
 - Y_{1i} es el resultado en caso de ser tratado
 - Y_{0i} es el resultado en caso de no ser tratado
- El **problema contrafactual** consiste en que solo observamos uno de estos dos estados para cada individuo: para aquellos que recibieron el tratamiento observamos Y_{1i} , mientras que para quienes no lo recibieron observamos Y_{0i}
- **Implicancia:** no podemos saber el **efecto individual** del tratamiento ($Y_{1i} - Y_{0i}$) pero sí podemos conocer el **efecto promedio**

Modelo de resultados potenciales de Rubin

Diferencia promedio observada: $E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 0]$

Sumando y restando $E[Y_{0i}|D_i = 1]$:

$$E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 1] + E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]$$

- *Diferencia promedio observada = Efecto del tratamiento + sesgo*
- *Efecto del tratamiento:* $E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 1]$
- *sesgo:* $E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]$

Este sesgo es llamado **sesgo de selección**, y es igual a la diferencia entre los resultados de individuos tratados y no tratados en la situación contrafactual de ausencia de tratamiento .

Modelo de resultados potenciales de Rubin

- ¿Cómo eliminamos el sesgo de selección?
- La asignación aleatoria resuelve el problema
- Consideremos dos muestras aleatorias tomadas de una población. Por construcción, las muestras son estadísticamente idénticas a la población. A una se le aplica el tratamiento, $D = 1$, y a la otra no, $D = 0$.
- La asignación aleatoria significa que D_i es independiente de los resultados potenciales, entonces $E[Y_{0i}|D_i = 1] = E[Y_{0i}|D_i = 0]$

$$E[Y_i|D_i = 1] - E[Y_i|D_i = 0] = E[Y_{1i} - Y_{0i}|D_i = 1] = E[Y_{1i} - Y_{0i}]$$

Modelo de resultados potenciales de Rubin

A través de un análisis de regresión podemos llegar a la misma conclusión:

$$Y_i = \alpha + \rho D_i + \epsilon_i$$

Estamos suponiendo que el efecto del tratamiento es el mismo para todos ($= \rho$)

Grupo tratado: $E[Y_i|D_i = 1] = \alpha + \rho + E[\epsilon_i|D_i = 1]$

Grupo control: $E[Y_i|D_i = 0] = \alpha + E[\epsilon_i|D_i = 0]$

Entonces:

$$E[Y_i|D_i = 1] - E[Y_i|D_i = 0] = \rho + E[\epsilon_i|D_i = 1] - E[\epsilon_i|D_i = 0]$$

Modelo de resultados potenciales de Rubin

Si D fue asignada aleatoriamente sabemos que los grupos están balanceados, en promedio, en términos de observables e inobservables y el sesgo desaparece

$$E[\epsilon_i | D_i = 1] - E[\epsilon_i | D_i = 0] = 0$$

También podríamos agregar otras variables de control al modelo, ¿cómo afectarían la estimación del efecto causal ρ ?

La estimación del efecto causal no debería cambiar pero la incorporación de controles puede ayudar a mejorar la precisión de las estimaciones.

Experimentos controlados vs. experimentos naturales

- Hasta ahora vimos que si la asignación de la variable de interés (D) es aleatoria, la estimación del efecto causal es muy simple y elimina cualquier fuente de sesgo
- En la práctica difícilmente dispongamos de un experimento controlado
- Cuando trabajamos con un experimento natural podemos analizar e interpretar los datos “como si” se tratara de un experimento controlado, es decir, como si la variable de interés hubiese sido asignada aleatoriamente
- Pero siguen existiendo factores que son potenciales fuentes de sesgo (*confounding factors*)

Experimentos controlados vs. experimentos naturales

Ejemplos

- Analizamos el efecto de un programa de entrenamiento sobre la probabilidad de empleo. Si los individuos deciden sobre su participación, esperamos que D_i esté correlacionada con el término de error en un modelo econométrico (sesgo de selección)
- Efecto de hacer la maestría sobre los ingresos futuros
- Analizamos el efecto de un aumento en el salario mínimo sobre el nivel de empleo para el mismo grupo de individuos antes y después de la intervención. En ese periodo de tiempo pueden haber cambiado otras cosas además del salario: características observables, inobservables, cualquier factor que se modifique en el tiempo.

Una manera de mejorar el diseño es incorporar una “segunda diferencia” en la estimación

Estimador de Diferencias en Diferencias

Tipos de información:

- **Post-proyecto:** si solo se tiene información del grupo tratado después del tratamiento, es imposible decir algo respecto al impacto del tratamiento porque no es posible contruir un escenario contrafactual
- **Before and After:** La situación antes del proyecto no es un buen contrafactual: el impacto del tratamiento se confunde con cualquier otro evento que haya sucedido en ese momento y que puede eventualmente haber afectado la variable de interés
 - Supuesto: el nivel de la variable de interés no hubiese cambiado en ausencia del tratamiento. Supuesto muy fuerte.
 - Notar que aunque no haya grupo control, existe un escenario contrafactual que no es creíble

Estimador de Diferencias en Diferencias

Tipos de información:

- **With and Without:** Datos post tratamiento para grupo tratado y control (corte transversal). Es creíble si los dos grupos eran similares antes de la intervención, pero sin información previa es imposible de testear.
 - **Supuesto:** no hay sesgo de selección.
 - El efecto del tratamiento puede deberse a diferencias preexistentes entre los grupos
- **Diferencias en Diferencias:** Datos antes y después del tratamiento para el grupo tratado y control.
 - Combina los enfoques *before and after* y *with and without*
 - Se necesita de datos en panel, alcanza con cuatro observaciones.
 - **Supuesto:** ambos grupos se hubiesen comportado/evolucionado de la misma forma después del tratamiento en ausencia del tratamiento.

Estimador de Diferencias en Diferencias

Disponemos de información para el grupo de tratamiento y el grupo de control, antes y después de la intervención:

$$Y_{it}^j = \alpha + \alpha_1 D_{it} + \alpha^1 D_i^j + \beta D_{it}^j + u_{it}^j$$

- D_t indica el periodo de tiempo de la observación: $D_t = 0$ si $t = 0$ y $D_t = 1$ si $t = 1$
- D^j indica el grupo al que pertenece la observación: $D^j = 0$ para el grupo de control y $D^j = 1$ para el grupo de tratamiento
- D_t^j es la interacción entre los anteriores efectos: $D_t^j = 1$ para el grupo de tratamiento en $t = 1$

Estimador de Diferencias en Diferencias

Derivamos qué implica esto para cada uno de los grupos

Para el grupo tratamiento:

- tratados en $t = 0$: $Y_{i0}^1 = \alpha + \alpha^1 + u_{i0}^1$
- tratados en $t = 1$: $Y_{i1}^1 = \alpha + \alpha_1 + \alpha^1 + \beta + u_{i1}^1$
- Diferencia en el tiempo: $Y_{i1}^1 - Y_{i0}^1 = \alpha_1 + \beta + (u_{i1}^1 - u_{i0}^1)$

Estimador de Diferencias en Diferencias

Derivamos qué implica esto para cada uno de los grupos

Para el grupo control:

- control en $t = 0$: $Y_{i0}^0 = \alpha + u_{i0}^1$
- control en $t = 1$: $Y_{i1}^0 = \alpha + \alpha_1 + \beta + u_{i1}^0$
- Diferencia en el tiempo: $Y_{i1}^0 - Y_{i0}^0 = \alpha_1 + (u_{i1}^0 - u_{i0}^0)$

Estimador de Diferencias en Diferencias

El estimador de diferencias en diferencias lo obtenemos haciendo la doble diferencia: restamos las diferencias en el tiempo que calculamos para cada grupo

$$(Y_{i1}^1 - Y_{i0}^1) - (Y_{i1}^0 - Y_{i0}^0) = \beta + (u_{i1}^1 - u_{i0}^1) - (u_{i1}^0 - u_{i0}^0)$$

- Si se cumple que $E[(u_{i1}^1 - u_{i0}^1) - (u_{i1}^0 - u_{i0}^0)] = 0$, entonces *DD* nos provee de un estimador consistente del efecto de *D* sobre *Y*, es decir sobre β .
- Intuitivamente, la condición anterior implica que, en ausencia de tratamiento, la tendencia para la variable *Y* sería la misma para los grupos de tratamiento y control.
- El supuesto de identificación clave de *DD* es el de tendencia común en ausencia de tratamiento (*common trend*)

Estimador de Diferencias en Diferencias

El estimador lo podemos obtener calculando la doble diferencia o estimando por MCO el modelo previo

$$Y_{it}^j = \alpha + \alpha_1 D_{it} + \alpha^1 D_i^j + \beta D_{it}^j + u_{it}^j$$

- El coeficiente que acompaña la interacción entre la dummy de periodo de tiempo y la dummy de grupo (D_{it}^j) es el estimador de diferencias en diferencias ($\hat{\beta}$)
- La ventaja de estimar el modelo es que podemos controlar por cualquier diferencia en características observables entre el grupo de tratamiento y el de control.
- Estamos controlando por características no observables, siempre que estas no varíen en el tiempo
- Diferencias en niveles iniciales pueden estar reflejando que futuros shocks afecten distinto a los individuos en los distintos grupos.

Diferencias en Diferencias

Ejemplo 1:

Efecto de un aumento del salario mínimo en una provincia y no en una provincia vecina. Se compara el empleo de cadenas de comidas rápidas antes y después del cambio de política en ambas provincias. (Card y Krueger, 1992)

Ejemplo 2 (Alternativa)

En vez de comparar antes vs. después de la implementación de una política, es posible comparar una región donde la política fue implementada con otra en donde no fue implementada.

Política de micro-créditos dirigida a hogares pobres de una determinada región. Se compara hogares pobres y ricos en regiones afectadas y no afectadas. (Morduch, 1998)

Diferencias en Diferencias

Posibles chequeos en la estrategia de DD

- Si se dispone de varios períodos anteriores al tratamiento
 - Experimentos falsos\placebos
 - Graficar las tendencias para el grupo tratamiento y control y analizar si son paralelas y cambian justo después de que el grupo tratamiento sea tratado.
 - DD dinámico o gráfico de la brecha entre el grupo tratamiento y control, pudiendo controlar por otros factores
- Usar un grupo de control alternativo.
- Reemplazar Y por un resultado que se supone no es afectado por el cambio de política.

Cuanto más parecidos son tratamiento y control, más convincente es la estrategia de DD

Diferencias en Diferencias

- Problemas posibles
 - La política\reforma se implementa basada en diferencias preexistentes en variables de resultado (Ashenfelter dip)
 - Dependencia de la forma funcional. Si Y es muy diferentes entre grupos antes del tratamiento, estimar DD en niveles o en cambios logarítmicos puede arrojar resultados ambiguos
 - Otras políticas o eventos con efectos diferentes sobre el grupo de tratamiento y de control
 - Cambios composicionales de los grupos

Extensiones

Estimador de triple diferencias (DDD estimator - *diff in diff in diff*)

- Ejemplo: cambio en política de salud para los ancianos (>65) de Buenos Aires, grupo control personas de 55-65 años. [¿Supuesto de identificación?]
- Además se pueden usar los mismos grupos etarios de en provincias no afectadas como controles.

Si A es una dummy igual a uno para los >65 , D es una dummy que indica el periodo después de la reforma y E indica si el individuo vive en la provincia tratada,

$$Y = \beta_0 + \beta_1 A + \beta_2 E + \beta_3 A.E + \delta_0 D + \delta_1 D.A + \delta_2 D.E + \delta_3 A.E.D + u$$

donde δ_3 captura el efecto causal:

$$\begin{aligned} \delta_3 = & [(\bar{Y}_{A,E,2} - \bar{Y}_{A,E,1}) - (\bar{Y}_{NoA,E,2} - \bar{Y}_{NoA,E,1})] \\ & - [(\bar{Y}_{A,NoE,2} - \bar{Y}_{A,NoE,1}) - (\bar{Y}_{NoA,NoE,2} - \bar{Y}_{NoA,NoE,1})] \end{aligned}$$

Extensiones

Estimador de triple diferencias (DDD estimator - *diff in diff in diff*)

- Eliminamos tendencias que podrían afectar de forma diferente al grupo tratamiento y control bajo el estimador DD (pero pueden haber shocks distintos a la reforma que afecten solo al tratamiento en la provincia tratada)
- Es una especie de DD robusto. Si no es diferente, es como un ejercicio de robustez
- Es la diferencia entre el estimador DD que tenemos y un DD placebo (DD entre dos grupos de control)
- ¿Vale la pena?
 - Si DD placebo $\neq 0$, DD falla, y será difícil de creer que DDD elimina el sesgo
 - Si DD placebo $= 0$, DD=DDD pero DDD tiene mayor errores estándar

Lecturas recomendadas

- Wooldridge, J., 2002, Econometric Analysis of Cross Section and Panel Data, MIT Press, Cambridge. Capítulo 4.
- Angrist, J. y J. Pischke, (2009), Mostly Harmless Econometrics. Capítulos 2 y 5