

Métodos de Evaluación de Impacto de Políticas Públicas

Clase 1: Introducción. El problema fundamental de la evaluación

María Laura Alzua

UNLP

- Interés creciente en evaluar políticas públicas de manera cuantitativa
 - 1.cuestiones de política
 - 2.accountability
 - 3.cuestiones metodológicas
- Experimentos clínicos y programas sociales
- Nuevas herramientas econométricas
- Contribución a la economía aplicada: problemas de identificación
- Descubrir mecanismos causales

Por qué evaluar?

- Tres razones:

- 1 Motivación para aquellos con recursos a invertir o donar más fondos
- 2 Para saber cómo gastar recursos limitados
- 3 Para saber cómo mejorar programas existentes

- Cuando hacemos evaluación de impacto, siempre buscamos el efecto causal de una intervención: qué medir y cómo? (forma de medición y atribución del efecto)
- Efecto del cambio en el número de alumnos por clase en el rendimiento académico
- Efecto de los programas de entrenamiento laboral en la probabilidad de conseguir empleo
- Efecto de la provisión de agua y saneamiento en la mortalidad infantil

Evaluación y resultados potenciales

- En las ciencias sociales, la mayoría de las preguntas empíricas dependen del efecto causal de políticas
- Queremos evaluar el efecto de la exposición de ciertas unidades (individuos, hogares, firmas, provincias, países, etc.) a un programa o tratamiento (programas de entrenamiento laboral, medicina, tecnología, etc.).
- El objeto de interés es la comparación de dos unidades, con y sin tratamiento. Problema, sólo observamos al agente en un estado. (Holland, 1996)
- Hay que comparar distintas unidades con distintos niveles de tratamiento. Bajo qué supuestos es esa comparación válida?
- Literatura estadística, originada con la aparición de experimentos aleatorizados (Fisher, 1935 y otros)
- Rubin (1973-1978) interpretación de los efectos causales en forma de "resultados potenciales "

Modelo Causal de Rubin (RCM) - *Revisited* Imbens (2009)

- Para un individuo $i = 1, \dots, N$, podemos definir la existencia de dos "resultados potenciales": (Y_0, Y_1)
- Definimos $D = 1$ "recibir la intervención" y $D = 0$ "no recibir la intervención". ej.: participar de un programa de entrenamiento laboral
- $D = 0$ debido a que no fueron elegidos o decidieron no participar.
- El resultado observado es:

$$\begin{aligned} Y &= DY_1 + (1 - D)Y_0 \\ &= \begin{cases} Y_0 & \text{si } D = 0 \\ Y_1 & \text{si } D = 1 \end{cases} \end{aligned}$$

Ventajas sobre los resultados utilizando valores

"observados "

- Permite definir efectos causales sin necesidad de especificar la forma de asignación o de hacer supuestos sobre la forma funcional o la distribución

*Por ejemplo, queremos ver $Y_1 - Y_0$, es más general que en el entorno de regresión tradicional: $Y_i = \alpha + \tau W_i + \epsilon_i$
(efectos heterogéneos, supuestos sobre el error, forma funcional, etc.)*

- Permite vincular el análisis del efecto causal a una manipulación explícita del tratamiento: Ejemplo: discriminación en el mercado laboral. La comparación de resultados por género es difícil de interpretar. Sin embargo, podemos estimar un efecto causal si específicamente manipulamos el "tratamiento". (Bertrand & Mullhainathan 2004)

Ventajas...

- Separa la modelación del resultado potencial de la del mecanismo de asignación. Cuando se estudia en términos de resultados observados, se mezclan los resultados potenciales con los mecanismos de asignación.

Ejemplo: Programa de entrenamiento laboral, necesitamos modelar Y_0 , ingresos en ausencia de programa. Podemos postular que Y_0 depende de características individuales e historias laborales. O podemos postular que la elección de participar en el programa depende de características individuales e historias laborales. Finalmente podemos postular la probabilidad de participar en el programa, condicional a características individuales. Terminaremos con un modelo de Y "observado", pero mediante un mecanismo distinto.

- Podemos formular supuestos probabilísticos basados en resultados observados (ej.: prob. de participación dada la historia laboral) y no en términos de componentes no observados. (CIA o supuesto de independencia condicional)
- Permite clarificar de dónde viene la incertidumbre en el estimador: ej.: con acceso a bases de datos que permiten evaluar a toda la población (en lugar de muestras), podemos estimar las medias poblacionales sin error, el error proviene del hecho de que como máximo observamos un resultado potencial por individuo (cuando estimamos los efectos causales).

El problema de la evaluación

- Suponemos por simplicidad que hay dos estados, correspondientes a estar o no bajo tratamiento.
- Definimos $D = 1$ "recibir la intervención" y $D = 0$ "no recibir la intervención".
- Y_1 es el resultado potencial en el estado "tratado" e Y_0 en el no tratado.
- A cada individuo, le podemos asociar un par (Y_0, Y_1) que representan los resultados que se observarían en los dos estados. (Resultados: salarios, empleo, indicadores de salud, educacionales, etc.)
- El problema de la evaluación es que una persona sólo puede estar en un estado a la vez.
- Necesito construir un "contrafáctico" válido para imputar la variable de interés en ausencia de la intervención.

- El resultado observado es:

$$Y = DY_1 + (1 - D)Y_0$$

- La ganancia para un individuo de ir del "estado de no tratamiento " al de "tratamiento " es:

$$\Delta = Y_1 - Y_0$$

- Esta "ganancia " no es observada para ningún individuo ("missing data ")
- Para inferir las ganancias de un tratamiento, la literatura de evaluación de impacto ha desarrollado distintas metodologías.

Parámetros de interés (Heckman, Smith y Lalonde)

- Cuando evaluamos un programa social existen varios parámetros de interés: p.ej.: beneficios para los participantes, efectos en los no beneficiarios, costos del programa, etc.
 - Ejemplo: *Consideremos los efectos de un subsidio a la demanda para aumentar la escolaridad. Si los subsidios son grandes, podemos esperar efectos en las familias. También puede tener efectos en las flías. no participantes, a través de cambios en las escuelas a las que asisten niños no participantes y que son inducidos por el programa. A su vez, si el programa está financiado por impuestos, los efectos pueden incluir un desincentivo a trabajar debido a impuestos más altos en los no participantes.*
- Es importante distinguir entre *efectos directos* (efectos sobre los participantes) y *efectos indirectos* (no directamente relacionados a la participación en el programa)
- En evaluación de impacto: efectos directos en los participantes + efectos de expandir el programa.

- En qué estamos interesados?

- 1 Proporción de participantes que se benefician del programa:
 $\Pr(Y_1 \geq Y_0 | D = 1) = \Pr(\Delta \geq 0 | D = 1)$
- 2 Proporción de la población total que se beneficia del programa:
 $\Pr(\Delta \geq 0 | D = 1) \Pr(D = 1)$
- 3 Impacto por cuantiles, en donde q es el cuantil seleccionado:
 $\inf_{\Delta} \{ \Delta : F(\Delta | D = 1) > q \}$
- 4 La distribución de las ganancias para individuos con características X_0 :
 $F(\Delta | D = 1, X = X_0)$, en donde X son características no afectadas por el programa tales como edad, sexo, educación, raza, nivel de pobreza antes de la intervención, etc.
- 5 Ganancias promedio del programa para personas con características X :
 $E(Y_1 - Y_0 | X) = E(\Delta | X)$ (Average Impact of Treatment, ATE)
- 6 Ganancia promedio del programa para participantes con características X :
 $E(Y_1 - Y_0 | D = 1, X) = E(\Delta | D = 1, X)$ (Average Impact of Treatment on the Treated, TT)

- Si los individuos que participan del programa son los que obtienen las ganancias más grandes, deberíamos esperar que:

$$TT(X) > ATE(X)$$

- Cuál es la diferencia entre $TT(X)$ y $ATE(X)$ y bajo qué condiciones $TT(X) = ATE(X)$?

Supongamos que los resultados en cada estado pueden escribirse como funciones aditivas y separables de observables (X) y no observables (U_0, U_1) :

$$Y_1 = \varphi_1(X) + U_1$$

$$Y_0 = \varphi_0(X) + U_0$$

en donde $Y = DY_1 + (1 - D)Y_0$ puede ser escrito como:

$$Y = \varphi_0(X) + D(\varphi_1(X) - \varphi_0(X)) + \{U_0 + D(U_1 - U_0)\}$$

- Si asumimos que $E(U_0|X) = E(U_1|X) = 0$, la ganancia de participación en el programa es: $\Delta = (\varphi_1(X) - \varphi_0(X)) + (U_1 - U_0)$.
- Los individuos pueden saber o no U_1 y U_0 en el momento de decidir participar o no del programa. Si la gente se autoselecciona en el programa, es de esperar que $E(U_0|X, D) \neq 0$ y $E(U_1|X, D) \neq 0$. Esto es, si la ganancia del programa depende de U_1 y U_0 y la gente conoce sus valores de U_1 y U_0 , o, puede de alguna manera predecir sus valores, deberíamos esperar que usaran esta información para elegir participar o no del programa.
- En la notación vista anteriormente, el $ATE = E(\Delta|X) = \varphi_1(X) - \varphi_0(X) + E(U_1|X) - E(U_0|X) = \varphi_1(X) - \varphi_0(X)$.
- El $TT = E(\Delta|X, D = 1) = \varphi_1(X) - \varphi_0(X) + E(U_1 - U_0|X, D = 1)$.
- También podemos definir el impacto medio en los no tratados como: $UT = E(\Delta|X, D = 0) = \varphi_1(X) - \varphi_0(X) + E(U_1 - U_0|X, D = 0)$.

- Si asumimos que $U_0 = U_1$, entonces $TT = ATE = UT$
- o si $E(U_1 - U_0|X, D) = 0$, en cuyo caso, D no es informativa acerca de $U_1 - U_0$, pero no necesariamente se verifica que $U_0 = U_1$.

Supuestos para el problema de la evaluación:

(A.1) condicional a X , el efecto del programa es el mismo para todos.

($U_0 = U_1$)

(A.2) el efecto del programa (dado X) varía a lo largo de los individuos pero $U_1 - U_0$ no me ayuda a predecir la participación en el programa

(A.3) el efecto del programa (dado X) varía a lo largo de los individuos pero $U_1 - U_0$ me ayuda a predecir la participación en el programa

(A.1) es la más restrictiva, (A.3) la más general. Vamos a estimar TT y ATE bajo los tres sets de supuestos.

Fuentes de sesgos

- Queremos estimar $TT = E(\Delta|X, D = 1)$ y $ATE = E(\Delta|X)$

- Re-escribiendo

$$\begin{aligned} Y &= \varphi_0(X) + D(\varphi_1(X) - \varphi_0(X)) + \{U_0 + D(U_1 - U_0)\} = \\ &\varphi_0(X) + D(E(\Delta|X)) + \{U_0 + D(U_1 - U_0)\} = \\ &\varphi_0(X) + D(E(\Delta|X)) + \{U_0 + D(U_1 - U_0)\} = \\ &= \varphi_0(X) + D(E(\Delta|X, D = \\ &1)) + \{U_0 + D[(U_1 - U_0) - E(U_1 - U_0|X, D = 1)]\} \end{aligned}$$

- Supongamos que las X son discretas y que podemos estimar los efectos de la intervención (D) mediante MCO.

$$y = aX + b_xXD + v$$

- Este modelo es muy aplicado en la práctica, conocido como "efectos comunes", y posee sesgos para estimar el ATE/TT si $E(U_0 + D(U_1 - U_0)|X, D) \neq 0$

Soluciones al problema de la evaluación

- Construcción del contrafáctico: qué supuestos necesito para que mi contrafáctico sea válido?
- Selección basada en observables
- Selección basada en no-observables:
 - 1 constante en el tiempo
 - 2 no constante en el tiempo

Tipos de evaluación de impacto de políticas públicas

- Usando datos que resultan de una asignación aleatoria: tamaño de la muestra, unidades lo suficientemente separables, efectos derrame y externalidades y efectos de equilibrio general, que los efectos no sean "demasiado" agregados, control sobre el proceso, planeadas en el momento del diseño del programa.
- Datos no experimentales, ex-ante y ex-post.
 - Evaluación ex-post usando datos no experimentales.
 - Evaluación ex-post con datos experimentales
 - Evaluación ex-ante.
 - Modelos estructurales
 - Aplicaciones
- La elección del método depende de tres factores:
 - 1 pregunta a ser respondida
 - 2 tipo de datos disponibles y su calidad
 - 3 mecanismo de asignación al programa/política

- En general, las regresiones se usan con datos "observacionales".
- Sin el beneficio de una asignación aleatoria, los coeficientes pueden o no tener una interpretación causal.
- Bajo qué condiciones los coeficientes de una regresión tienen una interpretación causal?
- Características del vector de regresión poblacional y su contraparte muestral, interpretación de los resultados por parte del investigador


Conceptos básicos para el análisis de regresión:

- Relación positiva entre años de educación e ingresos. Es causal?
- La educación "predice" ingresos en sentido estadístico. (CEF)
- La CEF para una variable y_i , dados un vector de $k \times 1$ variables explicativas X_i , (x_{ik}) es el valor esperado, o el promedio poblacional de y_i , con X_i fijos.

$$E[Y_i|X_i] = \left(\int t f_y(t|X_i=x) dt, \text{ para } Y_i \text{ continua} \right) \left(\sum_t t P(y_i=t|X_i=x), \text{ para } Y_i \text{ discreta} \right) (1)$$

- Como X_i son aleatorios, entonces (1) también lo es.
- (1) es un concepto poblacional.

Conceptos básicos para el análisis de regresión:



- Ley de expectativas iteradas: $E[Y_i] = E\{E[Y_i|X_i]\}$ (2)
- Descomposición de la CEF (teorema): $Y_i = E[Y_i|X_i] + \epsilon_i$, (3)

en donde ϵ_i es independiente de X_i , $E[\epsilon_i|X_i]$, y en consecuencia, ϵ_i no está correlacionado con cualquier función de X_i .

- Propiedad de predicción de la CEF:

Sea $m(X_i)$ una función cualquiera de X_i . La CEF satisface entonces:

$$E[Y_i|X_i] = \arg \min_{m(X_i)} E[(Y_i - m(X_i))^2] \quad (4),$$

es el predictor con el mínimo error cuadrático.


- ANOVA:

$$V(Y_i) = V(E[Y_i|X_i]) + E[V(Y_i|X_i)] = V(E[Y_i|X_i]) + E[\epsilon_i^2] \quad (5)$$

(la varianza de Y_i es la varianza de $E[Y_i|X_i]$ más la varianza de ϵ_i).

Conceptos....

- La validez de la regresión lineal no depende del supuesto de linealidad de la CEF. Incluso cuando la CEF es no lineal, el modelo de regresión lineal brinda la mejor aproximación "lineal" de la misma.



- En el caso de la regresión lineal, $m(X_i)$, es $X_i' b$

$$\beta = \arg \min_b E[(Y_i - X_i' b)^2]$$
$$E[X_i(Y_i - X_i' b)] = 0 \text{ (CPO)} \implies \beta = E[X_i X_i']^{-1} E[X_i y_i]$$

- Con un regresor solo y una constante: $\beta_1 = \frac{\text{Cov}(Y_i, x_i)}{V(x_i)}$ y $\alpha = E(Y_i) - \beta_1 E(X_i)$
- Con k regresores: $\beta_k = \frac{\text{Cov}(Y_i, \tilde{x}_i)}{V(\tilde{x}_i)}$, en donde $\tilde{x}_i$ es el residuo de la regresión de x_{ki} en todos los otros regresores.

- No conocemos la CEF, con lo cual hacemos inferencia basados en muestras.
- Esto nos permite interpretar los resultados de una regresión
- Queremos estimar la distribución en el análogo muestral de:
 $\beta = E[X_i X_i']^{-1} E[X_i y_i]$, más conocido como el estimador de MCO (OLS): $\hat{\beta} = [\sum X_i X_i']^{-1} \sum X_i y_i$
- La distribución de $\hat{\beta}$ es asintóticamente normal. (son funciones continuas de un vector de variables aleatorias con distribución asintótica normal), con media β y matriz de varianzas y covarianzas $E[X_i X_i']^{-1} E[X_i X_i' \epsilon_i^2] E[X_i X_i']^{-1}$
- Si se asume homocedasticidad, la matriz se transforma en $\sigma^2 E[X_i X_i']^{-1}$

- Una regresión es causal cuando la CEF que aproxima es causal.
- Es útil pensar en relaciones causales en términos de resultados potenciales para describir qué le pasaría a un individuo/situación, etc. en la comparación hipotética de escenarios alternativos.
- Por ejemplo: 1) Mejora los indicadores de salud asistir a un hospital?, 2) Problema de los retornos a la educación.
- Necesitamos que la variable causal de interés sea independiente de los potenciales resultados.
- Supuesto de Independencia Condicional (CIA): selección basada en observables.

- Resultados potenciales:

$$Y_{1i} \text{ si } D_i = 1$$

$$Y_{0i} \text{ si } D_i = 0$$

- El resultado observado (escrito en términos de resultados potenciales) puede escribirse como:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i$$

Observamos Y_{1i} o Y_{0i} , pero nunca ambos. Esperamos medir un promedio para cierto grupo, $E[(Y_{1i} - Y_{0i}) | D_i = 1]$

Qué es lo que vemos con estudios de datos observacionales:

$$E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 0] =$$

Diferencia-observada

$$E[(Y_{1i} - Y_{0i})|D_i = 1] + E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]$$

TT

Sesgo-de-selección

(sumo y resto $E[Y_{0i}|D_i = 1]$)

- Con sesgo de selección positivo (negativo), la comparación naive $E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 0]$ sobrestima (subestima) el efecto que queremos medir
- La CIA dice que si condicionamos en características observadas, el sesgo de selección desaparece:

$$\{Y_{1i}, Y_{0i}\} \perp D_i | X_i \implies$$

$$E[Y_i|X_i, D_i = 1] - E[Y_i|X_i, D_i = 0] = E[Y_{1i} - Y_{0i}|X_i]$$

- Qué requisitos deben cumplirse para que el sesgo de selección sea eliminado?
- Sesgo de variables omitidas (OVB)

Ejemplo:

$$Y_i = \alpha + \rho s_i + \eta_i, (1)$$

η_i puede descomponerse en: $\eta_i = X_i' \gamma + v_i$.

Supongamos que las variables relevantes en la regresión (poblacional) para ver los efectos de los años de escolaridad en el ingreso pueden reducirse a una combinación de inteligencia, motivación y background familiar.

Llamemos a ese vector de controles A_i .

$$Y_i = \alpha + \rho s_i + A_i' \gamma + \epsilon_i (2)$$

Si la CIA es válida dado A_i entonces, ρ en (2) tiene la interpretación causal, en donde ϵ_i es el componente aleatorio de los ingresos.

- El problema es que no tenemos buenas medidas de A_i
- Qué pasa al estimar la regresión sin A_i ?
- Verdadero PGD= $y = x'\beta + z\alpha + v$
- Pero estimo $y = x'\beta + u$
- Ahora $u = z\alpha + v$
- v no está correlacionado con x , pero si z está correlacionado con x , tendremos sesgos.

- $\hat{\beta}_{ols} = (x'x)^{-1}(x'y)$
- $\hat{\beta}_{ols} = \beta + (N^{-1}x'x)^{-1}(N^{-1}x'z)\alpha + (N^{-1}x'x)^{-1}(N^{-1}x'v)$
- $\hat{\beta}_{ols} = \beta + \delta\alpha$
- $\delta = p\lim[(N^{-1}x'x)^{-1}(N^{-1}x'z)]$

CIA y Variables Omitidas:

$$\frac{\text{Cov}(Y_i, s_i)}{V(s_i)} = \rho + \gamma' \delta_{As}, \delta \text{ es el vector de coeficientes de la regresión de } A_i \text{ en } s_i.$$

Con la fórmula podemos darnos una idea del signo del sesgo.

Table 3.2.1: Estimates of the returns to education for men in the NLSY

	(1)	(2)	(3)	(4)	(5)
Controls:	None	Age dummies	Col. (2) and additional controls*	Col. (3) and AFQT score	Col. (4), with occupation dummies
	0.132 (0.007)	0.131 (0.007)	0.114 (0.007)	0.087 (0.009)	0.066 (0.010)

Notes: Data are from the National Longitudinal Survey of Youth (1979 cohort, 2002 survey). The table reports the coefficient on years of schooling in a regression of log wages on years of schooling and the indicated controls. Standard errors are shown in parentheses. The sample is restricted to men and weighted by NLSY sampling weights. The sample size is 2434.

*Additional controls are mother's and father's years of schooling and dummy

CIA: Qué controles elegimos?

- Variables que se consideren fijas a la hora de determinar el regresor de interés
- No incluir controles que sean variables resultados: p.ej.: sector ocupacional en la ecuación de educación e ingresos (se correlaciona tanto con educación como con ingresos)
- Variables proxy: p.ej.: notas académicas como proxies de cociente intelectual.

$$y_i = \alpha + \rho s_i + \gamma a_i + e_i \quad (1)$$

a_i es una medida de "habilidad temprana" tomada antes que las decisiones de escolaridad, entonces $E[s_i e_i] = E[a_i e_i] = 0$, por definición.

Pero a_i no está disponible, tenemos una medida de habilidad (a_{ji}) tomada luego de algunos años de escolaridad. a_{ji} se relaciona con a_i y con s_i .

$$a_{ji} = \pi_0 + \pi_1 s_i + \pi_2 a_i \quad (2)$$

CIA: Qué controles elegimos?

- **Problema:** tanto a_i como s_i aumentan a_{ji} . Despejando a_i de (2) y reemplazando en (1) obtenemos:

$$y_i = (\alpha - \gamma \frac{\pi_0}{\pi_2}) + (\rho - \gamma \frac{\pi_1}{\pi_2}) s_i + \frac{\gamma}{\pi_2} a_i + e_i \quad (3)$$

γ, π_1, π_2 son positivos, con lo cual $(\rho - \gamma \frac{\pi_1}{\pi_2})$ es pequeño, a menos que $\pi_1 = 0$. Esto es, una variable proxy que depende positivamente de nuestra variable de interés genera un coeficiente que está por debajo del efecto deseado. De todas maneras, dicho efecto puede ser investigado, regresando a_{ji} en s_i .

- Permite estimar "bounds" o cotas.

- Angrist J, y Pischke, (2008), "Mostly Harmless Econometrics "
- Heckman, J., Lalonde, R. y Smith, J. (1999). The economics and econometrics of active labor market programs. Handbook of Labor Economics 3A.
- Capítulo de Imbens (2009), "Recent Developments in Program Evaluation"
- Angrist, Joshua and Alan Krueger. 1999. "Empirical Strategies in Labor Economics"