

Cálculos de potencia estadística y muestreo para experimentos aleatorizados

Curso Evaluación de Impacto de
Políticas Públicas

Maestría en Economía - UNLP

Resumen

- Cómo planificamos la asignación aleatoria?
- Algunos conceptos estadísticos
- Cálculos de potencia (“power”)
- Algunas consideraciones

Cómo aleatorizar?

- **Sobresubscripción:** una oportunidad natural para introducir una aleatorización es cuando hay exceso de demanda. Problema de falta de cooperación de los que no reciben el tratamiento. El programa se implementa mediante, por ejemplo, una lotería. (ej.: vouchers para las escuelas de Colombia).
- **Phase-in:** por restricciones presupuestarias, muchas veces no se puede implementar todo el programa a la vez. Cuando es discutible no recibir tratamiento. (ej.: Proyecto de desparasitación en Kenia). Problema para estimar los efectos de largo plazo, puesto que el grupo de control desaparece. Depende del horizonte del proyecto y de cuanto tardan en materializarse los efectos del programa.

Cómo aleatorizar?

- **Dentro del grupo o "within":** beneficios a todos, pero para distintos sub-grupos. (ej. programa balsakhi en la India) Se evitan problemas de falta de cooperación de los que no reciben tratamiento, pero existe el riesgo de "contaminación del control".
- **Diseño de incentivos:** el programa está disponible para todos, pero la tasa de participación no es universal. Aquí sólo hay un aumento en la probabilidad de participar. (ej.: estudio para el GRE)

Técnicas para la asignación aleatoria

- Aleatorización individual
 - Mido el resultado al mismo nivel que a la unidad de tratamiento
 - Ej: programa de entrenamiento laboral. Cola de interesados, asigno un número a cada uno y luego aleatorizo.
 - El tratamiento y resultado de interés son administrados en diferentes niveles.
 - Ej.: Intervención a nivel escuela, mido resultados a nivel individual
 - Se llama aleatorización a nivel grupo o cluster.

Técnicas para la asignación aleatoria

- **Block y Within Subject Design:**
 - Más fácil: diseño completamente aleatorizado
 - Minimiza riesgo de que el tratamiento esté correlacionado con características observables e inobservables de los individuos
 - ...pero la varianza tiende a ser muy grande, problemas de inferencia.
 - **Block:** Si existe heterogeneidad en el *pool* de individuos, podemos reducir la varianza incluyendo X_i en una regresión lineal (*blocking*). Agregar covariables reduce la varianza del componente no observado.
 - **Within study:** más de un tratamiento, utilizado en medicina.
 - Efectos de aprendizaje, sensibilización, interacción inesperada entre tratamientos, etc.

Técnicas para la asignación aleatoria

- **Diseño factorial:**
 - **Block:** el tamaño de la muestra puede variar significativamente a lo largo de los bloques.
 - En cambio, en el diseño factorial: el experimentador elige un nro. específico de sujetos por bloque.
 - **Diseño básico factorial:** número de sujetos pre-determinados asignado a cada combinación de tratamiento.
 - Caro en presencia de tratamientos múltiples con interacciones.

Asignación aleatoria

- Los métodos llamados experimentales permiten solucionar el problema fundamental de la evaluación :
 - No podemos observar la misma unidad “tratada” y “no tratada”.
 - La asignación aleatoria reduce el sesgo, pero no elimina el ruido.
 - La asignación aleatoria funciona debido a la “ley de los grandes números”.
 - La identificación requiere la comparación de los resultados esperados para dos (o más) grupos de manera “creíble”.

Planificando la asignación aleatoria

- Utilizar métodos estadísticos para hacer test de hipótesis
- Comparar dos resultados (Tratamiento vs. Control)
 - La teoría nos dice que deberíamos esperar una diferencia.
- Necesitamos datos....Cuántos?
- Test de hipótesis
 - Caso un sólo tratamiento, con dos grupos:
 - Diferencias en medias
 - Otros momentos de la distribución
 - Con datos en panel, diferencias en cambios

Test de Hipótesis

- Es la versión estadística de “se supone inocente”, hipótesis nula de “no hay diferencia”
 - No hay diferencias entre los resultados de participantes y no participantes del programa.
- La evidencia busca refutar esto.
- Se testea la hipótesis de $H_0 =$ el efecto es igual a cero.

Resumen (I)

- El efecto que obtenemos es sólo válido para nuestra muestra.
- Cómo se hace inferencia?
- Un intervalo de confianza de 95% nos dice que para un programa dado, el 95% de las muestras que tomemos para una población dada arrojarán un efecto que se ubicará dentro de dicho intervalo.
- El error estándar (ES) captura el tamaño de la muestra y la variabilidad de la variable que utilizemos como resultado.

Resumen (II)

- **Test:**
 - Queremos testear la hipótesis de “no tiene efecto”
 - $H_0 = 0$
 - $H_a = \neq 0$
 - Error de tipo I:
 - Error de tipo I: Rechazar falsamente una hipótesis nula. Concluir que existe un efecto cuando en realidad, no lo hay.
 - Con $\alpha = 5\%$, 1 cada 20.
 - α = nivel de significatividad, probabilidad de cometer error de tipo I.

Resumen (III)

- Error de tipo II: No rechazar cuando existe un efecto.
 - La potencia estadística o “*power*” de un test es la probabilidad de encontrar un efecto significativo (en nuestro experimento).
- La potencia es un elemento clave en la planificación de un experimento.
- Para un tamaño de muestra dada, cuán probable es que encontremos un efecto significativo.
 - En nuestra intervención, el error de tipo II significa que existe un efecto, pero que no lo podemos detectar.

Qué concluimos de nuestro test de hipótesis

		Rechazar H_0 de no efecto	No rechazar H_0 de no efecto
“Verdad”	Experimento tiene efecto	ok	Error de tipo II o bajo poder
	Experimento no tiene efecto	Error de tipo I	ok

Qué concluimos de nuestro test de hipótesis

		Rechazar H_0 de no efecto	No rechazar H_0 de no efecto
"Verdad"	Experimento tiene efecto	ok	Error de tipo II o bajo poder
	Experimento no tiene efecto	Error de tipo I	ok

Probabilidad de rechazar H_0 dado que es verdadera.

Qué concluimos de nuestro test de hipótesis

		Rechazar H_0 de no efecto	No rechazar H_0 de no efecto
“Verdad”	Experimento tiene efecto	ok	Error de tipo II o bajo poder
	Experimento no tiene efecto	Error de tipo I	ok

Probabilidad de no rechazar H_0 dado que es falsa.

La tiranía de *power*– Bland, BMJ 2008

- Es una idea muy simple.
- Realizamos un estudio y evaluaremos la evidencia vía tests de hipótesis.
- Es importante decidir cuán grande es el efecto que nos gustaría detectar.
- Elegimos un tamaño de muestra tal que si existiera un efecto real en la población, una gran proporción de las muestras posibles produciría una diferencia estadísticamente significativa.

Cálculos de potencia

- Una potencia de 80% nos dice que el 80% de los experimentos en una población con un tamaño de muestra dado, si existe un efecto, lo encontraremos con el nivel de significatividad elegido.
 - La potencia aumenta con el tamaño de la muestra
 - Cuanto más grande es la muestra, más cerca estamos de las características poblacionales.
 - Es más probable que podamos concluir que hay una diferencia en resultados, si esa diferencia existe.
 - Además, reduce la variabilidad de los estimadores.
 - *Advertencia:* si la variabilidad del resultado de interés se explica en gran parte por otros factores, menor será el efecto que le podremos atribuir a la intervención.

Cómo se calcula?

- Para un conjunto de datos dado, o una muestra dada, el error de tipo II viene dado, pero podremos calcular que efecto podremos detectar.
- Pero, si planeamos un experimento, podemos elegir cuánto error de tipo II estamos dispuestos a tolerar.
- Cuánto mayor sea la diferencia entre los dos grupos (efecto), más grande la potencia (o menos error de tipo II) para una muestra dada.

Cómo se calcula?

- Cuánto es el efecto mínimo que justifica nuestro programa?
 - Un efecto muy pequeño, puede no ser económicamente significativo.
 - Si es un efecto más grande, lo queremos detectar.
 - Mirar intervenciones similares
 - *Unidades de medición distintas, cm, US\$, kg...*
 - *No es lo mismo una diferencia de \$100 cuando la desviación estándar es de 10 o de 20.*

Cómo se calcula?

- Efectos estandarizados, delta o ES.
 - Efecto dividido por la desviación estándar de la variable resultado.
 - Lo mido en unidades de sd.
 - ES: cuán grande?
 - 0.1, 0.2, etc

Cómo se calcula?

- Muy pequeño
 - 0.10
 - Qué significa?
 - El miembro promedio del grupo de tratamiento tiene un resultado mejor que el 54% de los miembros del grupo de control.

Cómo se calcula?

- Modesto
 - 0.20
 - Qué significa?
 - El promedio del grupo de tratamiento tiene un resultado mejor que el 58% de los miembros del grupo de control.

Cómo se calcula?

- Grande
 - 0.50
 - Qué significa?
 - El promedio del grupo de tratamiento tiene un resultado mejor que el 69% de los miembros del grupo de control.

Cómo se calcula?

- Muy grande
 - 0.80
 - Qué significa?
 - El promedio del grupo de tratamiento tiene un resultado mejor que el 79% de los miembros del grupo de control.

Cómo se calcula?

- Qué delta elegimos?
 - Cuanto más chico, más grande la muestra
 - Literatura relacionada para el delta / medias y varianzas: información local
 - Mejor ser conservadores
 - Qué resultados?
 - Tratamientos múltiples
 - Stata/Optimal Design Software

Los más utilizados....

- Nivel de significatividad: 1%, 5%
- Potencia: 0.80, 0.90
- delta: 0.2, 0.5
- Fácil de calcular

Qué necesitamos?


- Fórmula:

$$N=4 (t_{(\theta)} + t_{\alpha})^2 / ES$$

- $t_{(\theta)}$ = Valor crítico θ , $t_{(\theta)}=0.84$, si queremos una potencia de 80%
- t_{α} = Valor críticos para una significatividad α . Si $\alpha=0.05$, $t_{\alpha}=1.666$
- $ES=(Effect\ Size)=\delta$
- $N=n_0+n_1$
 - Nota: status quo igual tamaño puede ser costoso en términos de sobre-muestreo


Ejemplos

Potencia, tamaño muestra y δ



Ejemplos

Cómo cambia la potencia con ***N***?



Ejemplo: Intervención para mejorar talla y BMI

El tamaño de muestra necesario en cada grupo (suponiendo el mismo número para cada uno) para realizar tests de hipótesis bilaterales es: $n \geq 2[(z_{\{(\alpha/2)\}} + z_{\{\beta\}})(\sigma/\Delta)]^2$

Donde σ es la desviación estándar, y Δ es la diferencia entre las medias que se espera observar, usando un nivel de significación $\alpha=0.05$ y una potencia 0.80, los valores $z_{\{(\alpha/2)\}} = 1.96$ y $z_{\{\beta\}} = 0.84$

En la comparación de tallas, se eligió $\Delta=1.5\text{cm}$: $\sigma=3.05$ (para niños, tablas de OMS), se obtiene $n \geq 65$

$\sigma=3.23$ (para niñas, tablas de OMS), se obtiene $n \geq 73$

En la comparación de BMI, se eligió $\Delta=0.5\text{kg/m}^2$: $\sigma=1.3$ de la mitad superior (para niños, tablas de OMS), se obtiene $n \geq 106$

$\sigma=1.4$ de la mitad superior (para niñas, tablas de OMS), se obtiene $n \geq 123$

Tomando el mayor valor, se decidió elegir 150 niños en cada grupo, previendo un posible abandono del estudio de aproximadamente 20%


Algunas consideraciones

1. Datos de línea de base
2. Nivel de asignación aleatoria
3. Cumplimiento con la asignación aleatoria
4. Estratificación

1. Línea de base

- Tenemos datos de línea de base?
- Para un delta y N dado, tendremos mayor potencia si las covariables de la línea de base explican una parte más grande de la variación del resultado de interés.
 - Ejemplos:
 1. Intervenciones en área de educación: resultados de exámenes
 2. Salud: prevalencia e incidencia de diarrea
 3. Agricultura: productividad de la tierra
- Para una potencia y un delta dado, necesitaremos una muestra más pequeña.
- Nos preocupa la varianza residual, luego de limpiar por el efecto de la covariable relevante.

Ejemplo




2. Nivel de asignación aleatoria (*clusters*)

- La unidad de aleatorización es una comunidad, colegio, hospital.
- Por qué? Efectos derrame, costos, restricciones políticas, etc.
- El nivel de aleatorización es distinto de la unidad en la que medimos los resultados.
- Problema: las observaciones en una unidad de aleatorización están correlacionadas. (ej: shocks económicos, productividad, shocks temporales, etc.)


2. Nivel de asignación aleatoria (*clusters*)

- Nuevo parámetro ρ (correlación intra-cluster)
- Relevante para los cálculos de potencia
- Es importante para inferencia
- Cómo varia la potencia con ρ ?
- De dónde obtenemos este parámetro?


Ejemplo: ρ & potencia



Ejemplo: ρ & potencia



Ejemplo: ρ & potencia



En términos de potencia, el número de clusters es más importante que las unidades que tenemos por cluster.

ρ & potencia

$$Y_{ij} = \alpha + \beta T + v_j + \omega_{ij}$$

Para n individuos en J clusters.

v_j es i.i.d. con varianza τ^2

ω_{ij} es i.i.d. con variance σ^2

$\rho = \tau^2 / (\tau^2 + \sigma^2)$, la proporción de la varianza total explicada por la varianza dentro del grupo.
(*within group variance*).

ρ & potencia

δ es ahora:

$$= \sqrt{\frac{M_{J-2}}{\sqrt{P(1-P)} J}} \sqrt{\rho + \frac{(1-\rho)}{n}} \sigma$$

donde $M_{(j-2)} = t_{\alpha/2} + t_{\beta}$

3. Cumplimiento imperfecto

- Hasta ahora asumimos que todo el mundo participa, tal como fue estipulado en el protocolo para la aleatorización.
- Individuos o unidades asignadas al tratamiento pueden no participar
- Los controles pueden acceder al tratamiento o parte del tratamiento

3. Cumplimiento imperfecto

- Hay que ajustar los cálculos de potencia por la diferencia en cumplimiento entre el tratamiento y el control
- La muestra debe ser ajustada en la proporción $1/(c-s)^2$, en donde c y s son las tasas de cumplimiento de los grupos de tratamiento y control respectivamente.

4. Estratificación

- Reduce el tamaño de la muestra para una potencia dada.
- Reduce la variabilidad del resultado de interés dentro de cada estrato.
 - En general se utilizan variables resultado pre-tratamiento de la línea de base.
 - Esperamos que el tratamiento sea distinto entre los grupos en los que basamos los estratos.

Consideraciones Finales (I)

- **Externalidades**
 - Individuos no tratados se benefician del tratamiento.
 - Aprendizaje/ imitación, etc. .
- **SUTVA (Stable unit treatment value assumption)** no se verifica. Ahora el efecto sobre el individuo/unidad, etc. no es independiente del tratamiento de otro individuo (ejemplos: vacunas, tratamientos antiparasitarios, educación, etc.)
- **Soluciones:** distintos niveles de exposición e intensidad de tratamiento, aleatorización en grupos.

Consideraciones Finales (II)

- **Atrición**
 - Aleatoria: reduce el power
 - Qué pasa si no es aleatoria?
 - Comparar usando datos de línea de base, los resultados de los que abandonan vs. los que no.
 - Soluciones no paramétricas [Manski (1989) & Lee (2002)]

Consideraciones Finales (III)

- Validez externa .
 - Replicabilidad y generalización de los resultado
 - Efectos de equilibrio general (scale up), depende de cuán grande es la unidad de intervención
 - Cambios de comportamiento: Hawthorne (tratamiento) & John Henry (control).
 - Datos de largo plazo

Consideraciones Finales (IV)

- Qué resultado utilizamos para el cálculo de potencia?
- Es triste ver un programa con una buena estrategia de evaluación, pero con poca potencia.
 - Tamaño de la muestra
 - Muy optimista respecto de delta
 - Pocos clusters
 - Muy optimistas sobre el cumplimiento
- Elegir cuidadosamente el nivel de aleatorización
- Ser muy conservadores en términos de delta
- Piloto para tener estimadores de la varianza
- Consulte a su estadístico amigo

References

- Duflo, Esther, Glennerster, Rachel and Kremer, Michael, “Using Randomization in Development Economics Research: A Toolkit” (December 12, 2006). Available at <http://ssrn.com/abstract=951841> or <http://dx.doi.org/10.2139/ssrn.951841>
- List, John, Sally Sadoff y Mathis Wagner, “So You Want to Run an Experiment, Now What? Some Simple Rules of Thumb of Optimal Experiment Design”, NBER WP
- Bruhn, Miriam, and David McKenzie. 2009. "In Pursuit of Balance: Randomization in Practice in Development Field Experiments." American Economic Journal: Applied Economics, 1(4): 200-232.
- Optimal Design Software Guide available at http://sitemaker.umich.edu/group-based/optimal_design_software

Consideraciones éticas

- Cuándo es éticamente cuestionable aleatorizar?
 - Cuando el grupo de control se verá dañado por la falta de tratamiento (asignación aleatoria para un tratamiento que previene el contagio de HIV de madre a hijo)
 - Cuando se afectan decisiones personales (anticonceptivos orales vs. DIU)
 - Cuando los riesgos de tratamiento nuevo exceden los de un tratamiento existente
 - Cuando se conocen los beneficios del tratamiento

Reporte Belmont sobre Principios Éticos

- Autonomía y respeto por los individuos
 - Elección libre e independiente sin coerción
 - Consentimiento informado
- Maximizar beneficio y minimizar daño
- Justicia
 - Igual oportunidad de obtener los beneficios
 - Provisión de los tratamientos beneficios a la población

Reporte Belmont sobre Principios Éticos

- Los participantes no pueden estar coercionados
 - Negando los beneficios a las personas que se rehúsan (tratamiento alternativo)
 - Ofreciendo compensación excesiva por la participación
 - Ejerciendo presión para participar
- Los participantes deben saber:
 - Razones para conducir el experimento, por qué se elige al beneficiario para participar, quien financia el experimento
 - Procedimiento el experimento
 - Riesgos, beneficios y medidas para reducir los riesgos
 - Confidencialidad