

Diferencias en Diferencias

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Abril 2020

Diferencias en Diferencias

- Ejemplo de caso: Hay un grupo de personas, podemos llamarlas «tratadas», a las que en cierto momento se las sometió a alguna intervención («tratamiento»)
- Las observamos antes de que el tratamiento entrara en vigor y después
- Queremos ver si el tratamiento generó un efecto en la variable Y
- Idealmente, podríamos ver si Y cambió después del tratamiento en comparación con cómo era antes
 - **Comparación antes y después:** si observamos los resultados antes y después del tratamiento podríamos usar a los tratados antes del tratamiento como controles para los tratados luego del tratamiento (i.e. ellos mismos antes de ser tratados)
 - ¿Es esta una buena idea?: El problema de esta comparación es que puede estar contaminada por el efecto de otros eventos simultáneos diferentes al tratamiento que ocurrieron entre los dos periodos

Diferencias en Diferencias


- ¿Qué podemos usar para controlar por esos otros cambios simultáneos al tratamiento?
- Si solo una fracción de la población está expuesta al tratamiento, podemos usar el grupo que no recibió el tratamiento, pero que sí pudo haber estado expuesto a los demás cambios simultáneos, para identificar la variación temporal en las variables de resultados que no se debe a la exposición al tratamiento
 - **Esta es la idea básica del método DID**

Diferencias en Diferencias


Diferencias en diferencias

- Los métodos de diferencias en diferencias (DID) se han convertido en una herramienta muy importante para la investigación empírica.
- En el caso típico hay:
 - dos o más grupos, al menos uno tratado y un control,
 - que los observamos en dos o más períodos de tiempo: antes del tratamiento («pre») y después del tratamiento («post»)
 - **DD**: la diferencia observada en el outcome de interés entre el tratamiento y el control después del tratamiento se ajusta por la diferencia entre esos dos grupos antes del tratamiento

Diferencias en Diferencias



Diferencias en Diferencias



Diferencias en Diferencias: notación

- $D = 0$: control (nunca tratados)
- D : tratados
- $t = 1, \dots, T_0$: períodos pre-intervención
- $t = T_0 + 1, \dots, T$: períodos post-intervención
- Notar que los tratados reciben el tratamiento sólo en el período posterior a la intervención
→ cuando $t > T_0$
- $Y^d(t)$: resultado potencial bajo tratamiento « $D=d$ » en el período t
- X : covariables observables
- U : covariables no observables

Diferencias en Diferencias: notación

- Si tomemos por el momento un ejemplo con 2 períodos:
 - $t=2$ es el período post-intervención y $t=1$ pre-intervención
 - $ATT \equiv \mathbb{E} [Y^1(2) - Y^0(2)|D = 1]$
 - Problema: no sabemos cuál es el valor del contrafactual $Y^0(2)|D = 1$
 - Solución bajo algunos supuestos podemos estimar este contrafactual por medio del método de DD

DiD - Supuesto de tendencias paralelas

«La diferencia entre ambos grupos (Tratamiento y Control) se habría mantenido constante si la intervención no hubiese ocurrido»

- Esto quiere decir que en ausencia del tratamiento habría **«tendencias paralelas»**: El cambio en los resultados entre los períodos pre y post-intervención en el grupo de control es un buen indicador de cuál hubiera sido el cambio (contrafactual) en los resultados potenciales del grupo tratado si no hubiera sido tratado

DiD - Supuesto de tendencias paralelas

Por ejemplo, en el caso en que observamos las unidades tratadas y de control solo una vez antes del tratamiento ($t = 1$) y una vez después del tratamiento ($t = 2$) tenemos que este supuesto nos dice que:

$$\mathbb{E} [Y^0(2) - Y^0(1)|D = 1] = \mathbb{E} [Y^0(2) - Y^0(1)|D = 0]$$

Esto es un supuesto, no es algo que podemos testear!

- para $D=1$: $Y^0(1)$ siempre se observa pero $Y^0(2)$ no,
- tenemos que mostrar evidencia que sustente este supuesto,
- a veces el supuesto contrafactual puede mantenerse solo después de condicionar algunas covariables observadas

Diferencias en Diferencias: desagregando el supuesto

- **Tendencias paralelas previas:** En el período previo a la intervención, las tendencias temporales en las variables de resultado son las mismas en el tratamiento y en el control
 - esto no es un supuesto, es algo que podemos testear
- **Shocks comunes:** En el período posterior a la intervención, los shocks exógenos afectan a los grupos tratados y de control por igual (**este sí es un supuesto**)

Bajo este supuesto podemos estimar el ATT

$$ATT \equiv \mathbb{E} [Y^1(2) - Y^0(2) | D = 1]$$

$$= \{\mathbb{E}[Y(2) | D = 1] - \mathbb{E}[Y(1) | D = 1]\} - \{\mathbb{E}[Y(2) | D = 0] - \mathbb{E}[Y(1) | D = 0]\}$$

Demostración:

$$ATT \equiv \mathbb{E} [Y^1(2) - Y^0(2) | D = 1] \quad (\text{Definición de ATT})$$

$$= \mathbb{E} [Y^1(2) | D = 1] - \mathbb{E} [Y^0(2) | D = 1]$$


$$= \mathbb{E} [Y^1(2) | D = 1] - (\mathbb{E} [Y^0(2) - Y^0(1) | D = 0] + \mathbb{E} [Y^0(1) | D = 1])$$

(por supuesto contrafactual)


$$= (\mathbb{E} [Y^1(2) | D = 1] - \mathbb{E} [Y^0(1) | D = 1]) - (\mathbb{E} [Y^0(2) | D = 0] - \mathbb{E} [Y^0(1) | D = 0])$$

$$= \{\mathbb{E} [Y(2) | D = 1] - \mathbb{E} [Y(1) | D = 1]\} - \{\mathbb{E} [Y(2) | D = 0] - \mathbb{E} [Y(1) | D = 0]\}$$


Diferencias en Diferencias



Diferencias en Diferencias



Diferencias en Diferencias



Diferencia en Diferencias: Estimación por regresión

- La formulación del modelo de DiD por medio de regresiones ofrece una manera conveniente de construir estimaciones DD y errores estándar (sobretudo en el caso de múltiples períodos y múltiples grupos dentro del control y el tratamiento)

Diferencia en Diferencias: Estimación por regresión

Nosotros observamos Y_{it}

- $Y_{it} = Y_{it}^0 + \beta D_i \cdot I(t > T_0)$
- Llamemos $I(t > T_0) = "Post"$ $\rightarrow Y_{it} = Y_{it}^0 + \beta D_i \cdot Post_t$
- (notar que estamos asumiendo que el efecto del tratamiento es el mismo para todos)

Si tenemos 2 períodos (pre, $t=1$, y post, $t=2$)

$$Y_{it}^0 = \alpha + \delta I(t = 2) + \gamma I(D_i = 1) + \epsilon_{it}$$

$$Y_{it}^0 = \alpha + \delta Post + \gamma D + \epsilon_{it}$$

$$Y_{it} = Y_{it}^0 + \beta D_i \cdot Post$$

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \epsilon_{it}$$

Diferencia en Diferencias: Estimación por regresión

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \epsilon_{it}$$

$$\hat{Y}(tratado, post)_i = \hat{\alpha} + \hat{\delta} + \hat{\gamma} + \hat{\beta}$$

$$\hat{Y}(tratado, pre)_i = \hat{\alpha} + \hat{\gamma}$$

$$\hat{Y}(tratado, post)_i - \hat{Y}(tratado, pre)_i = \hat{\delta} + \hat{\beta}$$

$$\hat{Y}(no tratado, post)_i = \hat{\alpha} + \hat{\delta}$$

$$\hat{Y}(no tratado, pre)_i = \hat{\alpha}$$

$$\hat{Y}(no tratado, post)_i - \hat{Y}(no tratado, pre)_i = \hat{\delta}$$

$$[\hat{Y}(tratado, post)_i - \hat{Y}(tratado, pre)_i] - [\hat{Y}(no tratado, post)_i - \hat{Y}(no tratado, pre)_i] = \hat{\beta}^{DD}$$

Estamos usando el supuesto de tendencia común:

$$\mathbb{E}[Y^0(2) - Y^0(1) | D = 1] = (\alpha + \delta + \gamma) - (\alpha + \gamma) = \delta$$

$$\mathbb{E}[Y^0(2) - Y^0(1) | D = 0] = (\alpha + \delta) - (\alpha) = \delta$$

Diferencia en Diferencias: Estimación por regresión

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \epsilon_{it}$$

	<i>Pre</i>	<i>Post</i>	<i>Diferencia</i>
<i>Tratado</i>	$\hat{\alpha} + \hat{\gamma}$	$\hat{\alpha} + \hat{\delta} + \hat{\gamma} + \hat{\beta}$	$\hat{\delta} + \hat{\beta}$
<i>No tratado</i>	$\hat{\alpha}$	$\hat{\alpha} + \hat{\delta}$	$\hat{\delta}$
<i>Diferencia</i>	$\hat{\gamma}$	$\hat{\gamma} + \hat{\beta}$	$\hat{\beta}$

Diferencias en Diferencias: adicionales

Podemos sumar covariables

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \lambda X_{it} + \epsilon_{it}$$

$$\begin{aligned}\mathbb{E}[Y^0(2) - Y^0(1)|D = 1] &= (\alpha + \delta + \gamma + \lambda \mathbb{E}\{X|D = 1\}) - (\alpha + \gamma + \lambda \mathbb{E}\{X|D = 1\}) \\ &= \delta\end{aligned}$$

$$\begin{aligned}\mathbb{E}[Y^0(2) - Y^0(1)|D = 0] &= (\alpha + \delta + \lambda \mathbb{E}\{X|D = 0\}) - (\alpha + \lambda \mathbb{E}\{X|D = 0\}) \\ &= \delta\end{aligned}$$

- Notar que estamos asumiendo que el efecto de λ no depende de t
 - Podríamos controlar por $X \cdot \text{time}$ si el efecto de x sobre Y varía con el tiempo
- Podríamos incluir efectos fijos (ejemplo: efecto fijo de individuo si tenemos datos de panel a nivel individual). Veremos esto con más detalle más adelante en esta clase.

Una aplicación de DiD

Ejemplo salarios mínimos: Card y Krueger (1994)

- El 1 de abril de 1992, Nueva Jersey elevó el mínimo estatal de \$ 4.25 a \$ 5.05, mientras que en el estado limítrofe de Pensilvania el salario mínimo se mantuvo en \$ 4.25 durante todo este período
- Card y Krueger (1994) evaluaron el efecto de este cambio en el empleo de trabajadores de bajos salarios. En un modelo competitivo el resultado de aumentar el salario mínimo es reducir el empleo
- Para esto hicieron una encuesta a unos 400 restaurantes de comida rápida de los dos estados justo antes de la reforma de NJ, y una segunda encuesta a los mismos puntos de venta 7-8 meses después

Ejemplo salarios mínimos

Características de los restaurantes de comida rápida:

- ① Gran fuente de empleo para trabajadores de bajos salarios.
- ② Cumplen la normativa de salario mínimo (especialmente las franquicias de restaurantes).
- ③ Trabajo bastante homogéneo (fácil de obtener buenas medidas de empleo y salarios)
- ④ Fácil de obtener una lista de restaurantes franquiciados (por medio de las páginas amarillas) con altas tasas de respuesta (tasas de respuesta: 87 % y 73 % - menos en Penn, porque el entrevistador era menos persistente?).

Ejemplo salarios mínimos

Estimador DiD:

- $\beta = [E(Y_2|D=1) - E(Y_1|D=1)] - [E(Y_2|D=0) - E(Y_1|D=0)]$
- Llamemos Y_1 e Y_2 al empleo antes y después de la reforma, respectivamente
- $D=1$: restaurantes en NJ (tratados), $D=0$ restaurantes den Penn (controles)
- β mide la diferencia entre el cambio promedio en el nivel de empleo en NJ y el cambio promedio en Penn
- El supuesto clave al dar una interpretación causal es que el efecto del tiempo en los dos estados es el mismo en ausencia de intervención

Ejemplo salarios mínimos

New Jersey

- Empleo en febrero: $E(Y_{ist}|s = NJ, t = Feb) = \gamma_{NJ} + \lambda_{Feb}$
- Empleo en noviembre: $E(Y_{ist}|s = NJ, t = Nov) = \gamma_{NJ} + \lambda_{Nov} + \beta$
- Diferencia entre noviembre y febrero:

$$E(Y_{ist}|s = NJ, t = Nov) - E(Y_{ist}|s = NJ, t = Feb) = \lambda_{Nov} - \lambda_{Feb} + \beta$$

Pensilvania

- Empleo en febrero: $E(Y_{ist}|s = PA, t = Feb) = \gamma_{PA} + \lambda_{Feb}$
- Empleo en noviembre: $E(Y_{ist}|s = PA, t = Nov) = \gamma_{PA} + \lambda_{Nov}$
- Diferencia entre noviembre y febrero

$$E(Y_{ist}|s = PA, t = Nov) - E(Y_{ist}|s = PA, t = Feb) = \lambda_{Nov} - \lambda_{Feb}$$

DiD

$$\begin{aligned}\hat{\beta} &= (E(Y_{ist}|s = NJ, t = Nov) - E(Y_{ist}|s = NJ, t = Feb)) \\ &\quad - (E(Y_{ist}|s = PA, t = Nov) - E(Y_{ist}|s = PA, t = Feb)) \\ &= (\lambda_{Nov} - \lambda_{Feb} + \beta) - (\lambda_{Nov} - \lambda_{Feb}) \\ &= \beta\end{aligned}$$

Ejemplo salarios mínimos

Table 5.2.1: Average employment per store before and after the New Jersey minimum wage increase

Variable	PA (i)	NJ (ii)	Difference, NJ-PA (iii)
1. FTE employment before, all available observations	23.33 (1.35)	20.44 (0.51)	-2.89 (1.44)
2. FTE employment after, all available observations	21.17 (0.94)	21.03 (0.52)	-0.14 (1.07)
3. Change in mean FTE employment	-2.16 (1.25)	0.59 (0.54)	2.76 (1.36)

Notes: Adapted from Card and Krueger (1994), Table 3. The table reports average full-time equivalent (FTE) employment at restaurants in Pennsylvania and New Jersey before and after a minimum wage increase in New Jersey. The sample consists of all stores with data on employment. Employment at six closed stores is set to zero. Employment at four temporarily closed stores is treated as missing. Standard errors are reported in parentheses

Ejemplo salarios mínimos

$$Y_{its} = \alpha + \gamma NJ_s + \delta Post_t + \beta(NJ \times Post)_{st} + \varepsilon_{its}$$

PA Pre: α

PA Post: $\alpha + \delta$

NJ Pre: $\alpha + \gamma$

NJ Post: $\alpha + \gamma + \delta + \beta$

$$\mathbf{DD} \rightarrow (NJ\ Post - NJ\ Pre) - (PA\ Post - PA\ Pre) = \beta$$

Ejemplo salarios mínimos

- Card y Krueger encontraron que el aumento del salario mínimo aumentó empleo en algunas de sus comparaciones, pero en ningún caso causó una reducción del empleo
- Este artículo originó mucho debate económico y político
- La estimación de DID se ha convertido en un método muy popular para obtener efecto causales (especialmente en los Estados Unidos, donde la estructura federal proporciona variación entre estados en cuando a la legislación)



Fuente: Scott Cunningham

Tests, placebos y SE

Test de tendencias previas paralelas


Si tenemos observaciones de varios períodos previos al tratamiento, podemos usar solo datos del período antes de la intervención para testear si hay diferencias previas en tendencias entre los dos grupos (tratamiento y control)

$$Y_{it} = \alpha + \delta time_t + \gamma D_i + \beta D_i \cdot time_t + \epsilon_{it}$$

$$H_0 : \beta = 0$$

- Notar que necesitamos varios períodos para poder estimar estas tendencias
- Problema: bajo poder para detectar diferencias...


¿Y si las tendencias no fueran paralelas?



En ese caso la identificación vendría por desviaciones de la tendencia previa

¿Y si las tendencias no fueran paralelas?

$$Y_{st} = \alpha + \gamma D_s + \delta time + \beta D_s \cdot Post_t + D_s \cdot time + e_{st}$$



- Podríamos poner efectos fijos de estado y de año
- Tendencia específica están capturadas por θ_k :

$$Y_{st} = \alpha + \sum_k \beta_k STATE_{ks} + \sum_{j=1971}^{1983} \gamma_j YEAR_{jt} + \beta D_s \cdot Post_t + \sum_k \theta_k (STATE_{ks} \times t) + e_{st}$$

Placebos

Hacer pruebas placebo (de falsificación) usando:

- ① variables de resultados alternativas que no deberían ser afectadas por el tratamiento
- ② hacer análisis usando datos de períodos anteriores (momentos ficticios de implementación del tratamiento)
 - ① ¡En este placebo no incluir períodos post tratamiento!

Errores estándar

- 1 DiD es un caso especial de datos de panel: Tenemos varias observaciones de la misma unidad $\rightarrow$ correlación serial
- 2 Además posiblemente haya correlación dentro de grupos (ej. individuos que viven en un mismo estado de US, o que van a la misma escuela)
- Por estos dos problemas, los errores estándar convencionales a menudo subestiman severamente la desviación estándar de los estimadores, por lo que los errores estándar están sesgados hacia abajo (es decir, incorrectamente pequeños)

Ver Bertrand et al. [2004]

Errores estándar: agregar los datos y cluster SE

Correlación serial

- Posible solución: **agregar** los datos en dos períodos (antes y después de la intervención)

Correlación dentro de grupos

- Posibles soluciones:
 - **agregar** los datos a un nivel superior
 - **cluster SE:** permitir un estructura de varianza-covarianza sin restricción temporal dentro de los grupos definidos a nivel de la correlación (ej. estados).
 - En Stata esto se implementa de manera directa mediante el uso de la opción «**cluster**» (en el ejemplo de estados, eligiendo como nivel de cluster los estados completos y no solo las celdas año-estado). Tener en cuenta que esto funciona solo cuando N (número de clusters) es suficientemente grande (N más grande de 50).
 - Esta es la estrategia mas usual

«Extras»

Triple diferencias en diferencias (DDD)

En algunos casos nos encontramos con una diferencia en las tendencias que podemos corregirla usando un segundo grupo de control y un DiD «placebo»

	<i>Pre</i>	<i>Post</i>	<i>Diferencia</i>
<i>Tratado</i>	$\alpha + \gamma$	$\alpha + \delta + \eta + \gamma + \beta$	$\delta + \eta + \beta$
<i>No tratado</i>	α	$\alpha + \delta$	δ
<i>Diferencia</i>	γ	$\eta + \gamma + \beta$	$\eta + \beta$

	<i>Pre</i>	<i>Post</i>	<i>Diferencia</i>
<i>Placebo tratado</i>	$\alpha + \gamma$	$\alpha + \delta + \eta + \gamma$	$\delta + \eta$
<i>Placebo no tratado</i>	α	$\alpha + \delta$	δ
<i>Placebo diferencia</i>	γ	$\eta + \gamma$	η

β^{DDD} : El estimador DDD es la diferencia entre el DD de interés y un DD placebo

Triple diferencias en diferencias (DDD)

$$Y_{ijt} = \alpha + \beta_1 X_{ijt} + \beta_2 \tau_t + \beta_3 \delta_j + \beta_4 D_i + \beta_5 (\delta \times \tau)_{jt} \\ + \beta_6 (\tau \times D)_{ti} + \beta_7 (\delta \times D)_{ij} + \beta_8 (\delta \times \tau \times D)_{ijt} + \varepsilon_{ijt}$$

El estimador DDD es la diferencia entre el DD de interés y un DD placebo

Cuidado con los cambios de composición

- Cambios de composición de la muestra cuando usamos datos repetidos de corte transversal (cross-sectional data):
 - DD puede aplicarse a secciones transversales repetidas, así como a datos de panel. Pero uno de los riesgos de trabajar con cortes transversales es que a diferencia de los datos de panel (por ejemplo, datos de panel de nivel individual), corremos el riesgo de cambios en la composición de la muestra

Intensidad del tratamiento

- Variaciones en la intensidad del tratamiento: podemos interactuar la variable de tratamiento con una variable de intensidad para explotar variación en la intensidad del tratamiento

SUTVA


Recordar siempre verificar/discutir que:

- Se cumple la condición SUTVA (Stable Unit Treatment Value assumption)
 - "las observaciones del grupo de control no se ven afectadas por el tratamiento"
 - ¿posibles violaciones de esta condición?
- No hay efecto anticipación
 - ¿posibles violaciones de esta condición?

Efectos dinámicos

- También podemos analizar si el efecto del tratamiento cambia a medida que pasa el tiempo luego de la intervención: $\sum_{\tau=0}^m \delta_{\tau} D_{s\tau}$
- Podríamos tener un modelo que incluya los dos puntos:

$$Y_{its} = \alpha + \gamma_s + \delta_t + \sum_{\tau=-q}^{-1} \gamma_{\tau} D_{s\tau} + \sum_{\tau=0}^m \beta_{\tau} D_{s\tau} + X_{ist} + \varepsilon_{ist}$$



Relación entre DiD & estudio de eventos

$$Y_{it} = \alpha + \delta Post_t + \gamma Tratado_i + \beta Tratado_i \cdot Post_t + \epsilon_{it}$$

Aquí voy a usar esta notación: $D = Tratado * Post$

- Si tenemos datos de panel, podemos generalizar esta especificación incluyendo un conjunto de efectos fijos de individuo (α_i , que capturaría la variable «tratado») y uno de tiempo (δ_t , capturarían «Post»):

$$Y_{it} = \alpha_i + \delta_t + \beta D_{it} + \epsilon_{it}$$

- ¿Qué pasa si las unidades tratadas entran al tratamiento en diferentes momentos?: i.e. D_{it} pasa de 0 a 1 en diferentes momentos para diferentes i (y puede ser siempre 0 o 1).
 - ¡Podemos usar esa misma especificación!
 - obtendremos un promedio del efecto para todos los tratados en nuestro período de análisis.

Relación entre DiD & estudio de eventos

$$Y_{it} = \alpha_i + \delta_t + \beta D_{it} + \epsilon_{it}$$

- Un modelo más general permite efectos diferenciados a lo largo del tiempo:

$$Y_{it} = \alpha_i + \delta_t + \sum_{-S}^R \beta_{\tau} D_i * 1\{\text{períodos hasta/desde el tratamiento} = \tau\} + \epsilon_{it}$$

- S: número de períodos pre tratamiento (lo ideal es que los β_{τ} sean cero antes del tratamiento)
- R: número de períodos post tratamiento
- Notar que la diferencia con lo que vemos en la clase de estudios de eventos es que aquí tenemos la posibilidad de tener un grupo de control de «nunca tratados»

Más ejemplos con aplicaciones de DiD

The impact of a social program on labor informality: The case of AUH in Argentina - Garganta y Gasparini (2015)

Garganta y Gasparini (2015) examinan el impacto de la AUH sobre la informalidad laboral

- ITT DiD
- Datos: EPH (panel rotativo)

Garganta y Gasparini (2015)

- **Tratados:** desempleados y no registrados en el período inicial de cada panel, con edades entre 18 y 70 años, pertenecientes a hogares informales (es decir, hogares sin trabajadores registrados) con niños menores de 18 años
- **Control:** trabajadores con las mismas características que el grupo de tratados potenciales excepto porque en el hogar no hay menores de 18 años (la presencia de niños menores de 18 años constituye la variable crucial que determina la elegibilidad para el grupo de trabajadores no registrados)
- **Pre y post** intervención: 2005-2009 y 2010-2011

Garganta y Gasparini (2015)

- Supuesto de identificación: en ausencia de la AUH las tendencias de la tasa de formalización laboral para los grupos de tratamiento y control habría sido similar

$$F_{it} = \alpha + \beta_1 H_{it} + \beta_2 Post + \gamma (H_{it} Post) + \theta X_{it} + u_{it}$$

- F: formalización (si un empleado informal se formaliza)
- H: Grupo tratado (con hijos)

Garganta y Gasparini (2015)

- **Resultados:** El programa podría desalentar las transiciones de los trabajadores al sector formal. Los autores encuentran que desincentiva la formalización del mercado laboral de los beneficiarios

Figure 1: Proportion of informal workers that become formal




Table 3: Effect of the AUH on the probability of becoming formal

	(1)	(2)	(3)
With_Children * After	-0.0765*** (0.0184)	-0.0695*** (0.0167)	-0.0842*** (0.0187)
With_Children (<i>H</i>)	0.0385*** (0.0123)	0.0472*** (0.0132)	0.0807*** (0.0184)
After (<i>Post</i>)	0.108*** (0.0276)	0.152*** (0.0229)	0.116*** (0.0446)
With controls, time and regional dummies	No	Yes	Yes
Excluding the unemployed	No	No	Yes
Observations	16,635	16,635	13,777
Pseudo R2	0.005	0.086	0.096

Source: Authors' calculation based on EPH microdata, 2005-2011.

Berniell, de la Mata y Machado (2019)

Título: The Impact of a Permanent Income Shock on the Situation of Women in the Household: the case of a pension reform in Argentina

- Many countries have implemented social programs to fight poverty, that are changing the relative income of spouses.
 - these transfer programs do not only redistribute income between households but also alter the distribution of income within households.
- Non-contributory pensions: potentially higher impact on women.
 - Ideal settings to analyze impact of **asymmetric permanent income** shocks within the household.

Berniell, de la Mata y Machado (2019)

Título: The Impact of a Permanent Income Shock on the Situation of Women in the Household: the case of a pension reform in Argentina

- Many countries have implemented social programs to fight poverty, that are changing the relative income of spouses.
 - these transfer programs do not only redistribute income between households but also alter the distribution of income within households.
- Non-contributory pensions: potentially higher impact on women.
 - Ideal settings to analyze impact of **asymmetric permanent income** shocks within the household.
- This paper focus on **senior** women and ask:

*Can permanent transfers (from non-contributory pensions) affect their **marital status** and their **bargaining power** within the household despite their perceived stable lives?*

Empirical Strategy: Diff-in-Diff

Pre and post-treatment periods

- Pre-treatment years: 2004-2006
- Post-treatment years: 2007-2009.

Control and treated groups

- Treated group: Cohorts of women born between 1941-1944
- Control group: Cohorts of women born between 1950-1953.

Women	Pre treatment (2004-2006)	Post treatment (2007-2009)
TREATED born 1941-1944	ages 60-65	ages 63-68
CONTROL born 1950-1953	ages 51-56	ages 54-59

Note: control group is not affected by the reform during sample period.


Empirical Strategy: Diff-in-Diff

$$y_{i,t} = \alpha + \beta \text{Treat}_i \times \text{Post}_t + \delta_i^C + \delta_t^{YQ} + X_i' \gamma + \epsilon_{i,t} \quad (1)$$


- y is the outcome of interest
 - $\text{Treat} = 1$ if woman born in 1941-1944.
 - $\text{Post} = 1$ if outcome observed in 2007-2009.
 - δ^C and δ^{YQ} are cohort and year-quarter FE, respectively.
 - X individual characteristics (e.g. education, born abroad, regional dummies; and for married sample: age and educational differences within couples -proxy for previous bargaining power- and indicator of husband being above legal retirement-age).
 - β is the diff-in-diff estimate of the effect of the moratorium (ITT).
- Data: EPH

Results: Effects of the reform on Income


Pension recipients




Women without personal income



Monthly personal income (logs)



Wife's share of income within the couple



Effects on Divorce/Separation

	Prob. divorced/separated
Post*treated	0.027
p-value	(0.002)***
p-value wild bootstrap-t	(0.095)*
Observations	34,039
Obs. treatment	12,554
Mean dep. var.	0.14
% change	19.21%

In parentheses are two-tail p-values clustered by urban area. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. "p-value" indicates the stata outcome for two-tail p-values clustered at the urban area level. "p-value wild bootstrap" indicates two-tail p-values computed using wild bootstrap-t techniques as in Cameron et al. 2008 with a 6-point distribution as in Webb 2013 and 1500 bootstraps. Controlling for cohort dummies, year-quarter fixed effects, region fixed effects, dummy for top 1 percent of personal income, dummy for high school diploma. Sample weights using variable pondera in the EPH.

Presencia policial: Di Tella y Schargrodsky (2004)

- Rafael Di Tella and Ernesto Schargrodsky. 2004. "Do Police Reduce Crime? Estimates Using the Allocation of Police Forces After a Terrorist Attack." American Economic Review
- El artículo estudia, empíricamente, el efecto causal de la presencia policial en la reducción del crimen.
- Tras el ataque terrorista en el principal centro judío en Buenos Aires en julio de 1994, todas las instituciones judías recibieron protección policial.
- Es decir que ese suceso indujo una asignación geográfica de las fuerzas policiales que se puede presumir exógena.

Di Tella y Schargrodsky (2004)




FIGURE 1. TIMELINE OF EVENTS

- Usando datos sobre la ubicación de los robos de automóviles antes y después del ataque, los autores encuentran un gran efecto disuasivo de la presencia policial sobre el crimen.

Di Tella y Schargrodsky (2004)

$$\text{Robo de autos}_{it} = \alpha_0 + \beta * \text{Misma cuadra} * \text{Policía}_{it} + M_t + F_i + \epsilon_{it}$$

- M_t : efecto fijo del mes t
- F_i : efecto fijo de la cuadra i
- $\text{Misma cuadra} * \text{Policía}_{it}$: variable que asume el valor 1 para los meses posteriores al terrorismo si hay una institución protegida en esa cuadra y es 0 para el resto de los casos.

	number of car thefts per month per block
<i>Same-Block Police</i>	-0.07752*** (0.022)
Block fixed effect	Yes
Month fixed effect	Yes
Number of observations	7,884
R^2	0.1983

Aplicación en Stata

Ejemplo aplicación en Stata

- Datos y programas del paper de Card y Krueger (1994) disponibles en:

<http://economics.mit.edu/faculty/angrist/data1/mhe/card>