

Diseño de Regresión Discontinua

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Mayo 2020

Hoy - Estimación de efectos causales a partir de un diseño no-experimental: **Regresión Discontinua (RD)**

- **RD:** es una de las estrategias no experimentales más creíbles para estimar efectos causales con datos observacionales (aunque tiene la desventaja de que el efecto estimado es local).

Caso para un diseño de regresión discontinua:

- todas las unidades tienen un score (puntuación asignada),
 - la probabilidad de que el tratamiento sea asignado a una unidad específica aumenta abruptamente para las unidades que tienen un puntaje superior a un punto de corte ("cutoff").
 - lo podemos pensar como una «aleatorización» del tratamiento a nivel «local».

Regresión discontinua

Ejemplos de reglas con “cortes arbitrarios” que darían lugar a experimentos naturales para ser analizados con un diseño de RD:

- nota para aprobar un examen
- nota para ganar una beca/premio
- edad para entrar a la escuela
- edad para conducir

¿Otro ejemplo de una regla de este estilo?

RD: idea y supuestos de identificación

- **Idea:** Si las unidades no pueden manipular su puntaje alrededor del punto de corte, esa discontinuidad en la probabilidad de recibir el tratamiento puede ser usada para aprender sobre el efecto causal (local) del tratamiento, usando a las unidades que están justo por debajo del punto de corte como contrafactuales (controles) para las unidades que están justo por arriba del punto de corte
- **Supuesto de identificación:** El supuesto básico es que las unidades que están justo por arriba y justo por debajo del cutoff son comparables entre sí en todos los aspectos relevantes, excepto por el hecho de que algunas son tratadas y otras no

Regresión discontinua: componentes

- Hay n **unidades**, indexadas por $i = 1, 2, \dots, n$,
- Cada unidad tiene un **puntaje** (score): X_i
 - en inglés también conocida como “running variable” o “forcing variable”
- **Punto de corte** (cutoff): c
- Asignación al grupo de **tratamiento**
 - La probabilidad de ser asignado al tratamiento en función del puntaje (X) cambia de forma discontinua en el punto de corte ($X=c$)
 - $T=1$ si $X \geq c$ y $T=0$ si $X < c$
 - $$Y_i = \begin{cases} Y_i(0) & \text{si } X_i < c \\ Y_i(1) & \text{si } X_i \geq c \end{cases}$$

Regresión discontinua: tipos

① **Sharp:** el cumplimiento con la asignación del tratamiento es perfecto

- todas las unidades con puntaje igual o mayor que el punto de corte reciben el tratamiento, y todas las unidades con puntaje por debajo del corte no reciben el tratamiento

② **Fuzzy RD:** el cumplimiento con lo asignado es imperfecto, pero la probabilidad a ser tratado aumenta discontinuamente en el punto de corte

③ Algunos casos especiales de RD, que no cubriremos aquí pero cuya lógica es parecida a la que analizaremos:

- ① RD con múltiples puntos de corte
- ② RD geográficos
- ③ RD con una variable de puntaje discreta que asume pocos valores

SHARP RD

(discontinuidad nítida)

Ejemplo que vamos a analizar en esta clase: Meyersson (2014)

Meyersson (2014) analiza el efecto de la representación política islámica en los municipios de Turquía sobre el desempeño educativo de las mujeres

Econometrica, Vol. 82, No. 1 (January, 2014), 229–269

ISLAMIC RULE AND THE EMPOWERMENT OF THE POOR AND PIOUS

BY ERIK MEYERSSON¹

Does Islamic political control affect women's empowerment? Several countries have recently experienced Islamic parties coming to power through democratic elections. Due to strong support among religious conservatives, constituencies with Islamic rule often tend to exhibit poor women's rights. Whether this reflects a causal relationship or a spurious one has so far gone unexplored. I provide the first piece of evidence using a new and unique data set of Turkish municipalities. In 1994, an Islamic party won multiple municipal mayor seats across the country. Using a regression discontinuity (RD) design, I compare municipalities where this Islamic party barely won or lost elections. Despite negative raw correlations, the RD results reveal that, over a period of six years, Islamic rule increased female secular high school education. Corresponding effects for men are systematically smaller and less precise. In the longer run, the effect on female education remained persistent up to 17 years after, and also reduced adolescent marriages. An analysis of long-run political effects of Islamic rule shows increased female political participation and an overall decrease in Islamic political preferences. The results are consistent with an explanation that emphasizes the Islamic party's effectiveness in overcoming barriers to female entry for the poor and pious.


Ejemplo que vamos a analizar en esta clase: Meyersson (2014)

- **unidades** de análisis: municipalidades
- **puntaje**: margen de victoria del mayor partido islámico en el municipio en las elecciones de 1994 (variable “casi” continua)
 - % de votos del candidato islámico - % de votos del oponente mas fuerte
- **tratamiento**: victoria del partido islámico
- **punto de corte** es “0” ($c=0$)

Literatura de “close elections”: comienza en con Lee (2008) y Pettersson-Lidbom (2008)

Probabilidad de recibir el tratamiento: sharp RD

$$P(T_i = 1 | X_i = x)$$



Sharp RD

- Outcomes potenciales: $Y_i(1)$ y $Y_i(0)$
 - $Y_i(1)$: resultado que se observaría bajo tratamiento
 - $Y_i(0)$: resultado que se observaría sin tratamiento
- Son potenciales porque solo se observa uno de ellos. Si la unidad i recibe el tratamiento, observaremos $Y_i(1)$ y en ese caso $Y_i(0)$ permanecerá latente (no observado)
 - Así, el efecto del tratamiento a nivel individual es imposible de conocer

Sharp RD


- Lo que observamos para cada individuo es:

$$Y_i = (1 - T_i) \cdot Y_i(0) + T_i \cdot Y_i(1) = \begin{cases} Y_i(0) & \text{si } X_i < c \\ Y_i(1) & \text{si } X_i \geq c \end{cases}$$

- Y para el promedio podemos observar:

$$\mathbb{E}[Y_i|X_i] = \begin{cases} \mathbb{E}[Y_i(0)|X_i] & \text{if } X_i < c \\ \mathbb{E}[Y_i(1)|X_i] & \text{if } X_i \geq c \end{cases}$$

ATE (Average treatment effect): $E[Y_i(1)|X_i = x] - E[Y_i(0)|X_i = x]$



- Como no hay soporte común el análisis de RD se basa en la **extrapolación**: lo central es que podamos extrapolar correctamente para poder comparar control y tratamiento.
- ¿Dónde podemos hacer la mejor extrapolación? **¿En qué punto de la gráfica “casi” que vemos las dos curvas?: en $X=c$**

$$\tau_{\text{SRD}} = \mathbb{E}[Y_i(1) - Y_i(0)|X_i = c]$$

Sharp RD: ATE (Average treatment effect)

- ¿Dónde podemos hacer la mejor extrapolación?: en $X=c$
 - Las unidades que están antes y después de c son muy similares, excepto por el efecto del tratamiento.
 - Usando los resultados observados, en ese punto podríamos calcular bastante bien la distancia vertical entre ambas curvas

$$\tau_{\text{SRD}} = \underbrace{\mathbb{E}[Y_i(1) - Y_i(0) | X_i = c]}_{\text{No observable}} = \underbrace{\lim_{x \downarrow c} \mathbb{E}[Y_i | X_i = x]}_{\text{Observable}} - \underbrace{\lim_{x \uparrow c} \mathbb{E}[Y_i | X_i = x]}_{\text{Observable}}$$

Sharp RD: ATE

- Efecto (local) del tratamiento = $\tau_{SRD} = E[Y_i(1) - Y_i(0)|X_i = c]$

$$E[Y_i(1)|X_i \rightarrow c] - E[Y_i(0)|X_i \leftarrow c]$$

ATE en el cutoff ($E[Y_i(1)|T = 1] - E[Y_i(0)|T = 0]$)



Para que esto sea cierto, nos basamos en el supuesto de continuidad

$$\tau_{SRD} = \underbrace{\mathbb{E}[Y_i(1) - Y_i(0)|X_i = c]}_{\text{No observable}} = \underbrace{\lim_{x \downarrow c} \mathbb{E}[Y_i|X_i = x]}_{\text{Observable}} - \underbrace{\lim_{x \uparrow c} \mathbb{E}[Y_i|X_i = x]}_{\text{Observable}}$$

- τ_{SRD} nos dice cuál sería el cambio de resultado promedio para unidades con nivel de puntaje $X_i = c$ si cambiamos su estado de control a tratado

Sharp RD: validez interna y validez externa

- Validez interna: muy fuerte (local, en $X=c$)
- Validez externa: limitada
 - τ_{SRD} es una estimación local, poco informativo sobre los efectos del tratamiento a otros niveles del puntaje



Sharp RD: Implementación

① Análisis gráfico

- ① datos crudos
- ② datos suavizados

② Estimación

- ① datos usados en la estimación (ancho de banda)
- ② orden del polinomio
- ③ función de pesos

③ Tests de validez

- ① variables pre-determinadas y placebos
- ② continuidad de la densidad de X
- ③ puntos de corte artificiales
- ④ sensibilidad a la exclusión de observaciones
- ⑤ sensibilidad al ancho de banda

(1) Análisis gráfico

Algo muy bueno del análisis de RD es que podemos usar análisis gráficos, que hacen al análisis más transparente

Inspeccionaremos los datos de dos formas:

(a) Presentación de datos **crudos**


(b) Presentación de datos **suavizados** (elección de la ubicación de los bins y el ancho del intervalo)

Nos sirven para detectar «a ojo» la discontinuidad y ver la variabilidad en los datos

Análisis gráfico - (a) Datos crudos de Meyersson (2014)

Comenzamos el estudio inspeccionando los datos por medio de un análisis gráfico

- **unidades** de análisis: municipalidades
- **score**: margen de victoria del mayor partido islámico
- **tratamiento**: victoria del partido islámico
- **punto de corte** es "0" ($c=0$)
- **outcome**: desempeño educativo de las mujeres



Pero no se ve muy claro si hay o no una discontinuidad, ¿no?

Sharp RD: (b) Suavizando los datos


Es más útil agregar o “suavizar” los datos antes de graficarlos

El típico gráfico inicial de un análisis de RD presenta:

- Un **polinomio** global t , que es simplemente una aproximación suave a las funciones de regresión desconocidas basadas en una regresión polinómica de orden t , ajustado por separado arriba y debajo del punto de corte y usando todos los datos originales
- **Promedios** de las muestras **locales**, representados por puntos
 - los promedio locales se crean eligiendo primero intervalos disjuntos (“**bins**”) del puntaje y calculando la media del outcome para las observaciones que caen dentro de cada bin

Meyersson (2014)

Si con los datos de Meyersson (2014) usamos 20 bins de igual longitud en cada lado del punto de corte (40 intervalos de longitud 5), y calculamos sus medias, obtenemos lo siguiente:



(al gráfico también agregamos un polinomio global de orden 4 estimado por separado para las observaciones del tratamiento y del control)

Ahora se ve un poco más claro... Pero **¿Cómo elegir el tipo y la cantidad de bins de una manera transparente y óptima?**

Sharp RD: Eligiendo la ubicación de los bins

Hay dos tipos de bins:

- 1 los que tienen la **misma longitud** (“espaciados uniformemente”, **ES**)
- 2 los que contienen (más o menos) el **mismo número de observaciones** pero cuya longitud puede variar (“espaciados por cuantiles”, **QS**)

Hay un comando de Stata que nos ayuda a construir los bins


`rdplot`

Eligiendo la ubicación de los bins con rdplot


- usamos la opción binselect para elegir entre los métodos ES y QS (binselect = "qs" o binselect = "es")
- y la opción nbins se usa para definir el número de bins

```
. rdplot Y X, nbins(20 20) binselect(qs) ///  
> graph_options(graphregion(color(white))) ///  
> xtitle(Score) ytitle(Outcome))
```

Sharp RD: Eligiendo la ubicación de los bins



(a) 40 Evenly-Spaced Bins



(b) 40 Quantile-Spaced Bins

¿Cómo elegir el ancho del intervalo (número de bins)?

Cómo elegir el ancho del intervalo: balancear precisión y sesgo

- Intervalos muy chicos (# de K grande): estimación imprecisa
- Intervalos muy grandes (# de K chico): estimación poco informativa

Hay dos métodos para elegir el número de bins:

- 1 Integrated Mean Squared Error (IMSE) Method (default de Stata)
- 2 Mimicking Variance Method

Método para elegir el número de bins: Integrated Mean Squared Error (IMSE)

¿Cómo implementarlo en Stata?


- Usamos el comando `rdplot` omitiendo la opción `nbins = c(20 20)`, y así automáticamente por default este comando elige el número de bins óptimo de acuerdo al criterio IMSE

```
. rdplot Y X, binselect(es) ///  
> graph_options(graphregion(color(white))) ///  
> xtitle(Score) ytitle(Outcome))
```


Si queremos usar MVM, usamos la opción `binselect = "esmv"`

Si queremos usar MVM pero con QS bins: opción `binselect = "qsmv"`

Método para elegir el número de bins: Integrated Mean Squared Error (IMSE)



IMSE RD Plot with Evenly-Spaced Bins



IMSE RD Plot with Quantile-Spaced Bins

(2) Estimación

Debemos tomar las siguientes decisiones:

1. la función de **pesos** $K(\cdot)$
2. el **orden** del polinomio p
3. el **ancho** de banda h (datos usados para la estimación)

Sharp RD: Estimación

La estimación normalmente se lleva a cabo estimando regresiones (polinomios) para aproximar la función de regresión $E[Y_i | X_i = x]$ a cada lado del punto de corte (con diferentes pendientes a cada lado de “c”)

Podemos hacer esta estimación de forma conjunta

Caso lineal:

$$Y = \alpha + \tau \cdot T + \beta_1 \cdot (X - c) + \beta_2 \cdot (X - c) \cdot T + \epsilon$$

donde τ estima el efecto del tratamiento en $X=c$

Podemos incrementar el orden del polinomio. Por ej.:

$$Y = \alpha + \tau \cdot T + \beta_1 \cdot (X - c) + \beta_2 \cdot (X - c)^2 + \beta_3 \cdot (X - c) \cdot T + \beta_4 \cdot (X - c)^2 \cdot T + \epsilon$$

Sharp RD: Estimación

Cuestiones importantes:

- 1 ¿Cuál es el orden adecuado del polinomio?
- 2 ¿Hace falta usar todos los datos?


Cuando todas las observaciones se utilizan para la estimación, se dice que trabajamos con polinomios globales

Cuando la estimación emplea solo observaciones con puntajes cercanos al punto de corte, los polinomios son locales


Los métodos locales son ahora el estándar en el análisis empírico de RD.

- El estimador del RD se define en un punto local ($X=c$), así que los métodos globales pueden llevar a estimadores poco confiables

Local



Global: peligro!



Sharp RD: Estimación


Los métodos locales emplean solo observaciones cercanas al punto de corte para estimar regresiones a cada lado del punto de corte

- Como los métodos locales se enfocan en aproximar las funciones de regresión solo cerca del punto de corte, se emplean polinomios de orden bajo (generalmente lineal)
- Se usan observaciones que están entre $c - h$ y $c + h$, donde $h > 0$ es el “ancho de banda” que determina el área sobre el que se realiza el análisis
- Dentro de este ancho de banda, es común pesar las observaciones para garantizar que las observaciones más cercanas a c reciban más peso que las más alejadas
 - Los pesos están determinados por una función de Kernel $K(\cdot)$

Sharp RD: Estimación

La implementación requiere entonces de elegir:


1. la función de **pesos** $K(\cdot)$,
2. el **orden** del polinomio p (en general lo óptimo es lineal)
3. el **ancho** de banda h (“bandwidth”)



Nota: en la estimación se emplean los datos crudos, no los datos agrupados que sólo los usamos en el gráfico.

Estimación: (1) Elección de la función Kernel Function

La función kernel $K(\cdot)$ asigna pesos a cada observación basándose en la distancia entre el X_i y c . Lo recomendado es usar un kernel triangular




En la práctica, las estimaciones **no varían mucho con la función K elegida**

Estimación: (2) elección del orden del polinomio

Esta sí es una **decisión que importa**, y diferentes factores han llevado a los econométristas a **preferir** que el polinomio sea de grado 1 (**lineal**)

Estimación: (3) Selección de la cantidad de datos a usar (bandwidth, "h")

Figura: dos bandwidths diferentes (h1 vs h2)



La elección del ancho de banda implica balancear el sesgo y la varianza de la estimación

Sharp RD: Estimación

$$Y_i = \alpha_- + (X_i - c) \cdot \beta_- + \varepsilon_{-,i} \quad \Bigg| \quad Y_i = \alpha_+ + (X_i - c) \cdot \beta_+ + \varepsilon_{+,i}$$

Estimación del efecto del tratamiento:

$$\hat{\tau}_{\text{SRD}}(h_n) = \hat{\alpha}_+ - \hat{\alpha}_-$$

$$Y_i = \alpha + \tau_{\text{SRD}} \cdot T_i + (X_i - c) \cdot \beta_1 + T_i \cdot (X_i - c) \cdot \gamma_1 + \varepsilon_i, \quad -h_n \leq X_i \leq h_n$$

Sharp RD: Estimación en Stata

Supongamos (ad hoc) un bandwidth de 20 %, polinomio 1 y Kernel uniforme

```
. reg Y X if X < 0 & X >= -20
```

Source	SS	df	MS	Number of obs =	608
Model	1181.56011	1	1181.56011	F(1, 606) =	13.41
Residual	53411.5774	606	88.1379165	Prob > F =	0.0003
Total	54593.1375	607	89.939271	R-squared =	0.0216
				Adj R-squared =	0.0200
				Root MSE =	9.3882

Y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
X	-.2480689	.0677526	-3.66	0.000	-.3811272 -.1150105
_cons	12.62254	.7806026	16.17	0.000	11.08952 14.15555

```
. reg Y X if X >= 0 & X <= 20
```

Source	SS	df	MS	Number of obs =	280
Model	117.305392	1	117.305392	F(1, 278) =	1.40
Residual	23307.145	278	83.838651	Prob > F =	0.2379
Total	23424.4504	279	83.9586035	R-squared =	0.0050
				Adj R-squared =	0.0014
				Root MSE =	9.1563

Y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
X	-.1219474	.1030945	-1.18	0.238	-.3248925 .0809977
_cons	15.54961	.9457779	16.44	0.000	13.68781 17.41141

$$\tau_{SRD} = 15,549 - 12,622 = 2,927$$

Sharp RD: Estimación

Como dijimos antes, obtendríamos el mismo estimador puntual mediante una regresión lineal única:

```
gen T_X = X * T
```

```
reg Y X T T_X if X >= -20 & X <= 20
```

Source	SS	df	MS	Number of obs =	888
Model	1343.1216	3	447.7072	F(3, 884) =	5.16
Residual	76718.7224	884	86.785885	Prob > F =	0.0015
Total	78061.844	887	88.0065885	R-squared =	0.0172
				Adj R-squared =	0.0139
				Root MSE =	9.3159

Y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
X	-.2480689	.0672309	-3.69	0.000	-.3800197	-.1161181
T	2.927075	1.235287	2.37	0.018	.5026378	5.351512
T_X	.1261215	.1245877	1.01	0.312	-.1184008	.3706438
_cons	12.62254	.7745922	16.30	0.000	11.10228	14.14279

Estimación usando comando "rdrobust"

- Aunque la estimación por MCO es útil para la estimación puntual, los errores estándar proporcionados por esta rutina no son siempre válidos. Por lo tanto es mejor usar el paquete de software `rdrobust`, diseñado específicamente para análisis de RD
- Este paquete además incluye funciones para realizar la selección del ancho de banda óptimo

Estimación: comando de Stata “rdrobust”

```
rdrobust Y X, kernel(uniform) p(1) h(20)
```

Opciones:

- **p** para definir el orden del polinomio
- **kernel** para definir el kernel (uniforme, triangular, etc)
- **h** para elegir el ancho de banda manualmente
- Por default, rdrobust fija $c=0$, pero esto se puede cambiar usando la opción **c**

```
. rdrobust Y X, kernel(uniform) p(1) h(20)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	2629
			BW type =	Manual
Number of obs	2314	315	Kernel =	Uniform
Eff. Number of obs	608	280	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	20.000	20.000		
BW bias (b)	20.000	20.000		
rho (h/b)	1.000	1.000		

Outcome: Y. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
Conventional	2.9271	1.2345	2.3710	0.018	.507448 5.3467
Robust	-	-	1.6364	0.102	-.582163 6.47096

Estimación: eligiendo h con el comando “rdbwselect”

rdbwselect selecciona, basándose en los datos, el ancho de banda “óptimo”

```
. rdbwselect Y X, kernel(triangular) p(1) bwselect(mserd)
```

Bandwidth estimators for sharp RD local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	2629
			Kernel =	Triangular
			VCE method =	NN
Number of obs	2314	315		
Min of X	-100.000	0.051		
Max of X	-0.098	99.051		
Order est. (p)	1	1		
Order bias (q)	2	2		

Outcome: Y. Running variable: X.

Method	BW est. (h)		BW bias (b)	
	Left of c	Right of c	Left of c	Right of c
mserd	17.239	17.239	28.575	28.575

Sharp RD: Estimación

Podemos calcular el h óptimo usando directamente la opción `bwselect` en `rdrobust`, así:

```
. rdrobust Y X, kernel(triangular) p(1) bwselect(mserd)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	2629
			BW type =	mserd
Number of obs	2314	315	Kernel =	Triangular
Eff. Number of obs	529	266	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	17.239	17.239		
BW bias (b)	28.575	28.575		
rho (h/b)	0.603	0.603		

Outcome: Y. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	3.0195	1.4271	2.1159	0.034	.222516	5.81653
Robust	-	-	1.7758	0.076	-.30934	6.27579

Sharp RD: Errores estándar

Notar que el SE más conservador es el Robust SE

En Stata podemos estimar clustered SE usando la opción `vce(nncluster variable_de_cluster)`

```
rdrobust Y X, p(1) kernel(triangular) bwselect(mserd) vce(nncluster  
prov_num)
```


Sharp RD: incluyendo otras variables de control

- Si queremos incluir otras variables de control, notar que las variables usadas deben estar balanceadas entorno al punto de corte
- La estimación puntual no debería cambiar mucho al incluir covariables, pero sí podría mejorar la precisión
- `rdrobust Y X, covs(lista de covariates) p(1) kernel(triangular)
bwselect(mserd)`

Estimación: Representación gráfica

```
rdrobust Y X, p(1) kernel(triangular) bwselect(mserd)  
local bw = e(h_1)
```

```
rdplot Y X if abs(X) <= 'bw', p(1) h('bw') kernel(triangular)
```



(3) Tests de validez

Veremos 5 pruebas de validación

Sharp RD: Tests de validez

- Necesitamos validar el supuesto de que los resultados potenciales (promedios) son continuos en el punto de corte
- Por ejemplo, si el punto de corte es conocido por quienes serán potencialmente beneficiarios del tratamiento, debemos preocuparnos por la posibilidad de que haya manipulación del valor de su puntaje cuando estén cerca del punto de corte
- También puede haber un problema si otros tratamientos se activen en el mismo punto de corte (si por ejemplo se usan los mismos umbrales para diferentes programas sociales)
- Podemos testear formalmente si estos son o no problemas en nuestro diseño

Métodos que proporcionan evidencia indirecta sobre la validez del diseño RD

Veremos 5 pruebas de validación empírica basadas en:

- 1 chequear que “el efecto del tratamiento” es nulo sobre las **covariables** que están **predefinidas** antes del tratamiento o es nulo sobre variables en las que el tratamiento no debería tener ningún efecto (**placebos**)
- 2 chequear la continuidad de la **densidad** de puntaje alrededor del punto de corte
- 3 chequear que no hay “efecto” del tratamiento en **valores de corte artificiales**
- 4 chequear que la **exclusión de observaciones cerca del límite** no afecta tanto los resultados
- 5 analizar la sensibilidad de los resultados a las elecciones de **ancho de banda** (h)

(1) Covariables pre-determinadas y outcomes placebo

- Examinar si, cerca del punto de corte, las unidades tratadas son similares a las unidades de control en términos de características observables pre-determinadas
 - Las unidades justo arriba y justo debajo del corte deberían ser similares en todas las variables que no son afectadas por el tratamiento
- ¿Cómo lo chequeamos? Analizamos todas las covariables predeterminadas y los outcomes placebos de la misma manera en la que analizamos al outcome de interés
- Para cada una de estas variables elegimos primero un ancho de banda óptimo y luego hacemos el análisis de RD dentro de ese ancho de banda para analizar si hay un “efecto” del tratamiento en donde no debería haberlo

Análisis de continuidad para las covariables

Usando nuestro ejemplo empírico:


```
rdrobust lpop1994 X, p(1) kernel(triangular) bwselect(mserd)
```

lpop1994 es la población del municipio en 1994 (antes de las elecciones)


En un diseño RD convincente estas pruebas mostrarían que no hay discontinuidades en ninguna de esas variables

Variable	MSE-Optimal Bandwidth	RD Estimator	<u>Robust Inference</u>		Eff. Number Observations
			p-value	Conf. Int.	
Percentage of men aged 15-20 with high school education	12.055	1.561	0.358	[-1.757, 4.862]	590
Islamic Mayor in 1989	11.782	0.053	0.333	[-0.077, 0.228]	418
Islamic percentage of votes in 1994	13.940	0.603	0.711	[-2.794, 4.095]	668
Number of parties receiving votes 1994	12.166	-0.168	0.668	[-1.357, 0.869]	596
Log population in 1994	13.319	0.012	0.999	[-0.644, 0.645]	633
District center	13.033	-0.067	0.462	[-0.285, 0.130]	624
Province center	11.556	0.029	0.609	[-0.064, 0.109]	574
Sub-metro center	10.360	-0.016	0.572	[-0.114, 0.063]	513
Metro center	13.621	0.008	0.723	[-0.047, 0.068]	642


Análisis de continuidad para las covariables




(a) Log Population in 1994



(b) Number of Parties Receiving Votes in 1994



(c) Islamic Vote Percentage in 1994




(d) Islamic Mayor in 1989


(2) Densidad de la variable de puntaje

Aquí analizamos si el número de observaciones debajo del punto de corte es significativamente diferente del número de observaciones sobre el punto de corte

Si los potenciales beneficiarios no tienen la capacidad de manipular con precisión el valor del puntaje que reciben, el número de observaciones tratadas justo por encima y por debajo del corte debería ser aproximadamente similar



(a) No Sorting



(b) Sorting

(2) Densidad de la variable de puntaje

Podemos hacer un test Binomial en Stata:

Si, por ejemplo, en el caso del artículo de Meyersson nos quedamos con $X_i \in [-2, 2]$, tendremos 47 observaciones de control y 53 observaciones tratadas. Estableciendo una probabilidad de éxito igual a $1/2$, podemos realizar una prueba binomial:

```
. bitesti 100 53 1/2
```

N	Observed k	Expected k	Assumed p	Observed p
100	53	50	0.50000	0.53000

Pr(k >= 53)	= 0.308650	(one-sided test)
Pr(k <= 53)	= 0.757941	(one-sided test)
Pr(k <= 47 or k >= 53)	= 0.617299	(two-sided test)

$p=0.53$, por lo que esta simple prueba no muestra evidencia de manipulación alrededor del punto de corte

Test de densidad de CJM

- Hay tests de densidad más sofisticados (fácil de implementar en Stata)
 - Ej: rddensity implementa un test de densidad local (CJM)
- Usando los datos de Meyersson: rddensity X

```
. rddensity X
Computing data-driven bandwidth selectors.

RD Manipulation Test using local polynomial density estimation.
```

Cutoff c = 0	Left of c	Right of c	
Number of obs	2314	315	Number of obs = 2629
Eff. Number of obs	965	301	Model = unrestricted
Order est. (p)	2	2	BW method = comb
Order bias (q)	3	3	Kernel = triangular
BW est. (h)	30.540	28.285	VCE method = jackknife


Running variable: X.

Method	T	P> T
Robust	-1.3940	0.1633


- $t = -1.394$ (p-value 0.1633): no podemos rechazar la hipótesis nula de ausencia de diferencia en la densidad de las observaciones tratadas y de control en el punto de corte

Test de densidad de Cattaneo et al (CJM) , implementado en Stata vía: rddensity - Gráficos

```
rddensity X, plot plot_range(-'bandw_left' 'bandw_right')
```



(a) Histogram



(b) Estimated Density

Test de densidad

- Hay otros tests de densidad. En la clase de práctico verán el de McCrary, que también puede implementarse fácilmente en Stata
- La prueba de densidad para detectar la manipulación de RD fue propuesta por primera vez por McCrary (2008)
- El test de McCrary era el test estándar en el análisis de RD hasta hace poco, pero el nuevo test (2017) propuesto por Cattaneo et al (CJM) tiene mejores propiedades que el de McCrary

(3) Puntos de corte placebos

Idea: Probar si hay efectos significativos en valores de corte falsos

- Hacemos el mismo análisis que antes, pero suponiendo que el corte se da en otros valores diferentes al punto de corte real
 - Notar que para puntos de corte falsos que estén debajo del corte real, usaremos las observaciones del control y para los puntos de corte falsos que estén por arriba del corte, usaremos las observaciones del tratamiento

(3) Puntos de corte placebos

```
. rdrobust Y X if X >= 0, c(1)
```


Sharp RD estimates using local polynomial regression.

Cutoff c = 1	Left of c	Right of c	Number of obs =	315
			BW type =	mserd
Number of obs	30	285	Kernel =	Triangular
Eff. Number of obs	30	49	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	2.362	2.362		
BW bias (b)	3.326	3.326		
rho (h/b)	0.710	0.710		

Outcome: Y. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	-1.1306	4.2515	-0.2659	0.790	-9.46352	7.20222
Robust	-	-	0.2696	0.787	-9.96715	13.1469

Estimación real y placebos



(4) Sensibilidad a eliminar observaciones cerca del corte

Si hay una manipulación sistemática de los valores de puntaje, es natural suponer que las unidades más cercanas al punto de corte sean las que con mayor probabilidad se manipularon


La idea aquí es excluir esas unidades que están muy cerca al corte y repetir el análisis de estimación usando la muestra restante, para ver si los resultados se ven muy afectados

Ejemplo:

```
rdrobust Y X if abs(X) >= 0.3
```

Donut-Hole Radius	MSE-Optimal Bandwidth	RD Estimator	<u>Robust Inference</u>		Number of Observations	Excluded Obs.	
			p-value	Conf. Int.		Left	Right
0.00	17.239	3.020	0.076	[-0.309, 6.276]	795	0	0
0.10	17.954	3.081	0.064	[-0.175, 6.298]	815	1	1
0.20	16.621	3.337	0.052	[-0.033, 6.759]	765	5	4
0.30	16.043	3.414	0.055	[-0.067, 6.965]	730	7	6
0.40	17.164	3.286	0.050	[-0.001, 6.601]	774	9	9
0.50	15.422	3.745	0.028	[0.408, 7.292]	697	13	14

Sensibilidad a eliminar observaciones cerca del corte



Aquí vemos que los resultados casi no cambian al excluir observaciones cercanas, lo cual nos hace seguir creyendo en los resultados estimados por medio del análisis RD

(5) Sensibilidad a cambios en el ancho de banda

Aquí la idea es que realicemos la estimación variando el valor que toma el ancho de banda y veamos si los resultados cambian significativamente

```
rdrobust Y X, h('k')
```

- donde k va variando según el valor que toma el bandwidth

Resumen de la estimación de Sharp RD en Stata

- `rdbwselect`
 - se usa para seleccionar el ancho de banda basándonos en los datos (que hace que sea de forma transparente y “óptima”)
- `rdrobust`
 - se usa para la estimación e inferencia
- `rdplot`
 - se usa para el análisis gráfico de RD
- `rddensity`
 - proporciona pruebas de manipulación de la discontinuidad de densidad
- En el práctico verán formas alternativas de realizar estas estimaciones en Stata

Sharp RD con score discreto

RD cuando la variable de “puntaje” es discreta

- El diseño de RD canónico visto anteriormente supone que el puntaje que determina el tratamiento es una variable aleatoria continua
- Si el puntaje es discreto pero el número de puntos que asume es suficientemente grande, podemos seguir usando el mismo método analizado hasta aquí
- Ejemplo que analizaremos en donde X es una variable discreta: artículo de Lindo et al. (2010)

Ejemplo: Lindo et al. (2010)


En educación, en la práctica los puntajes de los exámenes son discretos

En el artículo de Lindo et al (2010):

- la unidad de análisis es el estudiante,
- el puntaje es el nota (GPA) del estudiante,
- el tratamiento de interés es si al estudiante se lo coloca en “un período de prueba”,
- el punto de corte es el valor de GPA que estandarizamos a $c=0$
- outcomes de interés:
 - la decisión del estudiante de dejar la universidad de forma permanente
 - nota (GPA) a largo plazo

Ejemplo: Lindo et al. (2010)

Primero debemos contar la cantidad de valores que asume X



Hay 44,362 observaciones que asumen 430 valores distintos

Luego chequeamos la densidad de X

rddensity X

Cutoff c = 0.00	Left of c	Right of c	Number of obs =	2629
			Order of poly =	0
Number of obs	2314	315	Kernel type =	uniform
Eff. Number of obs	68	62	Reps =	1000
Mean of outcome	13.972	15.044	Window =	set by user
S.D. of outcome	8.541	9.519	H0: tau =	0.000
Window	-2.500	2.500	Randomization =	fixed margins

Outcome: Y. Running variable: X.

Statistic	T	Finite sample	Large sample	
		P> T	P> T	Power vs d = 4.27
Diff. in means	1.072	0.497	0.501	0.765

Test placebo usando como outcome la nota en secundaria

```
. rdrobust hgrade_pct X
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	44362
			BW type =	mserd
Number of obs	37211	7151	Kernel =	Triangular
Eff. Number of obs	6115	3665	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	0.465	0.465		
BW bias (b)	0.759	0.759		
rho (h/b)	0.612	0.612		


Outcome: hgrade_pct. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	1.3282	1.0104	1.3145	0.189	-.652165	3.30865
Robust	-	-	1.2980	0.194	-.788018	3.87804

Parece que los estudiantes cuyo GPA está justo arriba y abajo del corte son similares en términos de su desempeño en la escuela secundaria (igual conclusión sacamos al hacer el análisis con otras variables predeterminadas)

Primero hacemos un análisis gráfico para inspeccionar el efecto del tratamiento

```
rdplot nextGPA_nonnorm X, binselect(esmv) ///  
graph_options(graphregion(color(white)) xtitle(Score) /// ytitle(Outcome))
```



Estimamos el efecto del tratamiento como lo hicimos antes

```
. rdrobust nextGPA_nonorm X, kernel(triangular) p(1) bwselect(mserd)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	40582
			BW type =	mserd
			Kernel =	Triangular
			VCE method =	NN
Number of obs	34854	5728		
Eff. Number of obs	5249	3038		
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	0.437	0.437		
BW bias (b)	0.717	0.717		
rho (h/b)	0.610	0.610		

Outcome: nextGPA_nonorm. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	.22212	.03956	5.6146	0.000	.144579	.299652
Robust	-	-	4.5718	0.000	.121721	.304402

Los estudiantes que son puestos en un período de prueba mejoran su GPA en el siguiente término en 0.22 puntos adicionales, en relación a los estudiantes que por poquito no entraron en el período de prueba

Fuzzy RD

The Fuzzy RD Design

Caso de “Fuzzy RD”: Cuando algunas unidades no cumplen con la condición de tratamiento que se les asigna:

- algunas de las unidades con $X_i \geq c$ no reciben el tratamiento y/o algunas de las unidades con $X_i < c$ reciben el tratamiento,
- pero la probabilidad de recibir tratamiento igual salta significativamente en el punto de corte c


Ahora usaremos la variable D_i para indicar si la unidad i es realmente tratada

- Para algunas unidades $T_i \neq D_i$


Probabilidad de ser tratado: Sharp vs Fuzzy RD

Probabilidad condicional de recibir el tratamiento dado el puntaje X:

$$P(D_i = 1 | X_i = x)$$



(a) Sharp RD



(b) Fuzzy RD (One-Sided)

Fuzzy RD en el contexto de variables instrumentales

- Con lo que aprendimos para un Sharp RD, podríamos estimar τ_{ITT}
 - $Y = \alpha_{ITT} + \tau_{ITT}D + f_{ITT}(X - c) + \epsilon_{ITT} \rightarrow$ efecto “ITT”
- Pero nosotros estamos interesados en estimar τ
 - $Y = \alpha + \tau D + f(X - c) + \epsilon$ (1)
 - Problema: D es endógeno
- Se puede pensar en T como una variable instrumental para D en un modelo de regresión para Y en X y D
 - $D = \gamma + \delta T + g(X - c) + v$ (2)
- 1 Primera etapa: estimamos ecuación (2)
- 2 Segunda etapa: estimamos ecuación (1) usando la estimación $\hat{D}$

Supuestos de identificación

Ahora la identificación del efecto del tratamiento estará basada en:

- “**Restricción de exclusión**”: la asignación al tratamiento (T) afecta al outcome (Y) **sólo** porque esta asignación induce un cambio en el tratamiento efectivo (D) que a su vez afecta a Y
- Condición de **monotonicidad**: una unidad con puntaje X que rechaza el tratamiento cuando el corte es c también debe rechazar el tratamiento para cualquier punto de corte mayor a c , y una unidad que toma el tratamiento cuando el corte es c también debe tomar el tratamiento para cualquier punto de corte menor c

LATE

Estimaremos el efecto promedio sobre los “cumplidores” (población que se ve afectada por la regla)

- Podremos identificar el efecto promedio del tratamiento en el punto de corte para el subconjunto de unidades que obedecen a la asignación del tratamiento, es decir, para las unidades que sí toman el tratamiento cuando su puntaje está por encima del corte y rechazan el tratamiento cuando su puntaje está por debajo del corte (LATE)

Implementación en Stata

- El proceso de implementación en Stata es igual al que hemos analizado anteriormente, solo que ahora usaremos la opción “fuzzy()”

```
rdrobust Y X, fuzzy(D)
```

- donde Y es el outcome de interés, D el estatus de tratamiento real y X la variable de puntaje (suponemos $T=1$ si $X \geq 0$)
- Veremos también una aplicación en Stata

Comandos

RDROBUST:

net install rdrobust, from(<https://sites.google.com/site/rdpackages/rdrobust/stata>) replace

RDDENSITY:

net install rddensity, from(<https://sites.google.com/site/rdpackages/rddensity/stata>) replace