

Método de Emparejamiento

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Mayo 2020

Método de emparejamiento

- Intuitivamente, el método de emparejamiento permite encontrar para cada individuo en el programa (tratado), otro «idéntico», excepto por la participación en el programa (control)
 - Comparamos individuos que son similares en características observables (predeterminadas!)
- La comparación funciona bajo la presunción de que para $X = x$ hay una variación «aleatoria» en D , de modo que «podemos observar tanto Y_1 como Y_0 »
- La selección en el programa se basa en características o variables observables únicamente y que son observadas por el investigador

Supuesto de identificación: (1) Independencia condicional (CI)

Independencia condicional («selection-on-observables»): $Y_0, Y_1 \perp D|X, \quad \forall X$

- La participación no está determinada por variables no observadas, sino que se atribuyen exclusivamente a variables observables del individuo
- Supuesto muy fuerte; su violación puede inducir a sesgos en el estimador de emparejamiento. Pero, si se cumple, podemos encontrar el ATT simplemente «controlando por X »

- $$E[Y_{1i}|X_i, D_i = 1] - E[Y_{0i}|X_i, D_i = 0] = E[Y_{1i} - Y_{0i}|X_i, D_i = 1] + E[Y_{0i}|X_i, D_i = 1] - E[Y_{0i}|X_i, D_i = 0]$$

- La CI dice que condicionando a un conjunto de características observadas X_i ese sesgo desaparece

- $E[Y_{0i}|X_i, D_i = 1] = E[Y_{0i}|X_i, D_i = 0]$
- entonces $E[Y_{1i}|X_i, D_i = 1] - E[Y_{0i}|X_i, D_i = 0] = E[Y_{1i} - Y_{0i}|X_i, D_i = 1]$

Supuesto: Independencia condicional (CI)

La CI resuelve el problema de sesgo de selección, pero obtenemos efectos causales por separado para cada X_i . Si buscamos una única medida de resumen podríamos calcular el efecto causal promedio de la población

$$E \{ E [Y_{1i} - Y_{0i} | X_i] \}$$

o sobre los tratados (ATET)

ATE y ATET

$$\begin{aligned}\alpha_{ATE} &= E(Y_1 - Y_0) = \int E(Y_1 - Y_0|X) dF(X) \\ &= \int [E(Y|D=1, X) - E(Y|D=0, X)] dF(X)\end{aligned}$$

$$\begin{aligned}\alpha_{ATET} &= E(Y_1 - Y_0) = \int E(Y_1 - Y_0|X) dF(X) \\ &= \int [E(Y|D=1, X) - E(Y|D=0, X)] dF(X|D=1)\end{aligned}$$

Notar: La mayor parte de la literatura se centró en los efectos promedio, pero también sirve para comparaciones distributivas

ATE y ATET

Supongamos que X toma K valores (celdas) diferentes $(X_1, \dots, X_k, \dots, X_K)$

Entonces, por el principio del análogo tenemos los siguientes estimadores:

$$\hat{\alpha}_{AIE} = \sum_{k=1}^K \left(\bar{Y}_1^k - \bar{Y}_0^k \right) \cdot \left(\frac{N^k}{N} \right)$$

$$\hat{\alpha}_{ATET} = \sum_{k=1}^K \left(\bar{Y}_1^k - \bar{Y}_0^k \right) \cdot \left(\frac{N_1^k}{N_1} \right)$$

- N^k es el # de observaciones en la celda k
- N_1^k es el # de observaciones de tratados en la celda k
- $\bar{Y}_1^k$ es el resultado promedio para el grupo de tratados en la celda k
- $\bar{Y}_0^k$ es el resultado promedio para los no tratados en la celda k

Usarlo con cuidado

- Los métodos de emparejamiento no deben aplicarse solo porque no existe una solución experimental o cuasi experimental para estimar los efectos del tratamiento. Deben aplicarse solo cuando el supuesto de selección sobre observables es factible

La maldición de la dimensionalidad

- Subclasificar las observaciones se vuelve inviable con muchas covariables
- Buscar una coincidencia exacta puede no ser factible si la muestra es pequeña, el conjunto de covariables es grande y muchas de ellas asumen múltiples valores o son continuas
- Si tenemos k covariables y dividimos cada una de ellas en 3 categorías (por ejemplo, la edad podría ser "joven", "mediana edad" o "adulto", y el ingreso podría ser "bajo", "medio" o "alto"), el número de celdas es 3^k
 - Para $k = 10$ (k es el número de variables, y 3 las categorías en cada variable), obtenemos $3^{10} = 59049$
- Muchas celdas pueden contener solo observaciones tratadas o no tratadas, y no podríamos usar este sistema de subclasificación para estimar efectos causales
- La subclasificación también es problemática si las celdas son "demasiado anchas"
 - Pero el uso de celdas "más finas" empeora el problema de la «maldición de la dimensionalidad»!

Matching (Nearest Neighbor)

Match exacto: Pasos ATET

- 1 estratificar los datos en celdas definidas por cada valor particular de X
- 2 dentro de cada celda (es decir, condicionamiento en X) calcular la diferencia entre los resultados promedio de los tratados y los controles
- 3 promediar estas diferencias con respecto a la distribución de X en la población de unidades tratadas.

Matching: el ejemplo ideal

Trainees		
unit	age	earnings
1	28	17700
2	34	10200
3	29	14400
4	25	20800
5	29	6100
6	23	28600
7	33	21900
8	27	28800
9	31	20300
10	26	28100
11	25	9400
12	27	14300
13	29	12500
14	24	19700
15	25	10100
16	43	10700
17	28	11500
18	27	10700
19	28	16300
Average:	28.5	16426


Non-Trainees		
unit	age	earnings
1	43	20900
2	50	31000
3	30	21000
4	27	9300
5	54	41100
6	48	29800
7	39	42000
8	28	8800
9	24	25500
10	33	15500
11	26	400
12	31	26600
13	26	16500
14	34	24200
15	25	23300
16	24	9700
17	29	6200
18	35	30200
19	32	17800
20	23	9500
21	32	25900
Average:	33	20724

Matched Sample		
unit	age	earnings
8	28	8800
14	34	24200
17	29	6200
15	25	23300
17	29	6200
20	23	9500
10	33	15500
4	27	9300
12	31	26600
11,13	26	8450
15	25	23300
4	27	9300
17	29	6200
9,16	24	17700
15	25	23300
1	43	20900
8	28	8800
4	27	9300
8	28	8800
Average:		


Matching: el ejemplo ideal

Trainees			Non-Trainees			Matched Sample		
unit	age	earnings	unit	age	earnings	unit	age	earnings
1	28	17700	1	43	20900	8	28	8800
2	34	10200	2	50	31000	14	34	24200
3	29	14400	3	30	21000	17	29	6200
4	25	20800	4	27	9300	15	25	23300
5	29	6100	5	54	41100	17	29	6200
6	23	28600	6	48	29800	20	23	9500
7	33	21900	7	39	42000	10	33	15500
8	27	28800	8	28	8800	4	27	9300
9	31	20300	9	24	25500	12	31	26600
10	26	28100	10	33	15500	11,13	26	8450
11	25	9400	11	26	400	15	25	23300
12	27	14300	12	31	26600	4	27	9300
13	29	12500	13	26	16500	17	29	6200
14	24	19700	14	34	24200	9,16	24	17700
15	25	10100	15	25	23300	15	25	23300
16	43	10700	16	24	9700	1	43	20900
17	28	11500	17	29	6200	8	28	8800
18	27	10700	18	35	30200	4	27	9300
19	28	16300	19	32	17800	8	28	8800
Average:	28.5	16426	20	23	9500	Average:	28.5	13982
			21	32	25900			
			Average:	33	20724			

Distribución por edad: antes de emparejar



Distribución por edad: después de emparejar



Matching: el ejemplo ideal

Diferencia en los ingresos promedios entre aprendices y no aprendices:

- Antes del emparejamiento: $16426 - 20724 = -4298$
- Después del emparejamiento: $16426 - 13982 = 2444$

Matching: el ejemplo ideal

- Cuando el vector de covariables X tiene más de una dimensión ($k > 1$) necesitamos definir una métrica de distancia para medir la "cercanía" (ej. distancia euclidiana)
- Es difícil encontrar buenas coincidencias en grandes dimensiones: necesitamos muchas observaciones si k es grande
- Solución: Propensity score methods (lo veremos en unas slides más adelante)

Matching con reemplazo en Stata

`nnmatch`: Nearest Neighbor Matching Estimation for Average Treatment Effects

```
ssc install nnmatch
```

```
nnmatch depvar treatvar varlist_nnmatch
```

- `nnmatch Y D X1 X2 ...`

`m` especifica el número de coincidencias que se harán por observación:

- `nnmatch Y D X1 X2 ..., m(2)`

ATET (default es ATE):

- `nnmatch Y D X1 X2 ..., tc(att)`
 - (default is normalized Euclidean)

Coincidencias exactas para algunas covariables:

Propensity Score Matching (PSM)

Estimando la probabilidad de participación en el programa

- Como dijimos, la implementación del estimador es compleja cuando el vector de variables observables X tiene una dimensión muy grande (difícil encontrar individuos con valores similares, 'parejas', en todas las dimensiones de X)
- Solución: emparejar individuos con base en: $P(X) = P(D = 1|X)$
 - Usar la probabilidad estimada de participación en el programa dadas sus características observables (propensity score)
 - Podemos hacer coincidir unidades con valores muy diferentes de X siempre que tengan valores similares de $p(X)$
- IC supuesto de identificación: Si $(Y_1, Y_0) \perp D|X \rightarrow (Y_1, Y_0) \perp D|p(X)$
- Condicionar por $p(X)$ es suficiente para tener independencia entre el indicador de tratamiento y el resultado potencial
- Hay una reducción sustancial de la dimensión!: El match se hace en base a una variable « $p(X)$ »

Propensity Score Matching

$$E[Y_1 - Y_0 | p(X)] = E[Y | D = 1, p(X)] - E[Y | D = 0, p(X)]$$


Procedimiento de dos etapas:

- ① Estimar la «puntuación de propensión» $p(X) = P(D = 1 | X)$ (logit o probit)
- ② Hacer la «coincidencia/emparejamiento» sobre $p(X)$
 - ① idealmente emparejaríamos a tratados con controles con exactamente el mismo $p(X)$ estimado
 - ② calcularíamos el efecto del tratamiento para cada valor de $p(X)$
 - ③ calcularíamos el promedio de estos efectos
 - ④ Esto no es factible de forma exacta en la práctica porque es raro encontrar dos unidades con exactamente el mismo $p(X)$, pero se puede hacer por
 - ① Estratificación en $p(X)$
 - ② Emparejamiento con el vecino con score más cercano
 - ③ Radio en $P(X)$
 - ④ Kernel

Condición para construir un buen grupo de control

- Comencemos por estimar $p(X)$ y entender qué condiciones cumple un buen control
 - Cualquier combinación de características observadas en el grupo de tratamiento debe existir también en el grupo de control
 - Un control adecuado para un individuo en el grupo de tratamiento es aquel que tiene una probabilidad de participar en el programa muy parecida

Soporte común



- El emparejamiento por probabilidad de participación (PSM) sólo debe calcularse sobre la región de soporte común, esto asegura que el grupo de tratamiento y el de control sean parecidos

Soporte común ¿Qué implica en la estimación?

- Para la estimación se toman aquellos individuos que de acuerdo con sus variables observables muestran probabilidades no cero de ser tanto participantes como no participantes
- Así los individuos del grupo de control son aquellos que tienen probabilidades de participación parecidas a las de los individuos en el grupo de tratamiento

Estimador de PSM

- Asumiendo que se cumplen las condiciones de independencia condicional y de soporte común, el estimador del efecto promedio del programa sobre los tratados de PSM está dado por:

$$\tau_{ATT}^{PSM} = E_{P(X)|D=1} \{ E[Y(1)|D=1, P(X)] - E[Y(0)|D=0, P(X)] \}$$

- Promedio ponderado de las diferencias entre corchetes, donde los ponderadores son funciones de probabilidad de participación en el programa. Para individuos con $P(X)$ similares, se restan las diferencias entre tratados y no tratados, y se agrega ponderando por las probabilidades de participación

Información necesaria para aplicar un PSM

- En términos de datos y contextos para que el PSM funcione:
- 1 Debe contener la información de las variables independientes relevantes
 - 2 La evidencia preliminar debe indicar que no hay muchas diferencias entre los dos grupos en términos de las variables observables; de lo contrario, habría evidencia de que también pueden ser diferentes en variables no observables (y va a ser difícil tener un soporte común)
 - 3 Los métodos de emparejamiento son confiables siempre que no existan razones para pensar que las variables no observables determinan fundamentalmente la participación en el programa, como por ejemplo sucede cuando la motivación es clave en la participación

Algoritmo de PSM

Algoritmo de PSM

- 1 Estimar la probabilidad de participar en el programa, utilizando tanto el grupo de tratamiento como el de control
- 2 Estimar la probabilidad de participación predicha para cada individuo
- 3 Restringir la muestra al soporte común
- 4 Seleccionar el algoritmo de emparejamiento
- 5 Observar que las variables observables entre el grupo de control y de tratamiento estén balanceadas en términos de probabilidades
- 6 Calcular el impacto del programa

Propensity Score: Estimación

1) Estimar la probabilidad de participar en el programa

- 1 Estimar la probabilidad de participar en el programa, utilizando tanto el grupo de tratamiento como el de control

- 1 ¿Qué variables incluir?

- La estimación de $P(X)$ sólo debe incluir variables que afectan la decisión de participación y la variable de resultado
- Recordar que la variable de resultado deben ser independiente del tratamiento, una vez se condiciona por la probabilidad de participación (independencia condicional)

2) Estimación de la probabilidad de participación

- 1 Estimar la probabilidad de participación predicha para cada individuo

Estimamos $D_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_K X_{Ki} + u_i$

- D_i : Dummy si la unidad i es tratada

Predecimos $\hat{P}(X_i) = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \dots + \hat{\beta}_K X_{Ki} \rightarrow$ Caracterización de la unidad i según su probabilidad de participación en el programa

Stata: pscore - matching por estratos

```
findit pscore
```

pscore estimates the propensity score (pscore) of the treatment on varlist (the control variables) using a probit (or logit) model and stratifies individuals in blocks according to the pscore

```
pscore treat varlist , pscore(newvar)
```


```
pscore treat age age2, pscore(mypscore) logit blockid(myblock)
```

Restringir la muestra a una con soporte común

3) Restringir la muestra al soporte común

¿Cómo chequear soporte común ?

1. Inspección visual de las distribuciones de densidad de la probabilidad estimada de participación



3) Restringir la muestra al soporte común

Probabilidades estimadas de participación

	1	2	3	4	5	6	7	8	9	10
Tratamiento	0.40	0.48	0.54	0.65	0.75	0.76	0.77	0.8	0.86	0.9
Control	0.21	0.30	0.38	0.42	0.52	0.55	0.59	0.62	0.65	0.77

Eliminando las personas que no hacen parte del soporte común (aquí se pierden tres observaciones de cada lado)

3) Restringir la muestra al soporte común

2. Criterio de mínimo y máximo: Elimina observaciones inferiores al mínimo y mayores al máximo del otro grupo (no es infalible, ver siguiente figura. . .)

3. Elegir variables de la probabilidad estimada de participación para los cuales hay densidad positiva en los dos grupos.

Algoritmo de emparejamiento: (1) Estimación por estratificación

Selección del algoritmo de emparejamiento: Estimación por estratificación

Se hace una partición en el espacio de las probabilidades estimadas y se divide en estratos (rangos de probabilidad de participación)

$$\tau_{ATT}^{PSM-ESTRATO_i} = \text{Promedio}(Y_i | D = 1) - \text{Promedio}(Y_{C(i)} | D = 0)$$

- Impacto en cada estrato calculado como la diferencia promedio en la variable de resultado entre los grupos de tratamiento y de control
- Dentro de los estratos la probabilidad de participar debe estar balanceada (de lo contrario, hay que dividir en más estratos) y se debe chequear que las variables observables estén balanceadas
- ATT: promedio del efecto sobre cada estrato ponderado por la proporción de tratados en el soporte común.

Stata: ATET por matching por estratos

```
atts re75 treat, pscore(myscore) blockid(myblock)
```

- Help de Stata: «atts estimates the average treatment effect on the treated (ATT) using stratification matching; users have to provide the name of a variable specifying the estimated propensity score and the name of a variable specifying a block identifier of the estimated propensity score, both of which can be produced with pscore»

$$\bullet \tau_q^S = \frac{\sum_{i \in I(q)} Y_i^T}{N_q^T} - \frac{\sum_{j \in I(q)} Y_j^C}{N_q^C}$$

$$\bullet \tau^S = \sum_{q=1}^Q \tau_q^S \frac{\sum_{i \in I(q)} D_i}{\sum_{\forall i} D_i}$$

- el peso para cada bloque viene dado por la fracción correspondiente de unidades tratadas y Q es el número de bloques

Estimación del ATET por el vecino más cercano, radio y emparejamiento por Kernel


Lo más cercano que podemos llegar a una coincidencia exacta es hacer coincidir cada unidad tratada con «el control más cercano» en términos de $p(X)$

- Métodos (con/sin reemplazo)
 - Vecino más cercano
 - Radio/distancia máxima
 - Coincidencia de kernel

Algoritmo de emparejamiento: (2) Vecino más cercano, (3) radio/distancia máxima

Estimación del ATET por el vecino más cercano

- Vecino más cercano con el reemplazo: unidades de control pueden aparecer más de una vez
- Sea $C(i)$ el conjunto de unidades de control emparejadas con la unidad tratada i con un valor estimado de la puntuación de propensión de p_i
 - $C(i) = \{j \in D = 0 \mid \arg \min_j \|p_i(X) - p_j(X)\|\}$




Estimación del ATET por radio o distancia máxima

$$C(i) = \{p_j | \|p_i - p_j\| < r\}$$

- Radio, con reemplazo

- Para cada unidad tratada, encontrar todas las unidades de control cuyo $p(X)$ difiera en menos de una tolerancia dada « r » elegida por el investigador y permitir el reemplazo de las unidades de control

$C(i) = \{j \in D = 0 | \|p_i(X) - p_j(X)\| \leq k\}$, que contendrá tantos elementos como individuos del grupo de control haya dentro del nivel de tolerancia



Estimación del ATET por el vecino más cercano y por radio

La fórmula para ambos tipos de estimadores se puede escribir de la siguiente manera

$$\begin{aligned}\tau &= \frac{1}{N^T} \sum_{i \in T} \left[Y_i^T - \sum_{j \in C(i)} w_{ij} Y_j^C \right] \\ &= \frac{1}{N^T} \left[\sum_{i \in T} Y_i^T - \sum_{i \in T} \sum_{j \in C(i)} w_{ij} Y_j^C \right] \\ &= \frac{1}{N^T} \sum_{i \in T} Y_i^T - \frac{1}{N^T} \sum_{j \in C} w_j Y_j^C\end{aligned}$$

con $w_{ij} = \frac{1}{N_i^C}$ si $j \in C(i)$ y $w_{ij} = 0$ si no, $w_j = \sum_i w_{ij}$ y el número de unidades en el grupo tratado se denota por N^T

Estimación del ATET por el vecino más cercano y por radio en Stata

«Estimation of the average treatment effect on the treated using nearest neighbor matching»:

`attnd`

```
attnd outcome treatment , pscore(scorevar) logit
```

```
attnd re75 treat age age2, pscore(mypscore) logit blockid(myblock)
```

«Calculate the average treatment effect on the treated using radius matching»: `attr`

```
attr outcome treatment , pscore(scorevar) logit radius(#)
```

```
attnd re75 treat age age2, pscore(mypscore) logit blockid(myblock)  
radius(0.01)
```

Algoritmo de emparejamiento: (4) Kernel

Estimación del ATET por medio de Kernel

Cada unidad tratada se compara con un promedio ponderado de todas las unidades de control con pesos que son inversamente proporcionales a la distancia entre los $p(X)$ de la tratada y los controles

Selección del algoritmo de emparejamiento: Estimador PSM por Kernel

Emparejamiento por Kernel: Diferencia entre la variable objetivo del individuo del grupo de tratamiento y el promedio ponderado de la variable objetivo en todo el grupo de control


$$\tau_{ATT}^{PSM-KERNEL,LL} = \frac{1}{n} \left\{ \sum_{i \in D=1} [(Y_i | D = 1) - \sum_{j \in D=0} w_{ij} (Y_j | D = 0)] \right\}$$

$$w_{ij}^{KERNEL} = \frac{G\left(\frac{P_j(X) - P_i(X)}{\alpha_n}\right)}{\sum_{k \in D=0} G\left(\frac{P_k(X) - P_i(X)}{\alpha_n}\right)}$$

- G : Función Kernel (uniforme, triangular, gaussiana, ...)
- α_n : Ancho de la banda
- n : Número de individuos en el grupo de tratamiento
- Los pesos usados para calcular el contrafactual dependen del tipo de Kernel elegido


Selección del algoritmo de emparejamiento: (4) Estimador PSM por Kernel

Por Kernel: Pesos con Kernel triangular




Selección del algoritmo de emparejamiento: (4) Estimador PSM por Kernel

Por Kernel: Pesos con Kernel gaussiano



Selección del algoritmo de emparejamiento: (4) Estimador PSM por Kernel

Pesos con Kernel Epanechnikov



Estimación del ATET por medio de Kernel en Stata: attk

```
attk outcome treatment , pscore(scorevar)
```

```
attk re75 treat age age2, pscore(mypscore) logit
```

Pruebas de falsificación

Falsificación

- El supuesto de independencia condicional, $E(u|D) = 0$, permite la identificación en PSM
- El supuesto de independencia condicional no tiene implicaciones que se puedan comprobar directamente en los datos $\rightarrow$ No es posible determinar de manera directa si se cumple o no
- Pruebas de falsificación: ejercicios para evaluar si la estrategia de identificación tiene validez
- Imbens y Rubin (2010) sugieren dos tipos de pruebas de falsificación:
 - 1 Estimar el efecto del programa sobre una variable de resultado ficticia, que no puede ser afectada por el tratamiento (seudo-resultado)
 - 2 Estimar el efecto causal de una intervención ficticia que se sabe no debería tener efectos en nuestra variable de resultado (seudo-tratamiento)