

Métodos de Evaluación de Impacto de Políticas Públicas

Clase 1: Introducción. El problema fundamental de la evaluación

María Laura Alzua

UNLP

- Interés creciente en evaluar políticas públicas de manera cuantitativa
 - 1. cuestiones de política
 - 2. accountability
 - 3. cuestiones metodológicas
- Experimentos clínicos y programas sociales
- Nuevas herramientas econométricas
- Contribución a la economía aplicada: problemas de identificación
- Descubrir mecanismos causales

Por qué evaluar?

- Tres razones:

- 1 Motivación para aquellos con recursos a invertir o donar más fondos
- 2 Para saber cómo gastar recursos limitados
- 3 Para saber cómo mejorar programas existentes

- Cuando hacemos evaluación de impacto, siempre buscamos el efecto causal de una intervención: qué medir y cómo? (forma de medición y atribución del efecto)
- Efecto del cambio en el número de alumnos por clase en el rendimiento académico
- Efecto de los programas de entrenamiento laboral en la probabilidad de conseguir empleo
- Efecto de la provisión de agua y saneamiento en la mortalidad infantil

Evaluación y resultados potenciales

- En las ciencias sociales, la mayoría de las preguntas empíricas dependen del efecto causal de políticas
- Queremos evaluar el efecto de la exposición de ciertas unidades (individuos, hogares, firmas, provincias, países, etc.) a un programa o tratamiento (programas de entrenamiento laboral, medicina, tecnología, etc.).
- El objeto de interés es la comparación de dos unidades, con y sin tratamiento. Problema, sólo observamos al agente en un estado. (Holland, 1996)
- Hay que comparar distintas unidades con distintos niveles de tratamiento. Bajo qué supuestos es esa comparación válida?
- Literatura estadística, originada con la aparición de experimentos aleatorizados (Fisher, 1935 y otros)
- Rubin (1973-1978) interpretación de los efectos causales en forma de "resultados potenciales "

Modelo Causal de Rubin (RCM) - *Revisited* Imbens (2009)

- Para un individuo $i = 1, \dots, N$, podemos definir la existencia de dos "resultados potenciales": (Y_0, Y_1)
- Definimos $D = 1$ "recibir la intervención" y $D = 0$ "no recibir la intervención". ej.: participar de un programa de entrenamiento laboral
- $D = 0$ debido a que no fueron elegidos o decidieron no participar.
- El resultado observado es:

$$\begin{aligned} Y &= DY_1 + (1 - D)Y_0 \\ &= \begin{cases} Y_0 & \text{si } D = 0 \\ Y_1 & \text{si } D = 1 \end{cases} \end{aligned}$$

Ventajas sobre los resultados utilizando valores

"observados "

- Permite definir efectos causales sin necesidad de especificar la forma de asignación o de hacer supuestos sobre la forma funcional o la distribución

*Por ejemplo, queremos ver $Y_1 - Y_0$, es más general que en el entorno de regresión tradicional: $Y_i = \alpha + \tau W_i + \epsilon_i$
(efectos heterogéneos, supuestos sobre el error, forma funcional, etc.)*

- Permite vincular el análisis del efecto causal a una manipulación explícita del tratamiento: Ejemplo: discriminación en el mercado laboral. La comparación de resultados por género es difícil de interpretar. Sin embargo, podemos estimar un efecto causal si específicamente manipulamos el "tratamiento". (Bertrand & Mullhainathan 2004)

Ventajas...

- Separa la modelación del resultado potencial de la del mecanismo de asignación. Cuando se estudia en términos de resultados observados, se mezclan los resultados potenciales con los mecanismos de asignación.

Ejemplo: Programa de entrenamiento laboral, necesitamos modelar Y_0 , ingresos en ausencia de programa. Podemos postular que Y_0 depende de características individuales e historias laborales. O podemos postular que la elección de participar en el programa depende de características individuales e historias laborales. Finalmente podemos postular la probabilidad de participar en el programa, condicional a características individuales. Terminaremos con un modelo de Y "observado", pero mediante un mecanismo distinto.

Ventajas...

- Podemos formular supuestos probabilísticos basados en resultados observados (ej.: prob. de participación dada la historia laboral) y no en términos de componentes no observados. (CIA o supuesto de independencia condicional)
- Permite clarificar de dónde viene la incertidumbre en el estimador: ej.: con acceso a bases de datos que permiten evaluar a toda la población (en lugar de muestras), podemos estimar las medias poblacionales sin error, el error proviene del hecho de que como máximo observamos un resultado potencial por individuo (cuando estimamos los efectos causales).

El problema de la evaluación

- Suponemos por simplicidad que hay dos estados, correspondientes a estar o no bajo tratamiento.
- Definimos $D = 1$ "recibir la intervención" y $D = 0$ "no recibir la intervención".
- Y_1 es el resultado potencial en el estado "tratado" e Y_0 en el no tratado.
- A cada individuo, le podemos asociar un par (Y_0, Y_1) que representan los resultados que se observarían en los dos estados. (Resultados: salarios, empleo, indicadores de salud, educacionales, etc.)
- El problema de la evaluación es que una persona sólo puede estar en un estado a la vez.
- Necesito construir un "contrafáctico" válido para imputar la variable de interés en ausencia de la intervención.

- El resultado observado es:

$$Y = DY_1 + (1 - D)Y_0$$

- La ganancia para un individuo de ir del "estado de no tratamiento " al de "tratamiento " es:

$$\Delta = Y_1 - Y_0$$

- Esta "ganancia " no es observada para ningún individuo ("missing data ")
- Para inferir las ganancias de un tratamiento, la literatura de evaluación de impacto ha desarrollado distintas metodologías.

Parámetros de interés (Heckman, Smith y Lalonde)

- Cuando evaluamos un programa social existen varios parámetros de interés: p.ej.: beneficios para los participantes, efectos en los no beneficiarios, costos del programa, etc.
 - Ejemplo: *Consideremos los efectos de un subsidio a la demanda para aumentar la escolaridad. Si los subsidios son grandes, podemos esperar efectos en las familias. También puede tener efectos en las flías. no participantes, a través de cambios en las escuelas a las que asisten niños no participantes y que son inducidos por el programa. A su vez, si el programa está financiado por impuestos, los efectos pueden incluir un desincentivo a trabajar debido a impuestos más altos en los no participantes.*
- Es importante distinguir entre *efectos directos* (efectos sobre los participantes) y *efectos indirectos* (no directamente relacionados a la participación en el programa)
- En evaluación de impacto: efectos directos en los participantes + efectos de expandir el programa.

- En qué estamos interesados?

- 1 Proporción de participantes que se benefician del programa:
 $\Pr(Y_1 \geq Y_0 | D = 1) = \Pr(\Delta \geq 0 | D = 1)$
- 2 Proporción de la población total que se beneficia del programa:
 $\Pr(\Delta \geq 0 | D = 1) \Pr(D = 1)$
- 3 Impacto por cuantiles, en donde q es el cuantil seleccionado:
 $\inf_{\Delta} \{ \Delta : F(\Delta | D = 1) > q \}$
- 4 La distribución de las ganancias para individuos con características X_0 :
 $F(\Delta | D = 1, X = X_0)$, en donde X son características no afectadas por el programa tales como edad, sexo, educación, raza, nivel de pobreza antes de la intervención, etc.
- 5 Ganancias promedio del programa para personas con características X :
 $E(Y_1 - Y_0 | X) = E(\Delta | X)$ (Average Impact of Treatment, ATE)
- 6 Ganancia promedio del programa para participantes con características X :
 $E(Y_1 - Y_0 | D = 1, X) = E(\Delta | D = 1, X)$ (Average Impact of Treatment on the Treated, TT)

- Si los individuos que participan del programa son los que obtienen las ganancias más grandes, deberíamos esperar que:

$$TT(X) > ATE(X)$$

- Cuál es la diferencia entre $TT(X)$ y $ATE(X)$ y bajo qué condiciones $TT(X) = ATE(X)$?

Supongamos que los resultados en cada estado pueden escribirse como funciones aditivas y separables de observables (X) y no observables (U_0, U_1) :

$$Y_1 = \varphi_1(X) + U_1$$

$$Y_0 = \varphi_0(X) + U_0$$

en donde $Y = DY_1 + (1 - D)Y_0$ puede ser escrito como:

$$Y = \varphi_0(X) + D(\varphi_1(X) - \varphi_0(X)) + \{U_0 + D(U_1 - U_0)\}$$

- Si asumimos que $E(U_0|X) = E(U_1|X) = 0$, la ganancia de participación en el programa es: $\Delta = (\varphi_1(X) - \varphi_0(X)) + (U_1 - U_0)$.
- Los individuos pueden saber o no U_1 y U_0 en el momento de decidir participar o no del programa. Si la gente se autoselecciona en el programa, es de esperar que $E(U_0|X, D) \neq 0$ y $E(U_1|X, D) \neq 0$. Esto es, si la ganancia del programa depende de U_1 y U_0 y la gente conoce sus valores de U_1 y U_0 , o, puede de alguna manera predecir sus valores, deberíamos esperar que usaran esta información para elegir participar o no del programa.
- En la notación vista anteriormente, el $ATE = E(\Delta|X) = \varphi_1(X) - \varphi_0(X) + E(U_1|X) - E(U_0|X) = \varphi_1(X) - \varphi_0(X)$.
- El $TT = E(\Delta|X, D = 1) = \varphi_1(X) - \varphi_0(X) + E(U_1 - U_0|X, D = 1)$.
- También podemos definir el impacto medio en los no tratados como: $UT = E(\Delta|X, D = 0) = \varphi_1(X) - \varphi_0(X) + E(U_1 - U_0|X, D = 0)$.

- Si asumimos que $U_0 = U_1$, entonces $TT = ATE = UT$
- o si $E(U_1 - U_0|X, D) = 0$, en cuyo caso, D no es informativa acerca de $U_1 - U_0$, pero no necesariamente se verifica que $U_0 = U_1$.

Supuestos para el problema de la evaluación:

(A.1) condicional a X , el efecto del programa es el mismo para todos.

($U_0 = U_1$)

(A.2) el efecto del programa (dado X) varía a lo largo de los individuos pero $U_1 - U_0$ no me ayuda a predecir la participación en el programa

(A.3) el efecto del programa (dado X) varía a lo largo de los individuos pero $U_1 - U_0$ me ayuda a predecir la participación en el programa

(A.1) es la más restrictiva, (A.3) la más general. Vamos a estimar TT y ATE bajo los tres sets de supuestos.

Fuentes de sesgos

- Queremos estimar $TT = E(\Delta|X, D = 1)$ y $ATE = E(\Delta|X)$

- Re-escribiendo

$$\begin{aligned} Y &= \varphi_0(X) + D(\varphi_1(X) - \varphi_0(X)) + \{U_0 + D(U_1 - U_0)\} = \\ &\varphi_0(X) + D(E(\Delta|X)) + \{U_0 + D(U_1 - U_0)\} = \\ &\varphi_0(X) + D(E(\Delta|X)) + \{U_0 + D(U_1 - U_0)\} = \\ &= \varphi_0(X) + D(E(\Delta|X, D = \\ &1)) + \{U_0 + D[(U_1 - U_0) - E(U_1 - U_0|X, D = 1)]\} \end{aligned}$$

- Supongamos que las X son discretas y que podemos estimar los efectos de la intervención (D) mediante MCO.

$$y = aX + b_xXD + v$$

- Este modelo es muy aplicado en la práctica, conocido como "efectos comunes", y posee sesgos para estimar el ATE/TT si $E(U_0 + D(U_1 - U_0)|X, D) \neq 0$

Soluciones al problema de la evaluación

- Construcción del contrafáctico: qué supuestos necesito para que mi contrafáctico sea válido?
- Selección basada en observables
- Selección basada en no-observables:
 - 1 constante en el tiempo
 - 2 no constante en el tiempo

Tipos de evaluación de impacto de políticas públicas

- Usando datos que resultan de una asignación aleatoria: tamaño de la muestra, unidades lo suficientemente separables, efectos derrame y externalidades y efectos de equilibrio general, que los efectos no sean "demasiado" agregados, control sobre el proceso, planeadas en el momento del diseño del programa.
- Datos no experimentales, ex-ante y ex-post.
 - Evaluación ex-post usando datos no experimentales.
 - Evaluación ex-post con datos experimentales
 - Evaluación ex-ante.
 - Modelos estructurales
 - Aplicaciones
- La elección del método depende de tres factores:
 - 1 pregunta a ser respondida
 - 2 tipo de datos disponibles y su calidad
 - 3 mecanismo de asignación al programa/política

- En general, las regresiones se usan con datos "observacionales".
- Sin el beneficio de una asignación aleatoria, los coeficientes pueden o no tener una interpretación causal.
- Bajo qué condiciones los coeficientes de una regresión tienen una interpretación causal?
- Características del vector de regresión poblacional y su contraparte muestral, interpretación de los resultados por parte del investigador


Conceptos básicos para el análisis de regresión:

- Relación positiva entre años de educación e ingresos. Es causal?
- La educación "predice" ingresos en sentido estadístico. (CEF)
- La CEF para una variable y_i , dados un vector de $k \times 1$ variables explicativas X_i , (x_{ik}) es el valor esperado, o el promedio poblacional de y_i , con X_i fijos.

$$E[Y_i|X_i] = \left(\int t f_y(t|X_i=x) dt, \text{ para } Y_i \text{ continua} \right) \left(\sum_t t P(y_i=t|X_i=x), \text{ para } Y_i \text{ discreta} \right) (1)$$

- Como X_i son aleatorios, entonces (1) también lo es.
- (1) es un concepto poblacional.

Conceptos básicos para el análisis de regresión:



- Ley de expectativas iteradas: $E[Y_i] = E\{E[Y_i|X_i]\}$ (2)
- Descomposición de la CEF (teorema): $Y_i = E[Y_i|X_i] + \epsilon_i$, (3)

en donde ϵ_i es independiente de X_i , $E[\epsilon_i|X_i]$, y en consecuencia, ϵ_i no está correlacionado con cualquier función de X_i .

- Propiedad de predicción de la CEF:

Sea $m(X_i)$ una función cualquiera de X_i . La CEF satisface entonces:

$$E[Y_i|X_i] = \arg \min_{m(X_i)} E[(Y_i - m(X_i))^2] \quad (4),$$

es el predictor con el mínimo error cuadrático.


- ANOVA:

$$V(Y_i) = V(E[Y_i|X_i]) + E[V(Y_i|X_i)] = V(E[Y_i|X_i]) + E[\epsilon_i^2] \quad (5)$$

(la varianza de Y_i es la varianza de $E[Y_i|X_i]$ más la varianza de ϵ_i).

Conceptos....

- La validez de la regresión lineal no depende del supuesto de linealidad de la CEF. Incluso cuando la CEF es no lineal, el modelo de regresión lineal brinda la mejor aproximación "lineal" de la misma.



- En el caso de la regresión lineal, $m(X_i)$, es $X_i' b$

$$\beta = \arg \min_b E[(Y_i - X_i' b)^2]$$
$$E[X_i(Y_i - X_i' b)] = 0 \text{ (CPO)} \implies \beta = E[X_i X_i']^{-1} E[X_i y_i]$$

- Con un regresor solo y una constante: $\beta_1 = \frac{\text{Cov}(Y_i, x_i)}{V(x_i)}$ y $\alpha = E(Y_i) - \beta_1 E(X_i)$
- Con k regresores: $\beta_k = \frac{\text{Cov}(Y_i, \tilde{x}_i)}{V(\tilde{x}_i)}$, en donde $\tilde{x}_i$ es el residuo de la regresión de x_{ki} en todos los otros regresores.

- No conocemos la CEF, con lo cual hacemos inferencia basados en muestras.
- Esto nos permite interpretar los resultados de una regresión
- Queremos estimar la distribución en el análogo muestral de:
 $\beta = E[X_i X_i']^{-1} E[X_i y_i]$, más conocido como el estimador de MCO (OLS): $\hat{\beta} = [\sum X_i X_i']^{-1} \sum X_i y_i$
- La distribución de $\hat{\beta}$ es asintóticamente normal. (son funciones continuas de un vector de variables aleatorias con distribución asintótica normal), con media β y matriz de varianzas y covarianzas $E[X_i X_i']^{-1} E[X_i X_i' \epsilon_i^2] E[X_i X_i']^{-1}$
- Si se asume homocedasticidad, la matriz se transforma en $\sigma^2 E[X_i X_i']^{-1}$

- Una regresión es causal cuando la CEF que aproxima es causal.
- Es útil pensar en relaciones causales en términos de resultados potenciales para describir qué le pasaría a un individuo/situación, etc. en la comparación hipotética de escenarios alternativos.
- Por ejemplo: 1) Mejora los indicadores de salud asistir a un hospital?, 2) Problema de los retornos a la educación.
- Necesitamos que la variable causal de interés sea independiente de los potenciales resultados.
- Supuesto de Independencia Condicional (CIA): selección basada en observables.

- Resultados potenciales:

$$Y_{1i} \text{ si } D_i = 1$$

$$Y_{0i} \text{ si } D_i = 0$$

- El resultado observado (escrito en términos de resultados potenciales) puede escribirse como:

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i})D_i$$

Observamos Y_{1i} o Y_{0i} , pero nunca ambos. Esperamos medir un promedio para cierto grupo, $E[(Y_{1i} - Y_{0i}) | D_i = 1]$

Qué es lo que vemos con estudios de datos observacionales:

$$E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 0] =$$

Diferencia-observada

$$E[(Y_{1i} - Y_{0i})|D_i = 1] + E[Y_{0i}|D_i = 1] - E[Y_{0i}|D_i = 0]$$

TT

Sesgo-de-selección

(sumo y resto $E[Y_{0i}|D_i = 1]$)

- Con sesgo de selección positivo (negativo), la comparación naive $E[Y_{1i}|D_i = 1] - E[Y_{0i}|D_i = 0]$ sobrestima (subestima) el efecto que queremos medir
- La CIA dice que si condicionamos en características observadas, el sesgo de selección desaparece:

$$\{Y_{1i}, Y_{0i}\} \perp D_i | X_i \implies$$

$$E[Y_i|X_i, D_i = 1] - E[Y_i|X_i, D_i = 0] = E[Y_{1i} - Y_{0i}|X_i]$$

- Qué requisitos deben cumplirse para que el sesgo de selección sea eliminado?
- Sesgo de variables omitidas (OVB)

Ejemplo:

$$Y_i = \alpha + \rho s_i + \eta_i, (1)$$

η_i puede descomponerse en: $\eta_i = X_i' \gamma + v_i$.

Supongamos que las variables relevantes en la regresión (poblacional) para ver los efectos de los años de escolaridad en el ingreso pueden reducirse a una combinación de inteligencia, motivación y background familiar.

Llamemos a ese vector de controles A_i .

$$Y_i = \alpha + \rho s_i + A_i' \gamma + \epsilon_i (2)$$

Si la CIA es válida dado A_i entonces, ρ en (2) tiene la interpretación causal, en donde ϵ_i es el componente aleatorio de los ingresos.

- El problema es que no tenemos buenas medidas de A_i
- Qué pasa al estimar la regresión sin A_i ?
- Verdadero PGD= $y = x'\beta + z\alpha + v$
- Pero estimo $y = x'\beta + u$
- Ahora $u = z\alpha + v$
- v no está correlacionado con x , pero si z está correlacionado con x , tendremos sesgos.

- $\hat{\beta}_{ols} = (x'x)^{-1}(x'y)$
- $\hat{\beta}_{ols} = \beta + (N^{-1}x'x)^{-1}(N^{-1}x'z)\alpha + (N^{-1}x'x)^{-1}(N^{-1}x'v)$
- $\hat{\beta}_{ols} = \beta + \delta\alpha$
- $\delta = p\lim[(N^{-1}x'x)^{-1}(N^{-1}x'z)]$

CIA y Variables Omitidas:

$$\frac{\text{Cov}(Y_i, s_i)}{V(s_i)} = \rho + \gamma' \delta_{As}, \delta \text{ es el vector de coeficientes de la regresión de } A_i \text{ en } s_i.$$

Con la fórmula podemos darnos una idea del signo del sesgo.

Table 3.2.1: Estimates of the returns to education for men in the NLSY

	(1)	(2)	(3)	(4)	(5)
Controls:	None	Age dummies	Col. (2) and additional controls*	Col. (3) and AFQT score	Col. (4), with occupation dummies
	0.132 (0.007)	0.131 (0.007)	0.114 (0.007)	0.087 (0.009)	0.066 (0.010)

Notes: Data are from the National Longitudinal Survey of Youth (1979 cohort, 2002 survey). The table reports the coefficient on years of schooling in a regression of log wages on years of schooling and the indicated controls. Standard errors are shown in parentheses. The sample is restricted to men and weighted by NLSY sampling weights. The sample size is 2434.

*Additional controls are mother's and father's years of schooling and dummy

CIA: Qué controles elegimos?

- Variables que se consideren fijas a la hora de determinar el regresor de interés
- No incluir controles que sean variables resultados: p.ej.: sector ocupacional en la ecuación de educación e ingresos (se correlaciona tanto con educación como con ingresos)
- Variables proxy: p.ej.: notas académicas como proxies de cociente intelectual.

$$y_i = \alpha + \rho s_i + \gamma a_i + e_i \quad (1)$$

a_i es una medida de "habilidad temprana" tomada antes que las decisiones de escolaridad, entonces $E[s_i e_i] = E[a_i e_i] = 0$, por definición.

Pero a_i no está disponible, tenemos una medida de habilidad (a_{ji}) tomada luego de algunos años de escolaridad. a_{ji} se relaciona con a_i y con s_i .

$$a_{ji} = \pi_0 + \pi_1 s_i + \pi_2 a_i \quad (2)$$

CIA: Qué controles elegimos?

- **Problema:** tanto a_i como s_i aumentan a_{ji} . Despejando a_i de (2) y reemplazando en (1) obtenemos:

$$y_i = (\alpha - \gamma \frac{\pi_0}{\pi_2}) + (\rho - \gamma \frac{\pi_1}{\pi_2}) s_i + \frac{\gamma}{\pi_2} a_i + e_i \quad (3)$$

γ, π_1, π_2 son positivos, con lo cual $(\rho - \gamma \frac{\pi_1}{\pi_2})$ es pequeño, a menos que $\pi_1 = 0$. Esto es, una variable proxy que depende positivamente de nuestra variable de interés genera un coeficiente que está por debajo del efecto deseado. De todas maneras, dicho efecto puede ser investigado, regresando a_{ji} en s_i .

- Permite estimar "bounds" o cotas.

- Angrist J, y Pischchke, (2008), "Mostly Harmless Econometrics "
- Heckman, J., Lalonde, R. y Smith, J. (1999). The economics and econometrics of active labor market programs. Handbook of Labor Economics 3A.
- Capítulo de Imbens (2009), "Recent Developments in Program Evaluation"
- Angrist, Joshua and Alan Krueger. 1999. "Empirical Strategies in Labor Economics"

Evaluación de Políticas Públicas

UNLP

Buenos Aires, Argentina

March 10, 2020

Experimentos (Introducción)

- El diseño experimental aparece hoy como el “gold standard”
 - permite estimar efectos causales
 - esto es particularmente difícil con los datos que observamos en las ciencias sociales
 - “correlación no implica causalidad”

Experimentos (Introducción)

- Ir al hospital vs no ir al hospital
 - Estado general de salud (EGS), medido en una escala de 1 (muy enfermo) a 5 (muy saludable)

Grupo	N	EGS
Hospital	7,774	3.21
No-hospital	90,049	3.93

- Una diferencia de 0.72, grande y estadísticamente significativa ($t\text{-stat} = 58.9$)
- Debemos concluir que ir al hospital hace que la gente se enferme más?

Investigación Experimental (Introducción)

- Poco probable!
- Es más plausible que la gente que ha sido hospitalizada se debe a que en promedio, tengan un peor estado de salud que los que no.
- Comparamos dos grupos que son intrínsecamente diferentes y erróneamente atribuimos el efecto “ser hospitalizado” a la diferencia inicial en estado de salud.
 - esto es una mala inferencia
- Cómo podemos hacerlo mejor?

Investigación Experimental (Introducción)

- Los experimentos en economía en el siglo XXI son lo que los ensayos clínicos a la medicina en el siglo XX: una *revolución* (Duflo and Kremer 2003)
- Diseño Experimental: un espectro de métodos
 - factor común: asignación aleatoria del “tratamiento”
- pero ...la extrapolación a las ciencias sociales no es tan clara en términos de interpretación de resultados

- **Cómo funciona la asignación aleatoria?**

- asignar aleatoriamente una persona (o unidad) a 1 de 2 (o más) situaciones: con y sin tratamiento
- ejemplo 1: tirar una moneda, $\text{prob}(\text{ser asignado al tratamiento})=0.5$
- example 2: tirar un dado, si sale 1, 2, 3, o 4, asignar al tratamiento, 5 y 6 asignar a control: $\text{prob}(\text{ser asignado al tratamiento})=4/6=66\%$

- Por qué es una característica deseable?
 - todo el mundo (de la población de interés) enfrenta la *misma* probabilidad de ser asignado al tratamiento
 - en *promedio*, la gente (o unidades) del grupo de control son similares a las del de tratamiento (en factores observables y no observables)
 - la única diferencia es el tratamiento
 - puede medirse el efecto causal del tratamiento sin error

Investigación Experimental (Introducción)

- Aprender y testear teorías económicas a través de experimentos
 - Tomar decisiones de manera colectiva vs. individual
- Descubrir motivaciones e informar a los hacedores de política
- Aplicaciones múltiples a distintas áreas que afectan a países en desarrollo

- Distintas áreas y preguntas:

- Efecto de los vouchers para mejorar el acceso a una educación de calidad
- Efecto del seguro de desempleo en el esfuerzo de búsqueda de un nuevo empleo
- Efecto del entrenamiento laboral en el desempleo
- Son las mujeres más o menos competitivas que los hombres?
- Podemos explicar los distintos niveles de corrupción en el mundo como consecuencia de la calidad de las leyes o regulaciones?

Investigación experimental: distintas formas

- Experimentos de política
- Experimentos en campo (Field experiments)
- Experimentos en laboratorio (Lab experiments)

Experimentos de política vs. experimentos de campo

- Los experimentos de política están designados para aprender sobre la efectividad de una intervención:
 - El principal objetivo es saber si el programa debe expandirse, reformarse o incluso, terminarse.
- Son emprendimientos grandes y costosos

Un experimento en México: PROGRESA

- En 1997, el gobierno diseña un programa de lucha contra la pobreza con los siguientes componentes
 - transferencias monetarias focalizadas específicamente para familias pobres
 - suplementos nutricionales para embarazadas, bebés y niños
 - charlas informativas con mejores prácticas nutricionales, salud e higiene
 - con condicionalidades: asistencia escolar por parte de los niños y chequeos médicos

Un experimento en México: PROGRESA

- 506 comunidades rurales pobres, 24.000 hogares:
 - 320 comunidades asignadas aleatoriamente al grupo de tratamiento (comienzan a recibir transferencias en 1998) y 186 al grupo de control (se pospuso la transferencia por un año y medio)
 - Impactos de corto plazo en nutrición, educación y salud (todos positivos)
 - Continuación y expansión de los programas, a pesar de los cambios políticos
 - expansión a casi todos los países de América Latina y el Caribe, en NYC y en África y Asia

Conditional Cash Transfers in the World: 1997 and 2008

1997



2008



Conditional Cash Transfers in the World - 1997 and 2008

CLOSE X

Source: <http://go.worldbank.org/2NS1R2QIM0>

Experimentos de política vs. experimentos en campo

- Los experimentos de política se limitan a ver si el programa funciona o no
 - el programa comprende un paquete de incentivos (condicionalidad para la asistencia escolar, charlas sobre salud, complementos nutricionales, transferencias, focalización en mujeres, etc.)
 - en general no se sabe la efectividad de los componentes por separado
 - no busca explicar los mecanismos de transmisión
- Experimentos en campo (focalización en hombres vs. mujeres, cambiar frecuencia del beneficio, con y sin condicionalidades):
 - uso de la teoría (económica) para describir mecanismos o testear hipótesis

Experimentos de laboratorio vs. experimentos en campo

- Los experimentos de laboratorio suelen hacerse en un ambiente muy controlado.
- Ej., *gift exchange game*: si ofrezco salarios más altos, induciré un mayor esfuerzo?
 - quiero testear la siguiente hipótesis: los empleados responden a salarios más altos trabajando más
 - con datos observacionales: en general, el mercado premia a los empleados más productivos con salarios más altos
 - correlación positiva, pero no puede hablarse de causalidad
 - un experimento en laboratorio me permite ver estas dos historias
- Los experimentos de laboratorio son, si se quiere, un primer paso en la cadena entre teoría a experimento y luego política (y su impacto)
 - en el ejemplo anterior, la teoría tiene predicciones claras

Experimentos de laboratorio vs. experimentos en campo

- Los experimentos en laboratorio en general se hacen con estudiantes universitarios
 - bajo costo!
- El contexto en general se evita
 - No se les informa a los participantes que se quiere testear un modelo o teoría
 - A los participantes se les presenta un conjunto de estrategias con sus pagos asociados
- Podemos extrapolar?
 - el contexto es artificial,
 - el comportamiento puede verse afectado por este contexto artificial
 - los participantes pueden no tener experiencia con la tarea
 - no hay mucho en juego, (reputación, etc.)
 - los estudiantes no son una población representativa

Experimentos de laboratorio vs. experimentos en campo

- Una forma de pensar los experimentos en campo es la de hacer los experimentos de laboratorio de manera más realista, con individuos, y contextualizados
- Gneezy y List (2006) testean la hipótesis de *gift-exchange* con contratos de trabajo reales:
 - contratan empleados para codificar libros en una biblioteca, dejando en claro que es una tarea de una vez.
 - A un subconjunto se le ofrece un bono sorpresa de manera aleatoria (\$20/hr), mientras que el grupo de control recibe \$12, como era estipulado.
 - La gente trabaja más luego de recibir el bono sorpresa, pero el efecto desaparece rápidamente.
 - También experimentaron con ventas puerta a puerta, el efecto inicial es más grande, pero desaparece rápidamente.

Los experimentos en campo como herramientas de política

- Los experimentos de campo se convirtieron en una herramienta de política para testear futuras intervenciones de política
- Requiere el uso de teoría para identificar un mecanismo en la cadena de resultados que sera responsable del efecto buscado
 - Si no encontramos un efecto, es poco probable pensar que una política diseñada basada en el mismo sea efectiva.

Investigación experimental : relación con la teoría y relevancia de política

- En la investigación experimental hay distintas dosis de teoría atrás (Card et al. 2011)
- Generalmente, gradiente de experimentos en el lab (+++), en campo y (++) de política (+)
- La relevancia directa para política: no siempre, pero el ranking es al revés

Ejemplos: experimentos de campo

- En el comportamiento de los trabajadores:
 - son los trabajadores más productivos cuando se les paga salarios fijos o de acuerdo con lo trabajado?
- En el comportamiento de los consumidores:
 - existen bienes cuya demanda aumenta cuando aumentan los precios?
- En comportamiento de los estudiantes:
 - existe una tendencia a la procrastinación?

“Piece rates, fixed wages and incentives: evidence from a field experiment”

- Bruce Shearer (RESTUD 2004/JHR 1996)
- Cuándo son los trabajadores más productivos?
 - el pago a destajo significa que las ganancias son proporcionales a la cantidad de trabajo realizado
 - difícil de conseguir estimadores insesgados con datos observacionales (autoselección)

“Piece rates, fixed wages and incentives: evidence from a field experiment”

- Experimento en campo con una empresa que plantaba árboles en British Columbia, Canadá
 - Responsable de la re-forestación de bosques recién talados
 - Por qué esa tarea? clara definición de tareas: hacer un pozo, poner la planta, llenar el pozo.
 - Tarea físicamente demandante: el esfuerzo es costoso, la productividad puede medirse
 - Las condiciones para plantar varían con la pendiente, el tiempo, la preparación del terreno: los pagos por árbol plantado variaban
 - La firma emplea 90 empleados por año, en general a destajo
- Trabajadores asignados aleatoriamente de una firma que operaba en BC

“Piece rates, fixed wages and incentives: evidence from a field experiment”

- Trabajadores son monitoreados y seguidos por un período de 120 días
- Cada trabajador es observado en los dos regímenes: 120 obs. de productividad diaria 60 a destajo, 60 con sueldo fijo
- Los trabajadores plantan 20% cuando trabajan a destajo respecto de cuando trabajan por un sueldo fijo!

“Giffen behavior and subsistence consumption”

- Robert Jensen y Nolan Miller (AER 2008)
- Ley de la demanda: cuando el precio $\uparrow$, la demanda debería $\downarrow$
- Giffen good (Marshall 1895): *As M. Giffen pointed out, the rise in the price of bread makes so large a drain on the resources of the poorer labouring families and raises so much the marginal utility of money to them, that they are forced to curtail their consumption of meat and the more expansive farinaceous food: and bread, being still the cheapest food which they can get and will take, they consume more, and not less of it.*
- Un bien Giffen es un bien en el cual el efecto ingreso domina al efecto sustitución
 - es un bien inferiores (cuando aumenta el ingreso $\uparrow$, la demanda debería caer $\downarrow$)
 - no tiene sustitutos cercanos
 - representa una proporción importante de los gastos del consumidor (pero no la totalidad)

“Giffen behavior and subsistence consumption”

- Cómo cambia la demanda de arroz en la provincia de Hunan en China (Trigo en Gansu) varía con un cambio exógeno en los precios?
 - focalizado en los pobres
- Experimento: seleccionar aleatoriamente hogares y darles un voucher que les permite obtener un descuento en sus compras de arroz (trigo).
- Resultado: cuanto más alto es el descuento, menos se consume

“Giffen behavior and subsistence consumption”

- Qué pasaba si los vouchers eran cambiados por dinero en efectivo?
 - Con reventa, se espera un efecto riqueza, por lo que la caída en el consumo sería consistente con ser un bien inferiores.
- Para prevenir esto:
 - Los comercios no podían cambiar el voucher por otra cosa que no fuera el arroz o el trigo
 - Los vouchers deberían ser firmados por los beneficiarios, sólo los vouchers firmados eran re-embolsados
 - Los comercios recibían monitoreos sorpresa
 - Los vouchers se entregaban mensualmente y se les decía a los beneficiarios que si eran encontrados revendiendo, no se les entregarían futuros vouchers (los mismos equivalían a dos veces el consumo per cápita por un período de 5 meses)

“Giffen behavior and subsistence consumption”

- El consumo de arroz y trigo cae cuando cae el precio, y esta caída depende de la participación del alimento en la cantidad total de la canasta de consumo:
 - para los más pobres, que no consumen otro bien, este efecto es negativo, puede esperarse que este grupo sea el más castigado en una crisis de los precios de los alimentos
 - para los más ricos, el bien no es un bien Giffen
 - Es sólo un bien Giffen para los pobres en la zona de subsistencia




FIGURE 2. COEFFICIENT PLOTS

Source: Jensen and Miller (2008)

“Giffen behavior and subsistence consumption”

- Implicancias de políticas:
 - los subsidios pueden no causar mejoras en la nutrición para los pobres en la zona de subsistencia
 - para ser efectivos, los programas de subsidios a los alimentos deben mover a los individuos fuera de la zona de subsistencia a la zona estandar.
 - en el extremo, para los más pobres, las mejoras pueden llevarlos a la zona de subsistencia.

- Los experimentos son una herramienta poderosa para aprender acerca del comportamiento de los individuos
 - Evidencia de ciertas predicciones de los modelos neoclásicos: incentivos al trabajo, destajo vs. sueldo fijo, bienes Giffen
 - Evidencia en el comportamiento: gift-exchange model, procrastinación, auto-control, etc.
- Los experimentos son una herramienta importante de política
 - Testear la efectividad de una política social (ej, Progresa): funciona?
 - Para designar mejores políticas (ej., como ayudar mejor a los pobres en una crisis en el precio de los alimentos)

- Cómo maximizar el diseño de un experimento de manera que sea útil en términos de política?
 - experimentos y evaluaciones de política: son extrapolables?
 - Desafío: cuáles son los mecanismos subyacentes de una política?
 - Si se conocen o se pueden conjeturar, pueden ser utilizados
- Evaluaciones tradicionales vistas como "caja negra", no se sabe qué es lo que funciona

Ejemplo I: "Moving to Opportunity" (MTO)

- Qué efecto tiene la concentración de la pobreza en familias pobres?
- 4600 familias de bajos ingresos que vivían en barrios pobres asignadas aleatoriamente a:
 - voucher tradicional: podían utilizarlo como subsidio para cualquier transacción de alquiler privada
 - voucher de baja pobreza: igual al anterior, pero sólo podía ser utilizado en barrios que según el Censo de 1990 tuvieran menos del 10% de tasa de pobreza
 - grupo de control
- Voucher tradicional: sin efectos, el de baja pobreza, efectos sobre la violencia juvenil, sin efectos en el mercado laboral, pero sí en salud física y mental, incluída las tasas de obesidad.

Qué se concluye?

- El voucher tradicional es el que parecería ser relevante en términos de política y aplicación a escala.
- ...pero, es el de baja pobreza el que genera una "dosis de tratamiento" lo suficientemente fuerte como para ver los efectos del "ambiente del barrio" en otras variables. Esto no hubiera sido descubierto si sólo se hubiera llevado a cabo la política de voucher más tradicional.
- Debate para países en desarrollo: cómo se soluciona el déficit habitacional? relocalización de villas miseria? *upgrading*?

Ejemplo II: Extensión de los años obligatorios de educación

- Evidencia de efectos positivos en ingresos laborales, disminución de actividad criminal, embarazo adolescente, etc.
- Qué es lo que pasa?
 - efecto incapacitación?
 - aprendizaje?
 - qué tipo de curricula favorece cada efecto?

- Desarrollos metodológicos de reciente utilización en economía pueden arrojar luz sobre problemas para países en desarrollo.
 - Respuestas parciales a problemas que general trampas de pobreza
 - equilibrios de baja educación, baja productividad, baja inversión
 - fallas de mercado en mercados de crédito
 - prevalencia de enfermedades en países pobres
 - etc....

- Angrist & Pischke, Mostly Harmless Econometrics
- Jensen, Robert T., and Nolan H. Miller. 2008. "Giffen Behavior and Subsistence Consumption." *American Economic Review*, 98(4): 1553-77.
- Mullainathan, Sendhil, Jens Ludwig, and Jeffrey R Kling. 2011. "Mechanism Experiments and Policy Evaluations." *Journal of Economic Perspectives* 25 (3): 17-38.
- Shearer, B, Piece rates, fixed wages and incentives: evidence from a field experiment, JHR 1986

Cálculos de potencia estadística y muestreo para experimentos aleatorizados

Curso Evaluación de Impacto de
Políticas Públicas

Maestría en Economía - UNLP

Resumen

- Cómo planificamos la asignación aleatoria?
- Algunos conceptos estadísticos
- Cálculos de potencia (“power”)
- Algunas consideraciones

Cómo aleatorizar?

- **Sobresubscripción:** una oportunidad natural para introducir una aleatorización es cuando hay exceso de demanda. Problema de falta de cooperación de los que no reciben el tratamiento. El programa se implementa mediante, por ejemplo, una lotería. (ej.: vouchers para las escuelas de Colombia).
- **Phase-in:** por restricciones presupuestarias, muchas veces no se puede implementar todo el programa a la vez. Cuando es discutible no recibir tratamiento. (ej.: Proyecto de desparasitación en Kenia). Problema para estimar los efectos de largo plazo, puesto que el grupo de control desaparece. Depende del horizonte del proyecto y de cuanto tardan en materializarse los efectos del programa.

Cómo aleatorizar?

- **Dentro del grupo o "within":** beneficios a todos, pero para distintos sub-grupos. (ej. programa balsakhi en la India) Se evitan problemas de falta de cooperación de los que no reciben tratamiento, pero existe el riesgo de "contaminación del control".
- **Diseño de incentivos:** el programa está disponible para todos, pero la tasa de participación no es universal. Aquí sólo hay un aumento en la probabilidad de participar. (ej.: estudio para el GRE)

Técnicas para la asignación aleatoria

- Aleatorización individual
 - Mido el resultado al mismo nivel que a la unidad de tratamiento
 - Ej: programa de entrenamiento laboral. Cola de interesados, asigno un número a cada uno y luego aleatorizo.
 - El tratamiento y resultado de interés son administrados en diferentes niveles.
 - Ej.: Intervención a nivel escuela, mido resultados a nivel individual
 - Se llama aleatorización a nivel grupo o cluster.

Técnicas para la asignación aleatoria

- **Block y Within Subject Design:**
 - Más fácil: diseño completamente aleatorizado
 - Minimiza riesgo de que el tratamiento esté correlacionado con características observables e inobservables de los individuos
 - ...pero la varianza tiende a ser muy grande, problemas de inferencia.
 - **Block:** Si existe heterogeneidad en el *pool* de individuos, podemos reducir la varianza incluyendo X_i en una regresión lineal (*blocking*). Agregar covariables reduce la varianza del componente no observado.
 - **Within study:** más de un tratamiento, utilizado en medicina.
 - Efectos de aprendizaje, sensibilización, interacción inesperada entre tratamientos, etc.

Técnicas para la asignación aleatoria

- **Diseño factorial:**
 - **Block:** el tamaño de la muestra puede variar significativamente a lo largo de los bloques.
 - En cambio, en el diseño factorial: el experimentador elige un nro. específico de sujetos por bloque.
 - **Diseño básico factorial:** número de sujetos pre-determinados asignado a cada combinación de tratamiento.
 - Caro en presencia de tratamientos múltiples con interacciones.

Asignación aleatoria

- Los métodos llamados experimentales permiten solucionar el problema fundamental de la evaluación :
 - No podemos observar la misma unidad “tratada” y “no tratada”.
 - La asignación aleatoria reduce el sesgo, pero no elimina el ruido.
 - La asignación aleatoria funciona debido a la “ley de los grandes números”.
 - La identificación requiere la comparación de los resultados esperados para dos (o más) grupos de manera “creíble”.

Planificando la asignación aleatoria

- Utilizar métodos estadísticos para hacer test de hipótesis
- Comparar dos resultados (Tratamiento vs. Control)
 - La teoría nos dice que deberíamos esperar una diferencia.
- Necesitamos datos....Cuántos?
- Test de hipótesis
 - Caso un sólo tratamiento, con dos grupos:
 - Diferencias en medias
 - Otros momentos de la distribución
 - Con datos en panel, diferencias en cambios

Test de Hipótesis

- Es la versión estadística de “se supone inocente”, hipótesis nula de “no hay diferencia”
 - No hay diferencias entre los resultados de participantes y no participantes del programa.
- La evidencia busca refutar esto.
- Se testea la hipótesis de $H_0 =$ el efecto es igual a cero.

Resumen (I)

- El efecto que obtenemos es sólo válido para nuestra muestra.
- Cómo se hace inferencia?
- Un intervalo de confianza de 95% nos dice que para un programa dado, el 95% de las muestras que tomemos para una población dada arrojarán un efecto que se ubicará dentro de dicho intervalo.
- El error estándar (ES) captura el tamaño de la muestra y la variabilidad de la variable que utilizemos como resultado.

Resumen (II)

- **Test:**
 - Queremos testear la hipótesis de “no tiene efecto”
 - $H_0 = 0$
 - $H_a = \neq 0$
 - Error de tipo I:
 - Error de tipo I: Rechazar falsamente una hipótesis nula. Concluir que existe un efecto cuando en realidad, no lo hay.
 - Con $\alpha = 5\%$, 1 cada 20.
 - α = nivel de significatividad, probabilidad de cometer error de tipo I.

Resumen (III)

- Error de tipo II: No rechazar cuando existe un efecto.
 - La potencia estadística o “*power*” de un test es la probabilidad de encontrar un efecto significativo (en nuestro experimento).
- La potencia es un elemento clave en la planificación de un experimento.
- Para un tamaño de muestra dada, cuán probable es que encontremos un efecto significativo.
 - En nuestra intervención, el error de tipo II significa que existe un efecto, pero que no lo podemos detectar.

Qué concluimos de nuestro test de hipótesis

		Rechazar H_0 de no efecto	No rechazar H_0 de no efecto
“Verdad”	Experimento tiene efecto	ok	Error de tipo II o bajo poder
	Experimento no tiene efecto	Error de tipo I	ok

Qué concluimos de nuestro test de hipótesis

		Rechazar H_0 de no efecto	No rechazar H_0 de no efecto
"Verdad"	Experimento tiene efecto	ok	Error de tipo II o bajo poder
	Experimento no tiene efecto	Error de tipo I	ok

Probabilidad de rechazar H_0 dado que es verdadera.

Qué concluimos de nuestro test de hipótesis

		Rechazar H_0 de no efecto	No rechazar H_0 de no efecto
“Verdad”	Experimento tiene efecto	ok	Error de tipo II o bajo poder
	Experimento no tiene efecto	Error de tipo I	ok

Probabilidad de no rechazar H_0 dado que es falsa.

La tiranía de *power*– Bland, BMJ 2008

- Es una idea muy simple.
- Realizamos un estudio y evaluaremos la evidencia vía tests de hipótesis.
- Es importante decidir cuán grande es el efecto que nos gustaría detectar.
- Elegimos un tamaño de muestra tal que si existiera un efecto real en la población, una gran proporción de las muestras posibles produciría una diferencia estadísticamente significativa.

Cálculos de potencia

- Una potencia de 80% nos dice que el 80% de los experimentos en una población con un tamaño de muestra dado, si existe un efecto, lo encontraremos con el nivel de significatividad elegido.
 - La potencia aumenta con el tamaño de la muestra
 - Cuanto más grande es la muestra, más cerca estamos de las características poblacionales.
 - Es más probable que podamos concluir que hay una diferencia en resultados, si esa diferencia existe.
 - Además, reduce la variabilidad de los estimadores.
 - *Advertencia:* si la variabilidad del resultado de interés se explica en gran parte por otros factores, menor será el efecto que le podremos atribuir a la intervención.

Cómo se calcula?

- Para un conjunto de datos dado, o una muestra dada, el error de tipo II viene dado, pero podremos calcular que efecto podremos detectar.
- Pero, si planeamos un experimento, podemos elegir cuánto error de tipo II estamos dispuestos a tolerar.
- Cuánto mayor sea la diferencia entre los dos grupos (efecto), más grande la potencia (o menos error de tipo II) para una muestra dada.

Cómo se calcula?

- Cuánto es el efecto mínimo que justifica nuestro programa?
 - Un efecto muy pequeño, puede no ser económicamente significativo.
 - Si es un efecto más grande, lo queremos detectar.
 - Mirar intervenciones similares
 - *Unidades de medición distintas, cm, US\$, kg...*
 - *No es lo mismo una diferencia de \$100 cuando la desviación estándar es de 10 o de 20.*

Cómo se calcula?

- Efectos estandarizados, delta o ES.
 - Efecto dividido por la desviación estándar de la variable resultado.
 - Lo mido en unidades de sd.
 - ES: cuán grande?
 - 0.1, 0.2, etc

Cómo se calcula?

- Muy pequeño
 - 0.10
 - Qué significa?
 - El miembro promedio del grupo de tratamiento tiene un resultado mejor que el 54% de los miembros del grupo de control.

Cómo se calcula?

- Modesto
 - 0.20
 - Qué significa?
 - El promedio del grupo de tratamiento tiene un resultado mejor que el 58% de los miembros del grupo de control.

Cómo se calcula?

- Grande
 - 0.50
 - Qué significa?
 - El promedio del grupo de tratamiento tiene un resultado mejor que el 69% de los miembros del grupo de control.

Cómo se calcula?

- Muy grande
 - 0.80
 - Qué significa?
 - El promedio del grupo de tratamiento tiene un resultado mejor que el 79% de los miembros del grupo de control.

Cómo se calcula?

- Qué delta elegimos?
 - Cuanto más chico, más grande la muestra
 - Literatura relacionada para el delta / medias y varianzas: información local
 - Mejor ser conservadores
 - Qué resultados?
 - Tratamientos múltiples
 - Stata/Optimal Design Software

Los más utilizados....

- Nivel de significatividad: 1%, 5%
- Potencia: 0.80, 0.90
- delta: 0.2, 0.5
- Fácil de calcular

Qué necesitamos?


- Fórmula:

$$N=4 (t_{(\theta)} + t_{\alpha})^2 / ES$$

- $t_{(\theta)}$ = Valor crítico θ , $t_{(\theta)}=0.84$, si queremos una potencia de 80%
- t_{α} = Valor críticos para una significatividad α . Si $\alpha=0.05$, $t_{\alpha}=1.666$
- $ES=(Effect\ Size)=\delta$
- $N=n_0+n_1$
 - Nota: status quo igual tamaño puede ser costoso en términos de sobre-muestreo


Ejemplos

Potencia, tamaño muestra y δ



Ejemplos

Cómo cambia la potencia con ***N***?



Ejemplo: Intervención para mejorar talla y BMI

El tamaño de muestra necesario en cada grupo (suponiendo el mismo número para cada uno) para realizar tests de hipótesis bilaterales es: $n \geq 2[(z_{\{(\alpha/2)\}} + z_{\{\beta\}})(\sigma/\Delta)]^2$

Donde σ es la desviación estándar, y Δ es la diferencia entre las medias que se espera observar, usando un nivel de significación $\alpha=0.05$ y una potencia 0.80, los valores $z_{\{(\alpha/2)\}} = 1.96$ y $z_{\{\beta\}} = 0.84$

En la comparación de tallas, se eligió $\Delta=1.5\text{cm}$: $\sigma=3.05$ (para niños, tablas de OMS), se obtiene $n \geq 65$

$\sigma=3.23$ (para niñas, tablas de OMS), se obtiene $n \geq 73$

En la comparación de BMI, se eligió $\Delta=0.5\text{kg/m}^2$: $\sigma=1.3$ de la mitad superior (para niños, tablas de OMS), se obtiene $n \geq 106$

$\sigma=1.4$ de la mitad superior (para niñas, tablas de OMS), se obtiene $n \geq 123$

Tomando el mayor valor, se decidió elegir 150 niños en cada grupo, previendo un posible abandono del estudio de aproximadamente 20%


Algunas consideraciones

1. Datos de línea de base
2. Nivel de asignación aleatoria
3. Cumplimiento con la asignación aleatoria
4. Estratificación

1. Línea de base

- Tenemos datos de línea de base?
- Para un delta y N dado, tendremos mayor potencia si las covariables de la línea de base explican una parte más grande de la variación del resultado de interés.
 - Ejemplos:
 1. Intervenciones en área de educación: resultados de exámenes
 2. Salud: prevalencia e incidencia de diarrea
 3. Agricultura: productividad de la tierra
- Para una potencia y un delta dado, necesitaremos una muestra más pequeña.
- Nos preocupa la varianza residual, luego de limpiar por el efecto de la covariable relevante.

Ejemplo




2. Nivel de asignación aleatoria (*clusters*)

- La unidad de aleatorización es una comunidad, colegio, hospital.
- Por qué? Efectos derrame, costos, restricciones políticas, etc.
- El nivel de aleatorización es distinto de la unidad en la que medimos los resultados.
- Problema: las observaciones en una unidad de aleatorización están correlacionadas. (ej: shocks económicos, productividad, shocks temporales, etc.)


2. Nivel de asignación aleatoria (*clusters*)

- Nuevo parámetro ρ (correlación intra-cluster)
- Relevante para los cálculos de potencia
- Es importante para inferencia
- Cómo varia la potencia con ρ ?
- De dónde obtenemos este parámetro?


Ejemplo: ρ & potencia



Ejemplo: ρ & potencia



Ejemplo: ρ & potencia



En términos de potencia, el número de clusters es más importante que las unidades que tenemos por cluster.

ρ & potencia

$$Y_{ij} = \alpha + \beta T + v_j + \omega_{ij}$$

Para n individuos en J clusters.

v_j es i.i.d. con varianza τ^2

ω_{ij} es i.i.d. con variance σ^2

$\rho = \tau^2 / (\tau^2 + \sigma^2)$, la proporción de la varianza total explicada por la varianza dentro del grupo.
(*within group variance*).

ρ & potencia

δ es ahora:

$$= \sqrt{\frac{M_{J-2}}{\sqrt{P(1-P)} J}} \sqrt{\rho + \frac{(1-\rho)}{n}} \sigma$$

donde $M_{(j-2)} = t_{\alpha/2} + t_{\beta}$

3. Cumplimiento imperfecto

- Hasta ahora asumimos que todo el mundo participa, tal como fue estipulado en el protocolo para la aleatorización.
- Individuos o unidades asignadas al tratamiento pueden no participar
- Los controles pueden acceder al tratamiento o parte del tratamiento

3. Cumplimiento imperfecto

- Hay que ajustar los cálculos de potencia por la diferencia en cumplimiento entre el tratamiento y el control
- La muestra debe ser ajustada en la proporción $1/(c-s)^2$, en donde c y s son las tasas de cumplimiento de los grupos de tratamiento y control respectivamente.

4. Estratificación

- Reduce el tamaño de la muestra para una potencia dada.
- Reduce la variabilidad del resultado de interés dentro de cada estrato.
 - En general se utilizan variables resultado pre-tratamiento de la línea de base.
 - Esperamos que el tratamiento sea distinto entre los grupos en los que basamos los estratos.

Consideraciones Finales (I)

- **Externalidades**
 - Individuos no tratados se benefician del tratamiento.
 - Aprendizaje/ imitación, etc. .
- **SUTVA (Stable unit treatment value assumption)** no se verifica. Ahora el efecto sobre el individuo/unidad, etc. no es independiente del tratamiento de otro individuo (ejemplos: vacunas, tratamientos antiparasitarios, educación, etc.)
- **Soluciones:** distintos niveles de exposición e intensidad de tratamiento, aleatorización en grupos.

Consideraciones Finales (II)

- **Atrición**
 - Aleatoria: reduce el power
 - Qué pasa si no es aleatoria?
 - Comparar usando datos de línea de base, los resultados de los que abandonan vs. los que no.
 - Soluciones no paramétricas [Manski (1989) & Lee (2002)]

Consideraciones Finales (III)

- Validez externa .
 - Replicabilidad y generalización de los resultado
 - Efectos de equilibrio general (scale up), depende de cuán grande es la unidad de intervención
 - Cambios de comportamiento: Hawthorne (tratamiento) & John Henry (control).
 - Datos de largo plazo

Consideraciones Finales (IV)

- Qué resultado utilizamos para el cálculo de potencia?
- Es triste ver un programa con una buena estrategia de evaluación, pero con poca potencia.
 - Tamaño de la muestra
 - Muy optimista respecto de delta
 - Pocos clusters
 - Muy optimistas sobre el cumplimiento
- Elegir cuidadosamente el nivel de aleatorización
- Ser muy conservadores en términos de delta
- Piloto para tener estimadores de la varianza
- Consulte a su estadístico amigo

References

- Duflo, Esther, Glennerster, Rachel and Kremer, Michael, “Using Randomization in Development Economics Research: A Toolkit” (December 12, 2006). Available at <http://ssrn.com/abstract=951841> or <http://dx.doi.org/10.2139/ssrn.951841>
- List, John, Sally Sadoff y Mathis Wagner, “So You Want to Run an Experiment, Now What? Some Simple Rules of Thumb of Optimal Experiment Design”, NBER WP
- Bruhn, Miriam, and David McKenzie. 2009. "In Pursuit of Balance: Randomization in Practice in Development Field Experiments." American Economic Journal: Applied Economics, 1(4): 200-232.
- Optimal Design Software Guide available at http://sitemaker.umich.edu/group-based/optimal_design_software

Consideraciones éticas

- Cuándo es éticamente cuestionable aleatorizar?
 - Cuando el grupo de control se verá dañado por la falta de tratamiento (asignación aleatoria para un tratamiento que previene el contagio de HIV de madre a hijo)
 - Cuando se afectan decisiones personales (anticonceptivos orales vs. DIU)
 - Cuando los riesgos de tratamiento nuevo exceden los de un tratamiento existente
 - Cuando se conocen los beneficios del tratamiento

Reporte Belmont sobre Principios Éticos

- Autonomía y respeto por los individuos
 - Elección libre e independiente sin coerción
 - Consentimiento informado
- Maximizar beneficio y minimizar daño
- Justicia
 - Igual oportunidad de obtener los beneficios
 - Provisión de los tratamientos beneficios a la población

Reporte Belmont sobre Principios Éticos

- Los participantes no pueden estar coercionados
 - Negando los beneficios a las personas que se rehúsan (tratamiento alternativo)
 - Ofreciendo compensación excesiva por la participación
 - Ejerciendo presión para participar
- Los participantes deben saber:
 - Razones para conducir el experimento, por qué se elige al beneficiario para participar, quien financia el experimento
 - Procedimiento el experimento
 - Riesgos, beneficios y medidas para reducir los riesgos
 - Confidencialidad

Métodos de Evaluación de Impacto de Políticas Públicas

Experimentos Sociales - Estimaciones

María Laura Alzua

UNLP

Abril 2020

Estimaciones

- ▶ Estimación de ATE con perfecto cumplimiento
- ▶ Inferencia
- ▶ Análisis de regresión con datos experimentales
- ▶ Estimando ATE con cumplimiento imperfecto
- ▶ Observaciones adicionales

Estimaciones

- ▶ Por construcción, el sesgo de selección es cero cuando hay asignación aleatoria del tratamiento
- ▶ Estimamos el ATE en dos etapas
 1. Estimamos la diferencia de medias entre el grupo de tratamiento y de control
 2. Estimamos el error estándar de esa diferencia

Estimaciones

- ▶ El ATE es una diferencia de medias

$$ATE = \Delta E(Y_i | T_i=1) - \Delta E(Y_i | T_i=0)$$

- ▶ Los errores estándar son:

$$std(\Delta) = \sqrt{\frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}}$$

- ▶ n_1 y n_0 son la cantidad de observaciones en el grupo de tratamiento y de control, y σ^2 es la varianza del resultado de interés entre el grupo de tratamiento y de control.

Análisis de Regresión

- ▶ El análisis de regresión es útil para analizar datos experimentales

$$(1) Y_i = T_i Y_{1i} + (1 - T_i) Y_{0i}$$

$$Y_i = Y_{0i} + (Y_{1i} - Y_{0i}) T_i$$

- ▶ Bajo el supuesto de efectos comunes: $Y_{1i} - Y_{0i} = \beta$
- ▶ $E(Y_{0i}) = \alpha$ and $\varepsilon_i = Y_{0i} - E(Y_{0i})$
- ▶ podemos re-escribir (1) como: $(2) = Y_i = \alpha + \beta T_i + \varepsilon_i$

Análisis de Regresión

Re-escribiendo:

- ▶ $(2) = Y_i\alpha + \beta T_i + \varepsilon_i$
- ▶ En términos de esperanza condicionada esto es:
 - ▶ $E(Y_i|T = 1) = \alpha + \beta + E(\varepsilon_i|T = 1)$
 - ▶ $E(Y_i|T = 0) = \alpha + E(\varepsilon_i|T = 0)$
- ▶ ATE en una aleatorización es β , ya que no hay sesgo de selección.

Pasos a seguir

1. Implementar un test de balance de co-variables en la línea de base.
 - 1.1 Ver nivel de aleatorización
 - 1.2 Qué covariables: resultados pre-tratamiento y resultados que expliquen la variabilidad del tratamiento
2. Estimaciones
 - 2.1 Analizar la magnitud del resultado
 - 2.2 Significatividad estadística
 - 2.3 Significatividad económica
3. Identificar, reportar y discutir atrición y dropout. Son conceptos distintos y requieren soluciones distintas.

Estimación de efectos causales con cumplimiento imperfecto

- ▶ En muchos experimentos sociales, algunos miembros del grupo de tratamiento no reciben tratamiento (no-shows) y algunos miembros del grupo de control reciben tratamiento (cross-overs).
 - ▶ Los no-shows pueden haber distintos casos: no recibir nada del tratamiento, recibir parte, etc.
- ▶ Es importante distinguir dos cuestiones importantes
 1. Cuál es el efecto promedio de **ofrecer** tratamiento?
 2. Cuál es el efecto promedio de **recibir** tratamiento?

Estimación de efectos causales con cumplimiento imperfecto

1. Cuál es el efecto promedio de *ofrecer* tratamiento?
 - ▶ Efecto promedio de la Intención a tratar (Intent to treat o ITT)
 - ▶ cuándo es igual a ATE?
2. Cuál es el efecto promedio de *recibir* tratamiento?
 - ▶ Efecto promedio sobre los tratados (TT, ATT o LATE para estudios no experimentales)

Estimación de efectos causales con cumplimiento imperfecto

- ▶ Supongamos que tenemos un experimento en donde ciertas unidades tratadas no recibieron tratamiento, pero no hay miembros del grupo de control que lo hayan recibido (no hay cross-overs).
 - ▶ Sea Y la medida de resultado de interés
 - ▶ Defino $Z = \begin{cases} 1 & \text{si los individuos son asignados al tratamiento} \\ 0 & \text{si los individuos son asignados al control} \end{cases}$
 - ▶ Defino $T = \begin{cases} 1 & \text{si los individuos reciben tratamiento} \\ 0 & \text{si los individuos no reciben tratamiento} \end{cases}$
 - ▶ Tasa de “recibidores de tratamiento” $= E(T|Z = 1)$
 - ▶ Tasa de “now-shows” $= 1 - E(T|Z = 1)$

Estimación de efectos causales con cumplimiento imperfecto

- ▶ ITT es un promedio ponderado de ATT para “cumplidores” (los que siendo asignados al tratamiento lo reciben) y Cero para los no-shows.

$$ITT = E(T|Z = 1)ATT + (1 - E(T|Z = 1))0 = E(T|Z = 1)ATT$$

- ▶ Entonces, el ATT es igual a:

$$ATT = \frac{ITT}{E(T|Z=1)} \simeq \frac{\hat{Y}_T - \hat{Y}_c}{(\hat{T}|Z=1)}$$

- ▶ La diferencia en los resultados promedios para tratamiento y control nos da un estimador insesgado del ITT.

Errores estándar con datos experimentales y no-shows

Podemos estimar los errores estándar de la siguiente manera:

$$std(\Delta) = \frac{\sqrt{\frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}}}{E(T|Z=1)}$$

- ▶ n_1 y n_0 son la cantidad de observaciones en el grupo de tratamiento y de control, y σ^2 es la varianza del resultado de interés entre el grupo de tratamiento y de control.
- ▶ Los estimadores puntuales de los errores estándar se ven ajustados por la tasa de unidades que efectivamente reciben el tratamiento.

Análisis Multivariado con no-shows

- ▶ Para mejorar la precisión de los estimadores pueden estimarse regresiones multivariadas con MCC con los no-shows (o con cumplimiento perfecto **$ITT=ATT$**)
 - ▶ $Y_i = \alpha + \beta_1 T_i + \beta_2 NS + X_i \beta_3 + \varepsilon_i$
- ▶ en donde **T** es 1 para participantes, 0 para no participantes y **NS** es 1 para no-shows.
- ▶ $ATT = \beta_1 + \beta_2 \left[\frac{k}{(1-k)} \right]$
- ▶ en donde $k = (1 - E(T|Z = 1))$, la tasa de no-shows.

Análisis Multivariado con no-shows

- ▶ La estimación de los errores estándar para el ATT

$$V(ATT) = V(\beta_1) + \left[\frac{k}{(1-k)} \right]^2 V(\beta_2) + 2 \left[\frac{k}{(1-k)} \right] cov(\beta_1\beta_2)$$

- ▶ en donde, $V(\beta_1)$, $V(\beta_2)$ y $cov(\beta_1\beta_2)$ son los elementos de la matriz de varianzas y covarianzas de los coeficientes estimados.

Ejemplo

- ▶ “Youth training programs beyond employment. Experimental Evidence for Argentina”, M.L.Alzua, G.Cruces y Carolina Lopez.
- ▶ Programa de entrenamiento laboral para jóvenes por debajo de la línea de pobreza y con problemas de empleo.
- ▶ Training en aulas seguido de pasantía
- ▶ Problemas de no-shows y dropouts: 220 jóvenes asignados al tratamiento y 187 al grupo de control.
- ▶ 178 participaron, 42 no-shows y dropouts. Problemas de atrición en el follow up.
- ▶ Utilización de datos administrativos para la evaluación de impacto.

Table 1: Pre treatment summary statistics: Individual characteristics and pre treatment outcomes.

Variables	Treatment		Control		Difference		
	Mean (1)	SE	Mean (2)	SE	(1)-(2)	SE	P-value
<i>1) Baseline survey data</i>							
Male	0.29	0.03	0.34	0.04	-0.04	0.05	0.37
Age	23.55	0.24	23.80	0.26	-0.25	0.35	0.48
Incomplete elementary school	0.04	0.01	0.03	0.01	0.01	0.02	0.58
Complete elementary school	0.08	0.02	0.05	0.02	0.02	0.02	0.34
Incomplete high school	0.28	0.03	0.33	0.03	-0.05	0.05	0.28
Complete high school	0.33	0.03	0.33	0.04	-0.00	0.05	0.93
Incompl tertiary level/college	0.18	0.03	0.16	0.03	0.02	0.04	0.65
Complete tertiary level/college	0.07	0.02	0.06	0.02	0.01	0.02	0.70
Children in the household	0.19	0.03	0.25	0.03	-0.06	0.04	0.18
Single/Widower	0.69	0.03	0.67	0.04	0.03	0.05	0.56
Married/Cohabiting	0.23	0.03	0.27	0.03	-0.04	0.04	0.34
Divorced/Separated	0.04	0.01	0.04	0.01	0.01	0.02	0.69
<i>2) Administrative data</i>							
Avg employment Q1 2003-Q4 2007	0.07	0.01	0.05	0.01	0.02	0.02	0.13
Avg employment Q1 2008-Q3 2010	0.16	0.02	0.12	0.02	0.05	0.03	0.07*
Avg earnings Q1 2003-Q4 2007	1,463.96	88.44	1,351.15	106.36	112.81	140.32	0.42
Avg earnings Q1 2008-Q3 2010	1,599.48	83.75	1,513.60	105.94	85.88	134.37	0.52
Always AUH Q1 2010-Q3 2010	0.10	0.02	0.10	0.02	0.00	0.03	0.93
<i>3) Credit agencies data</i>							
Avg credit good Q2 2010-Q3 2010	0.09	0.02	0.06	0.02	0.03	0.03	0.31
Avg inquiries Q1 2008-Q3 2010	0.11	0.01	0.12	0.01	-0.01	0.02	0.73

Table 2: Impact of random assignment. Post treatment outcomes.


	Average Q2-2011 to Q3-2012	Q3-2012	Average Q4-2012 to Q4-2013	Q4-2013	Average Q2-2011 to Q4-2013
<i>A. Formal employment</i>					
Treatment group - ITT	0.0796** [0.0371]	0.1020** [0.0465]	0.0434 [0.0403]	0.0382 [0.0450]	0.0691* [0.0371]
Completed training - TOT	0.1641** [0.0762]	0.2104** [0.0962]	0.0895 [0.0831]	0.0787 [0.0925]	0.1433* [0.0769]
Control group mean	0.2504	0.2460	0.3048	0.2888	0.2752
<i>B. Earnings</i>					
Treatment group - ITT	384.15*** [143.20]	357.15** [158.20]	234.81 [163.06]	124.24 [160.33]	311.30** [147.33]
Completed training - TOT	796.71*** [298.36]	740.72** [327.97]	486.99 [336.87]	257.68 [332.60]	646.09** [306.17]
Control group mean	837.13	678.96	1025.29	818.52	1136.95
<i>C. Credit in good standing</i>					
Treatment group - ITT	0.0455** [0.0227]	0.0674* [0.0348]	0.0247 [0.0315]	0.0350 [0.0358]	0.0387 [0.0251]
Completed training - TOT	0.0937** [0.0469]	0.1389* [0.0714]	0.0508 [0.0646]	0.0722 [0.0736]	0.0803 [0.0521]
Control group mean	0.0882	0.1070	0.1326	0.1230	0.1084
<i>D. Credit inquiries</i>					
Treatment group - ITT	0.0776** [0.0300]	0.0006 [0.0663]	-0.0212 [0.0359]	-0.0062 [0.0797]	0.0295 [0.0255]
Completed training - TOT	0.1582*** [0.0601]	0.0012 [0.1351]	-0.0432 [0.0734]	-0.0126 [0.1625]	0.0611 [0.0528]
Control group mean	0.1881	0.2513	0.2877	0.3957	0.2333
<i>Observations</i>	407	407	407	407	407

- ▶ Qué parámetro me interesa?
 - ▶ ITT relevante para costos, hacedores de política, etc. Puede ser o no cercano al ATE, dependiendo de la validez externa
 - ▶ ATT es el impacto sobre los que recibieron el tratamiento

Estimación de los efectos causales con cumplimiento imperfecto

- ▶ Ahora agregamos Cross-overs: unidades del grupo de control que reciben tratamiento
- ▶ ITT sigue siendo la diferencia de las medias entre los asignados al grupo de tratamiento y control.
- ▶ Sin embargo, para estimar el ATT, necesitamos algunos supuestos adicionales
- ▶ En todo experimento, supongo que habrá cuatro categorías: “always-takers” (siempre tomadores), “never-takers” (nunca tomadores), “compliers” (cumplidores) y “defiers” (desafiantes).
- ▶ Es importante ver para qué grupos la aleatorización induce a un efecto del tratamiento.
 - ▶ siempre tomadores: no brindan información sobre el impacto del tratamiento
 - ▶ nunca tomadores: no brindan información sobre el impacto del tratamiento
- ▶ La aleatorización induce un efecto sólo para cumplidores y desafiantes.

Experimento con “no-shows” y “cross-overs”



SOURCE: Howard S. Bloom (ed.). 2005. *Learning More from Social Experiments: Evolving Analytic Approaches*. New York: Russell Sage Foundation.

- ▶ Bajo monotocidad, el efecto del tratamiento para los cumplidores, is called LATE:

$$LATE = \frac{ITT}{E(T|Z=1) - E(T|Z=0)}$$

Entonces, para estimar el LATE de un experimento, estimamos

$$\widehat{LATE} = \frac{\hat{Y}_t - \hat{Y}_c}{(\hat{T}|Z=1) - (\hat{T}|Z=0)}$$

Ejemplo: Efecto del servicio militar en el mercado de trabajo (Angrist 1998)

- ▶ Cuando es voluntario, hay sesgo de selección
- ▶ Lotería para la guerra de Vietnam
- ▶ El supuesto de monotonicidad me dice que nadie que hubiera querido ir a Vietnam sin lotería, va a ir a Vietnam si sale sorteado. Esto es, el instrumento no puede afectar negativamente a los always takers.
- ▶ Estimación con TSLS
- ▶ 15% caída en los salarios de blancos, no hay caída significativa de los no blancos.

TABLE 4—TWO-STAGE INSTRUMENTAL VARIABLES ESTIMATES

Whites			
Cohort	FICA Taxable Earnings	Adjusted FICA Earnings	Total W-2 Compensation
Model 1			
1950	-1709.2 (946.8)	-2093.7 (1108.8)	-1895.0 (1333.1)
1951	-1457.1 (959.3)	-1983.7 (1036.1)	-2431.4 (1152.1)
1952	-1724.0 (863.1)	-1943.0 (927.2)	-2058.7 (1001.9)
1953	1223.8 (3232.1)	900.7 (3505.3)	-488.6 (3936.0)
$\chi^2(873)$	578.3	630.3	569.5
Model 2			
1950-53	-1562.9 (521.8)	-1920.4 (575.9)	-2094.5 (646.3)
$\chi^2(876)$	579.1	631.0	569.7

Nonwhites

Cohort	FICA Taxable Earnings	Adjusted FICA Earnings	Total W-2 Compensation
Model 1			
1950	3893.7 (5358.5)	3891.9 (6244.5)	5711.8 (7206.0)
1951	- 891.3 (4397.1)	- 333.4 (4664.2)	2609.0 (4894.6)
1952	- 3182.9 (3997.4)	- 3457.7 (4195.2)	- 3068.0 (4229.2)
1953	- 5928.3 (10296.3)	- 8571.4 (10697.1)	- 6325.8 (11410.6)
$\chi^2(873)$	616.7	681.7	693.6
Model 2			
1950-53	- 643.3 (2407.5)	- 999.7 (2602.5)	366.7 (2734.2)
$\chi^2(876)$	618.4	683.4	695.6

Notes: Standard errors in parentheses.

The table shows estimates of the effect of military service on average 1981-84 earnings in 1978 dollars. The estimation method is optimally weighted Two-Sample Instrumental Variables, described in the text. FICA and W-2 earnings are from the Social Security CWSHS. The adjusted FICA series is described in the Appendix.

Comentarios adicionales

- ▶ En base a qué parámetro definimos el objetivo de la evaluación?
 - ▶ Media?
 - ▶ Otros momentos de la distribución: muchas veces es más difícil proveer información sobre otros parámetros más interesantes (cuantiles, ATE, etc.)
 - ▶ En el caso de efecto común, si podemos identificar la distribución completa.
- ▶ Sesgo de la aleatorización
 - ▶ Cuando como consecuencia de la aleatorización las personas que participan son diferentes que las que participarían si el programa operara normalmente.
 - ▶ Ej.: entra21
- ▶ Limitaciones institucionales:
 - ▶ validez externa

Pasos para un RCT exitoso

► 1. Cuáles son las preguntas?

1. preguntas basadas en la teoría
2. Motivación
3. Qué tratamiento o tratamientos se van a probar?
- 4.Cuál es el estado de contrafáctico?

► 2. Diseño Experimental

1. Instituciones participantes
2. Definición de la unidad de aleatorización
3. Cantidad de unidades en la muestra
4. Proporción de la muestra aleatorizada en cada grupo o grupos
5. Covariables de interés

Pasos para un RCT exitoso

▶ 3. Marco empírico

1. Cuáles son los resultados que serán afectados por los tratamientos implementados, cómo se van a medir dichos resultados?
2. Qué características de la línea de base serán utilizadas como covariables y cómo van a ser medidas?
3. Cómo se calcularán las diferencias entre tratamientos?

▶ 4. Estrategia de implementación

1. Cómo se van a seleccionar los lugares para el experimento, como van a reclutarse, elegirse e informarse los sujetos?
2. Cómo se implementará la aleatorización?
3. Cómo se administrarán los tratamientos?
4. Cómo se garantizará la recolección de datos confiables?

Pasos para un RCT exitoso

► Análisis estadístico

1. El cálculo de los efectos debe tener en cuenta la forma en la que la aleatorización se realizó.
 - Método inicial para aleatorizar
2. Cómo se implementó el tratamiento?
3. Qué datos de línea de base han sido recolectados y cuáles serán utilizados en el análisis multivariado

Referencias

- ▶ Howard S. Bloom, (2005) “ Learning More From Social Experiments Evolving Analytic Approaches” Russel Sage
- ▶ Shadish, W., Cook, T., y Campbell, D. (2002). Experimental and quasi-experimental designs for generalized causal inference. Hoghgton Mifflin
- ▶ Alzua, Cruces y Lopez (2014) “Youth training programs beyond employment. Experimental Evidence from Argentina”, mimeo.
- ▶ Joshua D. Angrist, (1990) “Earnings and the Vietnam Era Draft Lottery: Evidence from Social SecurityAdministrative Records”. The American Economic Review, Vol. 80, No. 3 (Jun.), pp. 313-336
- ▶ Guido W. Imbens and Joshua D. Angrist, (1994) “Identification and Estimation of Local Average Treatment Effects” Econometrica, Vol. 62, No. 2 (Mar.), pp. 467-475

Ejemplos experimentos

Maria Laura Alzua

CEDLAS UNLP, PEP & Conicet

April 14, 2020

"Worms: Identifying Impacts on Education and Health in the Presence of Externalities" (Kremer, M and E. Miguel - Econometrica 72, 2004) y tablas y gráficos del curso de Ted Miguel en U.C. Berkeley

- ▶ Por qué hay lugar para una intervención de salud por parte del estado?
- ▶ Por qué las familias no deciden intervenir en la salud de sus hijos en forma privada?
 - ▶ Desconocimiento (o bajo conocimiento) de la existencia de nuevas tecnologías de salud
 - ▶ Restricciones al crédito
 - ▶ Problemas de agencia en el hogar o altruismo imperfecto entre padres e hijos
 - ▶ Externalidades positivas del tratamiento

- ▶ Finanzas públicas: en la presencia de externalidades, el nivel de provisión de un bien o servicio es sub-óptimo, porque los individuos solo tienen en cuenta los beneficios privados.
- ▶ Sin subsidio: nivel de desparasitación es bajo: provisión pública de programas de desparasitación.
- ▶ Cuán grave? 1 en 4 personas tiene infección parasitaria en países en desarrollo.
- ▶ Cómo aleatorizar?
 - ▶ Individual, clusters, within school?
 - ▶ Cálculos de potencia
 - ▶ Cómo calcular externalidades

Externalidades

- ▶ Aleatorización a nivel escuela
- ▶ Identificación de externalidades a lo largo de escuelas (a cierta distancia de las escuelas tratadas) - variación experimental
- ▶ Identificación de externalidades dentro de las escuelas tratadas (niños no tratados) - no tengo variación experimental
- ▶ Estudios con aleatorización individual no mostraban resultados de magnitud relevante, lo que hacía que no fueran costo-efectivas
- ▶ Problema para medir externalidades y algunos resultados de interés no son estudiados: asistencia, efecto en salarios, etc.

Infecciones parasitarias

- ▶ Anquilostoma, tricocéfalos, lombrices y esquistosomiasis (hookworm, whipworm, roundworm, shistosomiasis) son las infecciones parasitarias más comunes
- ▶ Se estudia un tratamiento de desparasitación masiva en escuelas de zonas de alta prevalencia de parásitos en Kenia
- ▶ 90% infectados en la línea de base, 30% con infecciones severas
- ▶ Los parásitos no se reproducen dentro del cuerpo, dejan larvas en la excreta, y esto contamina a otro.
- ▶ El tratamiento genera una externalidad positiva pues reduce la transmisión.

Programa de desparasitación y diseño del RCT

- ▶ ICS (ONG) con el Departamento de Salud de Busia, Kenia implementan el proyecto
- ▶ Asentamientos pobres y densamente poblados en Busia, Oeste de Kenia.
- ▶ Altas tasas de infección
- ▶ 75 escuelas primarias en el área, asostemcoa de 30.000 alumnos entre 6 y 18 años
- ▶ Aleatorización

Aleatorización

- ▶ Escalonada a lo largo de tres grupos experimentales. Los grupos son similares en observables
 - ▶ Listar las escuelas alfabéticamente (por zona), por tamaño y contar 1, 2, 3, 1, 2, 3, etc. La asignación es arbitraria y debería ser ortogonal respecto de las variables omitidas.
- ▶ Grupo 1: tratamiento en 1998 y 1999
- ▶ Grupo 2: sin tratamiento en 1998, tratamiento en 1999
- ▶ Grupo 3: sin tratamiento en 1998, 1999, tratadas recién en 2001.
- ▶ Cálculos de potencia?

Características de la línea de base

- ▶ Cuestionarios de línea de base administrados por ICS a comienzos de 1998 y 1999.
- ▶ La mayor parte de las características están balanceadas, pero los del Grupo I parecen estar peor en algunas dimensiones, creando un sesgo en contra de encontrar resultados significativos.
- ▶ Submuestra para ver prevalencia de infección
- ▶ Tablas 1 y 2

TABLE I
1998 AVERAGE PUPIL AND SCHOOL CHARACTERISTICS, PRE-TREATMENT*

	Group 1 (25 schools)	Group 2 (25 schools)	Group 3 (25 schools)	Group 1 – Group 3	Group 2 – Group 3
<i>Panel A: Pre-school to Grade 8</i>					
Male	0.53	0.51	0.52	0.01 (0.02)	–0.01 (0.02)
Proportion girls <13 years, and all boys	0.89	0.89	0.88	0.00 (0.01)	0.01 (0.01)
Grade progression (= Grade – (Age – 6))	–2.1	–1.9	–2.1	–0.0 (0.1)	0.1 (0.1)
Year of birth	1986.2	1986.5	1985.8	0.4** (0.2)	0.8*** (0.2)
<i>Panel B: Grades 3 to 8</i>					
Attendance recorded in school registers (during the four weeks prior to the pupil survey)	0.973	0.963	0.969	0.003 (0.004)	–0.006 (0.004)
Access to latrine at home	0.82	0.81	0.82	0.00 (0.03)	–0.01 (0.03)
Have livestock (cows, goats, pigs, sheep) at home	0.66	0.67	0.66	–0.00 (0.03)	0.01 (0.03)
Weight-for-age Z-score (low scores denote undernutrition)	–1.39	–1.40	–1.44	0.05 (0.05)	0.04 (0.05)
Blood in stool (self-reported)	0.26	0.22	0.19	0.07** (0.03)	0.03 (0.03)
Sick often (self-reported)	0.10	0.10	0.08	0.02** (0.01)	0.02** (0.01)
Malaria/fever in past week (self-reported)	0.37	0.38	0.40	–0.03 (0.03)	–0.02 (0.03)
Clean (observed by field workers)	0.60	0.66	0.67	–0.07** (0.03)	–0.01 (0.03)

TABLE II
JANUARY 1998 HELMINTH INFECTIONS, PRE-TREATMENT, GROUP 1 SCHOOLS^a

	Prevalence of infection	Prevalence of moderate-heavy infection	Average infection intensity, in eggs per gram (s.e.)
Hookworm	0.77	0.15	426 (1055)
Roundworm	0.42	0.16	2337 (5156)
Schistosomiasis, all schools	0.22	0.07	91 (413)
Schistosomiasis, schools <5 km from Lake Victoria	0.80	0.39	487 (879)
Whipworm	0.55	0.10	161 (470)
At least one infection	0.92	0.37	—
Born since 1985	0.92	0.40	—
Born before 1985	0.91	0.34	—
Female	0.91	0.34	—
Male	0.93	0.38	—
At least two infections	0.31	0.10	—
At least three infections	0.28	0.01	—

La intervención

- ▶ Tratamiento recomendado por la WHO, tratamientos cada seis meses o anuales, droga de acuerdo con la infección de prevalencia.
- ▶ Consentimiento de las familias y de las comunidades
 - ▶ Firmar un formulario en la escuela: no trivial, hay que ir, problemas si se debían cuotas de escuelas, etc. Potenciales sesgos de quien no lo recibe?
- ▶ No se trataba a las niñas mayores de 13 años.
- ▶ Tratamiento complementado con información sobre prevención
 - Tabla 3 para asignación y cumplimiento
- ▶ Transferencias entre escuelas/ tratamientos en la casa? Table 4: transferencias

Project Schools


① Group 1 school

② Group 2 school

③ Group 3 school

▬ District Boundary

▬ Division Boundary



Objetivo del paper:

- ▶ Comparar el estimador naive de tratamiento, con estimadores que tienen en cuenta las externalidades.
- ▶ Ignorar las externalidades genera que
 - ▶ si se contamina el grupo de control: subestimaré los efectos
 - ▶ o si no mido los efectos en el grupo de tratamiento: subestimaré los efectos
 - ▶ tanto el tratamiento con el control van a verse afectados por las externalidades

- ▶ Nivel de infección en el tratamiento con externalidades: μ
- ▶ Efecto naive del programa: β , comparando externalidades en el tratamiento con control que se beneficia por las externalidades
- ▶ Diferencia entre Control con externalidades y sin: γ
- ▶ Efecto de un programa masivo $\gamma + \beta$
 - ▶ Si trato a una proporción de escuelas ρ en una región entonces el efecto promedio es $\rho(\gamma + \beta) + (1 - \rho)\gamma = \gamma + \beta$
- ▶ Tabla 5: diferencia de medias, estimadores naive. Hay también re-infección, con lo cual el efecto medido puede ser menor dado el paso del tiempo.

Especificación econométrica:

$$(1) Y_{ijt} = \alpha + \beta_1 T_{1it} + \beta_2 T_{2it} + X'_{ijt} \delta + \sum_d (\gamma_d N_{dit}^T) + \sum_d (\phi_d N_{dit}) + u_i + e_{ijt}$$

- i se refiere a la escuela, j al estudiante t son los períodos en los que fueron asignados a tratamiento X_{ijt} características de la escuela, N_{dit} cantidad de niños en escuelas a una distancia t en un año dado, N_{di}^T cantidad de niños en esa escuela asignados al tratamiento.

- ▶ Qué parámetros me permiten ver las externalidades entre escuelas?
 - ▶ N_{dit} captura la densidad, la cantidad de tratados en un área es exógena.
 - ▶ γ_d mide las externalidades entre escuelas.
 - ▶ Efecto promedio del primer año: $\beta_1 + \sum_d (\gamma_d N_{dit}^{\bar{T}})$
 - ▶ Efecto promedio del segundo año: $\beta_2 + \sum_d (\gamma_d N_{dit}^{\bar{T}})$, $N_{dit}^{\bar{T}^T}$ promedio de niños tratados ese año.

y las externalidades dentro de la escuela?

- ▶ Acá no tenemos el beneficio de la asignación aleatoria
 - ▶ la cantidad de alumnos tratados en una escuela no varió experimentalmente
 - ▶ no se puede descomponer el efecto directo de ser tratado en una escuela, del de la externalidad de los que no son tratados y reciben tratamiento
- ▶ No hay evidencia de que entre las escuelas tratadas, fueran los más enfermos los que recibían tratamiento: faltaban más, menos fácil obtener el consentimiento. La evidencia apunta a lo contrario.
 - ▶ Tabla 6

► Externalidades dentro de la escuela

$$(2) Y_{ijt} = \alpha + \beta_1 T_{1it} + \beta_2 T_{2it} + b_1 D_{1ij} + b_2 (T_{1it} * D_{1ij}) + X'_{ijt} \delta + \sum_d (\gamma_d N_{dit}^T) + \sum_d (\phi_d N_{dit}) + u_i + e_{ijt}$$

- en donde D es un indicador de recibir el tratamiento ofrecido por primera vez, 1998 para el primer grupo y 1999 para el segundo. β_1 es la externalidad dentro de la escuela para los no tratados, $\beta_1 + b_2$ es la suma de la externalidad dentro de la escuela más el efecto del tratamiento sobre los tratados.
(Panel B, tabla 6)

- en donde D es un indicador de recibir el tratamiento ofrecido por primera vez, 1998 para el primer grupo y 1999 para el segundo. β_1 es la externalidad dentro de la escuela para los no tratados, $\beta_1 + b_2$ es la suma de la externalidad dentro de la escuela más el efecto del tratamiento sobre los tratados.
(Panel B, tabla 6)

- Resultados, tabla 7

- ▶ Resultados
- ▶ Cane las tasas de infección, más a 3km que a 6.
- ▶ Error de código, los resultados no cambian para 3km pero son estimados más imprecisamente para 0-6km

Table B1: Summary of any moderate-to-heavy helminth infection results, updated and original

	UPDATED			ORIGINAL		
	(1)	(2)	(3)	(4)	(5)	(6)
Treatment Indicator	-0.347*** (0.052)	-0.333*** (0.052)	-0.313*** (0.057)	-0.347*** (0.052)	-0.311*** (0.052)	-0.247*** (0.053)
Treatment pupils w/in 3 km (per 1000 pupils)		-0.234** (0.097)	-0.212** (0.104)		-0.249*** (0.085)	-0.256*** (0.087)
Treatment pupils w/in 3 - 6 km (per 1000 pupils)			-0.050 (0.077)			-0.140** (0.060)
Total PSDP 'eligible' students w/in 3 km (per 1000 pupils)		0.069* (0.037)	0.046 (0.036)		0.074** (0.033)	0.109*** (0.040)
Total PSDP 'eligible' students w/in 3-6 km (per 1000 pupils)			-0.022 (0.039)			0.133** (0.056)
<i>Calculated Effects</i>						
Average 0-3 km externality effect		-0.102** (0.043)	-0.090** (0.044)		-0.111*** (0.038)	-0.106*** (0.037)
Average 3-6 km externality effect			-0.052 (0.079)			-0.096** (0.042)
Average overall cross-school externality effect		-0.102** (0.043)	-0.146 (0.110)		-0.111*** (0.038)	-0.212*** (0.065)
Overall deworming effect	-0.347*** (0.057)	-0.435*** (0.061)	-0.459*** (0.091)	-0.347*** (0.057)	-0.421*** (0.055)	-0.460*** (0.055)

Table B2: Summary of school participation results, updated and original

	UPDATED				ORIGINAL	
	(1)	(2)	(3)	(4)	(5)	(6)
Treatment Indicator	0.057*** (0.014)	0.058*** (0.014)	0.055*** (0.014)	0.051** (0.022)	0.054** (0.023)	0.055** (0.023)
Treatment pupils w/in 3 km (per 1000 pupils)		0.045** (0.021)	0.038* (0.021)		0.046** (0.018)	0.048** (0.019)
Treatment pupils w/in 3 - 6 km (per 1000 pupils)			-0.024 (0.015)			-0.013 (0.015)
Total PSDP 'eligible' students w/in 3 km (per 1000 pupils)		-0.030* (0.013)	-0.030** (0.012)		-0.031*** (0.012)	-0.037*** (0.012)
Total PSDP 'eligible' students w/in 3-6 km (per 1000 pupils)			0.012 (0.009)			-0.014 (0.012)
<i>Calculated Effects</i>						
Average 0-3 km externality effect		0.027** (0.013)	0.023* (0.013)		0.028** (0.011)	0.029** (0.012)
Average 3-6 km externality effect			-0.040 (0.024)			-0.009 (0.011)
Average overall cross-school externality effect		0.027** (0.013)	-0.017 (0.030)		0.028** (0.011)	0.020 (0.013)
Overall deworming effect	0.057*** (0.014)	0.085*** (0.017)	0.039 (0.032)	0.051** (0.022)	0.081*** (0.026)	0.075*** (0.027)

- ▶ Resultados educacionales:
 - ▶ La asistencia aumenta, muy costo-efectivo
 - ▶ Ausentismo cae en un 8-9%, reducción de un cuarto.
 - ▶ No hay efectos en pruebas académicas (efecto congestión?)
- ▶ Datos de largo plazo

"Short Run Subsidies..."

- ▶ "Short Run Subsidies and Long-Run Adoption of New Health Products: Evidence from a Field Experiment"; Pascaline Dupas, Econometrica (2014)
- ▶ Cómo aumentar el uso de productos de salud que reducen enfermedades infecciosas y salvan vidas: Vacunas, Condones, Redes Antimalaria, etc.
- ▶ Presencia de externalidades positivas y restricciones de acceso al crédito: Subsidios?
- ▶ Efectos sobre salud: uso una vez (vacunas) vs. usos en el tiempo (Redes anti-malaria)
- ▶ Subsidios en el corto plazo (o una vez): como afectan su uso/adopción en el largo plazo?
- ▶ Experimento de campo en Kenia

"Short Run Subsidies..."

- ▶ Bienes llamados "experience goods", el subsidio de corto plazo aumenta la demanda de largo plazo
- ▶ Aprendizaje de los beneficios del producto, estarán más dispuestos a pagarlo luego del subsidio
- ▶ Efecto contrario I: "Screening effect of prices" no querer pagar el precio o los costos asociados con el consumo (no-monetarios)
- ▶ Efecto contrario II: El subsidio funciona como "ancla" o precios de referencia, no se pagarán los precios más altos

Intervención

- ▶ Nueva red para prevenir la malaria: más resistente y duradera que las existentes en el mercado
- ▶ LLIN: Long-Lasting Insecticide treated Net
- ▶ Un subsidio inicial, permitiendo el uso, debería aumentar la demanda de largo plazo
- ▶ Cómo medirlo? Aumento de la demanda vs. "anchoring" o precios de referencia

Diseño del experimento

- ▶ Experimento en dos fases:
 - ▶ Primera Fase: En seis comunidades, se asignaba aleatoriamente el subsidio a los hogares. Cada hogar tenía tres meses para comprar el producto al precio subsidiado.
 - ▶ Subsidios variaban entre U\$0 a U\$3.8 (equivalente a dos días de trabajo en agricultura en el área)
 - ▶ Segunda fase: Un año más tarde, todos podían comprarla a U\$2.30. La red no se vendía fuera del experimento. La red tradicional costaba U\$1.50
- ▶ Permite estimar efectos de corto y largo plazo

Diseño del experimento

- ▶ Evidencia de redes tratadas con insecticidas, bajo uso, necesitan re-tratamiento cada seis meses
- ▶ Innovación LLIN dura 4-5 años.
- ▶ Olyset Net (LLIN) se introduce en Kenia en 2006 (aprobada por WHO en 2001)
- ▶ Subsidios existentes para las redes tradicionales para embarazadas y con menores de 5 años, costo de U\$0.75, U\$1.50 para el resto de la población.

Muestra

- ▶ 80% de los hogares tenía una red en la línea de base, hogares grandes
- ▶ 41% de la gente dormía regularmente usando la red
- ▶ 33% tenía una LLIN que había sido distribuida gratis por el gobierno 10 meses antes del estudio, pero eran de otra marca (Permanet)

Primera Fase

- ▶ Distrito de Busia, Oeste de Kenia, malaria durante todo el año.
- ▶ 1120 hogares de seis comunidades rurales.
- ▶ Se creó una muestra por área con los registros administrativos escolares para localizar hogares con niños.
- ▶ Los hogares se asignaban aleatoriamente a un nivel de subsidio entre 100 y 40%.(U\$ 0 a U\$ 1 al tipo de cambio corriente)
- ▶ 17 precios se ofrecían en total, pero cada área recibía solo 4 o 5 de los precios posibles.
- ▶ Solo dos áreas tenían un subsidio de 100%.

Primera Fase

- ▶ Encuesta de línea de base y entrega de cupones con descuento
- ▶ Cupón con descuento: fecha de vencimiento, en donde podía canjearse, precio final, precio de mercado.
- ▶ Seis negocios participantes, no se podían vender fuera del estudio. Si no eran canjeadas con los cupones, no podían ser vendidas.
- ▶ Monitoreos en los negocios cada dos semanas
- ▶ Seguimiento de los hogares que canjeaban los cupones durante dos meses (encuesta de seguimiento) con visitas sorpresa: uso de la red, autorreportado y observado por los encuestadores.

Segunda Fase

- ▶ En 4 de las 6 áreas se hizo un seguimiento de largo plazo (12 meses luego de la distribución inicial)
- ▶ Todos los hogares asignados inicialmente, no importaba si hubieran redimido el cupón o no.
- ▶ Incidencia de malaria, redimieron cupón, sabían de otros hogares que sí lo hubieran hecho, comentarios.
- ▶ Para los que lo habían redimido, se recolectaba el uso como en la primera encuesta de seguimiento
- ▶ Al final de la visita, todos recibían un segundo cupón por U\$2.30.
- ▶ Mismo procedimiento con los negocios.
- ▶ Alto cumplimiento con el protocolo (+90%)

"Short Run Subsidies..."

TABLE I
BASELINE CHARACTERISTICS OF PARTICIPATING HOUSEHOLDS

	(1) Sample Mean	(2) Sample Std. Dev.	(3) OLS Coeff. on Phase 1 Price (in US\$)	(4) OLS Coeff. on (Phase 1 Price in US\$) Squared	(5) <i>p</i> -Value Joint Test (Price and Price Squared)	(6) OLS Coeff. on High Subsidy in Phase 1	(7) <i>N</i>
<i>Household (HH) demographics</i>							
Household size	7.1	2.7	-1.207 (0.536)	-0.919 (0.443)	0.145	-0.586 (0.393)	1112
Age of household head	45.7	13.4	-1.608 (2.608)	-2.311 (2.165)	0.065	-1.064 (1.912)	1079
Number of children (under 18) currently living in household	5.4	2.9	-0.747 (0.552)	-0.606 (0.456)	0.490	-0.299 (0.405)	1120
<i>Socio-Economic Status</i>							
Female head has completed primary school	0.25	0.43	-0.068 (0.084)	-0.013 (0.07)	0.765	-0.020 (0.062)	1116
Number of household members with an income-generating activity	1.8	1.0	-0.247 (0.203)	-0.094 (0.168)	0.071	-0.2 (0.149)	1112
Household assets index value (in US\$)	338	325	-30.866 (62.897)	6.329 (51.957)	0.800	-30.097 (46.132)	1120
Electricity at home	0.02	0.14	0.013 (0.027)	0.019 (0.022)	0.791	0.004 (0.02)	1108
At least one member of HH has a bank account	0.12	0.33	-0.071 (0.064)	-0.045 (0.053)	0.520	-0.016 (0.047)	1116

"Short Run Subsidies..."

TABLE I—Continued

	(1) Sample Mean	(2) Sample Std. Dev.	(3) OLS Coeff. on Phase 1 Price (in US\$)	(4) OLS Coeff. on (Phase 1 Price in US\$) Squared	(5) <i>p</i> -Value Joint Test (Price and Price Squared)	(6) OLS Coeff. on High Subsidy in Phase 1	(7) <i>N</i>
<i>Bednet Ownership at Baseline</i>							
Number of bednets owned	1.7	1.5	−0.226 (0.292)	−0.274 (0.241)	0.636	−0.051 (0.214)	1112
Share of HH members that slept under a net the previous night	0.41	0.37	−0.038 (0.072)	−0.047 (0.059)	0.615	0.002 (0.052)	1112
HH owns a circular PermaNet LLIN ^a	0.33	0.47	−0.169 (0.132)	−0.195 (0.141)	0.520	−0.068 (0.076)	538
HH ever received a free bednet	0.32	0.47	−0.108 (0.091)	−0.095 (0.075)	0.533	−0.027 (0.067)	1112
Has ever shopped at shop where voucher has to be redeemed	0.62	0.49	−0.036 (0.085)	0.029 (0.071)	0.609	−0.035 (0.062)	1110
Declared willingness to pay for a bed net (in US\$)	1.56	1.55	−0.285 (0.306)	−0.003 (0.252)	0.353	−0.202 (0.225)	1100
Distance from shop where voucher has to be redeemed (in km)	1.86	1.58	−0.677 (0.302)	−0.534 (0.249)	0.108	−0.334 (0.222)	1094

Notes: Columns 3 and 4 show coefficient estimates and their standard errors for two independent variables (the Phase 1 price, column 3, and its square, column 4) estimated through a common linear regression (one for each row) with area fixed effects. Column 6 presents coefficient estimates from a separate OLS regression with area fixed effects for each row. Standard errors are presented in parentheses.

^aThe LLINs subsidized during the experiment were family-size rectangular Olysets.

Resultados Directos - Primera fase




FIGURE 1.—Effects of phase 1 price subsidy on *Phase 1* adoption. Notes: Data from 1120 households (Panels A and C), 479 households (Panel B, hollow circles), 273 households (Panel B, solid circles). The size of the circles reflects the relative size of the sample at each price point. The lines are quadratic fits (Panels A and C) or linear fits (panel B). The 1-yr follow-up was conducted in only four of the six study areas. Usage is self-reported (see Table II for results on observed usage). The exchange rate at the time of the study was around Ksh 65 to US\$1.

Efectos derrame

- ▶ Asignación aleatoria de monto de subsidios "within villages"
- ▶ Mayor adopción con subsidios más grandes, mayor exposición si había más subsidios altos
- ▶ $Y_{hj1} = \beta high_{hj1} + \gamma ShareHigh_{hj1} + v_j + \varepsilon_{hj1}$
- ▶ Y_{hj1} si el hogar h del área j compró la red en la fase 1
- ▶ $high_{hj1} = 1$ si el hogar recibió un subsidio alto
- ▶ $ShareHigh_{hj1}$ % de vecinos en distintos radios con subsidio alto

Efectos derrame positivos

TABLE II
EXPERIMENTAL RESULTS

	(1)	(2)	(3)	(4)	(5)
	Purchased Olyset Net in Phase 1	Purchased and Used Olyset Net in Phase 1 ^a	Purchased Olyset at 150 Ksh in Phase 2	Purchased Both Olysets	Purchased Waterguard ^b
Phase 1 Price $\leq$ Ksh 50 (high subsidy)	0.387 (0.034)*** [0.034]***	0.281 (0.033)*** [0.033]***	0.068 (0.040)* [0.04]*	0.115 (0.031)*** [0.033]***	0.046 (0.065) [0.052]
Density of Phase 1 high subsidy recipients within 500-meter radius	0.223 (0.092)** [0.083]***	0.168 (0.090)* [0.088]*	-0.183 (0.099)* [0.119]	-0.102 (0.078) [0.104]	-0.156 (0.144) [0.145]
Area fixed effects	Yes	Yes	Yes	Yes	Yes
Observations	1094	1094	584	584	256
Mean of dependent variable	0.458	0.321	0.158	0.094	0.434
Mean of dependent variable in non-“high subsidy” group	0.341	0.233	0.137	0.057	0.411

Notes: Linear probability model estimates. All regressions include enumeration area fixed effects and control for two cross-cutting randomized treatments (gender of voucher recipient and framing) discussed in Dupas (2009). Twenty-six (15) observations are dropped for Phase 1 (Phase 2) because they do not have valid GIS data to compute the social exposure variables. White standard errors presented in parentheses. Standard errors corrected for spatial dependence are presented in brackets. * indicates significance at 10%; ** at 5%; *** at 1%. Results are unaffected if household-level characteristics shown in Table I are controlled for. Results are also unaffected if a control for population density (total number of study households within 500-meter radius) is controlled for.

^a“Purchased and Used Olyset in Phase 1” is a dummy equal to 1 if the household redeemed the first Olyset voucher and the net was seen hanging during at least one of the two surprise follow-up visits.

^bWaterguard is a water purification product. Vouchers for Waterguard subsidized at 50% were offered 5 months after the first Olyset voucher was distributed, to test for the presence of cross-product entitlement effects. This Waterguard voucher sub-experiment was conducted in only the two enumeration areas where the High Subsidy was a full subsidy. See Section 5 of the text for details.

Resultados segunda fase

- ▶ Existe efecto aprendizaje que haga que los hogares que recibieron el subsidio más alto (y que adoptó más) en la primera fase lo compren más en la fase 2?
- ▶ Los efectos son más bajos (Columna 3), pero parecen ser más altos que los "anchoring", que reducirían la voluntad a pagar un precio más alto cuando los subsidios caen.

Comentarios Finales: Validez Externa

- ▶ Un subsidio no reduce la voluntad a pagar cuando el subsidio desaparece (manteniendo el riesgo de enfermedad constante)
- ▶ Parece consistente con la idea de aprendizaje
- ▶ Son representativos para otros productos de salud? Vacunas? filtros purificadores de agua? cloro? Cocinas? Medicación para desparasitación?
- ▶ Durabilidad, creencias previas sobre la facilidad o conveniencia de usarlo
- ▶ Distintos tipos de aprendizaje: p.ej. clorinar el agua una vez.
- ▶ Depende de las externalidades: Cocinas vs. Redes para malaria

Diseños no experimentales

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Clase 1 - Abril 2020

Evaluación segunda parte del curso

- ① **Trabajos prácticos (2).**
- ② **Presentación de artículo.**

Presentación de artículo

Mi idea era hacerlo en grupos de 3 personas. Ahora propongo que sea virtual (video grabado) y si quieren hacerlo en grupo OK.

- ❶ **Hasta este miércoles tienen tiempo de enviarme las preferencias (ranking) de los temas** que veremos en las próximas clases. Para el próximo lunes, en base a sus preferencias, yo les enviaré un artículo que tienen que presentar en un video de 5-7 minutos y les diré en qué fecha tienen que mandarlo.
- ❷ **¿Qué espero de esta presentación?**
 - ❶ Presentarán filmas en las que resuman el artículo.
 - ❷ Se espera que además hagan una buena crítica del artículo.
 - ❸ Sería ideal si pueden replicarlo (le proporcionaría los datos) o que propongan una extensión interesante. En ese caso pueden dedicar 3 minutos más a explicar eso en el video.
- ❸ **TODOS veremos estos videos.** Los vamos a comentar, entre todos, en los primeros minutos de las clases online.

Bibliografía

① Libros:

- ① Angrist, J. y J.S. Pischke. (2014). Mastering 'Metrics: The Path from Cause to Effect, Princeton University Press.
- ② Angrist, Joshua and Jorn-Steffen Pischke. (2008) Mostly Harmless Econometrics: An Empiricists's Companion. Princeton University Press.
- ③ Cunningham, Scott. (2018). Causal Inference: The Mixtape.
- ④ Hay más en el programa.

② Papers con aplicaciones.

Economía empírica

- Actualmente en Economía hay gran interés por la evidencia empírica.
 - Usamos datos para testear predicciones de la teoría y para cuantificar las relaciones predichas.
- Particular interés por el uso de métodos cuantitativos para medir el impacto de políticas públicas → Entender qué funciona y qué no, para así mejorar la asignación de recursos.
 - Necesitamos personas que sean capaces de evaluar correctamente los efectos de las políticas públicas (ustedes!) y ciudadanos y hacedores de políticas que sepan entender y usar esas evaluaciones (ustedes!).
 - Por eso es fundamental que uds. tengan las herramientas para hacer buenos análisis empíricos y para comprender los análisis de otros. Y este es el objetivo del curso.

¿De qué hablamos cuando hablamos de causalidad?


- Tenemos una variable «X» y una variable «Y» y queremos entender cómo Y se ve afectada por X.
- Si observamos que ambas variables, X e Y, están correlacionadas... ¿podemos inferir que X causa Y?
 - Correlación vs causalidad.

Correlación y causalidad

- **Correlación:** grado de asociación entre dos variables.
 - X (lluvia) e Y (gente con paraguas)
- **Causalidad:** efecto causal de una variable sobre otra
 - La relación va sólo en una dirección: $X \rightarrow Y$
- En este curso intentaremos entender bajo qué escenarios/supuestos podemos concluir que X causa Y (¿cómo podemos identificar el efecto de X en Y?)

¡Correlación no implica causalidad!

Los países en donde se come más chocolate reciben más premios Nobel...



¿Deberíamos comer más chocolate?

Y: # de premios Nobel en el país (proxy de habilidades cognitivas en ese país)

X: Consumo de chocolate pc

¿Deberíamos comer más chocolate?

Y: # de premios Nobel en el país (proxy de habilidades cognitivas en ese país)

X: Consumo de chocolate pc

$$\text{corr}(X, Y) \neq 0$$

① $X \rightarrow Y$: el chocolate mejora las habilidades cognitivas

¿Deberíamos comer más chocolate?

Y: # de premios Nobel en el país (proxy de habilidades cognitivas en ese país)

X: Consumo de chocolate pc

$$\text{corr}(X, Y) \neq 0$$

- 1 $X \rightarrow Y$: el chocolate mejora las habilidades cognitivas
- 2 $Y \rightarrow X$: la gente más inteligente come más chocolate (quizás están más informadas de los recientes estudios académicos sobre cómo el chocolate nos hace más felices, incluso a nuestros bebés!)

¿Deberíamos comer más chocolate?

Y: # de premios Nobel en el país (proxy de habilidades cognitivas en ese país)

X: Consumo de chocolate pc

$$\text{corr}(X, Y) \neq 0$$

- 1 $X \rightarrow Y$: el chocolate mejora las habilidades cognitivas
- 2 $Y \rightarrow X$: la gente más inteligente come más chocolate (quizás están más informadas de los recientes estudios académicos sobre cómo el chocolate nos hace más felices, incluso a nuestros bebés!)
- 3 $Z \rightarrow X, Y$: condiciones climáticas, geográficas, socioeconómicas, etc, aumentan el consumo de chocolate y también impactan sobre otras variables que son las que realmente aumentan la probabilidad de que haya más premios Nobel en un país...

Más evidencia sobre los beneficios del chocolate: Los efectos de comerlo durante el embarazo

news.bbc.co.uk/2/hi/health/3604275.stm

an error occurred while processing this directive

BBC NEWS

Watch One Minute World News

News Front Page

- Africa
- Americas
- Asia-Pacific
- Europe
- Middle East
- South Asia
- UK
- Business
- Health**
- Medical notes
- Science & Environment
- Technology
- Entertainment

Also in the news

Video and Audio

Programmes

- Have Your Say
- In Pictures
- Country Profiles
- Special Reports

RELATED BBC SITES

- SPORT
- WEATHER
- ON THIS DAY
- EDITORS' BLOG

Last Updated: Tuesday, 6 April, 2004, 23:16 GMT 00:16 UK

E-mail this to a friend

Printable version

Chocolate 'makes for happy babies'

It could be the perfect excuse for mums-to-be everywhere this Easter.

Scientists in Finland say eating chocolate during pregnancy may make for happier, livelier babies.

They questioned 300 women before and after they gave birth. They found those who ate chocolate daily were more likely to say they had happy babies.

According to a report in New Scientist magazine, the scientists believe mood-altering chemicals in chocolate may be responsible.

Katri Raikkonen and colleagues at the University of Helsinki questioned each of the women while they were pregnant.

The women were asked to rate their stress levels and the amount of chocolate they ate.

The women were surveyed again six months after they had given birth. This time they were asked to rate their infants' behaviour.

The scientists found that women who regularly ate chocolate while they were pregnant were more likely to say their babies smiled and laughed a lot. They were also more likely to say they were active.



Some of the women ate chocolate everyday during their pregnancy

"I wouldn't advocate supplementing the diet during pregnancy with chocolate"
Nigel Denby,
British Dietetic Association

New Scientist

HOME NEWS TECHNOLOGY SPACE PHYSICS HEALTH EARTH HUMANS LIFE TOPICS EVENTS JOBS MAGAZINE

Home | News

f t e p + 13

DAILY NEWS 7 April 2004

Chocolate in pregnancy keeps baby happy

Expectant mothers can take heart this Easter. Tucking into chocolate eggs is good for the baby, according to a study of over 300 women – especially if you are feeling a bit on edge.

Katri Raikkonen at the University of Helsinki, Finland, and her colleagues asked pregnant women to rate their stress levels and chocolate consumption.

After the babies were born, they looked for an association between the amount of chocolate their mothers had eaten and the babies' behaviour. Six months after birth, the researchers asked mothers to rate their infants' behaviour in various categories, including fear, soothability, smiling and laughter.

The babies born to women who had been eating chocolate daily during pregnancy were more active and "positively reactive" – a measure that encompasses traits such as smiling and laughter.

And the babies of stressed women who had regularly consumed chocolate showed less fear of new situations than babies of stressed women who abstained.

The researchers point out that they cannot rule out the possibility that chocolate consumption and baby behaviour are both linked with some other factor.

But they speculate that the effects they observed could result from chemicals in chocolate associated with positive mood being passed on to the baby in the womb.

Journal reference: *Early Human Development* (vol 76, p 139)

Los efectos de comer chocolate durante el embarazo

Early Human Development

RSS Feeds Mobile

Login Register Subscribe

Articles & Issues Best Practice Guidelines Special Issues: Neonatal Update For Authors Journal Info Subscribe More Periodicals

All Content Search Advanced Search

< Previous Article February 2004 Volume 76, Issue 2, Pages 139–145 Next Article >

Access this article on ScienceDirect

Sweet babies: chocolate consumption during pregnancy and infant temperament at six months

Katri Raikkonen Anu-Katriina Pesonen Anna-Liisa Järvenpää Timo E Strandberg

DOI: <http://dx.doi.org/10.1016/j.earlhumdev.2003.11.005>

Purchase this article (PDF Included)

Buy Now \$31.50 USD (24 hour access)

Subscribe to this title

Subscribe Now

Article Tools

PDF (108 KB)

Download Images (.ppt)

About Images & Usage

Email Article

Add to My Reading List

Export Citation

Create Citation Alert

Cited by in Scopus (8)

Request Permissions

Order Reprints (100 minimum order)

Related Articles

Social stress regulation in 4-month-old infants: Contribution of maternal social engagement and infants' 5-HTTLPR genotype
Early Human Development, Vol. 91, Issue 3

Infants of opioid-dependent mothers: Neurodevelopment at six months
Early Human Development, Vol. 91, Issue 1

The relation of infant attachment to attachment and cognitive and behavioural outcomes in early childhood
Early Human Development, Vol. 90, Issue 9

Abstract Full Text Images References

Abstract

Background: Chocolate contains several biologically active components potentially having behavioral and psychological consequences. **Aims:** We tested whether chocolate consumption and stress experiences during pregnancy predict mother-rated infant temperament at 6 months. **Design and subjects:** Prenatal frequency of chocolate consumption and intensity of psychological stress experience of the mothers, and temperament characteristics of the infants 6 months postpartum were evaluated in 305 consecutive, healthy mother-infant dyads. **Results:** Mothers who reported daily consumption of chocolate rated more positively the temperament of their infants at 6 months. Maternal prenatal stress predicted more negatively tuned ratings of the infant temperament, particularly among those who reported never/seldom chocolate consumption. However, this effect was not observed among the mothers reporting weekly or daily chocolate consumption. **Conclusions:** In addition to producing subjective feelings of psychological well being, chocolate may have effects at multiple environmental and psychological levels.

¿Comer más chocolate para tener bebés más felices?

Sweet babies: chocolate consumption during pregnancy and infant temperament at six months (Early Human Development, vol 76, p 139)

- **Objetivo:** testear si el consumo de chocolate durante el embarazo predice el temperamento infantil calificado por la madre.
- **Resultados:** Las madres que informaron consumir chocolate semanalmente calificaron más positivamente el temperamento de sus bebés a los 6 meses.
- **Conclusiones:** el chocolate puede tener efectos positivos en múltiples aspectos ambientales y psicológicos.

¿Comer más chocolate para tener bebés más felices?

Sweet babies: chocolate consumption during pregnancy and infant temperament at six months (Early Human Development, vol 76, p 139)

- **Objetivo:** testear si el consumo de chocolate durante el embarazo predice el temperamento infantil calificado por la madre.
- **Resultados:** Las madres que informaron consumir chocolate semanalmente calificaron más positivamente el temperamento de sus bebés a los 6 meses.
- **Conclusiones:** el chocolate puede tener efectos positivos en múltiples aspectos ambientales y psicológicos.

Intuitivamente, ¿qué problemas (de identificación) ven en el estudio?

- Piensen en términos de X, Y , Z y sus relaciones.

¿La correlación implica causalidad?

No siempre...

- ① $Y \rightarrow X$: causalidad inversa
- ② $Z \rightarrow X, Y$: confounding factors / selección
- ③ By chance

Nosotros intentaremos lidiar con estos problemas de endogeneidad a fin de poder identificar efectos causales.

Contrafactuales

- El problema fundamental en cuanto a inferencia causal es que es imposible observar a la misma unidad bajo tratamiento ($D_i = 1$) o sin tratamiento ($D_i = 0$).
- No observamos el contrafactual para estimar $\Delta_i = Y_i(1) - Y_i(0)$
 - Porque no sabemos qué hubiera pasado con el individuo i si no hubiera sido tratado (si observamos $Y_i(1)$ no podemos observar $Y_i(0)$).
- ¿Y por qué no hacemos la diferencia entre los valores de Y para los $D=1$ y los valores de Y para $D=0$?
- **Sesgo de selección** (visto la clase pasada).

Sesgo de selección: estimación naive (ATT)

$$\begin{aligned} E\{Y_i|D_i = 1\} - E\{Y_i|D_i = 0\} &= \\ &= E\{Y_i(1)|D_i = 1\} - E\{Y_i(0)|D_i = 0\} \\ &= E\{Y_i(1)|D_i = 1\} - E\{Y_i(0)|D_i = 1\} + \mathbf{E\{Y_i(0)|D_i = 1\} - E\{Y_i(0)|D_i = 0\}} \\ &= \tau + \mathbf{\text{sesgo de selección}} \end{aligned}$$

- Sesgo: diferencia entre los outcomes de los tratados y los no tratados en ausencia de tratamiento. Si estos outcomes no son iguales en el baseline, entonces habrá un sesgo en nuestra estimación.
- Existen características observadas y no observadas que causan que unos individuos decidan participar y otros decidan no hacerlo (grupos de control y tratamiento son distintos aun en ausencia del programa)
- Este es el gran reto al evaluar el impacto de un programa.

Contrafactuales

¿De qué depende el criterio de selección en el programa?

- Selección en variables observables (Conditional Independence Assumption o CIA).
- Selección en no observables constante en el tiempo.
- Selección en no observables no constante en el tiempo.

¿Cómo construir un buen grupo de control?

- Los grupos de tratamiento y de control deben ser iguales en tres dimensiones:
 - Idénticos en ausencia del programa, esto no debe ser cierto a nivel individual, si para el promedio
 - Los dos grupos deben reaccionar al programa de la misma manera
 - No pueden estar expuestos a otras intervenciones de manera diferencial
- Si el grupo de comparación es inválido, entonces los estimadores de impacto estarán sesgados.

Solución 1: Aleatorización

- La aleatorización resuelve el problema fundamental de la identificación causal porque permite utilizar las unidades de control, C, como el contrafactual de lo que sucedería con las unidades tratadas, T, en ausencia de tratamiento, y viceversa.
- $E\{Y_i(0)|D_i = 1\} = E\{Y_i(0)|D_i = 0\} = E\{Y_i(0)\} \rightarrow \text{sesgo} = 0$
- Experimentos: Podemos diseñar experimentos en los que aleatoriamente algunos reciban el tratamiento y otros no, y así evitar sesgos de selección.
- Podríamos entonces analizar el efecto causal de un “tratamiento” comparando las unidades asignadas al control y al tratamiento cuando el mismo se asigna de forma aleatoria por medio de un experimento diseñado.
- La parte del curso de María Laura les enseña lo que hay por detrás de estos diseños.

Aleatorización: Desventajas

- Pero muchas veces no podemos asignar aleatoriamente un tratamiento a unos y excluir a otros, ya sea por cuestiones éticas, técnicas/prácticas o por ambas razones
- **Selective compliance:** individuos pueden o no aceptar el programa al cual fueron asignados aleatoriamente. Si la autoselección no es aleatoria, reaparecen los sesgos.
- **Substitution problem:** el saberse fuera de la elección puede incentivar a los del grupo C a cambiar el comportamiento (ej. buscar asistencia por su cuenta).
- Comportamientos pueden variar sabiendo que se trata de un experimento (Hawthorne effect).
- Validez externa: ¿cuán extrapolables son los resultados del experimento?

Estimación causal a partir de un diseño no-experimental

- Nosotros veremos métodos alternativos de evaluación para aplicar cuando no podemos implementar evaluaciones por medio de experimentos aleatorios.
 - **Experimentos naturales** con «datos observacionales».
- **Idea:** aproximarnos tanto como podamos a un experimento aleatorio.
- Clave: los **supuestos de identificación** deberán ser muy claros.

Algunos diseños no experimentales que cubriremos

- Diferencia en Diferencias
- Estimadores de Apareamiento
- Variables Instrumentales
- Regresión Discontinua
- ***Estudios de Eventos***


Estudio de Eventos

Estudio de Eventos

- Datos necesarios: datos de panel.
- **Caso:** todos los individuos (unidades) del panel reciben el tratamiento en algún momento, pero lo hacen en momentos distintos y esos momentos son “cuasi-aleatorios” (o “como si fueran aleatorios”).
- **Plus:** Intuitivo y visualmente atractivo.

Motivación por medio de un ejemplo (Kleven y Landais (2018))

Kleven y Landais (2018) utilizan datos administrativos daneses (período 1980-2013) para evaluar el efecto que el nacimiento de un hijo tiene sobre los ingresos de las mujeres y de los hombres



Resultados: La llegada del primer hijo genera una brecha de género en ingresos de alrededor del 20 % (que se mantiene en el largo plazo).

Identificación

Supuesto de identificación: el momento del evento (entrada al tratamiento) es “aleatorio”: no está correlacionado con el outcome de interés

- El momento en el que los individuos comienzan a recibir el tratamiento no está correlacionado con variables no-observables (para el econometrista) que sí correlacionan con la trayectoria de la variable de interés sobre la cual se quieren medir los efectos causales del tratamiento
- El supuesto puede ser condicional a observables (variables de control que sí vea el econometrista)

Identificación

- Como el momento en el que comienza el tratamiento del individuo es ortogonal a los determinantes no observables de la variable de interés (que debería tener una trayectoria “suave” en el tiempo), la discontinuidad que se observe en la variable de interés después del tratamiento puede ser asignada al efecto del tratamiento

Estimación y estructura de los datos

- En la base de datos tendremos un **panel** de $i = 1, \dots, N$ unidades
- **Outcome:** Y_{it} , que será observado por $t = 1, \dots, T$ periodos ("tiempo calendario"), o al menos para un subconjunto de estos períodos.
- **Evento:** Cada unidad recibirá el tratamiento en algún período " E_i " dentro de la muestra
 - y aquí asumimos que i se mantiene en el tratamiento por todos los períodos siguientes a E_i
- Definimos $\tau_{it} = t - E_i$ como "**tiempo relativo al evento**", que indica el número de períodos hasta o desde el evento.
 - Indicador de **tratamiento**: $D_{it} = 1$ si $\tau_{it} \geq 0$, $D_{it} = 0$ si $\tau_{it} < 0$

Especificación básica

$$Y_{it} = \sum_{(k \neq -1)} \beta_k \cdot I(\tau_{it} = k) + \sum_{t=1}^T \delta_t + \epsilon_{it}$$

- $\sum_{(k \neq -1)} \beta_k \cdot I(\tau_{it} = k)$: indicadores del tiempo hasta/desde el evento
 - La categoría omitida es $k = -1$: β_k mide el impacto del tratamiento en relación con el período inmediatamente anterior al evento
 - El análisis nos permite estudiar la dinámica del efecto causal
 - β_k para $k \geq 0$ capturan los impactos dinámicos posteriores al evento para cada período k
 - β_k para $k < 0$ capturan tendencias previas al evento
- $\sum_{t=1}^T \delta_t$: efectos fijos del tiempo calendario (abreviación de $\sum_{t=1}^T \delta_y \cdot I(y = t)$)

Nota: Podríamos incluir otros controles en la regresión (X_{it})

Tendencia previa al evento

Una forma de evaluar la credibilidad del supuesto de identificación (“ortogonalidad entre el momento del evento y la variable de interés”) es analizar la tendencia del outcome previamente al momento del evento

- Si el momento en el que sucede el evento es aleatorio, en el outcome de interés no debería haber tendencias previas al evento
 - La presencia de tendencias previas cuestionaría la validez del supuesto.

Las estimaciones de β_k **dan una prueba visual** sobre esa tendencia

- Tests formales pueden encontrarse en Borusyak y Jaravel (2016).

Extensiones

1 Inclusión de **efectos fijos** en la especificación

- No podemos incluir efectos fijos individuales en la especificación anterior porque así no sería posible poder distinguir el paso del tiempo calendario t del paso del tiempo relativo al evento –ya que, para cada individuo, ambos se mueven a la par.
- Para poder incluir efectos fijos debemos hacer supuestos adicionales.
- Ver las normalizaciones requeridas para la identificación con EF en el artículo de Dobkin et al (2018) o Borusyak y Jaravel (2016).

2 Permitir **pre-trends** (ver Dobkin et al, 2018)

3 Incluir grupo de **control** (en el espíritu de DiD, que veremos más adelante).

Aplicaciones

Efectos de la maternidad en el mercado laboral femenino

- ¿Cómo podemos estimar el efecto que tienen los hijos en el mercado laboral de las madres?
- ¿Qué tal si comparamos madres y no madres?
 - ¿Les parece una buena idea? ¿Por qué?
 - ¿Qué otra idea se les ocurre? ¿Qué supuestos tienen en mente?

(1) Kleven y Landais (2018)

¿Cómo afecta la maternidad/paternidad la situación de las mujeres y hombres en el mercado laboral?


$$Y_{it} = \sum_{(k \neq -1)} \beta_k \cdot I(\tau_{it} = k) + \sum_{t=1}^T \delta_t + \gamma X_{it} + \epsilon_{it}$$

Esta regresión se estima, por separado, para hombres y mujeres que han sido padres durante el período de análisis.


- ¿Qué representan Y , τ y X ?
- ¿Cuáles son los supuestos de identificación?

(1) Kleven y Landais (2018)


A: Earnings




B: Hours Worked



C: Participation Rates



D: Wage Rates




Notas: Los gráficos muestran los coeficientes estimados a partir de la ecuación anterior divididos por un contrafactual estimado en el cual los individuos no tendrían hijos.

(2) Berniell et al (2019)


¿Qué pasa en América Latina?: El caso de Chile

Figure 2: Impacts on Earnings



(2) Berniell et al (2019): Efectos de la maternidad en el mercado laboral de la mujer

Figure 3: Impacts on labor supply



(2) Berniell et al (2019). Efectos de la maternidad en la informalidad laboral (brecha de género en informalidad)

Figure 6: Impacts on occupational choice: formal and informal employment (unconditional on working)





Figure 7: Impacts on occupational choice: informal employment (conditional on working)



(3) Sarsons (2018) - Interpreting Signals in the Labor Market: Evidence from Medical Referrals

Utilizando datos sobre las derivaciones de sus pacientes que los médicos hacen a los cirujanos, este artículo encuentra que el médico “recomendador” evalúa los resultados de las operaciones hechas por los cirujanos de manera diferente dependiendo del género del cirujano.

¿Cómo creen que estima este artículo un efecto causal? ¿Alguna otra idea?

(3) Sarsons (2018) - Interpreting Signals in the Labor Market: Evidence from Medical Referrals


¿Cómo estima este artículo un efecto causal?: Estudio de eventos

- **Tratamiento:** muerte de un paciente del cirujano i luego de la cirugía (hasta una semana después)
- **Evento:** momento de la muerte (E_i)
- **Outcome:** derivaciones que los médicos (“recomendadores”) hacen a sus pacientes para realizar cirugías con el cirujano i


¿Cuál sería la ecuación a estimar?

(3) Sarsons (2018)

- **Efecto** estimado: después de la muerte de un paciente del cirujano i , los médicos (“recomendadores”) se vuelven más pesimistas sobre la capacidad del cirujano i si el cirujano es mujer que si es hombre
- disminución más pronunciada de derivaciones a cirujanas que a cirujanos luego de que se haya muerto un paciente de estos cirujanos



(3) Sarsons (2018): Placebo




(4) Bachas et al (2018): How Debit Cards Enable the Poor to Save More

- Tratamiento: Se le dieron tarjetas de débito a beneficiarios de un programa de transferencia monetarias, que antes recibían las transferencias por medio de depósitos en sus cuentas de ahorros.
- Este artículo usa un estudio de eventos para encontrar el impacto de las tarjetas de débito en diferentes outcomes

(4) Bachas et al (2018): How Debit Cards Enable the Poor to Save More


- **Resultados:** con las tarjetas de débito los beneficiarios aumentaron la cantidad de retiros de las cuentas, revisiones del saldo, la confianza reportada en el banco y sus ahorros (tasa de ahorro general aumentó en un 3-4 % del ingreso familiar)

Debit cards lead to gradual increase in savings balances (savings balance in pesos)



(5) Dobkin et al (AER 2018): The Economic Consequences of Hospital Admissions

- Consecuencias económicas de los ingresos hospitalarios de adultos.
- Datos: HRS y datos de hospitalización vinculados a informes de crédito.
- Resultados: Para los adultos mayores que no tienen seguro de salud, los ingresos hospitalarios aumentan los gastos médicos «de bolsillo», las facturas médicas impagas y la prob. de bancarrota. También reducen los ingresos, el acceso al crédito y el endeudamiento de los consumidores hospitalizados.



(5) Dobkin et al (2018): The Economic Consequences of Hospital Admissions

- Supuestos de identificación: condicionado porque hay un ingreso hospitalario durante la ventana de observación y condicionando por los controles incluidos en las regresiones, el momento de la admisión al hospital no está correlacionado con el resultado (variables de interés).
- Una admisión que esté precedida por un deterioro de la salud o una admisión causada por los efectos adversos que la pérdida del empleo genera en la salud violaría este supuesto.
- Este artículo, entre otras cosas, combina estudios de eventos y DiD, que veremos más adelante en el curso.

Otros artículos, recientes, sobre estudios de eventos

- Borusyak, Kirill y Xavier Jaravel, "Revisiting Event Study Designs," DT (2016).
- Bhalotra, Sonia Rudi Rocha y Rodrigo R. Soares. (2019). Does Universalization of Healthwork? Evidence from Health Systems Restructuring and Expansion in Brazil, IZA DP No. 12111.
- Bottan, N. and Perez-Truglia, R. (2015), "Losing my Religion: The Effects of Religious Scandals on Religious Participation and Charitable Giving," Journal of Public Economics, Vol. 129, pp. 106–119.
- Gentzkow, M., J. M. Shapiro, y M. Sinkinson (2011). The effect of newspaper entry and exit on electoral politics. American Economic Review 101(7), 2980–3018.
- Linden, Leigh, and Jonah E. Rockoff. 2008. "Estimates of the Impact of Crime Risk on Property Values from Megan's Laws." American Economic Review, 98(3): 1103-27.
- Notowidigdo Matthew J. y Jialan Wang. (2016). "The Marginal Propensity to Consume Over the Business Cycle Tal Gross", DT NBER No. 22518.

Diferencias en Diferencias

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Abril 2020

Diferencias en Diferencias

- Ejemplo de caso: Hay un grupo de personas, podemos llamarlas «tratadas», a las que en cierto momento se las sometió a alguna intervención («tratamiento»)
- Las observamos antes de que el tratamiento entrara en vigor y después
- Queremos ver si el tratamiento generó un efecto en la variable Y
- Idealmente, podríamos ver si Y cambió después del tratamiento en comparación con cómo era antes
 - **Comparación antes y después:** si observamos los resultados antes y después del tratamiento podríamos usar a los tratados antes del tratamiento como controles para los tratados luego del tratamiento (i.e. ellos mismos antes de ser tratados)
 - ¿Es esta una buena idea?: El problema de esta comparación es que puede estar contaminada por el efecto de otros eventos simultáneos diferentes al tratamiento que ocurrieron entre los dos periodos

Diferencias en Diferencias


- ¿Qué podemos usar para controlar por esos otros cambios simultáneos al tratamiento?
- Si solo una fracción de la población está expuesta al tratamiento, podemos usar el grupo que no recibió el tratamiento, pero que sí pudo haber estado expuesto a los demás cambios simultáneos, para identificar la variación temporal en las variables de resultados que no se debe a la exposición al tratamiento
 - **Esta es la idea básica del método DID**

Diferencias en Diferencias


Diferencias en diferencias

- Los métodos de diferencias en diferencias (DID) se han convertido en una herramienta muy importante para la investigación empírica.
- En el caso típico hay:
 - dos o más grupos, al menos uno tratado y un control,
 - que los observamos en dos o más períodos de tiempo: antes del tratamiento («pre») y después del tratamiento («post»)
 - **DD**: la diferencia observada en el outcome de interés entre el tratamiento y el control después del tratamiento se ajusta por la diferencia entre esos dos grupos antes del tratamiento

Diferencias en Diferencias



Diferencias en Diferencias



Diferencias en Diferencias: notación

- $D = 0$: control (nunca tratados)
- D : tratados
- $t = 1, \dots, T_0$: períodos pre-intervención
- $t = T_0 + 1, \dots, T$: períodos post-intervención
- Notar que los tratados reciben el tratamiento sólo en el período posterior a la intervención
→ cuando $t > T_0$
- $Y^d(t)$: resultado potencial bajo tratamiento « $D=d$ » en el período t
- X : covariables observables
- U : covariables no observables

Diferencias en Diferencias: notación

- Si tomemos por el momento un ejemplo con 2 períodos:
 - $t=2$ es el período post-intervención y $t=1$ pre-intervención
 - $ATT \equiv \mathbb{E} [Y^1(2) - Y^0(2)|D = 1]$
 - Problema: no sabemos cuál es el valor del contrafactual $Y^0(2)|D = 1$
 - Solución bajo algunos supuestos podemos estimar este contrafactual por medio del método de DD

DiD - Supuesto de tendencias paralelas

«La diferencia entre ambos grupos (Tratamiento y Control) se habría mantenido constante si la intervención no hubiese ocurrido»

- Esto quiere decir que en ausencia del tratamiento habría **«tendencias paralelas»**: El cambio en los resultados entre los períodos pre y post-intervención en el grupo de control es un buen indicador de cuál hubiera sido el cambio (contrafactual) en los resultados potenciales del grupo tratado si no hubiera sido tratado

DiD - Supuesto de tendencias paralelas

Por ejemplo, en el caso en que observamos las unidades tratadas y de control solo una vez antes del tratamiento ($t = 1$) y una vez después del tratamiento ($t = 2$) tenemos que este supuesto nos dice que:

$$\mathbb{E} [Y^0(2) - Y^0(1)|D = 1] = \mathbb{E} [Y^0(2) - Y^0(1)|D = 0]$$

Esto es un supuesto, no es algo que podemos testear!

- para $D=1$: $Y^0(1)$ siempre se observa pero $Y^0(2)$ no,
- tenemos que mostrar evidencia que sustente este supuesto,
- a veces el supuesto contrafactual puede mantenerse solo después de condicionar algunas covariables observadas

Diferencias en Diferencias: desagregando el supuesto

- **Tendencias paralelas previas:** En el período previo a la intervención, las tendencias temporales en las variables de resultado son las mismas en el tratamiento y en el control
 - esto no es un supuesto, es algo que podemos testear
- **Shocks comunes:** En el período posterior a la intervención, los shocks exógenos afectan a los grupos tratados y de control por igual (**este sí es un supuesto**)

Bajo este supuesto podemos estimar el ATT

$$ATT \equiv \mathbb{E} [Y^1(2) - Y^0(2) | D = 1]$$

$$= \{\mathbb{E}[Y(2) | D = 1] - \mathbb{E}[Y(1) | D = 1]\} - \{\mathbb{E}[Y(2) | D = 0] - \mathbb{E}[Y(1) | D = 0]\}$$

Demostración:

$$ATT \equiv \mathbb{E} [Y^1(2) - Y^0(2) | D = 1] \quad (\text{Definición de ATT})$$

$$= \mathbb{E} [Y^1(2) | D = 1] - \mathbb{E} [Y^0(2) | D = 1]$$


$$= \mathbb{E} [Y^1(2) | D = 1] - (\mathbb{E} [Y^0(2) - Y^0(1) | D = 0] + \mathbb{E} [Y^0(1) | D = 1])$$

(por supuesto contrafactual)


$$= (\mathbb{E} [Y^1(2) | D = 1] - \mathbb{E} [Y^0(1) | D = 1]) - (\mathbb{E} [Y^0(2) | D = 0] - \mathbb{E} [Y^0(1) | D = 0])$$

$$= \{\mathbb{E} [Y(2) | D = 1] - \mathbb{E} [Y(1) | D = 1]\} - \{\mathbb{E} [Y(2) | D = 0] - \mathbb{E} [Y(1) | D = 0]\}$$


Diferencias en Diferencias



Diferencias en Diferencias



Diferencias en Diferencias



Diferencia en Diferencias: Estimación por regresión

- La formulación del modelo de DiD por medio de regresiones ofrece una manera conveniente de construir estimaciones DD y errores estándar (sobretudo en el caso de múltiples períodos y múltiples grupos dentro del control y el tratamiento)

Diferencia en Diferencias: Estimación por regresión

Nosotros observamos Y_{it}

- $Y_{it} = Y_{it}^0 + \beta D_i \cdot I(t > T_0)$
- Llamemos $I(t > T_0) = "Post"$ $\rightarrow Y_{it} = Y_{it}^0 + \beta D_i \cdot Post_t$
- (notar que estamos asumiendo que el efecto del tratamiento es el mismo para todos)

Si tenemos 2 períodos (pre, $t=1$, y post, $t=2$)

$$Y_{it}^0 = \alpha + \delta I(t = 2) + \gamma I(D_i = 1) + \epsilon_{it}$$

$$Y_{it}^0 = \alpha + \delta Post + \gamma D + \epsilon_{it}$$

$$Y_{it} = Y_{it}^0 + \beta D_i \cdot Post$$

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \epsilon_{it}$$

Diferencia en Diferencias: Estimación por regresión

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \epsilon_{it}$$

$$\hat{Y}(tratado, post)_i = \hat{\alpha} + \hat{\delta} + \hat{\gamma} + \hat{\beta}$$

$$\hat{Y}(tratado, pre)_i = \hat{\alpha} + \hat{\gamma}$$

$$\hat{Y}(tratado, post)_i - \hat{Y}(tratado, pre)_i = \hat{\delta} + \hat{\beta}$$

$$\hat{Y}(no tratado, post)_i = \hat{\alpha} + \hat{\delta}$$

$$\hat{Y}(no tratado, pre)_i = \hat{\alpha}$$

$$\hat{Y}(no tratado, post)_i - \hat{Y}(no tratado, pre)_i = \hat{\delta}$$

$$[\hat{Y}(tratado, post)_i - \hat{Y}(tratado, pre)_i] - [\hat{Y}(no tratado, post)_i - \hat{Y}(no tratado, pre)_i] = \hat{\beta}^{DD}$$

Estamos usando el supuesto de tendencia común:

$$\mathbb{E}[Y^0(2) - Y^0(1) | D = 1] = (\alpha + \delta + \gamma) - (\alpha + \gamma) = \delta$$

$$\mathbb{E}[Y^0(2) - Y^0(1) | D = 0] = (\alpha + \delta) - (\alpha) = \delta$$

Diferencia en Diferencias: Estimación por regresión

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \epsilon_{it}$$

	<i>Pre</i>	<i>Post</i>	<i>Diferencia</i>
<i>Tratado</i>	$\hat{\alpha} + \hat{\gamma}$	$\hat{\alpha} + \hat{\delta} + \hat{\gamma} + \hat{\beta}$	$\hat{\delta} + \hat{\beta}$
<i>No tratado</i>	$\hat{\alpha}$	$\hat{\alpha} + \hat{\delta}$	$\hat{\delta}$
<i>Diferencia</i>	$\hat{\gamma}$	$\hat{\gamma} + \hat{\beta}$	$\hat{\beta}$

Diferencias en Diferencias: adicionales

Podemos sumar covariables

$$Y_{it} = \alpha + \delta Post_t + \gamma D_i + \beta D_i \cdot Post_t + \lambda X_{it} + \epsilon_{it}$$

$$\begin{aligned}\mathbb{E}[Y^0(2) - Y^0(1)|D = 1] &= (\alpha + \delta + \gamma + \lambda \mathbb{E}\{X|D = 1\}) - (\alpha + \gamma + \lambda \mathbb{E}\{X|D = 1\}) \\ &= \delta\end{aligned}$$

$$\begin{aligned}\mathbb{E}[Y^0(2) - Y^0(1)|D = 0] &= (\alpha + \delta + \lambda \mathbb{E}\{X|D = 0\}) - (\alpha + \lambda \mathbb{E}\{X|D = 0\}) \\ &= \delta\end{aligned}$$

- Notar que estamos asumiendo que el efecto de λ no depende de t
 - Podríamos controlar por $X \cdot \text{time}$ si el efecto de x sobre Y varía con el tiempo
- Podríamos incluir efectos fijos (ejemplo: efecto fijo de individuo si tenemos datos de panel a nivel individual). Veremos esto con más detalle más adelante en esta clase.

Una aplicación de DiD

Ejemplo salarios mínimos: Card y Krueger (1994)

- El 1 de abril de 1992, Nueva Jersey elevó el mínimo estatal de \$ 4.25 a \$ 5.05, mientras que en el estado limítrofe de Pensilvania el salario mínimo se mantuvo en \$ 4.25 durante todo este período
- Card y Krueger (1994) evaluaron el efecto de este cambio en el empleo de trabajadores de bajos salarios. En un modelo competitivo el resultado de aumentar el salario mínimo es reducir el empleo
- Para esto hicieron una encuesta a unos 400 restaurantes de comida rápida de los dos estados justo antes de la reforma de NJ, y una segunda encuesta a los mismos puntos de venta 7-8 meses después

Ejemplo salarios mínimos

Características de los restaurantes de comida rápida:

- ① Gran fuente de empleo para trabajadores de bajos salarios.
- ② Cumplen la normativa de salario mínimo (especialmente las franquicias de restaurantes).
- ③ Trabajo bastante homogéneo (fácil de obtener buenas medidas de empleo y salarios)
- ④ Fácil de obtener una lista de restaurantes franquiciados (por medio de las páginas amarillas) con altas tasas de respuesta (tasas de respuesta: 87 % y 73 % - menos en Penn, porque el entrevistador era menos persistente?).

Ejemplo salarios mínimos

Estimador DiD:

- $\beta = [E(Y_2|D=1) - E(Y_1|D=1)] - [E(Y_2|D=0) - E(Y_1|D=0)]$
- Llamemos Y_1 e Y_2 al empleo antes y después de la reforma, respectivamente
- $D=1$: restaurantes en NJ (tratados), $D=0$ restaurantes den Penn (controles)
- β mide la diferencia entre el cambio promedio en el nivel de empleo en NJ y el cambio promedio en Penn
- El supuesto clave al dar una interpretación causal es que el efecto del tiempo en los dos estados es el mismo en ausencia de intervención

Ejemplo salarios mínimos

New Jersey

- Empleo en febrero: $E(Y_{ist}|s = NJ, t = Feb) = \gamma_{NJ} + \lambda_{Feb}$
- Empleo en noviembre: $E(Y_{ist}|s = NJ, t = Nov) = \gamma_{NJ} + \lambda_{Nov} + \beta$
- Diferencia entre noviembre y febrero:

$$E(Y_{ist}|s = NJ, t = Nov) - E(Y_{ist}|s = NJ, t = Feb) = \lambda_{Nov} - \lambda_{Feb} + \beta$$

Pensilvania

- Empleo en febrero: $E(Y_{ist}|s = PA, t = Feb) = \gamma_{PA} + \lambda_{Feb}$
- Empleo en noviembre: $E(Y_{ist}|s = PA, t = Nov) = \gamma_{PA} + \lambda_{Nov}$
- Diferencia entre noviembre y febrero

$$E(Y_{ist}|s = PA, t = Nov) - E(Y_{ist}|s = PA, t = Feb) = \lambda_{Nov} - \lambda_{Feb}$$

DiD

$$\begin{aligned}\hat{\beta} &= (E(Y_{ist}|s = NJ, t = Nov) - E(Y_{ist}|s = NJ, t = Feb)) \\ &\quad - (E(Y_{ist}|s = PA, t = Nov) - E(Y_{ist}|s = PA, t = Feb)) \\ &= (\lambda_{Nov} - \lambda_{Feb} + \beta) - (\lambda_{Nov} - \lambda_{Feb}) \\ &= \beta\end{aligned}$$

Ejemplo salarios mínimos

Table 5.2.1: Average employment per store before and after the New Jersey minimum wage increase

Variable	PA (i)	NJ (ii)	Difference, NJ-PA (iii)
1. FTE employment before, all available observations	23.33 (1.35)	20.44 (0.51)	-2.89 (1.44)
2. FTE employment after, all available observations	21.17 (0.94)	21.03 (0.52)	-0.14 (1.07)
3. Change in mean FTE employment	-2.16 (1.25)	0.59 (0.54)	2.76 (1.36)

Notes: Adapted from Card and Krueger (1994), Table 3. The table reports average full-time equivalent (FTE) employment at restaurants in Pennsylvania and New Jersey before and after a minimum wage increase in New Jersey. The sample consists of all stores with data on employment. Employment at six closed stores is set to zero. Employment at four temporarily closed stores is treated as missing. Standard errors are reported in parentheses

Ejemplo salarios mínimos

$$Y_{its} = \alpha + \gamma NJ_s + \delta Post_t + \beta(NJ \times Post)_{st} + \varepsilon_{its}$$

PA Pre: α

PA Post: $\alpha + \delta$

NJ Pre: $\alpha + \gamma$

NJ Post: $\alpha + \gamma + \delta + \beta$

$$\mathbf{DD} \rightarrow (NJ\ Post - NJ\ Pre) - (PA\ Post - PA\ Pre) = \beta$$

Ejemplo salarios mínimos

- Card y Krueger encontraron que el aumento del salario mínimo aumentó empleo en algunas de sus comparaciones, pero en ningún caso causó una reducción del empleo
- Este artículo originó mucho debate económico y político
- La estimación de DID se ha convertido en un método muy popular para obtener efecto causales (especialmente en los Estados Unidos, donde la estructura federal proporciona variación entre estados en cuando a la legislación)



Fuente: Scott Cunningham

Tests, placebos y SE

Test de tendencias previas paralelas


Si tenemos observaciones de varios períodos previos al tratamiento, podemos usar solo datos del período antes de la intervención para testear si hay diferencias previas en tendencias entre los dos grupos (tratamiento y control)

$$Y_{it} = \alpha + \delta time_t + \gamma D_i + \beta D_i \cdot time_t + \epsilon_{it}$$

$$H_0 : \beta = 0$$

- Notar que necesitamos varios períodos para poder estimar estas tendencias
- Problema: bajo poder para detectar diferencias...


¿Y si las tendencias no fueran paralelas?



En ese caso la identificación vendría por desviaciones de la tendencia previa

¿Y si las tendencias no fueran paralelas?

$$Y_{st} = \alpha + \gamma D_s + \delta time + \beta D_s \cdot Post_t + D_s \cdot time + e_{st}$$



- Podríamos poner efectos fijos de estado y de año
- Tendencia específica están capturadas por θ_k :

$$Y_{st} = \alpha + \sum_k \beta_k STATE_{ks} + \sum_{j=1971}^{1983} \gamma_j YEAR_{jt} + \beta D_s \cdot Post_t + \sum_k \theta_k (STATE_{ks} \times t) + e_{st}$$

Placebos

Hacer pruebas placebo (de falsificación) usando:

- ① variables de resultados alternativas que no deberían ser afectadas por el tratamiento
- ② hacer análisis usando datos de períodos anteriores (momentos ficticios de implementación del tratamiento)
 - ① ¡En este placebo no incluir períodos post tratamiento!

Errores estándar

- 1 DiD es un caso especial de datos de panel: Tenemos varias observaciones de la misma unidad $\rightarrow$ correlación serial
- 2 Además posiblemente haya correlación dentro de grupos (ej. individuos que viven en un mismo estado de US, o que van a la misma escuela)
- Por estos dos problemas, los errores estándar convencionales a menudo subestiman severamente la desviación estándar de los estimadores, por lo que los errores estándar están sesgados hacia abajo (es decir, incorrectamente pequeños)

Ver Bertrand et al. [2004]

Errores estándar: agregar los datos y cluster SE

Correlación serial

- Posible solución: **agregar** los datos en dos períodos (antes y después de la intervención)

Correlación dentro de grupos

- Posibles soluciones:
 - **agregar** los datos a un nivel superior
 - **cluster SE**: permitir un estructura de varianza-covarianza sin restricción temporal dentro de los grupos definidos a nivel de la correlación (ej. estados).
 - En Stata esto se implementa de manera directa mediante el uso de la opción «**cluster**» (en el ejemplo de estados, eligiendo como nivel de cluster los estados completos y no solo las celdas año-estado). Tener en cuenta que esto funciona solo cuando N (número de clusters) es suficientemente grande (N más grande de 50).
 - Esta es la estrategia mas usual

«Extras»

Triple diferencias en diferencias (DDD)

En algunos casos nos encontramos con una diferencia en las tendencias que podemos corregirla usando un segundo grupo de control y un DiD «placebo»

	<i>Pre</i>	<i>Post</i>	<i>Diferencia</i>
<i>Tratado</i>	$\alpha + \gamma$	$\alpha + \delta + \eta + \gamma + \beta$	$\delta + \eta + \beta$
<i>No tratado</i>	α	$\alpha + \delta$	δ
<i>Diferencia</i>	γ	$\eta + \gamma + \beta$	$\eta + \beta$

	<i>Pre</i>	<i>Post</i>	<i>Diferencia</i>
<i>Placebo tratado</i>	$\alpha + \gamma$	$\alpha + \delta + \eta + \gamma$	$\delta + \eta$
<i>Placebo no tratado</i>	α	$\alpha + \delta$	δ
<i>Placebo diferencia</i>	γ	$\eta + \gamma$	η

β^{DDD} : El estimador DDD es la diferencia entre el DD de interés y un DD placebo

Triple diferencias en diferencias (DDD)

$$Y_{ijt} = \alpha + \beta_1 X_{ijt} + \beta_2 \tau_t + \beta_3 \delta_j + \beta_4 D_i + \beta_5 (\delta \times \tau)_{jt} \\ + \beta_6 (\tau \times D)_{ti} + \beta_7 (\delta \times D)_{ij} + \beta_8 (\delta \times \tau \times D)_{ijt} + \varepsilon_{ijt}$$

El estimador DDD es la diferencia entre el DD de interés y un DD placebo

Cuidado con los cambios de composición

- Cambios de composición de la muestra cuando usamos datos repetidos de corte transversal (cross-sectional data):
 - DD puede aplicarse a secciones transversales repetidas, así como a datos de panel. Pero uno de los riesgos de trabajar con cortes transversales es que a diferencia de los datos de panel (por ejemplo, datos de panel de nivel individual), corremos el riesgo de cambios en la composición de la muestra

Intensidad del tratamiento

- Variaciones en la intensidad del tratamiento: podemos interactuar la variable de tratamiento con una variable de intensidad para explotar variación en la intensidad del tratamiento

SUTVA


Recordar siempre verificar/discutir que:

- Se cumple la condición SUTVA (Stable Unit Treatment Value assumption)
 - "las observaciones del grupo de control no se ven afectadas por el tratamiento"
 - ¿posibles violaciones de esta condición?
- No hay efecto anticipación
 - ¿posibles violaciones de esta condición?

Efectos dinámicos

- También podemos analizar si el efecto del tratamiento cambia a medida que pasa el tiempo luego de la intervención: $\sum_{\tau=0}^m \delta_{\tau} D_{s\tau}$
- Podríamos tener un modelo que incluya los dos puntos:

$$Y_{its} = \alpha + \gamma_s + \delta_t + \sum_{\tau=-q}^{-1} \gamma_{\tau} D_{s\tau} + \sum_{\tau=0}^m \beta_{\tau} D_{s\tau} + X_{ist} + \varepsilon_{ist}$$



Relación entre DiD & estudio de eventos

$$Y_{it} = \alpha + \delta Post_t + \gamma Tratado_i + \beta Tratado_i \cdot Post_t + \epsilon_{it}$$

Aquí voy a usar esta notación: $D = Tratado * Post$

- Si tenemos datos de panel, podemos generalizar esta especificación incluyendo un conjunto de efectos fijos de individuo (α_i , que capturaría la variable «tratado») y uno de tiempo (δ_t , capturarían «Post»):

$$Y_{it} = \alpha_i + \delta_t + \beta D_{it} + \epsilon_{it}$$

- ¿Qué pasa si las unidades tratadas entran al tratamiento en diferentes momentos?: i.e. D_{it} pasa de 0 a 1 en diferentes momentos para diferentes i (y puede ser siempre 0 o 1).
 - ¡Podemos usar esa misma especificación!
 - obtendremos un promedio del efecto para todos los tratados en nuestro período de análisis.

Relación entre DiD & estudio de eventos

$$Y_{it} = \alpha_i + \delta_t + \beta D_{it} + \epsilon_{it}$$

- Un modelo más general permite efectos diferenciados a lo largo del tiempo:

$$Y_{it} = \alpha_i + \delta_t + \sum_{-S}^R \beta_{\tau} D_i * 1\{\text{períodos hasta/desde el tratamiento} = \tau\} + \epsilon_{it}$$

- S: número de períodos pre tratamiento (lo ideal es que los β_{τ} sean cero antes del tratamiento)
- R: número de períodos post tratamiento
- Notar que la diferencia con lo que vemos en la clase de estudios de eventos es que aquí tenemos la posibilidad de tener un grupo de control de «nunca tratados»

Más ejemplos con aplicaciones de DiD

The impact of a social program on labor informality: The case of AUH in Argentina - Garganta y Gasparini (2015)

Garganta y Gasparini (2015) examinan el impacto de la AUH sobre la informalidad laboral

- ITT DiD
- Datos: EPH (panel rotativo)

Garganta y Gasparini (2015)

- **Tratados:** desempleados y no registrados en el período inicial de cada panel, con edades entre 18 y 70 años, pertenecientes a hogares informales (es decir, hogares sin trabajadores registrados) con niños menores de 18 años
- **Control:** trabajadores con las mismas características que el grupo de tratados potenciales excepto porque en el hogar no hay menores de 18 años (la presencia de niños menores de 18 años constituye la variable crucial que determina la elegibilidad para el grupo de trabajadores no registrados)
- **Pre y post** intervención: 2005-2009 y 2010-2011

Garganta y Gasparini (2015)

- Supuesto de identificación: en ausencia de la AUH las tendencias de la tasa de formalización laboral para los grupos de tratamiento y control habría sido similar

$$F_{it} = \alpha + \beta_1 H_{it} + \beta_2 Post + \gamma (H_{it} Post) + \theta X_{it} + u_{it}$$

- F: formalización (si un empleado informal se formaliza)
- H: Grupo tratado (con hijos)

Garganta y Gasparini (2015)

- **Resultados:** El programa podría desalentar las transiciones de los trabajadores al sector formal. Los autores encuentran que desincentiva la formalización del mercado laboral de los beneficiarios

Figure 1: Proportion of informal workers that become formal




Table 3: Effect of the AUH on the probability of becoming formal

	(1)	(2)	(3)
With_Children * After	-0.0765*** (0.0184)	-0.0695*** (0.0167)	-0.0842*** (0.0187)
With_Children (<i>H</i>)	0.0385*** (0.0123)	0.0472*** (0.0132)	0.0807*** (0.0184)
After (<i>Post</i>)	0.108*** (0.0276)	0.152*** (0.0229)	0.116*** (0.0446)
With controls, time and regional dummies	No	Yes	Yes
Excluding the unemployed	No	No	Yes
Observations	16,635	16,635	13,777
Pseudo R2	0.005	0.086	0.096

Source: Authors' calculation based on EPH microdata, 2005-2011.

Título: The Impact of a Permanent Income Shock on the Situation of Women in the Household: the case of a pension reform in Argentina

- Many countries have implemented social programs to fight poverty, that are changing the relative income of spouses.
 - these transfer programs do not only redistribute income between households but also alter the distribution of income within households.
- Non-contributory pensions: potentially higher impact on women.
 - Ideal settings to analyze impact of **asymmetric permanent income** shocks within the household.

Berniell, de la Mata y Machado (2019)

Título: The Impact of a Permanent Income Shock on the Situation of Women in the Household: the case of a pension reform in Argentina

- Many countries have implemented social programs to fight poverty, that are changing the relative income of spouses.
 - these transfer programs do not only redistribute income between households but also alter the distribution of income within households.
- Non-contributory pensions: potentially higher impact on women.
 - Ideal settings to analyze impact of **asymmetric permanent income** shocks within the household.
- This paper focus on **senior** women and ask:

*Can permanent transfers (from non-contributory pensions) affect their **marital status** and their **bargaining power** within the household despite their perceived stable lives?*

Empirical Strategy: Diff-in-Diff

Pre and post-treatment periods

- Pre-treatment years: 2004-2006
- Post-treatment years: 2007-2009.

Control and treated groups

- Treated group: Cohorts of women born between 1941-1944
- Control group: Cohorts of women born between 1950-1953.

Women	Pre treatment (2004-2006)	Post treatment (2007-2009)
TREATED born 1941-1944	ages 60-65	ages 63-68
CONTROL born 1950-1953	ages 51-56	ages 54-59

Note: control group is not affected by the reform during sample period.


Empirical Strategy: Diff-in-Diff

$$y_{i,t} = \alpha + \beta \text{Treat}_i \times \text{Post}_t + \delta_i^C + \delta_t^{YQ} + X_i' \gamma + \epsilon_{i,t} \quad (1)$$


- y is the outcome of interest
 - $\text{Treat} = 1$ if woman born in 1941-1944.
 - $\text{Post} = 1$ if outcome observed in 2007-2009.
 - δ^C and δ^{YQ} are cohort and year-quarter FE, respectively.
 - X individual characteristics (e.g. education, born abroad, regional dummies; and for married sample: age and educational differences within couples -proxy for previous bargaining power- and indicator of husband being above legal retirement-age).
 - β is the diff-in-diff estimate of the effect of the moratorium (ITT).
- Data: EPH

Results: Effects of the reform on Income


Pension recipients




Women without personal income



Monthly personal income (logs)



Wife's share of income within the couple



Effects on Divorce/Separation

	Prob. divorced/separated
Post*treated	0.027
p-value	(0.002)***
p-value wild bootstrap-t	(0.095)*
Observations	34,039
Obs. treatment	12,554
Mean dep. var.	0.14
% change	19.21%

In parentheses are two-tail p-values clustered by urban area. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. "p-value" indicates the stata outcome for two-tail p-values clustered at the urban area level. "p-value wild bootstrap" indicates two-tail p-values computed using wild bootstrap-t techniques as in Cameron et al. 2008 with a 6-point distribution as in Webb 2013 and 1500 bootstraps. Controlling for cohort dummies, year-quarter fixed effects, region fixed effects, dummy for top 1 percent of personal income, dummy for high school diploma. Sample weights using variable pondera in the EPH.

Presencia policial: Di Tella y Schargrodsky (2004)

- Rafael Di Tella and Ernesto Schargrodsky. 2004. "Do Police Reduce Crime? Estimates Using the Allocation of Police Forces After a Terrorist Attack." American Economic Review
- El artículo estudia, empíricamente, el efecto causal de la presencia policial en la reducción del crimen.
- Tras el ataque terrorista en el principal centro judío en Buenos Aires en julio de 1994, todas las instituciones judías recibieron protección policial.
- Es decir que ese suceso indujo una asignación geográfica de las fuerzas policiales que se puede presumir exógena.

Di Tella y Schargrodsky (2004)




FIGURE 1. TIMELINE OF EVENTS

- Usando datos sobre la ubicación de los robos de automóviles antes y después del ataque, los autores encuentran un gran efecto disuasivo de la presencia policial sobre el crimen.

Di Tella y Schargrodsky (2004)

$$\text{Robo de autos}_{it} = \alpha_0 + \beta * \text{Misma cuadra} * \text{Policía}_{it} + M_t + F_i + \epsilon_{it}$$

- M_t : efecto fijo del mes t
- F_i : efecto fijo de la cuadra i
- $\text{Misma cuadra} * \text{Policía}_{it}$: variable que asume el valor 1 para los meses posteriores al terrorismo si hay una institución protegida en esa cuadra y es 0 para el resto de los casos.

	number of car thefts per month per block
<i>Same-Block Police</i>	-0.07752*** (0.022)
Block fixed effect	Yes
Month fixed effect	Yes
Number of observations	7,884
R^2	0.1983

Aplicación en Stata

Ejemplo aplicación en Stata

- Datos y programas del paper de Card y Krueger (1994) disponibles en:

<http://economics.mit.edu/faculty/angrist/data1/mhe/card>

Diseño de Regresión Discontinua

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Mayo 2020

Hoy - Estimación de efectos causales a partir de un diseño no-experimental: **Regresión Discontinua (RD)**

- **RD:** es una de las estrategias no experimentales más creíbles para estimar efectos causales con datos observacionales (aunque tiene la desventaja de que el efecto estimado es local).

Caso para un diseño de regresión discontinua:

- todas las unidades tienen un score (puntuación asignada),
 - la probabilidad de que el tratamiento sea asignado a una unidad específica aumenta abruptamente para las unidades que tienen un puntaje superior a un punto de corte ("cutoff").
 - lo podemos pensar como una «aleatorización» del tratamiento a nivel «local».

Regresión discontinua

Ejemplos de reglas con “cortes arbitrarios” que darían lugar a experimentos naturales para ser analizados con un diseño de RD:

- nota para aprobar un examen
- nota para ganar una beca/premio
- edad para entrar a la escuela
- edad para conducir

¿Otro ejemplo de una regla de este estilo?

RD: idea y supuestos de identificación

- **Idea:** Si las unidades no pueden manipular su puntaje alrededor del punto de corte, esa discontinuidad en la probabilidad de recibir el tratamiento puede ser usada para aprender sobre el efecto causal (local) del tratamiento, usando a las unidades que están justo por debajo del punto de corte como contrafactuales (controles) para las unidades que están justo por arriba del punto de corte
- **Supuesto de identificación:** El supuesto básico es que las unidades que están justo por arriba y justo por debajo del cutoff son comparables entre sí en todos los aspectos relevantes, excepto por el hecho de que algunas son tratadas y otras no

Regresión discontinua: componentes

- Hay n **unidades**, indexadas por $i = 1, 2, \dots, n$,
- Cada unidad tiene un **puntaje** (score): X_i
 - en inglés también conocida como “running variable” o “forcing variable”
- **Punto de corte** (cutoff): c
- Asignación al grupo de **tratamiento**
 - La probabilidad de ser asignado al tratamiento en función del puntaje (X) cambia de forma discontinua en el punto de corte ($X=c$)
 - $T=1$ si $X \geq c$ y $T=0$ si $X < c$
 - $$Y_i = \begin{cases} Y_i(0) & \text{si } X_i < c \\ Y_i(1) & \text{si } X_i \geq c \end{cases}$$

Regresión discontinua: tipos

① **Sharp:** el cumplimiento con la asignación del tratamiento es perfecto

- todas las unidades con puntaje igual o mayor que el punto de corte reciben el tratamiento, y todas las unidades con puntaje por debajo del corte no reciben el tratamiento

② **Fuzzy RD:** el cumplimiento con lo asignado es imperfecto, pero la probabilidad a ser tratado aumenta discontinuamente en el punto de corte

③ Algunos casos especiales de RD, que no cubriremos aquí pero cuya lógica es parecida a la que analizaremos:

- ① RD con múltiples puntos de corte
- ② RD geográficos
- ③ RD con una variable de puntaje discreta que asume pocos valores

SHARP RD

(discontinuidad nítida)

Ejemplo que vamos a analizar en esta clase: Meyersson (2014)

Meyersson (2014) analiza el efecto de la representación política islámica en los municipios de Turquía sobre el desempeño educativo de las mujeres

Econometrica, Vol. 82, No. 1 (January, 2014), 229–269

ISLAMIC RULE AND THE EMPOWERMENT OF THE POOR AND PIOUS

BY ERIK MEYERSSON¹

Does Islamic political control affect women's empowerment? Several countries have recently experienced Islamic parties coming to power through democratic elections. Due to strong support among religious conservatives, constituencies with Islamic rule often tend to exhibit poor women's rights. Whether this reflects a causal relationship or a spurious one has so far gone unexplored. I provide the first piece of evidence using a new and unique data set of Turkish municipalities. In 1994, an Islamic party won multiple municipal mayor seats across the country. Using a regression discontinuity (RD) design, I compare municipalities where this Islamic party barely won or lost elections. Despite negative raw correlations, the RD results reveal that, over a period of six years, Islamic rule increased female secular high school education. Corresponding effects for men are systematically smaller and less precise. In the longer run, the effect on female education remained persistent up to 17 years after, and also reduced adolescent marriages. An analysis of long-run political effects of Islamic rule shows increased female political participation and an overall decrease in Islamic political preferences. The results are consistent with an explanation that emphasizes the Islamic party's effectiveness in overcoming barriers to female entry for the poor and pious.


Ejemplo que vamos a analizar en esta clase: Meyersson (2014)

- **unidades** de análisis: municipalidades
- **puntaje**: margen de victoria del mayor partido islámico en el municipio en las elecciones de 1994 (variable “casi” continua)
 - % de votos del candidato islámico - % de votos del oponente mas fuerte
- **tratamiento**: victoria del partido islámico
- **punto de corte** es “0” ($c=0$)

Literatura de “close elections”: comienza en con Lee (2008) y Pettersson-Lidbom (2008)

Probabilidad de recibir el tratamiento: sharp RD

$$P(T_i = 1 | X_i = x)$$



Sharp RD

- Outcomes potenciales: $Y_i(1)$ y $Y_i(0)$
 - $Y_i(1)$: resultado que se observaría bajo tratamiento
 - $Y_i(0)$: resultado que se observaría sin tratamiento
- Son potenciales porque solo se observa uno de ellos. Si la unidad i recibe el tratamiento, observaremos $Y_i(1)$ y en ese caso $Y_i(0)$ permanecerá latente (no observado)
 - Así, el efecto del tratamiento a nivel individual es imposible de conocer

Sharp RD


- Lo que observamos para cada individuo es:

$$Y_i = (1 - T_i) \cdot Y_i(0) + T_i \cdot Y_i(1) = \begin{cases} Y_i(0) & \text{si } X_i < c \\ Y_i(1) & \text{si } X_i \geq c \end{cases}$$

- Y para el promedio podemos observar:

$$\mathbb{E}[Y_i|X_i] = \begin{cases} \mathbb{E}[Y_i(0)|X_i] & \text{if } X_i < c \\ \mathbb{E}[Y_i(1)|X_i] & \text{if } X_i \geq c \end{cases}$$

ATE (Average treatment effect): $E[Y_i(1)|X_i = x] - E[Y_i(0)|X_i = x]$



- Como no hay soporte común el análisis de RD se basa en la **extrapolación**: lo central es que podamos extrapolar correctamente para poder comparar control y tratamiento.
- ¿Dónde podemos hacer la mejor extrapolación? **¿En qué punto de la gráfica “casi” que vemos las dos curvas?: en $X=c$**

$$\tau_{\text{SRD}} = \mathbb{E}[Y_i(1) - Y_i(0)|X_i = c]$$

Sharp RD: ATE (Average treatment effect)

- ¿Dónde podemos hacer la mejor extrapolación?: en $X=c$
 - Las unidades que están antes y después de c son muy similares, excepto por el efecto del tratamiento.
 - Usando los resultados observados, en ese punto podríamos calcular bastante bien la distancia vertical entre ambas curvas

$$\tau_{\text{SRD}} = \underbrace{\mathbb{E}[Y_i(1) - Y_i(0) | X_i = c]}_{\text{No observable}} = \underbrace{\lim_{x \downarrow c} \mathbb{E}[Y_i | X_i = x]}_{\text{Observable}} - \underbrace{\lim_{x \uparrow c} \mathbb{E}[Y_i | X_i = x]}_{\text{Observable}}$$

Sharp RD: ATE

- Efecto (local) del tratamiento = $\tau_{SRD} = E[Y_i(1) - Y_i(0)|X_i = c]$

$$E[Y_i(1)|X_i \rightarrow c] - E[Y_i(0)|X_i \leftarrow c]$$

ATE en el cutoff ($E[Y_i(1)|T = 1] - E[Y_i(0)|T = 0]$)



Para que esto sea cierto, nos basamos en el supuesto de continuidad

$$\tau_{SRD} = \underbrace{\mathbb{E}[Y_i(1) - Y_i(0)|X_i = c]}_{\text{No observable}} = \underbrace{\lim_{x \downarrow c} \mathbb{E}[Y_i|X_i = x]}_{\text{Observable}} - \underbrace{\lim_{x \uparrow c} \mathbb{E}[Y_i|X_i = x]}_{\text{Observable}}$$

- τ_{SRD} nos dice cuál sería el cambio de resultado promedio para unidades con nivel de puntaje $X_i = c$ si cambiamos su estado de control a tratado

Sharp RD: validez interna y validez externa

- Validez interna: muy fuerte (local, en $X=c$)
- Validez externa: limitada
 - τ_{SRD} es una estimación local, poco informativo sobre los efectos del tratamiento a otros niveles del puntaje



Sharp RD: Implementación

① Análisis gráfico

- ① datos crudos
- ② datos suavizados

② Estimación

- ① datos usados en la estimación (ancho de banda)
- ② orden del polinomio
- ③ función de pesos

③ Tests de validez

- ① variables pre-determinadas y placebos
- ② continuidad de la densidad de X
- ③ puntos de corte artificiales
- ④ sensibilidad a la exclusión de observaciones
- ⑤ sensibilidad al ancho de banda

(1) Análisis gráfico

Algo muy bueno del análisis de RD es que podemos usar análisis gráficos, que hacen al análisis más transparente

Inspeccionaremos los datos de dos formas:

(a) Presentación de datos **crudos**


(b) Presentación de datos **suavizados** (elección de la ubicación de los bins y el ancho del intervalo)

Nos sirven para detectar «a ojo» la discontinuidad y ver la variabilidad en los datos

Análisis gráfico - (a) Datos crudos de Meyersson (2014)

Comenzamos el estudio inspeccionando los datos por medio de un análisis gráfico

- **unidades** de análisis: municipalidades
- **score**: margen de victoria del mayor partido islámico
- **tratamiento**: victoria del partido islámico
- **punto de corte** es "0" ($c=0$)
- **outcome**: desempeño educativo de las mujeres



Pero no se ve muy claro si hay o no una discontinuidad, ¿no?

Sharp RD: (b) Suavizando los datos


Es más útil agregar o “suavizar” los datos antes de graficarlos

El típico gráfico inicial de un análisis de RD presenta:

- Un **polinomio** global t , que es simplemente una aproximación suave a las funciones de regresión desconocidas basadas en una regresión polinómica de orden t , ajustado por separado arriba y debajo del punto de corte y usando todos los datos originales
- **Promedios** de las muestras **locales**, representados por puntos
 - los promedio locales se crean eligiendo primero intervalos disjuntos (“**bins**”) del puntaje y calculando la media del outcome para las observaciones que caen dentro de cada bin

Meyersson (2014)

Si con los datos de Meyersson (2014) usamos 20 bins de igual longitud en cada lado del punto de corte (40 intervalos de longitud 5), y calculamos sus medias, obtenemos lo siguiente:



(al gráfico también agregamos un polinomio global de orden 4 estimado por separado para las observaciones del tratamiento y del control)

Ahora se ve un poco más claro... Pero **¿Cómo elegir el tipo y la cantidad de bins de una manera transparente y óptima?**

Sharp RD: Eligiendo la ubicación de los bins

Hay dos tipos de bins:

- 1 los que tienen la **misma longitud** (“espaciados uniformemente”, **ES**)
- 2 los que contienen (más o menos) el **mismo número de observaciones** pero cuya longitud puede variar (“espaciados por cuantiles”, **QS**)

Hay un comando de Stata que nos ayuda a construir los bins


`rdplot`

Eligiendo la ubicación de los bins con rdplot


- usamos la opción binselect para elegir entre los métodos ES y QS (binselect = "qs" o binselect = "es")
- y la opción nbins se usa para definir el número de bins

```
. rdplot Y X, nbins(20 20) binselect(qs) ///  
> graph_options(graphregion(color(white))) ///  
> xtitle(Score) ytitle(Outcome))
```

Sharp RD: Eligiendo la ubicación de los bins



(a) 40 Evenly-Spaced Bins



(b) 40 Quantile-Spaced Bins

¿Cómo elegir el ancho del intervalo (número de bins)?

Cómo elegir el ancho del intervalo: balancear precisión y sesgo

- Intervalos muy chicos (# de K grande): estimación imprecisa
- Intervalos muy grandes (# de K chico): estimación poco informativa

Hay dos métodos para elegir el número de bins:

- 1 Integrated Mean Squared Error (IMSE) Method (default de Stata)
- 2 Mimicking Variance Method

Método para elegir el número de bins: Integrated Mean Squared Error (IMSE)

¿Cómo implementarlo en Stata?


- Usamos el comando `rdplot` omitiendo la opción `nbins = c(20 20)`, y así automáticamente por default este comando elige el número de bins óptimo de acuerdo al criterio IMSE

```
. rdplot Y X, binselect(es) ///  
> graph_options(graphregion(color(white))) ///  
> xtitle(Score) ytitle(Outcome))
```


Si queremos usar MVM, usamos la opción `binselect = "esmv"`

Si queremos usar MVM pero con QS bins: opción `binselect = "qsmv"`

Método para elegir el número de bins: Integrated Mean Squared Error (IMSE)



IMSE RD Plot with Evenly-Spaced Bins



IMSE RD Plot with Quantile-Spaced Bins

(2) Estimación

Debemos tomar las siguientes decisiones:

1. la función de **pesos** $K(\cdot)$
2. el **orden** del polinomio p
3. el **ancho** de banda h (datos usados para la estimación)

Sharp RD: Estimación

La estimación normalmente se lleva a cabo estimando regresiones (polinomios) para aproximar la función de regresión $E[Y_i | X_i = x]$ a cada lado del punto de corte (con diferentes pendientes a cada lado de “c”)

Podemos hacer esta estimación de forma conjunta

Caso lineal:

$$Y = \alpha + \tau \cdot T + \beta_1 \cdot (X - c) + \beta_2 \cdot (X - c) \cdot T + \epsilon$$

donde τ estima el efecto del tratamiento en $X=c$

Podemos incrementar el orden del polinomio. Por ej.:

$$Y = \alpha + \tau \cdot T + \beta_1 \cdot (X - c) + \beta_2 \cdot (X - c)^2 + \beta_3 \cdot (X - c) \cdot T + \beta_4 \cdot (X - c)^2 \cdot T + \epsilon$$

Sharp RD: Estimación

Cuestiones importantes:

- 1 ¿Cuál es el orden adecuado del polinomio?
- 2 ¿Hace falta usar todos los datos?


Cuando todas las observaciones se utilizan para la estimación, se dice que trabajamos con polinomios globales

Cuando la estimación emplea solo observaciones con puntajes cercanos al punto de corte, los polinomios son locales


Los métodos locales son ahora el estándar en el análisis empírico de RD.

- El estimador del RD se define en un punto local ($X=c$), así que los métodos globales pueden llevar a estimadores poco confiables

Local



Global: peligro!



Sharp RD: Estimación


Los métodos locales emplean solo observaciones cercanas al punto de corte para estimar regresiones a cada lado del punto de corte

- Como los métodos locales se enfocan en aproximar las funciones de regresión solo cerca del punto de corte, se emplean polinomios de orden bajo (generalmente lineal)
- Se usan observaciones que están entre $c - h$ y $c + h$, donde $h > 0$ es el “ancho de banda” que determina el área sobre el que se realiza el análisis
- Dentro de este ancho de banda, es común pesar las observaciones para garantizar que las observaciones más cercanas a c reciban más peso que las más alejadas
 - Los pesos están determinados por una función de Kernel $K(\cdot)$

Sharp RD: Estimación

La implementación requiere entonces de elegir:


1. la función de **pesos** $K(\cdot)$,
2. el **orden** del polinomio p (en general lo óptimo es lineal)
3. el **ancho** de banda h (“bandwidth”)



Nota: en la estimación se emplean los datos crudos, no los datos agrupados que sólo los usamos en el gráfico.

Estimación: (1) Elección de la función Kernel Function

La función kernel $K(\cdot)$ asigna pesos a cada observación basándose en la distancia entre el X_i y c . Lo recomendado es usar un kernel triangular




En la práctica, las estimaciones **no varían mucho con la función K elegida**

Estimación: (2) elección del orden del polinomio

Esta sí es una **decisión que importa**, y diferentes factores han llevado a los econométristas a **preferir** que el polinomio sea de grado 1 (**lineal**)

Estimación: (3) Selección de la cantidad de datos a usar (bandwidth, "h")

Figura: dos bandwidths diferentes (h1 vs h2)



La elección del ancho de banda implica balancear el sesgo y la varianza de la estimación

Sharp RD: Estimación

$$Y_i = \alpha_- + (X_i - c) \cdot \beta_- + \varepsilon_{-,i} \quad \Bigg| \quad Y_i = \alpha_+ + (X_i - c) \cdot \beta_+ + \varepsilon_{+,i}$$

Estimación del efecto del tratamiento:

$$\hat{\tau}_{\text{SRD}}(h_n) = \hat{\alpha}_+ - \hat{\alpha}_-$$

$$Y_i = \alpha + \tau_{\text{SRD}} \cdot T_i + (X_i - c) \cdot \beta_1 + T_i \cdot (X_i - c) \cdot \gamma_1 + \varepsilon_i, \quad -h_n \leq X_i \leq h_n$$

Sharp RD: Estimación en Stata

Supongamos (ad hoc) un bandwidth de 20 %, polinomio 1 y Kernel uniforme

```
. reg Y X if X < 0 & X >= -20
```

Source	SS	df	MS	Number of obs =	608
Model	1181.56011	1	1181.56011	F(1, 606) =	13.41
Residual	53411.5774	606	88.1379165	Prob > F =	0.0003
Total	54593.1375	607	89.939271	R-squared =	0.0216
				Adj R-squared =	0.0200
				Root MSE =	9.3882

Y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
X	-.2480689	.0677526	-3.66	0.000	-.3811272 -.1150105
_cons	12.62254	.7806026	16.17	0.000	11.08952 14.15555

```
. reg Y X if X >= 0 & X <= 20
```

Source	SS	df	MS	Number of obs =	280
Model	117.305392	1	117.305392	F(1, 278) =	1.40
Residual	23307.145	278	83.838651	Prob > F =	0.2379
Total	23424.4504	279	83.9586035	R-squared =	0.0050
				Adj R-squared =	0.0014
				Root MSE =	9.1563

Y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
X	-.1219474	.1030945	-1.18	0.238	-.3248925 .0809977
_cons	15.54961	.9457779	16.44	0.000	13.68781 17.41141

$$\tau_{SRD} = 15,549 - 12,622 = 2,927$$

Sharp RD: Estimación

Como dijimos antes, obtendríamos el mismo estimador puntual mediante una regresión lineal única:

```
gen T_X = X * T
```

```
reg Y X T T_X if X >= -20 & X <= 20
```

Source	SS	df	MS	Number of obs =	888
Model	1343.1216	3	447.7072	F(3, 884) =	5.16
Residual	76718.7224	884	86.785885	Prob > F =	0.0015
Total	78061.844	887	88.0065885	R-squared =	0.0172
				Adj R-squared =	0.0139
				Root MSE =	9.3159

Y	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
X	-.2480689	.0672309	-3.69	0.000	-.3800197	-.1161181
T	2.927075	1.235287	2.37	0.018	.5026378	5.351512
T_X	.1261215	.1245877	1.01	0.312	-.1184008	.3706438
_cons	12.62254	.7745922	16.30	0.000	11.10228	14.14279

Estimación usando comando "rdrobust"

- Aunque la estimación por MCO es útil para la estimación puntual, los errores estándar proporcionados por esta rutina no son siempre válidos. Por lo tanto es mejor usar el paquete de software `rdrobust`, diseñado específicamente para análisis de RD
- Este paquete además incluye funciones para realizar la selección del ancho de banda óptimo

Estimación: comando de Stata “rdrobust”

```
rdrobust Y X, kernel(uniform) p(1) h(20)
```

Opciones:

- **p** para definir el orden del polinomio
- **kernel** para definir el kernel (uniforme, triangular, etc)
- **h** para elegir el ancho de banda manualmente
- Por default, rdrobust fija $c=0$, pero esto se puede cambiar usando la opción **c**

```
. rdrobust Y X, kernel(uniform) p(1) h(20)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	2629
			BW type =	Manual
Number of obs	2314	315	Kernel =	Uniform
Eff. Number of obs	608	280	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	20.000	20.000		
BW bias (b)	20.000	20.000		
rho (h/b)	1.000	1.000		

Outcome: Y. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
Conventional	2.9271	1.2345	2.3710	0.018	.507448 5.3467
Robust	-	-	1.6364	0.102	-.582163 6.47096

Estimación: eligiendo h con el comando “rdbwselect”

rdbwselect selecciona, basándose en los datos, el ancho de banda “óptimo”

```
. rdbwselect Y X, kernel(triangular) p(1) bwselect(mserd)
```

Bandwidth estimators for sharp RD local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	2629
			Kernel =	Triangular
			VCE method =	NN
Number of obs	2314	315		
Min of X	-100.000	0.051		
Max of X	-0.098	99.051		
Order est. (p)	1	1		
Order bias (q)	2	2		

Outcome: Y. Running variable: X.

Method	BW est. (h)		BW bias (b)	
	Left of c	Right of c	Left of c	Right of c
mserd	17.239	17.239	28.575	28.575

Sharp RD: Estimación

Podemos calcular el h óptimo usando directamente la opción `bwselect` en `rdrobust`, así:

```
. rdrobust Y X, kernel(triangular) p(1) bwselect(mserd)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	2629
			BW type =	mserd
Number of obs	2314	315	Kernel =	Triangular
Eff. Number of obs	529	266	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	17.239	17.239		
BW bias (b)	28.575	28.575		
rho (h/b)	0.603	0.603		

Outcome: Y. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	3.0195	1.4271	2.1159	0.034	.222516	5.81653
Robust	-	-	1.7758	0.076	-.30934	6.27579

Sharp RD: Errores estándar

Notar que el SE más conservador es el Robust SE

En Stata podemos estimar clustered SE usando la opción `vce(nncluster variable_de_cluster)`

```
rdrobust Y X, p(1) kernel(triangular) bwselect(mserd) vce(nncluster  
prov_num)
```



Sharp RD: incluyendo otras variables de control

- Si queremos incluir otras variables de control, notar que las variables usadas deben estar balanceadas entorno al punto de corte
- La estimación puntual no debería cambiar mucho al incluir covariables, pero sí podría mejorar la precisión
- `rdrobust Y X, covs(lista de covariates) p(1) kernel(triangular)
bwselect(mserd)`

Estimación: Representación gráfica

```
rdrobust Y X, p(1) kernel(triangular) bwselect(mserd)  
local bw = e(h_1)
```

```
rdplot Y X if abs(X) <= 'bw', p(1) h('bw') kernel(triangular)
```



(3) Tests de validez

Veremos 5 pruebas de validación

Sharp RD: Tests de validez

- Necesitamos validar el supuesto de que los resultados potenciales (promedios) son continuos en el punto de corte
- Por ejemplo, si el punto de corte es conocido por quienes serán potencialmente beneficiarios del tratamiento, debemos preocuparnos por la posibilidad de que haya manipulación del valor de su puntaje cuando estén cerca del punto de corte
- También puede haber un problema si otros tratamientos se activen en el mismo punto de corte (si por ejemplo se usan los mismos umbrales para diferentes programas sociales)
- Podemos testear formalmente si estos son o no problemas en nuestro diseño

Métodos que proporcionan evidencia indirecta sobre la validez del diseño RD

Veremos 5 pruebas de validación empírica basadas en:

- 1 chequear que “el efecto del tratamiento” es nulo sobre las **covariables** que están **predefinidas** antes del tratamiento o es nulo sobre variables en las que el tratamiento no debería tener ningún efecto (**placebos**)
- 2 chequear la continuidad de la **densidad** de puntaje alrededor del punto de corte
- 3 chequear que no hay “efecto” del tratamiento en **valores de corte artificiales**
- 4 chequear que la **exclusión de observaciones cerca del límite** no afecta tanto los resultados
- 5 analizar la sensibilidad de los resultados a las elecciones de **ancho de banda** (h)

(1) Covariables pre-determinadas y outcomes placebo

- Examinar si, cerca del punto de corte, las unidades tratadas son similares a las unidades de control en términos de características observables pre-determinadas
 - Las unidades justo arriba y justo debajo del corte deberían ser similares en todas las variables que no son afectadas por el tratamiento
- ¿Cómo lo chequeamos? Analizamos todas las covariables predeterminadas y los outcomes placebos de la misma manera en la que analizamos al outcome de interés
- Para cada una de estas variables elegimos primero un ancho de banda óptimo y luego hacemos el análisis de RD dentro de ese ancho de banda para analizar si hay un “efecto” del tratamiento en donde no debería haberlo

Análisis de continuidad para las covariables

Usando nuestro ejemplo empírico:


```
rdrobust lpop1994 X, p(1) kernel(triangular) bwselect(mserd)
```

lpop1994 es la población del municipio en 1994 (antes de las elecciones)


En un diseño RD convincente estas pruebas mostrarían que no hay discontinuidades en ninguna de esas variables

Variable	MSE-Optimal Bandwidth	RD Estimator	<u>Robust Inference</u>		Eff. Number Observations
			p-value	Conf. Int.	
Percentage of men aged 15-20 with high school education	12.055	1.561	0.358	[-1.757, 4.862]	590
Islamic Mayor in 1989	11.782	0.053	0.333	[-0.077, 0.228]	418
Islamic percentage of votes in 1994	13.940	0.603	0.711	[-2.794, 4.095]	668
Number of parties receiving votes 1994	12.166	-0.168	0.668	[-1.357, 0.869]	596
Log population in 1994	13.319	0.012	0.999	[-0.644, 0.645]	633
District center	13.033	-0.067	0.462	[-0.285, 0.130]	624
Province center	11.556	0.029	0.609	[-0.064, 0.109]	574
Sub-metro center	10.360	-0.016	0.572	[-0.114, 0.063]	513
Metro center	13.621	0.008	0.723	[-0.047, 0.068]	642


Análisis de continuidad para las covariables




(a) Log Population in 1994



(b) Number of Parties Receiving Votes in 1994



(c) Islamic Vote Percentage in 1994




(d) Islamic Mayor in 1989


(2) Densidad de la variable de puntaje

Aquí analizamos si el número de observaciones debajo del punto de corte es significativamente diferente del número de observaciones sobre el punto de corte

Si los potenciales beneficiarios no tienen la capacidad de manipular con precisión el valor del puntaje que reciben, el número de observaciones tratadas justo por encima y por debajo del corte debería ser aproximadamente similar



(a) No Sorting



(b) Sorting

(2) Densidad de la variable de puntaje

Podemos hacer un test Binomial en Stata:

Si, por ejemplo, en el caso del artículo de Meyersson nos quedamos con $X_i \in [-2, 2]$, tendremos 47 observaciones de control y 53 observaciones tratadas. Estableciendo una probabilidad de éxito igual a $1/2$, podemos realizar una prueba binomial:

```
. bitesti 100 53 1/2
```

N	Observed k	Expected k	Assumed p	Observed p
100	53	50	0.50000	0.53000
Pr(k >= 53) = 0.308650 (one-sided test)				
Pr(k <= 53) = 0.757941 (one-sided test)				
Pr(k <= 47 or k >= 53) = 0.617299 (two-sided test)				

$p=0.53$, por lo que esta simple prueba no muestra evidencia de manipulación alrededor del punto de corte

Test de densidad de CJM

- Hay tests de densidad más sofisticados (fácil de implementar en Stata)
 - Ej: rddensity implementa un test de densidad local (CJM)
- Usando los datos de Meyersson: rddensity X

```
. rddensity X
Computing data-driven bandwidth selectors.

RD Manipulation Test using local polynomial density estimation.
```

Cutoff c = 0	Left of c	Right of c	
Number of obs	2314	315	Number of obs = 2629
Eff. Number of obs	965	301	Model = unrestricted
Order est. (p)	2	2	BW method = comb
Order bias (q)	3	3	Kernel = triangular
BW est. (h)	30.540	28.285	VCE method = jackknife


Running variable: X.

Method	T	P> T
Robust	-1.3940	0.1633


- $t = -1.394$ (p-value 0.1633): no podemos rechazar la hipótesis nula de ausencia de diferencia en la densidad de las observaciones tratadas y de control en el punto de corte

Test de densidad de Cattaneo et al (CJM) , implementado en Stata vía: rddensity - Gráficos

```
rddensity X, plot plot_range(-'bandw_left' 'bandw_right')
```



(a) Histogram



(b) Estimated Density

Test de densidad

- Hay otros tests de densidad. En la clase de práctico verán el de McCrary, que también puede implementarse fácilmente en Stata
- La prueba de densidad para detectar la manipulación de RD fue propuesta por primera vez por McCrary (2008)
- El test de McCrary era el test estándar en el análisis de RD hasta hace poco, pero el nuevo test (2017) propuesto por Cattaneo et al (CJM) tiene mejores propiedades que el de McCrary

(3) Puntos de corte placebos

Idea: Probar si hay efectos significativos en valores de corte falsos

- Hacemos el mismo análisis que antes, pero suponiendo que el corte se da en otros valores diferentes al punto de corte real
 - Notar que para puntos de corte falsos que estén debajo del corte real, usaremos las observaciones del control y para los puntos de corte falsos que estén por arriba del corte, usaremos las observaciones del tratamiento

(3) Puntos de corte placebos

```
. rdrobust Y X if X >= 0, c(1)
```


Sharp RD estimates using local polynomial regression.

Cutoff c = 1	Left of c	Right of c	Number of obs =	315
			BW type =	mserd
Number of obs	30	285	Kernel =	Triangular
Eff. Number of obs	30	49	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	2.362	2.362		
BW bias (b)	3.326	3.326		
rho (h/b)	0.710	0.710		

Outcome: Y. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	-1.1306	4.2515	-0.2659	0.790	-9.46352	7.20222
Robust	-	-	0.2696	0.787	-9.96715	13.1469

Estimación real y placebos



(4) Sensibilidad a eliminar observaciones cerca del corte

Si hay una manipulación sistemática de los valores de puntaje, es natural suponer que las unidades más cercanas al punto de corte sean las que con mayor probabilidad se manipularon


La idea aquí es excluir esas unidades que están muy cerca al corte y repetir el análisis de estimación usando la muestra restante, para ver si los resultados se ven muy afectados

Ejemplo:

```
rdrobust Y X if abs(X) >= 0.3
```

Donut-Hole Radius	MSE-Optimal Bandwidth	RD Estimator	<u>Robust Inference</u>		Number of Observations	Excluded Obs.	
			p-value	Conf. Int.		Left	Right
0.00	17.239	3.020	0.076	[-0.309, 6.276]	795	0	0
0.10	17.954	3.081	0.064	[-0.175, 6.298]	815	1	1
0.20	16.621	3.337	0.052	[-0.033, 6.759]	765	5	4
0.30	16.043	3.414	0.055	[-0.067, 6.965]	730	7	6
0.40	17.164	3.286	0.050	[-0.001, 6.601]	774	9	9
0.50	15.422	3.745	0.028	[0.408, 7.292]	697	13	14

Sensibilidad a eliminar observaciones cerca del corte



Aquí vemos que los resultados casi no cambian al excluir observaciones cercanas, lo cual nos hace seguir creyendo en los resultados estimados por medio del análisis RD

(5) Sensibilidad a cambios en el ancho de banda

Aquí la idea es que realicemos la estimación variando el valor que toma el ancho de banda y veamos si los resultados cambian significativamente

```
rdrobust Y X, h('k')
```

- donde k va variando según el valor que toma el bandwidth

Resumen de la estimación de Sharp RD en Stata

- `rdbwselect`
 - se usa para seleccionar el ancho de banda basándonos en los datos (que hace que sea de forma transparente y “óptima”)
- `rdrobust`
 - se usa para la estimación e inferencia
- `rdplot`
 - se usa para el análisis gráfico de RD
- `rddensity`
 - proporciona pruebas de manipulación de la discontinuidad de densidad
- En el práctico verán formas alternativas de realizar estas estimaciones en Stata

Sharp RD con score discreto

RD cuando la variable de “puntaje” es discreta

- El diseño de RD canónico visto anteriormente supone que el puntaje que determina el tratamiento es una variable aleatoria continua
- Si el puntaje es discreto pero el número de puntos que asume es suficientemente grande, podemos seguir usando el mismo método analizado hasta aquí
- Ejemplo que analizaremos en donde X es una variable discreta: artículo de Lindo et al. (2010)

Ejemplo: Lindo et al. (2010)


En educación, en la práctica los puntajes de los exámenes son discretos

En el artículo de Lindo et al (2010):

- la unidad de análisis es el estudiante,
- el puntaje es el nota (GPA) del estudiante,
- el tratamiento de interés es si al estudiante se lo coloca en “un período de prueba”,
- el punto de corte es el valor de GPA que estandarizamos a $c=0$
- outcomes de interés:
 - la decisión del estudiante de dejar la universidad de forma permanente
 - nota (GPA) a largo plazo

Ejemplo: Lindo et al. (2010)

Primero debemos contar la cantidad de valores que asume X



Hay 44,362 observaciones que asumen 430 valores distintos

Luego chequeamos la densidad de X

rddensity X

Cutoff c = 0.00	Left of c	Right of c	Number of obs =	2629
			Order of poly =	0
Number of obs	2314	315	Kernel type =	uniform
Eff. Number of obs	68	62	Reps =	1000
Mean of outcome	13.972	15.044	Window =	set by user
S.D. of outcome	8.541	9.519	H0: tau =	0.000
Window	-2.500	2.500	Randomization =	fixed margins

Outcome: Y. Running variable: X.

Statistic	T	Finite sample	Large sample	
		P> T	P> T	Power vs d = 4.27
Diff. in means	1.072	0.497	0.501	0.765

Test placebo usando como outcome la nota en secundaria

```
. rdrobust hgrade_pct X
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	44362
			BW type =	mserd
Number of obs	37211	7151	Kernel =	Triangular
Eff. Number of obs	6115	3665	VCE method =	NN
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	0.465	0.465		
BW bias (b)	0.759	0.759		
rho (h/b)	0.612	0.612		


Outcome: hgrade_pct. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	1.3282	1.0104	1.3145	0.189	-.652165	3.30865
Robust	-	-	1.2980	0.194	-.788018	3.87804

Parece que los estudiantes cuyo GPA está justo arriba y abajo del corte son similares en términos de su desempeño en la escuela secundaria (igual conclusión sacamos al hacer el análisis con otras variables predeterminadas)

Primero hacemos un análisis gráfico para inspeccionar el efecto del tratamiento

```
rdplot nextGPA_nonnorm X, binselect(esmv) ///  
graph_options(graphregion(color(white)) xtitle(Score) /// ytitle(Outcome))
```



Estimamos el efecto del tratamiento como lo hicimos antes

```
. rdrobust nextGPA_nonorm X, kernel(triangular) p(1) bwselect(mserd)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	40582
			BW type =	mserd
			Kernel =	Triangular
			VCE method =	NN
Number of obs	34854	5728		
Eff. Number of obs	5249	3038		
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	0.437	0.437		
BW bias (b)	0.717	0.717		
rho (h/b)	0.610	0.610		

Outcome: nextGPA_nonorm. Running variable: X.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	.22212	.03956	5.6146	0.000	.144579	.299652
Robust	-	-	4.5718	0.000	.121721	.304402

Los estudiantes que son puestos en un período de prueba mejoran su GPA en el siguiente término en 0.22 puntos adicionales, en relación a los estudiantes que por poquito no entraron en el período de prueba

Fuzzy RD

The Fuzzy RD Design

Caso de “Fuzzy RD”: Cuando algunas unidades no cumplen con la condición de tratamiento que se les asigna:

- algunas de las unidades con $X_i \geq c$ no reciben el tratamiento y/o algunas de las unidades con $X_i < c$ reciben el tratamiento,
- pero la probabilidad de recibir tratamiento igual salta significativamente en el punto de corte c


Ahora usaremos la variable D_i para indicar si la unidad i es realmente tratada

- Para algunas unidades $T_i \neq D_i$


Probabilidad de ser tratado: Sharp vs Fuzzy RD

Probabilidad condicional de recibir el tratamiento dado el puntaje X:

$$P(D_i = 1 | X_i = x)$$



(a) Sharp RD



(b) Fuzzy RD (One-Sided)

Fuzzy RD en el contexto de variables instrumentales

- Con lo que aprendimos para un Sharp RD, podríamos estimar τ_{ITT}
 - $Y = \alpha_{ITT} + \tau_{ITT}D + f_{ITT}(X - c) + \epsilon_{ITT} \rightarrow$ efecto “ITT”
- Pero nosotros estamos interesados en estimar τ
 - $Y = \alpha + \tau D + f(X - c) + \epsilon$ (1)
 - Problema: D es endógeno
- Se puede pensar en T como una variable instrumental para D en un modelo de regresión para Y en X y D
 - $D = \gamma + \delta T + g(X - c) + v$ (2)
- 1 Primera etapa: estimamos ecuación (2)
- 2 Segunda etapa: estimamos ecuación (1) usando la estimación $\hat{D}$

Supuestos de identificación

Ahora la identificación del efecto del tratamiento estará basada en:

- “**Restricción de exclusión**”: la asignación al tratamiento (T) afecta al outcome (Y) **sólo** porque esta asignación induce un cambio en el tratamiento efectivo (D) que a su vez afecta a Y
- Condición de **monotonicidad**: una unidad con puntaje X que rechaza el tratamiento cuando el corte es c también debe rechazar el tratamiento para cualquier punto de corte mayor a c , y una unidad que toma el tratamiento cuando el corte es c también debe tomar el tratamiento para cualquier punto de corte menor c

LATE

Estimaremos el efecto promedio sobre los “cumplidores” (población que se ve afectada por la regla)

- Podremos identificar el efecto promedio del tratamiento en el punto de corte para el subconjunto de unidades que obedecen a la asignación del tratamiento, es decir, para las unidades que sí toman el tratamiento cuando su puntaje está por encima del corte y rechazan el tratamiento cuando su puntaje está por debajo del corte (LATE)

Implementación en Stata

- El proceso de implementación en Stata es igual al que hemos analizado anteriormente, solo que ahora usaremos la opción “fuzzy()”

```
rdrobust Y X, fuzzy(D)
```

- donde Y es el outcome de interés, D el estatus de tratamiento real y X la variable de puntaje (suponemos $T=1$ si $X \geq 0$)
- Veremos también una aplicación en Stata

Comandos

RDROBUST:

net install rdrobust, from(<https://sites.google.com/site/rdpackages/rdrobust/stata>) replace

RDDENSITY:

net install rddensity, from(<https://sites.google.com/site/rdpackages/rddensity/stata>) replace

Variables Instrumentales

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Mayo 2020

Algunos comentarios antes de empezar

- Vamos a usar el caso de variables omitidas para motivar la implementación de IV
 - pero IV puede solucionar toda forma de endogeneidad!
- Usaremos como ejemplo la estimación de retorno a la educación, en donde llamaremos S_i al nivel de educación del individuo i (ej. años de educación) y esa será nuestra **variable endógena**
 - En el caso más general, llamaremos a nuestra variable endógena «D»
- Cuando hablemos de instrumentos la notación será «Z»

Retornos a la educación

- Imaginemos que queremos estimar la siguiente ecuación:

- $Y_i = a + \rho S_i + \eta_i$

- donde Y_i son los ingresos del individuo i , y S_i sus años de educación

- i.e. queremos computar el retorno de la educación (S_i) sobre los ingresos (Y_i)

- ¿Qué pasa si S_i está correlacionada con η_i ?, ¿cómo estimamos ρ si S_i es endógena?

- ¿Por qué creen que es factible pensar que S_i es una variable «endógena» en este caso?

Retornos a la educación

Pensemos en el caso de variables omitidas

- Si $\text{cov}[S_i, \eta_i] \neq 0$ con $\eta_i = A_i'\gamma + e_i$ y $\text{cov}[S_i, e_i] = 0$ y sí podemos controlar por A_i , entonces podríamos estimar ρ por MCO
 - $Y_i = a + \rho S_i + \gamma A_i + e_i$
- ¿Pero qué incluye A_i ? ¿Hay algo que no podamos observar y que no esté en A_i ? ¿Cómo estimamos ρ sin observar completamente A_i ?
- **Solución IV:** La solución IV es aislar la variación en S_i que no está relacionada con A_i . La variable que hace tal «aislamiento» es la variable instrumental (Z_i). Lo bueno es que solo necesitamos algunas de estas variaciones en S_i

Condiciones que debe cumplir un instrumento

. Un instrumento (Z_i) válido necesita satisfacer dos condiciones:

- 1 Z_i satisface la **restricción de exclusión**, es decir, no aparece como regresor separado en la regresión larga ($Y_i = a + \rho S_i + \gamma A_i + e_i$) que nos gustaría correr

- 1 $Cov(Z_i, \eta_i) = 0$

- 2 Z_i afecta al regresor endógeno S_i (condición de **relevancia**)

- 1 $Cov(Z_i, S_i) \neq 0$

- De estas condiciones sólo la (2), también llamada «primera etapa», puede ser «probada»

- ¿Cómo? Por ejemplo, corremos una regresión de S en Z y vemos si el instrumento es estadísticamente significativo. Si tenemos varios instrumentos, hacemos un test de significatividad conjunta y en gral. la regla es que el F de significancia conjunta de las variables instrumentales Z_i en la regresión de S_i sobre Z_i y X_i es mayor a 10

- La (1) debe ser argumentada en base al conocimiento que tenemos por fuera de los datos

Condiciones de un instrumento válido

1 Restricción de exclusión

$$\textcircled{1} \text{ Cov}(Z_i, \eta_i) = 0$$

2 Relevancia

$$\textcircled{1} \text{ Cov}(Z_i, S_i) \neq 0$$

«Z se relaciona con S, y todo el efecto de Z sobre Y **va a través** de S»

$$Z \longrightarrow S \longrightarrow Y$$

La idea intuitiva detrás de IV

- S varía en respuesta a η
- También varía en respuesta a Z
- Z no varía cuando η cambia
- Aprovechamos la variación en S que se debe a la variación en Z, para identificar el efecto de S en Y

$$Z \longrightarrow S \longrightarrow Y$$

¿Cómo calculamos el estimador por IV?

Si Z_i es tal que:

① $\text{Cov}(Z_i, \eta_i) = 0$

② $\text{Cov}(Z_i, S_i) \neq 0$

Y queremos estimar ρ de $Y_i = \alpha + \rho S_i + \eta_i$

$$\text{Cov}(Z_i, Y_i) = \rho \text{Cov}(Z_i, S_i) + \text{Cov}(Z_i, \eta_i)$$

$$\rho = \frac{\text{Cov}(Z_i, Y_i)}{\text{Cov}(Z_i, S_i)}$$

Estimador IV

$$\rho = \frac{\text{Cov}(Z_i, Y_i)}{\text{Cov}(Z_i, S_i)}$$

Reemplazando por el análogo muestral: $\hat{\rho} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(S_i - \bar{S})} \rightarrow$ **Estimador de Wald**

$$\rho = \frac{\text{Cov}(Z_i, Y_i)}{\text{Cov}(Z_i, S_i)} = \frac{\frac{\text{Cov}(Z_i, Y_i)}{V(Z_i)}}{\frac{\text{Cov}(Z_i, S_i)}{V(Z_i)}}$$

ρ es el ratio entre la forma reducida y la primera etapa!

Lo vemos en más detalle...

Hay tres efectos causales en los que podemos pensar en este caso:

- 1 El efecto causal de Z_i en S_i .
- 2 El efecto causal de Z_i en Y_i .
- 3 El efecto causal de S_i en Y_i $\rightarrow$ el que más nos interesa (ej, el retorno a la escuela ρ).

- ① **Primera etapa:** la regresión de los años de escolarización en el instrumento (efecto causal «1»)

$$① S_i = \pi_{10} + \pi_{11}Z_i + \xi_{1i}$$

- ② **Forma reducida:** la regresión del ingreso en el instrumento (efecto causal «2»)

$$① Y_i = \pi_{20} + \pi_{21}Z_i + \xi_{2i}$$

- ③ **Ecuación estructural:** la regresión del ingreso en los años de escolarización (esto involucra el efecto causal número 3)

$$① Y_i = \alpha + \rho S_i + \eta_i,$$

$$① \text{ donde } \eta_i = \gamma A_i + e_i$$

Sustituyendo la primera etapa en la ecuación estructural:

$$\begin{aligned} Y_i &= \alpha + \rho S_i + \eta_i \\ &= \alpha + \rho [\pi_{10} + \pi_{11} Z_i + \xi_{1i}] + \eta_i \\ &= (\alpha + \rho \pi_{10}) + \rho \pi_{11} Z_i + (\xi_{1i} + \eta_i) \\ &= \pi_{20} + \pi_{21} Z_i + \zeta_{2i} \end{aligned}$$

Entonces, los coeficientes de la forma reducida son:

$$\pi_{20} = \alpha + \rho \pi_{10}$$

$$\pi_{21} = \rho \pi_{11}$$

$$\rho = \frac{\pi_{21}}{\pi_{11}}$$

Aquí queda claro que la estimación por IV es igual a la relación del coeficiente de forma reducida en el instrumento con respecto al coeficiente de la primera etapa

¿Cuál podría ser un buen instrumento para el nivel de educación?

¿Cuál podría ser un buen instrumento para el nivel de educación?

- ① ¿coeficiente intelectual (IQ)?
- ② ¿último dígito del número de seguridad social?
- ③ ¿educación de los padres?

Aplicaciones

Ejemplos de instrumentos para el nivel de educación

Retorno de la educación

- Proximidad geográfica (Altonji, Elder & Taber, JHR 2005)
- Trimestre de nacimiento (Angrist y Krueger, QJE 1991)
- Leyes de educación obligatoria (Björklund, Anders, Mikael Lindahl, y Erik Plug, QJE 2006)

Otros ejemplos de instrumentos en la literatura

Efecto del tamaño de la familia en la educación de los niños

- Gemelos, género del primogénito, género de los primeros dos hijos (Black, Devereux & Salvanes, QJE 2005; Angrist, Lavy & Schlosser, JOLE 2009)

Tamaño de la clase

- Reglas de Maimonides (Angrist & Lavy 1999)
- Asignación basada en orden alfabético (Bagues, Berniell y Cabrales)

El impacto del servicio militar de la era de Vietnam (Angrist 1990)

El efecto de un tercer hijo en el empleo de la madre (Angrist and Evans 1998)

Angrist & Krueger (1991): US compulsory schooling & school entry rules

- Las leyes de escolarización obligatoria de EE. UU. están definidas en términos de la edad y no de los años de escolaridad completados
- Si la edad de escolarización obligatoria es 16 años, una persona puede abandonar sus estudios a los 16 años (incluso si está en la mitad del año escolar)
- La entrada a la escuela es una vez al año, y los cortes se basan en la fecha de cumpleaños. La combinación de estos dos genera una variación en los años de educación para aquellos que abandonan la escuela tan pronto como pueden. Esta variación depende de la fecha de cumpleaños

Angrist & Krueger (1991): Instrumento


- ① Asignación «aleatoria»: ¿es la fecha de cumpleaños «random» con respecto a las ganancias contrafactuales para diferentes niveles de escolaridad?
 - ① Ojo, hay pequeñas diferencias en nivel socio-económico promedio por fechas de cumpleaños a lo largo de todo el año
- ② ¿Cumple la fecha de cumpleaños con la restricción de exclusión, o podría estar la fecha de cumpleaños correlacionada con los ingresos por otras razones además de por su efecto sobre la escolarización?
 - ① Ojo, hay otros efectos de la fecha de nacimiento, por ejemplo, edad relativa con los compañeros de clase
- ③ ¿Es cierto que la fecha de nacimiento afecta el nivel de escolarización? Comprobarlo en la primera etapa

Angrist & Krueger (1991): Datos

- Censo estadounidense de 1980
- 329,509 hombres nacidos entre 1930 y 1939 (es decir, en sus 40 años cuando se observaron)
- Para estos hombres tenemos año de nacimiento, trimestre de nacimiento, años de escolaridad y ganancias en 1979

Angrist & Krueger (1991): Primera etapa (S_i en trimestre de nacimiento)

A. Average Education by Quarter of Birth (first stage)




Angrist & Krueger (1991): Primera etapa (S_i en trimestre de nacimiento)

Regressor	Dependent variable: schooling			
	(1)	(2)	(3)	(4)
quarter 2		0.057 (0.017)		0.057 (0.016)
quarter 3		0.117 (0.016)		0.113 (0.016)
quarter 4	0.092 (0.013)	0.151 (0.016)	0.091 (0.013)	0.148 (0.016)
9 year of birth dummies			✓	✓

Angrist & Krueger (1991): Primera etapa (S_i en trimestre de nacimiento)

B. Average Weekly Wage by Quarter of Birth (reduced form)



Angrist & Krueger (1991): Forma reducida ($\log(y_i)$ en trimestre de nacimiento)

Regressor	Dependent variable: log wages			
	(1)	(2)	(3)	(4)
quarter 2		0.0045 (0.0034)		0.0046 (0.0034)
quarter 3		0.0149 (0.0033)		0.0150 (0.0033)
quarter 4	0.0068 (0.0027)	0.0135 (0.0034)	0.0068 (0.0027)	0.0135 (0.0034)
9 year of birth dummies			✓	✓

Angrist & Krueger (1991): Regresión IV de $\log(y_i)$ en educación

Regressor	Dependent variable: log wages			
	(1)	(2)	(3)	(4)
schooling	0.074 (0.028)	0.103 (0.020)	0.075 (0.028)	0.105 (0.020)
Instruments	Quarter 4	4 quarter dummies	Quarter 4	4 quarter dummies
9 year of birth dummies			✓	✓

Comparemos con el coeficiente de años de escolaridad en una regresión OLS: 0.072 (0.0004)

Con $Q4_i$ como instrumento, tenemos:

$$\beta_{IV} = \frac{\text{cov}(\ln Y_i, Q4_i)}{\text{cov}(S_i, Q4_i)}$$
$$= \frac{E[\ln Y_i | Q4_i = 1] - E[\ln Y_i | Q4_i = 0]}{E[S_i | Q4_i = 1] - E[S_i | Q4_i = 0]}$$

Este es el **estimador de Wald**

Estimador de Wald

La primera etapa y la forma reducida son:

$$S_i = \pi_{11} + \pi_{14}Q4_i + \xi_{1i}$$

$$\ln Y_i = \pi_{21} + \pi_{24}Q4_i + \xi_{2i}$$

Tomando esperanza condicionada en $Q4_i$:

$$E[\ln Y_i | Q4_i = 1] = \pi_{21} + \pi_{24}$$

$$E[\ln Y_i | Q4_i = 0] = \pi_{21}$$

Entonces, los coeficientes de forma reducidos en $Q4_i$ son las diferencias en medias cuando el instrumento está «on» y «off»:

$$\pi_{24} = E[\ln Y_i | Q4_i = 1] - E[\ln Y_i | Q4_i = 0]$$

$$\pi_{14} = E[S_i | Q4_i = 1] - E[S_i | Q4_i = 0]$$

La estimación por IV es la división entre esas dos ecuaciones

Estimador de Wald: retorno a la educación

	born quarter 1, 2, 3	born quarter 4	Difference
log earnings	5.8983	5.9051	0.0068 (0.0027)
schooling	12.747	12.839	0.092 (0.013)
Wald estimate			0.074 (0.028)

$$0.0068/0.092 = 0.074$$

2SLS

- En un modelo con una sola variable endógena y un solo instrumento, los estimadores IV son equivalentes a un procedimiento de dos etapas:
 - Corremos un OLS de x en z y guardamos $\hat{x}$
 - Corremos otro OLS de y en $\hat{x}$
- **SE:** Con el procedimiento de dos etapas no obtenemos los errores estándar correctos ($\hat{x}$ es un regresor «generado» e infla la varianza)
 - Stata `ivreg2` lo soluciona

Si ajustamos por covariables

- $Y_i = \beta_0 + \beta_1 S_i + \beta_2 X_{1i} + \dots + \beta_{k+1} X_{ki} + u_i$

- 1 En la primera etapa estimamos una regresión por OLS de S_i (variable endógena) sobre la variable instrumental Z_i y todas las demás variables exógenas $X_{1i} \dots X_{ki}$ y en base a esta estimación predecimos $S_i \rightarrow \hat{S}_i$

- $\hat{S}_i = \hat{\alpha}_0 + \hat{\alpha}_1 Z_i + \hat{\alpha}_2 X_{1i} + \dots + \hat{\alpha}_{k+1} X_{ki}$

- 2 En la segunda etapa estimamos $Y_i = \beta_0 + \beta_1 S_i + \beta_2 X_{1i} + \dots + \beta_{k+1} X_{ki} + u_i$ pero usando $\hat{S}_i$ en lugar de S_i

- $Y_i = \beta_0 + \beta_1 \hat{S}_i + \beta_2 X_{1i} + \dots + \beta_{k+1} X_{ki} + u_i$

Angrist & Krueger (1991)

Table 4.1.1: 2SLS estimates of the economic returns to schooling

	OLS		2SLS					
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Years of education	0.075 (0.0004)	0.072 (0.0004)	0.103 (0.024)	0.112 (0.021)	0.106 (0.026)	0.108 (0.019)	0.089 (0.016)	0.061 (0.031)
<i>Covariates:</i>								
Age (in quarters)								✓
Age (in quarters) squared								✓
9 year of birth dummies		✓			✓	✓	✓	✓
50 state of birth dummies		✓			✓	✓	✓	✓
<i>Instruments:</i>								
			dummy for QOB=1	dummy for QOB=1 or QOB=2	dummy for QOB=1	full set of QOB dummies	full set of QOB dummies int. with year of birth dummies	full set of QOB dummies int. with year of birth dummies

Notes: The table reports OLS and 2SLS estimates of the returns to schooling using the the Angrist and Krueger (1991) 1980 Census sample. This sample includes native-born men, born 1930-1939, with positive earnings and non-allocated values for key variables. The sample size is 329,509. Robust standard errors are reported in parentheses.

Restricción de exclusión en Angrist & Krueger (1991)

¿Es creíble la restricción de exclusión?

- ¿Variables socioeconómicas omitidas?
- ...

Datos y programas Angrist & Krueger (1991)

Datos y programas para replicar Angrist & Krueger (1991):

<http://economics.mit.edu/faculty/angrist/data1/data/angkru1991>

Más de un instrumento

Sobreidentificación

- ¿Qué pasa si tenemos más de un instrumento?
- En principio, podríamos obtener muchas estimaciones IV
- Pero no parece muy prudente no usar algunos instrumentos
- ¿Qué tal combinarlos? Pero ¿cómo combinarlos?
- Idealmente, nos gustaría dar más peso a mejores instrumentos (todos deben verificar la condición de ortogonalidad, pero algunos pueden tener más poder predictivo que otros).

Sobreidentificación

- Supongamos que tenemos más instrumentos que regresores endógenos
- Necesitamos una matriz de pesos (P_z) que le dé más peso a los instrumentos que están más correlacionados con la variable endógena

- $P_z = Z(Z'Z)^{-1}Z'$

- Intuición: supongamos que tenemos una variable endógena x y dos instrumentos z_1 y z_2
- corremos un OLS de x en z_1 y z_2 , guardamos el valor ajustado y llamemos γ a los parámetros de esta regresión
- $\hat{\gamma} = (Z'Z)^{-1}Z'S$
- Es decir que tenemos $\hat{S} = Z\hat{\gamma} = Z(Z'Z)^{-1}Z'S$

Test de exogeneidad (Sargan)

Averiguar si se cumple la condición de exclusión es complicado porque necesitamos saber si el instrumento (Z) y el término de error (u) están correlacionados. Pero el problema es que no observamos η

- ¿Y si tenemos más de un instrumento?
 - Test de Sargan

Test de exogeneidad (Sargan)

- **Intuición** del test de Sargan
- tenemos un regresor endógeno y dos instrumentos z_1 y z_2
- Estimemos entonces el modelo utilizando solo z_1 , calculemos el residuo y verifiquemos si el residuo es ortogonal a z_2
- Si z_1 es un buen instrumento, podemos probar qué tan bueno es z_2
 - $\hat{u}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 \hat{S}_i - \hat{\beta}_2 X_i$ donde a $\hat{S}_i$ lo calculamos de la primera etapa sin haber incluido en la primera etapa al instrumento z_2
 - Ahora probamos si $\hat{u}$ y z_2 están correlacionados. Si lo están, entonces z_2 no es un buen instrumento

$$\hat{u}_i = \lambda_0 + \lambda_1 Z_i + \lambda_2 X_i + \epsilon_i$$

Test de exogeneidad (Sargan)

- $\hat{u}_i = \lambda_0 + \lambda_1 Z_i + \lambda_2 X_i + \epsilon_i$
- Construimos el estadístico $S = n * R^2 \sim \chi^2_{L-K}$
- n es el número de observaciones, R^2 es de la regresión $\hat{u}_i = \lambda_0 + \lambda_1 Z_i + \lambda_2 X_i + \epsilon_i$ y los grados de libertad corresponden al número de restricciones de sobreidentificación (número de instrumentos menos número de variables endógenas)
- Por supuesto, podemos hacer lo contrario
- Stata `ivreg2` lo hace por nosotros (recordar que solo funciona si nosotros tener al menos un buen instrumento!)

Instrumentos débiles

Instrumentos débiles

- Un IV débil exagera el sesgo $\rightarrow$ reportar siempre la primera etapa!

$$\begin{aligned}\hat{\beta}_1 &= \frac{\text{cov}(Y_i, Z_i)}{\text{cov}(S_i, Z_i)} \\&= \frac{\text{cov}(\beta_0 + \beta_1 S_i + u_i, Z_i)}{\text{cov}(S_i, Z_i)} \\&= \frac{\beta_1 \text{cov}(S_i, Z_i) + \text{cov}(u_i, Z_i)}{\text{cov}(S_i, Z_i)} \\&= \beta_1 + \frac{\text{cov}(u_i, Z_i)}{\text{cov}(S_i, Z_i)}\end{aligned}$$

Si el instrumento es débil, entonces $\text{cov}(S_i, Z_i)$ es pequeña y eso haría que el estimador $\hat{\beta}$ estaría exagerando el sesgo en caso de que no se cumpla $\text{cov}(u_i, Z_i) = 0$

Efectos heterogéneos

Efectos heterogéneos: monotonicidad

- En el caso de efectos heterogéneos necesitamos un supuesto adicional para identificar efectos causales: condición de monotonicidad
 - cualquier persona que estuviera dispuesta a tratarse si es asignada al grupo de control, también estaría preparada para tratarse si se la asigna al grupo de tratamiento
- Cuán plausible es este supuesto depende del contexto del tratamiento/intervención
- Bajo monotonicidad, el coeficiente IV coincide con el efecto promedio del tratamiento para aquellos cuyo valor de D cambiaría cuando cambia el valor de Z (efecto de tratamiento promedio local o LATE)

Sea $Y_i(d; z)$ el resultado potencial del individuo i si esta persona tuviera el estado de tratamiento $D_i = d$ y el valor del instrumento $Z_i = z$

Podemos pensar que las variables instrumentales inician una cadena causal donde el instrumento, Z_i , afecta la variable de interés, D_i , que a su vez afecta los resultados, Y_i

Sea D_{1i} el estado de tratamiento cuando $Z_i = 1$, mientras que D_{0i} sea el tratamiento cuando $Z_i = 0$. El estado de tratamiento observado es por lo tanto:

$$D_i = D_{0i} + (D_{1i} - D_{0i}) Z_i$$

Podemos dividir a cualquier población en un conjunto de cuatro subgrupos definidos por la manera en que los miembros de la población reaccionan al instrumento:

- Los **cooperativos** $\rightarrow$ Compliers: $D_{i1} = 1, D_{i0} = 0$
- Los que nunca participan $\rightarrow$ Never-takers: $D_{i1} = 0, D_{i0} = 0$
- Los desafiantes $\rightarrow$ Defiers: $D_{i1} = 0, D_{i0} = 1$
- Los que siempre participan $\rightarrow$ Always-takers: $D_{i1} = 1, D_{i0} = 1$

(siendo $D_{iz} = D_i | Z_i = z$)

- El supuesto de monotonicidad requiere que no exista un grupo de desafiantes

- Examinemos más en detalle por qué el supuesto de monotonicidad podría ser importante
- $$E(Y_i|Z_i = 1) = E(Y_{i0}) + E(Y_{i1} - Y_{i0}) D_{i1}$$

$$E(Y_i|Z_i = 0) = E(Y_{i0}) + E(Y_{i1} - Y_{i0}) D_{i0}$$
- $$E(Y_i|Z_i = 1) - E(Y_i|Z_i = 0) = E[(Y_{i1} - Y_{i0})(D_{i1} - D_{i0})]$$

$$= E[Y_{i1} - Y_{i0}|D_{i1} - D_{i0} = 1] * \text{Prob}(D_{i1} - D_{i0} = 1)$$

$$- E[Y_{i1} - Y_{i0}|D_{i1} - D_{i0} = -1] * \text{Prob}(D_{i1} - D_{i0} = -1)$$
- $E(Y_i|Z_i = 1) - E(Y_i|Z_i = 0)$ podría ser negativo y, sin embargo, el efecto causal sería positivo para todos, siempre que la probabilidad de los desafiantes sea lo suficientemente grande
- Por ejemplo, consideremos el caso donde hay un 50 % de cumplidores, un 25 % de no afectados y un 25 % de desafiantes, y el ATE para cumplidores es igual a 1 y el ATE para desafiantes es igual a 2. Incluso si todos se benefician a partir del tratamiento, la estimación IV sería igual a cero!

- Si descartamos los desafiantes, tenemos:

$$E(Y_i|Z_i = 1) - E(Y_i|Z_i = 0) = E[Y_{i1} - Y_{i0}|D_1 - D_0 = 1] * \text{Prob}(D_1 - D_0 = 1)$$

$$E(D_i|Z_i = 1) - E(D_i|Z_i = 0) = E(D_{i1}) - E(D_{i0}) = \text{Pr}(D_{i1} - D_{i0} = 1)$$

- Entonces: $E(Y_{i1} - Y_{i0}|D_{i1} - D_{i0} = 1) = \frac{E(Y_i|Z_i=1) - E(Y_i|Z_i=0)}{E(D_i|Z_i=1) - E(D_i|Z_i=0)}$
- Imbens y Angrist llamaron a este parámetro **LATE (efectos de tratamiento local promedio)**

Veamos ahora la aplicación en **Stata**

```
ivreg2 y x1 x2 x3 x4 (D = z1 z2), first
```

Método de Emparejamiento

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Mayo 2020

Método de emparejamiento

- Intuitivamente, el método de emparejamiento permite encontrar para cada individuo en el programa (tratado), otro «idéntico», excepto por la participación en el programa (control)
 - Comparamos individuos que son similares en características observables (predeterminadas!)
- La comparación funciona bajo la presunción de que para $X = x$ hay una variación «aleatoria» en D , de modo que «podemos observar tanto Y_1 como Y_0 »
- La selección en el programa se basa en características o variables observables únicamente y que son observadas por el investigador

Supuesto de identificación: (1) Independencia condicional (CI)

Independencia condicional («selection-on-observables»): $Y_0, Y_1 \perp D|X, \quad \forall X$

- La participación no está determinada por variables no observadas, sino que se atribuyen exclusivamente a variables observables del individuo
- Supuesto muy fuerte; su violación puede inducir a sesgos en el estimador de emparejamiento. Pero, si se cumple, podemos encontrar el ATT simplemente «controlando por X »

- $$E[Y_{1i}|X_i, D_i = 1] - E[Y_{0i}|X_i, D_i = 0] = E[Y_{1i} - Y_{0i}|X_i, D_i = 1] + E[Y_{0i}|X_i, D_i = 1] - E[Y_{0i}|X_i, D_i = 0]$$

- La CI dice que condicionando a un conjunto de características observadas X_i ese sesgo desaparece

- $E[Y_{0i}|X_i, D_i = 1] = E[Y_{0i}|X_i, D_i = 0]$
- entonces $E[Y_{1i}|X_i, D_i = 1] - E[Y_{0i}|X_i, D_i = 0] = E[Y_{1i} - Y_{0i}|X_i, D_i = 1]$

Supuesto: Independencia condicional (CI)

La CI resuelve el problema de sesgo de selección, pero obtenemos efectos causales por separado para cada X_i . Si buscamos una única medida de resumen podríamos calcular el efecto causal promedio de la población

$$E \{ E [Y_{1i} - Y_{0i} | X_i] \}$$

o sobre los tratados (ATET)

ATE y ATET

$$\begin{aligned}\alpha_{ATE} &= E(Y_1 - Y_0) = \int E(Y_1 - Y_0|X) dF(X) \\ &= \int [E(Y|D=1, X) - E(Y|D=0, X)] dF(X)\end{aligned}$$

$$\begin{aligned}\alpha_{ATET} &= E(Y_1 - Y_0) = \int E(Y_1 - Y_0|X) dF(X) \\ &= \int [E(Y|D=1, X) - E(Y|D=0, X)] dF(X|D=1)\end{aligned}$$

Notar: La mayor parte de la literatura se centró en los efectos promedio, pero también sirve para comparaciones distributivas

ATE y ATET

Supongamos que X toma K valores (celdas) diferentes $(X_1, \dots, X_k, \dots, X_K)$

Entonces, por el principio del análogo tenemos los siguientes estimadores:

$$\hat{\alpha}_{AIE} = \sum_{k=1}^K \left(\bar{Y}_1^k - \bar{Y}_0^k \right) \cdot \left(\frac{N^k}{N} \right)$$

$$\hat{\alpha}_{ATET} = \sum_{k=1}^K \left(\bar{Y}_1^k - \bar{Y}_0^k \right) \cdot \left(\frac{N_1^k}{N_1} \right)$$

- N^k es el # de observaciones en la celda k
- N_1^k es el # de observaciones de tratados en la celda k
- $\bar{Y}_1^k$ es el resultado promedio para el grupo de tratados en la celda k
- $\bar{Y}_0^k$ es el resultado promedio para los no tratados en la celda k

Usarlo con cuidado

- Los métodos de emparejamiento no deben aplicarse solo porque no existe una solución experimental o cuasi experimental para estimar los efectos del tratamiento. Deben aplicarse solo cuando el supuesto de selección sobre observables es factible

La maldición de la dimensionalidad

- Subclasificar las observaciones se vuelve inviable con muchas covariables
- Buscar una coincidencia exacta puede no ser factible si la muestra es pequeña, el conjunto de covariables es grande y muchas de ellas asumen múltiples valores o son continuas
- Si tenemos k covariables y dividimos cada una de ellas en 3 categorías (por ejemplo, la edad podría ser "joven", "mediana edad" o "adulto", y el ingreso podría ser "bajo", "medio" o "alto"), el número de celdas es 3^k
 - Para $k = 10$ (k es el número de variables, y 3 las categorías en cada variable), obtenemos $3^{10} = 59049$
- Muchas celdas pueden contener solo observaciones tratadas o no tratadas, y no podríamos usar este sistema de subclasificación para estimar efectos causales
- La subclasificación también es problemática si las celdas son "demasiado anchas"
 - Pero el uso de celdas "más finas" empeora el problema de la «maldición de la dimensionalidad»!

Matching (Nearest Neighbor)

Match exacto: Pasos ATET

- 1 estratificar los datos en celdas definidas por cada valor particular de X
- 2 dentro de cada celda (es decir, condicionamiento en X) calcular la diferencia entre los resultados promedio de los tratados y los controles
- 3 promediar estas diferencias con respecto a la distribución de X en la población de unidades tratadas.

Matching: el ejemplo ideal

Trainees		
unit	age	earnings
1	28	17700
2	34	10200
3	29	14400
4	25	20800
5	29	6100
6	23	28600
7	33	21900
8	27	28800
9	31	20300
10	26	28100
11	25	9400
12	27	14300
13	29	12500
14	24	19700
15	25	10100
16	43	10700
17	28	11500
18	27	10700
19	28	16300
Average:	28.5	16426

Non-Trainees		
unit	age	earnings
1	43	20900
2	50	31000
3	30	21000
4	27	9300
5	54	41100
6	48	29800
7	39	42000
8	28	8800
9	24	25500
10	33	15500
11	26	400
12	31	26600
13	26	16500
14	34	24200
15	25	23300
16	24	9700
17	29	6200
18	35	30200
19	32	17800
20	23	9500
21	32	25900
Average:	33	20724

Matched Sample		
unit	age	earnings
8	28	8800
14	34	24200
17	29	6200
15	25	23300
17	29	6200
20	23	9500
10	33	15500
4	27	9300
12	31	26600
11,13	26	8450
15	25	23300
4	27	9300
17	29	6200
9,16	24	17700
15	25	23300
1	43	20900
8	28	8800
4	27	9300
8	28	8800
Average:		


Matching: el ejemplo ideal

Trainees		
unit	age	earnings
1	28	17700
2	34	10200
3	29	14400
4	25	20800
5	29	6100
6	23	28600
7	33	21900
8	27	28800
9	31	20300
10	26	28100
11	25	9400
12	27	14300
13	29	12500
14	24	19700
15	25	10100
16	43	10700
17	28	11500
18	27	10700
19	28	16300
Average:	28.5	16426


Non-Trainees		
unit	age	earnings
1	43	20900
2	50	31000
3	30	21000
4	27	9300
5	54	41100
6	48	29800
7	39	42000
8	28	8800
9	24	25500
10	33	15500
11	26	400
12	31	26600
13	26	16500
14	34	24200
15	25	23300
16	24	9700
17	29	6200
18	35	30200
19	32	17800
20	23	9500
21	32	25900
Average:	33	20724

Matched Sample		
unit	age	earnings
8	28	8800
14	34	24200
17	29	6200
15	25	23300
17	29	6200
20	23	9500
10	33	15500
4	27	9300
12	31	26600
11,13	26	8450
15	25	23300
4	27	9300
17	29	6200
9,16	24	17700
15	25	23300
1	43	20900
8	28	8800
4	27	9300
8	28	8800
Average:	28.5	13982

Distribución por edad: antes de emparejar



Distribución por edad: después de emparejar



Matching: el ejemplo ideal

Diferencia en los ingresos promedios entre aprendices y no aprendices:

- Antes del emparejamiento: $16426 - 20724 = -4298$
- Después del emparejamiento: $16426 - 13982 = 2444$

Matching: el ejemplo ideal

- Cuando el vector de covariables X tiene más de una dimensión ($k > 1$) necesitamos definir una métrica de distancia para medir la "cercanía" (ej. distancia euclidiana)
- Es difícil encontrar buenas coincidencias en grandes dimensiones: necesitamos muchas observaciones si k es grande
- Solución: Propensity score methods (lo veremos en unas slides más adelante)

Matching con reemplazo en Stata

`nnmatch`: Nearest Neighbor Matching Estimation for Average Treatment Effects

```
ssc install nnmatch
```

```
nnmatch depvar treatvar varlist_nnmatch
```

- `nnmatch Y D X1 X2 ...`

`m` especifica el número de coincidencias que se harán por observación:

- `nnmatch Y D X1 X2 ..., m(2)`

ATET (default es ATE):

- `nnmatch Y D X1 X2 ..., tc(att)`
 - (default is normalized Euclidean)

Coincidencias exactas para algunas covariables:

Propensity Score Matching (PSM)

Estimando la probabilidad de participación en el programa

- Como dijimos, la implementación del estimador es compleja cuando el vector de variables observables X tiene una dimensión muy grande (difícil encontrar individuos con valores similares, 'parejas', en todas las dimensiones de X)
- Solución: emparejar individuos con base en: $P(X) = P(D = 1|X)$
 - Usar la probabilidad estimada de participación en el programa dadas sus características observables (propensity score)
 - Podemos hacer coincidir unidades con valores muy diferentes de X siempre que tengan valores similares de $p(X)$
- IC supuesto de identificación: Si $(Y_1, Y_0) \perp D|X \rightarrow (Y_1, Y_0) \perp D|p(X)$
- Condicionar por $p(X)$ es suficiente para tener independencia entre el indicador de tratamiento y el resultado potencial
- Hay una reducción sustancial de la dimensión!: El match se hace en base a una variable « $p(X)$ »

Propensity Score Matching

$$E[Y_1 - Y_0 | p(X)] = E[Y | D = 1, p(X)] - E[Y | D = 0, p(X)]$$


Procedimiento de dos etapas:

- 1 Estimar la «puntuación de propensión» $p(X) = P(D = 1 | X)$ (logit o probit)
- 2 Hacer la «coincidencia/emparejamiento» sobre $p(X)$
 - 1 idealmente emparejaríamos a tratados con controles con exactamente el mismo $p(X)$ estimado
 - 2 calcularíamos el efecto del tratamiento para cada valor de $p(X)$
 - 3 calcularíamos el promedio de estos efectos
 - 4 Esto no es factible de forma exacta en la práctica porque es raro encontrar dos unidades con exactamente el mismo $p(X)$, pero se puede hacer por
 - 1 Estratificación en $p(X)$
 - 2 Emparejamiento con el vecino con score más cercano
 - 3 Radio en $P(X)$
 - 4 Kernel

Condición para construir un buen grupo de control

- Comencemos por estimar $p(X)$ y entender qué condiciones cumple un buen control
 - Cualquier combinación de características observadas en el grupo de tratamiento debe existir también en el grupo de control
 - Un control adecuado para un individuo en el grupo de tratamiento es aquel que tiene una probabilidad de participar en el programa muy parecida

Soporte común



- El emparejamiento por probabilidad de participación (PSM) sólo debe calcularse sobre la región de soporte común, esto asegura que el grupo de tratamiento y el de control sean parecidos

Soporte común ¿Qué implica en la estimación?

- Para la estimación se toman aquellos individuos que de acuerdo con sus variables observables muestran probabilidades no cero de ser tanto participantes como no participantes
- Así los individuos del grupo de control son aquellos que tienen probabilidades de participación parecidas a las de los individuos en el grupo de tratamiento

Estimador de PSM

- Asumiendo que se cumplen las condiciones de independencia condicional y de soporte común, el estimador del efecto promedio del programa sobre los tratados de PSM está dado por:

$$\tau_{ATT}^{PSM} = E_{P(X)|D=1} \{ E[Y(1)|D=1, P(X)] - E[Y(0)|D=0, P(X)] \}$$

- Promedio ponderado de las diferencias entre corchetes, donde los ponderadores son funciones de probabilidad de participación en el programa. Para individuos con $P(X)$ similares, se restan las diferencias entre tratados y no tratados, y se agrega ponderando por las probabilidades de participación

Información necesaria para aplicar un PSM

- En términos de datos y contextos para que el PSM funcione:
- 1 Debe contener la información de las variables independientes relevantes
 - 2 La evidencia preliminar debe indicar que no hay muchas diferencias entre los dos grupos en términos de las variables observables; de lo contrario, habría evidencia de que también pueden ser diferentes en variables no observables (y va a ser difícil tener un soporte común)
 - 3 Los métodos de emparejamiento son confiables siempre que no existan razones para pensar que las variables no observables determinan fundamentalmente la participación en el programa, como por ejemplo sucede cuando la motivación es clave en la participación

Algoritmo de PSM

Algoritmo de PSM

- 1 Estimar la probabilidad de participar en el programa, utilizando tanto el grupo de tratamiento como el de control
- 2 Estimar la probabilidad de participación predicha para cada individuo
- 3 Restringir la muestra al soporte común
- 4 Seleccionar el algoritmo de emparejamiento
- 5 Observar que las variables observables entre el grupo de control y de tratamiento estén balanceadas en términos de probabilidades
- 6 Calcular el impacto del programa

Propensity Score: Estimación

1) Estimar la probabilidad de participar en el programa

- 1 Estimar la probabilidad de participar en el programa, utilizando tanto el grupo de tratamiento como el de control

- 1 ¿Qué variables incluir?

- La estimación de $P(X)$ sólo debe incluir variables que afectan la decisión de participación y la variable de resultado
- Recordar que la variable de resultado deben ser independiente del tratamiento, una vez se condiciona por la probabilidad de participación (independencia condicional)

2) Estimación de la probabilidad de participación

- 1 Estimar la probabilidad de participación predicha para cada individuo

Estimamos $D_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_K X_{Ki} + u_i$

- D_i : Dummy si la unidad i es tratada

Predecimos $\hat{P}(X_i) = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \dots + \hat{\beta}_K X_{Ki} \rightarrow$ Caracterización de la unidad i según su probabilidad de participación en el programa

Stata: pscore - matching por estratos

```
findit pscore
```

pscore estimates the propensity score (pscore) of the treatment on varlist (the control variables) using a probit (or logit) model and stratifies individuals in blocks according to the pscore

```
pscore treat varlist , pscore(newvar)
```


```
pscore treat age age2, pscore(mypscore) logit blockid(myblock)
```

Restringir la muestra a una con soporte común

3) Restringir la muestra al soporte común

¿Cómo chequear soporte común ?

1. Inspección visual de las distribuciones de densidad de la probabilidad estimada de participación



3) Restringir la muestra al soporte común

Probabilidades estimadas de participación

	1	2	3	4	5	6	7	8	9	10
Tratamiento	0.40	0.48	0.54	0.65	0.75	0.76	0.77	0.8	0.86	0.9
Control	0.21	0.30	0.38	0.42	0.52	0.55	0.59	0.62	0.65	0.77

Eliminando las personas que no hacen parte del soporte común (aquí se pierden tres observaciones de cada lado)

3) Restringir la muestra al soporte común

2. Criterio de mínimo y máximo: Elimina observaciones inferiores al mínimo y mayores al máximo del otro grupo (no es infalible, ver siguiente figura. . .)

3. Elegir variables de la probabilidad estimada de participación para los cuales hay densidad positiva en los dos grupos.

Algoritmo de emparejamiento: (1) Estimación por estratificación

Selección del algoritmo de emparejamiento: Estimación por estratificación

Se hace una partición en el espacio de las probabilidades estimadas y se divide en estratos (rangos de probabilidad de participación)

$$\tau_{ATT}^{PSM-ESTRATO_i} = \text{Promedio} (Y_i | D = 1) - \text{Promedio} (Y_{C(i)} | D = 0)$$

- Impacto en cada estrato calculado como la diferencia promedio en la variable de resultado entre los grupos de tratamiento y de control
- Dentro de los estratos la probabilidad de participar debe estar balanceada (de lo contrario, hay que dividir en más estratos) y se debe chequear que las variables observables estén balanceadas
- ATT: promedio del efecto sobre cada estrato ponderado por la proporción de tratados en el soporte común.

Stata: ATET por matching por estratos

```
atts re75 treat, pscore(myscore) blockid(myblock)
```

- Help de Stata: «atts estimates the average treatment effect on the treated (ATT) using stratification matching; users have to provide the name of a variable specifying the estimated propensity score and the name of a variable specifying a block identifier of the estimated propensity score, both of which can be produced with pscore»

$$\bullet \tau_q^S = \frac{\sum_{i \in I(q)} Y_i^T}{N_q^T} - \frac{\sum_{j \in I(q)} Y_j^C}{N_q^C}$$

$$\bullet \tau^S = \sum_{q=1}^Q \tau_q^S \frac{\sum_{i \in I(q)} D_i}{\sum_{\forall i} D_i}$$

- el peso para cada bloque viene dado por la fracción correspondiente de unidades tratadas y Q es el número de bloques

Estimación del ATET por el vecino más cercano, radio y emparejamiento por Kernel


Lo más cercano que podemos llegar a una coincidencia exacta es hacer coincidir cada unidad tratada con «el control más cercano» en términos de $p(X)$

- Métodos (con/sin reemplazo)
 - Vecino más cercano
 - Radio/distancia máxima
 - Coincidencia de kernel

Algoritmo de emparejamiento: (2) Vecino más cercano, (3) radio/distancia máxima

Estimación del ATET por el vecino más cercano

- Vecino más cercano con el reemplazo: unidades de control pueden aparecer más de una vez
- Sea $C(i)$ el conjunto de unidades de control emparejadas con la unidad tratada i con un valor estimado de la puntuación de propensión de p_i
 - $C(i) = \{j \in D = 0 \mid \arg \min_j \|p_i(X) - p_j(X)\|\}$




Estimación del ATET por radio o distancia máxima

$$C(i) = \{p_j | \|p_i - p_j\| < r\}$$

- Radio, con reemplazo

- Para cada unidad tratada, encontrar todas las unidades de control cuyo $p(X)$ difiera en menos de una tolerancia dada « r » elegida por el investigador y permitir el reemplazo de las unidades de control

$C(i) = \{j \in D = 0 | \|p_i(X) - p_j(X)\| \leq k\}$, que contendrá tantos elementos como individuos del grupo de control haya dentro del nivel de tolerancia



Estimación del ATET por el vecino más cercano y por radio

La fórmula para ambos tipos de estimadores se puede escribir de la siguiente manera

$$\begin{aligned}\tau &= \frac{1}{N^T} \sum_{i \in T} \left[Y_i^T - \sum_{j \in C(i)} w_{ij} Y_j^C \right] \\ &= \frac{1}{N^T} \left[\sum_{i \in T} Y_i^T - \sum_{i \in T} \sum_{j \in C(i)} w_{ij} Y_j^C \right] \\ &= \frac{1}{N^T} \sum_{i \in T} Y_i^T - \frac{1}{N^T} \sum_{j \in C} w_j Y_j^C\end{aligned}$$

con $w_{ij} = \frac{1}{N_i^C}$ si $j \in C(i)$ y $w_{ij} = 0$ si no, $w_j = \sum_i w_{ij}$ y el número de unidades en el grupo tratado se denota por N^T

Estimación del ATET por el vecino más cercano y por radio en Stata

«Estimation of the average treatment effect on the treated using nearest neighbor matching»:

`attnd`

```
attnd outcome treatment , pscore(scorevar) logit
```

```
attnd re75 treat age age2, pscore(mypscore) logit blockid(myblock)
```

«Calculate the average treatment effect on the treated using radius matching»: `attr`

```
attr outcome treatment , pscore(scorevar) logit radius(#)
```

```
attnd re75 treat age age2, pscore(mypscore) logit blockid(myblock)  
radius(0.01)
```


Algoritmo de emparejamiento: (4) Kernel

Estimación del ATET por medio de Kernel

Cada unidad tratada se compara con un promedio ponderado de todas las unidades de control con pesos que son inversamente proporcionales a la distancia entre los $p(X)$ de la tratada y los controles

Selección del algoritmo de emparejamiento: Estimador PSM por Kernel

Emparejamiento por Kernel: Diferencia entre la variable objetivo del individuo del grupo de tratamiento y el promedio ponderado de la variable objetivo en todo el grupo de control


$$\tau_{ATT}^{PSM-KERNEL,LL} = \frac{1}{n} \left\{ \sum_{i \in D=1} [(Y_i | D = 1) - \sum_{j \in D=0} w_{ij} (Y_j | D = 0)] \right\}$$

$$w_{ij}^{KERNEL} = \frac{G\left(\frac{P_j(X) - P_i(X)}{\alpha_n}\right)}{\sum_{k \in D=0} G\left(\frac{P_k(X) - P_i(X)}{\alpha_n}\right)}$$

- G : Función Kernel (uniforme, triangular, gaussiana, ...)
- α_n : Ancho de la banda
- n : Número de individuos en el grupo de tratamiento
- Los pesos usados para calcular el contrafactual dependen del tipo de Kernel elegido


Selección del algoritmo de emparejamiento: (4) Estimador PSM por Kernel

Por Kernel: Pesos con Kernel triangular




Selección del algoritmo de emparejamiento: (4) Estimador PSM por Kernel

Por Kernel: Pesos con Kernel gaussiano



Selección del algoritmo de emparejamiento: (4) Estimador PSM por Kernel

Pesos con Kernel Epanechnikov



Estimación del ATET por medio de Kernel en Stata: `attk`

```
attk outcome treatment , pscore(scorevar)
```

```
attk re75 treat age age2, pscore(mypscore) logit
```

Pruebas de falsificación

Falsificación

- El supuesto de independencia condicional, $E(u|D) = 0$, permite la identificación en PSM
- El supuesto de independencia condicional no tiene implicaciones que se puedan comprobar directamente en los datos $\rightarrow$ No es posible determinar de manera directa si se cumple o no
- Pruebas de falsificación: ejercicios para evaluar si la estrategia de identificación tiene validez
- Imbens y Rubin (2010) sugieren dos tipos de pruebas de falsificación:
 - 1 Estimar el efecto del programa sobre una variable de resultado ficticia, que no puede ser afectada por el tratamiento (seudo-resultado)
 - 2 Estimar el efecto causal de una intervención ficticia que se sabe no debería tener efectos en nuestra variable de resultado (seudo-tratamiento)

Controles Sintéticos

Inés Berniell

UNLP

Métodos de Evaluación de Impacto de Políticas Públicas

Junio 2019

Estudios de Casos Comparados

Nota: estas slides y la aplicación en Stata siguen el texto de Scott Cunningham (2018): «Causal Inference: The Mixtape»

- Objetivo: Estimar los efectos de políticas públicas que afectan a unidades agregadas, como ciudades, regiones, o países.
- Estudios de Casos Comparados: Comparan la evolución de variables de interés entre la entidad afectada por la intervención de política pública y un grupo de control.
 - Ventajas:
 - Muchas intervenciones de política pública afectan a unidades macro/agregadas
 - Los datos macro/agregados son más comunes que los datos micro/desagregados
 - Desventajas:
 - Ambigüedad con respecto al proceso de selección del grupo de control, que se hace *ad hoc*
 - Inferencia

Estudios de Casos Comparados: Ejemplo del Éxodo de Mariel

- Cómo afecta la llegada de inmigrantes al empleo de los trabajadores autóctonos?
- Card (1990) usa el éxodo de Mariel para estimar el efecto de un influjo migratorio sobre las oportunidades laborales de los trabajadores autóctonos (low-skilled).
- El éxodo de Mariel incrementó en un 7 % el número de trabajadores en Miami.
- Card (1990) compara la evolución del empleo autóctono en Miami con el de cuatro ciudades de control no afectadas por el éxodo (Atlanta, Los Angeles, Houston y Tampa)
- No encuentra ningún efecto en el empleo o los salarios (un resultado sorprendente para la mayoría de los economistas, dado el gran impacto de la oferta laboral)

El Método de Control Sintético

- Para unidades agregadas, como regiones o países, puede no existir una unidad no tratada que proporcione una aproximación razonable a las características de la unidad tratada.
- El método de control sintético se basa en la observación de que una combinación de unidades de no tratados (es decir, un «control sintético») frecuentemente proporciona una aproximación más cercana a las características de la unidad afectada por la intervención de política pública que cualquier unidad individual.
- El método de control sintético emplea como unidad de control la media ponderada de las unidades no tratadas (que son potenciales controles) que hace una mejor aproximación de las características de la unidad tratada que lo haría la comparación de la tratada con cada potencial control (uno a uno).

El Método de Control Sintético

- La unidad de comparación en el método de control sintético se selecciona como el promedio ponderado de todas las unidades de comparación potenciales que mejor se asemejan a las características de la(s) unidad(es) tratada(s)
- Se hace explícita la contribución de cada unidad de comparación a la contrafactual de interés
- Esta formalización provee una metodología sistemática para la selección de unidades de control en estudios de casos comparados, y también tiene importantes implicaciones para el método de inferencia estadística.

El Método de Control Sintético

- Observamos un conjunto de unidades antes y después de una cierta intervención de política pública.
- Una de las unidades es expuesta a la intervención de interés.
- El resto de las unidades constituyen una reserva de posibles miembros del grupo de control sintético.
- Deseamos encontrar la combinación de unidades no tratadas que mejor aproxime las características de la unidad tratada antes de la intervención.

Método de control sintético: estimación

- Supongamos que observamos $J + 1$ unidades en los periodos $1; 2; \dots; T$
- La unidad «1» está expuesta a la intervención de interés (es decir, «tratamiento») durante los periodos $T_0 + 1; \dots; T$
- Los restantes J son un reservorio de potenciales controles
- Sea Y_{it}^N es el resultado que se observaría para la unidad i en período t en ausencia de la intervención
- Sea Y_{it}^I el resultado que se observaría para la unidad i en el período t si la unidad i está expuesta a la intervención en los periodos $T_0 + 1$ a T
- Nuestro objetivo es estimar el efecto de la intervención sobre la unidad tratada $(\alpha_1 T_0 + 1, \dots, \alpha_1 T)$, donde
 - $\alpha_{1t} = Y_{1t}^I - Y_{1t}^N = Y_{1t} - Y_{1t}^N$ para $t > T_0$ y Y_{1t} es el resultado de interés para la unidad 1 en el período t

Método de control sintético: implementación

- Sea $W = (w_2, \dots, w_{J+1})'$ con $w_j \geq 0$ para $j = 2, \dots, J+1$ y $w_2 + \dots + w_{J+1} = 1$. Cada valor de W representa un potencial control sintético.
- Sea X_1 un vector ($k \times 1$) de características previas a la intervención para la unidad tratada (X puede incluir lagged outcomes).
- Sea X_0 una matriz ($k \times J$) que contiene las mismas variables pero para las unidades no tratadas.
- El vector $W^* = (w_2^*, \dots, w_{J+1}^*)'$ se elige para minimizar $\|X_1 - X_0 W\|$, sujeto a las restricciones de pesos ($w_2 + \dots + w_{J+1} = 1$).
- Sea Y_{jt} el valor del resultado para la unidad j en el período t , tenemos que para el período t post-intervención ($t \geq T_0$) el estimador por control sintético es:

$$\hat{\alpha}_{1t} = Y_{1t} - \sum_{j=2}^{J+1} w_j^* Y_{jt}$$

- es decir, $Y_{1t}^N = \sum_{j=2}^{J+1} w_j^* Y_{jt}$

Método de control sintético: estimación

Es decir que para producir el contrafactual Y_{it}^N buscamos la combinación de unidades no tratadas que mejor se asemeja a la unidad tratada antes de la intervención en términos de los valores de k covariables relevantes (predictores del resultado de interés).

Ejemplo: Programa de control del tabaco en California (1988)

- En 1988, California aprobó por primera vez el control integral del tabaco.
- Unidad tratada: California
- Variable de interés: consumo de tabaco en California luego de 1988
- Posibles controles: otros estados en los EE.UU.
- Covariables: predictores de consumo de tabaco a nivel de estado medidas antes de 1988

Método de control sintético: estimación

- Considere $\|X_1 - X_0 W\| = \sqrt{(X_1 - X_0 W)' V (X_1 - X_0 W)}$ (Abadie, et al.), donde
 - V es una matriz ($k \times k$) semidefinita simétrica positiva
 - X_{jm} el valor de la covariable m de la unidad j
- V es típicamente diagonal con la diagonal principal $v_1; \dots; v_k$, entonces, los pesos del control sintético $w_2^*; \dots; w_J^* + 1$ minimizan:
 - $\sum_{m=1}^k v_m \left(X_{1m} - \sum_{j=2}^{J+1} w_j X_{jm} \right)^2$
- donde v_m es la ponderación que refleja la importancia relativa que se le asigna al predictor «m» cuando se mide la discrepancia entre la característica de la unidad tratada (X_1) y la del control sintético ($X_0 W$)
- Así para una matriz de pesos V dada tendremos unos pesos óptimos $W^*(V)$

Método de control sintético: estimación

La elección de V es importante porque W^* depende de la elección de $V \rightarrow W^*(V)$

- El control sintético $W^*(V)$ está destinado a reproducir el comportamiento de la variable de resultado para la unidad tratada en ausencia del tratamiento, por lo tanto, los pesos $v_1; \dots; v_k$ debe reflejar el valor predictivo de las covariables

Método de control sintético: estimación

Hay varias formas de elegir V . La elección de $v_1; \dots; v_k$ puede basarse en:

- Evaluación subjetiva del poder predictivo de cada uno de las covariables
- El uso de una regresión para evaluar el poder predictivo de las covariables
- Minimizar el error cuadrático medio de predicción (**MSPE**): en la práctica esta es el método para elegir V

- $\frac{1}{T_0} \sum_{t=1}^{T_0} \left(Y_{1t} - \sum_{j=2}^J w_j^*(V) Y_{jt} \right)^2$

- El MSPE mide la falta de ajuste entre la trayectoria de la variable de resultado y su contraparte sintética, medido para el período previo a la política

Aplicaciones


Consumo de Cigarrillos: California y Resto de EE.UU.

- Ejemplo: Programa de control del tabaco en California (1988)
- En 1988, California aprobó por primera vez el control integral del tabaco.
- Legislación: aumento del impuesto al cigarrillo en 25 centavos / paquete
- Ingresos fiscales destinados a presupuestos de salud y antitabaco.
- campañas de medios antitabaco financiadas por el estado
- impulsaron ordenanzas de aire limpio en todo el estado
- más de \$ 100 millones por año destinado a proyectos antitabaco


Consumo de Cigarrillos: California y Resto de EE.UU.

- Unidad tratada: California
- Variable de interés: consumo de tabaco en California
- Posibles controles: otros estados en los EE.UU.
 - estados que posteriormente pasaron los programas de control son excluidos del grupo de controles de donantes (AK, AZ, FL, HI, MA, MD, MI, NJ, OR, WA, DC)
- Características a reproducir: predictores de consumo de tabaco

Consumo de Cigarrillos: California y Resto de EE.UU.



Consumo de Cigarrillos: California y Control Sintético




Características de California y del Control Sintético

Variables	California		Media de 38 estados de control
	Real	Sintética	
Log PIB per cápita	10.08	9.86	9.86
Porcentage edad 15-24	17.40	17.40	17.29
Precio del paquete	89.42	89.41	87.27
Consumo de cerveza cápita	24.28	24.20	23.75
Ventas de cigarrillos per cápita 1988	90.10	91.62	114.20
Ventas de cigarrillos per cápita 1980	120.20	120.43	136.58
Ventas de cigarrillos per cápita 1975	127.10	126.99	132.81

Nota: Para todas las variables con excepción de las ventas de cigarrillos usamos la media para el periodo 1980-1988 (1984-1988 en el caso del consumo de cerveza).

Efecto Estimado para California: La “Brecha”



Inferencia

¿Cómo determinamos si la diferencia observada entre las dos series es una diferencia estadísticamente significativa?

Método basado en placebo para la inferencia: Para evaluar la importancia de nuestros resultados, llevamos a cabo una serie de experimentos placebo en los que reasignamos el programa de control del tabaco a otros estados distintos de California.


- Estos test se basan en la premisa de que nuestra confianza en que el impacto estimado, utilizando la metodología descrita, refleja correctamente el impacto de la intervención se pondría en duda si obtenemos efectos estimados de magnitudes similares o incluso mayores en los casos en que no tuvo lugar la política.

Inferencia

Procedimiento:

- Aplicar iterativamente el método sintético a cada estado en el grupo de no tratados y obtener una distribución de los efectos del placebo
 - Comparar la brecha estimadas para California con la distribución de las brechas de los placebos.
- La pregunta es si el efecto estimado por medio del control sintético para el caso de California es grande en relación con el efecto estimado para un estado elegido al azar.

Inferencia: California y otros 38 estados




Inferencia: California y otros 19 estados

Ahora solo dejemos los estados que tienen un buen ajuste en el período previo a la política

- Se excluyen todos los estados que tenían para el período pre-tratamiento un error cuadrático medio estimado (MSPE) más de dos veces mayor al de California.

(PRE-PROP. 99 MSPE $\leq$ 2 TIMES PRE-PROP. 99 MSPE FOR CA)




Cocientes de Efectos Estimados: Después/Antes de 1988

- Otra forma de evaluar la relación entre las estimaciones realizadas para California y los test de placebo es observar la distribución de los ratios de los errores de predicción pre y post tratamiento.
- Es decir, se compara que tanto diverge el estado con su sintético, antes y después del tratamiento, para comprobar si el efecto de la política en California es superior al de los placebos.

$$RMSPE = \left(\frac{1}{T-T_0} \sum_{t=T_0+1}^T \left(Y_{1t} - \sum_{j=2}^{J+1} w_j^* Y_{jt} \right)^2 \right)^{\frac{1}{2}}$$

Cocientes de Efectos Estimados: Después/Antes de 1988

- El gráfico muestra la distribución de los ratios de los errores cuadráticos medios estimados (MSPE) pre y post tratamiento para California y los 38 estados de control




California ocupa el primer lugar entre los 38 estados. Esto da un p-valor de 0.026 (1/38)

Más placebos

- Replicar el método de control sintético para períodos en los cuales no tuvo lugar la política.
- Intiución: Si las estimaciones de los estudios placebos encuentran en alguno de los años previos al tratamiento magnitudes similares o superiores a las encontradas en para el grupo tratado luego de la política, se interpreta que el análisis realizado no proporciona evidencia significativa de que exista un efecto positivo.
- Si, por el contrario, la brecha estimada luego de la política entre el grupo tratado y el control sintético es inusualmente grande en relación con los placebos para otros años, se deduce que existe evidencia significativa del efecto de la política.

Ejemplo: reunificación alemana de 1990


- Estimación del impacto económico de la reunificación alemana de 1990 en Alemania Occidental
- La lista de posibles miembros de la unidad sintética se restringe a 16 países de la OCDE.



Características Antes de la Reunificación

	Alemania Occidental	Alemania Occidental Sintética	Muestra OCDE
PIB per-cápita	15808.9	15800.9	8021.1
Apertura al Comercio	56.8	56.9	31.9
Inflación	2.6	3.5	7.4
Tamaño sector industrial	34.5	34.4	34.2
Educación	55.5	55.2	44.1
Tasa de Inversión	27.0	27.0	25.9


Alemania Occidental y Unidad Sintética




Pesos por País en el Control Sintético

País	Ponderación	País	Ponderación
Australia	0	Holanda	0.10
Austria	0.42	Nueva Zelanda	0
Bélgica	0	Noruega	0
Dinamarca	0	Portugal	0
Francia	0	España	0
Grecia	0	Suiza	0.11
Italia	0	Gran Bretaña	0
Japón	0.16	EE.UU.	0.22

Relación post-reunificación RMSPE a previa a la reunificación RMSPE



Reunificación de Placebo: 1975



Resumen de los pasos típicos de una estimación por control sintético y su validación


- 1 Estimar el efecto del tratamiento
- 2 Encontrar los p-valores a través de la inferencia basada en placebo
- 3 Verificar la calidad del ajuste previo al tratamiento
- 4 Investigar si las covariables utilizadas para el emparejamiento están balanceadas
- 5 Verifica la validez del modelo a través de la estimación con placebo (ej., «retroceder» la fecha del tratamiento)

Practiquemos nosotros en Stata

- Descripción del experimento natural:
- De 1993 a 1995, Texas invirtió fuertemente en la construcción de prisiones
- El crecimiento anual de la capacidad operativa de las prisiones fue del 35 % en 1994, 1995 y 1996.
- Queremos ver el efecto que ha tenido la encarcelación en masa en variables sociales
- Solo nos centraremos en la primera etapa: Efecto del boom de cárceles en el encarcelamiento de hombres afroamericanos


Texas prison growth

Operational capacity



Back male incarceration per 100 000

Texas vs US



1993 starts the prison expansion

Código en Stata: synth


- net from "https://web.stanford.edu/~jhain/Synth"
- net install synth, all replace force

synth

```
synth depvar predictorvars , trunit(#) trperiod(#) [cunit(numlist)  
xperiod(numlist) mspeperiod() resultsperiod() unitnames(varname) figure  
keep(file)]
```


```
synth bmprison bmprison(1992) bmprison(1990) bmprison(1991) bmprison(1988)  
alcohol(1990) aidscapita(1990) aidscapita(1991) income ur poverty  
black(1990) black(1991) black(1992) perc1519(1990), trunit(48)  
trperiod(1993) unitnames(state) mspeperiod(1985(1)1993)  
resultsperiod(1985(1)2000) keep(synth_bmprate.dta) replace fig
```

- Notar que permite elegir hacer coincidir con el promedio del tratamiento previo intervención o se pueden elegir años particulares



Inferencia

Hacemos lo mismo pero para cada estado




Inferencia

Para cada uno de esos ejercicios placebos estimamos el pre- y post-RMSPE y calculamos el ratio de post-pre RMSPE

```
gen gap_aux=gap' i'^2
egen premean=mean(gap_aux) if year<=1993
egen postmean=mean(gap_aux) if year>1993
gen rmspe=sqrt(premean) if year<=1993
replace rmspe=sqrt(postmean) if year>1993
gen ratio=rmspe/rmspe[_n-1] if year==1994
```

Inferencia



$$\text{p-value: } \frac{1}{46} * 2 = 0,044$$

Más Aplicaciones del Método de Control Sintético en Economía (además de las que nos presentarán 3 compañeros)

- Abadie, A. and J. Gardeazabal. 2003. «The Economic Costs of Conflict: A Case Study of the Basque Country.» American Economic Review 93(1), 112-132.
- Abadie, A., A. Diamond, and J. Hainmueller. 2010. «Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program.» Journal of the American Statistical Association 105(490), 493-505.
- Abadie, A., A. Diamond, and J. Hainmueller. 2014. «Comparative Politics and the Synthetic Control Method.» American Journal of Political Science.
- Abdallah, C.S. and W.D. Lastrapes. 2012. «Home Equity Lending and Retail Spending: Evidence from a Natural Experiment in Texas.» American Economic Journal: Macroeconomics 4(4), 94-125.
- Acemoglu, D., et al. 2013. «The Value of Connections In Turbulent Times: Evidence from the United States.»
- Billmeier, A. and T. Nannicini. 2013. «Assessing Economic Liberalization Episodes: A Synthetic Control Approach.» Review of Economics and Statistics 95(3), 983-1001.
- Cavallo, E. et al. 2014. «Catastrophic Natural Disasters and Economic Growth.» Review of Economics and Statistics 95(5), 1549-1561.
- Kleven, H.J., C. Landais, C. and E. Saez. 2013. «Taxation and International Migration of Superstars: Evidence from the European Football Market.» American Economic Review 103(5), 1892-1924.
- Pinotti, P. 2012. «The Economic Costs of Organized Crime: Evidence from Southern Italy.»
- Trandafir, M. 2014. «The Effect of Same-Sex Marriage Laws on Different-Sex Marriage: Evidence from the Netherlands.» Demography 51, 317-340.