

Trabajo Práctico N°2 - Evaluación de Impacto

Maestría en Economía-UNLP

Matías Ciaschi

matiasciaschi@gmail.com

Diseño de Regresión Discontinua, Diferencias en Diferencias
y Variables Instrumentales

1 de Junio de 2020


I. Diseño de Regresión Discontinua

Diseño de Regresión Discontinua

- El supuesto mas importante para que un diseño de RDD posea interpretación causal es el de **continuidad de la forcing variable** para cada individuo / unidad de análisis.
- Esto será así siempre que los individuos no poseen control exacto sobre si su valor de forcing variable se ubicará de un lado u otro del umbral.
- Esto es equivalente a una **asignación aleatoria en los alrededores** del dicho valor de corte.
- En Cattaneo, Frandsen y Titiunik (2015) tenemos un RDD de tipo **Sharp** ya que la asignación al tratamiento es dicotómica.

Diseño de Regresión Discontinua


- Asignación al tratamiento en un RDD Sharp. Caso de Cattaneo, Frandsen y Titiunik (2015).



- Definición de la **variable de tratamiento**
 - ▶ **Tratados:** años/estados con triunfo demócrata.
 - ▶ **No Tratados:** años/estados con derrota demócrata.

Diseño de Regresión Discontinua


- Relación entre share de votos demócratas en $t+2$ y margen de victoria en t .



- Clara relación positiva entre ambas variables.
- Casi todas las observaciones pertenecen al I y III cuadrante.


Diseño de Regresión Discontinua

- Suavizar los datos por cuestiones descriptivas.
- Se puede utilizar **"bins"**: promedio del valor de la variable explicada en cierto intervalo.
- Los "bins" pueden seleccionarse **a mano** (opcion nbins en STATA, comando rdplot)




Diseño de Regresión Discontinua

- También se pueden agrupar **por mismo número de observaciones (cuartiles)**. Opción `binselect(qs)`.
- Desventaja: esto puede generar intervalos de longitud diferente.




Diseño de Regresión Discontinua

- También se pueden agruparen **intervalos de igual longitud**.
Opción binselect(es).
- Desventaja: esto puede generar intervalos de diferente número de observaciones.



Diseño de Regresión Discontinua

- Sea cual sea el método que elijamos, vemos una **discontinuidad en la variable de interés al valor de corte de la forcing variable.**
- Es importante que esto **no ocurra también en otros valores de corte** de dicha variable.



Diseño de Regresión Discontinua

- Veamos ahora una **primera aproximación** para identificar el efecto que nos interesa: **MCO**.
- Elegir un **bandwith del 10 %** . Es decir, utilizaremos los datos pertenecientes a ese intervalo.
- Obtenemos el **mismo resultado con dos regresiones a izquierda y derecha que con una regresión conjunta**.
- Modelo de regresión: $Y = \alpha + \beta T + \gamma(X - c) + \rho(X - c) * T + \epsilon_{i,t}$

Diseño de Regresión Discontinua

```
. reg demvoteshfor2 demmv t inter if demmv>-10 & demmv<10
```

Source	SS	df	MS	Number of obs	=	451
				F(3, 447)	=	39.74
Model	10697.908	3	3565.96935	Prob > F	=	0.0000
Residual	40108.8411	447	89.728951	R-squared	=	0.2106
				Adj R-squared	=	0.2053
Total	50806.7491	450	112.903887	Root MSE	=	9.4725

demvoteshf~2	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
demmv	.1702432	.2166656	0.79	0.432	-.2555666	.5960529
t	6.898794	1.750895	3.94	0.000	3.457787	10.3398
inter	.2275241	.3118728	0.73	0.466	-.3853948	.8404431
_cons	45.30183	1.223463	37.03	0.000	42.89738	47.70629

- Obtenemos un efecto de alrededor de 6.9%.
- **Mismo resultado que hacer una regresión a cada lado del valor de corte y comparar las constantes.**

Diseño de Regresión Discontinua

```
. *Lado izquierdo
. reg demvoteshfor2 demmv if demmv<0 & demmv>=-10
```

Source	SS	df	MS	Number of obs	=	245
				F(1, 243)	=	0.57
Model	55.3977246	1	55.3977246	Prob > F	=	0.4503
Residual	23543.1063	243	96.8852112	R-squared	=	0.0023
				Adj R-squared	=	-0.0018
Total	23598.5041	244	96.7151805	Root MSE	=	9.843

demvoteshf~2	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
demmv	.1702432	.2251399	0.76	0.450	-.2732316	.613718
_cons	45.30183	1.271315	35.63	0.000	42.79763	47.80604

```
. *Lado derecho
. reg demvoteshfor2 demmv if demmv>=0 & demmv<=10
```

Source	SS	df	MS	Number of obs	=	206
				F(1, 204)	=	3.47
Model	282.127092	1	282.127092	Prob > F	=	0.0638
Residual	16565.7348	204	81.2045821	R-squared	=	0.0167
				Adj R-squared	=	0.0119
Total	16847.8618	205	82.184692	Root MSE	=	9.0114

demvoteshf~2	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
demmv	.3977673	.2134012	1.86	0.064	-.0229876	.8185222
_cons	52.20063	1.191527	43.81	0.000	49.85134	54.54991

Diseño de Regresión Discontinua

- Sin embargo, **no podemos confiar en los errores estándar el MCO.**
- Es insesgado (consistente a N grande) pero **puede ser ineficiente** (errores estándar grandes).
- Además, con MCO tenemos que elegir el **bandwidth a mano**. Esto afecta tanto al coeficiente como a los errores estándar de la regresión.
- Con `rdrobust`, la opción `bwselect` toma el **ancho de banda óptimo basándose en los datos**. Existen varias opciones (ver `help rdrobust`)
 - ▶ Opción por default: `mserd` (error cuadrático medio). Calonico, Cattaneo, Farrell and Titiunik (2018).
 - ▶ Robustez: probar con otros métodos de bandwidth óptimo.

Diseño de Regresión Discontinua

- Si elegimos el **mismo ancho de banda que hicimos con MCO**, pero ahora utilizando **rdrobust**...

```
. rdrobust demvoteshfor2 demmv, kernel(uni) h(10)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	1297
			BW type =	Manual
			Kernel =	Uniform
			VCE method =	NN
Number of obs	595	702		
Eff. Number of obs	245	206		
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	10.000	10.000		
BW bias (b)	10.000	10.000		
rho (h/b)	1.000	1.000		

Outcome: demvoteshfor2. Running variable: demmv.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
Conventional	6.8988	1.7216	4.0072	0.000	3.52456 10.273
Robust	-	-	3.8907	0.000	5.15603 15.624

- Obtenemos el **mismo coeficiente pero errores estándar un poco más conservadores.**

Diseño de Regresión Discontinua

- Ahora **no imponemos ningún ancho de banda.**

```
. rdrobust demvoteshfor2 demmv, kernel(uni)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	1297
			BW type =	mserd
			Kernel =	Uniform
			VCE method =	NN
Number of obs	595	702		
Eff. Number of obs	262	228		
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	11.157	11.157		
BW bias (b)	22.670	22.670		
rho (h/b)	0.492	0.492		


Outcome: demvoteshfor2. Running variable: demmv.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
Conventional	7.3608	1.6354	4.5009	0.000	4.15542 10.5661
Robust	-	-	4.1586	0.000	4.10229 11.4162

- El ancho de banda óptimo era un poco más grande que el que estábamos suponiendo.
- Ha cambiado el coeficiente de la regresión.

Diseño de Regresión Discontinua

- Gráficamente esto se puede ver de la siguiente forma (rdplot).



Diseño de Regresión Discontinua

- Sometamos nuestros resultados a algunas pruebas.
- Por ejemplo, **no deberíamos encontrar relación causal entre el share de votos en t-1 y el margen de victoria en t.**

```
. rdrobust demvoteshlag1 demmv, kernel(uni) h(10)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 0	Left of c	Right of c	Number of obs =	1349
			BW type =	Manual
			Kernel =	Uniform
			VCE method =	NN
Number of obs	623	726		
Eff. Number of obs	241	209		
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	10.000	10.000		
BW bias (b)	10.000	10.000		
rho (h/b)	1.000	1.000		

Outcome: demvoteshlag1. Running variable: demmv.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
Conventional	1.557	2.6371	0.5904	0.555	-3.61164 6.72573
Robust	-	-	0.6078	0.543	-5.51544 10.4734

Diseño de Regresión Discontinua

- Podemos probar también el supuesto clave de un diseño de RD: **que no exista una discontinuidad en la forcing variable.**
- Test de Cattaneo (superador de McCrary). Cattaneo, Jansson y Ma (2017).
- En STATA: "findit lpdensity".

```
. rddensity demmv, plot p(1)  
Computing data-driven bandwidth selectors.
```

RD Manipulation Test using local polynomial density estimation.


Cutoff c = 0	Left of c	Right of c	Number of obs =	1390
			Model	= unrestricted
Number of obs	640	750	BW method	= comb
Eff. Number of obs	120	141	Kernel	= triangular
Order est. (p)	1	1	VCE method	= jackknife
Order bias (q)	2	2		
BW est. (h)	4.510	6.013		

Running variable: demmv.

Method	T	P> T
Robust	0.1391	0.8894

Diseño de Regresión Discontinua

- Gráficamente:



Diseño de Regresión Discontinua

- Por último, podemos ver qué ocurre si cambiamos el valor de corte de la forcing variable.
- Queremos ver si existen otras discontinuidades en la variable explicada, fuera del valor de corte elegido.

```
. rdrobust demvoteshfor2 demmv if demmv>=0, kernel(uni) c(1)
```

Sharp RD estimates using local polynomial regression.

Cutoff c = 1	Left of c	Right of c	Number of obs =	702
			BW type =	mserd
			Kernel =	Uniform
			VCE method =	NN
Number of obs	25	677		
Eff. Number of obs	25	106		
Order est. (p)	1	1		
Order bias (q)	2	2		
BW est. (h)	4.925	4.925		
BW bias (b)	5.625	5.625		
rho (h/b)	0.876	0.876		

Outcome: demvoteshfor2. Running variable: demmv.

Method	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
Conventional	1.4275	3.8216	0.3735	0.709	-6.06272	8.91778
Robust	-	-	-0.8199	0.412	-14.0895	5.77808

II. Diferencias en Diferencias

Diferencias en Diferencias

- Nos gustaría comparar al grupo de **tratados antes y después del tratamiento**.
- Pero otras cosas también pueden haber ocurrido.
- Necesitamos un **grupo de control**: grupo de observaciones igualmente afectados por esos otros factores, pero no afectados por el tratamiento que nos interesa.
- **Primera diferencia**: variación temporal, entre un momento y otro entre el mismo grupo de observaciones
- **Diferencia de la diferencia**: variación entre grupos de la variación temporal anterior.

Diferencias en Diferencias

- Estamos suponiendo que, **de no existir tratamiento**, ambos grupos (T y C) **seguirían iguales tendencias** en el outcome de interés.
- Modelo: $Y_{i,t} = \alpha + \beta Post_t + \gamma D_i + \rho Post_t * D_i + \epsilon_{i,t}$

```
. *i) Salarios  
. reg wage_st treat##post
```

Source	SS	df	MS	Number of obs	=	702
				F(3, 698)	=	156.91
Model	36.1932033	3	12.0644011	Prob > F	=	0.0000
Residual	53.668587	698	.076889093	R-squared	=	0.4028
				Adj R-squared	=	0.4002
Total	89.8617903	701	.128190856	Root MSE	=	.27729

wage_st	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
1.treat	-.0406539	.0378784	-1.07	0.284	-.1150232	.0337153
1.post	-.0348485	.0482698	-0.72	0.471	-.1296199	.0599229
treat#post						
1 1	.5040066	.0535681	9.41	0.000	.3988326	.6091805
_cons	4.653636	.0341319	136.34	0.000	4.586623	4.72065

Diferencias en Diferencias

```
.  
*ii) Empleo  
. reg fte treat##post
```

Source	SS	df	MS	Number of obs	=	702
				F(3, 698)	=	1.87
Model	450.83442	3	150.27814	Prob > F	=	0.1334
Residual	56108.8427	698	80.3851614	R-squared	=	0.0080
				Adj R-squared	=	0.0037
Total	56559.6771	701	80.6842754	Root MSE	=	8.9658

fte	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
1.treat	-2.838198	1.224749	-2.32	0.021	-5.242831	-.4335642
1.post	-2.015152	1.560741	-1.29	0.197	-5.079462	1.049159
treat#post						
1 1	2.301994	1.732057	1.33	0.184	-1.098672	5.702659
_cons	20.11364	1.103611	18.23	0.000	17.94684	22.28043

- También puede hacerse creando una variable de interacción: *Treat * Post*.
- No hay efectos del aumento del salario mínimo sobre el empleo.

Diferencias en Diferencias

- ¿Qué ocurre si definimos un nuevo **tratamiento subdividiendo el grupo de tratados?**
- **Tratamiento nuevo:** estar pagando salarios menores a 5 dólares.
- Queremos **testear la validez del grupo de control** (PA).
- Si hacemos un DD sólo para NJ, encontramos coeficientes más grandes.
- Si hacemos un DD sólo para PA, podemos confundir efectos: otras razones pueden haber hecho variar los salarios o el empleo en ese estado.

Diferencias en Diferencias

```
. *i) Salarios  
. reg wage_st treat2##post if state==1
```

Source	SS	df	MS	Number of obs	=	570
				F(3, 566)	=	653.18
Model	52.9176907	3	17.6392302	Prob > F	=	0.0000
Residual	15.2848408	566	.027005019	R-squared	=	0.7759
				Adj R-squared	=	0.7747
Total	68.2025315	569	.119863851	Root MSE	=	.16433

wage_st	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
1.treat2	-.6509444	.0230755	-28.21	0.000	-.6962684	-.6056204
1.post	-.0040907	.0286065	-0.14	0.886	-.0602787	.0520972
treat2#post						
1 1	.6158718	.0326336	18.87	0.000	.5517739	.6799696
_cons	5.113182	.0202279	252.78	0.000	5.073451	5.152913

Diferencias en Diferencias

```
. *ii) Empleo  
. reg fte treat2##post if state==1
```

Source	SS	df	MS	Number of obs	=	570
Model	322.084224	3	107.361408	F(3, 566)	=	1.44
Residual	42103.1005	566	74.3871034	Prob > F	=	0.2292
				R-squared	=	0.0076
				Adj R-squared	=	0.0023
Total	42425.1848	569	74.5609574	Root MSE	=	8.6248

fte	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
1.treat2	-2.229504	1.211092	-1.84	0.066	-4.608288	.14928
1.post	-2.25	1.501384	-1.50	0.135	-5.198965	.698965
treat2#post						
1 1	3.30137	1.712743	1.93	0.054	-.0627386	6.665478
_cons	18.98864	1.061639	17.89	0.000	16.9034	21.07387

Diferencias en Diferencias

```
. *i) Salarios
. reg wage_st treat2##post if state==0
```

Source	SS	df	MS	Number of obs	=	132
Model	7.17950431	3	2.3931681	F(3, 128)	=	31.61
Residual	9.69220199	128	.075720328	Prob > F	=	0.0000
				R-squared	=	0.4255
				Adj R-squared	=	0.4121
Total	16.8717063	131	.128791651	Root MSE	=	.27517

wage_st	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
1.treat2	-.631729	.0710853	-8.89	0.000	-.7723835	-.4910745
1.post	-.2652174	.0811442	-3.27	0.001	-.425775	-.1046598
treat2#post						
1 1	.3535895	.1005299	3.52	0.001	.154674	.552505
_cons	5.065217	.0573776	88.28	0.000	4.951686	5.178749

Diferencias en Diferencias

```
.  
*ii) Empleo  
. reg fte treat2##post if state==0
```

Source	SS	df	MS	Number of obs	=	132
				F(3, 128)	=	0.63
Model	201.184009	3	67.0613363	Prob > F	=	0.5970
Residual	13628.2061	128	106.47036	R-squared	=	0.0145
				Adj R-squared	=	-0.0085
Total	13829.3902	131	105.567864	Root MSE	=	10.318

fte	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
1.treat2	-.8933266	2.665558	-0.34	0.738	-6.167589	4.380936
1.post	-3.847826	3.042744	-1.26	0.208	-9.868415	2.172763
treat2#post						
1 1	2.812942	3.769669	0.75	0.457	-4.645991	10.27188
_cons	20.69565	2.151545	9.62	0.000	16.43845	24.95285

- Entonces, PA es útil como grupo de control.

Diferencias en Diferencias

- Para ver adecuadamente el efecto causal del aumento del salario mínimo necesito una **triple diferencia (DDD)**.
- Modelo: $Y_{i,t} = \alpha + \beta Post_t + \gamma D_i + \delta D1_i + \rho Post_t * D_i + \theta Post_t * D1_i + \eta D_i * D1_i + \pi Post_t * D_i * D1_i + \epsilon_{i,t}$
- π captura el **efecto del aumento en el salario mínimo en los restaurantes realmente afectados** por la medida (aquellos pagando salarios menores a 5 antes de la medida)
- DDD = Diferencia entre DD de interés (treat1) y DD placebo (treat2).

Diferencias en Diferencias

```
. *i) Salarios
. reg wage_st treat##treat2##post
```

Source	SS	df	MS	Number of obs	=	702
Model	64.8847475	7	9.26924965	F(7, 694)	=	257.55
Residual	24.9770428	694	.035989975	Prob > F	=	0.0000
				R-squared	=	0.7221
				Adj R-squared	=	0.7192
Total	89.8617903	701	.128190856	Root MSE	=	.18971

wage_st	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
1.treat	.0479644	.0459357	1.04	0.297	-.0422251 .1381539
1.treat2	-.631729	.0490077	-12.89	0.000	-.7279502 -.5355078
treat#treat2 1 1	-.0192154	.0557799	-0.34	0.731	-.128733 .0903022
1.post	-.2652174	.0559425	-4.74	0.000	-.3750542 -.1553806
treat#post 1 1	.2611266	.0649628	4.02	0.000	.1335794 .3886739
treat2#post 1 1	.3535895	.0693074	5.10	0.000	.2175122 .4896668
treat#treat2#post 1 1 1	.2622823	.0788847	3.32	0.001	.107401 .4171636
_cons	5.065217	.0395573	128.05	0.000	4.987551 5.142884

Diferencias en Diferencias

```
. *ii) Empleo
. reg fte treat##treat2##post
```

Source	SS	df	MS	Number of obs	=	702
Model	828.370406	7	118.338629	F(7, 694)	=	1.47
Residual	55731.3067	694	80.3044765	Prob > F	=	0.1735
Total	56559.6771	701	80.6842754	R-squared	=	0.0146
				Adj R-squared	=	0.0047
				Root MSE	=	8.9613

	fte	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
	1.treat	-1.707016	2.169846	-0.79	0.432	-5.967266 2.553235
	1.treat2	-.8933266	2.314961	-0.39	0.700	-5.438494 3.651841
	treat#treat2					
	1 1	-1.336177	2.634856	-0.51	0.612	-6.509422 3.837068
	1.post	-3.847826	2.642536	-1.46	0.146	-9.03615 1.340498
	treat#post					
	1 1	1.597826	3.068626	0.52	0.603	-4.427078 7.62273
	treat2#post					
	1 1	2.812942	3.273849	0.86	0.391	-3.614895 9.240779
	treat#treat2#post					
	1 1 1	.4884275	3.726249	0.13	0.896	-6.827646 7.804501
	_cons	20.69565	1.868555	11.08	0.000	17.02695 24.36435

- Tampoco se encuentran efectos sobre empleo.

III. Variables Instrumentales

1. Principales contribuciones de AJR (2001)

Variables Instrumentales

- AJR evalúan el efecto de “buenas instituciones” en el desarrollo económico.
- **Mejores instituciones** (menores riesgos de expropiación) $\Rightarrow$ **Mayor desarrollo económico.**
- Posibles problemas de **endogeneidad y medición**. Esto origina estimadores sesgados.
- Para evitar estos problemas necesitamos una fuente de variación exógena.
- **Tasa de mortalidad de colonos entre los siglos XVII y XIX como proxy de calidad de instituciones coloniales.**

Variables Instrumentales

- Los colonos europeos establecieron diferentes tipos de instituciones de acuerdo a las condiciones del lugar.
- **“Malas instituciones” (extractivas) donde el asentamiento fue difícil.** Esa dificultad se aproxima con la tasa de mortalidad de colonos.
- “Buenas instituciones” (derechos de propiedad fuertes) donde el asentamiento fue más sencillo (tasas de mortalidad menores).
- Importantemente, AJR suponen que ese tipo de instituciones perduran en la actualidad.

Variables Instrumentales

- Entonces, **las tasas de mortalidad de colonos entre los S. XVII y XIX representan una fuente de variación exógena de las instituciones actuales.**
- No afectan el grado de desarrollo actual de los países.
- Tasas de mortalidad del pasado como instrumento de las Instituciones actuales.
- AJR encuentran que **“buenas instituciones” afectan positivamente el grado de desarrollo actual** de los países.
- También encuentran que variables de tipo geográficas o climáticas no poseen un rol relevante en este esquema.

2) Supuestos fundamentales para la validez de Variables Instrumentales. ¿Se cumple para AJR (2001)?.

Variables Instrumentales

- Dos supuestos fundamentales:
 - ▶ Relevancia
 - ▶ Exclusión
- **Relevancia:** correlación entre el instrumento y el regresor potencialmente endógeno. Si no se cumple, el instrumento es débil y el estimador IV inconsistente (no se distribuye asintóticamente normal). Supuesto **testeable**.
- **Exclusión:** inexistencia de correlación entre el instrumento y el término de error. Si no se cumple, obtendremos estimadores sesgados. Supuesto **no testeable**.

Variables Instrumentales

- Existen dudas sobre el cumplimiento de ambos supuestos en AJR(2001).
- Albouy (2006) y Glaeser (2004) corrigen la base de datos de AJR y encuentran que el **instrumento es débil**.
- Sachs (2012) cuestiona la **validez del supuesto de exclusión**. Para el autor, la tasa de mortalidad en la época colonial está correlacionada con la prevalencia de enfermedades en la actualidad.
- De esta manera, las tasas de mortalidad de los colonos puede afectar el PBI actual no sólo a través de Instituciones actuales, sino también mediante prevalencia de enfermedades.

3) Reproducir la columna 2 de la Tabla 4 de AJR(2001). Comentar resultados.

Variables Instrumentales

- Keep if baseco==1.
- Vemos que los estimadores de **MCO** sufrían un sesgo de **atenuación**.
- Factores geográficos no relevantes. Es decir, el coeficiente asociado a Latitud no resulta significativo.
- Fortaleza del instrumento utilizado (**primera etapa válida**).
- Es necesario tener en cuenta que **estos resultados representan un LATE (Local Average Treatment Effect)**. Es decir, su validez es meramente local.

4) Supuestos adicionales para interpretar el resultado como un ATE.

Variables Instrumentales

- El estimador LATE identifica el efecto de las instituciones sobre el nivel de desarrollo actual a partir de un promedio ponderado donde las ponderaciones están establecidas de acuerdo a **cuánto afecta el instrumento a la variable instrumentada.**
- Entonces, de acuerdo a Imbens y Wooldridge (2007), el LATE sólo brinda información acerca de los efectos promedio **para la subpoblación afectada por el instrumento.**
- Entonces, un LATE será interpretado como un ATE sólo si la relación entre mortalidad de los colonos europeos y calidad de las instituciones fuese igual para todos los países. Supuesto de monotonicidad en Duflo et al (2007).

Variables Instrumentales

- También es necesario el **supuesto de independencia** para interpretar un LATE como un ATE. Éste establece que:
 - ▶ i) La comparación de resultados entre unidades de análisis expuestas a diferentes valores del instrumento identifica el impacto causal del mismo, lo cual se verifica con **asignación aleatoria del instrumento**.
 - ▶ ii) Los resultados potenciales no deben ser afectados directamente por el instrumento.
- En definitiva, para que un LATE sea interpretable como un ATE es necesario suponer: **monotonicidad e independencia**.

5) Resume las principales críticas y respuestas al trabajo

Variables Instrumentales

- **Sachs (2012):**

- ▶ Regímenes dictatoriales con riesgos de expropiación altos no instauraron instituciones extractivas.
- ▶ AJR deja de lado cuestiones climáticas a la hora de explicar el desarrollo económico.
- ▶ Critica el supuesto de que las instituciones son estáticas.

- **Albouy (2006):**

- ▶ Soluciona problemas de comparabilidad en las tasas de mortalidad de los colonos.
- ▶ Mayores muertes militares en países poco desarrollados y con altos riesgos de expropiación. Sesgo en las estimaciones IV.