

Maestría en Economía - UNLP

Examen Final - Regresiones por Cuantiles

Ejercicio 1. Regresión por Cuantiles: Curva de Kuznets Ambiental (CKA).

La totalidad de este ejercicio está inspirado en el trabajo Flores, Flores-Lagunes y Kapetanakis (2009), sugerido como paper de referencia en las clases del curso. El objetivo del mismo es aplicar sus conocimientos en regresiones por cuantiles (QR) al estudio de la CKA, un tópico recurrente en los papers sobre economía ambiental. La idea implícita en esta literatura es que existe una relación entre el nivel de contaminación de un país con su grado de desarrollo. La variable más utilizada para medir el desarrollo es el PBI per cápita (GDP), aunque también se puede incluir el nivel educativo, el grado de urbanización e industrialización, entre otros.

Suponer que el cuantil τ -ésimo de la contaminación (y) condicional en el desarrollo (x) es lineal en parámetros, donde x es un vector que incluye a todos los factores observables del desarrollo. El archivo “EKC-data.dta” contiene un panel de datos para las 6 regiones que conforman un país a lo largo del periodo 1971 a 2018. Utilizar la cantidad de emisiones de dióxido de carbono (CO2 en Kg.) por unidades de GDP como el índice de contaminación. El resto de la información se encuentra en las etiquetas de cada variable.¹

Como primera aproximación a la CKA, considerar a la contaminación como una función que depende, únicamente, del PBI per cápita (en log) y su cuadrado. Para esta parte del ejercicio, omitir la estructura de panel de los datos; es decir, estime sus regresiones tratando a los datos como si fueran un único corte transversal (pool data). En base a esto, se pide:

(a) *Estimar por mínimos cuadrados ordinarios (MCO) la relación entre polución y desarrollo. Además, utilizar quantile regression (QR) para estudiar la misma relación estimando los cuantiles 0.10, 0.25, 0.50, 0.75 y 0.90. Mostrar e interpretar los resultados. Evaluar, empíricamente, el aporte de utilizar QR en comparación con el análisis basado en MCO.²*

Se considera el siguiente modelo:

$$polu_i = \beta_0 + \beta_1 lgdp_i + \beta_2 lgdp_i^2 + u_i, \quad (1)$$

donde $polu$ es el índice de contaminación (emisiones de dióxido de carbono -CO2 en kg.- por unidades de PBI) y $lgdp$ y $lgdp^2$ son el PBI per cápita y su cuadrado (en log), respectivamente.

¹ Una vez abierta la base de datos, se puede utilizar el comando “describe” de Stata para ver las etiquetas de todas las variables.

² En caso que se considere que se debe utilizar el método de *bootstrap* para computar los errores estándar, se pide utilizar 100 reposiciones. Para que el resultado sea replicable, escribir en el *do-file* el comando *set seed 123* en la línea previa a la que se ejecuta la regresión.

En la tabla 1, se presenta la estimación del modelo (1) por MCO y por el método de Koenker y Bassett (1978), para los cuantiles condicionales 0.10, 0.25, 0.50, 0.75 y 0.90 (computando los errores estándar mediante un *bootstrap* de 100 reposiciones), como enfoques alternativos para entender la relación entre el nivel de contaminación de las regiones del país considerado con sus grados de desarrollo.

Por un lado, se puede observar que, tanto en la estimación por MCO como por QR, el *lgdp* (y su cuadrado) es estadísticamente significativo para explicar el índice de contaminación. Por otro lado, se observa que el efecto marginal del *lgdp* sobre el índice de contaminación no es homogéneo a lo largo de la distribución condicional, no siendo el efecto sobre la media condicional un buen resumen de lo que sucede en el resto de la distribución condicional. En particular, para el valor promedio del *lgdp*³, el efecto marginal sobre la media condicional es igual a -0,079, mientras que, para los cuantiles condicionales 0.10, 0.25, 0.50, 0.75 y 0.90, es igual a -0,122, -0,106, -0,048, -0,106 y -0,085, respectivamente. Siendo así, el efecto marginal es considerablemente mayor (en valor absoluto) en los cuantiles condicionales 0.10, 0.25 y 0.75, indicando que un aumento de un punto logarítmico del *lgdp* promedio (*ceteris paribus*) disminuye los cuantiles condicionales en 0,122, 0,106 y 0,106 unidades de CO2 (en kg.) por unidades de PBI, respectivamente.

En resumen, en todas las estimaciones, se encuentra una relación positiva hasta cierto punto y negativa luego entre el nivel de contaminación de las regiones de este país con sus grados de desarrollo (medidos por el PBI *per cápita*), es decir, a medida que el PBI *per cápita* (en log) aumenta, el nivel de contaminación predicho aumenta hasta cierto punto y, a partir de allí, cuando el PBI *per cápita* sigue aumentando, el nivel de contaminación predicho comienza a disminuir. Se supone que esto se da así porque, cuando los países (regiones) recién comienzan a desarrollarse, la instalación de nuevas fábricas y nuevas tecnologías aumenta la contaminación, pero, cuando llegan a cierto nivel de desarrollo, evolucionan hacia métodos más sofisticados asociados a una menor contaminación.

Tabla 1. Estimaciones del modelo (1).

Variables	MCO	QR(0.10)	QR(0.25)	QR(0.50)	QR(0.75)	QR(0.90)
<i>lgdp</i>	0,912*** (0,099)	0,829*** (0,068)	0,870*** (0,073)	1,029*** (0,161)	0,701*** (0,169)	0,932** (0,460)
<i>lgdp</i> ²	-0,059*** (0,005)	-0,057*** (0,003)	-0,058*** (0,003)	-0,064*** (0,008)	-0,048*** (0,008)	-0,061*** (0,021)
constante	5,353*** (0,470)	5,119*** (0,311)	5,081*** (0,344)	4,585*** (0,744)	6,527*** (0,815)	6,387*** (2,158)
Observaciones	288	288	288	288	288	288

Los datos en paréntesis corresponden a los desvíos estándar (*bootstrap* 100 réplicas). Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.


(b) Realizar un gráfico de dispersión (o nube de puntos) que muestre, en el eje horizontal, al PBI *per cápita* (en log) y, en el eje vertical, al nivel de polución junto con la predicción del modelo estimado para cada cuantil condicional (vale aclarar, superpuestos en el

³ Igual a 8,359785.

mismo gráfico). Comentar las conclusiones sobre la relación entre el desarrollo económico y la contaminación observada en el gráfico.

En la figura 1, se presenta un gráfico de dispersión que muestra, en el eje vertical, al nivel de polución junto con la predicción del modelo estimado para cada cuantil condicional (0.10, 0.25, 0.50, 0.75 y 0.90) y, en el eje horizontal, al PBI *per cápita* (en log). En línea con lo comentado previamente, en términos generales, se puede observar una relación en forma de U invertida entre la contaminación y el desarrollo económico. Adicionalmente, como es de esperar, se observa que el cuantil condicional 0.90 tiene los niveles de polución predichos más altos, mientras que el 0.10 los más bajos.

Figura 1. Relación entre nivel de polución y PBI *per cápita* (en log) - modelo (1).



Fuente: Elaboración propia.

Una crítica obvia al análisis anterior es que el PBI *per cápita* es una medida imperfecta del desarrollo y, por lo tanto, no refleja la verdadera relación con el nivel de contaminación. Considerar, ahora, una versión ampliada de la CKA en donde, además de la relación cuadrática con el PBI *per cápita* (en log), se incluye, como variables explicativas, a la cobertura educativa en primaria y secundaria junto con el grado de urbanización. Vale aclarar que se debe seguir utilizando a los datos como si fuera un corte transversal para resolver los dos incisos siguientes:

(c) Repetir el inciso (a) pero con el modelo en su versión ampliada. Realizar un test para contrastar la hipótesis nula de que los efectos marginales del desarrollo sobre la contaminación son homogéneos en los distintos puntos de la distribución condicional. Además, realizar el mismo test pero para tres sub-grupos de regresores diferentes: (i) los

de desarrollo económico, (ii) los de desarrollo educativo y (iii) el de urbanización. Comentar, brevemente, los resultados.

Se considera el siguiente modelo:

$$polu_i = \beta_0 + \beta_1 lgdp_i + \beta_2 lgdp_i^2 + \beta_3 educ1_i + \beta_4 educ2_i + \beta_5 urbano_i + u_i, \quad (2)$$

donde *polu*, *lgdp* y *lgdp*² se definen como en el modelo (1); *educ1* y *educ2* refieren al porcentaje de la población mayor a 12 y 18 años (respectivamente) con primaria completa y secundaria completa (respectivamente); y *urbano* es el porcentaje de urbanización de la población.

En la tabla 2, se presenta la estimación del modelo (2) análogamente a lo presentado en el inciso (a).

Por un lado, se puede observar que, tanto en la estimación por MCO como por QR, las variables explicativas *lgdp*, *lgdp*² y *educ1* son estadísticamente significativas para explicar el índice de contaminación; *educ2* no es estadísticamente significativa en ninguna estimación; y *urbano* sólo es estadísticamente significativa en MCO y en los cuantiles condicionales 0.25 y 0.50. Por otro lado, se observa que, al igual que en el modelo (1), el efecto marginal del *lgdp* sobre el índice de contaminación no es homogéneo a lo largo de la distribución condicional; en particular, para el valor promedio del *lgdp*, el efecto marginal sobre la media condicional es igual a -0,114, mientras que, para los cuantiles condicionales 0.10, 0.25, 0.50, 0.75 y 0.90, es igual a -0,133, -0,117, -0,116, -0,142 y -0,110, respectivamente. Por último, se ve que el efecto marginal de *educ1* es negativo en todas las estimaciones (aunque con un impacto mayor en el cuantil condicional 0.90), indicando que, cuanto mayor es el porcentaje de la población mayor a 12 años con primaria completa, menor es el nivel de contaminación; y el efecto marginal de *urbano* es positivo (con mayor impacto en el cuantil condicional 0.50), indicando que, cuanto mayor es el porcentaje de urbanización de la población, mayor es el nivel de contaminación.

Tabla 2. Estimaciones del modelo (2).

Variables	MCO	QR(0.10)	QR(0.25)	QR(0.50)	QR(0.75)	QR(0.90)
lgdp	0,833*** (0,104)	0,818*** (0,056)	0,883*** (0,082)	0,838*** (0,145)	0,669*** (0,197)	0,847** (0,414)
lgdp ²	-0,057*** (0,005)	-0,057*** (0,003)	-0,060*** (0,004)	-0,057*** (0,008)	-0,049*** (0,010)	-0,057*** (0,020)
educ1	-0,027*** (0,006)	-0,014** (0,007)	-0,030*** (0,005)	-0,030*** (0,005)	-0,025** (0,012)	-0,042 (0,031)
educ2	0,036 (0,044)	0,015 (0,019)	0,036* (0,021)	-0,003 (0,047)	0,091 (0,083)	0,037 (0,183)
urbano	0,044*** (0,016)	0,019 (0,013)	0,044*** (0,013)	0,060*** (0,017)	0,024 (0,035)	0,096 (0,066)
constante	4,064*** (0,833)	4,702*** (0,515)	3,642*** (0,504)	4,289*** (0,999)	4,402*** (1,436)	2,908 (3,615)
Observaciones	288	288	288	288	288	288

Los datos en paréntesis corresponden a los desvíos estándar (*bootstrap* 100 réplicas). Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.


[illegible]

$$\begin{aligned}
 R_1 &= \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}; \quad \beta_1 = \begin{bmatrix} [q10]\beta_1 \\ [q10]\beta_2 \\ [q10]\beta_3 \\ [q10]\beta_4 \\ [q10]\beta_5 \\ [q25]\beta_1 \\ [q25]\beta_2 \\ [q25]\beta_3 \\ [q25]\beta_4 \\ [q25]\beta_5 \\ [q50]\beta_1 \\ [q50]\beta_2 \\ [q50]\beta_3 \\ [q50]\beta_4 \\ [q50]\beta_5 \\ [q75]\beta_1 \\ [q75]\beta_2 \\ [q75]\beta_3 \\ [q75]\beta_4 \\ [q75]\beta_5 \\ [q90]\beta_1 \\ [q90]\beta_2 \\ [q90]\beta_3 \\ [q90]\beta_4 \\ [q90]\beta_5 \end{bmatrix}; \quad r_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \\
 R_2 &= \begin{bmatrix} 1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & -1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & -1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 \end{bmatrix}; \quad \beta_2 = \begin{bmatrix} [q10]\beta_1 \\ [q10]\beta_2 \\ [q25]\beta_1 \\ [q25]\beta_2 \\ [q50]\beta_1 \\ [q50]\beta_2 \\ [q75]\beta_1 \\ [q75]\beta_2 \\ [q90]\beta_1 \\ [q90]\beta_2 \end{bmatrix}; \quad r_2 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}. \\
 R_3 &= \begin{bmatrix} 1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & -1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & -1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 \end{bmatrix}; \quad \beta_3 = \begin{bmatrix} [q10]\beta_3 \\ [q10]\beta_4 \\ [q25]\beta_3 \\ [q25]\beta_4 \\ [q50]\beta_3 \\ [q50]\beta_4 \\ [q75]\beta_3 \\ [q75]\beta_4 \\ [q90]\beta_3 \\ [q90]\beta_4 \end{bmatrix}; \quad r_3 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}. \\
 R_4 &= \begin{bmatrix} 1 & -1 & 0 & 0 & 0 \\ 1 & 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & -1 & 0 \\ 1 & 0 & 0 & 0 & -1 \end{bmatrix}; \quad \beta_4 = \begin{bmatrix} [q10]\beta_5 \\ [q25]\beta_5 \\ [q50]\beta_5 \\ [q75]\beta_5 \\ [q90]\beta_5 \end{bmatrix}; \quad r_4 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}.
 \end{aligned}$$

(d) Construir un gráfico análogo al realizado en el inciso (b) pero tomando el caso de una región con niveles cobertura educativa y grado de urbanización promedios (omitir la nube de puntos). Un rasgo latente en la metodología de Koenker y Bassett (1978) es lo que se conoce como cruce de cuantiles (*quantile crossing*). Comentar por qué esto representa un problema e indagar sobre las propiedades algebraicas del método relacionadas con este aspecto.

En la figura 2, se presenta un gráfico de dispersión análogo al presentado en el inciso (b), tomando el caso de una región con niveles de cobertura educativa y grado de urbanización promedios. Nuevamente, se puede observar una relación en forma de U invertida entre la contaminación y el desarrollo económico.

Figura 2. Relación entre nivel de polución y PBI per cápita (en log) - modelo (2).



Fuente: Elaboración propia.

Finalmente, un rasgo latente en la metodología de Koenker y Bassett (1978) es lo que se conoce como cruce de cuantiles (*quantile crossing*), lo cual, si bien es un resultado posible, es contraintuitivo porque, teóricamente, los cuantiles condicionales deberían estar ordenados y no cruzarse. Sin embargo, esto es un problema en tanto puede tener que ver con errores de especificación del modelo y, de esta manera, se tendrían estimaciones sesgadas. Una propiedad algebraica del método relacionada con este aspecto refiere a que no habrá cruce de cuantiles muestrales en el centro de la distribución de x , por lo cual, en este tramo, sí se respeta el ordenamiento cualesquiera sean los datos y la distribución.

Otra crítica natural en este tipo de estudios es que, si las regiones son entidades autónomas, es posible que tengan preferencias diferentes respecto al problema de la

contaminación ambiental y, por lo tanto, puede existir un problema de endogeneidad no observable asociado a un “efecto región”. Para esta parte del ejercicio, se debe considerar la estructura de panel de los datos provistos. Se pide:

(e) Explicar las consecuencias del “efecto región” sobre las estimaciones realizadas en los incisos anteriores. Repetir los ejercicios en los incisos (c) y (d) pero utilizando un modelo que incluya efectos fijos por región. En el caso de los cuantiles condicionales, se debe indicar, explícitamente, qué estimador se está usando, citando el paper de referencia. Comentar todo lo que se considere relevante en los resultados y explicar las ventajas de utilizar dicho método.

A pesar de que los signos de los coeficientes obtenidos en los incisos (a) y (c) son consistentes con lo que indica la literatura económica relacionada, es muy posible que la presencia de heterogeneidad no observable a nivel región haga que las estimaciones anteriores sean sesgadas e inconsistentes. Existen factores característicos de las regiones que no son observables y, por lo tanto, ignorar el vínculo mencionado conduciría a estimaciones inconsistentes y a inferencias no válidas con respecto al efecto causal de los regresores. Un modelo que incluya efectos fijos por región permitiría resolver este problema, ya que, al “eliminar” el efecto de la heterogeneidad inobservable (fuente potencial de sesgo) que afecta a los regresores del modelo, se obtienen estimadores insesgados y consistentes para evaluar la relación entre las variables analizadas, siendo ésta la mayor ventaja de utilizar métodos que incluyan efectos fijos por región.

En la tabla 4, se presenta, por un lado, la estimación del modelo (2) pero incluyendo efectos fijos por región (*within*) y, por otro lado, las estimaciones de los cuantiles condicionales por el método de Canay (2011). Luego, en la tabla 5, se presentan tests de significatividad análogos a los presentados en el inciso (c); lo mismo respecto a la figura 3 (análoga a las presentadas en los incisos anteriores).

Comparando estos resultados con los hallados en el inciso (c), se puede observar que:

- el coeficiente estimado de la variable *lgdp* es mayor en los cuantiles condicionales 0.10, 0.25 y 0.50 (sesgo negativo) y menor en *within* y en los cuantiles condicionales 0.75, 0.90 (sesgo positivo);
- la variable *educ1* pasa a ser estadísticamente no significativa (excepto en el cuantil condicional 0.10), mientras que la variable *educ2* pasa a ser estadísticamente significativa (excepto en *within* y en el cuantil condicional 0.90);
- los efectos marginales de estas dos variables de desarrollo educativo son, drásticamente, menores en el caso de *educ1* (sesgo positivo) y mayores en el caso de *educ2* (sesgo negativo);
- el efecto marginal de la variable *urbano* cambia de signo positivo a negativo (sesgo positivo), indicando que, cuanto mayor es el porcentaje de urbanización de la población, menor es el nivel de contaminación; y
- los efectos marginales de los regresores del modelo sobre la contaminación no difieren estadísticamente (al 5% de significatividad) entre los cuantiles condicionales estimados, indicando que estos efectos son homogéneos.

Tabla 4. Estimaciones del modelo (3).

Variables	Within	QR(0.10)	QR(0.25)	QR(0.50)	QR(0.75)	QR(0.90)
lgdp	0,813*** (0,107)	0,914*** (0,058)	0,888*** (0,078)	0,859*** (0,106)	0,593*** (0,190)	0,726 (0,441)
lgdp ²	-0,055*** (0,005)	-0,061*** (0,003)	-0,060*** (0,004)	-0,058*** (0,006)	-0,046*** (0,010)	-0,052** (0,022)
educ1	0,013 (0,011)	0,021*** (0,008)	0,008 (0,006)	0,007 (0,005)	0,005 (0,014)	-0,005 (0,031)
educ2	0,077 (0,052)	0,146*** (0,033)	0,129*** (0,024)	0,117*** (0,037)	0,222*** (0,069)	0,127 (0,183)
urbano	-0,056 (0,035)	-0,123*** (0,016)	-0,088*** (0,013)	-0,078*** (0,0144)	-0,109*** (0,034)	-0,046 (0,059)
constante	6,015*** (1,041)	6,409*** (0,776)	6,144*** (0,671)	6,316*** (0,740)	6,855*** (1,327)	6,806* (3,665)
Observaciones	288	288	288	288	288	288


Los datos en paréntesis corresponden a los desvíos estándar (*bootstrap* 100 réplicas). Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia.

Tabla 5. Tests de significatividad del modelo (3).

Test ^(*)	Estadístico	P-valor
(1) $H_0^a: R_1\beta_1 = r_1$	F (20, 282)=1,57	Prob>F=0,0590
(2) $H_0^b: R_2\beta_2 = r_2$	F (8, 282)=0,62	Prob>F=0,7635
(3) $H_0^c: R_3\beta_3 = r_3$	F (8, 282)=1,25	Prob>F=0,2710
(4) $H_0^d: R_4\beta_4 = r_4$	F (4, 282)=2,34	Prob>F=0,0557

(*) Las hipótesis nulas son las mismas que en el inciso (c). Fuente: Elaboración propia.

Figura 3. Relación entre nivel de polución y PBI per cápita (en log) - modelo (3).



Fuente: Elaboración propia.

Finalmente, un colega comenta que tanto el nivel de polución como el desarrollo regional se determinan simultáneamente y, por lo tanto, recomienda utilizar el método de variables instrumentales para estimar los modelos anteriores.

(f) *Indicar, claramente, cuál es el problema econométrico que sospecha el colega y por qué esto podría afectar a las estimaciones previas. Explicar, brevemente, al menos, una estrategia que permita estimar un modelo de cuantiles utilizando instrumentos válidos.*

El problema econométrico que sospecha el colega se refiere a que los regresores del modelo son endógenos (en el sentido de que están correlacionados con los factores inobservables), por lo que las estimaciones por MCO serían sesgadas e inconsistentes. Este “sesgo por endogeneidad”, potencialmente, se puede solucionar mediante el método de variables instrumentales generalizado (conocido como método de mínimos cuadrados en dos etapas). Este sesgo se puede ver como un “sesgo por variable omitida”, en donde las variables que se omiten son los residuos de los regresores endógenos en los instrumentos (Z), aquellas partes que explican a los regresores conjuntamente con los instrumentos y que están correlacionadas con el término de error del modelo (u). En particular, una estrategia que permite estimar un modelo de cuantiles utilizando instrumentos válidos es la de Chernozhukov y Hansen (2005), en donde la restricción de momento es⁴ $Pr[Y < q(D, x, \tau) | X, Z] = \tau$, siendo que, una vez que se controla por Z , uno se puede olvidar del efecto de los factores inobservables sobre los posicionamientos de la distribución condicional.

⁴ Considerando cinco supuestos de identificación: “resultados potenciales”, “endogeneidad”, “independencia”, “invarianza o similitud de rankings” y “variables observadas”.

Ejercicio 2. Descomposiciones Econométricas: Convenios Colectivos, Sindicatos y Distribución Salarial.

Un tópico relevante en la literatura empírica sobre desigualdad salarial es tratar de medir el impacto de la actividad gremial sobre la distribución de los ingresos laborales. El trabajo de Lombardo y Martínez (2019) (a partir de acá, LyM2019) intenta abordar dicha temática para el caso del mercado laboral argentino utilizando la metodología propuesta por Fortin et al. (2011), paper referenciado en las clases de este curso. La tarea, en esta parte del examen, consiste en leer, detenidamente, el trabajo de LyM2019, disponible en el siguiente link: LyM2019. Una vez leído este artículo, se pide:

(a) *En la Sección 4.1 (pág. 11), los autores dicen que “Los dos supuestos necesarios para la identificación de los parámetros de la distribución contrafactual son la hipótesis de independencia condicional (ignorability)...” y también que “Se agrega, además, el supuesto implícito de que el convenio colectivo no tiene efectos indirectos sobre los trabajadores no cubiertos”. Explicar estas dos citas con sus palabras (no con las de LyM2019) dando detalles sobre su relevancia e indicando si dichos supuestos se cumplen en la aplicación que hacen los autores. Vale aclarar que la explicación no debe ser genérica, sino que debe ser aplicada al caso bajo estudio.*

En la Sección 4.1, los autores dicen que uno de los supuestos necesarios para la identificación de los parámetros de la distribución contrafactual es la hipótesis de independencia condicional (*ignorability*), es decir, condicional en X , la distribución de los factores inobservables entre grupos es independiente. En términos generales, este supuesto implica que el efecto composición en factores inobservables es nulo. En el caso de LyM2019, este supuesto implica que la diferencia entre la distribución salarial de los trabajadores comprendidos por convenio colectivo de trabajo (CCT) y la distribución salarial contrafactual (aquella que surgiría si estos mismos trabajadores, con sus características, no estuvieran protegidos por CCT) se debe sólo a la diferencia de remuneración entre los trabajadores cubiertos (abarcados por CCT) y los trabajadores no cubiertos (no abarcados por CCT), es decir, se debe sólo a la brecha salarial entre estos dos grupos. Es decir, este supuesto anula la posibilidad de que parte de la diferencia entre estas dos distribuciones se deba a la diferencia entre las distribuciones de los factores inobservables. Si este supuesto no se cumpliera, no es posible identificar, correctamente, el efecto causal de los CCT sobre la distribución salarial, ya que las estimaciones de la descomposición serían sesgadas e inconsistentes. Dadas las diferencias significativas en un conjunto de estadísticas descriptivas entre los trabajadores cubiertos y los no cubiertos expuestas por los autores (Tabla 1 del *paper*), el supuesto de *ignorability* pareciera no cumplirse en la aplicación que hacen estos, por lo cual parte de la brecha salarial y de las brechas en la desigualdad entre grupos podría estar explicada por la selección en puestos o establecimientos cubiertos, interfiriendo con la correcta identificación del efecto causal mencionado.

Adicionalmente, en esta misma sección, los autores mencionan que otro supuesto implícito es que el CCT no tiene efectos indirectos sobre los trabajadores no cubiertos. Dado que se quiere identificar el efecto causal de los CCT sobre la distribución salarial, es necesario este supuesto en tanto y en cuanto el impacto de estos convenios recaiga sólo sobre los trabajadores cubiertos (sin efectos indirectos sobre los no cubiertos). Este supuesto podría no estar cumpliéndose si, por ejemplo, en el caso de los trabajadores

informales (no cubiertos), los salarios resultantes de los CCT funcionarían como una referencia para sus salarios.

(b) Indicar, claramente, cuáles son los dos grupos contrafactuales utilizados por los autores y mencionar si la descomposición realizada es sensible a la elección de los mismos. Comentar qué hicieron los autores al respecto indicando si enfrentaron dificultades (o no) con este aspecto de la metodología.

Siendo B el grupo de trabajadores cubiertos y A el de no cubiertos, Y el logaritmo del salario horario y X el conjunto de características observables que determinan Y , los dos grupos contrafactuales utilizados por los autores son:

$$F_{Y_A^C|X=X_B} = \int F_{Y_A|X_A}(y|X) dF_{X_B}, \quad (1)$$

$$F_{Y_B^C|X=X_A} = \int F_{Y_B|X_B}(y|X) dF_{X_A}, \quad (2)$$

en donde $F_{Y_A|X_A}(y|X)$ y $F_{Y_B|X_B}(y|X)$ son las funciones de distribución de Y en los grupos A y B (respectivamente) condicionales a sus características respectivas; dF_{X_B} y dF_{X_A} significan que la integración se realiza diferenciando sobre la función de distribución marginal de las características observables del grupo B y A (respectivamente).

La distribución contrafactual (1) refleja cómo las características del grupo B se remunerarían con la estructura de salarios del grupo A , mientras que (2) es la distribución contrafactual opuesta, que refleja cómo las características del grupo A se remunerarían con la estructura de salarios del grupo B . En el primer caso, se tiene la distribución de salarios que los trabajadores cubiertos tendrían si sus características fueran remuneradas como las de los no cubiertos, mientras que, en el segundo caso, se tiene la distribución de salarios que los trabajadores no cubiertos tendrían si sus características fueran remuneradas como las de los cubiertos.

Desde ya, las descomposiciones realizadas por los autores (de la brecha salarial y de las brechas en la desigualdad) son sensibles a la elección del grupo contrafactual, siendo un problema típico de las descomposiciones *à la* Oaxaca-Blinder. En este caso, al respecto, los autores realizaron los ejercicios de descomposiciones, primero, con el grupo contrafactual (1) y, luego, con el (2). En particular, cuando la elección fue el grupo contrafactual (1), se encontraron efectos estructura salarial positivos y significativos (en los cuantiles 10, 25 y 50), mientras que, cuando la elección fue el (2), estos efectos resultaron negativos. Sin embargo, ambos resultados apuntan hacia la misma dirección (siendo robustos a la elección del grupo contrafactual), el efecto de estar bajo CCT sobre los salarios se concentra, básicamente, en la cola izquierda de la distribución, provocando cierta compresión salarial mediante el aumento salarial de los menos calificados y, por lo tanto, un efecto igualador en los salarios.

(c) En la Sección 5.4, los autores podrían haber utilizado el método de regresión por cuantiles de Koenker y Bassett (1978). Exponer, muy sintéticamente, cuáles se considera

que son los vínculos con la metodología utilizada y si se considera que existen ventajas y/o desventajas en dicha elección.

En la Sección 5.4, los autores podrían haber utilizado el método de regresión por cuantiles condicionales (Koenker y Bassett, 1978). Sin embargo, dado que les interesa estudiar el efecto de los CCT en los cuantiles no condicionales de la distribución salarial (por ejemplo, en la cola izquierda de la distribución, trabajadores con baja remuneración pero con distintas características observables) y no en los cuantiles condicionales (trabajadores con mismas características observables), utilizan el método de regresión por cuantiles no condicionales (Firpo *et al.*, 2009), buscando computar, dadas las características del conjunto de los trabajadores, el efecto marginal sobre la distribución salarial de un aumento infinitesimal en la tasa de cobertura de los CCT (*ceteris paribus*).

Ejercicio 3. Regresiones RIF para estudiar la pobreza.

El indicador de Foster-Greer-Thorbecke, popularmente conocido como $FGT(\alpha)$, es uno de los más utilizados para estudiar la pobreza monetaria. Si se llama y al ingreso y z a la línea de pobreza, el índice es:

$$FGT(\alpha) = \int_0^z \left(1 - \frac{y}{z}\right)^\alpha dF_Y(y),$$

donde $F_Y(y)$ es la función de distribución acumulada del ingreso en la población.

Un colega plantea la posibilidad de utilizar la metodología de regresiones RIF desarrollada por Firpo et al. (2009) como una forma de abordar el estudio de los determinantes de la pobreza. La tarea, en este punto, es analizar esta aplicación:

(a) Sea $r(y) = I(y < z) \left(1 - \frac{y}{z}\right)^\alpha$ la función de influencia centrada (RIF) del indicador $FGT(\alpha)$, donde $I(A)$ es una variable binaria que vale 1 si el argumento A es verdadero y 0 si es falso. Mostrar que $r(y)$ cumple con la primera línea de la condición (4) en Firpo et al. (2009) (pág. 957).

Sea $r(y) = I(y < z) \left(1 - \frac{y}{z}\right)^\alpha$ la función de influencia centrada (RIF) del indicador $FGT(\alpha)$, donde $I(A)$ es una variable binaria que vale 1 si el argumento A es verdadero y 0 si es falso. Se muestra que $r(y)$ cumple con la primera línea de la condición (4) en Firpo et al. (2009) (pág. 957):

$$\begin{aligned} \nu(F_Y) &= \int RIF(y; \nu, F_Y) dF_Y(y) \\ \nu(F_Y) &= \int I(y < z) \left(1 - \frac{y}{z}\right)^\alpha dF_Y(y) \\ \nu(F_Y) &= \int_0^z \left(1 - \frac{y}{z}\right)^\alpha dF_Y(y) \\ \nu(F_Y) &= FGT(\alpha). \end{aligned}$$

(b) Comentar sobre la relevancia que tiene la condición mencionada en el inciso (a) para el desarrollo de la metodología propuesta por Firpo et al. (2009).

Para el desarrollo de la metodología propuesta por Firpo et al. (2009), la condición mencionada en el inciso (a) es importante en tanto cualquier indicador $\nu(F_Y)$ del cual se tenga la RIF se puede recomputar, utilizando la ley de esperanzas iteradas (dado que $\mathbb{E}[RIF(y; \nu, F_Y)] = \nu(F_Y)$), como la esperanza de la esperanza de la RIF condicional en X , lo cual permite vincular la distribución no condicional con la distribución condicional y, así, estimar el efecto marginal incondicional de variar cualquier característica observable sobre el indicador considerado.

Referencias.

- Canay, I. A. (2011). A Simple Approach to Quantile Regression for Panel Data. *Econometric Journal*, 44, 368-386. <https://doi.org/10.1111/j.1368-423X.2011.00349.x>
- Chernozhukov, V. y Hansen, C. (2005). An IV Model of Quantile Treatment Effects. *Econometrica*, 73(1), 245-261. <https://doi.org/10.1111/j.1468-0262.2005.00570.x>
- Firpo, S. P., Fortin, N. M. y Lemieux, T. (2009). Unconditional Quantile Regressions. *Econometrica*, 77(3), 953-973. <https://doi.org/10.3982/ECTA6822>
- Flores, C. A., Flores-Lagunes, A. y Kapetanakis, D. (2009). Lessons from Quantile Panel Estimation of the Environmental Kuznets. *Econometric Reviews*, 33(8), 1-13. <https://doi.org/10.1080/07474938.2013.806148>
- Koenker, R. y Bassett, G. (1978). Regression Quantiles. *Econometrica*, 46(1), 33-50. Recuperado de <https://people.eecs.berkeley.edu/~jordan/sail/readings/koenker-bassett.pdf>
- Lombardo, C. y Martínez Correa, J. (2019). Convenio colectivo, sindicatos y dispersión salarial: Evidencia de Argentina. Asociación Argentina de Economía Política, LIV Reunión Anual. Recuperado de <https://aaep.org.ar/anales/works/works2019/lombardo.pdf>