

Regresión por cuantiles

Javier Alejo

Microeconometría

FCE-UNLP

Octubre, 2020

Temario de la clase

1 Introducción.

- Objeto interés
- Ejemplos
- Estimadores

2 Regresión por cuantiles.

- Modelos de regresión
- Interpretación

3 Propiedades estadísticas.

- Inferencia (asintótica)
- Robustez



Medidas de posición

Variable aleatoria univariada: función de distribución

$$F_Y(y) = \Pr(Y \leq y)$$



Media o esperanza:

$$E(Y) = \int_{-\infty}^{+\infty} y dF_Y(y)$$

Cuantil τ - ésimo de Y

$$\int_{-\infty}^{Q_\tau(Y)} dF_Y(y) = F_Y[Q_\tau(Y)] = \tau$$

donde τ está en el intervalo $[0, 1]$.



Un ejemplo paramétrico

Supongamos que $Y \sim N(\mu, \sigma^2)$. En este caso, sabemos que

$$E(Y) = \mu$$

Por otro lado, para el cuantil τ - ésimo de Y debemos resolver

$$P[Y < Q_\tau(Y)] = \tau$$

Sabemos que:

$$P[Y < Q_\tau(Y)] = \Phi\left(\frac{Q_\tau(Y) - \mu}{\sigma}\right)$$

Luego,

$$Q_\tau(Y) = \mu + \sigma\Phi^{-1}(\tau)$$

donde $\Phi^{-1}(\tau)$ es la inversa de la función de probabilidad acumulada para una $N(0,1)$.

Distribución condicional

Si Y es una VA continua, la distribución de Y dado $X = x$

$$F_{Y|X=x}(y) = \Pr(Y \leq y | X = x)$$


Esperanza condicional:

$$E(Y|X = x) = \int_{-\infty}^{+\infty} y dF_{Y|X=x}(y)$$

Cuantil condicional:

$$\int_{-\infty}^{Q_{\tau}(Y|X=x)} dF_{Y|X=x}(y) = F_{Y|X=x}[Q_{\tau}(Y|X=x)] = \tau$$

Importante: no confundir distribución de $Y|X$ con la de Y .



Otro ejemplo paramétrico

- Supongamos ahora que $Y|X = x \sim N[\mu(x), \sigma^2]$.
- Notar que ahora $E(Y|X = x) = \mu(x)$
- Cuantil τ - ésimo de Y condicional en $X = x$:

$$P[Y < Q_\tau(Y|X = x)|X = x] = \tau$$

- Al condicionar en $X = x$, $\mu(x)$ es constante, luego:

$$P[Y < Q_\tau(Y|X = x)|X = x] = \Phi\left(\frac{Q_\tau(Y|X = x) - \mu(x)}{\sigma}\right)$$

- La solución explícita es:


$$Q_\tau(Y|X = x) = \mu(x) + \sigma\Phi^{-1}(\tau)$$

Ejemplo: rendimiento educativo


- **Muestra:** 2013 estudiantes para Contador Público (UBA, 1994).
- **Variable dependiente:** cantidad de materias aprobadas desde el ingreso (en log)
- **Variable explicativa:** horas diarias dedicadas a estudiar
- **Referencia:** Sosa Escudero et al. (2009)

Grupos según horas de estudio	Cantidad de datos	Cantidad de materias (log)					
		Media	q(10)	q(25)	q(50)	q(75)	q(95)
1	82	2.34	1.61	1.79	2.48	2.77	3.04
2	231	2.07	1.39	1.61	2.08	2.56	3.00
3	576	2.30	1.39	2.08	2.48	2.71	3.00
4	457	2.49	1.95	2.30	2.64	2.83	3.04
5	426	2.52	1.95	2.40	2.64	2.83	3.00
6	158	2.57	1.79	2.48	2.71	2.83	3.04
7	40	2.73	2.56	2.71	2.77	2.89	3.09
8	32	2.58	2.20	2.48	2.64	2.83	3.09
9	11	2.73	2.30	2.77	2.83	2.89	2.89
Todos	2013	2.39	1.61	2.20	2.56	2.77	3.04


Promedio condicional




Modelo lineal para la media condicional



¿Y el resto de la distribución condicional?



Modelo lineal para cada cuantil condicional



Media

Es fácil mostrar analíticamente a $E(Y)$ cómo la solución de este problema de optimización:

$$\min_a E[(Y - a)^2]$$

CPO: $E(Y) - a = 0$

Con una muestra $Y_1, \dots, Y_n$, el análogo muestral este problema es

$$\min_a \frac{1}{n} \sum_{i=1}^n (Y_i - a)^2$$

Solución: $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$

Cuantil τ - ésimo

También es posible mostrar que $Q_\tau(Y)$ es la solución del siguiente problema de minimización:

$$\min_a E[\rho_\tau(Y - a)]$$


donde

$$\rho_\tau(u) = \begin{cases} -u(1 - \tau) & \text{si } u < 0 \\ u\tau & \text{si } u \geq 0 \end{cases}$$

Notar que $u \equiv Y - a$ (residuo) y que $\rho_\tau(u) \geq 0$.

CPO: $F(a) - \tau = 0$

Función de penalización



MCO y el modelo lineal

En el caso de la media muestral, el problema de optimización era:

$$\min_{a \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n (y_i - a)^2$$

Supongamos ahora que $a(x) = x' b$ con x (vector de $K \times 1$ de regresores), entonces:

$$\min_{b \in \mathbb{R}^K} \frac{1}{n} \sum_{i=1}^n (y_i - x_i' b)^2$$

- **Resultado:** regresión por MCO.
- **Supuesto:** linealidad en parámetros.
- Estima los K parámetros de la media condicional

Quantile Regression (Koenker y Bassett, 1978)

El cuantil muestral es la solución del problema:

$$\min_{a \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - a)$$

donde $\rho_{\tau}(u) = u[\tau - I(u < 0)]$.

Si ahora suponemos que el cuantil condicional $a(x) = x'b$:

$$\min_{b \in \mathbb{R}^K} \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - x_i'b)$$

- En este problema τ está dado.
- Se trata de encontrar K parámetros del cuantil condicional τ .
- Se puede resolver mediante programación lineal.
- No hay solución explícita.

Esperanza condicional

Supongamos el siguiente modelo lineal para la media condicional:

$$E(Y|X) = \beta_0 + \beta_1 X_1 + \dots + \beta_K X_K$$

Si X_j es continua, entonces:

$$\frac{\partial E(Y|X)}{\partial X_j} = \beta_j$$

β_j es el efecto parcial de X_j sobre el promedio de Y dado X .

Cuantil condicional

Análogamente para el cuantil condicional:

$$Q_{\tau}(Y|X) = \beta_0(\tau) + \beta_1(\tau)X_1 + \dots + \beta_K(\tau)X_K$$

Si X_j es continua, entonces:

$$\frac{\partial Q_{\tau}(Y|X)}{\partial X_j} = \beta_j(\tau)$$

$\beta_j(\tau)$ es el efecto parcial de X_j sobre el cuantil τ -ésimo de la distribución de Y dado X

Importante:

- El vector $\beta(\tau)$ es una función de τ .
- La forma depende del ajuste a los datos (*distribution-free*).



Quantile Treatment Effect

- Consideremos una variable de resultado Y con una función de distribución F .
- Un variable que indica un tratamiento bajo RCT: $T = \{0,1\}$
- Denotemos al efecto del tratamiento como $\Delta(Y)$.
- Si el tratamiento cambia la distribución de F (control) a G (tratados), definimos:

$$F(y) = G[y + \Delta(y)]$$

- El caso más simple: $\Delta(y) = \Delta_0 \forall y$ (*location shift*).

Dos ejemplos



Llamando $\Delta(Y) = \Delta(F^{-1}(\tau)) \equiv \delta(\tau)$ es fácil ver que:

$$\delta(\tau) = G^{-1}(\tau) - F^{-1}(\tau)$$

Modelo de regresión

- $\delta(\tau)$ se conoce como *Quantile Treatment Effect* (QTE).
- *Average Treatment Effect* (ATE):

$$ATE = \int_0^1 \delta(\tau) d\tau$$

Es fácil escribir al QTE dentro de un cuantil de Y condicional en T :

$$\begin{aligned} Q_{\tau}(Y|T) &= F^{-1}(\tau) + [G^{-1}(\tau) - F^{-1}(\tau)] T \\ &= \alpha(\tau) + \delta(\tau) T \end{aligned}$$

QTE condicional $X = x$ (controles adicionales):

$$Q_{\tau}(Y|T, x) = \alpha(\tau) + \delta(\tau) T + x' \beta(\tau)$$

Ambos modelos son estimables por Quantile Regression (QR).

Inferencia asintótica

Sea $\beta_0(\tau)$ el parámetro que satisface:

$$P[Y \leq x' \beta_0(\tau) | X = x] = \tau$$

y bajo ciertas condiciones de regularidad (Koenker, 2005) el estimador QR cumple con las siguientes propiedades:

- **Consistencia:**

$$\hat{\beta}(\tau) \xrightarrow{P} \beta_0(\tau)$$

- **Normalidad Asintótica:**

$$\sqrt{n}[\hat{\beta}(\tau) - \beta_0(\tau)] \xrightarrow{d} N(0, \Omega_\tau)$$

donde:

$$\Omega_\tau = \tau(1 - \tau)D_1^{-1}(\tau)D_0D_1^{-1}(\tau)$$

Varianza asintótica


Es una matriz de $k \times k$ tiene la siguiente forma:

$$\Omega = \tau(1 - \tau)E[x_i x_i' f_i(Q_\tau)]^{-1} E(x_i x_i') E[x_i x_i' f_i(Q_\tau)]^{-1}$$

Algunas alternativas para estimarla:


- **Hendricks-Koenker:** aproximación numérica de $f_i(\cdot)$ (sparsity function)
- **Powell (1990):** estimador de Kernels para $f_i(\cdot)$
- **Bootstrap:** es la más usada.

QR es robusto a outliers





Robustez

- En comparación con MCO, los $\hat{\beta}(\tau)$ de QR son menos sensibles a la presencia de outliers.
- Es la característica de los denominados estadísticos *robustos*.




QR $\neq$ MCO por cuantiles de X




QR $\neq$ MCO por cuantiles de Y



MCO por Quintiles de Y



Quintiles Condicionales



QR $\neq$ Intervalo de confianza de MCO



Resumen

- MCO estiman funciones que reflejan a la media Y condicional en X .
- QR incorpora el mismo análisis funcional, para el resto de la distribución de Y condicional X .
- El método es *distribution-free*.
- No es un sustituto de MCO, más bien son complementos.
- ¿Qué aspecto de la relación entre Y y X nos interesa?

Referencias

- Roger Koenker, “Quantile Regression”. Cambridge University Press (2005). Cap. 1, Cap. 2 (2.1-2.6).
- Angrist y Pischke (2009). Mostly Harmless Econometrics: An Empiricist’s Companion. Cap. 7.
- Walter Sosa Escudero (2005), “Progresos en Econometría”. AAEP, Serie Progresos en Economía. Cap. 5.
- Sosa Escudero, Giovagnoli y Porto (2009) “*The Effects of Individual Characteristics on the Distribution of College Performances*”, Economica, Vol LV, 99-130.