

Estimación y Propiedades Algebraicas de QR: aplicación a ecuaciones de Mincer

Javier Alejo

Tópicos de Econometría

FCE-UNLP

Octubre/Noviembre, 2020

Temario de la clase

Estimación QR


- 1 Parámetros
- 2 Predicción lineal y residuos
- 3 Propiedades algebraicas

Inferencia en QR

- 1 Errores estándar
- 2 Test de hipótesis

Análisis gráfico

- 1 Coeficientes
- 2 Distribución condicional



El modelo

Modelo para la media condicional:

$$\begin{aligned} E(w|x) = & \beta_1 + \beta_2 edad + \beta_3 edad^2 + \beta_4 pric + \beta_5 seci + ... \\ & ... + \beta_6 secc + \beta_7 supi + \beta_8 supc + ... \\ & ... + \beta_9 casado \end{aligned}$$

Modelo para el τ -ésimo cuantil condicional:

$$\begin{aligned} Q_\tau(w|x) = & \beta_1(\tau) + \beta_2(\tau) edad + \beta_3(\tau) edad^2 + \beta_4(\tau) pric + \beta_5(\tau) seci + ... \\ & ... + \beta_6(\tau) secc + \beta_7(\tau) supi + \beta_8(\tau) supc + ... \\ & ... + \beta_9(\tau) casado \end{aligned}$$

Variables

- **edad**: son los años de edad del individuo al momento de la encuesta.
- **pric**: =1 si el máximo nivel alcanzado es primaria completa, =0 en otro caso.
- **seci**: =1 si el máximo nivel alcanzado es secundario incompleta, =0 en otro caso.
- **secc**: =1 si el máximo nivel alcanzado es secundario completa, =0 en otro caso.
- **supi**: =1 si el máximo nivel alcanzado es superior incompleto, =0 en otro caso.
- **supc**: =1 si el máximo nivel alcanzado es superior completo, =0 en otro caso.
- **casado**: =1 si vive en pareja, =0 en otro caso.

Para la aplicación

- **Datos:** extraídos de la Encuesta Continua de Hogares (ECH) 2014, solo para Montevideo.
- **Muestra:** son 13235 observaciones de hombres con datos completos de ingreso, edad, educación y situación marital.
- **Método:** Mínimos Cuadrados Ordinarios (MCO) y Regresión por Cuantiles (QR).
- **Referencia:** Buchinsky, M. (1994).

Koenker y Bassett (1978)

- Modelo para el τ -ésimo cuantil de Y condicional X :

$$\begin{aligned} Q_{\tau}(y|x) &= \beta_0(\tau) + \beta_1(\tau)x_1 + \dots + \beta_K(\tau)x_K \\ &= x_i^T \beta(\tau) \end{aligned}$$

- Quantile Regression:** nos da estimadores de $\beta(\tau)$ como solución de

$$\min_{b \in \mathbb{R}^K} \sum_{i=1}^n \rho_{\tau}(y_i - x_i^T b)$$

donde $\rho_{\tau}(u) = u[\tau - I(u < 0)]$

- Notar:** τ es una constante dentro del problema de minimización.

Ecuación de ingresos (ECH 2014)

	QR(0.10)	QR(0.20)	QR(0.30)	QR(0.40)	QR(0.50)	QR(0.60)	QR(0.70)	QR(0.80)	QR(0.90)
edad	0.0466*** (0.00789)	0.0361*** (0.00587)	0.0394*** (0.00455)	0.0380*** (0.00463)	0.0414*** (0.00423)	0.0444*** (0.00406)	0.0438*** (0.00475)	0.0442*** (0.00587)	0.0472*** (0.00863)
edad2	-0.000490*** (9.18e-05)	-0.000353*** (6.89e-05)	-0.000372*** (5.26e-05)	-0.000345*** (5.28e-05)	-0.000366*** (4.87e-05)	-0.000387*** (4.74e-05)	-0.000358*** (5.50e-05)	-0.000351*** (6.85e-05)	-0.000349*** (0.000102)
pric	0.589*** (0.0901)	0.419*** (0.0688)	0.311*** (0.0439)	0.256*** (0.0466)	0.213*** (0.0371)	0.194*** (0.0345)	0.179*** (0.0481)	0.172*** (0.0385)	0.189*** (0.0518)
seci	0.825*** (0.0874)	0.645*** (0.0687)	0.542*** (0.0419)	0.500*** (0.0460)	0.451*** (0.0340)	0.435*** (0.0304)	0.416*** (0.0461)	0.399*** (0.0361)	0.437*** (0.0511)
secc	1.063*** (0.0889)	0.869*** (0.0686)	0.773*** (0.0437)	0.747*** (0.0473)	0.720*** (0.0387)	0.704*** (0.0313)	0.686*** (0.0480)	0.679*** (0.0408)	0.756*** (0.0532)
supi	1.249*** (0.0914)	1.065*** (0.0732)	1.010*** (0.0459)	0.952*** (0.0495)	0.911*** (0.0355)	0.889*** (0.0339)	0.883*** (0.0457)	0.859*** (0.0415)	0.928*** (0.0541)
supc	1.583*** (0.0897)	1.424*** (0.0694)	1.313*** (0.0453)	1.286*** (0.0487)	1.255*** (0.0352)	1.262*** (0.0330)	1.261*** (0.0469)	1.302*** (0.0407)	1.395*** (0.0515)
casado	0.132*** (0.0209)	0.132*** (0.0139)	0.142*** (0.0124)	0.142*** (0.0130)	0.134*** (0.0131)	0.144*** (0.0104)	0.143*** (0.0142)	0.143*** (0.0148)	0.136*** (0.0227)
Constant	3.458*** (0.183)	4.067*** (0.130)	4.215*** (0.103)	4.403*** (0.105)	4.465*** (0.0890)	4.511*** (0.0883)	4.632*** (0.101)	4.774*** (0.125)	4.857*** (0.183)
Observations	12,783	12,783	12,783	12,783	12,783	12,783	12,783	12,783	12,783

Errores Estandar entre parentesis *** p<0.01, ** p<0.05, * p<0.1. Bootstrap (300 replicas)

Predicción y Residuos

Definiciones: sea $\hat{\beta}(\tau)$ el estimador de QR

- **Predicción:** $\hat{Q}_\tau(Y|X) = X\hat{\beta}(\tau)$
- **Residuos:** $e(\tau) = y - X\hat{\beta}(\tau)$

Consideremos el siguiente conteo

- $P, N, Z = \#$ de observaciones con residuos positivos, negativos y nulos.

(Algunas) Propiedades Algebraicas de QR


Si X contiene un intercepto, entonces se satisface que:

- 1 Condición de los residuos

$$\frac{N}{n} \leq \tau \leq \frac{N+Z}{n}$$
$$\frac{P}{n} \leq (1 - \tau) \leq \frac{P+Z}{n}$$

- 2 Solución básica: $Z = k$

Condición de los residuos



Inferencia: un solo cuantil

Vimos que el estimador de QR tiene normalidad asintótica:

$$\sqrt{n}[\hat{\beta}(\tau) - \beta_0(\tau)] \xrightarrow{d} N(0, \Omega)$$

donde Ω es una matriz de $k \times k$ tiene la siguiente forma:

$$\Omega_{\tau} = \tau(1 - \tau)E[x_i x_i' f_i(Q_{\tau})]^{-1} E(x x') E[x_i x_i' f_i(Q_{\tau})]^{-1}$$

Algunas alternativas:

- **Hendricks-Koenker:** aproximación numérica de $f_i(\cdot)$

$$\hat{f}_i(\cdot) = \frac{2h}{x_i^T \hat{\beta}(\tau + h) - x_i^T \hat{\beta}(\tau - h)}$$

- **Powell (1990):** utilizar un estimador de Kernels para $f_i(\cdot)$
- **Bootstrap:** es la más usada

Inferencia: un solo cuantil

Vimos que el estimador de QR tiene normalidad asintótica:

$$\sqrt{n}[\hat{\beta}(\tau) - \beta_0(\tau)] \xrightarrow{d} N(0, \Omega)$$

donde Ω es una matriz de $k \times k$ tiene la siguiente forma:

$$\Omega_\tau = \tau(1 - \tau)E[x_i x_i' f_i(Q_\tau)]^{-1} E(x x') E[x_i x_i' f_i(Q_\tau)]^{-1}$$

Algunas alternativas:

- **Hendricks-Koenker:** aproximación numérica de $f_i(\cdot)$

$$\hat{f}_i(\cdot) = \frac{2h}{x_i' \hat{\beta}(\tau + h) - x_i' \hat{\beta}(\tau - h)}$$

- **Powell (1990):** utilizar un estimador de Kernels para $f_i(\cdot)$
- **Bootstrap:** es la más usada

Inferencia: varios cuantiles

Si nos interesa los parámetros de un conjunto de m cuantiles $\beta = [\beta(\tau_1), \dots, \beta(\tau_m)]$, entonces:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, V)$$

donde $\hat{\beta} = [\hat{\beta}(\tau_1), \dots, \hat{\beta}(\tau_m)]$ y donde V es una matriz de varianzas y covarianzas.

- V covarianza de los coeficientes del mismo cuantil y también entre cuantiles.
- V es de dimensión $mk \times mk$ (compuesta por bloques de $k \times k$).
- Bootstrap!

Restricciones lineales de parámetros

Modelo lineal general:

$$Q_{\tau}(Y|X) = X\beta(\tau)$$

Si llamamos $\beta = [\beta(\tau_1), \dots, \beta(\tau_m)]$, consideremos una hipótesis nulas con la siguiente forma general:

$$H_0 : R\beta = r$$

- R es una matriz de dimensión $qm \times km$ y r un vector de qm coordenadas que contienen constantes.
- **Normalidad asintótica:** procedimientos usuales (Z, χ^2) .

Restricciones lineales de parámetros

- Si contamos con m estimadores de QR

$$\hat{\beta} = [\hat{\beta}(\tau_1), \dots, \hat{\beta}(\tau_m)]$$

- Estadístico de prueba (estadístico de Wald):

$$T_n = n(R\hat{\beta} - r)^\top [R\hat{V}^{-1}R^\top]^{-1}(R\hat{\beta} - r) \xrightarrow{d} \chi_q^2$$

donde q es la cantidad de restricciones lineales en la H_0 y $\hat{V} \xrightarrow{P} V$.

- Dependiendo de cómo se especifique a R y r , esta forma engloba distintas pruebas: significatividad individual, grupal, global, efectos marginales homogéneos entre cuantiles, etc.

Ejemplos de inferencia


En nuestro caso, el modelo es:

$$\begin{aligned} Q_{\tau}(w|x) = & \beta_1(\tau) + \beta_2(\tau)edad + \beta_3(\tau)edad^2 + \beta_4(\tau)pric + \beta_5(\tau)seci + ... \\ & ... + \beta_6(\tau)secc + \beta_7(\tau)supi + \beta_8(\tau)supc + ... \\ & ... + \beta_9(\tau)casado \end{aligned}$$

Ejemplos: hipótesis sobre los parámetros


- 1 H_0 : la brecha salarial entre casados y solteros no difiere entre cuantiles.
- 2 H_0 : la educación no afecta a la mediana condicional de los salarios.
- 3 H_0 : la educación tiene un efecto homogéneo sobre la distribución condicional de salarios.

¿Forma funcional de $\beta(\tau)$?




Perfiles de ingreso por edad


Caso: soltero con secundaria completa.



Quantile crossing



Quantile crossing




¿Es un problema?

- *Contraintuitivo*: teóricamente, los cuantiles deberían estar ordenados.
- El cruce de los cuantiles muestrales es un resultado posible.
- También puede ser evidencia de errores de especificación.
- El método de QR garantiza que no habrá cruce de cuantiles muestrales en el centro de la distribución de x .

(Otra) Propiedad algebraica de QR

Sea $\hat{\beta}(\tau)$ el estimador de QR, entonces $\hat{Q}_\tau(y|\bar{x}) = \bar{x}^\top \hat{\beta}(\tau)$ es una función monótona no decreciente en τ , donde $\bar{x} = n^{-1} \sum_i x_i$.

Quantile crossing



Referencias

- Roger Koenker, “Quantile Regression”. Cambridge University Press (2005). Cap. 1, Cap. 2 (2.1-2.6).
- Cameron y Trivedi (2009). Microeconometrics Using Stata. Cap. 7.
- Buchinsky, M. (1994) Changes in the U.S. Wage Structure 1963-1987: Application of Quantile Regression, *Econometrica*, 62(2), 405-458.