

Extensiones en Regresión por Cuantiles (Parte I)

Javier Alejo

Tópicos de Econometría

Universidad Nacional de La Plata

Noviembre, 2020

Temario de la clase

1 Variable dependiente limitada

- Censura
- Variable binaria

2 Variables Instrumentales

- Endogeneidad
- Identificación
- Estimador e Inferencia.
- Otros IVQR



Previa: Propiedad de Invarianza

Sea $h(y)$ una transformación monótona no decreciente.

$$Pr(Y \leq Q_\tau) = \tau$$

Dado que $h(y)$ es no decreciente, también es cierto que:

$$Pr[h(Y) \leq h(Q_\tau)] = \tau$$

Luego:

$$Q_\tau[h(Y)] = h[Q_\tau(Y)]$$

Esto también vale para el cuantil de Y dado X

$$Q_\tau[h(Y)|X] = h[Q_\tau(Y|X)]$$

Censura

- Nos interesa una variable Y_i^* que no observamos.
- En su lugar observamos Y_i , una versión censurada.
- Censura simple:

$$Y_i = \begin{cases} C & \text{si } Y_i^* \leq C \\ Y_i^* & \text{si } Y_i^* > C \end{cases}$$

- Ejemplos: gasto y consumo, horas de trabajo/ocio, calificación de un examen, etc.

Modelo Tobit

- Modelo lineal para la variable latente

$$Y_i^* = x_i^T \beta + u_i$$

- Asume que $u_i | x_i \sim N(0, \sigma^2)$.
- Supuestos estadísticos: homocedasticidad, normalidad,...

- Sin pérdida de generalidad, $C = 0$.
- La probabilidad de observar un dato censurado es:


$$\begin{aligned}P(Y_i = C) &= P(Y_i^* \leq 0) = P(x_i^\top \beta + u_i \leq 0) \\&= P(u_i/\sigma \leq -x_i^\top \beta/\sigma) \\&= \Phi(-x_i^\top \beta/\sigma)\end{aligned}$$

- Por otro lado, la densidad de observar los valores continuos es:


$$f(Y_i|x_i) = \sigma^{-1}\phi((Y_i - x_i^\top \beta)/\sigma)$$

- Es posible estimar este modelo por máxima verosimilitud.

Relación homogénea



Relación heterogénea



Censura como una transformación

Mecanismo de censura:

$$Y_i = \begin{cases} C & \text{si } Y_i^* < C \\ Y_i^* & \text{si } Y_i^* \geq C \end{cases}$$

o lo que es igual

$$Y_i = \max(Y_i^*, C)$$

donde $\max(a, b)$ devuelve el mayor entre los valores a y b .

Cuantiles condicionales

Modelo lineal:

$$Q_{\tau}(Y_i^*|x_i) = x_i^T \beta(\tau)$$

Quisiéramos estimar:

$$\hat{\beta}(\tau) = \arg \min_{b \in \mathbb{R}^K} n^{-1} \sum_{i=1}^n \rho_{\tau}(Y_i^* - x_i^T b)$$

Sin embargo, sólo contamos con $Y_i = \max(Y_i^*, C)$.

- Por propiedad de invarianza: $Q_\tau[h(Y)|X] = h[Q_\tau(Y|X)]$
- En este caso: $Y = h(Y^*) = \max(Y_i^*, C)$
- Luego,

$$\begin{aligned} Q_\tau[Y_i|x_i] &= Q_\tau[h(Y_i^*)|x_i] \\ &= h[Q_\tau(Y_i^*|x_i)] \\ &= h[x_i^\top \beta(\tau)] \\ &= \max[x_i^\top \beta(\tau), C] \end{aligned}$$

Censored Quantile Regression

Powell (1986): propone como estimador de $\beta(\tau)$


$$\hat{\beta}(\tau) = \arg \min_{b \in \mathbb{R}^K} n^{-1} \sum_{i=1}^n \rho_{\tau}[Y_i - \max(x_i^{\top} b, C)]$$

Ventajas (teóricas)

- No requiere supuestos paramétricos sobre distribución condicional.
- Heterogeneidad en los efectos de X .

Desventajas (prácticas):

- Problemas de convergencia (Buchinsky 1998; Portnoy, 2003).
- Estimación de los errores estándar.
- Algunas mejoras con algoritmos por simulación (Baker, 2013).



Buchinsky y Han (1998): un estimador alternativo

Sabemos que el truncamiento altera la distribución original:

$$\underbrace{F(y^*)}_{\text{Dist. latente}} \neq \underbrace{F(y|y > 0)}_{\text{Dist. truncada}}$$

Llamemos q_τ al cuantil definido por la distribución truncada:


$$F(q_\tau|y > 0) \equiv \tau$$

Luego, si lo evaluamos en la distribución original (latente):

$$F(q_\tau) \equiv \tau^* \neq \tau$$

Problema: la distribución observada no identifica los cuantiles de la variable latente.

Distribución latente *versus* truncada



$$\tau = A + B$$

$$\tau^* = B + C$$

Relación entre τ y τ^*

Notar que por definición de distribución condicional:

$$\begin{aligned} F(q_\tau | y > 0) &= \frac{P(0 < y^* < q_\tau)}{P(y^* > 0)} \\ &= \frac{P(y^* < q_\tau) - P(y^* < 0)}{P(y > 0)} \\ \tau &= \frac{\tau^* - P(y^* < 0)}{1 - P(y^* < 0)} = \frac{\tau^* - P(y = 0)}{1 - P(y = 0)} \end{aligned}$$

Si nos interesa el cuantil τ^* de la variable latente debemos buscar el cuantil τ en con la muestra truncada ($i : y_i > 0$).

Estimador alternativo

La versión condicional en un grupo de regresores x_i es:

$$\tau(x_i) = \frac{\tau^* - P(y = 0|x_i)}{1 - P(y = 0|x_i)}$$

Luego, para los coeficientes $\hat{\beta}(\tau^*)$ del modelo latente podemos hacer (Buchinsky y Han, 1998):

$$\hat{\beta}(\tau^*) = \arg \min_{b \in \mathbb{R}^K} n^{-1} \sum_{i: y_i > 0}^n \rho_{\tau(x_i)}(y_i - x_i^\top b)$$

Notar que es una versión reponderada del QR estándar (globalmente cóncava) con la muestra truncada.

En la práctica...

- **Problema:** ¿cómo estimamos a $P(y = 0|x_i)$? (probabilidad de censura)
- **No es trivial:** se trata de un modelo binario. Alternativas:
 - Usar un **modelo paramétrico** (Probit o Logit), pero se pierde la esencia *distribution free* de QR.
 - **Modelo no paramétrico:** es posible (ej. Nadaraya (1965) y Watson (1964)), pero computacionalmente vuelve a ser complicado.
- **Ventajas sobre Powell (1986) un poco relativas...**

Variable dependiente binaria


Pensemos ahora en un caso de censura más extremo:

$$Y_i = \begin{cases} 0 & \text{si } Y_i^* \leq 0 \\ 1 & \text{si } Y_i^* > 0 \end{cases}$$

Métodos paramétricos: Probit, Logit, ...

$$Y_i^* = x_i^T \beta + u_i$$

- Supuestos distributivos sobre el u_i : Normal, Logística, ...
- Comportamiento homogéneo alrededor de $x_i^T \beta$.



Variable latente y observada

$$Y_i = \begin{cases} 0 & \text{si } Y_i^* < 0 \\ 1 & \text{si } Y_i^* \geq 0 \end{cases}$$

Luego, esto es una transformación no decreciente de Y^*

$$Y_i = I\{Y_i^* \geq 0\}$$

Idea: usar nuevamente la propiedad de invarianza.

- Modelo lineal: $Q_{\tau}(Y_i^*|x_i) = x_i^T \beta(\tau)$
- La transformación es $Y_i = h(Y_i^*) = I\{Y_i^* \geq 0\}$ (respuesta binaria).
- Luego,

$$\begin{aligned} Q_{\tau}[Y_i|x_i] &= Q_{\tau}[h(Y_i^*)|x_i] \\ &= h[Q_{\tau}(Y_i^*|x_i)] \\ &= h[x_i^T \beta(\tau)] \\ &= I\{x_i^T \beta(\tau) > 0\} \end{aligned}$$

Binary Quantile Regression

Manski (1975,1985) utiliza esta idea y propone:

$$\hat{\beta}(\tau) = \arg \min_{b: \|b\|=1} n^{-1} \sum_{i=1}^n \rho_{\tau}[Y_i - I\{x_i^T b \geq 0\}]$$

- La expresión $\|b\| = 1$ normaliza la escala de los parámetros.
- El método es consistente y asintóticamente normal.
- Función objetivo complicada.

Smoothed Binary Quantile Regression

Manski (1985) muestra que el BQR es equivalente a:

$$\hat{\beta}(\tau) = \arg \max_{b: \|b\|=1} n^{-1} \sum_{i=1}^n [Y_i - (1 - \tau)] I\{x_i^\top b \geq 0\}$$

Kordas (2006) propone reemplazar a $I\{x_i^\top b(\tau) \geq 0\}$ por una función suave $K(x_i^\top b/h_n)$ que satisface:

- 1 $K(-\infty) = 0$
- 2 $K(+\infty) = 1$
- 3 $K'(\cdot) > 0$

Notar:

- h_n es un parámetro que controla el suavizado.
- Este problema es menos complicado computacionalmente.

Última slide sobre BQR

Probabilidad condicional: tomando un valor particular de $X = x$, podemos estimarla como:

$$\hat{P}(Y = 1|X = x) = m^{-1} \sum_{j=1}^m I\{x^\top \hat{\beta}(\tau_j) > 0\}$$

En la balanza:

- BQR no está forzado por modelos paramétricos.
- La relevancia de usar o no BQR depende del tipo de pregunta.
- Nada en Stata, solo R o S-Plus.
- En la práctica requiere un alto costo computacional.

Previa: otra interpretación de VI

Consideren el siguiente modelo

$$Y = D\alpha + u$$

donde D es una variable endógena.

- MCO es sesgado.
- MCO es inconsistente.

Estimador de VI: usando OGMM

$$\hat{\alpha}_{VI} = (D'P_Z D)^{-1} D'P_Z Y$$

donde Z son instrumentos válidos y

$$P_Z = Z(Z'Z)^{-1}Z'$$

Previa: otra interpretación de VI

Galvao y Montes-Rojas (2015): prueban que el estimador de VI es equivalente a resolver lo siguiente

$$\hat{\alpha}_{VI} = \arg \min_{\alpha} \hat{\gamma}(\alpha)'(Z'Z)\hat{\gamma}(\alpha)$$

sujeito a:

$$\hat{\gamma}(\alpha) = \arg \min_{\gamma} (Y - D\alpha - Z\gamma)'(Y - D\alpha - Z\gamma)$$

Prueba: noten que

$$\hat{\gamma}(\alpha) = (Z'Z)^{-1}Z'(Y - D\alpha)$$

Reemplazando

$$\min_{\alpha} (Y - D\alpha)'P_Z(Y - D\alpha)$$

Luego, $\hat{\alpha} = (D'P_ZD)^{-1}D'P_ZY = \hat{\alpha}_{VI}$

¿Endogeneidad en cuantiles?

- Pregunta complicada...
- En general, con datos no experimentales las variables de interés (educación, precios, etc.) son endógenas.
- Simultaneidad, error de medición en X , auto-selección, variables omitidas, etc.
- Cuando X es endógena:

$$Pr[Y \leq x'\beta(\tau)|X = x] \neq \tau$$

- Problema: efecto causal versus correlación.

Chernozhukov y Hansen (2005)

- Establecen condiciones de identificación sin suponer ninguna forma funcional específica.
- Variable de resultado (observada): $Y \equiv Y_D$, con $D = \{0, 1\}$
- Quantile Treatment Response (objeto a estimar): $q(D, x, \tau)$
- QTE: $q(1, x, \tau) - q(0, x, \tau)$
- Restricción de momento (identificación):

$$Pr[Y \leq q(D, x, \tau) | X, Z] = \tau$$

donde Z es un instrumento para D .

Supuestos para la identificación

- **Supuesto 1 (resultados potenciales):** para $d = \{0, 1\}$ es

$$Y_d = q(d, x, U_d)$$

con $U_d \sim U(0, 1)$ y donde $q(d, x, \tau)$ es una función estrictamente creciente en τ .

- **Supuesto 2 (endogeneidad):** existe un proceso de selección dado por

$$D \equiv \delta(Z, X, V)$$

para alguna función desconocida $\delta(\cdot)$ y alguna variable aleatoria V .

Supuestos para la identificación

- **Supuesto 3 (independencia):** los rankings condicionales $U_d|X = x$ son independientes de Z .
- **Supuesto 4 (invarianza o similitud de rankings):** dado $X = x$ y $Z = z$ se satisface alguna de estas propiedades:
 - (a) U_d son iguales para todo valor d .
 - (b) $U_d|V$ son idénticamente distribuidas.
- **Supuesto 5 (variables observadas):** consisten en
 - Resultado: $Y_D = q(D, x, U_D)$,
 - Tratamiento: D
 - Controles: X
 - Instrumento: Z

Prueba de la condición de momento

Versión simple:

$$\begin{aligned}Pr[Y < q(D, X, \tau)|X, Z] &= Pr[q(D, X, U_D) < q(D, X, \tau)|X, Z] \\&= Pr[U_D < \tau|X, Z] \\&= Pr[U < \tau|X, Z] \\&= \tau\end{aligned}$$

- La demostración puede flexibilizarse fácilmente usando el supuesto más general 4.(b).
- (ver Chernozhukov y Hansen, 2005, pag. 256).

Estimador IVQR

Para simplificar, supongamos que:

$$q(d, x, \tau) = d' \alpha(\tau) + x' \beta(\tau)$$

Chernozhukov y Hansen (2005) proponen el siguiente algoritmo:

$$\min_{\alpha, \beta, \gamma} \|\gamma\|_A$$

sujeto a:

$$(\beta, \gamma) = \underset{(\beta, \gamma)}{\operatorname{argmin}} \sum_{i=1}^N \rho_{\tau}(y_i - q(d_i, x_i, \tau) - \gamma \Phi(z_i, x_i))$$

En la práctica:

- Computacionalmente muy costoso.
- Hay simplificaciones para el caso con $\dim(d) = 1$.

Inferencia IVQR

Chernozhukov y Hansen (2008)

Resultado: bajo los supuestos 1 a 5

- **Consistencia:**

$$\hat{\theta}(\tau) \equiv (\hat{\alpha}, \hat{\beta}, \hat{\gamma}) \xrightarrow{p} (\alpha_0, \beta_0, \gamma_0) \equiv \theta_0(\tau)$$

- **Normalidad asintótica:**

$$\sqrt{n} [\hat{\theta}(\tau) - \theta_0(\tau)] \xrightarrow{d} N(0, \Omega_\theta)$$

Test de identificación: Chernozhukov y Hansen (2020)

$$H_0 : \gamma_0 = 0$$

Estadístico de prueba

$$W_n = n\hat{\gamma}' V(\hat{\gamma})^{-1} \hat{\gamma} \xrightarrow{d} \chi^2_{\dim(z)}$$

Otros IVQR

Modelo triangular

$$\begin{aligned}Y &= g(X, \varepsilon) \\ X &= h(Z, \eta)\end{aligned}$$

con $Z \perp \varepsilon$ y $Z \perp \eta$.

- Koenker and Ma (2006).
- Imbens and Newey (2009).

Estimador muestral

- Abadie, et al. (2002): QR reponderado (similar a PSM).
- Kaplan y Sun (2016), GMM suavizado.
- Machado y Santos Silva (2019) proponen un modelo location-scale e identificarlo vía momentos.

Referencias

- Koenker, R. (2017). "Quantile regression 40 years on". Annual Review of Economics, Vol. 9:155-176.
- Roger Koenker, "Quantile Regression". Cambridge University Press (2005). Cap. 8 (8.1, 8.2, 8.8).
- Cajias, M., Freudenreich, P. and Freudenreich, A. (2020); "Exploring the determinants of real estate liquidity from an alternative perspective: censored quantile regression in real estate research". Journal of Business Economics:1057–1086.
- Autor, D., Houseman, S. and Kerr, S. (2012). "The Effect of Work First Job Placements on the Distribution of Earnings: An Instrumental Variable Quantile Regression Approach". Journal of Labor Economics. 35.