

Extensiones en Regresión por Cuantiles (Parte II)

Javier Alejo

Tópicos de Econometría

Universidad Nacional de La Plata

Noviembre, 2020

Temario de la clase

1 Modelos dinámicos

- Modelos autoregresivos
- Datos en panel

2 Selección muestral

- Estimador en etapas
- Estimador conjunto

3 QR misceláneo

- Error de especificación
- Otros avances en QR



Modelos autoregresivos

Supongamos el siguiente modelo AR(1)

$$y_t = \alpha + \delta y_{t-1} + \varepsilon_t$$

donde $E(\varepsilon_t) = 0$, $V(\varepsilon_t) = \sigma^2$ y $COV(\varepsilon_t, \varepsilon_s) = 0$ para $t \neq s$.

El parámetro δ nos da información sobre la dinámica de y_t :

- $|\delta| < 1$: el proceso es estacionario.
- $|\delta| \geq 1$: comportamiento divergente.

Modelo para la media condicional en el pasado:

$$E(y_t | y_{t-1}) = \alpha + \delta y_{t-1}$$

Quantile Autoregression (QAR)

Koenker y Xiao (2006) proponen el siguiente modelo QAR(1):

$$Q_{\tau}(y_t|y_{t-1}) = \alpha(\tau) + \delta(\tau)y_{t-1}$$


Notar:

- $\delta(\tau)$: dinámica en distintos puntos de la distribución de y_t condicional en su pasado.
- Parámetro de la media condicional:


$$\delta = \int_0^1 \delta(\tau) d\tau$$

- El caso $|\delta| < 1$ no es incompatible con $|\delta(\tau_0)| \geq 1$ para algún cuantil τ_0 .



AR(1)



Random walk



QAR(1)



El modelo puede ser estimado a la Koenker y Bassett (1978):

$$\begin{aligned}\hat{\delta}(\tau) &= \underset{d}{\operatorname{argmin}} \sum_{t=2}^T \rho_{\tau}(y_t - a - dy_{t-1}) \\ &\xrightarrow{P} \delta(\tau)\end{aligned}$$

Supuesto fundamental: media condicional estacionaria.

Comentarios:

- Bajo las mismas condiciones se puede estimar $\text{QAR}(p)$.
- Heterocedasticidad autoregresiva: natural en QR.
- Dinámica asimétrica: usual en algunas series económicas (por ejemplo, senderos de precios).
- Forecast: predicción puntual *versus* una distribución para y_{t+1} .

Datos en panel

Modelo lineal:

$$y_{it} = x_{it}^T \beta + u_{it}$$

donde $i = 1, \dots, N$ y $t = 1, \dots, T$.

Estructura del término de error:

$$u_{it} = \alpha_i + \varepsilon_{it}$$

Posturas sobre la naturaleza de α_i :

- Efectos fijos (EF)
- Efectos Aleatorios (EA).

Supuestos estadísticos

En notación matricial:

$$Y = X\beta + D\alpha + \varepsilon$$

Supongamos que

- $\alpha \sim (0, \sigma_\alpha^2 I_N)$
- $\varepsilon \sim (0, \sigma_\varepsilon^2 I_{NT})$
- $\alpha \perp \varepsilon$

Luego,

$$\Omega = \sigma_\alpha^2 DD^\top + \sigma_\varepsilon^2 I_{NT}$$

es la matriz de varianzas y covarianzas $\Omega \equiv V(u)$

Estimación

Estimador de MCG (EA):

$$\begin{aligned}\hat{\beta}_{RE} &= (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} Y \\ &= (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{Y}\end{aligned}$$

donde $\tilde{X} = \Omega^{-1/2} X$ y $\tilde{Y} = \Omega^{-1/2} Y$.

Modelo transformado (Baltagi, 2005):

$$\underbrace{\tilde{y}_{it}}_{y_{it} - \theta \bar{y}_i} = \underbrace{\tilde{x}_{it}^T}_{(x_{it}^T - \theta \bar{x}_i^T)} \beta + \underbrace{\tilde{u}_{it}}_{u_{it} - \theta \bar{u}_i}$$

donde

$$\theta = 1 - \sigma_\varepsilon^2 / (\sigma_\varepsilon^2 + T \sigma_\alpha^2)$$

MCO, EF y EA

$$y_{it} - \theta \bar{y}_i = (x_{it}^T - \theta \bar{x}_i^T) \beta + u_{it} - \theta \bar{u}_i$$

donde

$$\theta = 1 - \sigma_\varepsilon^2 / (\sigma_\varepsilon^2 + T \sigma_\alpha^2)$$

Notar:

- Si $\theta \rightarrow 0$ entonces $\hat{\beta}_{EA} \rightarrow \hat{\beta}_{MCO}$
- Si $\theta \rightarrow 1$ entonces $\hat{\beta}_{EA} \rightarrow \hat{\beta}_{EF}$

MCG como problema de minimización

$$\hat{\beta}_{EA} = \underset{b}{\operatorname{argmin}} (Y - Xb)^T \Omega^{-1} (Y - Xb)$$

Esto es equivalente a [Koenker 2005, Proposition 8.1., pag. 277]:

$$\hat{\beta}_{EA} = \underset{(b,a)}{\operatorname{argmin}} \{ (Y - Xb - Za)^T V(\varepsilon)^{-1} (Y - Xb - Za) + a^T V(\alpha)^{-1} a \}$$

En notación observacional:

$$\begin{aligned} \hat{\beta}_{EA} &= \underset{(b,a)}{\operatorname{argmin}} \sum_i \sum_t (\sigma_\varepsilon^2)^{-1} (y_{it} - x_{it}^T b - a_i)^2 + \sum_i (\sigma_\alpha^2)^{-1} a_i^2 \\ &= \underset{(b,a)}{\operatorname{argmin}} \sum_i \sum_t (y_{it} - x_{it}^T b - a_i)^2 + \lambda \sum_i a_i^2 \end{aligned}$$

donde $\lambda = \sigma_\varepsilon^2 / \sigma_\alpha^2$.

QR para paneles

En forma análoga, Koenker (2004) propone:

$$(\hat{\alpha}(\tau), \hat{\beta}(\tau)) = \underset{(a,b)}{\operatorname{argmin}} \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau}(y_{it} - x_{it}^{\top} b - a_i) + \lambda \sum_{i=1}^N |a_i|$$

De la misma manera, el parámetro λ controla la penalización de a_i :

- $\lambda \rightarrow 0 \Rightarrow \text{QR EF}$
- $\lambda \rightarrow \infty \Rightarrow \text{QR Pool}$
- $0 < \lambda < \infty \Rightarrow \text{QR Penalized}$

Paneles cortos

- Estimar $\alpha_i(\tau)$ puede ser bastante impreciso si T no es grande.
- Koenker (2004): estimación conjunta de M cuantiles:

$$\min_{(a,b)} \sum_{m=1}^M \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau_m}[y_{it} - x_{it}^T b(\tau_m) - a_i] + \lambda \sum_{i=1}^N |a_i|$$

- Notar que es el caso con $\alpha_i(\tau) = \alpha_i$ (*pure location shift*).
- Nada en Stata, por ahora solo R.

¿Cómo elegir λ ?

Cada estimador de QR penalizado depende del valor elegido para λ :

$$\hat{\beta}(\tau_m, \lambda) \xrightarrow{P} \beta(\tau)$$

Bajo ciertas condiciones de regularidad:

$$\sqrt{TN}(\hat{\beta}(\tau, \lambda) - \beta(\tau)) \xrightarrow{d} N(0, \Sigma(\lambda))$$

Lamarche (2010): elegir aquel que minimiza a la varianza asintótica

$$\lambda^* = \underset{\lambda}{\operatorname{argmin}} \{ \operatorname{tr} \Sigma(\lambda) \}$$

Endogeneidad generada por α_i :

- $\hat{\beta}(\tau_m, \lambda) \xrightarrow{P} \beta(\tau)$ para $\lambda > 0$
- Luego, $\lambda = 0$ (EF QR) asegura la consistencia.

EF: el caso *location-shift*

Modelo lineal:

$$y_{it} = x_{it}^T \beta(\tau) + \alpha_i(\tau)$$

Supongamos $\alpha_i(\tau) = \alpha_i$ para todo τ .

$$\begin{aligned} y_{it} - \alpha_i &= x_{it}^T \beta(\tau) \\ z_{it} &= x_{it}^T \beta(\tau) \end{aligned}$$

Si observáramos a z_i :

$$\begin{aligned} \hat{\beta}(\tau) &= \underset{b}{\operatorname{argmin}} \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau}(z_{it} - x_{it}^T b) \\ &\xrightarrow{P} \beta(\tau) \end{aligned}$$

Si contamos con $\hat{\alpha}_i \xrightarrow{p} \alpha_i$, entonces:

$$\begin{aligned}\hat{z}_{it} &= y_{it} - \hat{\alpha}_i \\ &\xrightarrow{p} y_{it} - \alpha_i = z_{it}\end{aligned}$$

Canay (2011) propone un estimador en dos pasos:

- 1 Obtener a $\hat{\alpha}_i$ por EF regresando y_{it} en x_{it} .
- 2 Estimar a $\beta(\tau)$ por QR usando a $(y_{it} - \hat{\alpha}_i)$ como variable dependiente en función de x_{it} .

Este estimador en etapas es consistente y asintóticamente normal.

Paneles dinámicos

Consideren un modelo de panel pero con un componente dinámico:

$$y_{it} = \delta y_{it-1} + x_{it}^T \beta + \alpha_i + \varepsilon_{it}$$

Los estimadores estándar (MCO, EF y EA) son sesgados e inconsistentes.

- **Causa:** la propia dinámica del modelo genera un problema de endogeneidad.
- **Solución:** estimar con EF-VI utilizando a Δy_{it-2} o y_{it-2} como instrumento válido.
- **Clave:** los instrumentos salen de la propia estructura del modelo (Anderson and Hsiao, 1981; Arellano, 1989).

Paneles dinámicos

Esperanza condicional con efectos fijos:

$$E(y_{it}|y_{it-1}, x_{it}) = \delta y_{it-1} + x_{it}^T \beta + \alpha_i$$

La versión para el cuantil condicional es:

$$Q_{\tau}(y_{it}|y_{it-1}) = \delta(\tau)y_{it-1} + x_{it}^T \beta(\tau) + \alpha_i$$

Galvao (2011): estimar este modelo combinando dos métodos

- Minimización penalizada de Koenker (2004), con $\lambda = 0$ (EF).
- Estimador de VI-QR de Chernozhukov y Hansen (2005) usando y_{it-2} como instrumento válido.

Galvao (2011)

Propone solucionar

$$\min_{\delta} \|\hat{\gamma}(\delta)\|_A$$

sujeto a:

$$(\hat{\beta}(\delta), \hat{\alpha}_i(\delta), \hat{\gamma}(\delta)) = \underset{(\beta, \gamma)}{\operatorname{argmin}} \sum_{m=1}^M \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau_m}(y_{it} - \delta y_{it-1} - x_{it}^T \beta - \alpha_i - \gamma z_{it})$$

Notar:

- Estamos en el caso con único regresor endógeno.
- Instrumento: $z_{it} = y_{it-2}$.
- Algoritmo computacional: el grid es conocido! $\delta \in [-1, 1]$

Media condicional

Ecuaciones de regresión y selección:

$$\begin{aligned}y_{1i} &= x_{1i}^T \beta_1 + u_{1i} \\ s_i &= 1(x_{2i}^T \beta_2 + u_{2i} > 0)\end{aligned}$$

donde en lugar de y_{1i} se observa $s_i = 1$.

Supuestos principales:

- 1 $E(u_{1i}|u_{2i}) = \delta u_{2i}$
- 2 $u_{2i}|x_{2i} \sim N(0; \sigma_2^2)$

Resultado: sesgo potencial por el proceso de selección

$$E(y_{1i}|x_{1i}, s_i = 1) = x_{1i}^T \beta_1 + \gamma \lambda(x_{2i}^T \beta_2 / \sigma_2)$$

donde $\lambda(\cdot) = \phi(\cdot)/\Phi(\cdot)$ es la inversa del ratio de Mills.

Heckman (1979)

Propone un estimador consistente dos etapas:

- **Etapla 1:** obtener un $\hat{\beta}_2^*$ usando un Probit usando la muestra completa y estimar a $\hat{\lambda}_i = \lambda(x'_{2i}\hat{\beta}_2^*)$.
- **Etapla 2:** estimar a β_1 con una regresión de MCO para $i : s_i = 1$ del modelo:

$$E(y_{1i}|x_{1i}, s_i = 1) = x_{1i}^T \beta_1 + \gamma^* \hat{\lambda}_i$$

Noten que:

- **Supuesto (1):** problema potencial de endogeneidad sobre MCO.
- **Supuesto (2):** impone cierta estructura distributiva.

Buchinsky (1998)

Propone un procedimiento similar al de Heckman (1979) para estimar un modelo de cuantiles:

- Etapla 1: estimar un modelo de probabilidad de selección no paramétrico y computar $\hat{g}_i = \hat{P}(s_i = 1|x_{2i})$.
- Etapla 2: estimar a $\beta_1(\tau)$ por QR para $i : s_i = 1$ del modelo:

$$Q_\tau(y_{1i}|x_{1i}, s_i = 1) = x_{1i}^\top \beta_1(\tau) + \sum_{s=1}^S \theta_s(\tau) h(\hat{g}_i)^s$$

con varias alternativas en la elección de S y $h(\cdot)$.

A favor: es relativamente fácil de implementar.

Aditividad y cuantiles

Buchinsky es consistente si el modelo es aditivo, es decir si:

$$Q_{\tau}(y_{1i}|x_{1i}, s_i) = x_{1i}^T \beta_1 + m(\tau, x_2)$$

donde $m(\tau, x_2)$ es alguna función.

La aditividad es natural en la media condicional, ya que:

$$E(W_1 + W_2) = E(W_1) + E(W_2)$$

Sin embargo:

$$Q_{\tau}(W_1 + W_2) \stackrel{(?)}{=} Q_{\tau}(W_1) + Q_{\tau}(W_2)$$

Por lo tanto, la aditividad es un supuesto bastante restrictivo en el contexto de cuantiles.

Arellano y Bonhomme (2017)

Siguen con la estructura bivariada del modelo:

$$\begin{aligned}y_{1i} &= x'_{1i}\beta_1(U_1) \\ s_i &= 1[U_2 \leq p(x_{2i})]\end{aligned}$$

donde $(U_1, U_2) \in (0, 1)^2$ son dos variables aleatorias [inobservables] con distribución conjunta $F_{12}(u_1, u_2|x)$, con $x = (x_1, x_2)$.

Notar:

- $p(x_{2i}) = P(s_i = 1|x_{2i})$
- *Inobservables*: no necesariamente son independientes.
- Modelo de correlación de rankings (*copula*):

$$F_{12}(\tau, p|x) = C(\tau, p, \rho)$$

donde $p = p(x_2)$ y ρ es un parámetro de correlación.

Arellano y Bonhomme (2017)

Notar que:

$$\begin{aligned} P(y_{1i} < x'_{1i}\beta_1(\tau)|s_i = 1, x) &= \tau^* \\ &\neq \tau \end{aligned}$$

Con los supuestos que hicimos:

$$\begin{aligned} P(y_{1i} < x'_{1i}\beta_1(\tau)|s_i = 1, x) &= P(U_1 < \tau | U_2 \leq p(x_{2i}), x) \\ &= F_{12}(\tau, p|x) \\ &= C(\tau, p, \rho) \end{aligned}$$

Si conociéramos a ρ tenemos una correspondencia entre τ^* y τ dada por $\tau^* = C(\tau, p, \rho)$.

Arellano y Bonhomme (2017)

- Es la misma idea que Buchinsky y Han (1998) para datos censurados! (reponderar la distribución truncada).
- **Problema:** no conocemos a ρ ni a $p = p(x_2)$.
- Para estimar a $p(x_2)$ solo necesitamos (s_i, x_{2i}) para $i = 1, \dots, n$ y utilizar algún modelo de elección binaria (Probit, Logit, ...)
- Por otro lado, para estimar a ρ se usa la igualdad

$$P(y_{1i} < x'_{1i}\beta_1(\tau) | s_i = 1, x) = C(\tau, p, \rho)$$

que da origen a una condición de momento, similar a la que vimos con IV-QR de Chernozhukov y Hansen (2005).

Error en la especificación

En general,

$$E(y|x) = m(x)$$

donde $m(x)$ es alguna función desconocida.

Sea β la solución del problema de minimización:

$$\beta \equiv \underset{b}{\operatorname{argmin}} E \left[(y - x'b)^2 \right]$$

Resultado: $x'\beta$ es la mejor aproximación lineal a $m(x)$, es decir:

$$\beta \equiv \underset{b}{\operatorname{argmin}} E \left[(m(x) - x'b)^2 \right]$$

Verbalización: "MCO es la mejor aproximación lineal a $E(y|x)$ "

¿QR como mejor aproximación lineal?

Consideremos al cuantil condicional τ -ésimo

$$Q_{\tau}(y|x) = m_{\tau}(x)$$

donde $m_{\tau}(x)$ es alguna función desconocida.

Sea ahora $\beta(\tau)$ la solución de:

$$\beta(\tau) \equiv \underset{b}{\operatorname{argmin}} E[\rho_{\tau}(y - x'b)]$$

De la misma manera:

- QR es la mejor aproximación lineal bajo una penalización asimétrica.
- No es una forma muy usual de evaluar la especificación de un modelo.

QR como mejor aproximación lineal

Angrist et al. (2006) muestran que:

$$\beta(\tau) \equiv \underset{b}{\operatorname{argmin}} E \left[\omega_{\tau}(x, b) (m_{\tau}(x) - x' b)^2 \right]$$

para todo $\tau \in (0, 1)$.

Comentarios:

- Función de pérdida es simétrica.
- $\omega_{\tau}(x, b) \geq 0$ es un ponderador que depende de $f_{y|x}(\cdot)$
- "QR es la mejor aproximación lineal a $m_{\tau}(x)$ "

Omisión de una variable

Supongamos que

$$m_{\tau}(x) = x_1' \beta_1(\tau) + x_2' \beta_2(\tau)$$

Pero que omitimos la variable x_2 en el modelo. Del resultado anterior:

$$\gamma_1(\tau) = E[\omega_{\tau} x_1 x_1']^{-1} E[\omega_{\tau} x_1 m_{\tau}(x)]$$

Luego,

$$\gamma_1(\tau) = \beta_1(\tau) + \underbrace{E[\omega_{\tau} x_1 x_1']^{-1} E[\omega_{\tau} x_1 x_2'] \beta_2(\tau)}_{\text{Sesgo de QR por omitir a } x_2}$$

(el caso $\beta_2(\tau) = 0$ es trivial...)

¿Eso es todo?

- **Regresión no-lineal:** Koenker y D'Orey (1994); Lee (2003).
- **Variables censuradas y datos en panel:** Lamarche (2013).
- **Raíces unitarias:** Galvao (2009).
- **Count data:** Machado y Santos Silva (2005); Harding y Lamarche (2015).
- **Modelos multivariados:** Hallin et al. (2010); Garlier et. al (2016); Montes-Rojas (2017).

Referencias

- Koenker, R. (2017). "Quantile regression 40 years on". Annual Review of Economics, Vol. 9:155-176.
- Roger Koenker, "Quantile Regression". Cambridge University Press (2005). Cap. 8 (8.3, 8.4, 8.7).
- Flores, C., Flores-Lagunes, A. y Kapetanakis, D. (2009). "Lessons from Quantile Panel Estimation of the Environmental Kuznets Curve". Econometric Reviews 33(8).
- Zheng, M., Feng, G., Feng, S. and Yuan X. (2019) "The road to innovation vs. the role of globalization: A dynamic quantile investigation". Economic Modelling. Volume 83, Pages 65-83.