

Unconditional Quantile Regression

Javier Alejo

Tópicos de Econometría

Universidad Nacional de La Plata

Noviembre, 2020

Temario de la clase

- Introducción
- Función de Influencia Centrada
- Regresiones RIF
- Aplicación Empírica



Modelo lineal

Consideremos el modelo lineal

$$Y = X\beta + u$$

Supongamos que $E(u|x) = 0$ (exogeneidad).

- En promedio Y y X tienen una relación lineal.
- Interpretación de β

$$\frac{\partial E(Y|X)}{\partial X} = \beta$$

El impacto de X sobre $E(Y)$

Calculemos la esperanza de Y :

$$\begin{aligned} E(Y) &= E\{E(Y|X)\} \\ &= E\{E(X\beta + u|X)\} \\ &= E\{X\beta + E(u|X)\} \\ &= E(X)\beta \end{aligned}$$

Supongamos un cambio en $E(X)$ dado por $\partial E(X)$, luego

$$\frac{\partial E(Y)}{\partial E(X)} = \beta$$

El impacto de X sobre $Q_\tau(Y)$

Consideremos nuevamente el modelo lineal

$$Y = X\beta + u$$

Calculemos el cuantil τ -ésimo de Y :

$$\begin{aligned} Q_\tau(Y) &= Q_\tau(X\beta + u) \\ &= ? \end{aligned}$$

Problema: no es obvio como seguir...

¿Cuantíl condicional?

Podríamos pensar que el cuantíl condicional es lineal:

$$Q_{\tau}(Y|X) = X\beta(\tau)$$

¿Cómo obtenemos a $Q_{\tau}(Y)$ a partir de $Q_{\tau}(Y|X)$?

- No existe una “Ley de Cuantiles Iterados”.

$$Q_{\tau}(Y) \neq Q_{\tau}[Q_{\tau}(Y|X)]$$

- Tomar un promedio tampoco ayuda:

$$E[Q_{\tau}(Y|X)] = E(X)\beta(\tau) \neq Q_{\tau}(Y)$$

Condicional e Incondicional

Estrictamente:

$$\begin{aligned} F_Y(y) &= \int F_{Y,X}(y,x)dx \\ &= \int F_{Y|X=x}(y)f_X(x)dx \end{aligned}$$

con $F_{Y|X=x}(y) = F_{Y,X}(y,x)/f_X(x)$.

- No fácil pasar de $Q_\tau(Y|X)$ a $Q_\tau(Y)$.
- Métodos numéricos: Machado y Mata (2004) y Melly (2006).
- El eje de la cuestión: contar con algo similar a la Ley de Esperanzas Iteradas (LEI).

Parámetro de interés

En términos generales:

$$Y = h(X, \varepsilon)$$

Notar que esto junto con $F(X, \varepsilon)$ definen a $F_Y(y)$.

Definición: vamos a considerar el efecto de una traslación horizontal en X (*location shift*)

$$\alpha(\tau) \equiv \lim_{t \rightarrow 0} \frac{Q_\tau[h(X+t, \varepsilon)] - Q_\tau[Y]}{t}$$

- Cambio: $f_X(\cdot)$ se mueve hacia $f_{X+t}(\cdot)$.
- Esto es lo que se conoce como una derivada funcional.

Terminología

- X contiene varios regresores, $\alpha(\tau)$ son derivadas parciales.
- A $\alpha(\tau)$ se lo ha denominado como *Unconditional Quantile Partial Effect* (UQPE).
- Luego, si recordamos que suponíamos

$$Q_{\tau}(Y|X) = X\beta(\tau)$$

- Entonces el parámetro $\beta(\tau)$ es el *Conditional Quantile Partial Effect* (CQPE).

Función de Influencia

- Supongamos un indicador $T(F)$ construido a partir de la distribución F .
- Formalmente: $T : \mathcal{F} \rightarrow \mathbb{R}$, donde $\mathcal{F}$ es el conjunto de funciones F tal que $|T(F)| < \infty$.
- La función de influencia se define como:

$$IF(y, T) = \lim_{\eta \rightarrow 0} \frac{T[(1-\eta)F + \eta\delta_y] - T(F)}{\eta}$$

- La expresión δ_y es una distribución degenerada en y , un punto particular del soporte de F .

Función de Influencia

La $IF(y, T)$ tiene una forma funcional específica para cada indicador:

Indicador	$T(F)$	$IF(y, T)$
Media (μ)	$\int_{-\infty}^{+\infty} y dF(y)$	$y - \mu$
Varianza (σ^2)	$\int_{-\infty}^{+\infty} (y - \mu)^2 dF(y)$	$(y - \mu)^2 - \sigma^2$
Cuantil τ (q_τ)	$\int_{-\infty}^{q_\tau} dF(y) = \tau$	$IF(y,) = \frac{\tau - I(y < q_\tau)}{f(q_\tau)}$

- La $IF(y, T)$ proviene de la estadística robusta.
- Miden la sensibilidad del indicador T en el punto y .

Algunas propiedades de la IF

- 1 Depende de parámetros poblacionales.
- 2 El valor esperado de $IF(.)$ es cero, es decir:

$$E[IF(Y, T)] = 0$$

Ejemplo 1: si $T(F) = \mu$, esta propiedad es obvia

$$\begin{aligned} E[IF(Y, \mu)] &= E[Y - \mu] \\ &= 0 \end{aligned}$$

Ejemplo 2: en el caso del cuantil τ -ésimo

$$\begin{aligned} E[IF(Y, q_\tau)] &= E\left[\frac{\tau - I(Y < q_\tau)}{f(q_\tau)}\right] \\ &= [\tau - Pr(Y < q_\tau)] / f(q_\tau) \\ &= 0 \end{aligned}$$

Ejercicio: corroborar que $E[IF(Y, \sigma^2)] = 0$

Función de Influencia Centrada (RIF)

Definamos a la siguiente función:

$$RIF(y, T) \equiv T(F) + IF(y, T)$$

Esto es lo que se conoce como *Recentered Influence Function* (RIF).

Propiedades de la RIF

- 1 Depende de parámetros poblacionales.
- 2 Trivialmente:

$$E[RIF(Y, T)] = T(F)$$

- 3 Por LEI:

$$T(F) = E\{E[RIF(Y, T)|X]\}$$

RIF regression

Todo el razonamiento que hemos hecho es el eje central de la idea propuesta por **Firpo, Fortin y Lemieux (2009)**.

Resultado (FFL 2009)

Los autores muestran que el efecto marginal de X sobre T es:

$$\alpha(T) \equiv \lim_{t \rightarrow 0} \frac{T[h(X+t, u)] - T[Y]}{t} = E \left\{ \frac{dE[RIF(Y, T)|X=x]}{dx} \right\}$$

El método:

- 1 Proponer un modelo para la RIF condicional en X .

$$E[RIF(Y, T)|X] = m(X, \beta)$$

- 2 Estimar ese modelo por algún método de regresión conocido.

Ejemplo: modelo lineal y μ

Vimos que si $IF(Y, \mu) = Y - \mu$, entonces:

$$\begin{aligned} RIF(Y, \mu) &= \mu + IF(Y, \mu) \\ &= \mu + Y - \mu \\ &= Y \end{aligned}$$

Siguiendo la metodología de FFL (2009) supongamos un modelo lineal $E[RIF(Y, T)|X]$:

$$\begin{aligned} E[RIF(Y, T)|X] &= X\beta \\ E[Y|X] &= \end{aligned}$$

Luego, estimaríamos β por MCO.

Unconditional Quantile Regression

En el caso del cuantil no condicional es:

$$\begin{aligned}
 RIF(Y, q_\tau) &= q_\tau + IF(Y, q_\tau) \\
 &= q_\tau + \frac{\tau - I(y < q_\tau)}{f(q_\tau)} \\
 &= q_\tau + \frac{\tau - 1}{f(q_\tau)} + \frac{I(y \geq q_\tau)}{f(q_\tau)} \\
 &= c_{2,\tau} + c_{1,\tau} I(y \geq q_\tau)
 \end{aligned}$$

donde las constantes $c_{1,\tau}$ y $c_{2,\tau}$ son:

$$\begin{aligned}
 c_{1,\tau} &= 1/f(q_\tau) \\
 c_{2,\tau} &= q_\tau - c_{1,\tau}(1 - \tau)
 \end{aligned}$$

En esencia es un modelo binario!

Tomando esperanza condicional en X :

$$E[RIF(Y, q_\tau)|X] = c_{2,\tau} + c_{1,\tau}Pr(y \geq q_\tau|X)$$

Luego, la expresión para el *Unconditional Quantile Partial Effect* (UQPE) es:

$$\alpha(\tau) = \frac{1}{f(q_\tau)} \cdot E \left[\frac{\partial Pr(y \geq q_\tau|X)}{\partial X} \right]$$

Componentes del UQPE:

- 1 q_τ : cuantil τ -ésimo.
- 2 $f(q_\tau)$: densidad de Y evaluada en q_τ .
- 3 $E \left[\frac{\partial Pr(Y \geq q_\tau|X)}{\partial X} \right]$: efecto marginal promedio.

Estimador factible

Notar que $Pr(Y \geq q_\tau | X)$ es un modelo de regresión binario, donde la variable dependiente es:

$$D_i = \begin{cases} 0 & \text{si } Y_i < \hat{q}_\tau \\ 1 & \text{si } Y_i \geq \hat{q}_\tau \end{cases}$$

Varias alternativas:

- (a) **Modelo lineal:** $Pr(D_i = 1 | X = x_i) = x_i^\top \gamma$
- (b) **Logit/Probit:** $Pr(D_i = 1 | X = x_i) = G(x_i^\top \gamma)$
- (c) **No paramétrico:** $Pr(D_i = 1 | X = x_i) = m(x_i)$

Errores estándar: bootstrap!

(a) RIF - OLS Regression

Modelo lineal estimado por MCO

$$Pr(D_i = 1|X = x_i) = x_i^T \gamma$$

Efectos parciales sobre la probabilidad:

$$\frac{\partial \widehat{Pr}(Y_i \geq \hat{q}_\tau | X = x_i)}{\partial X} = \hat{\gamma}$$

Luego, el UQPE estimado es:

$$\hat{\alpha}(\tau) = \frac{1}{\hat{f}(\hat{q}_\tau)} \cdot \hat{\gamma}$$

Ventajas:


- Es simple de estimar y computar los efectos parciales.
- Usar un Logit/Probit o no paramétrico da resultados similares.

Educación y desigualdad salarial


- **Muestra:** hombres de 18 a 64 años de edad extraídos de la EPH 1992, 1998 y 2008.
- **Variable dependiente:** salario por hora (en log)
- **Variable explicativa:** años de educación, edad, controles regionales,...
- **Literatura:** retornos a la educación, economía de la distribución.
- **Referencia:** Sosa Escudero et al. (2014).

RIF Regression


Año	q(0.10)	q(0.20)	q(0.30)	q(0.40)	q(0.50)	q(0.60)	q(0.70)	q(0.80)	q(0.90)
1992	0.046 (13.23)**	0.047 (17.39)**	0.054 (20.81)**	0.065 (23.46)**	0.075 (24.44)**	0.087 (25.81)**	0.107 (27.15)**	0.119 (23.58)**	0.140 (15.89)**
1998	0.066 (14.50)**	0.059 (19.87)**	0.070 (24.91)**	0.079 (29.23)**	0.090 (31.53)**	0.104 (33.87)**	0.124 (35.15)**	0.148 (30.45)**	0.190 (20.08)**
2008	0.063 (13.46)**	0.071 (21.14)**	0.072 (26.65)**	0.076 (31.17)**	0.077 (33.46)**	0.082 (33.71)**	0.087 (31.84)**	0.097 (26.63)**	0.110 (19.25)**



EPH 1992



EPH 1998



EPH 2008

(a) *Años de educación*

Relación entre CQPE y UQPE

FFL (2009) muestran la siguiente relación:


$$UQPE(\tau) = E[\omega_\tau(X) \cdot CQPE(\xi_\tau(X), X)]$$

donde el ponderador es:

$$\omega_\tau(x) = \frac{f_{Y|X=x}(q_\tau)}{f_Y(q_\tau)}$$

$\xi_\tau(x)$ es una función de matching entre cuantiles condicionales y no condicionales:

$$\xi_\tau(x) \equiv \{s : Q_s[Y|X=x] = q_\tau\}$$



Resumen

- El método de Quantile Regression es útil para caracterizar al cuantil de Y condicional en X .
- Extrapolar conclusiones de QR a los cuantiles no condicionales no es tan obvio como en el caso de la media condicional.
- El método de regresiones RIF ofrece una alternativa para poder aprovechar la LEI.
- En el caso UQR, el método se simplifica a la estimación de un regresor binario.
- Para otros indicadores se requiere conocer la *RIF*.

Referencias

- Firpo, S. Fortin, N. y Lemieux, T. (2009) "Unconditional Quantile Regressions". *Econometrica*, Vol. 77, No. 3, pp. 953-973.
- Sosa Escudero, W, Alejo, J. y Gabrielli, F. (2014) "The distributive effects of education: an unconditional quantile regression approach". *Economic Analysis Review*, Vol 29, No 1.
- Bonacini, L. Gallo, G. y Scicchitano, S. (2020) "Working from home and income inequality: risks of a 'new normal' with COVID-19". *Journal of Population Economics*, volume 34, pages303–360.