

Regresión por Cuantiles: cuestiones operativas del curso

Javier Alejo

Maestría en Economía

FCE - UNLP

Octubre, 2020

- **Teoría:** video grabado (se sube durante el fin de semana).
- **Reunión de consultas:**
 - Lunes 17 hs por Zoom.
 - Idealmente sobre el tema subido, pero obviamente pueden ser sobre clases anteriores.
- **Material:**
 - Slides/Videos: usar como guía de una lectura selectiva.
 - Bibliografía: se indicará al final de cada clase.
- **Interacción:**
 - Grupo de FB “**Regresión por Cuantiles 2020 (FCE-UNLP)**”
 - Mail: javieralejo@gmail.com

- **Teoría:** video grabado (se sube durante el fin de semana).
- **Reunión de consultas:**
 - Lunes 17 hs por Zoom.
 - Idealmente sobre el tema subido, pero obviamente pueden ser sobre clases anteriores.
- **Material:**
 - Slides/Videos: usar como guía de una lectura selectiva.
 - Bibliografía: se indicará al final de cada clase.
- **Interacción:**
 - Grupo de FB “Regresión por Cuantiles 2020 (FCE-UNLP)”
 - Mail: javieralejo@gmail.com

- **Teoría:** video grabado (se sube durante el fin de semana).
- **Reunión de consultas:**
 - Lunes 17 hs por Zoom.
 - Idealmente sobre el tema subido, pero obviamente pueden ser sobre clases anteriores.
- **Material:**
 - Slides/Videos: usar como guía de una lectura selectiva.
 - Bibliografía: se indicará al final de cada clase.
- **Interacción:**
 - Grupo de FB “Regresión por Cuantiles 2020 (FCE-UNLP)”
 - Mail: javieralejo@gmail.com

- **Teoría:** video grabado (se sube durante el fin de semana).
- **Reunión de consultas:**
 - Lunes 17 hs por Zoom.
 - Idealmente sobre el tema subido, pero obviamente pueden ser sobre clases anteriores.
- **Material:**
 - Slides/Videos: usar como guía de una lectura selectiva.
 - Bibliografía: se indicará al final de cada clase.
- **Interacción:**
 - Grupo de FB “**Regresión por Cuantiles 2020 (FCE-UNLP)**”
 - Mail: javieralejo@gmail.com

Distribución condicional.

- **Regresión por cuantiles (QR).**
 - Introducción.
 - Taller teórico-práctico.
- Tópicos de QR:
 - Variables parcialmente continuas.
 - Datos en panel.
 - Variables instrumentales.
 - Modelos dinámicos.
 - Sesgo por selección.

Distribución incondicional

- Regresiones RIF.
- Descomposiciones econométricas.
- Tratamiento continuo.

Distribución condicional.

- **Regresión por cuantiles (QR).**
 - Introducción.
 - Taller teórico-práctico.
- **Tópicos de QR:**
 - Variables parcialmente continuas.
 - Datos en panel.
 - Variables instrumentales.
 - Modelos dinámicos.
 - Sesgo por selección.

Distribución incondicional

- Regresiones RIF.
- Descomposiciones econométricas.
- Tratamiento continuo.

Distribución condicional.

- **Regresión por cuantiles (QR).**
 - Introducción.
 - Taller teórico-práctico.
- **Tópicos de QR:**
 - Variables parcialmente continuas.
 - Datos en panel.
 - Variables instrumentales.
 - Modelos dinámicos.
 - Sesgo por selección.

Distribución incondicional

- Regresiones RIF.
- Descomposiciones econométricas.
- Tratamiento continuo.

Distribución condicional.

- **Regresión por cuantiles (QR).**
 - Introducción.
 - Taller teórico-práctico.
- **Tópicos de QR:**
 - Variables parcialmente continuas.
 - Datos en panel.
 - Variables instrumentales.
 - Modelos dinámicos.
 - Sesgo por selección.

Distribución incondicional

- **Regresiones RIF.**
- Descomposiciones econométricas.
- Tratamiento continuo.

Distribución condicional.

- **Regresión por cuantiles (QR).**
 - Introducción.
 - Taller teórico-práctico.
- **Tópicos de QR:**
 - Variables parcialmente continuas.
 - Datos en panel.
 - Variables instrumentales.
 - Modelos dinámicos.
 - Sesgo por selección.

Distribución incondicional

- **Regresiones RIF.**
- **Descomposiciones econométricas.**
- Tratamiento continuo.

Distribución condicional.

- **Regresión por cuantiles (QR).**
 - Introducción.
 - Taller teórico-práctico.
- **Tópicos de QR:**
 - Variables parcialmente continuas.
 - Datos en panel.
 - Variables instrumentales.
 - Modelos dinámicos.
 - Sesgo por selección.

Distribución incondicional

- **Regresiones RIF.**
- **Descomposiciones econométricas.**
- **Tratamiento continuo.**

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- **TP:** 20 % de la nota final
- **Examen:** 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- **TP:** 20 % de la nota final
- **Examen:** 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- TP: 20 % de la nota final
- Examen: 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- TP: 20 % de la nota final
- Examen: 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- **TP:** 20 % de la nota final
- **Examen:** 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- **TP:** 20 % de la nota final
- **Examen:** 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

Dos instancias, ambas obligatorias.

- **Grupal:** trabajo práctico con plazo de entrega, fecha a definir.
- **Individual:** examen domiciliario con plazo de entrega, fecha a definir.

Ponderaciones:

- **TP:** 20 % de la nota final
- **Examen:** 80 % de la nota final

Sobre los grupos: compuesto por 3 o 4 miembros.

¿Consultas y/o dudas?

Regresión por cuantiles

Javier Alejo

Microeconometría

FCE-UNLP

Octubre, 2020

Temario de la clase

1 Introducción.

- Objeto interés
- Ejemplos
- Estimadores

2 Regresión por cuantiles.

- Modelos de regresión
- Interpretación

3 Propiedades estadísticas.

- Inferencia (asintótica)
- Robustez



Medidas de posición

Variable aleatoria univariada: función de distribución

$$F_Y(y) = \Pr(Y \leq y)$$



Media o esperanza:

$$E(Y) = \int_{-\infty}^{+\infty} y dF_Y(y)$$

Cuantil τ - ésimo de Y

$$\int_{-\infty}^{Q_{\tau}(Y)} dF_Y(y) = F_Y[Q_{\tau}(Y)] = \tau$$

donde τ está en el intervalo $[0, 1]$.



Un ejemplo paramétrico

Supongamos que $Y \sim N(\mu, \sigma^2)$. En este caso, sabemos que

$$E(Y) = \mu$$

Por otro lado, para el cuantil τ - ésimo de Y debemos resolver

$$P[Y < Q_\tau(Y)] = \tau$$

Sabemos que:

$$P[Y < Q_\tau(Y)] = \Phi\left(\frac{Q_\tau(Y) - \mu}{\sigma}\right)$$

Luego,

$$Q_\tau(Y) = \mu + \sigma\Phi^{-1}(\tau)$$

donde $\Phi^{-1}(\tau)$ es la inversa de la función de probabilidad acumulada para una $N(0,1)$.

Distribución condicional

Si Y es una VA continua, la distribución de Y dado $X = x$

$$F_{Y|X=x}(y) = \Pr(Y \leq y | X = x)$$


Esperanza condicional:

$$E(Y|X = x) = \int_{-\infty}^{+\infty} y dF_{Y|X=x}(y)$$

Cuantil condicional:

$$\int_{-\infty}^{Q_{\tau}(Y|X=x)} dF_{Y|X=x}(y) = F_{Y|X=x}[Q_{\tau}(Y|X=x)] = \tau$$

Importante: no confundir distribución de $Y|X$ con la de Y .



Otro ejemplo paramétrico

- Supongamos ahora que $Y|X = x \sim N[\mu(x), \sigma^2]$.
- Notar que ahora $E(Y|X = x) = \mu(x)$
- Cuantil τ - ésimo de Y condicional en $X = x$:

$$P[Y < Q_\tau(Y|X = x)|X = x] = \tau$$

- Al condicionar en $X = x$, $\mu(x)$ es constante, luego:

$$P[Y < Q_\tau(Y|X = x)|X = x] = \Phi\left(\frac{Q_\tau(Y|X = x) - \mu(x)}{\sigma}\right)$$

- La solución explícita es:


$$Q_\tau(Y|X = x) = \mu(x) + \sigma\Phi^{-1}(\tau)$$

Ejemplo: rendimiento educativo


- **Muestra:** 2013 estudiantes para Contador Público (UBA, 1994).
- **Variable dependiente:** cantidad de materias aprobadas desde el ingreso (en log)
- **Variable explicativa:** horas diarias dedicadas a estudiar
- **Referencia:** Sosa Escudero et al. (2009)

Grupos según horas de estudio	Cantidad de datos	Cantidad de materias (log)					
		Media	q(10)	q(25)	q(50)	q(75)	q(95)
1	82	2.34	1.61	1.79	2.48	2.77	3.04
2	231	2.07	1.39	1.61	2.08	2.56	3.00
3	576	2.30	1.39	2.08	2.48	2.71	3.00
4	457	2.49	1.95	2.30	2.64	2.83	3.04
5	426	2.52	1.95	2.40	2.64	2.83	3.00
6	158	2.57	1.79	2.48	2.71	2.83	3.04
7	40	2.73	2.56	2.71	2.77	2.89	3.09
8	32	2.58	2.20	2.48	2.64	2.83	3.09
9	11	2.73	2.30	2.77	2.83	2.89	2.89
Todos	2013	2.39	1.61	2.20	2.56	2.77	3.04


Promedio condicional




Modelo lineal para la media condicional



¿Y el resto de la distribución condicional?



Modelo lineal para cada cuantil condicional



Media

Es fácil mostrar analíticamente a $E(Y)$ cómo la solución de este problema de optimización:

$$\min_a E[(Y - a)^2]$$

CPO: $E(Y) - a = 0$

Con una muestra $Y_1, \dots, Y_n$, el análogo muestral este problema es

$$\min_a \frac{1}{n} \sum_{i=1}^n (Y_i - a)^2$$

Solución: $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$

Cuantil τ - ésimo

También es posible mostrar que $Q_\tau(Y)$ es la solución del siguiente problema de minimización:

$$\min_a E[\rho_\tau(Y - a)]$$


donde

$$\rho_\tau(u) = \begin{cases} -u(1 - \tau) & \text{si } u < 0 \\ u\tau & \text{si } u \geq 0 \end{cases}$$

Notar que $u \equiv Y - a$ (residuo) y que $\rho_\tau(u) \geq 0$.

CPO: $F(a) - \tau = 0$

Función de penalización



MCO y el modelo lineal

En el caso de la media muestral, el problema de optimización era:

$$\min_{a \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n (y_i - a)^2$$

Supongamos ahora que $a(x) = x' b$ con x (vector de $K \times 1$ de regresores), entonces:

$$\min_{b \in \mathbb{R}^K} \frac{1}{n} \sum_{i=1}^n (y_i - x_i' b)^2$$

- **Resultado:** regresión por MCO.
- **Supuesto:** linealidad en parámetros.
- Estima los K parámetros de la media condicional

Quantile Regression (Koenker y Bassett, 1978)

El cuantil muestral es la solución del problema:

$$\min_{a \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - a)$$

donde $\rho_{\tau}(u) = u[\tau - I(u < 0)]$.

Si ahora suponemos que el cuantil condicional $a(x) = x'b$:

$$\min_{b \in \mathbb{R}^K} \frac{1}{n} \sum_{i=1}^n \rho_{\tau}(y_i - x_i'b)$$

- En este problema τ está dado.
- Se trata de encontrar K parámetros del cuantil condicional τ .
- Se puede resolver mediante programación lineal.
- No hay solución explícita.

Esperanza condicional

Supongamos el siguiente modelo lineal para la media condicional:

$$E(Y|X) = \beta_0 + \beta_1 X_1 + \dots + \beta_K X_K$$

Si X_j es continua, entonces:

$$\frac{\partial E(Y|X)}{\partial X_j} = \beta_j$$

β_j es el efecto parcial de X_j sobre el promedio de Y dado X .

Cuantil condicional

Análogamente para el cuantil condicional:

$$Q_{\tau}(Y|X) = \beta_0(\tau) + \beta_1(\tau)X_1 + \dots + \beta_K(\tau)X_K$$

Si X_j es continua, entonces:

$$\frac{\partial Q_{\tau}(Y|X)}{\partial X_j} = \beta_j(\tau)$$

$\beta_j(\tau)$ es el efecto parcial de X_j sobre el cuantil τ -ésimo de la distribución de Y dado X

Importante:

- El vector $\beta(\tau)$ es una función de τ .
- La forma depende del ajuste a los datos (*distribution-free*).



Quantile Treatment Effect

- Consideremos una variable de resultado Y con una función de distribución F .
- Un variable que indica un tratamiento bajo RCT: $T = \{0,1\}$
- Denotemos al efecto del tratamiento como $\Delta(Y)$.
- Si el tratamiento cambia la distribución de F (control) a G (tratados), definimos:

$$F(y) = G[y + \Delta(y)]$$

- El caso más simple: $\Delta(y) = \Delta_0 \forall y$ (*location shift*).

Dos ejemplos



Llamando $\Delta(Y) = \Delta(F^{-1}(\tau)) \equiv \delta(\tau)$ es fácil ver que:

$$\delta(\tau) = G^{-1}(\tau) - F^{-1}(\tau)$$

Modelo de regresión

- $\delta(\tau)$ se conoce como *Quantile Treatment Effect* (QTE).
- *Average Treatment Effect* (ATE):

$$ATE = \int_0^1 \delta(\tau) d\tau$$

Es fácil escribir al QTE dentro de un cuantil de Y condicional en T :

$$\begin{aligned} Q_{\tau}(Y|T) &= F^{-1}(\tau) + [G^{-1}(\tau) - F^{-1}(\tau)] T \\ &= \alpha(\tau) + \delta(\tau) T \end{aligned}$$

QTE condicional $X = x$ (controles adicionales):

$$Q_{\tau}(Y|T, x) = \alpha(\tau) + \delta(\tau) T + x' \beta(\tau)$$

Ambos modelos son estimables por Quantile Regression (QR).

Inferencia asintótica

Sea $\beta_0(\tau)$ el parámetro que satisface:

$$P[Y \leq x' \beta_0(\tau) | X = x] = \tau$$

y bajo ciertas condiciones de regularidad (Koenker, 2005) el estimador QR cumple con las siguientes propiedades:

- **Consistencia:**

$$\hat{\beta}(\tau) \xrightarrow{P} \beta_0(\tau)$$

- **Normalidad Asintótica:**

$$\sqrt{n}[\hat{\beta}(\tau) - \beta_0(\tau)] \xrightarrow{d} N(0, \Omega_\tau)$$

donde:

$$\Omega_\tau = \tau(1 - \tau)D_1^{-1}(\tau)D_0D_1^{-1}(\tau)$$

Varianza asintótica


Es una matriz de $k \times k$ tiene la siguiente forma:

$$\Omega = \tau(1 - \tau)E[x_i x_i' f_i(Q_\tau)]^{-1} E(x_i x_i') E[x_i x_i' f_i(Q_\tau)]^{-1}$$

Algunas alternativas para estimarla:


- **Hendricks-Koenker:** aproximación numérica de $f_i(\cdot)$ (sparsity function)
- **Powell (1990):** estimador de Kernels para $f_i(\cdot)$
- **Bootstrap:** es la más usada.

QR es robusto a outliers





Robustez

- En comparación con MCO, los $\hat{\beta}(\tau)$ de QR son menos sensibles a la presencia de outliers.
- Es la característica de los denominados estadísticos *robustos*.




QR $\neq$ MCO por cuantiles de X




QR $\neq$ MCO por cuantiles de Y



MCO por Quintiles de Y



Quintiles Condicionales



QR $\neq$ Intervalo de confianza de MCO



Resumen

- MCO estiman funciones que reflejan a la media Y condicional en X .
- QR incorpora el mismo análisis funcional, para el resto de la distribución de Y condicional X .
- El método es *distribution-free*.
- No es un sustituto de MCO, más bien son complementos.
- ¿Qué aspecto de la relación entre Y y X nos interesa?

Referencias

- Roger Koenker, “Quantile Regression”. Cambridge University Press (2005). Cap. 1, Cap. 2 (2.1-2.6).
- Angrist y Pischke (2009). Mostly Harmless Econometrics: An Empiricist’s Companion. Cap. 7.
- Walter Sosa Escudero (2005), “Progresos en Econometría”. AAEP, Serie Progresos en Economía. Cap. 5.
- Sosa Escudero, Giovagnoli y Porto (2009) “*The Effects of Individual Characteristics on the Distribution of College Performances*”, *Economica*, Vol LV, 99-130.

Estimación y Propiedades Algebraicas de QR: aplicación a ecuaciones de Mincer

Javier Alejo

Tópicos de Econometría

FCE-UNLP

Octubre/Noviembre, 2020

Temario de la clase

Estimación QR


- 1 Parámetros
- 2 Predicción lineal y residuos
- 3 Propiedades algebraicas

Inferencia en QR

- 1 Errores estándar
- 2 Test de hipótesis

Análisis gráfico

- 1 Coeficientes
- 2 Distribución condicional



El modelo

Modelo para la media condicional:

$$\begin{aligned} E(w|x) = & \beta_1 + \beta_2 edad + \beta_3 edad^2 + \beta_4 pric + \beta_5 seci + ... \\ & ... + \beta_6 secc + \beta_7 supi + \beta_8 supc + ... \\ & ... + \beta_9 casado \end{aligned}$$

Modelo para el τ -ésimo cuantil condicional:

$$\begin{aligned} Q_\tau(w|x) = & \beta_1(\tau) + \beta_2(\tau) edad + \beta_3(\tau) edad^2 + \beta_4(\tau) pric + \beta_5(\tau) seci + ... \\ & ... + \beta_6(\tau) secc + \beta_7(\tau) supi + \beta_8(\tau) supc + ... \\ & ... + \beta_9(\tau) casado \end{aligned}$$

Variables

- **edad**: son los años de edad del individuo al momento de la encuesta.
- **pric**: =1 si el máximo nivel alcanzado es primaria completa, =0 en otro caso.
- **seci**: =1 si el máximo nivel alcanzado es secundario incompleta, =0 en otro caso.
- **secc**: =1 si el máximo nivel alcanzado es secundario completa, =0 en otro caso.
- **supi**: =1 si el máximo nivel alcanzado es superior incompleto, =0 en otro caso.
- **supc**: =1 si el máximo nivel alcanzado es superior completo, =0 en otro caso.
- **casado**: =1 si vive en pareja, =0 en otro caso.

Para la aplicación

- **Datos:** extraídos de la Encuesta Continua de Hogares (ECH) 2014, solo para Montevideo.
- **Muestra:** son 13235 observaciones de hombres con datos completos de ingreso, edad, educación y situación marital.
- **Método:** Mínimos Cuadrados Ordinarios (MCO) y Regresión por Cuantiles (QR).
- **Referencia:** Buchinsky, M. (1994).

Koenker y Bassett (1978)

- Modelo para el τ -ésimo cuantil de Y condicional X :

$$\begin{aligned} Q_{\tau}(y|x) &= \beta_0(\tau) + \beta_1(\tau)x_1 + \dots + \beta_K(\tau)x_K \\ &= x_i^T \beta(\tau) \end{aligned}$$

- Quantile Regression:** nos da estimadores de $\beta(\tau)$ como solución de

$$\min_{b \in \mathbb{R}^K} \sum_{i=1}^n \rho_{\tau}(y_i - x_i^T b)$$

donde $\rho_{\tau}(u) = u[\tau - I(u < 0)]$

- Notar:** τ es una constante dentro del problema de minimización.

Ecuación de ingresos (ECH 2014)

	QR(0.10)	QR(0.20)	QR(0.30)	QR(0.40)	QR(0.50)	QR(0.60)	QR(0.70)	QR(0.80)	QR(0.90)
edad	0.0466*** (0.00789)	0.0361*** (0.00587)	0.0394*** (0.00455)	0.0380*** (0.00463)	0.0414*** (0.00423)	0.0444*** (0.00406)	0.0438*** (0.00475)	0.0442*** (0.00587)	0.0472*** (0.00863)
edad2	-0.000490*** (9.18e-05)	-0.000353*** (6.89e-05)	-0.000372*** (5.26e-05)	-0.000345*** (5.28e-05)	-0.000366*** (4.87e-05)	-0.000387*** (4.74e-05)	-0.000358*** (5.50e-05)	-0.000351*** (6.85e-05)	-0.000349*** (0.000102)
pric	0.589*** (0.0901)	0.419*** (0.0688)	0.311*** (0.0439)	0.256*** (0.0466)	0.213*** (0.0371)	0.194*** (0.0345)	0.179*** (0.0481)	0.172*** (0.0385)	0.189*** (0.0518)
seci	0.825*** (0.0874)	0.645*** (0.0687)	0.542*** (0.0419)	0.500*** (0.0460)	0.451*** (0.0340)	0.435*** (0.0304)	0.416*** (0.0461)	0.399*** (0.0361)	0.437*** (0.0511)
secc	1.063*** (0.0889)	0.869*** (0.0686)	0.773*** (0.0437)	0.747*** (0.0473)	0.720*** (0.0387)	0.704*** (0.0313)	0.686*** (0.0480)	0.679*** (0.0408)	0.756*** (0.0532)
supi	1.249*** (0.0914)	1.065*** (0.0732)	1.010*** (0.0459)	0.952*** (0.0495)	0.911*** (0.0355)	0.889*** (0.0339)	0.883*** (0.0457)	0.859*** (0.0415)	0.928*** (0.0541)
supc	1.583*** (0.0897)	1.424*** (0.0694)	1.313*** (0.0453)	1.286*** (0.0487)	1.255*** (0.0352)	1.262*** (0.0330)	1.261*** (0.0469)	1.302*** (0.0407)	1.395*** (0.0515)
casado	0.132*** (0.0209)	0.132*** (0.0139)	0.142*** (0.0124)	0.142*** (0.0130)	0.134*** (0.0131)	0.144*** (0.0104)	0.143*** (0.0142)	0.143*** (0.0148)	0.136*** (0.0227)
Constant	3.458*** (0.183)	4.067*** (0.130)	4.215*** (0.103)	4.403*** (0.105)	4.465*** (0.0890)	4.511*** (0.0883)	4.632*** (0.101)	4.774*** (0.125)	4.857*** (0.183)
Observations	12,783	12,783	12,783	12,783	12,783	12,783	12,783	12,783	12,783

Errores Estandar entre parentesis *** p<0.01, ** p<0.05, * p<0.1. Bootstrap (300 replicas)

Predicción y Residuos

Definiciones: sea $\hat{\beta}(\tau)$ el estimador de QR

- **Predicción:** $\hat{Q}_\tau(Y|X) = X\hat{\beta}(\tau)$
- **Residuos:** $e(\tau) = y - X\hat{\beta}(\tau)$

Consideremos el siguiente conteo

- $P, N, Z = \#$ de observaciones con residuos positivos, negativos y nulos.

(Algunas) Propiedades Algebraicas de QR

Si X contiene un intercepto, entonces se satisface que:

- 1 Condición de los residuos

$$\frac{N}{n} \leq \tau \leq \frac{N+Z}{n}$$
$$\frac{P}{n} \leq (1 - \tau) \leq \frac{P+Z}{n}$$

- 2 Solución básica: $Z = k$

Condición de los residuos

Inferencia: un solo cuantil

Vimos que el estimador de QR tiene normalidad asintótica:

$$\sqrt{n}[\hat{\beta}(\tau) - \beta_0(\tau)] \xrightarrow{d} N(0, \Omega)$$

donde Ω es una matriz de $k \times k$ tiene la siguiente forma:

$$\Omega_{\tau} = \tau(1 - \tau)E[x_i x_i' f_i(Q_{\tau})]^{-1} E(x x') E[x_i x_i' f_i(Q_{\tau})]^{-1}$$

Algunas alternativas:

- **Hendricks-Koenker:** aproximación numérica de $f_i(\cdot)$

$$\hat{f}_i(\cdot) = \frac{2h}{x_i' \hat{\beta}(\tau + h) - x_i' \hat{\beta}(\tau - h)}$$

- **Powell (1990):** utilizar un estimador de Kernels para $f_i(\cdot)$
- **Bootstrap:** es la más usada

Inferencia: un solo cuantil

Vimos que el estimador de QR tiene normalidad asintótica:

$$\sqrt{n}[\hat{\beta}(\tau) - \beta_0(\tau)] \xrightarrow{d} N(0, \Omega)$$

donde Ω es una matriz de $k \times k$ tiene la siguiente forma:

$$\Omega_\tau = \tau(1 - \tau)E[x_i x_i' f_i(Q_\tau)]^{-1} E(x x') E[x_i x_i' f_i(Q_\tau)]^{-1}$$

Algunas alternativas:

- **Hendricks-Koenker:** aproximación numérica de $f_i(\cdot)$

$$\hat{f}_i(\cdot) = \frac{2h}{x_i' \hat{\beta}(\tau + h) - x_i' \hat{\beta}(\tau - h)}$$

- **Powell (1990):** utilizar un estimador de Kernels para $f_i(\cdot)$
- **Bootstrap:** es la más usada

Inferencia: varios cuantiles

Si nos interesa los parámetros de un conjunto de m cuantiles $\beta = [\beta(\tau_1), \dots, \beta(\tau_m)]$, entonces:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, V)$$

donde $\hat{\beta} = [\hat{\beta}(\tau_1), \dots, \hat{\beta}(\tau_m)]$ y donde V es una matriz de varianzas y covarianzas.

- V covarianza de los coeficientes del mismo cuantil y también entre cuantiles.
- V es de dimensión $mk \times mk$ (compuesta por bloques de $k \times k$).
- Bootstrap!

Restricciones lineales de parámetros

Modelo lineal general:

$$Q_{\tau}(Y|X) = X\beta(\tau)$$

Si llamamos $\beta = [\beta(\tau_1), \dots, \beta(\tau_m)]$, consideremos una hipótesis nulas con la siguiente forma general:

$$H_0 : R\beta = r$$

- R es una matriz de dimensión $qm \times km$ y r un vector de qm coordenadas que contienen constantes.
- **Normalidad asintótica:** procedimientos usuales (Z, χ^2) .

Restricciones lineales de parámetros

- Si contamos con m estimadores de QR

$$\hat{\beta} = [\hat{\beta}(\tau_1), \dots, \hat{\beta}(\tau_m)]$$

- Estadístico de prueba (estadístico de Wald):

$$T_n = n(R\hat{\beta} - r)^\top [R\hat{V}^{-1}R^\top]^{-1}(R\hat{\beta} - r) \xrightarrow{d} \chi_q^2$$

donde q es la cantidad de restricciones lineales en la H_0 y $\hat{V} \xrightarrow{P} V$.

- Dependiendo de cómo se especifique a R y r , esta forma engloba distintas pruebas: significatividad individual, grupal, global, efectos marginales homogéneos entre cuantiles, etc.

Ejemplos de inferencia


En nuestro caso, el modelo es:

$$\begin{aligned} Q_{\tau}(w|x) = & \beta_1(\tau) + \beta_2(\tau)edad + \beta_3(\tau)edad^2 + \beta_4(\tau)pric + \beta_5(\tau)seci + ... \\ & ... + \beta_6(\tau)secc + \beta_7(\tau)supi + \beta_8(\tau)supc + ... \\ & ... + \beta_9(\tau)casado \end{aligned}$$

Ejemplos: hipótesis sobre los parámetros


- 1 H_0 : la brecha salarial entre casados y solteros no difiere entre cuantiles.
- 2 H_0 : la educación no afecta a la mediana condicional de los salarios.
- 3 H_0 : la educación tiene un efecto homogéneo sobre la distribución condicional de salarios.

¿Forma funcional de $\beta(\tau)$?




Perfiles de ingreso por edad


Caso: soltero con secundaria completa.



Quantile crossing



Quantile crossing




¿Es un problema?

- *Contraintuitivo*: teóricamente, los cuantiles deberían estar ordenados.
- El cruce de los cuantiles muestrales es un resultado posible.
- También puede ser evidencia de errores de especificación.
- El método de QR garantiza que no habrá cruce de cuantiles muestrales en el centro de la distribución de x .

(Otra) Propiedad algebraica de QR

Sea $\hat{\beta}(\tau)$ el estimador de QR, entonces $\hat{Q}_\tau(y|\bar{x}) = \bar{x}^\top \hat{\beta}(\tau)$ es una función monótona no decreciente en τ , donde $\bar{x} = n^{-1} \sum_i x_i$.

Quantile crossing



Referencias

- Roger Koenker, “Quantile Regression”. Cambridge University Press (2005). Cap. 1, Cap. 2 (2.1-2.6).
- Cameron y Trivedi (2009). Microeconometrics Using Stata. Cap. 7.
- Buchinsky, M. (1994) Changes in the U.S. Wage Structure 1963-1987: Application of Quantile Regression, *Econometrica*, 62(2), 405-458.

Extensiones en Regresión por Cuantiles (Parte I)

Javier Alejo

Tópicos de Econometría

Universidad Nacional de La Plata

Noviembre, 2020

Temario de la clase

1 Variable dependiente limitada

- Censura
- Variable binaria

2 Variables Instrumentales

- Endogeneidad
- Identificación
- Estimador e Inferencia.
- Otros IVQR



Previa: Propiedad de Invarianza

Sea $h(y)$ una transformación monótona no decreciente.

$$Pr(Y \leq Q_\tau) = \tau$$

Dado que $h(y)$ es no decreciente, también es cierto que:

$$Pr[h(Y) \leq h(Q_\tau)] = \tau$$

Luego:

$$Q_\tau[h(Y)] = h[Q_\tau(Y)]$$

Esto también vale para el cuantil de Y dado X

$$Q_\tau[h(Y)|X] = h[Q_\tau(Y|X)]$$

Censura

- Nos interesa una variable Y_i^* que no observamos.
- En su lugar observamos Y_i , una versión censurada.
- Censura simple:

$$Y_i = \begin{cases} C & \text{si } Y_i^* \leq C \\ Y_i^* & \text{si } Y_i^* > C \end{cases}$$

- Ejemplos: gasto y consumo, horas de trabajo/ocio, calificación de un examen, etc.

Modelo Tobit

- Modelo lineal para la variable latente

$$Y_i^* = x_i^T \beta + u_i$$

- Asume que $u_i | x_i \sim N(0, \sigma^2)$.
- Supuestos estadísticos: homocedasticidad, normalidad,...

- Sin pérdida de generalidad, $C = 0$.
- La probabilidad de observar un dato censurado es:


$$\begin{aligned}P(Y_i = C) &= P(Y_i^* \leq 0) = P(x_i^\top \beta + u_i \leq 0) \\&= P(u_i/\sigma \leq -x_i^\top \beta/\sigma) \\&= \Phi(-x_i^\top \beta/\sigma)\end{aligned}$$

- Por otro lado, la densidad de observar los valores continuos es:


$$f(Y_i|x_i) = \sigma^{-1}\phi((Y_i - x_i^\top \beta)/\sigma)$$

- Es posible estimar este modelo por máxima verosimilitud.

Relación homogénea



Relación heterogénea



Censura como una transformación

Mecanismo de censura:

$$Y_i = \begin{cases} C & \text{si } Y_i^* < C \\ Y_i^* & \text{si } Y_i^* \geq C \end{cases}$$

o lo que es igual

$$Y_i = \max(Y_i^*, C)$$

donde $\max(a, b)$ devuelve el mayor entre los valores a y b .

Cuantiles condicionales

Modelo lineal:

$$Q_{\tau}(Y_i^*|x_i) = x_i^T \beta(\tau)$$

Quisiéramos estimar:

$$\hat{\beta}(\tau) = \arg \min_{b \in \mathbb{R}^K} n^{-1} \sum_{i=1}^n \rho_{\tau}(Y_i^* - x_i^T b)$$

Sin embargo, sólo contamos con $Y_i = \max(Y_i^*, C)$.

- Por propiedad de invarianza: $Q_\tau[h(Y)|X] = h[Q_\tau(Y|X)]$
- En este caso: $Y = h(Y^*) = \max(Y_i^*, C)$
- Luego,

$$\begin{aligned} Q_\tau[Y_i|x_i] &= Q_\tau[h(Y_i^*)|x_i] \\ &= h[Q_\tau(Y_i^*|x_i)] \\ &= h[x_i^\top \beta(\tau)] \\ &= \max[x_i^\top \beta(\tau), C] \end{aligned}$$

Censored Quantile Regression

Powell (1986): propone como estimador de $\beta(\tau)$


$$\hat{\beta}(\tau) = \arg \min_{b \in \mathbb{R}^K} n^{-1} \sum_{i=1}^n \rho_{\tau}[Y_i - \max(x_i^{\top} b, C)]$$

Ventajas (teóricas)

- No requiere supuestos paramétricos sobre distribución condicional.
- Heterogeneidad en los efectos de X .

Desventajas (prácticas):

- Problemas de convergencia (Buchinsky 1998; Portnoy, 2003).
- Estimación de los errores estándar.
- Algunas mejoras con algoritmos por simulación (Baker, 2013).



Buchinsky y Han (1998): un estimador alternativo

Sabemos que el truncamiento altera la distribución original:

$$\underbrace{F(y^*)}_{\text{Dist. latente}} \neq \underbrace{F(y|y > 0)}_{\text{Dist. truncada}}$$

Llamemos q_τ al cuantil definido por la distribución truncada:


$$F(q_\tau|y > 0) \equiv \tau$$

Luego, si lo evaluamos en la distribución original (latente):

$$F(q_\tau) \equiv \tau^* \neq \tau$$

Problema: la distribución observada no identifica los cuantiles de la variable latente.

Distribución latente *versus* truncada



$$\tau = A + B$$

$$\tau^* = B + C$$

Relación entre τ y τ^*

Notar que por definición de distribución condicional:

$$\begin{aligned} F(q_\tau | y > 0) &= \frac{P(0 < y^* < q_\tau)}{P(y^* > 0)} \\ &= \frac{P(y^* < q_\tau) - P(y^* < 0)}{P(y > 0)} \\ \tau &= \frac{\tau^* - P(y^* < 0)}{1 - P(y^* < 0)} = \frac{\tau^* - P(y = 0)}{1 - P(y = 0)} \end{aligned}$$

Si nos interesa el cuantil τ^* de la variable latente debemos buscar el cuantil τ en con la muestra truncada ($i : y_i > 0$).

Estimador alternativo

La versión condicional en un grupo de regresores x_i es:

$$\tau(x_i) = \frac{\tau^* - P(y = 0|x_i)}{1 - P(y = 0|x_i)}$$

Luego, para los coeficientes $\hat{\beta}(\tau^*)$ del modelo latente podemos hacer (Buchinsky y Han, 1998):

$$\hat{\beta}(\tau^*) = \arg \min_{b \in \mathbb{R}^K} n^{-1} \sum_{i: y_i > 0}^n \rho_{\tau(x_i)}(y_i - x_i^\top b)$$

Notar que es una versión reponderada del QR estándar (globalmente cóncava) con la muestra truncada.

En la práctica...

- **Problema:** ¿cómo estimamos a $P(y = 0|x_i)$? (probabilidad de censura)
- No es trivial: se trata de un modelo binario. Alternativas:
 - Usar un **modelo paramétrico** (Probit o Logit), pero se pierde la esencia *distribution free* de QR.
 - **Modelo no paramétrico:** es posible (ej. Nadaraya (1965) y Watson (1964)), pero computacionalmente vuelve a ser complicado.
- **Ventajas sobre Powell (1986) un poco relativas...**

Variable dependiente binaria


Pensemos ahora en un caso de censura más extremo:

$$Y_i = \begin{cases} 0 & \text{si } Y_i^* \leq 0 \\ 1 & \text{si } Y_i^* > 0 \end{cases}$$

Métodos paramétricos: Probit, Logit, ...

$$Y_i^* = x_i^T \beta + u_i$$

- Supuestos distributivos sobre el u_i : Normal, Logística, ...
- Comportamiento homogéneo alrededor de $x_i^T \beta$.



Variable latente y observada

$$Y_i = \begin{cases} 0 & \text{si } Y_i^* < 0 \\ 1 & \text{si } Y_i^* \geq 0 \end{cases}$$

Luego, esto es una transformación no decreciente de Y^*

$$Y_i = I\{Y_i^* \geq 0\}$$

Idea: usar nuevamente la propiedad de invarianza.

- Modelo lineal: $Q_{\tau}(Y_i^*|x_i) = x_i^T \beta(\tau)$
- La transformación es $Y_i = h(Y_i^*) = I\{Y_i^* \geq 0\}$ (respuesta binaria).
- Luego,

$$\begin{aligned} Q_{\tau}[Y_i|x_i] &= Q_{\tau}[h(Y_i^*)|x_i] \\ &= h[Q_{\tau}(Y_i^*|x_i)] \\ &= h[x_i^T \beta(\tau)] \\ &= I\{x_i^T \beta(\tau) > 0\} \end{aligned}$$

Binary Quantile Regression

Manski (1975,1985) utiliza esta idea y propone:

$$\hat{\beta}(\tau) = \arg \min_{b: \|b\|=1} n^{-1} \sum_{i=1}^n \rho_{\tau}[Y_i - I\{x_i^T b \geq 0\}]$$

- La expresión $\|b\| = 1$ normaliza la escala de los parámetros.
- El método es consistente y asintóticamente normal.
- Función objetivo complicada.

Smoothed Binary Quantile Regression

Manski (1985) muestra que el BQR es equivalente a:

$$\hat{\beta}(\tau) = \arg \max_{b: \|b\|=1} n^{-1} \sum_{i=1}^n [Y_i - (1 - \tau)] I\{x_i^\top b \geq 0\}$$

Kordas (2006) propone reemplazar a $I\{x_i^\top b(\tau) \geq 0\}$ por una función suave $K(x_i^\top b/h_n)$ que satisface:

- 1 $K(-\infty) = 0$
- 2 $K(+\infty) = 1$
- 3 $K'(\cdot) > 0$

Notar:

- h_n es un parámetro que controla el suavizado.
- Este problema es menos complicado computacionalmente.

Última slide sobre BQR

Probabilidad condicional: tomando un valor particular de $X = x$, podemos estimarla como:

$$\hat{P}(Y = 1|X = x) = m^{-1} \sum_{j=1}^m I\{x^\top \hat{\beta}(\tau_j) > 0\}$$

En la balanza:

- BQR no está forzado por modelos paramétricos.
- La relevancia de usar o no BQR depende del tipo de pregunta.
- Nada en Stata, solo R o S-Plus.
- En la práctica requiere un alto costo computacional.

Previa: otra interpretación de VI

Consideren el siguiente modelo

$$Y = D\alpha + u$$

donde D es una variable endógena.

- MCO es sesgado.
- MCO es inconsistente.

Estimador de VI: usando OGMM

$$\hat{\alpha}_{VI} = (D'P_Z D)^{-1} D'P_Z Y$$

donde Z son instrumentos válidos y

$$P_Z = Z(Z'Z)^{-1}Z'$$

Previa: otra interpretación de VI

Galvao y Montes-Rojas (2015): prueban que el estimador de VI es equivalente a resolver lo siguiente

$$\hat{\alpha}_{VI} = \arg \min_{\alpha} \hat{\gamma}(\alpha)'(Z'Z)\hat{\gamma}(\alpha)$$

sujeito a:

$$\hat{\gamma}(\alpha) = \arg \min_{\gamma} (Y - D\alpha - Z\gamma)'(Y - D\alpha - Z\gamma)$$

Prueba: noten que

$$\hat{\gamma}(\alpha) = (Z'Z)^{-1}Z'(Y - D\alpha)$$

Reemplazando

$$\min_{\alpha} (Y - D\alpha)'P_Z(Y - D\alpha)$$

Luego, $\hat{\alpha} = (D'P_ZD)^{-1}D'P_ZY = \hat{\alpha}_{VI}$

¿Endogeneidad en cuantiles?

- Pregunta complicada...
- En general, con datos no experimentales las variables de interés (educación, precios, etc.) son endógenas.
- Simultaneidad, error de medición en X , auto-selección, variables omitidas, etc.
- Cuando X es endógena:

$$Pr[Y \leq x'\beta(\tau)|X = x] \neq \tau$$

- Problema: efecto causal versus correlación.

Chernozhukov y Hansen (2005)

- Establecen condiciones de identificación sin suponer ninguna forma funcional específica.
- Variable de resultado (observada): $Y \equiv Y_D$, con $D = \{0, 1\}$
- Quantile Treatment Response (objeto a estimar): $q(D, x, \tau)$
- QTE: $q(1, x, \tau) - q(0, x, \tau)$
- Restricción de momento (identificación):

$$Pr[Y \leq q(D, x, \tau) | X, Z] = \tau$$

donde Z es un instrumento para D .

Supuestos para la identificación

- **Supuesto 1 (resultados potenciales):** para $d = \{0, 1\}$ es

$$Y_d = q(d, x, U_d)$$

con $U_d \sim U(0, 1)$ y donde $q(d, x, \tau)$ es una función estrictamente creciente en τ .

- **Supuesto 2 (endogeneidad):** existe un proceso de selección dado por

$$D \equiv \delta(Z, X, V)$$

para alguna función desconocida $\delta(\cdot)$ y alguna variable aleatoria V .

Supuestos para la identificación

- **Supuesto 3 (independencia):** los rankings condicionales $U_d|X = x$ son independientes de Z .
- **Supuesto 4 (invarianza o similitud de rankings):** dado $X = x$ y $Z = z$ se satisface alguna de estas propiedades:
 - (a) U_d son iguales para todo valor d .
 - (b) $U_d|V$ son idénticamente distribuidas.
- **Supuesto 5 (variables observadas):** consisten en
 - Resultado: $Y_D = q(D, x, U_D)$,
 - Tratamiento: D
 - Controles: X
 - Instrumento: Z

Prueba de la condición de momento

Versión simple:

$$\begin{aligned} Pr[Y < q(D, X, \tau) | X, Z] &= Pr[q(D, X, U_D) < q(D, X, \tau) | X, Z] \\ &= Pr[U_D < \tau | X, Z] \\ &= Pr[U < \tau | X, Z] \\ &= \tau \end{aligned}$$

- La demostración puede flexibilizarse fácilmente usando el supuesto más general 4.(b).
- (ver Chernozhukov y Hansen, 2005, pag. 256).

Estimador IVQR

Para simplificar, supongamos que:

$$q(d, x, \tau) = d' \alpha(\tau) + x' \beta(\tau)$$

Chernozhukov y Hansen (2005) proponen el siguiente algoritmo:

$$\min_{\alpha, \beta, \gamma} \|\gamma\|_A$$

sujeto a:

$$(\beta, \gamma) = \underset{(\beta, \gamma)}{\operatorname{argmin}} \sum_{i=1}^N \rho_{\tau}(y_i - q(d_i, x, \tau) - \gamma \Phi(z_i, x_i))$$

En la práctica:

- Computacionalmente muy costoso.
- Hay simplificaciones para el caso con $\dim(d) = 1$.

Inferencia IVQR

Chernozhukov y Hansen (2008)

Resultado: bajo los supuestos 1 a 5

- **Consistencia:**

$$\hat{\theta}(\tau) \equiv (\hat{\alpha}, \hat{\beta}, \hat{\gamma}) \xrightarrow{p} (\alpha_0, \beta_0, \gamma_0) \equiv \theta_0(\tau)$$

- **Normalidad asintótica:**

$$\sqrt{n} [\hat{\theta}(\tau) - \theta_0(\tau)] \xrightarrow{d} N(0, \Omega_\theta)$$

Test de identificación: Chernozhukov y Hansen (2020)

$$H_0 : \gamma_0 = 0$$

Estadístico de prueba

$$W_n = n\hat{\gamma}' V(\hat{\gamma})^{-1} \hat{\gamma} \xrightarrow{d} \chi^2_{\dim(z)}$$

Otros IVQR

Modelo triangular

$$\begin{aligned} Y &= g(X, \varepsilon) \\ X &= h(Z, \eta) \end{aligned}$$

con $Z \perp \varepsilon$ y $Z \perp \eta$.

- Koenker and Ma (2006).
- Imbens and Newey (2009).

Estimador muestral

- Abadie, et al. (2002): QR reponderado (similar a PSM).
- Kaplan y Sun (2016), GMM suavizado.
- Machado y Santos Silva (2019) proponen un modelo location-scale e identificarlo vía momentos.

Referencias

- Koenker, R. (2017). "Quantile regression 40 years on". Annual Review of Economics, Vol. 9:155-176.
- Roger Koenker, "Quantile Regression". Cambridge University Press (2005). Cap. 8 (8.1, 8.2, 8.8).
- Cajias, M., Freudenreich, P. and Freudenreich, A. (2020); "Exploring the determinants of real estate liquidity from an alternative perspective: censored quantile regression in real estate research". Journal of Business Economics:1057–1086.
- Autor, D., Houseman, S. and Kerr, S. (2012). "The Effect of Work First Job Placements on the Distribution of Earnings: An Instrumental Variable Quantile Regression Approach". Journal of Labor Economics. 35.

Extensiones en Regresión por Cuantiles (Parte II)

Javier Alejo

Tópicos de Econometría

Universidad Nacional de La Plata

Noviembre, 2020

Temario de la clase

1 Modelos dinámicos

- Modelos autoregresivos
- Datos en panel

2 Selección muestral

- Estimador en etapas
- Estimador conjunto

3 QR misceláneo

- Error de especificación
- Otros avances en QR



Modelos autoregresivos

Supongamos el siguiente modelo AR(1)

$$y_t = \alpha + \delta y_{t-1} + \varepsilon_t$$

donde $E(\varepsilon_t) = 0$, $V(\varepsilon_t) = \sigma^2$ y $COV(\varepsilon_t, \varepsilon_s) = 0$ para $t \neq s$.

El parámetro δ nos da información sobre la dinámica de y_t :

- $|\delta| < 1$: el proceso es estacionario.
- $|\delta| \geq 1$: comportamiento divergente.

Modelo para la media condicional en el pasado:

$$E(y_t | y_{t-1}) = \alpha + \delta y_{t-1}$$

Quantile Autoregression (QAR)

Koenker y Xiao (2006) proponen el siguiente modelo QAR(1):

$$Q_{\tau}(y_t|y_{t-1}) = \alpha(\tau) + \delta(\tau)y_{t-1}$$



Notar:

- $\delta(\tau)$: dinámica en distintos puntos de la distribución de y_t condicional en su pasado.
- Parámetro de la media condicional:


$$\delta = \int_0^1 \delta(\tau) d\tau$$

- El caso $|\delta| < 1$ no es incompatible con $|\delta(\tau_0)| \geq 1$ para algún cuantil τ_0 .



AR(1)



Random walk



QAR(1)



El modelo puede ser estimado a la Koenker y Bassett (1978):

$$\begin{aligned}\hat{\delta}(\tau) &= \underset{d}{\operatorname{argmin}} \sum_{t=2}^T \rho_{\tau}(y_t - a - dy_{t-1}) \\ &\xrightarrow{P} \delta(\tau)\end{aligned}$$

Supuesto fundamental: media condicional estacionaria.

Comentarios:

- Bajo las mismas condiciones se puede estimar $\text{QAR}(p)$.
- Heterocedasticidad autoregresiva: natural en QR.
- Dinámica asimétrica: usual en algunas series económicas (por ejemplo, senderos de precios).
- Forecast: predicción puntual *versus* una distribución para y_{t+1} .

Datos en panel

Modelo lineal:

$$y_{it} = x_{it}^T \beta + u_{it}$$

donde $i = 1, \dots, N$ y $t = 1, \dots, T$.

Estructura del término de error:

$$u_{it} = \alpha_i + \varepsilon_{it}$$

Posturas sobre la naturaleza de α_i :

- Efectos fijos (EF)
- Efectos Aleatorios (EA).

Supuestos estadísticos

En notación matricial:

$$Y = X\beta + D\alpha + \varepsilon$$

Supongamos que

- $\alpha \sim (0, \sigma_\alpha^2 I_N)$
- $\varepsilon \sim (0, \sigma_\varepsilon^2 I_{NT})$
- $\alpha \perp \varepsilon$

Luego,

$$\Omega = \sigma_\alpha^2 DD^\top + \sigma_\varepsilon^2 I_{NT}$$

es la matriz de varianzas y covarianzas $\Omega \equiv V(u)$

Estimación

Estimador de MCG (EA):

$$\begin{aligned}\hat{\beta}_{RE} &= (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} Y \\ &= (\tilde{X}^T \tilde{X})^{-1} \tilde{X}^T \tilde{Y}\end{aligned}$$

donde $\tilde{X} = \Omega^{-1/2} X$ y $\tilde{Y} = \Omega^{-1/2} Y$.

Modelo transformado (Baltagi, 2005):

$$\underbrace{\tilde{y}_{it}}_{y_{it} - \theta \bar{y}_i} = \underbrace{\tilde{x}_{it}^T}_{(x_{it}^T - \theta \bar{x}_i^T)} \beta + \underbrace{\tilde{u}_{it}}_{u_{it} - \theta \bar{u}_i}$$

donde

$$\theta = 1 - \sigma_\varepsilon^2 / (\sigma_\varepsilon^2 + T \sigma_\alpha^2)$$

MCO, EF y EA

$$y_{it} - \theta \bar{y}_i = (x_{it}^T - \theta \bar{x}_i^T) \beta + u_{it} - \theta \bar{u}_i$$

donde

$$\theta = 1 - \sigma_\varepsilon^2 / (\sigma_\varepsilon^2 + T \sigma_\alpha^2)$$

Notar:

- Si $\theta \rightarrow 0$ entonces $\hat{\beta}_{EA} \rightarrow \hat{\beta}_{MCO}$
- Si $\theta \rightarrow 1$ entonces $\hat{\beta}_{EA} \rightarrow \hat{\beta}_{EF}$

MCG como problema de minimización

$$\hat{\beta}_{EA} = \underset{b}{\operatorname{argmin}} (Y - Xb)^T \Omega^{-1} (Y - Xb)$$

Esto es equivalente a [Koenker 2005, Proposition 8.1., pag. 277]:

$$\hat{\beta}_{EA} = \underset{(b,a)}{\operatorname{argmin}} \{ (Y - Xb - Za)^T V(\varepsilon)^{-1} (Y - Xb - Za) + a^T V(\alpha)^{-1} a \}$$

En notación observacional:

$$\begin{aligned} \hat{\beta}_{EA} &= \underset{(b,a)}{\operatorname{argmin}} \sum_i \sum_t (\sigma_\varepsilon^2)^{-1} (y_{it} - x_{it}^T b - a_i)^2 + \sum_i (\sigma_\alpha^2)^{-1} a_i^2 \\ &= \underset{(b,a)}{\operatorname{argmin}} \sum_i \sum_t (y_{it} - x_{it}^T b - a_i)^2 + \lambda \sum_i a_i^2 \end{aligned}$$

donde $\lambda = \sigma_\varepsilon^2 / \sigma_\alpha^2$.

QR para paneles

En forma análoga, Koenker (2004) propone:

$$(\hat{\alpha}(\tau), \hat{\beta}(\tau)) = \underset{(a,b)}{\operatorname{argmin}} \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau}(y_{it} - x_{it}^{\top} b - a_i) + \lambda \sum_{i=1}^N |a_i|$$

De la misma manera, el parámetro λ controla la penalización de a_i :

- $\lambda \rightarrow 0 \Rightarrow$ QR EF
- $\lambda \rightarrow \infty \Rightarrow$ QR Pool
- $0 < \lambda < \infty \Rightarrow$ QR Penalized

Paneles cortos

- Estimar $\alpha_i(\tau)$ puede ser bastante impreciso si T no es grande.
- Koenker (2004): estimación conjunta de M cuantiles:

$$\min_{(a,b)} \sum_{m=1}^M \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau_m}[y_{it} - x_{it}^T b(\tau_m) - a_i] + \lambda \sum_{i=1}^N |a_i|$$

- Notar que es el caso con $\alpha_i(\tau) = \alpha_i$ (*pure location shift*).
- Nada en Stata, por ahora solo R.

¿Cómo elegir λ ?

Cada estimador de QR penalizado depende del valor elegido para λ :

$$\hat{\beta}(\tau_m, \lambda) \xrightarrow{P} \beta(\tau)$$

Bajo ciertas condiciones de regularidad:

$$\sqrt{TN}(\hat{\beta}(\tau, \lambda) - \beta(\tau)) \xrightarrow{d} N(0, \Sigma(\lambda))$$

Lamarche (2010): elegir aquel que minimiza a la varianza asintótica

$$\lambda^* = \underset{\lambda}{\operatorname{argmin}} \{ \operatorname{tr} \Sigma(\lambda) \}$$

Endogeneidad generada por α_i :

- $\hat{\beta}(\tau_m, \lambda) \xrightarrow{P} \beta(\tau)$ para $\lambda > 0$
- Luego, $\lambda = 0$ (EF QR) asegura la consistencia.

EF: el caso *location-shift*

Modelo lineal:

$$y_{it} = x_{it}^T \beta(\tau) + \alpha_i(\tau)$$

Supongamos $\alpha_i(\tau) = \alpha_i$ para todo τ .

$$\begin{aligned} y_{it} - \alpha_i &= x_{it}^T \beta(\tau) \\ z_{it} &= x_{it}^T \beta(\tau) \end{aligned}$$

Si observáramos a z_i :

$$\begin{aligned} \hat{\beta}(\tau) &= \underset{b}{\operatorname{argmin}} \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau}(z_{it} - x_{it}^T b) \\ &\xrightarrow{P} \beta(\tau) \end{aligned}$$

Si contamos con $\hat{\alpha}_i \xrightarrow{p} \alpha_i$, entonces:

$$\begin{aligned}\hat{z}_{it} &= y_{it} - \hat{\alpha}_i \\ &\xrightarrow{p} y_{it} - \alpha_i = z_{it}\end{aligned}$$

Canay (2011) propone un estimador en dos pasos:

- 1 Obtener a $\hat{\alpha}_i$ por EF regresando y_{it} en x_{it} .
- 2 Estimar a $\beta(\tau)$ por QR usando a $(y_{it} - \hat{\alpha}_i)$ como variable dependiente en función de x_{it} .

Este estimador en etapas es consistente y asintóticamente normal.

Paneles dinámicos

Consideren un modelo de panel pero con un componente dinámico:

$$y_{it} = \delta y_{it-1} + x_{it}^T \beta + \alpha_i + \varepsilon_{it}$$

Los estimadores estándar (MCO, EF y EA) son sesgados e inconsistentes.

- **Causa:** la propia dinámica del modelo genera un problema de endogeneidad.
- **Solución:** estimar con EF-VI utilizando a Δy_{it-2} o y_{it-2} como instrumento válido.
- **Clave:** los instrumentos salen de la propia estructura del modelo (Anderson and Hsiao, 1981; Arellano, 1989).

Paneles dinámicos

Esperanza condicional con efectos fijos:

$$E(y_{it}|y_{it-1}, x_{it}) = \delta y_{it-1} + x_{it}^T \beta + \alpha_i$$

La versión para el cuantil condicional es:

$$Q_{\tau}(y_{it}|y_{it-1}) = \delta(\tau)y_{it-1} + x_{it}^T \beta(\tau) + \alpha_i$$

Galvao (2011): estimar este modelo combinando dos métodos

- Minimización penalizada de Koenker (2004), con $\lambda = 0$ (EF).
- Estimador de VI-QR de Chernozhukov y Hansen (2005) usando y_{it-2} como instrumento válido.

Galvao (2011)

Propone solucionar

$$\min_{\delta} \|\hat{\gamma}(\delta)\|_A$$

sujeto a:

$$(\hat{\beta}(\delta), \hat{\alpha}_i(\delta), \hat{\gamma}(\delta)) = \underset{(\beta, \gamma)}{\operatorname{argmin}} \sum_{m=1}^M \sum_{i=1}^N \sum_{t=1}^T \rho_{\tau_m}(y_{it} - \delta y_{it-1} - x_{it}^T \beta - \alpha_i - \gamma z_{it})$$

Notar:

- Estamos en el caso con único regresor endógeno.
- Instrumento: $z_{it} = y_{it-2}$.
- Algoritmo computacional: el grid es conocido! $\delta \in [-1, 1]$

Media condicional

Ecuaciones de regresión y selección:

$$\begin{aligned}y_{1i} &= x_{1i}^T \beta_1 + u_{1i} \\ s_i &= 1(x_{2i}^T \beta_2 + u_{2i} > 0)\end{aligned}$$

donde en lugar de y_{1i} se observa $s_i = 1$.

Supuestos principales:

- 1 $E(u_{1i}|u_{2i}) = \delta u_{2i}$
- 2 $u_{2i}|x_{2i} \sim N(0; \sigma_2^2)$

Resultado: sesgo potencial por el proceso de selección

$$E(y_{1i}|x_{1i}, s_i = 1) = x_{1i}^T \beta_1 + \gamma \lambda(x_{2i}^T \beta_2 / \sigma_2)$$

donde $\lambda(\cdot) = \phi(\cdot)/\Phi(\cdot)$ es la inversa del ratio de Mills.

Heckman (1979)

Propone un estimador consistente dos etapas:

- **Etapla 1:** obtener un $\hat{\beta}_2^*$ usando un Probit usando la muestra completa y estimar a $\hat{\lambda}_i = \lambda(x'_{2i}\hat{\beta}_2^*)$.
- **Etapla 2:** estimar a β_1 con una regresión de MCO para $i : s_i = 1$ del modelo:

$$E(y_{1i}|x_{1i}, s_i = 1) = x_{1i}^T \beta_1 + \hat{\gamma}^* \hat{\lambda}_i$$

Noten que:

- **Supuesto (1):** problema potencial de endogeneidad sobre MCO.
- **Supuesto (2):** impone cierta estructura distributiva.

Buchinsky (1998)

Propone un procedimiento similar al de Heckman (1979) para estimar un modelo de cuantiles:

- Etapla 1: estimar un modelo de probabilidad de selección no paramétrico y computar $\hat{g}_i = \hat{P}(s_i = 1|x_{2i})$.
- Etapla 2: estimar a $\beta_1(\tau)$ por QR para $i : s_i = 1$ del modelo:

$$Q_\tau(y_{1i}|x_{1i}, s_i = 1) = x_{1i}^\top \beta_1(\tau) + \sum_{s=1}^S \theta_s(\tau) h(\hat{g}_i)^s$$

con varias alternativas en la elección de S y $h(\cdot)$.

A favor: es relativamente fácil de implementar.

Aditividad y cuantiles

Buchinsky es consistente si el modelo es aditivo, es decir si:

$$Q_{\tau}(y_{1i}|x_{1i}, s_i) = x_{1i}^T \beta_1 + m(\tau, x_2)$$

donde $m(\tau, x_2)$ es alguna función.

La aditividad es natural en la media condicional, ya que:

$$E(W_1 + W_2) = E(W_1) + E(W_2)$$

Sin embargo:

$$Q_{\tau}(W_1 + W_2) \stackrel{(?)}{=} Q_{\tau}(W_1) + Q_{\tau}(W_2)$$

Por lo tanto, la aditividad es un supuesto bastante restrictivo en el contexto de cuantiles.

Arellano y Bonhomme (2017)

Siguen con la estructura bivariada del modelo:

$$\begin{aligned}y_{1i} &= x'_{1i}\beta_1(U_1) \\ s_i &= 1[U_2 \leq p(x_{2i})]\end{aligned}$$

donde $(U_1, U_2) \in (0, 1)^2$ son dos variables aleatorias [inobservables] con distribución conjunta $F_{12}(u_1, u_2|x)$, con $x = (x_1, x_2)$.

Notar:

- $p(x_{2i}) = P(s_i = 1|x_{2i})$
- *Inobservables*: no necesariamente son independientes.
- Modelo de correlación de rankings (*copula*):

$$F_{12}(\tau, p|x) = C(\tau, p, \rho)$$

donde $p = p(x_2)$ y ρ es un parámetro de correlación.

Arellano y Bonhomme (2017)

Notar que:

$$\begin{aligned} P(y_{1i} < x'_{1i}\beta_1(\tau)|s_i = 1, x) &= \tau^* \\ &\neq \tau \end{aligned}$$

Con los supuestos que hicimos:

$$\begin{aligned} P(y_{1i} < x'_{1i}\beta_1(\tau)|s_i = 1, x) &= P(U_1 < \tau | U_2 \leq p(x_{2i}), x) \\ &= F_{12}(\tau, p|x) \\ &= C(\tau, p, \rho) \end{aligned}$$

Si conociéramos a ρ tenemos una correspondencia entre τ^* y τ dada por $\tau^* = C(\tau, p, \rho)$.

Arellano y Bonhomme (2017)

- Es la misma idea que Buchinsky y Han (1998) para datos censurados! (reponderar la distribución truncada).
- **Problema:** no conocemos a ρ ni a $p = p(x_2)$.
- Para estimar a $p(x_2)$ solo necesitamos (s_i, x_{2i}) para $i = 1, \dots, n$ y utilizar algún modelo de elección binaria (Probit, Logit, ...)
- Por otro lado, para estimar a ρ se usa la igualdad

$$P(y_{1i} < x'_{1i}\beta_1(\tau) | s_i = 1, x) = C(\tau, p, \rho)$$

que da origen a una condición de momento, similar a la que vimos con IV-QR de Chernozhukov y Hansen (2005).

Error en la especificación

En general,

$$E(y|x) = m(x)$$

donde $m(x)$ es alguna función desconocida.

Sea β la solución del problema de minimización:

$$\beta \equiv \underset{b}{\operatorname{argmin}} E \left[(y - x'b)^2 \right]$$

Resultado: $x'\beta$ es la mejor aproximación lineal a $m(x)$, es decir:

$$\beta \equiv \underset{b}{\operatorname{argmin}} E \left[(m(x) - x'b)^2 \right]$$

Verbalización: "MCO es la mejor aproximación lineal a $E(y|x)$ "

¿QR como mejor aproximación lineal?

Consideremos al cuantil condicional τ -ésimo

$$Q_{\tau}(y|x) = m_{\tau}(x)$$

donde $m_{\tau}(x)$ es alguna función desconocida.

Sea ahora $\beta(\tau)$ la solución de:

$$\beta(\tau) \equiv \underset{b}{\operatorname{argmin}} E[\rho_{\tau}(y - x'b)]$$

De la misma manera:

- QR es la mejor aproximación lineal bajo una penalización asimétrica.
- No es una forma muy usual de evaluar la especificación de un modelo.

QR como mejor aproximación lineal

Angrist et al. (2006) muestran que:

$$\beta(\tau) \equiv \underset{b}{\operatorname{argmin}} E \left[\omega_{\tau}(x, b) (m_{\tau}(x) - x' b)^2 \right]$$

para todo $\tau \in (0, 1)$.

Comentarios:

- Función de pérdida es simétrica.
- $\omega_{\tau}(x, b) \geq 0$ es un ponderador que depende de $f_{y|x}(\cdot)$
- "QR es la mejor aproximación lineal a $m_{\tau}(x)$ "

Omisión de una variable

Supongamos que

$$m_{\tau}(x) = x_1' \beta_1(\tau) + x_2' \beta_2(\tau)$$

Pero que omitimos la variable x_2 en el modelo. Del resultado anterior:

$$\gamma_1(\tau) = E[\omega_{\tau} x_1 x_1']^{-1} E[\omega_{\tau} x_1 m_{\tau}(x)]$$

Luego,

$$\gamma_1(\tau) = \beta_1(\tau) + \underbrace{E[\omega_{\tau} x_1 x_1']^{-1} E[\omega_{\tau} x_1 x_2'] \beta_2(\tau)}_{\text{Sesgo de QR por omitir a } x_2}$$

(el caso $\beta_2(\tau) = 0$ es trivial...)

¿Eso es todo?

- **Regresión no-lineal:** Koenker y D'Orey (1994); Lee (2003).
- **Variables censuradas y datos en panel:** Lamarche (2013).
- **Raíces unitarias:** Galvao (2009).
- **Count data:** Machado y Santos Silva (2005); Harding y Lamarche (2015).
- **Modelos multivariados:** Hallin et al. (2010); Garlier et. al (2016); Montes-Rojas (2017).

Referencias

- Koenker, R. (2017). "Quantile regression 40 years on". Annual Review of Economics, Vol. 9:155-176.
- Roger Koenker, "Quantile Regression". Cambridge University Press (2005). Cap. 8 (8.3, 8.4, 8.7).
- Flores, C., Flores-Lagunes, A. y Kapetanakis, D. (2009). "Lessons from Quantile Panel Estimation of the Environmental Kuznets Curve". Econometric Reviews 33(8).
- Zheng, M., Feng, G., Feng, S. and Yuan X. (2019) "The road to innovation vs. the role of globalization: A dynamic quantile investigation". Economic Modelling. Volume 83, Pages 65-83.

Unconditional Quantile Regression

Javier Alejo

Tópicos de Econometría

Universidad Nacional de La Plata

Noviembre, 2020

Temario de la clase

- Introducción
- Función de Influencia Centrada
- Regresiones RIF
- Aplicación Empírica



Modelo lineal

Consideremos el modelo lineal

$$Y = X\beta + u$$

Supongamos que $E(u|x) = 0$ (exogeneidad).

- En promedio Y y X tienen una relación lineal.
- Interpretación de β

$$\frac{\partial E(Y|X)}{\partial X} = \beta$$

El impacto de X sobre $E(Y)$

Calculemos la esperanza de Y :

$$\begin{aligned} E(Y) &= E\{E(Y|X)\} \\ &= E\{E(X\beta + u|X)\} \\ &= E\{X\beta + E(u|X)\} \\ &= E(X)\beta \end{aligned}$$

Supongamos un cambio en $E(X)$ dado por $\partial E(X)$, luego

$$\frac{\partial E(Y)}{\partial E(X)} = \beta$$

El impacto de X sobre $Q_\tau(Y)$

Consideremos nuevamente el modelo lineal

$$Y = X\beta + u$$

Calculemos el cuantil τ -ésimo de Y :

$$\begin{aligned} Q_\tau(Y) &= Q_\tau(X\beta + u) \\ &= ? \end{aligned}$$

Problema: no es obvio como seguir...

¿Cuantíl condicional?

Podríamos pensar que el cuantíl condicional es lineal:

$$Q_{\tau}(Y|X) = X\beta(\tau)$$

¿Cómo obtenemos a $Q_{\tau}(Y)$ a partir de $Q_{\tau}(Y|X)$?

- No existe una “Ley de Cuantiles Iterados”.

$$Q_{\tau}(Y) \neq Q_{\tau}[Q_{\tau}(Y|X)]$$

- Tomar un promedio tampoco ayuda:

$$E[Q_{\tau}(Y|X)] = E(X)\beta(\tau) \neq Q_{\tau}(Y)$$

Condicional e Incondicional

Estrictamente:

$$\begin{aligned} F_Y(y) &= \int F_{Y,X}(y,x)dx \\ &= \int F_{Y|X=x}(y)f_X(x)dx \end{aligned}$$

con $F_{Y|X=x}(y) = F_{Y,X}(y,x)/f_X(x)$.

- No fácil pasar de $Q_\tau(Y|X)$ a $Q_\tau(Y)$.
- Métodos numéricos: Machado y Mata (2004) y Melly (2006).
- El eje de la cuestión: contar con algo similar a la Ley de Esperanzas Iteradas (LEI).

Parámetro de interés

En términos generales:

$$Y = h(X, \varepsilon)$$

Notar que esto junto con $F(X, \varepsilon)$ definen a $F_Y(y)$.

Definición: vamos a considerar el efecto de una traslación horizontal en X (*location shift*)

$$\alpha(\tau) \equiv \lim_{t \rightarrow 0} \frac{Q_\tau[h(X+t, \varepsilon)] - Q_\tau[Y]}{t}$$

- Cambio: $f_X(\cdot)$ se mueve hacia $f_{X+t}(\cdot)$.
- Esto es lo que se conoce como una derivada funcional.

Terminología

- X contiene varios regresores, $\alpha(\tau)$ son derivadas parciales.
- A $\alpha(\tau)$ se lo ha denominado como *Unconditional Quantile Partial Effect* (UQPE).
- Luego, si recordamos que suponíamos

$$Q_{\tau}(Y|X) = X\beta(\tau)$$

- Entonces el parámetro $\beta(\tau)$ es el *Conditional Quantile Partial Effect* (CQPE).

Función de Influencia

- Supongamos un indicador $T(F)$ construido a partir de la distribución F .
- Formalmente: $T : \mathcal{F} \rightarrow \mathbb{R}$, donde $\mathcal{F}$ es el conjunto de funciones F tal que $|T(F)| < \infty$.
- La función de influencia se define como:

$$IF(y, T) = \lim_{\eta \rightarrow 0} \frac{T[(1-\eta)F + \eta\delta_y] - T(F)}{\eta}$$

- La expresión δ_y es una distribución degenerada en y , un punto particular del soporte de F .

Función de Influencia

La $IF(y, T)$ tiene una forma funcional específica para cada indicador:

Indicador	$T(F)$	$IF(y, T)$
Media (μ)	$\int_{-\infty}^{+\infty} y dF(y)$	$y - \mu$
Varianza (σ^2)	$\int_{-\infty}^{+\infty} (y - \mu)^2 dF(y)$	$(y - \mu)^2 - \sigma^2$
Cuantil τ (q_τ)	$\int_{-\infty}^{q_\tau} dF(y) = \tau$	$IF(y,) = \frac{\tau - I(y < q_\tau)}{f(q_\tau)}$

- La $IF(y, T)$ proviene de la estadística robusta.
- Miden la sensibilidad del indicador T en el punto y .

Algunas propiedades de la IF

- 1 Depende de parámetros poblacionales.
- 2 El valor esperado de $IF(.)$ es cero, es decir:

$$E[IF(Y, T)] = 0$$

Ejemplo 1: si $T(F) = \mu$, esta propiedad es obvia

$$\begin{aligned} E[IF(Y, \mu)] &= E[Y - \mu] \\ &= 0 \end{aligned}$$

Ejemplo 2: en el caso del cuantil τ -ésimo

$$\begin{aligned} E[IF(Y, q_\tau)] &= E\left[\frac{\tau - I(Y < q_\tau)}{f(q_\tau)}\right] \\ &= [\tau - Pr(Y < q_\tau)] / f(q_\tau) \\ &= 0 \end{aligned}$$

Ejercicio: corroborar que $E[IF(Y, \sigma^2)] = 0$

Función de Influencia Centrada (RIF)

Definamos a la siguiente función:

$$RIF(y, T) \equiv T(F) + IF(y, T)$$

Esto es lo que se conoce como *Recentered Influence Function* (RIF).

Propiedades de la RIF

- 1 Depende de parámetros poblacionales.
- 2 Trivialmente:

$$E[RIF(Y, T)] = T(F)$$

- 3 Por LEI:

$$T(F) = E\{E[RIF(Y, T)|X]\}$$

RIF regression

Todo el razonamiento que hemos hecho es el eje central de la idea propuesta por **Firpo, Fortin y Lemieux (2009)**.

Resultado (FFL 2009)

Los autores muestran que el efecto marginal de X sobre T es:

$$\alpha(T) \equiv \lim_{t \rightarrow 0} \frac{T[h(X+t, u)] - T[Y]}{t} = E \left\{ \frac{dE[RIF(Y, T)|X=x]}{dx} \right\}$$

El método:

- 1 Proponer un modelo para la RIF condicional en X .

$$E[RIF(Y, T)|X] = m(X, \beta)$$

- 2 Estimar ese modelo por algún método de regresión conocido.

Unconditional Quantile Regression

En el caso del cuantil no condicional es:

$$\begin{aligned}
 RIF(Y, q_\tau) &= q_\tau + IF(Y, q_\tau) \\
 &= q_\tau + \frac{\tau - I(y < q_\tau)}{f(q_\tau)} \\
 &= q_\tau + \frac{\tau - 1}{f(q_\tau)} + \frac{I(y \geq q_\tau)}{f(q_\tau)} \\
 &= c_{2,\tau} + c_{1,\tau} I(y \geq q_\tau)
 \end{aligned}$$

donde las constantes $c_{1,\tau}$ y $c_{2,\tau}$ son:

$$\begin{aligned}
 c_{1,\tau} &= 1/f(q_\tau) \\
 c_{2,\tau} &= q_\tau - c_{1,\tau}(1 - \tau)
 \end{aligned}$$

En esencia es un modelo binario!

Tomando esperanza condicional en X :

$$E[RIF(Y, q_\tau)|X] = c_{2,\tau} + c_{1,\tau}Pr(y \geq q_\tau|X)$$

Luego, la expresión para el *Unconditional Quantile Partial Effect* (UQPE) es:

$$\alpha(\tau) = \frac{1}{f(q_\tau)} \cdot E \left[\frac{\partial Pr(y \geq q_\tau|X)}{\partial X} \right]$$

Componentes del UQPE:

- 1 q_τ : cuantil τ -ésimo.
- 2 $f(q_\tau)$: densidad de Y evaluada en q_τ .
- 3 $E \left[\frac{\partial Pr(Y \geq q_\tau|X)}{\partial X} \right]$: efecto marginal promedio.

Estimador factible

Notar que $Pr(Y \geq q_\tau | X)$ es un modelo de regresión binario, donde la variable dependiente es:

$$D_i = \begin{cases} 0 & \text{si } Y_i < \hat{q}_\tau \\ 1 & \text{si } Y_i \geq \hat{q}_\tau \end{cases}$$

Varias alternativas:

- (a) **Modelo lineal:** $Pr(D_i = 1 | X = x_i) = x_i^\top \gamma$
- (b) **Logit/Probit:** $Pr(D_i = 1 | X = x_i) = G(x_i^\top \gamma)$
- (c) **No paramétrico:** $Pr(D_i = 1 | X = x_i) = m(x_i)$

Errores estándar: bootstrap!

(a) RIF - OLS Regression

Modelo lineal estimado por MCO

$$Pr(D_i = 1|X = x_i) = x_i^T \gamma$$

Efectos parciales sobre la probabilidad:

$$\frac{\partial \widehat{Pr}(Y_i \geq \hat{q}_\tau | X = x_i)}{\partial X} = \hat{\gamma}$$

Luego, el UQPE estimado es:

$$\hat{\alpha}(\tau) = \frac{1}{\hat{f}(\hat{q}_\tau)} \cdot \hat{\gamma}$$

Ventajas:


- Es simple de estimar y computar los efectos parciales.
- Usar un Logit/Probit o no paramétrico da resultados similares.

Educación y desigualdad salarial


- **Muestra:** hombres de 18 a 64 años de edad extraídos de la EPH 1992, 1998 y 2008.
- **Variable dependiente:** salario por hora (en log)
- **Variable explicativa:** años de educación, edad, controles regionales,...
- **Literatura:** retornos a la educación, economía de la distribución.
- **Referencia:** Sosa Escudero et al. (2014).

RIF Regression


Año	q(0.10)	q(0.20)	q(0.30)	q(0.40)	q(0.50)	q(0.60)	q(0.70)	q(0.80)	q(0.90)
1992	0.046 (13.23)**	0.047 (17.39)**	0.054 (20.81)**	0.065 (23.46)**	0.075 (24.44)**	0.087 (25.81)**	0.107 (27.15)**	0.119 (23.58)**	0.140 (15.89)**
1998	0.066 (14.50)**	0.059 (19.87)**	0.070 (24.91)**	0.079 (29.23)**	0.090 (31.53)**	0.104 (33.87)**	0.124 (35.15)**	0.148 (30.45)**	0.190 (20.08)**
2008	0.063 (13.46)**	0.071 (21.14)**	0.072 (26.65)**	0.076 (31.17)**	0.077 (33.46)**	0.082 (33.71)**	0.087 (31.84)**	0.097 (26.63)**	0.110 (19.25)**



EPH 1992



EPH 1998



EPH 2008

(a) *Años de educación*

Relación entre CQPE y UQPE

FFL (2009) muestran la siguiente relación:


$$UQPE(\tau) = E[\omega_{\tau}(X) \cdot CQPE(\xi_{\tau}(X), X)]$$

donde el ponderador es:

$$\omega_{\tau}(x) = \frac{f_{Y|X=x}(q_{\tau})}{f_Y(q_{\tau})}$$

$\xi_{\tau}(x)$ es una función de matching entre cuantiles condicionales y no condicionales:

$$\xi_{\tau}(x) \equiv \{s : Q_s[Y|X=x] = q_{\tau}\}$$



Resumen

- El método de Quantile Regression es útil para caracterizar al cuantil de Y condicional en X .
- Extrapolar conclusiones de QR a los cuantiles no condicionales no es tan obvio como en el caso de la media condicional.
- El método de regresiones RIF ofrece una alternativa para poder aprovechar la LEI.
- En el caso UQR, el método se simplifica a la estimación de un regresor binario.
- Para otros indicadores se requiere conocer la *RIF*.

Referencias

- Firpo, S. Fortin, N. y Lemieux, T. (2009) "Unconditional Quantile Regressions". *Econometrica*, Vol. 77, No. 3, pp. 953-973.
- Sosa Escudero, W, Alejo, J. y Gabrielli, F. (2014) "The distributive effects of education: an unconditional quantile regression approach". *Economic Analysis Review*, Vol 29, No 1.
- Bonacini, L. Gallo, G. y Scicchitano, S. (2020) "Working from home and income inequality: risks of a 'new normal' with COVID-19". *Journal of Population Economics*, volume 34, pages303–360.

Descomposiciones Econométricas

Javier Alejo


Maestría en Economía

FCE-UNLP

Noviembre, 2020

Temario de la clase

- 1 Introducción
- 2 Identificación (supuestos)
- 3 Estimación
- 4 Aplicación empírica



Análisis de descomposiciones

- ¿Qué factores fueron relevantes en el cambio de la desigualdad en los últimos 20 años?
- ¿Cuál son las principales fuentes detrás de las brechas distributivas de género?

Ejercicios de descomposición: caracterizan el cambio o la brecha en algún indicador económico.

- Se basa en algún modelo econométrico de regresión.
- Dependiendo de cada caso, requiere de una serie de supuestos para que su interpretación sea correcta.

Ejemplo: modelo lineal

Consideremos el modelo lineal para la relación entre Y y X :

$$Y_g = X_g \beta_g + u_g$$

donde $g = A, B$.

- Notación general: grupos, momentos en el tiempo, países, etc.
- Supongamos que $E(u_g | x_g) = 0$ (exogeneidad) para cada g .
- Modelo: en promedio Y tienen una relación lineal con X .

Brecha promedio

Calculemos la esperanza de Y_g :

$$\begin{aligned}\mu_g &= E(Y_g) \\ &= E\{X_g\beta_g + E(u_g|X_g)\} \\ &= E(X_g)\beta_g\end{aligned}$$

para $g = A, B$.

Luego, la brecha total entre A y B es:

$$\begin{aligned}\Delta_O^\mu &= \mu_B - \mu_A \\ &= E(X_B)\beta_B - E(X_A)\beta_A\end{aligned}$$

Escenario contrafactual

Consideremos la siguiente expresión:

$$\mu_B^c = E(X_B)\beta_A$$

Sumando y restando en la brecha total:

$$\begin{aligned}\Delta_O^\mu &= E(X_B)\beta_B - E(X_A)\beta_A \\ &= E(X_B)\beta_B - \cancel{E(X_B)\beta_A} + \cancel{E(X_B)\beta_A} - E(X_A)\beta_A \\ &= E(X_B)(\beta_B - \beta_A) + [E(X_B) - E(X_A)]\beta_A\end{aligned}$$

Una descomposición...

Esto plantea que la brecha total está compuesta de dos términos:

$$\begin{aligned}\Delta_X^\mu &= [E(X_B) - E(X_A)]\beta_A \\ \Delta_S^\mu &= E(X_B)(\beta_B - \beta_A)\end{aligned}$$

Luego:

$$\Delta_O^\mu = \Delta_S^\mu + \Delta_X^\mu$$

Terminología:

- Δ_S^μ : efecto estructura (parámetros, retornos).
- Δ_X^μ : efecto composición (características).

Evaluación de impacto

Supongamos que B es un grupo de individuos bajo un tratamiento y A es el grupo de control.

$$ATE = \mu_B - \mu_A = \Delta_O^\mu$$

- ¿Supuestos de identificación?
- ¿Selección basada en observables/inobservables?
- ¿Qué indicaría Δ_S^μ y Δ_X^μ en cada caso?

¿Cambios distributivos?

- Descomposiciones más allá del efecto promedio (cuantiles, desigualdad, etc.)
- Dos grandes líneas metodológicas:
 - 1 Semi-paramétricos: MCO, QR.
 - 2 No paramétricos: estrategias de re-ponderación, matching, etc.
- Algunos problemas:
 - Elección de grupo de referencia.
 - ¿Qué hay dentro de cada efecto? (*descomposición detallada*)
 - *Path dependence*.

Descomposición econométrica

- **Referencia:** Fortin, Lemieux y Firpo (2011) "Decomposition Methods in Economics" Handbook of Labor Economics, Elsevier.
- ¿Supuestos para identificar correctamente cada parámetro de interés?

Sobre los "grupos"

- Dos grupos A y B mutuamente excluyentes (Ej: tratamiento y control, urbano y rural, antes y después).
- Dummy: sea $D_{gi} = 1(i \in g)$ para $g = A, B$. Entonces $D_A + D_B = 1$.

El modelo

Para ello es útil contar un modelo para cada grupo:

$$\begin{aligned}Y_{Ai} &= m_A(X_i, \varepsilon_i) \\ Y_{Bi} &= m_B(X_i, \varepsilon_i)\end{aligned}$$

donde X y ε son características observables e inobservables, respectivamente.

- A esto se le llama “*forma estructural*”.
- Ambos determinantes siguen alguna distribución $F_{X|D_g}$ y $F_{\varepsilon|X, D_g}$.

Términos a descomponer

Efecto composición: brechas asociadas con la distribución de los determinantes entre los grupos. Factores:

- 1 **Observables:** $F_{X|D_g}$ (edad, educación, género, etc.)
- 2 **Inobservables:** $F_{\varepsilon|D_g}$ (inteligencia, contactos, suerte, etc.)

Efecto estructura: diferencias en las forma funcional $m_g(\cdot)$, asociadas con:

- 1 **Observables:** $m_g(X_i, \cdot)$
- 2 **Inobservables:** $m_g(\cdot, \varepsilon_i)$

- No todos estos componentes son identificables.
- Supuestos estadísticos.

¿Es posible desglosar todos los componentes?

La forma de $m_g(X, \varepsilon)$ es general. Lo más razonable es agrupar la forma funcional de $m_g(.,.)$ en un solo efecto (*efecto estructura*).

Definamos entonces:

- Δ_S^v : efecto estructura
- Δ_X^v : efecto composición en observables.
- Δ_ε^v : efecto composición en inobservables.

De forma tal que:

$$\Delta_O^v = \Delta_S^v + \Delta_X^v + \Delta_\varepsilon^v$$

Ejemplo: si pertenecer al grupo A o B es aleatorio $\Delta_X^v = \Delta_\varepsilon^v = 0$.

Contrafactual

La distribución observada de Y_g es:

$$F_{Y_g|D_g}(y) = \int F_{Y_g|X,D_g}(y|X=x) dF_{X|D_g}(x)$$

donde $g = A, B$.

Escenario contrafactual para A :

$$F_{Y_A^C|X=X_B}(y) = \int F_{Y_A|X,D_A}(y|X=x) dF_{X|D_B}(x)$$

Supuesto: soporte común en sus determinantes. Formalmente:

$$0 < Pr(D_B = 1|X = x, \varepsilon = e) < 1$$

para todo $(x, e) \in \mathcal{X} \times \mathcal{E}$

Conexión con la forma estructural:

$$\begin{aligned} F_{Y_B|X,D_B}(y|X=x) &= Pr[Y < y|X=x, D_B=1] \\ &= Pr[m_B(X,\varepsilon) < y|X=x, D_B=1] \end{aligned}$$

Luego,

$$F_{Y_B|D_B}(y) = \int Pr[m_B(X,\varepsilon) < y|X=x, D_B=1] dF_{X|D_B}(x)$$

Comparado con el contrafactual,

$$F_{Y_A^C|X=X_B}(y) = \int Pr[m_A(X,\varepsilon) < y|X=x, D_A=1] dF_{X|D_B}(x)$$

Problema: estamos condicionando en dos grupos distintos!

Descomposición agregada

Recapitulando, sea v_g un indicador distributivo observado en el grupo/momento g . Bajo los supuestos discutidos previamente, es posible escribir:

$$\Delta_O^v = \Delta_S^v + \Delta_X^v$$

Los efectos son

- **Estructura:** $\Delta_S^v = v(F_{Y_B|D_B}) - v(F_{Y_A^C|X=X_B})$
- **Composición:** $\Delta_X^v = v(F_{Y_A^C|X=X_B}) - v(F_{Y_A|D_A})$

Equilibrio parcial

El contrafactual se basa en el supuesto de que

- Intercambiar las estructuras $m_g(.,.)$ no afecta a la distribución de los determinantes (X, ε)
- Intercambiar la distribución de las X no afecta a $m_g(.,.)$.

Ejemplo:

- Supongamos que estamos estudiando la distribución salarial (Y) y consideramos que pertenecer a un sindicato es un factor determinante (X).
- Supuesto: cambiar la proporción de trabajadores sindicalizados no afecta la estructura salarial en ambos grupos.

Interpretación: corto plazo, efectos de primer orden, etc.

Simulación/Integración numérica

Ambas usan quantile regression (QR) para modelar a $F_{Y_g|X,D_g}$:

$$\begin{aligned}Y_{Ai} &= X_{Ai}\beta_A(U_{Ai}) \\ Y_{Bi} &= X_{Bi}\beta_B(U_{Bi})\end{aligned}$$

donde $U_{gi} \sim U(0,1)$ para $g = A, B$.

En la balanza:

- Ventajas: es adaptable a literatura extendida de QR.
- Desventajas: computacionalmente muy lento!

¿Stata?: `rqdeco` (Melly, 2005)

Re-ponderación (DiNardo, et al., 2011)

La distribución de Y_A es:

$$F_{Y_A|D_A}(y) = \int F_{Y_A|X,D_A}(y|X=x) dF_{X|D_A}(x)$$

Escenario contrafactual:

$$F_{Y_A^C|X_B}(y) = \int F_{Y_A|X,D_A}(y|X=x) dF_{X|D_B}(x)$$

Se puede describir como:

$$F_{Y_A^C|X_B}(y) = \int F_{Y_A|X,D_A}(y|X=x) \phi(x) dF_{X|D_A}(x)$$

donde $\phi(x) \equiv dF_{X|D_B}(x)/dF_{X|D_A}(x)$.

DiNardo, Fortin y Lemieux (1996)

$$\varphi(x) \equiv \frac{dF_{X|D_B}(x)}{dF_{X|D_A}(x)} = \frac{f_{X|D_B}(x)dx}{f_{X|D_A}(x)dx} = \frac{f_{X|D_B}(x)}{f_{X|D_A}(x)}$$

Por definición $f_{X|D}(x) = f_{X,D}(x, d) / Pr(D)$, luego:

$$\varphi(x) = \frac{f_{X,D_B}(x, d_B)}{f_{X,D_A}(x, d_A)} \cdot \frac{Pr(D_A)}{Pr(D_B)}$$

Sea $h_X(x)$ la densidad marginal de X , entonces

$$f_{X,D}(x, d) / h_X(x) = Pr(D|X=x)$$

Luego,

$$\varphi(x) = \frac{Pr(D_B|X=x)}{Pr(D_A|X=x)} \cdot \frac{Pr(D_A)}{Pr(D_B)}$$

El estimador factible:

$$\hat{\varphi}(x) = \frac{\hat{Pr}(D_B=1|X=x)}{\hat{Pr}(D_B=0|X=x)} \cdot \frac{\hat{Pr}(D_B=0)}{\hat{Pr}(D_B=1)}$$

Cómputo de la descomposición

La re-ponderación nos da una forma de obtener a:

$$\hat{v}^C = v(\hat{F}_{Y_A^C|X_B})$$

Para cada grupo: $\hat{v}_g = v(\hat{F}_{Y_g|D_g})$, donde $\hat{F}_{Y_g|D_g}$ es la distribución empírica. Finalmente:

- Efecto estructura: $\hat{\Delta}_S^v = \hat{v}_B - \hat{v}^C$
- Efecto composición: $\hat{\Delta}_X^v = \hat{v}^C - \hat{v}_A$

¿Inferencia? Bootstrap.

En Stata: `oaxaca8`

Una aproximación: regresiones RIF

La RIF permite expresar a $v(F)$ como una esperanza:

$$v_g = E[RIF(Y_g, v_g)] = E\{E[RIF(Y_g, v_g)|X_g]\}$$

para $g = A, B$. Si además sigue un modelo lineal:

$$E[RIF(Y_g, v_g)|X_g] = X_g \gamma_g$$

podemos implementar una descomposición a la O-B.


Advertencias ⚠:

- La clave es considerar a $v^C = E(X_B)\gamma_A$ como contrafactual.
- Se trata de una aproximación de primer orden!!
- Ajuste del contrafactual: computar a $\hat{\gamma}_A$ mediante una regresión RIF re-ponderada.

Desigualdad e informalidad

- **Muestra:** asalariados en edad de trabajar, Encuesta de Hogares y Personas de Brasil 1999 a 2009 (PNAD).
- **Variable dependiente:** ingreso laboral horario.
- **Variable binaria:** dos momento en el tiempo, años 1999 y 2009.
- **Controles:** formalidad, años de educación, edad, diferencias regionales, étnicas...
- **Referencia:** “Desigualdad e informalidad. Un análisis de cinco experiencias latinoamericanas”. Amarante, V. y Arim, R. (eds.). ONU 2015.
- **Metodología:** descomposición con re-ponderaciones y regresiones RIF.

Descomposición agregada



Fuente: Elaboración propia en base a PNAD 1999-2009.


Indicadores

		90-10	50-10	90-50	Gini	Theil
Asalariados	Brecha bruta	-0.405	-0.245	-0.161	-0.047	-0.008
		(0.008)	(0.008)	(0.005)	(0.004)	(0.032)
	Efecto composición	0.159	-0.002	0.160	0.031	0.038
		(0.014)	(0.009)	(0.011)	(0.003)	(0.015)
	Efecto estructura	-0.564	-0.243	-0.321	-0.077	-0.046
		(0.014)	(0.011)	(0.012)	(0.005)	(0.029)

Robust standard errors in brackets

*** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Descomposición detallada: informalidad



Resumen

- **Análisis de descomposiciones:** es útil para caracterizar cambios y/o brechas distributivas.
- **Requisitos:** supuestos de identificación similares a los requeridos en el análisis de evaluación de impacto.
- **Descomposición agregada:** hay varias opciones. El método de re-ponderaciones es el más flexible en cuanto a formas funcionales.
- **Descomposición detallada:** fuera de la media es complicado (regresiones RIF son útiles).
- **Stata:** web de Nicole Fortín; recientemente `oaxaca_rif` (Rios-Avila, 2020).