

Trabajo Práctico

Ejercicio 1.

Calcular estadísticas descriptivas (promedio, mediana, deciles, etc.) que muestren la relación entre el logaritmo del salario con cada una de las variables explicativas (en el caso de los regresores continuos, se puede utilizar categorías por grupo de edad). Adicionalmente, computar la estimación de la ecuación de Mincer por MCO e interpretar económica y estadísticamente sus resultados¹.

En la tabla 1, a modo de introducción, se presentan estadísticas descriptivas (promedio, mediana, deciles, etc.) que muestran la relación entre el logaritmo del ingreso horario en la ocupación principal con cada una de las variables explicativas (edad, educación, sexo y lugar de residencia), para una muestra de individuos de 18 a 65 años de edad del Gran Buenos Aires extraída de la Encuesta Permanente de Hogares de Argentina del segundo semestre del 2014. Por un lado, se puede observar que el logaritmo del salario promedio es mayor para los individuos entre 25 y 40 años de edad, para los hombres y para los residentes de CABA y, a su vez, aumenta con el nivel educativo máximo alcanzado. Por otro lado, tomando otro punto de la distribución, la mediana, se observan resultados similares.

Tabla 1. Estadísticas descriptivas del logaritmo del salario horario.

Variable	Media	p10	Mediana	p90	Mínimo	Máximo
Tramo Etario						
18-24 años	3,340	2,601	3,408	4,097	-0,488	6,245
25-40 años	3,643	2,844	3,673	4,442	-0,488	7,498
41-64 años	3,631	2,739	3,675	4,511	-1,523	6,718
65 años	3,562	2,435	3,590	4,731	1,527	6,427
Nivel Educativo						
Nunca asistió	3,387	2,402	3,249	5,082	1,292	5,264
Primario incompleto	3,199	2,151	3,249	3,988	0,773	6,186
Primario completo	3,297	2,507	3,372	3,942	-0,366	6,112
Secundario incompleto	3,347	2,597	3,403	4,019	-0,488	6,246
Secundario completo	3,529	2,784	3,568	4,250	-0,776	7,498
Superior incompleto	3,758	2,966	3,760	4,511	0,887	6,718
Superior completo	4,087	3,412	4,106	4,798	-1,529	6,427
Sexo						
Mujer	3,578	2,670	3,627	4,453	-1,529	6,651
Hombre	3,613	2,779	3,631	4,442	-0,711	7,498
Lugar de Residencia						
Conurbano Bonaerense	3,503	2,662	3,537	4,329	-1,529	7,498
CABA	3,862	3,095	3,882	4,645	-0,776	6,651

Fuente: Elaboración propia en base a EPH-INDEC.

Se considera la siguiente función de ingresos (ecuación de Mincer):

$$\ln l_{i,t} = \beta_0 + \beta_1 \text{edad}_i + \beta_2 \text{edad}_i^2 + \beta_3 \text{educ}_i + \beta_4 \text{educ}_i^2 + \beta_5 \text{sexo}_i + \beta_6 \text{caba}_i + u_i. \quad (1)$$

En la tabla 2, se presenta la estimación del modelo (1) por MCO, como primer enfoque para entender la relación entre el salario horario y las variables explicativas ya mencionadas. Éste es un modelo para el centro de la distribución condicional, lo cual

¹ Se debe tener en cuenta que el modelo presenta, en su especificación, variables al cuadrado (edad y años de educación) para medir efectos no lineales. Interpretar los efectos marginales para un individuo de 30 años de edad con 12 de años de educación formal.

quiere decir que, al estimar los coeficientes, se observa el efecto parcial sobre la media condicional $E(Y|X)$ proveniente de alterar marginalmente la k -ésima variable explicativa.

Realizando los cálculos correspondientes², por un lado, se puede observar que, para un individuo con 30 años de edad, un año más de edad aumenta el salario horario, en promedio y *ceteris paribus*, 1,35%. Por otro lado, se observa que, para un individuo con 12 años de educación formal, un año más de educación formal aumenta el salario horario, en promedio y *ceteris paribus*, 8,50%. Por último, se ve que un hombre percibe un salario horario, en promedio, un 15,30% mayor respecto a una mujer con idénticas características, mientras que un individuo residente de CABA percibe un salario horario, en promedio, un 14,53% mayor respecto a un residente del Conurbano Bonaerense con idénticas características.

Tabla 2. Estimación ecuación de Mincer por MCO.

Variables	MCO
Edad	0,035*** (0,004)
Edad al cuadrado	-0,000*** (0,000)
Años de educación	-0,039*** (0,010)
Años de educación al cuadrado	0,005*** (0,000)
Sexo	0,142*** (0,015)
CABA	0,136*** (0,017)
Constante	2,392*** (0,098)
Observaciones	7.903
R^2	0,214

Los datos en paréntesis corresponden a los desvíos estándar. Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia en base a EPH-INDEC.

² El efecto marginal de la variable *edad* se computa de la siguiente manera: $\frac{\partial E(Y|X)}{\partial edad} = \hat{\beta}_1 + 2\hat{\beta}_2 * 30$. Y el efecto marginal de la variable *educ*: $\frac{\partial E(Y|X)}{\partial educ} = \hat{\beta}_3 + 2\hat{\beta}_4 * 12$.

Ejercicio 2.

Estimar la misma especificación del modelo en el inciso anterior pero para los siguientes cuantiles condicionales: 0.05, 0.25, 0.50, 0.75, 0.95. Computar los errores estándar mediante un bootstrap de 500 reposiciones³. Realizar una interpretación económica y estadística de sus resultados.

Si bien analizar el efecto sobre la media condicional es la herramienta empírica más utilizada, el efecto sobre el centro de la distribución puede ser un buen resumen o no de lo que sucede en el resto de la distribución condicional. En este contexto, surgen los modelos de regresiones por cuantiles, con el objetivo de caracterizar toda la distribución condicional de una variable.

En la tabla 3, se presenta la estimación del modelo (1) por el método de Koenker y Bassett (1978), para los cuantiles condicionales 0.05, 0.25, 0.50, 0.75 y 0.95, computando los errores estándar mediante un *bootstrap* de 500 reposiciones.

En primer lugar, se puede observar que el efecto marginal de la edad sobre el salario horario no es homogéneo a lo largo de la distribución condicional, por lo que el efecto sobre la media condicional obtenido en el ejercicio anterior no representa un buen resumen de lo que sucede en el resto de la distribución condicional. En particular, si bien, para un individuo de 30 años de edad, un año más de edad (*ceteris paribus*) aumenta todos los cuantiles condicionales estimados, el efecto marginal es mayor en el cuantil condicional 0.25 y significativamente menor en los cuantiles condicionales 0.05 y 0.95.

En segundo lugar, se observa que el efecto marginal de la educación sobre el salario horario es heterogéneo a lo largo de los cuantiles condicionales, al igual que en el caso de la edad. Además, cabe aclarar que, en los cuantiles condicionales 0.05 y 0.25, la variable en forma lineal no es estadísticamente significativa, mientras que, en su forma cuadrática, sí lo es⁴ (aunque, en ambos cuantiles, conjuntamente, son estadísticamente significativas); en el resto de los cuantiles condicionales estimados, ambas variables son estadísticamente significativas. En particular, para un individuo con 12 años de educación formal, un año más de educación formal (*ceteris paribus*) aumenta los cuantiles condicionales 0.05, 0.25, 0.50, 0.75 y 0.95 en 9,75%, 8,69%, 8,03%, 8,52%, y 8,32%, respectivamente. De esta manera, se observa que el retorno a la educación no es homogéneo a lo largo de la distribución condicional, siendo el cuantil 0.05 el más beneficiado.

Finalmente, se ve que, por un lado, ser hombre aumenta todos los cuantiles condicionales estimados respecto a una mujer con idénticas características; y que, por otro lado, ser residente de CABA también aumenta todos los cuantiles condicionales estimados respecto a un residente del Conurbano Bonaerense con idénticas características. En ambos casos, el efecto marginal es mayor en el cuantil condicional 0.05.

³ Para que los resultados no cambien con cada ejecución del código, se sugiere escribir lo siguiente en las primeras líneas del do-file: *set seed 123*.

⁴ Sin embargo, para el primer cuantil considerado, la variable en forma cuadrática resulta estadísticamente significativa al 10%, por lo que, al considerar un nivel de significatividad más estricto, el primer cuantil no percibiría beneficios por su educación.

Tabla 3. Estimación ecuación de Mincer para cuantiles condicionales.

Variables	QR(0.05)	QR(0.25)	QR(0.50)	QR(0.75)	QR(0.95)
Edad	0,027** (0,012)	0,045*** (0,006)	0,039*** (0,004)	0,035*** (0,004)	0,023** (0,009)
Edad al cuadrado	-0,000** (0,000)	-0,001*** (0,000)	-0,000*** (0,000)	-0,000*** (0,000)	-0,000* (0,000)
Años de educación	0,033 (0,037)	-0,0197 (0,015)	-0,026** (0,012)	-0,058*** (0,018)	-0,062** (0,036)
Años de educación al cuadrado	0,003* (0,002)	0,004*** (0,001)	0,004*** (0,001)	0,006*** (0,001)	0,006*** (0,001)
Sexo	0,323*** (0,054)	0,116*** (0,019)	0,125*** (0,016)	0,129*** (0,017)	0,107*** (0,033)
CABA	0,311*** (0,063)	0,117*** (0,024)	0,123*** (0,015)	0,095*** (0,019)	0,139*** (0,033)
Constante	0,953*** (0,339)	1,856*** (0,138)	2,328*** (0,094)	2,856*** (0,146)	3,642*** (0,271)
Observaciones	7.903	7.903	7.903	7.903	7.903
Pseudo R^2	0,087	0,114	0,141	0,160	0,127

Los datos en paréntesis corresponden a los desvíos estándar (*bootstrap* 500 réplicas). Nivel de significatividad: * al 10%, ** al 5%, *** al 1%. Fuente: Elaboración propia en base a EPH-INDEC.

Ejercicio 3.

¿El efecto parcial de los años de educación sobre el salario es el mismo para los cuantiles condicionales 0.05 y 0.95? Realizar un test para evaluar esta hipótesis particular. Adicionalmente, realizar un test que ponga a prueba la hipótesis nula de que el conjunto de coeficientes del modelo (a excepción de la ordenada al origen) no difieren entre cuantiles condicionales (utilizar los cinco cuantiles estimados en el inciso anterior). ¿En qué medida este test es útil para ver la relevancia del método de regresión por cuantiles?

En la tabla 4, se presentan los resultados de dos tests (los cuales utilizan la matriz ampliada de varianzas y covarianzas, computadas mediante un *bootstrap* de 500 reposiciones): uno para analizar si el efecto parcial de los años de educación sobre el salario es el mismo para los cuantiles condicionales 0.05 y 0.95; otro para analizar si el conjunto de coeficientes del modelo (a excepción de la ordenada al origen) no difieren entre cuantiles condicionales (se utilizan los cinco cuantiles estimados en el ejercicio anterior). Por un lado, se puede observar que el efecto parcial de los años de educación sobre el salario difiere estadísticamente (al 10% de significatividad) para los cuantiles 0.05 y 0.95. Por otro lado, se observa que el conjunto de los coeficientes del modelo difieren estadísticamente (al 1% de significatividad) entre los cuantiles condicionales estimados.

Este último test es útil para ver la relevancia del método de regresión por cuantiles en la medida en que analiza si los efectos marginales de cada una de las variables explicativas son homogéneos entre cada uno de los cuantiles condicionales estimados, es decir, a fin de cuentas, se quiere ver si existen efectos marginales diferenciales (estadísticamente) entre cuantiles condicionales que justifiquen la utilización de este método en comparación a MCO.

Tabla 4. Tests de significatividad.

Test	Estadístico	P-valor
test [q05=q95]: educ educ2	F (2, 7.896)=2,51	Prob>F=0,081
test [q05=q25=q50=q75=q95]: edad edad2 educ educ2 sexo caba	F (24, 7.896)=5,11	Prob>F=0,000


Fuente: Elaboración propia en base a EPH-INDEC.

Ejercicio 4.

Utilizando los cuantiles estimados en el punto 2, graficar el valor de los coeficientes de cada regresión (eje vertical) en función de τ (eje horizontal). Agregar los intervalos de confianza y el coeficiente estimado para la media condicional (MCO). ¿Por qué se dice que el método de regresión por cuantiles es *distribution free*?

En la figura 1, utilizando los cuantiles estimados del ejercicio 2, se presenta el valor de los coeficientes de cada regresión (eje vertical) en función de τ (eje horizontal), agregando los intervalos de confianza y el coeficiente estimado para la media condicional (MCO)⁵. Se puede observar que, tanto para la variable *sexo* como para la variable *caba*, el efecto marginal es heterogéneo a lo largo de la distribución condicional, en el sentido de que ambos coeficientes estimados para la media condicional (línea punteada) no caen en su totalidad dentro de los intervalos de confianza de los coeficientes estimados en las regresiones por cuantiles.

Figura 1. Coeficientes estimados de cada regresión por cuantiles en función de τ (τ).



Fuente: Elaboración propia en base EPH-INDEC.

Por último, se dice que el método de regresión por cuantiles es *distribution free* porque, si bien los coeficientes estimados dependen de τ (τ), es decir, hay tantos vectores de coeficientes estimados como cuantiles estimados (el vector $\beta(\tau)$ es una función de τ), la forma funcional (no explícita) de $\beta(\tau)$ depende del ajuste de los datos.

⁵ A modo ilustrativo, se presentan los coeficientes estimados de *edad* y *educ* en sus versiones lineal y cuadrática, aunque verlos por separado no tiene sentido.

Es así que se dice que este modelo es semiparamétrico, ya que, por un lado, en función de los regresores, es paramétrico, pero, por otro lado, en función de τ , es no paramétrico.

Ejercicio 5.

Considerar un residuo definido por la diferencia entre el logaritmo del salario observado para cada individuo y la predicción hecha por el modelo del cuantil condicional estimado dadas sus características. Computar el porcentaje de residuos positivos, negativos y nulos para los cuantiles 25, 50 y 75. Comentar los resultados que se encuentren.

En la tabla 5, considerando las diferencias entre el logaritmo del salario observado para cada individuo y la predicción hecha por el modelo del cuantil condicional estimado dadas sus características, se presenta el porcentaje de residuos negativos, nulos y positivos para los cuantiles 25, 50 y 75. En términos generales, se puede observar que, si X contiene un intercepto, entonces, se satisface la “condición de los residuos”, a saber:

$$\frac{N}{n} \leq \tau \leq \frac{N+Z}{n},$$

$$\frac{P}{n} \leq (1 - \tau) \leq \frac{P+Z}{n},$$

donde N , Z y P son el número de observaciones con residuos negativos, nulos y positivos, n es la cantidad de observaciones en la muestra y τ es el cuantil. En la tabla, se observa que, por ejemplo, para el cuantil 50, aproximadamente, el 50% de los residuos son negativos y el 50% de los residuos son positivos; lo análogo sucede en los casos de los cuantiles 25 y 75.

Tabla 5. *Porcentaje de residuos negativos, nulos y positivos.*

Residuos	Porcentaje (%)
Cuantil 25	
Negativos	24,95
Nulos	0,10
Positivos	74,95
Cuantil 50	
Negativos	49,93
Nulos	0,10
Positivos	49,97
Cuantil 75	
Negativos	74,96
Nulos	0,09
Positivos	24,95

Fuente: Elaboración propia en base a EPH-INDEC.

Referencias.

Koenker, R. y Bassett, G. (1978). Regression Quantiles. *Econometrica*, 46(1), 33-50.
Recuperado de <https://people.eecs.berkeley.edu/~jordan/sail/readings/koenker-bassett.pdf>